主动推断

Active Inference 的中文学习版

Sociology Study Notes

2026 年 4 月

版本说明

使用说明

本工作区面向中文阅读与后续学习整理。正文以章节为单位翻译为中文 TeX 文稿，优先保留原书的论证顺序、概念关系与公式表达，以便后续继续扩写为讲义、笔记或课程化材料。

原书信息

- 书名：*Active Inference: The Free Energy Principle in Mind, Brain, and Behavior*
- 作者：Thomas Parr, Giovanni Pezzulo, Karl J. Friston
- 出版社：The MIT Press
- 本中文稿用途：学习版中文 TeX 工作区

前言

卡尔 · 弗里斯顿

主动推断是一种理解有感知能力之行为的方式。你正在阅读这些文字这一事实，本身就意味着你正在以一种特定方式进行主动推断，也就是在主动采样世界，因为你相信自己会从中学到些什么。你的眼睛之所以在页面上来回探查，只是因为这种行动能够消解你接下来会看到什么，以及这些词语究竟传达什么的不确定性。简言之，主动推断把“行动”放进了“知觉”之中，于是知觉被视为一种感知推断，或一种假设检验。主动推断更进一步，把规划也视为推断，也就是说，去推断你下一步会做什么，以便消解你对自身生活世界的不确定性。

为了说明主动推断的简洁性，以及我们试图解释的究竟是什么，请把指尖轻轻放在你的腿上，保持不动一两秒。现在，你的腿摸起来是粗糙还是光滑？如果你必须移动手指，才能唤起粗糙或光滑的感觉，那么你就已经发现了主动推断的一项基本原理。感受，就是触探；看见，就是去看；听见，就是去听。这种触探未必一定是外显的，我们也可以通过把注意力导向这里或那里来进行隐性的行动。简言之，我们并不只是试图理解自己的感觉；我们还必须主动创造自己的感官世界。在接下来的内容中，我们会看到为什么事情必须如此，也会看到为何我们所感知、所做、所规划的一切，都受一个存在性的根本命令所统摄，那就是“自我证成”。

主动推断并不只是关于阅读，或关于以认识为目的的信息觅取。从一种观点看，凡是生物乃至粒子，只要存在，就都在进行某种主动推断。这听起来也许是一个很强的主张；但它揭示了这样一个事实：主动推断承继自自由能原理，而这一原理将存在等同于自我证成，并将自我证成等同于一种具身生成的推断。不过，本书并不关心有感知系统的物理学本身。它关注的是，这种物理学对于理解大脑如何运作意味着什么。

这种理解绝非易事，几千年的自然哲学与几百年的神经科学已经充分说明了这一点。尽管我们可以在关于自组织行为的第一性原理解释中找到主动推断的根基，例如与哈密顿最小作用原理相近的变分原理，但当我们追问某一个具体大脑是如何工作的、又为何不同于另一个大脑时，第一性原理并不能帮上太多忙。比如，接受自然选择进化论，并不能丝毫帮助我们理解为什么我有两只眼睛，或者为什么我会说法语。本书的目标，是利用这些原理为神经科学与人工智能中的关键问题搭建脚手架。为此，我们必须超越原理本身，真正进入这些原理所作用其上的机制层面。

因此，主动推断以及与之相伴的贝叶斯机制，其作用是为我们如何感知、规划和行动的问题提供一个框架。关键在于，它并不试图取代行为心理学、决策理论、强化学习等其他框架。恰恰相反，它希望在一个统一框架中吸纳所有那些已经被证明卓有成效的方法。在下文中，我们将特

别关注如何把心理学、认知神经科学、生成行动论、动物行为学等领域中的关键构念，与主动推断中的信念更新计算及其相关过程理论连接起来。

所谓过程理论，指的是解释信念更新如何在具身大脑乃至更广泛系统中的神经过程和其他生物物理过程中得以实现的理论。迄今为止，主动推断领域已经提供了一套相当直接的计算架构与仿真工具，既可用于建模一个运作中的大脑的不同方面，也能让研究者检验关于不同计算架构的假设。然而，这些工具只解决了问题的一半。主动推断的核心是一种生成模型，也就是对如下关系的概率表征：外部世界中那些不可观测的原因，如何生成可观测的结果，也就是我们的感觉。如何构造出恰当的生成模型，使之能够充分解释某个实验对象或某种生物的有感行为，这才是最大的挑战。

本书正是试图说明如何应对这一挑战。第一部分将搭建基本思想与形式化工具，第二部分则说明如何在实践中运用这些工具。简言之，本书面向那些希望使用主动推断来模拟和建模有感行为的人，无论他们的目的在于科学研究，还是可能在于人工智能。因此，本书聚焦于那些理解并实现一套主动推断方案所必需的思想与方法，而不会让读者被一方面有关有感系统物理学的问题、另一方面有关哲学的问题分散注意力。

卡尔 · 弗里斯顿的一则说明

我得坦白一件事。这本书并不是我写的，至少大部分不是。更准确地说，别人不允许我多写。这本书的写作目标要求一种简洁、清晰的文风，而这并非我所擅长。尽管他们允许我偷偷塞进几个自己喜欢的词，但接下来的内容主要证明了托马斯和乔瓦尼对相关问题的深刻理解，以及同样重要的，他们在各种意义上的“心智理论”。

致谢

我们衷心感谢朋友和同事们给予的宝贵帮助，尤其感谢伦敦大学学院威康信托人类神经影像中心理论神经生物学小组现在和过去的成员，感谢意大利国家研究委员会认知科学与技术研究所“行动中的认知”（Cognition in Action, CONAN）实验室的同仁，也感谢众多国际合作者；他们都对本书所呈现思想的发展发挥了关键作用。这个年轻却不断壮大的共同体在智识支持与持续激励方面都极为慷慨。与此同时，我们还诚挚感谢 MIT Press 的 Robert Prior 和 Anne-Marie Bono 在本书准备过程中给予我们的陪伴与指导，也感谢 Jakob Hohwy 以及其他审稿人提出的宝贵意见。最后，我们感谢为本研究提供资金支持的资助机构：KJF 获得了 Wellcome Trust 首席研究员基金资助（Ref: 088130/Z/09/Z）；GP 获得了欧洲研究委员会第 820213 号资助协议（ThinkAhead）以及欧盟“地平线 2020”研究与创新框架计划第 945539 号专项资助协议（Human Brain Project SGA3）的支持。

目录

版本说明 ii

前言 iii

第一部分　基础框架 1

第一章　总览 2

1.1 引言 2
1.2 生命有机体如何持续存在并进行适应性行动? 2
1.3 主动推断：从第一性原理推导行为 3
1.4 本书结构 3
1.4.1 第一部分：理论中的主动推断 4
1.4.2 第二部分：实践中的主动推断 6
1.5 总结 8

第二章　通往主动推断的低路 9

2.1 引言 9
2.2 作为推断的知觉 9
2.3 生物学推断与最优性 13
2.4 作为推断的行动 14
2.5 最小化模型与世界之间的差异 15
2.6 最小化变分自由能 16
2.7 期望自由能与作为推断的规划 18
2.8 什么是期望自由能? 19
2.9 低路的终点 21
2.10 总结 21

第三章　通往主动推断的高路 23

3.1 引言 23
3.2 马尔可夫毯 24
3.3 惊讶最小化与自证 25

3.3.1 作为哈密顿最小作用量原理的惊讶最小化 26
3.4 推断、认知与随机动力学之间的关系 27
3.4.1 变分自由能、模型证据与惊讶 28
3.4.2 期望自由能与最可能轨迹的推断 29
3.5 主动推断：理解行为与认知的一种新基础 29
3.6 模型、策略与轨迹 31
3.7 在主动推断下对生成论、控制论与预测理论的统一 32
3.8 主动推断：从生命的涌现到能动性 33
3.9 总结 33

第四章 主动推断的生成模型 35
4.1 引言 35
4.2 从贝叶斯推断到自由能 35
4.3 生成模型 37
4.4 离散时间中的主动推断 39
4.4.1 部分可观测马尔可夫决策过程 39
4.4.2 POMDP 中的主动推断 42
4.5 连续时间中的主动推断 44
4.5.1 用于预测编码的生成模型 44
4.5.2 作为带有运动反射的预测编码的主动推断 47
4.6 总结 49

第五章 消息传递与神经生物学 50
5.1 引言 50
5.2 微回路与消息 51
5.3 运动指令 52
5.4 皮层下结构 53
5.5 神经调制与学习 54
5.6 连续层级与离散层级 57
5.7 总结 57

第二部分 建模与应用 59

第六章 设计主动推断模型的配方 60
6.1 引言 60
6.2 设计主动推断模型：一个四步配方 61
6.3 我们在为哪个系统建模？ 61
6.4 生成模型最合适的形式是什么？ 62
6.4.1 离散变量还是连续变量，还是两者兼有？ 62
6.4.2 推断的时间尺度：浅层模型与层级模型 63

6.4.3 推断的时间深度与规划 64
6.5 如何搭建生成模型? 64
6.5.1 设置生成模型中的变量 64
6.5.2 生成模型的哪些部分是固定的，哪些部分是学习得到的? 66
6.6 搭建生成过程 68
6.7 使用主动推断进行模拟、可视化、分析与数据拟合 69
6.8 总结 70

第七章 离散时间中的主动推断 71
7.1 引言 71
7.2 感知处理 71
7.3 作为推断的决策与规划 73
7.4 信息搜寻 75
7.5 学习与新颖性 77
7.6 层级推断或深度推断 81
7.7 总结 83

第八章 连续时间中的主动推断 84
8.1 引言 84
8.2 运动控制 84
8.3 动力系统 86
8.3.1 框 8.1：精度、注意与感觉衰减 87
8.3.2 框 8.2：连续模型中的学习 87
8.4 广义同步 88
8.5 混合模型（离散与连续） 90
8.5.1 框 8.3：混合模型与聚类 91
8.6 小结 91

第九章 基于模型的数据分析 92
9.1 引言 92
9.2 元贝叶斯方法 92
9.3 变分拉普拉斯 94
9.4 参数经验贝叶斯（PEB） 95
9.5 基于模型分析的操作说明 95
9.6 生成模型示例 97
9.7 错误推断模型 98
9.8 总结 100

第十章 作为有感行为统一理论的主动推断 102
10.1 引言 102
10.2 总结前文 102

10.3 连接各个线头：主动推断的整合性视角 104
10.4 预测性大脑、预测性心智与预测加工 105
10.4.1 预测加工 106
10.5 知觉 106
10.5.1 贝叶斯大脑假说 107
10.6 动作控制 107
10.6.1 动作观念运动理论 108
10.6.2 控制论 108
10.6.3 最优控制理论 109
10.7 效用与决策 110
10.7.1 贝叶斯决策理论 111
10.7.2 强化学习 111
10.7.3 规划即推断 113
10.8 行为与有限理性 113
10.8.1 有限理性的自由能理论 114
10.9 效价、情绪与动机 115
10.10 内稳态、异稳态与内感受加工 115
10.11 注意、显著性与认识动态 117
10.12 规则学习、因果推断与快速泛化 117
10.13 主动推断与其他领域：开放方向 118
10.13.1 社会与文化动力学 119
10.13.2 机器学习与机器人学 119
10.14 总结 120

附录 A 附录 A：数学背景 121
A.1 引言 121
A.2 线性代数 121
A.2.1 基础 121
A.2.2 导数 123
A.2.3 概率 124
A.3 泰勒级数近似 126
A.3.1 引言 126
A.3.2 拉普拉斯近似 126
A.3.3 运动的广义坐标 128
A.4 变分法 129
A.4.1 泛函导数 129
A.4.2 变分贝叶斯 130
A.5 随机动力学 131
A.5.1 随机微分方程 131
A.5.2 非平衡稳态 131

A.5.3 运动的广义坐标 132

附录 B 附录 B：主动推断的方程 135

B.1 引言 135
B.2 马尔可夫决策过程 135
B.2.1 状态推断 135
B.2.2 作为推断的规划 137
B.2.3 学习 137
B.2.4 精度 138
B.2.5 期望自由能 140
B.2.6 贝叶斯模型约简 142
B.3 （主动）广义滤波 143

附录 C 附录 C：Matlab 代码注释示例 146

C.1 引言 146
C.2 预备 146
C.3 似然 147
C.3.1 转移概率 148
C.3.2 先验偏好与初始状态 148
C.3.3 策略空间 149
C.4 整合各个组成部分 149
C.5 仿真与绘图 150

第一部分

基础框架

第一章　总览

机遇偏爱有准备的头脑。

— 路易斯 · 巴斯德

1.1　引言

本章引入主动推断试图回答的核心问题：生命有机体如何在与环境进行适应性交换的同时持续存在？我们将讨论为何要从规范性视角来处理这一问题。这样的视角从第一性原理出发，再逐步展开其在认知和生物学上的含义。此外，本章还将简要介绍全书结构，包括它被划分为两个部分：第一部分旨在帮助读者理解主动推断，第二部分旨在帮助读者将其用于自己的研究。

1.2　生命有机体如何持续存在并进行适应性行动？

生命有机体持续不断地与其环境（包括其他有机体）发生相互作用。它们发出会改变环境的动作，并从环境中接收感觉观察，这一点如图 1.1 的示意所示。

生命有机体只有对行动--感知回路施加适应性控制，才能维持其身体完整性。这意味着，它们要通过行动来引出那些要么对应于理想结果或目标、要么有助于理解世界的感觉观察。前者例如对简单有机体而言，获得营养和庇护时所伴随的感觉；对更复杂的有机体而言，则可能是朋友和工作。后者则例如为有机体提供关于其周围环境的信息。

与环境进入适应性的行动--感知回路，会给生命有机体带来严峻挑战。这在很大程度上源于该循环的递归性质：每一次由前一个动作引出的观察，都会改变我们如何决定下一个动作，从而再去引出下一个观察。控制与适应的可能性极其丰富，但真正有用的却很少。尽管如此，在进化过程中，生命有机体还是发展出了适应性策略，以应对生存的根本挑战。这些策略在认知复杂度上彼此不同：较简单的有机体采用更简单、更刚性的解决方案（例如细菌沿着营养梯度移动），而更高级的有机体则采用认知要求更高、也更灵活的解决方案（例如人类为实现远端目标而进行规划）。这些策略在被选择和发挥作用的时间尺度上也不相同：有的体现为对环境威胁的简单反应，或是在进化时间尺度上形成的形态适应；有的体现为在文化学习或个体发育学习中建立起来的行为模式；还有的则需要与行动和感知处于相近时间尺度上的认知过程，例如注意和记忆。

1.3 主动推断：从第一性原理推导行为

这种多样性对生物学而言是一种福音，但对大脑与心智的形式理论而言却是一项挑战。大体上，我们可以采取两种看法。

一种看法认为，不同的生物适应、神经过程（例如突触交换与脑网络）以及认知机制（例如感知、注意、社会互动）都具有很强的特殊性，因此需要各自专门的解释。这样一来，哲学、心理学、神经科学、动物行为学、生物学、人工智能和机器人学等领域中的理论就会不断繁殖，而几乎看不到统一它们的希望。

另一种看法认为，尽管生命有机体中的行为、认知和适应具有多样化的表现形式，但它们的核心方面仍然可以从第一性原理出发获得连贯解释。

这两种可能性对应着两种不同的研究纲领，在某种程度上也对应着两种不同的科学态度："整洁派"与"杂糅派"（这两个术语出自 Roger Shank）。整洁派总是试图在大脑与心智现象表面的异质性背后寻求统一。这通常对应于构建自上而下的规范性模型[1]，从第一性原理起步，并尝试尽可能多地推导出关于大脑与心智的结论。相反，杂糅派则拥抱异质性，聚焦于那些要求专门解释的细节。这通常对应于构建自下而上的模型：从数据出发，采用任何有效的方法去解释复杂现象，甚至允许不同现象对应不同解释。

那么，是否可能像整洁派所设想的那样，从第一性原理解释异质的生物学与认知现象？是否可能建立一个统一的框架来理解大脑与心智？

本书对这些问题给出肯定回答，并将主动推断推进为一种理解大脑与心智的规范性路径。我们对主动推断的处理从第一性原理出发，并逐步展开它们在认知与生物学上的含义。

1.4 本书结构

本书由两个部分组成。它们分别面向两类读者：一类希望理解主动推断（第一部分），另一类希望将其用于自己的研究（第二部分）。本书第一部分将从概念和形式两个层面介绍主动推断，并把它放入当前认知理论的背景中加以定位。其目标是对主动推断给出一个全面、形式化且自洽的入门介绍：包括它的主要构件，以及它对于大脑与认知研究的含义。

本书第二部分将展示若干使用主动推断来解释认知现象的计算模型实例，例如感知、注意、记忆和规划。其目标是帮助读者既能理解现有的主动推断计算模型，也能设计新的模型。简言之，本书分为理论（第一部分）与实践（第二部分）。

[1]这里的"规范性"是指：模型从系统应当满足的原则或约束出发，而不是仅仅从经验数据中做归纳。

1.4.1 第一部分：理论中的主动推断

主动推断是一个规范性框架，用于刻画生命有机体中的贝叶斯最优[2]行为与认知。它的规范性特征体现在这样一个观点中：生命有机体中行为与认知的所有方面，都服从同一个唯一的命令，即最小化其感觉观察的惊讶（surprise）。这里的惊讶必须从技术意义上理解：它衡量的是，一个主体当前的感觉观察与其偏好的感觉观察之间有多大差异。所谓偏好的感觉观察，就是那些能够维持其完整性的观察（例如，对一条鱼来说，处于水中）。重要的是，最小化惊讶并不是靠被动地观察环境就能做到的；相反，主体必须对其行动--感知回路进行适应性控制，以便引出理想的感觉观察。这正是主动推断中“主动”二字的含义。

由于一些稍后会显现出来的技术原因，最小化惊讶是一个很困难的问题。主动推断对此提供了一种解决方案。它假定，即使生命有机体不能直接最小化惊讶，它们也可以最小化一个代理量，即（变分）自由能。这个量可以通过神经计算，在回应感觉观察以及预期感觉观察时被最小化。对自由能最小化的强调，也揭示了主动推断与激发它的那个（首要）原理之间的关系：自由能原理（Friston 2009）。

以自由能最小化作为出发点来解释生物现象，乍看之下似乎非常抽象。然而，我们可以从中推导出一系列形式和经验上的含义，并回答认知理论与神经理论中的一系列核心问题。这些问题包括：参与自由能最小化的变量如何可能被编码到神经元群体中；自由能最小化计算如何映射到具体认知过程，例如感知、动作选择与学习；以及当主动推断主体最小化其自由能时，会涌现出何种行为。

从上面的议题列表可以看出，本书主要关注的是生命有机体层面的主动推断与自由能最小化，不论这些有机体较为简单（例如细菌）还是较为复杂（例如人类），以及与之相关的行为、认知、社会和神经过程。做出这一澄清，是为了将我们对主动推断的讨论置于更一般的自由能原理（FEP）之中加以定位。后者讨论的是远远超出神经信息处理范围的、更广泛生物现象与时间尺度上的自由能最小化，从进化、细胞到文化层面皆在其内（Friston, Levin et al. 2015; Isomura and Friston 2018; Palacios, Razi et al. 2020; Veissière et al. 2020），而这些并不属于本书的讨论范围。

我们可以沿着两条道路中的任意一条来引出主动推断：一条是高路（high road），另一条是低路（low road）；见图 1.2。这两条道路为主动推断提供了两个彼此不同、但又高度互补的视角。

高路通向主动推断，是从“生命有机体如何在世界中持续存在并适应性行动”这一问题出发，并将主动推断作为这些问题的规范性解答来加以论证。高路视角有助于理解主动推断的规范性本质：生命有机体为了面对其根本性的存在挑战，必须做什么（最小化其自由能），以及为什么必须这样做（以间接方式最小化其感觉观察的惊讶）。

低路通向主动推断，则从“贝叶斯大脑”这一观念出发。该观念将大脑视为一个推断引擎，试图优化关于其感觉输入原因的概率表征。随后，它把主动推断论证为一种针对该推断问题的特定变分近似；否则，这个推断问题往往是不可处理的，而这种近似还具有一定的生物学合理性。低路视角有助于说明主动推断主体如何最小化其自由能，因此它不仅把主动推断展示为一条原则，

[2]这里的“贝叶斯最优”是指：在给定概率模型与目标偏好的前提下，以概率推断和决策原则达到最优。

也把它展示为一种认知功能及其神经基础的机制性解释（即过程理论）。

在第 2 章中，我们将展开主动推断的低路视角。我们从那些把感知视为统计推断（贝叶斯推断）问题的奠基性理论（Helmholtz 1866）出发，再看到它们在贝叶斯大脑假说（Doya 2007）中的现代形态。我们将看到，为了执行这种（感知）推断，生命有机体必须拥有或体现一个概率生成模型，用以说明其感觉观察是如何被生成的。这个模型编码了关于可观察变量（感觉观察）和不可观察（隐藏）变量的信念（概率分布）。我们还会把这一推断视角从感知扩展到动作选择、规划和学习等问题。

在第 3 章中，我们将展示与之互补的主动推断高路视角。该章将引入自由能原理以及生物有机体最小化惊讶这一命令。进一步地，我们会分析这一原理如何涵盖自组织动力学，以及如何维持一个统计边界或马尔可夫毯（Markov blanket），从而保持与环境的分离。这对于维持生物体的完整性至关重要，也是其自创生（autopoiesis）的核心。

在第 4 章中，我们将更为形式化地展开主动推断。该章以第 2 章对贝叶斯大脑的讨论为线索，阐明第 3 章中“自我证成”（self-evidencing）动力学与变分推断之间的数学关系。此外，该章还会介绍两类用于表述主动推断问题的生成模型：一类是用于决策与规划的部分可观察马尔可夫决策过程，另一类是与感觉受体和肌肉相接口的连续时间动力学模型。最后，我们将看到，对于这两类模型，自由能最小化如何体现为动态的信念更新。

在第 5 章中，我们将从形式处理转向主动推断的生物学含义。以“大脑中一切发生变化的东西都必须最小化自由能”（Friston 2009）这一前提出发，我们将讨论参与自由能最小化的具体量（例如预测、预测误差与精度信号）如何体现在神经动力学之中。这有助于把主动推断的抽象计算原理映射到可由生理基质执行的具体神经计算上。这一点对于在该框架下形成假设至关重要，并能确保这些假设可以通过测量数据来回答。换句话说，第 5 章将阐述与主动推断相关联的过程理论。

在本书第一部分中，我们还会持续讨论主动推断的若干典型特征。这些特征凸显了它与其他试图解释生物调节与认知的框架之间的差异，下面先作简要预告。

在主动推断之下，感知与行动是完成同一命令的两种互补方式：最小化自由能。感知通过（贝叶斯）信念更新，也就是改变你的想法，使你的信念与感觉观察相容，从而最小化自由能（以及惊讶）。相反，行动则是通过改变世界，使其与您的信念和目标更加相容，从而最小化自由能（以及惊讶）。这种对认知功能的统一处理，是主动推断与那些将行动和感知彼此割裂开来对待的路径之间的根本差别。学习是最小化自由能的另一种方式，但它在本质上并不不同于感知，只是作用于更慢的时间尺度上。感知与行动之间的互补性将在第 2 章展开。

除了在当下驱动动作选择以改变当前可获得的感觉数据之外，主动推断框架还容纳了规划，也就是在未来选择最优行动路线（或策略）。这里的“最优”是相对于期望自由能来衡量的，它不同于上文在行动与感知背景下讨论的变分自由能。事实上，计算变分自由能依赖于当前和过去的观察，而计算期望自由能还要求对未来观察作出预测（因此称为“期望”）。有趣的是，一个策略的期望自由能由两个部分构成：第一部分量化该策略预计将在多大程度上消除不确定性（探索），第二部分量化预测结果与主体目标的一致程度（利用）。与其他框架不同，主动推断中的

策略选择会自动平衡探索与利用。变分自由能与期望自由能之间的关系将在第 2 章展开。

在主动推断之下，所有认知操作都被概念化为对生成模型的推断，这与 ‘‘大脑执行概率计算’’ 这一观点保持一致，也就是贝叶斯大脑假说。然而，对某一种近似形式的贝叶斯推断的诉求，即一种由第一性原理所驱动的变分方案，则为该过程理论增添了具体性。此外，主动推断把推断路径扩展到了认知中那些很少被纳入考虑的领域，并对生物大脑可能实现的模型类型和推断过程增加了更具体的限定。在某些假设下，主动推断中所用生成模型涌现出来的动力学，与计算神经科学中的一些常见模型高度对应，例如预测编码（Rao and Ballard 1999）和 Helmholtz machine (Dayan et al. 1995)。这一变分方案的细节将在第 4 章展开。

在主动推断之下，感知和学习二者都是主动过程，原因有二。第一，大脑本质上是一台预测机器，它不断预测即将到来的刺激，而不是被动等待刺激到来。这一点很重要，因为感知与学习过程总是被先前的预测所情境化，例如，预期刺激与非预期刺激会以不同方式影响感知与学习。第二，从事主动推断的生物体会主动寻求那些能够消解其不确定性的显著性感觉观察，例如转动其感受器，或者选择信息量更大的学习情节。感知与学习的这种主动特征，与大多数把它们视为大体被动过程的现代理论形成对照；这一点将在第 2 章展开。

行动在本质上是目标导向且带有意图性的。它从一个期望结果或目标出发（类似于控制论中的设定点 set-point 概念），而这一目标被编码为一个先验预测。规划则通过推断出一条能够满足这一预测的动作序列来进行，或者等价地说，通过减少先验预测与当前状态之间的任何预测误差来进行。主动推断中行动的目标导向特征，与早期控制论表述是一致的，但不同于大多数用刺激--反应映射或状态--动作策略来解释行为的现代理论。刺激--反应式或习惯性行为，因此就成为主动推断中更广泛策略家族的一个特例。主动推断的目标导向性质将在第 2 章和第 3 章展开。

主动推断中的各种构件，在大脑中都具有可信的生物学对应物。这意味着，一旦人们为手头问题定义了一个具体生成模型，就能够从主动推断作为规范性理论，转向主动推断作为过程理论，并据此提出具体的经验预测。例如，知觉推断与学习分别对应于突触活动的变化和突触效能的变化；预测的精度（在预测编码中）对应于预测误差单元的突触增益；策略的精度则对应于多巴胺能活动。主动推断的一些生物学后果将在第 5 章展开。

1.4.2 第二部分：实践中的主动推断

如果说本书第一部分为读者提供了理解主动推断所需的概念工具和形式工具，那么第二部分则聚焦于实践问题。具体而言，我们希望为读者提供工具，使他们既能理解主动推断对于认知功能（以及功能障碍）的现有模型，也能设计新的模型。为此，我们将讨论若干使用主动推断的具体模型例子。重要的是，主动推断模型可以沿着不同维度变化，例如采用离散时间还是连续时间表述，采用平坦推断还是层级推断。第二部分的结构如下。

在第 6 章中，我们将介绍一套构建主动推断模型的配方。这套配方涵盖设计有效模型所需的关键步骤，包括识别研究对象系统、选择最合适的生成模型形式（例如用于刻画离散时间或连续时间现象），以及确定应当纳入模型的具体变量。因此，这一章将介绍支撑后续各章模型的设计

原则。

在第 7 章中，我们将讨论处理离散时间问题的主动推断模型，例如将问题表述为隐马尔可夫模型（HMM）或部分可观察马尔可夫决策过程（POMDP）。我们的例子包括一个知觉加工模型，以及一个离散觅食选择模型，也就是在决策点处向左还是向右转，以获得奖励。我们还将引入信息寻求、学习与新奇寻求等主题，它们都可以在离散时间的主动推断框架下得到处理。

在第 8 章中，我们将讨论处理连续时间问题的主动推断模型，它们使用随机微分方程来表述。这些模型包括知觉模型（如预测编码）、运动控制模型以及序列动力学模型。有趣的是，正是在连续时间表述中，主动推断的一些最具辨识度的预测会显现出来，例如运动生成源于预测的实现，以及注意现象可以理解为精度控制。我们还将介绍同时包含离散时间变量与连续时间变量的混合主动推断模型。这些模型能够同时评估离散选项之间的选择（例如眼跳的目标）以及由该选择所引出的连续运动（例如眼动运动）。

在第 9 章中，我们将说明如何使用主动推断模型来分析行为实验数据。我们将讨论进行基于模型的数据分析所必需的具体步骤，从数据收集，到模型构建，再到模型反演，以支持对单个参与者层面或群体层面数据的分析。

在第 10 章中，我们将讨论主动推断与心理学、神经科学、人工智能以及哲学中其他理论之间的关系。我们还会强调主动推断中最重要、也最能将其与其他理论区分开来的方面。

在附录中，我们将简要讨论理解本书技术性较强部分所需的数学背景，包括泰勒级数近似、变分拉普拉斯、变分法等概念。此外，我们还会以简洁形式给出主动推断中最重要的方程，供读者查阅。

总而言之，本书第二部分将展示如何使用主动推断来构建关于生物学与认知现象的广泛模型，以及如何设计新的模型的方法论。除具体模型本身的兴趣之外，我们更希望我们的处理方式能澄清：使用一个统一的、规范性的框架，以连贯视角来处理生物学与认知现象，究竟有何价值。归根结底，这正是规范性框架真正的吸引力：它提供统一视角和指导性原则，以调和那些表面上彼此断裂的现象。在这里，这些现象包括感知、决策、注意、学习和运动控制，而在任何一本心理学或神经科学手册中，它们通常都会被分置于不同章节。

第二部分所强调的模型，被选择出来是为了尽可能简单地说明一些特定要点。虽然我们覆盖了若干模型与领域，从离散时间决策到连续时间知觉和运动控制，但显然忽略了许多同样有趣的其他模型。现有文献中还存在许多其他主动推断模型，覆盖的领域极其广泛，包括生物自组织与生命起源（Friston 2013）、形态发生（Friston, Levin et al. 2015）、认知机器人学（Pio-Lopez et al. 2016; Sancaktar et al. 2020）、社会动力学与生态位建构（Bruineberg, Rietveld et al. 2018）、突触网络动力学（Palacios, Isomura et al. 2019）、生物网络中的学习（Friston and Herreros 2016），以及创伤后应激障碍（Linson et al. 2020）和惊恐障碍（Maisto, Barca et al. 2021）等精神病理状况。这些模型在许多维度上各不相同：有些与生物学联系更直接，有些则较弱；有些是单主体模型，有些是多主体模型；有些针对适应性推断，有些则针对失适应性推断（例如患者群体中的推断），等等。

这套不断增长的文献，体现了主动推断日益上升的受欢迎程度，也说明它能够被用于极其广泛

的领域。本书的目标，是让读者具备理解并在自身研究中使用主动推断的能力，并且有可能进一步探索它那些尚未被预见的潜力。

1.5 总结

本章从规范性视角出发，简要介绍了主动推断这一解释生物学问题的路径，并预告了这一视角的一些含义，而这些含义将在后续章节中展开。此外，本章还强调了本书分为两个部分：分别帮助读者理解主动推断，以及将其用于自己的研究。在接下来的几章中，我们将发展这里勾勒出的低路与高路视角，然后进一步深入到生成模型的结构及其所导出的消息传递。它们共同构成原则层面的主动推断，并为实践层面的主动推断奠定基础。我们希望这些章节能够说服读者：主动推断不仅为理解行为提供了一个统一原则，也为研究自主系统中的行动与感知提供了一条可处理的路径。

第二章　通往主动推断的低路

2.1　引言

本章从亥姆霍兹式, 或者也可以说康德式的观点出发来介绍主动推断: 知觉乃是 ‘‘无意识的推断”(Helmholtz 1867)。同时, 本章也会讨论在贝叶斯大脑假说之下近年发展出的相关思想。主动推断不仅把知觉视为推断问题, 还把行动、规划与学习一并处理为 (贝叶斯) 推断问题, 并为这些原本难以直接求解的问题给出一种有原则的 (变分) 近似方法。正是在这一点上, 主动推断既吸收又扩展了前述思想。

2.2　作为推断的知觉

把大脑看成一台 ‘‘预测机器”, 或看成一个能够推断并预测外部世界状态的统计器官, 这一传统由来已久。这个想法可以追溯到 ‘‘知觉是无意识推断’’ 这一观念 (Helmholtz 1866), 而在较近时期, 它又被重新表述为 ‘‘贝叶斯大脑’’ 假说 (Doya 2007)。从这个视角看, 知觉并不是一种纯粹自下而上的转导过程, 即把感觉状态 (例如来自视网膜的输入) 直接变成关于外部事物的内部表征 (例如神经元活动模式)。相反, 知觉是一种推断过程: 它把关于感觉最可能成因的自上而下先验信息, 与自下而上的感觉刺激结合起来。推断过程作用于对世界状态的概率表征, 并遵循贝叶斯法则; 贝叶斯法则规定了在感觉证据出现之后, 应如何以最优方式更新信念。知觉不是一个被动的、由外而内的信息提取过程, 不是简单从感觉上皮所受到的 ‘‘外部’’ 刺激中抽取信息; 它是一个建构性的、由内而外的过程, 在这个过程中, 感觉被用来证实或证伪关于其生成方式的假设 (MacKay 1956; Gregory 1980; Yuille and Kersten 2006; Neisser 2014; A. Clark 2015)。

而要执行贝叶斯推断, 我们需要一个生成模型, 它有时也被称为前向模型。生成模型是统计理论中的一种构造, 用来生成关于观测的预测。它可以写成观测 y 与产生这些观测的世界隐状态 x 的联合概率 $P(y, x)$。后者之所以被称为隐状态或潜在状态, 是因为它们无法被直接观测。这个联合概率可以分解为两部分。第一部分是先验 $P(x)$, 表示有机体在看到感觉数据之前, 对世界隐状态所拥有的知识。第二部分是似然 $P(y \mid x)$, 表示有机体关于观测如何由状态生成的知识。贝叶斯法则告诉我们如何把这两部分结合起来, 本质上就是在接收观测之后, 把先验概率 $P(x)$ 更新为关于隐状态的后验概率 $P(x \mid y)$。对于需要快速回顾基础概率论的读者, 框 2.1 给出了简要总结。

贝叶斯推断这一主题非常广泛, 它出现在统计学、机器学习与计算神经科学等多个学科中。对相

关内容的完整处理超出了本书范围, 但希望深入理解的读者可以参考非常优秀的教材 (Murphy 2012)。不过, 这一切都建立在一条简单规则之上。为了说明这条规则, 我们来看一个贝叶斯知觉推断的例子 (图 2.1)。设想某人强烈相信自己面前的是一个苹果。这个信念对应于先验概率, 简称先验。这个先验包含分配给 ‘‘苹果’’ 假设的概率, 以及分配给替代假设的概率。在这个例子里, 替代假设是它不是苹果, 而是一只青蛙。在数值上, 先验概率分布给苹果赋值 0.9, 给青蛙赋值 0.1。注意, 由于我们假定只有两个合理且互斥的假设, 它们的概率必须加总为 1。与此同时, 这个人还拥有一个似然模型, 该模型给 ‘‘青蛙会跳’’ 赋予很高概率, 而 ‘‘苹果会跳’’ 的概率很低。这个似然给出了从两个隐状态 (青蛙或苹果) 到两个观测 (跳或不跳) 的概率映射。先验与似然合在一起, 就构成了该人的生成模型。

现在设想这个人观察到她面前这个 ‘‘苹果--青蛙’’ 跳了起来。贝叶斯法则告诉我们, 应当如何在考虑 ‘‘跳跃’’ 这一似然信息后, 由先验形成后验信念。这个规则写作:

$$P(x \mid y) = \frac{P(x)P(y \mid x)}{P(y)} \tag{2.1}$$

框 2.1 概率的求和规则与乘法规则 概率推理依赖于两条关键规则: 概率的求和规则与乘法规则, 分别为

$$\sum_x P(x) = 1$$

$$P(x)P(y \mid x) = P(x, y)$$

求和规则表示, 所有可能事件 x 的概率必须加总 (或积分) 为 1。乘法规则表示, 两个随机变量 x 与 y 的联合概率, 可以分解为其中一个变量的概率 $P(x)$ 与在该变量给定时另一个变量的条件概率 $P(y \mid x)$ 的乘积。所谓条件概率, 就是在我们知道一个变量 (这里是 x) 取何值的条件下, 另一个变量 (这里是 y) 发生的概率。

由这两条简单规则, 我们可以推出两个重要结果。第一个是边缘化操作, 第二个是贝叶斯法则。边缘化使我们能够从联合分布中得到其中一个变量的分布:

$$\sum_x P(x, y) = \sum_x P(y)P(x \mid y) = P(y) \sum_x P(x \mid y) = P(y)$$

其中, $P(y)$ 被称为边缘概率, 而这个操作则称为把 x 边缘化掉。贝叶斯法则也可以直接从乘法规则得到:

$$P(x)P(y \mid x) = P(x, y) = P(y)P(x \mid y)$$

这使我们能够在先验与条件分布 (似然), 以及相应的边缘分布与另一条件分布 (后验) 之间来回转换。简单说, 贝叶斯法则无非是在说: 两件事同时发生的概率, 等于在第二件事已知时第一件

事发生的概率乘以第二件事的概率; 这也等于在第一件事已知时第二件事发生的概率乘以第一件事的概率。

在图 2.1 的似然模型下, 分配给青蛙的后验概率是 0.9, 分配给苹果的概率是 0.1。如框 2.1 所强调, 公式 2.1 的分母可以通过对分子进行边缘化来计算。借助苹果--青蛙这个例子, 我们也可以顺带展开说明两种不同的 ‘‘惊讶’’ 概念, 这两者在主动推断中都非常重要。

第一种, 我们直接称之为惊讶 (surprise), 它是负对数证据, 而证据就是观测的边缘概率。在我们的例子里, 它就是在生成模型之下, 观察到某物跳起来这一事件的负对数概率。对贝叶斯视角而言, 惊讶是一个非常重要的量, 因为它衡量的是模型对其试图解释的数据拟合得有多差。直观地说, 我们可以算出在模型下观察到 ‘‘跳跃’’ 行为的概率。请记住, 这个模型给苹果赋予了很高的先验概率, 给青蛙赋予了较低的先验概率。因此, ‘‘跳跃’’ 的边缘概率是

$$
\begin{aligned}
P(y=\text{jumps}) &= \sum_x P(x, y=\text{jumps}) \\
&= \sum_x P(x)P(y=\text{jumps} \mid x) \\
&= P(x=\text{frog})P(y=\text{jumps} \mid x=\text{frog}) \\
&\quad + P(x=\text{apple})P(y=\text{jumps} \mid x=\text{apple}) \\
&= 0.1 \times 0.81 + 0.9 \times 0.01 \\
&= 0.09
\end{aligned}
\tag{2.2}
$$

这意味着, 在这个模型下, 我们平均每 100 次观测中只会大约有 9 次看到跳跃行为。因此, 如果我们认同图 2.1 中的模型, 那么观察到跳跃就应当让我们感到惊讶。我们可以用惊讶 $\mathfrak{S}$ 来量化这一点:

$$\mathfrak{S}(y=\text{jumps}) = -\ln P(y=\text{jumps}) = -\ln(0.09) = 2.4 \text{ nats.}$$

这个数越大, 模型作为当前观测之解释就越差。这使我们能够相对于数据来比较不同模型。比如, 考虑一个替代模型: 我们先验上相信自己 100% 的时间都会看到青蛙。按照与公式 2.2 同样的步骤计算, 会得到大约 0.2 nats 的惊讶值。这个模型更适合这些数据, 因为这项观测在该模型下没有那么令人惊讶。基于证据 (或惊讶) 为模型打分的程序, 常被称为贝叶斯模型比较。对于更复杂的模型, 惊讶的形式可能不再这么简单。表 2.1 给出了一系列概率分布对应的惊讶形式 (省略常数项), 除了我们例子中的范畴分布之外也一并列出。关键在于, 这让我们能够针对支持集不同于当前简单例子的概率分布来讨论惊讶。这一点很重要, 因为世界生成感觉数据的方式会随数据类型而变化。我们可能会因为看到一张本不期待见到的面孔而感到惊讶 (范畴分布), 也可能因为室外温度比预想更低而感到惊讶 (连续分布)。表 2.1 可以看作是我们在后续章节构建生成模型时可用的一组概率分布工具箱。更一般地说, 它说明惊讶是一个可以针对任意给定概率分布族进行评估的概念。

表 2.1 概率分布与惊讶

分布	支持集	惊讶 $\mathfrak{S}$
Gaussian	$x \in \mathbb{R}$	$(x-\mu)^2$
Multinomial	$x_i \in \{0,\dots,N\},\ \sum_i x_i = N$	$-\sum_i x_i \ln d_i$
Dirichlet	$x_i \in (0,1),\ \sum_i x_i = 1$	$\sum_i (1-\alpha_i)\ln x_i$
Gamma	$x \in (0,\infty)$	$bx + (1-a)\ln x$

注: Multinomial 的特例包括 categorical($K>2, N=1$)、binomial($K=2, N>1$) 与 Bernoulli($K=2, N=1$) 分布; Dirichlet 的一个特例是 beta 分布 ($K=2$)。

第二种惊讶概念被称为贝叶斯惊讶 (Bayesian surprise)。这个术语多少有些容易混淆, 因为它衡量的是在一次观测之后我们必须更新信念的程度。换言之, 贝叶斯惊讶量化的是先验分布与后验分布之间的差异。这就提出了一个问题: 我们应如何度量两个概率分布之间的不同? 信息论给出的一个答案是使用 Kullback–Leibler 散度 (KL 散度)。它被定义为两个对数概率之差的平均值:

$$D_{\mathrm{KL}}[Q(x)\|P(x)] \triangleq E_Q(x)\big[\ln Q(x) - \ln P(x)\big] \tag{2.3}$$

这里的 E 表示平均值 (或期望), 具体见框 2.2。借助 KL 散度, 我们可以量化本例中的贝叶斯惊讶:

$$\begin{aligned} D_{\mathrm{KL}}[P(x \mid y)\|P(x)] &= P(x=\text{frog} \mid y=\text{jumps})\big(\ln P(x=\text{frog} \mid y=\text{jumps}) - \ln P(x=\text{frog})\big) \\ &\quad + P(x=\text{apple} \mid y=\text{jumps})\big(\ln P(x=\text{apple} \mid y=\text{jumps}) - \ln P(x=\text{apple})\big) \\ &= 0.9\big(\ln 0.9 - \ln 0.1\big) + 0.1\big(\ln 0.1 - \ln 0.9\big) \\ &\approx 1.8 \text{ nats} \end{aligned} \tag{2.4}$$

这个量衡量的是信念更新的幅度, 而不是观测本身有多不可能。为了突出惊讶与贝叶斯惊讶之间的区别, 考虑这样一种情况: 我们先验上坚信自己总会看到苹果。在这种情况下, 贝叶斯惊讶将为零, 因为先验信念如此强烈, 以至于我们在看到观测之后完全不会更新它。然而, 惊讶却会非常大 (4.6 nats), 因为苹果跳起来本身极不可能。

框 2.2 期望 引用随机变量 x 的期望很有用, 通常记为 $E[x]$。它表示该变量所有可能取值的加权平均, 权重即各取值对应的概率。对于离散随机变量 (只能取可数多个值), 期望可写为加权求和:

$$E[x] = \sum_x xP(x)$$

例如, 若一个离散数值变量只能以相等概率 1/2 取值 1 和 2, 则

$$E[x] = 1 \times \frac{1}{2} + 2 \times \frac{1}{2} = \frac{3}{2}.$$

对于连续随机变量 (可以取无限多个值), 求和需要替换为积分。期望也可以作用于随机变量的函数, 而不是变量本身。例如, 若有函数 $f(x)$, 且 x 服从某个连续分布, 则

$$E[f(x)] = \int f(x)p(x)\,dx.$$

本书会一直使用这一记号, 其中函数 $f(x)$ 往往是对数概率, 或对数概率比。

请注意, 尽管我们是以一个非常简单的生成模型来展示贝叶斯推断, 但它实际上适用于任意复杂度的生成模型。在第 4 章中, 我们将重点介绍支撑主动推断大多数应用的两类生成模型。

2.3 生物学推断与最优性

有两个重要观点把上述推断框架与生物学和心理学中的知觉理论联系起来。第一, 前面讨论的推断程序需要自上而下过程与自下而上过程的相互作用: 前者编码来自先验的预测, 后者编码由似然所中介的感觉观测。正是这种自上而下与自下而上之间的互动, 使推断视角有别于那些只考虑自下而上过程的替代路径。此外, 这种互动也是现代生物学知觉理论的核心, 例如预测编码 (将在第 4 章讨论), 它是这里所讨论的更一般的 (贝叶斯) 推断框架的一种特定算法性 (或过程层面) 实现。

第二, 贝叶斯推断是最优的。所谓最优性, 是相对于一个被优化 (即最小化) 的代价函数而言的; 对于贝叶斯推断, 这个代价函数被称为变分自由能, 它与惊讶密切相关。我们将在第 2.5 节回到这一点。通过显式考虑隐状态上的完整分布, 贝叶斯推断能够自然处理不确定性, 从而避免那些只考虑隐状态点估计 (例如 x 的均值) 的方法所具有的局限。一种这样的替代方法是极大似然估计, 它只是简单选出最有可能生成当前数据的那个隐状态。问题在于, 这种估计忽略了隐状态的先验合理性, 也忽略了估计本身周围的不确定性。贝叶斯推断没有这些局限。

不过, 尽管惊讶可以用来客观评估一个模型是否适用, 我们仍需理解, 推断本身是主观的。推断结果未必在客观意义上准确, 也就是说, 有机体的信念未必真的对应现实, 原因至少有两点。第一, 生物体所拥有的计算资源与能量资源都是有限的, 这使得精确贝叶斯推断通常不可行。这就要求我们采用近似, 而近似会让精确贝叶斯最优性不再有保障。这些近似包括变分后验这一概念, 它建立在所谓平均场近似之上, 并在第 4 章处于核心位置。

第二个使最优性呈现出主观性质的原因在于, 有机体运行的基础是主体关于其观测如何产生的生成模型, 而这个模型未必对应于现实中真正生成这些观测的过程。这并不是说, 生成模型就必须与生成过程完全一致。实际上, 某些模型甚至可能比真实生成它们的过程更擅长给出更好的 (例如更简单的) 数据解释; 这一点可以通过相对惊讶来量化。一个很好的例子是错觉: 某人面对被一位调皮的心理物理学家精心设计过的视觉刺激时, 会为自己的视觉输入找到一个更简单的解释。随着新经验的积累, 生成模型本身也可能被优化, 而这种优化未必会收敛到真实的生成过程。

图 2.2 说明了这一点, 也展示了真实环境因果关系 (即生成过程) 与有机体对世界的生成模型之间的区别。在这个例子中, 生成过程处于一个对有机体不可达的真实状态 x^*。然而, 有机体与世

界是相互耦合的, 因此 x^* 会生成一个观测 y, 并被有机体感知。有机体随后可以利用这个观测 y 与贝叶斯法则, 去推断生成模型中某个解释变量或隐状态的后验概率。图中我们同时把 x^* 与 x 都称作隐状态, 以强调两者都不可直接观测, 但它们又有细微差异: 前者属于生成过程, 后者属于有机体的生成模型。进一步说, x^* 与 x 并不一定生活在同一个状态空间里。外部世界中的隐状态可能会取到超出大脑可用解释空间的值; 反过来, 大脑的解释也可能包含一些外部世界并不存在的变量。例如, 前者可以是五维的, 后者是二维的; 或者一个是连续的, 另一个是范畴性的。行动 u 则是依据生成模型下所做出的推断而产生的, 但一旦执行, 它就作为生成过程的一部分作用于世界。

生成模型与生成过程之间的区分, 对于把握心理学中关于推断最优性的主张非常重要。即便这些主张成立, 它们在贝叶斯视角下也总是以有机体可用资源为条件。这里所谓资源, 指的是其具体的生成模型, 以及受限的计算与记忆资源。

2.4 作为推断的行动

到目前为止的讨论, 与所有贝叶斯大脑理论是一致的。不过现在, 我们引入主动推断所提供的一个简单但根本性的推进: 把行动也视为推断。这个思想起始于这样一个观念: 贝叶斯推断会最小化惊讶 (或者等价地, 最大化贝叶斯模型证据)。前面我们讨论的是, 当我们通过推断来计算惊讶, 并依照模型最小化惊讶的能力在模型之间做选择时, 会发生什么。然而, 惊讶不仅依赖于模型, 还依赖于数据本身。若我们通过作用于世界来改变数据的生成方式, 就可以挑选那些在我们的模型之下最不令人惊讶的数据, 从而保证模型适用。

一旦配备了产生行动的机制, 有机体就能够与其环境展开相互往复的交换, 见图 2.2。在动物身上, 这一机制表现为运动反射回路。本质上, 在每一个行动--知觉循环中, 环境向有机体发送一个观测; 有机体使用 (对) 贝叶斯推断的 (近似) 来推断其最可能的隐状态; 然后它生成一个行动, 并把行动发送给环境, 试图让环境变得没那么令人惊讶。环境执行这一行动, 产生新的观测, 再把它发送给有机体, 新的循环由此开始。这里采用顺序描述只是出于教学目的; 重要的是要看到, 这些并不真是离散步骤, 而是连续的动力学过程。

主动推断不只是认识到知觉与行动拥有相同的推断本性。它还主张, 知觉与行动是合作着实现同一个目标, 也就是共同优化同一个函数, 而不是像更常见的理论那样分别优化两个不同目标。在主动推断文献中, 这个共同目标曾被以多种非正式或正式方式描述为最小化惊讶、熵、不确定性、预测误差, 或 (变分) 自由能。这些术语彼此相关, 但其关系有时并不立刻清晰, 因而造成了一些混乱。更进一步, 它们往往出现在不同语境中; 例如, 预测误差最小化多出现在生物学语境里, 用于解释脑信号, 而变分自由能最小化则更多出现在机器学习语境中。

在接下来的两节里, 我们将澄清, 主动推断主体通过知觉与行动实际最小化的单一量是变分自由能。不过在某些条件下, 变分自由能可以还原为其他概念, 例如生成模型与世界之间的不匹配, 或我们所期望者与我们所观察者之间的差异 (即预测误差)。第 2.5 节将正式引入变分自由能。为简明起见, 第 2.4 节先聚焦于知觉与行动如何最小化生成模型与世界之间的差异。

2.5 最小化模型与世界之间的差异

既然我们已经用贝叶斯推断刻画了知觉与行动, 现在就可以进一步追问: 推断的目标究竟是什么? 换句话说, 推断在优化什么? 在认知科学中, 人们通常假定不同认知功能, 如知觉与行动, 优化的是不同目标。例如, 可以认为知觉最大化重建准确性, 而行动选择最大化效用。与此相反, 主动推断的一个根本洞见是: 知觉与行动服务于完全相同的目标。作为第一近似, 这一共同目标可以表述为最小化模型与世界之间的差异。有时这一点会被操作化为预测误差最小化。

为了理解知觉与行动如何减少模型与世界之间的差异, 我们再来看那个期待看见苹果的人 (图 2.3)。她会生成一个自上而下的视觉预测, 例如 ‘‘会看到某个红色且不会跳动的东西’’。这个视觉预测随后会与感觉输入进行比较, 比如感觉到 ‘‘有某个东西跳了起来”, 而这种比较便产生了差异。

她有两种方式来消除这一差异。第一, 她可以改变自己对所见之物的判断, 承认那是青蛙而不是苹果, 以便让自己的心智适配世界, 从而消除差异。这对应于知觉。第二, 她也可以把视线转移到最近的苹果树上, 看到一个看起来确实很像苹果的东西。这样同样能消除最初的差异, 但方式不同: 它不是改变心智来适配世界, 而是改变世界 (包括自己的注视方向) 以及随后的感觉输入, 使之适配心中已有的预期。这就是另一种拟合方向, 也就是行动。

如果在苹果与青蛙的世界里, 改变目光方向听起来还没有改变想法那么有说服力, 那么考虑另一种情况: 某个人期待自己的体温维持在某个区间, 但通过中枢温度感受器却感知到高温。这样的状态会让人惊讶, 也带来了一个需要解决的显著差异。与前面的例子一样, 他有两条最小化差异的路径, 分别对应于知觉 (改变想法) 与行动 (改变世界)。在这里, 仅仅 ‘‘改变想法’’ 显然并不适应, 而采取行动来降低体温 (例如打开窗户) 则是适应性的。

这也说明, 在主动推断中, 边缘概率或惊讶 (例如对体温的惊讶) 这一概念, 其意义超出了标准贝叶斯处理方式, 并吸收了诸如内稳态与异稳态设定点之类的思想。从技术上说, 主动推断主体拥有的模型会给它们偏好访问的状态, 或偏好获得的观测, 赋予高边缘概率。对鱼来说, 这意味着 ‘‘处于水中’’ 会具有很高的边缘似然。换句话说, 有机体会隐含地期待自己抽样到的观测落在其舒适区内, 例如处于生理边界允许的范围中。

总而言之, 我们讨论了在任意一个时间点上, 知觉与行动如何共同帮助我们最小化模型与世界之间的差异。我们究竟是调整信念还是调整数据, 取决于我们对这些信念有多大把握。在苹果的例子中, 相关信念带着足够高的不确定性, 因而更适合被更新而不是被付诸行动。相反, 在体温的例子中, 我们对核心体温拥有更高的确信, 因为它支撑着我们的存在本身。正因如此, 我们会更新世界, 使之符合我们的信念。不过, 在主动推断中, 知觉与行动之间的合作比上述表述还要紧密。为了理解这一点, 下一节将从较受限的 ‘‘差异”(或预测误差) 概念, 转向更一般的 ‘‘变分自由能’’ 概念; 后者才是主动推断真正最小化的量, 而预测误差只是它的一个特例。

2.6 最小化变分自由能

到目前为止, 我们是在一个试图最小化惊讶的贝叶斯框架下讨论知觉与行动的。然而, 在绝大多数情形中, 支撑知觉与行动的精确贝叶斯推断在计算上都是不可行的, 因为有两个量无法直接求出: 模型证据 $P(y)$ 与后验概率 $P(x \mid y)$。这可能有两个原因。第一, 对于复杂模型而言, 可能存在许多种都需要被边缘化掉的隐状态, 这会让问题在计算上变得不可处理。第二, 边缘化操作本身可能需要解析上无法求解的积分。主动推断诉诸一种对贝叶斯推断的变分近似, 从而使问题变得可处理。

第 4 章将详细展开变分推断的形式主义。这里我们只需知道, 执行变分贝叶斯推断意味着把两个难以计算的量, 即后验概率与 (对数) 模型证据, 替换为两个能够高效计算的近似量: 近似后验 Q 与变分自由能 F。近似后验有时也被称为变分分布或识别分布。负的变分自由能在机器学习中也常被称作证据下界 (evidence lower bound, ELBO)。

最重要的是, 贝叶斯推断问题因此被转化为一个优化问题: 最小化变分自由能 F。变分自由能这一量源于统计物理, 在主动推断中扮演根本性角色。在公式 2.5 中, 它记为 $F[Q, y]$, 因为它既是近似后验 Q 的泛函 (函数的函数), 也是数据 y 的函数:

$$
\begin{aligned}
F[Q, y] &= -E_Q(x)[\ln P(y, x)] - H[Q(x)] \\
&= D_{\mathrm{KL}}[Q(x) \| P(x)] - E_Q(x)[\ln P(y \mid x)] \\
&= D_{\mathrm{KL}}[Q(x) \| P(x \mid y)] - \ln P(y)
\end{aligned}
\tag{2.5}
$$

这三行分别可以理解为:

$$\text{Energy} - \text{Entropy}$$

$$\text{Complexity} - \text{Accuracy}$$

$$\text{Divergence} - \text{Evidence}$$

乍看之下, 变分自由能似乎是一个抽象概念, 但只要把它分解为认知科学里更直观、更熟悉的量, 它的性质及其在主动推断中的作用就会变得清晰。对变分自由能的每一种表述, 都给我们提供了一个理解自由能最小化含义的有用直觉。这里我们先作简要勾勒, 因为它们在本书后半部分讨论实例时会变得重要。

公式 2.5 的第一行表明, 相对于 Q 进行最小化时, 我们既要求与生成模型保持一致 (能量项), 又要求保持较高的后验熵。后者意味着, 在没有数据或没有精确先验信念时 (这些只会影响能量项), 我们应当对世界隐状态采取尽可能不确定的信念, 这与 Jaynes 的最大熵原理 (Jaynes 1957) 一致。简单说, 没有信息时就应当保持不确定。这里的 ‘‘能量’’ 一词继承自统计物理。具体说, 在

玻尔兹曼分布下, 一个系统采取某种构型的平均对数概率, 与该构型所关联的能量成反比, 即系统从基线构型移动到该构型所需的能量。

第二行强调, 自由能最小化可以理解为为感觉数据寻找最佳解释, 而这个最佳解释必须既足够简单 (复杂度最低), 又能够准确解释数据 (参见奥卡姆剃刀)。复杂度与准确性之间的权衡在多个领域反复出现, 通常出现在数据分析中的模型比较语境里。在统计学中, 有时也会用其他近似模型证据的指标, 例如贝叶斯信息准则或赤池信息准则。当我们后面介绍如何在基于模型的数据分析中用自由能进行模型比较, 以及在结构学习与模型缩减的语境下讨论时, 复杂度--准确性权衡会变得很重要。从认知角度看, 推断出复杂度最小的解释同样重要, 因为可以假设, 为了容纳数据而更新我们已经知道的内容 (即先验), 会带来认知代价 (Ortega and Braun 2013; Zénon et al. 2019); 因此, 与先验偏离最小的解释会更可取。

从这个角度看, 复杂度代价其实就是贝叶斯惊讶。换句话说, ‘‘我改变自己想法的幅度’’ 可以用先验与后验之间的散度来量化。这意味着, 对感觉的每一个准确解释都要付出复杂度代价, 而这个代价衡量的正是贝叶斯信念更新的程度。因此, 变分自由能刻画的是准确性与复杂度之间的差值。

最后一行则把自由能表述为负对数证据的一个上界 (见图 2.4)。图的左半部分说明, 自由能是负对数证据的上界, 其中上界与若能执行精确推断 (而非变分推断) 时本应获得的后验概率之间的差异, 正是 Q 与真实后验之间的散度。图的右半部分表明, 随着这个散度减小, 自由能会逼近负对数证据 (惊讶); 当近似后验 Q 与精确后验 $P(x \mid y)$ 完全一致时, 它就与惊讶相等。这为知觉推断提供了形式化动机: 通过尽可能优化近似后验 Q, 我们就能降低自由能。

公式 2.5 的最后一行还表明, 知觉推断并不是最小化自由能的唯一方式。我们也可以通过行动来改变感觉数据, 从而改变对数证据项。从认知角度看, 这一分解很有意思, 因为最小化散度与最大化证据, 分别对应于知觉与行动这两个互补的子目标, 见图 2.5。注意, 如果把 Q 用 $P(x \mid y)$ 替换, 那么上述所有表达式都会退化为对负对数证据的刻画, 也就是精确推断的情形。

总之, 主动推断就是通过知觉与行动最小化变分自由能。这种最小化使有机体能够让自己的生成模型去拟合它所抽样到的观测。这样的拟合, 一方面衡量知觉上的充分性 (由散度项表达), 另一方面也衡量对外部状态的主动控制能力, 因为它使有机体能够把自己维持在由生成模型所定义的一组适宜且偏好的状态内。换一种表述, 可以借助自由能的散度/证据分解来理解。把负对数证据等同于惊讶, 再注意到散度最小只能到 0, 我们就能看到自由能是惊讶的一个上界, 因而它只可能大于或等于惊讶。当有机体通过知觉最小化散度时, 自由能就成为惊讶的一个近似; 当有机体进一步通过行动改变自己收集到的观测, 使其更接近先验预测时, 它就会最小化惊讶。

变分自由能具有回顾性, 因为它只依赖过去与当前的观测, 不依赖未来观测。尽管它可以基于过去数据帮助我们对未来作出推断, 但它并不直接支持基于预期未来数据的前瞻性推断形式。而这对于规划与决策至关重要。在这些场景下, 我们需要根据某个行动或行动序列 (策略) 预期会带来的未来观测, 去推断最好的行动。要做到这一点, 就必须在生成模型中补充 ‘‘期望自由能’’ 这一概念。

2.7 期望自由能与作为推断的规划

期望自由能把主动推断扩展到一种典型的前瞻性认知形式: 规划。规划一连串行动, 例如走出迷宫所需的一系列移动, 需要考虑我们预计将会收集到的未来观测。比如, 某些备选行动路线的后果可能包括: 右转之后看到一个死胡同, 或在连续三次左转之后看到出口。每一种可能的行动序列都被称为一项策略 (policy)。这也凸显了主动推断中对行动与策略所作的一个重要区分。前者是直接作用于外部世界的东西, 后者则是一种关于行为方式的假设。其含义是, 主动推断把规划与决策视为一个推断 ‘‘该做什么’’ 的过程。这样一来, 规划就被明确纳入了贝叶斯推断的领域, 我们也必须像前面一样指明先验与似然 (见第 2.1 节)。不过, 在这里, 可供选择的不再是青蛙与苹果, 而是行为策略 (例如: 我更可能去看池塘还是看果树?)。

在这一节中, 我们先简要处理似然, 即执行某项策略所带来的后果, 然后再转向先验, 而期望自由能正是在这里登场。

与策略相关的结果并不是当下立刻可得的, 因为它们位于未来, 但我们可以把生成模型中的两个组成部分串联起来, 从而对其进行预测。第一部分是我们关于隐状态如何随策略而变化的信念。具体细节将在第 4 章讨论。此处我们用 $\tilde{x}$ 表示一段时间上的隐状态序列或轨迹, 并把轨迹条件化在生物所采取的策略 π 之上。这意味着, 我们模型的动力学部分写作 $P(\tilde{x} \mid \pi)$。继续沿用苹果--青蛙的例子, 策略可以是去池塘还是去果园的决定, 而这会改变遇到青蛙与苹果的概率。

模型的第二部分则是通常的似然分布。它描述在每一个可能状态下应期待什么观测, 例如在是青蛙或是苹果的条件下, 会跳还是不会跳。把这两个部分结合起来, 有机体就能通过替身式地运行自己的生成模型, 对自己可能采取的行动或策略进行 ‘‘如果..... 会怎样’’ 的反事实模拟, 例如 ‘‘如果我去池塘, 会发生什么?’’。对状态做边缘化后, 我们就得到某项策略的边缘似然, 即该策略的证据 $P(\tilde{y} \mid \pi)$, 或者其自由能近似。换句话说, 只要知道策略如何影响状态转移, 我们就能够计算在该策略下某个观测序列发生的似然。正如公式 2.1 所示, 要计算某项策略的后验概率, 我们需要把这个似然与一个先验概率结合起来。

主动推断把这一规划问题分解为两个连续操作。第一步是给每个策略计算一个分数; 第二步是形成关于 ‘‘应追求哪一策略’’ 的后验信念。前者定义了关于策略的先验信念: 最好的策略拥有较高概率, 最差的策略则拥有较低概率。在主动推断中, 一项策略的优劣由其负期望自由能打分, 就像模型拟合的优劣由该模型的负自由能打分一样。策略的期望自由能 G 与变分自由能 F 不同, 因为计算前者必须考虑依赖于策略的未来观测; 相比之下, 后者只涉及当前与过去的观测。因此, 计算期望自由能时, 需要调用生成模型去预测在每个策略被执行时直至某个规划时域内将会出现的未来观测。并且, 因为一项策略会跨越多个时间步展开, 每项策略最终的期望自由能都必须对其所有未来时间步进行整合。

每项策略的期望自由能都可以通过取负号转换成一个质量分数, 并可直接作为主动推断主体的先验。这之所以成立, 是因为与物理学中的势能观念一致, 期望自由能是以对数概率空间来表达的。要把它转成关于策略的信念 (或概率分布), 只需要进行指数化 (以抵消对数) 并归一化 (以满足框 2.1 中的求和规则)。那些期望自由能更低的策略会被赋予更高概率, 从而成为有机体预期自己会采取的策略。

归根结底, 推断自己正在执行某项特定策略, 会对我们所预测的感觉数据产生后果。例如, 一个包含 ‘‘屈肘’’ 动作的策略, 会蕴含关于肱二头肌与肱三头肌本体感觉输入的预测。正是在这里, 规划与行动被连接起来: 与某个计划相关联的预测, 会转化为行动, 以解决它们与实际测得的本体感觉数据之间的差异 (见第 2.3 节)。

2.8 什么是期望自由能?

到目前为止, 我们一直假定有机体在规划过程中会依照各策略的期望自由能来打分, 但我们还没有正面说明期望自由能究竟是什么。与变分自由能一样, 期望自由能也可以用多种在数学上等价的方式加以分解, 而每一种分解都为理解这一量提供了一个不同视角。

$$
\begin{aligned}
G(\pi) &= -E_{Q(\tilde{x},\tilde{y}|\pi)}\Big[D_{\mathrm{KL}}\big[Q(\tilde{x} \mid \tilde{y},\pi)\|Q(\tilde{x} \mid \pi)\big]\Big] - E_{Q(\tilde{y}|\pi)}[\ln P(\tilde{y} \mid C)] \\
&= E_{Q(\tilde{x}|\pi)}\big[H[P(\tilde{y} \mid \tilde{x})]\big] + D_{\mathrm{KL}}\big[Q(\tilde{y} \mid \pi)\|P(\tilde{y} \mid C)\big] \\
&\leq E_{Q(\tilde{x}|\pi)}\big[H[P(\tilde{y} \mid \tilde{x})]\big] + D_{\mathrm{KL}}\big[Q(\tilde{x} \mid \pi)\|P(\tilde{x} \mid C)\big] \\
&= -E_{Q(\tilde{x},\tilde{y}|\pi)}[\ln P(\tilde{y},\tilde{x} \mid C)] - H[Q(\tilde{x} \mid \pi)]
\end{aligned}
\tag{2.6}
$$

这些分解中的第一种, 从直觉上说大概最有用, 因为它用与追求偏好观测 (即利用, exploitation) 完全相同的单位 (nats), 来表达追求新信息 (即探索, exploration) 的价值。如此一来, 行为心理学中的经典 ‘‘探索--利用’’ 两难被消解了。通过最小化期望自由能, 这两项的相对权重就决定了行为是以探索为主, 还是以利用为主。需要注意, 语用价值 (pragmatic value) 在这里表现为关于观测的先验信念, 其中参数 C 编码了偏好。先验信念与偏好之间这种可能显得不太直观的联系, 会在第 7 章中展开; 目前我们只需指出, 在把有价值的结果理解为每个主体所特有的那类结果 (例如体温维持在 37°C) 的前提下, 这一项可以被当作期望效用或价值。

信息增益项继承了我们在第 2.5 节讨论过的散度概念, 而正是这个散度保证了自由能是惊讶的上界。不过这里有一个转折: 我们现在不是要最小化散度, 而是要选择能最大化期望散度的策略, 也就是最大化信息增益。之所以会发生这种变化, 是因为我们现在是在对尚未观测到的未来结果取平均。这一点很微妙, 其核心在于结果的角色发生了切换。在评估观测结果的自由能时, 结果扮演的是后果; 但在评估期望自由能时, 结果则扮演原因的角色, 因为它们是未来尚未显现、却解释当前决策的隐藏变量。

由此得到的信息增益会惩罚那些从观测到状态是多对一映射的情形, 也就是说, 在不同状态下会产生相同观测, 从而无法实现精确信念更新。在人工智能与机器人学中, 能带来相同观测的状态 (例如迷宫中两个看起来完全相同的 T 形岔路口) 有时被称为别名化 (aliased) 状态, 而用简单方法 (即只有刺激--反应, 没有推断或记忆) 往往很难处理这种状态。问题在于, 仅凭当前观测, 我们无法知道自己到底处于哪个状态。主动推断则会由于这些状态的信息增益潜力较低, 而尽量避免把自己带入这样的局面。

一个简单例子有助于拆解信息增益 (或认知价值) 与语用价值之间的区别, 并说明为何在大多数现实情境中, 语用价值与认知价值必须被联合作为目标。想象一个想喝浓缩咖啡的人, 他知道镇

上有两家不错的咖啡馆: 一家只在周一到周五营业, 另一家只在周末营业。如果他不知道今天是星期几, 那么他就必须先选择一个具有认知价值、能够消除不确定性的行动 (例如看日历), 然后才能选择一个携带语用价值、能带来奖赏的行动 (例如去正确的咖啡馆)。这个场景说明, 在大多数不确定情境中, 人们往往必须先执行认知性行动来消除不确定性, 然后才能有把握地选择语用性行动。那些不考虑选择所具认知可供性的策略选择方法, 只能通过随机数生成器来挑选策略, 结果往往就是错过那杯咖啡。因此, 只考虑语用价值的方案通常只能适用于不存在认知不确定性的情形, 例如这个人本来就知道今天是星期几, 因而可以直接前往正确的咖啡馆。

公式 2.6 的第二种分解把期望自由能写成风险 (risk) 与期望歧义 (expected ambiguity)。这两项分别对应于复杂度与不准确性的类比: 风险就是期望复杂度, 歧义则是期望不准确性。风险是经济学中的常见概念, 对应的是策略与其后果之间可能存在的一对多映射, 即同一策略之下可能随机地产生几种不同结果。一个例子是带有随机奖赏的赌博场景 (例如单臂老虎机), 其中你可能知道奖赏分布, 比如知道 10% 的时候会中奖。经济学把这称为风险情境, 因为在同样一次动作 (拉动拉杆) 之后, 你可能得到两种不同观测 (中奖或未中奖)。这意味着, 你必须选择那些能够容纳不确定性的策略或计划。在像主动推断这样的风险敏感框架中, 关键是选择那些其概率性结果与先验偏好相匹配的策略, 这种匹配通过 KL 散度来衡量。简而言之, 当复杂度与偏离先验信念的程度是同一回事时, 最小化复杂度代价就等同于最小化风险。

同样地, 歧义对应于由于状态到结果之间映射不明确而导致的期望不准确性。若即便我们对生成结果的状态充满把握, 所预期的结果分布依然非常分散 (或者说熵很高), 那么这一映射就是有歧义的。例如, 在知道天气是晴天还是雨天的条件下, 抛硬币出现正面还是反面的概率依然是 50–50, 因为天气与硬币结果之间没有关系, 因而这个映射具有最大歧义。于是, 仅仅看到一次反面并不能让我们获得关于天气的信息。需要注意的是, 大多数情境同时具有风险与歧义, 这意味着在状态到结果以及策略到结果之间都存在多对一或一对多的映射。回想一下, 结果 (观测) 是唯一真正可以被观测到的变量。主动推断能够自动处理这类情境, 因为期望自由能同时包含风险项与歧义项。

公式 2.6 的第三行则通过把风险重新表达为 ‘‘关于状态的信念’’ 与 ‘‘以状态定义的偏好’’ 之间的散度, 提供了另一种期望自由能的写法。这个形式的吸引人之处在于, 它可以像变分自由能 (公式 2.5) 那样被重排为期望能量与熵。不过, 这一写法的代价是它假定状态空间事先已知, 从而先验偏好可以直接与状态相联系。在大多数场景中, 这并不是问题, 而且用状态还是用结果来定义偏好, 在实践上差别也不大。不过, 更常见的做法还是以结果来定义偏好, 这样即使状态空间本身需要被学习, 外在动机也依然能够保留下来。

总之, 期望自由能既可以分解为风险与歧义, 也可以分解为语用价值与认知价值。这些分解很有意义, 因为它们使我们能够形式化地理解主动推断所处理的多种场景。此外, 它们也有助于我们看清主动推断如何吸收多种决策方案, 而这些方案通常可以通过忽略期望自由能中的一个或多个组成部分而得到 (图 2.6)。如果移除先验偏好, 那么语用价值就变得无关紧要, 所有行动都只受认知可供性驱动, 此时这种方案只能处理不确定性的消解。在去掉先验偏好后, 负的期望自由能在不同语境里会被称为期望贝叶斯惊讶 (例如注意性探索) 或内在动机 (例如自主学习)。如果移除歧义项, 得到的方案就对应于控制理论中的风险敏感控制或 KL 控制。最后, 如果同时移除歧义与先验偏好, 那么剩下的唯一要求就是最大化观测 (或在第三行表述下的状态) 的熵, 这可

以被理解为不确定性抽样, 或者说 ‘‘保持选择余地’’。主动推断揭示了这些方案之间的形式关系, 也揭示了它们适用情境的局限。

尽管我们已经细致地分解了期望自由能, 以适应不同读者对这个泛函的理解方式, 但并不存在唯一正确或错误的切分方式。本书后半部分将会说明, 某一类自治系统只要要继续存在, 就必须选择那些看起来像是在最小化期望自由能的行动。从这个角度看, 认知性 (探索性) 命令与语用性 (利用性) 命令, 或风险与歧义, 都没有哪一方享有特权地位。这些可能人为制造出来的二分, 不过是同一枚存在性硬币的两面。

2.9 低路的终点

在引入了变分自由能与期望自由能这两个不同概念之后, 我们现在可以来看它们结合起来究竟实现了什么。这也标志着通往主动推断的低路走到了一个阶段性终点: 它从无意识推断这一观念出发, 经过贝叶斯大脑、知觉与行动的二重性, 最终到达 ‘‘作为推断的规划’’。

变分自由能是主动推断的核心。它衡量内部生成模型与当前和过去观测之间的拟合程度。通过最小化变分自由能, 生物体就最大化了自身模型的证据。这既保证生成模型会成为环境的良好模型, 也保证环境在一定程度上会服从该模型。

期望自由能则是一种给备选策略打分的方法, 用于规划。它在根本上是前瞻性的, 因为它考虑的是可能出现的未来观测; 同时它也是反事实性的, 因为这些可能的未来观测是以某个潜在可执行策略为条件的。期望自由能衡量的是行动策略相对于偏好中的未来状态与未来观测而言有多可信。通过按负期望自由能给策略打分, 参与主动推断的生物体实际上会相信自己正在追求那个使这一量最低的行动路线。从心理学角度说, 这意味着生物体关于策略的信念会直接对应于其意图, 而它会通过行动去实现这一意图。

从概念上看, 我们可以把变分自由能最小化与期望自由能最小化理解为两个推断回路, 其中一个嵌套在另一个内部。变分自由能最小化是主动推断的关键外层回路, 它足以优化知觉以及关于策略的信念。如果一个主动推断主体还拥有一个关于其行动后果的生成模型, 那么它就能够进一步评估期望自由能, 这便形成了内层回路。这种向未来进行规划的能力, 通过为策略赋予概率值, 支持了前瞻性的行动选择 (Friston, Samothrakis, and Montague 2012; Pezzulo 2012)。

2.10 总结

主动推断是一种关于生命性人工物如何通过知觉与行动最小化惊讶, 或最小化惊讶的一个可处理代理量即变分自由能, 从而维系其存在的理论。在本章中, 我们试图从 ‘‘知觉即推断’’ 的贝叶斯处理方式出发, 再把这一思路扩展到行动领域, 以此为这一观念提供动机。贝叶斯推断依赖于一个关于感觉观测如何被生成的生成模型。这个模型以概率形式编码了有机体对世界的隐含知识, 具体表现为先验信念, 以及在不同状态与策略下所预期的结果。

主动推断的独特视角迫使我们重新审视贝叶斯推断中 ‘‘先验’’ 这一概念的通常语义。被期待的

状态就是被偏好的状态, 其中包括支撑有机体生存的条件 (例如特定生态位中的目标状态); 而与之相反, 令人惊讶的状态则是不被偏好的。通过实现自己的期待, 主动推断主体也就保障了自己的生存。正由于先验的概念与支撑有机体存在的条件之间存在紧密联系, 我们也可以说, 在主动推断中, 一个主体的身份与其先验是同构的。本书后面会让这种术语变得更加自然。

需要注意的是, 在这一视角下, 惊讶 (surprise, 有时也写作 surprisal) 是信息论中的一个形式构造, 并不必然等同于日常心理学意义上的 ‘‘惊讶’’。粗略地说, 有机体当前状态与先验 (即编码其偏好状态的东西) 偏离得越多, 该状态就越令人惊讶。因此, 主动推断的核心思想就是: 有机体 (或它的大脑) 必须主动最小化自己的惊讶, 才能维持生命。在某些条件下, 惊讶最小化可以被理解为减少模型与世界之间的差异。更一般地说, 主动推断真正最小化的量是变分自由能。变分自由能是惊讶的一个上界近似, 并且能够通过化学或神经层面的消息传递, 借助有机体生成模型可获得的信息被高效最小化。

重要的是, 知觉与行动以互补的方式共同最小化变分自由能: 前者通过改进自身的后验信念估计, 后者通过有选择地抽样那些被期望的观测。此外, 主动推断还会通过追随歧义与风险都最小的策略, 来最小化期望自由能。期望自由能因此把主动推断扩展到了前瞻性与反事实性的推断形式。至此, 我们沿着通往主动推断的低路完成了旅程。第 3 章中, 我们将转向高路: 它会从第一性原理与自组织出发, 抵达同样的结论。

第三章　通往主动推断的高路

> 能够模拟未来的生存机器，比那些只能依赖公开的试错来学习的生存机器领先一步。公开试验的问题在于它需要时间和能量。公开犯错的问题在于它往往是致命的。模拟既更安全，也更迅速。
>
> — 理查德 · 道金斯

3.1　引言

在第 2 章中，我们把自由能的引入说明为一种执行近似贝叶斯推断的方法（也就是通往主动推断的“低路”）。本章则从另一种视角引入自由能，即“高路”：它倒转了前面的论证顺序，从统计物理学的第一性原理以及生物体必须维持自身存在这一核心要求出发，也就是说，生物体必须避免令人惊讶的状态，然后再把自由能最小化引入为这一问题在计算上可处理的解法。本章揭示了变分自由能最小化与近似贝叶斯推断中模型证据最大化（或称“自证”）之间的形式等价性，从而展示了自由能与关于适应系统的贝叶斯视角之间的联系。最后，本章讨论主动推断如何提供一种新的第一性原理视角，用来理解（最优）行为。

主动推断是一种理论，说明生物有机体如何通过知觉与行动最小化惊讶，或者最小化惊讶的一个可处理替代量，即变分自由能，从而维持自身存在。通过从第一性原理出发，它推进了一种基于信念的新方案，用以理解行为与认知，而这一方案带来了大量经验层面的含义。

通往主动推断的高路始于这样一个前提：为了生存，任何生物体都必须把自身维持在一组适当的偏好状态之中，同时避开环境中的其他非偏好状态。这些偏好状态首先由生态位特定的进化适应所界定。不过，正如我们稍后将看到的，在高级生物体中，这些状态也可以扩展到习得的认知目标。例如，为了生存，一条鱼必须停留在一个舒适区内，而这个舒适区只对应宇宙所有可能状态中的一个很小子集：它必须待在水里。类似地，人类必须确保自己的内部状态（例如体温、心率之类的生理变量）始终保持在可接受范围内，否则他们就会死亡（更准确地说，会变成别的东西，比如一具尸体）。这个可接受的范围或舒适区，以约定方式界定了某个对象要成为“它自身”所必须处于的特征状态。

生物体通过在多个层次上主动控制自身状态来解决这一根本的生物学问题，例如调节体温。这些层次从出汗这样的自动调节机制（生理学），延伸到购买并饮用一杯饮料这样的认知机制（心理学），再到配置空调系统这样的文化实践（社会科学）。

从更形式化的角度看，主动推断把生存这一生物学问题，或者说生存的解释，表述为惊讶最小化。这一表述建立在信息论中关于“令人惊讶状态”的技术性定义之上，本质上，令人惊讶的状态就是那些落在生物体舒适区之外的状态。随后，它提出以自由能最小化作为一种实践上可行、并且具有生物学基础的方式，使生物体或适应系统最小化其感官遭遇的惊讶。

3.2 马尔可夫毯

任何适应系统的一个重要前提，是它必须与环境享有某种分离与自主性，否则它就会简单地耗散、溶解，并因此屈从于环境动力学。没有这种分离，就不会有需要最小化的惊讶；必须有某个会感到惊讶的东西，以及某个使其感到惊讶的东西。换言之，至少存在两个东西，即系统与环境，而且二者可以彼此区分。表达系统与其余环境之间分离的一种形式化方式，是马尔可夫毯这一统计构造（Pearl 1988）；见框 3.1。

框 3.1 马尔可夫毯 马尔可夫毯是本书中一个重要且反复出现的概念（Friston 2019a, Kirchhoff et al. 2018, Palacios et al. 2020）。从技术上说，毯状态 b 的定义如下：

$$\mu \perp x \mid b \iff p(\mu, x \mid b) = p(\mu \mid b)p(x \mid b)$$

这句话用两种不同但等价的方式说明：如果已知 b，那么变量 μ 与变量 x 条件独立。换句话说，如果我们知道 b，那么再知道 x，也不会给我们带来关于 μ 的额外信息。一个常见例子是马尔可夫链：过去导致现在，现在导致未来。在这种情形下，过去只能通过现在影响未来。这意味着，在已知现在的前提下，再去了解过去，并不会给我们带来关于未来的额外信息。

如果我们已知某个系统中的条件依赖关系，那么要识别其中的一个马尔可夫毯，可以遵循一个简单规则：某个给定变量的毯，包含它的父节点（即它所依赖的变量）、它的子节点（即依赖于它的变量），以及在某些设定下，它那些子节点的其他父节点。

简而言之，马尔可夫毯是一组变量，它中介了系统与其环境之间全部的统计交互。图 3.1 展示了马尔可夫毯在动态场景中的一种解释。在这里，条件独立关系又补充了动力学约束，因此流不会依赖于毯另一侧的状态。

图 3.1 中的马尔可夫毯，把适应系统内部的状态（即大脑活动）与环境的外部状态区分开来。此外，它还识别出另外两类状态，分别标记为感觉状态与主动状态，这两类状态共同构成了在统计上把内部状态与外部状态分开的“毯”。所谓统计分离，意味着如果我们知道主动状态和感觉状态，那么外部状态就不会再为内部状态提供额外信息，反之亦然。在动力学语境中，这通常被解释为：内部状态不能直接改变外部状态，但可以通过改变主动状态而间接地做到这一点；同样，外部状态不能直接改变内部状态，但可以通过改变感觉状态而间接地做到这一点。

这其实是经典行动--知觉循环的重述：适应系统与环境分别只能通过行动与观测发生交互。这种重新表述有两个主要好处。

图 3.1 一个动态马尔可夫毯，它把一个适应系统（此处是大脑）与环境分隔开来。每组状态的动力学都由一个确定性流决定，这个流由函数 f 指定，给出平均变化率，并叠加额外的随机波动 ω。箭头表示各变量对其他变量变化率的影响方向（从技术上说，就是相关雅可比矩阵中的非零元素）。这只是一个例子；马尔可夫毯既可以用来把整个有机体与环境分开，也可以彼此嵌套多个马尔可夫毯。例如，大脑、有机体、二人关系以及共同体，都可以被理解为不同层级、彼此嵌套的马尔可夫毯（形式化处理见 Friston 2019a；Parr, Da Costa, and Friston 2020）。容易让人困惑的是，不同领域对变量采用不同记号；有时感觉状态记作 s，外部状态记作 η，主动状态记作 a。这里我们选择当前这组变量，是为了与本书其他章节保持一致。

第一，它形式化地表达了这样一个事实：适应系统的内部状态对于环境动力学具有自主性，因此能够抵抗环境影响。第二，它为适应系统如何最小化惊讶提供了结构支架：它凸显出系统能够接触到的内部状态、感觉状态和主动状态。具体而言，惊讶是相对于感觉状态来定义的，而内部状态与主动状态的动力学，则是最小化感觉状态惊讶的手段。

这里需要注意的关键点是，适应系统的内部状态与外部状态之间存在一种形式关系。这源于马尔可夫毯两侧的一种对称性，因为二者都会影响毯状态，同时也都会被毯状态影响。由此带来的一个结果是，我们可以在给定毯状态的条件下，为内部状态和外部状态分别构造条件概率分布。由于这两个分布都条件化于同一组毯状态，我们就可以把成对的期望内部状态与期望外部状态联系起来。换言之，平均而言，内部状态与外部状态获得了一种（广义的）同步，就像我们在一根木梁两端各挂一个钟摆时所预期的那样。随着时间推移，当它们逐渐同步时，每个钟摆都会通过木梁的间接影响而对另一个钟摆具有预测性（Huygens 1673）。图 3.2 为这种关系提供了图示直觉。这意味着，如果我们能够写下在给定马尔可夫毯条件下外部状态与内部状态各自独立的分布，那么这两类状态就会经由这层毯而彼此提供信息。

这种同步使内部状态看起来像是在表征（或建模）外部状态，这又把我们带回第 2 章引入的惊讶最小化思想。因为惊讶依赖于一个关于感觉数据如何生成的内部模型。回顾一下，对感觉观测之惊讶（负对数概率）的最小化，与对该模型证据（边缘似然）的最大化是同一回事，而模型证据就是在该模型下感觉观测出现的概率。对惊讶最小化的这一观念，可以从两个等价视角来理解：贝叶斯视角与自由能视角。下面我们将讨论这两种视角。

3.3 惊讶最小化与自证

从贝叶斯视角看，一个拥有马尔可夫毯的主体似乎在对外部环境进行建模，因为其内部状态（平均而言）对应于对系统外部状态的一种概率表征，也就是一种近似后验信念（图 3.2）。内部状态的动力学对应于对外部状态进行的一种（近似）贝叶斯推断，因为内部状态的运动会改变相应的概率分布，而这种变化又得益于一个隐含的生成模型，该模型说明感觉，或者用马尔可夫毯术语来说“感觉状态”，是如何产生的。如果我们恢复“主体由内部状态和毯状态构成”这一观念，那么我们就可以谈论主体的生成模型。

重要的是，主体的生成模型不能只是简单复制外部动力学，否则主体就只会跟随外部的耗散动力学。相反，这个模型还必须规定主体得以存在的偏好条件，或者主体为了维持自身存在而必

须访问的状态区域，或者说，以占据特征状态的方式来满足其存在标准。这些偏好状态（或观测）可以被指定为模型的先验，这意味着模型隐含地假定：如果主体满足了自身存在的标准，那么它偏好的（先验的）感觉更有可能出现，也就是更不令人惊讶。这意味着模型带有一种隐性的乐观偏差。这种乐观偏差是必需的，因为只有这样，主体才不会止于复制外部动力学，而是能够规定那些支撑其偏好状态或特征状态的主动状态。

在这种表述下，可以把最优行为（相对于先验偏好而言）理解为通过知觉与行动实现模型证据最大化。事实上，模型证据概括了生成模型对感觉的拟合或解释程度。良好的拟合表明，该模型成功说明了自己的感觉输入（这是推断的描述性一面）；与此同时，它也实现了自己的偏好感觉，因为这些感觉更不令人惊讶（这是推断的规定性一面）。这种良好拟合保证了惊讶最小化，因为最大化模型证据 $P(y)$ 在数学上等价于最小化惊讶：$\Im(y) = -\ln P(y)$。

对上述论证的一种更简洁重述，是说任何适应系统都在进行“自证”（self-evidencing）（Hohwy 2016）。这里的自证，是指通过行动去获取与内部模型一致的感觉数据，也就是为该模型提供证据，从而最大化模型证据。

3.3.1 作为哈密顿最小作用量原理的惊讶最小化

在前面的几节中，我们断言惊讶必须被最小化，但还没有详细说明原因。尽管自证背后的物理学细节超出了本书的范围（详见 Friston 2019b），这里我们仍对这些原理作一个简要概述。这些原理建立在这样一个思想之上：带有马尔可夫毯的生物体能够在时间中持续存在，并抵抗环境波动的离散效应。马尔可夫毯的持续存在意味着，毯状态的分布在时间中保持恒定。简单地说，这意味着每当感觉状态（或主动状态）偏离该分布下高概率区域时，这种偏离都必须由状态的平均流来纠正，而平均流正是图 3.1 中流的确定性部分。如果用物理学家的方式来表述，那么处于稳态的随机系统会进行这样的动力学：它们平均而言沿着一个能量函数（或哈密顿量）下降，而这个能量函数可以被解释为负对数证据或惊讶。这就像一个球从山顶的高重力势能处滚下，最后滚入低能量的盆地。见图 3.3。

对于图 3.3 左侧所示的系统，每当一次波动导致系统进入一个概率更低的状态，这种偏移都会通过沿概率梯度上升的运动得到纠正，因此该系统会在更大比例的时间里占据概率密集的区域。这里的关键洞见在于：这个系统通过最小化惊讶（平均而言）把感觉状态维持在一个狭窄范围内；相比之下，右侧那个系统的惊讶则会无限增长。

惊讶最小化使得生物体能够（暂时地）抵抗热力学第二定律。第二定律指出，熵，也就是系统状态的离散程度，总是在增长。这是因为，平均而言，熵就是惊讶的长期平均，而平均来说，最大化观测对数概率等价于最小化香农熵：

$$H[P(y)] = E_{P(y)}[\Im(y)] = -E_{P(y)}[\ln P(y)] \tag{3.1}$$

确保只有一小部分感觉状态以高概率被占据，就等价于维持某种特定熵。这正是自组织系统的一个定义性特征，也是控制论理论早已认识到的事实。

从生理学视角看，惊讶最小化形式化了稳态（homeostasis）这一思想。当某个传感值偏离其最优范围时，负反馈机制就会启动，并逆转这些偏离。从控制论视角看，我们可以把最优行为理解为相对于某种目标稳态概率密度而言的行为。换言之，如果我们定义一个偏好结果的分布，那么最优行为就会推动系统向该分布演化，并维持在该分布附近。

正如第 2 章所见，自由能是惊讶的一个上界，这意味着面对随机波动时，可以通过最小化自由能来获得最优行为。回忆一下，自由能与惊讶之间的差异，是精确后验概率（即在给定毯状态下外部状态的分布）与近似后验概率（即在给定平均内部状态下外部状态的分布）之间的散度。因此，内部状态的运动可以被理解为在最小化这一散度，而这又使主动状态平均而言能够最小化伴随感觉状态出现的惊讶。换句话说，由自由能最小化导出的最优行为，是最不令人惊讶的行为，并且它沿着一条从当前状态通向目标状态的最小作用量路径前进，也就是说，这是把哈密顿最小作用量原理应用到了行为之上。

图 3.3 给出了一个非常简单的例子：一个具备随机吸引子的系统。这类似于一个恒温器，它在控制论语言中只有单一设定点，既不能学习，也不能规划。主动推断试图使用同一套解释装置，去覆盖复杂得多且适应性强得多的系统。在这里，最简单系统与更复杂系统之间的区别，可以归结为它们吸引子形状的不同，从固定点到越来越复杂、越来越游走的动力学。由此可见，生物体可以被理解为不断在过度稳定与过度离散之间寻求折中，而主动推断的目标，就是解释这种折中是如何实现的。

3.4 推断、认知与随机动力学之间的关系

物理学家 E. T. Jaynes 曾著名地指出，推断、信息论与统计物理学，只是对同一事物的不同视角（Jaynes 1957）。前面几节中，我们讨论了贝叶斯视角与统计物理学视角如何为惊讶最小化和最优行为提供两种等价的理解方式，这实际上等于在 Jaynes 的三元组中又加入了一种认知维度。各种思想流派之间的这种等价性很有吸引力，但对不熟悉相应形式体系的人来说也可能令人困惑，因为许多不同术语指向的其实是相同的量。为了帮助澄清这一点，本节将详细说明贝叶斯视角与统计物理学视角之间的主要等价关系，以及它们在认知上的解释；概览见表 3.1 和框 3.2。

表 3.1 统计物理学、贝叶斯推断、信息论及其认知解释 最小化变分自由能，对应于最大化模型证据（或边缘似然）、最小化惊讶（或自信息）；其认知解释是知觉与行动。

最小化期望自由能，以及满足哈密顿最小作用量原理，对应于推断最可能的（或最不令人惊讶的）行动进程；其认知解释是“把规划理解为推断”。

达到非平衡稳态，对应于执行近似贝叶斯推断；其认知解释是自证。

能量函数上的梯度流，对应于模型证据上的梯度上升、惊讶上的梯度下降；其认知解释是神经元动力学。

框 3.2 统计物理学中的自由能与主动推断中的自由能 自由能这一概念在统计物理学中被广泛使用，例如用于刻画热力学系统。虽然主动推断使用的是完全相同的方程，但它把这些方程应用于刻画主体的信念状态（相对于一个生成模型而言），而不是刻画其身体中的粒子之类的东西。因此，当我们说一个主动推断主体在最小化它的（变分）自由能时，我们指的是那些改变其信念状态的过程。为了避免误解，我们使用“变分自由能”这一术语，从而采用一种在机器学习中更常见的表述。

另一个更微妙的点在于，自由能的概念常常被用于平衡态统计热力学语境。主动推断所针对的却是生物体，也就是处于非平衡稳态、并且是开放的系统；它们与环境之间存在持续的、双向的交换。这是一个令人兴奋的新领域（Friston 2019a）。

3.4.1 变分自由能、模型证据与惊讶

第一个重要等价关系，是贝叶斯推断中的模型证据最大化（或边缘似然最大化）与变分自由能最小化之间的等价，而二者都在最小化惊讶。当我们诉诸一个特定的、用于处理推断难题的近似解法，即变分推断时，这种等价性就变得尤为明显。变分推断把推断问题改写为一个通过最小化自由能来求解的优化问题。自由能的最小值，对应于精确解近似得最好的那个点。把这种关系形式化写出来，就能看清这三个量之间的关系：

$$\Im(y \mid m) = -\ln P(y \mid m) \leq D_{KL}[Q(x) \,\|\, P(x \mid y, m)] - \ln P(y \mid m) \tag{3.2}$$

其中左边是惊讶，中间的 $-\ln P(y \mid m)$ 对应模型证据的负值，而右边整体对应变分自由能。

在式（3.2）中，与第 2 章不同，我们显式地把所有量都条件化在模型 m 上，以强调这些量依赖于我们拥有的模型，或者说我们自身作为一个关于 y 如何生成的模型；如果采用不同模型，这些量也会不同。这些量之间的等价性会引出一个问题：既然它们等价，为什么还要加以区分？主要原因在于，与模型证据不同，变分自由能可以被高效地最小化。回忆第 2 章，只有当 KL 散度项变为零时，变分自由能才与负模型证据或惊讶完全等价。这个条件并不总能严格达到，但可以逼近到非常接近零。因此，在为 $Q(x)$ 找到越来越好的取值的过程中，变分自由能也会越来越精确地逼近惊讶。我们已经多次提到这一点，因为必须反复强调：自由能与惊讶之间的核心关系，是本书的基础。具体地说，自由能是惊讶的一个上界。它可以与惊讶相等，也可以大于惊讶；大多少，由 KL 散度来量化。

这一点有一个有趣的方面：任何最小化其惊讶的系统，包括图 3.2 中那个非常简单的系统，也都在最小化某种自由能，只不过此时 $Q(x)$ 总是被设定为与精确后验概率相同，也就是把 KL 散度设为零。对于认知系统与非认知系统之间差异的一种看法是：后者总是具有零 KL 散度，而认知系统则必须先经过一个最小化这一项的（知觉）过程，然后它们的行动才会被保证能够最小化惊讶。注意，最小化这一散度，是知觉唯一能做的事情。这使内部状态的运动变得极其关键，因为这些内部状态所参数化的分布（图 3.2）必须尽可能接近精确后验。

然而，知觉无法最小化变分自由能中的第二个组成部分，也就是对应于实际惊讶的那个“证据”成分，因为它无法改变已经获得的感觉。只有通过行动，以改变感觉，主体才可能最小化变分

自由能中的第二个成分，解决它的惊讶，或者等价地，最大化它的模型证据。这使得在自证过程中，给定内部状态时主动状态的运动变得至关重要。

一个例子有助于说明这一点。想象你的生成模型会根据饥饿水平预测血糖水平的分布，其中较高血糖对应饱腹，较低血糖对应饥饿。此外，假设这个模型赋予饱腹状态，也就是相对较高的血糖水平，以更高的先验概率，因此低血糖就变得令人惊讶。再设想你起初对自己的饥饿水平并不确定，却感知到低血糖。知觉会导向这样的推断：你是饥饿的，于是你体验到饥饿，这就闭合了 KL 散度。然而，知觉无法再进一步减少你的惊讶，无法缩小你先验上所期待的高血糖与实际感知到的低血糖之间的差距，因为知觉不能直接作用于你的感觉（低血糖）或其原因（生理过程）。你只有通过行动，去改变你所获取感觉的那个隐藏来源，才能最小化你的惊讶，例如吃一份甜点。

总而言之，知觉可以通过减少近似后验与真实后验之间的差异来最小化变分自由能，但它不能进一步最小化惊讶。惊讶最小化的下一步，是通过行动改变自己所获取的感觉；此时，推断超越了知觉，变得主动。

3.4.2 期望自由能与最可能轨迹的推断

另一个重要的等价关系，是期望自由能最小化与推断最可能的行动进程或策略之间的等价。这超出了仅仅规定状态空间中哪一部分最不令人惊讶的范围，而涉及抵达该区域或位置的不同路线本身可能有多令人惊讶。这些替代路径以策略的形式表达，而策略本质上就是跨越状态的轨迹。重要的是，在主动推断中，一项策略的对数概率被设定为与执行该策略时的期望自由能成比例。这意味着，最可能、或最不令人惊讶的路径，就是那个最小化期望自由能的路径。这一表述等价于物理学中对“作用量”的定义：作用量通过对某个能量沿路径进行积分（或求和），来给路径的概率打分。物理系统也许会面对一个假设路径空间，但它实际遵循的路径，是作用量最小的那一条，也就是哈密顿最小作用量原理。下一节将进一步展开这种主动推断与哈密顿最小作用量原理之间的类比。

3.5 主动推断：理解行为与认知的一种新基础

在最优控制、强化学习和经济学等领域，行为的优化来自状态的价值函数，并遵循贝尔曼方程（Sutton and Barto 1998）。本质上，每个状态（或状态--行动对）都会被赋予一个价值，这个价值代表该状态对主体来说有多“好”。状态（或状态--行动对）的价值通常通过试错学习得到，方法是统计从这些状态出发，在多少次尝试、以及经过多长时间之后，能够获得奖励。行为于是表现为通过到达高价值状态来优化奖励获取，也就是利用既往学习历史。

相比之下，在主动推断中，行为是推断的结果，而其优化是信念的函数。这一表述把（先验）信念与偏好结合在了一起。正如上文所述，采用期望自由能这一概念，相当于赋予主体一个隐含的先验信念：它将实现自己的偏好。因此，主体对于某条行动路线的偏好，就变成了它关于自己未来会做什么、未来会遇到什么的一种信念，或者说，关于自己将访问哪些未来状态轨迹的

一种信念。这用（先验）信念的概念替代了价值的概念。

如果一个人具有强化学习背景，那么这种转换似乎相当奇怪，因为在强化学习中，价值与信念是分开的；如果一个人具有贝叶斯统计背景，这也会显得奇怪，因为在贝叶斯统计中，信念并不蕴含任何价值。然而，这是一种很有力量的转换，至少有三个原因。

第一，它自动包含了一个关于目的性行为（或目的论行为）的自洽过程模型，这与控制论的表述相近。如果我们赋予一个主动推断主体某种先验偏好，那么它就会行动去实现这种偏好，因为只有这样做，才与它关于“自己将会行动以实现其预期”的先验信念保持一致。注意，由此产生的（偏好）行动路线，也就是策略，在实验环境中是可以直接测量的；而价值函数或先验信念则需要被反推，因此是更间接、甚至近乎同义反复的测量。

第二，把行为看成信念（概率分布）的函数，会自动带来信念程度与不确定性之类的概念。这些概念支撑着适应性行动的重要方面，但在贝尔曼表述中并不能直接获得。出于同样的原因，这种表述在建模序列动力学和游走式行为时也更加灵活，而这些内容若仅用状态价值函数来建模会更困难（Friston, Daunizeau, and Kiebel 2009）。

第三，在这种表述下，最优行为会遵循统计物理学中的哈密顿最小作用量原理。事实上，主动推断在“行为是信念的函数”这一思想上又进一步：它还假定这种函数会成为一个能量函数，而主动推断主体最可能采取的行动路线，就是最小化自由能的那一条。一个深刻的结果是，生物体按照哈密顿最小作用量原理行事：它们沿着阻力最小的路径前进，直到到达稳态（或某条状态轨迹），图 3.3 中随机动力系统的行为就是例子。这是一个基础性假设，使主动推断不同于那些建立在贝尔曼表述之上的其他行为与认知理论。

这里值得简要说明一下，我们所说的哈密顿物理学与主动推断之间的类比是什么意思。这种类比包含三个层次。

第一，主动推断之于行为科学和生命科学的推进，可与拉格朗日表述和哈密顿表述之于牛顿力学的推进相比。牛顿力学最初是用微分方程来表述的，其中包括牛顿著名的第三定律，用来表达加速度与力之间的比例关系。后来，一种互补的视角出现了：人们开始通过考察动力系统中哪些量被守恒，来理解力学。于是，牛顿动力学也可以从这些守恒律中导出。这些守恒律提供了进一步理论推进的基础，并构成了随机物理学、相对论物理学和量子物理学某些部分的根基。类似地，主动推断重新表述了神经元动力学和行为动力学：过去这些动力学可能需要由一系列微分方程逐步搭建，而现在则可以通过指定一个量，也就是自由能，来导出这些动力学。正如不同种类的哈密顿量会导向不同类型的物理学一样，建立在不同生成模型基础上的自由能，也会导向不同的神经元动力学与行为动力学。

第二，哈密顿物理学与主动推断之间还有一种更直接的联系，即哈密顿量与概率测度之间的联系。这里的思想是把守恒的哈密顿量与系统的能量联系起来。请记住，到目前为止我们在这里以及第 2 章中所说的各种“能量”，都具有负对数概率的形式。这反映出一种把能量理解为“系统任何给定构型之不大可能性”的看法。从这个视角看，能量守恒与概率守恒是等价的定律。当耗散系统通过马尔可夫毯与外部状态耦合，并朝向低能量或高概率状态移动时，我们就可以直接把能量或哈密顿量与惊讶联系起来。因此，主动推断可以被看成应用于某一类特殊系统的哈

密顿物理学，这类系统的特征就是拥有马尔可夫毯。

第三，这两种表述之间的联系还体现在把能量与动力学联系起来的变分法上。当哈密顿物理学被表达为最小作用量原理时，这一点尤其明显。这里的“作用量”指的是某个拉格朗日量沿一条路径的积分。关键在于，作用量是路径的泛函。这里，路径是一个时间函数，它在每个时刻给出该路径上粒子的位置与速度。一个确定性粒子实际遵循的路径，就是使该作用量最小的路径。类似地，主动推断建立在这样一个思想之上：信念，作为隐藏状态的函数，本身也必须最小化某个自由能泛函。这里真正的接触点在于：在两种情形中，被优化的都是函数（路径或信念），而相对于它们进行优化的都是泛函（分别是作用量或自由能）。因此，二者都属于变分法的范围，而变分法正是研究如何寻找泛函极值的数学分支。在物理学中，这导向欧拉--拉格朗日方程；在主动推断中，这导向变分推断程序。

3.6 模型、策略与轨迹

在第 3.2 节中，我们强调主动推断所适用的范围，是那些与环境之间享有某种分离的系统，并指出这在形式上体现为马尔可夫毯的存在。在第 3.3 节中，我们强调这种毯的持续存在要求系统具有这样一种动力学：平均而言最小化（感觉）状态的惊讶。由于这一点可以被解释为自证，我们就得到一个结论：行为由某种稳态分布所决定，而这种稳态分布又可以被解释为一个关于（感觉）数据如何生成的生成模型。

这告诉我们一件非常重要的事：每一种生成模型都应当对应不同类型的行为。因此，不同类型的行为可以通过指定不同生成模型来加以说明，也就是隐含地指定该系统会把什么视为令人惊讶的东西。进一步地，不同种类的生成模型还可能对应于具有不同复杂程度的适应性生物或认知生物（Corcoran et al. 2020）。像图 3.3 中驱动动力学的那类非常简单的生成模型，只提供了一种最小形式的认知，因为它们无法设想替代性的，或反事实性的，轨迹。此外，这些模型是浅层的，因为它们只能在单一时间尺度上进行推断。相比之下，层级式生成模型则允许在多个时间尺度上进行推断。在层级式或深层模型中，更高层级上的动力学通常编码那些变化较慢的事物，例如我正在读的这句话，而这些事物又为变化较快的事物，例如我正在读的这个词，提供语境，后者则由较低层级来表征（Kiebel et al. 2008; Friston, Parr, and de Vries 2017）。

那么，我们需要在一个模型中加入什么，才能导出那种更复杂、并且通常会与能动性和有感知系统联系在一起的行为呢？一个答案是：要具备对不同未来进行建模的能力，也就是对事件可能如何展开的不同方式进行建模，并在它们之间作出选择。反过来，考虑可能的未来，要求生成模型具有某种时间深度，并且显式表征行动的后果。把这些内容纳入模型，将会确保行为符合这些未来之中最可能实现的那个。具备这种对替代未来进行反事实思考的能力，或许正是把有感知系统所对应的稳态，与更简单生物区分开来的关键。当这些替代未来涉及我们能够控制的事物时，我们就把它们称为策略或计划。正如第 2 章所见，区分这些计划的一种方法，是把一种先验信念纳入模型：即那些具有最低期望自由能的策略，是最可信的策略。这为刻画某种带有马尔可夫毯、且处于稳态中的系统提供了一种方式，而这种刻画似乎与像我们这样的系统非常契合。

3.7 在主动推断下对生成论、控制论与预测理论的统一

通过强调自由能最小化，主动推断把三种表面上彼此脱节的理论视角统一并扩展起来。

第一，主动推断与关于生命和认知的生成论（enactive）理论是一致的。后者强调行为的自组织，以及与环境之间的自创生式交互，而这种交互确保生物体保持在可接受边界之内（Maturana and Varela 1980）。主动推断提供了一个形式框架，用来解释生物体如何通过自组织出一种统计结构，即马尔可夫毯，来抵抗其状态的离散化。这种结构既允许生物体与环境之间发生双向交换，同时又把生物体的状态与外部环境动力学分离开来，并在某种意义上保护了生物体状态的完整性。

第二，主动推断与控制论理论是一致的。控制论把行为描述为有目的的、目的论的。所谓目的论，意味着行为受到某种内部调节机制的调控，这种机制会持续检测目标是否达成；如果没有达成，就会引导纠正性行动（Rosenblueth et al. 1943, Wiener 1948, Ashby 1952, G. Miller et al. 1960, Powers 1973）。类似地，主动推断主体通过知觉与行动共同最小化偏好状态与感知状态之间的差异。主动推断通过明确指出真正被最小化的是一个主体可以测量的统计量，即变分自由能，来为这一最小化过程提供一种规范性的、可行的描述。在某些条件下，这个量对应于预测误差，也就是预期到的东西与实际感知到的东西之间的差别。这意味着，控制论控制可以被表述为一种前瞻性的过程，这也把我们引向下一点。

第三，主动推断与那些把控制描述为前瞻性过程的理论也是一致的，而这种前瞻性过程依赖于一个关于环境的模型，这个模型甚至可能在大脑中有物理实现（Craik 1943）。主动推断假定，主体使用一个（生成）模型来构造指导知觉与行动的预测，并评估其未来的、以及反事实的行动可能性。这一假定与“良好调节器定理”一致（Conant and Ashby 1970），该定理指出，任何控制器都应该拥有，或者本身就是，一个关于环境的良好模型。主动推断在严格的（近似）贝叶斯推断与（变分和期望）自由能最小化框架下，统一了这些基于模型的大脑与行为观点。进一步地，主动推断与观念运动理论（ideomotor theory）在很大程度上也是一致的（Herbart 1825, James 1890, Hoffmann 1993, Hommel et al. 2001）。观念运动理论认为，行动起始于一个想象过程，并且真正触发行动的，是对行动后果的一种预测性表征，而不是像刺激--反应理论那样由刺激来触发（Skinner 1938）。主动推断把这一思想置于一个推断框架中，在该框架里，行动源于一种关于未来的信念；这带来许多含义，例如，为了触发行动，主体必须暂时削弱感觉证据，因为否则这些证据会否证那种触发行动的信念（H. Brown et al. 2013）。

这些框架之间的统一很有意思，因为它们通常被认为彼此冲突。例如，在生物学中，自组织与目的论常常被视为不相容。此外，生成论理论往往弱化表征与控制的地位，而在大多数基于模型推断的理论中，表征与控制却是核心构件。主动推断从一个不寻常的角度对适应性主体的自创生动力学作出形式化，这个角度同时考虑了自组织与预测。通过连接不同视角，主动推断有可能帮助我们理解这些视角如何彼此照亮。

3.8 主动推断：从生命的涌现到能动性

主动推断从第一性原理出发，并逐步展开，用以解释从最简单到最复杂的适应系统和生命系统所表现出的行为与认知。在更简单生物与更复杂生物所构成的连续谱上，主动推断在两类系统之间划出一条界线：一类系统最小化变分自由能，另一类系统则还会最小化期望自由能。

任何通过主动采样感觉来最小化变分自由能的适应系统，等价地说，都是一个主动为其生成模型收集证据的主体，也就是一个自证主体（Hohwy 2016）。这类系统能够通过达成基本稳态过程所提供的设定点，来避免耗散、进行自我调节并存活下来。这些系统可以生成复杂而多样的行为形式，也可以具有很高的适应度，这一点在病毒身上已经可以看得很清楚。它们中的一些还可以拥有层级式生成模型，从而允许对在不同时间尺度上变化的事件进行推断，从更快的变化（位于较低层级）到更慢的变化（位于较高层级），并因此能够发展出复杂的策略来应对它们所经历的情境。然而，这些生物仍然有一个根本限制：它们的生成模型缺乏时间深度，也就是缺乏显式规划和显式考虑未来的能力，尽管它们也可以通过隐式方式做到这一点，例如作为遗传进化的结果。因此，它们始终活在当下。

一个具有时间深度的生成模型，为期望自由能最小化打开了大门，或者用心理学语言说，就是为规划打开了大门。在主动推断中，这带来的远不止是更强的适应性：它至少意味着一种原初形式的能动性。对于一个适应系统而言，最小化期望自由能，等价于拥有这样一种隐含先验：自己是一个最小化自由能的主体，而且会在未来通过行动来最小化自由能。当这种（先验）信念进入生成模型之后，适应系统就能够形成关于自己未来应当如何行动、将会追随哪些轨迹的信念。换句话说，它开始能够在不同的未来之间作出选择，而不只是像前文所述那些最简单的主体那样，仅仅选择如何应对已感知到的现在。因此，这种时间深度也转化为一种心理深度。至于不同生物如何分布在最简单与最复杂适应系统之间的连续谱上，以及它们能表现出什么形式的主动推断，这是一个经验问题。

3.9 总结

本章的主要内容可以概括如下：生物体必须确保自己只访问那些特征性的、或偏好的状态。如果把这些偏好状态定义为期望状态，那么就可以说，生物体必须最小化其感觉观测的惊讶，并维持一种最优熵，见框 3.3。

做到这一点，要求主体对环境动力学拥有某种自主性，并且配备一个马尔可夫毯，把它们的内部状态与环境的外部状态分开，也就是在二者之间表达一种条件独立。处于马尔可夫毯之内的主体，能够与环境进行双向的行动--知觉交换。这些交换由主动推断理论来形式化描述，在其中，知觉与行动都会最小化惊讶。之所以能够做到这一点，是因为主体配备了一个概率生成模型，用来说明其感觉观测如何生成。这个模型定义了惊讶，或者更准确地说，定义了一个可处理的代理量，即变分自由能；后者可以被测量，也可以被高效地最小化。

框 3.3 熵最小化与开放式行为 主动推断建立在这样一个前提上：生物体努力维持相对的秩序（或负熵）、可控性和可预测性，尽管它们沉浸在一个其自然力量会不断制造波动、并带来无休止熵侵蚀威胁的环境中。这种主动追求秩序最基本的表现，就是生理稳态，因为若干关键的生理参数必须被维持在可生存区域之内。然而，熵最小化不应被等同于一套僵硬的反应库，例如自主神经式的稳态反应；恰恰相反，尤其在高级生物中，情况往往相反。我们可以发展出开放式的新行为库，以追求我们原初的稳态要求，例如为了满足口渴和其他需要而生产并购买好酒。这有时被称为“异稳态”（allostasis）（Sterling 2012）。

更广泛地说，我们还会主动追求某种秩序与可控性本身，而不一定直接指向某个具体的稳态要求，或许是因为保留秩序本身就有助于满足许多这类要求。我们会主动雕刻自己的生态位，使之变得更可预测、更不令人惊讶。这一点体现在我们构造物理空间的方式中，例如庇护所和城市，它们使我们免受失控自然力量的侵袭；也体现在我们构造文化空间的方式中，例如拥有法律和义务规范的社会，它们使我们免受无政府状态社会力量的侵袭。在所有这些例子里，我们通常都需要接受某种短期的熵或惊讶增加，例如建造新事物或改变社会立场，以确保长期的熵或惊讶下降。这帮助我们理解，惊讶最小化这一基本要求并不与认知性要求、新奇寻求、好奇和探索行为相冲突；相反，它恰恰促进了这些被我们视为许多物种核心特征的行为。

认知性要求首先体现在变分自由能最小化过程中。对自由能的一种分解方式，是把它表达为在近似后验下取期望的 Gibbs 能量减去近似后验的熵。换言之，主体是在努力增加熵。虽然这看起来像个悖论，但一旦注意到这里增加的是主体信念，也就是其近似后验信念的熵，这个悖论就消失了。可以把它理解为这样一种要求：既要尽可能准确地解释事物，又要“保持选项开放”，除非必要，不要过早承诺于任何一个具体解释，这就是最大熵原理（Jaynes 1957）。

认知性动力学表现出来的第二种方式，是在期望自由能最小化过程中。有意思的是，在这里会出现两个符号相反的熵。它们包括：后验预测熵，也就是“在给定某种选择时，我对自己会遇到什么结果有多不确定”，这一项必须被最大化，这一点与变分自由能中关于状态信念的情况相同；以及在给定状态条件下结果的条件熵，也就是某项策略所包含的歧义性，这一项必须被最小化。因此，在变分自由能最小化过程中，要求是最大化关于当前信念的熵；而在期望自由能最大化过程中，要求则是选择那些能够最小化未来信念歧义性的行动。由此便产生了认知性的、好奇的、寻求新奇的、搜寻信息的行为，它们支持不确定性的消解，或者支持生成模型的改进，而这反过来又会在长期中最小化惊讶（Seth 2013; Friston, Rigoli et al. 2015; Seth and Friston 2016; Schwartenbeck, Passecker et al. 2019）。

一个主动推断主体看起来是在某个生成模型之下执行（近似）贝叶斯推断，并为自己的模型最大化证据，也就是说，它是一个自证主体。推断中的前瞻性部分，则通过选择那些预期将在未来最小化自由能的行动路线或策略来实现。这一形式体系导向了一种关于（最优）行为的新视角：即把行为理解为哈密顿最小作用量原理的体现。这是一条把主动推断与统计物理学、热力学以及非平衡稳态领域连接起来的第一性原理。

第四章　主动推断的生成模型

一切都应尽可能简单，但不能更简单。

— 阿尔伯特 · 爱因斯坦

4.1　引言

本章是在前几章对主动推断进行概念性讨论的基础上，补上一层更形式化的说明。具体来说，本章将阐明自由能与贝叶斯推断之间的关系、主动推断中通常使用的生成模型的形式，以及在这些模型下通过最小化自由能所得到的动力学。一个核心关注点，是时间如何在生成模型中被表示。我们将看到，以连续时间表述的生成模型，与把时间视为事件序列的生成模型之间存在重要差别。最后，我们还将介绍推断性消息传递这一思想，它支撑了神经生物学中的若干重要理论，包括预测编码。

4.2　从贝叶斯推断到自由能

在前两章中，我们概述了主动推断与神经科学中其他既有范式之间的一些重要联系。在第 2 章里，我们重点讨论了“贝叶斯大脑”这一观念（Knill and Pouget 2004, Doya 2007）。它是主动推断最接近的亲属之一，也为我们从更形式化的视角理解主动推断的若干后果提供了有用框架。更具体地说，它帮助我们界定一个从事主动推断的主体必须解决的问题。总体而言，这些问题包括：推断世界状态（知觉）以及推断行动路线（规划）。虽然人们很容易把贝叶斯最优性等同于精确的贝叶斯推断，但精确推断通常在计算上不可处理，甚至根本不可行。在认知心理学和人工智能应用中，人们常常考虑受限形式的推断与理性。我们在第 3 章中已经举过一些例子。在贝叶斯框架下，这就转化为使用近似推断。

这些方法包括采样方法与变分方法，而主动推断正是建立在后者基础之上。本节将回顾贝叶斯推断及其变分形式的基本要素（Beal 2003, Wainwright and Jordan 2008）。这样做的目的是帮助读者建立对自由能角色的直觉，并强调生成模型在我们对世界进行推断时的重要性。

本章比第 1 至第 3 章更具技术性，需要用到少量线性代数、微分与泰勒级数展开。对细节感兴趣，或需要复习相关内容的读者，可以查阅附录以获取必要背景。不想深入理论基础的读者，也可以跳过本章。不过，在行文过程中，我们都会解释每个公式的关键含义，因此即便不完全跟

随形式推导，也仍然可以理解本章中最重要的概念要点。

一个好的起点是贝叶斯定理。回忆第 2 章，这一定理表达的是：先验与似然的乘积，等于后验与边缘似然的乘积。其形式见式（4.1）：

$$P(x)P(y \mid x) = P(x \mid y)P(y) \tag{4.1}$$

$$P(y) = \sum_x P(y, x) = \sum_x P(y \mid x)P(x) \tag{4.1}$$

式（4.1）的第一行是贝叶斯定理。第二行表明，边缘似然，也就是模型证据 $P(y)$，可以直接由先验和似然计算得到。[1] 这说明，先验与似然共同构成的生成模型，已经足以让我们计算模型证据和后验概率。尽管如此，这样做并不总是容易的。式（4.1）中的求和（若是连续变量则为积分）在计算上或解析上都可能不可处理。处理这一问题的一种方法，也是变分推断的起点，就是把这个潜在困难的积分问题转化为一个优化问题。要理解这一点，我们需要诉诸 Jensen 不等式。它指出："平均值的对数，总是大于或等于对数的平均值。" 图 4.1 为这一点提供了图形化直觉。

图 4.1 对数函数为 Jensen 不等式提供了直觉。假设只有两个数据点 x_1 和 x_2。我们既可以先求它们的平均值 $E[x]$，再取对数；也可以先分别对每个数据点取对数，再对这些对数求平均，即 $E[\ln x]$。由于对数函数是凹函数，后者总会低于前者，即 $E[\ln x] \leq \ln E[x]$；只有当数据点相同的时候，两者才相等。这个不等式对任意数量的数据点都成立。

为了利用这一性质，我们可以改写式（4.1）：在第二行求和项内部，将某个任意函数 Q 除以自身后乘进去。由于这等价于乘以 1，因此等式仍然成立。然后对等式两边取对数。从数学上看，这没有改变任何东西；但现在我们可以把该表达式看成是关于两个概率之比的期望 E，从而利用 Jensen 不等式：

$$\ln P(y) = \ln \sum_x P(y, x) \frac{Q(x)}{Q(x)} = \ln E_{Q(x)}\left[\frac{P(y, x)}{Q(x)}\right] \geq E_{Q(x)}\left[\ln \frac{P(y, x)}{Q(x)}\right] \triangleq -F[Q, y] \tag{4.2}$$

该式的第二步使用了这样一个事实：我们面对的是 "对数下的期望"，而根据 Jensen 不等式，它一定大于或等于 "期望下的对数"。这一步有时被称为重要性采样。这个不等式右侧被称为（负的）变分自由能：自由能越小，它就越接近负的对数模型证据。带着这一点，我们可以把贝叶斯定理（式（4.1））写成对数形式，在后验分布下取平均，并揭示它与式（4.2）中的量之间的关系：

$$\ln P(x, y) = \ln P(y) + \ln P(x \mid y) \Rightarrow E_{P(x|y)}[\ln P(x, y)] = \ln P(y) + E_{P(x|y)}[\ln P(x \mid y)] \tag{4.3}$$

[1] 如果处理的是连续变量，则求和应替换为积分。

$$E_{Q(x)}[\ln P(x,y)] = -F[Q,y] + E_{Q(x)}[\ln Q(x)] \tag{4.3}$$

第二行成立的原因是，y 的对数概率不是 x 的函数，因此在后验分布下取期望并不会改变这一项。式（4.3）帮助我们理解自由能与 Q 分布各自扮演的角色。这两个量如果不使用变分近似，就很难直接计算。前者扮演的是负对数模型证据的角色，后者则表现得像后验概率。更正式地说，我们可以像第 2 章那样重排自由能，量化自由能与模型证据之间的关系：

$$F[Q,y] = D_{KL}[Q(x) \,||\, P(x \mid y)] - \ln P(y) \tag{4.4}$$

$$D_{KL}[Q(x) \,||\, P(x \mid y)] = E_{Q(x)}[\ln Q(x) - \ln P(x \mid y)] \tag{4.4}$$

式（4.4）的第一行表明，自由能可以写成一个 KL 散度加上一个负对数证据。第二行给出了 KL 散度的定义：它是两个对数概率之差的期望。KL 散度通常被用来衡量两个概率分布彼此有多不同。

有时，人们会直接从这种散度的角度来解释为什么要使用自由能。论证是这样的：如果我们的目标是执行近似贝叶斯推断，那么我们就需要找到一个尽可能贴近精确后验的近似后验。因此，我们可以选择某种衡量两者差异的散度，并将其最小化。式（4.4）中的 KL 散度只是其中一个例子。问题在于，由于我们并不知道精确后验，所以不能直接使用这个散度。一种解决方法是加上对数证据项；这样它就可以与对数后验合并，形成联合概率，而联合概率正是我们已知的生成模型。所得结果就是自由能。

从这个角度看，还有一个有趣的后果，即究竟该使用哪一种散度似乎存在某种不确定性。如果我们的目标仅仅是让近似后验与精确后验尽可能接近，那么我们也可以使用另一个 KL 散度，也就是把 Q 与 P 的位置交换，或者从一大族散度中进行选择，而不同散度会强调分布差异的不同方面。然而，第 3 章所提出的思想强调：对于从事主动推断的系统而言，自证尤为重要。因此，我们首先寻找的是一种可处理的证据最大化方案，而只有在次要意义上才是在最小化散度。从这个视角看，究竟该选哪种散度并不存在歧义；它是由 Jensen 不等式自然导出的。

4.3 生成模型

要计算自由能，我们需要三样东西：数据、一族变分分布，以及一个生成模型（即先验与似然）。本节概述主动推断中使用的两类非常一般的生成模型，以及自由能在每一类模型下的形式。第一类处理的是关于类别变量的推断，例如对象身份，它被表述为一个事件序列。第二类处理的是关于连续变量的推断，例如亮度对比，它以随机微分方程的形式在连续时间中表述。在给出这些模型的细节之前，我们先回顾一种图形化形式主义，用来表达生成模型所蕴含的依赖关系。

图 4.2 展示了若干以因子图表示的生成模型，目的是帮助读者形成对这种表达方式的直觉。图中，生成模型的因子（例如先验与似然）用方框表示，而模型中的变量（隐藏状态或数据）用圆

圈表示。箭头表示这些变量之间的因果方向。左上角的图显示了最简单的模型形式：一个隐藏状态 x 导致数据 y。该模型中的先验由因子 1 表示，似然由因子 2 表示。其余图则通过引入更多变量，对这一思路进行扩展。例如右上图中，z 扮演第二个隐藏状态的角色，使得 y 同时依赖于 x 与 z 的状态。

以临床诊断检测为例，左上角的简单因子图可以被理解为疾病是否存在（x）与检测结果（y）之间的关系。这里的先验就是该疾病在人群中的患病率，而似然则刻画检测的性质，包括特异性（在没有疾病时得到阴性结果的概率）与敏感性（在有疾病时得到阳性结果的概率）。于是，我们可以按照因子图自上而下的方式来理解检测结果是如何产生的。首先，从某个已知疾病患病率的人群中抽取一个人。如果此人患病，那么他以由检测敏感性给定的概率生成真阳性结果，否则生成假阴性结果。如果此人未患病，那么他以由特异性给定的概率生成真阴性结果，否则生成假阳性结果。

沿用这个例子，我们还可以解释其他因子图。右上图中，x 和 z 可以代表两种不同疾病是否存在，而任何一种疾病都可能导致阳性检测结果。左下图中，w 扮演数据的角色。y 与 w 都由 x 生成，例如它们可以代表两种都能为同一疾病过程提供信息的不同诊断测试。最后，右下图把 x 和 v 都视为隐藏状态，但引入了一个层级结构，其中 v 导致 x，x 又导致 y。在这里，我们可以把 v 理解为某种为疾病 x 的有无提供背景或易感因素的变量，例如一种遗传多态性，而 y 则是对该疾病进行测量所得的数据。原则上，我们可以在这个层级结构中加入任意数量的变量。

这类生成模型常被用于静态知觉任务，例如物体识别或线索整合。主动推断使用的生成模型则有一个重要不同点：随着新的观测被采样，它们会随时间演化，而且被加入的观测还依赖于主体对模型中变量的信念，并通过行动体现出来。这带来两个关键含义。第一，条件依赖关系不仅包括某一时刻隐藏变量之间的关系，还包括某一时刻的隐藏变量对先前时刻隐藏变量的依赖。第二，这些模型有时还会把“我正在如何行动”的假设也纳入隐藏变量之中。

图 4.3 用因子图形式展示了主动推断中使用的两种基本动态生成模型（Friston, Parr, and de Vries 2017）。上图是部分可观测马尔可夫决策过程（POMDP），它表示一个状态序列 s 随时间演化的模型。在每一个时间步，当前状态在条件上依赖于前一时刻的状态，以及当前正在执行的策略 π。这里的策略可以被理解为替代轨迹，或者可供遵循的不同行动序列的索引。每一个时间点都对应一个观测 o，而该观测只依赖于该时刻的状态。这类模型对处理序列规划任务非常有用，例如走迷宫（Kaplan and Friston 2018），或者在多个选项之间进行选择的决策过程，例如场景分类（Mirza et al. 2016）。

图 4.3 的下图展示了一个非常相似的图形模型，但它是用连续时间来表达的。该模型不再把轨迹表示为一系列状态，而是表示一个状态 x 的当前位置、速度、加速度以及更高阶时间导数。这些量被称为运动的广义坐标，可以通过泰勒级数展开重建一条轨迹（见附录 A 中相关介绍）。这里，状态与其时间导数之间的关系取决于缓慢变化的原因 v，而 v 所扮演的角色与上文中的策略类似。与前面一样，状态会生成观测 y。记号上的差别（s, π, o 对比 x, v, y）是为了强调两类变量之间的区别：前者是离散时间中演化的类别变量，后者是连续时间中演化的连续变量。与此类似，从这里开始，我们将用小写 p 和 q 表示连续变量上的概率密度，用大写 P 和 Q 表示类别变量上的概率分布。第 4.4 节和第 4.5 节会更详细地展开这些模型，并展示在每种情形下

最小化自由能如何导出一组描述推断过程动力学的方程。

4.4 离散时间中的主动推断

本节聚焦于上面介绍的离散时间模型。这对于理解一系列涉及类别性推断与替代假设选择的认知过程十分重要。此外，这种形式体系还便于考察经典的利用--探索问题，并说明主动推断如何解决它。

4.4.1 部分可观测马尔可夫决策过程

如图 4.3 所示，POMDP 表达的是一个依赖于策略的隐藏状态序列随时间演化的过程。要形式化地刻画这一过程，我们需要说明图中每个方形因子节点的具体形式。下面先分别描述这些因子，再将它们组合起来，写出构成生成模型的联合分布。

与第 2 章中给出的贝叶斯规则简单例子一样，我们可以把这些因子区分为表示似然的因子，以及共同构成先验的因子。这里的似然与之前相似，它表达的是在给定状态（隐藏量）条件下结果（可观测量）的概率。如果结果与状态都是类别变量，那么似然就是一个类别分布，由一个矩阵 A 参数化：

$$P(o_\tau \mid s_\tau) = \mathrm{Cat}(A) \tag{4.5}$$

$$A_{ij} = P(o_\tau = i \mid s_\tau = j) \tag{4.5}$$

第二行说明了 Cat 记号的含义，也就是类别分布的具体指定方式。这对应于图 4.3 中标记为 “2” 的节点。隐藏状态序列的先验（仍用符号 ˜ 表示序列）则依赖两样东西：初始状态的先验（由向量 D 指定），以及关于状态如何从一个时刻转移到下一个时刻的信念（由矩阵 B 指定）：

$$P(\tilde{s} \mid \pi) = P(s_1) \prod_{\tau=1} P(s_{\tau+1} \mid s_\tau, \pi) \tag{4.6}$$

$$P(s_1) = \mathrm{Cat}(D) \tag{4.6}$$

$$P(s_{\tau+1} \mid s_\tau, \pi) = \mathrm{Cat}(B_\tau^\pi) \tag{4.6}$$

这些对应于图 4.3 中标记为 “3” 的节点。请注意，状态转移在条件上依赖于所选择的策略。因此，我们可以把式（4.6）中的先验与式（4.5）中的似然合在一起，理解为对某个行为序列的模型，也就是策略 π。为了允许我们在这些模型之间作出选择，也就是形成计划，我们还需要一个

关于哪条序列最可能的先验信念。对于一个最小化自由能的生物来说，一种自洽的先验是：那些将在未来带来最低期望自由能 G 的策略，就是最可能的策略：

$$P(\pi) = \mathrm{Cat}(\pi^0) \tag{4.7}$$

$$\pi^0 = \sigma(-G) \tag{4.7}$$

$$G_\pi = G(\pi) = -E_{\tilde{Q}}[D_{KL}[Q(\tilde{s} \mid \tilde{o}, \pi) \,||\, Q(\tilde{s} \mid \pi)]] - E_{\tilde{Q}}[\ln P(\tilde{o} \mid C)] \tag{4.7}$$

$$\tilde{Q} = Q(\tilde{o}, \tilde{s} \mid \pi) = P(\tilde{o} \mid \tilde{s}) Q(\tilde{s} \mid \pi) \tag{4.7}$$

由于这组方程对主动推断具有基础性的重要意义，因此值得更仔细地加以拆解。前两行说明，每个策略的先验概率由参数 π^0 给出，并与该策略对应的负期望自由能有关。softmax 函数 σ 保证归一化，也就是确保所有策略上的概率总和为 1。式（4.7）的最后两行给出了期望自由能的形式。可以注意到，它与自由能的函数形式（式（4.4））非常相似，同样包含结果的对数概率以及一个 KL 散度。关键区别在于，这里的期望是关于后验预测密度来取的，正如最后一个等式所定义的那样。这个分布表达了未来状态与未来观测上的联合概率。最关键的是，这意味着我们能够计算未来的期望自由能，而这一点是变分自由能做不到的，因为后者依赖于当前和过去的观测。

另外还要注意两点：一是结果分布依赖于参数 C；二是 KL 散度项前的符号发生了翻转，而这源于我们是在后验预测概率下取期望。最后这一点容易引发混淆，因此值得明确说明。对于变分自由能而言，KL 散度表示近似后验与精确后验的对数概率之差的期望（式（4.4））。而在期望自由能中，与之对应的项表示的是这样一种差异的期望：即把当前后验信念当作先验使用时，我们基于整条结果轨迹所能得到的精确后验，与近似后验之间的差异。把这一点展开，可以得到：

$$E_{\tilde{Q}}[\ln Q(\tilde{s} \mid \pi) - \ln Q(\tilde{s} \mid \tilde{o}, \pi)] \tag{4.8}$$

$$= E_{Q(\tilde{o}|\pi)}\big[E_{Q(\tilde{s}|\tilde{o},\pi)}[\ln Q(\tilde{s} \mid \pi) - \ln Q(\tilde{s} \mid \tilde{o}, \pi)]\big] \tag{4.8}$$

$$= -E_{Q(\tilde{o}|\pi)}\big[E_{Q(\tilde{s}|\tilde{o},\pi)}[\ln Q(\tilde{s} \mid \tilde{o}, \pi) - \ln Q(\tilde{s} \mid \pi)]\big] \tag{4.8}$$

$$= -E_{Q(\tilde{o}|\pi)}[D_{KL}[Q(\tilde{s} \mid \tilde{o}, \pi) \,||\, Q(\tilde{s} \mid \pi)]] \tag{4.8}$$

这里可以看到，取期望的顺序非常重要。正是这一点使该项相对于变分自由能中的对应项出现了符号反转。这也支撑了两者之间的一个重要区别：期望自由能通过选择那些会导致信念发生较大改变的观测而被最小化；相反，变分自由能则在观测与当前信念相符合时被最小化。这就是对已经获取的数据优化信念（变分自由能最小化），与选择最能优化信念的数据（期望自由能最小化）之间的差别。

这再次说明，主动推断使用了两个数学上相关但功能上不同、又彼此互补的量：变分自由能 F 与期望自由能 G。变分自由能是随时间被主要最小化的量。它相对于一个生成模型来优化，而该生成模型可以包含策略，也就是行动序列。与所有其他隐藏状态一样，主体也必须给策略分配先验概率，因为策略不过是生成模型中的另一个随机变量。主动推断所使用的先验，大体上等价于这样一种信念：主体将在未来最小化自由能，也就是最小化期望自由能。换句话说，期望自由能为策略提供了一个先验，因此它是最小化变分自由能的前提。

在第 2 章中我们已经看到，和变分自由能一样，期望自由能也可以用若干种方式重排，从而揭示不同的解释。这里我们着重讨论把它看作一个策略的风险与歧义之间差异的解释。这与式（4.7）是等价的：

$$G(\pi) = -E_{\tilde{Q}}[D_{KL}[Q(\tilde{s} \mid \tilde{o}, \pi) \,||\, Q(\tilde{s} \mid \pi)]] - E_{\tilde{Q}}[\ln P(\tilde{o} \mid C)] \tag{4.9}$$

$$= E_{\tilde{Q}}[H[P(\tilde{o} \mid \tilde{s})]] + D_{KL}[Q(\tilde{o} \mid \pi) \,||\, P(\tilde{o} \mid C)] \tag{4.9}$$

第一种写法中的两项，分别对应信息增益与务实价值；第二种写法中的两项，则分别对应期望歧义与风险。回忆第 2 章，前一种分解表达了寻求新信息（探索）与寻求偏好观测（利用）之间的权衡。通过最小化期望自由能，这些项的相对大小决定了行为更偏探索还是更偏利用。需要注意的是，务实价值在这里是作为关于观测的先验信念出现的，而该分布的 C 参数可以依照我们希望刻画的系统来选择，以反映该系统的典型结果状态或偏好结果状态。

按照式（4.9）的第二行，我们可以把式（4.7）进一步写成线性代数形式：

$$\pi^0 = \sigma(-G) \tag{4.10}$$

$$G_\pi = H \cdot s_\tau^\pi + o_\tau^\pi \cdot \varsigma_\tau^\pi \tag{4.10}$$

$$\varsigma_\tau^\pi = \ln o_\tau^\pi - \ln C_\tau \tag{4.10}$$

$$H = -\operatorname{diag}(A \cdot \ln A) \tag{4.10}$$

$$P(o_\tau \mid C) = \mathrm{Cat}(C_\tau) \tag{4.10}$$

$$Q(o_\tau \mid \pi) = \mathrm{Cat}(o_\tau^\pi), \qquad o_\tau^\pi = A s_\tau^\pi \tag{4.10}$$

$$Q(s_\tau \mid \pi) = \mathrm{Cat}(s_\tau^\pi) \tag{4.10}$$

$$Q(s_\tau) = \mathrm{Cat}(s_\tau), \qquad s_\tau = \sum_\pi \pi\, s_\tau^\pi \tag{4.10}$$

式（4.10）的第一行使用 softmax（归一化指数）算子，从期望自由能向量构造出一个总和为 1 的概率分布，其充分统计量为 π^0。第二到第四行用线性代数记号表达了期望自由能的各个组成部分。第五行说明关于观测的先验信念是一个类别分布，其充分统计量由向量 C 给出。第六到第八行则说明了这些线性代数量与相应概率分布之间的关系。

在完成了生成模型的说明之后，我们现在可以用上述变量写出自由能：

$$F = \pi \cdot F_\pi \tag{4.11}$$

$$F_\pi = \sum_\tau F_{\pi\tau} \tag{4.11}$$

$$F_{\pi\tau} = s_\tau^\pi \cdot \left(\ln s_\tau^\pi - \ln A \cdot o_\tau - \ln B_\tau^\pi s_{\tau-1}^\pi\right) \tag{4.11}$$

之所以能把自由能分解为对时间的求和，是因为这里隐含采用了均值场近似，也就是假定近似后验可以因子化为多个因子的乘积：

$$Q(\tilde{s} \mid \pi) = \prod_\tau Q(s_\tau \mid \pi) \tag{4.12}$$

在对数形式下，这就变成一个求和，正如式（4.11）所示。这种因子化只是变分推断中众多可能方案中的一种，而且是其中最简单的选项。在实践中，人们通常会作出一些细微修正，附录 B 会对此进行说明。

4.4.2 POMDP 中的主动推断

到目前为止，我们已经定义了离散时间生成模型的四个关键成分：似然 A、转移概率 B、关于观测的先验信念 C，以及关于初始状态的先验信念 D。一旦这些概率分布被指定，就可以使用

一种通用的消息传递方案来最小化自由能，并求解该 POMDP。为了在给定策略下对隐藏状态进行推断，我们令一个辅助变量 v 的变化率等于自由能梯度的负值。这个辅助变量相当于对数后验 s 的替身。随后，再通过 softmax（归一化指数）函数由 v 计算出 s：

$$s_\tau^\pi = \sigma(v_\tau^\pi) \tag{4.13}$$

$$\dot{v}_\tau^\pi = \varepsilon_\tau^\pi - \nabla_s F_{\pi\tau} \tag{4.13}$$

$$= \ln A \cdot o_\tau + \ln B_\tau^\pi s_{\tau-1}^\pi + \ln {B_{\tau+1}^\pi}^\top s_{\tau+1}^\pi - \ln s_\tau^\pi \tag{4.13}$$

式（4.13）可以被视为变分消息传递的一个例子（见框 4.1）。为了更新关于策略的信念，我们求取那个使自由能最小的后验：

$$\nabla_\pi F = 0 \Leftrightarrow \pi = \sigma(-G - F) \tag{4.14}$$

对于最简单形式的 POMDP，式（4.13）与式（4.14）已经足以用来求解任意一组概率矩阵下的主动推断问题；这些矩阵可以分别被看作对知觉与规划的描述。在本书后半部分，我们会进一步展开这一点，并给出主动推断用于知觉、规划以及其他认知功能的具体示例。

图 4.4 对式（4.10）、式（4.13）和式（4.14）所作的图形化表示，还暗示了自由能最小化在大脑中的一种可能神经元实现方式，只要我们把节点解释为神经元群体，把边解释为突触，把消息解释为突触交换即可。在后面的章节里，我们会进一步讨论这一方案如何扩展到因子化状态空间、深层时间模型，以及生成模型自身参数的优化，也就是学习。

框 4.1 信息传递与推断　马尔可夫毯

我们在第 3 章已经遇到过马尔可夫毯这一概念，但这里仍值得简要回顾，因为它与由多个相互作用变量构成的系统有关。某个变量的马尔可夫毯，是与该变量相互作用的一组变量子集。如果我们已经完全知道这个子集，那么再知道这组变量之外的任何东西，都不会增加我们对该目标变量的知识。在这里，它的重要性在于：在图模型中，我们只需基于某个变量马尔可夫毯中的局部信息，就可以对这个变量作出推断。变量 x 的马尔可夫毯包括：导致 x 的变量，也就是其父节点 $\rho(x)$；由 x 导致的变量，也就是其子节点 $\kappa(x)$；以及 x 的子节点的父节点。用这一记号，下面给出两种最常用的、用于近似推断的贝叶斯消息传递方案。

变分消息传递

$$\ln Q(x) = E_{Q(\rho(x))}[\ln P(x \mid \rho(x))] + E_{Q(\kappa(x))Q(\rho(\kappa(x)))}[\ln P(\kappa(x) \mid \rho(\kappa(x)))] - Q(x) \tag{4.1}$$

这里的消息来自 x 的马尔可夫毯的全部组成部分，包括父节点（通过在父节点条件下 x 的条件概率）和子节点。后者取决于这样一个条件概率：x 的子节点在其全部父节点条件下的概率，而这些父节点中也包括 x。需要注意的是，期望中包含子节点及其父节点。由于这些父节点里包含 x，我们需要除以 $Q(x)$，以确保期望只覆盖其马尔可夫毯。

信念传播

$$\ln Q(x) = \ln \mu_{\kappa(x)} + \ln \mu_{\rho(x)} \tag{4.2}$$

$$\mu_{\kappa(x)} = E_{\mu_{\kappa(\kappa(x))}\mu_{\rho(\kappa(x))}} \left[\frac{P(\kappa(x) \mid \rho(\kappa(x)))}{\mu_x(\kappa(x))} \right] \tag{4.3}$$

$$\mu_{\rho(x)} = E_{\mu_{\rho(\rho(x))}\mu_{\kappa(\rho(x))}} \left[\frac{P(x \mid \rho(x))}{\mu_x(\rho(x))} \right] \tag{4.4}$$

这一方案在总体结构上与变分消息传递相似，但它使用的是递归定义的消息：每一条消息（$\mu_a(b)$ 表示从 a 发送到 b 的消息）都依赖于其他消息，也就是发送到 a 的消息。这里具有方向性，因此从 a 到 b 的消息依赖于所有发送到 a 的消息，但不包括来自 b 的那一条，所以期望中会出现相应的除法项。

这里稍微非标准地使用期望算子，是为了同时满足两点：第一，覆盖离散变量与连续变量两种情形；第二，突出变分消息传递与信念传播在形式上的相似性。

4.5 连续时间中的主动推断

上一节中，我们讨论了主动推断在某一特定生成模型选择下所呈现的形式。这些 POMDP 对于刻画规划与决策等推断问题非常有用。然而，当我们面对真实环境中的交互时，仅用离散时间和类别变量来描述的模型就显得不足了。原因在于，感觉输入与运动输出本身是连续演化的变量。为了处理这一点，我们现在转向另一类生成模型。我们将把完全相同的思想，即对变分自由能作梯度下降，应用到这些模型上，以得到与之对应的消息传递方案。

4.5.1 用于预测编码的生成模型

为了引出连续状态所使用的生成模型形式，我们从下面这对方程开始：

$$\dot{x} = f(x, v) + \omega_x \tag{4.15}$$

$$y = g(x, v) + \omega_y \tag{4.15}$$

第一条方程表示一个隐藏状态如何随时间演化：它由一个确定性函数 $f(x,v)$ 与随机涨落 ω_x 共同决定。第二条方程表示数据是如何由该隐藏状态生成的。在这两种情况下，涨落都被假定为服从正态分布，因此对应的动力学概率密度与似然概率密度为：

$$p(\dot{x} \mid x, v) = \mathcal{N}(f(x,v), \Pi_x) \tag{4.16}$$

$$p(y \mid x, v) = \mathcal{N}(g(x,v), \Pi_y) \tag{4.16}$$

精度项 Π 是这些涨落协方差的逆矩阵。这两条方程构成了 Kalman–Bucy 滤波器在工程中所依据的生成模型。然而，这类方案受限于这样一个假设：不同时间上的涨落彼此不相关，也就是 Wiener 假设。这对生物系统中的推断并不合适，因为在生物系统中，涨落本身也是由动力系统生成的，因此具有一定平滑性。为了刻画这一点，我们不仅要考虑隐藏状态变化率与当前数据值本身，还要考虑它们的速度、加速度以及更高阶时间导数，也就是运动的广义坐标（Friston, Stephan et al. 2010；见框 4.2）：

$$\dot{x} = f(x,v) + \omega_x, \qquad y = g(x,v) + \omega_y \tag{4.17}$$

$$\dot{x}' = f'(x',v') + \omega_x', \qquad y' = g'(x',v') + \omega_y' \tag{4.17}$$

$$\dot{x}'' = f''(x'',v'') + \omega_x'', \qquad y'' = g''(x'',v'') + \omega_y'' \tag{4.17}$$

$$\dot{\tilde{x}}^{[i]} = f^{[i]}(\tilde{x}^{[i]}, \tilde{v}^{[i]}) + \omega_x^{[i]}, \qquad \tilde{y}^{[i]} = g^{[i]}(\tilde{x}^{[i]}, \tilde{v}^{[i]}) + \omega_y^{[i]} \tag{4.17}$$

这些广义坐标可以更简洁地总结为：把一条轨迹（仍用 ˜ 记号）表示为一个向量，其各元素对应于上述连续的各阶导数：

$$D\tilde{x} = \tilde{f}(\tilde{x}, \tilde{v}) + \tilde{\omega}_x, \qquad p(\tilde{x} \mid \tilde{v}) = \mathcal{N}(D\tilde{x} \mid \tilde{f}, \tilde{\Pi}_x) \tag{4.18}$$

$$\tilde{y} = \tilde{g}(\tilde{x}, \tilde{v}) + \tilde{\omega}_y, \qquad p(\tilde{y} \mid \tilde{x}, \tilde{v}) = \mathcal{N}(\tilde{y} \mid \tilde{g}, \tilde{\Pi}_y) \tag{4.18}$$

在式（4.18）中，D 是一个主对角线上方全为 1、其余元素为 0 的矩阵。它会把向量的各个元素整体向上平移，因此可以被看作一个导数算子。广义精度矩阵则可以根据我们对涨落平滑性的假设来构造，附录 B 会给出具体说明。再配合一个关于隐藏原因 v 的先验，下面我们就可以为这一生成模型写出自由能。这个先验的作用稍后会变得更清楚：

$$F[\mu, y] = -\ln p(\tilde{y}, \tilde{\mu}_x, \tilde{\mu}_v) = \frac{1}{2}\tilde{\varepsilon}^\top \tilde{\Pi} \tilde{\varepsilon} \tag{4.19}$$

$$= \frac{1}{2}\left(\tilde{\varepsilon}_y^\top \tilde{\Pi}_y \tilde{\varepsilon}_y + \tilde{\varepsilon}_x^\top \tilde{\Pi}_x \tilde{\varepsilon}_x + \tilde{\varepsilon}_v^\top \tilde{\Pi}_v \tilde{\varepsilon}_v\right) \tag{4.19}$$

$$\tilde{\varepsilon} = \begin{bmatrix} \tilde{\varepsilon}_y \\ \tilde{\varepsilon}_x \\ \tilde{\varepsilon}_v \end{bmatrix} = \begin{bmatrix} \tilde{y} - \tilde{g}(\tilde{\mu}_x, \tilde{\mu}_v) \\ D\tilde{\mu}_x - \tilde{f}(\tilde{\mu}_x, \tilde{\mu}_v) \\ \tilde{\mu}_v - \tilde{\eta} \end{bmatrix} \tag{4.19}$$

$$\tilde{\Pi} = \begin{bmatrix} \tilde{\Pi}_y & 0 & 0 \\ 0 & \tilde{\Pi}_x & 0 \\ 0 & 0 & \tilde{\Pi}_v \end{bmatrix} \tag{4.19}$$

在式（4.19）中，μ 项表示关于 x 和 v 的近似后验密度的众数。之所以自由能在第一行中具有如此简单的形式，是因为我们采用了 Laplace 近似，详见框 4.3。简单地说，这一近似把所有概率密度都视为高斯分布；通过泰勒级数展开来看，这等价于假定我们正在分布众数附近工作。第二行则用按精度加权的平方预测误差来表达对数概率。这里省略了所有相对于后验众数为常数的项。第三行则进一步把这一表达式展开成对数似然、x 在给定 v 条件下的对数概率，以及 v 的对数先验。

框 4.2 运动的广义坐标 为了在连续时间中表示一条轨迹，运动的广义坐标提供了一种简单的参数化方案。它基于围绕当前时刻所作的多项式（泰勒级数）展开，从而得到一个函数，使我们可以向近过去和近未来进行外推。图 4.5 中的曲线用实线表示空间中的某条轨迹 x 随时间 τ 的变化。从左到右，这些图依次展示了只用一个、两个和三个广义坐标（即 x 的连续高阶时间导数）来表示该轨迹时的近似结果，虚线即为这种近似。这里的展开围绕初始时刻进行。每多加入一个广义坐标，就能更准确地逼近近未来中的轨迹。在多数应用中，大约使用六个广义坐标就已足够。

$$x(\tau) \approx x_0 \tag{4.5}$$

$$x(\tau) \approx x_0 + \tau x_0' \tag{4.6}$$

$$x(\tau) \approx x_0 + \tau x_0' + \frac{1}{2}\tau^2 x_0'' \tag{4.7}$$

4.5.2 作为带有运动反射的预测编码的主动推断

在 Laplace 近似下，由于近似后验的方差是众数的解析函数，我们就可以直接针对众数来优化自由能。一种简单的理解方式是：我们只需要为每个状态找到最大后验（MAP）估计。[2] 这些估计是后验分布的均值，而且在 Laplace 近似下，一旦知道众数，就可以直接为其配上精度，而无需进一步推断（见框 4.3）。

$$\dot{\tilde{\mu}} - D\tilde{\mu} = -\nabla_{\tilde{\mu}} F \tag{4.20}$$

$$= \nabla_{\tilde{\mu}} \ln p(\tilde{y}, \tilde{\mu}) = -\nabla_{\tilde{\mu}} \tilde{\varepsilon}^\top \tilde{\Pi} \tilde{\varepsilon} \tag{4.20}$$

$$\begin{bmatrix} \dot{\tilde{\mu}}_x - D\tilde{\mu}_x \\ \dot{\tilde{\mu}}_v - D\tilde{\mu}_v \end{bmatrix} = \begin{bmatrix} \nabla_{\tilde{\mu}_x} \tilde{g}^\top \tilde{\Pi}_y \tilde{\varepsilon}_y - D^\top \tilde{\Pi}_x \tilde{\varepsilon}_x + \nabla_{\tilde{\mu}_x} \tilde{f}^\top \tilde{\Pi}_x \tilde{\varepsilon}_x \\ \nabla_{\tilde{\mu}_v} \tilde{g}^\top \tilde{\Pi}_y \tilde{\varepsilon}_y + \nabla_{\tilde{\mu}_v} \tilde{f}^\top \tilde{\Pi}_x \tilde{\varepsilon}_x - \tilde{\Pi}_v \tilde{\varepsilon}_v \end{bmatrix} \tag{4.20}$$

与我们在离散时间方案中看到的梯度下降不同，式（4.20）左边表示的是 μ 的变化率与导数算子作用在 μ 上的差。这是因为在自由能最小化点，如果与变化率相对应的后验众数不为零，那么后验众数本身的变化率就不应该为零。换言之，在自由能达到最小值时，“众数的运动应当等于运动的众数”。这保证了在自由能最小化时，$\dot{\mu}^{[i]} = \mu^{[i+1]}$。

我们还可以比式（4.20）更进一步，把隐藏原因 v 看成是由更高层级生成的数据，而且其动力学更慢，因此在较低层级上看起来几乎不发生变化。这样一来，我们就可以把一整个层级链式连接起来：

$$\begin{bmatrix} \dot{\tilde{\mu}}_x^{(i)} - D\tilde{\mu}_x^{(i)} \\ \dot{\tilde{\mu}}_v^{(i)} - D\tilde{\mu}_v^{(i)} \end{bmatrix} = \begin{bmatrix} \nabla_{\tilde{\mu}_x^{(i)}} \tilde{g}^{(i)\top} \tilde{\Pi}_v^{(i-1)} \tilde{\varepsilon}_v^{(i-1)} - D^\top \tilde{\Pi}_x^{(i)} \tilde{\varepsilon}_x^{(i)} + \nabla_{\tilde{\mu}_x^{(i)}} \tilde{f}^{(i)\top} \tilde{\Pi}_x^{(i)} \tilde{\varepsilon}_x^{(i)} \\ \nabla_{\tilde{\mu}_v^{(i)}} \tilde{g}^{(i)\top} \tilde{\Pi}_v^{(i-1)} \tilde{\varepsilon}_v^{(i-1)} + \nabla_{\tilde{\mu}_v^{(i)}} \tilde{f}^{(i)\top} \tilde{\Pi}_x^{(i)} \tilde{\varepsilon}_x^{(i)} - \tilde{\Pi}_v^{(i)} \tilde{\varepsilon}_v^{(i)} \end{bmatrix} \tag{4.21}$$

$$\begin{bmatrix} \tilde{\varepsilon}_x^{(i)} \\ \tilde{\varepsilon}_v^{(i)} \end{bmatrix} = \begin{bmatrix} D\tilde{\mu}_x^{(i)} - f^{(i)}(\tilde{\mu}_x^{(i)}, \tilde{\mu}_v^{(i)}) \\ \tilde{\mu}_v^{(i)} - g^{(i+1)}(\tilde{\mu}_x^{(i+1)}, \tilde{\mu}_v^{(i+1)}) \end{bmatrix} \tag{4.21}$$

$$\tilde{\varepsilon}_v^{(0)} \equiv \tilde{\varepsilon}_y \tag{4.21}$$

图 4.6 从图形上强调了隐藏状态 x 在单一层级内连接不同时间导数的作用，以及隐藏原因 v 在不同层级之间建立联系的作用。在这一预测编码方案中（Rao and Ballard 1999, Friston and Kiebel 2009），更高层会向更低层发送向下的预测；较低层则计算这些预测的误差，并把误差沿层级向上传回，以更新信念。

为了完成我们对主动推断语境下预测编码的概览，还需要把行动纳入进来。既然我们的目标是最小化自由能，而行动的后果正是改变我们的感觉数据，那么便有：

[2] 也就是在后验分布下最可能的值。

$$\dot{u} = -\nabla_u F \tag{4.22}$$

$$= -\nabla_u \tilde{y}(u)^\top \tilde{\Pi}_y \tilde{\varepsilon}_y \tag{4.22}$$

这条方程告诉我们：我们通过行动来最小化自由能，而在自由能中，唯一直接依赖于行动的部分，是最低层的预测误差。换言之，行动只是通过最小化行动所导致的感觉后果与预测感觉后果之间的误差，来实现向下传递的感官预测。一个理解这一点的方式是：仿佛我们给预测编码方案的最低层加上了经典的反射弧（Adams, Shipp, and Friston 2013）。在这种设置里，主动推断就是“预测编码加上反射弧”。

从神经生物学角度看，其思想是：感觉传入纤维进入脑干或脊髓，并与运动神经元形成突触。关于感觉输入的向下预测从皮层传递到运动神经元，而后者的输出则取决于其皮层输入与感觉输入之间的差异。

从计算角度看，反射弧是最简单的一类控制器之一；它们负责纠正预期本体感觉信号与实际本体感觉信号之间的偏差。更复杂的运动行为，则要求生成一串预测，并依次通过反射弧去实现它们。正是这一机制，使主动推断不同于生物运动控制中的其他方案，例如最优控制。那些方案并不建立在预测编码基础上，而且它们需要逆模型以及比反射弧更复杂的控制器（Friston 2011）。主动推断还有一个特殊之处：它抛弃了最优控制与强化学习中常见的价值或代价概念，而是把这些内容完全吸收到先验这一通常更具表达力的概念之中（第 10 章会对此作进一步讨论）。

框 4.3 Laplace 近似 Laplace 近似所依赖的原则，与框 4.2 中介绍的运动广义坐标在思路上是相似的。基本想法是：自由能可以在后验众数 μ 附近用二次展开来近似。在一维情况下，可以写成：

$$F[y,q] = E_{q(x)}[\ln q(x) - \ln p(y,x)] \tag{4.8}$$

$$\approx E_{q(x)}\left[\ln q(\mu) + (x-\mu)\partial_x \ln q(x)|_{x=\mu} + \frac{1}{2}(x-\mu)^2\partial_x^2 \ln q(x)|_{x=\mu} - \ln p(y,\mu) - (x-\mu)\partial_x \ln p(y,x)|_{x=\mu} - \frac{1}{2}(x \tag{4.9}$$

这里假定二次展开已经足够，等价于说我们可以把这些概率都视为高斯分布，因为高斯密度的对数正是二次形式。把这一点写得更明确，就能把上式简化为：

$$q(x) = \mathcal{N}(\mu, \Sigma^{-1}) \tag{4.10}$$

$$F[y,\mu] = -\ln 2\pi\Sigma - \ln p(y,\mu) - \mathrm{tr}\left[\Sigma\, \partial_x^2 \ln p(y,x)|_{x=\mu}\right] \tag{4.11}$$

在二次假设下，唯一依赖于众数的项是第二项。去掉其余项，就得到式（4.19）中的表达。并且，一旦知道众数，我们还可以直接得到近似后验的精度：

$$\ln q(x) \approx \ln p(x \mid y) = \ln p(x, y) - \ln p(y) \tag{4.12}$$

$$\approx \ln p(\mu, y) + (x-\mu)^\top \partial_x \ln p(x, y)|_{x=\mu} + \frac{1}{2}(x-\mu)^\top \partial_x^2 \ln p(x, y)|_{x=\mu}(x-\mu) - \ln p(y) \tag{4.13}$$

$$\Rightarrow q(x) \propto e^{-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)}, \qquad \Sigma^{-1} = -\partial_x^2 \ln p(x, y)|_{x=\mu} \tag{4.14}$$

这告诉我们，后验精度就是在后验众数处对联合概率取二阶导数所得的结果。

4.6 总结

本章概述了支撑主动推断的基本形式化思想。最重要的信息是：（近似）贝叶斯推断可以被表述为对一个称为变分自由能的量进行最小化。

第五章　消息传递与神经生物学

“从根本上说，动物大致分为两类：动物，以及没有大脑的动物；后者被叫作植物。植物不需要神经系统，因为它们不会主动移动，它们不会把根拔起来，在森林大火中逃跑！任何能够主动移动的东西都需要神经系统；否则它很快就会死亡。”

——Rodolfo Llinas

5.1　引言

在第 4 章中，我们已经看到，对于两类生成模型，变分推断分别采取怎样的形式。本章聚焦于这些推断动力学所对应的过程理论：也就是解释大脑可能如何实现变分推断的理论。在这种贝叶斯信念更新的实现中，核心概念是贝叶斯消息传递，它涵盖了信念传播、变分消息传递以及其他相关方案。这些方案背后的基本思想是：并不是所有东西都直接依赖于所有其他东西。相反，生成模型中的每个变量只依赖于相对较少的其他变量。类似地，大脑也表现出稀疏的连接结构，其中任一神经元的活动只依赖于那些与它共享突触连接的神经元。本章关注的是，如何把与变分推断相关的稀疏消息传递，映射到生物计算中的稀疏连接结构上。

让我们暂时从第 4 章的技术细节后退一步，把注意力转向主动推断所伴随的过程理论。必须区分一个原理，也就是自由能最小化，与关于这一原理如何在某类系统中得到实现的过程理论，例如它如何在大脑中被实现。后者使我们能够提出可以接受经验数据检验的假设。为了讨论主动推断可能如何在大脑中显现，我们把第 4 章末尾看到的消息传递等同于突触通信，把梯度下降动力学等同于神经元活动。本章有两个目标：一方面，向具有技术背景的读者介绍主动推断的神经生物学；另一方面，向生物学家强调理论对于实践神经科学的意义。我们强调，本章并不打算给出关于主动推断过程理论的最终定论（Pezzulo, Rigoli, and Friston 2015, 2018; Friston and Buzsaki 2016; Friston and Herreros 2016; Friston, FitzGerald et al. 2017; Friston, Parr et al. 2017; Parr and Friston 2018b; Parr, Markovic et al. 2019）；它只是目前看来与现有证据最一致的一种解释。我们的目的也不是为某一个特定的过程理论背书，而是说明第 1–4 章提出的思想，如何被用于构造能够接受神经生物学测量检验的假设。

本章结构如下。首先，在第 5.2 节，我们讨论皮层微回路的作用。它是由若干彼此连接的神经元群体构成的功能单元，而这种连接模式在许多皮层区域中都会重复出现。我们将强调这种定型化回路与图 4.4 和图 4.6 中消息传递架构之间的关系，而后者本身也会在层级各层上反复出现。在第 5.3 节，我们转向效应系统，并讨论在主动推断框架下如何表述运动控制。这里处理的是

运动皮层如何调节脊髓和脑干的反射弧，以生成有目的的行为。第 5.4 节将简要涉及丘脑、基底神经节等皮层下结构，它们在规划与决策中发挥重要作用。随后，在第 5.5 节，我们讨论突触效能的调制，包括神经递质在精度优化中的作用，以及学习中的可塑性变化。最后，在第 5.6 节，我们回到层级这一主题，并讨论决策与动作生成之间的关系。

5.2 微回路与消息

在第 4 章中，我们已经看到，介导变分推断的信念更新方程可以被解释为一种神经元网络。前面给出的连续模型与分类模型的推断方案，都会产生一种定型化回路，而这种结构会在层级式生成模型中重复出现。与此类似，大脑皮层的结构也具有一种定型化架构（Shipp 2007）。新皮层被划分为六层，或称板层，从表浅层（靠近脑表面）到深层（更接近皮层下白质）编号。每一层都以特定的细胞类型和连接模式为特征（Zeki and Shipp 1988; Felleman and Van Essen 1991; Callaway and Wiser 2009）；这些连接关系在图 5.1 的单个皮层柱示意图中得到了概括。

一个脑区中的皮层柱会与其他脑区的皮层柱以及皮层下结构发生连接。皮层区域通常被描绘为一个层级结构；粗略地说，最接近感觉输入或运动输出的区域位于层级的底部。随着我们远离这些区域，例如从初级视觉皮层走向次级视觉皮层，我们就在层级中向上移动。之所以能够提出这样的层级概念，是因为图 5.1 所示的层特异性连接结构。来自较低级皮层区域或感觉性（初级）丘脑核团的上行投射，往往指向第 IV 层的棘状星形细胞。较低级皮层区域的上行连接来源于其表浅锥体细胞，即第 II 和 III 层。来自较高级皮层区域的下行投射，会同时指向较低级区域的表浅层和深层，其来源则是深层，即第 VI 层的锥体细胞。此外，第 V 层中的深层锥体细胞（Betz 细胞）还会投射到其他靶点，包括基底神经节、次级丘脑核团等皮层下核团，以及脊髓运动神经元。

图 5.1 中间的示意图展示了一种可能的映射方式，即如何把预测编码网络（图 4.4）映射到皮层的层状解剖结构上（Friston, Parr, and de Vries 2017）。这一图有些复杂，但关键点如下：进入第 IV 层棘状星形细胞的上行输入，对应于隐藏原因的预测误差 $\epsilon_v^{(i)}$。来自第 III 层表浅锥体细胞的上行输出，则把同样的预测误差传递给层级中的上一层，即 $\epsilon_v^{(i+1)}$。下行输入表示来自更高层的预测 $g^{(i+1)}$，而下行输出表示对更低层的预测 $g^{(i)}$。在最低层，我们看到来自第 V 层的下行预测，这与左图中通向脊髓运动神经元的输出一致。我们将在第 5.3 节回到这一点。回忆第 4 章，隐藏原因的作用是把一个在多个不同时间尺度上运行的模型的各层级连接起来。这与隐藏状态不同，后者的作用是在某一特定时间尺度上形成动力学，这一点与图 5.1 中柱内的内在连接作用是一致的。

消息传递中的不对称性十分重要，因为它为上行活动与下行活动之间的差异提供了经验预测。其中一个预测是：我们可以预期这些消息由不同时间频率的神经活动来传递。原因在于，从期望计算预测误差所需的运算是非线性的（Friston 2019b）。这种非线性来自使用非线性函数 g 来计算预测，而这通常会提高信号频率，例如对正弦波求平方会使频率翻倍。因此，一个可检验的预测是：来自误差单元的上行消息，可能出现在比来自期望单元的下行消息更高的频段中，如图 5.2 所示。这与实测到的频谱不对称性是一致的：上行连接通常与 γ 频段相关，而下行连接则更常与 α 或 β 频段相关（Arnal and Giraud 2012; Bastos, Litvak et al. 2015）。

图 5.1 右侧的示意图，则给出了把 POMDP 模型的消息传递解释为一种皮层微回路的方式。它与预测编码架构具有类似结构：期望 s 由表浅和深层锥体细胞表示，并在皮层层级中向上和向下传播。此外，第 IV 层中的误差单元 ϵ 接收上行信号。不同于预测编码式架构的是，区域之间传递的消息是期望的混合，而不是误差（Friston, Rosch et al. 2017; Parr, Markovic et al. 2019）。不过，通过更新期望来最小化误差，也就是自由能梯度，这一总体结构仍然保持不变。这种消息传递区分了以策略为条件的期望（下标 π）与在各策略下平均后的期望。要从前者转换到后者，我们还需要关于策略的后验信念 π。我们会在第 5.4 节回到这一点；此处值得先指出的是，这种消息传递与某些皮层下结构投向皮层表浅层的事实是相容的，而这些皮层下结构可能正是用来计算这些信念的。

在图 5.1 中，要注意左图的解剖结构与中图、右图的消息传递方案之间并不存在一一对应关系。例如，中图与左图之间似乎存在一个差异：左图中进入该皮层柱的下行输入到达第 II 层和第 IV 层，而中图中对应的目标却是第 III 层。这表明，消息传递方案所蕴含的连接，并不一定体现为单一突触。指向第 III 层的下行抑制性连接，可能是通过如下组合来实现的：先有一条兴奋性投射到达第 IV 层的抑制性中间神经元，再由这些中间神经元投射到第 III 层。这个双突触通路就解决了两种架构之间看似存在的矛盾。

在第 5.3 节和第 5.4 节，我们将分别讨论第 V 层神经元在运动和规划中的作用，它们对应于通向脊髓（或脑干）与皮层下结构的投射。到了第 5.5 节和第 5.6 节，我们将讨论神经消息传递如何随时间被调制，并回到分类推断与连续推断这两类微回路之间的关系。

5.3 运动指令

图 5.1 左侧示意图表明，皮层第 V 层投射到脊髓锥体神经元，而这可以被解释为一种预测（Adams, Shipp, and Friston 2013）。图 5.3 将这一点进一步展开，展示了这一回路在脊髓中的组成部分。我们看到，一个基于初级运动皮层第 V 层 Betz 细胞所编码期望的预测，被送出并下传。该预测与传入脊髓背角的本体感觉输入相减，结果得到本体感觉预测误差。这一误差驱动肌肉活动，而肌肉活动又会导致这一误差自身被消除，因为本体感觉数据会改变，从而与预测相一致。把运动命令看作一种预测，是主动推断的核心思想之一，因为它凸显了行动与知觉之间的对偶性。行动这一部分，就是通过改变感觉数据来最小化预测与感觉数据之间的任何不一致。这意味着，要生成一个动作，我们唯一需要的，就是去预测：如果这个动作被执行，将会出现什么样的感觉后果。正因为本体感觉预测误差总是可以通过反射而非信念更新来解决，这也许解释了为什么初级运动皮层第 IV 层中颗粒细胞相对稀少（Shipp, Adams, and Friston 2013）。

这种运动控制的一个重要方面，是所谓的感觉衰减（Brown et al. 2013）。考虑这样一个问题：我们如何启动一个新动作？要做到这一点，我们必须能够预测“自己正在移动”。然而，在我们真正开始移动之前，手头的本体感觉数据其实与这一假设相矛盾，因此可能促使我们修正它。因此，我们需要一种机制，能够阻止感觉数据去更新我们的期望，好让我们在最初事实上仍然为假的情况下，也能保持“我正在移动”这一信念，并最终通过行动把它实现出来，这与观念运动现象相呼应。其含义是，我们必须能够通过降低本体感觉数据的增益，把注意力从这些数据上移开。从技术上说，这个增益由这些数据被预测时所对应的精度，也就是方差的倒数，来给定。

要实现这种衰减，我们就需要下行运动通路不仅预测数据本身，还要预测这些数据的精度，或者说对这些数据赋予的信心，并在启动动作时降低这种精度。这就是所谓的感觉衰减。它可以被看作感觉注意的补足面，使我们有能力忽略某些预测误差，例如由扫视眼动产生的误差；在这种情形下，感觉衰减被称为扫视抑制。无法正常衰减被认为是多种神经系统和精神病理综合征的核心机制，包括被动体验现象（Pareés et al. 2014），以及更极端的精神分裂症紧张状态和帕金森病中的动作启动失败。

5.4 皮层下结构

除了投向脊髓之外，皮层第 V 层还会投射到若干其他结构，其中之一便是纹状体（Shipp 2007; Wall et al. 2013）。纹状体位于大脑深部，由尾状核和壳核构成，是一组复杂网络即基底神经节的输入核团。中型棘状神经元是纹状体的功能单元，它们接收来自皮层的输入，并投射到基底神经节的其他核团。这些神经元分为两类：表达 D1 多巴胺受体的，以及表达 D2 受体的。多巴胺会增强前者的活动，并减弱后者的活动。前者构成了基底神经节中的直接通路，通过一次抑制性突触与输出核团，即苍白球内侧部和黑质网状部，相连接。D2 细胞则形成间接通路，其路径稍微更复杂，包含两次抑制性突触和一次兴奋性突触。纹状体抑制苍白球外侧部，而后者又抑制丘脑底核（STN）。丘脑底核再投射到基底神经节的输出核团。因此，输出核团受到直接通路的抑制，而受到间接通路的去抑制。由于这些输出核团本身也是抑制性的，所以激活表达 D1 的纹状体神经元，净效果就是解除对行为的抑制；而表达 D2 的神经元则会压制这种行为（Freeze et al. 2013）。

既然我们已经把投向脊髓的投射解释为本体感觉预测，那么皮层第 V 层投向纹状体的投射，又应该对应什么样的消息呢？观察图 5.1 可以得到一种可能的答案。在这一层中，预测结果 o 与偏好结果和预测结果之间的差异 ς 一起出现，二者结合起来计算某一策略的期望自由能 G。把这一计算放在纹状体中，是与“基底神经节参与规划”这一观念相一致的，也就是它评估不同的行动方案。图 5.4 展示了一种可能的映射方式：如何把策略评估的消息传递映射到基底神经节的解剖结构上。

从图 5.4 中应当抓住的关键点是，正如第 4 章所述，关于策略的后验概率 π，在图中显示于苍白球内侧部，是根据这些策略的期望自由能来计算的。这一模式沿着直接通路传播：从皮层第 V 层出发，经由纹状体，到达基底神经节输出核团。不过，其中还有一些额外的细节。在图 4.4 左侧的层级架构中，我们看到，高层状态上的期望能够影响低层策略上的信念。图 5.4 左侧对此作了展示：高层状态下的期望观测，被用来形成经验先验 E，这些先验会独立于期望自由能而影响策略选择。我们将在第 7 章回到这一点，但核心思想是：在特定情境下，我们会对自己如何行动持有某种信念。当我们再次处于同样情境时，这些先验期望往往会对策略评估形成偏置，这很像习惯的形成。从这个意义上说，E 与 G 的影响可以分别被理解为习惯驱动与目标导向驱动。在强化学习中（Lee et al. 2014），它们有时分别被称为“无模型”与“有模型”系统。[1] 如果把它们分别与基底神经节的直接通路和间接通路对应起来，就会产生一个有趣后果：这意味

[1]这里的“无模型”和“有模型”并不是说前者完全没有内部模型，而是指其行为更依赖经验累积的先验偏置，后者则更依赖对结果与路径的显式评估。

着，多巴胺会调节这两种驱动之间的平衡。请记住，多巴胺倾向于促进直接通路，从而推动特定策略的执行（Moss and Bolam 2008），而这些策略大概正是那些具有最低期望自由能的策略。相反，在低多巴胺状态下，我们也许更应预期由间接通路承载的、对情境敏感的先验会占优势，而它们的作用正是在特定情境中压制那些不可信的策略。从某种意义上说，纹状体中的多巴胺可以被看成是在调节“推断该做什么”与“推断不该做什么”之间的平衡（Parr 2020）。

上述解释与多巴胺系统受到扰动时的表现是一致的。严重帕金森病中的多巴胺耗竭，会导致运动不能，也就是无法执行特定策略；而外源性多巴胺激动剂则会促进冲动性行为（Frank 2005; Galea et al. 2012; Friston, Schwartenbeck et al. 2014）。此外，这也与基底神经节功能的概念模型相一致。例如，Nambu（2004）提出，直接通路会造成对苍白球内侧部快速而聚焦的抑制，随后出现广泛而缓慢的兴奋，这分别导致基底神经节靶结构的兴奋和抑制。这被认为能够形成一种“中心-周边”式模式，从而促进高特异性的运动程序。这与如下图景是一致的：快速过程通过计算期望自由能来促进动作，而较慢通路提供的更广泛情境化信息，则用于传递经验先验。

关于图 5.4 最后还需要指出的是：同一个基底神经节回路，接收到了来自皮层层级两个层次的输入，上标对此作了区分。这暗示了这样一种情况：在指向间接通路神经元时，来自时间上较慢区域的影响占优；而直接通路则同时受到快与慢两种影响。随着我们在皮层层级中向上移动，神经元通常会表征更慢的动力学。例如，我们预期额叶皮层区域表征的时间尺度会长于顶叶区域。这与皮层输入在基底神经节各通路上的解剖分布相一致（Wall et al. 2013）。这种在间接通路中的时间粗粒化，还伴随着空间上的粗粒化：直接通路的中型棘状神经元具有更大的树突分支范围（Gertler et al. 2008），从而能够实现更精细的调节。因此，图 5.4 所示的解剖构造，同时得到了临床病理学证据，例如帕金森综合征，以及细胞形态学证据的支持。

除了基底神经节之外，还有许多其他重要的皮层下结构也参与神经消息传递。下一节我们将讨论神经调质系统的起源结构；在本节末尾，我们先简要谈及丘脑。我们无法在这里对这一高度复杂的结构做出充分讨论，但可以概述一些基本原则。丘脑通常被分为初级核团和次级核团。图 5.1 表明，初级丘脑核团可以发挥与低级皮层区域相同的作用，也就是说，它们投向皮层第 IV 层，并接收来自第 VI 层深层锥体细胞的输入（Thomson 2010; Olsen et al. 2012）。例如，视觉系统中的外侧膝状体，就常被看作眼睛与视觉皮层之间的中继站。与那些表征预测误差的神经元类似，它既接收来自眼睛的感觉信息，也接收来自皮层的反馈投射，而后者可以被理解为预测。二级丘脑核团则包括内侧背核和枕核，它们分别与额叶皮层和后部皮层发生相互作用。这些结构可能参与对感觉输入或更高阶输入的二阶统计量，也就是精度和方差，进行预测，并且被发现与图-底分离任务有关（Kanai et al. 2015）。如果做一个简化理解，那么丘脑划分为初级核团和次级核团，可能正对应于一阶统计量与二阶统计量之间的划分。

5.5 神经调制与学习

结构性神经解剖很重要，但它只能告诉我们神经处理图景的一部分，因为一条连接的存在，并不能充分说明它究竟是如何被使用的。举例来说，考虑图 5.4 中黑质的作用。它对纹状体连接施加的调制效应，会根据释放的多巴胺量不同，使基底神经节产生非常不同的输出。像这样的突触效能快速调制，可以与学习中发生的、更慢但更持久的变化形成对照。本节聚焦于突触效

能发生改变的这两种方式。

精度是理解神经调制的一个重要概念（Feldman and Friston 2010）。我们在第 4 章以及前面关于感觉衰减的讨论中已经接触过这个概念；在那里我们看到，精度作为预测误差上的一个乘性权重而发挥作用。更广泛地说，精度是一个概率分布中“我们有多大把握”的度量。二者之间的关系很简单。如果我们对于“数据如何由隐藏状态生成”持有非常高精度的信念，那么与在我们对这些信念缺乏把握时相比，观察到数据将更强烈地更新我们关于隐藏状态的信念。当这种信念更新表现为神经元放电变化时，一个更高精度的似然分布，就体现为对给定感觉刺激更强的神经反应。这一点对于从注意（Parr and Friston 2019a）到多感觉整合（Limanowski and Friston 2019）的一系列认知功能都至关重要。

这种关于突触增益控制的视角，告诉我们一件简单却重要的事：如果精度是生成模型中某个分布的属性，那么不同分布就应当对应不同的精度。这在直觉上是合理的，因为我们对于感觉的可靠性、事物将如何随时间演化，甚至我们可能如何行动，都可能有高低不等的信心（Parr and Friston 2017b）。在基底神经节的情境中，我们已经看到其中最后一种，即关于策略的精度。与之相关的精度越高，我们就越有信心认为自己的策略会最小化期望自由能。

如果多巴胺系统，也就是起源于中脑黑质致密部和腹侧被盖区的系统，其功能之一是传递“该做什么”的信心，那么其他神经调质系统是否也扮演类似角色？表 5.1 总结了把不同精度与不同神经调质系统联系起来的证据，并给出了这些精度有时使用的符号。具体而言，起源于 Meynert 基底核的胆碱能系统，似乎传递某些似然分布的精度。

表 5.1：主动推断中神经递质的可能作用 乙酰胆碱对应似然精度 ζ。相关证据包括：丘脑-皮层传入纤维上存在突触前受体（Sahin et al. 1992; Lavine et al. 1997）；它能够调节视觉诱发反应的增益（Gil et al. 1997; Disney et al. 2007）；药理学操纵会改变有效连接（Moran et al. 2013）；在药理操纵条件下，对行为反应的建模结果也支持这一点（Vossel et al. 2014; Marshall et al. 2016）。

去甲肾上腺素对应转移精度 ω。证据包括：前额叶持续性活动，也就是延迟期活动，而这种活动要求转移概率具有足够高的精度，其维持依赖于去甲肾上腺素（Arnsten and Li 2005; Zhang et al. 2013）；瞳孔对令人惊讶，也就是低精度序列的反应与其相关（Nassar et al. 2012; Lavín et al. 2013; Liao et al. 2016; Krishnamurthy et al. 2017; Vincent et al. 2019）；药理操纵条件下的行为建模同样提供支持（Marshall et al. 2016）。

多巴胺对应策略精度 γ。证据包括：其受体在纹状体中型棘状神经元上以后突触形式表达（Freund et al. 1984; Yager et al. 2015）；计算性 fMRI 揭示，当精度发生变化时，中脑活动也随之变化（Schwartenbeck, FitzGerald, Mathys, Dolan, and Friston 2015）；药理操纵条件下的行为建模也支持这种联系（Marshall et al. 2016）。

血清素则可能对应偏好精度，或者内感受似然精度 χ。证据包括：其受体在内侧前额叶皮层第 V 层锥体细胞上表达（Aghajanian and Marek 1999; Lambe et al. 2000; Elliott et al. 2018）；而内侧前额叶皮层区域又与内感受加工和自主神经调节高度相关（Marek et al. 2013; Mukherjee et al. 2016）。

上述内容据 Parr and Friston 2018 整理。

来自蓝斑的去甲肾上腺素系统，似乎在传递时间转移的精度方面发挥作用。血清素系统的情况则没有那么明确，但它可能与先验偏好的精度有关。

为什么把这些精度与神经调质系统对应起来会有用？答案有三点：它能帮助我们解释已观察到的生物学现象，提出新的假设，并发展无创方式来测量精度。下面我们分别举一个例子。首先，在解释已观察生物学方面，关于多巴胺的经验测量，经典上看起来像是“奖励预测误差”（Schultz 1997）：动物在获得意外果汁奖励，或看到预示果汁即将出现的线索时，多巴胺会升高。主动推断对这些发现提供了一种替代性解释（Schwartenbeck, FitzGerald, Mathys, Dolan, and Friston 2015）。当我们获得奖励，或满足自身偏好，又或者遇到预示未来奖励的线索时，我们对自己正在追随一项能够最小化期望自由能的策略这件事，会更有信心。这种信心的提升，就表现为多巴胺的尖峰。

其次，在提出假设方面，一个例子是路易体痴呆中胆碱能信号的下降（Parr, Benrimoh et al. 2018），这种疾病会导致复杂视觉幻觉。一种合理解释是：较高阶视觉皮层中的病理积累，促使这些区域发出的预测与初级视觉皮层中的活动之间出现不匹配。这种不匹配会降低相关似然分布的置信度，从而导致胆碱能信号丧失。精度丧失的后果，是个体无法根据感觉数据来更新信念，也就是知觉失去了感觉所提供的约束。这或许可以解释为什么这一疾病会发展出幻觉性知觉。

第三，在无创测量精度参数方面，一个例子是计算型表型的识别。中枢神经化学活动在外周有许多表现形式，例如自发眨眼率与多巴胺之间的关系（Karson 1983），以及瞳孔大小与去甲肾上腺素之间的关系（Koss 1986）。近期关于后者的研究（Vincent et al. 2019）已经表明，一名理想贝叶斯观察者本应推断出的转移精度，与瞳孔收缩和扩张的动力学之间存在对应关系。这意味着，我们或许可以通过此类外周测量，去探测某个人隐含生成模型中的经验先验信念。

虽然精度的快速变化很重要，但它是一种相当粗糙的有效连接优化方式；它只会提高或降低信号增益，而无法实现更细腻的调整。如果我们想改变信号被解释的方式，就必须依赖学习。关于这一点，我们将在第 7 章中详细讨论。这里的基本思想是：我们不仅持有关于世界状态的信念，也持有关于固定参数，或者缓慢变化参数的信念，而这些参数决定了变量之间的依赖关系（Friston, FitzGerald et al. 2016）。这些信念的物质基础，是表征时间变化变量，如隐藏状态或结果的神经群体之间的突触连接效能。当我们观察到一个结果，并相信它是由某个给定状态生成时，我们就能够更新连接二者的参数信念，这体现为它们未来共同出现概率的上升。换句话说，连接这两组神经元的突触会得到加强。这就得到了 Hebb 那句著名命题的含义，可概括为：“一起放电的细胞，会连接在一起。”

图 5.1 的一个重要特征在于：无论是在预测编码方案还是边缘消息传递方案中，进入和离开皮层柱的连接都与似然分布有关。相比之下，转移概率和连续动力学则依赖于微回路内部的连接。这暗示着：学习动力学应当导致内在连接发生变化，而学习观测模型则应当修改外在连接。利用动态因果建模等技术，我们可以从神经影像数据中评估有效连接，并据此检验这些假设（Tsvetanov et al. 2016; Zhou et al. 2018）。这正凸显了此类过程理论的作用：它让我们能够超越抽象理论化，形成具体而可检验的假设。

5.6 连续层级与离散层级

最后，值得强调的是，在神经层级的低层中，表征往往是连续的，而在更高层中，则会转向分类变量。原因在于，我们前面讨论过的离散消息传递方案与连续消息传递方案，很可能在大脑中同时存在，因为我们不仅能够持有分类式信念，例如识别一个物体是什么、一个人是谁，也能够与连续变化的感觉受体和效应器接口，例如肌肉长度或视觉亮度对比。这一点也反映在神经生理学中：有些神经元对特定刺激具有选择性，而另一些神经元的反应则会随着刺激强度成比例变化。

一个有趣的观察是，我们与周围世界的接口处于连续域中，而这意味着，大脑中任何层级的最低层都必须是连续的。尽管如此，我们在图 5.4 中看到，基底神经节中的策略选择可以被表述为一个离散过程，也就是在不同动作之间进行选择。这说明，我们可以把动作理解为若干离散轨迹被组合成有目的行为。最低层也许处理的是肌肉长度所需发生的具体变化，而下行输入则建立在“该做哪一种动作”的决策之上。从生成模型的角度看，这意味着：我们要把关于世界的不同离散假设，与这些假设所蕴含的连续动力学联系起来。第 8 章中我们会回到这个问题，讨论如何从计算角度把这二者整合起来。在这里，我们只需指出：离感觉受体越远，神经系统中就越容易出现离散化表征。事实上，神经生理学中经典感受野的存在，本身就可以被理解为一种概率性表征：它表示世界正处于知觉状态空间中的某个特定区间，而这个状态空间被感受野所铺砌，因此被切分为大量小类别。图 5.5 将这些方案汇集到一起，可视作本章思想的总结。

5.7 总结

本章试图勾勒出第 4 章生成模型所蕴含的消息传递方案，与推断、行动和规划的神经生物学之间的连接点。把消息传递与神经元通信联系起来，我们能得到什么？它使我们能够根据我们假定大脑正在反演的生成模型，提出经验性预测。这种预测可以表现为诱发反应，也就是当大脑接收到感觉刺激时，头皮上可测得的电位变化，而其时间进程将取决于该刺激诱发了多大程度的信念更新。另一种路径，则是使用计算神经影像方法，把模拟得到的推断过程，与那些表现出相似时间动力学的脑区联系起来（Schwartenbeck, FitzGerald, Mathys, Dolan, and Friston 2015）。建立这种联系，对于理解计算性，也就是神经学和精神病学意义上的病理，以及相应治疗，都很重要，因为它使我们能够用生物学语言来表达功能性病理。

最后，值得承认的是，本章明显没有涉及大脑的很多部分，这部分是因为篇幅限制，另一部分则是因为神经科学本身仍在发展中。对于本章提出的解释框架，还存在许多可以扩展，甚至替代它的机会。在一定程度上，我们可以从已经看到的内容向外推演。例如，杏仁核的某些部分在细胞构筑学上与基底神经节核团是等价的。这是否意味着，杏仁核也在评估某一类策略？对于自主神经策略来说，它是否扮演着类似基底神经节在骨骼运动领域中的角色？其他结构，例如枕核，是否会对其他类型，例如心理层面的策略，发挥类似作用？对于那些不同于图 5.1 六层结构的皮层架构，我们又该如何理解？小脑和海马结构都呈现出各自独特但又具有定型性的微回路（Wesson and Wilson 2011）。我们应当把它们看成是同一套贝叶斯消息传递方案在解剖上的重新排列，还是说它们处理的是生成模型中的其他方面（Pezzulo, Kemere, and van der Meer

2017; Stoianov et al. 2020)？提出这些问题，并不是为了在这里给出答案，而是为了指出理论神经生物学中一些令人兴奋的未来研究方向。主动推断及其相关过程理论，为处理这些问题提供了一个严格的形式化框架和概念框架。

第二部分

建模与应用

第六章　设计主动推断模型的配方

6.1　引言

本章给出一个由四个步骤组成的配方，用于构建主动推断模型。我们将讨论为了实现一个模型必须作出的关键设计选择，并为这些选择提供若干指导原则。本章也为本书第二部分作铺垫；在那里，我们将展示若干基于主动推断的具体计算模型，以及它们在不同认知领域中的应用。

由于主动推断是一种规范性方法，它试图尽可能从第一性原理出发，解释行为、认知与神经过程。因此，主动推断的设计哲学是一种自上而下的哲学。与许多其他计算神经科学方法不同，这里的挑战并不是把大脑一块一块地仿真出来，而是找到那个能够刻画大脑试图解决之问题的生成模型。一旦这个问题被恰当地形式化为生成模型，在主动推断之下，问题的解就会自然显现，同时也会给出关于大脑与心智的相应预测。换言之，生成模型为所研究系统提供了一种完整描述。由此产生的行为、推断以及神经动力学，都可以通过最小化自由能从模型中推导出来。

生成建模方法已被广泛用于认知模型实现、统计建模、实验数据分析和机器学习等多个领域（Hinton 2007b; Lee and Wagenmakers 2014; Pezzulo, Rigoli, and Friston 2015; Allen et al. 2019; Foster 2019）。在这里，我们主要关心的是如何设计能够产生目标认知过程的生成模型。前几章已经展示过这种设计方法。例如，在预测编码的生成模型中，知觉被表述为对感觉最可能原因的推断；在离散时间演化的生成模型中，规划被表述为对最可能行动路线的推断。根据问题本身的不同（例如空间导航中的规划，或视觉搜索中的扫视规划），我们可以调整这些生成模型的形式，为它们赋予不同的结构（例如浅层或层级式）和变量（例如关于以环境为中心或以自我为中心的空间位置的信念）。关键在于，在对被优化生成模型的形式作出不同假设时，主动推断会呈现出多种不同面貌。例如，关于模型是在离散时间还是连续时间中演化的假设，会影响消息传递的形式（见第 4 章）。这意味着，对生成模型的选择，也对应着对行为和神经生物学的具体预测。

这种灵活性很有价值，因为它允许我们用同一种语言来描述多个领域中的过程。然而，从实践角度看，它也会带来困惑，因为为了找到研究对象的恰当描述层次，研究者必须作出一系列选择。在本书第二部分中，我们将通过一系列主动推断的计算示例来化解这种困惑。本章首先提出一个用于设计主动推断模型的一般配方，突出后续章节数值分析中会反复出现的一些关键设计选择、区分和二分法。

6.2 设计主动推断模型：一个四步配方

设计一个主动推断模型需要四个基础步骤，每一步都在回答一个特定的设计问题：

1. 我们在为哪个系统建模？首先必须确定感兴趣的系统。这一点并不像看上去那样简单，因为它依赖于对该系统边界，也就是马尔可夫毯的识别。什么算作主动推断主体（生成模型）？什么算作外部环境（生成过程）？它们之间的接口，也就是感觉数据与动作，又是什么？

2. 生成模型最合适的形式是什么？接下来的三个实践挑战中的第一个，是判断一个过程更适合被理解为类别性的（离散）推断，还是连续推断，这会推动我们在主动推断的离散时间实现、连续时间实现或混合实现之间作出选择。随后，我们需要选择最合适的层级深度，即在浅层模型与深层模型之间作出取舍。最后，我们还要考虑是否有必要赋予生成模型时间深度，以及预测依赖动作的观测的能力，以支持规划。

3. 如何搭建生成模型？生成模型最合适的变量和先验是什么？哪些部分是固定的，哪些部分必须通过学习获得？我们将强调选择正确变量和先验信念的重要性；同时也会强调时间尺度上的分离，即推断过程中较快更新的是状态变量，而学习过程中较慢更新的是模型参数。

4. 如何搭建生成过程？生成过程由哪些要素构成？它们与生成模型有何不同？

在大多数情况下，这四个步骤就足以设计出一个主动推断模型。一旦完成，系统的行为便由主动推断的标准机制所决定：主动状态和内部状态沿着与模型相关的自由能泛函下降。从更实际的角度说，一旦我们明确了生成模型与生成过程，就可以使用标准的主动推断软件程序来获得数值结果，并完成数据可视化、分析和拟合（例如基于模型的数据分析）。下面我们将依次回顾这四项设计选择。

6.3 我们在为哪个系统建模？

把主动推断形式主义用于具体问题时，一个有用的第一步，是识别感兴趣系统的边界，因为我们关心的是：系统内部的东西如何通过感觉受体和效应器（例如肌肉或腺体）与外部世界发生交互。正如第 3 章所讨论的，形式化地区分系统内部状态、外部变量以及介于两者之间并中介其相互作用的变量，一种方法是诉诸马尔可夫毯（Pearl 1988）。再次强调，马尔可夫毯可以分为两类变量（Friston 2013）：一类中介外部世界对系统内部状态的影响，也就是感觉状态；另一类中介系统内部状态对外部世界的影响，也就是主动状态。见图 6.1。

需要强调的是，内部与外部之间的边界可以有多种划定方式。在本书第二部分将讨论的大多数模拟中，都会在一个主体（大致上是一个生物体）与其环境之间设置一种马尔可夫毯式的分离。这与认知模型的常规设定一致：一个主体依靠其内部状态（例如脑状态）实现知觉与动作选择等认知过程，并配备传感器和效应器。

但这并不是唯一可能的设定。从神经生物学角度看，我们可以把马尔可夫毯画在单个神经元周围，也可以画在大脑周围，或者画在整个身体周围。在第一种情况下，感觉状态包括突触后受体占据情况，主动状态则包括装载神经递质的囊泡与突触前膜融合的速率。神经元的内部状态

（例如膜电位、钙离子浓度）于是就可以被看作是在依据某种隐含的生成模型，对其感觉状态的原因进行推断（Palacios, Isomura et al. 2019）。在这种设定里，被建模的外部状态包括该神经元所参与的神经网络。这与把整个网络都视为马尔可夫毯内部时发生的推断非常不同。比如，如果我们考察一个系统，它的感觉状态是视网膜中的光感受器，主动状态是眼动肌，那么内部状态所做的推断就是关于大脑之外的事物。这说明尺度十分重要，因为在这个马尔可夫毯下的内部状态，也包含了从单个神经元视角看见的内部状态。后一种内部状态在马尔可夫毯围绕单个神经元时，看起来是在推断大脑内部的事物；但当马尔可夫毯围绕整个神经系统时，情况就不是这样了。

这一点对于处理具身认知或延展认知视角尤其重要（Clark and Chalmers 1998; Barsalou 2008; Pezzulo, Lw et al. 2011）。例如，如果我们把马尔可夫毯画在神经系统周围，那么身体其他部分就会成为一种外部状态，我们必须通过内感受感觉状态对其作出推断（Allen et al. 2019）。或者，我们也可以把马尔可夫毯画在整个有机体周围。这样一来，看起来就像是除了大脑之外的其他器官也在对其环境进行推断。例如，皮肤在外部压力下发生凹陷，可以被表述为对外部压力来源的一种推断。延展认知观点更进一步，认为身体外部的对象也可以被纳入马尔可夫毯之内；例如，使用计算器来辅助推断，就意味着这个计算器成为推断系统内部状态空间的一部分。最后，我们还可以设想多个彼此嵌套的马尔可夫毯，例如大脑、有机体与共同体。

总之，定义马尔可夫毯能够确保我们知道：什么是被推断的对象（外部状态），以及什么在执行推断。事实上，相对于某个生成模型的自由能最小化，只涉及系统的内部状态和主动状态；这些状态只能够接触感觉状态，因此它们只能通过感觉状态间接地推断世界的外部状态。

6.4 生成模型最合适的形式是什么？

一旦我们确定了系统的内部状态，以及中介其与外部世界相互作用的状态，接下来就需要明确那个用来解释外部状态如何影响感觉状态的生成模型。正如前几章所述，主动推断可以作用于不同种类的生成模型。因此，我们必须为手头的问题指定最合适的生成模型形式。这主要意味着三项设计选择。第一，是在包含连续变量、离散变量或两者兼有的模型之间作出选择。第二，是在浅层模型与层级式或深层模型之间作出选择。浅层模型中的推断只在单一时间尺度上进行，也就是说所有变量都在同一时间尺度上演化；而层级模型中的推断则跨越多个时间尺度进行，不同变量会在不同时间尺度上演化。第三，是在只考虑当前观测的模型，与具有某种时间深度、能够考虑动作或计划后果的模型之间作出选择。

6.4.1 离散变量还是连续变量，还是两者兼有？

第一项设计选择，是考虑使用离散变量还是连续变量的生成模型更合适。前者包括对象身份、备选行动计划，以及连续变量的离散化表征。这些通常通过表达某个变量在每一个时间步上转移为另一种类型的概率来建模。后者则包括位置、速度、肌肉长度、亮度等变量，它们需要用变化率形式来表达生成模型。

从计算角度看，这一区分并不总是泾渭分明，因为连续变量可以被离散化，而离散变量也可以通过连续变量来表达。然而，在概念层面上，这一区分很重要，因为它支撑着关于目标认知过程时间进程是离散还是连续的具体假设。在当前大多数主动推断实现中，高层决策过程，例如在不同行动路线之间作出选择，通常用离散变量建模；而更细粒度的知觉和动作动力学，则通常用连续变量实现。我们将在第 7 章和第 8 章分别给出两类例子。

此外，离散变量与连续变量之间的选择，对神经生物学也有意义。虽然两种建模风格都诉诸自由能最小化，但它们所隐含的消息传递形式不同。如果人们认为消息传递与一种过程理论相关（见第 5 章），那么这意味着，实现自由能最小化的神经动力学在两类模型下也不相同。连续方案支撑的是预测编码，这是一种依赖自上而下预测并由自下而上预测误差进行校正的神经处理理论。而离散推断的类似过程理论，则涉及另一种形式的消息。最后，这两类模型也可以结合起来，使离散状态与连续变量相联系。也就是说，我们可以指定一个生成模型，其中某个离散状态（例如物体身份）会生成一组连续变量模式（例如亮度）。第 8 章将讨论一个同时包含离散变量和连续变量的混合生成模型示例。

6.4.2 推断的时间尺度：浅层模型与层级模型

第二项设计选择涉及主动推断所处的时间尺度。我们可以选择浅层生成模型，其中所有变量都在同一时间尺度上演化；也可以选择层级式或深层模型，其中包含在不同时间尺度上演化的变量，高层更慢，低层更快。

许多简单认知模型只需要浅层模型，但当目标认知过程中不同方面之间存在明确的时间尺度分离时，浅层模型就不够用了。语言加工就是一个例子：短时长的音素序列要由所说出的单词来提供语境，而短时长的单词序列又要由当前句子来提供语境。关键在于，一个单词的持续时间超出了组成它的任何单个音素，而一个句子的持续时间又超出了构成它的任何单个单词。因此，要为语言加工建模，我们可以考虑一种层级模型：句子、单词和音素分别位于从高到低的不同层级上，并以从慢到快、彼此近似独立的时间尺度演化。当然，这种分离只是近似的，因为不同层级之间必须相互影响；例如，句子会影响序列中的下一个单词，单词会影响序列中的下一个音素。

不过，这并不意味着为了开发针对某个单一层级的有意义模拟，我们就必须尝试建模整个大脑。例如，如果我们想聚焦于单词加工，那么就可以在不处理音素加工细节的情况下讨论它的某些方面。这意味着，从对音素进行推断的大脑区域传来的输入，可以被视为从单词加工区域角度看到的观测。用马尔可夫毯的语言来说，这通常意味着我们把模型较低层所执行的推断，当作该毯感觉状态的一部分。这样一来，我们就可以在不指定较低层、较快速推断过程细节的情况下，总结与当前时间尺度相关的推断；而这种层级分解也带来了巨大的计算收益。

另一个例子来自有意图的动作选择。在这种场景下，同一个目标，例如“进入你的公寓”，可以在较长时间内保持激活状态，并为一系列以更快时间尺度得到解决的子目标与动作提供语境，例如“找钥匙”“开门”“进去”。无论在连续域还是离散域中，这种时间尺度的分离都要求使用层级式、也就是深层生成模型。在神经科学中，我们可以假设皮层层级嵌入了这种时间尺度分离，即高层状态缓慢演化，低层状态快速演化，而这又重现了环境动力学的多时间尺度结构，例如

在语音识别或阅读等知觉任务中所面对的环境动力学。在心理学中，这类模型有助于复现层级目标加工（Pezzulo, Rigoli, and Friston 2018）以及工作记忆任务（Parr and Friston 2017c），尤其是那些依赖延迟期活动的任务（Funahashi et al. 1989）。

6.4.3 推断的时间深度与规划

第三项设计选择涉及推断的时间深度。这里需要区分两类生成模型：第一类具有时间深度，会显式表征动作或动作序列，也就是策略或计划的后果；第二类则没有时间深度，只考虑当前观测而不考虑未来观测。图 4.3 展示了这两类模型的例子：上方的动态 POMDP，以及下方的连续时间模型。这两类模型的关键差别并不在于它们分别使用离散变量和连续变量，而在于只有前者，也就是具有时间深度的模型，赋予主体前瞻规划并在多个可能未来之间作出选择的能力。

想象一只啮齿动物在迷宫中规划通往已知食物位置的路线。要做到这一点，它需要一个具有时间深度的模型，这个模型大致等价于一种空间地图或认知地图（Tolman 1948），能够编码在动作条件下当前地点与未来地点之间的依赖关系，例如右转之后会到哪里，左转之后又会到哪里。动物可以利用这个具有时间深度的模型，反事实地考虑多条可能的行动路线，例如一系列左转和右转，并选择那条预期能够到达食物位置的路线。

为什么规划需要一个具有时间深度的模型？在主动推断中，规划是通过计算不同动作或策略所对应的期望自由能来实现的，然后选择那个具有最低期望自由能的策略。期望自由能并不仅仅是当前观测的函数，像变分自由能那样；它还是未来观测的泛函。未来观测按定义无法被直接观察，只能借助一个具有时间深度的模型来预测，而这个模型描述了动作如何产生未来观测。

因此，在设计主动推断主体时，一个有用的问题是：它是否应该拥有规划和面向未来的能力；如果答案是肯定的，就应该选择一个具有时间深度的模型。此外，还要考虑规划深度，也就是规划过程能够看多远的未来。最后，我们还可以设计既具有层级结构又具有时间深度的生成模型，使规划在多个时间尺度上展开，低层更快，高层更慢。是否对依赖策略选择的备选未来进行建模，在很大程度上也与离散模型和连续模型之间的选择纠缠在一起，因为“在多个由动作序列定义的备选未来之间进行选择”这一想法，用离散时间模型来表达通常更加直接。

6.5 如何搭建生成模型？

当我们已经明确研究的系统，并识别出生成模型的相关形式，例如连续或离散表征、浅层或层级结构之后，接下来的挑战，就是指定要纳入生成模型的具体变量，并决定其中哪些变量保持固定，哪些变量会因学习而发生变化。

6.5.1 设置生成模型中的变量

生成模型中的变量，既可以预先定义，也可以从数据中学习得到。为了说明问题，本书讨论的大多数模型都使用了预定义变量。在设计这类模型时，实践中的主要挑战是：判断哪些隐状态、

观测和动作最适合当前问题。例如，第 2 章中那个能够区分青蛙和苹果的知觉模型，只包含两个隐状态（青蛙、苹果）和两个观测（跳、不跳）。一个更复杂的模型还可以加入额外观测，例如红色、绿色，以及诸如触摸之类的动作；这些动作在面对青蛙或苹果时，会产生不同的感觉结果，例如跳或不跳。

图 6.2 以示意方式展示了一个关于“会跳的青蛙”这一概念的生成模型。这个概念被表述为一个层级模型：图中央的一个单一的、多模态或超模态隐状态，会级联展开为对应不同模态知觉的一组单模态隐状态，最终在这些模态上引起感觉。这里的模态包括外感受、本体感受和内感受，见框 6.1。这样的安排相当于把“会跳的青蛙”这一概念视为多种感觉后果的共同原因，例如在视觉域中看到一个绿色且会跳的东西，在听觉域中听到蛙鸣；其中有些后果还可能依赖动作，例如当你去触碰它时，看到某物跳动的可能性会增加。对这一生成模型的反演，就对应于一种知觉推断：从它已被观察到的感觉后果，例如看到一个绿色而且会跳的东西，推断出“有一只会跳的青蛙”；并且这一推断会整合来自多个模态的信息。

框 6.1 感觉模态的类型：外感受、本体感受与内感受 在主动推断中，通常会对三类感觉模态作概念区分：外感受模态，例如视觉和听觉；本体感受模态，例如对关节和肢体位置的感觉；以及内感受模态，例如对身体内部器官状态的感觉，如心脏和胃。在多模态生成模型中，往往可以把与不同模态相关的模型部分进行因子化；这样便能够表示，例如扫视运动会产生视觉后果，但不会产生听觉后果。

需要强调的是，主动推断的相同原则适用于所有这些模态。例如，正如视觉处理可以被描述为对知觉场景中某些隐变量的推断，内感受处理也可以被描述为对报告身体内部状态之隐变量的推断。进一步地，那些改变知觉场景的运动动作，以及那些改变内感受状态的内向动作，也可以用相似的方式来描述。前者会调动满足本体感受预测的脊髓反射，后者则会调动满足内感受预测的自主神经反射。这样的内感受处理支撑着异稳态与适应性调节，而其失调则可能带来精神病理学后果（Pezzulo 2013; Seth 2013; Pezzulo and Levin 2015; Seth and Friston 2016; Allen et al. 2019）。

一旦这些感兴趣的变量被确定下来，下一步工作就是把完整的生成模型写出来。图 2.1 中那个区分青蛙和苹果的简单生成模型就是一个例子：它完全由关于隐状态的先验信念，以及隐状态与观测之间的似然映射所指定，而这些数值既可以手工设定，也可以从数据中学习得到（见 6.5.2）。

超出这个简单例子之后，需要明确哪些元素，将完全由所选生成模型的形式决定。例如，图 4.3 上方展示的离散时间 POMDP 模型，需要指定 A、B、C、D 和 E 矩阵；连续方案也有与之类似的要素，只是命名没有这么按字母排序，第 8 章会讨论它们。但即使在这些更复杂的情形中，工作内容与上面的思路并没有本质差别：也就是为感兴趣的变量指定先验信念，例如在离散时间实现中，对第一个时间步的隐状态使用 D 向量，对观测使用 C 矩阵；并指定它们之间的概率映射，例如在 A 矩阵中给出隐状态与观测之间的似然映射。不过，在某些情况下，从生成模型状态空间的因子化角度来思考会很有帮助，因为如果某些变量并不必要，就可以避免考虑所有可能的变量组合。在第 7 章中，我们会讨论一个发生在知觉处理中的、具有生物学合理性的因子化例子，即“是什么”通路与“在哪里”通路之间的分工（Ungerleider and Haxby 1994）；也就是分别表示物体身份和位置的变量，它们在模型中往往可以被独立处理，从而简化模型，因

为二者经常彼此不变。

决定哪些变量值得纳入模型，以及它们在模型中如何相互关联或被因子化，往往是模型设计中最困难、但也最具创造性的部分。它本质上是在把我们的认知假设翻译成一种支持主动推断的数学形式。我们应当如何选择“正确”的变量？归根到底，这个问题可以表述为：提出若干看起来合理的备选模型，然后选择自由能最低的那个，这与贝叶斯模型比较的精神一致。不过，从大多数研究的实践角度看，一个很有用的观点是：生成模型应当尽可能接近我们认为数据是如何被生成出来的方式。当我们在认知心理学场景中诉诸主动推断时，这通常意味着，我们应当去想：实验心理学家是如何生成并呈现给被试的刺激的。当这些过程被形式化为所需的概率分布之后，我们就得到了一个生成模型，而对其自由能的最小化动力学，会自然导向相关任务的完成。

这里可以类比大多数关于知觉的贝叶斯模型或理想观察者模型：这些模型被设计成在很大程度上模仿当前任务的结构，就像识别青蛙还是苹果的例子那样（第 2 章）。这一想法有时被称为良好调节器定理（Conant and Ashby 1970），其含义是：为了有效调节环境，一个生物体，无论是生物性的还是人工的，都必须是该系统的良好模型。从生态位建构的角度看，这有时又会被表述为：生物体模型与环境之间具有某种统计适配性（Bruineberg et al. 2018），反之亦然。不过，这并不意味着一个主体的生成模型必须与真实生成数据的生成过程完全相同。对于大多数实践应用来说，它可以更简单，也可以有所不同。稍后在本章的 6.6 节中，我们还会回到这一点。

框 6.2 先验与经验行为 关于如何选择先验，还有另一种视角，它来自一组被称为完全类定理的结果（Wald 1947; Daunizeau et al. 2010）。这些结果指出，任何统计决策程序，也就是任何行为，都可以在一组合适的先验信念之下被表述为贝叶斯最优。这意味着，如果我们想解释经验行为，挑战就在于识别出那样一个生成模型，也就是一组先验信念，使得该行为能够尽可能简单地被重现。简言之，先验表达的是关于目标系统的一种假设。如果还存在其他同样合理的先验信念，这就为借助经验数据进行贝叶斯模型比较提供了机会。

这一点对临床人群中的计算表型分析也有含义。既然总会存在某组先验信念使行为在贝叶斯意义下成为最优，那么，在理解那些产生精神病学或神经学综合征的计算缺陷时，关键问题就不再是行为是否最优，而是这些先验究竟是什么。这个想法起初可能有些违反直觉。然而，完全类定理意味着，单纯问一个行为是不是贝叶斯最优，本身并没有意义。真正重要的问题是：什么样的先验信念会使这种行为成为最优？在第 9 章中，我们将看到，借助以科学家自身信念为基础的自由能最小化，我们可以回答这个问题。

6.5.2 生成模型的哪些部分是固定的，哪些部分是学习得到的？

另一项设计选择，是决定生成模型中哪些部分保持固定，哪些部分会随着时间推移并由于学习而被更新。原则上，主动推断允许模型的每一个部分，甚至包括模型结构本身，随着时间而被更新或学习。因此，学习是一项设计选择，而不是某种必需项。相应地，我们既会讨论完全由手工设计出来的主动推断模型，也会讨论这样一些模型：其中某些部分，例如转移概率，保持固定，而另一些部分，例如似然，则会随着时间而被更新。

在主动推断中，学习被表述为推断的一个方面，也是一种自由能最小化过程。到目前为止，我们把推断描述为对生成模型状态之信念的更新。以完全类似的方式，我们也可以把学习描述为对生成模型参数之信念的更新。为此，生成模型必须被赋予关于待学习分布参数的先验信念，而这些具体参数取决于每个变量所对应的概率分布形式，例如高斯分布中的均值和方差。每当遇到新数据时，这些先验值就会被更新，形成后验信念。正如我们将在第 7 章讨论的，这种更新在算法形式上与状态变量的更新是相同的。

推断和学习都依赖同一种贝叶斯式信念更新，这一点在模型设计时可能会引起混淆；部分原因是，什么应该被建模为状态，什么应该被建模为参数，并不总是显而易见。然而，在认知模型中，推断和学习之间仍然存在明确差别。推断描述的是我们关于模型状态之信念的快速变化，例如当我们看到一个红色物体后，如何更新“面前是一个苹果”的信念。学习描述的是我们关于模型参数之信念的缓慢变化，例如在多次观察到红苹果之后，如何更新似然分布，从而提高“苹果--红色”映射的数值。关于参数的信念通常比关于状态的信念变化得慢得多，而且它们往往只有在状态已被推断之后才会更新。从神经生物学角度看，把推断映射为神经动力学、把学习映射为突触可塑性，是很有吸引力的。进一步地，正如我们将在第 7 章看到的，对模型参数持有概率性信念会诱发新奇寻求行为，使主体选择最有利于学习其世界因果结构的数据。这说明，赋予主动推断模型以学习其参数，甚至其结构的能力，是研究主动学习与基于好奇心探索之行为动力学的一种有效方式。

在结束本节之前，值得指出的是：本书所举的例子大多是相对简单的生成模型，它们使用表格式方法来定义，例如用显式矩阵表示先验和似然，并且运行在较小的状态空间中。相比之下，在机器学习、深度学习和机器人学等领域，人们正在发展更复杂的生成模型及其相应的学习方案，例如变分自编码器（Kingma and Welling 2014）、生成对抗网络（Goodfellow et al. 2014）、递归皮层网络（George et al. 2017）以及世界模型（Ha and Schmidhuber 2018）。原则上，我们可以借用其中任何一种方法，或者更多其他方法，来实现主动推断模型的一个或多个组成部分，例如似然模型或转移模型。通过利用最新的机器学习方法，主动推断有望被扩展到越来越具有挑战性的领域和应用；例如可参见 Ueltzhöffer（2018）和 Millidge（2019）。

不过，在设计使用复杂机器学习模型的主动推断模型时，有几点必须认真考虑，尤其是在我们关心其认知和神经生物学含义的时候。主动推断的吸引力之一，在于它为认知功能提供了一种整合性视角，认为知觉推断、动作规划和学习等都来自同一个自由能最小化过程。如果我们把若干彼此独立运行或学习的生成模型简单并列，这种整合力量就会丧失。此外，上述机器学习方法本身对应于与主动推断不同的过程模型，因此也会带来不同的认知和神经生物学解释。最后，当使用机器学习方法时，这里讨论的某些设计选择，例如关于模型变量的选择，可能会被跳过，因为它们成为学习中涌现出来的属性；但与此同时，它们又会被另一类设计选择取代，例如深度神经网络的层数、参数数量和学习率等。这些设计选择同样可能具有重要的认知和神经生物学含义，但已经超出了本章的讨论范围。

6.6 搭建生成过程

在主动推断中，生成过程描述的是主动推断主体之外的世界动力学，也就是决定主体观测的那个过程（见图 6.1）。看起来似乎有些奇怪：我们直到介绍完主体的生成模型之后，才来定义生成过程。毕竟，一个建模者通常从一开始就会心里有一个任务，也就相应地有一个生成过程；因此，把顺序倒过来，先设计生成过程，再设计生成模型，似乎完全说得通。特别是在生成模型需要通过情境中的交互学习获得的应用里，例如游戏式环境或机器人场景（Ueltzhöffer 2018; Millidge 2019; Sancaktar et al. 2020），这种顺序看起来尤其自然。

我们之所以把生成过程的设计推迟到这里，是因为在本书讨论的许多实践应用中，我们只是简单地假定：生成过程的动力学与生成模型相同，或者非常相似。换句话说，我们通常假设主体的生成模型会紧密模仿生成其观测的过程。这并不等于说主体对环境拥有完美知识。事实上，即便主体知道是什么过程生成了它的观测，它也仍然可能对该过程中的某些因素不确定，例如对其初始状态不确定，正如苹果与青蛙的例子那样。用离散时间主动推断的语言来说，我们完全可以设计这样一个模型：生成模型与生成过程具有相同的 A 矩阵，但主体关于初始状态的信念，即作为其生成模型一部分的 D 向量，却与生成过程的真实初始状态不同，甚至彼此不一致。这里有一个微妙之处需要注意：即使生成模型和生成过程都由相同的 A 矩阵和 B 矩阵来刻画，它们的语义也并不一样。生成过程中的 A 矩阵是环境的一种客观属性，在贝叶斯模型中有时称为测量分布；而生成模型中的 A 矩阵则编码了主体的主观信念，在贝叶斯模型中称为似然函数。

当然，除了最简单的情形之外，生成模型与生成过程并不必须相同。在主动推断的实践实现中，我们总是可以把生成过程与生成模型分开指定：既可以使用不同于生成模型的方程，也可以使用其他方法，例如游戏模拟器，这类系统以动作作为输入、以观测作为输出（Cullen et al. 2018），从而遵循图 6.1 所隐含的、由马尔可夫毯界定的通常行动--知觉回路。

设计与生成过程相似或不相似的生成模型，还具有一些哲学含义（Hohwy 2013; Clark 2015; Pezzulo, Donnarumma et al. 2017; Nave et al. 2020; Tschantz et al. 2020）。如前所述，良好调节器定理（Conant and Ashby 1970）认为，一个有效的适应性生物体必须拥有，或者本身就是，它所调节系统的一个良好模型。不过，这可以通过多种方式实现。第一种方式，也是到目前为止我们一直在讨论的方式，是让生物体的生成模型去模仿生成过程，至少在很大程度上如此。以这种方式构建的模型，可以称为显式模型或环境模型，因为它们的内部状态与环境的外部状态之间存在相似性。第二种方式，则是让生物体的生成模型比生成过程更加简约，甚至与生成过程显著不同，只要它能够正确处理环境中那些对适应性行动和目标达成真正有用的方面。以这种方式构建的模型，可以称为感觉运动模型或行动导向模型，因为它们主要编码的是动作--观测，或者说感觉运动依赖关系，其首要作用是支持目标导向行动，而不是提供对环境的精确描述。

如果我们考虑对同一个场景的不同建模方式，这一区别会更容易理解。例如，一只啮齿动物试图逃离一个迷宫，而迷宫中的某些通道是死胡同。一个显式生成模型可能会像一张迷宫的认知地图，并对位置、走廊和死胡同等外部实体进行详细刻画。借助这种模型，啮齿动物可以依靠基于地图的导航走出迷宫。而一个行动导向模型，则可能编码胡须动作与触觉之间的依赖关系。这样的模型能够支持情境上合适的策略选择，例如当没有体验到或预期到触觉时就向前移动，而

在相反情况下改变方向。最终，啮齿动物也能够借此逃出迷宫，而无需显式表征位置、走廊或死胡同。这两类模型会引出对主动推断不同的哲学解释：生成模型究竟是在重建外部环境，还是在提供精确的动作控制条件。

最后，正如形态计算领域所讨论的那样（Pfeifer and Bongard 2006），生物体或机器人的控制有些方面可以外包给身体本身，因此并不需要被编码进其生成模型。一个例子是被动动力步行器：这种物理对象在外形上类似人体，由两条“腿”和两只“臂”组成，却能够在没有传感器、电机或控制器的情况下沿斜坡行走（Collins et al. 2016）。这个例子意味着，至少某些运动能力方面的功能，可以通过精心调谐的身体力学来实现，以便利用环境依赖关系，例如合适的体重或体型使个体能够在不打滑的情况下行走；因此，这些依赖关系不必被编码进生物体的生成模型。这提示了设计主动推断主体及其身体的另一种方式：不是让它们拥有环境的良好模型，而是让它们本身就成为环境的良好模型。不过，这些不同的主动推断模型设计方式并不是互斥的，而是可以根据具体问题恰当地组合起来。

6.7 使用主动推断进行模拟、可视化、分析与数据拟合

在大多数实践应用中，一旦生成模型和生成过程都被定义出来，我们只需要使用主动推断的标准程序，也就是让主动状态和内部状态沿着与模型相关的自由能泛函下降，就可以得到数值结果。可以说，建模者的目标通常是模拟、可视化、分析以及拟合数据，例如开展基于模型的数据分析。支持这些功能的标准主动推断程序可以免费获得（`https://www.fil.ion.ucl.ac.uk/spm/`）；附录 C 给出了一个使用这些程序的注释示例。

尽管在大多数情况下，主动推断程序都可以开箱即用，但在某些实践应用中，人们仍然可能考虑做一些特定的微调或改动。例如，指定规划的时间深度，会决定在计算期望自由能时要考虑多少未来状态。对于大型状态空间中的主动推断实践应用来说，设置一个有限的时间深度，再结合其他替代穷举搜索的近似方法，例如采样（Fountas et al. 2020），可能会很有帮助。

另一个对主动推断标准运行方式进行调整的例子，是有选择地移除期望自由能方程中的某些部分。这种消融操作有助于把标准主动推断，即使用完整期望自由能的系统，与若干简化版本进行比较；在这些简化版本中，期望自由能的某些部分被压制，从而使其在形式上与 KL 控制或效用最大化系统等框架变得可比（Friston, Rigoli et al. 2015）。此外，我们也可以为主动推断模型增加一些额外机制，例如习惯学习（Friston, FitzGerald et al. 2016）或学习率调制（Sales et al. 2019）；不过需要注意的是，如果想保持主动推断的规范性特征，就必须把这些附加机制同样表述为自由能最小化过程。

最后，对主动推断作出其他一些微调或改变，也有助于刻画推断障碍和精神病理状态。例如，我们可以通过赋予某个生物体的生成模型过强或过弱的先验，也就是过高或过低水平的神经调质，来探索其行为和神经后果。第 9 章将给出若干与精神病理学相关的主动推断模型示例。

6.8 总结

本章概述了在搭建主动推断模型时必须作出的最重要设计选择。我们提供了一个四步配方，并给出了一些指导原则，用来处理模型设计者通常会面对的挑战。当然，并不需要以僵硬的方式遵循这套配方。有些步骤可以颠倒顺序，例如先设计生成过程再设计生成模型，也可以把若干步骤合并。但总体上说，这些步骤都是必需的。

这也为本书余下内容奠定了基础。接下来的章节将通过一系列示例把这些思想付诸实践，以展示本书前半部分提出的理论原则。后文所有示例之间真正不同的地方，只在于我们在这里强调过的这些设计选择。第二部分将展示具有不同边界的系统，展示离散或连续动力学在不同时间尺度上的实现，也将展示在许多不同领域中，先验信念的选择对于重现行为为何至关重要；但它们都在实现同一个主动推断框架。

第七章　离散时间中的主动推断

我不能创造的东西，我就无法理解。

— Richard Feynman

7.1　引言

到目前为止，我们一直在相对抽象的层面讨论主动推断的原理。本章转向具体例子，以及如何在实践情境中对这些例子加以规定。我们聚焦于离散时间中的类别变量模型。通过一系列复杂度逐步提升的例子，我们将说明感知处理、决策、信息搜寻、学习以及层级推断的模型。这些例子的选择目标，是尽可能简单地凸显主动推断方案中涌现出来的性质，包括可测量的生理表现与行为表现。

7.2　感知处理

我们首先考察感知处理，以及如何反演第 4 章引入的那类离散时间模型。稍后在本章中，我们会逐步构建一个完整的部分可观测马尔可夫决策过程（POMDP）。不过，我们先从 POMDP 的一个特殊情形开始：在这一情形下，我们可以忽略选择与行为，只关注隐藏马尔可夫模型（HMM）；它可用于顺序性的、类别性的感知推断（见图 7.1）。为此，我们先借助一个简单例子。想象你正在聆听一段短小乐曲的演奏。乐谱中写下来的音符序列可以看作隐藏状态（不可观测状态），而我们实际听到的音符序列则是结果（可观测结果）。如果演奏者是一位专业音乐家，那么隐藏状态与结果之间的对应关系会非常紧密。但如果演奏者是业余的，那么从本应弹出的音符到实际听到的音符之间，在似然映射上就会多出一层随机性。即便如此，只要我们对每个音符前后衔接另一个音符的概率具有先验信念，我们依然可能据此推断出原本应该听到的是哪个音符。

将聆听业余音乐家的这个例子形式化，方法如下。首先，我们要决定这位音乐家实际弹出她意图弹出的音符（结果）有多可靠。我们可以用 A 矩阵来表达这一点，其中的元素表示在给定某个状态（列）时产生某个结果（行）的概率。在这个玩具例子中，我们将其设定为：

$$A = \frac{1}{10}\begin{bmatrix} 7 & 1 & 1 & 1 \\ 1 & 7 & 1 & 1 \\ 1 & 1 & 7 & 1 \\ 1 & 1 & 1 & 7 \end{bmatrix} \tag{7.1}$$

这意味着有 70% 的时间里，这位音乐家会准确地弹出她打算弹的音符。接着我们规定 B 矩阵中的转移概率，它刻画在给定当前状态（列）的情况下，下一个状态（行）的概率：

$$B = \frac{1}{100}\begin{bmatrix} 1 & 1 & 1 & 97 \\ 97 & 1 & 1 & 1 \\ 1 & 97 & 1 & 1 \\ 1 & 1 & 97 & 1 \end{bmatrix} \tag{7.2}$$

这表示第一个音符之后有 97% 的概率接第二个，第二个之后有 97% 的概率接第三个，以此类推。如果我们知道这个序列总是以第一个音符开始，那么先验概率可设为：

$$D = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} \tag{7.3}$$

式 (7.1)–(7.3) 共同完整规定了图 7.1 所示的 HMM 生成模型。换句话说，它们描述了我们关于“所听到的音乐如何由这位业余音乐家生成”的信念。利用式 4.12，并把这里的生成模型代入进去，我们就可以模拟一串结果所诱发的贝叶斯信念更新动力学。结果如图 7.2 所示。注意左上图中，随着时间推移积累到更多数据，置信度不断提高；但在第三个时间步出现了一个意外结果，因此这一趋势被打断。这个结果可以有两种解释。第一种是：在式 (7.2) 所表达的先验信念之下，被意图演奏的音符本身就是一个不寻常的音符。但由于该模型的 B 矩阵中这类转移极其罕见，因此这种解释并不太可能。另一种、更可信的解释是：音乐家失误了，弹错了音。正如右上图第三列所示，我们模拟出来的听者最终采取的就是这种解释。不过，他仍然给“其实本来就是正确音符”保留了非零概率。能够报告这种不确定性，正是主动推断所提供的贝叶斯视角的一项关键特征。

这里展示的模型还可以在许多方向上变得更复杂，而也许最简单的一种方式就是对状态空间进行因子分解（Mirza et al. 2016）。例如，可以把音符分解为音高与力度（结果也做类似区分）。在视觉推断任务中，这种分解可以是“是什么”和“在哪里”，而这一区分在神经生物学中非常重要（Ungerleider and Haxby 1994）。在后续各节中，我们会利用这种因子分解，把那些受生物体自身影响的状态与那些不受其影响的状态区分开来。若想进一步了解这种不涉及行动的模型，以及可通过最小化自由能来反演它的神经元消息传递方案，可参见 Parr, Markovic et al. (2019)。

7.3 作为推断的决策与规划

上面的 HMM 说明了一种非常简单的、基于结果序列的类别推断形式。然而，这种模型所描绘的“固着不动”的生物相当乏味。自主生物显然不只是被动接受感觉数据的容器。相反，它们会主动改变环境，并与其感觉系统进行双向交换。这说明有必要把 HMM 扩展为 POMDP：我们不仅要推断环境如何变化，还要推断我们所选择的行动路径如何改变环境，以及应该选择哪一条行动路径。

图 7.3 展示了一个 POMDP 生成模型。这与第 4 章中介绍的模型相同，那里已经详细拆解了在这类模型中如何进行推断。请注意，它在结构上与图 7.1 中的 HMM 极其相似，只是多了一个额外变量 π，转移概率 B 以它为条件。这意味着我们可以同时考虑关于状态动力学的不同假设。这些假设可以解释为生物体可在其间进行选择的计划。从这个角度看，策略评估等同于模型比较，而策略本身不过是对一串已观测到的（由自身生成的）感觉序列的解释变量。

图 7.3 中的模型与第 4 章介绍的版本有一个细微差别：它允许对状态（上标 n）和结果（上标 m）进行因子分解。当我们考虑视觉世界可被分解为物体的位置与物体的身份时，这种做法的效用就显而易见。若要表示“位置”和“身份”的每一种可能组合，不仅极其低效，而且会付出很高的复杂性代价；而通常情况下，身份不随位置变化，位置也不由身份决定。对于把时间与身份、位置分离开来，也可以提出类似论证（Friston and Buzsaki 2016）。在这个阶段引入因子分解的好处在于，我们可以把世界中那些受生物体控制的状态，与那些不受其控制的状态分离开来。前一类状态的转移概率会随策略不同而变化，而后一类状态则对策略保持不变。

有了这些预备知识之后，我们现在概述一个简单任务的例子（Friston, FitzGerald et al. 2017）。这个任务需要规划，并展示了使用 POMDP 的主动推断的一些关键方面。任务情境是一只处在 T 迷宫中的老鼠：一条臂上有厌恶性刺激，另一条臂上有吸引性刺激，而最后一条臂上则有一个线索，用来指示前两种刺激各自所在的位置。这样的设置意味着，老鼠的行为大致有两种方式。它可以直接走向两条可能藏有吸引性刺激的臂之一，但要承担遭遇厌恶性刺激的风险。或者，它也可以先去寻找信息性线索，然后再走向最有可能包含吸引性刺激的那条臂。

这个选择触及了心理学中的经典“探索---利用”困境，而在主动推断框架下，这一困境会被化解。其化解方式来自于：关于策略的先验信念要求最小化期望自由能。简要回顾一下（详见第 4 章），对于一个最小化变分自由能的生物体而言，最可能的策略，就是那些会导向最低期望自由能的策略。期望自由能具有如下形式：

$$G(\pi) = \mathbb{E}_{Q(\tilde{s}|\pi)}[H[P(\tilde{o} \mid \tilde{s})]] - H[Q(\tilde{o} \mid \pi)] - \mathbb{E}_{Q(\tilde{o}|\pi)}[\ln P(\tilde{o} \mid C)] \tag{7.4}$$

这里第一、二项对应负的认知价值（即 $-I(\pi)$），最后一项对应务实价值。

把期望自由能分解为认知价值与务实价值，突出了两种驱动力：其一是朝向信息采集的（认知）驱动，其二是朝向实现先验信念的（务实）驱动（图 7.3 中的 C）。下一节我们会尝试更深入地建立对认知价值的直觉理解；暂时可以把它简单理解为，在某个特定策略下我们有望获得的信息量。务实价值的形式，实质上是把对所有策略取平均后的结果概率当成一种先验。这样一来，

那些后果与该先验一致的策略就会变得更可能，因为它们对应更低的期望自由能。换一种更直观的说法：如果我们认为某类观察很可能会发生，那么我们就会采取行动去实现“自己将会遭遇这些观察”的信念。因此，结果的对数概率可以被看作与其他形式化框架中的效用函数等价，例如最优控制理论和强化学习中的效用函数。由于效用与信息价值都自然地作为期望自由能的两个组成部分涌现出来，我们就不再需要额外操心如何平衡探索与利用，因为二者都服务于同一个目标函数的优化。

要看这一点在 T 迷宫例子中如何展开，我们需要像前面的 HMM 那样，把生成模型形式化。图 7.4 至图 7.6 展示了构成 T 迷宫生成模型的似然与转移概率。我们会稍微详细地解释这一过程，因为这个最小例子提供了构建读者自己生成模型的基本积木。第一步，是决定有多少个结果模态来表示模型需要解释的（感觉）数据。这会告诉我们需要规定多少个 A 矩阵。在这里，我们有两个模态：一个表示与老鼠在迷宫中所处位置有关的外感受数据（A^1），另一个是“是什么”的模态，可以理解为当老鼠找到吸引性（可食用）刺激时所经历的内感受数据（A^2）。这些模态中的各个水平，也就是每一种可能出现的观察结果，决定了每个 A 矩阵的行数。下一步，要决定用于解释这些数据的隐藏状态因子的数量；这决定了我们需要多少个 B 矩阵。这里我们考虑两个因子：老鼠在迷宫中的位置，以及情境（吸引性刺激在左边还是右边）。它们分别有四个与两个水平。然后，我们必须对每一种隐藏状态组合，规定各个结果出现的概率。图 7.4 给出了情境 1，图 7.5 给出了情境 2。对于第一个模态，A^1 以概率 1 把每个位置映射到一个结果。线索位置会根据情境不同而与一个“向左线索”或“向右线索”相关联。第二个模态即内感受模态（A^2），它把起始位置与线索位置都关联到中性结果；当情境与老鼠所进入的迷宫臂一致时，它以 98% 的概率产生吸引性结果。严格来说，这些 A 矩阵其实是张量对象，因为它们的元素由三个数字决定（结果、位置、情境），而矩阵只需要两个数字（行与列）即可确定。

随后我们需要规定转移概率。B 矩阵描述在给定策略 π 的情况下，从某一状态（列）转移到另一状态（行）的概率。它们规定了老鼠在迷宫中位置的转移（B^1），以及情境的转移（B^2）。图 7.6 给出了可控制的 B^1 转移。每个矩阵对应一种不同的动作选择（以下标标记）。这些动作允许老鼠从任何位置移动到任何其他位置，惟独不能从迷宫的两条臂离开，因为那两条臂是吸收状态。这意味着一旦进入其中，无论老鼠再选什么动作，它都必须停留在那里。相比之下，老鼠无法控制情境，也就是说，它无法控制自己究竟处于图 7.4 所示的情境 1，还是图 7.5 所示的情境 2。情境在时间上保持不变，因此可以表示为单位矩阵：

$$B^{\pi 2} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \tag{7.5}$$

这里每一列（和每一行）都对应于图 7.4 或图 7.5 中的一个状态索引。这意味着无论起始于哪个情境，它都会随时间保持不变，也即只发生对自身的转移。而且，不管选择什么策略，这一点都成立。向量 C^1 给出了该模态下各结果的先验偏好：总体上是均匀偏好，但对起始位置有轻微厌恶（-1）。向量 C^2 则表达了对吸引性刺激的偏好（$+6$）以及对厌恶性刺激的排斥（-6）。对二者都没有遇到则视为中性（0）。

$$
\begin{aligned}
C^1 &= \sigma\big([-1,0,0,0,0]^T\big) \\
C^2 &= \sigma\big([0,6,-6]^T\big)
\end{aligned}
\tag{7.6}
$$

这些向量中元素的顺序，对应于各自 A 矩阵中行的顺序。Softmax 函数 σ 允许我们用正值和负值来表述偏好（对应未归一化的对数概率），再把它们转换为概率。这既保留了对数概率之间的差异（或相对概率），又保证了归一化。从实践上看，这意味着在老鼠的生成模型中，吸引性刺激被认为比中性刺激的概率高出 e^6（约 400）倍。这是一种非常强烈的偏好，意味着老鼠相信自己的行动更有可能导向吸引性结果。正是这种对行动推断的约束，对接下来出现的行为至关重要。最后，D 向量规定初始状态的先验概率：

$$
\begin{aligned}
D^1 &= [1,0,0,0]^T \\
D^2 &= \frac{1}{2}[1,1]^T
\end{aligned}
\tag{7.7}
$$

这些向量中元素的顺序与 B 矩阵中的顺序一致。D^1 表示对 “从迷宫中心开始” 的高度确信；D^2 则表示在起始时，两种情境（图 7.4 或图 7.5）被认为等可能。

图 7.7 展示了当我们对图 7.4 至图 7.6 的生成模型进行反演时会发生什么。上排描述的是如果我们直接观察老鼠行为所能看到的情形。老鼠先从中心出发，然后前往信息性线索所在位置。这是因为该位置具有很高的认知价值，也就是说，在这个位置获得的观察有潜力消除关于情境的不确定性。看到指向左侧情境（情境 1）的线索后，老鼠便选择迷宫左臂，并在那里找到奖励性刺激。这一步是由该位置的高务实价值驱动的。下方图像展示了这一简单试次中发生的信念更新。与图 7.2 一样，这里也以一种理想化老鼠的可观测形式来表示这些更新，也就是说，如果我们测量神经活动（如发放率和局部场电位，LFP），理论上会看到这样的形式。请注意，在第二个时间步，也就是老鼠到达信息性线索位置时，信念发生了快速变化，并伴随出现相应的 LFP（虚线）。

7.4 信息搜寻

第 7.2 节中的模拟展示了一个简单的探索---利用权衡例子：先通过搜寻信息来消除不确定性，然后再利用已推断出的内容去满足先验偏好。本节将更细致地剖析认知价值这一概念。正如式 (7.4) 所示，它由两项组成：

$$
\begin{aligned}
I(\pi) &= H[Q(\tilde{o} \mid \pi)] - \mathbb{E}_{Q(\tilde{s}|\pi)}[H[P(\tilde{o} \mid \tilde{s})]] \\
&= D_{\mathrm{KL}}[P(\tilde{o} \mid \tilde{s})Q(\tilde{s} \mid \pi) \,\|\, Q(\tilde{o} \mid \pi)Q(\tilde{s} \mid \pi)] \\
&= \mathbb{E}_{Q(\tilde{o}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \pi, \tilde{o}) \,\|\, Q(\tilde{s} \mid \pi)]]
\end{aligned}
\tag{7.8}
$$

这三种写法分别突出了不同视角：第一行是后验预测熵减去期望模糊性；第二行把它写成互信息；第三行则把它写成信息增益，也就是显著性或贝叶斯惊奇。为了更直观地理解这些量，我们不妨借用视觉范式来说明：不同的眼跳（π）会导致不同注视位置（s）之间的转移。除了注视

位置之外，隐藏状态还包括各位置上刺激的身份。刺激身份与注视位置共同生成视觉和本体感觉上的后果（o）。

在这个框架下，后验预测熵可以理解为“如果我执行这次眼跳，我会看到什么”这一问题所对应的不确定性程度。从科学家的角度看，它衡量的是：如果我们执行某个实验，我们对将会获得的数据究竟有多不确定。沿着这个思路，选择那些后验预测熵最大的眼跳（或实验）是合理的，因为这类行为拥有最大的潜力去消除不确定性。如果我们已经高度确信某个实验会得到什么结果，那么去做它就几乎没有收益。

然而，预测熵只告诉我们总共有多少不确定性，并没有告诉我们其中有多少是真正可以被消除的。对于一串随机生成的数字，我们总会对下一个数感到不确定，但即便一直盯着它们看，我们也永远无法消除关于其生成过程的不确定性。这正是期望模糊性发挥作用的地方。它衡量的是观察结果与状态彼此独立的程度。如果状态总是生成同一个观察，这个量就为零；而如果像随机数生成器那样，状态与结果之间毫无关联，它就达到最大。在视觉领域中，这意味着最好的眼跳目标将是一个照明良好的刺激，因为对“如果我去看这个刺激，会看到什么”几乎没有模糊性。综合来看，最好的眼跳，也即最好的感知实验，是那些既存在大量不确定性有待消除（后验预测熵高），又确实可以被消除（模糊性低）的情形。有趣的是，这与统计学中根据信息增益来评估实验设计的表达式具有完全相同的形式（Lindley 1956）。

图 7.9 展示了在一个眼跳范式中（Parr and Friston 2017b），当我们操纵模糊性和后验预测熵时会发生什么。图中有四个刺激（方块），每个方块的颜色都会随时间变化。其上叠加了一条模拟的眼动轨迹，仿佛我们正在测量实验参与者注视的位置。关键在于，我们把对结果的先验信念设为均匀，也就是让务实价值不存在，从而排除了任何基于偏好的选择。这样一来，每一次眼跳都是为了最大化认知价值而被选中。当生成模型把四个刺激都视为等价时（左图），四个位置会以大致相同的频率被采样。然而，我们可以调节各刺激所对应的不确定性（见框 7.1）。如果我们把某个刺激设得更模糊，即通过增大对应 A 矩阵非对角元素的值，这个方块就会被忽略（中图）。这就是著名的“路灯效应”（streetlight effect）的一个例子（Demirdjian et al. 2005）。这个名称来自这样一个比喻：有人深夜丢了钥匙，最先找的地方往往是路灯下面，并不是因为钥匙最可能在那里，而是因为那里最容易获得高质量、低歧义、能够消除不确定性的信息。模拟表明，那个模糊的（例如光线昏暗的）方块会被忽略，从而在计算机模拟中复现了路灯效应。

相对地，图 7.9 右图展示了当我们让左下方方块的转移变得更难预测时会发生什么。我们会很快在该位置积累不确定性，因此在不改变模糊性的前提下，它拥有很高的后验预测熵。正如图中所见，这会导致眼睛更频繁地注视该位置，因为那里总有新的不确定性等待消除。直观来说，如果我知道某件东西的动力学非常可预测，那么我不必经常去看它，也可以对它的状态保持信心。相反，如果某件东西可能在我看别处的时候发生了变化，那么值得回头去检查。这些模拟的目的，是帮助我们建立对认知价值两部分的直觉理解，并看清期望自由能最小化如何确保我们主动选择感觉数据，以便更好地了解世界。

框 7.1：不确定性与精度

图 7.7 中的例子诉诸了“精度”这一概念，而这是本书中的一个重要思想。精度是方差的倒数，用于刻画我们对某个概率分布的置信程度。它与一个分布的负熵（negentropy）密切相关：

$$-H[P(s)] = \mathbb{E}_{P(s)}[\ln P(s)] \tag{7.9}$$

要给一个分布加上“可以变得更精确或更不精确”的参数化方式，最简单的方法之一就是采用带有逆温参数 ω 的 Gibbs 形式。其表达式为：

$$P(s \mid \omega) = \mathrm{Cat}(\sigma(\omega \ln D)) \tag{7.10}$$

注意，精度是乘在对数先验上的，因此它可以被理解为一种增益控制装置，即它会放大神经信号，而不是简单地把信号相加。图 7.8 中的图像展示了：对同一个 D，当我们改变 ω 时，概率分布会如何变化（每一列代表某个备选状态的概率）。可以看到，随着精度升高，置信度也在升高。

这种参数化方式可以应用到 POMDP 中用到的任何分布上。此外，我们还可以对精度本身定义先验，并像推断其他潜变量一样去推断它，即通过自由能最小化。若假定先验服从 Gamma 分布（从而排除精度取负值的可能），则可得到如下更新式（推导见附录 B）：

$$\begin{aligned} P(\omega) &= \Gamma(1, \beta^{\omega}) \\ Q(\omega) &= \Gamma(1, \beta^{\omega}) \\ \Rightarrow \beta^{\omega} &= (D\beta^{\omega} - s) \cdot \ln D + \beta^{\omega} - \beta^{\omega} \end{aligned} \tag{7.11}$$

越来越多的研究认为，这些精度参数在生物学上的底层载体，可能正是那些调节神经反应增益的神经调质系统。第 5 章讨论了将这些参数与特定神经化学物质相联系的证据。

7.5 学习与新颖性

第 7.2 至 7.4 节已经给出了大多数主动推断实际应用所需要的一切。不过，在前面的讨论中，我们一直假定生成模型本身是已知的，并且不会因学习而发生改变。而在一些实际应用中，我们可能希望考虑生成模型的某些部分（例如 A 矩阵或 B 矩阵）如何在实验过程中被学习；更广泛地说，还希望考虑如何在已有数据的基础上优化生成模型的结构本身（Friston, FitzGerald et al. 2016）。一旦如此，主动推断就扩展为主动学习，而描述“关于状态的信息增益”的显著性（式 (7.5) 之后的讨论，或更准确地说式 (7.8) 中的量）就会得到一个补充：新颖性。新颖性关心的，是例如式 (7.1) 中 A 矩阵元素、式 (7.2) 中 B 矩阵元素，或生成模型其他参数上的不确定性如何被消除。此时，这些信念不再像之前假定的那样固定不变，而是可以随时间变化（Schwartenbeck

et al. 2019)。为了达到这一点，我们首先必须像图 7.10 那样扩展生成模型，把关于这些模型参数的信念也包含进来。

从概念上说，把关于参数的信念纳入生成模型，就意味着可以把学习也看作另一种贝叶斯推断：也就是从关于模型参数的先验信念，过渡到后验信念。这凸显了感知与学习在根本上的相似性：就像感知可以描述为通过反演生成模型来根据观察推断隐藏状态一样，学习也可以描述为反演一个包含参数信念的生成模型，只不过这种反演通常运行在更慢的时间尺度上。

框 7.2：共轭先验

在搭建图 7.10 这种形式的生成模型时，审慎选择适合先验信念的分布极其重要。通常，这应该是与似然相对应的共轭先验分布。所谓共轭先验，是指在进行贝叶斯推断时，后验信念会保持与先验相同的分布类型。举例来说，根据贝叶斯公式：

$$P(D \mid s) \propto P(D)\, P(s \mid D) \tag{7.12}$$

如果 $P(s \mid D)$ 是类别分布，那么只要我们为 $P(D)$ 选择与类别分布共轭的 Dirichlet 分布，就可以保证 $P(D \mid s)$ 也仍是 Dirichlet 分布。形式化地写：

$$\left.\begin{aligned} P(D) &= \mathrm{Dir}(d) \\ P(s \mid D) &= \mathrm{Cat}(D) \end{aligned}\right\} \Rightarrow P(D \mid s) = \mathrm{Dir}(d) \tag{7.13}$$

要选择合适类型的先验，最简单的办法就是查找与当前似然分布形式相对应的共轭先验。对于本章使用的类别分布，适合作为参数信念的就是 Dirichlet 分布（见框 7.2）。引入这些额外的先验信念之后，我们现在就可以优化关于生成模型结构的后验信念。这意味着，要像第 4 章中处理状态那样，把这些量纳入自由能之中，并寻找自由能的极小值：

$$\theta = (A, B, C, D, E) \tag{7.14}$$

$$F = \mathbb{E}_{Q(\pi,\theta)}[F(\pi,\theta)] + D_{\mathrm{KL}}[Q(\theta) \| P(\theta)] + D_{\mathrm{KL}}[Q(\pi) \| P(\pi)] \tag{7.15}$$

Dirichlet 分布由计数（或伪计数）参数化，这些参数表示某个类别变量出现过多少次；对于先验而言，则表示“仿佛它曾被观测到这么多次”。关于这些参数的更新规则推导，可见附录 B。这里我们先概括其更新规则与 Dirichlet 分布的几个关键性质，重点关注与 A 的先验和后验相联系的浓度参数 a 与 $\bar{a}$：

$$
\begin{aligned}
\bar{a} &= a + \sum_{\tau} s_\tau \otimes o_\tau \\
\mathbb{E}_Q[A_{ij}] &= \bar{A}_{ij} \approx \frac{a_{ij}}{a_{0j}} \\
\mathbb{E}_Q[\ln A_{ij}] &= \ln \bar{A}_{ij} = \psi(a_{ij}) - \psi(a_{0j}), \qquad a_{0j} = \sum_k a_{kj}
\end{aligned}
\tag{7.16}
$$

第一行表达的是：在经历了一系列观察之后，并结合对引起这些观察之状态的信念，浓度参数如何从先验更新为后验。圆圈中的叉号表示 Kronecker 张量积（当作用于两个向量时，就是外积）；在这里，它生成一个矩阵，其每个元素都等于 s_τ 和 o_τ 中某一对元素的乘积。这个更新规则可以被简单理解为一种活动依赖型可塑性：当某个结果被观测到，同时我们在后验上相信某个特定状态导致了这一结果，那么表示两者关系的矩阵元素就会增加。第二行强调了把 Dirichlet 浓度参数理解为“计数”的意义：对于给定状态（某一列），a 中每个元素都表示相应结果出现过多少次。把它除以这一列元素之和（即总观测次数或总伪观测次数），就得到在该状态下各结果的概率。

要理解这种（伪）计数方法为什么直观，可以回到本章开头的业余音乐家例子。如果我们统计：当她本来想弹第一个音符时，实际弹出第一个音符多少次（第一行第一列）；想弹第二个音符时，实际弹出第二个音符多少次（第二行第二列）；依此类推；然后把这些计数除以她每个目标音符总共尝试过多少次，那么最终就会收敛到式 (7.1) 所示 A 矩阵的正确数值，也就是她有 70% 的概率会正确命中自己想弹的音符。计数法还带来另一个重要后果，我们稍后还会回到这一点：在一次观察发生之前，已经积累了多少计数或伪计数，会决定我们在看到这个观察时多大程度上更新自己的信念。设想我们掷一枚硬币五次，结果连续五次都是正面，这可能会使我们倾向于认为这是一枚不公平的硬币；但如果在此之前已经掷过 100 次，并且其中 50 次正面、50 次反面，那么最后这连续五次正面，对我们关于“这枚硬币是否公平”的信念影响就会很小。式 (7.16) 的第三行给出了与 Dirichlet 分布有关的一个有用恒等式：随机变量对数的期望，可表示为两个 digamma 函数（Gamma 函数导数）之差。

这种以推断来理解学习的方式，突显了主动推断与大多数计算神经科学和机器学习方法之间的重要差异。后者往往引入各种学习规则，例如 Hebb 规则或误差反向传播，并把它们视作生物学上更真实或计算上更高效的机制；而在主动推断中，支配学习的更新规则是从统计学考虑中推导出来的，但它们最终却与生物学上关于活动依赖型可塑性的规则惊人地相似（见上面对式 (7.16) 第一行的讨论）。这正体现了规范性方法的一大吸引力：它从第一原理出发，不仅解释我们已经知道的大脑与行为事实，也解释那些我们之前并不知道的现象。

主动推断与大多数机器学习方法的另一个差别是：学习在这里天然被描述为一个主动过程，生物体会自主选择最有利于改进其生成模型的数据。当我们把关于参数的信念纳入模型时，这一点就变得尤其明显，因为期望自由能会多出一项：

$$
\begin{aligned}
G(\pi) &= D_{\mathrm{KL}}[Q(\tilde{o} \mid \pi) \| P(\tilde{o} \mid C)] + \mathbb{E}_{Q(\tilde{s}|\pi)}[H[P(\tilde{o} \mid \tilde{s})]] \\
&\quad + \mathbb{E}_{Q(\tilde{o},\tilde{s},\theta|\pi)}[\ln Q(\theta) - \ln P(\theta \mid \tilde{o}, \tilde{s})] \\
&= -\mathbb{E}_{Q(\tilde{o}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \pi, \tilde{o}) \| Q(\tilde{s} \mid \pi)]] \\
&\quad - \mathbb{E}_{Q(\tilde{o},\tilde{s}|\pi)}[D_{\mathrm{KL}}[Q(\theta \mid \tilde{o}, \tilde{s}) \| Q(\theta)]] \\
&\quad - \mathbb{E}_{Q(\tilde{o}|\pi)}[\ln P(\tilde{o} \mid C)]
\end{aligned}
\tag{7.17}
$$

前两节已经有了显著性与务实价值项，但这里新增的是新颖性项。最后一个等式的写法凸显了显著性与新颖性之间的关系。简而言之，显著性之于推断，正如新颖性之于学习。二者都表达了这样一个思想：一旦执行了某个感知实验（也即策略中的一个动作），我们的信念会发生多大变化。正如科学实验一样，数据收集之后信念变化越大，这个实验就越“好”。

回到掷硬币并累积计数的比喻，它还能告诉我们另一件有用的事。假如我们有两枚硬币，而且可以任选其一来掷，那么如果想引发最大的信念变化，我们应该去掷那枚之前只掷过 5 次的硬币，而不是那枚已经掷过 100 次的硬币。前者具有更大的新颖性，因为我们对它还不熟悉。类似地，如果我们对某些变量的先验信念非常确信，就好像已经观测过它们很多次一样，那么去探查这些变量的策略所对应的新颖性就会比探查那些我们知之甚少的变量要低。

为了说明这一点在实践中如何运作，设想一个高度近视的生物站在铺有瓷砖的地板上。这个生物只能看到自己脚下那块砖的颜色，而且每次只能移动一块砖的距离。对于一个足够大、包含许多砖块的场景而言，如果把每块砖的颜色都表示为不同的隐藏状态，在计算上会非常昂贵。不过有一种更简单的模型可用：如果我们只把位置与隐藏状态相关联，把颜色只与结果相关联，那么就可以把“如果我走到那边，会看到什么”这样的信念高效地表示在一个由位置生成彩色砖块的 A 矩阵中。通过累积 Dirichlet 参数（式 (7.16)），这个生物可以基于观察去优化这些信念。我们可以把这理解为一种突触记忆，而不是通过持续的神经活动来维持“某块砖是什么颜色”的信念。对于这种生成模型而言，所有不确定性都位于似然分布的参数中；于是，在没有任何偏好的情况下（也就是式 (7.17) 中新颖性主导策略选择时），看看会发生什么就很有意思。图 7.11 展示了一个由 64 块黑白砖组成的简单环境的模拟。每访问一块砖，关于该位置出现黑色还是白色的似然信念都会通过累积 Dirichlet 参数而得到更新。由于较大的 Dirichlet 参数会阻止信念发生大幅更新，期望自由能最小化所驱动的新颖性消解，会使我们的模拟生物避免回到任何之前已经访问过的位置。

同样的原理还可以应用到许多其他范式中。例如，如果我们把该生物的移动路径重新解释为一条眼跳扫描路径，那么这个框架就可以用于主动视觉采样。在主动视觉领域，这一框架已经被用来模拟由目标划消任务所诱发的视觉搜索行为（Parr and Friston 2017a）。随后，相关研究还展示了在这种情境下积累 Dirichlet 参数所需的短时程可塑性的证据（Parr, Mirza et al. 2019）。

正如我们能够把关于推断的思想扩展到学习一样，我们还可以至少再向前迈一步，去思考结构学习：它不只是优化模型中的参数，而是在参数多少不同的模型之间进行选择。框 7.3 给出了一种实现方式：它允许对不同假设模型进行高效的事后比较。这种思路已被用作睡眠的隐喻（Friston, Lin et al. 2017），以及静息态自发活动的隐喻（Pezzulo, Zorzi, and Corbetta 2020）：即便没有收集新的数据，模型的结构仍然可以被精炼和简化。

框 7.3：结构学习与模型约简

第 7.5 节前半部分讨论的是一种重要但有限的（参数性）学习形式。进一步的复杂化，也就是学习世界结构本身，超越了对模型参数的优化，而转向这样一个问题：我们是否应该扩展模型结构，或者修剪模型结构？这可以被表述为模型比较问题（Friston, Lin et al. 2017）。换句话说，如果我消除似然矩阵中的某些元素，自由能会升高还是降低？通过比较含有这些元素和不含这些元素的模型，我们就可以回答这个问题。然而，显式地反演多个模型可能代价很高。幸运的是，有一种高效方法可以做到这一点，这就是贝叶斯模型约简（Friston, Litvak et al. 2016; Friston, Parr, and Zeidman 2018）；它只需要反演一个完整模型。在一般情形下，完整模型与采用另一组先验（记作 ˜）的模型之间的比较，可通过下列公式实现：

$$\Delta F = F[\tilde{P}(\theta)] - F[P(\theta)] = \ln \mathbb{E}_{Q(\theta)}\left[\frac{\tilde{P}(\theta)}{P(\theta)}\right] \tag{7.18}$$

$$\tilde{Q}(\theta) \propto \exp\Big(\ln Q(\theta) + \ln \tilde{P}(\theta) - \ln P(\theta) + \Delta F\Big) \tag{7.19}$$

对第 7.5 节使用的 Dirichlet 先验而言，上式可写成如下形式（其中 B 是多元 Beta 函数）：

$$\Delta F = \ln B(\tilde{d}) - \ln B(d) + \ln B(a) - \ln B(\tilde{a}) \tag{7.20}$$

$$\tilde{a} = a + \tilde{d} - d \tag{7.21}$$

这种模型约简形式，可能有助于理解离线状态下的模型优化，例如睡眠中可能发生的那种优化。第 8 章中，当我们讨论同时具有离散与连续成分的层级模型优化时，还会简要回到贝叶斯模型约简。

7.6 层级推断或深度推断

上一节中，我们看到了一种对原始生成模型进行层级扩展的方法，即为生成模型的参数定义先验。图 7.12 展示了第二种层级形式，它关涉时间尺度的嵌套。这个用于层级推断或深度推断的生成模型，可以被看作图 7.3 所示浅层模型的层级扩展：在较低层级上，它包含一系列与图 7.3 相同的 POMDP 模型（其中一个例子由虚线框标出），而这些低层模型又被更高一层的 POMDP 所情境化。

重要的是，这个生成模型包含了在不同时间尺度上演化的变量：高层级变化较慢，低层级变化较快（Friston 2008; Friston, Rosch et al. 2017; Pezzulo, Rigoli, and Friston 2018）。这一点可以从如下事实中看出：第 1 层的 POMDP 模型各自演化 3 个时间步，但这些短轨迹中的每一条，都依赖于高层级（第 2 层）上的一个单一状态，而这个高层状态在整个低层轨迹期间保持不变。

换句话说，从高层级的视角看，每经过 1 个时间步，低层级实际上已经运行了多个（这里是 3 个）时间步。

为了对这种时间尺度分离，也就是支撑深度时间推断的机制，形成一些直觉，不妨考虑日常生活中的一个简单层级例子：阅读。我们对构成句子的词进行推断；句子又组合成段落；段落构成页面；页面构成书籍；书籍构成图书馆，以此类推。如果我们把图 7.12 低层级中的每个状态想象成一个词，那么高层级中的每个状态就可以看作一个句子。关键在于，句子的持续时间跨越了序列中任何单个词的持续时间。

阅读的例子在图 7.13 中有更详细的说明，它基于 Friston, Rosch et al. (2017) 的例子，更多细节可参见该文。该模型的结构与图 7.12 相同，表示一个非常简单语言中的句子（高层）与词（低层）。这个语言包含三个可能的词：*flee*、*feed*、*wait*，它们可以组成六种可能的四词句子。如果句子是 “flee, wait, feed, wait”，那么高层会对第一个低层 POMDP 预测词 *flee*，对第二个低层 POMDP 预测词 *wait*，依此类推。在低层，我们从一个基于高层的经验性先验 D 出发，它告诉我们哪些词更可能出现。例如，如果我们在图 7.13 上方面板所示句子上采用均匀分布，那么会发现第一个词在其中三分之二的句子里是 *wait*，其余三分之一则是 *flee*。这意味着，在第一个低层 POMDP 的第一个时间步中，我们的 D 向量就应当为这些词赋予相应概率。

低层的词随后会生成观察，也就是基于当前注视于词的哪一部分所形成的视觉输入。与图 7.9 的例子类似，这个 POMDP 允许选择不同的中央凹注视目标，从而为各个假设词积累支持或反对的证据。这同样诉诸前文已经介绍过的期望自由能最小化过程，因此我们这里不再详细展开具体的注视动作，只指出：随着低层级每一个时间步的推进，对当前词的置信度都会提高。在图 7.13 所示的序列中，我们看到在前几个快时间尺度 $\tau^{(1)}$ 的时间步里，低层为 *flee* 这个词积累了证据。这一推断随后被向上传播到高层，于是为第一句和第四句提供支持，因为它们都以这个词开头。在后续时间步中，低层积累到的证据与这两个句子都一致。到了第四个慢时间尺度 $\tau^{(2)}$ 的步骤，在第一句之下我们会预测 *wait*，在第二句之下则会预测 *flee*。当在快时间尺度上推断出的是 *wait* 时，慢时间尺度上的第一句便被推断出来。到最后一步，模拟成功选中了正确句子，并获得正确反馈作为奖励。由此产生的信念更新可以在图 7.12 下部的 LFP 图中看到。

这类深度时间模型已被用于模拟阅读（Friston, Rosch et al. 2017）、延迟期工作记忆任务（Parr and Friston 2017c），以及为视觉推断计算经验性先验（Parr, Benrimoh et al. 2018）。此外，它们还被用于关于动机与控制的理论解释（Pezzulo, Rigoli, and Friston 2018）。原则上，这类模型可以扩展到任意多的层级，从而刻画一个具有深度结构、并且在许多不同时间尺度上展开动力学的世界。

我们还可以在图 7.12 与图 7.13 那类层级模型，以及图 7.10 那类学习模型之间，看出一个有趣的平行关系。学习模型可以被视为层级生成模型，它强调的是较快的推断动力学（对状态信念的更新）与较慢的学习动力学（对参数信念的更新）之间的时间尺度分离。图 7.10 与图 7.12 所示的模型还可以按照任意复杂度进行组合；在这样的组合中，不同层级变量之间的关系本身也可以被学习。这使得我们能够设计出越来越复杂的生成模型，以应对系统层面的认知与神经生物学问题。

7.7 总结

本章展示了如何构造离散时间生成模型，以处理一系列认知与神经生物学问题，例如感知推断、决策与规划、探索与利用的平衡、参数学习与结构学习，以及新颖性搜寻。这当然远不能穷尽离散模型在主动推断中的全部应用，但它足以说明这类建模的关键原则。前面介绍的模型可以进行层级组合，可以加入参数上的先验，也可以为策略或偏好引入情境敏感的先验。更重要的是，无论是简单生成模型还是更复杂的生成模型，其推断都始终可以通过自由能最小化来推进，这恰好说明了这种方法的普适性。主动推断的不同方面会在不同生成模型下显现出来，例如当我们为模型参数引入先验时，新颖性搜寻就会浮现出来；这为通过设计合适的生成模型来探索一个开放无边的认知与生物学问题集合，打开了可能性。

第八章　连续时间中的主动推断

8.1　引言

万物流变，无物恒常不动。

— 赫拉克利特，公元前 501 年

本章在第 7 章的基础上继续讨论如何构建生成模型。这里的重点是连续状态空间模型。这类模型尤其适合刻画作用于感觉受体的物理波动，以及我们用来改变周围世界的效应器（例如肌肉）的连续运动。这些模型有许多应用。本章将说明其使用背后的基本原理，突出运动控制中常用的模型类型，以及在此类模型中发挥作用的动力系统，并简要讨论广义同步这一概念。最后，我们将讨论离散生成模型与连续生成模型之间如何得到统一。

8.2　运动控制

正如我们在第 4 章所见，支撑连续时间主动推断的生成模型可以写成一对随机方程，它们决定了状态 x 如何生成数据 y，以及状态如何在某个静态变量 v 的作用下随时间演化：

$$
\begin{aligned}
y &= g(x) + \omega_y \\
\dot{x} &= f(x, v) + \omega_x
\end{aligned}
\tag{8.1}
$$

这些方程以及与波动 ω 相关的精度，共同决定了用于推断感觉原因的模型。

注意，动作并未出现在公式 8.1 中。这是因为，如第 6 章所述，动作属于生成过程，而不属于生成模型。生成模型只处理那些会被马尔可夫毯之外的状态直接影响的变量。如果我们要写出真实世界的动力学，也就是生成过程，就必须把动作 u 包含进来：

$$
\begin{aligned}
y &= g(x) + \omega_y \\
\dot{x} &= f(x, u) + \omega_x
\end{aligned}
\tag{8.2}
$$

需要注意的是，用来定义生成模型（公式 8.1）的函数 g 与 f，以及 ω 的精度，并不一定与定义生成过程（公式 8.2）时使用的函数相同。正如我们在第 2–4 章中看到的，动作会改变感觉数

据，使自由能最小化。这意味着，我们不需要在生成模型中显式写出动作的动力学，它们会从公式 8.1 中各项的具体选择里自然涌现。为了建立直觉，我们从一种非常简单的生成模型开始：

$$g(x) = x \tag{8.3}$$

$$f(x, v) = v - x$$

公式 8.3 表明，隐藏状态表示数据的期望值，并且它服从一个简单的，也就是点吸引子的动力学。所谓吸引子，是指当 $x < v$ 时，x 的期望变化率为正；反之则为负。这意味着 x 总会流向 v，也就是 v 是一个吸引点或固定点。为了生成数据，我们定义一个简单的生成过程：

$$g(x) = x \tag{8.4}$$

$$f(x, u) = u$$

在最小化自由能时，这意味着动作会发生变化，以满足公式 8.3 的预测。如果 μ 是 x 的期望值，那么能够最小化预测数据 $g(\mu)$ 与观测数据 y 之间差异的动作，就是令 $u = v - \mu$。这正是“平衡点假说”的一种表达（Feldman and Levin 2009）。该假说认为，运动控制可由反射弧实现，肢体只需被简单地拉向由下行运动信号设定的平衡点。在主动推断框架下，这些信号是预测，更具体地说，是本体感觉预测，例如对肢体或眼睛预期位置的预测（Adams, Shipp, and Friston 2013）。因此，运动控制就是通过动作实现对这些（本体感觉）预测的满足，如图 8.1 的示意所示。值得注意的是，这一方案并不需要规定“逆模型”，也就是那种从期望后果映射到实现该后果所需运动指令的模型；而这类逆模型在其他运动控制理论中被广泛使用（Wolpert and Kawato 1998）。

公式 8.3 所表达的是我们可以在生成模型中使用的最简单吸引子系统。但在许多情形下，它过于简单，因为更现实的情况需要服从牛顿动力学。更复杂的模型会认识到，由肌肉产生的力改变的是速度，也就是引起加速度，而不是直接改变位置。公式 8.5 明确说明了这一点，其中 x_1 是位置，x_2 是速度：

$$f(x, v) = \begin{bmatrix} x_2 \\ \frac{\kappa}{m}(v - x_1) \end{bmatrix} \tag{8.5}$$

这个表达式等价于服从胡克定律的弹簧动力学。位置变化率（第一项）就是速度；速度变化率（第二项）与当前位置和点 v 之间的距离成正比，其比例常数由物体质量 m 与弹簧常数 κ 的比值给出。若两边同乘质量，则可得到由连接点 v 与 x_1 的弹簧所产生的力[1]，即 $\kappa(v - x_1)$，它等于质量乘以速度变化率。这正是牛顿第二定律。换言之，我们可以写下一个生成模型，预测如果有一根弹簧把肢体拉向某个期望位置，会出现怎样的动力学。通过预测这种牛顿力学所导致的（本体感觉）数据，我们就能够实施满足这些预测的运动。

[1]原文在此处标注脚注编号 1。

8.3 动力系统

如 8.2 节所述，主动推断的连续时间形式特别适合刻画运动。更一般地说，它适合用于指定非线性动力系统的生成模型，在这类系统中，对时间和空间进行离散化会显得低效。最简单的动力系统形式就是公式 8.3 中的吸引子，但更复杂的系统可以产生丰富得多的行为。受本书篇幅限制，我们无法充分介绍基于更复杂动力系统的大量模型研究工作，不过可参见表 8.1 中列出的一些关键进展。这里我们聚焦于理解这些系统所需的若干基本原理。本节将简要概述两类被用于构造此类生成模型的动力系统：Lotka–Volterra 动力学和 Lorenz 系统。前者可以用于描述那些动力学具有顺序性的系统，后者则代表混沌系统。

Lotka–Volterra 动力学起源于生态学中对捕食者--猎物关系的刻画。虽然它后来被应用到许多学科，但捕食者--猎物系统仍是帮助我们形成直觉的有用例子。当捕食者数量较少时，猎物数量可以增长到相对较大的规模。这又为捕食者提供了更多食物，从而使捕食者数量增长。捕食增加会使猎物数量下降，进而又导致捕食者数量下降。随后，这一循环继续进行。于是就会出现一种振荡模式：先是猎物种群达到峰值，然后是捕食者种群达到峰值，接着又轮到猎物，如此往复。如果把这一机制推广到两个以上的种群，例如食肉动物、食草动物和植物三个种群，我们就可以生成一串峰值序列。图 8.2 展示了三个种群下的广义 Lotka–Volterra 动力学，其形式如下：

$$f(x, v) = x \circ (v + Ax) \tag{8.6}$$

这里的 x 与前面一样是一个向量；符号 $\circ$ 表示按元素相乘。向量 v 给出内禀的出生率与死亡率，矩阵 A 的元素则表示不同物种之间的关系：若矩阵中某列索引的物种捕食某行索引的物种，则对应元素为正；若关系相反，则为负。

图 8.2 清楚表明，只要生成模型中包含 Lotka–Volterra 动力学，就能够实现时间顺序结构（Huerta and Rabinovich 2004），具体取决于当前哪个峰值最高。每一条曲线都可以被看作一个隐藏状态，而不必真的对应一个物种。图 8.3 突出了两种利用这类动力学来生成行为的重要例子。其一是一个层级模型，它利用 Lotka–Volterra 系统所提供的顺序动力学，来安排条件刺激相对于眨眼反应的时序（Friston and Herreros 2016）。这一范式基于用于研究小脑功能的实验：一个无条件刺激，例如朝动物眼睛吹气，会引发眨眼反应；如果多次在无条件刺激之前播放一个条件刺激，例如听觉音调，那么动物就可以通过学习（见框 8.2）Lotka–Volterra 动力学中条件刺激与无条件刺激之间相隔的峰值个数，学会预先眨眼，以恰当时机应对气流刺激。这是一种时间学习，因为峰值个数为条件刺激到无条件刺激之间的时间间隔提供了一个隐式估计。

图 8.3 的第二个例子中，每个顺序峰值都与一个不同的吸引点相关联，这些吸引点驱动动作依次移动到一系列位置，而这些位置被安排成类似手写笔画的轨迹（Friston, Mattout, and Kilner 2011）。这两个例子表明，广义 Lotka–Volterra 系统能够利用连续动力系统来提供对顺序动力学的有效建模。

8.3.1 框 8.1：精度、注意与感觉衰减

我们在第 7 章中已经讨论过精度的重要性，但仍有必要回顾它在连续时间系统中的作用。在许多方面，这一概念在连续时间背景下更自然，因为变量 Π 直接作为拉普拉斯近似的结果出现。它在推断动力学中直接充当乘性增益（见图 8.1），不同的精度会为信念更新中的不同影响因素赋予不同权重。

将精度解释为突触增益，使其与若干重要的神经生物学问题联系起来。从经验角度看，更高的精度意味着更强烈的信念更新。在电生理研究中，这可能表现为振幅更大且峰值更早的诱发反应；在单细胞记录中，则可能表现为当刺激落入某个神经元感受野时，该刺激对神经元放电率产生乘性影响。这些现象常常与注意加工联系在一起，即某一个感觉通道，或某些通道的子集，相对于其他通道被优先处理。从主动推断的角度看，精度与注意是同义词。利用这一点，人们已经在计算机仿真中复现了多种注意现象，包括 Posner 范式（Feldman and Friston 2010）。具体而言，如果用一个线索来预测来自两个位置之一的感觉输入精度，那么模型就能够复现实证发现：位于被提示位置的刺激，其反应速度快于位于另一位置的刺激。

精度控制的第二个重要方面，是它在运动生成中的作用。为了理解这一点，不妨设想缺乏这种控制会发生什么。首先设想感觉数据以高精度被预测。这样一来，来自这些数据的信息就被赋予较高的突触增益，从而产生关于身体某部分位置的真实推断。问题在于，在主动推断中，运动指令与预测是等价的。一个准确的“我没有在动”的信念，无法用来预测运动的感觉后果，而这种预测恰恰是启动运动所必需的。在高精度感觉输入下，“我正在移动”这一信念会立刻在相反证据面前被纠正，因此动作无法执行。这告诉我们一个重要事实：为了生成运动，我们必须能够暂时忽略该运动的感觉后果，从而形成一个起初并不为真的信念，即“我正在移动”。一旦这个信念建立起来，运动的本体感觉及其他感觉后果就可以被预测，并通过图 8.1 所示的机制付诸实现。对相反证据的这种忽略被称为“感觉衰减”，它代表了运动得以发生所需的精度下降（Brown, Adams et al. 2013; Pezzulo 2013; Seth 2013; Pezzulo, Rigoli, and Friston 2015; Seth and Friston 2016; Allen et al. 2019）。显然，在两次运动之间恢复这种精度是有益的，因为这样才能基于感觉输入进行适当推断。这意味着一个周期性过程：先衰减，再运动；例如扫视期间视觉输入被周期性抑制，随后扫视本身又被抑制。把运动建立在注意暂时中止之上的观点，与一种起源于 19 世纪的意念运动理论密切相关，该理论最初用于解释催眠状态下诱发的动作。

8.3.2 框 8.2：连续模型中的学习

如第 7 章所述，学习是对生成模型参数 θ 的信念进行优化的过程。在连续时间域中，这意味着要随时间积累证据。其工作方式可以理解为：把一系列无穷小时间区间中的数据视作满足 i.i.d.（独立同分布）假设，并构造一个由时间不变参数生成观测的生成模型：

$$\begin{aligned}\ln p(y,\theta) &= \ln p(\theta) + \int \ln p(y(t) \mid \theta)\, dt \\ &\approx \ln p(\theta) - \int F[y(t) \mid \theta]\, dt\end{aligned}$$

这可以用来构造一个泛函 S，它通过对条件于参数的自由能做时间积分，扮演参数自由能的角色。采用拉普拉斯近似，可得

$$
\begin{aligned}
S(\theta) &= \mathbb{E}_{q(\theta)}\left[\ln q(\theta) + \int F[y(t) \mid \theta]\, dt - \ln p(\theta)\right] \\
&\approx \int F[y(t) \mid \mu_\theta]\, dt - \ln p(\mu_\theta) \\
\dot{\mu}_\theta &= \partial_{\mu_\theta} S(\mu_\theta) \\
&= \partial_{\mu_\theta} \ln p(\mu_\theta) - \partial_{\mu_\theta} \int F[y(t) \mid \mu_\theta]\, dt \\
&= \partial_{\mu_\theta} \ln p(\mu_\theta) - \alpha \\
\alpha &= \partial_{\mu_\theta} F[y(t) \mid \mu_\theta]
\end{aligned}
$$

其中，α 起到积累自由能梯度，也就是证据梯度的作用。

第 7 章中的 POMDP 形式，在主动推断应用中很大程度上已经取代了广义 Lotka–Volterra 系统的使用。不过，把这种动力学记作一种可能支撑第 7 章离散顺序动力学的连续系统，仍然是有益的。此外，Lotka–Volterra 系统还明确区分了两类表征：一类是 temporally deep planning 中与序列有关的表征；另一类则是在广义运动坐标中对变化率的表征（见第 4 章）。二者各有位置，但处理的是不同类型的问题。

第二类在主动推断研究中被广泛应用的动力系统是 Lorenz 系统：

$$
\dot{x} = \begin{bmatrix} \sigma(x_2 - x_1) \\ x_1(\rho - x_3) - x_2 \\ x_1 x_2 - \beta x_3 \end{bmatrix} \tag{8.7}
$$

这些参数分别被称为 Prandtl 数 σ、Rayleigh 数 ρ，以及一个与系统物理性质相关的常数 β。根据这些参数取值的不同，系统可能表现出截然不同的行为。Lorenz 吸引子最初是为了解释大气对流动力学而提出的。其漫游式行为促使人们将其纳入生成模型，用于模拟具有挑战性的推断问题。一个重要例子是鸟鸣模拟，下一节将详细展开。此类系统也被用来模拟简单物理系统，并研究在何种条件下其行为开始表现出类似有感知主体的特征。图 8.4 展示了 Lorenz 系统在一组示例参数下的行为。

8.4 广义同步

如上所述，连续状态空间模型的一个关键应用例子，是一系列基于合成鸟鸣的研究（Friston and Frith 2015b）。这些研究的一个重要方面是通信与多主体推断问题。其核心思想在于：一个生物体能够使其内部状态与外部世界中的某物同步，这本质上就是推断。当外部之物是另一个拥有相似模型的生物体时，这种同步就意味着，一个生物体的内部状态应当逐渐变得与另一个生物体的内部状态相似。这可以被视为一种原始形式的心智理论。

图 8.5 展示了用于模拟鸣禽的生成模型。在这个层级模型中，高层状态（第 2 层）按照一个缓慢的 Lorenz 系统演化。该系统的一个维度又被用来参数化低层，也就是第 1 层中一个更快 Lorenz 系统的 Rayleigh 数。随后，低层变量映射到感觉性的声谱图数据。与图 8.1 类似，生成过程还额外包含动作；只不过这里动作并不是移动肢体，而是影响鸣禽的发声器官，从而使鸟能够影响声谱数据。与前面一样，动作被生成出来以消除预测误差。这意味着，如果一只鸟听到了它正在预测的歌曲，它就没有必要自己发声；但如果它预测某段歌声却没有听到，那么它就必须开始歌唱，以消除误差。

当场景中有两只鸟，而且它们的生成模型具有相似结构时，这种动力学就会变得更有趣。只要一只鸟在唱，另一只就不需要唱，因为没有需要消除的误差。然而，如果一只鸟停止歌唱，另一只就必须把同一首歌继续唱下去。这就产生了一种轮流接唱的形式，有时被表述为“唱同一本圣歌本上的歌”，即每只鸟都贡献同一首歌中的一部分。是什么导致了这种轮替？为什么一只鸟不会把整首歌都唱给同类听？答案与感觉衰减有关（见框 8.1）：发声以产生鸟鸣需要降低对动作后果预测的精度。正如在扫视眼动中一样，这意味着主体必须在两种状态之间交替：一是注意感觉数据（视觉或听觉数据），二是在执行旨在改变这些数据的动作期间对感觉影响进行衰减。当系统中涉及两个主体时，这就导致了在倾听对方与自己歌唱之间的交替，也就是一种简单形式的对话。

要使这种合成对话顺利工作，关键在于两只鸟必须彼此同步，并知道自己当前处于歌曲，也就是对话轨迹的哪个位置。这意味着，两只鸟在生成模型中对隐藏状态的推断必须保持一致。图 8.5 右上角展示了一个同步流形，其对象是两只尚未针对彼此优化自身生成模型的鸟；该图描绘了每只鸟对高层隐藏状态所持信念的轨迹。所谓同步，意味着当一只鸟推断出某个特定隐藏状态取值时，另一只鸟也应推断出相同的值；因此，我们会预期这条轨迹贴近 $x = y$ 这条直线，从技术上说这叫作混沌系统的相同同步。围绕这条直线的波动意味着同步不完美，图中的确如此。然而，在两只鸟彼此接触，并学习了对方生成模型的参数之后（见框 8.2），同步就几乎完美了，如图右下所示。这意味着，每只鸟都已经学会了关于另一只鸟的内容，并且能够推断对方“脑中正在发生什么”。简而言之，它们学会了共享同一个叙事，也就是“唱同一本圣歌本上的歌”。

更一般的同步形式并不要求行为必须沿着 $x = y$ 这条线同步。在广义同步中，联合行为所占据的空间维度更低，是一个低维空间，而不是原本可能占据的更高维空间。具体到这里，它占据的是低维的一维空间，而不是更高的二维空间。不过，这个低维空间，也就是同步流形，可以是弯曲的，也可以具有其他形状。这类似于我们虽然生活在二维的地表上，但这个地表本身其实弯曲成一个三维球面。除了在社会行为中的核心作用之外，广义同步，即在高维联合空间中占据一个低维区域，对于把生物系统描述为在进行推断也极其重要；此时所谓推断，正是内部状态与外部状态之间的广义同步。尽管本书没有篇幅深入展开这一庞大主题，但从推断视角出发，我们可以理解某些神经精神综合征，例如自闭症，与广义同步失效之间的关系。需要指出的是，这种同步不仅对连续时间模型重要，在涉及多个主体语言交流的 POMDP 模型中同样重要（Friston, Parr et al. 2020）。

8.5 混合模型（离散与连续）

正如本章以及上一章所展示的，离散模型和连续模型在主动推断中都具有重要应用。虽然许多场景只需要其中一种，但更整体的观点会承认，两者很可能是同时发挥作用的。这就要求我们找到一种方式来结合这两类生成模型，使得单一模型同时包含连续变量与离散变量（Friston, Parr, and de Vries 2017）。这种混合模型能够一方面对顺序性的动作计划进行推断，另一方面又通过连续模型把这些决策转化为具体动作。图 8.6 展示了这类模型的形式：其高层是一个 POMDP，行为方式与第 7 章中描述的一样；而在每一个离散时间步上，它都会生成一个本章所讨论类型的连续模型。这样一来，连续时间就被分解成一串离散排列的短连续轨迹。

为了把离散层的结果翻译到连续层，我们需要把每一个备选结果与某个连续空间中的一点联系起来。为了帮助建立直觉，我们考虑一个延迟期眼动任务的例子，这种任务在灵长类研究中很常见，如图 8.7 所示。该任务包含三个阶段。首先，在猴子保持注视中央注视十字的同时，一个目标会出现在例如四个可能位置中的某一个。接着，目标消失，猴子必须在一段延迟期内记住它的位置。最后，系统给出一个信号，提示猴子执行一次扫视，此时猴子必须把目光移向原始目标出现的位置。要完成这一任务，猴子必须能够对序列进行推断，例如当前处于任务的哪个阶段；同时还要推断四个位置中哪一个才是应该瞄准的位置。这些都是典型的范畴式推断问题，适合用 POMDP 来表述。然而，一旦正确位置被选定，猴子还必须执行一段眼球运动，把中央凹移动到目标位置的连续坐标上。

图 8.7 展示了一个解决该问题的混合生成模型是如何工作的。在顶部图中，模型高层做出范畴性决策：它计算在四个离散时间段上，对四个离散目标位置的后验信念。在中部和底部图中，模型低层则根据高层的离散推断，计算连续的行为轨迹，也就是眼动轨迹。

把关于离散目标位置的决策转换成连续眼动，需要使每一个离散目标位置 o 都对应于一个关于连续隐藏原因 v 的分布，而该分布给出目标的坐标。随后，关于目标坐标的先验可以通过对这些位置进行贝叶斯模型平均而得到，并以 POMDP 层中的推断结果为权重：

$$
\begin{aligned}
P(v \mid o_\tau) &= \mathcal{N}(\eta_v^{o_\tau}, \Pi_v) \\
P(v) &\approx \mathcal{N}(\eta_v, \Pi_v) \\
\eta_v &= \mathbb{E}_{Q(o_\tau)}[\eta_v] = \sum_i o_{\tau i}\, \eta_v^i
\end{aligned}
\tag{8.8}
$$

为了推断哪个离散目标最能解释连续数据，我们还必须能够计算与每一个假设目标对应的证据，而该证据又是观测到的连续数据的函数。这体现出一个事实：混合模型要求层级中的高层与低层之间存在双向相互作用。正如图 8.7 所示，这种结构使系统既能形成“在何处执行扫视”的信念，又能在恰当时刻把这些扫视真正执行出来。在第一个离散时间步，也就是连续时间尺度上的前 250 ms 内，猴子能够较有信心地推断：在第一个时间步上，它的眼睛位于中央注视十字；在第二个时间步上，也就是 500 ms 之前，它将继续保持这种注视；而在这之后，最可能的行动过程将使其中央凹对准上方目标位置。这一点可以从顶部图中的离散放电率看出来。随后，这些离散推断会转化为连续行为；而当这些行为真正被实施时，又会反过来增强关于离散状态的

信念。注意，在第三个时间步，也就是 500 到 750 ms 之间，一旦连续数据出现，向上扫视这一选项的概率就会增大。这个基于实验认知研究的简单例子，说明了在离散动作计划与其连续实施之间进行转换的基本原则。

8.5.1 框 8.3：混合模型与聚类

在主动推断之外，把范畴性生成模型与连续生成模型结合起来的问题，主要是通过聚类的视角来理解的。在这种问题中，目标是把每个连续数据点分配到一个离散簇。为解决这一问题，人们已经采用了多种算法，但其中大多数在隐含层面上都依赖于与这里类似的生成模型，也就是高斯混合模型：

$$
\begin{aligned}
P(y, s, D, \eta, \Pi) &= P(D)P(\eta)P(\Pi)\prod_i P(s_i \mid D)\, P(y_i \mid s_i, \eta, \Pi) \\
P(D) &= \mathrm{Dir}(d) \\
P(s_i \mid D) &= \mathrm{Cat}(D) \\
P(y_i \mid s_i, \eta, \Pi) &= \mathcal{N}(\eta_{s_i}, \Pi_{s_i})
\end{aligned}
$$

在聚类方法中，问题是推断每个簇的均值与精度，分别记为 η 与 Π，以及每个数据点 y_i 属于给定簇的后验概率 $P(s_i \mid y_i)$。对于我们当前的目的，也就是 8.5 节中描述的场景，我们假定对 η 和 Π 具有精确的 delta 函数先验，并通过贝叶斯模型约减来计算 $Q(s_i) \approx P(s_i \mid y_i)$（见框 7.3）。

8.6 小结

本章概述了主动推断框架下连续时间生成模型的应用。这是一个极其庞大的主题，许多内容都未能展开，进一步阅读可参见表 8.1。不过，这里阐述的总体概念已经为继续深入这些模型提供了基础。具体来说，我们从“满足预测”的角度讨论了运动生成。这种处理方式极大简化了运动控制问题，因为我们不再需要额外的机制或逆模型，只需要脊髓或脑干反射弧即可。我们还强调了精度与感觉衰减在这类运动控制中的作用。

鉴于连续方案的一项关键优势，在于能够用动力系统来表述生成模型，我们概述了两类在主动推断研究中被广泛使用的动力系统。广义 Lotka–Volterra 系统为连续背景下的时间排序提供了机制，而 Lorenz 吸引子则能够用来生成丰富的模拟，包括合成鸟鸣。随后，我们讨论了广义同步这一概念。一个系统的内部状态与外部状态之间的同步，构成了以推断方式理解脑功能的基础；同时，它对于社会系统的理论也至关重要，因为在社会情境中，外部状态在很大程度上由同类个体，也就是“像我这样的生物”构成。

最后，我们说明了如何把第 7 章的离散模型与第 8 章的连续模型统一起来，把 POMDP 形式下最小化期望自由能的动力学，包括利用性与探索性行为，与通过连续过程来实现这些行为，以及在两者之间进行调节的双向消息传递机制结合起来。简言之，这一整合让我们能够从决策走向动作，再从动作返回决策。

第九章　基于模型的数据分析

仅仅因为我们手里有最好的锤子，并不意味着每个问题都是钉子。

— 巴拉克 · 奥巴马

9.1　引言

归根到底，本书描述的模型只有在能够回答科学问题时才真正有用。本章聚焦于如何用主动推断来理解经验数据。核心思想是：作为科学家，我们可以调用与前几章中假定大脑所使用的同一套数学工具。我们的总体目标，是恢复受试者大脑用来生成行为的生成模型参数，也就是其**主观模型**。为此，我们可以使用我们自己的生成模型，即“主观模型如何产生行为”的模型，也就是**客观模型**。我们可以根据观察到的行为，对客观模型进行反演，从而推断主观生成模型中的参数。这种元贝叶斯推断为我们提供了机会：一方面检验我们关于大脑所使用模型的假设，另一方面根据个体必须持有什么样的先验信念，才能使其行为成为贝叶斯最优，来对个体进行表型刻画。此类基于信念的计算表型分析，在计算精神病学、神经心理学和神经病学等新兴领域中具有重要前景。

9.2　元贝叶斯方法

本章讨论主动推断表述在行为实验数据分析中的用途。这已经超出了前几章中那些“原理验证”式的模拟，而是直接利用主动推断来回答科学问题。我们已经看到，在主动推断框架下，受试者的生成模型是决定行为的关键因素。这意味着，对于经验性行为测量之成因的假设，必须表述为：主体在选择这些动作时所使用的是哪一种备选生成模型。因此，我们面临的挑战，是通过调节生成模型的参数，也就是先验信念，将一个主动推断方案拟合到观察到的数据上。

广义上说，将计算模型拟合到观察到的行为上，有两个彼此相关的目的。第一个目的，是估计模型中最能解释某一特定受试者或某一组受试者行为的参数。这有助于用生成这些行为的计算过程来刻画主观行为，这一过程通常被称为**计算表型分析**。计算表型既可以与其他测量结合使用，例如建立神经影像结果与功能之间的联系，也可以单独使用，例如预测个体在其他情境下的行为表现，或预测治疗干预后的变化。

第二个目的，是比较不同的模型假设，也就是用不同模型来代表对某种行为现象的不同解释。这

两项工作，即参数估计和模型比较，都对应于贝叶斯定理的同一侧。参数估计是在某个模型之下寻找参数设定的后验概率；模型比较则依赖于找到每个模型的边缘似然，也就是模型证据。回顾一下，贝叶斯定理为

$$P(u \mid \theta, m)\, P(\theta \mid m) = P(\theta \mid u, m)\, P(u \mid m). \tag{9.1}$$

右侧对应的是：在给定模型 m 和行为数据 u 的条件下，参数 θ 的后验概率，以及模型证据；左侧告诉我们在建模时必须指定什么：我们需要对目标参数给出先验信念，并给出一个似然函数。

需要强调的是，虽然我们这里调用的仍是前几章中同样的贝叶斯推断方案，但其用途已经不同。原因在于，此处实际上同时存在两个推断过程。第一个过程是：生物体利用其关于感觉数据生成过程的模型，对世界状态以及该如何行动作出推断。这正是前几章的焦点。第二个过程是：作为客观科学家的我们，观察该生物体的行为，并试图通过反演我们自己的客观生成模型，来推断它正在使用的主观生成模型。换言之，我们此时是在对一个“推断过程本身”进行推断，这通常被称为**元贝叶斯**推断。

更形式化地说，这一路径将似然分布定义为一个主动推断问题的解。给定某一组参数，我们可以在主动推断之下模拟行为，并量化某一串动作会被采取的可能性。再结合我们对这些参数取值的先验信念，我们就得到了一个关于“生物体如何利用其生成模型来产生动作”的生成模型。虽然本章聚焦于主动推断，尤其是离散时间模型，但这里采用的一般方法也可以和任意似然函数配合使用。其他规范性行为模型，例如强化学习中使用的模型，也可以替代主动推断模型而被纳入这一框架。

接下来的部分将展开一个可用于元贝叶斯推断的通用推断方案示例，即变分拉普拉斯，以及用于模型比较的层级模型。之后，我们会给出一套基于模型的数据分析简明操作流程，并回顾一个关键应用案例。需要强调的是，要有效使用这些方法，并不要求读者完全掌握其中的技术细节；因此，如果读者对这些细节兴趣不大，可以跳过第 9.3 节和第 9.4 节。

简言之，基本思想是：评估在给定未知目标参数，也就是受试者先验信念参数时，任何一组被观察到的选择序列出现的似然。然后，把这一似然与我们对这些参数的客观先验结合起来，按通常方式求得受试者先验的后验分布。如果我们拥有多个受试者，就可以使用参数经验贝叶斯（PEB）把这些后验组合起来，从而对群体效应或被试间差异作出推断。这里所需的似然，本质上就是：在受试者对动作的后验信念之下，采样到该观察到的选择序列的概率。这些后验信念取决于受试者看到了什么，也就是线索或刺激，以及她原本持有的先验信念；而它们可以通过求解相应的主动推断方案来直接得到。要注意，我们在这里实际上使用了两次贝叶斯程序：第一次是为了求出受试者关于动作的后验信念；第二次是为了求出我们关于那些刻画受试者的未知先验参数的后验信念。下面我们依次梳理这一元贝叶斯程序的各个组成部分。

9.3 变分拉普拉斯

变分拉普拉斯是一种与预测编码建立在同样原理之上的推断方案。不过，它可以用于比前面所遇到的高斯型似然更一般的似然函数。本节先给出这里关心的似然函数 $L(\theta)$ 的概览。该似然函数应当给出：当生成模型的参数取值为 θ 时，一个主动推断方案产生相应动作的概率。被选中的动作依赖于所获得的观测：

$$
\begin{aligned}
L(\theta) &= \ln P(\tilde{u} \mid \theta, m, \tilde{o}), \\
P(\tilde{u} \mid \theta, m, \tilde{o}) &= \tilde{u} \cdot \sigma\big(\theta_\alpha \ln \mathbf{u}\big), \\
\mathbf{u} &= \pi \cdot U, \\
\pi &= \arg\min_{\pi} F.
\end{aligned}
\tag{9.2}
$$

把它拆开来看，第一行给出的是：观察到的动作序列 $\tilde{u}$ 的对数似然，它是参数 θ、模型 m 以及真实实验中呈现的刺激序列 $\tilde{o}$ 的函数。动作序列出现的概率，是通过把这些参数写入某个第 7 章那样的 POMDP 模型中的先验信念来计算的。然后，我们像第 4 章和第 7 章那样去求解该 POMDP，不过在模拟中强制它采取已经观察到的动作序列，并向它呈现与真实实验相同的刺激。正如前几章所述，这一过程会得到一个合成受试者关于其所选择策略或行动路径的信念 π。这些信念使其世界生成模型的自由能 F 达到最小。接着，我们就可以利用这些策略信念，计算执行某一动作序列的平均概率。为此，需要把每个策略的概率分配到该策略所隐含的动作上，动作由数组 U 索引。最后，引入一个 softmax 温度参数 θ_α，以刻画模型未能解释的行为随机性，也就是“手抖性”。如果这个 softmax 参数等于 1，我们实际上是在假设受试者按照其关于动作的后验信念进行采样，这有时也称为**匹配行为**。相反，如果这个 softmax 参数非常大，那么实际发出的动作就是主观后验概率最大的那个动作，也就是说，受试者总是选择最可能的选项。这个 softmax 参数本身也可以被估计。

由此，我们得到了在给定刺激序列与参数的条件下，模型产生这些动作的概率，也就是“在某个模型下，行为数据的似然”。如果进一步为客观层参数赋予高斯先验

$$
\theta \sim \mathcal{N}\big(\eta, \Pi^{(1)}\big),
$$

那么我们就可以借助拉普拉斯假设，写出对模型证据的一个自由能近似：

$$
\begin{aligned}
\ln P(\tilde{u} \mid m, \tilde{o}) &\approx L(\mu) + \frac{1}{2}\varepsilon^{\mathsf{T}}\Pi^{(1)}\varepsilon + \ln\left|\nabla_{\mu\mu}L(\mu) - \Pi^{(1)}\right|, \\
\varepsilon &= \eta - \mu, \\
\mu &= \arg\max_{\mu}\left\{L(\mu) - \frac{1}{2}\left(\varepsilon^{\mathsf{T}}\Pi^{(1)}\varepsilon + \ln\left|\nabla_{\mu\mu}L(\mu) - \Pi^{(1)}\right|\right)\right\}.
\end{aligned}
\tag{9.3}
$$

式 (9.3) 与框 4.3 中展开的结果本质相同，只是这里推广到了多维参数空间，并显式代入了后验协方差的形式，同时假定先验服从正态分布。在第 4 章以及第 8 章中的应用里，我们忽略了那些不依赖于众数的项；但当我们讨论模型比较问题时，这些项就必须保留。

为了找到使式 (9.3) 最后一行达到最大值的 μ，我们可以执行梯度上升。在二次近似下，这可化为

$$\dot{\mu} = \nabla_{\mu} L(\mu) + \Pi^{(1)}\varepsilon. \tag{9.4}$$

虽然这里使用的对数似然梯度未必总能写出显式形式，但我们可以利用有限差分方法对其进行合理的数值近似。同样的方法也可用于求取后验精度，也就是负对数似然的二阶导数或 Hessian，再加上先验精度。式 (9.4) 是最简单的更新形式，但在实践中往往会使用基于局部曲率的更复杂方法。

9.4 参数经验贝叶斯（PEB）

上一节中的变分拉普拉斯程序，使我们能够对选择行为模型进行推断，并量化该模型的证据。这让我们可以对个体进行计算表型分析，也可以比较关于该个体的不同解释性假设。然而，更有趣的问题往往发生在群体层面。举例来说，我们可能关心某个参数，例如先验偏好的精度，如何随着年龄变化。为了回答这个问题，我们可以先使用第 9.3 节的方法，对不同年龄个体的行为分别拟合模型；然后再建立一个生成该参数的广义线性模型，并把年龄纳入其中：

$$P(\theta \mid \beta, X) = \mathcal{N}\big(X\beta, \Pi^{(2)}\big). \tag{9.5}$$

这里，X 是一个矩阵，它的列表示不同的解释变量，它的行对应不同参与者。通常，X 的第一列是一列全 1，用来表示受试者总体平均参数的效应；在本例中，第二列则可以是每位参与者的年龄。向量 β 表示 X 中每个解释变量的效应大小。于是，β 的第一个元素就是该精度参数的平均值，第二个元素则表示年龄对精度的影响。这个值也就是在“年龄为横轴、预测精度为纵轴”的图中那条直线的斜率。X 可以有任意多列，β 也可以有任意多个元素。

一旦拟合了式 (9.5) 所表达的模型，并为 β 设定先验，我们就可以询问各个解释变量的作用。例如，我们可以通过比较两个模型的证据，来判断年龄是否影响先验偏好的精度：一个模型允许 β 的第二个元素偏离零，另一个模型则对它是零持有精确先验。实践中，这通常可以借助贝叶斯模型约简来完成，而不必重新反演多个模型。

9.5 基于模型分析的操作说明

在实践中，我们通常按照下面的步骤，使用主动推断来分析经验性选择行为。这些步骤对应于 SPM12 Matlab 包中的相关程序。

1. 收集行为数据，包括个体做出的选择，以及该个体在作出该选择时可获得的感觉输入。此外，还要收集用于第二层被试间分析的数据，例如受试者是否属于患者组或对照组、相关人口统计信息等。

2. 像第 7 章那样构造一个 POMDP 模型。它应当是一个以参数为输入、并输出一个已被完整指定但尚未求解的 POMDP 的函数。

3. 指定一个似然函数，也就是式 (9.2)。它规定模型应如何被用来计算似然。通常，这一步会调用一个 POMDP 求解器，例如 `spm_MDP_VB_X.m`，来模拟行为，并量化观察到的动作之似然。

4. 用期望与精度来指定参数的先验信念。通常这些先验会以 0 为中心，而精度则反映参数可能取值的合理范围。

5. 求解后验概率和模型证据。这里通常使用一种标准推断方案，例如上面介绍的变分拉普拉斯程序，也就是式 (9.4) 所对应的方法。例行程序 `spm_nlsi_Newton.m` 可以自动完成这一过程。

6. 进行群体层分析。通常使用 PEB，把每个个体的已估计参数视为由第二层模型生成。这样就可以检验关于这些参数成因的假设。实践中，这一步可使用 `spm_dcm_peb.m`。其他可选分析还包括：把每位受试者的推断参数与其他个体特异性测量之间做标准统计关联分析。例如，可以使用典型变量分析来评估问卷分数与推断参数之间的关系。

图 9.2 对上述步骤的概括，是以第 7 章所描述的 T 迷宫任务中的老鼠行为为例的。首先，我们把一只老鼠放入 T 迷宫，在左臂或右臂之一放置奖励性刺激，并在中央臂放置信息性线索。然后记录老鼠采取的动作序列。这一程序可以在多个试次中重复，以记录学习后的行为；也可以在多只不同老鼠、不同干预条件下重复，例如药理学干预或光遗传学干预。

一旦获得这些行为数据，我们就需要一个似然函数，用来量化：在特定参数设定之下，某一只老鼠在某一条件下产生这些行为的概率。为此，我们可以构造第 7 章讨论过的 POMDP 模型。这个模型必须按我们希望求似然的参数来参数化。例如，如果我们想评估偏好相关的精度，就可以引入一个对数尺度参数，使偏好分布变得更尖锐或更平坦。

在搭建好从老鼠视角出发的生成模型后，我们就能利用第 4 章中的信念更新方程，自动求解该 POMDP。这使得我们能够计算：在某一特定偏好尺度参数取值下，给定模型产生这些数据，也就是访问迷宫不同臂的序列的概率。再把这一似然与我们的先验结合起来，就完成了从科学家视角出发的行为生成模型的指定。然后，就可以用变分拉普拉斯，为每只老鼠求出该尺度参数的后验分布。

在真正分析实际数据之前，一个合理步骤，是先用该 POMDP 模型生成虚构数据，检查其表面有效性，看看这些数据在定性上是否与手头问题相符。另一个明智测试是**参数恢复**：在某些已知参数设定之下生成虚构数据，再反演模型，看看这些参数能否被恢复出来。这有助于验证某些参数，或者它们的组合，是否是可恢复的，也就是是否可识别。

最后，我们可以为一个线性模型构造设计矩阵，其中每一行代表一种计算表型，例如每位受试者偏好参数的后验密度，而各列则代表这些受试者的不同属性。这些属性可能解释不同老鼠偏好的差异。除了一列全 1，用于表示所有老鼠的平均偏好，还可以加入年龄、是否接受药物、等等变量。借助这个被试间效应模型，我们就可以进一步进行 PEB 分析，以评估这些解释变量对先验偏好的贡献。

9.6 生成模型示例

本节借助文献中的两个例子，说明如何使用连续型和离散型生成模型。首先，我们简要回顾 Adams、Aponte 等人（2015）以及 Adams、Bauer 等人（2016）的做法。下文统称其为 Adams 等人。他们用平滑追踪眼动任务来量化每位受试者生成模型中的精度参数。该研究设计的重要之处在于：它同步采集了电生理数据，也就是脑磁图数据，使作者能够进一步询问精度或置信度编码的神经生物学基础。接着，我们再看 Mirza 等人（2018）的研究，他们把扫视眼动建模为一个 POMDP，用以分析主动信息搜寻行为。图 9.3 以示意方式给出了这两个实验。希望这两个例子能帮助读者理解：上文概括的一般方法，是怎样被真正用于回答科学问题的。

如果按照图 9.2 中的步骤来看，Adams 等人首先进行了数据收集，也就是步骤 1。他们让受试者盯住一个移动的视觉目标，并维持注视。具体任务细节并不重要，但该任务有两个条件：在第一种条件下，目标沿可预测的正弦轨迹移动；在第二种条件下，目标沿相同轨迹移动，但叠加了高斯噪声。收集到的数据包括眼动轨迹。接着，作者建立了一个主观模型，也就是步骤 2。与图 9.2 中的 POMDP 不同，他们选择的是第 8 章那类连续时间模型。简言之，该模型预测来自眼睛的本体感觉输入和视觉输入，并假设注视点会被目标位置所吸引。步骤 3 中的似然，是借助第 4 章概述的主动预测编码方案构造出来的。这个似然量化的是：在给定一组对数精度参数以及步骤 2 中所设模型时，观测到这些眼球运动动作的概率。再往下的步骤 4，作者为这些对数精度指定了正态分布先验。随后，他们进行模型反演，也就是步骤 5，从而得到这些精度参数的后验分布。至于步骤 6，他们没有使用 PEB，而是把与行为任务同步采集的神经影像数据纳入分析。他们利用动态因果建模估计了初级视觉皮层浅层锥体细胞的增益。这样一来，他们就为每个受试者同时得到了精度参数估计和突触增益估计，从而可以在群体层面检验主观模型参数及其生物学基底之间的相关关系。这个相关性的展示，提供了一个重要例子：主动推断形式的行为模型如何使我们能够提出并回答“信念更新与神经生物学之间关系”的问题。

第二个例子中，Mirza 等人使用 POMDP 形式的主动推断，研究信息增益在驱动人类行为中的作用。仍按图 9.2 的步骤来看，他们首先收集行为数据，也就是步骤 1。当时，受试者执行的是一个视觉觅食任务：目标是把一个视觉场景归入若干类别之一。场景的每个部分，只有当受试者把目光落在相应位置时才会显露出来，因此受试者必须进行多次注视，才能获得足够证据来判断场景类别。作者收集的数据包括扫视，也就是快速眼动的序列。步骤 2 中使用的模型，是 Mirza 等人（2016）描述过的一个 POMDP 模型。它根据当前注视位置和场景类别，来预测离散化的本体感觉、视觉和反馈结果。偏好，也就是第 7 章中的 C，被施加在反馈结果上，使模型预期并因此偏好自己分类正确。步骤 3 中的似然函数，是在不同参数设定下用第 4 章中的方案求解该模型而得到的。这里涉及的参数包括一个偏好分布精度的对数尺度参数，以及其他一些参数。步骤 4 中，作者为该对数尺度和其他参数指定先验分布，并在步骤 5 中为每一位受试者分别反演模型。他们利用每位受试者的对数证据，比较了两类模型：一类把期望自由能中的认知成分纳入行为动机，一类则没有。结果发现，对所有受试者而言，包含认知可供性的模型都具有更高证据。随后，他们在步骤 6 中使用 PEB，评估受试者在多次试验过程中先验信念如何变化，结果发现证据支持信念参数发生了变化，也就是出现了主动学习。最后，他们又使用典型协变量分析，来评估两类量之间的关系：一类是每位受试者的表型变量线性组合，例如偏好精度；另一类是其行为表现指标的线性组合，例如正确率和反应时。

9.7 错误推断模型

人们通常都会很快相信那些他们希望为真的东西。

— 尤利乌斯 · 凯撒

鉴于这些方法对计算精神病学等领域的重要性，本章最后概述一下**错误推断**。这一主题之所以关键，是因为精神病理学常常可以被理解为信念更新失败的结果。像主动推断这样的推断框架有一个重要优势：它能够同时处理精神障碍的多个层面，把适应不良行为，例如强迫、成瘾，与心理层面现象，例如错误信念，以及生物层面现象，例如神经调质异常，连接在同一个解释框架中。

由于这里不可能公正覆盖利用主动推断建模疾病过程的庞大文献，本节只提供一个高度压缩的概览，目的是给出一个思考计算病理学的框架。表 9.1 给出了一组并不穷尽的示例，它们既包括离散时间模型，也包括连续时间模型，分别可追溯到第 7 章和第 8 章中的方案。下面的讨论主要借助 POMDP 一类模型的结构来展开；而支撑这些情境中错误推断的原则，其实大体相同。

这类推断路径，也就是主动推断等方法，背后的基本假设是：精神病理状态可以被概念化为**推断障碍**。这里所谓“障碍”并不一定意味着推断机制本身是坏的，例如后验概率计算错误。事实上，在表 9.1 所回顾的大多数研究中，推断机制本身运行正常，只是它所依据的生成模型存在缺陷，也就是生成模型中被赋予了异常的先验信念。因此，从根本上说，病理性表现是异常先验信念的后果；而这些先验是可以通过本章介绍的基于模型的数据分析方法恢复出来的。

下面按照若干病理类型做简要概括。

成瘾、冲动性与强迫性

成瘾是一个重要例子：表面上看，它是一类异常行为，但在合适的生成模型之下，它同样可以被表述为最优推断。相关研究利用“有限报价任务”等范式说明了这一点：在任务中，参与者对“等待后是否会获得奖励”的把握程度不同；较低的置信度会导向与成瘾相关的强迫性行为。后续工作还进一步分析了更冲动或更不冲动的行为背后对应的先验信念，并在“离开资源斑块”范式中考察了强迫症里先验精度减弱所扮演的角色。

妄想

妄想以固定而错误的信念为特征。在主动推断中，它可以被直接刻画为：在缺乏支持性证据时，后验概率分布却异常精确。如果这种后验足够精确，那么即使后来出现相互矛盾的证据，它也依旧会保持不变。不同妄想背后的机制可能并不相同。例如，感觉衰减失败可能是“行动归属妄想”的关键原因。近期研究还提供了共享性妄想的例子，即两个没有信息的主体如何就世界状态达成高度自信的一致判断。

幻觉

这类模拟通常建立在先验精度与似然精度失衡之上。若似然精度的衰减不足，就会过度解读偶然的感觉数据；若先验精度的衰减过强，又会使先验信念无法被经验修正。这两条路径都可能构成错误知觉推断的机制，也就是幻觉的机制。

人际与人格障碍

人际推断依赖于我们对他人以及他们会如何回应自己决策的模型。这推动了信任博弈模型以及慈善博弈模型的发展。后者被用于复现心理病态中常见的自我膨胀与缺乏悔意等特征。相关特质可以通过调节如下因素来模拟：关于自我价值的信念在多大程度上依赖于“慈善”还是“自利”的选择，以及主体对他人认可的敏感程度。

眼动综合征

在一些论文中，连续时间生成模型被用来预测牛顿系统的动态演化。通过让生成模型的某些部分在条件上与其他部分独立，就可以诱发某些眼动综合征，例如核间性眼肌麻痹。

药物治疗

结合第 5 章中关于精度参数与神经化学物质之间关系的讨论，可以设想通过模拟药理操控来研究这些系统。相关工作展示了若干合成药理干预对一个眼动延迟任务表现的影响，从而证明：这些方法不仅可以模拟病理状态，也可以模拟治疗措施的作用。

前额叶综合征

一些模拟通过削弱转移精度，区分了内侧前额叶与外侧前额叶综合征的差异：前者更影响任务动机，后者更影响记忆引导任务的表现。

视觉忽略

对空间左侧的忽视，可以通过多种不同的“病损先验”诱发。例如，若左侧空间的狄利克雷参数升高，则朝左扫视所带来的新奇性就会降低，导致个体更多去采样右侧。又或者，如果把偏好设置为与右侧本体感觉或视觉结果一致，或者增强向右扫视的习惯性倾向，也会重现定性上类似的行为。

内感受推断障碍

关于内感受推断，也就是主动推断在内感受领域中的应用，相关模拟表明：例如关于心脏或胃部信号的先验精度与似然精度一旦失衡，就会导致关于身体内部状态的错误信念、对身体症状的错误知觉，甚至心身性幻觉。此外，这种失衡还会级联性地影响自主调节与行动选择，进而引发多种适应不良行为，例如过度警觉、过度用药以及过度节食。

异常先验既可以是关于状态或精度的先验，也可以是关于生成模型形式本身的结构先验。要理解病理行为的成因，一个有用的思路，是去分析用于策略的先验信念，并考察其中每一部分的破坏会如何导致异常的策略选择。策略先验依赖于期望自由能，而期望自由能又依赖于后验信念、信息增益的潜力以及先验偏好 C。此外，策略先验中还可以加入一个固定形式项 E，用来表示习惯性偏置。

依次来看。首先，后验信念依赖于先验和似然。若要形成异常的后验信念，则其中一者或二者必定出了问题。最常见的情况，是精度平衡被高估或低估。当似然精度相对于先验精度过高时，主体就会过度解读感觉输入，即使这些感觉输入本身带有噪声；这会导致一种“过拟合”式的状态，也就是从偶然数据中得出不恰当结论。若精度平衡朝相反方向偏移，即过度偏向先验置信度，那么由内部生成的知觉就会对相矛盾的感觉输入表现出顽固抵抗。这两种机制都与幻觉的形成有关；在层级模型中，它们甚至可以并存。考虑到多种精度与神经调质系统之间的联系，这也使得一些伴有神经化学异常的疾病，例如胆碱能系统受损的路易体痴呆，以及多巴胺系统异常的精神分裂症，出现幻觉现象就显得合理了。

其次，我们再看信息增益的作用。在这里，似然精度与先验信念精度共同决定了：不确定性在多大程度上是可以被消解的，以及当前究竟有多少不确定性需要被消解。先验精度既可以作用于生成模型参数，也就是影响新奇性，也可以作用于状态，也就是影响显著性。若把条件概率参数理解为突触效能，或者把精度理解为突触增益，那么突触断连综合征就可以被看作这二者之一，或二者同时，发生了破坏。失去的突触无法被调制，因此它非常类似于对某个条件概率持有极其自信的先验，因为新数据已无法再更新对应的效能。这对不同策略所能带来的信息增益有重要影响，而这正是感官忽略综合征建模中被利用的机制。

最后，偏好与策略先验对行为具有清晰而直接的影响。它们可能构成成瘾性习惯的基础，也可能构成许多精神病学和神经病学综合征中冷漠状态的基础。总之，在上述生成模型的不同位置上出现的有缺陷先验信念，可以为病理行为提供一种功能性或目的论层面的解释。

9.8 总结

本章概述了一种把前几章中理论模型用于经验数据发问的方法。借助这种方法，主动推断可以作为一种非侵入式工具，用来探查个体在决策时所依赖的计算过程。我们聚焦于若干相对简单的例子，但实际上，基于主动推断的模型已经被扩展到更真实、更复杂的任务上，以便诱发更丰富的行为，从而支持计算表型分析。

除了给出一个六步式的基于模型分析流程外，我们还强调了两个具体应用案例。这两个案例突

出了这一流程在实践中的若干关键变化维度，包括所测量行为的类型，例如连续轨迹还是离散选择，所使用模型的类型，例如连续模型还是离散模型，以及最关键的，研究者真正想回答的科学问题。正是最后这一点决定了前面各项建模选择。我们看到，计算表型分析既可以和神经影像结合起来，用以探究突触增益与精度之间的关系；也可以通过模型反演来评估不同行为驱动力及其绩效预测因子的贡献。归根到底，图 9.2 中的六个步骤提供了一种通用方法，用来设计实验，以非侵入方式审问人类或其他动物用来驱动行为的隐含生成模型。这为我们回答“神经系统在健康与疾病中的功能如何运作”提供了现实路径。

第十章　作为有感行为统一理论的主动推断

10.1　引言

本章将为主动推断收束全书的主要理论要点（第一部分）与实践实现（第二部分），并进一步把这些线索连接起来：我们将暂时抽离前面各章讨论的具体主动推断模型，转而聚焦这一框架的整合性面向。主动推断的一个重要优势在于，它为有感生物体必须解决的适应性问题提供了一套完整解法。因此，它能够以统一视角看待知觉、行动选择、注意、情绪调节等问题；而在心理学与神经科学中，这些问题通常被彼此分割，在人工智能中也往往由不同的计算方法分别处理。我们将把主动推断对这些问题的理解，放在控制论、动作观念运动理论、强化学习与最优控制等既有理论背景下加以讨论。最后，我们还会简要说明，主动推断的适用范围如何扩展到本书未深入展开的其他生物、社会与技术主题。

10.2　总结前文

本书系统介绍了主动推断的理论基础与实践实现。这里我们简要回顾前九章的讨论，以便重温后续分析所需的关键概念。

在第 1 章中，我们将主动推断引入为一种规范性方法，用来理解那些与环境构成行动--知觉回路的有感生物体（Fuster 2004）。所谓规范性方法，是从第一性原理出发，推导并检验有关目标现象的经验预测；在这里，目标现象就是生物体如何在与环境进行适应性交换（行动--知觉回路）的同时持续存在。我们还指出，人们可以沿着一条“低路”或一条“高路”抵达主动推断。

在第 2 章中，我们展示了通往主动推断的低路。这一路径始于这样一种观念：大脑是一台预测机器，拥有一个生成模型，即关于世界中隐变量如何生成感觉输入的概率性表征（例如，苹果反射的光如何刺激视网膜）。通过对这一模型做反演，大脑便能推断感觉的成因（例如，在视网膜以某种方式受到刺激的情况下，我是否看到了一个苹果）。这种关于知觉的看法，也即“知觉即推断”，其历史根源可以追溯到 Helmholtz 的无意识推断观，以及更晚近的贝叶斯大脑假说。主动推断进一步把动作控制与规划也纳入推断的范围，即“控制即推断”“规划即推断”。更重要的是，它表明知觉与行动并不是本质上彼此分离的过程，而是在实现同一个目标。我们首先以较为非正式的方式描述这一目标，把它说成是最小化模型与世界之间的不一致，而这通常可归结为最小化惊异或预测误差。简单说来，最小化模型与世界之间的不一致有两种方式：要么改变自己的心智以适配世界（知觉），要么改变世界以适配模型（行动）。这些都可以用贝叶斯

推断来描述。然而，精确推断往往难以直接求解，因此主动推断采用了一种（变分）近似，并注意到精确推断本身也可被视为近似推断的特例。由此，我们得到了对知觉与行动共同目标的第二种、也更正式的描述：最小化变分自由能。这是主动推断的核心量，可以被拆解为若干组成部分，例如能量与熵、复杂性与准确性，或惊异与散度。最后，我们又引入了第二种自由能：期望自由能。它在规划过程中尤其重要，因为它为替代策略打分提供了方法，即考虑这些策略预期会生成的未来结果。它同样可以展开为若干组成部分，例如信息增益与务实价值，或期望模糊性与风险。

在第 3 章中，我们展示了通往主动推断的高路。这条替代路径从一个“去通胀”的生物学要求出发：生物体必须维持自身完整性并避免耗散，而这可以描述为避免落入令人惊异的状态。随后我们引入了马尔可夫毯的概念，它形式化了生物体内部状态与世界外部状态之间的统计分离。关键在于，内部状态与外部状态只能通过中间变量，也就是毯状态（主动状态与感觉状态）间接影响彼此。这种由马尔可夫毯介导的统计分离，对于赋予生物体相对于外部世界的一定自主性至关重要。要理解这种视角为何有用，可以看它带来的三个后果。第一，具有马尔可夫毯的生物体，在贝叶斯意义上仿佛拥有一个关于外部环境的模型：它的内部状态，平均而言，对应于关于世界外部状态的近似后验信念。第二，这种自主性之所以能够成立，是因为该生物体的模型（即其内部状态）并非无偏，而是预设了一些必须维持的生存前提，或者说先验偏好；例如，对鱼来说，就是待在水里。第三，在这一形式之下，我们可以把相对于先验偏好的最优行为描述为：通过知觉与行动最大化（贝叶斯）模型证据。通过最大化模型证据，也即“自证”，生物体确保自己实现先验偏好（例如鱼留在水中），并避开令人惊异的状态。反过来，最大化模型证据在数学上与最小化变分自由能近似等价，因此我们再次以另一条路径抵达了第 2 章中的核心构造。最后，我们还详细讨论了最小化惊异与 Hamilton 最小作用原理之间的关系，这揭示了主动推断与统计物理第一性原理之间的形式联系。

在第 4 章中，我们概述了主动推断的形式方面。重点是从贝叶斯推断走向可计算的近似，也就是变分推断，以及生物体由此通过知觉与行动最小化变分自由能的目标。这里最重要的启发是：生物体用来理解世界的生成模型至关重要。我们介绍了两类生成模型，它们表达我们关于数据如何被生成的信念，分别使用离散变量或连续变量。两者都支持主动推断，但分别适用于以离散时间形式表述的事态（如部分可观测马尔可夫决策问题）与以连续时间形式表述的事态（如随机微分方程）。

在第 5 章中，我们强调了作为规范性原理的自由能最小化，与关于大脑如何实现这一原理的过程理论之间的区别，并说明后者会生成可检验的预测。随后我们概述了伴随主动推断而来的若干过程理论，它们涵盖神经元消息传递、神经解剖回路（如皮层--皮层下回路）以及神经调质等领域。例如，在解剖层面，消息传递与经典皮层微回路高度契合：在某一级，来自深层皮层的预测会投向下一层级的浅层皮层（Bastos et al. 2012）。在更系统的层面，我们讨论了贝叶斯推断、学习与精度加权分别如何对应神经动力学、突触可塑性与神经调质，以及预测编码中的自上而下与自下而上的神经消息传递如何映射到较慢的脑节律（如 alpha 或 beta）与较快的脑节律（如 gamma）。这些以及其他例子表明，一旦设计出一个特定的主动推断模型，就可以从其生成模型的形式出发，导出神经生物学层面的含义。

在第 6 章中，我们给出了一套设计主动推断模型的配方。我们看到，尽管所有生物体都在最小

化自身的变分自由能，但由于它们拥有不同的生成模型，所以会表现出彼此不同、甚至相反的行为。因此，区分不同生物体（例如较简单者与较复杂者）的关键，就在于它们的生成模型。可能的生成模型有着丰富谱系，它们对应不同的生物学实现（例如神经实现），并会在不同情境与生态位中产生不同的适应性或失适应性行为。正因如此，主动推断既适合刻画那种能够感知并追逐营养梯度的简单生物（如细菌），也适合刻画像我们这样追求复杂目标并参与丰富文化实践的复杂生物，甚至适用于不同个体，只要能够恰当地刻画各自的生成模型即可。进化似乎逐步发现了越来越复杂的脑和身体设计结构，使生物体能够应对并塑造更丰富的生态位。建模者则可以逆向工程这一过程，依据目标生物所占据的生态位，以生成模型的形式指定其脑与身体的设计。这对应于一系列设计选择，例如使用离散变量还是类别变量，使用浅层模型还是层级模型；这些我们都在该章中进行了展开。

在第 7 章与第 8 章中，我们提供了大量离散时间与连续时间下的主动推断模型示例，涉及知觉推断、目标导向导航、模型学习、动作控制等问题。这些例子意在展示这类模型下涌现行为的多样性，并详细说明它们在实践中如何被具体设定。

在第 9 章中，我们讨论了如何使用主动推断进行基于模型的数据分析，以及如何恢复一个个体生成模型中最能解释其任务行为的参数。这种计算表型分析使用的仍然是本书其余部分讨论过的那种贝叶斯推断，只是用途不同：它帮助我们设计并评估关于他人主观模型的客观模型。

10.3 连接各个线头：主动推断的整合性视角

数十年前，哲学家 Dennett 曾抱怨，认知科学家把太多精力花在对孤立子系统建模上，例如知觉、语言理解等，而这些子系统的边界往往带有很大任意性。他建议，与其如此，不如试着去建模“整只鬣蜥”：一个完整的认知生物体，也许相对简单，但要连同它所处、必须应对的环境生态位一起建模（Dennett 1978）。

主动推断的一个重要优点，就是它从第一性原理出发解释生物体如何解决适应性问题。本书所采取的规范性路线假定，我们可以从变分自由能最小化这一原理出发，推导出关于具体认知过程及其神经基础的含义，例如知觉、行动选择、注意与情绪调节。

设想一个简单生物，它必须解决寻找食物或庇护所之类的问题。若以主动推断来表述，这类问题可以用具身行动的语言描述为：通过行动去召唤偏好的感觉，例如与食物相关的感觉。只要这些偏好感觉已作为先验信念写入其生成模型，那么这个生物体实际上就在为自己的模型收集证据，或者更形象地说，为自己的存在收集证据，也就是最大化模型证据，进行自证。这个简单原理会延伸到通常被分开处理的多种心理功能，包括知觉、动作控制、记忆、注意、意向、情绪等。比如，知觉与行动都属于自证行为：生物体既可以通过改变信念来让自身期望与感觉对齐，例如更新关于“是否有食物”的信念；也可以通过改变世界来做到这一点，例如主动获得与食物相关的感觉。记忆与注意同样可以被看作优化同一目标。长期记忆通过学习生成模型的参数而发展；工作记忆则是信念更新，只不过这些信念关涉外部状态的过去与未来；注意是对感觉输入精度信念的优化。各种形式的规划与意向性，则可以通过某些生物体在若干可能未来之间进行选择的能力来理解，而这又要求其拥有时间深度生成模型。这类模型能够预测某条行动路线

会产生怎样的结果，并且对这些结果持一种乐观态度。这种乐观体现为：相信未来结果将导向偏好结果。时间深度模型还帮助我们理解更复杂的前瞻与回顾形式：前者是以关于现在的信念推导关于未来的信念，后者则是以关于现在的信念更新关于过去的信念。各种内感受调节与情绪，也可以诉诸关于内部生理状态的生成模型来理解；这类模型会预测未来事件的异稳态后果。

上述例子表明，从一种关于有感行为的规范性理论来研究认知与行为，会带来一个重要后果。这样的理论并不是先把知觉、决策、规划等分离的认知功能拼装起来；相反，它先为生物体必须解决的问题提供一个完整解法，然后再分析这一解法，从中导出关于各类认知功能的含义。譬如，究竟是什么机制使一个生命体或人工体（如机器人）能够知觉世界、记住它，或对其进行规划（Verschure et al. 2003, 2014; Verschure 2012; Pezzulo, Barsalou et al. 2013; Krakauer et al. 2017）？这一转向很重要，因为心理学与神经科学教科书中常用的认知功能分类，大多继承自早期哲学与心理学理论，有时也被称为 James 式范畴。它们虽然具有很高的启发价值，却可能相当任意，或者根本不对应彼此分离的认知与神经过程（Pezzulo and Cisek 2016; Buzsaki 2019; Cisek 2019）。的确，这些 James 式范畴或许更像是我们用来解释自己与感觉世界互动的生成模型成分，而不是真正解释这种互动本身的机制。举例来说，那种带有唯我论色彩的假设“我正在知觉”，也许只是我对当前事态的一种解释，而这些当前事态中就包括了我正在更新信念这一事实。

采取规范性视角还有助于识别不同领域中认知现象之间的形式类比。一个例子就是“探索与利用的权衡”，它以多种形式反复出现（Hills et al. 2015）。这一权衡常常在觅食情境中被研究：生物体必须在利用以往成功方案与探索新的、可能更优的方案之间做出选择。然而，同样的权衡也会在记忆搜索与资源受限的审议过程中出现，例如当时间有限或搜索努力受限时，生物体必须在继续利用当前最佳方案，与投入更多时间和认知努力以探索更多可能性之间抉择。若用自由能来刻画这些看似无关的现象，就可能揭示其深层相似性（Friston, Rigoli et al. 2015; Pezzulo, Cartoni et al. 2016; Gottwald and Braun 2020）。

最后，除了为心理现象提供统一视角，主动推断还为理解其对应的神经计算提供了原则化方法。换言之，它提供了一种过程理论，把认知处理与预期的神经动力学联系起来。主动推断假定，凡是与大脑、心智和行为相关的重要内容，都可用变分自由能最小化来描述。反过来，这种最小化会带来特定的神经签名，例如消息传递样式或脑解剖结构，而这些都可以接受经验检验。

本章余下部分将像是在勾勒一本心理学教材那样，讨论主动推断对若干心理功能的含义。针对每一种功能，我们也会指出主动推断与文献中其他流行理论之间的联系与分歧。

10.4 预测性大脑、预测性心智与预测加工

传统的大脑与认知理论强调从外部刺激到内部表征、再到运动行动的前馈式转换。这种观点被称为“三明治模型”，因为凡是夹在刺激与反应之间的内容都被统一贴上“认知”的标签（Hurley 2008）。在这一视角下，大脑的主要功能是把输入刺激转化为与情境相适配的反应。

主动推断与此显著不同，它强调大脑与认知的预测性与目标导向性。用心理学语言说，主动推断生物体（或其大脑）是一种概率推断机器，会基于自身生成模型持续地产生预测。

进行自证的生物体以两种基本方式使用这些预测。第一，它们把预测与到来的数据进行比较，以检验自身假设（预测编码），并在更慢的时间尺度上修正模型（学习）。第二，它们会把预测付诸实施，以引导自身如何去采样数据（主动推断）。通过这样做，主动推断生物体履行了两个要求：其一是认识性的，例如去视觉探索那些存在显著信息、能够消解关于假设或模型不确定性的地方；其二是务实性的，例如移动到能够确保偏好观测、如奖励的位置。认识性要求使知觉与学习都成为主动过程；务实性要求则使行为具有目标导向性。

10.4.1 预测加工

这种以预测与目标为中心的大脑与认知观，与预测加工（predictive processing, PP）密切相关，也为其提供了重要灵感。预测加工是心灵哲学与认识论中的一个新兴框架，强调预测在大脑与认知中的核心地位，并诉诸“预测性大脑”或“预测性心智”等概念（Clark 2013, 2015; Hohwy 2013）。

预测加工理论有时会诉诸主动推断的具体机制及其若干核心构件，例如生成模型、预测编码、自由能、精度控制与马尔可夫毯；但有时它们也会诉诸其他并不属于主动推断的构件，例如成对耦合的逆模型与前向模型。因此，“预测加工”这一术语的使用范围比“主动推断”更广，也更少受约束。

预测加工理论在哲学中引起了相当大的关注，因为它在多重意义上都具有统一潜力：它可以横跨知觉、行动、学习与精神病理等多个认知领域；可以贯通从较低层级的感知运动处理到较高层级的心理构造；还可以从简单生物体一路延伸到大脑、个体以及社会和文化构造。预测加工理论的另一种吸引力在于，它使用了信念、惊异等概念性术语，这些术语与哲学家熟悉的心理学分析层面相衔接。当然，需要注意的是，这些术语有时带有不同于日常用法的技术含义。

然而，随着预测加工受到越来越多关注，人们也逐渐发现，哲学家们对于它的理论与认识论含义并不一致。例如，有人将其解读为内在主义的（Hohwy 2013），有人强调其具身性或行动基础（Clark 2015），也有人以生成论或非表征主义的方式来理解它（Bruineberg et al. 2016; Ramstead et al. 2019）。围绕这些概念解释的争论超出了本书讨论范围。

10.5 知觉

主动推断把知觉视为一种基于生成模型的推断过程，这个生成模型描述感觉观测是如何产生的。贝叶斯规则本质上是在对这一模型进行反演，以在给定观测的情况下计算关于环境隐状态的信念。把知觉理解为推断的思想可追溯到 Helmholtz（1866），并在心理学、计算神经科学与机器学习中多次被重新提出，例如“分析即综合”等观点（Gregory 1980; Dayan et al. 1995; Mesulam 1998; Yuille and Kersten 2006）。这种生成建模取向已被证明能够有效应对困难的知觉问题，例如破解基于文本的 CAPTCHA（George et al. 2017）。

10.5.1 贝叶斯大脑假说

这一思想在当代最突出的表达，就是贝叶斯大脑假说，它已被应用于决策、感觉处理与学习等多个领域（Doya 2007）。主动推断为这些推断性思想提供了规范性基础，因为它把它们从变分自由能最小化这一要求中推导出来。由于同一要求也扩展到行动动力学，主动推断自然能够建模主动知觉，以及生物体如何通过主动采样观测来检验自己的假设（Gregory 1980）。相比之下，在贝叶斯大脑的议程下，知觉与行动通常依照不同的要求来建模，其中行动需要诉诸贝叶斯决策理论，见第 10.7.1 节。

更广义地说，贝叶斯大脑假说指的是一族彼此未必整合、且常常给出不同经验预测的方法。例如，它包括计算层级的主张，即大脑执行贝叶斯最优的感觉运动与多感觉整合（Kording and Wolpert 2006）；算法层级的主张，即大脑实现某种特定的贝叶斯近似，例如抽样式决策（Stewart et al. 2006）；以及神经层级的主张，即神经群体如何执行概率计算或编码概率分布，例如用样本或概率性群体编码来实现（Fiser et al. 2010; Pouget et al. 2013）。在每一个解释层级上，都存在相互竞争的理论。例如，人们常诉诸精确贝叶斯推断的近似来解释偏离最优行为的现象，但不同工作考虑的是不同的、且并不总彼此兼容的近似方案，例如不同的抽样方法。更广泛地说，不同层级上的提案之间也并不总能顺畅对接。这是因为，贝叶斯计算可以通过多种算法路径来实现或近似，即便系统并未显式表征概率分布（Aitchison and Lengyel 2017）。

主动推断提供了一个更加整合的视角，它把规范性原理与过程理论连接起来。在规范性层面，其核心假设是所有过程都在最小化变分自由能。与之相应的推断过程理论，是对自由能做梯度下降；这一点具有明确的神经生理学含义，我们已在第 5 章中讨论过（Friston, FitzGerald et al. 2016）。更广泛地说，人们可以从自由能最小化原理出发，推导关于脑结构的含义。

例如，知觉推断在连续时间中的经典过程模型就是预测编码。预测编码最初由 Rao 与 Ballard（1999）提出，作为一种层级化知觉处理理论，用以解释一系列已知的自上而下效应；这些效应难以与纯前馈架构以及既有生理事实（例如感觉层级中前向/自下而上与后向/自上而下连接的存在）相调和。然而，在某些假设下，如 Laplace 近似，预测编码可以从自由能最小化原理中推导出来（Friston 2005）。进一步地，连续时间中的主动推断可以被构造为对预测编码向行动领域的定向扩展，即给一个预测编码主体配上运动反射（Shipp et al. 2013）。这就引出了下一节。

10.6 动作控制

在主动推断中，行动处理与知觉处理是平行的，因为两者都由前向预测引导，只不过前者主要依赖本体感觉预测，后者主要依赖外感受预测。正是“我的手抓住了杯子”这一类本体感觉预测，诱发了抓取动作。行动与知觉的等价性在神经生物学层面同样成立：运动皮层的组织方式与感觉皮层相同，也是一种预测编码架构；不同之处在于，它能够影响脑干与脊髓中的运动反射（Shipp et al. 2013），而且它接收的上行输入相对较少。运动反射使系统可以通过设定沿着期望轨迹的一系列“平衡点”来控制运动，这一思想与平衡点假说相呼应（Feldman 2009）。

需要强调的是，启动一个动作，例如抓杯子，要求对先验信念与感觉流的精度（方差的倒数）进

行适当调节。这是因为，这些精度的相对大小决定了生物体如何处理以下冲突：一方面，它的先验信念认为自己握住了杯子；另一方面，感觉输入却表明它并未握住。若关于“抓住杯子”的先验信念精度很低，那么它就很容易在相冲突的感觉证据面前被修正，结果是改变想法，而不发生动作。相反，当先验信念占据主导地位，也就是具有更高精度时，它即便面对冲突性感觉证据仍会被维持下来，从而诱发抓取动作，以解决这一冲突。为了确保这一点，动作启动会引发短暂的感觉衰减，也就是下调感觉预测误差的权重。如果这种感觉衰减失效，便可能带来失适应后果，例如无法启动或控制运动（Brown et al. 2013）。

10.6.1 动作观念运动理论

在主动推断中，动作源自本体感觉预测，而不是运动指令（Adams, Shipp, and Friston 2013）。这一思想把主动推断与动作观念运动理论联系起来。该理论可追溯到 William James（1890），后来又发展出“事件编码”与“预期行为控制”等理论（Hommel et al. 2001; Hoffmann 2003）。动作观念运动理论认为，动作--效果联结（类似前向模型）是认知架构中的关键机制。重要的是，这些联结可以双向使用：当它们沿着“动作到效果”的方向使用时，可以生成感觉预测；当它们沿着“效果到动作”的方向使用时，则可以选择那些能实现预期知觉后果的动作。这意味着，动作的选择与控制，是基于它们预期后果来进行的，这也正是“观念 + 运动”这一名称的含义。这种前瞻性的动作控制观得到了大量文献支持，这些研究记录了预期动作后果对动作选择与执行的影响（Kunde et al. 2004）。主动推断为这一思想提供了数学刻画，并补入了若干额外机制，例如精度控制与感觉衰减的重要性；这些机制在动作观念运动理论中尚未被充分展开，但与其是兼容的。

10.6.2 控制论

主动推断与控制论关于行为具有目的性、目标导向性以及主体--环境反馈交互重要性的观点密切相关，这一点在 TOTE（Test, Operate, Test, Exit）及其相关模型中表现得尤为典型（Miller et al. 1960; Pezzulo, Baldassarre et al. 2006）。在 TOTE 与主动推断中，动作的选择都由偏好目标状态与当前状态之间的差异所决定。这些方法都不同于简单的刺激--反应关系，后者更常见于行为主义理论与强化学习等计算框架中（Sutton and Barto 1998）。

主动推断中的动作控制观，尤其接近知觉控制理论（perceptual control theory）（Powers 1973）。该理论的核心主张是：被控制的是知觉状态，而不是运动输出或动作本身。比如开车时，我们所控制并在扰动下努力维持稳定的，是一个参考速度或目标速度，例如时速 90 英里，这一目标通过速度表反映出来；至于为了保持这一速度而采取的动作，例如加速还是减速，则更具可变性，也更依赖情境。例如，根据扰动的性质不同，如风、陡坡或其他车辆，我们可能需要加速，也可能需要减速，才能维持参考速度。这一看法实现了 William James（1890）的一个建议：人类是以灵活手段达成稳定目标的。

尽管在主动推断与知觉控制理论中，真正控制动作的都是知觉预测，尤其是本体感觉预测，但两者在控制如何实施这一点上有所不同。主动推断而非知觉控制理论，强调动作控制具有基于生

成模型的前瞻性或前馈成分。相比之下，知觉控制理论认为反馈机制基本已足够控制行为，而试图预测扰动、实施前馈控制或开环控制是没有价值的。不过，这一反对意见主要针对的是那些使用逆--前向模型的控制理论的局限，见下一小节。在主动推断中，生成模型或前向模型并不是用来预测扰动，而是用来预测需要通过行动来实现的未来期望状态与轨迹，并据此推断知觉事件的潜在原因。

主动推断与知觉控制理论之间另一重要契合点，是它们对控制层级的理解。知觉控制理论提出，更高层级通过设定更低层级的参考点或设定点，也就是规定低层级“要实现什么”，来控制低层级；而低层级仍可自由选择实现目标的手段，而不是被直接指定或偏置“怎么做”。这与大多数关于层级控制与自上而下控制的理论形成对照，后者通常认为高层级要么直接选择计划（Botvinick 2008），要么偏置低层级对动作或运动指令的选择（Miller and Cohen 2001）。类似知觉控制理论，主动推断也允许把层级控制分解为一个自上而下的目标与子目标级联结构，并使之在适当的较低层级上被自主实现。此外，在主动推断中，控制层级不同层次上表征的目标，其贡献还可以被动机过程所调制，即按精度加权，从而优先处理更显著或更紧迫的目标（Pezzulo, Rigoli, and Friston 2015, 2018）。

10.6.3 最优控制理论

主动推断对动作控制的说明，与神经科学中其他控制模型，如最优控制理论，有显著差异（Todorov 2004; Shadmehr et al. 2010）。该框架认为，大脑的运动皮层通过一个把刺激映射到反应的（反应式）控制策略来选择动作。而主动推断则认为，运动皮层传递的是预测，而不是指令。

此外，虽然最优控制理论与主动推断都诉诸内部模型，但它们对内部建模的理解不同（Friston 2011）。在最优控制中，内部模型分为两类：逆模型编码刺激--反应联结，并依据某种代价函数选择运动指令；前向模型则编码动作--结果联结，并向逆模型提供模拟输入，以替代噪声较大或延迟的反馈，从而超越纯反馈控制。逆模型与前向模型还可以在一个脱离外部行动--知觉回路的闭环中运作，也就是当输入与输出被抑制时，为内部的“如果如此会怎样”的动作序列模拟提供支持。这种内部动作模拟被用于解释多种认知功能，例如规划、动作知觉与社会领域中的模仿（Jeannerod 2001; Wolpert et al. 2003），以及多种运动障碍与精神病理现象（Frith et al. 2000）。

与前向--逆向建模方案不同，在主动推断中，动作控制的主要负担由前向（生成）模型承担，而逆模型非常简约，通常可以简化为在外周层级，也就是脑干或脊髓中解决的简单反射。当预期状态与观测状态之间存在差异时，例如期望的手臂位置与当前手臂位置不同，动作便被启动；这也就是一种感觉预测误差。换言之，在主动推断中，运动指令等价于前向模型作出的预测，而不是像最优控制中那样由逆模型计算出的结果。本体感觉预测误差会通过动作，也就是手臂移动，被消解。主动推断认为，这一需要由动作来填补的缺口很小，因此无需复杂的逆模型，只需简单得多的运动反射即可（Adams, Shipp, and Friston 2013）。[1]

最优运动控制与主动推断之间另一个关键差异在于，前者使用代价函数或价值函数来驱动行动，而后者则以贝叶斯意义上的先验来取而代之，更准确地说，是以期望自由能中隐含的先验偏好

[1]运动反射之所以比逆模型更简单，是因为它不编码从推断出的世界状态到动作的映射，而只编码动作与感觉后果之间更简单的映射。关于这一点的进一步讨论，见 Friston, Daunizeau et al. (2010)。

来承担这一角色。下一节将继续讨论这一点。

10.7 效用与决策

状态代价函数或价值函数的观念，在最优运动控制、效用最大化的经济学理论与强化学习等许多领域都居于核心地位。例如，在最优控制理论中，针对一个到达任务的最优控制策略，常被定义为使某一特定代价函数最小的策略，例如运动最平滑或最小跃度。在强化学习问题中，例如在带有一个或多个奖励的迷宫中导航，最优策略则是那个既能最大化贴现奖励，又能最小化运动成本的策略。这些问题往往通过 Bellman 方程来求解，在连续时间中则是 Hamilton–Jacobi–Bellman 方程。其一般思想是：一个决策的价值可以分解成两部分，即即时奖励与剩余决策问题的价值。正是这种分解使动态规划这一迭代程序成为可能，而动态规划正是控制理论与强化学习的核心（Bellman 1954）。

主动推断与上述思路在两个主要方面不同。第一，主动推断并不只考虑效用最大化，而是考虑更广义的目标，即最小化（期望）自由能；其中还包含额外的认识性要求，例如消除当前状态歧义与寻求新奇，见图 2.5。这些额外目标有时会在经典奖励之外被额外加入，例如作为“新奇奖励加成”（Kakade and Dayan 2002）或“内在奖励”（Schmidhuber 1991; Oudeyer et al. 2007; Baldassarre and Mirolli 2013; Gottlieb et al. 2013）；但在主动推断中，它们会自动出现，使系统能够处理许多决策中隐含的探索--利用权衡。原因在于，自由能是关于信念的泛函，因此我们进入的是信念优化而非外部奖励函数的领域；这一点在探索性问题中尤其关键，因为在这类问题里，成功依赖于尽可能消除不确定性。

第二，在主动推断中，代价的观念被吸收到先验之中。先验，或先验偏好，规定了控制的目标，例如要遵循的轨迹或要抵达的终点。用先验来编码偏好观测或偏好观测序列，可能比使用效用更具表达力（Friston, Daunizeau, and Kiebel 2009）。在这种方法下，寻找最优策略被改写成一个推断问题：推断出那组能够实现偏好轨迹的控制状态序列。它不需要显式价值函数或 Bellman 方程，尽管可以诉诸类似的递归逻辑（Friston, Da Costa et al. 2020）。至少有两个基本差异，区分了主动推断与强化学习中通常使用先验与价值函数的方式。其一，强化学习使用的是状态价值函数或状态--动作对价值函数，而主动推断使用的是关于观测的先验。其二，价值函数是以遵循特定策略时，处于某个状态（或在某个状态下采取某一动作）的期望回报来定义的，即从该状态出发并执行该策略后所获得的未来贴现奖励之和。相比之下，在主动推断中，先验通常既不把未来奖励相加，也不对其贴现。相反，只有在计算某一策略的期望自由能时，才会涌现出与期望回报相近的量。因此，期望自由能才是价值函数最接近的对应物。但即便如此，它也不同，因为期望自由能是关于状态信念的泛函，而不是状态本身的函数。尽管如此，人们仍然可以构造出近似于强化学习状态价值函数的先验，例如把期望自由能的计算结果缓存到这些状态之中（Friston, FitzGerald et al. 2016; Maisto, Friston, and Pezzulo 2019）。

此外，把效用吸收到先验中还带来一个重要的理论后果：先验承担了目标的角色，并使生成模型具有偏置，或者说具有一种乐观性，即生物体相信自己会遭遇偏好的结果。正是这种乐观性支撑了主动推断中那些能实现期望结果的被推断计划；若缺乏这种类型的乐观，便可能对应于冷漠或意志缺失（Hezemans et al. 2020）。这与贝叶斯决策理论等其他决策形式化方法形成对

照，因为那些方法会把事件的概率与其效用区分开来。不过，这种区分在某种程度上只是表面的，因为一个效用函数总是可以被改写为某种先验信念，这与如下事实一致：最大化该效用函数的行为，先天地、按设计就是更可能发生的。从一种稍显同义反复式的去通胀视角看，这本就是“效用”的定义。

10.7.1 贝叶斯决策理论

贝叶斯决策理论是一套数学框架，它把贝叶斯大脑的思想扩展到决策、感觉运动控制与学习等领域（Kording and Wolpert 2006; Shadmehr et al. 2010; Wolpert and Landy 2012）。它将决策描述为两个相互区分的过程。第一过程利用贝叶斯计算预测未来结果的概率，这些结果依赖于动作或策略；第二过程则利用固定或学习到的效用函数或代价函数，来定义对计划的偏好。最终的决策过程，也即动作选择，会整合这两条信息流，从而以更高概率选择那条更可能带来更高回报的行动方案。这与主动推断形成对比：在主动推断中，先验分布直接标示出对生物体而言什么是有价值的，或者说什么在进化历史上曾经有价值。不过，人们仍可在贝叶斯决策理论的这两条信息流，与主动推断中变分自由能与期望自由能的优化之间建立类比。在主动推断里，最小化变分自由能能够带来关于世界状态及其可能演化的准确且简洁的信念；而通过策略选择来最小化期望自由能的先验信念，则内含了偏好的观念。

在某些学术圈中，人们对贝叶斯决策理论的地位有所疑虑。这一疑虑源自完全类定理（Wald 1947; Brown 1981）：对于任意给定的一组决策与代价函数，总存在某些先验信念使这些决策成为贝叶斯最优。也就是说，当先验信念与代价函数被分开处理时，两者之间存在一种隐含的对偶性或退化性。在某种意义上，主动推断正是通过将效用或代价函数吸收进先验信念并表述为偏好，来消解这种退化。

10.7.2 强化学习

强化学习（reinforcement learning, RL）是一种求解马尔可夫决策问题的方法，在人工智能与认知科学中都极为流行（Sutton and Barto 1998）。它关注主体如何通过试错来学习一个策略，例如平衡杆子的策略；主体尝试动作，例如向左移动，并根据动作成功（如杆子保持平衡）或失败（如杆子倒下）而获得正或负的强化。

主动推断与强化学习处理的问题集有重叠，但在数学形式与概念理解上有许多不同。正如前文所述，主动推断抛弃了奖励、价值函数与 Bellman 最优性这些强化学习的核心概念。此外，“策略”这一概念在两种框架中的用法也不同。在强化学习中，策略表示一组需要通过学习获得的刺激--反应映射；而在主动推断中，策略是生成模型的一部分，表示需要被推断出来的控制状态序列。

强化学习方法种类繁多，但大致可分为三大家族。前两类方法都试图学习良好的价值函数，只是路径不同。

无模型强化学习方法直接从经验中学习价值函数：它们执行动作、收集奖励、更新价值函数，再利用价值函数更新策略。之所以称为“无模型”，是因为它们不使用那种能够预测未来状态的转

移模型，而这种模型正是主动推断所使用的。取而代之，它们隐含地诉诸更简单的模型，例如状态--动作映射。无模型强化学习中的价值函数学习，往往涉及奖励预测误差的计算，例如广为人知的时序差分规则。主动推断当然也常诉诸预测误差，但那是状态预测误差，而非奖励预测误差，因为主动推断里没有奖励这一概念。

有模型强化学习方法并不直接从经验中学习价值函数或策略。相反，它们从经验中学习一个任务模型，利用该模型进行规划，也就是模拟可能经验，然后再用这些模拟经验来更新价值函数与策略。虽然主动推断与强化学习都诉诸基于模型的规划，但二者使用方式不同。在主动推断中，规划是为每一条策略计算期望自由能，而不是用来更新价值函数。严格说来，如果把期望自由能看作一种价值泛函，那么也可以说，借助生成模型得出的推断结果被用于更新这个泛函；这为两者提供了一个类比点。

第三类强化学习方法是策略梯度法。它们试图直接优化策略，而不经过价值函数这一中间层，而价值函数恰恰是有模型与无模型强化学习的核心。这类方法从参数化策略出发，这些策略能够生成例如运动轨迹，然后通过调整参数来优化策略：如果某条轨迹带来较高的正奖励，就提高该策略发生的概率；反之，则降低其概率。这一点使策略梯度方法与主动推断存在某种关联，因为主动推断同样不依赖价值函数（Millidge 2019）。但策略梯度的一般目标，即最大化长期累积奖励，与主动推断的目标仍然不同。

除了形式差异之外，主动推断与强化学习在概念上也有若干重要区别。其中一个区别涉及对目标导向行为与习惯行为的解释。在动物学习文献中，目标导向选择由关于动作与结果之间联结的前瞻性知识所中介（Dickinson and Balleine 1990）；而习惯性选择则不具前瞻性，依赖更简单的机制，例如刺激--反应机制。强化学习中的一个流行观点认为，目标导向与习惯性选择分别对应于有模型与无模型强化学习，并且二者是并行习得、持续竞争行为控制权的（Daw et al. 2005）。

主动推断则把目标导向与习惯性选择映射到不同机制。在离散时间的主动推断中，策略选择本质上是基于模型的，因此符合目标导向、审议性选择的定义。这一点与有模型强化学习相似，但仍有区别：在有模型强化学习中，动作是在前瞻意义上被选择的，因为使用了模型，但动作控制本身仍是反应式的，依赖刺激--反应策略；而在主动推断中，动作可以通过实现本体感觉预测而以前摄方式受到控制，参见第 10.6 节。

在主动推断中，习惯可以通过反复执行目标导向策略，并缓存“在什么情境下哪些策略会成功”的信息来获得。这些缓存的信息可以作为策略的先验价值被并入模型（Friston, FitzGerald et al. 2016; Maisto, Friston, and Pezzulo 2019）。这一机制允许系统在不经审议的情况下，直接执行在给定情境中具有高先验价值的策略。简单说，这相当于主体反复观察“我在做什么”，进而学到“我是那种倾向于这样做的生物”。与无模型强化学习中习惯独立于目标导向策略选择而被习得不同，主动推断中的习惯是通过反复追求目标导向策略而形成的，例如把这些策略的结果缓存下来。

在主动推断中，目标导向机制与习惯机制可以合作，而不只是竞争。这是因为，对策略的先验信念同时依赖于一个习惯项，即策略的先验价值，以及一个审议项，即期望自由能。主动推断的层级化扩展甚至暗示，反应式机制与目标导向机制可以被组织成一个层级，而不是并行通路

(Pezzulo, Rigoli, and Friston 2015)。

最后还值得指出的是，主动推断与强化学习在如何理解行为及其成因上也有微妙差异。强化学习起源于行为主义理论，认为行为是由强化所中介的试错学习结果。主动推断则假定，行为是推断的结果。这就引向下一小节。

10.7.3 规划即推断

就像知觉问题可以被表述为推断问题一样，控制问题也可以被表述为一种近似贝叶斯推断问题(Todorov 2008)。与此一致，在主动推断中，规划被看作一种推断过程，即对生成模型中的控制状态序列进行推断。

这一想法与其他若干路径密切相关，包括“控制即推断”(Rawlik et al. 2013; Levine 2018)、“规划即推断”(Attias 2003; Botvinick and Toussaint 2012)，以及风险敏感控制与 KL 控制(Kappen et al. 2012)。在这些方法中，规划通过推断关于动作或动作序列的后验分布来进行；其依据是一个动态生成模型，该模型编码状态、动作与未来期望状态之间的概率联结。通过在生成模型中对未来奖励（Pezzulo and Rigoli 2011; Solway and Botvinick 2012）或最优未来轨迹（Levine 2018）进行条件化，就可以推断出最佳动作或计划。例如，可以把模型中的未来期望状态夹定，也就是固定其取值，然后推断最可能把当前状态带到未来期望状态的动作序列。

主动推断、规划即推断以及其他相关方案，都采用一种前瞻式控制：它们从对未来待观测状态的显式表征出发，而不是像最优控制与强化学习那样更多地从一组刺激--反应规则或策略出发。不过，控制即推断与规划即推断的具体实现至少沿着三个维度有所不同：使用什么形式的推断，例如抽样还是变分推断；推断的对象是什么，例如关于动作还是动作序列的后验分布；以及推断的目标是什么，例如最大化某种最优性条件的边缘似然，还是最大化获得奖励的概率。

主动推断在这三个维度上都采取了独特立场。第一，它使用一种可扩展的近似方案，即变分推断，来解决规划即推断中出现的困难计算问题。第二，它支持基于模型的规划，也就是对控制状态后验的推断，而控制状态对应的是动作序列或策略，而非单个动作。[2] 第三，为了推断动作序列，主动推断考虑的是期望自由能这一泛函；它在数学上囊括了其他广泛使用的规划即推断方案，例如 KL 控制，并且能够处理含糊不清的情形（Friston, Rigoli et al. 2015）。

10.8 行为与有限理性

在主动推断中，行为会自动混合多种成分：审议性、持续性与习惯性（Parr 2020）。设想一个人正在从家附近走向一家商店。如果她能够预测自己行动的后果，例如向左转还是向右转会发生什么，那么她就能形成一个到达商店的好计划。行为中的这一审议性面向由期望自由能提供；当一个人以实现偏好观测的方式行动时，例如出现在商店里，期望自由能就会被最小化。需要注意的是，期望自由能还包含降低不确定性的驱动力，这一点也会体现在审议过程中。例如，如

[2]在离散时间主动推断中，策略通常就是未来一段时间内控制状态的序列。

果此人不确定哪条路最好，她可能会先走到一个更合适的观察位置，从那里更容易看清通往商店的路，即便这意味着绕远一些。总之，她的计划会获得认识性可供性。

如果这个人较少有能力进行审议，例如因为她分心了，那么她可能在到达商店后还继续往前走。这种行为中的持续性面向由变分自由能提供；当一个人收集到与当前信念相容的观测时，包括与当前行动进程相关的信念，变分自由能就会被最小化。她所收集到的感觉与本体感觉观测会为“正在行走”这一解释提供证据，因此在缺少审议时便可能导致行为持续。

最后，当这个人不太能进行审议时，她还可能不假思索地选择那条平常回家的路线。这种习惯性成分由策略的先验价值提供。它会把较高概率赋给“回家”这一计划，因为这是她过去多次观察自己实际执行过的计划；在没有被审议过程压过的情况下，这一先验便可能占据主导。

需要注意的是，审议性、持续性与习惯性并非互斥，而是在主动推断中共存并可组合。换言之，主体完全可以推断出：在当前情境中，习惯是最可能的行动路线。这一点不同于那些“双系统理论”，后者假定我们被两个彼此分离的系统所驱动，一个理性，一个直觉（Kahneman 2017）。行为中这三种成分的混合比例，似乎取决于情境条件，例如经验多少，以及个体能投入到审议过程中的认知资源多少，因为审议往往伴随着较高的复杂性成本。[3]

认知资源对决策的影响，通常在“有限理性”这一框架下被研究（Simon 1990）。其核心思想是：理想的理性主体应当总是充分考虑自身行动的后果，而有限理性的主体则必须平衡计算的成本、努力与时效性，例如为审议最佳计划而承担的信息处理成本（Todorov 2009; Gershman et al. 2015）。

10.8.1 有限理性的自由能理论

有限理性已经被表述为 Helmholtz 自由能最小化问题，而这一热力学构造与主动推断中所使用的变分自由能概念有严格关联；详见 Gottwald and Braun（2020）。“有限理性的自由能理论”用自由能的两个组成部分，即能量与熵，来表述在信息处理能力受限时进行动作选择所面临的权衡，见第 2 章。前者代表一个选择的期望价值，也就是准确性项；后者代表审议成本，也就是复杂性项。审议之所以有成本，是因为为了在决策前让信念更精确，就需要降低其熵，也就是降低其不确定性或复杂性（Ortega and Braun 2013; Zénon et al. 2019）。直观地说，更精确的后验信念会带来更准确的选择，也可能蕴含更高效用；但由于提高信念精度本身是有代价的，因此有限理性的决策者必须通过最小化自由能来寻求折中。在主动推断中，同样的权衡自然会出现，从而生成有限理性的行为形式。有限理性的观念也呼应了主动推断的一个决定性特征，即使用证据，也就是边缘似然的变分下界。总之，主动推断提供了一种关于有限理性与最优性的模型：在给定问题上，最佳解不是单纯把某个单一指标推到极致，而是来自准确性与复杂性之间的折中。这些目标源于一种比经典目标，如经济学常讨论的效用最大化，更丰富的规范性要求，即自由能最小化。

[3]这里的复杂性成本，可以理解为为了让信念更精确而付出的信息处理代价。

10.9 效价、情绪与动机

主动推断把负自由能看作适应度与生物体实现目标能力的一种度量。虽然主动推断认为生物体会通过行动来最小化自由能，但这并不意味着它们必须显式计算自由能本身。一般来说，只要沿着自由能的梯度行动即可。打个比方，我们不需要知道自己当前的海拔高度，也能通过顺着坡向上走而抵达山顶。不过，也有人提出，生物体可能会建模自身自由能如何随时间变化。支持这一假设的人认为，这将有助于刻画效价、情绪与动机等现象。

按照这一观点，情绪效价，也就是情绪的正向或负向性质，可以被理解为自由能随时间变化的速率，也就是自由能关于时间的一阶导数（Joffily and Coricelli 2013）。具体而言，当一个生物体体验到自由能随时间上升时，它可能会对当下情境赋予负效价；而当它体验到自由能随时间下降时，则可能赋予正效价。若再把这一思路扩展到自由能的长期动态，乃至其二阶时间导数，便可能刻画更复杂的情绪状态，例如从低效价阶段转入高效价阶段时的宽慰，或从高效价阶段跌入低效价阶段时的失望。监控自由能动态及其引发的情绪状态，可能有助于系统根据长期环境统计来调整行为策略或学习速率。

当然，假设还存在第二个生成模型，专门负责监控第一个生成模型的自由能，这看起来似乎跨得太远了。不过，这些思想还可以有另一种解释方式。一个有趣的形式化思路是，去思考究竟是什么导致了自由能的快速变化。由于自由能本身是关于信念的泛函，因此自由能的快速变化必定来自快速的信念更新。而决定这种更新速度的关键因素是精度；在预测编码动力学中，精度相当于一个时间常数。有意思的是，这又把我们带回自由能的高阶导数，因为精度等于自由能景观曲率的负值，也就是二阶导数的负号。不过，这又引出了一个问题：为什么我们应把精度与效价联系起来？答案在于，精度与模糊性成反比。某件事越精确，其解释就越不含糊。选择一条能够最小化期望自由能的行动路线，也就意味着最小化模糊性，从而最大化精度。这样一来，我们就直接把自由能的高阶导数、自由能变化速率与受动机驱动的行为联系起来了。

关于自由能增长或下降的预期，也可能发挥动机功能并激励行为。在主动推断中，一个关于自由能变化的替代性预期量，就是关于策略的信念精度，这再次凸显了这一二阶统计量的重要性。举例而言，高精度信念表明主体已经找到了一条好策略，也就是一条可以被高度自信地预期为最小化自由能的策略。有意思的是，关于策略的信念精度已经被联系到多巴胺信号（FitzGerald, Dolan, and Friston 2015）。从这一角度看，那些提高策略信念精度的刺激会触发多巴胺爆发，而这可能标示了它们的激励显著性（Berridge 2007）。这一视角也许能帮助解释：为什么对目标或奖励即将实现的预期，会与注意增加（Anderson et al. 2011）和动机增强（Berridge and Kringelbach 2011）之间存在神经生理联系。

10.10 内稳态、异稳态与内感受加工

一个生物体的生成模型不仅关乎外部世界，而且也关乎，也许更重要地关乎，其内部环境。关于身体内部的生成模型，也就是内感受图式，承担双重角色：一方面解释内感受，也就是身体感觉，是如何产生的；另一方面确保生理参数得到正确调节（Iodice et al. 2019），例如体温或

血糖水平。控制论传统，前文第 10.6.2 节已略有涉及，认为生命体的一个核心目标是维持内稳态（Cannon 1929），即让生理参数保持在可生存范围内，例如体温不能高得离谱；而内稳态只有通过成功控制环境才能实现（Ashby 1952）。

在主动推断中，这种内稳态调节可以通过把生理参数的可存活范围设定为关于内感受观测的先验来实现。有趣的是，内稳态调节可以通过多层嵌套方式完成。最简单的调节回路，是当某些参数已经超出，或预计将超出范围时，启动自主神经反射，例如血管扩张，以应对过高体温。这类自主控制可以被构造为内感受推断，也就是一种作用于内感受流而非本体感觉流的主动推断过程，后者更对应朝向外部的行动（Seth et al. 2012; Seth and Friston 2016; Allen et al. 2019）。为此，大脑可以使用一个预测内感受与生理流的生成模型，并通过触发自主神经反射来修正内感受预测误差，例如“体温出奇地高”。这类似于系统如何通过激活运动反射来修正本体感觉预测误差，并引导朝向外部的行动。

主动推断并不止步于简单的自主回路。它还可以用越来越复杂的方式来修正同一个内感受预测误差，例如体温过高（Pezzulo, Rigoli, and Friston 2015）。它可以采用预测性的异稳态策略（Sterling 2012; Barrett and Simmons 2015; Corcoran et al. 2020），超越单纯内稳态，在内感受预测误差被真正触发之前，就以异稳态方式预先控制生理状态，例如在过热之前先去找阴凉处。另一种预测性策略，是在预计生理设定点将发生偏离之前，预先动员资源，例如在长跑之前提高心输出量，以应对即将增加的氧气需求。这要求系统动态修改关于内感受观测的先验，从而超越静态内稳态（Tschantz et al. 2021）。最终，预测性大脑还可以发展出更复杂的目标导向策略，例如去海滩时提前带上冰水，以更丰富、更高效的方式满足同一个要求，也就是控制体温。

生物学调节与内感受调节，对情感与情绪加工可能至关重要（Barrett 2017）。在情境化互动中，大脑的生成模型不断预测的不只是“接下来会发生什么”，还包括“这些事件对内感受与异稳态会带来什么后果”。在感知外部对象与事件时被激发的内感受流，会为这些对象与事件赋予情感维度，提示它们对生物体的异稳态与生存究竟是好还是坏，从而使它们变得“有意义”。如果这一看法是正确的，那么内感受与异稳态加工的障碍，就可能引发情绪失调以及多种精神病理状态（Pezzulo 2013; Barrett et al. 2016; Maisto, Barca et al. 2019; Pezzulo, Maisto et al. 2019）。

与内感受推断相伴而生的，还有一个新兴方向，即情绪推断。在这种主动推断应用中，情绪被视为生成模型的一部分：它们只是大脑用来在深层生成模型中部署精度的另一类构念或假设。从信念更新的角度看，这意味着焦虑不过是对贝叶斯信念“我很焦虑”的一种承诺，而这一信念最能解释当前占优的感觉与内感受线索。从行动的角度看，随之而来的内感受预测会增强或减弱各种精度，也就是隐性行动，或者驱动自主神经反应，也就是显性行动。这种状态看起来很像唤醒，从而反过来确认“我很焦虑”这一假设。通常，情绪推断涉及一种领域一般性的信念更新，它会同时整合来自内感受与外感受感觉流的信息；这也解释了为何情绪、内感受与注意在健康状态（Seth and Friston 2016; Smith, Lane et al. 2019; Smith, Parr, and Friston 2019）与疾病状态（Peters et al. 2017; J. E. Clark et al. 2018）中关系如此紧密。

10.11 注意、显著性与认识动态

考虑到本章中我们已经无数次提到精度与期望自由能，如果不专门给注意与显著性留出一点篇幅，那就失职了。这两个概念贯穿整个心理学史，且经历过无数次重定义与分类。有时，人们用它们来指涉突触增益控制机制（Hillyard et al. 1998），即优先选择某种感觉模态，或某个模态内的一部分通道；有时，它们又指我们如何通过显性或隐性行动来调整定向，以获取更多世界信息（Rizzolatti et al. 1987; Sheliga et al. 1994, 1995）。

尽管“注意”这一术语的多重含义使该研究领域带有某种认识上的吸引力，但消解由此带来的歧义同样有价值。形式化心理学的一个好处就在于，我们不必被这些歧义困住。我们可以在操作上把注意定义为与某些感觉输入相关联的精度。这一定义与增益控制的概念恰好契合，因为那些被我们推断为更精确的感觉，会比那些被推断为不精确的感觉，对信念更新产生更大影响。这种对应关系的构念效度已经在若干心理学范式中得到展示，包括著名的 Posner 范式（Feldman and Friston 2010）。更具体地说，对视觉空间中被赋予更高精度位置上的刺激所做出的反应，会比对其他位置刺激的反应更快。

这就使“显著性”这一术语也需要一个类似的形式定义。通常，在主动推断中，我们把显著性与期望信息增益，也就是认识价值，联系起来；它是期望自由能的一个组成部分。直观上说，我们越预期某个对象或位置会提供更多信息，它就越显著。不过，这一定义是相对于动作或策略来说的，而注意则是感觉输入信念的属性。这与把显著性理解为显性或隐性定向是一致的。我们在第 7 章中已经看到，还可以把期望信息增益进一步拆分为显著性与新奇性：前者关乎推断的潜力，后者关乎学习的潜力。一个能够表达注意与显著性或新奇性区别的类比，是科学实验的设计与分析。注意，是在我们已经测得的数据中，挑选质量最高的数据，并用它们来支持假设检验的过程；显著性，则是设计下一次实验，以确保能获得质量最高的数据。

我们在这里停留这一问题，并不是要再给文献贡献一种新的注意现象分类，而是要强调：一旦承诺于一种形式化心理学，就会带来一个重要优势。在主动推断之下，别人如何定义注意，或者如何定义任何其他构念，都不再重要，因为我们可以直接诉诸相应的数学构造，从而避免混淆。最后还有一点值得考虑：上述定义还提供了一个简单解释，说明为什么注意与显著性常常被混为一谈。高精度数据意味着最小模糊性。因此，这些数据理应得到注意，而获取这些数据的行动也会显得高度显著（Parr and Friston 2019a）。

10.12 规则学习、因果推断与快速泛化

人类与其他动物擅长进行复杂因果推断，学习抽象概念与对象之间的因果关系，并从有限经验中实现泛化。相比之下，当前机器学习范式往往需要大量样本才能取得类似表现。这种差异提示我们，现有机器学习方法虽然在模式识别方面高度成熟，但可能并没有完整捕捉人类学习与思考的方式（Lake et al. 2017）。

主动推断的学习范式建立在生成模型的发展之上，而生成模型用来刻画动作、事件与观测之间的因果关系。本书中，我们讨论的任务相对简单，例如第 7 章中的 T 形迷宫例子，只需要不太

复杂的生成模型即可。相反，要理解并推理复杂情境，就需要深层生成模型，能够把握环境中的潜在结构，例如那些允许我们跨越表面不相似情境进行泛化的隐藏规律（Tervo et al. 2016; Friston, Lin et al. 2017）。

一个由隐藏规则支配复杂社会互动的简单例子，是交通路口。设想一个天真的观察者站在繁忙十字路口，试图预测或解释“在什么情况下行人过马路、车辆通过”。他可以积累关于事件共现的统计，例如一辆红车停下时，一个高个子男人过街；或一位老妇人停下时，一辆大车驶过，但其中大多数统计最终都没什么用。经过一段时间，他也许会发现某些重复出现的统计模式，例如所有车辆在路上某一点停下后不久，行人就会过街。如果任务仅仅是预测行人何时准备过街，那么在机器学习设定中，这种统计规律也许已经足够；但它并不意味着对情境有了真正理解。事实上，它甚至可能导向错误结论，例如以为是“车辆停下”导致了“行人移动”。这类错误在不诉诸因果模型的机器学习应用中很典型，因为它们无法区分是下雨导致草地变湿，还是草地变湿导致下雨（Pearl and Mackenzie 2018）。

另一方面，推断出正确的隐藏规则，例如交通灯规则，则能更深入地理解该情境的因果结构，例如是交通灯导致车辆停下，也导致行人通行。隐藏规则不仅带来更好的预测能力，也使推断更为简约，因为它可以抽离掉大多数感觉细节，例如车辆的颜色。反过来，这又允许系统把理解泛化到其他情境，例如不同的十字路口或不同城市，尽管那些地方的大多数感觉细节都显著不同。当然，面对某些城市的路口，例如罗马，也许只看交通灯还不够。最后，关于交通灯规则的学习，还可能使个体在新情境中的学习更高效，也就是发展出心理学所谓的“学习定势”，或机器学习里的“学会学习”能力（Harlow 1949）。当面对一个交通灯失灵的路口时，先前习得的规则虽然不再能直接使用，但个体仍可能预期：这里还有另一个相似的隐藏规则在起作用，这种预期会帮助他理解交通警察到底在做什么。

这一简单例子说明，学习关于环境潜在结构的丰富生成模型，也就是结构学习，能够支持复杂形式的因果推理与泛化。如何扩展生成模型，使其足以处理这类复杂情境，是计算建模与认知科学中的一个持续目标（Tenenbaum et al. 2006; Kemp and Tenenbaum 2008）。有趣的是，这里存在一种张力：当前机器学习的发展趋势常常强调“越大越好”，而主动推断的统计学方法则强调平衡模型的准确性与复杂性，并偏好更简单的模型。模型约简，也就是修剪不必要的参数，并不仅仅是为了避免浪费资源，它也是学习隐藏规则的一种有效方式，包括在睡眠这类离线阶段中进行（Friston, Lin et al. 2017）；这种过程也许会体现在静息态活动中（Pezzulo, Zorzi, and Corbetta 2020）。

10.13 主动推断与其他领域：开放方向

本书主要关注那些处理生存与适应等生物学问题的主动推断模型。但主动推断同样可以应用于许多其他领域。在最后这一节里，我们简要讨论其中两个领域：社会与文化动力学，以及机器学习与机器人学。前者要求我们思考多个主动推断主体彼此互动的方式，以及这种互动所带来的涌现效应；后者则要求我们理解，如何在不违背该理论基本假设的前提下，为主动推断赋予更高效的学习与推断机制，从而将其扩展到更复杂的问题上。这两者都是极具吸引力的开放研究方向。

10.13.1 社会与文化动力学

人类认知中许多有趣方面，涉及的不是个体主义式的知觉、决策与行动，而是社会与文化动力学（Veissière et al. 2020）。按定义，社会动力学需要多个主动推断生物体彼此互动，这些互动可以是物理性的，例如联合行动或团队运动，也可以是更抽象的，例如选举或社交网络。即使只是相同生物体之间的简单“相互主动推断”演示，也已经产生了有趣的涌现现象，例如能够抵抗离散的简单生命形式的自组织，参与形态发生过程以获得并恢复身体形态的能力，以及相互协调的预测与轮流互动（Friston 2013; Friston and Frith 2015a; Friston, Levin et al. 2015）。其他模拟则关注，生物体如何把自身认知延伸到物质人工物之上，并塑造自己的认知生态位（Bruineberg et al. 2018）。

这些模拟当然只捕捉到了我们社会与文化动力学复杂性的一小部分，但它们已经表明：主动推断具有从“个体科学”扩展为“社会科学”的潜力，也表明认知并不止于头骨之内（Nave et al. 2020）。

10.13.2 机器学习与机器人学

本书讨论的生成建模与变分推断方法，也在机器学习与机器人学中被广泛使用。在这些领域里，重点通常放在如何学习连接主义生成模型上，而不是像本书这样，重点放在如何使用这些模型进行主动推断。这一点很有意义，因为机器学习方法有潜力扩展本书中所讨论的生成模型与问题的复杂度；当然，它们也可能诉诸与主动推断十分不同的过程理论。

虽然我们不可能在这里综述机器学习中庞大的生成建模文献，但仍可简要提及几类最流行的模型，它们也孕育出许多变体。两个早期的连接主义生成模型，Helmholtz 机与 Boltzmann 机（Ackley et al. 1985; Dayan et al. 1995），为如何以无监督方式学习神经网络内部表征提供了范例。Helmholtz 机尤其接近主动推断的变分路线，因为它使用分离的识别网络与生成网络来推断隐变量上的分布，并从这些分布中采样以获得虚构数据。这些早期方法在实践上的成功有限，但后来，多层堆叠的受限 Boltzmann 机使系统能够学习多层内部表征，并成为无监督深度神经网络早期成功的代表之一（Hinton 2007）。

近年的两个连接主义生成模型例子，变分自编码器（variational autoencoders, VAEs）（Kingma and Welling 2014）与生成对抗网络（generative adversarial networks, GANs）（Goodfellow et al. 2014），如今已被广泛用于图像和视频的识别与生成等机器学习应用。VAE 展示了变分方法在生成网络学习中的一种优雅应用。它们的学习目标，即证据下界（evidence lower bound, ELBO），在数学上与变分自由能等价。这个目标既要求对数据做出准确描述，也就是最大化准确性；又偏好那些与先验差异不太大的内部表征，也就是最小化复杂性。后者起到所谓正则化器的作用，有助于泛化并避免过拟合。

GAN 采取的是另一条路径：它由一个生成网络和一个判别网络组成，两者在学习过程中持续竞争。判别网络学习区分生成网络生成的样本数据中哪些是真实数据、哪些是虚构数据；而生成网络则努力生成足以欺骗判别网络，也就是会被其误判的虚构数据。两者之间的竞赛迫使生成网络不断提高自身生成能力，产出高保真虚构数据；这一能力已被广泛用于生成逼真图像等任

务。

上述生成模型以及其他模型，也都可以用于控制任务。例如，Ha and Eck (2017) 使用一种序列到序列的 VAE 来学习预测铅笔笔画。通过从 VAE 的内部表征中采样，模型可以构造新的笔画式图画。生成建模方法同样被用于控制机器人运动。其中有些方法明确使用主动推断（Pio-Lopez et al. 2016; Sancaktar et al. 2020; Ciria et al. 2021）或与其非常接近的思想，只是处在连接主义设定中（Ahmadi and Tani 2019; Tani and White 2020）。

这一领域的主要挑战之一在于，机器人运动通常是高维的，因此需要学习复杂的生成模型。主动推断及其相关方法的一个有趣之处在于，最需要学习的，是动作与下一时刻感觉反馈，例如视觉与本体感觉反馈之间的前向映射。这种前向映射可以通过多种方式获得：自主探索、示范学习，甚至与人直接互动。例如，教师，也就是实验者，可以抓着机器人的手，沿着通往目标的轨迹引导其移动，从而为高效目标导向动作的习得提供支架（Yamashita and Tani 2008）。能够以多种方式学习生成模型，大大拓展了机器人最终可掌握技能的范围。反过来，利用主动推断发展更先进的神经机器人，不仅对技术发展重要，对理论发展也同样重要。因为主动推断中的一些关键特征，例如适应性的主体--环境互动、认知功能的整合以及具身性的重要性，在机器人场景中都能得到天然检验。

10.14 总结

本书一开始提出的问题是：我们是否可能从第一性原理出发理解大脑与行为？随后，我们把主动推断介绍为一个有资格回应这一挑战的候选理论。我们希望，读者此时已经被说服：对最初问题的回答是肯定的。在本章中，我们考察了主动推断为有感行为提供的统一视角，以及这一理论对熟悉的心理学构念，如知觉、行动选择与情绪，意味着什么。这也让我们有机会重新回顾全书引入的概念，并提醒自己：未来研究仍有许多引人入胜的问题处于开放状态。我们希望，本书能成为主动推断相关著作的有益补充，一方面补充其哲学讨论（Hohwy 2013; Clark 2015），另一方面也补充其物理学讨论（Friston 2019a）。

现在，我们来到了这段旅程的终点。我们的目标，一直是为那些有兴趣使用这些方法的人提供一个入门，无论是在概念层面还是形式层面。不过必须强调的是，主动推断并不是一种只靠阅读理论就能真正掌握的东西。我们鼓励所有喜欢这本书的读者，进一步在实践中追求它。在理论神经生物学中，一些重要的成人礼包括：试着写下一个生成模型；亲身体验模拟表现失常时的挫败；以及当意料之外的事情发生时，学会从自身先验信念被违背之中获得教训。无论你是否选择在计算层面继续推进这种实践，我们都希望，你会在日常生活中反思自己所进行的主动推断。它也许表现为，你不由自主地把目光转向视野边缘某个不确定的对象，以消解不确定性；也许表现为，你选择去一家自己喜欢的餐馆吃饭，以满足先验的味觉偏好；也许表现为，当淋浴水太热时，你会把温度调低，好让世界重新符合你关于其应然样貌的模型。归根结底，我们相信，你会以某种形式持续地实践主动推断。

附录 A　附录 A：数学背景

A.1　引言

本附录旨在介绍，或帮助读者温习，本书反复使用的基本数学技术。我们将对四个主题给出入门性但并不穷尽的概览：线性代数、泰勒级数近似、变分法以及随机动力学。对于每一种技术，我们也会指出它在本书何处发挥作用。这里的目标是提供一种聚焦式介绍，重点放在建立直觉，而不是给出形式化且严格的证明。理解并运用主动推断所需的数学并不复杂，但由于其基础横跨多个学科，往往很难找到把必要前置知识汇集在一起的材料。希望本附录能够在一定程度上弥补这一缺口。

A.2　线性代数

A.2.1　基础

线性代数提供了一套记号，用来以简单而紧凑的方式表达乘法与求和的组合。它依赖矩阵与向量：矩阵是由多行多列数字构成的数组结构，而向量可以看作多行单列的特殊情形。矩阵 A 在第 i 行第 j 列的元素记作 A_{ij}。两个矩阵 B 与 C 的乘积 A（或者矩阵与向量的乘积）定义如下：

$$A = BC \quad \Rightarrow \quad A_{ij} = \sum_k B_{ik} C_{kj}. \tag{A.1}$$

要使这个定义成立，B 的列数必须等于 C 的行数。但如果我们想表达下面这个求和：

$$A_{ij} = \sum_k B_{ki} C_{kj}, \tag{A.2}$$

那么应当怎样用线性代数记号来写呢？这时需要借助一种交换 B 的下标顺序的运算，也就是把数组沿对角线翻转，使列变成行、行变成列。这就是转置运算，通常用上标 T 表示：

$$B^T_{ik} = B_{ki}, \qquad A = B^T C = B \cdot C, \qquad A_{ij} = \sum_k B_{ki} C_{kj}. \tag{A.3}$$

式 (A.3) 展示了如何用转置算子表达式 (A.2) 中的求和。第二种写法使用了点积记号。这个记号的灵感在于，当 B 和 C 都只有一列时，式 (A.3) 就退化为向量点积。

另一个有用的运算是迹算子。它取出一个方阵主对角线上的元素并将其求和：

$$\mathrm{tr}[A] = \sum_i A_{ii}. \tag{A.4}$$

迹算子的一个重要性质在于：对于矩阵乘积，迹中的元素可以循环置换：

$$\begin{aligned}\mathrm{tr}[ABC] &= \sum_i \sum_j \sum_k A_{ij} B_{jk} C_{ki} \\ &= \sum_k \sum_i \sum_j C_{ki} A_{ij} B_{jk} = \mathrm{tr}[CAB] \\ &= \sum_j \sum_k \sum_i B_{jk} C_{ki} A_{ij} = \mathrm{tr}[BCA].\end{aligned} \tag{A.5}$$

本书最常用到这一恒等式的情形是标量。一个标量可以看作只有一行一列的矩阵，因此也可以对它施加迹算子，而结果不会改变。这意味着只要某个矩阵乘积最终得到的是标量，我们就可以像上面那样对项进行循环置换。

例如，设 B 是一个有 N 行 N 列的方阵，c 是一个有 N 行的向量，则由式 (A.5) 可得：

$$\begin{aligned}a &= c \cdot Bc \\ &= \mathrm{tr}[c^T Bc] \\ &= \mathrm{tr}[Bcc^T] \\ &= \mathrm{tr}[BC], \qquad C = c \otimes c = cc^T.\end{aligned} \tag{A.6}$$

这把一个二次型表达式（第一行）重写为两个矩阵乘积之迹（倒数第二行）。最后一行定义了外积，与内积（点积）相对。式 (A.6) 在多元正态分布的语境中特别有用，我们将在第 A.2.3 节看到这一点。

线性代数中最后还需要了解的两个概念是矩阵的逆和行列式。逆矩阵定义为

$$A^{-1}A = AA^{-1} = I. \tag{A.7}$$

式 (A.7) 表明，一个矩阵与其逆矩阵相乘得到单位矩阵，也就是主对角线上为 1、其他位置为 0 的方阵。任何矩阵乘以单位矩阵都会保持不变。它在线性代数中的地位相当于标量乘法中的 1。这意味着，如果某个量先乘以一个矩阵，再乘以该矩阵的逆，就会回到原来的量。

行列式也是一个有用的量，只是较难建立直观理解。本书中它只出现在多元正态分布的归一化常数中。因此，知道它如何计算就足够了，这里不作深入展开。它可递归地定义为

$$|A| = \sum_i (-1)^{i-1} A_{1i} \left|A_{\setminus(1,i)}\right|. \tag{A.8}$$

这里，$A_{\setminus(1,i)}$ 表示从矩阵 A 中去掉第 1 行和第 i 列后得到的矩阵。例如：

$$\begin{aligned} A &= \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \qquad A_{\setminus(1,1)} = A_{22}, \qquad A_{\setminus(1,2)} = A_{21}, \\ |A| &= A_{11}A_{22} - A_{12}A_{21}. \end{aligned} \tag{A.9}$$

至此，我们完成了对线性代数基本运算的概述。

A.2.2 导数

对矩阵和向量求导，本质上就是把常规微积分逐元素应用到矩阵中的每个元素。例如，如果矩阵 B 的元素都是标量 x 的函数，那么 B 关于 x 的导数为

$$A(x) = \partial_x B(x) \quad \Rightarrow \quad A(x)_{ij} = \partial_x B(x)_{ij}. \tag{A.10}$$

不过，为了理解本书中的技术细节，还需要掌握若干重要定义和恒等式。首先是如何对非标量对象求导。若向量 b 是另一个向量 c 的函数，那么 b 对 c 的导数是一个矩阵：

$$A = \partial_c b(c) \quad \Rightarrow \quad A_{ij} = \partial_{c_j} b(c)_i. \tag{A.11}$$

我们还会用到梯度算子，它处理的是对向量的导数，定义为

$$\nabla_b = \begin{bmatrix} \partial_{b_1} & \partial_{b_2} & \partial_{b_3} & \cdots \end{bmatrix}^T, \qquad a = \nabla_b x(b) \quad \Rightarrow \quad a_i = \partial_{b_i} x(b). \tag{A.12}$$

把梯度算子理解为由导数算子组成的向量，也就可以紧凑地定义一个相关量，即向量函数的散度：

$$\nabla_a \cdot b(a) = \sum_i \partial_{a_i} b(a)_i. \tag{A.13}$$

关于线性代数量的导数恒等式有很多，这里不试图给出完整综述；如果读者希望进一步深入，推荐参阅 *The Matrix Cookbook*（Petersen and Pedersen 2012）。这里我们只保留两个在本书中特别有用的恒等式。第一个是二次型的梯度：

$$
\begin{aligned}
d(a) &= \nabla_a\big(b(a)\cdot Cb(a)\big),\\
d(a)_i &= \partial_{a_i}\sum_j\sum_k b(a)_j C_{jk} b(a)_k\\
&= \sum_j\sum_k\left[\big(\partial_{a_i} b(a)_j\big)C_{jk}b(a)_k + \big(\partial_{a_i} b(a)_k\big)C_{jk}b(a)_j\right],\\
\Rightarrow\quad d(a) &= \nabla_a b(a)\cdot(C+C^T)b(a).
\end{aligned}
\tag{A.14}
$$

这里（以及本书其他地方）点积记号所隐含的转置是在梯度算子之前施加的：

$$
\nabla_a b(a)\cdot(\cdot) \;=\; \nabla_a b(a)^T(\cdot) \;\neq\; \big(\nabla_a b(a)\big)^T(\cdot).
\tag{A.15}
$$

式 (A.14) 在第 4 章推导预测编码的信念更新方程时会被用到。第二个有用恒等式是同一个二次型关于矩阵 C 的导数：

$$
\begin{aligned}
D(a) &= \nabla_C\big(b(a)\cdot Cb(a)\big),\\
D(a)_{ij} &= \partial_{C_{ij}}\sum_k\sum_l b(a)_k C_{kl} b(a)_l = b(a)_i b(a)_j,\\
\Rightarrow\quad D(a) &= b(a)\otimes b(a).
\end{aligned}
\tag{A.16}
$$

这里使用带矩阵下标的梯度算子，表示

$$
\nabla_C = \begin{bmatrix} \partial_{C_{11}} & \partial_{C_{12}} & \cdots \\ \partial_{C_{21}} & \partial_{C_{22}} & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}.
\tag{A.17}
$$

在附录 B 中，我们会看到式 (A.16) 如何帮助估计后验概率的协方差矩阵。

A.2.3 概率

在线性代数与概率推理结合的场景中，上述恒等式主要在两个方面发挥作用。第一，当我们推理的随机变量，也就是概率分布的支撑，是一个向量时；第二，当概率分布本身由向量、矩阵或更高阶张量形式的充分统计量来描述时。[1] 一个同时体现这两点的例子就是多元正态分布，其定义为

$$
p(x) = \frac{1}{(2\pi)^{k/2}|\Pi|^{-1/2}}\exp\left(-\frac{1}{2}(x-\eta)\cdot\Pi(x-\eta)\right),\qquad \dim(x)=k.
\tag{A.18}
$$

[1] 此处原文用脚注说明更高阶充分统计量的情形。

这里，x 是一个 k 维向量，因此众数 η 也是一个 k 维向量。精度矩阵 Π 是协方差矩阵的逆，是一个 $k \times k$ 的对称矩阵，用来描述概率质量围绕众数的离散程度。它在式 (A.18) 中出现两次：一次出现在归一化常数中（以行列式的形式），一次出现在指数项中。注意，指数中的二次项是一个标量，因此可以应用式 (A.6) 中的恒等式。这一点会在附录 B 中变得重要。

对于类别概率分布，其充分统计量就是概率构成的向量、矩阵或张量。例如，一个人掷六面骰子后可能得到的点数分布，可以用一个 6 维向量表示，其中每个元素给出对应点数出现的概率。真正更有意思的是条件概率。对变量 o 和 s 而言，若它们各自都可以取多个值，那么给定 s 时 o 的条件概率可以写成一个矩阵 A，其元素为

$$P(o = i \mid s = j) = A_{ij}. \tag{A.19}$$

这表示：若 s 取其第 j 个可能值，则 o 取其第 i 个可能值的概率，就是矩阵 A 第 i 行第 j 列的元素。进一步地，如果条件集合中有多个变量，就会得到张量结构：

$$P(o = i \mid s_1 = j, s_2 = k, s_3 = l, \ldots) = A_{ijkl\ldots}. \tag{A.20}$$

这里，条件集合中可以包含任意多个变量，因此会有任意多个下标，也就得到任意阶的张量。第 7 章中的一个 T 迷宫模型就使用了三阶概率张量；其原理可以直接推广到更高阶的情形。对于张量 A，我们在全书中都沿用式 (A.3) 的点积记号，表示对第一个下标求和：

$$A = B \cdot x \quad \Rightarrow \quad A_{jklm\ldots} = \sum_i B_{ijklm\ldots} x_i. \tag{A.21}$$

把分布表示为数字数组的一个好处在于，我们可以直接利用第 A.2.1 节和第 A.2.2 节中的定义，简洁地写出相关量。比如，本书经常需要计算信息论量，如概率分布的熵。熵是对对数概率的负期望（平均值）。对式 (A.19) 所示的条件分布，其熵可以写成

$$\begin{aligned}
H[P(o \mid s)] &\coloneqq -\mathbb{E}_{P(o|s)}[\ln P(o \mid s)], \\
H_j &\coloneqq H[P(o \mid s = j)] \\
&= -\sum_i P(o = i \mid s = j) \ln P(o = i \mid s = j), \\
\Rightarrow \quad H &= -\operatorname{diag}(A \cdot \ln A).
\end{aligned} \tag{A.22}$$

在式 (A.22) 中，diag 表示取一个矩阵的对角线元素并把它们堆叠成向量。这也说明了第 4 章中定义期望自由能时的一个例子：借助线性代数记号，可以非常紧凑地描述这些量是如何计算的。

A.3 泰勒级数近似

A.3.1 引言

很多时候，把函数 $f(x)$ 在某个局部区域内（例如点 a 附近）用一个近似函数 $\hat{f}(x)$ 来替代，会让问题变得更容易处理。如果我们只关心函数在 a 点的值，那么可以直接用该点处的常数来替换它：

$$\hat{f}(x) = f(a). \tag{A.23}$$

但这只有在 x 与 a 完全相等时才成立。若要使近似在 a 附近也有效，就可以添加一项，使得当 x 发生一个很小变化时，函数值的变化与 a 点处的梯度一致：

$$\hat{f}(x) = f(a) + \varepsilon\, \partial_x f(x)\big|_{x=a}, \qquad \varepsilon \coloneqq x - a. \tag{A.24}$$

当 $x = a$ 时，ε 项为零，与式 (A.23) 一致。此外，原函数与近似函数在 a 点的一阶导数也相同。

继续沿着这个思路，我们还可以再加上一项，用来刻画梯度变化的速率，也就是曲率，这样近似在偏离 a 更远一些的区域内仍然有效。事实上，并不需要在这里停下；我们可以不断加入新项，使原函数与近似函数的各阶导数逐次匹配：

$$\hat{f}(x) = f(a) + \varepsilon\, \partial_x f(x)\big|_{x=a} + \frac{\varepsilon^2}{2}\, \partial_x^2 f(x)\big|_{x=a} + \cdots = \sum_{n=0}^{\infty} \frac{\varepsilon^n}{n!}\, \partial_x^n f(x)\big|_{x=a}. \tag{A.25}$$

式 (A.25) 给出了一维情形下的泰勒展开。它也可以推广到多变量情形，此时 x 是一个向量：

$$f(x) \approx f(a) + \varepsilon \cdot \nabla_x f(x)\big|_{x=a} + \frac{1}{2}\varepsilon \cdot \nabla_x \big(\nabla_x f(x)\big)^T \varepsilon + \cdots. \tag{A.26}$$

其中，$\nabla_x(\nabla_x f(x))^T$ 被称为 Hessian 矩阵。

级数中的项越多，近似就越好。对本书的目的来说，我们不需要超过二阶（即二次）展开。下面几小节中，我们会指出本书如何利用这种近似。其中包括拉普拉斯近似，它支撑了第 4 章与第 8 章中的预测编码方案，以及第 9 章中用于基于模型的数据分析的变分拉普拉斯方案。此外，用于刻画连续轨迹的运动广义坐标（框 4.2）也可以理解为泰勒级数的系数。我们将在第 A.3.2 节和第 A.3.3 节中分别展开这些应用。

A.3.2 拉普拉斯近似

泰勒级数近似在概率推断中的一个重要应用，就是拉普拉斯近似。它指的是：在某个概率分布 p 的众数 μ 附近，用高斯分布来逼近该概率分布。若对概率分布的对数应用式 (A.26)，可得

$$\ln p(x) \approx \ln p(\mu) + \varepsilon \cdot \nabla_x \ln p(x)\big|_{x=\mu} + \frac{1}{2}\varepsilon \cdot \nabla_x \big(\nabla_x \ln p(x)\big)^T \varepsilon\big|_{x=\mu}, \qquad \varepsilon \coloneqq x - \mu. \tag{A.27}$$

这就是把式 (A.26) 中的 $f(x)$ 替换为 $\ln p(x)$，并令 $a = \mu$。近似等号右边第一项相对于 x 来说是常数，因此可吸收到归一化常数中。第二项在众数处为零，因为对数概率在众数处的梯度为零。对两边取指数，就得到

$$p(x) \approx \frac{1}{Z} \exp\left(-\frac{1}{2}\varepsilon \cdot C^{-1}\varepsilon\right) = \mathcal{N}(\mu, C^{-1}), \qquad C^{-1} \coloneqq -\nabla_x \big(\nabla_x \ln p(x)\big)^T\big|_{x=\mu}. \tag{A.28}$$

式 (A.28) 表明：当我们在众数附近用二次函数来近似对数概率时，相应的概率密度就是高斯分布。这就是对概率分布应用拉普拉斯近似。

不过，我们还可以把拉普拉斯近似应用到自由能泛函上。为了建立直觉，我们从一个自由能泛函开始（见第 4 章）：

$$F[q, y] = \mathbb{E}_{q(x)}\big[\ln q(x) - \ln p(y, x)\big]. \tag{A.29}$$

式 (A.29) 把自由能写成了两个对数概率之差的期望。q 是近似后验概率密度，p 是生成模型，用于描述隐状态 x 如何生成数据 y。与式 (A.27) 类似，我们可以对这两个对数概率分别做泰勒展开。先看变分密度：

$$\begin{aligned}
\ln q(x) &\approx \ln q(\mu) + (x-\mu) \cdot \nabla_x \ln q(x)\big|_{x=\mu} + \frac{1}{2}(x-\mu) \cdot \nabla_x \big(\nabla_x \ln q(x)\big)^T (x-\mu)\big|_{x=\mu} \\
&= \ln q(\mu) + \frac{1}{2}(x-\mu) \cdot \nabla_x \big(\nabla_x \ln q(x)\big)^T (x-\mu)\big|_{x=\mu}, \\
\Rightarrow \quad q(x) &\approx \mathcal{N}(\mu, \Sigma^{-1}), \qquad \Sigma^{-1} \coloneqq -\nabla_x \big(\nabla_x \ln q(x)\big)^T\big|_{x=\mu}, \qquad \mu = \arg\max_x q(x).
\end{aligned} \tag{A.30}$$

将式 (A.29) 中的期望作用到式 (A.30)，可得

$$\begin{aligned}
\mathbb{E}_{q(x)}[\ln q(x)] &\approx \ln q(\mu) - \frac{1}{2}\mathbb{E}_{q(x)}\big[(x-\mu) \cdot \Sigma^{-1}(x-\mu)\big] \\
&= \ln q(\mu) - \frac{1}{2}\operatorname{tr}\big[\Sigma^{-1}\mathbb{E}_{q(x)}[(x-\mu)(x-\mu)^T]\big] \\
&= -\frac{k}{2}\ln 2\pi - \frac{1}{2}\ln|\Sigma| - \frac{k}{2} \\
&= -\frac{1}{2}\ln\big((2\pi e)^k|\Sigma|\big).
\end{aligned} \tag{A.31}$$

这里，k 是 x 的维度。从第一行到第二行用到了式 (A.6) 中的迹恒等式。第三行的前两项来自多元正态分布的定义，也就是式 (A.18)。因此，式 (A.31) 给出了在拉普拉斯假设下，式 (A.29) 第一项的表达。

同样地，式 (A.29) 的第二项也可以围绕 μ 做展开：

$$
\begin{aligned}
\ln p(y,x) &\approx \ln p(y,\mu) + (\mu - x)\cdot \nabla_x \ln p(y,x)\big|_{x=\mu} \\
&\quad + \frac{1}{2}(\mu - x)\cdot \nabla_x\big(\nabla_x \ln p(y,x)\big)^T(\mu - x)\big|_{x=\mu}, \\
\mathbb{E}_{q(x)}[\ln p(y,x)] &\approx \ln p(y,\mu) + (\mu - \mathbb{E}_{q(x)}[x])\cdot \nabla_x \ln p(y,x)\big|_{x=\mu} \\
&\quad + \frac{1}{2}\operatorname{tr}\Big[\mathbb{E}_{q(x)}[(\mu - x)(\mu - x)^T]\nabla_x\big(\nabla_x \ln p(y,x)\big)^T\big|_{x=\mu}\Big] \\
&= \ln p(y,\mu) + \frac{1}{2}\operatorname{tr}\Big[\Sigma\nabla_x\big(\nabla_x \ln p(y,x)\big)^T\big|_{x=\mu}\Big]. \qquad \text{(A.32)}
\end{aligned}
$$

最后一步用到了一个事实：如果 q 是正态分布，那么它的均值也就是它的众数。把式 (A.31) 和式 (A.32) 代回式 (A.29)，便得到拉普拉斯自由能：

$$
F[q,y] \approx -\frac{1}{2}\ln\big((2\pi e)^k|\Sigma|\big) - \ln p(y,\mu) - \frac{1}{2}\operatorname{tr}\Big[\Sigma\nabla_x\big(\nabla_x \ln p(y,x)\big)^T\big|_{x=\mu}\Big]. \qquad \text{(A.33)}
$$

当 x 是一维时，最后一项中的迹算子可以省略。这个表达形式的一个重要优点在于：如果把自由能对后验精度求导并令其为零，就得到

$$
\partial_\Sigma F[q,y] = 0 \quad \Leftrightarrow \quad \Sigma^{-1} = -\nabla_x\big(\nabla_x \ln p(y,x)\big)^T\big|_{x=\mu}. \qquad \text{(A.34)}
$$

这意味着，后验精度就是在后验众数处评估得到的、状态与数据的对数概率的负曲率。因此，最小化自由能并不要求我们显式优化精度；它可以从后验均值解析地计算出来。进一步地，把式 (A.34) 代入式 (A.33) 后可以发现，自由能中唯一依赖后验均值的项，是数据与状态的对数概率。关于如何利用这一点在连续状态空间模型中执行推断，可参见第 4 章。

A.3.3 运动的广义坐标

除了是拉普拉斯近似的核心之外，泰勒级数近似在主动推断中还扮演了另一个重要角色，即用运动的广义坐标来表示关于时间轨迹的信念。简言之，这意味着我们不仅推断变量的位置 x，还推断它的速度 x'、加速度 x'' 以及更高阶的时间导数。这些量隐式地表示了一种轨迹近似，而这种近似可以通过下列泰勒展开显式写出：

$$
x(t) \approx x(\tau) + \varepsilon\, x'(t)\big|_{t=\tau} + \frac{\varepsilon^2}{2}x''(t)\big|_{t=\tau} + \cdots, \qquad \varepsilon = t - \tau. \qquad \text{(A.35)}
$$

这也意味着，我们能够处理随机波动协方差中的结构，而在生物系统中这是必要的，因为这些波动本身也是由动力学过程生成的。我们将在第 A.5 节进一步讨论这一点。这里先只指出：定义在运动广义坐标上的概率密度，等价于一个关于局部轨迹的分布，其中这些坐标被视为泰勒展开的系数。

A.4 变分法

A.4.1 泛函导数

由于主动推断关心的是信念，也就是概率分布的优化，因此经常需要讨论：如何对函数的函数，也就是泛函，关于函数本身做最小化。这就需要引入泛函导数（也称变分导数）的概念。基本问题是：寻找一个函数 f，使得某个泛函 S 最小。这个泛函通常写成包含 f 的函数的积分形式[2]：

$$\phi(x) = \arg\min_f S[f(x)], \qquad S[f(x)] \coloneqq \int_{x_1}^{x_2} L\big(f(x), x\big)\, dx. \tag{A.36}$$

如果用一个任意函数 g 来参数化这个函数，并要求 g 在积分区间两端都为零，再乘上一个小数 u，就可以对 S 关于 u 求导：

$$\begin{aligned} f(x,u) &\coloneqq \phi(x) + ug(x), \\ \partial_u S[f(x,u)] &= \int_{x_1}^{x_2} \partial_u L\big(f(x,u), x\big)\, dx \\ &= \int_{x_1}^{x_2} \partial_f L\big(f(x,u), x\big)\, \partial_u f(x,u)\, dx \\ &= \int_{x_1}^{x_2} g(x)\, \partial_f L\big(f(x,u), x\big)\, dx. \end{aligned} \tag{A.37}$$

当 $u = 0$ 时，f 就是使积分最小的函数。因此，式 (A.37) 在 $u = 0$ 处应当为零。于是，f 最小化 S 所必须满足的条件就是

$$\int_{x_1}^{x_2} g(x)\, \partial_f L\big(f(x), x\big)\big|_{f=\phi}\, dx = 0. \tag{A.38}$$

要使式 (A.38) 对任意的 $g(x)$ 都成立，就意味着[3]

$$\delta_f S \coloneqq \partial_f L = 0. \tag{A.39}$$

需要注意的是，在物理学语境下，L 往往不仅依赖于函数 f 本身，还依赖于它的梯度。此时，沿用上面的步骤就会得到 Euler–Lagrange 方程：

$$\delta_f S \coloneqq \partial_f L - \frac{d}{dx}\partial_{f'} L = 0, \qquad f' \coloneqq \partial_x f. \tag{A.40}$$

视 L 是否包含梯度项而定，式 (A.39) 和式 (A.40) 共同表达了变分导数，也就是泛函导数的概念。

[2]原文在此处给出脚注，说明更一般的积分型泛函情形。

[3]原文此处给出脚注，说明该推论依赖变分法的基本引理。

A.4.2 变分贝叶斯

如果把上面的 f 设为近似后验分布的一个因子，把 S 设为自由能泛函，那么变分贝叶斯就可以相当直接地从上面的结果推出：

$$
\begin{aligned}
f(x) &= q_i(x_i), \\
q(x) &= \prod_i q_i(x_i), \\
L\big(q_i(x_i), x_i\big) &= \int q(x)\big(\ln q(x) - \ln p(y,x)\big)\, dx_{j\neq i}, \\
S[q(x)] &= F[q(x), y].
\end{aligned} \tag{A.41}
$$

这里第二行表达的是均值场近似：近似后验在变量 x 上分解成若干因子。这通常是出于计算可处理性的考虑。不过，这只是近似后验形式的诸多选择之一。将式 (A.39) 应用于这里，可以得到使自由能最小的近似后验形式（忽略常数项）：

$$
\begin{aligned}
\delta_{q_i} F[q,y] &= \ln q_i(x_i) - \int \prod_{j\neq i} q_j(x_j) \ln p(y,x)\, dx_{j\neq i}, \\
\delta_{q_i} F[q,y] = 0 \quad &\Leftrightarrow \quad \ln q_i(x_i) = \mathbb{E}_{q_{\setminus i}}[\ln p(y,x)].
\end{aligned} \tag{A.42}
$$

记号 $\setminus i$ 应读作“除第 i 个因子之外的所有因子”。式 (A.42) 是一种被称为变分消息传递（variational message passing；Winn and Bishop 2005, Dauwels 2007）的推断方案的核心。它通过分别优化 q 的每一个因子来工作，并依赖于 p 具有相对稀疏的结构，也就是并非每个 x_i 都依赖于所有其他 x_j。为帮助建立直觉，可以看一个任意例子：

$$
\begin{aligned}
& p(y,x) = p(y \mid x_1)\, p(x_1 \mid x_2, x_3)\, p(x_3)\, p(x_2 \mid x_4)\, p(x_4), \\
\Rightarrow \quad & \ln q(x_1) = \mathbb{E}_{q(x_2)q(x_3)q(x_4)}\big[\ln p(y \mid x_1) + \ln p(x_1 \mid x_2, x_3) + \ln p(x_3) p(x_2 \mid x_4) p(x_4)\big], \\
& \ln q(x_2) = \mathbb{E}_{q(x_1)q(x_3)q(x_4)}\big[\ln p(x_1 \mid x_2, x_3) + \ln p(x_2 \mid x_4) + \ln p(y \mid x_1) p(x_3) p(x_4)\big].
\end{aligned} \tag{A.43}
$$

式 (A.43) 展示了把第一行中的密度代入式 (A.42)，并取 q 的前两个因子时会发生什么。去掉对相应变量来说是常数的项后，得到

$$
\begin{aligned}
\ln q(x_1) &= \ln p(y \mid x_1) + \mathbb{E}_{q(x_2)q(x_3)}[\ln p(x_1 \mid x_2, x_3)], \\
\ln q(x_2) &= \mathbb{E}_{q(x_1)q(x_3)}[\ln p(x_1 \mid x_2, x_3)] + \mathbb{E}_{q(x_4)}[\ln p(x_2 \mid x_4)].
\end{aligned} \tag{A.44}
$$

其中，期望里的项之所以可以简化，是因为

$$\mathbb{E}_{p(b)}[f(a)] = \int p(b)f(a)\,db = f(a)\int p(b)\,db = f(a). \tag{A.45}$$

这也解释了变分消息传递为什么简洁：为了更新某个信念，我们只需要考虑一小部分相关信念，即关于 Markov blanket（见框 4.1）的那些信念。

A.5 随机动力学

A.5.1 随机微分方程

本书有几个地方会提到随机动力系统理论中的思想。例如在第 3 章，我们强调了随机系统随时间趋向某个稳态分布的重要性，以及这些动力学与自证（self-evidencing）概念之间的关系。在第 4 章和第 8 章中，我们还概述了如何把连续状态空间模型表述成随机微分方程。

尽管这是一个非常迷人的主题（Yuan and Ao 2012），但要完整剖析随机过程定义中的细微之处，超出了本书的范围。不过，至少有必要简要说明我们所说的随机微分方程是什么意思。简单地说，它就是在微分方程中加入一个随机项 ω：

$$\dot{x} = f(x) + \omega, \qquad \omega \sim \mathcal{N}(0, \tfrac{1}{2}\Gamma^{-1}). \tag{A.46}$$

这里随机项被选为正态分布，且均值为零，因此 x 变化率最可能的值就是 $f(x)$。式 (A.46) 的解释有时不太直观。消除歧义的最好方式，是把它看作一个离散化方案的极限情形：

$$\Delta x = f(x)\Delta\tau + \omega(\Delta\tau)^{1/2}, \qquad \Delta\tau \to 0 \Rightarrow \dot{x} = f(x) + \omega. \tag{A.47}$$

需要注意，如果 ω 的方差随 x 变化，那么我们可以采用多种不同离散化方式。最常见的选择对应于 Ito 解释和 Stratonovich 解释。不过，本书始终假设方差固定，因此这些解释会给出相同的结果。就像第 8 章中的生成模型那样，要定义这种模型，我们只需要描述 x 的变化率的概率分布。从式 (A.46) 立刻得到

$$p(\dot{x} \mid x) = \mathcal{N}(f(x), \tfrac{1}{2}\Gamma^{-1}). \tag{A.48}$$

这正是本书所用生成模型中的形式。它也概括了确定性动力系统与随机动力系统之间的区别：在确定性系统中，若知道 x 的值，就知道它的速度；在随机系统中，知道 x 只会告诉我们一个可能速度的分布。

A.5.2 非平衡稳态

在第 3 章中，我们看到：如果一个系统被定义为沿某个能量函数（或惊异函数）下降，那么它就会随时间维持其形式，并持续处于一个稳态，哪怕这个稳态并非平衡态。这里我们简要展开

这一点，从稳态的概念出发，再回到最小化惊异，也就是“自证”（Hohwy 2016）动力学。起点是把式 (A.46) 中的随机动力学改写为另一种形式：一个确定性的偏微分方程，用来描述概率密度如何随时间变化。这就是 Fokker–Planck 方程（Risken 1996）：

$$\partial_\tau p(x) = \nabla_x \cdot \big(\Gamma \nabla_x p(x) - f(x)p(x)\big). \tag{A.49}$$

Fokker–Planck 方程使我们可以直接通过令密度对时间的偏导为零来定义稳态：

$$\begin{aligned}
\partial_\tau p(x) &= 0 \\
\Rightarrow \quad \nabla_x \cdot \big(\Gamma \nabla_x p(x) - f(x)p(x)\big) &= 0 \\
\Rightarrow \quad f(x) &= -(\Gamma - Q(x))\nabla_x \mathcal{I}(x), \\
\nabla_x \cdot \big(Q(x)\nabla_x p(x)\big) &= 0, \qquad \mathcal{I}(x) \coloneqq -\ln p(x).
\end{aligned} \tag{A.50}$$

这里第三个等式[4] 是关键，因为它表明：凡是能够维持稳态的系统，其动力学平均而言都必须最小化它们的惊异 $\mathcal{I}$。Q 项允许系统沿着惊异的等值线运动，而这种运动既不会增加惊异，也不会减少惊异。这个表达支撑了主动推断中的自证视角，也是有感知系统物理学的核心。这里不再展开，感兴趣的读者可参阅 Friston (2019a) 获取更完整的后果分析。

A.5.3 运动的广义坐标

正如第 A.3.3 节所见，我们可以用时间上的泰勒展开系数来表示一段短轨迹。这在随机情形下会引出一个有趣问题：当我们用运动的广义坐标来表述一个连续时间模型时，怎样处理广义运动不同阶次之间的协方差？答案见于 Cox and Miller (1965)，这里作简要总结。一个随机过程在广义坐标中被表示为：伴随流的随机波动、该流变化率的随机波动，以及更高阶时间导数共同组成的向量：

$$\dot{\tilde{x}} = \tilde{f}(\tilde{x}) + \tilde{\omega}, \qquad \tilde{\omega} \coloneqq \begin{bmatrix} \omega \\ \omega' \\ \omega'' \\ \omega''' \\ \vdots \end{bmatrix} = \begin{bmatrix} \omega^{[0]} \\ \omega^{[1]} \\ \omega^{[2]} \\ \omega^{[3]} \\ \vdots \end{bmatrix}. \tag{A.51}$$

这些随机波动可以这样刻画：

$$p(\tilde{\omega}) = \mathcal{N}(0, \Pi), \qquad \mathbb{E}[\omega^{[0]}(\tau)] = 0, \qquad \mathbb{E}[\omega^{[0]}(\tau) \cdot \omega^{[0]}(\tau)] = \Sigma. \tag{A.52}$$

它们的自相关函数定义为

[4]原文此处有脚注，解释该重写依赖 Helmholtz 分解相关思想。

$$\rho(h) \coloneqq \Sigma^{-1}\mathbb{E}\big[\omega^{[0]}(\tau)\cdot\omega^{[0]}(\tau+h)\big]. \tag{A.53}$$

把式 (A.53) 两边乘以方差，可以看出：两个时刻噪声之间的协方差可以分解为自相关函数与方差的乘积。随机波动的第 i 阶导数定义为如下极限情形：

$$\omega^{[i]}(\tau,\Delta\tau) = \frac{\omega^{[i-1]}(\tau+\Delta\tau)-\omega^{[i-1]}(\tau)}{\Delta\tau}. \tag{A.54}$$

利用式 (A.52) 和式 (A.53)，可以写出一个变量与其一阶时间导数之间的协方差：

$$\begin{aligned}\mathbb{E}\big[\omega^{[1]}(\tau,\Delta\tau)\cdot\omega^{[0]}(\tau+h)\big] &= \frac{1}{\Delta\tau}\mathbb{E}\Big[\big(\omega^{[0]}(\tau+\Delta\tau)-\omega^{[0]}(\tau)\big)\omega^{[0]}(\tau+h)\Big]\\ &= \frac{1}{\Delta\tau}\Sigma\big(\rho(h-\Delta\tau)-\rho(h)\big).\end{aligned} \tag{A.55}$$

令时间变化趋于零，就得到

$$\mathbb{E}\big[\omega^{[1]}(\tau)\cdot\omega^{[0]}(\tau+h)\big] = \Sigma\dot{\rho}(h). \tag{A.56}$$

当 $h=0$ 时，这个协方差为零，因为瞬时速度与位置彼此正交，而此时自相关函数达到最大值，所以其时间导数为零。

再进一步，可以求出一阶导数自身的方差：

$$\begin{aligned}\mathbb{E}\big[\omega^{[1]}(\tau,\Delta\tau)\cdot\omega^{[1]}(\tau+h,\Delta\tau)\big] &= \frac{1}{\Delta\tau^2}\Sigma\mathbb{E}\Big[\big(\omega^{[0]}(\tau+\Delta\tau)-\omega^{[0]}(\tau)\big)\\ &\qquad\cdot\big(\omega^{[0]}(\tau+h+\Delta\tau)-\omega^{[0]}(\tau+h)\big)\Big]\\ &= \Sigma\frac{1}{\Delta\tau}\left[\frac{1}{\Delta\tau}\big(\rho(h)-\rho(h-\Delta\tau)\big)-\frac{1}{\Delta\tau}\big(\rho(h+\Delta\tau)-\rho(h)\big)\right].\end{aligned} \tag{A.57}$$

当 $\Delta\tau\to 0$ 时，上式变为

$$\mathbb{E}\big[\omega^{[1]}(\tau)\cdot\omega^{[1]}(\tau+h)\big] = -\Sigma\ddot{\rho}(h). \tag{A.58}$$

对更高阶导数重复这个过程，就能计算出广义精度矩阵的各个元素：

$$\Pi = \Sigma^{-1}\otimes\begin{bmatrix}1 & 0 & \ddot{\rho}(0) & \cdots\\ 0 & -\ddot{\rho}(0) & 0 & \cdots\\ \ddot{\rho}(0) & 0 & \rho^{(4)}(0) & \cdots\\ \vdots & \vdots & \vdots & \ddots\end{bmatrix}^{-1}. \tag{A.59}$$

如果把自相关函数选为高斯形式，那么有

$$\rho(h) = \exp\left(-\frac{1}{2}\lambda h^2\right), \qquad \rho(0) = 1. \tag{A.60}$$

附录 B　附录 B：主动推断的方程

B.1　引言

在本附录中，我们给出主动推断（Active Inference）的数学性概述。这一部分在正文各章公式的基础上补充其来源细节，并试图填补正文中省略的一些中间步骤。这里的内容直接建立在附录 A 的数学背景之上，讨论部分可观测马尔可夫决策过程（POMDP）与预测编码架构中的推断，并涉及正文中提到的结构学习与模型约简问题。我们的目标是让本附录尽量自洽，同时特别聚焦那些最容易引起混淆的主题。也请读者放心：即使不能完全理解本附录的所有内容，也并不妨碍对主动推断作出有用的应用；这一部分主要面向希望掌握更多技术细节的读者。

B.2　马尔可夫决策过程

B.2.1　状态推断

在求解一个 POMDP 问题时，我们的目标是选择合适的行动方案，即策略（policy）。在主动推断框架下，这被表述为一个推断问题：我们必须求得关于备选策略的后验概率分布。要计算后验概率，我们需要两样东西：其一是策略的先验概率（见第 §B.2.2 节），其二是在给定策略条件下观测的似然。本节专注于后者。

在给定策略时，观测似然并不容易直接计算。这是因为 POMDP 的结构决定了：策略（π）影响状态（s）的轨迹（记为 $\tilde{s}$），状态再影响结果（o），而策略本身并不直接影响结果。因此，问题需要对状态轨迹求和，将其边缘化，从而得到给定策略下观测的边缘似然：

$$P(\tilde{o} \mid \pi) = \sum_{\tilde{s}} P(\tilde{o} \mid \tilde{s}) P(\tilde{s} \mid \pi) \tag{B.1}$$

对于任何稍微复杂一些的状态空间，这个求和在计算上都可能极其困难。不过，正如第 2 章所示，我们可以用自由能泛函来近似这类边缘似然。第 2–4 章将自由能描述为两类对象的泛函：近似后验信念 Q 与生成模型 P。这使我们可以把某一给定策略的自由能写成：

$$F(\pi) = \mathbb{E}_{Q(\tilde{s}|\pi)}[\ln Q(\tilde{s} \mid \pi) - \ln P(\tilde{o}, \tilde{s} \mid \pi)] \geq -\ln P(\tilde{o} \mid \pi) \tag{B.2}$$

$$Q(\tilde{s} \mid \pi) = \arg\min_{Q} F(\pi) \;\Rightarrow\; F(\pi) \approx -\ln P(\tilde{o} \mid \pi) \tag{B.2 续}$$

式（B.2）说明了一件简单但重要的事。若要推断“应当做什么”，我们就必须近似策略的边缘似然；而为了得到这一边缘似然的良好近似，我们又必须优化该策略下关于状态的信念。简言之，要使规划得以进行，知觉推断是不可或缺的。那么，在实践中应如何解决这个问题？答案是诉诸第 A.4.2 节中概述的方法。通过为式（B.1）中的概率分布选取显式形式，我们可以得到一个简单的自由能表达式：

$$Q(\tilde{s} \mid \pi) = \prod_{\tau} Q(s_\tau \mid \pi), \qquad Q(s_\tau \mid \pi) = \mathrm{Cat}(s_\tau^\pi) \tag{B.1}$$

$$P(\tilde{o} \mid \tilde{s}) = \prod_{\tau} P(o_\tau \mid s_\tau), \qquad P(o_\tau \mid s_\tau) = \mathrm{Cat}(A) \tag{B.2}$$

$$P(\tilde{s} \mid \pi) = P(s_1) \prod_{\tau} P(s_{\tau+1} \mid s_\tau, \pi), \qquad P(s_{\tau+1} \mid s_\tau, \pi) = \mathrm{Cat}(B_\tau^\pi) \tag{B.3}$$

$$P(s_1) = \mathrm{Cat}(D) \tag{B.3}$$

简要来说，式（B.3）的第一行用均值场近似（见式 A.41）来定义关于状态的信念，并在时间上进行因子分解。每一个时间点都对应一个关于“若执行某策略，状态会是什么”的信念，它由向量 s_τ^π 给出，其元素就是各种备选状态的概率。第二行中的观测轨迹依赖于隐藏状态轨迹，其中矩阵 A（若状态还进一步因子化，则为张量）给出每个状态下观测分布。类似地，模型下的状态先验轨迹由该策略下的转移概率 B_τ^π 与初始状态概率 D 构成。把这些代回式（B.2）的自由能表达式，就得到策略条件下的自由能：

$$F_\pi = s_1^\pi \cdot (\ln s_1^\pi - \ln A\, o_1 - \ln D) + \sum_{\tau=2} s_\tau^\pi \cdot \left(\ln s_\tau^\pi - \ln A\, o_\tau - \ln B_{\tau-1}^\pi s_{\tau-1}^\pi\right) \tag{B.4}$$

注意，概率向量与另一个量的点积，等价于取期望操作；如果这里不够直观，可回看第 A.2.1 节。式（B.4）把结果当作概率向量处理，不过其形式是：在已观测结果所对应的位置上取值为 1，其余位置为 0（有时称为 one-hot 编码或 1-in-k 向量）。现在的挑战是，就我们关于状态的信念 s_τ^π 来最小化自由能，以保证自由能成为边缘似然的良好近似。我们当然也可以像第 A.4.2 节那样，对每一个信念因子逐个最小化并反复迭代直到收敛。然而，由于我们更关心生物学上更可信的方案，也可以构造一个收敛到同一解的动力系统。这种方法被称为梯度下降，因为我们沿着自由能梯度向下移动，直到到达最小值。

为了更新关于状态的信念，我们对当前状态信念求梯度。然后定义一个辅助变量 v，让它充当对数后验，并令其对自由能执行梯度下降。这个对数后验再经过 softmax 函数 σ，转化为归一化的概率分布。这样就能保证关于状态的信念以降低自由能的方式发生变化：

$$s_\tau^\pi = \sigma(v_\tau^\pi) \tag{B.4}$$

$$\dot{v}_\tau^\pi = -\nabla_{s_\tau^\pi} F_\pi \tag{B.5}$$

$$\nabla_{s_\tau^\pi} F_\pi = \ln s_\tau^\pi - \ln A\, o_\tau - \ln B_{\tau-1}^\pi s_{\tau-1}^\pi - \ln B_\tau^{\pi\dagger} s_{\tau+1}^\pi \tag{B.5}$$

式（B.5）与式 A.42 中给出的变分消息传递方案具有相同的解。它允许我们只利用局部可得的信息高效计算后验信念，在这里这些局部信息包括感觉数据、关于紧邻过去的信念，以及关于

紧邻未来的信念。不过值得注意的是，这里使用的均值场近似（即时间上的因子分解）往往会导致过度自信的后验。在实践中，这一问题可以通过一种称为边缘消息传递（marginal message passing）的修正方案来缓解（Friston, FitzGerald et al. 2017；Parr, Markovic et al. 2019）：

$$\dot{v}_\tau^\pi = \epsilon_\tau^\pi \tag{B.6}$$

$$\epsilon_\tau^\pi = \ln A\, o_\tau + \frac{1}{2}\ln\big(B_{\tau-1}^\pi s_{\tau-1}^\pi\big) + \frac{1}{2}\ln\Big(B_\tau^{\pi\dagger} s_{\tau+1}^\pi\Big) - \ln s_\tau^\pi \tag{B.6}$$

$$B_\tau^\dagger \propto B_\tau^T \tag{B.6 续}$$

这种形式会导向更保守的推断，即把更多不确定性归属于后验信念。其他替代方案也曾被探索过，包括 Bethe 近似（Schwöbel et al. 2018）。不过，在本书写作时，主动推断中最广泛使用的实现仍然是边缘消息传递。

B.2.2 作为推断的规划

上一节处理的是：在给定某个策略的条件下，对状态进行推断，并最小化以该策略为条件的自由能。这个自由能在这里扮演负对数边缘似然（即模型证据）的角色，其中每个策略都被视为一个模型。如果再为“哪个策略最可能”配上先验与后验信念，我们就可以把自由能写成关于策略信念的泛函：

$$F = \mathbb{E}_{Q(\pi)}[\ln Q(\pi) - \ln P(\pi, \tilde{o})] \tag{B.7}$$

$$\approx \mathbb{E}_{Q(\pi)}[\ln Q(\pi) + F(\pi) - \ln P(\pi)] \tag{B.8}$$

$$P(\pi) = \mathrm{Cat}(\pi_0) \tag{B.9}$$

$$Q(\pi) = \mathrm{Cat}(\pi) \tag{B.10}$$

$$\pi_0 = \sigma(\ln E - G) \tag{B.7}$$

第二行中的近似号来自式（B.2）。这里，E 是一个关于策略的固定信念向量（可以理解为偏置项或习惯项），而 G 是每个策略的期望自由能。与前面一样，我们现在可以把自由能写成充分统计量的形式：

$$F = \pi \cdot (\ln \pi - \ln E + F + G) \tag{B.8}$$

这里，F 是一个向量，其各元素都是式（B.4）中定义的 F_π。对其取梯度后，就得到关于策略信念的最优更新规则，也就是规划：

$$\nabla_\pi F = 0 \;\Leftrightarrow\; \pi = \sigma(\ln E - F - G) \tag{B.9}$$

B.2.3 学习

为了使学习成为可能，我们需要把关于那些构成生成模型的概率分布参数的先验信念纳入进来。由于这些分布都被表述为分类分布，因此适合的共轭先验是狄利克雷分布。以初始状态的先验为例，自由能中依赖于期望对数先验的项包括：

$$F = \ldots + D_{KL}[Q(D) \,\|\, P(D)] - \mathbb{E}_{Q(s_1)Q(D)}[\ln P(s_1 \mid D)] \tag{B.11}$$

$$= \ldots + (d - \boldsymbol{d}) \cdot \mathbb{E}_{Q(D)}[\ln D] - s_1 \cdot \mathbb{E}_{Q(D)}[\ln D] \tag{B.12}$$

$$\mathbb{E}_{Q(D)}[\ln D] = \psi(d) - \psi(d_0), \qquad d_0 = \sum_i d_i \tag{B.13}$$

$$Q(D) \sim \mathrm{Dir}(d), \qquad P(D) \sim \mathrm{Dir}(\boldsymbol{d}) \tag{B.10}$$

式（B.10）的第三个等式强调了一个很有用的恒等式：一个服从狄利克雷分布的变量，其对数的期望等于两个 digamma 函数 ψ 的差，而 digamma 函数又是 gamma 函数的导数。利用式（B.10），我们可以找到自由能的极小值：

$$\nabla_{\mathbb{E}[\ln D]} F = d - \boldsymbol{d} - s_1 = 0 \;\Leftrightarrow\; d = \boldsymbol{d} + s_1 \tag{B.11}$$

这给出了一个简单的更新方案，可用于把先验的狄利克雷参数更新为其后验值。对于生成模型中的其他概率分布，也可以写出非常类似的更新规则：

$$a = \boldsymbol{a} + \sum_\tau o_\tau \otimes s_\tau \tag{B.14}$$

$$b^\pi = \boldsymbol{b}^\pi + \sum_\tau s_\tau^\pi \otimes s_{\tau-1}^\pi \tag{B.15}$$

$$c = \boldsymbol{c} + \sum_\tau o_\tau \tag{B.16}$$

$$d = \boldsymbol{d} + s_1 \tag{B.17}$$

$$e = \boldsymbol{e} + \pi \tag{B.12}$$

这些式子的含义非常直接：只要某个概率分布项所预测的事情真的发生了（对于条件概率，这可能是两个对象的组合），我们就把概率数组中对应的那个元素增加一些，从而表示它在未来再次发生的可能性更高。

B.2.4 精度

在某些设定中，以稍有不同的方式参数化生成模型会更方便。这里的一种做法是使用 Gibbs 测度，也就是给概率分布配上一个逆温度参数，让它充当精度。最常见的做法，是对策略上的精度 γ 这样处理：

$$P(\pi \mid \gamma) = \mathrm{Cat}(\pi_0) \tag{B.18}$$

$$\pi_0 = \sigma(-\gamma G) \tag{B.13}$$

为了简化表述，本节省略向量 E。下面我们还将考虑观测似然的精度 ζ，以及状态转移的精度 ω。这些精度参数的先验分布都假定为 gamma 分布：

$$P(\zeta) \propto \beta_\zeta \exp(-\beta_\zeta \zeta) \tag{B.19}$$

$$P(\omega) \propto \beta_\omega \exp(-\beta_\omega \omega) \tag{B.20}$$

$$P(\gamma) \propto \beta_\gamma \exp(-\beta_\gamma \gamma) \tag{B.14}$$

近似后验分布具有同样的形式，也就是仍然是 gamma 分布。为区分后验与先验的充分统计量，下文用粗体的 $\boldsymbol{\beta}$ 表示超参数。采用这种参数化方式的 gamma 分布有一个很有用的性质：

$$\zeta = \mathbb{E}_{Q(\zeta)}[\zeta] = \beta_\zeta^{-1} \tag{B.21}$$

$$\omega = \mathbb{E}_{Q(\omega)}[\omega] = \beta_\omega^{-1} \tag{B.22}$$

$$\gamma = \mathbb{E}_{Q(\gamma)}[\gamma] = \beta_\gamma^{-1} \tag{B.15}$$

定义好这些分布之后，我们可以把变分自由能写为：

$$F = \mathbb{E}_Q[F(\pi,\zeta,\omega) + D_{KL}[Q(\pi) \,\|\, P(\pi \mid \gamma)]] + D_{KL}[Q(\gamma) \,\|\, P(\gamma)] + D_{KL}[Q(\omega) \,\|\, P(\omega)] + D_{KL}[Q(\zeta) \,\|\, P(\zeta)] \tag{B.16}$$

把它改写成充分统计量的形式（省略常数项），得到：

$$F = \pi \cdot \big(F + \ln \pi + \gamma G + \ln Z(\gamma)\big) + \ln \beta_\gamma + \ln \beta_\omega + \ln \beta_\zeta - \ln \boldsymbol{\beta}_\gamma - \ln \boldsymbol{\beta}_\omega - \ln \boldsymbol{\beta}_\zeta + \gamma \boldsymbol{\beta}_\gamma + \omega \boldsymbol{\beta}_\omega + \zeta \boldsymbol{\beta}_\zeta \tag{B.17}$$

$$F_\pi \approx -\sum_\tau s_\tau^\pi \cdot \big(\zeta \ln A\, o_\tau + \omega \ln B^\pi s_{\tau-1}^\pi - \ln Z(\zeta)\, o_\tau - \ln Z(\omega)\, s_{\tau-1}^\pi\big) \tag{B.17 续}$$

在式（B.17）中，Z 表示配分函数，也就是归一化常数：

$$Z(\zeta)_j = \sum_i (A_{ij})^\zeta \tag{B.23}$$

$$Z(\omega)_j = \sum_i (B_{ij}^\pi)^\omega \tag{B.24}$$

$$Z(\gamma) = \sum_\pi \exp(-\gamma G_\pi) \tag{B.25}$$

$$\partial_\zeta \ln Z(\zeta)\, s_\tau = o_\tau^\zeta \cdot \ln A \tag{B.26}$$

$$\partial_\omega \ln Z(\omega)\, s_{\tau-1}^\pi = s_\tau^{\pi\omega} \cdot \ln B^\pi \tag{B.27}$$

$$\partial_\gamma \ln Z(\gamma) = -\pi_0 \cdot G \tag{B.28}$$

$$o_\tau^\zeta \triangleq \sigma(\zeta \ln A) s_\tau \tag{B.29}$$

$$s_\tau^{\pi\omega} \triangleq \sigma(\omega \ln B_\tau^\pi) s_{\tau-1}^\pi \tag{B.30}$$

$$\pi_0 \triangleq \sigma(-\gamma G) \tag{B.18}$$

对期望精度取偏导之后，可以得到：

$$\partial_\zeta F = 0 \;\Leftrightarrow\; \beta_\zeta = \sum_\tau (o_\tau^\zeta - o_\tau) \cdot \ln A + \boldsymbol{\beta}_\zeta \tag{B.19a}$$

$$\partial_\omega F = 0 \;\Leftrightarrow\; \beta_\omega = \sum_\tau (s_\tau^{\pi\omega} - s_\tau^\pi) \cdot \ln B^\pi s_{\tau-1}^\pi + \boldsymbol{\beta}_\omega \tag{B.19b}$$

$$\partial_\gamma F = 0 \;\Leftrightarrow\; \beta_\gamma = (\pi - \pi_0) \cdot G + \boldsymbol{\beta}_\gamma \tag{B.19c}$$

如果把这些更新写成更符合生物学可实现性的梯度下降形式，就得到：

$$\dot{\beta}_\zeta = \sum_\tau (o_\tau - o_\tau^\zeta) \cdot \ln A + \boldsymbol{\beta}_\zeta - \beta_\zeta \tag{B.20a}$$

$$\dot{\beta}_\omega = \sum_\tau (s_\tau^\pi - s_\tau^{\pi\omega}) \cdot \ln B^\pi s_{\tau-1}^\pi + \boldsymbol{\beta}_\omega - \beta_\omega \tag{B.20b}$$

$$\dot{\beta}_\gamma = (\pi - \pi_0) \cdot G + \boldsymbol{\beta}_\gamma - \beta_\gamma \tag{B.20c}$$

注意，这里的维度意味着：对于 A，精度实际上是一个行向量，也就是说，A 的每一个状态列都对应其自身的精度参数。

B.2.5 期望自由能

正文已经相当详细地讨论了期望自由能。本节在此基础上补充两点。第一，我们简要概述目前为什么认为这正是用来定义策略先验信念的适当量。第二，我们补充这一量在实现层面的计算细节。

虽然数值模拟（如第 7 章所示）已经表明期望自由能很有用，但“它为什么有用”这个问题本身仍是一个活跃的研究主题。考虑到这一讨论未来仍可能继续演化，这里我们给出写作当下最简约的一种解释摘要（Da Costa et al. 2020；Friston, Da Costa et al. 2020）。起点是先规定：一个系统会达到某种稳态（见第 A.5.2 节），或者说，它会在未来某个时刻 τ 满足其偏好（这些偏好是在潜在状态层面上定义的）：

$$Q(s_\tau) = \mathbb{E}_{Q(\pi)}[Q(s_\tau \mid \pi)] = P(s_\tau \mid C) \tag{B.21}$$

我们的任务是找到满足式（B.21）的 $Q(\pi)$。为此，先注意到式（B.21）蕴含：

$$D_{KL}[Q(\pi \mid s_\tau)Q(s_\tau) \,\|\, Q(\pi \mid s_\tau)P(s_\tau \mid C)] = 0 \tag{B.22}$$

$$\Rightarrow\; \mathbb{E}_{Q(\pi,s_\tau)}[\ln Q(\pi, s_\tau)] = \mathbb{E}_{Q(\pi,s_\tau)}[\ln Q(\pi \mid s_\tau) + \ln P(s_\tau \mid C)] \tag{B.22 续}$$

接下来，我们对左侧进行因子分解，以便把我们真正关心的 $Q(\pi)$ 项隔离出来：

$$\mathbb{E}_{Q(\pi)}[\ln Q(\pi)] = \mathbb{E}_{Q(\pi,s_\tau)}[\ln Q(\pi \mid s_\tau) + \ln P(s_\tau \mid C) - \ln Q(s_\tau \mid \pi)] \tag{B.23}$$

再定义一个变量 α，用来表示两个熵的比值：

$$\alpha = \frac{\mathbb{E}_{Q(s_\tau)}[H(Q(\pi \mid s_\tau))]}{\mathbb{E}_{Q(s_\tau,\pi)}[H(P(o_\tau \mid s_\tau))]} \tag{B.24}$$

从直观上说，α 表达的是：在给定某个状态时，可能出现的行为输出范围（即策略）与该状态下预期结果范围之间的相对大小。如果它非常大，这可能描述的是一种生物：它的行为与其所处

世界的状态几乎没有关系，尽管该世界又能产生非常精确的感觉观测。如果它非常小，这可能描述的是另一种生物：一旦它知道世界处于什么状态，它几乎总是以同样的方式行动，但它又很少能从世界中获得精确数据。这里我们规定，我们关心的是满足 $\alpha = 1$ 的系统，也就是与其世界进行相对平衡、相对对称交换的系统。这样一来，式（B.24）中的两个熵就相等。回到式(B.23)：

$$\mathbb{E}_{Q(\pi)}[\ln Q(\pi)] = -\mathbb{E}_{Q(s_\tau)}[H(Q(\pi \mid s_\tau))] + \mathbb{E}_{Q(\pi,s_\tau)}[\ln P(s_\tau \mid C) - \ln Q(s_\tau \mid \pi)] \tag{B.25}$$

$$= -\mathbb{E}_{Q(s_\tau,\pi)}[H(P(o_\tau \mid s_\tau))] - \mathbb{E}_{Q(\pi)}[D_{KL}(Q(s_\tau \mid \pi) \,\|\, P(s_\tau \mid C))] \tag{B.25 续}$$

现在我们转向计算实现的问题。在这里，我们可以直接诉诸 A.2 节中看到的线性代数恒等式。若将偏好表示为先验概率向量 C，则期望自由能中的务实项可以写为

$$\mathbb{E}_{Q(o_\tau|\pi)}\big[\ln P(o_\tau \mid C)\big] = o_\tau^\pi \cdot \ln C_\tau, \qquad Q(o_\tau \mid \pi) = \mathrm{Cat}(o_\tau^\pi), \qquad o_\tau^\pi = A s_\tau^\pi. \tag{B.28}$$

与隐藏状态相关的期望信息增益（即显著性、认知价值或贝叶斯惊奇）可以表示为两个熵之差：

$$H[Q(o_\tau \mid \pi)] - \mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] = -\, o_\tau^\pi \cdot \ln o_\tau^\pi - H \cdot s_\tau^\pi, \tag{B.29}$$

$$H \equiv -\operatorname{diag}(A \cdot \ln A).$$

最后一行的说明见 A.2.3 节。将式 B.28 与 B.29 合并，便得到期望自由能：

$$G_\pi = \sum_\tau G_{\pi\tau}, \qquad G_{\pi\tau} = H \cdot s_\tau^\pi + o_\tau^\pi \cdot \big(\ln o_\tau^\pi - \ln C_\tau\big). \tag{B.30}$$

当我们需要考虑主动学习时，还要补充参数信息增益。与生成模型参数相关的信息增益（即新奇性）可如下推导。利用两个狄利克雷分布之间的 KL 散度，我们可以写出在给定状态--结果组合之后将发生的信息增益：

$$\begin{aligned} W_{ij} &\equiv D_{\mathrm{KL}}[P(A_{ij} \mid o = i, s = j) \,\|\, P(A_{ij})] \\ &= \ln\Gamma(a_{ij}) - \ln\Gamma(a_{ij}+1) + \ln\Gamma(a_{0j}+1) - \ln\Gamma(a_{0j}) \\ &\quad - \ln a_{ij} + \ln a_{0j} + \psi(a_{ij}+1) - \psi(a_{0j}+1), \qquad a_{0j} \equiv \sum_i a_{ij}. \end{aligned} \tag{B.31}$$

这里我们利用了这样一个事实：如果我们知道某个特定的状态--结果组合已经发生，那么就会将对应的狄利克雷参数加 1。这使我们能够利用对数伽马函数的标准恒等式（原文以下划线标出）来化简表达式：

$$\begin{aligned} W_{ij} &= \ln\frac{a_{0j}}{a_{ij}} + \frac{\partial_{a_{ij}}\Gamma(a_{ij}+1)}{\Gamma(a_{ij})} - \frac{\partial_{a_{0j}}\Gamma(a_{0j}+1)}{\Gamma(a_{0j})} \\ &= \ln\frac{a_{0j}}{a_{ij}} + \frac{1}{a_{ij}}\frac{\partial_{a_{ij}}\Gamma(a_{ij})}{\Gamma(a_{ij})} - \frac{1}{a_{0j}}\frac{\partial_{a_{0j}}\Gamma(a_{0j})}{\Gamma(a_{0j})}. \end{aligned} \tag{B.32}$$

这里用到了恒等式 $x\Gamma(x) = \Gamma(x+1)$ 以及一次乘积法则。接着再利用恒等式 $\psi(x)\Gamma(x) = \partial_x\Gamma(x)$，并采用近似 $\psi(x) \approx \ln x - (2x)^{-1}$，可进一步化简为

$$\begin{aligned} W_{ij} &= -\frac{1}{a_{ij}} + \frac{1}{a_{0j}} + \ln\frac{a_{0j}}{a_{ij}} + \psi(a_{ij}) - \psi(a_{0j}) \\ &\approx -\frac{1}{2a_{ij}} + \frac{1}{2a_{0j}}. \end{aligned} \tag{B.33}$$

于是，期望信息增益为

$$\mathbb{E}_{Q(o_\tau,s_\tau|\pi)}[D_{\mathrm{KL}}(P(A \mid o_\tau, s_\tau) \,\|\, P(A))] \approx o_\tau^\pi \cdot W s_\tau^\pi. \tag{B.34}$$

这个简单的表达式会进一步补充期望自由能，从而使系统除了追求务实和显著的选择之外，也表现出寻求新奇的行为。

B.2.6 贝叶斯模型约简

在第 7 章中，我们曾简要提到结构学习与模型约简的思想。这里我们借机更深入地展开这些原理。贝叶斯模型约简是一种用于比较不同模型的技术，这些模型之间唯一的差别仅在于其先验。根据贝叶斯定理（见第 2 章），我们可以用两种不同方式表示两个候选模型之间，数据 y 与参数 θ 的联合概率之比：

$$\frac{P(y,\theta)}{\tilde{P}(y,\theta)} = \frac{P(y \mid \theta)P(\theta)}{\tilde{P}(y \mid \theta)\tilde{P}(\theta)} = \frac{P(\theta \mid y)P(y)}{\tilde{P}(\theta \mid y)\tilde{P}(y)}. \tag{B.35}$$

如果两个模型之间唯一的差别是先验，也就是说 $P(y \mid \theta) = \tilde{P}(y \mid \theta)$，那么似然项就可以相互抵消。重新整理后，就得到这样一个表达式：在备择（约简）先验下的后验概率，可以通过原始（完整）先验下的后验概率来表示：

$$\tilde{P}(\theta \mid y) = P(\theta \mid y)\,\frac{P(y)}{\tilde{P}(y)}\,\frac{\tilde{P}(\theta)}{P(\theta)}. \tag{B.36}$$

对参数两边同时积分，可得

$$\begin{aligned} 1 &= \frac{P(y)}{\tilde{P}(y)}\,\mathbb{E}_{P(\theta|y)}\left[\frac{\tilde{P}(\theta)}{P(\theta)}\right], \\ \ln \tilde{P}(y) &= \ln P(y) + \ln \mathbb{E}_{P(\theta|y)}\left[\frac{\tilde{P}(\theta)}{P(\theta)}\right]. \end{aligned} \tag{B.37}$$

再将其代回式 B.36，得到

$$\ln \tilde{P}(\theta \mid y) = \ln P(\theta \mid y) + \ln \tilde{P}(\theta) - \ln P(\theta) - \ln \mathbb{E}_{P(\theta|y)}\left[\frac{\tilde{P}(\theta)}{P(\theta)}\right]. \tag{B.38}$$

式 B.37 与 B.38 合起来意味着：借助对完整模型进行反演所得到的结果，我们就能够求出如果当初采用某个约简先验，本会得到的模型证据与后验。我们还可以用第 4 章引入的变分量来重写这些公式：

$$\begin{aligned} F[\tilde{P}(\theta)] - F[P(\theta)] &= \ln \mathbb{E}_{Q(\theta)}\left[\frac{\tilde{P}(\theta)}{P(\theta)}\right], \\ \ln \tilde{Q}(\theta) &= \ln Q(\theta) + \ln \tilde{P}(\theta) - \ln P(\theta) - \ln \mathbb{E}_{Q(\theta)}\left[\frac{\tilde{P}(\theta)}{P(\theta)}\right]. \end{aligned} \tag{B.39}$$

作为参考，我们给出式 B.39 在两类不同先验下的形式。第一类是正态分布：[1]

$$
\begin{aligned}
P(\theta) &= \mathcal{N}(\eta, \Sigma), & \tilde{P}(\theta) &= \mathcal{N}(\tilde{\eta}, \tilde{\Sigma}), \\
Q(\theta) &= \mathcal{N}(\mu, C), & \tilde{Q}(\theta) &= \mathcal{N}(\tilde{\mu}, \tilde{C}), \\
\tilde{C}^{-1} &= P + \tilde{\Pi} - \Pi, \\
\tilde{\mu} &= \tilde{C}\big(P\mu + \tilde{\Pi}\tilde{\eta} - \Pi\eta\big), \\
\Delta F &= -\frac{1}{2}\left(\ln|\tilde{\Pi}\, P\, \tilde{C}\, \Sigma| + \mu^\top P\mu + \tilde{\eta}^\top \tilde{\Pi}\tilde{\eta} - \eta^\top \Pi\eta - \tilde{\mu}^\top P\tilde{\mu}\right).
\end{aligned} \tag{B.40}
$$

在实践中，这通常用于混合模型的情形，即模型同时包含连续部分和类别部分。如果后者的每个类别结果都对应一个连续先验，那么我们就可以高效地评估这些先验（从而也就是这些类别结果）的证据，而不必逐个反演每一个模型。第 8 章给出了一个例子。

更常见的是，在纯粹的 POMDP 设定中，我们可能关心的是比较关于狄利克雷先验分布的不同假设。这种方法曾被用来模拟概率矩阵元素的修剪，并把它作为睡眠期间突触修剪的隐喻（Friston, Lin 等，2017）。对于狄利克雷分布，贝叶斯模型约简的形式如下：

$$
\begin{aligned}
P(\theta) &= \mathrm{Dir}(a), & \tilde{P}(\theta) &= \mathrm{Dir}(\tilde{a}), \\
Q(\theta) &= \mathrm{Dir}(\mathbf{a}), & \tilde{Q}(\theta) &= \mathrm{Dir}(\tilde{\mathbf{a}}), \\
\tilde{\mathbf{a}} &= \mathbf{a} + \tilde{a} - a, \\
\Delta F &= \ln B(a) - \ln B(\mathbf{a}) + \ln B(\tilde{\mathbf{a}}) - \ln B(\tilde{a}).
\end{aligned} \tag{B.41}
$$

在这个表达式中，B 表示 Beta 函数。类似的结果还可以为多种分布推导出来（见 Friston、Parr 与 Zeidman，2018），但在主动推断中，最常见的仍然是正态先验与狄利克雷先验。

B.3 （主动）广义滤波

现在我们从 POMDP 模型下的离散推断转向连续域。这时，附录 A 中的一些预备知识就真正开始发挥作用了。我们将使用拉普拉斯近似与运动的广义坐标，这两者都在 A.3 节中介绍过。此外，我们还需要像 A.5.2 节那样，构造包含不同阶广义运动的精度矩阵。根据式 A.33 与 A.34，在拉普拉斯近似下，自由能可写为

$$
\begin{aligned}
F[q, y] &\approx -\frac{1}{2}\ln\big|(2\pi)^k \tilde{\Sigma}\big| - \ln p(y, \tilde{\mu}), \\
q(\tilde{x}) &= \mathcal{N}(\tilde{\mu}, \tilde{\Sigma}), \\
\tilde{\Sigma}^{-1} &= -\nabla_{\tilde{x}\tilde{x}} \ln p(y, \tilde{x})\Big|_{\tilde{x}=\tilde{\mu}}.
\end{aligned} \tag{B.42}
$$

这里我们是在广义坐标下，为一个模型写出拉普拉斯假设下的自由能。在拉普拉斯假设下，第一行中唯一会随 μ 变化的，就是最后一项；这一项表达的是生成模型。下一步就是明确生成模

[1] 原文此处为脚注编号 3。

型的形式：

$$
\begin{aligned}
p(y,\tilde{x},\tilde{v}) &= p(\tilde{y}\mid\tilde{x},\tilde{v})\,p(\tilde{x}\mid\tilde{v})\,p(\tilde{v}),\\
p(\tilde{y}\mid\tilde{x},\tilde{v}) &= \mathcal{N}\big(g(\tilde{x},\tilde{v}),\tilde{\Pi}_y^{-1}\big),\\
p(\tilde{x}\mid\tilde{v}) &= \mathcal{N}\big(D\tilde{x}\mid f(\tilde{x},\tilde{v}),\tilde{\Pi}_x^{-1}\big),\\
p(\tilde{v}) &= \mathcal{N}\big(\tilde{\eta},\tilde{\Pi}_v^{-1}\big),\\
D\tilde{x} &= f(\tilde{x},\tilde{v})+\tilde{\omega}_x,\\
\tilde{y} &= g(\tilde{x},\tilde{v})+\tilde{\omega}_y.
\end{aligned}
\tag{B.43}
$$

注意，这里现在有两个隐藏变量，x 和 v。两者的区别在于：前者依赖于一个运动方程 f，而后者依赖于一个静态先验。倒数第二行中的算子 D 是一个在主对角线上方为 1 的矩阵。在广义坐标中，这等价于取时间导数，因为时间导数向量中的每个分量都会向上移一位。广义精度矩阵的构造方式与 A.5.3 节相同。将式 B.43 中的量代入 B.42，可得

$$
\begin{aligned}
F[q,y] &= \frac{1}{2}\tilde{\varepsilon}_y^\top\tilde{\Pi}_y\tilde{\varepsilon}_y+\frac{1}{2}\tilde{\varepsilon}_x^\top\tilde{\Pi}_x\tilde{\varepsilon}_x+\frac{1}{2}\tilde{\varepsilon}_v^\top\tilde{\Pi}_v\tilde{\varepsilon}_v,\\
\tilde{\varepsilon}_y &\equiv \tilde{y}-g(\tilde{\mu}_x,\tilde{\mu}_v),\\
\tilde{\varepsilon}_x &\equiv D\tilde{\mu}_x-f(\tilde{\mu}_x,\tilde{\mu}_v),\\
\tilde{\varepsilon}_v &\equiv \tilde{\mu}_v-\tilde{\eta}.
\end{aligned}
\tag{B.44}
$$

这里我们省略了所有相对于 μ 的常数项。由式 B.44，我们可以求出自由能的梯度（使用 A.2.2 节中引入的恒等式）：

$$
\begin{aligned}
\nabla_{\tilde{\mu}_x}F[q,y] &= -\nabla_{\tilde{\mu}_x}g^\top\tilde{\Pi}_y\tilde{\varepsilon}_y+D^\top\tilde{\Pi}_x\tilde{\varepsilon}_x-\nabla_{\tilde{\mu}_x}f^\top\tilde{\Pi}_x\tilde{\varepsilon}_x,\\
\nabla_{\tilde{\mu}_v}F[q,y] &= -\nabla_{\tilde{\mu}_v}g^\top\tilde{\Pi}_y\tilde{\varepsilon}_y-\nabla_{\tilde{\mu}_v}f^\top\tilde{\Pi}_x\tilde{\varepsilon}_x+\tilde{\Pi}_v\tilde{\varepsilon}_v.
\end{aligned}
\tag{B.45}
$$

现在我们本可以指定一个梯度下降过程，去寻找使自由能最小的 μ。但是，这会意味着当自由能被最小时，μ 会变成静态。显然，如果我们相信更高阶的运动项并不为零，这样做并不理想。为了解决这一点，我们可以在一个移动的参考系中表达梯度下降，使得当自由能最小时，μ 仍继续以速度 μ' 运动：

$$
\begin{aligned}
\dot{\tilde{\mu}}_x-D\tilde{\mu}_x &= \nabla_{\tilde{\mu}_x}g^\top\tilde{\Pi}_y\tilde{\varepsilon}_y-D^\top\tilde{\Pi}_x\tilde{\varepsilon}_x+\nabla_{\tilde{\mu}_x}f^\top\tilde{\Pi}_x\tilde{\varepsilon}_x,\\
\dot{\tilde{\mu}}_v-D\tilde{\mu}_v &= \nabla_{\tilde{\mu}_v}g^\top\tilde{\Pi}_y\tilde{\varepsilon}_y+\nabla_{\tilde{\mu}_v}f^\top\tilde{\Pi}_x\tilde{\varepsilon}_x-\tilde{\Pi}_v\tilde{\varepsilon}_v.
\end{aligned}
\tag{B.46}
$$

式 B.46 指定了一种预测编码方案：预测误差驱动对期望的更新，而这些更新又会消解相应的误差。这类方案还可以通过复制 B.46 的方程并引入额外的层级来扩展到多层层级结构，只需将该额外层中的 y 替换为来自更低层的 v：

$$
\begin{aligned}
\dot{\tilde{\mu}}_x^{(i)}-D\tilde{\mu}_x^{(i)} &= \nabla_{\tilde{\mu}_x^{(i)}}g^{(i)\top}\tilde{\Pi}_v^{(i-1)}\tilde{\varepsilon}_v^{(i-1)}-D^\top\tilde{\Pi}_x^{(i)}\tilde{\varepsilon}_x^{(i)}+\nabla_{\tilde{\mu}_x^{(i)}}f^{(i)\top}\tilde{\Pi}_x^{(i)}\tilde{\varepsilon}_x^{(i)},\\
\dot{\tilde{\mu}}_v^{(i)}-D\tilde{\mu}_v^{(i)} &= \nabla_{\tilde{\mu}_v^{(i)}}g^{(i)\top}\tilde{\Pi}_v^{(i-1)}\tilde{\varepsilon}_v^{(i-1)}+\nabla_{\tilde{\mu}_v^{(i)}}f^{(i)\top}\tilde{\Pi}_x^{(i)}\tilde{\varepsilon}_x^{(i)}+\tilde{\Pi}_v^{(i)}\tilde{\varepsilon}_v^{(i)},\\
\tilde{\varepsilon}_v^{(i)} &\equiv \tilde{\mu}_v^{(i)}-g^{(i+1)}\big(\tilde{\mu}_x^{(i+1)},\tilde{\mu}_v^{(i+1)}\big),\\
\tilde{\varepsilon}_x^{(i)} &\equiv D\tilde{\mu}_x^{(i)}-f^{(i)}\big(\tilde{\mu}_x^{(i)},\tilde{\mu}_v^{(i)}\big).
\end{aligned}
\tag{B.47}
$$

在主动推断下，自由能不仅通过知觉最小化，也通过行动最小化。由于行动唯一改变的是感觉输入 y，所以式 B.44 中大多数项对于行动而言都不相关。对行动求自由能最小化可得

$$\dot{u} = -\nabla_u \tilde{y}(u)^\top \tilde{\Pi}_y \tilde{\varepsilon}_y. \tag{B.48}$$

式 B.47 与 B.48 合起来，为连续状态空间模型中的主动推断提供了一个非常一般的描述。至于学习或混合模型的问题，本节不再展开，因为它们已分别在专栏 8.2 和 8.3 中作了总结。

附录 C　附录 C：Matlab 代码注释示例

C.1　引言

本附录给出一个带注释的 Matlab 代码示例，展示如何借助 SPM12 中提供的标准反演与绘图例程来指定并求解一个生成模型。这里复现的是第 7 章中的 T 迷宫觅食示例。单独阅读这一附录可能会略显枯燥，但如果读者尝试在 Matlab 中亲自实现并运行这段代码，它会非常有帮助，因为只有这样，主动推断的机械过程才会真正变得直观。我们建议读者通过修改不同参数值、甚至有意“破坏”这个 demo 来加深理解。

C.2　预备

我们假定读者对 Matlab 已有基本熟悉，并已经成功从 https://www.fil.ion.ucl.ac.uk/spm/ 下载了 SPM12 软件包。第一步，是确保包含 SPM12 函数的文件夹已经加入 Matlab 的搜索路径。随后，我们打开一个 Matlab 脚本，先定义一个函数并为其命名（这里命名为 `demo_AI_book`）：

```
function demo_AI_book
rng default
```

图 C.1

图 C.1 中第二行的作用，是把随机数生成器设置为默认初始种子，从而保证每次调用该函数时生成同一组随机数。我们通常会在 demo 中这样做，以确保结果可复现。不过，如果我们想多次运行该函数，以计算跨多次试次行为的汇总统计量，也可以省略这一步。一般来说，最好在这里附上一些说明脚本用途的注释；但由于本附录本身就是对该脚本的逐段注释，这里便不再重复。

接下来，我们定义稍后会用到的一些重要常数。把这些量集中写在一起的好处是，后面如果想扰动它们、测试模型敏感性，就能很容易找到。这里我们定义两个将扮演概率角色的参数，它们在 C.3 节中会变得清晰起来：

```
a = .98;
b = 1 - a;
```

图 C.2

这样的定义保证了 $a + b = 1$。此时，我们就可以开始设置构成生成模型的 A、B、C、D 矩阵

与向量。在这个简单仿真中，我们假定这些参数在生成模型与生成过程里是相同的。

C.3 似然

这里我们的重点，是说明如何在 Matlab 里形式化一个似然矩阵，因此不会花太多篇幅去重复描述该生成模型及其对应范式本身；相关背景可参见第 7.2 节。我们的目标，是把图 7.4 与图 7.5 中给出的似然矩阵，翻译成反演例程能够理解的语法。我们从 A_1 开始，它在 Matlab 中写作 `A{1}`，其中花括号里的项对应上标，也就是结果模态。矩阵（更严格地说是张量）的元素可以用三个索引访问，分别对应结果、第一个隐藏状态因子（位置）以及第二个隐藏状态因子（上下文）。吸引性刺激位于右侧的上下文，可在第三个位置上用索引 1 指定；而当其位于左侧时，则用该位置上的索引 2 指定：

```
A{1} (:, :, 1) = [...
1 0 0 0; % start
0 0 0 0; % left cue
0 1 0 0; % right cue
0 0 1 0 % left
0 0 0 1]; % right
A{1} (:, :, 2) = [...
1 0 0 0; % start
0 1 0 0; % left cue
0 0 0 0; % right cue
0 0 1 0 % left
0 0 0 1]; % right
```

图 C.3

行表示结果，列表示第一个隐藏状态因子的不同可能水平。将其与图 7.4 和图 7.5 中展示的矩阵对照，有助于理解这种语法。A_2 矩阵也以类似方式为上下文加以定义。这里，我们使用脚本顶部在图 C.4 中定义的 a 和 b：

```
A{2} (:, :, 1) = [...
1 1 0 0; % reward neutral
0 0 a b; % reward positive
0 0 b a]; % reward negative
A{2} (:, :, 2) = [...
1 1 0 0; % reward neutral
0 0 b a; % reward positive
0 0 a b]; % reward negative
```

图 C.4

至此，我们完成了对 A 的设定。对于两个模态中的每一种结果组合（以上标或花括号区分，对应各行），以及两个隐藏状态因子的每一种取值组合（由第二和第三个索引区分），我们都已经定义了相应的概率。

C.3.1 转移概率

在 A 之后，我们接着指定 B。如第 7 章所讨论，与 B 矩阵相关联的上标指的是隐藏状态因子，而不是像 A 那样表示结果模态；同样，我们仍将花括号视为上标的等价写法（图 C.5）。回忆一下，这两个因子分别是位置（1）和上下文（2）。每个矩阵都把前一时刻的状态（列）映射到当前时刻的状态（行）。如果某个状态因子是可控制的，那么 B 矩阵还可以随动作而变化。这意味着控制状态需要额外一个索引，用来指明采取的是哪一个动作：

```
B{1}(:, :, 1)     = [1 1 0 0; 0 0 0 0;0 0 1 0;0 0 0 1];
B{1}(:, :, 2)     = [0 0 0 0; 1 1 0 0;0 0 1 0;0 0 0 1];
B{1}(:, :, 3)     = [0 0 0 0; 0 0 0 0;1 1 1 0;0 0 0 1];
B{1}(:, :, 4)     = [0 0 0 0; 0 0 0 0;0 0 1 0;1 1 0 1];

B{2} =
eye(2);
```

图 C.5

这里，我们针对四个可用动作中的每一个，给出了可控制的位置状态。回忆一下，一共有四个可用动作，每个动作都决定向四个位置之一发生转移。右臂和左臂都是吸收态，这意味着老鼠一旦进入这些位置，就必须停留在那里。这里的分号表示矩阵中每一行的结束。上下文状态并不受生物体控制，因此我们不需要为每个动作分别指定一组不同的转移概率。我们只需定义一个单一的单位矩阵，在 Matlab 中记作 `eye`。这就实现了图 7.6 和公式 7.5 中的设定。

C.3.2 先验偏好与初始状态

在 B 之后是 C。这里我们回到了与 A 相似的语法：上标和花括号都对应结果模态。此外，我们还像处理 B 那样指定 D：上标和花括号对应的是隐藏状态因子（图 C.6）。C 和 D 的行数必须分别与对应的 A 矩阵和 B 矩阵的行数一致。

```
C{1}   = [-1 -1 -1;
0 0 0;
0 0 0;
0 0 0;
0 0 0];
c      = 6;
C{2}   = [ 0 0 0;
c c c;
```

```
-c -c -c];
D{1} = [1 0 0 0]';
D{2} = [1 1]'/2;
```

图 C.6

偏好是在 C 矩阵中以对数概率的形式给出的（它们不必归一化）。两个结果之间若相差 6，就意味着概率更高的那个结果比另一个结果高出 exp(6) 倍。每一行对应一个不同的结果，列则对应不同的时间步。这使得时间变化的偏好成为可能。如果只给出一列，就默认每个时间点上的偏好都相同。这里给出的 D 向量，则只是为试次开始时的每个状态赋予一个概率。可将其与公式 7.6 和公式 7.7 对照理解。还要注意，在 Matlab 中，转置记号写作 '。

C.3.3 策略空间

我们已经通过 B 矩阵隐式地指定了允许的动作。我们可以假设策略与动作完全等同，并且在每个时间步都重新选择策略。另一种做法是把策略指定为动作序列。可以这样理解：每个策略都告诉我们，在每个时间步上，究竟是哪一个 B 矩阵（由第三个索引标识）在起作用。我们通过指定一个数组 V 来实现这一点（图 C.7）：

```
V(:, :, 1) = [1 1 1 1 3 4 2 2 2 2
1 2 3 4 3 4 1 2 3 4];
V(:, :, 2) = 1;
```

图 C.7

V 的第一个索引（即各行）表示动作序列中的位置。这意味着第一行是第一个动作，第二行是第二个动作。由于动作会导致状态转移，一个三步模型只会

C.4 整合各个组成部分

在完成 POMDP 的各项设定之后，我们现在将其整合到一个单独的 `mdp` 变量中（见图 C.8）：

```
mdp.V = V; % allowable policies
mdp.A = A; % observation model
mdp.B = B; % transition probabilities
mdp.C = C; % preferred outcomes
mdp.D = D; % prior over initial states
mdp.S = [1 1]'; % true initial state
```

图 C.8

这里最后一行使我们能够指定希望作为起点的真实隐藏状态。这个信息对我们模拟出来的生物体而言是不可用的；它必须依据这些状态所生成的结果，以及它自身的生成模型（由前五行给

出），来推断状态。

C.5 仿真与绘图

spm_MDP_VB_X 函数在幕后完成了主要工作；它实现了第 4 章和第 7 章中描述的消息传递与策略选择。此外，它还会模拟我们的生物体必须面对的世界，包括状态之间的转移以及结果的生成。我们本来还可以加入许多其他选项；有关细节，请读者参阅 Matlab 脚本中该函数的说明文档。

一旦完成一次试次的仿真，我们通常会希望找到某种图形化方式来呈现结果。像图 7.2 和图 7.7 那样的绘图，可以通过标准绘图例程自动生成：

```
MDP = spm_MDP_VB_X(mdp);
spm_figure('GetWin', 'Figure 1'); clf
spm_MDP_VB_trial(MDP);

spm_figure('GetWin', 'Figure 2'); clf
spm_MDP_VB_LFP(MDP,[],1);

spm_figure('GetWin','Figure 3'); clf
spm_MDP_VB_LFP(MDP,[],2);
```

图 C.9

图 C.9 中的这些代码行会完成仿真，并将结果绘制在三个图中。第一幅图给出仿真的总体摘要，包括状态、结果、被选中的策略，以及回顾性推断。第二幅图展示第一个隐藏状态因子在信念更新过程中的电生理相关量；第三幅图则对第二个因子做同样的展示。为了让你确信一切都在正常运行，我们把前几行代码的输出以图形形式重现出来（见图 C.10）。我们本来也可以把另外两幅图也重现出来；不过，我们希望给你一个亲自运行脚本的机会，通过实践主动推断来降低自己对这些图究竟展示了什么的不确定性。

这个带注释的简单示例到这里就结束了。我们希望它能引导你开始探索那些可以用相同原则和语法来指定的各种生成模型。你可以在 Matlab 命令行中输入 DEM，然后在随后出现的图形用户界面中选择相应的演示，以找到更多示例。我们提供的 demo 脚本，是 Friston、FitzGerald 等人（2017）所使用例程的一个简化版本。若想进一步了解更多细节，包括如何在多次试次中学习生成模型，我们建议读者参阅该论文，以及 SPM12 中提供的 DEM_demo_MDP_X.m 脚本。

图 C.10 spm_MDP_VB_trial 例程生成的输出。左上：对每个隐藏状态因子的回顾性信念（即在所有观测都已经获得之后）。黑色阴影表示概率为 1，白色表示概率为 0。灰色圆点（在彩色绘图中会显示为青色）表示由模拟环境生成的真实状态；我们可以看到，模拟出来的大鼠能够准确且有信心地推断出它的位置（因子 1）以及情境（因子 2）。左中：C.6 节中 V 变量所指定的“可选策略”，每一行表示一个策略：第一列是第一步采取的动作，第二列是第二步采取的动

作。每个元素中的不同阴影代表可被选择的不同动作。左下：每个模态中的真实结果（灰色圆点）。背景阴影显示的是每个模态的 C 矩阵，颜色越深表示该结果越受偏好。右上：被推断并被选择的动作。右中：每个时间步对各个策略的信念。右下：关于策略信念的推断精度（灰线），以及其变化率的柱状图；这种形式让人联想到电生理学中用于展示多巴胺能神经元放电的栅格图。注意，这里的时间是以更新次数来表示的；这些更新对应于对自由能进行梯度下降时的迭代。默认情况下，每个时间步有 16 次更新。