

用于贝叶斯推断的非参数集合变换方法*

Sebastian Reich

August 10, 2026

摘要

许多应用（例如间歇数据同化）需要在蒙特卡洛框架内递归应用贝叶斯推断。常用的数据同化算法包括序贯蒙特卡洛方法和集合卡尔曼滤波器（EnKF），二者实现贝叶斯推断的方式不同：序贯蒙特卡洛方法依赖重要性采样与重采样步骤的结合，而 EnKF 则依据经典卡尔曼滤波器对蒙特卡洛样本进行线性变换。尽管 EnKF 即使在集合规模较小时也表现得相当稳健，但由于其推导依赖线性回归假设，它并不具有相合性。本文提出另一种变换方法，它不对底层先验分布和后验分布作任何先验假设。该方法以求解离散随机变量的最优输运问题为基础。

关键词：贝叶斯推断，蒙特卡洛方法，序贯数据同化，线性规划，重采样。

AMS (MOS) 主题分类：65C05, 62M20, 93E11, 62F15, 86A22

1 引言

本文关注贝叶斯推断中蒙特卡洛方法的一种特定实现，以及它在滤波和间歇数据同化中的应用 (Jazwinski, 1970)。更具体地说，假设我们拥有来自（通常未知的）先验分布 π_{X^f} 的有限规模集合 $\{x_i^f\}_{i=1}^M$ ，我们考虑如何估计后验期望值。获得这类估计量的一种标准方法，是依据样本 x_i^f 对给定观测 y_0 的似然 $\pi_Y(y_0 | x_i^f)$ 进行重要性采样 (Doucet et al., 2001; Arulampalam et al., 2002; Bain and Crisan, 2008)。若递归应用这种方法，就必须把重要性采样与多项式重采样或系统重采样等步骤结合起来 (Arulampalam et al., 2002; Künsch, 2005)。近年来，人们提出了集合卡尔曼滤波器（EnKF）(Evensen, 2006)；它利用线性滤波中的经典卡尔曼更新步骤 (Jazwinski, 1970)，把先验集合 $\{x_i^f\}_{i=1}^M$ 变换成等权重的后验集合 $\{x_i^a\}_{i=1}^M$ 。然而，即使在 $M \rightarrow \infty$ 的极限下，EnKF 仍会产生有偏估计量 (Lei and Bickel, 2011)。本文提出一种非随机集合变换方法，它以线性规划形式的有限维最优输运为基础 (Strang, 1986; Cotter and Reich, 2012)。数值和理论证据表明，这种新方法能够得到相合的后验估计量。把它用于间歇数据同化，可以得到一种新的粒子滤波实现。我们在混沌 Lorenz-63 模型上展示了这一用途 (Lorenz, 1963)。

本文结构如下。第 2 节在贝叶斯推断背景下概述重要性采样蒙特卡洛方法；第 3 节继而在线性规划框架中表述重要性采样，由此得到一种新的重采样方法，使先验与后验集合成员之间的相关性最大。我们进一步提出一种改进，把重采样步骤转化为确定性的线性变换，并通过两个例子从数值上展示该变换步骤的收敛性。随后基于 McCann (1995) 的结果给出理论收敛结论。最后，第 4 节讨论其在序贯蒙特卡洛方法中的应用，提出一种新的集合变换滤波器，并给出 Lorenz-63 模型的数值结果。

2 贝叶斯推断与重要性采样

下面概述贝叶斯推断的重要性采样方法。给定先验随机变量（在动态模型语境下也称预报随机变量） $X^f : \Omega \rightarrow \mathbb{R}^N$ ，记其概率密度函数（PDF）为 $\pi_{X^f}(x)$ ，其中 $x \in \mathbb{R}^N$ ；并考虑同化一个观测 $y_0 \in \mathbb{R}^K$ ，其似然函数为 $\pi_Y(y | x)$ 。根据贝叶斯定理，分析（后验）PDF 为

$$\pi_{X^a}(x | y_0) = \frac{\pi_Y(y_0 | x) \pi_{X^f}(x)}{\int_{\mathbb{R}^N} \pi_Y(y_0 | x) \pi_{X^f}(x) dx}. \quad (1)$$

*德国波茨坦大学数学研究所，Am Neuen Palais 10, D-14469 Potsdam, Germany

通常无法显式获得预报随机变量 X^f 及其 PDF。我们转而假设已有一个预报集合 $x_i^f \in \mathbb{R}^N$, $i = 1, \dots, M$; 在数学上, 它们被视为 M 个相互独立 (或相关) 的随机变量 $X_i^f : \Omega \rightarrow \mathbb{R}^N$ 的实现 $X_i^f(\omega)$, $\omega \in \Omega$, 这些随机变量服从分布 π_{X^f} 。于是, 函数 $g : \mathbb{R}^N \rightarrow \mathbb{R}$ 关于先验 PDF $\pi_{X^f}(x)$ 的期望 $\bar{g}^f = \mathbb{E}_{X^f}[g]$ 可估计为

$$\bar{G}_M^f = \frac{1}{M} \sum_{i=1}^M g(X_i^f),$$

而对于集合 $\{x_i^f = X_i^f(\omega)\}_{i=1}^M$, 其实现为

$$\bar{g}_M^f = \bar{G}_M^f(\omega) = \frac{1}{M} \sum_{i=1}^M g(X_i^f(\omega)) = \frac{1}{M} \sum_{i=1}^M g(x_i^f).$$

对任意 $M > 0$, 该估计量均无偏; 若 g 的方差有限, 则当 $M \rightarrow \infty$ 时, 其方差趋于零。

按照重要性采样的思想 (Liu, 2001), 利用预报集合可得到后验 PDF $\pi_{X^a}(x | y_0)$ 下的如下估计量:

$$\bar{g}_M^a = \sum_{i=1}^M w_i g(x_i^f),$$

其中权重为

$$w_i = \frac{\pi_Y(y_0 | x_i^f)}{\sum_{i=1}^M \pi_Y(y_0 | x_i^f)}. \quad (2)$$

对于有限 M , 该估计量不再无偏, 但仍具有相合性。这里, 若估计量 $\bar{g}_M^a$ 与精确期望 $\bar{g}^a = \mathbb{E}_{X^a}[g]$ 之间的均方根误差在 $M \rightarrow \infty$ 时趋于零, 就称该估计量是相合的。

3 基于线性规划的集合变换方法

作为重要性采样的替代方案, 我们可以尝试把服从 $X_i^f \sim \pi_{X^f}$ 的样本 $x_i^f = X_i^f(\omega)$ 变换为服从后验分布 $\pi_{X^a}(x | y_0)$ 的样本 $\hat{x}_i^a$ 。这样, 对后验期望值又可使用等权估计量

$$\bar{g}_M^a = \frac{1}{M} \sum_{i=1}^M g(\hat{x}_i^a).$$

对于 PDF 分别为 π_{X^f} 和 π_{X^a} 的一元随机变量 X^f 与 X^a , 该变换由下式刻画:

$$F_{X^a}(\hat{x}_i^a) = F_{X^f}(x_i^f), \quad (3)$$

其中 F_{X^f} 和 F_{X^a} 分别表示 X^f 与 X^a 的累积分布函数, 例如

$$F_{X^f}(x) = \int_{-\infty}^x \pi_{X^f}(x') dx'.$$

式 (3) 需要已知相应的 PDF, 而且将其推广到多元随机变量并不容易。本节提出一种替代方法: 它不需要显式知道底层 PDF, 并且很容易推广到多元随机变量。为得到所需变换, 我们在 $\mathbb{R}^N$ 中选取适当的距离 $d(x, x')$, 利用最优输运思想 (Villani, 2003, 2009)。更具体地说, 首先在两个离散随机变量 $\mathbf{X}^f : \Omega' \rightarrow \mathcal{X}$ 与 $\mathbf{X}^a : \Omega' \rightarrow \mathcal{X}$ 之间寻找一个耦合; 二者的取值均在 $\mathcal{X} = \{x_1^f, \dots, x_M^f\}$ 中, $\mathbf{X}^f$ 的概率向量为 $p^f = (1/M, \dots, 1/M)^T$, $\mathbf{X}^a$ 的概率向量为 $p^a = (w_1, \dots, w_M)^T$ 。 $\mathbf{X}^f$ 与 $\mathbf{X}^a$ 之间的一个耦合, 是元素非负的 $M \times M$ 矩阵 $\mathbf{T}$, 其元素 $t_{ij} = (\mathbf{T})_{ij} \geq 0$ 满足

$$\sum_{i=1}^M t_{ij} = 1/M, \quad \sum_{j=1}^M t_{ij} = w_i. \quad (4)$$

现在寻找使期望距离

$$\mathbb{E}_{\mathbf{X}^f \mathbf{X}^a}[d(x^f, x^a)] = \sum_{i,j=1}^M t_{ij} d(x_i^f, x_j^f) \quad (5)$$

最小的耦合 $\mathbf{T}^*$ 。所需耦合 $\mathbf{T}^*$ 由一个线性规划问题刻画 (Strang, 1986)。由于式 (4) 给出 $2M - 1$ 个独立约束，矩阵 $\mathbf{T}^*$ 至多包含 $2M - 1$ 个非零元素。

本文采用平方欧氏距离，即

$$d(x_i^f, x_j^f) = \|x_i^f - x_j^f\|^2. \quad (6)$$

回顾可知，关于平方欧氏距离最小化期望距离，等价于最大化 $\mathbb{E}_{\mathbf{X}^f \mathbf{X}^a}[(x^f)^T x^a]$ ，因为

$$\mathbb{E}_{\mathbf{X}^f \mathbf{X}^a}[\|x^f - x^a\|^2] = \mathbb{E}_{\mathbf{X}^f}[\|x^f\|^2] + \mathbb{E}_{\mathbf{X}^a}[\|x^a\|^2] - 2\mathbb{E}_{\mathbf{X}^f \mathbf{X}^a}[\langle x^f, x^a \rangle],$$

其中 $\langle x^f, x^a \rangle = (x^f)^T x^a$ 。此外，最优耦合 $\mathbf{T}^*$ 满足循环单调性 (Villani, 2009)，其定义如下。令 S 表示所有满足 $t_{ij}^* > 0$ 的 $(x_i^f, x_j^f) \in \mathcal{X} \times \mathcal{X}$ 所组成的集合，则对任意成对元素集合 $(x_i^f, x_i^a) \in S$, $i = 1, \dots, k$ ，有

$$\langle x_1^a, x_2^f - x_1^f \rangle + \langle x_2^a, x_3^f - x_2^f \rangle + \dots + \langle x_k^a, x_1^f - x_k^f \rangle \leq 0. \quad (7)$$

任何具有此性质的集合 $S \subset \mathbb{R}^N \times \mathbb{R}^N$ 都称为循环单调集 (Villani, 2009)。

接下来通过

$$\mathbf{P} = M\mathbf{T}^*$$

在 $\mathcal{X}$ 上引入马尔可夫链 $\mathbf{P} \in \mathbb{R}^{M \times M}$ ，它满足

$$p^a = \mathbf{P}p^f.$$

给定来自先验 PDF 的实现 x_j^f , $j = 1, \dots, M$ ，蒙特卡洛重采样步骤如下：求解式 (5) 得到最优耦合矩阵 $\mathbf{T}^*$ ，并对 $j = 1, \dots, M$ 定义离散随机变量

$$\mathbf{X}_j^a \sim \begin{pmatrix} p_{1j} \\ \vdots \\ p_{Mj} \end{pmatrix}. \quad (8)$$

这里 p_{ij} 表示 $\mathbf{P}$ 的第 (i, j) 个元素。注意，随机变量 $\mathbf{X}_j^a$, $j = 1, \dots, M$ ，既不相相互独立，也不同于分布。最后从每个随机变量 $\mathbf{X}_j^a$ 中各取一个实现，得到规模为 M 的新集合，即

$$x_j^a := \mathbf{X}_j^a(\omega), \quad j = 1, \dots, M.$$

这个由等权样本组成的集合可用于近似后验分布 $\pi_{X^a}(x | y_0)$ 下的期望值。

上述过程给出了有放回重采样的一种特定形式 (Arulampalam et al., 2002; Künsch, 2005)。它与多项式重采样或系统重采样等技术的主要区别在于：这里选取的重采样使先验样本与后验样本之间的期望距离 (5) 最小。

下面再作一项改进：用确定性步骤替代随机重采样，并且通常避免在分析集合 $\{x_i^a\}_{i=1}^M$ 中产生多个重复副本。该改进基于如下观察：

$$\bar{x}_j^a = \mathbb{E}_{\mathbf{X}_j^a}[x] = \sum_{i=1}^M p_{ij} x_i^f. \quad (9)$$

据此，我们提出确定性变换

$$x_j^a := \bar{x}_j^a = \sum_{i=1}^M p_{ij} x_i^f, \quad (10)$$

其中 $j = 1, \dots, M$ 。其基本思想是，当 $M \rightarrow \infty$ 时，

$$\bar{g}_M^a = \frac{1}{M} \sum_{j=1}^M g(\bar{x}_j^a)$$

仍是 $\mathbb{E}_{X^a}[g]$ 的相合估计量。对于特殊情形 $g(x) = x$ ，容易验证

$$\bar{x}_M^a = \frac{1}{M} \sum_{j=1}^M x_j^a = \frac{1}{M} \sum_{j=1}^M \sum_{i=1}^M p_{ij} x_i^f = \sum_{i,j} t_{ij}^* x_i^f = \sum_{i=1}^M w_i x_i^f.$$




Figure 1: $M = 10$ 时，变换方法得到的先验实现 x_i^f 与后验实现 x_i^a 。




Figure 2: $M = 10$ 时的精确集合变换映射与数值集合变换映射。高斯情形的精确变换是线性的；数值近似主要在两端尾部偏离线性。




Figure 3: $M = 40$ 时矩阵 $\mathbf{P}$ 中的非零元素，即耦合的支撑。非零元素总数为 $2M - 1 = 79$ 。带状结构揭示了重采样步骤的空间局部性和循环单调性 (Villani, 2003, 2009)。

Table 1: 集合变换方法应用于高斯标量贝叶斯推断问题时，对后验分布一至四阶矩的估计。

	$\bar{x}$	σ^2	$\mathbb{E}[(X - \bar{x})^3]$	$\mathbb{E}[(X - \bar{x})^4]$
$M = 10$	0.5361	1.0898	-0.0137	2.3205
$M = 40$	0.5473	1.0241	0.0058	2.7954
$M = 100$	0.5493	1.0098	-0.0037	2.9167

在研究所提出变换 (10) 的理论性质之前，我们先考察两个例子。它们表明，在 $M \rightarrow \infty$ 的极限下，式 (10) 确实能对式 (3) 给出相合近似。

例。取均值 $\bar{x} = 1$ 、方差 $\sigma^2 = 2$ 的一元高斯分布作为先验随机变量 X^f 。 X^f 的实现由下式生成：

$$x_i^f = \sqrt{2} \operatorname{erf}^{-1}(2u_i - 1), \quad u_i = \frac{1}{2M} + \frac{i-1}{M},$$

其中 $i = 1, \dots, M$ 。似然函数为

$$\pi_Y(y | x) = \frac{1}{\sqrt{4\pi}} \exp\left(-\frac{(y-x)^2}{4}\right),$$

并假设观测值为 $y_0 = 0.1$ 。贝叶斯公式给出的后验分布仍为高斯分布，其均值 $\bar{x} = 0.55$ 、方差 $\sigma^2 = 1$ 。图 1 展示了 $M = 10$ 时变换方法所得的先验实现和后验实现。图 2 还展示了解析变换以及利用线性规划得到的近似变换；对于高斯分布，解析变换是一条直线。图 3 展示了 $M = 40$ 时马尔可夫链矩阵 $\mathbf{P}$ 的非零元素结构，可以看到局部相互作用形成的带状结构。其中阶梯状排列源于 $\mathbf{T}^*$ 支撑的循环单调性。更一般地，表 1 给出了后验分布前四阶矩的估计值，它们表明结果随 $M \rightarrow \infty$ 而收敛。

例。作为另一个（非高斯）例子，考虑区间 $[0, 1]$ 上的均匀先验，并采用样本 $x_i^f = u_i$ ，其中 u_i 的定义与前例相同。给定观测值 $y_0 = 0.1$ ，后验 PDF 为

$$\pi_{X^a}(x | 0.1) = \begin{cases} \frac{1}{0.9427 \dots} e^{-(x-0.1)^2/4}, & x \in [0, 1], \\ 0, & \text{其他情形.} \end{cases}$$

Table 2: 集合变换方法应用于非高斯标量贝叶斯推断问题时, 对后验分布一至四阶矩的估计。

	$\bar{x}$	σ^2	$\mathbb{E}[(X - \bar{x})^3]$	$\mathbb{E}[(X - \bar{x})^4]$
$M = 10$	0.4838	0.0886	0.0014	0.0114
$M = 40$	0.4836	0.0838	0.0016	0.0121
$M = 100$	0.4836	0.0825	0.0016	0.0122

由此得到的后验均值为 $\bar{x} \approx 0.4836$, 方差为 $\sigma^2 \approx 0.0818$; 三阶矩和四阶矩分别为 0.0016 和 0.0122。表 2 给出了变换方法所得的后验分布前四阶矩估计, 它们同样表明结果随 $M \rightarrow \infty$ 而收敛。

下面从理论上研究变换 (10)。我们的收敛结果基于以下引理以及 McCann (1995) 的一般性结果。

引理 1. 由所有有序对 $(x_j^f, \bar{x}_j^a)$ ($j = 1, \dots, M$) 组成的集合 $\hat{S}$ 是循环单调的, 其中 $\bar{x}_j^a$ 由式 (9) 定义。

Proof. 用 $I(j)$ 表示所有满足 $p_{ij} > 0$ 的指标 i 的集合。由于 $\mathbf{T}^*$ 是循环单调的, 对包含形如 $\langle x_i^f, x_{j+1}^f - x_j^f \rangle$ (其中 $i \in I(j)$) 这一项的序列, 式 (7) 成立。由于 $\langle x_i^f, x_{j+1}^f - x_j^f \rangle$ 对两个自变量分别都是线性的, 式 (7) 也适用于线性组合, 从而得到

$$\begin{aligned} \sum_{i=1}^M p_{ij} \{ \langle x_1^a, x_2^f - x_1^f \rangle + \langle x_2^a, x_3^f - x_2^f \rangle + \dots + \langle x_i^a, x_{j+1}^f - x_j^f \rangle + \dots + \langle x_k^a, x_1^f - x_k^f \rangle \} \\ = \langle x_1^a, x_2^f - x_1^f \rangle + \langle x_2^a, x_3^f - x_2^f \rangle + \dots + \langle \bar{x}_j^a, x_{j+1}^f - x_j^f \rangle + \dots + \langle x_k^a, x_1^f - x_k^f \rangle \leq 0, \end{aligned}$$

因为 $\sum_{i=1}^M p_{ij} = 1$ 。对所有 $j' \in \{1, \dots, k\} \setminus \{j\}$ 重复同样步骤, 可得

$$\langle \bar{x}_1^a, x_2^f - x_1^f \rangle + \langle \bar{x}_2^a, x_3^f - x_2^f \rangle + \dots + \langle \bar{x}_j^a, x_{j+1}^f - x_j^f \rangle + \dots + \langle \bar{x}_k^a, x_1^f - x_k^f \rangle \leq 0.$$

因此, 集合 $\hat{S}$ 是循环单调的。 $\square$

定理 1. 假设集合 $\mathcal{X}_M^f = \{x_i^f\}_{i=1}^M$ 由 M 个相互独立同分布的随机变量 $X_i^f : \Omega \rightarrow \mathbb{R}^N$ 的实现组成, 其 PDF 为 π_{X^f} 。令 $\mathcal{X}_M^a = \{\bar{x}_j^a\}_{j=1}^M$, 其中 $\bar{x}_j^a$ 由式 (9) 给出。对于固定的 M , 定义映射 $\Psi_M : \mathcal{X}_M^f \rightarrow \mathcal{X}_M^a$ 为

$$\bar{x}_j^a = \Psi_M(x_j^f), \quad j = 1, \dots, M.$$

则当 $M \rightarrow \infty$ 时, 这些映射弱收敛到一个映射 $\Psi : \mathbb{R}^N \rightarrow \mathbb{R}^N$ 。此外, 由 $X^a = \Psi(X^f)$ 定义的随机变量具有式 (1) 所给的分布; 在所有满足这一性质的映射中, X^a 与 X^f 之间的期望距离最小。

Proof. 映射 Ψ_M 定义了 $\mathcal{X}_M^f$ 与 $\mathcal{X}_M^a$ 上离散随机变量之间的一系列耦合; 根据引理 1, 这些耦合满足循环单调性。沿用 McCann (1995) 定理 6 的证明, 可得这些耦合弱收敛到一个耦合, 即 $\mathbb{R}^N \times \mathbb{R}^N$ 上的概率测度 $\mu_{X^f X^a}$, 其边缘分布分别为 π_{X^f} 和 π_{X^a} 。此外, $\mu_{X^f X^a}$ 也具有循环单调性, 因此可应用 McCann (1995) 的主定理来保证映射 Ψ 的存在; 该映射本身是某个凸势函数 ψ 的梯度。耦合 $\mu_{X^f X^a}$ 求解了代价为 $c(x, y) = \|x - y\|^2$ 的 Monge-Kantorovich 问题 (Villani, 2003, 2009)。 $\square$

可以用适当的随机向量 $p^f = (w_1^f, \dots, w_M^f)^T$ 替代 p^f 中的均匀概率, 其中 $w_i^f \geq 0$ 且 $\sum_{i=1}^M w_i^f = 1$ 。为使符号清晰, 按照贝叶斯公式把后验权重写成 $p^a = (w_1^a, \dots, w_M^a)^T$ 。相应调整线性规划问题 (5) 后, 可得到最优耦合 $\mathbf{T}^*$ 以及由它诱导的马尔可夫链 $\mathbf{P}$, 其元素为

$$p_{ij} = \frac{t_{ij}}{w_j^f}.$$

因此, 变换方法 (5) 现替换为

$$\bar{x}_j^a = \sum_{i=1}^M p_{ij} x_i^f, \quad (11)$$

且后验集合均值满足

$$\bar{x}_M^a = \sum_{j=1}^M w_j^f \bar{x}_j^a = \sum_{j=1}^M \sum_{i=1}^M w_j^f \frac{t_{ij}}{w_j^f} x_i^f = \sum_{i=1}^M w_i^a x_i^f,$$

这正是所需结果。更一般地，后验期望值由下式给出：

$$\bar{g}_M^a = \sum_{i=1}^M w_i^f g(x_i^a).$$

4 在序贯数据同化中的应用

现在把所提出的集合变换 (ET) 方法 (5) 应用于常微分方程模型的序贯状态估计：

$$\dot{x} = f(x), \quad (12)$$

其中，时刻 $t = 0$ 的初始条件 $x(0) \in \mathbb{R}^N$ 具有已知 PDF π_0 。因此，我们把解 $x(t)$ 视为随机变量 X_t ($t \geq 0$) 的实现；这些随机变量由式 (12) 的流和初始 PDF π_0 决定。

假设在离散时刻 $t_k = k\Delta t_{\text{obs}}$ ($k > 0$) 可以获得观测 $y(t_k) \in \mathbb{R}^K$ ，观测间隔为 $\Delta t_{\text{obs}} > 0$ 。观测满足前向模型

$$Y(t_k) = h(x_{\text{ref}}(t_k)) + \Xi_k,$$

其中 $\Xi_k : \Omega \rightarrow \mathbb{R}^K$ 表示相互独立同分布、均值为零、协方差矩阵为 $R \in \mathbb{R}^{K \times K}$ 的高斯随机变量， $h : \mathbb{R}^N \rightarrow \mathbb{R}^K$ 是前向映射，而 $x_{\text{ref}}(t) \in \mathbb{R}^N$ 表示希望估计的参考解。该前向模型产生似然函数

$$\pi_Y(y | x) = \frac{1}{(2\pi)^{K/2} |R|^{1/2}} \exp \left[-\frac{1}{2} (y - h(x))^T R^{-1} (y - h(x)) \right].$$

粒子滤波器从初始 PDF π_0 的 M 个实现所组成的集合 $\{x_i(0)\}_{i=1}^M$ 出发。我们按照模型动力学 (12) 演化该集合，直至获得第一个观测 $y_{\text{obs}}(\Delta t_{\text{obs}})$ ；此时，对预报集合成员 $x_i^f = x_i(\Delta t_{\text{obs}})$ 应用所提出的 ET 方法。进一步把这些先验实现汇集到一个 $N \times M$ 矩阵中：

$$\mathbf{X}^f = [x_1^f \cdots x_M^f].$$

那么，对于给定观测 $y_0 = y(\Delta t_{\text{obs}})$ ，ET 方法 (11) 产生的后验实现可简单写为

$$\mathbf{X}^a = \mathbf{X}^f \mathbf{P}, \quad [x_1^a \cdots x_M^a] = \mathbf{X}^a, \quad (13)$$

其中 $\mathbf{P}$ 是由相应线性规划问题诱导的马尔可夫链。随后把分析集合成员 x_i^a , $i = 1, \dots, M$ ，作为模型 (12) 的新初始条件；对所有 $k > 1$ ，重复模型动力学传播与数据同化交替进行的过程。

应当指出，集合平方根滤波器 (ESRF) (Evensen, 2006) 也会产生与式 (13) 类似的变换。然而，这里使用的变换矩阵 $\mathbf{P} \in \mathbb{R}^{M \times M}$ 是以完全不同的方式获得的，不依赖 PDF 为高斯分布的假设。关于修改 EnKF 使其与非高斯分布相合的另一种方法，可参见 Lei and Bickel (2011)。下面给出一个数值例子，把一种 ESRF 实现与使用新 ET 方法的粒子滤波器作比较。

例。考虑 Lorenz-63 模型 (Lorenz, 1963)

$$\begin{aligned} \dot{x} &= \sigma(y - x), \\ \dot{y} &= x(\rho - z) - y, \\ \dot{z} &= xy - \beta z, \end{aligned}$$

参数和数据同化设置采用 Anderson (2010) 的方案。具体而言，状态向量为 $x = (x, y, z)^T \in \mathbb{R}^3$ ；每隔 $\Delta t_{\text{obs}} = 0.12$ 个时间单位观测全部三个变量，各被观测解分量的测量误差方差均为 $R = 8$ 。方程采用隐式中点法作时间积分，步长为 $\Delta t = 0.01$ 。我们实现了 ESRF (Evensen, 2006) 和新的 ET 滤波器，集合规模取 $M = 10, 20, 40, 60, 80, 100$ 。两种方法的结果均采用优化形式的集合膨胀 (Evensen, 2006)。尽管如此，当 $M = 10$ 时 ET 仍出现滤波发散，而 ESRF 对所有给定的 M 均保持稳定。图 4 给出了 2000 个同化步骤上的时间平均均方根 (RMS) 误差。可以清楚看到，对所有 $M \geq 20$ ，新 ET 滤波器的 RMS 误差都低得多。与 Anderson (2010) 所示的秩直方图滤波器 (RHF) (Anderson, 2010) 和扰动观测 EnKF (Evensen, 2006) 相比，这些结果也更好。




Figure 4: 在 Anderson (2010) 的 Lorenz-63 模型设置下, 随着集合规模 M 增大, 集合平方根滤波器 (ESRF) 和新集合变换 (ET) 滤波器的时间平均 RMS 误差。

5 结论

本文研究了线性规划和最优输运在贝叶斯推断与粒子滤波中的应用。理论和数值结果均表明, 所提出的 ET 方法能够在 $M \rightarrow \infty$ 的极限下复现后验期望值, 并收敛到相应的连续最优输运问题 (Villani, 2003, 2009)。Moselhy and Marzouk (2012)、Reich (2011, 2012) 以及 Cotter and Reich (2012) 已讨论过连续最优输运在贝叶斯推断中的应用。然而, 在高维状态空间 $\mathbb{R}^N$ 中直接把连续最优输运用于贝叶斯推断, 目前似乎仍不可行, 还需要开发高效的数值技术。当集合规模 M 远小于状态空间维数 N (对于间歇数据同化, 也可能是式 (12) 吸引子的维数) 时, 为实现所提出的 ET 方法需要作何种修改 (例如局部化 (Evensen, 2006)), 仍有待研究。本文使用标准 Matlab 单纯形算法实现来求解线性规划问题。未来实现 ET 方法 (5) 时, 应考虑拍卖算法 (Bertsekas and Castanon, 1989) 等更高效的算法。

致谢

感谢 Yann Brenier 和 Jacques Vanneste 在 2010 年 Oberwolfach 研讨会期间围绕本文主题所作的启发性讨论。本文还受益于 2012 年另一场 Oberwolfach 研讨会上与 Wilhelm Stannat 和 Dan Crisan 的进一步讨论。

参考文献

- J.L. Anderson. A non-Gaussian ensemble filter update for data assimilation. *Monthly Weather Review*, 138:4186–4198, 2010.
- M.S. Arulampalam, S. Maskell, N. Gordon, and T. Clapp. A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking. *IEEE Trans. Sign. Process.*, 50:174–188, 2002.
- A. Bain and D. Crisan. *Fundamentals of stochastic filtering*, volume 60 of *Stochastic modelling and applied probability*. Springer-Verlag, New-York, 2008.
- D.P. Bertsekas and D.A. Castanon. The auction algorithm for the transportation problem. *Annals of Operations Research*, 20:67–96, 1989.
- C.J. Cotter and S. Reich. Ensemble filter techniques for intermittent data assimilation - a survey. *submitted*, 2012.

- A. Doucet, N. de Freitas, and N. Gordon (eds.). *Sequential Monte Carlo methods in practice*. Springer-Verlag, Berlin Heidelberg New York, 2001.
- G. Evensen. *Data assimilation. The ensemble Kalman filter*. Springer-Verlag, New York, 2006.
- A.H. Jazwinski. *Stochastic processes and filtering theory*. Academic Press, New York, 1970.
- H.R. Künsch. Rekursive Monte Carlo filter: Algorithms and theoretical analysis. *Ann. Statist.*, 33:1983–2021, 2005.
- J. Lei and P. Bickel. A moment matching ensemble filter for nonlinear and non-Gaussian data assimilation. *Mon. Weath. Rev.*, 139:3964–3973, 2011.
- J.S. Liu. *Monte Carlo Strategies in Scientific Computing*. Springer-Verlag, New York, 2001.
- E.N. Lorenz. Deterministic non-periodic flows. *J. Atmos. Sci.*, 20:130–141, 1963.
- R.J. McCann. Existence and uniqueness of monotone measure-preserving maps. *Duke Mathematical Journal*, 80:309–323, 1995.
- T.A. El Moselhy and Y.M. Marzouk. Bayesian inference with optimal maps. *J. Comput. Phys.*, 231:in press, 2012.
- S. Reich. A dynamical systems framework for intermittent data assimilation. *BIT Numer Math*, 51:235–249, 2011.
- S. Reich. A Gaussian mixture ensemble transform filter. *Q. J. R. Meteorolog. Soc.*, 138:222–233, 2012.
- G. Strang. *Introduction to Applied Mathematics*. Wellesley-Cambridge Press, 2nd edition, 1986.
- C. Villani. *Topics in Optimal Transportation*. American Mathematical Society, Providence, Rhode Island, NY, 2003.
- C. Villani. *Optimal transportation: Old and new*. Springer-Verlag, Berlin Heidelberg, 2009.