

粒子滤波网络及其在视觉定位中的应用

Peter Karkus^{1,2} David Hsu^{1,2} Wee Sun Lee²

¹ 新加坡国立大学综合科学与工程研究生院

² 新加坡国立大学计算机学院

{karkus, dyhsu, leews}@comp.nus.edu.sg

摘要

粒子滤波是序列状态估计的一种强大方法，并在机器人定位、目标跟踪等许多领域中得到应用。要在实践中应用粒子滤波，一个关键挑战是构造概率系统模型，尤其是面对动力学复杂或传感输入丰富的系统时，例如相机图像。本文提出粒子滤波网络 (Particle Filter Network, PF-net)，它把系统模型和粒子滤波算法编码在同一个神经网络中。PF-net 完全可微，并由数据进行端到端训练。它不是学习一个通用系统模型，而是学习一个针对粒子滤波算法优化过的模型。我们把 PF-net 应用于视觉定位任务：机器人必须只借助一张示意性的 2-D 楼层地图，在一个丰富的 3-D 世界中完成定位。在仿真实验中，在多种传感输入下，PF-net 一贯优于替代学习架构以及传统的基于模型的方法。此外，PF-net 能够很好地泛化到新的、未见过的环境。

关键词：序列状态估计，粒子滤波，深度神经网络，端到端学习，视觉定位

第 2 届机器人学习会议 (CoRL 2018)，瑞士苏黎世。

1 引言

粒子滤波，也称为序贯 Monte-Carlo 方法，是序列状态估计的一种强大方法 [1]。粒子滤波器广泛用于机器人学、计算机视觉、物理学、计量经济学等领域 [2–7]，并且对机器人任务至关重要，例如定位 [8]、SLAM [9] 以及部分可观测条件下的规划 [10]。要在实践中应用粒子滤波器，一个主要挑战是构造概率系统模型，或从数据中学习这些模型 [11–13]。例如，考虑配备机载相机的机器人定位 (图 1a)。观测模型是在连续机器人状态和环境地图条件下，对所有可能相机图像的概率分布。学习这样的模型很困难，因为观测空间极其庞大，而且缺乏足够的标注数据。一个新兴研究方向绕开了传统模型学习的困难：它把算法嵌入深度神经网络中，然后通过端到端学习来训练一个针对特定算法优化的模型 [14–18]。

沿着这一方向，我们提出粒子滤波网络 (Particle Filter Network, PF-net)，这是一种带有序列状态估计可微算法先验的循环神经网络 (RNN)。PF-net 将可学习的概率状态转移模型和观测模型，与粒子滤波算法一起编码在单个神经网络中 (图 1b)。它完全可微，并从数据中端到端训练。PF-net 处理了学习复杂概率系统模型的关键挑战。神经网络能够表示大空间上的复杂模型，例如图像上的观测模型。此外，网络表示把模型和算法统一起来，从而允许端到端训练。因此，PF-net 学习的是针对某个特定算法优化的系统模型，在本文中即粒子滤波，而不是学习通用系统模型。这些模型可以只学习与状态估计相关的特征，从而降低学习复杂度。

我们将 PF-net 应用于机器人视觉定位，这是移动机器人学中非常重要的问题。机器人在一个先前未见




图 1: (a) 机器人在 3-D 环境中的视觉定位，只使用示意性的 2-D 楼层地图。机器人必须把丰富的 3-D 视觉特征与地图中粗略的 2-D 几何特征相匹配。它还必须忽略地图中不存在的物体，例如家具。(b) PF-net 把学习得到的概率系统模型和粒子滤波算法编码在同一个神经网络中。它在粒子滤波算法的上下文中端到端训练模型，从而获得更好的性能。

过的环境中导航，并且不知道自身的精确位置。它必须只给定一张示意性的 2-D 楼层地图和机载传感器观测，在视觉丰富的 3-D 世界中完成定位（图 1a）。虽然粒子滤波是 LIDAR 的标准方法 [8]，但我们考虑视觉传感器，例如相机。此时，概率观测模型必须把来自相机图像的丰富 3-D 视觉特征与地图中的粗略 2-D 几何特征相匹配。此外，相机图像可能包含地图中没有的各种物体，例如家具。该任务体现了从模糊、部分观测中进行状态估计的关键困难。标准的基于模型的方法会把观测模型构造成在楼层地图和机器人姿态条件下的图像概率分布。这很困难，因为观测空间极其巨大，即所有可能图像的空间，这些图像显示不同的楼层布局、家具配置等。相比之下，PF-net 端到端训练模型，并且只学习与定位任务相关的特征。

本文有两项贡献。首先，我们把粒子滤波算法编码到神经网络中，以端到端方式学习序列状态估计模型。其次，我们把 PF-net 应用于视觉定位，并提出一种网络架构，用于把 3-D 世界的丰富视觉特征与示意性的 2-D 楼层地图相匹配。在 House3D 数据集 [19] 上的仿真实验表明，学习得到的 PF-net 对带有家具的新未见环境中的视觉定位是有效的。通过端到端训练，它还优于传统的基于模型的方法；它能够融合来自多个传感器的信息，特别是 RGB 相机和深度相机；并且它能够自然地整合用于定位的语义信息，例如门和房间类型的地图标签。

2 背景

2.1 相关工作

可微算法先验这一思想，也就是把算法嵌入深度神经网络，近来受到越来越多关注。它已经在图搜索 [16, 17, 20]、路径积分最优控制 [21]、二次优化 [18, 22]，以及完全可观测环境 [14] 和部分可观测环境 [15, 23] 中的决策问题上取得了有前景的结果。

当这个一般思想被应用于概率状态估计时，已经产生了例如 Kalman filter network [24] 和 histogram filter network [25] 等方法。然而，Kalman 滤波假设底层状态分布是单峰 Gaussian，或可以很好地近似为单峰 Gaussian。Histogram filtering 假设离散状态空间，并且由于“维度灾难”而难以扩展到高维状态空间。为了处理任意分布以及非常大的离散或连续状态空间，一种可能方案是粒子滤波。与我们的工作同期，Jonschkowski 等人也独立研究了可微粒子滤波的思想 [26]。该工作与本文密切相关，我们希望强调几项重要差异。首先，我们提出了重采样的可微近似，而重采样是许多粒子滤波算法中的关键步骤。其次，在学习完成后，我们把 PF-net 应用于新的、未见过的环境中的视觉定位。同期工作也处理定位，但它处理的是固定环境。最后，我们用于视觉定位的观测模型会把丰富的 3-D 视觉特征与示意性的 2-D 楼层地图相匹配，忽略地图中不存在的物体，并融合来自多个来源的信息。神经网络也已经与粒子滤波器一起用于变分学习。与

PF-net 不同，这类网络旨在参数化观测上的一族生成分布 [27–30]，因此不适合处理大而复杂的观测空间，例如相机图像和楼层地图的空间。

粒子滤波方法，例如 Monte-Carlo localization [8]，是移动机器人定位的标准解决方案。许多此类方法假设机器人上安装了 LIDAR 传感器，并依赖手工设计的简单解析观测模型 [31]。虽然已有工作尝试整合单目相机或深度相机 [32–35]，但为它们构造概率观测模型仍然是一个挑战。PF-net 通过端到端训练学习有效的系统模型，而不需要对模型组件进行直接监督。

2.2 粒子滤波算法

粒子滤波器在接收观测后周期性地近似状态后验分布，即它们维护状态上的 belief $b(s)$ 。这个 belief 由一组粒子来近似，即来自概率分布的加权样本：

$$b_t(s) \approx \langle s_t^k, w_t^k \rangle_{k=1:K}, \quad (1)$$

其中 $\sum_k w_k = 1$ ， K 是粒子数量， s_k 是粒子状态， w_k 是粒子权重， t 表示时间。重要的是，粒子集合可以近似任意分布，例如连续、多模态、非 Gaussian 分布。状态估计可以通过加权均值计算： $\bar{s}_t = \sum_k w_t^k s_t^k$ 。粒子会以 Bayesian 方式周期性更新。首先，粒子状态通过从概率转移模型中采样来更新：

$$s_t^k \sim T(s_t|u_t, s_{t-1}^k), \quad (2)$$

其中转移模型 T 定义了在前一状态 s_{t-1}^k 和最近动作 u_t 条件下，状态 s_t 的概率。在机器人定位中， u_t 是里程计输入。其次，更新粒子权重。对每个粒子计算似然 f_t^k ：

$$f_t^k = Z(o_t|s_t^k; \mathbb{M}), \quad (3)$$

其中观测模型 Z 定义了状态和 2-D 楼层地图 $\mathbb{M}$ 条件下，观测 o_t 的条件概率。粒子权重根据似然更新：

$$w_t^k = \eta f_t^k w_{t-1}^k, \quad (4)$$

其中 $\eta^{-1} = \sum_{j=1:K} f_t^j w_{t-1}^j$ 是归一化因子。

一个常见问题是粒子退化，即大多数粒子的权重接近零。这个问题可以通过对粒子重采样来处理。新粒子从当前集合中有放回地采样，某个粒子被选中的概率与其权重成正比：

$$p(k) = w_t^k. \quad (5)$$


权重按照均匀分布更新：

$$w_t'^k = 1/K. \quad (6)$$


新的粒子集合近似相同的分布，但把表示能力集中到 belief 空间中的重要区域。注意，新集合可能包含重复粒子，但在随机转移更新后它们会分散开。

3 粒子滤波网络

粒子滤波网络 (PF-net) 把可学习的转移模型和观测模型，与粒子滤波算法一起编码在单个神经网络中 (图 1b)。PF-net 是一种带有可微算法先验的 RNN，也就是说，它具有面向序列状态估计的特定结构。PF-net



(a) 作为计算图的 PF-net。状态转移模型和观测模型由网络权重刻画，并在粒子之间共享。



(b) PF-net 观测模型。输入是楼层地图 M 、观测 o_t 和粒子状态 s_t^k 。输出是粒子似然 f_t^k 。CNN、LFC 和 FC 分别表示卷积、局部全连接和全连接网络组件。

中的可微算法先验就是粒子滤波：belief 的粒子表示，以及针对转移和观测的 Bayesian 更新。与 LSTM [36] 等通用架构相比，这些先验使学习效率高得多。

我们方法背后的核心思想，是把学习得到的模型和推断算法统一表示。模型是一个神经网络，即带有可训练参数的计算图。推断算法是一个可微程序，即由可微操作组成的计算图。模型和算法都可以编码到同一个计算图中。这样做有什么好处？与传统模型学习方法不同，PF-net 能够通过推断算法反向传播梯度，从而端到端学习模型。此时模型会针对特定推断算法和特定任务进行优化。因此，模型可能不需要捕捉复杂的条件概率分布，而只需要学习与任务相关的特征。

具体而言，PF-net 在一个计算图中编码粒子滤波步骤 (1)–(6) (图 2a)。转移模型和观测模型，即 (2) 和 (3)，是具有适当结构的可训练神经网络。学习得到的网络权重在粒子之间共享。计算图的其余部分不是学习得到的，而是实现 (1)–(6) 中的操作。重要的是，这些操作必须可微，才能允许反向传播。对于从 (2) 中的学习分布采样，以及在 (5)–(6) 中对粒子重采样，这会成为问题。

采样操作 (2) 不可微，但可以使用“重参数化技巧” [37, 38] 很容易地把它表示为可微形式。该技巧把噪声向量作为输入，并把目标分布表示为这个输入的确定性可微函数。该函数可以具有可学习参数，例如 Gaussian 的均值和方差。

粒子重采样带来另一个问题：在 (5) 中，新粒子权重被设为常数，这会产生零梯度。我们通过引入软重采样来处理这个问题。软重采样是一种基于重要性采样的可微近似。我们不是从目标分布 $p(k)$ 中采样粒子，而是从 $q(k)$ 中采样； $q(k)$ 是 $p(k)$ 与均匀分布的组合：

$$q(k) = \alpha w_t^k + (1 - \alpha)1/K, \quad (7)$$

其中 α 是权衡参数。新权重由重要性采样公式计算：

$$w_t'^k = \frac{p(k)}{q(k)} = \frac{w_t^k}{\alpha w_t^k + (1 - \alpha)1/K}. \quad (8)$$

当 $\alpha \neq 1$ 时，该操作具有非零梯度。软重采样在目标采样分布 ($\alpha = 1$) 与均匀采样分布 ($\alpha = 0$) 之间折中。它通过保持对先前粒子权重的依赖来提供非零梯度。软重采样的一个替代方案，是简单地把粒子带到下一步，而不对它们重采样。我们发现，在低不确定性设置中训练时，这是一个好策略；此时多数粒子仍接近底层真实状态。在高不确定性下，软重采样效果更好；此时多数粒子会偏离真实状态很远。

至此，我们已经在一般设置中介绍了 PF-net 架构。当把 PF-net 应用于某个具体任务时，我们必须选择状态表示，以及 T 和 Z 的网络架构。注意，训练期间和评估期间可以使用不同数量的粒子。

4 视觉定位

我们把 PF-net 应用于视觉定位（图 1）。机器人在一个此前未见过的室内环境中导航。机器人不确定自己的位置。它拥有机载相机、里程计，并接收一张示意性的 2-D 楼层地图。任务是根据传感器观测历史周期性地估计位置。形式化地，我们希望最小化均方误差：

$$\mathcal{L} = \sum_t (\bar{x}_t - x_t^*)^2 + (\bar{y}_t - y_t^*)^2 + \beta(\bar{\phi}_t - \phi_t^*)^2, \quad (9)$$

其中 $\bar{x}_t, \bar{y}_t, \bar{\phi}_t$ 和 x_t^*, y_t^*, ϕ_t^* 分别是在时间 t 的估计机器人姿态与真实机器人姿态； β 是常数参数。

挑战有三重。首先，我们必须在给定模糊观测后周期性地更新状态后验，其中后验是多模态、非 Gaussian、连续分布。PF-net 通过编码适当的可微算法先验，即粒子滤波，来处理这一挑战。

其次，我们需要构造观测模型 $Z(o_t | s_t^k; \mathbb{M})$ ，它在粒子状态 s_t^k 和楼层地图 $\mathbb{M}$ 条件下，定义相机观测 o_t 的概率。生成式观测模型很难学习：它是图像的条件分布，而这些图像展示具有不同布局、不同配置家具等的环境。PF-net 转而学习判别式模型，该模型以 s_t^k, o_t 和 $\mathbb{M}$ 为输入，以粒子似然为输出。判别式模型只需要学习与定位相关的特征。重要的是，PF-net 端到端学习判别式模型，而不需要对粒子似然进行监督。

第三，观测模型必须比较从示意性 2-D 地图和相机图像中抽取出的几何信息。对于视觉丰富的环境，这尤其困难，因为环境中的某些物体并不存在于地图中，例如家具。我们为观测模型引入具有适当结构的神经网络（图 2b）。观测模型通过适当组合地图和相机图像的特征来定义粒子似然。首先，通过仿射图像变换，从 $\mathbb{M}$ 和 s_t^k 得到一张局部地图。在神经网络实现中，我们采用 Spatial Transformer Network [39]。对每个粒子计算仿射变换矩阵 A^k ，使得变换后的地图是从姿态 s_t^k 看到的局部视图。由于这一变换，我们的网络适用于任意地图大小。接下来，我们通过分离学习的 CNN 组件，从局部地图和相机图像中分别抽取特征。特征图被拼接后，输入局部全连接层，再重塑为向量，并输入最终的全连接层。输出是一个标量 f_t^k ，即粒子状态的似然。

PF-net 的细节如下。输入为图像观测 o_t 、里程计 u_t 和地图 $\mathbb{M}$ 。输出为连续姿态 $\bar{s}_t = \{\bar{x}_t, \bar{y}_t, \bar{\phi}_t\}$ 。粒子是候选姿态 s_t^k 和权重 w_t^k 的二元组。输出是粒子的加权均值。端到端训练的损失 $\mathcal{L}$ 由 (9) 定义。观测模型和转移模型 Z 与 T 是神经网络组件。上文已经讨论观测模型。转移模型在给定里程计输入 u_t 的情况下更新粒子状态，其中 u_t 是在机器人坐标系中定义的相对运动。我们的神经网络把 u_t 变换到全局坐标系 u_t' ，并将它与 Gaussian 噪声一起加到前一姿态上。形式化地，我们从如下可微函数中采样新的粒子状态：

$$T(s_t^k | u_t', s_{t-1}^k) = s_{t-1}^k + u_t' + \text{diag}(\sigma_t, \sigma_t, \sigma_r) \mathcal{N}(0; I),$$

其中 $\mathcal{N}(0; I)$ 是来自标准多元 Gaussian 的噪声输入； σ_t 和 σ_r 分别是平移和旋转的标准差。在实验中，我们手动选择 σ_t 和 σ_r ；不过，未来也可以学习它们。

5 仿真实验

我们实现了 PF-net¹，并在室内环境中的机器人视觉定位仿真中评估它。我们与若干替代方法进行比较，以考察可微算法先验和端到端训练带来的收益。我们在多种视觉和深度传感器上评估 PF-net。最后，当机器人的初始 belief 从集中在真实姿态附近的分布，变化到在整个空间上均匀分布的 belief 时，我们在逐渐增加的不确定性水平下评估 PF-net。结果汇总于表 1。

¹我们的 Tensorflow 实现可在 <https://github.com/AdaCompNUS/pfnet> 获取。



(a) 来自 House3D 数据集的训练和测试数据样例。



(b) 标注有门和房间类型的语义地图。

5.1 实验设置

仿真。 我们在 House3D 仿真器 [19] 中进行实验。House3D 基于 SUNCG 数据集 [40] 中大量由人类设计的真实住宅建筑构建。平均而言，建筑大小为 206 m^2 ，房间大小为 37 m^2 。样例见图 3a。

任务。 我们考虑具有不同不确定性水平的定位。对于跟踪，初始 belief 集中在真实状态附近。对于全局定位，belief 在建筑中的所有房间上均匀分布。位于两者之间的是半全局定位，其 belief 在一个或多个房间上均匀分布。

传感器。 我们考虑了单目 RGB 相机、深度相机、RGB-D 相机，以及一个仿真的 2-D LIDAR。遵循早期工作 [35]，我们的仿真 LIDAR 只是把深度图像变换为 2-D 激光扫描。仿真 LIDAR 的分辨率有限，只有 54 条 beams 和 60° 视场。因此，与典型真实 LIDAR 相比，使用仿真 LIDAR 定位更困难。我们还为 LIDAR 传感器考虑了一个简化环境 LIDAR-W：移除环境中的所有家具，只留下墙体。这样，对应的楼层地图就包含了环境中的所有几何物体。

训练。 训练数据由来自 200 栋建筑的 45,000 条轨迹构成。轨迹随机生成：机器人向前移动 ($p=0.8$) 或转向 ($p=0.2$)。距离和转角分别从区间 $[20 \text{ cm}, 80 \text{ cm}]$ 与 $[15^\circ, 60^\circ]$ 均匀采样。每条轨迹长 24 步，并且每一步都标注真实机器人姿态。机器人初始 belief b_0 是一个多元 Gaussian 分布。 b_0 的中心根据零均值和协方差矩阵 $\Sigma = \text{diag}(30 \text{ cm}, 30 \text{ cm}, 30^\circ)$ 的 Gaussian，从真实姿态扰动而来； b_0 的协方差也是同一个 Σ 。这一设置对应于跟踪任务。我们训练 PF-net 和替代网络，以最小化端到端损失 (9)。训练使用基于时间的反向传播，限制为 4 个时间步。训练 PF-net 时，我们使用 $K=30$ 个粒子。训练期间没有对粒子重采样，因为对于短轨迹和集中的初始 belief，并不需要重采样。

替代方法。 我们将 PF-net 与替代网络架构进行比较，包括 histogram filter (HF) network [25] 和 LSTM network [36]。HF network 将 belief 表示为离散状态上的直方图，在本文中是一个网格，单元大小为 $40 \text{ cm} \times 40 \text{ cm}$ ，并带有 16 个方向。更细的离散化没有带来更好结果。LSTM network 依赖其 hidden state 向量来表示 belief。我们使用一种基于局部地图的网络架构，类似于 PF-net 观测模型。输出是相对状态估计，并用里程计进行更新。我们还考虑一种传统粒子滤波 (PF) 方法，它带有手工设计的解析观测模型。我们使用 ROS 的 AMCL 包中的 beam model 实现 [41]，这是 LIDAR 定位的标准模型 [31]。模型参数针对我们的仿真 LIDAR 传感器进行了调节。最后，为了校准结果，我们还考虑 Odometry-NF，它只用里程计更新 belief，而不使用其他传感输入。

评估。 我们在 47 栋此前未见过的建筑中固定的 820 条轨迹上，对跟踪、半全局定位和全局定位任务评估各方法。只要可能，对所有方法都使用相同设置以及相同模型和算法参数。我们只针对跟踪任务训练一次网络，而没有为其他任务重新训练。需要注意的是，对 PF-net 而言，执行时使用的粒子数 K 不必与训练时相同。具体而言，我们在跟踪中使用 $K=300$ 个粒子，在半全局定位中使用 $K=1,000$ ，在全局定位中使用最多 $K=3,000$ 。我们还为半全局和全局定位启用重采样。相同设置也应用于 PF 方法。对于跟踪，我们报告机器人位置的平均 root mean squared error (RMSE) (表 1a)。对于半全局和全局定位，我们报告 100 步长轨迹上的成功率 (表 1b-c)。如果一条轨迹最后 25 步的估计误差低于 1 m ，则定位成功。最后，我们在带语

表 1: 机器人视觉定位上的实验比较。

	RGB	Depth	RGB-D	LIDAR	LIDAR-W
PF-net	40.5	35.9	33.3	48.3	31.5
HF network	92.0	91.6	89.8	95.6	92.4
LSTM network	66.9	58.8	60.3	74.2	64.4
PF	—	—	—	81.3	31.3
Odometry-NF	109.4	109.4	109.4	109.4	109.4

(a) 跟踪的 RMSE (cm)。

	RGB	Depth	RGB-D	LIDAR	LIDAR-W
PF-net	82.6%	84.0%	84.3%	69.4%	86.6%
HF network	2.7%	2.9%	4.5%	1.6%	2.2%
LSTM network	21.1%	24.4%	23.4%	17.2%	22.2%
PF	—	—	—	25.1%	86.2%
Odometry-NF	1.1%	1.1%	1.1%	1.1%	1.1%

(c) 一个房间上的半全局定位成功率 (%)。

K	$N = 1$	$N = 2$	All
500	80.0%	70.5%	46.1%
1,000	84.3%	80.1%	57.9%
2,000	87.3%	84.8%	68.5%
3,000	89.0%	85.9%	76.3%

(b) 半全局和全局定位中, 带 K 个粒子的 PF-net 成功率 (%). 初始 belief 在 $N = 1$, $N = 2$ 或所有房间上均匀分布。

Labels	RGB	Depth	RGB-D
None	82.6%	84.0%	84.3%
Doors	84.4%	83.9%	84.5%
Rooms	84.5%	86.2%	86.5%
Both	84.6%	86.7%	87.2%

(d) 使用关于门、房间类型或二者的额外语义信息时, PF-net 在半全局定位上的成功率 (%).

义地图的半全局定位上评估 PF-net (表 1d)。

5.2 主要结果

PF-net 在跟踪任务中成功降低了状态不确定性 (表 1a)。无需额外训练, 当初始 belief 在一个房间上均匀分布时, PF-net 也能成功定位 (表 1b), 甚至当 belief 在整张楼层地图上均匀分布时也能定位 (表 1c)。示例见 图 4。

可微算法先验是有用的。 PF-net 一贯优于替代端到端学习架构, 即 HF network 和 LSTM network。原因是什么? PF-net 编码了专门面向序列状态估计的可微算法先验, 即 belief 的粒子表示及其 Bayesian 更新。HF network 编码了类似的 belief 更新先验, 但是它被限制在离散 belief 表示上, 而这种表示难以扩展到大的连续状态空间。LSTM network 不受离散状态空间限制, 但它没有面向概率状态估计的特定结构, 必须依赖 hidden state 向量来编码 belief。

端到端学习带来更强鲁棒性。 我们把学习得到的 PF-net 与带有已知 LIDAR 模型的 PF 进行比较 (表 1a-b 的第一行和第四行)。当环境中只有墙体时 (*LIDAR-W* 列), PF-net 和 PF 表现相近。当环境中有一些物体不在地图中时 (*LIDAR* 列), PF-net 明显更好。为什么? Beam model 没有原则性方式区分相关墙体和无关物体, 因为它把 LIDAR 扫描解耦为单独 beam。通过端到端训练, PF-net 可能学会了 beam 之间的关系, 用以区分墙体和物体。PF-net 也可能学会了处理地图不完美, 例如缺失墙体、玻璃门和我们在 House3D 数据集中偶尔观察到的各种地图伪影。

PF-net 对多种传感器有效。 表 1a-b 的各列比较了用于定位的不同传感器。使用 RGB 图像的 PF-net 几乎与使用深度图像一样有效; 而且它比使用仿真 LIDAR 时表现更好。这说明 PF-net 成功学会了从 RGB 图




图 4: 使用 PF-net ($K = 1000$) 和 RGB 相机输入进行全局定位。红色表示 ground-truth 姿态。黑色表示 PF-net 粒子。绿色表示粒子的加权均值。

像中抽取相关几何信息，并学会忽略不在地图中的物体。当组合 RGB 和深度图像输入时，即 RGB-D 列，性能进一步提升。这表明 PF-net 可以从数据中端到端学习简单的传感器融合。这个方向的未来工作很有前景。

5.3 补充实验

全局定位。 我们在逐渐增加的难度下评估学习得到的 PF-net 定位能力 (表 1c)。我们选择初始 belief 分别在一个房间、两个房间以及整栋建筑上均匀分布。我们比较了不同粒子数的 PF-net，最多到 $K = 3000$ 。结果表明，只要提供足够多粒子，PF-net 可以在高初始不确定性下解决全局定位。

语义地图。 人类经常使用带有语义信息的楼层地图：地图上有办公室、厕所、电梯和楼梯的标签。利用语义地图进行机器人定位并不简单 [35, 42]。PF-net 可以通过端到端训练自然地学会使用语义地图。为证明这一点，我们训练了带有简化语义地图的 PF-net，这些地图包含门和房间类别标签。示例见 图 3b。我们把语义标签编码到输入地图的独立通道中：一个通道用于门，8 个通道用于 8 个不同房间类别。结果表明，简单语义地图确实可以提升定位性能 (表 1d)。

消融研究。 在补充实验中，我们改变 PF-net 训练期间的某些设置，并在固定的半全局定位任务上评估学习得到的 PF-net。

首先，我们在训练期间加入软重采样。当像之前一样针对跟踪任务训练时，软重采样使成功率从 79% 降到 75%。然而，当在初始不确定性增加且里程计有噪声的设置中训练时，软重采样使成功率从 39% 提升到 42%。正如预期，当多数粒子会远离真实状态时，重采样可能有益；但当靠近真实状态的粒子被消除时，重采样会造成伤害，而这在学习早期经常发生。未来工作可以整合多种策略，只在需要时进行重采样 [43]。事实上，当每两步才重采样一次时，成功率从 42% 提升到 54%。

接下来，我们改变 BPTT 的反向传播步数。通过多个步骤反向传播可以提升性能：1、2 和 4 步分别对应 73%、79%、79% 的成功率。这说明来自未来步骤的损失可以为当前步骤提供有用的学习信号。

最后，我们用 [26] 提出的概率损失函数替换损失函数 (9)。在标准跟踪设置中训练时，替代损失函数效果更差，成功率为 74%，而原损失为 79%。然而，在不确定性增加的训练设置中，替代损失函数效果更好，成功率为 67%，而原损失为 39%。我们的损失可能被远离真实状态的粒子主导，这在后一种情况下可能对学习产生负面影响。

6 结论与未来工作

我们提出了 PF-net，这是一种带有序列状态估计可微算法先验的神经网络架构。PF-net 把学习得到的概率模型与粒子滤波算法一起编码在一个可微网络表示中。我们把 PF-net 应用于地图上的机器人定位。通过端到端训练，PF-net 成功学会在具有挑战性的、此前未见过的环境中定位，而这些环境包含地图上没有显示的物体。

未来工作可以把 PF-net 应用于真实世界定位，这是移动机器人应用中非常重要的问题。一个关注点是在线执行。使用 RGB 输入时，PF-net 每个粒子每一步大约需要 0.6ms。具有高不确定性的室内定位可能需要多达 1,000–10,000 个粒子 [8]。我们可以通过整合粒子滤波的标准技术来提升鲁棒性并使用更少粒子，例如注入粒子和自适应重采样 [43]。我们也可以利用大量关于神经网络模型和硬件优化的工作 [44] 来提升推断时间。最后，学习得到的 PF-net 模型可以用于标准粒子滤波，因此视觉传感器可以成为激光的补充，并且可能以较低更新频率工作。

PF-net 还可以应用于其他领域，例如视觉目标跟踪和 SLAM。一个令人兴奋的未来方向，是扩展 PF-net，使其学习用于滤波的潜在状态表示，并可能在无监督设置中完成。最后，belief 的粒子表示对于在神经网络中编码更复杂的算法也可能很重要，例如用于部分可观测条件下的规划。

致谢

本研究部分得到新加坡教育部资助 MOE2016-T2-2-068 的支持。Peter Karkus 得到 NUS Graduate School for Integrative Sciences and Engineering Scholarship 的支持。

参考文献

- [1] A. Doucet, N. De Freitas, and N. Gordon. An introduction to sequential monte carlo methods. In *Sequential Monte Carlo methods in practice*, pages 3–14. Springer, 2001.
- [2] S. Thrun. Particle filters in robotics. In *Proceedings of the Eighteenth conference on Uncertainty in artificial intelligence*, pages 511–518. Morgan Kaufmann Publishers Inc., 2002.
- [3] A. Blake and M. Isard. The condensation algorithm-conditional density propagation and applications to visual tracking. In *Advances in Neural Information Processing Systems*, pages 361–367, 1997.
- [4] B. Ristic, S. Arulampalam, and N. Gordon. *Beyond the Kalman filter: Particle filters for tracking applications*. Artech house, 2003.
- [5] P. Del Moral, A. Doucet, and A. Jasra. Sequential monte carlo samplers. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 68(3):411–436, 2006.
- [6] J. S. Liu. *Monte Carlo strategies in scientific computing*. Springer Science & Business Media, 2008.
- [7] A. Doucet, N. De Freitas, and N. Gordon. *Sequential monte carlo methods in practice*. series statistics for engineering and information science, 2001.
- [8] S. Thrun, D. Fox, W. Burgard, and F. Dellaert. Robust monte carlo localization for mobile robots. *Artificial intelligence*, 128(1-2):99–141, 2001.

- [9] M. Montemerlo, S. Thrun, D. Koller, B. Wegbreit, et al. Fastslam: A factored solution to the simultaneous localization and mapping problem. *Aaai/iaai*, 593598, 2002.
- [10] N. Ye, A. Somani, D. Hsu, and W. S. Lee. Despot: Online POMDP planning with regularization. *Journal of Artificial Intelligence Research*, 58:231–266, 2017.
- [11] G. Shani, R. I. Brafman, and S. E. Shimony. Model-based online learning of POMDPs. In *European Conference on Machine Learning*, pages 353–364, 2005.
- [12] B. Boots, S. M. Siddiqi, and G. J. Gordon. Closing the learning-planning loop with predictive state representations. *The International Journal of Robotics Research*, 30(7):954–966, 2011.
- [13] L. Getoor, N. Friedman, D. Koller, and B. Taskar. Learning probabilistic models of link structure. *Journal of Machine Learning Research*, 3(Dec):679–707, 2002.
- [14] A. Tamar, S. Levine, P. Abbeel, Y. Wu, and G. Thomas. Value iteration networks. In *Advances in Neural Information Processing Systems*, pages 2146–2154, 2016.
- [15] P. Karkus, D. Hsu, and W. S. Lee. QMDP-net: Deep learning for planning under partial observability. In *Advances in Neural Information Processing Systems*, pages 4697–4707, 2017.
- [16] J. Oh, S. Singh, and H. Lee. Value prediction network. In *Advances in Neural Information Processing Systems*, pages 6120–6130, 2017.
- [17] G. Farquhar, T. Rocktäschel, M. Igl, and S. Whiteson. TreeQN and ATreeC: Differentiable tree planning for deep reinforcement learning. *arXiv preprint arXiv:1710.11417*, 2017.
- [18] B. Amos and J. Z. Kolter. Optnet: Differentiable optimization as a layer in neural networks. In *International Conference on Machine Learning*, pages 136–145, 2017.
- [19] Y. Wu, Y. Wu, G. Gkioxari, and Y. Tian. Building generalizable agents with a realistic and rich 3d environment. *arXiv preprint arXiv:1801.02209*, 2018.
- [20] A. Guez, T. Weber, I. Antonoglou, K. Simonyan, O. Vinyals, D. Wierstra, R. Munos, and D. Silver. Learning to search with MCTSnets. *arXiv preprint arXiv:1802.04697*, 2018.
- [21] M. Okada, L. Rigazio, and T. Aoshima. Path integral networks: End-to-end differentiable optimal control. *arXiv preprint arXiv:1706.09597*, 2017.
- [22] P. Donti, B. Amos, and J. Z. Kolter. Task-based end-to-end model learning in stochastic optimization. In *Advances in Neural Information Processing Systems*, pages 5484–5494, 2017.
- [23] T. Shankar, S. K. Dwivedy, and P. Guha. Reinforcement learning via recurrent convolutional neural networks. In *International Conference on Pattern Recognition*, pages 2592–2597, 2016.
- [24] T. Haarnoja, A. Ajay, S. Levine, and P. Abbeel. Backprop kf: Learning discriminative deterministic state estimators. In *Advances in Neural Information Processing Systems*, pages 4376–4384, 2016.
- [25] R. Jonschkowski and O. Brock. End-to-end learnable histogram filters. In *Workshop on Deep Learning for Action and Interaction at NIPS*, 2016.
- [26] R. Jonschkowski, D. Rastogi, and O. Brock. Differentiable particle filters: End-to-end learning with algorithmic priors. *arXiv preprint arXiv:1805.11122*, 2018.

- [27] C. A. Naesseth, S. W. Linderman, R. Ranganath, and D. M. Blei. Variational sequential monte carlo. *arXiv preprint arXiv:1705.11140*, 2017.
- [28] C. J. Maddison, J. Lawson, G. Tucker, N. Heess, M. Norouzi, A. Mnih, A. Doucet, and Y. Teh. Filtering variational objectives. In *Advances in Neural Information Processing Systems*, pages 6576–6586, 2017.
- [29] T. A. Le, M. Igl, T. Rainforth, T. Jin, and F. Wood. Auto-encoding sequential monte carlo. In *Proceedings of the 6th International Conference on Learning Representations (ICLR)*, 2018.
- [30] S. Gu, Z. Ghahramani, and R. E. Turner. Neural adaptive sequential monte carlo. In *Advances in Neural Information Processing Systems*, pages 2629–2637, 2015.
- [31] S. Thrun, W. Burgard, and D. Fox. *Probabilistic robotics*. MIT press, 2005.
- [32] F. Dellaert, W. Burgard, D. Fox, and S. Thrun. Using the condensation algorithm for robust, vision-based mobile robot localization. In *Computer Vision and Pattern Recognition, 1999. IEEE Computer Society Conference on.*, volume 2, pages 588–594. IEEE, 1999.
- [33] P. Elinas and J. J. Little. σ mcl: Monte-carlo localization for mobile robots with stereo vision. In *Proc. of Robotics: Science and Systems (RSS)*, 2005.
- [34] B. Coltin and M. Veloso. Multi-observation sensor resetting localization with ambiguous landmarks. *Autonomous Robots*, 35(2-3):221–237, 2013.
- [35] O. Mendez, S. Hadfield, N. Pugeault, and R. Bowden. Sedar-semantic detection and ranging: Humans can localise without lidar, can robots? *arXiv preprint arXiv:1709.01500*, 2017.
- [36] S. Hochreiter and J. Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [37] D. P. Kingma and M. Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- [38] C. Doersch. Tutorial on variational autoencoders. *arXiv preprint arXiv:1606.05908*, 2016.
- [39] M. Jaderberg, K. Simonyan, A. Zisserman, et al. Spatial transformer networks. In *Advances in neural information processing systems*, pages 2017–2025, 2015.
- [40] S. Song, F. Yu, A. Zeng, A. X. Chang, M. Savva, and T. Funkhouser. Semantic scene completion from a single depth image. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 190–198, 2017.
- [41] M. Quigley, K. Conley, B. Gerkey, J. Faust, T. Foote, J. Leibs, R. Wheeler, and A. Y. Ng. Ros: an open-source robot operating system. In *ICRA workshop on open source software*, 2009.
- [42] O. Mozos and W. Burgard. Supervised learning of topological maps using semantic information extracted from range data. In *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2006.
- [43] A. Doucet and A. M. Johansen. A tutorial on particle filtering and smoothing: Fifteen years later. *Handbook of nonlinear filtering*, 12(656-704):3, 2009.
- [44] V. Sze, Y.-H. Chen, T.-J. Yang, and J. S. Emer. Efficient processing of deep neural networks: A tutorial and survey. *Proceedings of the IEEE*, 105(12):2295–2329, 2017.