

DouZero+: 通过对手建模与教练引导学习改进斗地主 AI

Youpeng Zhao, Jian Zhao, Xunhan Hu, Wengang Zhou, Houqiang Li,

摘要—近年来, 深度强化学习 (DRL) 在多种完全信息和不完全信息游戏中取得了重大突破。在这些游戏中, 斗地主是中国流行的纸牌游戏, 由于不完全信息、大状态空间、协作要素, 以及每一轮可能动作数量巨大, 它对 AI 构成了很强挑战。最近, 一个名为 DouZero 的斗地主 AI 系统被提出。DouZero 使用传统 Monte Carlo 方法、深度神经网络和自博弈流程进行训练, 不依赖人类先验知识抽象, 并且已经超过了现有所有斗地主 AI 程序。在本文中, 我们提出通过把对手建模引入 DouZero 来增强 DouZero。此外, 我们提出一种新的教练网络, 以进一步提升 DouZero 的性能并加速其训练过程。将上述两项技术整合进 DouZero 后, 我们的斗地主 AI 系统获得了更好的性能, 并在 Botzone 排行榜上超过包括 DouZero 在内的 400 多个 AI 智能体, 排名第一。

关键词—斗地主, 强化学习, Monte Carlo 方法, 对手建模, 教练网络

1. 引言

在人工智能的发展过程中, 游戏常常作为重要测试平台, 因为游戏是许多真实世界问题的良好抽象; 同时, 由于游戏是为人类开发的, 与专门为测试 AI 而设计的环境相比, 它们也更加客观。近年来, 在求解围棋 [1]–[3]、将棋 (日本象棋) [4] 甚至格斗游戏 [5] 等完全信息游戏方面已经取得显著进展。当前研究努力正在转向更具挑战性的不完全信息游戏 (IIG), 在这类游戏中, 智能体可能在部分可观测环境下彼此合作或竞争。从简单的 Leduc Hold'em 和限注/无限注 Texas Hold'em [6]–[9] 等双人游戏, 到多人 Texas Hold'em [10]、StarCraft [11]、DOTA [12] 和日本麻将 [13] 等多人游戏, 研究者已经取得了令人鼓舞的成果。

本文致力于为斗地主 (又称 Fighting the Landlord) 设计一个 AI 程序。斗地主是中国最流行的纸牌游戏, 拥有数以亿计的日活跃玩家。斗地主有两个有趣特征, 这些特征给 AI 程序带来了巨大挑战。第一, 该游戏在部分可观测环境中同时包含合作与竞争。具体而言, 两个农民智能体组成团队, 对抗地主智能体。例如, 图 1 展示了一个典型局面: 下方农民可以打出一张较小的单牌, 帮助其队友获胜。这一性质使得扑克游戏中常用的 Counterfactual Regret Minimization (CFR) [14] 及其变体并不适合这种复杂的三人设定。第二, 与其他纸牌游戏相比, 斗地主由于牌型组合和复杂规则而具有庞大且复杂的状态空间和动作空间。可能的牌型组合有数千种, 而不同手牌对应的合法组合子集并不相同。图 2 展示了一个手牌示例, 它包含 119 个合法动作, 包括单牌、对子、三张、单顺等。不同于 Texas Hold'em, 斗地主中的动作无法轻易抽象, 这使得搜索计算代价高昂, 也使常用强化学习 (RL) 算法效果较差。Deep




图 1: 斗地主中关于合作的一个示例。如果农民学会彼此合作, 当前玩家应打出较小的单牌, 让队友赢得游戏。

119 Legal Combinations




图 2: 一手牌及其对应的合法动作。

Q-Learning (DQN) [15] 的性能会因大动作空间中的过估计问题 [16] 而受到严重影响; 而 A3C [17] 等策略梯度方法无法利用动作特征, 限制了其泛化到未见动作的能力。由此, 已有工作表明, 即使训练二十天, DQN 和 A3C 在斗地主中对简单规则智能体的胜率也低于 20% [18]。

尽管存在上述挑战, 构建斗地主 AI 方面仍取得了一些成果。为处理斗地主中的大动作空间, Combinatorial Q-Network (CQN) [18] 将动作拆分为分解选择和最终出牌选择。然而, 分解选择依赖人类启发式, 并且耗时较高, 这限制了其性能。事实上, CQN 相比启发式规则模型并没有优势。DeltaDou [19] 是第一个相对于人类专家达到顶尖人类水平表现的 bot。它使用一种类似 AlphaZero 的算法, 将神经网络、Fictitious Play Monte Carlo Tree Search (FPMCTS) 和自博弈流程中的推断算法结合起来。然而, DeltaDou 基

Y. Zhao, J. Zhao, X. Hu, W. Zhou 和 H. Li 任职于中国科学技术大学电子工程与信息科学系、中国科学院电磁空间信息处理与应用系统技术重点实验室, 中国合肥 230027。

W. Zhou 和 H. Li 同时任职于合肥综合性国家科学中心人工智能研究院, 中国合肥。

于启发式规则预训练一个 kicker network 来缩小动作空间, 如果该 kicker network 的输出不是最优, 这可能对其强度产生负面影响。此外, 推断和搜索的计算代价很高, 完成 DeltaDou 的训练需要两个月。最近, DouZero [20] 由于在这一复杂游戏中的优秀表现而受到广泛关注。它使用自博弈深度强化学习, 不对状态/动作空间做抽象, 也不使用人类知识。它将经典 Monte Carlo 方法 [21] 与深度神经网络结合, 以处理大状态空间和大动作空间, 为这类复杂大规模游戏打开了另一扇门。

在本文中, 我们通过引入对手建模和教练引导学习来改进 DouZero。对手建模旨在为对手隐藏手牌确定一个可能的概率分布, 其动机来自这样一个事实: 人类玩家会尝试预测对手手牌, 以帮助自己决定策略。由于斗地主的复杂性, 在做决策时可能有许多动作都是合适的。在这种情况下, 分析对手手牌非常重要, 因为掌握这类信息有助于 bot 选择最优动作。另一方面, 我们提出教练引导学习来加快 AI 的训练。由于该游戏的信息空间很大, 训练斗地主 AI 程序需要花费大量时间。考虑到斗地主的胜负很大程度上取决于三名玩家的初始手牌, 许多对局对学习价值较低。为此, 我们设计了一个新的教练网络, 均衡地挑选实力匹配的开局, 使模型能够从更有价值的数据中学习, 而不浪费时间进行无价值对局, 从而加速训练过程。将这些技术整合进 DouZero 后, 我们的斗地主 AI 程序表现优于原始 DouZero, 并在 Botzone [22]–[24] 排行榜上超过包括 DouZero 在内的 400 多个智能体, 排名第一。

II. 相关工作

本节简要介绍强化学习在不完全信息游戏中的应用, 以及关于对手建模的相关工作。

A. 面向不完全信息游戏的强化学习

近年来, 强化学习已成功应用于一些复杂的不完全信息游戏。例如, 关于扑克游戏的强化学习已有不少工作 [7], [25], [26]。不同于依赖游戏树遍历的 Counterfactual Regret Minimization (CFR) [14], RL 基于采样, 因此可以更容易地泛化到大规模游戏。因此, OpenAI、DeepMind 和 Tencent 分别利用这一技术构建了 DOTA [12]、StarCraft [11] 和王者荣耀 [27] 的游戏 AI, 并取得了惊人成果, 证明了强化学习在不完全信息游戏中的有效性。更近一些, 有研究尝试将强化学习与搜索结合, 并在单挑无限注 Texas Hold'em poker 和斗地主等扑克游戏中展示了其有效性 [19], [28]。

然而, 正如前文所讨论, 由于斗地主的复杂性, DQN [15] 和 A3C [17] 等传统强化学习方法在该游戏中表现较差。即便是改进方法, 例如 Combinatorial Q-Network, 也未能取得令人满意的表现。此外, DeltaDou [19] 会推断隐藏信息, 并使用 MCTS 将 RL 与搜索结合, 但它计算代价高昂且依赖人类专业知识, 从而限制了其实用性和性能。为此, DouZero [20] 使用 Monte Carlo 方法 [21], 目前已经成功击败所有斗地主 AI 程序。我们注意到, 该技术也被一些其他游戏 AI 采用, 例如现代桌游 Kingdomino 和一种新棋类 Tibetan Jiuqi [29], [30]。但不同于这些环境, 斗地主是一个复杂的不完全信息游戏, 需要在大状态空间和大动作空间上同时处理竞争与合作。DouZero 的出色表现揭示了 Monte Carlo 方法在此类大规模复杂纸牌游戏中的良好

效果, 并为未来处理复杂动作空间、稀疏奖励和不完全信息的研究提供了新洞见。

B. 游戏中的对手建模

在人类实践中, 获得对手的抽象描述会让玩家在游戏中获得明显优势, 尤其是在不完全信息游戏中。因此, 对手建模在游戏 AI 中受到了大量关注。例如, Southey *et al.* [31] 提出了一个用于扑克游戏的 Bayesian 概率模型, 该模型推断对手策略的后验分布, 并针对该分布做出适当响应。在另一个复杂不完全信息游戏麻将中, 有一种 AI bot 基于对手建模和 Monte Carlo simulation 设计 [32]。在这项工作中, 对手模型使用专家对局记录训练, bot 使用预测结果和 Monte Carlo simulation 来决定动作。此外, Schadd *et al.* [33] 提出了一种用于 RTS 游戏中对手建模的方法。它采用层次化结构模型来分类对手策略, 其中顶层可以区分对手的一般风格, 底层可以分类定义对手行为的具体策略。

最近, 受强化学习成功的启发, 许多研究者将对手建模与强化学习结合, 并取得了很大进展。结合 Deep Q-learning 后, 对手建模在模拟足球游戏和流行问答游戏中取得了优于 DQN 及其变体的表现 [34]。Knegt *et al.* [35] 将对手建模技术引入一个使用强化学习的街机电子游戏, 帮助智能体预测对手动作, 并显著提升智能体表现。此外, 对手建模可以用于多智能体强化学习问题, 在这类问题中, RL 智能体被设计为在更新自身策略时考虑环境中其他智能体的学习 [36]。另一个有前景的方案是通过结合专家玩家使用的对手模型和强化学习来模仿人类玩家 [37]。上述工作都表明, 将对手建模与强化学习结合有助于在多智能体不完全信息游戏中获得性能提升, 这也启发了本文工作。

III. 预备知识

本节首先讨论 DouZero 的主要算法, 即 Deep Monte Carlo (DMC), 它使用深度神经网络作为函数近似器来推广 Monte Carlo (MC) 方法。随后, 我们简要描述 DouZero 系统的细节。

作为强化学习中的关键技术, Monte Carlo (MC) 方法从经验中学习价值函数和最优策略, 也就是从与环境的实际或模拟交互中采样状态、动作和奖励序列 [21]。这一技术面向回合式任务, 其中经验可以划分为最终会终止的回合, 并且只在一个回合完成后才更新价值估计和策略。具体来说, 每个回合结束后, 观测到的回报会用于策略评估, 随后可以在该回合中访问过的状态上改进策略。为了使用 MC 方法优化策略 π , 其过程可以直观描述如下:

- 1) 使用 π 生成一个回合。
- 2) 对该回合中访问过的每个状态-动作对 (s, a) , 用平均回报计算并更新 $Q(s, a)$ 。
- 3) 对该回合中的每个状态 s , 更新策略: $\pi(s) \leftarrow \operatorname{argmax}_{\mathbf{a} \in \mathcal{A}} Q(s, \mathbf{a})$ 。

在实践中使用 MC 方法时, 我们可以在步骤 1 中使用 epsilon-greedy 来平衡探索和利用。此外, 上述过程可以自然地与深度神经网络结合, 从而得到 Deep Monte-Carlo (DMC)。这样, 在步骤 2 中, Q-table $Q(s, a)$ 可以被神经网络替代, 并通过均方误差 (MSE) 损失进行优化。

由于斗地主是一个典型回合式任务, MC 自然适合这一问题。此外, DMC 需要大量经验进行训练, 而并行高效生成数据比较容易, 这也可以缓解方差问题。再者, 与策




图 3: 将对手建模与 DouZero 结合的框架总览, 以及预测模型的细节。预测模型以与 DouZero 相同的状态信息作为输入, 并输出下一名智能体手中每种牌数量的概率。决策模型像 DouZero 一样使用 Deep Monte-Carlo 算法训练。关于下一名玩家手牌的预测结果会与状态特征和动作特征拼接在一起, 所有这些信息共同输入决策模型, 以决定采取哪个动作。对于预测模型, 它可以被视为一个多头分类器, 由一层用于编码历史动作的 LSTM、五层共享 MLP 和多头全连接层组成, 用于输出概率。我们可以从状态信息中提取“合法标签”, 它表示下一名玩家每种牌最多拥有多少张, 以帮助过滤不可能的答案。

略梯度方法和 Deep Q-learning 等其他强化学习算法相比, 在斗地主中采用 DMC 有一些明确优势, 相关内容可参见 DouZero [20]。由于 DMC 在斗地主中的这些优势, DouZero 采用了这一算法, 并获得了优秀性能。

在 DouZero 系统的实现中, 它使用自博弈流程: actors 进行游戏以生成样本, learner 则使用这些数据更新网络。网络输入由状态特征和动作特征组成。状态特征表示玩家已知的信息, 而动作特征描述当前状态下对应的合法出牌。具体来说, 动作特征中的动作被编码为 one-hot 的 4×15 牌矩阵。对于状态特征, 它们包含表示手牌、其他玩家手牌并集、其他玩家已出牌、最近若干动作的牌矩阵, 以及表示其他玩家剩余手牌数量和当前已出炸弹数量的一些 one-hot 向量。就网络结构而言, 一层 LSTM 用于编码历史动作, 其输出与其他状态/动作特征拼接。随后使用六层隐藏维度为 512 的 MLP 产生 Q 值。

此外, 该系统用多个 actor 进程和一个 learner 进程并行化 DMC。learner 为三个位置维护三个全局网络, 并基于 actor 进程生成的数据样本更新这些网络以近似目标值。每个 actor 维护三个本地网络, 并周期性地与全局网络同步。learner 与 actors 之间的通信通过三个共享经验缓冲区实现。由此, 系统可以在有效的自博弈流程中进行训练。

IV. 方法

本节介绍我们设计中的对手建模和教练网络, 并描述它们如何被应用。

A. 对手建模

对手建模研究的是构造模型以预测被建模智能体的各种属性, 例如动作、目标等。策略重构 [38] 和计划识别 [39] 等经典方法倾向于为智能体行为开发参数化模型。这些方法往往将被建模智能体与其他智能体之间的交互解耦, 以简化建模过程; 但当智能体交互之间存在耦合时, 这可能引入偏差。因此, 在自博弈流程中并发训练所有智能体时执行对手建模更加自然 [40], 也更适合斗地主 AI 系统的




图 4: 使用教练网络的框架总览。在图中, 我们用 $Card_{initial}$ 、 P_{win} 和 β 分别表示生成的初始手牌、地主获胜的预测概率和阈值。教练网络由一个嵌入层和若干全连接层组成, 模型以 $Card_{initial}$ 作为输入并输出 P_{win} 。如果 P_{win} 位于由 β 决定的给定范围内, 则使用该 $Card_{initial}$ 的游戏会继续进行并生成训练样本。否则, 将重新生成另一组初始手牌。

训练过程。此外, 并发学习有助于对手建模适应智能体的不同水平, 因为它见证了训练过程中智能体技能的演化。

在斗地主中采用对手建模时, 我们预测当前智能体后手玩家的手牌, 使模型能够据此做出决策。在对手建模的实现上, 我们可以自然地利用深度神经网络进行预测。为避免与选择出牌动作的网络混淆, 我们把对手建模部分称为“预测模型”, 把做决策的部分称为“决策模型”。遵循 DouZero 为游戏中三个玩家训练三个模型的做法, 我们也为对手建模训练三个预测模型。预测模型可以被视为一个多头分类器, 输出下一名智能体手中每种牌数量的概率。具体而言, 它必须预测下一名玩家手中有多少张点数为 3 的牌、多少张点数为 4 的牌, 等等。由于斗地主环境容易实现, 我们可以获得下一名玩家的真实手牌, 并用它作为标签来训练预测模型。此外, 以点数为 3 的牌为例, 我们还可以知道下一名玩家最多拥有多少张 3; 这一信息可以根据智能体自己的手牌以及已经打出多少张 3 计算得到。我们把这一信息称为“合法标签”, 它可以用于帮助训练预

测模型，因为它可以过滤掉错误答案。

对于预测模型的输入，我们使用与 DouZero 相同的状态特征。预测模型的架构也类似 DouZero：用一层 LSTM 编码历史动作，并使用五层共享 MLP。最后一层作为多头分类器，其中每个输出头对应一个全连接层，并输出一种牌的预测。该模型使用交叉熵损失函数训练。对于决策模型，所使用的特征也类似 DouZero，只是状态信息中额外包含下一名玩家手牌的预测。为简单起见，我们只是将预测结果和原始状态特征拼接起来，作为决策模型的状态输入。总之，将对手建模与 DouZero 结合的框架总览如图 3 所示。

B. 教练引导学习

在训练斗地主 AI 系统时，我们发现训练过程耗时很长。为此，我们提出一种方法帮助智能体更快掌握技巧。在本文中，我们的斗地主 AI 系统没有叫牌阶段，因为 DouZero 中的叫牌网络是用监督学习训练的。换句话说，游戏开始时三名玩家的初始手牌是固定的。然而，作为一种跑牌类游戏，玩家目标是在其他人之前清空自己手中所有牌，初始手牌质量会对游戏结果产生很大影响。如果某名玩家一开始拿到很强的牌，只要不犯严重错误就能轻易获胜。这样的初始牌对学习价值很低，因为它们几乎无法帮助智能体学习新知识。另一方面，如果一名玩家总是进行初始手牌相对均衡的对局，那么一旦做出任何不合适决策，他就会失败并收到负奖励，因此他能够更快、更好地学习一些技巧。在 DouZero 的设定中，我们发现三名玩家的初始牌是随机生成的，因此相当多样本的牌力可能并不匹配。然而，行动器仍必须使用这些严重不均衡的初始牌进行游戏，这同样耗费很多时间。如果我们只允许行动器基于均衡的初始手牌生成样本，智能体就可以更快学习，并形成能够处理这类局面的策略。

基于上述讨论，我们提出一个教练网络，用于识别初始手牌在强度上是否均衡。它以三名玩家的初始手牌作为输入，并输出一局游戏中地主获胜的预测概率，我们称其为 P_{win} 。随后可以设置一个用 β 表示的阈值，过滤掉 P_{win} 过小或过大的游戏。在这种情况下，行动器无需使用这些初始手牌进行游戏，从而可以腾出时间开展更有价值的对局。

教练网络的输入是地主和农民初始手牌的向量，其维度分别为 20 和 17。就教练网络架构而言，它由一个用于处理输入向量的嵌入层和若干全连接层组成，以提取表示并做出预测。由于我们的斗地主 AI 系统以自博弈方式训练，教练网络也与决策模型并发训练。自博弈游戏的结果可以作为训练该模型的标签。考虑到 AI 系统是从零开始学习，阈值一开始设为 0，并在训练过程中逐步增大。此外，由于该模块与斗地主中的位置无关，我们只需要训练一个教练网络用于预测。换句话说，我们的教练网络只在一局游戏开始时工作，用于挑选合适的初始数据，并不影响后续过程。因此，这一思想也可以迁移到其他类似游戏 AI 的开发中，并使训练受益。

V. 实验

本节进行实验，以证明我们引入 DouZero 的改进是有效的。具体来说，我们首先分别评估对手建模和教练网络的性能，然后将二者结合起来。所有实验都在一台配




图 5: 能够看到下一名玩家手牌的“开图”模型和 DouZero 模型的 ADP。两类模型都使用以 ADP 训练的 DouZero 基线进行测试。“Landlord”表示这些模型作为地主，对抗 DouZero 基线的农民；反向设置同理。

备 4 个 Intel(R) Xeon(R) Gold 6252 CPU @ 2.10GHz 和 GeForce RTX 2080Ti GPU 的服务器上运行。我们的代码可从 <https://github.com/submit-paper/Doudizhu> 获取。

A. 实验设置

可剥削度是扑克游戏中常用的策略强度度量 [41]。然而，斗地主巨大的状态空间和动作空间使可剥削度难以计算，更不用说该游戏有三名玩家，这进一步增加了评估难度。为了评估模型性能，我们按照 DouZero [20] 和 Deltadou [19] 的做法，启动包含地主和农民两个对立阵营的锦标赛。具体而言，对于两个竞争算法 A 和 B，它们首先在给定牌局下分别扮演地主和农民。随后我们交换双方位置，即 A 扮演地主、B 扮演农民，并再次使用同一副牌进行游戏。为展示模型在训练过程中的性能，我们每 30 分钟执行一次 10000 个回合的测试。由于我们的斗地主 AI 基于 DouZero，我们只比较它们之间的性能。我们使用 DouZero 的开源模型作为对手。为了展示改进效果，我们还复现了原始 DouZero，以直观呈现性能差异。至于评估指标，我们也遵循 DouZero，使用胜率 (WP) 和平均分差 (ADP)。具体来说，WP 表示算法 A 获胜的游戏数量除以总游戏数量。ADP 表示算法 A 与 B 之间每局得分差的平均值，其中基础分为 1，每个炸弹会使分数翻倍。

我们的实现基于 DouZero，行动器数量和训练超参数等训练日程保持与默认设置相同。由于斗地主环境由我们自己实现，奖励也需要定义。定义奖励时可以使用 WP 和 ADP 这两个评估指标。对于 WP，智能体赢得一局游戏时获得 +1 奖励，否则获得 -1 奖励；而在 ADP 设置中，ADP 可以直接用作奖励。DouZero 提供两类模型，分别使用 WP 和 ADP 训练。为简单起见，我们使用 ADP 作为目标训练我们的 AI 系统，并将其与对应基线比较。同时，我们在评估模型性能时也使用 ADP 指标。

B. 对手建模评估

在这一部分，我们证明将对手建模引入斗地主的有效性。由于 DouZero 使用的状态特征包含所有可知信息，下一名玩家手牌的信息被隐式包含其中，而对手建模的思想本质上是显式化这类信息。为了研究这一思想是否有助于智能体更好学习，我们首先做一个预实验：直接将下一名玩家




图 6: 将对手建模与 DouZero 结合的模型, 以及 DouZero 模型的 ADP。两类模型都使用以 ADP 训练的 DouZero 基线进行测试。“Landlord”表示这些模型作为地主, 对抗 DouZero 基线的农民; 反向设置同理。




图 7: 将教练网络与 DouZero 结合的模型, 以及 DouZero 模型的 ADP。两类模型都使用以 ADP 训练的 DouZero 基线进行测试。“Landlord”表示这些模型作为地主, 对抗 DouZero 基线的农民; 反向设置同理。

的手牌加入状态特征, 其结果如图 5 所示。可以观察到, 将下一名玩家的手牌加入状态特征确实提升了智能体表现, 尤其是农民的表现。我们认为, 农民的明显提升归因于这样一个事实: 知道下一名玩家手牌不仅帮助农民选择地主接不起的牌, 也帮助其更好地与队友合作。相反, 对于地主来说, 知道下一名玩家手牌确实有助于决策, 但如果手牌较弱, 仅有这类信息也帮不了太多。总之, 预实验结果说明, 引入下一名玩家手牌的显式表示能够提升斗地主 AI 的性能。

在验证我们想法的有效性后, 我们按照第 IV-A 节的讨论并发训练预测模型和决策模型, 结果如图 6 所示。结果表明, 将对手建模引入 DouZero 主要提升了农民模型的性能, 这与上述分析一致。尽管这些模型一开始表现差于 DouZero, 因为网络需要输入更多特征并具有更多神经元, 这会减慢学习速度; 但经过足够训练后, 它们成功掌握了更多知识, 并获得优于 DouZero 的性能。

C. 教练网络评估

除上述实验外, 我们还进行实验来展示“教练网络”在斗地主游戏中的表现。训练流程见第 IV-B 节, 阈值 β 的上限被设置为 0.3。实验结果如图 7 所示, 显著提升证明了该方法的有效性。可以观察到, 农民的提升也大于地主。

考虑到农民由于合作而在该游戏中具有优势, 这一现象是可以接受的, 因为他们可以在均衡对局中学到更多技巧。此外, 这种教练引导学习策略只控制游戏初始状态, 而结果展示了它能够带来的显著提升。这一事实说明, 运气因素在这类不完全信息游戏中扮演重要角色。换句话说, 我们的方法可以迁移到其他环境中, 帮助游戏 AI 获得更好表现。

此外, 我们还展示了 Botzone 平台上若干对局中教练网络预测的案例, 如表 1 所示。在案例 1 中可以观察到, 地主被分配到非常强的手牌, 其中包含大多数高等级牌, 以及能够组成其他组合的低等级牌, 因此地主可以轻松获胜。对于案例 2, 尽管地主手中有炸弹, 农民的手牌也很强。更糟糕的是, 地主还有不少难以打出的低等级牌。在案例 3 中, 初始手牌相对均衡。然而, 农民最终赢得了游戏, 这说明合作的重要性。该例子表明, 均衡样本确实可以帮助智能体更好地学习谨慎策略和合作, 从而证明我们想法的正确性。

D. 两种方法的结合

由上述讨论可知, 我们的两项改进都能帮助增强 DouZero 的性能。将这两种方法结合的结果如图 8 所示。由于“教练网络”的提升比对手建模更明显, 为了直观展示这两项技术的结合是否带来进一步改进, 我们还在图中加入了仅使用“教练网络”的结果。可以观察到, 性能一开始略差于仅使用教练网络, 这与仅引入对手建模时的讨论一致。需要说明的是, 当模型性能达到一定水平后, 取得一点改进都会非常困难, 因此两种方法结合所取得的进展并不那么明显。然而, 进一步提升仍证明了两种方法结合的有效性。

为全面比较我们的斗地主 AI 性能, 我们将最终模型上传到 BotZone [23], 这是一个带有斗地主竞赛的在线平台。除斗地主外, 该平台还支持围棋、麻将、象棋等 20 多种游戏。该平台上有 3500 多名用户上传 bot 程序, 与选定游戏中的其他 bot 竞争。Botzone 为每个游戏维护排行榜, 通过 Botzone Elo 系统的 Elo 评分对所有 bot 排名。在斗地主的 Botzone Elo 中 (平台上名为“FightTheLandlord”), 每局游戏由两个 bot 进行, 其中一个扮演地主, 另一个扮演农民。同时进行一对游戏, 两个 bot 扮演不同角色, 并且初始手牌也保持不变。尽管 Elo 评分通常被认为是一种稳定的相对强度度量, 但由于斗地主高方差的性质, Botzone 上的斗地主 Elo 排名存在一定流动性。此外, 受服务器资源限制, Elo 评分对局的安排并不频繁。一个 bot 平均每天进行少于 10 局 Elo 评分对局, 因此可能需要很长时间才能获得稳定排名。然而, 保持较高排名仍能证明一个 AI 系统的强度。即使 DouZero 相比其他用强化学习训练的斗地主 AI 系统具有明显优势, 但截至目前它在 Botzone 排行榜上大约排名第 20, 因为大多数 bot 由强启发式规则实现。尽管如此, 我们的斗地主 AI 一直排名前五, 甚至连续数月排名第一, 证明了我们所做改进的有效性。

VI. 结论与未来工作

在本文中, 我们对当前最先进的斗地主 AI 程序 DouZero 提出了一些改进。受人类玩家在实践中预测对手手牌的启发, 我们引入了对手建模。基于该游戏高方差的性质, 我们原创性地提出一个“教练网络”, 用于挑选有价值样本以

	地主	地主下家	地主上家	地主 P_{win} 预测值	实际结果 (地主)
案例 1	3455677789JQKAAAA22R	334569TTTJJQQQKK2	344566788899TJK2B	0.9932	胜
案例 2	45667788889TTTKKA22B	334567TJJJJQQQKK22	33445567999JKAAR	0.1726	负
案例 3	3455556677799JJQKAAB	3467889TTQKKK222R	33446889TTJJQQA2	0.5843	负

表 I: 用于展示“教练网络”效果的案例研究。它基于三名玩家的初始手牌预测地主获胜概率。我们从 Botzone 上的游戏中挑选若干案例，展示“教练网络”的预测结果，并从地主视角给出实际结果。需要说明的是，T 表示 10，J 表示 J，Q 表示 Q，K 表示 K，A 表示 A，B 表示小王，R 表示大王。




图 8: 将两项改进都与 DouZero 结合的模型，以及 DouZero 模型的 ADP。两类模型都使用以 ADP 训练的 DouZero 基线进行测试。“Landlord”表示这些模型作为地主，对抗 DouZero 基线的农民；反向设置同理。为便于比较，图中还包含只由“教练网络”改进的模型结果。

加速训练。我们的 AI 在 Botzone 平台上的出色表现证明了我们改进的有效性。

尽管我们的斗地主 AI 在采用这些技术后表现良好，仍然存在进一步改进空间。第一，为了更好地展示我们改进的效果，除非必要，我们没有改变 DouZero 中神经网络的架构。我们计划尝试其他神经网络，例如类似 ResNet [42] 的卷积神经网络。第二，我们发现仍有一些情况下模型无法做出良好决策。我们希望将搜索与我们的 AI 结合以增强性能，因为搜索在游戏 AI 研究中发挥重要作用并表现良好 [43], [44]。最后，我们将研究如何用经验回放 [45] 提高样本效率，因为即便使用我们的“教练网络”，训练仍然需要大量时间。此外，我们也会尝试把我们的方法迁移到其他游戏，以构建更强的游戏 AI。

参考文献

- [1] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. Van Den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot *et al.*, “Mastering the game of go with deep neural networks and tree search,” *Nature*, vol. 529, no. 7587, pp. 484–489, 2016.
- [2] D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton *et al.*, “Mastering the game of go without human knowledge,” *Nature*, vol. 550, no. 7676, pp. 354–359, 2017.
- [3] T. Cazenave, “Improving model and search for computer go,” in *IEEE Conference on Games (CoG)*, 2021, pp. 1–8.
- [4] D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez, M. Lanctot, L. Sifre, D. Kumaran, T. Graepel *et al.*, “A general reinforcement learning algorithm that masters chess, shogi, and go through self-play,” *Science*, vol. 362, no. 6419, pp. 1140–1144, 2018.
- [5] D.-W. Kim, S. Park, and S.-i. Yang, “Mastering fighting game using deep reinforcement learning with self-play,” in *IEEE Conference on Games (CoG)*, 2020, pp. 576–583.
- [6] M. Zinkevich, M. Johanson, M. Bowling, and C. Piccione, “Regret minimization in games with incomplete information,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 20, pp. 1729–1736, 2007.
- [7] J. Heinrich and D. Silver, “Deep reinforcement learning from self-play in imperfect-information games,” *arXiv preprint arXiv:1603.01121*, 2016.
- [8] M. Moravčík, M. Schmid, N. Burch, V. Lisý, D. Morrill, N. Bard, T. Davis, K. Waugh, M. Johanson, and M. Bowling, “Deepstack: Expert-level artificial intelligence in heads-up no-limit poker,” *Science*, vol. 356, no. 6337, pp. 508–513, 2017.
- [9] N. Brown and T. Sandholm, “Superhuman ai for heads-up no-limit poker: Libratus beats top professionals,” *Science*, vol. 359, no. 6374, pp. 418–424, 2018.
- [10] —, “Superhuman ai for multiplayer poker,” *Science*, vol. 365, no. 6456, pp. 885–890, 2019.
- [11] O. Vinyals, I. Babuschkin, W. M. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, D. H. Choi, R. Powell, T. Ewalds, P. Georgiev *et al.*, “Grandmaster level in starcraft II using multi-agent reinforcement learning,” *Nature*, vol. 575, no. 7782, pp. 350–354, 2019.
- [12] C. Berner, G. Brockman, B. Chan, V. Cheung, P. Debiak, C. Dennison, D. Farhi, Q. Fischer, S. Hashme, C. Hesse *et al.*, “Dota 2 with large scale deep reinforcement learning,” *arXiv preprint arXiv:1912.06680*, 2019.
- [13] J. Li, S. Koyamada, Q. Ye, G. Liu, C. Wang, R. Yang, L. Zhao, T. Qin, T.-Y. Liu, and H.-W. Hon, “Suphx: Mastering mahjong with deep reinforcement learning,” *arXiv preprint arXiv:2003.13590*, 2020.
- [14] T. W. Neller and M. Lanctot, “An introduction to counterfactual regret minimization,” in *Educational Advances in Artificial Intelligence (EAAI)*, vol. 11, 2013.
- [15] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [16] T. Zahavy, M. Haroush, N. Merlis, D. J. Mankowitz, and S. Mannor, “Learn what not to learn: Action elimination with deep reinforcement learning,” *arXiv preprint arXiv:1809.02121*, 2018.
- [17] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu, “Asynchronous methods for deep reinforcement learning,” in *International Conference on Machine Learning (ICML)*, 2016, pp. 1928–1937.
- [18] Y. You, L. Li, B. Guo, W. Wang, and C. Lu, “Combinatorial q-learning for dou di zhu,” in *AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 16, no. 1, 2020, pp. 301–307.
- [19] Q. Jiang, K. Li, B. Du, H. Chen, and H. Fang, “Deltadou: Expert-level doudizhu ai through self-play,” in *International Joint Conferences on Artificial Intelligence (IJCAI)*, 2019, pp. 1265–1271.
- [20] D. Zha, J. Xie, W. Ma, S. Zhang, X. Lian, X. Hu, and J. Liu, “Douzero: Mastering doudizhu with self-play deep reinforcement learning,” *arXiv preprint arXiv:2106.06135*, 2021.
- [21] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*. MIT press, 2018.
- [22] H. Zhou, Y. Zhou, H. Zhang, H. Huang, and W. Li, “Botzone: A competitive and interactive platform for game ai education,” in *Proceedings of the ACM Turing 50th Celebration Conference-China*, 2017, pp. 1–5.
- [23] H. Zhou, H. Zhang, Y. Zhou, X. Wang, and W. Li, “Botzone: an online multi-agent competitive platform for ai education,” in *ACM Conference on Innovation and Technology in Computer Science Education*, 2018, pp. 33–38.
- [24] H. Zhang, G. Gao, W. Li, C. Zhong, W. Yu, and C. Wang, “Botzone: A game playing system for artificial intelligence education,” in *Inter-*

national Conference on Frontiers in Education: Computer Science and Computer Engineering (FECS), 2012, p. 1.

- [25] N. Sweeney and D. Sinclair, "Applying reinforcement learning to poker," in *Computer Poker Symposium*, 2012.
- [26] M. Lanctot, V. Zambaldi, A. Gruslys, A. Lazaridou, K. Tuyls, J. Pérolat, D. Silver, and T. Graepel, "A unified game-theoretic approach to multiagent reinforcement learning," *arXiv preprint arXiv:1711.00832*, 2017.
- [27] D. Ye, Z. Liu, M. Sun, B. Shi, P. Zhao, H. Wu, H. Yu, S. Yang, X. Wu, Q. Guo *et al.*, "Mastering complex control in moba games with deep reinforcement learning," in *AAAI Conference on Artificial Intelligence (AAAI)*, 2020.
- [28] N. Brown, A. Bakhtin, A. Lerer, and Q. Gong, "Combining deep reinforcement learning and search for imperfect-information games," *arXiv preprint arXiv:2007.13544*, 2020.
- [29] M. Gedda, M. Z. Lagerkvist, and M. Butler, "Monte carlo methods for the game kingdomino," in *IEEE Conference on Computational Intelligence and Games (CIG)*, 2018, pp. 1–8.
- [30] J. Zhou, "Design and application of tibetan long chess using monte carlo algorithm and artificial intelligence," in *Journal of Physics: Conference Series*, vol. 1952, no. 4, 2021, p. 042104.
- [31] F. Southey, M. P. Bowling, B. Larson, C. Piccione, N. Burch, D. Billings, and C. Rayner, "Bayes' bluff: Opponent modelling in poker," *arXiv preprint arXiv:1207.1411*, 2012.
- [32] N. Mizukami and Y. Tsuruoka, "Building a computer mahjong player based on monte carlo simulation and opponent models," in *IEEE Conference on Computational Intelligence and Games (CIG)*, 2015, pp. 275–283.
- [33] F. Schadd, S. Bakkes, and P. Spronck, "Opponent modeling in real-time strategy games," in *GAMEON*, 2007, pp. 61–70.
- [34] H. He, J. Boyd-Graber, K. Kwok, and H. Daumé III, "Opponent modeling in deep reinforcement learning," in *International Conference on Machine Learning (ICML)*, 2016, pp. 1804–1813.
- [35] S. J. Knekt, M. M. Drugan, and M. A. Wiering, "Opponent modelling in the game of tron using reinforcement learning," in *International Conference on Agents and Artificial Intelligence (ICAART)*, 2018, pp. 29–40.
- [36] J. N. Foerster, R. Y. Chen, M. Al-Shedivat, S. Whiteson, P. Abbeel, and I. Mordatch, "Learning with opponent-learning awareness," *arXiv preprint arXiv:1709.04326*, 2017.
- [37] L. F. Teófilo, N. Passos, L. P. Reis, and H. L. Cardoso, "Adapting strategies to opponent models in incomplete information games: a reinforcement learning approach for poker," in *International Conference on Autonomous and Intelligent Systems*, 2012, pp. 220–227.
- [38] D. Carmel and S. Markovitch, "Model-based learning of interaction strategies in multi-agent systems," *Journal of Experimental & Theoretical Artificial Intelligence*, vol. 10, no. 3, pp. 309–332, 1998.
- [39] M. Fagan and P. Cunningham, "Case-based plan recognition in computer games," in *International Conference on Case-Based Reasoning*, 2003, pp. 161–170.
- [40] T. Bansal, J. Pachocki, S. Sidor, I. Sutskever, and I. Mordatch, "Emergent complexity via multi-agent competition," *arXiv preprint arXiv:1710.03748*, 2017.
- [41] M. Johanson, K. Waugh, M. Bowling, and M. Zinkevich, "Accelerating best response calculation in large extensive games," in *International Joint Conferences on Artificial Intelligence (IJCAI)*, 2011.
- [42] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [43] B. Bouzy, A. Rimbaud, and V. Ventos, "Recursive monte carlo search for bridge card play," in *IEEE Conference on Games (CoG)*, 2020, pp. 229–236.
- [44] S. Ariyurek, A. Betin-Can, and E. Sürer, "Enhancing the monte carlo tree search algorithm for video game testing," in *IEEE Conference on Games (CoG)*, 2020, pp. 25–32.
- [45] S. Zhang and R. S. Sutton, "A deeper look at experience replay," *arXiv preprint arXiv:1712.01275*, 2017.