

最优输运粒子滤波器

Mohammad Al-Jarrah*, Bamdad Hosseini†, Amirhossein Taghvaei*

摘要—本文从理论与计算两方面发展了一类新的非线性滤波算法,称为最优输运粒子滤波器(OTPF)。该算法基于近期提出的贝叶斯法则变分表述:通过求解一个随机优化问题,寻找先验分布与后验分布之间的 Brenier 最优输运映射。在理论方面,本文结合现有粒子滤波误差分析方法与最优输运映射估计的稳定性结果,用求解该变分问题时的优化间隙来给出滤波器性能的一致误差界。误差分析揭示了一种偏差—方差权衡,可据此理解这类滤波器是否以及何时能够避开维数灾难。在计算方面,本文在一个非线性滤波例子上评估所提算法,并与集合卡尔曼滤波器(EnKF)和序贯重要性重采样(SIR)粒子滤波器进行比较。

I. 引言

最优输运(OT)理论近年来受到广泛关注,因为它为概率分布的分析与操纵提供了自然的几何和数学工具[1], [51], [36]。其中有两个几何概念尤为重要:(i)衡量概率分布相似性或差异的度量,即 Wasserstein 度量;(ii)把一个分布输运到另一个分布的映射,即 OT (或 Monge)映射。与信息论中的对应量(例如 Kullback–Leibler (KL)散度)相比,OT 度量尊重数据的几何结构,通常对扰动和误差更加稳健。凭借这些独特性质,OT 度量与映射已成功用于多类应用,包括生成建模与采样[4], [47]、领域适应[11]和图像处理[24], [15], [31], [21], [41]。

鉴于 OT 理论的重要性,使用 OT 工具处理非线性滤波和贝叶斯推断的研究不断增多[17], [9], [35], [46]。其核心思想是把滤波/贝叶斯更新步骤视为将当前状态的先验分布输运到未来状态的后验分布。由此发展出多种新的贝叶斯推断算法,包括:学习采用多项式、径向基函数或神经网络参数化的三角输运映射,以便从后验分布中采样[17], [28], [25];集合变换粒子滤波器[34];以及反馈粒子滤波算法的 OT 解释[52], [44], [45], [46]。

本文建立在作者近期工作[43]之上。该工作提出了贝叶斯法则的一种基于 OT 的变分表述,用以针对观测信号的任意取值学习从先验分布到后验分布的 OT 映射。在这一表述中,给定观测 Y 时隐变量 X 的条件分布 $P_{X|Y}$ 被识别为 $P_{X|Y}(\cdot|y) = \nabla_x \tilde{f}(\cdot; y) \# P_X(\cdot)$, $\forall y$;也就是说,它是先验分布 P_X 在形如 $\nabla \tilde{f}$ 的映射下的推前,其中实值函数 $\tilde{f}$ 求解优化问题

$$\tilde{f} = \arg \min_{f \in \text{CVX}_x} \mathbb{E}[f(\bar{X}; Y) + f^*(X; Y)]. \quad (1)$$

这里, $\bar{X}$ 是 X 的一个独立副本, CVX_x 表示对任意固定 y 都关于变量 x 为凸函数的函数集合 $f(x; y)$, 而 f^* 表示 f 关于变量 x 的凸共轭。

上述变分表述有三个区别于既有工作的关键特征:(i)它基于模拟,即可以用联合分布 P_{XY} 的样本近似目标函数,而无须显式给出似然公式;(ii)通过选择集合 CVX_x 的不同子集或参数化,它为计算后验分布提供了新的近似方法;(iii)问题 (1) 是随机的,可以利用近期机器学习技术高效求解,例如将 f 参数化为深度神经网络,并用随机梯度下降进行训练。问题 (1) 可由独立耦合 $P_X \otimes P_Y$ 与联合分布 P_{XY} 之间分块三角 Monge 问题的对偶形式得到。在条件生成模型的分块三角分布输运中,也会出现类似变分表述;例如见 [40], [25], [32], [38], [39]。

本文的目标是利用表述 (1) 发展一种新的非线性滤波算法——最优输运粒子滤波器(OTPF),并给出初步理论分析和数值验证。所提算法可视为集合卡尔曼滤波算法(EnKF)[18], [7]的非线性、非高斯推广,以及反馈粒子滤波(FPF)算法[53], [52]的离散时间对应物:OTPF 通过求解变分问题 (1),同时处理 FPF 中的增益函数近似和数值时间离散化问题。

本文的理论部分关注所提算法的误差分析。具体而言,我们研究每个时刻求解问题 (1) 时产生的误差如何影响滤波算法的整体性能。为此,我们改造现有粒子滤波器(PF)误差分析方法,用 OT 映射的近似误差给出滤波误差的一致界[14], [49], [8], [13]。这些结果基于一致几何滤波稳定性这一强假设[6],该假设在 PF 分析中很常见。随后,我们将它与 OT 映射估计的稳定性结果[22]结合;后者把映射的近似误差与问题 (1) 的优化间隙联系起来(见引理 2)。误差分析既覆盖算法的平均场极限,也覆盖带有额外重采样步骤的粒子系统变体;该步骤使粒子彼此独立,从而显著简化分析。

数值实验从定性和定量两方面比较 OTPF、EnKF[18], [7]与序贯重要性重采样(SIR)PF[16]的性能。我们考察一个稳定的线性动力系统以及三种不同的观测函数:线性、二次和三次函数。数值结果表明,与另外两种方法相比,OTPF 在这三个基准例子上具有较强的通用性。

本文其余部分安排如下:第 II 节回顾滤波问题和滤波方程,并引入滤波稳定性的概念;第 III 节详细介绍 OTPF 算法;第 IV 节给出误差分析;第 V 节包含数值实验。

* 华盛顿大学西雅图分校航空航天系; mohd9485@uw.edu, amirtag@uw.edu.

† 华盛顿大学西雅图分校应用数学系; bamdadh@uw.edu.

II. 问题表述

A. 滤波问题

考虑由如下更新方程给出的离散时间随机动力系统:

$$X_t \sim a(\cdot|X_{t-1}), \quad X_0 \sim \pi_0, \quad (2a)$$

$$Y_t \sim h(\cdot|X_t), \quad (2b)$$

其中 $t = 1, 2, \dots$, $X_t \in \mathbb{R}^n$ 是系统状态, $Y_t \in \mathbb{R}^m$ 是观测, π_0 是初始状态 X_0 的概率分布, $a(x'|x)$ 是状态从 x 转移到 x' 的概率核, 而 $h(y|x)$ 是给定状态 x 时观测 y 的似然分布。假设更新方程 (2a) 由随机映射

$$X_t = \bar{a}(X_{t-1}, V_t) \quad (2c)$$

实现, 其中 $\{V_t\}_{t=1}^\infty$ 是独立同分布序列, 并且对所有 v , $\bar{a}(x, v)$ 关于 x 都是 Lipschitz 的。全文假设所有概率测度都有密度, 并用相同记号指代分布或相应测度; 必要时再根据上下文区分这两个概念。

滤波问题旨在推断给定观测历史 $\{Y_1, Y_1, \dots, Y_t\}$ 时状态 X_t 的条件分布, 即

$$\pi_t := \mathbb{P}(X_t \in \cdot | Y_1, \dots, Y_t), \quad t = 1, 2, \dots,$$

该分布通常称为后验分布。

B. 滤波器的递归更新

后验分布 π_t 具有递归更新方程, 这是设计滤波算法的基础。为表述该递归更新, 先引入如下算子:

$$(\text{传播}) \quad \pi \mapsto \mathcal{A}\pi := \int_{\mathbb{R}^n} a(\cdot|x)\pi(x) dx, \quad (3a)$$

$$(\text{条件化}) \quad \pi \mapsto \mathcal{B}_y\pi := \frac{h(y|\cdot)\pi(\cdot)}{\int_{\mathbb{R}^n} h(y|x)\pi(x) dx}. \quad (3b)$$

第一个算子表示依据动力模型 (2a) 更新状态分布, 第二个算子表示依据观测模型 (2b) 执行条件化的贝叶斯法则。用这两个算子, 后验分布的更新律可写为 (例如见 [8])

$$\pi_t = \mathcal{T}_t\pi_{t-1} = \mathcal{B}_{Y_t}\mathcal{A}\pi_{t-1}. \quad (3c)$$

其中定义 $\mathcal{T}_t := \mathcal{B}_{Y_t}\mathcal{A}$ 。稍微滥用记号, 进一步定义转移算子

$$\mathcal{T}_{t,s} := \mathcal{T}_t \circ \dots \circ \mathcal{T}_{s+1}, \quad \forall t > s \geq 0.$$

于是对所有 $t > s \geq 0$, 都有 $\pi_t = \mathcal{T}_{t,s}\pi_s$ 。注意, 转移算子 $\mathcal{T}_{t,s}$ 本质上是随机的, 因为它依赖于观测信号 $\{Y_{s+1}, \dots, Y_t\}$ 的实现。为简化表述, 下文省略这一依赖关系。

C. 滤波稳定性

对 (可能随机的) 概率测度 μ, ν , 采用如下度量:

$$d(\mu, \nu) := \sup_{g \in \mathcal{G}} \sqrt{\mathbb{E} \left| \int g d\mu - \int g d\nu \right|^2}, \quad (4)$$

其中, 期望关于概率测度 μ 和 ν 可能具有的随机性计算; $\mathcal{G} := \{g : \mathbb{R}^n \rightarrow \mathbb{R}; |g(x)| \leq 1, |g(x) - g(x')| \leq \|x - x'\|, \forall x, x'\}$ 是由一致有界于 1、且一致 Lipschitz 常数不超过 1 的函数组成的空间。该度量也称为对偶有界 Lipschitz 距离。下面用它引入滤波器的一致几何稳定性。

定义 1 (一致几何稳定滤波器): 若存在 $\lambda \in (0, 1)$ 和正常数 $C > 0$, 使得对所有 μ, ν 以及 $t > s \geq 0$ 都有

$$d(\mathcal{T}_{t,s}\mu, \mathcal{T}_{t,s}\nu) \leq C(1 - \lambda)^{t-s}d(\mu, \nu), \quad (5)$$

则称滤波更新 (3) 是一致几何稳定的。

注 1: 一致几何稳定性质 (5) 也用于 [14], [13] 中的 PF 误差分析。当动力转移核满足小集条件时, 可以验证这一性质: 即存在概率测度 ρ 和常数 $\epsilon > 0$, 使 $a(x|x') \geq \epsilon\rho(x)$ 。该小集条件是一种混合条件, 可保证马尔可夫过程 X_t 的几何遍历性 [29]。我们承认这是一个强条件, 只能对有限类别的系统加以验证, 例如 X_t 应属于紧集。完整刻画具有一致几何稳定滤波器的系统, 仍是该领域中一个开放且困难的问题。对于较弱的滤波渐近稳定性, 即 $\lim_{t \rightarrow \infty} d(\mathcal{T}_{t,s}\mu, \mathcal{T}_{t,s}\nu) = 0$, 目前已有更多认识; 当系统在适用于非线性随机动力系统的意义下“可检测”时, 该性质成立 [50], [10], [48], [23]。这种对渐近滤波稳定系统的刻画与卡尔曼滤波稳定性的既有结果一致: 当线性系统在经典意义下可检测时, 卡尔曼滤波具有稳定性 [30]。关于现有滤波稳定性结果的完整综述见 [12]。

下面的引理将用于误差分析。

引理 1: 令 π 为一个 (随机) 分布, T 和 S 为两个 (随机) 可测映射, 则

$$d(T\#\pi; S\#\pi) \leq \mathbb{E} \left[\|T - S\|_{L^2(\pi)}^2 \right]^{\frac{1}{2}},$$

其中期望同时关于分布 π 以及映射 T, S 可能具有的随机性计算。

Proof: 直接利用度量 (4) 的定义以及测试函数 g 的 Lipschitz 性质即可得证。 ■

III. 最优输运粒子滤波器

OTPF 的构造依赖于变分表述 (1)。考虑目标泛函

$$J(f; \pi) := \mathbb{E}[f(\bar{X}; Y) + f^*(X; Y)], \quad (6)$$

其中 $X \sim \pi$, $Y \sim h(\cdot|X)$, $\bar{X} \sim \pi$ 是 X 的一个独立副本; 相应优化问题为

$$\inf_{f \in \text{CVX}_x} J(f, \pi). \quad (7)$$

文献 [43, 命题 1] 表明, 该问题的解给出了贝叶斯算子 (3b) 的 OT 刻画。为完整起见, 下面重述该结果。

命题 1: 假设 π 关于 Lebesgue 测度具有密度, 则目标函数 (6) 存在唯一的极小化函数 $\bar{f} \in \text{CVX}_x$ (相差常数平移视为相同), 且

$$\nabla_x \bar{f}(\cdot; y) \# \pi = \mathcal{B}_y \pi, \quad \text{对几乎处处的 } y. \quad (8)$$

A. 精确平均场过程

我们利用条件分布的 OT 刻画, 构造一个 (精确) 平均场过程 $\bar{X}_t$, 其分布 $\bar{\pi}_t$ 与后验分布 π_t 完全相同。考虑如下定义的、分布为 $\bar{\pi}_t$ 的过程 $\bar{X}_t$:

$$\begin{aligned} \bar{X}_t &= \nabla_x \bar{f}_t(\bar{a}(\bar{X}_{t-1}, \bar{V}_t); Y_t), \quad \bar{X}_0 \sim \bar{\pi}_0, \\ \bar{f}_t &= \arg \min_{f \in \text{CVX}_x} J(f, \mathcal{A}\bar{\pi}_{t-1}), \end{aligned} \quad (9a)$$

其中 $\bar{V}_t$ 是动力模型 (2c) 中 V_t 的一个独立副本。于是容易验证

$$\bar{\pi}_t = \nabla_x \bar{f}_t(\cdot; Y_t) \# \mathcal{A}\bar{\pi}_{t-1} = \mathcal{B}_y \mathcal{A}\bar{\pi}_{t-1}. \quad (9b)$$

第二个等式是命题 1 的结果。因此, 只要 $\bar{\pi}_0 = \pi_0$, 就有 $\bar{\pi}_t = \pi_t$, 故称平均场过程 $\bar{X}_t$ 为精确过程。OTPF 通过下面所述的两个步骤近似精确平均场过程 $\bar{X}_t$ 。

B. 近似平均场过程

第一步近似把优化问题 (7) 的可行集限制为参数化凸函数类 $\mathcal{F} \subset \text{CVX}_x$ 。所得近似分布记为 $\pi_t^{\mathcal{F}}$, 其更新规则为

$$\begin{aligned} \pi_t^{\mathcal{F}} &= \nabla_x f_t^{\mathcal{F}}(\cdot, Y_t) \# \mathcal{A}\pi_{t-1}^{\mathcal{F}}, \quad \pi_0^{\mathcal{F}} = \pi_0, \\ f_t^{\mathcal{F}} &= \arg \min_{f \in \mathcal{F}} J(f, \mathcal{A}\pi_{t-1}^{\mathcal{F}}). \end{aligned} \quad (10a)$$

该更新定义了近似平均场过程

$$X_t^{\mathcal{F}} = \nabla_x f_t^{\mathcal{F}}(\bar{a}(X_{t-1}^{\mathcal{F}}; Y_t), \bar{V}_t), \quad X_0^{\mathcal{F}} \sim \bar{\pi}_0. \quad (10b)$$

由函数 f_t 的参数化引起的 $\pi_t^{\mathcal{F}}$ 与 $\bar{\pi}_t$ 之间的近似误差, 将在第 IV-A 节研究。

C. 有限粒子系统

第二步近似用粒子集合 $\{X_t^1, \dots, X_t^N\}$ 的经验分布替代平均场过程, 即 $\pi_t^{\mathcal{F}} \approx \frac{1}{N} \sum_{i=1}^N \delta_{X_t^i}$ 。有限 N 离散化可采用两种方法, 从而得到两个不同的粒子系统。第一种系统 (带重采样的粒子系统) 更便于误差分析, 第二种系统 (交互粒子系统) 则更实用。

(C.I) 带重采样的粒子系统: 定义采样算子

$$\pi \mapsto \mathcal{S}^N \pi := \frac{1}{N} \sum_{i=1}^N \delta_{X^i}, \quad X^i \stackrel{\text{i.i.d.}}{\sim} \pi, \quad (11)$$

并在更新方程中引入采样算子 $\mathcal{S}^N$, 从而近似平均场分布 $\pi_t^{\mathcal{F}}$:

$$\begin{aligned} \tilde{\pi}_t^{(\mathcal{F}, N)} &= \nabla_x \tilde{f}_t^{(\mathcal{F}, N)}(\cdot, Y_t) \# \mathcal{S}^N \mathcal{A}\tilde{\pi}_{t-1}^{(\mathcal{F}, N)}, \quad \pi_0^{(\mathcal{F}, N)} = \pi_0, \\ \tilde{f}_t^{(\mathcal{F}, N)} &= \arg \min_{f \in \mathcal{F}} J(f, \mathcal{S}^N \mathcal{A}\tilde{\pi}_{t-1}^{(\mathcal{F}, N)}). \end{aligned} \quad (12a)$$

采样算子的存在保证分布 $\tilde{\pi}_t^{(\mathcal{F}, N)}$ 是由一组粒子形成的经验分布, 即 $\tilde{\pi}_t^{(\mathcal{F}, N)} = \frac{1}{N} \sum_{i=1}^N \delta_{\tilde{X}_t^i}$ 。式 (12a) 还给出了粒子更新律:

$$\tilde{X}_t^i = \nabla_x \tilde{f}_t^{(\mathcal{F}, N)}(\bar{a}(\tilde{X}_{t-1}^i, V_t^i); Y_t). \quad (12b)$$

其中 $\sigma_i \sim \text{Unif}\{1, 2, \dots, N\}$, $\{V_t^i\}_{i=1}^N$ 是 V_t 的独立副本。该采样过程类似 PF 中的重采样阶段, 但这里的权重是均匀的。重采样步骤使粒子相互独立, 因而显著简化了误差分析, 见第 IV-B 节。

(C.II) 交互粒子系统: 构造有限 N 粒子系统的第二种方法, 是按下式离散化平均场过程 $X_t^{\mathcal{F}}$ 的更新方程 (10b):

$$\begin{aligned} X_t^i &= \nabla_x f_t^{(\mathcal{F}, N)}(\bar{a}(X_t^i, V_t^i); Y_t), \\ f_t^{(\mathcal{F}, N)} &= \arg \min_{f \in \mathcal{F}} J\left(f, \frac{1}{N} \sum_{i=1}^N \delta_{\bar{a}(X_t^i, V_t^i)}\right). \end{aligned} \quad (13)$$

由于算子 $\mathcal{A}$ 会平滑经验分布, 经验分布 $\pi_t^{(\mathcal{F}, N)} := \frac{1}{N} \sum_{i=1}^N \delta_{X_t^i}$ 不具有类似 $\tilde{\pi}_t^{(\mathcal{F}, N)}$ 的更新律。交互粒子系统的更新可改写为

$$\pi_t^{(\mathcal{F}, N)} = \nabla f^{(\mathcal{F}, N)} \# \mathcal{A}^N \pi_{t-1}^{(\mathcal{F}, N)},$$

其中随机算子 $\mathcal{A}^N$ 把任意经验分布 $\frac{1}{N} \sum_{i=1}^N \delta_{x_i}$ 映射为 $\frac{1}{N} \sum_{i=1}^N \delta_{a(x_i, V^i)}$ 。此外, 与前一种构造 (带重采样的粒子系统) 不同, 此时粒子之间存在相关性, 使得误差分析更具挑战性; 这一问题通常在混沌传播分析框架中研究 [42]。我们把交互粒子系统的误差分析留作未来工作, 但在第 V 节对该近似的性能作经验验证。

IV. 误差分析

本节研究上文所引入 OTPF 的近似误差。首先分析近似平均场过程, 然后转向带重采样的粒子系统。

A. 平均场分析

精确平均场分布 $\bar{\pi}_t$ 与近似分布 $\pi_t^{\mathcal{F}}$ 之间的距离由以下命题刻画。

命题 2: 分别考虑式 (9) 和 (10) 中的 $\bar{\pi}_t$ 与 $\pi_t^{\mathcal{F}}$ 。假设:

- 1) 精确滤波器按照定义 1 是稳定的。
- 2) 存在 $\epsilon_{\mathcal{F}} > 0$, 使

$$\inf_{f \in \mathcal{F}} J(f, \mathcal{A}\pi_t^{\mathcal{F}}) - \inf_{f \in \text{CVX}_x} J(f, \mathcal{A}\pi_t^{\mathcal{F}}) \leq \epsilon_{\mathcal{F}}, \quad \text{forall } t. \quad (14)$$

- 3) 对所有 y 和 t , 函数 $f_t^{\mathcal{F}}(\cdot; y)$ 是凸的, 且 $\nabla_x f_t^{\mathcal{F}}(\cdot; y)$ 是 β -Lipschitz 的。

则

$$d(\pi_t^{\mathcal{F}}, \pi_t) \leq \frac{C\sqrt{2\beta\epsilon_{\mathcal{F}}}}{\lambda}, \quad \forall t, \quad (15)$$

其中所有常数均与时间无关。

注 2: 命题中的第一个假设用于确保算法每一步产生的误差不会随时间增长。第二个假设涉及函数类 $\mathcal{F}$ 相

对于算法产生的概率分布类 $\mathcal{A}\pi_t^{\mathcal{F}}$ 的表示能力。例如，当 $\mathcal{F}$ 是凸二次函数类，且滤波问题基于线性高斯动力和观测模型时，该误差为零。此时，概率分布 $\pi_t^{\mathcal{F}}$ 是高斯分布，相应最优函数 $\bar{f}_t$ 为二次函数。一般而言，当分布本身较简单时，例如问题呈现低维结构或正则性时，预期误差较小。此类误差的分析属于表示理论的研究范畴 [3], [37]。最后一个假设与分布 $\mathcal{A}\pi_t^{\mathcal{F}}$ 及所得后验分布的正则性有关，可以通过适当选择函数类 $\mathcal{F}$ 来保证。

Proof: 为简化表述，对所有 t 引入算子 $\pi \mapsto \mathcal{T}_t^{\mathcal{F}}\pi := \nabla f_t^{\mathcal{F}}(\cdot, Y_t) \# \mathcal{A}\pi$ ，表示式 (10a) 中近似平均场分布的更新律。证明的第一步利用三角不等式和滤波稳定性，按如下方式限制 π_t 与 $\pi_t^{\mathcal{F}}$ 之间的误差：

$$\begin{aligned} d(\pi_t, \pi_t^{\mathcal{F}}) &\leq \sum_{k=1}^t d(\mathcal{T}_{t,k-1}\pi_{k-1}^{\mathcal{F}}, \mathcal{T}_{t,k}\pi_k^{\mathcal{F}}) \\ &\leq \sum_{k=1}^t d(\mathcal{T}_{t,k}\mathcal{T}_k\pi_{k-1}^{\mathcal{F}}, \mathcal{T}_{t,k}\mathcal{T}_k^{\mathcal{F}}\pi_{k-1}^{\mathcal{F}}) \\ &\leq \sum_{k=1}^t C(1-\lambda)^{t-k} d(\mathcal{T}_k\pi_{k-1}^{\mathcal{F}}, \mathcal{T}_k^{\mathcal{F}}\pi_{k-1}^{\mathcal{F}}) \\ &\leq \frac{C}{\lambda} \max_{k \in \{1,2,\dots,t\}} \{d(\mathcal{T}_k\pi_{k-1}^{\mathcal{F}}, \mathcal{T}_k^{\mathcal{F}}\pi_{k-1}^{\mathcal{F}})\}. \end{aligned}$$

接着利用引理 1，对所有 $k \geq 0$ 有

$$\begin{aligned} d(\mathcal{T}_k\pi_{k-1}^{\mathcal{F}}, \mathcal{T}_k^{\mathcal{F}}\pi_{k-1}^{\mathcal{F}}) &= d(\nabla \bar{f}_k(\cdot; Y_k) \# \mathcal{A}\pi_{k-1}^{\mathcal{F}}, \nabla f_k^{\mathcal{F}}(\cdot; Y_k) \# \mathcal{A}\pi_{k-1}^{\mathcal{F}}) \\ &\leq \mathbb{E} \left[\|\nabla \bar{f}_k(\cdot; Y_k) - \nabla f_k^{\mathcal{F}}(\cdot; Y_k)\|_{L^2(\mathcal{A}\pi_{k-1}^{\mathcal{F}})}^2 \right]^{\frac{1}{2}}. \end{aligned}$$

最后，利用命题的第二、第三个假设以及下文引理 2，可对 $\nabla \bar{f}_k$ 与 $\nabla f_k^{\mathcal{F}}$ 之间的误差给出一致界：

$$\begin{aligned} \mathbb{E} \left[\|\nabla \bar{f}_k(\cdot; Y_k) - \nabla f_k^{\mathcal{F}}(\cdot; Y_k)\|_{L^2(\mathcal{A}\pi_{k-1}^{\mathcal{F}})}^2 \right] &\leq 2\beta (J(f_k^{\mathcal{F}}, \mathcal{A}\pi_{k-1}^{\mathcal{F}}) - J(\bar{f}_k, \mathcal{A}\pi_{k-1}^{\mathcal{F}})) \\ &\leq 2\beta \epsilon_{\mathcal{F}}. \end{aligned}$$

由此得到最终界 (15)。 ■

引理 2: 考虑目标函数为 (6) 的优化问题 (7)。假设 π 具有密度， $\bar{f}$ 是最优函数， f 是任意凸且 β -光滑的函数，则

$$J(\pi, f) - J(\pi, \bar{f}) \geq \frac{1}{2\beta} \mathbb{E} [\|\nabla f(\bar{X}; Y) - \nabla \bar{f}(\bar{X}; Y)\|^2].$$

Proof: 该证明是文献 [22, 命题 10] 结果的推广；限于篇幅从略。 ■

B. 带重采样粒子系统的分析

下面分析粒子系统 (12) 与精确平均场过程 (9) 之间的误差。分析过程与上一节的平均场分析类似，但还包含由采样算子和经验近似引起的额外误差。

命题 3: 分别考虑式 (9) 与 (12) 所定义的精确平均场分布 $\bar{\pi}_t$ 和粒子分布 $\tilde{\pi}_t^{(\mathcal{F}, N)}$ 。假设：

- 1) 精确滤波器按照定义 1 是稳定的。

- 2) 存在常数 $\epsilon_{\mathcal{F}, N} > 0$ ，使得对所有 t 和 N ，

$$\begin{aligned} \inf_{f \in \mathcal{F}} J(f, \mathcal{S}^N \mathcal{A}\tilde{\pi}_t^{(\mathcal{F}, N)}) \\ - \inf_{f \in \text{CVX}_x} J(f, \mathcal{A}\tilde{\pi}_t^{(\mathcal{F}, N)}) \leq \epsilon_{\mathcal{F}, N}. \end{aligned}$$

- 3) 对所有 y, t, N ，函数 $f_t^{(\mathcal{F}, N)}(\cdot; y)$ 是凸的，且 $\nabla_x f_t^{(\mathcal{F}, N)}(\cdot; y)$ 是 β -Lipschitz 的。

则

$$d(\tilde{\pi}_t^{(\mathcal{F}, N)}, \pi_t) \leq \frac{C}{\lambda} \left(\sqrt{2\beta\epsilon_{\mathcal{F}, N}} + \frac{1}{\sqrt{N}} \right), \quad \forall t, \quad (16)$$

其中所有常数均与时间无关。

Proof: 证明与命题 2 类似。定义算子 $\tilde{\mathcal{T}}_t^{(\mathcal{F}, N)} : \pi \mapsto \nabla \tilde{f}_t^{(\mathcal{F}, N)}(\cdot, Y_t) \# \mathcal{S}^N \mathcal{A}\pi$ 。由三角不等式与滤波稳定性可得

$$\begin{aligned} d(\pi_t, \pi_t^{(\mathcal{F}, N)}) &\leq \frac{C}{\lambda} \max_{k \in \{1,2,\dots,t\}} \\ &\quad \{d(\mathcal{T}_k\pi_{k-1}^{(\mathcal{F}, N)}, \tilde{\mathcal{T}}_k^{(\mathcal{F}, N)}\pi_{k-1}^{(\mathcal{F}, N)})\}. \end{aligned}$$

再次应用三角不等式，可写成

$$\begin{aligned} d(\mathcal{T}_k\pi_{k-1}^{(\mathcal{F}, N)}, \tilde{\mathcal{T}}_k^{(\mathcal{F}, N)}\pi_{k-1}^{(\mathcal{F}, N)}) &= d(\nabla \bar{f}_k(\cdot, Y_t) \# \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}, \nabla \tilde{f}_k^{(\mathcal{F}, N)} \# \mathcal{S}^N \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}) \\ &\leq d(\nabla \bar{f}_k(\cdot, Y_t) \# \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}, \nabla f_k^{(\mathcal{F}, N)} \# \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}) \\ &\quad + d(\nabla f_k^{(\mathcal{F}, N)} \# \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}, \nabla \tilde{f}_k^{(\mathcal{F}, N)} \# \mathcal{S}^N \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}). \end{aligned}$$

应用引理 1 和引理 2 后，第一项被下式平方根控制：

$$\begin{aligned} \mathbb{E} \left[\|\nabla \bar{f}_k(\cdot; Y_k) - \nabla f_k^{(\mathcal{F}, N)}(\cdot; Y_k)\|_{L^2(\mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)})}^2 \right] &\leq 2\beta (J(f_k^{(\mathcal{F}, N)}, \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)}) - J(\bar{f}_k, \mathcal{A}\pi_{k-1}^{(\mathcal{F}, N)})) \\ &\leq 2\beta \epsilon_{\mathcal{F}, N}, \end{aligned}$$

其中使用了第二和第三个假设。这给出式 (16) 右侧的第一项。第二项来自采样误差；由于度量 d 定义中的测试函数 g 一致有界于 1，它的上界为 $1/\sqrt{N}$ （例如见 [33, 引理 2.17]）。两项相加即得最终界。 ■

注 3: 该命题的假设与命题 2 类似，只有第二个假设略有不同。第二个假设中的界可以分解为两项：

$$\begin{aligned} \inf_{f \in \mathcal{F}} J(f, \mathcal{S}^N \mathcal{A}\tilde{\pi}_t^{(\mathcal{F}, N)}) - \inf_{f \in \mathcal{F}} J(f, \mathcal{A}\tilde{\pi}_t^{(\mathcal{F}, N)}) \\ + \inf_{f \in \mathcal{F}} J(f, \mathcal{A}\tilde{\pi}_t^{(\mathcal{F}, N)}) - \inf_{f \in \text{CVX}_x} J(f, \mathcal{A}\tilde{\pi}_t^{(\mathcal{F}, N)}). \end{aligned}$$

第二项类似于命题 2 中使用的项，与 $\mathcal{F}$ 的表示能力有关。第一项对应使用经验样本近似分布所产生的统计泛化误差，属于统计泛化理论的研究对象 [37], [5], [26], [54]。预期该误差按 $O(C_{\mathcal{F}}/\sqrt{N})$ 缩放，其中常数 $C_{\mathcal{F}}$ 表征函数类 $\mathcal{F}$ 的复杂度，并与维数 d 无关。第一项也可解释为方差，第二项则是偏差。因此，我们的误差分析体现了依赖函数类 $\mathcal{F}$ 复杂度的偏差—方差权衡。类似的偏差—方差权衡也出现在局部 PF 的分析中 [33]。

V. 数值实验

下面通过一个数值例子说明所提 OTPF 的性能，并与另外两种滤波器比较：EnKF [18] 和序贯重要性重采样 (SIR) PF [16]。

对于 OTPF，采用文献 [43, 第 III-B 节] 所述、最初由 [27] 提出的变分问题 (7) 极小极大表述来估计 OT 映射。该表述还需对一个额外的凸函数 ψ 进行优化；它按下式表示凸共轭 f^* ：

$$\mathbb{E}[f^*(X; Y)] = \max_{\psi \in \text{CVX}_x} \mathbb{E}[X^\top \nabla_x \psi(X; Y) - f(\nabla_x \psi(X; Y); Y)].$$

然而，在数值实验中我们观察到，由于参数化具有更大的自由度，放松约束并对映射 $T(x; y)$ 而非 $\nabla_x \psi(x; y)$ 进行优化，会得到更好的数值结果。因此采用表述

$$\mathbb{E}[f^*(X; Y)] = \max_T \mathbb{E}[X^\top T(X; Y) - f(T(X; Y); Y)].$$

注意，这不会改变优化问题，因为最优 T 具有梯度形式，并等于 $\nabla_x f^*$ 。最终目标函数为

$$\min_{f \in \text{ICNN}} \max_{T \in \text{ResNet}} \{ \mathbb{E}_{P_{XY}} [f(X, Y)] + \mathbb{E}_{P_X \otimes P_Y} [X^\top T(X, Y) - f(T(X, Y), Y)] \}. \quad (17)$$

注 4：与原始表述 (1) 相比，我们交换了源分布 $P_X \otimes P_Y$ 和目标分布 P_{XY} 的角色，使 T 而非 $\nabla_x f$ 表示从先验到后验的运输映射。这种表述使映射的参数化更加方便。

类似的放松对计算 Wasserstein 重心 [19] 和 Wasserstein 梯度流 [20] 也有益。这里，ICNN 表示部分输入凸神经网络集合 [2]。

为说明各滤波器的性能，考虑如下动力和观测模型：

$$X_t = (1 - \alpha)X_{t-1} + 2\sigma V_t, \quad X_0 \sim \mathcal{N}(0, I_n), \quad (18a)$$

$$Y_t = h(X_t) + \sigma W_t, \quad (18b)$$

其中 $t = 1, 2, 3, \dots$, $X_t, Y_t \in \mathbb{R}^n$, $\{V_t\}_{t=1}^\infty$ 和 $\{W_t\}_{t=1}^\infty$ 是 n 维标准高斯随机变量的独立同分布序列， $\alpha = 0.1$, $\sigma = \sqrt{0.1}$ 。采用三种观测函数：

$$h(x) = x, qquad h(x) = x \odot x, qquad h(x) = x \odot x \odot x,$$

当 x 为向量时， $\odot$ 表示逐元素（即 Hadamard）乘积。

为求解 (17)，将 ICNN 参数化为

$$f(x; y) = \sum_{k=1}^K W_k (x^\top W_k^x + y^\top W_k^y + b_k)_+^2,$$

其中对 $k = 1, \dots, K$ ，有 $W_k \geq 0$, $W_k^x, W_k^y \in \mathbb{R}^n$, $b_k \in \mathbb{R}$ ，网络规模为 $K = 32$ 。映射 T 使用标准残差网络建模，该网络包含两个大小为 32 的残差块和 ReLU 激活函数。

我们使用 ADAM 优化器求解极小极大问题：学习率为 10^{-2} ，内循环迭代次数为 10，总迭代次数初始为 1024；在滤波问题的每个时刻后，总迭代次数减半，

直至达到 64。每次迭代都从总计 $N = 1000$ 个粒子 $\{(X_t^1, Y_t^1), \dots, (X_t^N, Y_t^N)\}$ 中随机选取大小为 32 的一批样本。观测样本 Y_t^i 通过观测模型 $Y_t^i \sim h(\cdot | X_t^i)$ 生成。独立耦合 $P_X \otimes P_Y$ 的样本通过随机打乱产生。所有算法使用相同的粒子数 N 。数值代码的详细信息可在线获取¹。

图 1 给出了二维问题 $n = 2$ 的数值结果，但图中仅展示第一个分量。我们选择 $n = 2$ ，是因为当 $n = 1$ 时 SIR 与 OT 方法差异不明显，而 $n = 2$ 时差异开始显现。图中同时给出粒子轨迹和隐状态轨迹。图 (a) 所示的第一个实验使用线性观测函数。正如预期，三种算法表现相近，因为它们都能捕捉此时的精确解：一个可由线性映射得到的高斯分布。图 (b) 所示的第二个实验使用二次观测函数 $h(x) = x \odot x$ 。这是一个有趣的情形，因为该问题不可观测，预期会出现（对称的）双峰分布。结果表明，EnKF 无法表示双峰分布，而 OT 和 SIR 都捕捉到了两个模态；不过 SIR 在 $t \in [2, 3.5]$ 的时间范围内发生了模态坍塌。最后，对于图 (c) 所示的三次观测函数 $h(x) = x \odot x \odot x$ ，由于观测模型具有强非线性，SIR 和 OT 的表现均优于 EnKF，符合预期。

我们还通过计算状态函数 ϕ 估计的均方误差 (MSE)，定量评价三项实验中所有算法的性能：

$$\text{MSE}_t(\phi) = \mathbb{E} \left\| \frac{1}{N} \sum_{i=1}^N \phi(X_t^i) - \phi(X_t) \right\|^2. \quad (19)$$

其中，经验平均通过 100 次独立模拟近似期望。结果见图 2。对于线性和三次观测模型，使用 $\phi(x) = x$ ；对于二次情形，使用 $\phi(x) = \max(0, x)$ ，因为该分布是均值为零的双峰分布，比较估计均值与真实均值并不是合适的判据。

从图 2 (a) 可见，OT 与 SIR 滤波器的结果都接近 EnKF；对于线性情形，EnKF 是渐近精确的。然而，在图 2 (b) 的二次情形中，OT 方法优于 EnKF 和 SIR；对于图 2 (c) 所示的三次情形，OT 与 SIR 的差异并不显著。通过进一步微调、增加训练迭代次数和神经网络参数数量，可以预期 OT 滤波器性能进一步提升，但代价是更高的计算量。对 OT 方法效率、其在高维问题中的缩放规律以及它在更现实数据上的应用作适当分析，是未来工作的主题。

VI. 讨论

本文提出 OTPF 算法，并给出了初步理论误差分析和数值结果；这些结果表明，在存在非线性观测和非高斯状态时，本文方法具有有竞争力的性能。我们还提出了若干未来研究方向：验证形如 (18) 的动力系统的几何稳定性；按照注 3 的讨论，从表示误差和泛化误差两方面分析求解变分问题时的优化间隙；分析无重采样交互粒子系统的误差；以及在真正的高维设置中开展大规模数值实验和比较。

¹<https://github.com/Mohd9485/OT-EnKF-SIR>




Fig. 1. 集合卡尔曼滤波器、最优输运粒子滤波器和序贯重要性重采样粒子滤波器在数值例子 (18) 上的结果；图中分别记为 EnKF、OT 和 SIR。图中给出了粒子 $\{X_t^1, \dots, X_t^N\}$ 的轨迹和真实状态 X_t 的轨迹。三种观测函数分别为：(a) $h(x) = x$ ；(b) $h(x) = x \odot x$ ；(c) $h(x) = x \odot x \odot x$ 。




Fig. 2. 滤波器在例子 (18) 上的数值结果，设置与图 1 相同。图中给出了估计状态函数时的 MSE (19)。图 (a) 和 (c) 采用 $\phi(x) = x$ ，图 (b) 采用 $\phi(x) = \max(0, x)$ 。MSE 通过对 100 次独立模拟取经验平均进行评估。

References

- [1] Luigi Ambrosio, Nicola Gigli, and Giuseppe Savaré. *Gradient flows: in metric spaces and in the space of probability measures*. Springer Science & Business Media, 2005.
- [2] Brandon Amos, Lei Xu, and J Zico Kolter. Input convex neural networks. *arXiv preprint arXiv:1609.07152*, 2016.
- [3] Martin Anthony and Peter L Bartlett. *Neural network learning: Theoretical foundations*, volume 9. cambridge university press Cambridge, 1999.
- [4] Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. In *International conference on machine learning*, pages 214–223. PMLR, 2017.
- [5] Sanjeev Arora, Rong Ge, Yingyu Liang, Tengyu Ma, and Yi Zhang. Generalization and equilibrium in generative adversarial nets (gans). In *International Conference on Machine Learning*, pages 224–232. PMLR, 2017.
- [6] Rami Atar and Ofer Zeitouni. Exponential stability for nonlinear filtering. In *Annales de l'Institut Henri Poincaré (B) Probability and Statistics*, volume 33, pages 697–725. Elsevier, 1997.
- [7] Edoardo Calvella, Sebastian Reich, and Andrew M Stuart. Ensemble Kalman methods: a mean field perspective. *arXiv preprint arXiv:2209.11371*, 2022.
- [8] Olivier Cappé, Eric Moulines, and Tobias Rydén. Inference in hidden markov models. In *Proceedings of EUSFLAT Conference*, pages 14–16, 2009.
- [9] Yuan Cheng and Sebastian Reich. A McKean optimal transportation perspective on Feynman-Kac formulae with application to data assimilation. *arXiv preprint arXiv:1311.6300*, 2013.
- [10] Pavel Chigansky, Robert Liptser, and Ramon Van Handel. Intrinsic methods in filter stability. *Handbook of Nonlinear Filtering*, 2009.
- [11] Nicolas Courty, Rémi Flamary, Devis Tuia, and Alain Rakotomamonjy. Optimal transport for domain adaptation. *arXiv preprint arXiv:1507.00504*, 2015.
- [12] Dan Crisan and Boris Rozovskii. *The Oxford handbook of nonlinear filtering*. Oxford University Press, 2011.
- [13] Pierre Del Moral and Pierre Del Moral. *Feynman-Kac formulae*. Springer, 2004.
- [14] Pierre Del Moral and Alice Guionnet. On the stability of interacting processes with applications to filtering and genetic algorithms. In *Annales de l'Institut Henri Poincaré (B) Probability and Statistics*, volume 37, pages 155–194. Elsevier, 2001.
- [15] Ayelet Dominitz and Allen Tannenbaum. Texture mapping via optimal mass transport. *IEEE transactions on visualization and computer graphics*, 16(3):419–433, 2010.
- [16] Arnaud Doucet and Adam M Johansen. A tutorial on particle filtering and smoothing: Fifteen years later. *Handbook of nonlinear filtering*, 12(656-704):3, 2009.
- [17] Tarek A El Moselhy and Youssef M Marzouk. Bayesian inference with optimal maps. *Journal of Computational Physics*, 231(23):7815–7850, 2012.
- [18] Geir Evensen. *Data Assimilation: The Ensemble Kalman Filter*. Springer Science & Business Media, 2006.
- [19] Jiaojiao Fan, Amirhossein Taghvaei, and Yongxin Chen. Scalable computations of Wasserstein barycenter via input convex neural networks. *arXiv preprint arXiv:2007.04462*, 2020.
- [20] Jiaojiao Fan, Amirhossein Taghvaei, and Yongxin Chen. Variational Wasserstein gradient flow. *arXiv preprint arXiv:2112.02424*, 2021.
- [21] Sira Ferradans, Nicolas Papadakis, Gabriel Peyré, and Jean-François Aujol. Regularized discrete optimal transport. *SIAM Journal on Imaging Sciences*, 7(3):1853–1882, 2014.
- [22] Jan-Christian Hütter and Philippe Rigollet. Minimax rates of

- estimation for smooth optimal transport maps. *arXiv preprint arXiv:1905.05828*, 2019.
- [23] Jin Won Kim and Prashant G Mehta. Duality for nonlinear filtering i: Observability. *arXiv preprint arXiv:2208.06586*, 2022.
- [24] Soheil Kolouri, Se Rim Park, Matthew Thorpe, Dejan Slepcev, and Gustavo K Rohde. Optimal mass transport: Signal processing and machine-learning applications. *IEEE signal processing magazine*, 34(4):43–59, 2017.
- [25] Nikola Kovachki, Ricardo Baptista, Bamdad Hosseini, and Youssef Marzouk. Conditional sampling with monotone GANs. *arXiv preprint arXiv:2006.06755*, 2020.
- [26] Shuang Liu, Olivier Bousquet, and Kamalika Chaudhuri. Approximation and convergence properties of generative adversarial learning. *Advances in Neural Information Processing Systems*, 30, 2017.
- [27] Ashok Makkuva, Amirhossein Taghvaei, Sewoong Oh, and Jason Lee. Optimal transport mapping via input convex neural networks. In *International Conference on Machine Learning*, pages 6672–6681. PMLR, 2020.
- [28] Youssef Marzouk, Tarek Moselhy, Matthew Parno, and Alessio Spantini. An introduction to sampling via measure transport. *arXiv preprint arXiv:1602.05023*, 2016.
- [29] Sean P Meyn and Richard L Tweedie. *Markov chains and stochastic stability*. Springer Science & Business Media, 2012.
- [30] Daniel Ocone and Etienne Pardoux. Asymptotic stability of the optimal filter with respect to its initial condition. *SIAM Journal on Control and Optimization*, 34(1):226–243, 1996.
- [31] Julien Rabin, Gabriel Peyré, Julie Delon, and Marc Bernot. Wasserstein barycenter and its application to texture mixing. In *International Conference on Scale Space and Variational Methods in Computer Vision*, pages 435–446. Springer, 2011.
- [32] Deep Ray, Harisankar Ramaswamy, Dhruv V Patel, and Assad A Oberai. The efficacy and generalizability of conditional GANs for posterior inference in physics-based inverse problems. *arXiv preprint arXiv:2202.07773*, 2022.
- [33] Patrick Rebeschini and Ramon Van Handel. Can local particle filters beat the curse of dimensionality? *The Annals of Applied Probability*, 25(5):2809–2866, 2015.
- [34] Sebastian Reich. A nonparametric ensemble transform method for Bayesian inference. *SIAM Journal on Scientific Computing*, 35(4):A2013–A2024, 2013.
- [35] Sebastian Reich. Data assimilation: The Schrödinger perspective. *Acta Numerica*, 28:635–711, 2019.
- [36] Filippo Santambrogio. Optimal transport for applied mathematicians. *Birkhäuser, NY*, 55(58-63):94, 2015.
- [37] Shai Shalev-Shwartz and Shai Ben-David. *Understanding machine learning: From theory to algorithms*. Cambridge university press, 2014.
- [38] Yuyang Shi, Valentin De Bortoli, George Deligiannidis, and Arnaud Doucet. Conditional simulation using diffusion Schrödinger bridges. In *Uncertainty in Artificial Intelligence*, pages 1792–1802. PMLR, 2022.
- [39] Ali Siahkoobi, Gabrio Rizzuti, Mathias Louboutin, Philipp A Witte, and Felix J Herrmann. Preconditioned training of normalizing flows for variational inference in inverse problems. *arXiv preprint arXiv:2101.03709*, 2021.
- [40] Alessio Spantini, Ricardo Baptista, and Youssef Marzouk. Coupling techniques for nonlinear ensemble filtering. *arXiv preprint arXiv:1907.00389*, 2019.
- [41] Zhengyu Su, Yalin Wang, Rui Shi, Wei Zeng, Jian Sun, Feng Luo, and Xianfeng Gu. Optimal mass transport for shape matching and comparison. *IEEE transactions on pattern analysis and machine intelligence*, 37(11):2246–2259, 2015.
- [42] Alain-Sol Sznitman. Topics in propagation of chaos. *Ecole d’été de probabilités de Saint-Flour XIX—1989*, 1464:165–251, 1991.
- [43] Amirhossein Taghvaei and Bamdad Hosseini. An optimal transport formulation of Bayes’ law for nonlinear filtering algorithms. In *2022 IEEE 61st Conference on Decision and Control (CDC)*, pages 6608–6613. IEEE, 2022.
- [44] Amirhossein Taghvaei and Prashant G Mehta. An optimal transport formulation of the linear feedback particle filter. In *2016 American Control Conference (ACC)*, pages 3614–3619. IEEE, 2016.
- [45] Amirhossein Taghvaei and Prashant G Mehta. An optimal transport formulation of the ensemble Kalman filter. *IEEE Transactions on Automatic Control*, 66(7):3052–3067, 2020.
- [46] Amirhossein Taghvaei and Prashant G Mehta. Optimal transportation methods in nonlinear filtering: The feedback particle filter. *arXiv preprint arXiv:2102.10712*, 2021.
- [47] Ilya Tolstikhin, Olivier Bousquet, Sylvain Gelly, and Bernhard Schölkopf. Wasserstein auto-encoders. *arXiv preprint arXiv:1711.01558*, 2017.
- [48] Ramon Van Handel. Observability and nonlinear filtering. *Probability theory and related fields*, 145:35–74, 2009.
- [49] Ramon Van Handel. Uniform observability of hidden Markov models and filter stability for unstable signals. 2009.
- [50] Ramon Van Handel. Nonlinear filtering and systems theory. In *Proceedings of the 19th International Symposium on Mathematical Theory of Networks and Systems (MTNS semi-plenary paper)*, 2010.
- [51] Cédric Villani. *Optimal Transport: Old and New*, volume 338. Springer, 2009.
- [52] Tao Yang, Richard S Laugesen, Prashant G Mehta, and Sean P Meyn. Multivariable feedback particle filter. *Automatica*, 71:10–23, 2016.
- [53] Tao Yang, Prashant G Mehta, and Sean P Meyn. Feedback particle filter. *IEEE transactions on Automatic control*, 58(10):2465–2480, 2013.
- [54] Pengchuan Zhang, Qiang Liu, Dengyong Zhou, Tao Xu, and Xiaodong He. On the discrimination-generalization tradeoff in GANs. *arXiv preprint arXiv:1711.02771*, 2017.