

AI-Newton：一种无需先验物理知识的概念驱动物理定律发现系统

You-Le Fang^{*} Dong-Shan Jian[†] Xiang Li[‡]
北京大学物理学院，中国北京 100871

Yan-Qing Ma[§]
北京大学物理学院，中国北京 100871
北京大学高能物理中心，中国北京 100871

2026 年 6 月 17 日

摘要

尽管当前由 AI 驱动的方法擅长从单个实验中推导经验模型，但揭示这些模型背后共同的基本物理规律仍然是一项重大挑战，而这正是人类物理学家所擅长的任务。为弥合这一差距，我们提出 AI-Newton，这是一种面向概念驱动科学发现的新框架。我们的系统能够直接从原始的多实验数据中自主推导一般物理定律，并且不依赖监督或任何先验物理知识。它的核心创新有两点：（1）提出可解释的物理概念来构造定律；（2）逐步把这些定律推广到更广泛的领域。将 AI-Newton 应用于一个大型且含噪声的力学实验数据集后，它成功重新发现了基础且普适的定律，例如 Newton 第二定律、能量守恒和万有引力。这项工作代表了朝向自主的、类人科学发现迈出的重要一步。

1 引言

几个世纪以来，基础物理研究的终极目标一直是通过少数被发现的定律来描述广泛现象。人工智能（AI）的进步，使 AI 驱动的科学发现成为一种极具前景的新范式 [1]。尽管 AI 在处理特定领域挑战方面已经取得显著成果 [2, 3]，但从范式转变的角度看，最终愿景仍然在于发展可靠的 AI 系统，使其能够在没有监督的情况下，直接从大量原始数据中自主完成科学发现 [4, 5]。

当前自动化物理发现方法主要关注单个实验，使用基于神经网络（NN）的方法 [6–25]，或符号技术 [26–33]。通过分析来自单个实验的数据，这些方法可以构造一个特定模型，用来预测同一实

^{*}eden@stu.pku.edu.cn

[†]dsjian@stu.pku.edu.cn

[‡]lix-PHY@pku.edu.cn

[§]yqma@pku.edu.cn




图 1: AI-Newton 的实验库、理论库和自主发现 workflow。

验的未来数据；如果模型足够简单，它甚至可以用符号形式表达 [34–36]。虽然这些方法代表了迈向自动化科学发现的关键且成功的阶段，但它们尚未达到可与人类物理学家相比的发现能力。

人类科学家会进一步辨识来自不同实验的特定模型之间的共同模式，并在此基础上形成可以解释所有这些实验数据的一般模型。例如，Newton 力学通过定义有意义的物理概念并建立适用于多种现象的一般定律，提供了一个统一且可解释的框架。因此，AI 驱动物理发现领域的核心挑战，是从面向具体问题的模型拟合，演进到能够发现本质上可推广且普遍适用知识的 AI 系统。

在本文中，我们提出 AI-Newton，这是一种概念驱动的发现系统，旨在回答一个关键问题：如何从面向具体问题的模型中抽取概念和一般定律。AI-Newton 整合了一个自主发现 workflow，其根基是似然推理和物理概念。给定一组物理实验，AI-Newton 可以在没有监督且没有任何先验物理知识的情况下，逐步形成一组适用于宽广问题范围的一般定律。作为一个概念验证实现¹，当把它应用于 46 个不同的经典力学实验时，它可以重新发现 Newton 第二定律、能量守恒、引力定律以及其他经典力学定律。

2 知识库与知识表示

AI-Newton 包含一个实验库和一个理论库，如图 1 所示。实验库保存物理实验以及对应的模拟数据生成器。每个实验的输入只包括所涉及的物理对象、几何信息、实验参数和时空坐标，这些输入共同定义一个实验。为强调没有使用先验物理知识，所有其他概念，例如质量或能量，都会在 AI-Newton 中自主发现。每个实验的输出是带有统计误差的模拟数据。

理论库以一个由符号、概念和定律相互连接而成的库，显式保存物理知识。这种设计模拟了人类物理学家如何从概念构件中构造简洁而普适的定律。与以往把 NN 中的潜在特征解释为物理概念的工作不同 [23, 37, 38]，AI-Newton 以显式的符号形式表示概念和定律。这极大增强了可解释

¹代码可在 <https://github.com/Science-Discovery/AI-Newton> 获取。

性，也使获得的知识更容易迁移到新问题。此外，引入强大的中间概念可以让复杂物理定律被简洁表达，进而使它们更适合通过符号回归（SR）等技术发现 [26–36]。初始时，概念层只包含时空坐标；新概念使用专门的物理领域特定语言（DSL）自主定义并注册。（详见补充材料（SMs） [39]。）

稳健的知识表示至关重要，因为我们的目标是让 AI 跨多样系统发现可推广知识，这要求知识能够在不同问题之间迁移。为实现这一点，我们设计了一种具有清晰结构的物理 DSL。该 DSL 不仅表达方程，还编码物理对象的属性以及物理量之间的关系。例如，在已知坐标 x 和时间 t 这两个概念时，球的速度可以在 DSL 中定义为：

$$C_1 := \forall i: \text{Ball}, dx[i]/dt, \quad (1)$$

其中 i 索引各个球， C_1 表示速度这一符号，测试之间下标 1 可以变化。除了速度这类动力学概念之外，系统还会自动识别另外两类概念：内禀概念（例如质量、弹簧常数），它们只依赖特定物理对象；以及普适常数（例如引力常数），它们不依赖任何其他量。二者都通过记录其测量程序来定义。例如，一个球的质量可以定义为：

$$C_2 := \forall i: \text{Ball}, \text{Intrinsic}[\text{ExpName}(o_1 \rightarrow i, o_2 \rightarrow s), L[s] - L_0[s]], \quad (2)$$

其中 ExpName 是实验名称。在该实验中，被测量的球 i 悬挂在固定弹簧 s 上，弹簧伸长量 $L[s] - L_0[s]$ 作为质量的测量值。记录内禀概念的测量程序是必要的，因为这允许通过调用其定义实验来取回内禀属性的值，从而确保不同问题之间的概念一致性。

这些显式概念是定律层的构件。定律层保存已发现的物理定律，例如守恒量和动力学方程。定律被分为特定定律和一般定律：特定定律只对一个具有特定形式的实验有效，一般定律则在多样实验中具有一般形式。在这一框架中，AI 驱动物理发现的既有研究主要集中于识别特定定律。引入一般定律使 AI-Newton 能够用紧凑简洁的表达同时描述各种复杂系统中的物理。例如，考虑一个斜面上的球通过弹簧连接到固定端的系统。应用 AI-Newton 发现的一般定律（ x 方向的 Newton 第二定律）：

$$\forall i: \text{Ball}, m_i a_{i,x} + (\nabla_i V_g)_x + (\nabla_i V_k)_x = 0, \quad (3)$$

可以具体推导出该球更复杂的动力学方程：

$$m a_x - \frac{c_x c_z}{c_x^2 + c_y^2 + c_z^2} m g + \frac{[(c_y^2 + c_z^2) x - c_x (c_y y + c_z z)]}{(c_x^2 + c_y^2 + c_z^2) L} k \Delta L = 0, \quad (4)$$

其中 (c_x, c_y, c_z) 是定义斜面的法向量。对于多对象系统，具体动力学方程可能比一般定律复杂得多，因此难以用以往符号方法获得。这些案例突出了我们这种概念驱动的层次化方法的有效性。

3 自主发现 workflow

AI-Newton 中的自主发现 workflow 会持续从实验数据中提炼知识；这些知识以物理概念和定律的形式表达，如图 1 所示。似然推理是一种基于不完全证据进行理性推断的方法 [40, 41]，它是发现知识的关键。不同于演绎逻辑，它产生的是在上下文中合理、而非普遍确定的结论，这与科学实践相似：在严格验证之前，先形成假设。

workflow 在每一次 trial 开始时，会从理论库中选择一个实验和少量概念。该选择由一个推荐引擎控制；推荐引擎把受 UCB 启发的价值函数 [42–46] 与动态适配的 NN 结合起来。NN 的架构会实时更新，以偏向能带来高效知识抽取的配置。该机制使系统能够模拟类人的学习方式，自然平衡探索与利用之间的权衡。

为确保 workflow 先建立基础知识，再处理复杂实验，我们引入 era-control 策略。在给定 era 内，每个 trial 都必须在特定的墙钟时间限制内结束。如果经过足够多 trial 后仍没有获得新知识，系统就进入一个新的 era，并指数级增加时间限制。因此，这一策略使系统在早期阶段专注于较简单的实验。（更多细节见 SMs [39]。）

每次 trial 的下一步，是从所选实验和概念中探索新定律。特定定律可以通过直接搜索所选概念在允许操作空间中的关系来发现，而这正是 SR。我们的 SR 实现结合了直接实例化-验证和基于 PCA 的微分多项式回归 [47–50]。此外，新的通用定律可能通过似然推理扩展既有定律而出现。这里似然推理的核心思想是：如果一个一般定律在多个实验中成立，却在当前实验中失败，那么有可能通过 SR 向原公式添加简单项，从而得到一个有效的修改后定律。例如，动能守恒支配弹性碰撞，但它在弹簧系统中失败。通过似然推理，AI-Newton 引入附加项（弹性势能）来恢复守恒。系统以类似人类研究实践的方式，启发式利用既有一般定律和所选概念，搜索能够解释新实验数据的物理定律。

上述过程可能生成冗余知识，使理论库和搜索空间都发生膨胀，从而在有限资源下严重阻碍持续发现。为解决这个问题，AI-Newton 会在每次 trial 中把物理定律简化为最小表示。对于本文展示的例子，我们使用微分代数中的 Rosenfeld Gröbner 算法 [51–54] 执行简化（详见 SMs [39]）。此外，通过受控变量分析，AI-Newton 会数值识别关系对物理对象和实验参数的依赖，并以这些依赖作为分类基础。

在识别新定律后，AI-Newton 通过似然推理从处理后的结果中抽取新概念：当前实验中的守恒量暗示其可能具有更广泛用途，从而触发它被抽取为新概念。类似地，系统也会从直接搜索到的特定定律中提出新的一般定律，只要这些特定定律也在多个其他实验中成立。所有累积知识都会更新到理论库中。

4 重新发现 Newton 力学定律

为评估 AI-Newton 的性能，我们把它应用于 Newton 力学问题，重点考察一组 46 个预定义实验。这些实验涉及三类主要物理对象：球（小球或天体）、弹簧和斜面。实验被设计用于研究孤立系




图 2: 已测试实验和发现的主要一般定律的示意图。为清晰起见, 省略了一些复杂配置。详见正文。

统和耦合系统, 如图 2 所示, 包括:

1. 单个球和弹簧的自由运动;
2. 球的弹性碰撞;
3. 展示平移振动、旋转振荡和类摆运动的耦合系统;
4. 与重力相关的问题, 例如抛体运动和斜面上的运动, 以及复杂的弹簧-球系统;
5. 涉及引力相互作用的天体力学问题。

实验复杂度通过改变物理对象数量和空间维度而系统增加, 涵盖高自由度问题, 例如斜面上链式 2 球-2 弹簧系统的耦合振荡、4 球-4 弹簧系统的旋转动力学, 以及其他复杂配置。为模拟真实实验条件, 所有测试数据都通过求解微分方程生成, 并加入 Gaussian 分布误差。这一综合实验设置覆盖了 Newton 力学中的三类力: 弹性力、地球表面附近的重力和万有引力, 同时包含真实的测量不确定性。由此, 它能够严格评估 AI-Newton 从含噪声实验数据中发现物理定律的能力。

我们在 Intel Xeon Platinum 8370C (128 threads @ 3.500GHz) 平台和 NVIDIA A40 GPU 上评估概念验证实现, 并配置 64 个核心用于并行处理。在最大 trial 数设为 1200、平均运行时间为 48 小时的条件下, 系统展示出稳健的知识发现能力: 在各测试案例中, 平均识别约 90 个物理概念和 50 条一般定律。如图 2 所示, 这些发现包括能量守恒、Newton 第二定律及其相关概念等重要一般定律, 能够为从简单系统到高自由度复杂配置的全部实验提供完整解释。

图 3 展示了 10 个测试案例中的统计发现进程, 显示了重要概念被发现时机的分布。该发现进程呈现增量模式: AI-Newton 首先探索简单概念 (例如质量), 然后推进到更复杂的概念 (例如力)。




图 3: 10 个测试案例中概念发现时间的统计分析，记录关键概念发现时机的均值和标准差。Number of trials 表示已完成的分析 trial 尝试次数，不区分具体实验。背景中的罗马数字 (I、II 等) 表示 era-control 策略定义的 eras。

例如，引力加速度 g 是通过分析自由落体或抛体运动而被定义为常数的；在这些运动中，球的竖直加速度 a_z 保持不变。在球的弹性碰撞实验中，动能 T 的守恒被发现并被提出为一般定律。通过似然推理，在尝试把动能守恒应用于非弹性实验时，弹性势能 V_k 、地球表面附近的重力势能 V_g 和万有引力势能 V_G 被逐步定义出来。随后，这些概念与动能守恒结合，最终形成完整的能量守恒定律。Newton 第二定律的发现遵循类似进程：它首先在一个简单实验语境中被提出，然后通过似然推理完成推广。

需要强调的是，系统能够从彼此不同的物理语境中独立发现并统一基础概念。例如，AI-Newton 可以通过两条不同实验路径推导出“质量”概念：一条来自重力作用下弹簧的静态伸长（定义引力质量 m_g ），另一条来自水平弹簧-质量振荡系统实验（定义惯性质量 m_i ）。关键的是，系统随后自主验证 m_g 与 m_i 的数值等价性，这实际上从原始数据中指出了广义相对论的一个基石，即弱等效原理。

5 总结

我们提出 AI-Newton，这是一种新框架，能够在没有监督和已有物理知识的情况下，从跨大量实验的原始数据中自主发现一般物理定律。该方法超越了当前 AI 驱动方法的局限；现有方法主要从单个实验中抽取特定定律。我们的主要贡献基于似然推理，使我们能够：(1) 从抽取出的定律中

提出物理概念；(2) 通过添加新项来扩展已有一般定律，使其适配并描述更广泛的实验。引入可解释的物理概念，使被发现的定律保持简洁，从而更易于由 SR 识别。此外，通过从既有一般定律迭代构造新的一般定律，可以形成一个渐进且可扩展的发现过程。将 AI-Newton 应用于一个大型且含噪声的力学实验数据集后，它成功重新发现了基础定律，包括 Newton 第二定律、能量守恒和万有引力定律。因此，这项工作为构建能够参与前沿科学研究的 AI 系统提供了一条有前景的路径。

作为第一步，我们使用 AI-Newton 来重新发现已知物理定律。在这类任务中，直接依赖大语言模型 (LLM) 并不合适，因为它们已经拥有这些知识。然而，在未来面向前沿科学的应用中，该框架中的 DSL、推荐引擎和似然推理组件可以由 LLM 替代或增强。这种整合将使系统能够直接访问所有既有知识，从而实现更有信息量且更高效的发现过程。

致谢

我们感谢 Hong-Fei Zhang 早期参与本项目并提供许多有价值的讨论。本工作得到国家自然科学基金 (No. 12325503) 以及北京大学高性能计算平台的支持。

参考文献

- [1] Y. Xu, X. Liu, X. Cao, C. Huang, E. Liu, S. Qian, X. Liu, Y. Wu, F. Dong, C.-W. Qiu, *et al.*, *Artificial intelligence: A powerful paradigm for scientific research*, *The Innovation* **2** (2021) .
- [2] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, *et al.*, *Scientific discovery in the age of artificial intelligence*, *Nature* **620** (2023) 47–60.
- [3] X. Zhang, L. Wang, J. Helwig, Y. Luo, C. Fu, Y. Xie, M. Liu, Y. Lin, Z. Xu, K. Yan, *et al.*, *Artificial intelligence for science in quantum, atomistic, and continuum systems*, *Foundations and Trends® in Machine Learning* **18** (2025) 385–912.
- [4] C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune, and D. Ha, *The ai scientist: Towards fully automated open-ended scientific discovery*, [[arXiv:2408.06292](https://arxiv.org/abs/2408.06292)].
- [5] C. K. Reddy and P. Shojaei, *Towards scientific discovery with generative ai: Progress, opportunities, and challenges*, *Proceedings of the AAAI Conference on Artificial Intelligence* **39** (Apr., 2025) 28601–28609.
- [6] M. Schmidt and H. Lipson, *Distilling free-form natural laws from experimental data*, *science* **324** (2009) 81–85.

- [7] S. Brunton, J. Proctor, and J. Kutz, *Discovering governing equations from data: Sparse identification of nonlinear dynamical systems*, *Proceedings of the National Academy of Sciences* **113** (09, 2015) 3932–3937.
- [8] K. Champion, B. Lusch, J. N. Kutz, and S. L. Brunton, *Data-driven discovery of coordinates and governing equations*, *Proceedings of the National Academy of Sciences* **116** (2019) 22445–22451.
- [9] T. Wu and M. Tegmark, *Toward an artificial intelligence physicist for unsupervised learning*, *Physical Review E* **100** (2019) 033311.
- [10] S. Greydanus, M. Dzamba, and J. Yosinski, *Hamiltonian neural networks*. Curran Associates Inc., Red Hook, NY, USA, 2019.
- [11] M. Cranmer, S. Greydanus, S. Hoyer, P. Battaglia, D. Spergel, and S. Ho, *Lagrangian neural networks*, [[arXiv:2003.04630](https://arxiv.org/abs/2003.04630)].
- [12] B. M. De Silva, D. M. Higdon, S. L. Brunton, and J. N. Kutz, *Discovery of physics from data: Universal laws and discrepancies*, *Frontiers in artificial intelligence* **3** (2020) 25.
- [13] Z. Liu and M. Tegmark, *Machine learning conservation laws from trajectories*, *Physical Review Letters* **126** (2021) 180604.
- [14] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, and L. Yang, *Physics-informed machine learning*, *Nature Reviews Physics* **3** (2021) 422–440.
- [15] Z. Liu, V. Madhavan, and M. Tegmark, *Machine learning conservation laws from differential equations*, *Physical Review E* **106** (2022) 045307.
- [16] G. Camps-Valls, A. Gerhardus, U. Ninad, G. Varando, G. Martius, E. Balaguer-Ballester, R. Vinuesa, E. Diaz, L. Zanna, and J. Runge, *Discovering causal relations and equations from data*, *Physics Reports* **1044** (2023) 1–68.
- [17] C. Cornelio, S. Dash, V. Austel, T. R. Josephson, J. Goncalves, K. L. Clarkson, N. Megiddo, B. El Khadir, and L. Horesh, *Combining data and theory for derivable scientific discovery with ai-descartes*, *Nature Communications* **14** (2023) 1777.
- [18] P. Lemos, N. Jeffrey, M. Cranmer, S. Ho, and P. Battaglia, *Rediscovering orbital mechanics with machine learning*, *Machine Learning: Science and Technology* **4** (2023) 045002.
- [19] Z. Liu, P. O. Sturm, S. Bharadwaj, S. J. Silva, and M. Tegmark, *Interpretable conservation laws as sparse invariants*, *Phys. Rev. E* **109** (Feb, 2024) L023301.

- [20] R. Cory-Wright, C. Cornelio, S. Dash, B. El Khadir, and L. Horesh, *Evolving scientific discovery by unifying data and background knowledge with ai hilbert*, [*Nature Communications* **15** \(2024\) 5922](#).
- [21] D. Zheng, V. Luo, J. Wu, and J. B. Tenenbaum, *Unsupervised learning of latent physical properties using perception-prediction networks*, [[arXiv:1807.09244](#)].
- [22] M. Tegmark, *Latent Representations of Dynamical Systems: When Two is Better Than One*, [[arXiv:1902.03364](#)].
- [23] R. Iten, T. Metger, H. Wilming, L. Del Rio, and R. Renner, *Discovering physical concepts with neural networks*, [*Physical review letters* **124** \(2020\) 010508](#).
- [24] B. Chen, K. Huang, S. Raghupathi, I. Chandratreya, Q. Du, and H. Lipson, *Automated discovery of fundamental variables hidden in experimental data*, [*Nature Computational Science* **2** \(2022\) 433–442](#).
- [25] Q. Li, T. Wang, V. Roychowdhury, and M. K. Jawed, *Metalearning generalizable dynamics from trajectories*, [*Physical Review Letters* **131** \(2023\) 067301](#).
- [26] S.-M. Udrescu and M. Tegmark, *Ai feynman: A physics-inspired method for symbolic regression*, [*Science Advances* **6** \(2020\) eaay2631](#).
- [27] S.-M. Udrescu, A. Tan, J. Feng, O. Neto, T. Wu, and M. Tegmark, *Ai feynman 2.0: Pareto-optimal symbolic regression exploiting graph modularity*, [*Advances in Neural Information Processing Systems* **33** \(2020\) 4860–4871](#).
- [28] T. Bendinelli, L. Biggio, and P.-A. Kamienny, *Controllable neural symbolic regression*, in *International Conference on Machine Learning*, pp. 2063–2077, PMLR. 2023.
- [29] W. Tenachi, R. Ibata, and F. I. Diakogiannis, *Deep symbolic regression for physics guided by units constraints: toward the automated discovery of physical laws*, [*The Astrophysical Journal* **959** \(2023\) 99](#).
- [30] Y. Tian, W. Zhou, M. Viscione, H. Dong, D. Kammer, and O. Fink, *Interactive symbolic regression with co-design mechanism through offline reinforcement learning*, [*Nature Communications* **16** \(04, 2025\) .](#)
- [31] M. Cranmer, *Interpretable machine learning for science with pysr and symbolicregression. jl*, [[arXiv:2305.01582](#)].
- [32] M. Du, Y. Chen, Z. Wang, L. Nie, and D. Zhang, *Large language models for automatic equation discovery of nonlinear dynamics*, [*Physics of Fluids* **36** \(2024\) .](#)

- [33] B. Romera-Paredes, M. Barekatin, A. Novikov, M. Balog, M. P. Kumar, E. Dupont, F. J. Ruiz, J. S. Ellenberg, P. Wang, O. Fawzi, *et al.*, *Mathematical discoveries from program search with large language models*, *Nature* **625** (2024) 468–475.
- [34] M. Valipour, B. You, M. Panju, and A. Ghodsi, *Symbolicgpt: A generative transformer model for symbolic regression*, *arXiv:2106.14131* (2021) .
- [35] X. Chu, H. Zhao, E. Xu, H. Qi, M. Chen, and H. Shao, *Neural symbolic regression using control variables*, [[arXiv:2306.04718](https://arxiv.org/abs/2306.04718)].
- [36] S. Mežnar, S. Džeroski, and L. Todorovski, *Efficient generator of mathematical expressions for symbolic regression*, *Machine Learning* **112** (2023) 4563–4596.
- [37] C. Wang, H. Zhai, and Y.-Z. You, *Emergent schrödinger equation in an introspective machine learning architecture*, *Science Bulletin* **64** (2019) 1228–1233.
- [38] B.-B. Li, Y. Gu, and S.-F. Wu, *Discover physical concepts and equations with machine learning*, [[arXiv:2412.12161](https://arxiv.org/abs/2412.12161)].
- [39] “See the arXiv supplemental material for details on the domain-specific language, recommendation engine, and computational engine.”
- [40] G. Pólya, *Mathematics and plausible reasoning: Induction and analogy in mathematics*, vol. 1. Princeton University Press, 1990.
- [41] G. Pólya, *Mathematics and Plausible Reasoning: Patterns of plausible inference*, vol. 2. Princeton University Press, 1990.
- [42] T. Lai and H. Robbins, *Asymptotically efficient adaptive allocation rules*, *Adv. Appl. Math.* **6** (Mar., 1985) 4–22.
- [43] T. L. Lai, *Adaptive treatment allocation and the multi-armed bandit problem*, *The Annals of Statistics* **15** (1987) 1091–1114. <http://www.jstor.org/stable/2241818>.
- [44] R. Agrawal, *Sample mean based index policies by o (log n) regret for the multi-armed bandit problem*, *Advances in applied probability* **27** (1995) 1054–1078.
- [45] M. N. Katehakis and H. Robbins, *Sequential choice from several populations.*, *Proceedings of the National Academy of Sciences* **92** (1995) 8584–8585.
- [46] P. Auer, *Using confidence bounds for exploitation-exploration trade-offs*, *Journal of Machine Learning Research* **3** (2002) 397–422. <https://www.jmlr.org/papers/volume3/auer02a/auer02a.pdf>.

- [47] K. Pearson, *Liii. on lines and planes of closest fit to systems of points in space*, *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* **2** (1901) 559–572.
- [48] L. Wang, *Discovering phase transitions with unsupervised learning*, *Phys. Rev. B* **94** (Nov, 2016) 195105.
- [49] H. Kiwata, *Deriving the order parameters of a spin-glass model using principal component analysis*, *Physical Review E* **99** (2019) 063304.
- [50] D. Yevick, *Conservation laws and spin system modeling through principal component analysis*, *Computer Physics Communications* **262** (2021) 107832.
- [51] F. Boulier, D. Lazard, F. Ollivier, and M. Petitot, *Representation for the radical of a finitely generated differential ideal*, in *Proceedings of the 1995 international symposium on Symbolic and algebraic computation*, ISSAC '95, pp. 158–166. Association for Computing Machinery, New York, NY, USA, 1995.
- [52] F. Boulier, D. Lazard, F. Ollivier, and M. Petitot, *Computing representations for radicals of finitely generated differential ideals*, *Applicable Algebra in Engineering, Communication and Computing* **20** (2009) 73–121.
- [53] Maplesoft, *Differential algebra in maple*, *Maplesoft Help Center* (2024) . <https://cn.maplesoft.com/support/help/Maple/view.aspx?path=DifferentialAlgebra>.
- [54] Maplesoft, *Maple 2024*, 2024. <https://www.maplesoft.com/products/maple/>.