
面向机器学习者的最优传输

Gabriel Peyré
CNRS 与 ENS, PSL Université
gabriel.peyre@ens.fr

2026 年 6 月 19 日

摘要

现代机器学习反复操作概率测度：经验数据集、生成样本、潜在分布、类条件定律、粒子系统、宽网络的权重以及注意力模式。最优传输在这一场景中有用，是因为它通过询问质量应如何移动来比较这些对象。因此，它把一种具有统计意义的差异概念，与插值、对偶证书和变分动力学的几何结合起来。这使 OT 成为损失、生成建模、领域适应、鲁棒学习、重心、梯度流以及学习算法的平均场描述的共同语言。

本书在这些机器学习用途的背景下介绍主要的 OT 技术。它从有限指派和 Monge 映射视角出发，经过 Kantorovich 耦合和对偶势，再解释使传输可用的算法思想：线性规划、半离散单元、Sinkhorn 缩放和低维投影。随后，这些同一对象被作为测度的几何重新使用，给出 Wasserstein 距离、重心、梯度流、动态表述以及高斯/Bures 公式。最后几章强调与现代 ML 最相关的变体：散度和对抗损失、熵正则化与非平衡松弛、鲁棒或谱的底层几何、Gromov 与量子扩展，以及生成模型、平均场网络和注意力动力学的基于传输的视角。目标是在保持数学明确的同时，展示把 OT 转化为机器学习者可用工具箱所需的计算和几何直觉。

本书的所有材料，包括用于复现图形的代码，均可在 [gpeyre/ot4ml](https://github.com/gpeyre/ot4ml) 获取。大多数计算图形使用 Python Optimal Transport (POT) 库生成 [90]。作者诚挚感谢 POT 团队和贡献者，他们为向社区提供可靠的最优传输算法付出了重要且持续的努力。

文献指南与范围

已有多本著作从互补视角讨论最优传输。Rachev 和 Rüschendorf 的两卷本专著 [190, 191] 对质量传输及其应用给出了广泛的概率论处理。Villani 的著作 [225, 226] 是现代数学理论的标准参考，涵盖从 Kantorovich 对偶到曲率、集中性和几何分析。Santambrogio 的教材 [202] 通过同样的基础给出了一条简洁的应用数学路径，并强烈强调 PDE 和变分论证。Ambrosio、Gigli 和 Savaré [7] 发展了梯度流的度量空间理论，它构成了本主题动力学部分的基础。

在计算方面，Peyré 和 Cuturi [185] 提供了数值 OT、熵正则化以及数据科学应用的参考性论述。Galichon 的著作 [96] 解释了经济学和匹配理论的视角，而 OT 的统计理论则在 Chewi、Niles-Weed 和 Rigollet 近期的讲义 [62] 中得到发展。近期综述通过强调可扩展算法和机器学习应用 [131, 168]，以及 OT 在成像和图形学中的作用 [39]，对这些书作了补充。这些参考文献仍然是寻找完整证明、历史细节和专门变体的自然去处。

这里的目标不同，也更具选择性。本书保持核心数学的明确性，但围绕机器学习中反复出现的问题来组织：如何比较奇异的经验测度，如何计算可微的传输损失，正则化如何改变优化和统计，对偶势如何成为判别器，以及传输几何如何产生粒子、神经元和词元的流。因此，本书意在作出的贡献并不是替代上述参考文献，而是在严格的 OT 与现代 ML 中使用它所需的几何直觉之间搭建一座紧凑的桥梁。

目录

摘要	i
文献指南与范围	ii
第一章 点云之间的最优匹配	1
1.1 离散点的 Monge 问题	1
1.2 匹配算法	6
第二章 测度之间的 Monge 问题	9
2.1 测度	9
2.2 推前	11
2.3 Monge 表述	12
2.4 Monge 映射的存在性与唯一性	14
2.5 一维传输与分位数	18
2.6 高斯测度与 Bures 度量	21
第三章 Kantorovich 松弛	24
3.1 离散松弛	24
3.2 线性规划算法	29
3.3 任意测度的松弛	30
3.4 c -循环单调性	33
3.5 度量性质: Wasserstein 距离	34
3.6 度量性质: 拓扑与应用	38
3.7 Wasserstein 上的 Wasserstein	41
3.8 分布鲁棒性与 W_∞	42
3.9 定量中心极限定理	44
第四章 对偶问题	45
4.1 离散对偶	45
4.2 拍卖算法与对偶价格	46
4.3 一般表述	47
4.4 c -变换	48
第五章 半离散与 W_1	52
5.1 半对偶	52
5.2 半离散	52
5.3 最优量化	54
5.4 W_1	56
第六章 散度与对偶范数	60
6.1 对偶范数 (积分概率度量)	60
6.2 对偶 RKHS 范数与最大均值差异	61
6.3 φ -散度	63
6.4 通过对偶性理解 GAN	66
第七章 熵正则化: Sinkhorn 算法	68
7.1 离散测度的熵正则化	68
7.2 Sinkhorn 算法	69
7.3 使用相对熵的重述	72
7.4 一般形式	75
7.5 路径空间 Schrödinger 问题	75

7.6 Sinkhorn 的对偶	78
7.7 其他凸正则化项	81
7.8 Sinkhorn 散度	84
第八章 熵正则化：收敛性	87
8.1 Sinkhorn 收敛性：Bregman 视角	87
8.2 Sinkhorn 收敛性：单调视角	89
8.3 Sinkhorn 收敛性：次线性稳健速率	90
8.4 Sinkhorn 收敛性：Hilbert 度量线性速率	92
8.5 高斯之间的熵最优传输	94
8.6 样本复杂度	96
第九章 广义 Wasserstein 距离	99
9.1 非平衡最优传输	99
9.2 切片 Wasserstein 距离	102
9.3 向量分位数与线性最优传输	105
9.4 谱与稳健 Wasserstein 距离	106
第十章 广义最优传输问题	109
10.1 最优传输重心	109
10.2 多边缘最优传输	113
10.3 度量学习与逆最优传输	114
10.4 弱最优传输	117
第十一章 超越测度比较	120
11.1 向量值与矩阵值测度	120
11.2 Gromov–Wasserstein	123
11.3 量子最优传输	126
第十二章 动态最优传输	131
12.1 测度空间上的演化	131
12.2 Benamou–Brenier 的最优传输动态表述	133
第十三章 Wasserstein 梯度流	137
13.1 最小化运动与 Wasserstein 梯度	137
13.2 测地凸性与收敛	142
13.3 把两层 MLP 训练看作 Wasserstein 流	145
第十四章 通过传输的生成模型	148
14.1 通过流匹配的生成模型	148
14.2 一步生成模型	154
14.3 Transformer 的深度演化	156
14.4 高斯流形上的流	158
结论	163
致谢	163
附录 A 记号表	177
索引	181

点云之间的最优匹配

本开篇章节分离出最优传输最简单的形式：将两个有限点云配对。其要点同时是算法性的和几何性的：可以看到传输的组合本质、直线上的特殊简洁性，以及在更高维中凸松弛将成为必要的最初迹象。匈牙利方法和拍卖方法等经典指派算法 [136, 26] 提供了计算背景，而几何例子则为 Kantorovich 松弛作准备。

1.1 离散点的 Monge 问题

本节把匹配表述为两个等权点云上的 Monge 确定性传输问题。一维情形是一个透明的参照情形，其中最优映射可以通过排序直接读出。

匹配问题 给定代价矩阵 $(C_{i,j})_{i \in [n], j \in [m]}$ 并假设 $n = m$ ，最优指派问题旨在 n 个元素的排列集合 $\text{Perm}(n)$ 中寻找一个双射 σ ，使其求解

$$\min_{\sigma \in \text{Perm}(n)} \frac{1}{n} \sum_{i=1}^n C_{i, \sigma(i)}. \quad (1.1)$$

可以朴素地使用集合 $\text{Perm}(n)$ 中的所有排列来评估上述代价函数。然而，这个集合的大小为 $n!$ ，即使 n 很小也会变得巨大。一般而言，最优的 σ 并不唯一。

一维情形 在一维中，对于凸代价，匹配定义一个单调映射。

命题 1.1 (直线上的单调匹配). 假设点 $(x_i)_i$ 和 $(y_j)_j$ 两两不同。如果代价具有形式 $C_{i,j} = h(x_i - y_j)$ ，其中 $h: \mathbb{R} \rightarrow \mathbb{R}^+$ 是严格凸的（例如，当 $p > 1$ 时 $C_{i,j} = |x_i - y_j|^p$ ），那么任意最优 σ 都定义一个严格递增映射 $x_i \mapsto y_{\sigma(i)}$ （因而唯一），即

$$\forall (i, i'), \quad (x_i - x_{i'})(y_{\sigma(i)} - y_{\sigma(i')}) > 0.$$

证明. 确实，如果这一性质被违反，即存在 (i, i') 使得 $(x_i - x_{i'})(y_{\sigma(i)} - y_{\sigma(i')}) < 0$ ，那么可以通过交换匹配来定义一个排列 $\tilde{\sigma}$ ，即 $\tilde{\sigma}(i) = \sigma(i')$ 且 $\tilde{\sigma}(i') = \sigma(i)$ ，从而得到严格更小的代价，正如下述事实所证明。令 $h: \mathbb{R} \rightarrow \mathbb{R}$ 严格凸，并令 $x < x'$ 且 $y < y'$ 。则

$$h(x - y) + h(x' - y') < h(x - y') + h(x' - y).$$

设间隙 $d := y' - y > 0$ ，并对每个 $s \in \mathbb{R}$ 定义

$$D(s) := \frac{h(s) - h(s-d)}{d} \quad \text{且} \quad \Delta := h(x - y') + h(x' - y) - h(x - y) - h(x' - y') = d(D(x' - y) - D(x - y)).$$

由于 h 严格凸， D 严格递增。因为 $x - y < x' - y$ ，单调性给出 $D(x - y) < D(x' - y)$ ，也就是 $\Delta > 0$ 。□

这一性质通过连续性扩展到诸如 $|x - y|$ 这样的凸（但非严格凸）代价，不过在这种情况下，匹配不一定唯一。因此，对于凸代价，计算最优传输的算法是对点排序，即找到某对排列 σ_X, σ_Y 使得

$$x_{\sigma_X(1)} \leq x_{\sigma_X(2)} \leq \dots \quad \text{and} \quad y_{\sigma_Y(1)} \leq y_{\sigma_Y(2)} \leq \dots$$

然后最优匹配是映射 $x_{\sigma_X(k)} \mapsto y_{\sigma_Y(k)}$ ，即一个最优传输为 $\sigma = \sigma_Y \circ \sigma_X^{-1}$ 。因此，使用例如快速排序算法，总计算代价为 $O(n \log(n))$ 。

如果距离剖面是凹的而不是凸的，几何会发生变化。对于 $c_p(x, y) = |x - y|^p$ 且 $0 < p < 1$ 这样的代价，把一个位移拆成若干更小的位移是昂贵的，因此最优匹配倾向于产生长距离交换，而不是单调的同秩配对；见图 1.1。这是 Gangbo 和 McCann [99] 研究的严格凹情形。

实数直线仍然给出特殊结构。将所有红点和蓝点一起排序后，有序序列分解为极大交替链，而局部匹配指标可以认证在最优解中必须匹配的点对。移除这些已认证的点对并重复这一过程，会得到单位质

算法 1.1 一维排序指派

输入： $\mathbb{R}$ 上的等权点云 $(x_i)_{i=1}^n, (y_j)_{j=1}^n$ ；凸代价 $h(x - y)$ 。

输出： 最优排列 σ 。

排序源点和目标点： $x_{\sigma_X(1)} \leq \dots \leq x_{\sigma_X(n)}, \quad y_{\sigma_Y(1)} \leq \dots \leq y_{\sigma_Y(n)}$ 。

对 $k = 1, \dots, n$ 执行：

匹配 $x_{\sigma_X(k)}$ 与 $y_{\sigma_Y(k)}$ 。

返回 $\sigma = \sigma_Y \circ \sigma_X^{-1}$ 。

量平衡指派问题的精确分层算法；在 Delon、Salomon 和 Sobolevski [77] 的框架中，最坏情况复杂度为 $O(n^2)$ 。非常凹的代价也会激发更简单的贪心启发式方法，例如 Ottolini 和 Steinerberger [177] 所研究的那些方法。关键在于，这些方法并不是通用的线性规划求解器；它们利用了一维次序和距离剖面的凹性。

所得构造性规则总结为算法 1.2。

算法 1.2 通过局部指标的凹直线匹配

输入： $\mathbb{R}$ 上的单位质量源点和目标点；严格凹的距离代价。

输出： 最优凹代价匹配 M 。

排序直线上的合并红蓝序列。

分解为极大交替链。

初始化： 置 $M = \emptyset$ 。

当仍有未匹配点时 执行：

对每条活跃交替链 执行：

计算局部匹配指标 [77]。

若某个指标认证点对 (i, j) 则：

更新 $M \leftarrow M \cup \{(i, j)\}$ 。

移除点 i 和 j 。

仅重新计算受移除影响的链。

返回 M 。

注意，如果 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 是递增映射，则可以通过变量变换，将这一技术应用于形如 $h(|\varphi(x) - \varphi(y)|)$ 的代价。一个典型应用是灰度直方图均衡化。图像亮度值的经验累积分布被传输到一个给定的目标直方图，例如集中直方图或参考图像直方图。在一维中，上述单调重排给出精确的传输映射，因此该操作在计算上简单，并且在几何上忠实：它匹配的是强度分布，而不是单个像素。




图 1.3: 直方图均衡化可视为像素强度上的一维 Monge 传输。该映射是单调重排 $T = Q_\beta \circ F_\alpha$ ，使用后文定义 2.29 中定义的累积函数和分位数函数；这里 β 是集中在暗强度附近的截断高斯。图像通过 $I_t = (1 - t)I + tT(I)$ 逐点插值，所有直方图共享相同的纵向尺度，以使强度质量的位移在时间上可比较。

注意，如果 h 严格凸，则所有最优指派都是递增的，并且如果所有点都不同，这个递增映射是唯一的。如果 h 不是严格凸的，例如 $c(x, y) = |x - y|$ ，也可能存在非递增的最优指派。例如，在具有重叠均匀分布的书本平移问题中就会发生这种情况，其中交集的质量可以保持不动。




图 1.1: 有序源点云和目标点云在代价 $c_p(x, y) = |x - y|^p$ 下的一维指派。上排使用单高斯源点云和目标点云；下排使用更密集的双分量源和三分量目标。对于凸二次代价，同秩点被匹配，线段不交叉。对于凹代价，最优解产生交叉的交替链；有序直线仍然有用，但它通过凹传输的交替链结构发挥作用，而不是通过单调重排。




图 1.2: 通过分位数排序的一维最优匹配。红色和蓝色曲线是用于生成等权经验测度的光滑定律；点是在共同分位数水平上的逆累积分布函数样本。无论是两个高斯混合分布，还是从一个中心高斯到三模态目标定律的传输，单调指派都连接同秩点。

圆周上的最优传输。 直线上的排序规则有一个周期性类似物。将圆周等同于 $S^1 = \mathbb{R}/\mathbb{Z}$ ，令

$$d_{S^1}(x, y) := \min_{k \in \mathbb{Z}} |x - y + k|, \quad c_p(x, y) := d_{S^1}(x, y)^p, \quad p > 1.$$

与直线相比，唯一额外的数据是在哪里打开圆周。一旦选择了一个切口，圆周就被展开为区间，并且可以使用一维单调指派。在离散情形中，改变切口等同于对两个圆周排序中的一个施加循环移位。

命题 1.2 (通过切口的离散圆周传输). 令 $x_1, \dots, x_n$ 和 $y_1, \dots, y_n$ 是 S^1 上两族不同点，且具有相等权重。令 $x_{(1)}, \dots, x_{(n)}$ 和 $y_{(1)}, \dots, y_{(n)}$ 表示任意固定的循环排序，并采用约定 $y_{(k+n)} = y_{(k)}$ 。对于代价 c_p , $p > 1$ ，一个最优指派是下列循环移位之一

$$x_{(k)} \mapsto y_{(k+s)}, \quad k \in \llbracket n \rrbracket, \quad s \in \{0, \dots, n-1\},$$

并通过最小化

$$\sum_{k=1}^n d_{S^1}(x_{(k)}, y_{(k+s)})^p$$

在 n 个可能移位上的值来找到。等价地，对于一个最优移位，可以选择切口 $\theta \in S^1 \setminus (\{x_i\}_i \cup \{y_j\}_j)$ ，使得在将所有点提升到 $(\theta, \theta + 1)$ 并排序之后，最优匹配就是该区间上的同秩单调匹配。

证明。 如果两个已匹配点对的源端点圆周次序与目标端点圆周次序相反，则称它们循环反转。在最优指派中，选择此类反转数量最少的一个。基本交换步骤是命题 1.1 中直线论证的圆周类似物：如果两个已匹配点对反转，则在一个不遇到这四个端点的间隙处切开圆周，并选择整数提升，可以把交换中涉及的四个测地距离实现为两个有序源提升点和两个反向有序目标提升点之间的普通距离。于是，严格凸函数

$r \mapsto |r|^p$ 的一维 Monge 不等式表明, 交换这两个目标不会增加代价, 并且除非四个端点处于退化平局配置, 否则会降低代价。

因此, 可以选择一个没有循环反转的最优指派。两个有限循环有序集合之间没有循环反转的双射就是次序的一个旋转, 因而是一个循环移位。这个移位指定了应如何打开两个循环排序; 在这一切口之后, 旋转变成普通线性次序, 而匹配就是展开区间上的同秩单调指派。反过来, 每个切口给出一个这样的循环移位, 因此在有限多个移位上最小化给出最优离散圆周指派。重复点或平局通过任意小扰动后的同一论证以及取极限得到。这是 [76] 的快速圆周 Monge 构造的离散形式。□

算法 1.3 通过切开的圆周指派

输入: $\mathbb{S}^1$ 上的等权点 $(x_i)_{i=1}^n, (y_j)_{j=1}^n$; 代价 $d_{\mathbb{S}^1}^p$ 。

输出: 最优循环指派。

令 $x_{(1)}, \dots, x_{(n)}$ 和 $y_{(1)}, \dots, y_{(n)}$ 为从固定原点出发按角度递增排序的点。

对 $s = 0, \dots, n-1$ **执行:**

$E_s = \sum_{k=1}^n d_{\mathbb{S}^1}^p(x_{(k)}, y_{(k+s)})^p, \quad y_{(k+n)} = y_{(k)}.$

置 $s^* = \min \arg \min_{0 \leq s < n} E_s$ 。

在将移位 s^* 的两个连续已匹配点对分开的空弧中 置 θ_{cut} 。

将每个角替换为其在 $[\theta_{\text{cut}}, \theta_{\text{cut}} + 2\pi)$ 中的代表元。返回 $x_{(k)} \mapsto y_{(k+s^*)}$ 。




图 1.4: 通过切开和展开实现圆周上的最优传输。红色和蓝色原子位于圆周的两个副本上; 较密的点云使循环排序可见。紫色线段显示最优匹配, 绿色半径标记所选切口。一旦圆周在这个角度打开, 同一匹配就表现为区间上的单调一维指派, 其中两个绿色端点被等同。

有理权重。 严格指派模型也绑定于相等基数和相等权重。一旦目标分辨率改变, 或者权重不均匀, 排列就不再描述可行传输。取而代之, 需要一个具有给定行和列和的非负传输矩阵, 如图 1.6 所示; 这就是第三章发展的有限维 Kantorovich 松弛。


命题 1.3 (作为复制均匀匹配的有理权重). 令

$$\mu = \sum_{i=1}^n \frac{k_i}{N} \delta_{x_i}, \quad \nu = \sum_{j=1}^m \frac{\ell_j}{N} \delta_{y_j}, \quad \sum_i k_i = \sum_j \ell_j = N,$$

其中 $k_i, \ell_j \in \mathbb{N}$. (μ, ν) 之间的离散 Kantorovich 问题等价于如下均匀指派问题: 用 k_i 个相同副本替换每个 x_i , 并用 ℓ_j 个相同副本替换每个 y_j . 更准确地说, 在将传输质量乘以 N 后, 最优耦合对应于具有行和 k_i 、列和 ℓ_j 的最优整数计数矩阵 (n_{ij}) , 而这些计数矩阵正是复制点云之间指派的折叠形式。

证明. 复制后的源点云与目标点云之间的任意指派都定义整数 n_{ij} , 计数有多少个 x_i 类型的复制粒子被匹配到 y_j 类型的复制粒子。这些计数满足 $\sum_j n_{ij} = k_i$ 和 $\sum_i n_{ij} = \ell_j$, 并且相关耦合 $P_{ij} = n_{ij}/N$ 具有边缘 k_i/N 和 ℓ_j/N . 指派代价为

$$\frac{1}{N} \sum_{i,j} n_{ij} c(x_i, y_j) = \sum_{i,j} P_{ij} c(x_i, y_j).$$




$$c(x, y) = \|x - y\|$$

$$c(x, y) = \|x - y\|^2$$

$$c(x, y) = \|x - y\|^6$$

图 1.5: 同两个点云之间在欧氏距离的三个幂次下的最优指派。源原子是中心圆盘中的半规则样本, 而目标原子是薄环带上的半规则样本; 这一典型几何将在后续耦合和正则化图中复用。可行集不变, 但增大 p 会更强烈地惩罚最长边, 并改变排列的全局组织。



$$n = m$$

$$m < n$$

$$n = m \text{ 但 } b_j \neq 1/n$$

图 1.6: 从指派到传输计划, 使用与图 1.5 相同的圆盘到环带几何。在平衡等权情形中, 每个源原子匹配到一个目标原子。当目标点云的原子数只有一半, 或者目标权重强烈非均匀时, 耦合矩阵可以合并或分裂质量; 线段粗细和不透明度编码其非零项, 蓝色标记面积编码给定目标质量。

反过来, 任意具有这些行和列和的非负整数计数矩阵都可以通过匹配相应的复制粒子来实现。最后, 运输约束矩阵是全幺模的, 因此具有整数供给和需求的线性问题存在一个最优整数计数矩阵。因此, 有理权重 Kantorovich 问题的最优值与复制均匀指派问题的最优值相同。□

二维情形。 这种在一维中计算 OT 的高效策略不能扩展到更高维。在二维中, 正如 Monge 已经注意到的, 有如下性质。

命题 1.4 (非交叉最优匹配)。 在二维中, 对于 $c(x, y) = \|x - y\|$, 如果 σ 是最优指派, 则线段 $[x_i, y_{\sigma(i)}]$ 不能交叉。

证明。 如果两条线段 $[x_i, y_{\sigma(i)}]$ 和 $[x_j, y_{\sigma(j)}]$ 在内部点 z 交叉, 则三角不等式给出

$$\|x_i - y_{\sigma(j)}\| + \|x_j - y_{\sigma(i)}\| < \|x_i - y_{\sigma(i)}\| + \|x_j - y_{\sigma(j)}\|.$$

因此, 通过交换 $(\sigma(i), \sigma(j))$ 得到的指派具有严格更小的代价, 这与最优性矛盾。□

然而, 仅有这一性质还不足以导向高效算法。非交叉只是一个必要的局部测试, 并不是最优性的紧凑证书。例如, 如果 n 个源点和 n 个目标点交替放置在凸多边形的边界上, 则非交叉完美匹配的数量是 Catalan 数

$$C_n = \frac{1}{n+1} \binom{2n}{n} \sim \frac{4^n}{\sqrt{\pi n^{3/2}}}.$$




图 1.7: 作为复制均匀匹配的有理权重, 使用与图 1.6 相同的圆盘到环带几何, 但显示的原子更少。红色和蓝色位置保持固定, 而圆盘面积编码整数重数 k_i 和 ℓ_j 。复制粒子后求解指派问题, 会产生若干连接到高重数原子的折叠线段; 这就是命题 1.3 的整数计数矩阵。

注 1.5 (交替非交叉匹配的 Catalan 计数). 该计数来自标准 Catalan 递推。固定一个红色顶点 r 。在非交叉完美匹配中, 如果 r 匹配到蓝色顶点 b , 则弦 $[r, b]$ 将多边形分成两个更小的多边形。由于边界颜色交替, 每一侧包含相同数量的红色和蓝色顶点。如果一侧包含 k 个红色和 k 个蓝色顶点, 则另一侧包含 $n-1-k$ 个红色和 $n-1-k$ 个蓝色顶点。两侧上的非交叉匹配是独立的, 因为没有线段可以穿过弦 $[r, b]$ 。因此, 若用 M_n 表示此类匹配的数量, 则有

$$M_0 = 1, \quad M_n = \sum_{k=0}^{n-1} M_k M_{n-1-k}.$$

这一递推刻画了 Catalan 数, 因此 $M_n = C_n$ 。

因此, 即使禁止交叉, 穷举搜索仍然是指数级的。不过, 上述证明中的双线段交换仍然有用: 它解释了为什么交叉匹配不可能最优, 但它不能在通过这一局部测试后仍保留下来的指数多个平面匹配中作出选择。

1.2 匹配算法

本节简要说明匹配在经典组合优化中的位置。其要点是, 确实存在高效算法, 但只有在引入线性规划视角之后, 才能得到最简洁的分析。

存在求解最优匹配问题的高效算法。最著名的是匈牙利方法和拍卖算法 [136, 25, 26]。拍卖算法在目标点上使用价格: 每个源点对具有最大约化利润的目标出价, 目标价格被提高, 并且当 ε -互补松弛条件满足时过程终止。对于整数代价, 选择 $\varepsilon < 1/n$ 会在有限次出价后给出精确最优解 [26]。第 4.2 节将在 Kantorovich 对偶之后重新考察这一算法, 并解释为什么它是一种对偶价格方法, 其精神与 Sinkhorn 缩放相平行。

匈牙利原对偶方法. 匈牙利方法最好被理解为指派线性规划的证书构造算法。它维护一个部分匹配 M 和对偶价格 (u_i, v_j) , 满足

$$u_i + v_j \leq C_{i,j} \quad \forall i, j.$$

等式图 $E(u, v) = \{(i, j) : u_i + v_j = C_{i,j}\}$ 包含约化代价为零的边。算法只沿由等式边组成的交替路径增广 M 。从一个未匹配源点出发, 它生长一棵具有源集合 S 和目标集合 T 的交替树。如果该树到达一个未匹配目标, 则沿路径增广匹配。如果不存在这样的边, 则按最小松弛量移动对偶变量

$$\delta = \min_{i \in S, j \notin T} (C_{i,j} - u_i - v_j), \quad u_i \leftarrow u_i + \delta \ (i \in S), \quad v_j \leftarrow v_j - \delta \ (j \in T).$$

这一更新保持所有不等式 $u_i + v_j \leq C_{i,j}$, 保持当前交替树为紧的, 并且至少产生一条离开 S 的新等式边。以增量方式维护这些松弛量, 就得到 $n \times n$ 指派问题的标准 $O(n^3)$ 实现。算法 1.4 总结了原对偶循环。图 1.8 通过只显示演化中的部分指派来展示实际迭代: 未指派行显示为平坦行以保持固定矩阵格式, 已匹配行显示为独热行。

命题 1.6 (匈牙利原对偶方法的正确性与复杂度). 假设匈牙利方法终止时得到一个包含在等式图中的完美匹配 σ

$$E(u, v) = \{(i, j) : u_i + v_j = C_{i,j}\},$$


算法 1.4 匈牙利原对偶增广**输入：** 方形代价矩阵 $C \in \mathbb{R}^{n \times n}$ 。**输出：** 最小代价完美匹配 M 。**初始化：** 置 $u_i = \min_j C_{ij}$ 且 $v_j = 0$ 。置 $M = \emptyset$ 。**当** M 不是完美匹配时 **执行：** 构造等式图： $E(u, v) = \{(i, j) : u_i + v_j = C_{i,j}\}$ 。 置根 $i_0 = \min\{i : i \text{ 在 } M \text{ 中未匹配}\}$ 。 置已到达集合 $S = \{i_0\}$ 和 $T = \emptyset$ ；清空父指针。 **当** T 不含未匹配目标时 **执行：** **若** $N_E(S) \setminus T = \emptyset$ **则：** 计算 $\delta = \min_{i \in S, j \notin T} (C_{i,j} - u_i - v_j)$ 。 更新对 $i \in S$ 令 $u_i \leftarrow u_i + \delta$ ，对 $j \in T$ 令 $v_j \leftarrow v_j - \delta$ 。 刷新等式图 $E(u, v)$ 。 置 $J = N_E(S) \setminus T$ 。 **对每个** $j \in J$ **按递增顺序 执行：** **将** j **加入** T ，并置父行 $p(j) = \min\{i \in S : (i, j) \in E(u, v)\}$ 。 **若** j **在** M **中匹配到** i' ，**则置** $S \leftarrow S \cup \{i'\}$ **且** $q(i') = j$ 。 置 $j_0 = \min\{j \in T : j \text{ 在 } M \text{ 中未匹配}\}$ 。 置 $j = j_0$ 。 **当** j **已定义时 执行：** 置 $i = p(j)$ 。 置 $M \leftarrow M \cup \{(i, j)\}$ 。 置 $j_{\text{old}} = q(i)$ 。 **若** j_{old} **已定义，则置** $M \leftarrow M \setminus \{(i, j_{\text{old}})\}$ 。置 $j = j_{\text{old}}$ 。**返回** M 。

图 1.8: 对角占优的有序一维平方距离指派上，实际匈牙利原对偶迭代的矩阵视图。每个面板记录当前部分指派状态：未指派行保持平坦，而已指派行是独热的。快照取自初始化以及两次、四次、六次和八次增广之后；对于这个教学实例，部分指派沿对角线增长，最终矩阵是由互补松弛认证的恒等指派。

其中 (u, v) 是对偶可行的，即对所有 (i, j) 有 $u_i + v_j \leq C_{i,j}$ 。则 σ 是一个最优指派。此外，通常的匈牙利更新会在有限次增广后终止。在维护松弛量的情况下，该方法使用 $O(n^3)$ 次算术操作。

证明。 对于任意排列 τ ，对偶可行性给出

$$\sum_i C_{i,\tau(i)} \geq \sum_i (u_i + v_{\tau(i)}) = \sum_i u_i + \sum_j v_j.$$

这是弱对偶下界。如果 σ 包含在等式图中，则

$$\sum_i C_{i,\sigma(i)} = \sum_i u_i + \sum_j v_j,$$

因此 σ 的原始代价达到对偶下界，从而是最优的。

剩下需要说明有限终止和复杂度界。每次成功增广时，匹配基数增加一，因此至多有 n 次增广。在一个增广阶段中，算法在等式图中生长一棵交替树。如果没有可用的增广路径，对偶更新使用离开当前树的一条边的最小松弛量。对于树内边，向源标签加上 δ 并从目标标签减去 δ 会保持紧性；对于从 S 到 T^c 的边， δ 的定义保持可行性并使至少一条新边变紧；所有其他不等式不变或变得更松。因此，在两次失败的增广尝试之间，可达集合严格增长，而在一个阶段内它们最多增长 n 次。如果当源点进入 S

时更新当前松弛量 $\min_{i \in S}(C_{i,j} - u_i - v_j)$, 则每次树扩展花费 $O(n)$ 。因此, 一个阶段花费 $O(n^2)$, 而 n 个阶段给出 $O(n^3)$ 次操作。于是该方法达到一个完美最优匹配。 $\square$

测度之间的 Monge 问题

本章的目标是从有限匹配过渡到任意概率律之间的传输。核心要点是足够仔细地定义测度、推前和 Monge 映射，使离散图景得以保留，同时说明为什么确定性映射可能不存在。Monge 的原始表述 [167] 和现代处理 [225, 226, 202, 190] 是这一过渡的概念背景。

上一章的表述只能处理具有相同点数的两个集合。要将其松弛到更一般的设置，需要考虑概率分布，使点由质量加权。

2.1 测度

测度是使点云、密度和奇异对象能够被统一处理的语言。我们只回顾后文所需的事实：积分、总变差、密度和概率律。

直方图 概率律的有限维模型是总质量为一的非负向量。

定义 2.1 (概率单纯形). 长度为 n 的概率单纯形是

$$\Sigma_n := \left\{ \mathbf{a} \in \mathbb{R}_+^n ; \sum_{i=1}^n a_i = 1 \right\}.$$

它的元素也称为概率向量或直方图。

离散测度，经验测度 一旦把概率向量的质量附着到位置上，它们就成为测度。

定义 2.2 (离散测度). 具有权重 $\mathbf{a}$ 和位置 $x_1, \dots, x_n \in \mathcal{X}$ 的离散测度是

$$\alpha = \sum_{i=1}^n a_i \delta_{x_i}, \quad (2.1)$$

其中 δ_x 是位置 x 处的 Dirac 质量。如果 $\mathbf{a} \in \Sigma_n$ ，它就是概率测度；如果所有权重 a_i 非负，它就是正测度。

Dirac 质量应被理解为无限集中在一个位置上的单位质量。一个“经验”概率分布是在点云上的均匀分布，即 $\alpha = \frac{1}{n} \sum_i \delta_{x_i}$ 。在实践中，在许多应用里，能够同时操作位置 x_i (“Lagrangian” 离散化) 和权重 a_i (“Eulerian” 离散化) 是有用的。Lagrangian 修改通常更强大（因为它导致自适应离散化），但它会破坏大多数问题的凸性。

一般测度 我们考虑度量空间 $(\mathcal{X}, d)$ 上的 Borel 测度 $\alpha \in \mathcal{M}(\mathcal{X})$ ，这意味着对每个 Borel 集 A (由开集经可数并、可数交和补集得到) 都定义了 $\alpha(A)$ 。除非另有说明，测度均为有限测度。于是 Dirac 测度 δ_x 定义为：若 $x \in A$ 则 $\delta_x(A) = 1$ ，否则为 0；对形如 (2.1) 的离散测度，这通过线性扩展为

$$\alpha(A) = \sum_{x_i \in A} a_i$$

我们用 $\mathcal{M}_+(\mathcal{X})$ 表示 $\mathcal{X}$ 上所有正测度的子集，即 $\alpha(A) \geq 0$ (并且若测度有限，则 $\alpha(\mathcal{X}) < +\infty$)。概率测度集合记为 $\mathcal{M}_+^1(\mathcal{X})$ ，这意味着任意 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ 都是正的，并且 $\alpha(\mathcal{X}) = 1$ 。

Polish 度量空间。 后文使用的许多测度论陈述需要对底层空间作一个温和的正则性假设。其目的不是限制应用，因为欧氏空间、完备可分流形和可分 Hilbert 空间都被涵盖在内，而是排除那些反常的可测空间，在这些空间中分解、紧性或弱收敛可能无法正常表现。

定义 2.3 (Polish 度量空间). 度量空间 $(\mathcal{X}, d)$ 若完备且可分, 则称为 Polish: 每个 Cauchy 序列都在 $\mathcal{X}$ 中收敛, 并且 $\mathcal{X}$ 含有一个可数稠密子集。更一般地, 如果某个拓扑空间的拓扑可由某个完备可分度量诱导, 则称它为 Polish。

Polish 空间是概率测度的自然环境范畴。其上的 Borel 概率测度是正则的, 紧性给出紧性判据, 正则条件概率和分解在标准假设下存在, 并且 Wasserstein 空间仍然是 Polish 的; 见命题 3.46。

定义 2.4 (测度的支撑). 度量空间 $\mathcal{X}$ 上 Borel 测度 α 的支撑 $\text{supp}(\alpha)$ 是具有满 α -质量的最小闭集。等价地, 若以 x 为中心的每个开球都具有正的 α -质量, 则 $x \in \text{supp}(\alpha)$ 。

Radon 测度 使用 Lebesgue 积分, Borel 测度可用于计算可测函数的积分(即可使水平集 $\{x; f(x) < t\}$ 为 Borel 集的函数), 我们将这一配对记为

$$\langle f, \alpha \rangle := \int f(x) d\alpha(x).$$

这样的可测 f 对离散测度 α 的积分计算为一个求和

$$\int_{\mathcal{X}} f(x) d\alpha(x) = \sum_{i=1}^n a_i f(x_i).$$

这尤其适用于连续测试函数, 它们是 Borel 可测的。因此, 在紧空间上对有限测度积分, 定义了连续函数 Banach 空间 $(\mathcal{C}(\mathcal{X}), \|\cdot\|_{\infty})$ 上的连续线性形式 $f \mapsto \int f d\alpha$; 确实有 $|\int f d\alpha| \leq \|f\|_{\infty} |\alpha|(\mathcal{X})$ 。在紧空间上, 反过来也成立: $\mathcal{C}(\mathcal{X})$ 上的每个连续线性形式都可由对某个有限带符号 Radon 测度积分来表示。这就是 Riesz–Markov–Kakutani 表示定理 [197, 35]。它将 $\mathcal{M}(\mathcal{X})$ 与 $\mathcal{C}(\mathcal{X})$ 的 Banach 对偶等同起来, 而这一对偶配对 $\langle f, \alpha \rangle$ 对后文使用的凸对偶论证至关重要。

相对密度。 下文的许多公式通过相对于参考测度的密度来比较测度。

定义 2.5 (相对密度). 如果 α 相对于参考测度 λ 绝对连续, 则它的相对密度是 Radon–Nikodym 导数

$$\rho_{\alpha} := \frac{d\alpha}{d\lambda}, \quad d\alpha(x) = \rho_{\alpha}(x) d\lambda(x).$$

等价地, 对所有 $h \in \mathcal{C}(\mathcal{X})$,

$$\int_{\mathcal{X}} h(x) d\alpha(x) = \int_{\mathcal{X}} h(x) \rho_{\alpha}(x) d\lambda(x).$$

在 $\mathbb{R}^d$ 上, 参考测度 λ 通常是 Lebesgue 测度 dx 。

总变差范数。 从对偶性 $\mathcal{M}(\mathcal{X}) = \mathcal{C}(\mathcal{X})^*$ 继承而来的范数是总变差范数。我们使用记号

定义 2.6 (总变差). 对于紧空间 $\mathcal{X}$ 上的有限带符号 Radon 测度 α ,

$$\|\alpha\|_{\text{TV}} := \sup_{f \in \mathcal{C}(\mathcal{X})} \{ \langle f, \alpha \rangle ; \|f\|_{\infty} \leq 1 \}.$$

这个公式很有用, 因为它把测度的范数计算为 $\mathcal{C}(\mathcal{X})$ 上相应线性形式的算子范数。

同一个范数也有直接的测度论表达。带符号测度的绝对值是

$$|\alpha|(A) := \sup_{A=\cup_i B_i} \sum_i |\alpha(B_i)|,$$

其中上确界取遍 A 的有限或可数可测划分。因此, 如果 $\alpha = \sum_i a_i \delta_{x_i}$ 且原子互异, 则 $|\alpha| = \sum_i |a_i| \delta_{x_i}$; 如果 $d\alpha(x) = \rho(x) d\lambda(x)$, 则 $d|\alpha|(x) = |\rho(x)| d\lambda(x)$ 。

命题 2.7 (总变差的对偶定义与测度定义). 对于紧空间 $\mathcal{X}$ 上的有限带符号 Radon 测度 α ,

$$\|\alpha\|_{\text{TV}} = |\alpha|(\mathcal{X}).$$

因此, $(\mathcal{M}(\mathcal{X}), \|\cdot\|_{\text{TV}})$ 等距地是 $(\mathcal{C}(\mathcal{X}), \|\cdot\|_{\infty})$ 的 Banach 对偶。

证明. 不等式 $\|\alpha\|_{\text{TV}} \leq |\alpha|(\mathcal{X})$ 来自

$$\left| \int f d\alpha \right| \leq \int |f| d|\alpha| \leq \|f\|_{\infty} |\alpha|(\mathcal{X}).$$

对于反向不等式, 写出 Jordan 分解 $\alpha = \alpha^+ - \alpha^-$, 于是 $|\alpha| = \alpha^+ + \alpha^-$. 可测符号 $s = \frac{d\alpha}{d|\alpha|}$ 在一个 $|\alpha|$ -零测集之外取值于 $\{-1, 1\}$, 并满足 $d\alpha = s d|\alpha|$. 由紧空间上 Radon 测度的正则性, s 可在 $L^1(|\alpha|)$ 中由满足 $\|f_k\|_{\infty} \leq 1$ 的连续函数 f_k 逼近. 因此 $\int f_k d\alpha \rightarrow \int s d\alpha = |\alpha|(\mathcal{X})$, 这证明了等式. 最后的陈述是带有此范数的 Riesz–Markov–Kakutani 表示定理. $\square$

对于两个绝对连续测度 $d\alpha = \rho_{\alpha} d\lambda$ 和 $d\beta = \rho_{\beta} d\lambda$, 这给出具体公式

$$\|\alpha - \beta\|_{\text{TV}} = \int_{\mathcal{X}} |\rho_{\alpha}(x) - \rho_{\beta}(x)| d\lambda(x).$$

对于写在同一支撑并集上的两个离散测度 $\alpha = \sum_k a_k \delta_{z_k}$ 和 $\beta = \sum_k b_k \delta_{z_k}$, 并将缺失系数置为零,

$$\|\alpha - \beta\|_{\text{TV}} = \sum_k |a_k - b_k|.$$

概率解释. Radon 概率测度表示随机变量的律. 取值于 $\mathcal{X}$ 的随机变量是从抽象概率空间 $(\Omega, \mathbb{P})$ 到 $\mathcal{X}$ 的可测映射 $X: \Omega \rightarrow \mathcal{X}$. 它的律是由下式定义的 Radon 概率测度 α

$$\alpha(A) = \mathbb{P}(\{\omega \in \Omega; X(\omega) \in A\}) \quad \text{对 Borel 集 } A \subset \mathcal{X}.$$

关于这一律的积分是期望:

$$\int_{\mathcal{X}} f(x) d\alpha(x) = \mathbb{E}[f(X)].$$

2.2 推前

推前编码映射如何移动质量. 本短节是确定性映射与测度上的线性操作之间的桥梁.

对于某个连续映射 $T: \mathcal{X} \rightarrow \mathcal{Y}$, 我们定义推前算子 $T_{\#}: \mathcal{M}(\mathcal{X}) \rightarrow \mathcal{M}(\mathcal{Y})$. 对于 Dirac 质量, 有 $T_{\#}\delta_x = \delta_{T(x)}$, 并且该公式通过线性性扩展到任意测度. 在某种意义上, 从 T 到 $T_{\#}$ 是一种线性化任意映射的方法, 其代价是从 (可能) 有限维空间 $\mathcal{X}$ 移动到无限维空间 $\mathcal{M}(\mathcal{X})$, 而这一思想对许多凸松弛方法是核心的, 最显著的是 Lasserre 松弛. 对于离散测度 (2.1), 推前操作只是移动测度支撑中所有点的位置

$$T_{\#}\alpha := \sum_i a_i \delta_{T(x_i)}.$$

对于更一般的测度, 例如具有密度的测度, 推前概念在描述概率测度的空间修改时起基础作用. 形式定义如下.

定义 2.8 (推前). 对于 $T: \mathcal{X} \rightarrow \mathcal{Y}$, 某个 $\alpha \in \mathcal{M}(\mathcal{X})$ 的推前测度 $\beta = T_{\#}\alpha \in \mathcal{M}(\mathcal{Y})$ 满足

$$\forall h \in \mathcal{C}(\mathcal{Y}), \quad \int_{\mathcal{Y}} h(y) d\beta(y) = \int_{\mathcal{X}} h(T(x)) d\alpha(x). \quad (2.2)$$

等价地, 对任意可测集 $B \subset \mathcal{Y}$, 有

$$\beta(B) = \alpha(\{x \in \mathcal{X}; T(x) \in B\}). \quad (2.3)$$

注意, $T_{\#}$ 保持正性和总质量, 因此如果 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$, 则 $T_{\#}\alpha \in \mathcal{M}_+^1(\mathcal{Y})$.

注 2.9 (拉回与推前). 如果 $T: \mathcal{X} \rightarrow \mathcal{Y}$ 连续, 则由 T 给出的拉回是线性算子

$$T^\# : \mathcal{C}(\mathcal{Y}) \rightarrow \mathcal{C}(\mathcal{X}), \quad T^\# g = g \circ T.$$

推前的定义正是函数上的这一拉回与 $T_\#$ 在测度上的作用之间的对偶关系:

$$\int_{\mathcal{X}} T^\# g(x) d\mu(x) = \int_{\mathcal{Y}} g(y) d(T_\# \mu)(y).$$

用配对记号表示,

$$\langle T^\# g, \mu \rangle_{\mathcal{C}(\mathcal{X}), \mathcal{M}(\mathcal{X})} = \langle g, T_\# \mu \rangle_{\mathcal{C}(\mathcal{Y}), \mathcal{M}(\mathcal{Y})}.$$

因此, 推前是拉回的伴随操作, 方向相反。不应混淆这两个箭头: $T_\#$ 将质量从 $\mathcal{X}$ 传输到 $\mathcal{Y}$, 而 $T^\#$ 将测试函数从 $\mathcal{Y}$ 拉回到 $\mathcal{X}$ 。

命题 2.10 (密度的推前公式). 令 α 和 β 在 $\mathbb{R}^d$ 的开子集上具有密度 ρ_α 和 ρ_β 。假设 T 是 C^1 微分同胚, 并且 $\beta = T_\# \alpha$ 。则对所有 x ,

$$\rho_\alpha(x) = |\det(T'(x))| \rho_\beta(T(x)). \quad (2.4)$$

等价地, 对 $y = T(x)$,

$$\rho_\beta(y) = \rho_\alpha(T^{-1}y) \frac{1}{|\det(T'(T^{-1}y))|}.$$

证明. 显式进行变量替换 $y = T(x)$, 使得对 $\mathbb{R}^d$ 上具有密度 $(\rho_\alpha, \rho_\beta)$ 的测度, 公式 (2.2) 中有 $dy = |\det(T'(x))| dx$; 于是对所有 $h \in \mathcal{C}(\mathcal{Y})$ 有

$$\begin{aligned} \int_{\mathcal{Y}} h(y) \rho_\beta(y) dy &= \int_{\mathcal{X}} h(T(x)) d\alpha(x) = \int_{\mathcal{X}} h(T(x)) \rho_\alpha(x) dx \\ &= \int_{\mathcal{Y}} h(y) \rho_\alpha(T^{-1}y) \frac{dy}{|\det(T'(T^{-1}y))|}, \end{aligned}$$

这表明

$$\rho_\beta(y) = \rho_\alpha(T^{-1}y) \frac{1}{|\det(T'(T^{-1}y))|}.$$

由于 T 是微分同胚, 等价地得到

$$\rho_\alpha(x) = |\det(T'(x))| \rho_\beta(T(x))$$

其中 $T'(x) \in \mathbb{R}^{d \times d}$ 是 T 的 Jacobian 矩阵 (由 T 的每个坐标的梯度组成的矩阵)。这意味着, 记 $y = T(x)$,

$$|\det(T'(x))| = \frac{\rho_\alpha(x)}{\rho_\beta(y)}.$$

□

注 2.11 (概率解释). 随机变量 X 的律, 即概率分布, 是 $\mathbb{P}$ 由 X 给出的推前, 即 $\alpha = X_\# \mathbb{P}$ 。对 $T: \mathcal{X} \rightarrow \mathcal{Y}$ 应用另一个推前 $\beta = T_\# \alpha$, 按照 (2.2), 等价于定义另一个随机变量 $Y = T(X)$, 即 $\omega \in \Omega \mapsto T(X(\omega)) \in \mathcal{Y}$ 。因此 β 是 Y 的律。因此, 从 Y 抽取随机样本 y 只需计算 $y = T(x)$, 其中 x 从 X 抽取。

2.3 Monge 表述

Monge 问题要求一个确定性映射, 在最小化给定代价的同时将一个律传输到另一个律上。这是 Monge 在关于“挖方与填方”问题的论文中引入的原始表述 [167]。它在几何上是直接的, 因为每个源点都被指派一个目的地, 但它在分析上也很脆弱: 可行集是非凸的, 可能为空, 并且映射不能分裂质量。这些局限正是下一节中 Kantorovich 松弛的动机。

Monge 问题. 给定 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ 、 $\beta \in \mathcal{M}_+^1(\mathcal{Y})$ 和代价 $c: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+$, Monge 问题为

$$\mathcal{M}_c(\alpha, \beta) := \inf_{T: \mathcal{X} \rightarrow \mathcal{Y}} \left\{ \int_{\mathcal{X}} c(x, T(x)) d\alpha(x); T_\# \alpha = \beta \right\}. \quad (2.5)$$

约束 $T_\# \alpha = \beta$ 意味着 T 在定义 2.8 的意义下将 α 的质量推前到 β 。

命题 2.12 (经验 Monge 映射与匹配). 假设源原子 $x_1, \dots, x_n$ 互异, 并且

$$\alpha = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}, \quad \beta = \frac{1}{n} \sum_{j=1}^n \delta_{y_j}.$$

如果 $T_{\#}\alpha = \beta$, 那么对于 β 支撑中的每个不同目标值 z , 恰有 $n\beta(\{z\})$ 个源原子被映射到 z . 特别地, 如果 y_j 互异, 则存在一个排列 $\sigma \in \text{Perm}(n)$, 使得对所有 i 都有 $T(x_i) = y_{\sigma(i)}$. 反过来, 每一个以正确质量将源原子指派到目标原子的此类指派, 都在 α 的支撑上定义一个可行 Monge 映射; 在目标互异的情形中,

$$\int_{\mathcal{X}} c(x, T(x)) d\alpha(x) = \frac{1}{n} \sum_{i=1}^n c(x_i, y_{\sigma(i)}).$$

如果源位置重复, 则应先将它们合并成质量更大的原子; 这样的原子不能由 Monge 映射分裂。

证明. 由于 $T_{\#}\alpha = \beta$, 所有像 $T(x_i)$ 都必须属于 β 的支撑; 否则推前会给该支撑之外的点赋予正质量。对于任意目标原子 z ,

$$\beta(\{z\}) = \alpha(T^{-1}(\{z\})) = \frac{1}{n} \# \{i; T(x_i) = z\}.$$

这证明了计数陈述。如果所有目标原子的质量都是 $1/n$, 则每个目标恰好接收一个源原子, 这就是一个排列。反向命题和代价恒等式由直接代入得到。□

命题 2.13 (从无原子源出发的传输映射存在性). 令 α 和 β 是 Polish 空间上的 Borel 概率测度, 并假设 α 无原子。则存在一个可测映射 T 使得 $T_{\#}\alpha = \beta$ 。

证明. 一个标准的测度同构定理将由 α 生成的无原子概率空间, 在零测集意义下, 与 $[0, 1]$ 上的 Lebesgue 测度等同起来 [35]。因此, 只需构造一个从 $[0, 1]$ 到目标律 β 的映射。选择一个从 β 的支撑到 $[0, 1]$ 的某个 Borel 子集上的 Borel 同构 i , 置 $\nu = i_{\#}\beta$, 并使用 ν 的累积分布函数的广义逆。该映射将 $[0, 1]$ 上的 Lebesgue 测度送到 ν , 并且几乎必然取值于 $i(\text{supp } \beta)$ 。再与 i^{-1} 以及源同构复合, 就得到从 α 到 β 的可测传输映射。□

注 2.14 (可行性与最优性). 求解 (2.5) 的最优映射可能因两个不同原因而不存在。第一, 约束集可能为空, 例如当 $\alpha = \delta_x$ 而 β 不是单个 Dirac 质量时。命题 2.13 表明, 源的非原子性消除了这一可行性障碍。第二, 即使可行映射存在, 下确界也可能无法达到, 因为映射类在弱极限下并不闭。

例 2.15 (分裂障碍). 一个经典例子, 例如 [202] 中讨论的例子, 取 α 为一条竖直线段上的均匀分布, β 等于位于左侧和右侧对称位置的两条平行竖直线段上的均匀测度的平均。对于二次代价, 松弛的 Kantorovich 最优解把每个源点分裂到它的两个对称目标。确定性 Monge 映射不能把一个点分裂到两个目的地, 因此极小化序列必须在两侧之间振荡, Monge 问题没有最优解。

例 2.16 (半离散 Monge 映射). Monge 表述在 α 和 β 上并不对称。例如, 当 α 相对于 Lebesgue 测度具有密度而 β 是离散的时, 它是有意义的。在 $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ 上, 令 $\beta = \sum_j b_j \delta_{y_j}$ 支撑在 $\{y_1, \dots, y_m\}$ 上。满足 $T_{\#}\alpha = \beta$ 的映射 T 定义了空间到单元的分割

$$C_j := T^{-1}(y_j), \quad \alpha(C_j) = b_j.$$

这就是半离散设置。第 5 章解释了当质量给定时, 这些单元如何成为 Laguerre 单元; 而当质量自由时, 它们如何成为普通 Voronoi 单元。如果交换 α 和 β 的角色, 使得 α 是离散的, 那么一般不存在有效的 T : 不可能将一个离散测度推前为一个具有密度的测度。

图 2.1 显示了这一确定性视角的一个有限维实例。源测度和目标测度是 RGB 空间中的经验颜色点云, 映射传输颜色, 同时保持像素位置固定。灰度均衡化是一维的, 但传输完整调色板需要在三维颜色空间中传输经验测度, 例如 RGB 或 Lab。早期颜色传输方法使用仿射统计或迭代的一维投影 [193, 188]; 用真正的三维 OT 映射替代这些投影, 可以在保持调色板几何的同时, 以更内在的方式匹配调色板 [189]。




图 2.1: RGB 空间中的 Monge 映射形式的颜色传输, 从海滩照片到花朵照片。上排将调色板映射应用于源图像; 下排显示 RGB 立方体中的经验颜色点云。这里仅传输颜色, 而不是像素位置。

Monge 距离。 当 $\mathcal{X} = \mathcal{Y}$ 且 $c(x, y) = d(x, y)^p$, 其中 d 是度量时, 置

$$\mathcal{E}_\alpha(T) := \int_{\mathcal{X}} d(x, T(x))^p d\alpha(x).$$

Monge 值定义了有向量

$$\tilde{\mathcal{W}}_p(\alpha, \beta)^p := \inf_{T: \mathcal{X} \rightarrow \mathcal{X}} \{\mathcal{E}_\alpha(T); T_\# \alpha = \beta\}. \quad (2.6)$$

如果约束集为空, 则 $\tilde{\mathcal{W}}_p(\alpha, \beta) = +\infty$ 。

命题 2.17 (有向 Monge 距离). 假设 $\mathcal{X} = \mathcal{Y}$ 是度量空间。量 $\tilde{\mathcal{W}}_p$ 非负, 仅在对角线上为零, 并满足三角不等式。因此它是一个有向扩展距离: 它不一定对称, 并且可能取值 $+\infty$ 。

证明. 非负性是直接的。如果 $\tilde{\mathcal{W}}_p(\alpha, \beta) = 0$, 选择可行映射 T_k 使得 $\int d(x, T_k(x))^p d\alpha(x) \rightarrow 0$ 。对每个有界 1-Lipschitz 函数 h ,

$$\left| \int h d\beta - \int h d\alpha \right| = \left| \int h(T_k(x)) - h(x) d\alpha(x) \right| \leq \left(\int d(x, T_k(x))^p d\alpha(x) \right)^{1/p} \rightarrow 0.$$

由于有界 Lipschitz 函数分离度量空间上的概率测度, $\alpha = \beta$ 。

我们证明三角不等式。如果 $\tilde{\mathcal{W}}_p(\alpha, \beta) = +\infty$, 但 $\tilde{\mathcal{W}}_p(\alpha, \gamma)$ 和 $\tilde{\mathcal{W}}_p(\gamma, \beta)$ 都有限, 则会存在映射 $S_\# \alpha = \gamma$ 和 $T_\# \gamma = \beta$, 从而 $(T \circ S)_\# \alpha = \beta$, 矛盾。因此, 只要左端为无穷大, 不等式就是自动的。在有限情形中, 固定 $\varepsilon > 0$, 并选择 ε -极小化映射 $S_\# \alpha = \gamma$ 和 $T_\# \gamma = \beta$, 使得

$$\mathcal{E}_\alpha(S)^{1/p} \leq \tilde{\mathcal{W}}_p(\alpha, \gamma) + \varepsilon, \quad \mathcal{E}_\gamma(T)^{1/p} \leq \tilde{\mathcal{W}}_p(\gamma, \beta) + \varepsilon.$$

复合映射从 α 到 β 可行, 而 Minkowski 不等式给出

$$\begin{aligned} \tilde{\mathcal{W}}_p(\alpha, \beta) &\leq \left(\int d(x, T(S(x)))^p d\alpha(x) \right)^{1/p} \\ &\leq \left(\int d(x, S(x))^p d\alpha(x) \right)^{1/p} + \left(\int d(S(x), T(S(x)))^p d\alpha(x) \right)^{1/p} \\ &= \mathcal{E}_\alpha(S)^{1/p} + \mathcal{E}_\gamma(T)^{1/p} \leq \tilde{\mathcal{W}}_p(\alpha, \gamma) + \tilde{\mathcal{W}}_p(\gamma, \beta) + 2\varepsilon. \end{aligned}$$

令 $\varepsilon \rightarrow 0$ 得到结论。 $\square$

有向值 $\tilde{\mathcal{W}}_p$ 在概念上有用, 但它过于刚性, 不能作为测度之间的主要距离: 它可能为无穷大且非对称。Kantorovich 表述通过用耦合替代映射来修正这两个问题。

2.4 Monge 映射的存在性与唯一性

本节记录 Monge 的确定性表述成为适定问题的主要情形。Brenier 定理是核心结果: 对于平方欧氏代价, 源的绝对连续性恢复了存在性、唯一性和凸势结构。

Brenier 定理。 Brenier 定理 [43, 44] 保证, 在 $\mathbb{R}^d$ 中对二次代价而言, 源的绝对连续性足以使 Monge 问题具有唯一解。它还给出该解的决定性结构描述: 最优映射不是任意映射, 而是一个凸势的梯度。

定理 2.18 (Brenier). 令 $\alpha, \beta \in \mathcal{M}_+^1(\mathbb{R}^d)$ 具有有限二阶矩, 并假设 α 相对于 Lebesgue 测度绝对连续。对于二次代价 $c(x, y) = \|x - y\|^2$, 存在一个凸函数 $\varphi: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ 使得

$$T = \nabla \varphi, \quad T_{\#} \alpha = \beta,$$

并且 T 是 α -几乎处处唯一的最优 Monge 映射。最优 Kantorovich 计划为 $(\text{Id}, T)_{\#} \alpha$ 。

证明. 证明使用后文第 4 章发展的 Kantorovich 松弛和对偶。二次代价的 Kantorovich 对偶给出最优势 (f, g) , 并在任意最优计划的支撑上满足等式 $f(x) + g(y) = \|x - y\|^2$ 。减去无害的二次项后, 该等式等价于某个凸函数 φ 的 Fenchel 等式 $\varphi(x) + \varphi^*(y) = \langle x, y \rangle$ 。因此, 每个最优计划的支撑都位于次微分 $\partial \varphi$ 的图中。由于 α 具有密度, 而凸函数 Lebesgue 几乎处处可微, $\partial \varphi(x)$ 对 α -几乎每个 x 都是单点。因此该计划集中在 $T = \nabla \varphi$ 的图上, 这证明了松弛最优解由 Monge 映射诱导。任意两个最优计划都在 α -几乎处处集中于同一个单值图上, 由此给出映射的唯一性。这是 Brenier 极分解定理背后的标准路径; 对于更一般严格凸代价的相关存在性和唯一性结果, 例如见 [99, 48, 226]。□

定义 2.19 (不赋予超曲面质量的测度). 若对每个可数 $(d-1)$ -可求长集 S 都有 $\alpha(S) = 0$, 则称 $\mathbb{R}^d$ 上的 Borel 测度 α 不赋予超曲面质量; 这里的可数 $(d-1)$ -可求长集指的是除一个 $\mathcal{H}^{d-1}$ -零测集外, 可由可数多个 C^1 超曲面覆盖的集合。

注 2.20 (尖锐的源假设). Brenier 定理中的绝对连续性假设可以削弱: 对于二次代价, 只需 α 不赋予超曲面质量即可 [99, 226, 202]。原因是, 凸势具有真正多值次微分的集合包含在可数个低维片段的并中。这个条件接近尖锐。如果源给一条线段或一个超曲面赋予正质量, 则次微分可能在一个具有正 α -质量的集合上是多值的, 而最优松弛计划可能需要分裂质量, 如例 2.15 所示。

注 2.21 (超越二次欧氏代价). Brenier 定理是最简洁的陈述, 因为平方欧氏代价把最优映射变成凸函数的梯度。对于 $p > 1$ 的代价 $c(x, y) = \|x - y\|^p$, 或者更一般地, 对于 h 光滑且严格凸的代价 $c(x, y) = h(x - y)$, 同一策略在源绝对连续时给出唯一最优映射, 但该映射要用 c -凸势来写。在 Riemannian 流形上, 代价 $d_M(x, y)^2/2$ 的局部类似物使用指数映射

$$T(x) = \exp_x(-\nabla \varphi(x)),$$

其中 φ 是 c -凸的。主要的额外问题是割迹和测地线正则性, 这就是通常先陈述欧氏情形的原因。这些扩展是 McCann 位移凸性理论以及流形上最优映射一般理论的一部分 [157, 226]。

Brenier 定理应通过凸梯度与递增函数之间的类比来理解。凸函数的梯度是单调场:

$$\langle \nabla \varphi(x) - \nabla \varphi(x'), x - x' \rangle \geq 0.$$

注 2.22 (单调场不一定是梯度). 在高于二维的情形中, 并非所有单调场都是凸函数的梯度。考虑 $\mathbb{R}^2$ 中的旋转矩阵

$$R_\theta = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}.$$

只要 $|\theta| \leq \pi/2$, 线性映射 $x \mapsto R_\theta x$ 就是单调的, 因为

$$\langle R_\theta x - R_\theta x', x - x' \rangle = \langle R_\theta(x - x'), x - x' \rangle = \cos(\theta) \|x - x'\|^2 \geq 0.$$

然而, 对于 $\theta \neq 0$, R_θ 不是对称的, 因此不可能是某个标量势的梯度。确实, 如果线性场 Ax 等于 $\nabla \varphi(x)$, 则其 Jacobian A 必须是对称的; 等价地, 二次势 $\varphi(x) = \langle Bx, x \rangle/2$ 的梯度为 $((B + B^\top)/2)x$ 。因此, 在维度 $d \geq 2$ 中, 单调性弱于 Brenier 最优性。

极分解。 Brenier 定理所做的不只是求解一个传输问题: 它提供了一种从任意映射中提取“单调部分”的典范方式。假设从一个平方可积形变 $u: \Omega \rightarrow \mathbb{R}^d$ 出发, 例如速度快照、图像形变或生成映射。律 $\nu = u_{\#} \lambda$ 记录质量最终到达何处, 但它忘记了 Ω 中的点在被送到那里之前是如何被标记的。Brenier 极分解 [43, 44] 分离了这两个效应。映射首先应用源的一个保测重排 s , 它改变标记但不改变质量, 然后应用将均匀源送到输出律的唯一凸梯度映射 $\nabla \varphi$ 。因此, 在所有具有相同像分布的映射中, Brenier 因子是典范的最优传输代表。这是有用的, 因为它把映射中携带真正 Wasserstein 位移的部分, 与参数化的保体积噪声分离开来。它也是通往流体力学的桥梁, 在那里保测映射描述不可压缩标记; 也是通往数据分析的桥梁, 在那里人们常希望在这些重标记的模式下比较映射。

命题 2.23 (极分解). 令 $\Omega \subset \mathbb{R}^d$ 赋予归一化 Lebesgue 测度 λ , 并令 $u \in L^2(\Omega; \mathbb{R}^d)$. 假设律 $\nu = u_{\#}\lambda$ 具有有限二阶矩. 则存在保测映射 $s: \Omega \rightarrow \Omega$ 和凸函数 φ 使得

$$u = \nabla \varphi \circ s \quad \lambda\text{-a.e.}$$

Brenier 因子 $\nabla \varphi$ 是 λ -几乎处处唯一的.

证明. 由 Brenier 定理, 存在一个唯一的凸函数梯度 $T = \nabla \varphi$ 将 λ 传输到 ν . 映射 u 和 T 具有相同的像律. 非原子概率空间的重排定理给出一个保测映射 s , 使得 $u = T \circ s$; 等价地, s 以正确的条件概率选择 $u(x)$ 在 T 下的原像. Brenier 因子的唯一性来自定理 2.18. $\square$

这个名称意在呼应矩阵通常的极分解. 对于高斯参考测度下的线性映射, 这一类比变成字面意义上的相同. 如果 $X \sim \mathcal{N}(0, \text{Id})$ 且 $u(x) = Ax$, 则 $u_{\#}\mathcal{N}(0, \text{Id}) = \mathcal{N}(0, AA^{\top})$. 从 $\mathcal{N}(0, \text{Id})$ 到这个高斯的 Brenier 映射是 $x \mapsto Sx$, 其中 $S = (AA^{\top})^{1/2}$ 是对称正半定的. 因此, 分解 $u = \nabla \varphi \circ s$ 写作

$$A = SO, \quad O = S^{\dagger}A,$$

当 A 可逆时 O 正交; 在奇异情形中, O 是部分等距. 因子 Sx 是凸梯度传输部分, 而 Ox 保持标准高斯律. 这个有限维图景常常是记住一般定理的最快方式: 极分解就是矩阵极分解, 其中矩阵被映射替代, 正交变换被保测重排替代.

位移插值. 最优映射不只是匹配两个端点测度; 它还说明如何在它们之间画出一条路径. 该构造是 Lagrangian 的和几何的: 每个粒子保持其身份, 并以恒定速度从初始位置行进到它在传输映射下的像.

定义 2.24 (Monge 与 McCann 位移插值). 如果 $T_{\#}\alpha = \beta$, 则由 T 生成的 Monge 插值是曲线

$$T_t(x) := (1-t)x + tT(x), \quad \alpha_t := (T_t)_{\#}\alpha, \quad t \in [0, 1].$$

对于二次代价, 当 T 是最优 Brenier 映射时, 该曲线称为 McCann 位移插值.

McCann 的位移凸性理论 [157] 澄清了沿 Brenier 映射插值的几何含义; 这就是后文第 10.1 节用于重心、第 13 章用于梯度流的 Wasserstein 测地线语言. 如果不存在 Monge 映射, 或者最优对象会分裂质量, 则同样的直线思想应用于耦合的每个活跃点对, 如第 3.5 节的 Kantorovich 插值所解释. 下面的命题为有向 Monge 值精确说明常速性质.

命题 2.25 (有向 Monge 位移测地线). 令 $p \geq 1$, 令 $\alpha, \beta \in \mathcal{M}_+^1(\mathbb{R}^d)$ 具有有限 p 阶矩, 并令 T 是 (2.6) 中 $\tilde{W}_p(\alpha, \beta)$ 的最优映射. 置 $\alpha_t = (T_t)_{\#}\alpha$, 其中 $T_t = (1-t)\text{Id} + tT$. 假设对每个 $t < 1$, T_t 在一个满 α -测度的 Borel 集上一一对应, 因此 T_t^{-1} 在 α_t -几乎处处有定义. 则对 $0 \leq s \leq t \leq 1$,

$$\tilde{W}_p(\alpha_s, \alpha_t) = (t-s)\tilde{W}_p(\alpha, \beta).$$

因此, $t \mapsto \alpha_t$ 是有向 Monge 距离的一条定向常速测地线. 特别地, 当 $p = 2$ 时, 这适用于定理 2.18 假设下的 Brenier 映射.

证明. 情形 $s = t$ 是平凡的, 因此假设 $s < t$. 由于 $s < 1$, 逆 T_s^{-1} 沿被传输粒子在 α_s -几乎处处有定义. 定义

$$S_{s,t} := T_t \circ T_s^{-1} \quad \alpha_s\text{-a.e.}$$

则 $(S_{s,t})_{\#}\alpha_s = \alpha_t$, 并利用 T 的最优性,

$$\begin{aligned} \tilde{W}_p(\alpha_s, \alpha_t)^p &\leq \int \|S_{s,t}(z) - z\|^p d\alpha_s(z) \\ &= \int \|T_t(x) - T_s(x)\|^p d\alpha(x) = (t-s)^p \tilde{W}_p(\alpha, \beta)^p. \end{aligned}$$

同一粒子构造给出 $\tilde{W}_p(\alpha, \alpha_s) \leq s\tilde{W}_p(\alpha, \beta)$. 如果 $t < 1$, 映射 $T \circ T_t^{-1}$ 将 α_t 送到 β , 并给出 $\tilde{W}_p(\alpha_t, \beta) \leq (1-t)\tilde{W}_p(\alpha, \beta)$; 如果 $t = 1$, 后一个距离为零. 使用命题 2.17 的三角不等式,

$$\tilde{W}_p(\alpha, \beta) \leq \tilde{W}_p(\alpha, \alpha_s) + \tilde{W}_p(\alpha_s, \alpha_t) + \tilde{W}_p(\alpha_t, \beta) \leq s\tilde{W}_p(\alpha, \beta) + \tilde{W}_p(\alpha_s, \alpha_t) + (1-t)\tilde{W}_p(\alpha, \beta).$$

因此 $\tilde{W}_p(\alpha_s, \alpha_t) \geq (t-s)\tilde{W}_p(\alpha, \beta)$, 这证明了等式. 对于 Brenier 映射 $T = \nabla \varphi$, 映射 T_t 是如下函数的梯度

$$x \mapsto (1-t)\frac{\|x\|^2}{2} + t\varphi(x),$$

它对每个 $t < 1$ 都是 $(1-t)$ -强凸的。在 φ 可微的满测集上, 这给出

$$\langle T_t(x) - T_t(y), x - y \rangle \geq (1-t)\|x - y\|^2,$$

因此 T_t 在那里是单射。这给出最后的断言。 $\square$




图 2.2: 猫轮廓与心形轮廓之间的 McCann 位移插值。第一排显示沿 $T_t(x) = (1-t)x + tT(x)$ 被传输粒子的一个小型最远点子集。第二排把更密集被传输点云的核平滑密度渲染为彩色图像: 白色表示零密度, 而高密度在相应时间的红到蓝插值颜色中饱和。

接下来讨论的 Caffarelli 正则性理论解释了何时凸势实际上足够光滑, 从而定义经典形变。

正则性与 Monge–Ampère 方程。 前面的结果识别了最优映射; 正则性理论询问何时这个映射是一个经典光滑形变, 而不仅仅是几乎处处定义的梯度。对于二次代价, 这个问题变成 Monge–Ampère 方程的正则性理论。

命题 2.26 (Caffarelli 正则性). 令 $\Omega, \Lambda \subset \mathbb{R}^d$ 是具有 C^2 边界的有界一致凸区域。令 $\alpha = \rho(x)dx$ 支撑在 Ω 上, $\beta = \eta(y)dy$ 支撑在 Λ 上, 并且 $0 < m \leq \rho, \eta \leq M < +\infty$ 。如果对某个 $\alpha \in (0, 1)$ 有 $\rho, \eta \in C^\alpha$, 则将 α 传输到 β 的 Brenier 势 φ 严格凸, 并满足 $\varphi \in C_{\text{loc}}^{2,\alpha}(\Omega)$; 特别地, $\nabla\varphi$ 局部 Hölder。在相应的边界相容性和光滑性假设下, 正则性一直成立到边界。

证明. 势函数在 Alexandrov 意义下求解 Monge–Ampère 方程

$$\det(\nabla^2\varphi(x)) = \frac{\rho(x)}{\eta(\nabla\varphi(x))}$$

并具有第二边界条件 $\nabla\varphi(\Omega) = \Lambda$ 。密度界和区域的凸性给出严格凸性和截面的局部化。Caffarelli 内部理论随后给出 φ 的 $C_{\text{loc}}^{2,\alpha}$ 估计; 边界陈述来自一致凸性和相容性假设下的边界正则性理论 [47, 226]。 $\square$

注 2.27 (正则性、弱映射与分裂). Caffarelli 定理既应被读作定理, 也应被读作警告。Brenier 定理在温和假设下给出存在性和唯一性, 但光滑性要求密度界、光滑性和凸几何, 而经验分布、流形支撑分布或神经生成分布很少满足这些条件。在这类应用中, 精确 OT 映射往往只是弱定义的, 可能不稳定, 并且最好由耦合、熵近似或学习到的参数替代物来表示。

即使没有光滑性, 凸势在其定义域内部也是局部 Lipschitz 的, 因此 $\nabla\varphi$ 在 Lebesgue 几乎处处有定义。如果源测度不满足 Brenier 定理的非分裂假设, 正确的松弛对象反而是集中在集合值映射 $\partial\varphi$ 图上的最优 Kantorovich 计划。在 $\partial\varphi(x)$ 包含多个目标位置的点处, 该计划可能分裂从 x 出发的质量。因此, 次微分仍描述最优性的几何, 但传输对象是耦合, 而不是单值映射。

对于光滑密度, 变量替换公式 (2.4) 给出 Monge–Ampère 方程

$$\det(\nabla^2\varphi(x))\rho_\beta(\nabla\varphi(x)) = \rho_\alpha(x). \quad (2.7)$$

在合适的边界条件下, 这在凸解中刻画了 Brenier 势, 差别至多为一个加性常数。凸性约束迫使 $\det(\nabla^2\varphi(x)) \geq 0$, 并且是这个完全非线性椭圆方程适定所必需的。该 PDE 的数值格式把 OT 与完全非线性椭圆求解器联系起来; 例如见 [21, 94]。

下面的命题记录了这个非线性方程的无穷小形式。它在概念上和数值上都有用: 在接近光滑参考密度时, Monge–Ampère 传输在一阶上化为加权 Poisson 方程。

命题 2.28 (Monge–Ampère 方程的线性化). 令 $\rho_\varepsilon = \rho_0 + \varepsilon r + o(\varepsilon)$ 是光滑有界区域上正参考密度 ρ_0 的光滑扰动, 并且 $\int r = 0$ 。如果 $T_\varepsilon(x) = x + \varepsilon \nabla u(x) + o(\varepsilon)$ 将 ρ_0 传输到 ρ_ε , 则在一阶上,

$$-\nabla \cdot (\rho_0 \nabla u) = r.$$

特别地, 当 ρ_0 是常数时, 线性化方程为 $-\Delta u = r/\rho_0$ 。

证明. T_ε 的变量替换方程为

$$\rho_0(x) = \rho_\varepsilon(T_\varepsilon(x)) \det(\nabla T_\varepsilon(x)).$$

展开 $\rho_\varepsilon(x + \varepsilon \nabla u) = \rho_0(x) + \varepsilon r(x) + \varepsilon \langle \nabla \rho_0, \nabla u \rangle + o(\varepsilon)$ 以及

$$\det(I + \varepsilon \nabla^2 u) = 1 + \varepsilon \Delta u + o(\varepsilon)$$

得到

$$\rho_0 = \rho_0 + \varepsilon (r + \langle \nabla \rho_0, \nabla u \rangle + \rho_0 \Delta u) + o(\varepsilon) = \rho_0 + \varepsilon (r + \nabla \cdot (\rho_0 \nabla u)) + o(\varepsilon).$$

一阶项必须为零。 $\square$

2.5 一维传输与分位数

在一维中, 最优传输完全显式。累积分布函数给质量排序, 而最优耦合通过匹配相同分位数水平得到。这个特殊情形既是计算工具, 也是后文若干线性化构造的模板。

定义 2.29 (累积函数和分位数函数). 对于 $\alpha \in \mathcal{M}_+^1(\mathbb{R})$, 其累积分布函数为

$$\mathcal{C}_\alpha(x) := \alpha((-\infty, x]). \quad (2.8)$$

其广义逆, 或分位数函数, 为

$$\mathcal{C}_\alpha^{-1}(r) := \inf \{x \in \mathbb{R} ; \mathcal{C}_\alpha(x) \geq r\}, \quad r \in (0, 1). \quad (2.9)$$

命题 2.30 (分位数推前). 有 $(\mathcal{C}_\alpha^{-1})_\# \text{Leb}_{[0,1]} = \alpha$ 。如果 α 没有原子, 则 $(\mathcal{C}_\alpha)_\# \alpha = \text{Leb}_{[0,1]}$ 。

证明. 为简单起见, 先假设 α 具有严格正密度, 因此 $\mathcal{C}_\alpha$ 严格递增且连续。记 $\gamma := (\mathcal{C}_\alpha^{-1})_\# \text{Leb}_{[0,1]}$ 。只需证明 $\mathcal{C}_\gamma = \mathcal{C}_\alpha$ 。对每个 x ,

$$\mathcal{C}_\gamma(x) = \int_0^1 \mathbf{1}_{(-\infty, x]}(\mathcal{C}_\alpha^{-1}(z)) dz = \int_0^1 \mathbf{1}_{[0, \mathcal{C}_\alpha(x)]}(z) dz = \mathcal{C}_\alpha(x),$$

其中使用了 $\mathcal{C}_\alpha^{-1}(z) \leq x$ 当且仅当 $z \leq \mathcal{C}_\alpha(x)$ 。一般测度的情形由相同论证得到, 只需使用广义逆和累积分布函数的右连续性。如果 α 没有原子, 概率积分变换给出 $(\mathcal{C}_\alpha)_\# \alpha = \text{Leb}_{[0,1]}$ 。 $\square$

如果 α 没有原子, 则映射

$$T = \mathcal{C}_\beta^{-1} \circ \mathcal{C}_\alpha \quad (2.10)$$

满足 $T_\# \alpha = \beta$ 。

对于代价 $c(x, y) = |x - y|^2$, 该映射非递减, 因此是一维中某个凸函数的导数。因此, 只要 α 无原子, Brenier 定理就把它识别为最优 Monge 映射。使用广义逆, 同一个分位数构造给出任意测度的最优 Kantorovich 耦合, 并且它对形如 $h(|x - y|)$ 且 h 凸且非递减的代价也是最优的。

命题 2.31 (直线上的单调重排). 令 $\alpha, \beta \in \mathcal{M}_+^1(\mathbb{R})$ 具有有限 p 阶矩, 其中 $p \geq 1$ 。耦合

$$\pi^* = (\mathcal{C}_\alpha^{-1}, \mathcal{C}_\beta^{-1})_\# \text{Leb}_{[0,1]}$$

在所有耦合中最小化 $\int |x - y|^p d\pi(x, y)$ 。如果 α 没有原子, 它由单调 Monge 映射 (2.10) 诱导。

证明. 由命题 2.30, 所显示的测度是一个耦合。它的支撑是单调的: 对于 $s < t$, 两个分位数函数都满足 $\mathcal{C}_\alpha^{-1}(s) \leq \mathcal{C}_\alpha^{-1}(t)$ 和 $\mathcal{C}_\beta^{-1}(s) \leq \mathcal{C}_\beta^{-1}(t)$ 。如果一个耦合具有正质量的两个交叉点对 $x < x'$ 和 $y > y'$, 则由命题 1.1 中使用的两点不等式, 交换目标会在严格凸幂次下降低代价, 并且在 $p = 1$ 时不增加代价。消除交叉得到单调最优耦合, 而具有给定边缘的单调耦合正是分位数耦合。如果 α 没有原子, 则 $(\mathcal{C}_\alpha)_\# \alpha = \text{Leb}_{[0,1]}$, 因此该耦合由 (2.10) 生成。 $\square$

注 2.32 (复合是一维现象). 在一维中, 最优映射可以复合。为简单起见, 假设中间律没有原子, 因此单调重排

$$T_{\alpha \rightarrow \beta} = C_{\beta}^{-1} \circ C_{\alpha}, \quad T_{\beta \rightarrow \gamma} = C_{\gamma}^{-1} \circ C_{\beta}$$

在 α -和 β -几乎处处良定义。于是

$$T_{\beta \rightarrow \gamma} \circ T_{\alpha \rightarrow \beta} = T_{\alpha \rightarrow \gamma} \quad \alpha\text{-a.e.}$$

确实, 每个映射都是非递减的, 并把分位数水平 r 送到目标律的同一分位数水平。这一半群性质是有序直线所特有的。

高维中的障碍已经在最基本的高斯映射中可见。

例 2.33 (Brenier 映射复合的线性障碍). 在更高维中, 二次代价的 Brenier 映射是凸函数的梯度, 而这类映射在复合后一般不再保持为梯度。最简单的障碍是线性的。如果 $T_1(x) = A_1x$ 且 $T_2(x) = A_2x$, 其中 A_1, A_2 对称正定, 则 $T_2 \circ T_1$ 的矩阵为 A_2A_1 。只有当这个乘积对称, 等价地 $A_1A_2 = A_2A_1$ 时, 它才是梯度场。高斯传输给出一个具体实例: 在非退化高斯律之间, Brenier 映射是仿射的, 并具有对称正定的线性部分。因此, 高斯最优映射的复合只有在特殊的可交换情形中才是最优的, 例如当所有协方差矩阵可同时对角化时。否则, 复合包含旋转或剪切分量, 并且不是初始高斯与最终高斯之间的 Brenier 映射。

对于离散测度, 当源具有原子时, 不能直接应用映射公式; 但如果这些测度是在相同数量的 Dirac 质量上的均匀分布, 那么它恰好就是命题 1.1 的排序公式。

算法 2.1 分位数重排与一维测地线

输入: 一维概率测度 α, β ; 时间 $t \in [0, 1]$ 。

输出: 分位数耦合、定义时的 Monge 映射, 以及测地线点 α_t 。

计算 C_{α}, C_{β} 和广义逆。

耦合相同分位数水平: $X = C_{\alpha}^{-1}(r), \quad Y = C_{\beta}^{-1}(r), \quad r \in (0, 1)$ 。

若 α 没有原子 则:

置 $T(x) = C_{\beta}^{-1}(C_{\alpha}(x))$ 。

插值分位数: $Q_t(r) = (1-t)C_{\alpha}^{-1}(r) + tC_{\beta}^{-1}(r), \quad \alpha_t = (Q_t)_{\#}\text{Leb}_{[0,1]}$ 。 **返回** (X, Y) 、若已定义则返回 T , 以及 α_t 。

命题 2.34 (一维 Wasserstein 公式). 令 $\alpha, \beta \in \mathcal{M}_{+}^1(\mathbb{R})$ 具有有限 p 阶矩。对每个 $p \geq 1$,

$$\mathcal{W}_p(\alpha, \beta)^p = \int_0^1 |C_{\alpha}^{-1}(r) - C_{\beta}^{-1}(r)|^p dr = \|C_{\alpha}^{-1} - C_{\beta}^{-1}\|_{L^p([0,1])}^p. \quad (2.11)$$

对于 $p = 1$, 这等价于

$$\mathcal{W}_1(\alpha, \beta) = \|C_{\alpha} - C_{\beta}\|_{L^1(\mathbb{R})} = \int_{\mathbb{R}} |C_{\alpha}(x) - C_{\beta}(x)| dx \quad (2.12)$$

$$= \int_{\mathbb{R}} \left| \int_{-\infty}^x d(\alpha - \beta) \right| dx. \quad (2.13)$$

证明. 第一个公式来自命题 2.31: 最优耦合通过对两个测度取相同分位数水平 r 得到。对于 $p = 1$, 使用层蛋糕恒等式。如果 q_{α} 和 q_{β} 是两个分位数函数, 则

$$\int_0^1 |q_{\alpha}(r) - q_{\beta}(r)| dr = \int_{\mathbb{R}} \lambda(\{r : q_{\alpha}(r) \leq x < q_{\beta}(r)\} \cup \{r : q_{\beta}(r) \leq x < q_{\alpha}(r)\}) dx.$$

所显示集合的测度对于几乎每个 x 正好是 $|C_{\alpha}(x) - C_{\beta}(x)|$ 。 $\square$

公式 (2.11) 意味着映射 $\alpha \mapsto C_{\alpha}^{-1}$ 将一维 Wasserstein 几何等距嵌入到线性 L^p 空间中。因此, 对于 $p = 2$, 实直线上概率测度的 Wasserstein 距离是 Hilbert 型的。这使一维 OT 远比高维 OT 简单, 因为后者的 Wasserstein 几何并非全局 Hilbert 型。

图 2.3 的最后一个面板是第 2.4 节中位移插值的一维特化。在分位数坐标中, 插值测度由下式刻画

$$C_{\alpha_t}^{-1}(r) = (1-t)C_{\alpha}^{-1}(r) + tC_{\beta}^{-1}(r), \quad r \in (0, 1).$$

第 1.1 节中的直方图均衡化图, 是同一构造应用于像素强度。

对于 $p = 1$, 公式 (2.12) 表明, 一旦把总质量为零的带符号测度与其累积原函数等同起来, $\mathcal{W}_1$ 就是其上的一个范数。其他经典一维距离通过用 L^2 或 L^{∞} 范数替换累积函数的 L^1 范数得到; 在适当紧性假设下, 这类范数也度量依律收敛, 并例如导向 Cramér-von Mises 和 Kolmogorov-Smirnov 型距离。




图 2.3: 通过分位数的维传输。同两个光滑律以密度、累积函数和分位数函数的形式显示。最后一个面板显示由线性分位数路径 $Q_t = (1-t)Q_\alpha + tQ_\beta$ 得到的位移插值, 这是显式的一维 W_2 测地线。

三角重排。 还有另一种在多维中构造传输映射的典范方式: 通过条件一维分位数一次传输一个坐标。该构造可追溯到 Knothe 和 Rosenblatt [133, 196]。它通常不是代价最优的, 但它在弱假设下给出确定性重排, 并澄清了多变量传输如何能够递归地化约为标量单调映射。

命题 2.35 (Knothe–Rosenblatt 三角重排). 令 $\alpha, \beta \in \mathcal{M}_+^1(\mathbb{R}^d)$. 为简单起见, 假设 α 的第一边缘以及下文使用的 α 的一维条件律都是无原子的, 并且已固定正则条件分布。存在一个三角映射

$$T(x_1, \dots, x_d) = (T_1(x_1), T_2(x_1, x_2), \dots, T_d(x_1, \dots, x_d))$$

使得 $T_\# \alpha = \beta$, 并且对每个 k , 函数 $x_k \mapsto T_k(x_1, \dots, x_k)$ 对 α -几乎每个 $(x_1, \dots, x_{k-1})$ 的取值都是非递减的。

证明. 构造是递归的。对于 $k = 1$, 令 T_1 为 α 的第一边缘与 β 的第一边缘之间的单调重排。假设 $T_1, \dots, T_{k-1}$ 已经构造完毕。记 $x_{<k} = (x_1, \dots, x_{k-1})$ 和 $T_{<k} = (T_1, \dots, T_{k-1})$ 。由归纳, $(T_{<k})_\# \alpha_{<k} = \beta_{<k}$, 其中 $\alpha_{<k}$ 和 $\beta_{<k}$ 是前 $(k-1)$ 个坐标的边缘。令 $\alpha_{x_{<k}}^k$ 和 $\beta_{y_{<k}}^k$ 为给定先前坐标时第 k 个坐标的正则条件律。将 $T_k(x_{<k}, \cdot)$ 定义为从 $\alpha_{x_{<k}}^k$ 到 $\beta_{T_{<k}(x_{<k})}^k$ 的一维单调重排。

由一维重排定理, 映射 $T_k(x_{<k}, \cdot)$ 是非递减的。分解的链式法则随后表明, 在第 k 步之后, $T_\# \alpha$ 的前 k 个坐标与 β 的前 k 个坐标具有相同的律。当 $k = d$ 时, 这给出 $T_\# \alpha = \beta$ 。目标原子由广义分位数处理。如果源条件律具有必须分裂的原子, 同一递归构造定义的是三角 Markov 核, 而不是确定性映射。□

证明中的递归构造就是一个算法: 它反复把一维分位数重排应用于条件分布。

算法 2.2 Knothe–Rosenblatt 三角重排

输入: $\mathbb{R}^d$ 上具有条件律的概率测度 α, β 。

输出: Knothe–Rosenblatt 三角映射 T 。

计算第一坐标重排: $T_1 = (F_{\beta_1})^{-1} \circ F_{\alpha_1}$ 。

对 $k = 2, \dots, d$ 执行:

置 $x_{<k} = (x_1, \dots, x_{k-1})$ 。

计算条件律 $\alpha_{x_{<k}}^k$ 和 $\beta_{T_{<k}(x_{<k})}^k$ 。

置 $T_k(x_{<k}, x_k) = (F_{\beta_{T_{<k}(x_{<k})}^k})^{-1} \circ F_{\alpha_{x_{<k}}^k}(x_k)$ 。

返回 $T(x) = (T_1(x_1), T_2(x_1, x_2), \dots, T_d(x_1, \dots, x_d))$ 。

图 2.4 在图像直方图上显示二维机制。第一阶段只传输水平边缘, 因此中间枢轴具有与目标相同的 x -边缘, 但保留源的竖直条件律。第二阶段随后在相应列内传输每个竖直条件律。



图 2.4: 图 2.2 中相同猫和心形密度之间的三角重排。这些面板直接在图像直方图上计算。前三个过渡通过 x -边缘之间的单调重排水平移动质量; 枢轴具有目标水平边缘。后三个过渡保持每一列固定, 并通过条件律之间的一维单调重排竖直移动质量。

这一构造沿坐标轴依次传输，因此常称为逐轴传输。它依赖于所选坐标次序，并且一般不是二次代价的最优解。不过，它仍是一个有用的极限对象：在适当假设下，越来越各向异性的二次代价的 Brenier 映射会收敛到三角重排 [52]。

命题 2.36 (各向异性 Brenier 映射收敛到 Knothe–Rosenblatt). 令 α, β 是 $\mathbb{R}^d$ 上紧支撑的概率测度，其密度在各自矩形支撑上有上下界，并假设进入命题 2.35 的条件律是无原子的。对 $\varepsilon > 0$ ，置

$$c_\varepsilon(x, y) := \sum_{k=1}^d \varepsilon^{k-1} |x_k - y_k|^2.$$

令 T_ε 为代价 c_ε 下从 α 到 β 的 Monge 映射，并令 T_{KR} 为使用上述坐标次序的三角 Knothe–Rosenblatt 重排。则

$$T_\varepsilon \longrightarrow T_{\text{KR}} \quad \text{in } L^2(\alpha; \mathbb{R}^d) \quad \text{as } \varepsilon \rightarrow 0.$$

证明. 我们给出标准的词典序论证，这是 [52] 的变分核心。令 $\pi_\varepsilon = (\text{Id}, T_\varepsilon)_\# \alpha$ 。由于支撑紧，某个子序列弱收敛到 α 和 β 之间的某个耦合 π 。 π_ε 对

$$F_\varepsilon(\gamma) = \sum_{k=1}^d \varepsilon^{k-1} \int |x_k - y_k|^2 d\gamma(x, y)$$

的最优性首先通过令 $\varepsilon \rightarrow 0$ 表明，在所有耦合中， π 最小化第一坐标上的一维二次代价。由于 α 的第一边缘无原子，一维极小化解是单调重排，因此在 π 下有 $y_1 = T_1(x_1)$ 。

现在把注意力限制在满足这一第一坐标约束的耦合上。减去第一坐标代价的共同最小值，将最优性不等式除以 ε ，并令 $\varepsilon \rightarrow 0$ 。极限耦合必须在所有已经实现第一单调重排的耦合中，最小化第二坐标二次代价。相对于 (x_1, y_1) 分解，把这个受约束问题化约为 x_2 和 y_2 的条件律之间的一维单调重排。因此在 π 下有 $y_2 = T_2(x_1, x_2)$ 。

重复同样的相减并重标度论证，对每个 k 都给出条件单调重排 $y_k = T_k(x_1, \dots, x_k)$ 。因此， $(\pi_\varepsilon)_\varepsilon$ 的每个弱极限都集中在 T_{KR} 的图上。这个图耦合是唯一的，所以整个族 π_ε 弱收敛到 $(\text{Id}, T_{\text{KR}})_\# \alpha$ 。

最后，令 $X \sim \alpha$ 。这些图耦合是 $(X, T_\varepsilon(X))$ 的律，并且它们弱收敛到 $(X, T_{\text{KR}}(X))$ 的律。为了把这转化为映射的收敛，固定 $\zeta > 0$ 。由 Lusin 定理，存在紧集 K ，满足 $\alpha(K) > 1 - \zeta$ ，并且 T_{KR} 在 K 上连续。在 K 上，集合

$$\{(x, y) ; x \in K, \|y - T_{\text{KR}}(x)\| \geq \delta\}$$

是闭的，并且在极限图耦合下具有零质量。Portmanteau 定理给出

$$\limsup_{\varepsilon \rightarrow 0} \alpha(\{x ; x \in K, \|T_\varepsilon(x) - T_{\text{KR}}(x)\| \geq \delta\}) = 0.$$

加上 K 的补集并令 $\zeta \rightarrow 0$ ，证明了在 α -概率意义下的收敛。由于所有映射的取值都在一个共同紧集中，该收敛是一致可积的，因此也在 $L^2(\alpha)$ 中成立。□

2.6 高斯测度与 Bures 度量

高斯测度构成了由二次最优传输保持的最重要有限维族。均值线性移动，而协方差遵循正半定矩阵的 Bures–Wasserstein 几何。

一维高斯。 令 $\alpha = \mathcal{N}(m_\alpha, \sigma_\alpha^2)$ 和 $\beta = \mathcal{N}(m_\beta, \sigma_\beta^2)$ 是 $\mathbb{R}$ 上的两个非退化高斯。则

$$T(x) = \frac{\sigma_\beta}{\sigma_\alpha}(x - m_\alpha) + m_\beta$$

满足 $T_\# \alpha = \beta$ 。它是凸函数

$$\varphi(x) = \frac{\sigma_\beta}{2\sigma_\alpha}(x - m_\alpha)^2 + m_\beta x,$$

的导数，因此 Brenier 定理表明它是最优二次传输。相关距离为

$$\mathcal{W}_2(\alpha, \beta)^2 = \int_{\mathbb{R}} \left(\frac{\sigma_\beta}{\sigma_\alpha}(x - m_\alpha) + m_\beta - x \right)^2 d\alpha(x) = (m_\alpha - m_\beta)^2 + (\sigma_\alpha - \sigma_\beta)^2.$$

该公式通过连续性扩展到 Dirac 质量，尽管仿射 Monge 映射本身只能把 Dirac 源推前到另一个 Dirac。因此，一维高斯的 OT 几何是半平面 $(m, \sigma) \in \mathbb{R} \times \mathbb{R}_+$ 的欧氏几何。这与 KL 几何形成对比，在 KL 几何中奇异高斯之间距离为无穷大。




图 2.5: 一维高斯 $\mathcal{W}_2$ 测地线。在坐标 (m, σ) 中, 测地线是上半平面中的欧氏线段。两个密度面板显示沿这两条线段的相应高斯密度, 颜色从红色端点插值到蓝色端点。

多变量高斯。 如果

$$\alpha = \mathcal{N}(\mathbf{m}_\alpha, \Sigma_\alpha), \quad \beta = \mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta), \quad T(x) = \mathbf{m}_\beta + A(x - \mathbf{m}_\alpha), \quad (2.14)$$

则 T 是凸二次势 $\varphi(x) = \langle \mathbf{m}_\beta, x \rangle + \langle A(x - \mathbf{m}_\alpha), x - \mathbf{m}_\alpha \rangle / 2$ 的梯度, 当且仅当 A 是对称正半定的。

命题 2.37 (高斯的仿射推前). 有 $T_\# \alpha = \beta$ 当且仅当

$$A \Sigma_\alpha A^\top = \Sigma_\beta. \quad (2.15)$$

证明. 仿射函数将高斯映射到高斯, 因此 $T(X)$ 的律由其均值和协方差决定。如果 $X \sim \alpha$ 且 $Y = T(X)$, 则

$$\mathbb{E}(Y) = \mathbf{m}_\beta + A\mathbb{E}(X - \mathbf{m}_\alpha) = \mathbf{m}_\beta,$$

且

$$\mathbb{E}((Y - \mathbf{m}_\beta)(Y - \mathbf{m}_\beta)^\top) = A\mathbb{E}((X - \mathbf{m}_\alpha)(X - \mathbf{m}_\alpha)^\top)A^\top = A \Sigma_\alpha A^\top.$$

因此, $A \Sigma_\alpha A^\top = \Sigma_\beta$ 是 Y 具有与 β 相同均值和协方差的充要条件。□

协方差方程关于 A 是二次的。在 Brenier 定理施加的对称约束下, 它变成 $A \Sigma_\alpha A = \Sigma_\beta$ 。所得代价的协方差部分是一个矩阵度量。

定义 2.38 (Bures 度量). 对于正半定协方差矩阵 Σ 和 Λ , Bures 度量为

$$\mathcal{B}(\Sigma, \Lambda)^2 := \text{tr} \left(\Sigma + \Lambda - 2(\Sigma^{1/2} \Lambda \Sigma^{1/2})^{1/2} \right). \quad (2.16)$$

下一个命题求解协方差方程, 并表明该度量正是高斯 $\mathcal{W}_2$ 的协方差贡献。

命题 2.39 (高斯 $\mathcal{W}_2$ 公式与 Bures 协方差项). 假设 Σ_α 和 Σ_β 是正定的。方程

$$A \Sigma_\alpha A = \Sigma_\beta$$

的唯一对称正定解是

$$A = \Sigma_\alpha^{-1/2} \left(\Sigma_\alpha^{1/2} \Sigma_\beta \Sigma_\alpha^{1/2} \right)^{1/2} \Sigma_\alpha^{-1/2}. \quad (2.17)$$

仿射映射 $T(x) = \mathbf{m}_\beta + A(x - \mathbf{m}_\alpha)$ 是从 $\mathcal{N}(\mathbf{m}_\alpha, \Sigma_\alpha)$ 到 $\mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta)$ 的最优二次代价传输, 并且

$$\mathcal{W}_2(\alpha, \beta)^2 = \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \mathcal{B}(\Sigma_\alpha, \Sigma_\beta)^2, \quad (2.18)$$

其中 $\mathcal{B}$ 是定义 2.38 的 Bures 度量。

证明. 在 $A \Sigma_\alpha A = \Sigma_\beta$ 左右两侧乘以 $\Sigma_\alpha^{1/2}$, 得到

$$(\Sigma_\alpha^{1/2} A \Sigma_\alpha^{1/2})^2 = \Sigma_\alpha^{1/2} \Sigma_\beta \Sigma_\alpha^{1/2}.$$


由于 A 对称正定, $\Sigma_\alpha^{1/2} A \Sigma_\alpha^{1/2}$ 也是对称正定的, 因此是右端的唯一正平方根。反过来, (2.17) 中的矩阵对称正定, 并满足协方差方程。

由命题 2.37, 该仿射映射将 α 推前到 β 。它是凸二次势的梯度, 因此 Brenier 定理推出最优性。如果 $X \sim \alpha$, 则

$$\begin{aligned}\mathbb{E}\|X - T(X)\|^2 &= \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \mathbb{E}\|(I - A)(X - \mathbf{m}_\alpha)\|^2 \\ &= \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \text{tr}((I - A)\Sigma_\alpha(I - A)^\top) \\ &= \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \text{tr}(\Sigma_\alpha) + \text{tr}(A\Sigma_\alpha A) - 2\text{tr}(A\Sigma_\alpha) \\ &= \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \text{tr}(\Sigma_\alpha) + \text{tr}(\Sigma_\beta) - 2\text{tr}((\Sigma_\alpha^{1/2}\Sigma_\beta\Sigma_\alpha^{1/2})^{1/2}),\end{aligned}$$

这就是所需表达式。奇异协方差矩阵的公式通过加上 ηI 并令 $\eta \downarrow 0$ 得到。 $\square$

协方差项 $\mathcal{B}$ 是正半定矩阵上的 Bures–Wasserstein 度量 [46, 102, 29]。它把均值的欧氏位移与协方差椭球的内在传输几何分离开来。



各向异性到各向同性

旋转的各向异性

图 2.6: 二维高斯 $\mathcal{W}_2$ 测地线。均值线性移动, 而协方差椭圆遵循 Bures–Wasserstein 插值。左面板将一个各向异性高斯收缩到各向同性高斯; 右面板在两个强定向的各向异性协方差之间插值。

命题 2.40 (Bures 项的度量与凸性性质). 函数 $\mathcal{B}$ 是正半定协方差矩阵上的距离。此外, $\mathcal{B}^2$ 是联合凸的: 对 $t \in [0, 1]$,

$$\mathcal{B}^2((1-t)\Sigma_0 + t\Sigma_1, (1-t)\Lambda_0 + t\Lambda_1) \leq (1-t)\mathcal{B}^2(\Sigma_0, \Lambda_0) + t\mathcal{B}^2(\Sigma_1, \Lambda_1).$$

证明. 关键恒等式是 Procrustes 表示

$$\mathcal{B}^2(\Sigma, \Lambda) = \min_{Q^\top Q = I} \|\Sigma^{1/2} - \Lambda^{1/2}Q\|_F^2.$$

确实, 展开平方给出 $\text{tr}\Sigma + \text{tr}\Lambda - 2\max_{Q^\top Q = I} \text{tr}(\Sigma^{1/2}Q^\top\Lambda^{1/2})$, 而正交 Procrustes 公式将最大值识别为 $\text{tr}((\Sigma^{1/2}\Lambda\Sigma^{1/2})^{1/2})$ 。对称性、正性和分离性立即由该表示推出。三角不等式通过选择两个近乎最优的正交矩阵 Q_1, Q_2 并写出

$$\|\Sigma^{1/2} - \Lambda^{1/2}Q_2Q_1\|_F \leq \|\Sigma^{1/2} - \Lambda^{1/2}Q_1\|_F + \|\Lambda^{1/2} - \Lambda^{1/2}Q_2\|_F.$$

令这两个选择趋于最优, 证明了度量性质。

对于凸性, 使用等价的因子表述

$$\mathcal{B}^2(\Sigma, \Lambda) = \min_{UU^\top = \Sigma, VV^\top = \Lambda} \|U - V\|_F^2.$$

为这两对选择近乎最优的因子 (U_0, V_0) 和 (U_1, V_1) , 并定义块因子

$$U_t = [\sqrt{1-t}U_0, \sqrt{t}U_1], \quad V_t = [\sqrt{1-t}V_0, \sqrt{t}V_1].$$

则 $U_t U_t^\top = (1-t)\Sigma_0 + t\Sigma_1$ 且 $V_t V_t^\top = (1-t)\Lambda_0 + t\Lambda_1$, 同时

$$\|U_t - V_t\|_F^2 = (1-t)\|U_0 - V_0\|_F^2 + t\|U_1 - V_1\|_F^2.$$

对初始因子取下确界, 证明联合凸性。 $\square$

注 2.41 (对角协方差与 Hellinger 几何). 如果 $\Sigma_\alpha = \text{diag}(r_i)_i$ 和 $\Sigma_\beta = \text{diag}(s_i)_i$ 是对角的, 则 Bures 度量化为平方根之间的欧氏距离,

$$\mathcal{B}(\Sigma_\alpha, \Sigma_\beta) = \|\sqrt{r} - \sqrt{s}\|_2.$$

这是非负协方差坐标上的有限维 Hellinger 几何: 方差在幅度变量替换 $r_i \mapsto \sqrt{r_i}$ 之后进行比较。

Kantorovich 松弛

Kantorovich 松弛是把传输转化为凸优化的决定性步骤。本章解释确定性映射如何被耦合取代，为什么这修正了不可行性与对称性问题，以及它如何产生 Wasserstein 距离。从历史上看，这种线性规划观点源于 Kantorovich 关于经济计划的工作 [128]，如今已成为最优传输的标准基础 [225, 226, 191]。

3.1 离散松弛

离散松弛是观察质量拆分最清楚的场景。它用传输多胞形取代排列，并揭示算法所利用的线性规划结构。

Monge 的离散匹配问题存在困难，因为当 $n \neq m$ 时它无法适用。一个忠实的表述必须跟踪质量 (a_i, b_j) 。基于推前映射的连续 Monge 问题 (2.5) 以另一种形式具有同样的障碍：可能不存在满足 $T_\# \alpha = \beta$ 的映射 T 。例如，当一个单个 Dirac 质量应被送往多个 Dirac 质量时，就会发生这种情况。

这种质量拆分的缺失也使 Monge 表述在 α 和 β 上不对称：可以把两个 Dirac 质量映射到一个 Dirac 质量，但反过来不行。即使存在可行映射，所得优化问题也是非凸的，因此在数值上难以求解。

Kantorovich 的关键思想 [128] 是放松传输的确定性性质。不再要求每个源点 x_i 必须被送到恰好一个目标，而是允许 x_i 处的质量被分派到若干位置。这样就从确定性的传输映射转向概率式的，或模糊的，传输计划。该松弛不是用排列 σ 或映射 T 来编码，而是用耦合矩阵 $P \in \mathbb{R}_+^{n \times m}$ 编码，其中在离散测度的形式中， $P_{i,j}$ 描述从 x_i 流向 y_j 的质量数量

$$\alpha = \sum_i a_i \delta_{x_i}, \quad \beta = \sum_j b_j \delta_{y_j}.$$

定义 3.1 (离散耦合与质量守恒). 可行耦合只受质量守恒约束：

$$U(a, b) := \{P \in \mathbb{R}_+^{n \times m}; P \mathbf{1}_m = a \quad \text{and} \quad P^\top \mathbf{1}_n = b\}. \quad (3.1)$$

等价地，

$$P \mathbf{1}_m = \left(\sum_j P_{i,j} \right)_i \in \mathbb{R}^n, \quad P^\top \mathbf{1}_n = \left(\sum_i P_{i,j} \right)_j \in \mathbb{R}^m.$$

该松弛的第一个有用后果是可行性：总是至少存在一个可行计划，它通过让源与目标独立而得到。

定义 3.2 (离散乘积耦合). 给定权重 $a \in \Sigma_n$ 和 $b \in \Sigma_m$ ，离散乘积耦合，或平凡耦合，为

$$(a \otimes b)_{i,j} := a_i b_j.$$

它属于 $U(a, b)$ ，并对应于独立地选择源标签和目标标签。

这个可行集是一个仿射空间与非负正交象限的有界交，因此是一个凸多胞形。在一维中，有序耦合可以读作一个矩阵：行索引源分箱，列索引目标分箱，而边缘约束表现为给定的行和与列和。

命题 3.3 (离散乘积最优性是退化的). 假设零质量行和列已经被移除，因此 $a_i > 0$ 且 $b_j > 0$ ，并令 C 为一个有限代价矩阵。乘积计划 $a \otimes b$ 在 $U(a, b)$ 上最小化 $P \mapsto \langle C, P \rangle$ ，当且仅当每个耦合 $P \in U(a, b)$ 都最小化它。

证明. 反向蕴含是直接的。反过来，假设 $a \otimes b$ 是最优的，并令 $Q \in U(a, b)$ 任意。由于 $a \otimes b$ 的所有条目都是正的，存在足够小的 $t > 0$ 使得

$$R := (1 + t)(a \otimes b) - tQ$$

具有非负条目。它的行和与列和为

$$R \mathbf{1}_m = (1 + t)a - ta = a, \quad R^\top \mathbf{1}_n = (1 + t)b - tb = b,$$

因此 $R \in U(a, b)$ 。此外,


$$a \otimes b = \frac{1}{1+t}R + \frac{t}{1+t}Q.$$

由 $a \otimes b$ 的最优性, $\langle C, R \rangle$ 和 $\langle C, Q \rangle$ 都至少为 $\langle C, a \otimes b \rangle$ 。将该凸组合恒等式与 C 取标量积得到

$$\langle C, a \otimes b \rangle = \frac{1}{1+t}\langle C, R \rangle + \frac{t}{1+t}\langle C, Q \rangle.$$

两个不小于 $\langle C, a \otimes b \rangle$ 的数的凸平均只有在这两个数都等于 $\langle C, a \otimes b \rangle$ 时才可能等于它。因此 $\langle C, Q \rangle = \langle C, a \otimes b \rangle$, 且 Q 是最优的。由于 Q 任意, 所有耦合都是最优的。□

因此, 乘积计划主要是一个可行性见证。除非在线性代价在整个传输多胞形上为常数的退化情形下, 否则它通常不应被期待求解最优传输。它也是最大程度弥散的: 当所有质量都为正时, 它有 nm 个正条目, 而下面的命题 3.4 表明, 总是存在至多有 $n + m - 1$ 个正条目的稀疏最优计划。



确定性图

乘积计划 $a \otimes b$

最优计划

图 3.1: 离散耦合表示为匹配章节所用规范点云上的直线传输线段。确定性图是一个可行的 Monge 型计划, 乘积计划把每个源质量散布到所有目标上, 而最优 Kantorovich 计划最小化二次传输代价。线宽和不透明度编码被传输的质量。




图 3.2: 带有给定边缘的耦合矩阵。中央灰度图显示 P_{ij} ; 左侧红色曲线是源边缘 a , 顶部蓝色曲线是目标边缘 b 。独立乘积计划是弥散的, 而一维最优计划集中在单调分位数对应附近。只有稠密的 200 分箱最优面板叠加了重心投影 $i \mapsto \sum_j P_{ij}j/a_i$, 因为该曲线只有在足够分辨率下才具有视觉意义。

Monge 表述本质上是不对称的, 而 Kantorovich 的松弛表述在可行集层面对称: 耦合 P 属于 $U(a, b)$, 当且仅当 $P^\top$ 属于 $U(b, a)$ 。

以经济计划为目标的 Kantorovich 作出了一个强简化假设: 传输代价应当关于被传输的质量数量是线性的。在该假设下, 记 $C_{i,j}$ 为把单位质量从 x_i 移到 y_j 的代价, 离散 Kantorovich 问题为

$$L_C(a, b) := \min_{P \in U(a, b)} \langle C, P \rangle := \min_{P \in U(a, b)} \sum_{i, j} C_{i, j} P_{i, j}. \quad (3.2)$$

这是一个线性规划, 其解不必唯一。




图 3.3: 从排列矩阵到拆分耦合。当两个经验测度具有相同数量的原子且权重均匀时, 一个最优计划可以是排列矩阵。一旦目标质量非均匀, 可行集 $U(a, b)$ 也包含这样的计划: 一个源向多个目标发送质量, 多个源并入同一个目标。

命题 3.4 (稀疏最优计划). 假设 $a_i > 0, b_j > 0$ 且 $\sum_i a_i = \sum_j b_j = 1$ 。线性规划 (3.2) 存在一个至多有 $n + m - 1$ 个非零条目的最优耦合。

证明. 传输多胞形是紧的, 因此线性目标在一个极点处达到其最小值。行边缘方程和列边缘方程的秩为 $n + m - 1$: 唯一的线性冗余是两组约束施加了相同的总质量。下面的支撑图论证是这个基本可行变量计数的组合形式。

令 P 为一个极点, 并令 $E = \{(i, j) : P_{ij} > 0\}$ 为它在二部顶点集 $\{1, \dots, n\} \cup \{1, \dots, m\}$ 上的支撑图。如果该图包含一个环, 则给该环定向, 并在其边上交替放置符号 $+1, -1$, 得到一个支撑在 E 上且行和、列和为零的非零矩阵 H 。对于足够小的 $t > 0$, $P + tH$ 和 $P - tH$ 都是非负耦合, 且 P 是它们的中点, 这与极点性矛盾。因此支撑图是一片森林。由于 $n + m$ 个顶点上的森林至多有 $n + m - 1$ 条边, 结论随之成立。 $\square$

命题 3.5 (西北角可行计划). 令 $a \in \mathbb{R}_+^n$ 和 $b \in \mathbb{R}_+^m$ 具有相同的正总质量。以下贪心扫描构造一个耦合 $P \in U(a, b)$, 它至多有 $n + m - 1$ 个正条目, 并且正支撑无环。从 $(i, j) = (1, 1)$ 开始, 残余质量为 $r_i = a_i$ 与 $s_j = b_j$, 跳过零残余, 设置

$$P_{ij} = \min(r_i, s_j),$$

从两个残余中都减去这个值, 并推进每个残余已变为零的索引。重复直到所有残余质量耗尽。

证明. 所有指派都是非负的。在每一步, 放入条目 (i, j) 的质量恰好从一个当前行残余和一个当前列残余中减去, 因此没有行或列会接收超过规定的质量。反过来, 只有当某个索引的残余已被完全填满时才推进该索引。当算法停止时, 总指派质量为 $\sum_i a_i = \sum_j b_j$, 因此所有行和列和恰好为 a 和 b 。

每个正指派至少耗尽一个当前行或一个当前列。在最后一次指派之前, 至多可以发生 $n - 1$ 次行推进和 $m - 1$ 次列推进而不终止构造。因此正条目的数量至多为 $(n - 1) + (m - 1) + 1 = n + m - 1$ 。对于无环性, 把正支撑看作二部图。一旦某个行或列索引被推进, 它就不会再次出现, 因此每条新的正边要么开始一个新连通分量, 要么把至少一个新顶点附接到当前正在扫描的连通分量上。永远不会在同一连通分量的两个旧顶点之间添加边, 因此不会产生环。 $\square$

算法 3.1 西北角耦合

输入: 源权重 $a \in \Sigma_n$ 和目标权重 $b \in \Sigma_m$ 。

输出: 稀疏可行耦合 $P \in U(a, b)$ 。

初始化: 设 $P = 0, r = a, s = b$, 并设 $(i, j) = (1, 1)$ 。

当 $i \leq n$ 且 $j \leq m$ 时执行:

$\eta = \min(r_i, s_j), \quad P_{ij} \leftarrow \eta.$

更新残余: $r_i \leftarrow r_i - \eta, \quad s_j \leftarrow s_j - \eta.$

如果 $r_i = 0$ 则:

设 $i \leftarrow i + 1$ 。

如果 $s_j = 0$ 则:

设 $j \leftarrow j + 1$ 。

返回 P 。

算法 3.1 总结的西北角规则不使用代价矩阵, 因此并不是为了求解 (3.2)。它的作用是算法性的: 无环支撑对应于线性无关的边缘约束。当支撑少于 $n + m - 1$ 个正条目时, 传输单纯形实现会用零质量基本变量补全它, 以得到一个退化的基本可行解。这为第 3.2 节讨论的枢轴方法提供了廉价初始化。

一维情形。 在一维中，传输多胞形具有一个规范的单调优化器。这是第 1.1 节排序规则的加权版本。

命题 3.6 (一维加权扫描). 令 $x_1 \leq \dots \leq x_n$ 和 $y_1 \leq \dots \leq y_m$ 为直线上的点，并令 $c(x, y) = h(x - y)$ ，其中 h 为凸函数。排序后的加权原子之间的西北角计划对于 (3.2) 是最优的。因此，对于未排序的一维输入，通过排序并随后从左到右扫描一次质量，可以在 $O(n \log n + m \log m)$ 时间内得到一个最优计划。

证明. 西北角计划是单调的：如果 $i < i'$ 且 $j > j'$ ，它不可能同时在 (i, j) 和 (i', j') 上放置正质量，因为扫描按递增顺序耗尽行和列。反过来，任何具有一对交叉正条目的可行计划，都可以通过把小质量 η 从 (i, j) 和 (i', j') 移到 (i, j') 和 (i', j) 来改进。两个边缘保持不变，而 h 的凸性给出

$$h(x_i - y_j) + h(x_{i'} - y_{j'}) \geq h(x_i - y_{j'}) + h(x_{i'} - y_j)$$

对于 $i < i'$ 和 $j' < j$ 成立；当 h 严格凸且点互异时，不等式严格。重复这种解交叉过程直到不再有交叉，就得到一个单调最优计划。对于给定的排序边缘，只有一个单调可行计划，即扫描计划：它在每一步把最左侧剩余源质量与最左侧剩余目标质量配对。排序代价为 $O(n \log n + m \log m)$ ，扫描至多使用 $n + m - 1$ 次指派。□

算法 3.2 加权一维扫描

输入： 一维原子 (x_i, a_i) 和 (y_j, b_j) ；凸代价 $h(x - y)$ 。

输出： 单调最优耦合 P 。

排序原子： $x_1 \leq \dots \leq x_n$, $y_1 \leq \dots \leq y_m$ 。

设 P 为将算法 3.1 应用于排序后权重 $(a_i)_i$ 和 $(b_j)_j$ 的输出。返回 P 。

作为耦合的排列矩阵。 现在我们把注意力限制在特殊情形 $n = m$ 和均匀权重 $a = b = \mathbf{1}_n/n$ 。在这种情况下，匹配可以编码为一个每行每列恰有一个活跃条目的矩阵。

定义 3.7 (排列矩阵). 对于排列 $\sigma \in \text{Perm}(n)$ ，其排列矩阵 P_σ 为

$$(P_\sigma)_{i,j} = \begin{cases} 1 & \text{if } j = \sigma(i), \\ 0 & \text{否则.} \end{cases}$$

所有排列矩阵的集合为

$$\mathcal{P}_n^{\text{perm}} := \{P_\sigma ; \sigma \in \text{Perm}(n)\}.$$

相应的概率耦合为 P_σ/n 。如果匹配代价矩阵为 C ，则

$$\langle C, P_\sigma/n \rangle = \frac{1}{n} \sum_{i=1}^n C_{i, \sigma(i)}.$$

因此，指派问题就是在离散、非凸的排列矩阵集合上最小化一个线性函数。

凸松弛用所有双随机矩阵取代这个有限集合。

定义 3.8 (Birkhoff 多胞形). Birkhoff 多胞形是双随机矩阵的凸集合

$$\mathcal{B}_n := \{P \in \mathbb{R}_+^{n \times n} ; P \mathbf{1}_n = \mathbf{1}_n \text{ and } P^\top \mathbf{1}_n = \mathbf{1}_n\}.$$

于是 $U(\mathbf{1}_n/n, \mathbf{1}_n/n) = \mathcal{B}_n/n$ ，且排列耦合包含在这个凸松弛中。更精确地，

$$\mathcal{P}_n^{\text{perm}} = \mathcal{B}_n \cap \{0, 1\}^{n \times n} \subset \mathcal{B}_n,$$

因此，在使用 $\mathcal{B}_n$ 的结构之前，首先只能得到松弛不等式

$$\min_{P \in \mathcal{B}_n} \langle C, P \rangle \leq \min_{P \in \mathcal{P}_n^{\text{perm}}} \langle C, P \rangle.$$

接下来的基本事实导向 Birkhoff–von Neumann 定理 [31, 228]，该定理解释了为什么这个松弛对于均匀匹配是紧的。

定义 3.9 (极点). 对于有限维向量空间中的紧凸集 C ,

$$\text{Extr}(C) := \{x \in C; x = (y+z)/2, y, z \in C \Rightarrow y = z = x\}.$$

命题 3.10 (极点的存在性). 如果 C 是有限维向量空间中非空紧凸子集, 则 $\text{Extr}(C)$ 非空。

证明. 在 C 的所有非空面中, 选择一个仿射维数最小的面。如果该面包含两个不同点, 则最大化一个在该面上非常数的线性泛函会产生一个非空真暴露子面, 这与最小性矛盾。因此最小面是单点集, 其点为极点。□

例 3.11 (无界凸集可能没有极点). 命题 3.10 中的紧性不能去掉。例如, 闭凸集 $\{(x, y) \in \mathbb{R}_+^2; xy \geq 1\}$ 是无界的, 且没有极点。

命题 3.12 (线性规划有极点极小化子). 令 C 非空且紧。对于每个线性形式 ℓ ,

$$\text{Extr}(C) \cap \underset{x \in C}{\text{argmin}} \ell(x) \neq \emptyset.$$

证明. 集合 $S = \underset{x \in C}{\text{argmin}} \ell(x)$ 非空、紧且凸。由命题 3.10, 它有一个极点 x 。如果 $x = (y+z)/2$ 且 $y, z \in C$, 则由线性性和 x 的最优性, y 和 z 也都在 C 上最小化 ℓ , 因此 $y, z \in S$ 。由于 x 是 S 中的极点, $y = z = x$ 。于是 x 是 C 中的极点。□

定理 3.13 (Birkhoff–von Neumann). B_n 的极点恰好是排列矩阵。

证明. 我们首先证明排列矩阵是极点。令 $P_\sigma \in \mathcal{P}_n^{\text{perm}}$, 并假设

$$P_\sigma = \frac{Q+R}{2} \quad \text{且} \quad Q, R \in B_n.$$

每个双随机矩阵的条目都在 $[0, 1]$ 中。由于 $[0, 1]$ 的唯一极点是 0 和 1, P_σ 的每个条目都固定了 Q 和 R 的相应条目: 如果 $(P_\sigma)_{ij} = 0$, 则 $Q_{ij} = R_{ij} = 0$; 而如果 $(P_\sigma)_{ij} = 1$, 则 $Q_{ij} = R_{ij} = 1$ 。因此 $Q = R = P_\sigma$, 所以 P_σ 是极点。

现在我们用逆否命题证明反向结论。取 $P \in B_n \setminus \mathcal{P}_n^{\text{perm}}$ 。由于整数双随机矩阵必然是排列矩阵, P 至少有一个分数条目。我们将把它分解为

$$P = \frac{Q+R}{2}$$

其中 $Q, R \in B_n$ 且 $Q \neq R$, 从而证明 P 不是极点。

给 P 关联一个二部图, 其左侧顶点是行, 右侧顶点是列, 边为分数条目

$$0 < P_{ij} < 1.$$

等于 1 的条目使用了其所在行和列的全部质量, 因此它在正支撑中是孤立的, 并且不会出现在这个分数图中。如果左顶点 i 与一条分数边 (i, j_1) 相接, 则它必须至少还与另一条分数边相接。确实, 行和为一; 在贡献 $P_{i, j_1} \in (0, 1)$ 之后, 同一行中仍剩下正量 $1 - P_{i, j_1}$, 而它不可能由一个等于 1 的条目承载。利用列和, 同样的论证适用于右顶点。因此, 分数图中的每个非孤立顶点的度至少为二。

因此, 从任意分数边出发, 可以沿相邻的分数边行走, 既不立即回退, 也不会卡住。由于图是有限的, 某个顶点最终会被访问两次; 两次访问之间的行走部分包含一个环。选择一个最短的此类环, 并把它写成交替形式

$$(i_1, j_1, i_2, j_2, \dots, i_p, j_p), \quad i_{p+1} = i_1,$$

其中对于每个 s , (i_s, j_s) 和 (i_{s+1}, j_s) 都是分数边。该环的最小性意味着顶点 i_s 彼此不同, 且顶点 j_s 也彼此不同。特别地,

$$0 < P_{i_s, j_s} < 1 \quad \text{and} \quad 0 < P_{i_{s+1}, j_s} < 1.$$

定义

$$\varepsilon := \min_{1 \leq s \leq p} \{P_{i_s, j_s}, P_{i_{s+1}, j_s}, 1 - P_{i_s, j_s}, 1 - P_{i_{s+1}, j_s}\}.$$

所有这些数都是正的, 因此 $\varepsilon > 0$ 。把环边分成两个交替族

$$A := \{(i_s, j_s)\}_{s=1}^p, \quad B := \{(i_{s+1}, j_s)\}_{s=1}^p.$$

现在执行标准的交替环扰动:

$$Q_{ij} := \begin{cases} P_{ij}, & (i, j) \notin A \cup B, \\ P_{ij} + \varepsilon/2, & (i, j) \in A, \\ P_{ij} - \varepsilon/2, & (i, j) \in B, \end{cases} \quad R_{ij} := \begin{cases} P_{ij}, & (i, j) \notin A \cup B, \\ P_{ij} - \varepsilon/2, & (i, j) \in A, \\ P_{ij} + \varepsilon/2, & (i, j) \in B. \end{cases}$$

由 ε 的定义, 所有被修改条目仍在 $[0, 1]$ 中, 因此 Q 和 R 非负。环的每个行顶点 i_s 恰好与 A 的一条边和 B 的一条边相接; 因此 $+\varepsilon/2$ 与 $-\varepsilon/2$ 扰动在该行中相互抵消。同样的抵消在每个列顶点 j_s 中成立, 其余行和列保持不变。因此

$$Q\mathbf{1}_n = R\mathbf{1}_n = \mathbf{1}_n, \quad Q^\top \mathbf{1}_n = R^\top \mathbf{1}_n = \mathbf{1}_n,$$

所以 $Q, R \in \mathcal{B}_n$ 。最后, 由于 $\varepsilon > 0$ 且环非空, $Q \neq R$; 而按构造 $P = (Q + R)/2$ 。因此 P 不是极点。于是 $\mathcal{B}_n$ 的每个极点都是整数的, 而每个整数双随机矩阵都是排列矩阵。□

同样的组合思想给出了构造性分解, 用来把一个双随机矩阵表示为排列的凸组合。

算法 3.3 Birkhoff–von Neumann 分解

输入: 双随机矩阵 $P \in \mathcal{B}_n$ 。

输出: 分解 $P = \sum_r \lambda_r P_{\sigma_r}$ 。

初始化: 设 $R = P$ 且 $\mathcal{L} = \emptyset$ 。

当 $R \neq 0$ 时执行:

构造二部图 $G_R = \{(i, j) : R_{ij} > 0\}$ 。
 设 σ 为 G_R 的字典序第一个完美匹配。
 设 $\lambda = \min_i R_{i, \sigma(i)}$ 。
 将 (λ, σ) 追加到 $\mathcal{L}$ 。
 更新 $R \leftarrow R - \lambda P_\sigma$ 。

返回 $P = \sum_{(\lambda_r, \sigma_r) \in \mathcal{L}} \lambda_r P_{\sigma_r}, \quad \sum_r \lambda_r = 1$ 。

推论 3.14 (用于匹配的 Kantorovich). 如果 $m = n$ 且 $\mathbf{a} = \mathbf{b} = \mathbf{1}_n/n$, 则离散 Kantorovich 问题 (3.2) 存在形如 P_σ/n 的最优解。相应排列 σ 求解第 1.1 节的指派问题。

证明. 可行集为 $\mathcal{B}_n/n$ 。由命题 3.12, 线性目标有一个最优极点。由于缩放保持极点, 而定理 3.13 确定了 $\mathcal{B}_n$ 的极点, 该优化器是某个排列 σ 的 P_σ/n 。它的代价恰好是 $n^{-1} \sum_i C_{i, \sigma(i)}$, 因此 σ 是一个最优指派。□

等价地, 对于均匀经验测度, 总能在松弛 Kantorovich 问题的极小化子中选择一个排列矩阵: 该松弛对于指派问题是紧的。

注 3.15 (一般离散情形). 对于一般输入测度, Monge 问题与 Kantorovich 问题并不等价, 因为 Monge 约束可能为空。然而在有限维中, 最优耦合的支撑仍具有强稀疏性: 可以选择一个最优基本可行计划, 其二部支撑无环, 因此至多有 $n + m - 1$ 个非零条目。图 3.3 展示了紧的均匀匹配情形与真正发生拆分的非均匀情形之间的差异。

3.2 线性规划算法

离散 Kantorovich 问题是一个线性规划, 但其结构远多于一般稠密线性规划。它的变量是完全二部网络的弧, 它的等式约束是流守恒约束, 它的极点是稀疏的树状耦合。这就是为什么虽然该表述是有限维且凸的, 经典传输算法仍然重要。

传输单纯形与网络单纯形. 传输单纯形可以追溯到 Dantzig 对传输问题的表述 [75]。它作用于基本可行耦合, 其正支撑被补全为二部供需图的一棵生成树。从一个基开始, 例如由西北角规则产生的基, 约化代价识别某条未使用弧是否能降低目标。添加这样一条弧会在树中产生唯一的环; 随后沿该环尽可能多地推送质量, 并移除被耗尽的弧。这正是专门化到传输多胞形的单纯形方法, 其枢轴可以用图操作实现, 而不需要一般的基逆。

网络单纯形是一般最小代价流问题对应的枢轴方法 [27]。它维护节点势、约化代价和生成树基, 并已成为中等规模离散最优传输最有效的精确求解器之一。与普通单纯形方法一样, 在对抗性实例上, 其最坏情形枢轴次数可能是指数级的, 但每次枢轴操作会利用稀疏性, 实践中非常高效。若需要理论上的多项式保证, 可以改用强多项式的最小代价流算法, 例如 Orlin 算法 [175]。在一个具有 n 个源和 n 个目标的稠密平衡传输问题中, 图有 $O(n)$ 个顶点和 $O(n^2)$ 条弧, 因此这些一般界是多项式的, 但仍然比 Sinkhorn 将利用的近似矩阵-向量结构重得多。

内点方法。 一般内点方法通过一条光滑的中心路径处理同一个线性规划。对于传输多胞形，对数障碍版本为

$$P_\varepsilon := \underset{\substack{P \mathbf{1}_m = \mathbf{a}, \ P^\top \mathbf{1}_n = \mathbf{b} \\ P_{ij} > 0}}{\operatorname{argmin}} \quad \langle C, P \rangle - \varepsilon \sum_{i,j} \log P_{ij}, \quad (3.3)$$

其中 $\varepsilon > 0$ 在算法过程中递减。障碍在边界处奇异，因此每次迭代都严格停留在传输多胞形内部；当 $\varepsilon \downarrow 0$ 时，中心路径趋近于线性规划极小化子集合。每个 Newton 步求解一个涉及边缘约束和当前对角 Hessian $\operatorname{diag}(\varepsilon/P_{ij}^2)$ 的线性系统，这给出稳健的多项式复杂度，但对稠密耦合可能代价高昂 [172]。




图 3.4: 一个线性规划的二维等边三角形切片上的对数障碍中心路径。可行三角形由正松弛量约束，所显示的目标为 $\ell^\top z - \varepsilon \sum_i \log(b_i - \langle a_i, z \rangle)$ 。大的 ε 选择中央内点；减小 ε 会把极小化子推向最优顶点，同时始终不接触边界。这应当与熵最优传输形成对照，在后者中，熵温度 ε 通常是固定的，并定义正则化问题本身。

因此，与 Sinkhorn 的比较是微妙的。两类方法都保持迭代为正，但它们以不同方式使用正性。内点算法通过减小障碍参数 ε 并沿中心路径前进来求解原始线性规划。Sinkhorn 固定一个熵温度 ε ，并通过交替对角缩放求解另一个 KL 正则化的最优传输问题。参数 ε 可以在延拓策略中递减，但对于一次固定运行，它是目标的一部分，而不仅是算法障碍。

3.3 任意测度的松弛

本节把有限维耦合矩阵提升为联合概率测度。其收益是，存在性、对偶性和度量性质可以针对任意分布律来陈述，包括离散、奇异和连续分布。

连续耦合。 第一步是形式化一个联合律具有给定边缘是什么意思。

定义 3.16 (联合测度的边缘). 令 $\pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y})$ ，并令 $P_{\mathcal{X}}(x, y) = x$ 、 $P_{\mathcal{Y}}(x, y) = y$ 为坐标投影。 π 的边缘为

$$\pi_1 := (P_{\mathcal{X}})_\# \pi \in \mathcal{M}_+^1(\mathcal{X}), \quad \pi_2 := (P_{\mathcal{Y}})_\# \pi \in \mathcal{M}_+^1(\mathcal{Y}).$$

等价地，对于 $\mathcal{X}$ 上所有有界连续测试函数 f 和 $\mathcal{Y}$ 上所有有界连续测试函数 g ，

$$\int_{\mathcal{X} \times \mathcal{Y}} f(x) d\pi(x, y) = \int_{\mathcal{X}} f d\pi_1, \quad \int_{\mathcal{X} \times \mathcal{Y}} g(y) d\pi(x, y) = \int_{\mathcal{Y}} g d\pi_2.$$

边缘约束 $\pi_1 = \alpha$ 和 $\pi_2 = \beta$ 的一个有用记忆方式是形式化的行列记号

$$\int_{\mathcal{Y}} d\pi(x, y) = d\alpha(x), \quad \int_{\mathcal{X}} d\pi(x, y) = d\beta(y),$$

它由定义 3.16 严格化，或等价地，由对可测集 $A \subset \mathcal{X}$ 与 $B \subset \mathcal{Y}$ 成立的恒等式 $\pi(A \times \mathcal{Y}) = \alpha(A)$ 和 $\pi(\mathcal{X} \times B) = \beta(B)$ 严格化。

定义 3.17 (耦合). 给定 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ 和 $\beta \in \mathcal{M}_+^1(\mathcal{Y})$ ， α 与 β 之间的耦合集为

$$\mathcal{U}(\alpha, \beta) := \{\pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y}) ; \pi_1 = \alpha \text{ and } \pi_2 = \beta\}. \quad (3.4)$$

这是传输多胞形 (3.1) 的连续类似物。

注 3.18 (耦合的概率解释). 如果 $X \sim \alpha$ 且 $Y \sim \beta$, 那么 $\pi \in \mathcal{U}(\alpha, \beta)$ 意味着 π 是一对 (X, Y) 的分布律, 其坐标分别具有分布律 α 和 β 。耦合编码 X 与 Y 之间的依赖关系。张量积 $\alpha \otimes \beta$ 对应于独立性, 而图耦合 $(\text{Id}, T)_\# \alpha$ 对应于确定性关系 $Y = T(X)$ 。

在离散情形中, 当 $\alpha = \sum_i a_i \delta_{x_i}$ 且 $\beta = \sum_j b_j \delta_{y_j}$ 时, 约束 $\pi_1 = \alpha$ 和 $\pi_2 = \beta$ 迫使每个耦合都具有形式 $\pi = \sum_{i,j} P_{ij} \delta_{(x_i, y_j)}$, 其中 $P \in \mathcal{U}(a, b)$ 。因此, 离散表述是连续表述的一个特例, 而不仅仅是近似。

与 Monge 约束不同, 耦合约束从不为空。连续可行性见证是张量积耦合, 它是上面离散乘积计划的测度论版本。

定义 3.19 (张量积与平凡耦合). 给定 $\alpha \in \mathcal{M}_+^1(\mathcal{X})$ 和 $\beta \in \mathcal{M}_+^1(\mathcal{Y})$, 张量积耦合 $\alpha \otimes \beta$ 是 $\mathcal{X} \times \mathcal{Y}$ 上的概率测度, 定义为

$$\int_{\mathcal{X} \times \mathcal{Y}} h(x, y) d(\alpha \otimes \beta)(x, y) = \int_{\mathcal{X}} \left(\int_{\mathcal{Y}} h(x, y) d\beta(y) \right) d\alpha(x)$$

对每个有界可测 h 成立。它也称为平凡耦合, 因为它使两个坐标独立。

确实, 对于每个 $f \in \mathcal{C}_b(\mathcal{X})$,

$$\int_{\mathcal{X} \times \mathcal{Y}} f(x) d(\alpha \otimes \beta)(x, y) = \left(\int_{\mathcal{X}} f(x) d\alpha(x) \right) \left(\int_{\mathcal{Y}} d\beta(y) \right) = \int f d\alpha,$$

第二个边缘同理, 因此 $\alpha \otimes \beta \in \mathcal{U}(\alpha, \beta)$ 。

命题 3.20 (乘积最优性是退化的). 假设 $\mathcal{X}$ 和 $\mathcal{Y}$ 是紧度量空间, 且 $c \in \mathcal{C}(\mathcal{X} \times \mathcal{Y})$ 。以下陈述等价:

$$\alpha \otimes \beta \in \operatorname{argmin}_{\pi \in \mathcal{U}(\alpha, \beta)} \int c d\pi, \quad \text{每个 } \mathcal{U}(\alpha, \beta) \text{ 中的耦合都是最优的.}$$

它们也等价于代价在乘积支撑上的加性分解,

$$c(x, y) = u(x) + v(y).$$

证明. 如果每个耦合都是最优的, 则 $\alpha \otimes \beta$ 是最优的。反过来, 假设 $\alpha \otimes \beta$ 是最优的。我们首先证明, 对于每个 $x_0, x_1 \in \operatorname{supp}(\alpha)$ 和 $y_0, y_1 \in \operatorname{supp}(\beta)$,

$$c(x_0, y_0) + c(x_1, y_1) = c(x_0, y_1) + c(x_1, y_0).$$

确实, 如果这个等式不成立, 则在必要时交换 y_0 和 y_1 后, 会有严格不等式

$$c(x_0, y_0) + c(x_1, y_1) > c(x_0, y_1) + c(x_1, y_0).$$

由连续性, 该严格不等式在 x_0, x_1 的小邻域 U_0, U_1 和 y_0, y_1 的小邻域 V_0, V_1 上以统一余量保持成立, 其中每一对邻域都选为不相交。由于这四个点位于支撑中, 这些邻域具有正的边缘质量。记 α_i 和 β_i 分别为 α 在 U_i 上以及 β 在 V_i 上限制后的归一化版本, 并选择

$$0 < \lambda \leq \min\{\alpha(U_0)\beta(V_0), \alpha(U_1)\beta(V_1)\}.$$

交换后的测度

$$\tilde{\pi} = \alpha \otimes \beta - \lambda \alpha_0 \otimes \beta_0 - \lambda \alpha_1 \otimes \beta_1 + \lambda \alpha_0 \otimes \beta_1 + \lambda \alpha_1 \otimes \beta_0$$

是非负的, 并且与 $\alpha \otimes \beta$ 有相同的两个边缘。邻域上的统一严格不等式意味着 $\int c d\tilde{\pi} < \int c d(\alpha \otimes \beta)$, 这与最优性矛盾。

固定任意 $x_\star \in \operatorname{supp}(\alpha)$ 和 $y_\star \in \operatorname{supp}(\beta)$, 交叉差分的相等性给出, 对于所有 $(x, y) \in \operatorname{supp}(\alpha) \times \operatorname{supp}(\beta)$,

$$c(x, y) = c(x, y_\star) + c(x_\star, y) - c(x_\star, y_\star).$$

因此 $c = u + v$ 在乘积支撑上成立。每个耦合都集中在这个乘积支撑上, 所以对于任意 $\pi \in \mathcal{U}(\alpha, \beta)$,

$$\int c d\pi = \int u d\alpha + \int v d\beta,$$

它只依赖于边缘。因此所有耦合都是最优的。 $\square$

因此, 张量积是一个平凡的可行耦合, 而不是典型的优化器。乘积最优性意味着, 在边缘固定后, 代价无法区分依赖关系。连续性假设很重要: 如果 $\alpha = \beta$ 是 $[0, 1]$ 上的均匀律且 $c(x, y) = \mathbf{1}_{\{x=y\}}$, 则 $\alpha \otimes \beta$ 的代价为零且是最优的, 而恒等耦合的代价为一。因此, 对于任意仅可测代价, 在一个 $\alpha \otimes \beta$ -零测集上改变代价, 可能会影响奇异耦合, 而不改变乘积代价。

如果存在映射 $T: \mathcal{X} \rightarrow \mathcal{Y}$ 使得 $T_{\#}\alpha = \beta$, 则该 Monge 映射诱导图耦合 $\pi = (\text{Id}, T)_{\#}\alpha \in \mathcal{U}(\alpha, \beta)$, 其特征为

$$\int_{\mathcal{X} \times \mathcal{Y}} h(x, y) d\pi(x, y) = \int_{\mathcal{X}} h(x, T(x)) d\alpha(x).$$

把这个恒等式应用于 $h(x, y) = f(x)$ 或 $h(x, y) = g(y)$, 分别得到 $\pi_1 = \alpha$ 和 $\pi_2 = \beta$ 。因此, 图耦合正是确定性 Monge 映射的 Kantorovich 表示。最后一类重要情形由半离散问题构成, 其中 α 有密度而 β 是离散的。在这种情况下, 耦合是支撑在 $\mathcal{X} \times \mathcal{Y}$ 内图或胞元并集上的奇异测度。

连续 Kantorovich 问题。 对于任意测度, 离散 Kantorovich 问题 (3.2) 变为在所有耦合上最小化平均代价,

$$\mathcal{L}_c(\alpha, \beta) := \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y). \quad (3.5)$$

这是测度空间上的无限维线性规划。

注 3.21 (Kantorovich 问题的概率解释). 同一问题可以写成

$$\mathcal{L}_c(\alpha, \beta) = \inf_{X \sim \alpha, Y \sim \beta} \mathbb{E}(c(X, Y)).$$

最小化不是在边缘律上进行的, 因为边缘律是固定的, 而是在两个随机变量之间所有可能的依赖关系上进行的。因此, 最优传输在所有耦合中选择最便宜的联合律。

命题 3.22 (紧空间上的存在性). 假设 $\mathcal{X}$ 和 $\mathcal{Y}$ 是紧度量空间, 且 $c \in \mathcal{C}(\mathcal{X} \times \mathcal{Y})$ 。则 Kantorovich 问题 (3.5) 至少存在一个极小化子。

证明. 约束集非空, 因为它包含乘积耦合 $\alpha \otimes \beta$ 。它对于测度的弱收敛是闭的, 因为边缘约束在弱收敛下保持。由于 $\mathcal{X} \times \mathcal{Y}$ 紧, 其上的概率测度集合在弱拓扑下紧, 因此 $\mathcal{U}(\alpha, \beta)$ 紧。最后, 泛函 $\pi \mapsto \int c d\pi$ 弱连续, 因为 c 连续且有界。因此最小值可以达到。□

在非紧域上, 需要强制性和矩条件。对于波兰度量空间上的 Wasserstein 代价 $c(x, y) = d(x, y)^p$, 自然定义域为

$$\mathcal{P}_p(\mathcal{X}) := \left\{ \mu \in \mathcal{M}_+^1(\mathcal{X}); \int d(x, x_0)^p d\mu(x) < +\infty \right\},$$

对于某个, 因而对于每个, 参考点 x_0 。如果 $\alpha, \beta \in \mathcal{P}_p(\mathcal{X})$, 则由三角不等式, 乘积耦合具有有限的 p -代价, 所以 Kantorovich 值有限。在 c 满足标准下半连续性假设时, 利用有限矩次水平集的紧性, 可得到极小化子的存在性 [226, 202]。

Monge–Kantorovich 等价性。 Brenier 定理 2.18 的证明依赖 Kantorovich 松弛与对偶性。它证明, 在其假设下, 该松弛是紧的: 它与 Monge 问题具有相同代价, 并且其最优耦合由一个映射诱导。

推论 3.23 (Brenier 条件下的 Monge–Kantorovich 等价性). 假设 α 关于 Lebesgue 测度绝对连续, 且 $c(x, y) = \|x - y\|^2$ 。如果 T 是求解 Monge 问题的 Brenier 映射, 则 $\pi = (\text{Id}, T)_{\#}\alpha$ 是求解 Kantorovich 问题的唯一最优耦合。特别地, Monge 代价与 Kantorovich 代价相同。

证明. Brenier 定理的证明表明, 任意最优 Kantorovich 计划的支撑包含在某个凸函数 φ 的次微分 $\partial\varphi$ 中。当 α 有密度时, φ 在 α -几乎处处可微, 因此对 α -几乎每个 x , $\partial\varphi(x) = \{\nabla\varphi(x)\}$ 。于是每个最优耦合都集中在 $T = \nabla\varphi$ 的图上, 并且必须等于 $(\text{Id}, T)_{\#}\alpha$ 。图耦合是可行且最优的, 并且两个表述具有相同的值。□

密度假设正是阻止松弛计划在非光滑点使用多个目的地的条件。

注 3.24 (非光滑势与拆分). 如果 α 没有密度, 那么 φ 可能在一个被 α 赋予质量的集合上非光滑, 而非光滑点可能导致质量拆分。例如, 把 δ_0 移到 $(\delta_{-1} + \delta_{+1})/2$ 可以由集中在 $\varphi(x) = |x|$ 的集合值次微分上的计划表示, 但不能由确定性映射表示。这是推论 3.14 的均匀匹配情形与一般拆分情形之间差距的连续对应物。

注 3.25 (紧性的概率形式). 如果在推论 3.23 的假设下 (X, Y) 具有最优 Kantorovich 律, 则 $Y = T(X)$ 几乎必然成立, 且 $X \sim \alpha$, $T(X) \sim \beta$ 。这类似于完全离散均匀情形中的 Birkhoff–von Neumann 结果: 在两种设定中, 凸松弛都存在一个满足原始确定性约束的优化器。然而, 假设相当不同: Birkhoff–von Neumann 是有限维的, 且不必给出唯一性; 而 Brenier 定理使用源的绝对连续性, 并给出最优映射几乎处处的唯一性。

3.4 c -循环单调性

循环单调性是最优性的局部几何指纹。它把一个全局最小化问题转化为有限交换不等式，并且是从 Kantorovich 计划通向凸势的桥梁。

当考察最优传输计划支撑中任意有限子集时，它们表现良好：限制到这些点本身仍然是最优匹配。对于有限支撑的边缘，这一点是直接的，并导向 c -循环单调性的概念。

支撑与 c -循环单调性。 为了形式化这一点，需要一个精确的支撑概念，即承载耦合质量的闭集。

定义 3.26 (支撑). 对于 $\mathcal{X} \times \mathcal{Y}$ 上的 Radon 测度 π ,

$$\text{supp}(\pi) := \{(x, y) ; \pi(U \times V) > 0 \text{ 对每个开 } U \ni x, V \ni y\}.$$

定义 3.27 (c -循环单调性). 集合 $\Gamma \subset \mathcal{X} \times \mathcal{Y}$ 是 c -循环单调的，如果对于每个 $k \geq 2$ 、每个有限族 $(x_i, y_i)_{i=1}^k \subset \Gamma$ 以及 $\{1, \dots, k\}$ 的每个排列 σ ,

$$\sum_{i=1}^k c(x_i, y_i) \leq \sum_{i=1}^k c(x_i, y_{\sigma(i)}).$$

任意排列都是循环的乘积，因此只需对循环排列验证该不等式，

$$\sum_{i=1}^k c(x_i, y_i) \leq \sum_{i=1}^k c(x_i, y_{i+1}), \quad y_{k+1} = y_1.$$

从最优匹配到最优传输。 令边缘是在 n 个点上的均匀测度， $\alpha = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}$ 且 $\beta = \frac{1}{n} \sum_{i=1}^n \delta_{y_i}$ 。由推论 3.14，存在一个由排列诱导的最优计划。其支撑 $\Gamma = \{(x_i, y_{\sigma(i)})\}_i$ 是 c -循环单调的：否则，沿违反条件的循环交换有限多个目标会降低匹配代价。下面的定理与 Rockafellar 的循环单调性定理 [195] 精神一致，它说明同样的有限交换条件对任意最优耦合都成立，而不仅限于有限均匀匹配。

定理 3.28 (最优计划是 c -循环单调的). 假设 c 连续。对于求解 Kantorovich 问题 (3.5) 的任意最优计划 π , $\text{supp}(\pi)$ 是 c -循环单调的。

证明。 我们证明逆否命题。假设 $\text{supp}(\pi)$ 不是 c -循环单调的。则存在支撑中的点 $(x_i, y_i)_{i=1}^k$ 和一个排列 σ , 使得

$$\sum_i c(x_i, y_i) > \sum_i c(x_i, y_{\sigma(i)}).$$

由 c 的连续性，缩小邻域 $U_i \ni x_i$ 和 $V_i \ni y_i$ 后，同样的严格不等式对这些邻域中点的每种选择都一致成立：

$$\sum_i c(u_i, v_i) > \sum_i c(u_i, \tilde{v}_{\sigma(i)}) \quad (u_i \in U_i, v_i \in V_i, \tilde{v}_{\sigma(i)} \in V_{\sigma(i)}).$$

选择这些集合使得 $\pi(U_i \times V_i) > 0$ 。由于只有有限多个矩形，可以选择足够小的 $\lambda > 0$, 使得缩放后的限制

$$\pi_i = \lambda \frac{\pi|_{U_i \times V_i}}{\pi(U_i \times V_i)}$$

具有共同质量 λ , 并满足 $\sum_i \pi_i \leq \pi$ 。令 $\alpha_i = (P_{\mathcal{X}})_\# \pi_i$ 且 $\beta_i = (P_{\mathcal{Y}})_\# \pi_i$ 。定义

$$\tilde{\pi} = \pi - \sum_i \pi_i + \sum_i \frac{\alpha_i \otimes \beta_{\sigma(i)}}{\lambda}.$$

被移除和重新插入的第一边缘都是 $\sum_i \alpha_i$, 而被移除和重新插入的第二边缘都是 $\sum_i \beta_i$, 因为 σ 是排列。因此 $\tilde{\pi} \in \mathcal{U}(\alpha, \beta)$ 。把统一严格不等式对乘积概率 $\otimes_i (\pi_i / \lambda)$ 积分，表明重新插入的交叉项代价严格小于被移除的对角项代价。这与 π 的最优性矛盾。□

单调性。 假设最优计划由可测映射 $T : \mathcal{X} \rightarrow \mathcal{Y}$ 诱导, 即 $\pi = (\text{Id}, T)_\# \alpha$ 。对于域中的任意 k 个点 $x_1, \dots, x_k$, 循环单调性写为

$$\sum_{i=1}^k c(x_i, T(x_i)) \leq \sum_{i=1}^k c(x_i, T(x_{i+1})), \quad x_{k+1} = x_1.$$

对于 $c(x, y) = \frac{1}{2} \|x - y\|^2$, 取 $k = 2$ 得到, 对任意 x, y ,

$$\langle T(x) - T(y), x - y \rangle \geq 0,$$

因此 T 是一个单调向量场。Brenier 定理进一步说明, 当 α 绝对连续时, $T = \nabla \varphi$, 其中 φ 是一个凸势。其逆命题在维数 $d \geq 2$ 时失败: 正如 Monge 章节中的旋转例子所示, 小旋转是单调的, 但不是梯度。

一维。 在一维空间中, 对于任意 $p \geq 1$, 代价 $c(x, y) = |x - y|^p$ 下的两点不等式变为

$$|x - T(x)|^p + |y - T(y)|^p \leq |x - T(y)|^p + |y - T(x)|^p,$$

这等价于只要 $x < y$ 就有 $T(x) \leq T(y)$ 。因此 T 必须非降, 从而恢复经典单调重排。

3.5 度量性质: Wasserstein 距离

本节最后部分证明, 当底层代价来自度量时, 最优传输代价是真正的距离。它还比较 Wasserstein 收敛与总变差, 并解释为什么最优传输足够弱, 能够使 Dirac 质量连续移动。

最优传输定义距离。 最优传输的一个重要特征是, 只要代价矩阵满足某些合适性质, 它就在直方图和概率测度之间定义一个距离。事实上, 最优传输可以理解成一种规范方式, 用来把点之间的底层距离提升为直方图或测度之间的距离。该结果的证明依赖一个“粘合引理”, 我们先在离散情形中证明它。

引理 3.29 (离散粘合引理)。 给定 $(a, b, c) \in \Sigma_n \times \Sigma_p \times \Sigma_m$, 令 $P \in U(a, b)$ 且 $Q \in U(b, c)$ 。则存在一个三维张量耦合 $S \in \mathbb{R}_+^{n \times p \times m}$, 使得二维边缘满足

$$\sum_k S_{i,j,k} = P_{i,j} \quad \text{and} \quad \sum_i S_{i,j,k} = Q_{j,k}.$$

因此, 第一个变量与第三个变量之间的边缘

$$R_{i,k} := \sum_j S_{i,j,k},$$

属于 $U(a, c)$ 。对于下面的规范构造, 这个粘合耦合是扭曲矩阵乘积

$$R = P \text{diag}(1/b) Q, \quad R_{i,k} = \sum_{j: b_j > 0} \frac{P_{i,j} Q_{j,k}}{b_j}.$$

在矩阵记号中, 当 $b_j = 0$ 时, $1/b_j$ 理解为 0。图 3.5 以矩阵形式展示该构造。

证明。 可以验证

$$S_{i,j,k} = \begin{cases} \frac{P_{i,j} Q_{j,k}}{b_j} & \text{if } b_j \neq 0 \\ 0 & \text{否则} \end{cases} \quad (3.6)$$

是可接受的。确实, 如果 $b_j \neq 0$,

$$\sum_k S_{i,j,k} = \sum_k \frac{P_{i,j} Q_{j,k}}{b_j} = \frac{P_{i,j}}{b_j} (Q \mathbf{1}_m)_j = \frac{P_{i,j}}{b_j} b_j.$$

如果 $b_j = 0$, 则必有 $P_{i,j} = 0$ 且 $\sum_k S_{i,j,k} = 0 = P_{i,j}$ 。同样的计算给出另一个给定边缘:

$$\sum_i S_{i,j,k} = \begin{cases} \frac{Q_{j,k}}{b_j} \sum_i P_{i,j} = Q_{j,k} & \text{if } b_j > 0, \\ 0 = Q_{j,k} & \text{if } b_j = 0. \end{cases}$$

再对 j 求和得到 R 的显示公式。它的行和与列和为

$$\sum_k R_{i,k} = \sum_j P_{i,j} = a_i, \quad \sum_i R_{i,k} = \sum_j Q_{j,k} = c_k,$$

因此 $R \in U(a, c)$ 。 □




图 3.5: 矩阵形式的离散粘合引理。前两个面板是通过中间边缘 b 的最优一维耦合。第三个面板显示 a 与 c 之间的诱导边缘 $R = P \operatorname{diag}(1/b)Q$; 它是可行的, 也是三角不等式证明中使用的耦合。由于中间边缘表示在较粗的网格上, 粘合耦合比右侧显示的直接最优耦合更其中介性。细框只框住每个面板中的耦合矩阵, 而附着的边缘条带保持在框外。

当代价矩阵是距离矩阵的 p 次幂时, 离散 Kantorovich 值成为直方图上的度量。

定义 3.30 (离散 Wasserstein 距离). 令 $D \in \mathbb{R}_+^{n \times n}$ 为 $[n]$ 上的距离矩阵, 并令 $p \geq 1$ 。直方图 $a, b \in \Sigma_n$ 之间的离散 p -Wasserstein 距离为

$$W_p(a, b) := L_{D^p}(a, b)^{1/p}. \quad (3.7)$$


它依赖于所选底层距离 D 。

命题 3.31 (离散 Wasserstein 距离的度量性质). 对于 $[n]$ 上的每个距离矩阵 D , 定义 3.30 在 Σ_n 上定义一个距离: W_p 对称、为正, $W_p(a, b) = 0$ 当且仅当 $a = b$, 并且它满足三角不等式

$$\forall a, b, c \in \Sigma_n, \quad W_p(a, c) \leq W_p(a, b) + W_p(b, c).$$

证明. 对于对称性, 由于 D^p 是对称的, 我们使用如下事实: 如果 $P \in U(a, b)$ 对 $W_p(a, b)$ 最优, 则 $P^\top \in U(b, a)$ 对 $W_p(b, a)$ 最优。对于正定性, 由于 $C = D^p$ 具有零对角线, 当 $a = b$ 时, $W_p(a, b) = 0$ 由对角耦合 $P^* = \operatorname{diag}(a) = \operatorname{diag}(b)$ 达到; 由于 D^p 的所有非对角元素为正, 只要 $a \neq b$, 就有 $W_p(a, b) > 0$, 因为此时任何可行耦合都在对角线外有非零元素。

为了在这个离散设定中证明三角不等式, 考虑 $a, b, c \in \Sigma_n$, 并令 P 与 Q 分别为 a 与 b 、 b 与 c 之间传输问题的两个最优解。我们使用粘合引理 3.29, 它定义 $S \in \mathbb{R}_+^{n^3}$, 其边缘满足 $\sum_k S_{\cdot, \cdot, k} = P$ 和 $\sum_i S_{i, \cdot, \cdot} = Q$ 。我们定义 $R = \sum_j S_{\cdot, j, \cdot}$, 它是 $U(a, c)$ 的元素。



注意, 如果假设 $b > 0$, 则 $R = P \operatorname{diag}(1/b)Q$ 。

三角不等式由以下推导得到：

$$\begin{aligned}
W_p(a, c) &= \left(\min_{\tilde{R} \in \mathcal{U}(a, c)} \langle \tilde{R}, D^p \rangle \right)^{1/p} \leq \langle R, D^p \rangle^{1/p} \\
&= \left(\sum_{i, k} D_{ik}^p \sum_j S_{i, j, k} \right)^{1/p} \leq \left(\sum_{i, j, k} (D_{ij} + D_{j, k})^p S_{i, j, k} \right)^{1/p} \\
&\leq \left(\sum_{i, j, k} D_{ij}^p S_{i, j, k} \right)^{1/p} + \left(\sum_{i, j, k} D_{j, k}^p S_{i, j, k} \right)^{1/p} \\
&= \left(\sum_{i, j} D_{ij}^p \sum_k S_{i, j, k} \right)^{1/p} + \left(\sum_{j, k} D_{j, k}^p \sum_i S_{i, j, k} \right)^{1/p} \\
&= \left(\sum_{i, j} D_{ij}^p P_{i, j} \right)^{1/p} + \left(\sum_{j, k} D_{j, k}^p Q_{j, k} \right)^{1/p} = W_p(a, b) + W_p(b, c).
\end{aligned}$$

第一个不等式来自 R 的可行性，第二个来自 D 中元素的通常三角不等式，第三个来自 Minkowski 不等式。 $\square$

连续粘合。 命题 3.31 从直方图推广到不必离散的任意测度。为此，需要下面的一般粘合引理。

引理 3.32 (粘合引理). 令 $(\alpha, \beta, \gamma) \in \mathcal{M}_+^1(\mathcal{X}) \times \mathcal{M}_+^1(\mathcal{Y}) \times \mathcal{M}_+^1(\mathcal{Z})$ ，其中 $(\mathcal{X}, \mathcal{Y}, \mathcal{Z})$ 是定义 2.3 意义下的波兰空间。给定 $\pi \in \mathcal{U}(\alpha, \beta)$ 和 $\xi \in \mathcal{U}(\beta, \gamma)$ ，则存在一个张量耦合测度 $\sigma \in \mathcal{M}_+(\mathcal{X} \times \mathcal{Y} \times \mathcal{Z})$ such that

$$(P_{\mathcal{X}, \mathcal{Y}})_\# \sigma = \pi \quad \text{and} \quad (P_{\mathcal{Y}, \mathcal{Z}})_\# \sigma = \xi$$

其中我们记投影器 $P_{\mathcal{X}, \mathcal{Y}}(x, y, z) = (x, y)$ 和 $P_{\mathcal{Y}, \mathcal{Z}}(x, y, z) = (y, z)$ 。

证明. 这个基本结果的证明较为复杂，因为它需要使用测度分解（对应于条件概率）。测度分解可以应用，因为这些空间是波兰的。我们相对于 β 分解 π 和 ξ ，得到 $\mathcal{X}$ 与 $\mathcal{Z}$ 上两个概率分布族 $(\pi_y)_{y \in \mathcal{Y}}$ 和 $(\xi_y)_{y \in \mathcal{Y}}$ 。这些族由以下事实定义：

$$\forall h \in \mathcal{C}(\mathcal{X} \times \mathcal{Y}), \quad \int_{\mathcal{Y}} \left(\int_{\mathcal{X}} h(x, y) d\pi_y(x) \right) d\beta(y) = \int h(x, y) d\pi(x, y).$$

对 ξ 同理。当 $\beta = \sum_j b_j \delta_{y_j}$ 且 $\pi = \sum_{i, j} P_{i, j} \delta_{(x_i, y_j)}$ 时，该条件分布在 β 的支撑上定义为 $\pi_{y_j} = \sum_i \frac{P_{i, j}}{b_j} \delta_{x_i}$ (对 ξ 同理)。于是粘合测度由条件乘积公式定义：

$$\forall g \in \mathcal{C}(\mathcal{X} \times \mathcal{Y} \times \mathcal{Z}), \quad \int g(x, y, z) d\sigma(x, y, z) = \int g(x, y, z) d\pi_y(x) d\xi_y(z) d\beta(y).$$

对于离散测度，这与定义 (3.6) 一致，因为 $\sigma = \sum_{i, j, k} S_{i, j, k} \delta_{x_i, y_j, z_k}$ ，其中

$$S_{i, j, k} = \frac{P_{i, j}}{b_j} \frac{Q_{j, k}}{b_j} b_j.$$

$\square$

利用这个粘合引理，现在可以在波兰空间上任意分布的一般设定中构造 Wasserstein 距离。

定义 3.33 (Wasserstein 距离). 令 $(\mathcal{X}, d)$ 为度量空间且 $p \geq 1$ 。对于 $\alpha, \beta \in \mathcal{P}_p(\mathcal{X})$ ， p -Wasserstein 距离为

$$\mathcal{W}_p(\alpha, \beta) := \mathcal{L}_{d^p}(\alpha, \beta)^{1/p} = \left(\inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{X}} d(x, y)^p d\pi(x, y) \right)^{1/p}. \quad (3.8)$$

它依赖于底层距离 d 。

命题 3.34 (Wasserstein 距离的度量性质). 定义 3.33 定义了一个距离： $\mathcal{W}_p$ 对称、为正， $\mathcal{W}_p(\alpha, \beta) = 0$ 当且仅当 $\alpha = \beta$ ，并且它满足三角不等式

$$\forall (\alpha, \beta, \gamma) \in \mathcal{P}_p(\mathcal{X})^3, \quad \mathcal{W}_p(\alpha, \gamma) \leq \mathcal{W}_p(\alpha, \beta) + \mathcal{W}_p(\beta, \gamma).$$

证明. 对称性来自如下事实: 由于 d 是对称的, 如果 $\pi(x, y)$ 对 $\mathcal{L}_{d^p}(\alpha, \beta)$ 最优, 则 $\pi(y, x) \in \mathcal{U}(\beta, \alpha)$ 对 $\mathcal{L}_{d^p}(\beta, \alpha)$ 最优. 如果 $\mathcal{L}_{d^p}(\alpha, \beta) = 0$, 则必然有一个最优耦合 π 支撑在对角线 $\Delta := \{(x, x)\}_x \subset \mathcal{X}^2$ 上. 我们记 $\lambda(x)$ 为对角线上的相应测度, 即满足 $\int h(x, y) d\pi(x, y) = \int h(x, x) d\lambda(x)$ 的测度. 于是由于 $\pi \in \mathcal{U}(\alpha, \beta)$, 必有 $\lambda = \alpha$ 且 $\lambda = \beta$, 从而 $\alpha = \beta$.

对于三角不等式, 我们考虑最优耦合 $\pi \in \mathcal{U}(\alpha, \beta)$ 和 $\xi \in \mathcal{U}(\beta, \gamma)$, 并根据引理 3.32 将它们粘合. 我们把两个耦合 (π, ξ) 的复合定义为 $\rho := (P_{\mathcal{X} \times \mathcal{Z}})_\# \sigma$. 注意, 如果 π 和 ξ 是由两个 Monge 映射 $T_{\mathcal{X}}(x)$ 与 $T_{\mathcal{Y}}(y)$ 诱导的耦合, 则 ρ 本身由 Monge 映射 $T_{\mathcal{Y}} \circ T_{\mathcal{X}}$ 诱导, 因此这种耦合复合的概念推广了映射复合. 三角不等式由以下推导得到:

$$\begin{aligned} \mathcal{W}_p(\alpha, \gamma) &\leq \left(\int_{\mathcal{X} \times \mathcal{Z}} d(x, z)^p d\rho(x, z) \right)^{1/p} = \left(\int_{\mathcal{X} \times \mathcal{Y} \times \mathcal{Z}} d(x, z)^p d\sigma(x, y, z) \right)^{1/p} \\ &\leq \left(\int_{\mathcal{X} \times \mathcal{Y} \times \mathcal{Z}} (d(x, y) + d(y, z))^p d\sigma(x, y, z) \right)^{1/p} \\ &\leq \left(\int_{\mathcal{X} \times \mathcal{Y} \times \mathcal{Z}} d(x, y)^p d\sigma(x, y, z) \right)^{1/p} + \left(\int_{\mathcal{X} \times \mathcal{Y} \times \mathcal{Z}} d(y, z)^p d\sigma(x, y, z) \right)^{1/p} \\ &= \left(\int_{\mathcal{X} \times \mathcal{Y}} d(x, y)^p d\pi(x, y) \right)^{1/p} + \left(\int_{\mathcal{Y} \times \mathcal{Z}} d(y, z)^p d\xi(y, z) \right)^{1/p} = \mathcal{W}_p(\alpha, \beta) + \mathcal{W}_p(\beta, \gamma). \end{aligned}$$

□

由最优计划诱导的插值. 二次 Wasserstein 距离不仅比较两个端点测度. 最优计划还说明如何在它们之间移动质量: 每个活跃对 (x, y) 沿连接 x 与 y 的线段运动. 这把一个最优耦合转化为一条测度曲线.

定义 3.35 (由最优计划诱导的 $\mathcal{W}_2$ 测地线). 令 $\alpha_0, \alpha_1 \in \mathcal{P}_2(\mathbb{R}^d)$, 并令 $\pi^* \in \mathcal{U}(\alpha_0, \alpha_1)$ 对 $\mathcal{W}_2^2(\alpha_0, \alpha_1)$ 最优. 对于 $t \in [0, 1]$, 定义

$$e_t(x, y) := (1 - t)x + ty, \quad \alpha_t := (e_t)_\# \pi^*.$$

曲线 $(\alpha_t)_{t \in [0, 1]}$ 是由 π^* 诱导的位移, 或 McCann, $\mathcal{W}_2$ 测地线。

在离散情形中, 每个质量 P_{ij} 沿自己的线段从 x_i 移动到 y_j . 当最优计划不是由映射诱导时, 一个源原子可以拆分为多个运动原子. 如果最优计划不唯一, 不同的最优计划也可能诱导不同的 $\mathcal{W}_2$ 测地线。

算法 3.4 来自传输计划的位移插值

输入: $\mathbb{R}^d$ 上的测度 α, β , 时间 $t \in [0, 1]$.

输出: 位移插值 α_t .

令 π^* 为二次 Kantorovich 问题的任意极小化子.

设置插值映射: $e_t(x, y) = (1 - t)x + ty$.

推前: $\alpha_t = (e_t)_\# \pi^*$.

如果 $\pi^* = \sum_{i,j} P_{ij}^* \delta_{(x_i, y_j)}$ **则:**

| **计算** $\alpha_t = \sum_{i,j} P_{ij}^* \delta_{(1-t)x_i + ty_j}$.

返回 α_t .

命题 3.36 (最优计划插值是 $\mathcal{W}_2$ 测地线). 令 $(\alpha_t)_{t \in [0, 1]}$ 由定义 3.35 给出. 则对于每个 $0 \leq s \leq t \leq 1$,

$$\mathcal{W}_2(\alpha_s, \alpha_t) = (t - s) \mathcal{W}_2(\alpha_0, \alpha_1).$$

因此 $t \mapsto \alpha_t$ 是度量 $\mathcal{W}_2$ 下的一条常速测地线。

证明. 通过 (e_s, e_t) 推前最优计划 π^* . 这给出一个耦合 $\gamma_{s,t} \in \mathcal{U}(\alpha_s, \alpha_t)$, 且

$$\int \|z - z'\|^2 d\gamma_{s,t}(z, z') = \int \|e_t(x, y) - e_s(x, y)\|^2 d\pi^*(x, y) = (t - s)^2 \mathcal{W}_2^2(\alpha_0, \alpha_1).$$

因此 $\mathcal{W}_2(\alpha_s, \alpha_t) \leq (t - s) \mathcal{W}_2(\alpha_0, \alpha_1)$. 把这个上界应用于三对 $(0, s)$ 、 (s, t) 和 $(t, 1)$, 并使用命题 3.34 的三角不等式, 得到

$$\mathcal{W}_2(\alpha_0, \alpha_1) \leq \mathcal{W}_2(\alpha_0, \alpha_s) + \mathcal{W}_2(\alpha_s, \alpha_t) + \mathcal{W}_2(\alpha_t, \alpha_1) \leq \mathcal{W}_2(\alpha_0, \alpha_1).$$

因此所有不等式都是等式, 特别是中间线段具有所声称的长度. □




图 3.6: 由非确定性最优传输计划诱导的 McCann 插值。在每个面板中, 红色与蓝色端点测度以低不透明度显示, 细灰线段显示耦合的支撑 $P_{ij} > \text{tol}$, 而运动原子沿插值从红色着色到蓝色。

一般测地空间。 对于欧几里得空间中的 Dirac 质量, 从 δ_x 到 δ_y 的 $\mathcal{W}_2$ 测地线是 $t \mapsto \delta_{(1-t)x+ty}$ 。同一思想扩展到任意测地度量空间 $(\mathcal{X}, d)$, 这意味着每一对点都可以由一条常速度量测地线连接。对于每对 (x, y) , 用曲线 $\gamma^{x,y} : [0, 1] \rightarrow \mathcal{X}$ 取代欧几里得线段, 使得 $\gamma_0^{x,y} = x$, $\gamma_1^{x,y} = y$, 且

$$d(\gamma_s^{x,y}, \gamma_t^{x,y}) = |t - s|d(x, y).$$

如果这条测地线唯一且可测地依赖于 (x, y) , 则定义 $e_t(x, y) = \gamma_t^{x,y}$, 并对一个最优耦合 π^* 设置 $\alpha_t = (e_t)_\# \pi^*$ 。当测地线不唯一时, 除非作出选择, 否则一对 Dirac 之间没有规范插值: 可以选择 x 与 y 之间的一条特定测地线, 或在若干这样的测地线之间随机化。内在表述是在常速测地线的路径空间上选择一个概率测度 η , 称为动力学最优计划, 使得 $(e_0, e_1)_\# \eta$ 是一个最优耦合, 并设置 $\alpha_t = (e_t)_\# \eta$ 。不同的可测选择, 或具有相同端点的测地线上的不同条件分布, 可能给出不同的 $\mathcal{W}_2$ 测地线; 常速恒等式保持不变。这种路径空间观点是 Wasserstein 空间一般理论中的标准观点 [7, 226, 202]。

与 Monge 的比较。 通过 Kantorovich 问题 (3.8) 定义的距离 $\mathcal{W}_p$ 应当与使用 Monge 问题 (2.6) 得到的有向距离 $\tilde{\mathcal{W}}$ 对照。Kantorovich 可行集从不为空, 因为它包含乘积耦合, 尽管在非紧空间上若没有矩假设, p -代价仍可能为无穷。相比之下, Monge 的约束集 $\{T; T_\# \alpha = \beta\}$ 可能为空。当存在最优 Monge 映射时, Kantorovich 通过选择图耦合 $(\text{Id}, T)_\# \alpha$ 给出相同的值; 在这个意义上, Kantorovich 问题是 Monge 问题的凸松弛, 并具有好多好的稳定性性质。

3.6 度量性质: 拓扑与应用

本节从度量公理转向拓扑和用途。在矩控制下, Wasserstein 距离度量量化弱收敛, 处于弱拓扑和强拓扑之间, 并在概率与鲁棒优化中提供定量估计。

依分布收敛拓扑。 在有界度量空间上, 所有 $\mathcal{W}_p$ 距离定义相同的拓扑, 尽管作为距离它们并不等价。

命题 3.37 (紧空间上 Wasserstein 距离的等价性). 当 $p \leq q$ 时, 有

$$\mathcal{W}_p(\alpha, \beta) \leq \mathcal{W}_q(\alpha, \beta) \leq \text{diam}(\mathcal{X})^{\frac{q-p}{q}} \mathcal{W}_p(\alpha, \beta)^{\frac{p}{q}}$$

其中 $\text{diam}(\mathcal{X}) := \sup_{x, y} d(x, y)$ 。

证明。 左侧不等式来自 Jensen 不等式 $\varphi(\int c(x, y) d\pi(x, y)) \leq \int \varphi(c(x, y)) d\pi(x, y)$, 将其应用于任意概率分布 π 和凸函数 $\varphi(r) = r^{q/p}$, 并取 $c(x, y) = d(x, y)^p$, 于是得到

$$\left(\int d(x, y)^p d\pi(x, y) \right)^{\frac{q}{p}} \leq \int d(x, y)^q d\pi(x, y).$$

右侧不等式来自

$$d(x, y)^q \leq \text{diam}(\mathcal{X})^{q-p} d(x, y)^p.$$

□

Wasserstein 距离 $\mathcal{W}_p$ 是一种弱距离: 它比较奇异分布, 例如离散测度, 并量化支撑之间的空间位移。其拓扑在 [226, 202, 6] 中有详细研究, 而经验速率在 [82, 92, 232, 37, 38] 中被量化。

定义 3.38 (弱 * 拓扑). $(\alpha_k)_k$ 在 $\mathcal{M}_+^1(\mathcal{X})$ 中弱 * 收敛到 α (记作 $\alpha_k \rightharpoonup \alpha$), 当且仅当对任意有界连续函数 $f \in C_b(\mathcal{X})$, $\int_{\mathcal{X}} f d\alpha_k \rightarrow \int_{\mathcal{X}} f d\alpha$. 在紧空间上, $C_b(\mathcal{X}) = \mathcal{C}(\mathcal{X})$, 这就是为什么有界性在那里常被省略。

注 3.39 (一个 Riemann 和弱极限). 在 $\mathcal{X} = \mathbb{R}$ 上, 规则网格上的经验测度满足

$$\frac{1}{n} \sum_{k=1}^n \delta_{k/n} \rightharpoonup \mathcal{U}_{[0,1]}.$$

确实, 对于每个连续有界函数 f ,

$$\frac{1}{n} \sum_{k=1}^n f(k/n) \rightarrow \int_0^1 f(x) dx,$$

这恰好是 Riemann 和的收敛。这种收敛是弱的但不是强的：对于每个 n , 离散测度与均匀密度相互奇异, 因此它们的总变差距离等于 2。

注 3.40 (离散测度的弱收敛). 在单个 Dirac 的特殊情形中, $\delta_{x^{(n)}} \rightharpoonup \delta_x$ 等价于对任意连续 f , $\int f d\delta_{x^{(n)}} = f(x^{(n)}) \rightarrow \int f d\delta_x = f(x)$. 这又等价于 $x^{(n)} \rightarrow x$. 对于固定数量的原子, 如果 $\alpha_n = \sum_{i=1}^N a_i^{(n)} \delta_{x_i^{(n)}}$, 并且在抽取子序列并重新标号后, $a_i^{(n)} \rightarrow a_i$ 且 $x_i^{(n)} \rightarrow x_i$, 则 α_n 弱收敛到 $\sum_i a_i \delta_{x_i}$, 其中相同极限处的原子被合并。若没有原子数量的统一界, 离散测度的弱极限可以是非离散的; 经验测度是标准例子。

用随机向量表述, 如果 $X_n \sim \alpha_n$ 且 $X \sim \alpha$ (不一定定义在同一个概率空间上), 则弱收敛对应于 X_n 向 X 的依分布收敛。

注 3.41 (随机变量的收敛模式). 分布律的收敛应当与随机变量的更强收敛概念区分开。如果 X_n 和 X 定义在同一个概率空间上, 则 $X_n \rightarrow X$ 几乎必然意味着在一个零测集之外逐点收敛, 而依概率收敛意味着

$$\forall \varepsilon > 0, \quad \mathbb{P}(\|X_n - X\| > \varepsilon) \rightarrow 0.$$

几乎必然收敛蕴含依概率收敛, 而依概率收敛蕴含依分布收敛。依分布收敛正是概率测度的弱 * 收敛 $(X_n)_\# \mathbb{P} \rightarrow X_\# \mathbb{P}$, 并不要求所有变量都生活在同一个概率空间上。测度的强收敛, 例如总变差收敛, 是不同且通常强得多的: 它控制分配给所有可测集的质量, 而不仅仅是对连续测试函数的平均。特别地, 总变差收敛蕴含弱收敛, 但对于连续律的经验近似, 其逆命题不成立。

注 3.42 (中心极限定理). 中心极限定理说明, 如果 $(X_1, \dots, X_n)$ 是具有有限二阶矩的独立同分布随机向量, $\mathbb{E}(X_i) = 0$, 且 $\mathbb{E}(X_i X_i^\top) = \text{Id}$, 则重缩放平均 $Z_n := \frac{1}{\sqrt{n}} \sum_{i=1}^n X_i$ 依分布收敛到高斯 $\mathcal{N}(0, \text{Id})$. 这意味着表示 Z_n 分布律的测度 α_n 弱收敛到中心化归一化高斯的测度 α 。

总变差范数已在定义 2.6 和命题 2.7 中引入。它诱导的拓扑通常称为测度上的“强”拓扑。在本节中, 我们只使用如下回顾：对于有符号差 $\alpha - \beta$,

$$\|\alpha - \beta\|_{\text{TV}} = |\alpha - \beta|(\mathcal{X}),$$

因此密度给出 L^1 范数, 而离散有符号测度给出有符号权重的 ℓ^1 范数。

下面的命题表明, TV 范数可以看作一种 Wasserstein 距离, 但对应于“退化”的 0/1 度量。

命题 3.43 (作为离散度量的 Wasserstein 的总变差). 记 d 为 0/1 距离, 即 $d(x, x) = 0$, 且当 $x \neq y$ 时 $d(x, y) = 1$, 则

$$\mathcal{W}_p(\alpha, \beta)^p = \frac{1}{2} \|\alpha - \beta\|_{\text{TV}}.$$

证明. 为简单起见, 我们对具有权重 (a, b) 的离散测度进行证明, 并不失一般性地假设它们具有相同支撑 $(x_i)_i$, 记 $D := (d(x_i, x_j))_{i,j}$, 它在对角线上为 0, 在对角线外为 1. 又由于 $d^p = d$, 我们考虑 $p = 1$. 记 $c_i = \min(a_i, b_i)$. 由质量守恒, 对于每个 $P \in U(a, b)$, $P_{i,i} \leq c_i$, 因此

$$\langle P, D \rangle = \sum_{i \neq j} P_{i,j} = 1 - \sum_i P_{i,i} \geq 1 - \sum_i c_i.$$

需要证明该界是紧的, 即构造 $\hat{P} \in U(a, b)$ 使得 $\text{diag}(\hat{P}) = c$. 令

$$\bar{a} := a - c = (a - b)_+ \geq 0 \quad \text{and} \quad \bar{b} := b - c = (b - a)_+ \geq 0$$

如果 $\bar{a} = \bar{b} = 0$, 则 $a = b$, 且对角耦合是最优的。否则, 有

$$\frac{\bar{a} \otimes \bar{b}}{\langle \bar{a}, \mathbf{1} \rangle} \in U(\bar{a}, \bar{b})$$

并注意到 $\langle \bar{a}, \mathbf{1} \rangle = \langle \bar{b}, \mathbf{1} \rangle = 1 - \langle c, \mathbf{1} \rangle$ 。因此记

$$\hat{P} := \text{diag}(c) + \frac{\bar{a} \otimes \bar{b}}{\langle \bar{a}, \mathbf{1} \rangle} \geq 0$$

满足

$$\hat{P}\mathbf{1} = c + \bar{a} = a \quad \text{and} \quad \hat{P}^\top \mathbf{1} = c + \bar{b} = b$$

因此 $\hat{P} \in U(a, b)$ 是一个耦合, 并且由于 $\text{diag}(\bar{a} \otimes \bar{b}) = 0$, 有 $\text{diag}(\hat{P}) = \text{diag}(c)$ 。于是我们得出

$$W_1(a, b) = \langle D, \hat{P} \rangle = \sum_{i,j} \frac{\bar{a}_i \bar{b}_j}{\langle \bar{a}, \mathbf{1} \rangle} = \sum_i \bar{a}_i = \sum_i \bar{b}_i = \frac{1}{2} \sum_i (\bar{a}_i + \bar{b}_i) = \frac{1}{2} \|a - b\|_{\text{TV}}.$$

□

如备注 3.40 所解释, 在 Dirac 的特殊情形中, $\delta_{x_n} \rightharpoonup \delta_x$ 等价于 $x_n \rightarrow x$ 。若 $x_n \neq x$, 则可以将强拓扑与 Wasserstein 距离进行对照:

$$\|\delta_{x_n} - \delta_x\|_{\text{TV}} = 2 \quad \text{and} \quad \mathcal{W}_p(\delta_{x_n}, \delta_x) = d(x_n, x).$$

这表明, 对于强拓扑, Dirac 从不收敛; 而对于 Wasserstein 距离, 它们确实收敛。这是 Wasserstein 距离的一个有力性质: 在紧空间上, 它度量化弱收敛。

命题 3.44 (Wasserstein 在紧空间上度量化弱收敛). 如果 $\mathcal{X}$ 紧, 则 $\alpha_k \rightharpoonup \alpha$ 当且仅当 $\mathcal{W}_p(\alpha_k, \alpha) \rightarrow 0$ 。

证明. 对于 $p = 1$, 这就是 Kantorovich–Rubinstein 度量化定理: 由对偶性, $\mathcal{W}_1$ 是在 1-利普希茨测试函数上的上确界, 并且在紧度量空间上, 由 Arzelà–Ascoli, 该函数类模去常数后是紧的。因此, $\mathcal{W}_1$ 收敛等价于弱收敛。命题 3.37 随后表明, 所有 Wasserstein 距离 $\mathcal{W}_p$ 在紧空间上诱导相同的收敛序列。因此, 对于每个 $p \geq 1$, 弱收敛等价于 $\mathcal{W}_p$ 收敛。□

在非紧空间上, 还需要施加 p 阶矩的收敛。更精确地, 在波兰度量空间上, $\mathcal{W}_p(\alpha_k, \alpha) \rightarrow 0$ 当且仅当 $\alpha_k \rightharpoonup \alpha$, 并且对于某个参考点 x_0 ,

$$\int d(x, x_0)^p d\alpha_k(x) \longrightarrow \int d(x, x_0)^p d\alpha(x).$$

在离散空间上, 强拓扑与弱拓扑重合, 下面的命题联系了 TV 距离与 Wasserstein 距离。

命题 3.45 (离散空间上与总变差的比较). 有

$$\frac{d_{\min}}{2} \|\alpha - \beta\|_{\text{TV}} \leq \mathcal{W}_1(\alpha, \beta) \leq \frac{d_{\max}}{2} \|\alpha - \beta\|_{\text{TV}} \quad \text{where} \quad \begin{cases} d_{\min} := \inf_{x \neq y} d(x, y) \\ d_{\max} := \sup_{x, y} d(x, y) \end{cases}$$

证明. 记 $d_0(x, y)$ 为满足 $d_0(x, x) = 0$ 且当 $x \neq y$ 时 $d_0(x, y) = 1$ 的距离。则有

$$d_{\min} d_0(x, y) \leq d(x, y) \leq d_{\max} d_0(x, y)$$

因此, 把它对任意 $\pi \in \mathcal{U}(\alpha, \beta)$ 积分, 并在这些 π 中取最小值, 再使用命题 3.43 即得结论。□

该界是尖锐的, 这可通过取 $\alpha = \delta_x$ 和 $\beta = \delta_y$ 来观察; 此时若 $x \neq y$, 该界简单地写为

$$d_{\min} \leq d(x, y) \leq d_{\max}.$$

这表明, 当 $d_{\max}/d_{\min}$ 增大时, 两种距离之间的比值可能爆炸。在非离散空间上, 如果 $d_{\min} = 0$, 则这两种距离不等价, 这与强拓扑和弱拓扑不重合这一事实一致。

3.7 Wasserstein 上的 Wasserstein

该构造可以迭代。一旦 $(\mathcal{X}, d)$ 是度量空间, $\mathcal{X}$ 上的概率测度集合就通过 $\mathcal{W}_p$ 成为一个度量空间。因此它可以作为新的底层空间。当要比较的对象本身是随机概率测度, 或其分量是有效对象而不仅仅是一个压缩密度的混合时, 这一点很有用。

标准设定是定义 2.3 中引入的波兰空间。这些假设排除了许多测度论病态: 概率律可以由可数对象近似, 紧性给出紧致性判据, 在相关博雷尔空间上存在正则条件概率, 并且弱收敛是稳定的。下一个命题记录 Wasserstein 空间保持这一结构, 因此该构造可以迭代, 而不会离开同一个行为良好的范畴。

命题 3.46 (作为底层空间的 Wasserstein 空间). 如果 $(\mathcal{X}, d)$ 是波兰度量空间, 则赋予 $\mathcal{W}_p$ 的 $\mathcal{P}_p(\mathcal{X})$ 是波兰的。如果 $\mathcal{X}$ 紧, 则 $\mathcal{P}(\mathcal{X})$ 对 Wasserstein 拓扑是紧的, 并且该构造可以迭代, 以形成 $\mathcal{P}(\mathcal{P}(\mathcal{X}))$ 、 $\mathcal{P}(\mathcal{P}(\mathcal{P}(\mathcal{X})))$, 依此类推。

证明. 这是 Wasserstein 空间的标准结构定理 [226, 202, 7]。完备性通过用几乎最优粘合的耦合表示一个 $\mathcal{W}_p$ -Cauchy 序列得到, 这给出一个 Cauchy 随机序列, 其分布律是所需极限; 可分性则通过用可数稠密子集上有限支撑且具有有理权重的测度来近似测度得到。如果 $\mathcal{X}$ 紧, 则 Prokhorov 紧致性给出 $\mathcal{P}(\mathcal{X})$ 对弱收敛的紧致性, 而命题 3.44 将这个拓扑与任意 Wasserstein 拓扑识别起来。□

我们用 $\alpha, \beta, \dots$ 表示 $\mathcal{P}_2(\mathcal{X})$ 的元素。 $\mathcal{P}_2(\mathcal{P}_2(\mathcal{X}))$ 的元素用花体字母表示, 例如 $\mathfrak{A}, \mathfrak{B}$; 它们是概率测度上的概率律, 或随机概率测度。一个基本的参数化例子来自族 $(\alpha_\zeta)_{\zeta \in Z}$ 和参数空间上的概率律 γ :

$$\mathfrak{A} = (\zeta \mapsto \alpha_\zeta)_\# \gamma. \quad (3.9)$$

如果 $\gamma = \sum_{i=1}^K a_i \delta_{\zeta_i}$, 则

$$\mathfrak{A} = \sum_{i=1}^K a_i \delta_{\alpha_{\zeta_i}}.$$

定义 3.47 (压缩的, 或重心的, 混合). 对于 $\mathfrak{A} \in \mathcal{P}(\mathcal{P}_2(\mathcal{X}))$, 与 $\mathfrak{A}$ 相关的压缩混合, 或重心混合, 是由下式定义的测度 $\bar{\alpha}_{\mathfrak{A}}$:

$$\int_{\mathcal{X}} f(x) d\bar{\alpha}_{\mathfrak{A}}(x) = \int_{\mathcal{P}_2(\mathcal{X})} \left(\int_{\mathcal{X}} f(x) d\alpha(x) \right) d\mathfrak{A}(\alpha), \quad (3.10)$$

对有界连续 f 成立。

在有限情形中, $\bar{\alpha}_{\mathfrak{A}} = \sum_i a_i \alpha_{\zeta_i}$ 。

Wasserstein 空间上的 Wasserstein 距离为

$$\mathcal{W}_2^2(\mathfrak{A}, \mathfrak{B}) := \inf_{\Pi \in \mathcal{U}(\mathfrak{A}, \mathfrak{B})} \int_{\mathcal{P}_2(\mathcal{X}) \times \mathcal{P}_2(\mathcal{X})} \mathcal{W}_2^2(\alpha, \beta) d\Pi(\alpha, \beta). \quad (3.11)$$

对于高斯混合, 这分离了两个层级的几何。一个混合 $\sum_i a_i \mathcal{N}(m_i, \Sigma_i)$ 可以被看作 $\mathcal{X}$ 上的压缩测度, 也可以被看作分量律

$$\mathfrak{A} = \sum_i a_i \delta_{\mathcal{N}(m_i, \Sigma_i)}$$

即高斯分量的 Bures-Wasserstein 空间上的测度。给定两个分量律

$$\mathfrak{A} = \sum_i a_i \delta_{\mathcal{N}(m_i, \Sigma_i)}, \quad \mathfrak{B} = \sum_j b_j \delta_{\mathcal{N}(n_j, \Lambda_j)},$$

由 (3.11) 诱导的离散问题使用分量代价

$$C_{ij} = \|m_i - n_j\|^2 + \mathcal{B}(\Sigma_i, \Lambda_j)^2.$$

令 Π^* 为权重 a 与 b 之间的最优耦合。如果 A_{ij} 表示从 Σ_i 到 Λ_j 的 Brenier 线性部分, 则每个活跃分量对通过下式插值:

$$m_{ij,t} = (1-t)m_i + tn_j, \quad \Sigma_{ij,t} = ((1-t)\text{Id} + tA_{ij})\Sigma_i((1-t)\text{Id} + tA_{ij}),$$




图 3.7: 相同三分量一维高斯混合之间的两种插值。左侧, 每个混合被表示为高斯分量上的离散律, 并使用高斯之间的 Bures-Wasserstein 距离匹配分量。右侧, 混合先被压缩成普通一维密度, 然后由 $\mathcal{W}_2$ 的真正分位数公式插值。两种构造编码了不同的几何。

压缩这些分量测地线给出

$$\bar{\alpha}_t = \sum_{i,j} \Pi_{ij}^* \mathcal{N}(m_{ij,t}, \Sigma_{ij,t}).$$

这种分量层插值先把高斯分量作为 Wasserstein 空间的原子来传输, 然后再返回到 $\mathcal{X}$ 上的测度。它通常不同于压缩混合密度之间真正的 $\mathcal{W}_2$ 插值, 后者可以在分量内部和分量之间拆分并重组质量。

命题 3.48 (压缩是非扩张的). 令 $\mathfrak{A}, \mathfrak{B} \in \mathcal{P}_2(\mathcal{P}_2(\mathcal{X}))$, 并令 $\bar{\alpha}_{\mathfrak{A}}$ 和 $\bar{\beta}_{\mathfrak{B}}$ 为由 (3.10) 定义的压缩混合。则

$$\mathcal{W}_2(\bar{\alpha}_{\mathfrak{A}}, \bar{\beta}_{\mathfrak{B}}) \leq \mathcal{W}_2(\mathfrak{A}, \mathfrak{B}).$$

证明. 固定 $\Pi \in \mathcal{U}(\mathfrak{A}, \mathfrak{B})$ 。对于每个 (α, β) , 通过标准可测选择论证, 并允许任意小误差, 选择一个耦合 $\pi_{\alpha, \beta} \in \mathcal{U}(\alpha, \beta)$, 其二次代价为 $\mathcal{W}_2^2(\alpha, \beta)$ 。将这个马尔可夫核对 Π 积分, 得到 $\bar{\alpha}_{\mathfrak{A}}$ 与 $\bar{\beta}_{\mathfrak{B}}$ 之间的一个耦合 $\bar{\pi}$ 。其代价满足

$$\int_{\mathcal{X} \times \mathcal{X}} d(x, y)^2 d\bar{\pi}(x, y) \leq \int_{\mathcal{P}_2(\mathcal{X})^2} \mathcal{W}_2^2(\alpha, \beta) d\Pi(\alpha, \beta)$$

至多差一个任意选择误差。先对 $\bar{\pi}$ 取下确界, 再对 Π 取下确界, 即证明该结论。 $\square$

下面的备注记录了这种迭代构造稍后在 Gromov-Wasserstein 下界中重新出现的一种有用方式。

注 3.49 (作为 Wasserstein 上的 Wasserstein 律的局部剖面). 给定度量-测度空间 $\mathbb{X} = (\mathcal{X}, d_{\mathcal{X}}, \mu_{\mathcal{X}})$, 每个点定义一个局部距离分布

$$\alpha_x = (d_{\mathcal{X}}(x, \cdot))_{\#} \mu_{\mathcal{X}} \in \mathcal{P}(\mathbb{R}_+), \quad \mathfrak{D}_{\mathcal{X}} = (x \mapsto \alpha_x)_{\#} \mu_{\mathcal{X}} \in \mathcal{P}(\mathcal{P}(\mathbb{R}_+)).$$

命题 11.11 中的 Mémoli 剖面下界, 正是这些局部剖面律的 Wasserstein 上的 Wasserstein 比较。它把完整成对畸变替换为一个普通最优传输问题, 其底层代价本身是一维 Wasserstein 距离。注意, 还存在其他也能度量化收敛的距离。最简单的是希尔伯特核范数, 它们在第 6.1 节中详细说明。

3.8 分布鲁棒性与 $\mathcal{W}_{\infty}$

DRO 歧义集. Wasserstein 距离也用于定义经验律周围的歧义集。给定样本 z_i 和 $\hat{\alpha}_n = \frac{1}{n} \sum_i \delta_{z_i}$, 分布鲁棒优化 (DRO) 问题把经验风险 $\frac{1}{n} \sum_i \ell_{\theta}(z_i)$ 替换为

$$\sup_{\beta: \mathcal{W}_p(\beta, \hat{\alpha}_n) \leq \rho} \int \ell_{\theta}(z) d\beta(z),$$

或在 Lagrange 惩罚形式中替换为 $\sup_{\beta} \int \ell_{\theta} d\beta - \lambda \mathcal{W}_p(\beta, \hat{\alpha}_n)^p$ 。约束形式与惩罚形式通过乘子 λ 的选择相联系, 但对于任意固定的 λ , 它们并不是同一个问题。二者都要求针对那些可通过在预算内传输经验质量而到达的分布给出性能。半径 ρ 用数据空间的几何表示, 因此可以编码特征扰动、域偏移或模型错误 [166, 33, 100]。

Wasserstein DRO 受欢迎的基本计算原因是一个对偶重表述。在损失满足通常的上半连续性和增长假设下, 有

$$\sup_{\beta: \mathcal{W}_p(\beta, \hat{\alpha}_n)^p \leq \rho^p} \int \ell_{\theta} d\beta = \inf_{\lambda \geq 0} \lambda \rho^p + \frac{1}{n} \sum_{i=1}^n \sup_z \{ \ell_{\theta}(z) - \lambda d(z, z_i)^p \}. \quad (3.12)$$

因此，鲁棒风险是这样一种经验风险：每个样本都被其最坏惩罚扰动替换。对于 $p = 1$ 和一个 L_θ -利普希茨损失，Kantorovich–Rubinstein 对偶给出透明的上界

$$\sup_{\beta: \mathcal{W}_1(\beta, \hat{\alpha}_n) \leq \rho} \int \ell_\theta d\beta \leq \frac{1}{n} \sum_i \ell_\theta(z_i) + \rho L_\theta,$$

这把 Wasserstein 鲁棒性展示为利普希茨正则化器。对于在完整利普希茨损失球上的最坏情形优化，该界是尖锐的；而固定损失可能无法实现所有极端利普希茨方向。

在机器学习中，(3.12) 中的内层上确界具有对抗扰动问题的形式：对手把每个数据点从 z_i 移开，但支付传输惩罚。这把 Wasserstein DRO 与对抗训练和认证鲁棒性联系起来 [208, 207]。在序贯决策问题中，同一思想把 Wasserstein 歧义集放在转移核或奖励周围，产生鲁棒 Bellman 算子和鲁棒强化学习模型 [234, 235]。

命题 3.50 (传输代价的凸性). 对于任意非负下半连续代价 c ，值

$$(\alpha, \beta) \mapsto \mathcal{L}_c(\alpha, \beta)$$

是联合凸的。特别地，对于底层度量 d 和 $p \geq 1$ ，映射 $(\alpha, \beta) \mapsto \mathcal{W}_p(\alpha, \beta)^p$ 是联合凸的。距离 $\mathcal{W}_1$ 是联合凸的，但当 $p > 1$ 时， $\mathcal{W}_p$ 本身不一定凸。

证明. 令 $\pi_0 \in \mathcal{U}(\alpha_0, \beta_0)$ 和 $\pi_1 \in \mathcal{U}(\alpha_1, \beta_1)$ 为 η -最优。则 $(1-t)\pi_0 + t\pi_1$ 是 $(1-t)\alpha_0 + t\alpha_1$ 与 $(1-t)\beta_0 + t\beta_1$ 之间的耦合，其代价是两个代价的相应凸组合。令 $\eta \rightarrow 0$ 即证明 $\mathcal{L}_c$ 的联合凸性。取 $c = d^p$ 得到 $\mathcal{W}_p^p$ 的凸性。对于 $p = 1$ ，这就是 $\mathcal{W}_1$ 本身的凸性。对于 $p > 1$ ，开根号可能破坏凸性：在实线上， $F(t) := \mathcal{W}_p((1-t)\delta_0 + t\delta_1, \delta_0) = t^{1/p}$ 满足 $F(1/2) > (F(0) + F(1))/2$ 。□

当分布本身是决策变量时，这种凸性很有用。然而，在通常的 DRO 问题中，一旦数据固定，歧义集就是固定的。因此，如果 $z \mapsto \ell_\theta(z)$ 可测，且对每个 z ， $\theta \mapsto \ell_\theta(z)$ 是凸的，则

$$\theta \mapsto \sup_{\beta: \mathcal{W}_p(\beta, \hat{\alpha}_n) \leq \rho} \int \ell_\theta d\beta$$

作为 θ 的凸函数上确界，它是凸的。这解释了为什么 Wasserstein DRO 能够在仍然建模对抗性分布偏移的同时保持凸学习表述。

$\mathcal{W}_\infty$ 鲁棒性。 极限距离

$$\mathcal{W}_\infty(\alpha, \beta) := \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \text{ess sup}_{(x, y) \sim \pi} d(x, y) \quad (3.13)$$

是在有界空间上当 $p \rightarrow \infty$ 时 $\mathcal{W}_p(\alpha, \beta)$ 的极限，而不是定义 $\mathcal{W}_p^p$ 的凸规划的极限。它最小化最坏位移而非平均位移，并且由于本质上确界目标，所得优化不再是线性凸规划。这使得 $\mathcal{W}_\infty$ 在算法上不那么方便，但在希望保证每个被传输样本都停留在给定扰动半径内的鲁棒表述中非常自然。

命题 3.51 (经验律周围的 $\mathcal{W}_\infty$ 鲁棒包络). 令 $(\mathcal{Z}, d)$ 为波兰度量空间。令 $\hat{\alpha} = \sum_{i=1}^n a_i \delta_{z_i}$ ，其中 $a_i > 0$ 且 $\sum_i a_i = 1$ ，并假设闭球 $\bar{B}(z_i, \rho)$ 是紧的。对于任意实值上半连续损失 ℓ ，

$$\sup_{\beta: \mathcal{W}_\infty(\beta, \hat{\alpha}) \leq \rho} \int \ell(z) d\beta(z) = \sum_{i=1}^n a_i \sup_{z \in \bar{B}(z_i, \rho)} \ell(z).$$

证明. 如果 $\mathcal{W}_\infty(\beta, \hat{\alpha}) \leq \rho$ ，则由对称性，存在耦合 $\pi_m \in \mathcal{U}(\hat{\alpha}, \beta)$ ，其本质位移至多为 $\rho + 1/m$ 。由于两个边缘是波兰空间上的固定概率测度， $\mathcal{U}(\hat{\alpha}, \beta)$ 是紧的且闭的，因此由 Prokhorov 定理弱紧。抽取后， $\pi_m \rightharpoonup \pi \in \mathcal{U}(\hat{\alpha}, \beta)$ 。对于每个 $\eta > 0$ ，闭集 $F_\eta = \{(x, z) : d(x, z) \leq \rho + \eta\}$ 对所有足够大的 m 都满足 $\pi_m(F_\eta) = 1$ 。Portmanteau 定理给出 $\pi(F_\eta) = 1$ 。令 $\eta \downarrow 0$ 沿一个可数序列下降，得到 $\pi(\{(x, z) : d(x, z) \leq \rho\}) = 1$ 。相对于第一边缘分解 π ，得到 $\pi = \sum_i a_i \delta_{z_i} \otimes \nu_i$ ，其中每个 ν_i 支撑在闭球 $\bar{B}(z_i, \rho)$ 中，且 $\beta = \sum_i a_i \nu_i$ 。因此

$$\int \ell d\beta = \sum_i a_i \int \ell d\nu_i \leq \sum_i a_i \sup_{\bar{B}(z_i, \rho)} \ell.$$

反向不等式通过对每个 i 选择一个极大化子 $z_i^* \in \bar{B}(z_i, \rho)$ 并设置 $\beta = \sum_i a_i \delta_{z_i^*}$ 得到。耦合 $\sum_i a_i \delta_{(z_i, z_i^*)}$ 的本质位移至多为 ρ ，因此这个 β 可行并达到显示的值。□

3.9 定量中心极限定理

弱拓扑只说明分布律是否收敛；Wasserstein 距离还量化它们收敛得有多快。下一个结果是一个有代表性的理论应用：中心极限定理变成 $\mathcal{W}_1$ 中的速率估计。这很有用，因为 $\mathcal{W}_1$ 恰好是对 1-利普希茨可观测量的上确界，所以该界一次性控制归一化和的所有稳定数值或统计测量误差。图 3.8 展示了初等伯努利情形。




图 3.8: 归一化伯努利和的中心极限定理。从 $\alpha_0 = \frac{1}{2}(\delta_{-1} + \delta_1)$ 出发， $Z_n = n^{-1/2} \sum_{i=1}^n X_i$ 的分布律仍然是离散的，但其重缩放原子高度趋近于灰色显示的标准高斯密度。下面的 Wasserstein Berry–Esseen 界用 $\mathcal{W}_1$ 距离量化这种弱收敛。

下面的估计是经典 Berry–Esseen 定理 [24, 88] 的 Wasserstein 形式。证明草图使用 Stein 方法，其现代正态近似表述在 [57] 中发展。

命题 3.52 ($\mathcal{W}_1$ 中的 Berry–Esseen 界). 令 $(X_i)_{i=1}^n$ 为独立同分布实随机变量，满足 $\mathbb{E}X_i = 0$ 、 $\mathbb{E}X_i^2 = 1$ 且 $\mathbb{E}|X_i|^3 < +\infty$ 。如果 α_n 是 $n^{-1/2} \sum_i X_i$ 的分布律，且 γ 是标准高斯律，则

$$\mathcal{W}_1(\alpha_n, \gamma) \leq \frac{C \mathbb{E}|X_1|^3}{\sqrt{n}},$$

其中 C 是一个普适常数。

证明. 我们给出标准 Stein 方法草图。由 Kantorovich–Rubinstein 对偶性，

$$\mathcal{W}_1(\alpha_n, \gamma) = \sup_{\text{Lip}(h) \leq 1} |\mathbb{E}h(S_n) - \mathbb{E}h(G)|, \quad S_n = n^{-1/2} \sum_i X_i, \quad G \sim \gamma.$$

对于每个这样的 h ，求解 Stein 方程

$$f'_h(x) - xf_h(x) = h(x) - \mathbb{E}h(G).$$

该解满足只依赖于 h 的利普希茨常数的一致导数界。因此

$$\mathbb{E}h(S_n) - \mathbb{E}h(G) = \mathbb{E}[f'_h(S_n) - S_n f_h(S_n)].$$

通过一次替换一个求和项来展开 $f'_h(S_n)$ 和 $f_h(S_n)$ ，一阶项和二阶项会因 $\mathbb{E}X_i = 0$ 和 $\mathbb{E}X_i^2 = 1$ 而抵消。泰勒余项由 $C \sum_i \mathbb{E}|X_i|/\sqrt{n}|^3$ 控制，这给出显示的 $n^{-1/2}$ 速率。更尖锐的常数和更高阶的传输距离改进见 [34, 194]。□

对偶问题

对偶性把传输问题转化为寻找势函数，而不是寻找耦合。本章解释为什么势函数能够证明最优性， c -变换如何使它们正则化，以及为什么二次情形揭示了 Brenier 映射背后的凸分析。线性规划对偶性给出了离散图景 [28]，而连续形式则是最优传输的核心定理之一 [225, 202]。

4.1 离散对偶

离散对偶给出有限维的最优性证书。它的互补松弛条件指出最优耦合可以把质量放在何处。

Kantorovich 问题 (3.2) 是一个线性规划，因此也可以等价地通过求解一个对偶线性规划来计算其值。

定义 4.1 (可行势). 对于边缘大小为 n, m 、代价矩阵为 $C \in \mathbb{R}^{n \times m}$ 的离散问题，如果一对 $(f, g) \in \mathbb{R}^n \times \mathbb{R}^m$ 位于代价之下，则称其为可行：

$$R(a, b) := \{(f, g) \in \mathbb{R}^n \times \mathbb{R}^m ; \forall (i, j) \in \llbracket n \rrbracket \times \llbracket m \rrbracket, f_i + g_j \leq C_{i,j}\}. \quad (4.1)$$

等价地， $f \oplus g \leq C$ 按元素成立。该记号省略了对 C 的依赖，因为 C 在当前问题中是固定的。

这两个向量扮演源端价格与目标端价格的角色；可行性意味着没有任何被传输的配对被定价得高于其通行代价。

命题 4.2 (离散 Kantorovich 对偶性). 有

$$L_C(a, b) = \max_{(f,g) \in R(a,b)} \langle f, a \rangle + \langle g, b \rangle \quad (4.2)$$

证明. 为了完整起见，我们用 Lagrange 对偶性推导这个对偶问题。与 (3.2) 相关的 Lagrangian 为

$$\min_{P \geq 0} \max_{(f,g) \in \mathbb{R}^n \times \mathbb{R}^m} \langle C, P \rangle + \langle a - P \mathbf{1}_m, f \rangle + \langle b - P^\top \mathbf{1}_n, g \rangle. \quad (4.3)$$

对于线性规划，如果原始约束集非空，就总能交换最小化与最大化并得到相同的值。因此我们考虑

$$\max_{(f,g) \in \mathbb{R}^n \times \mathbb{R}^m} \langle a, f \rangle + \langle b, g \rangle + \min_{P \geq 0} \langle C - f \mathbf{1}_m^\top - \mathbf{1}_n g^\top, P \rangle.$$

最后注意到

$$\min_{P \geq 0} \langle Q, P \rangle = \begin{cases} 0 & \text{if } Q \geq 0 \\ -\infty & \text{否则} \end{cases}$$

所以约束写作 $C - f \mathbf{1}_m^\top - \mathbf{1}_n g^\top = C - f \oplus g \geq 0$. □

Lagrangian (4.3) 的原始-对偶最优性关系使我们能够定位最优传输计划的支撑

$$\text{Supp}(P) \subset \{(i, j) \in \llbracket n \rrbracket \times \llbracket m \rrbracket ; f_i + g_j = C_{i,j}\}. \quad (4.4)$$

图 4.1 在一个一维二次问题上展示了这些有限维证书。势函数本身并不是传输映射；相反，它们与代价矩阵的接触集才是最优耦合允许放置质量的位置。

公式 (4.2) 表明 $(a, b) \mapsto L_C(a, b)$ 是凸函数（作为线性函数的上确界）。从原始问题 (3.2) 也可以看出， $C \mapsto L_C(a, b)$ 是凹函数。




图 4.1: 二次代价 $C_{i,j} = |x_i - y_j|^2$ 下的离散 Kantorovich 对偶势。在每个面板中, 上方条带用红色显示固定的源直方图, 用蓝色显示目标直方图: 一个平衡的双模态目标、一个平移更强的目标, 以及一个三成分混合。下方条带显示一对最优对偶向量 (f, g) , 规范选择为使 $\langle f, a \rangle = 0$ 。互补松弛表明, 质量只能通过满足 $f_i + g_j = C_{i,j}$ 的条目被传输。

4.2 拍卖算法与对偶价格

一旦有了对偶变量, 第 1 章提到的分配算法就会变得更加清晰。拍卖算法是一种对偶价格方法: 它更新目标价格, 并维护一个近似互补松弛证书。小容差 ε 会消除平局、稳定价格更新, 并给出定量的最优性证书 [25, 26, 164]。

考虑代价为 $C_{i,j}$ 的方形分配问题, 并把它改写为利润最大化问题, 其中 $a_{i,j} = -C_{i,j}$ 。拍卖算法在目标点上维护价格 p_j 和一个部分分配。对于尚未分配的源点 i , 定义最佳和次佳约化利润

$$v_i = \max_j (a_{i,j} - p_j), \quad j_i \in \operatorname{argmax}_j (a_{i,j} - p_j), \quad w_i = \max_{j \neq j_i} (a_{i,j} - p_j).$$

源点 i 对 j_i 出价, 并把它的价格提高到与次佳目标之间的差距再加一个裕量:

$$p_{j_i} \leftarrow p_{j_i} + v_i - w_i + \varepsilon.$$

随后目标 j_i 被分配给 i , 而它此前的拥有者 (若存在) 变为未分配。所有源点都被分配后代价停止。算法 4.1 记录出了价循环。图 4.2 使用与图 1.8 相同的分配状态约定显示实际拍卖迭代: 平坦的行表示未分配的出价者, 独热行表示当前持有的目标。

算法 4.1 带目标价格的拍卖出价

输入: 利润矩阵 $A = (a_{ij})$, 出价增量 $\varepsilon > 0$ 。

输出: 分配映射 σ 。

初始化: 设价格 $p_j = 0$, 所有权映射 $o(j) = \emptyset$, 并令 $U = \{1, \dots, n\}$ 。

当未分配集合 U 非空 时:

 令 $i = \min U$ 。

 令 $j_i = \min \operatorname{argmax}_j (a_{ij} - p_j)$ 。

 令 $v_i = a_{ij_i} - p_{j_i}$, 且 $w_i = \max_{j \neq j_i} (a_{ij} - p_j)$ 。

更新价格: $p_{j_i} \leftarrow p_{j_i} + v_i - w_i + \varepsilon$ 。

如果 $o(j_i) = i' \neq \emptyset$ **则:**

 令 $U \leftarrow U \cup \{i'\}$ 。

 令 $o(j_i) = i$ 且 $U \leftarrow U \setminus \{i\}$ 。

返回 $\sigma(i) = j$ 当且仅当 $o(j) = i$ 。

对于固定价格 p , 在对偶最小化中消去出价者效用 u_i 会得到凸目标

$$D(p) = \sum_j p_j + \sum_i \max_j (a_{i,j} - p_j),$$

它来自对偶约束 $u_i + p_j \geq a_{i,j}$ 。因此, 拍卖更新应被看作是在这个非光滑对偶景观上的价格调节方法, 而不是一般的梯度步: 其正确性证明依赖近似互补松弛。




图 4.2: 在与图 1.8 相同的对角占优一维平方距离分配上, 实际拍卖迭代的矩阵视图。每个面板记录当前所有权状态: 未分配的出价者显示为平坦的行, 而已分配的出价者在其当前持有的目标处显示为独热行。快照显示初始化、中间价格更新, 以及满足互补松弛的最终恒等分配。

定义 4.3 (ε -互补松弛). 如果对每个源点 i 都有

$$a_{i,\sigma(i)} - p_{\sigma(i)} \geq \max_j (a_{i,j} - p_j) - \varepsilon.$$

则分配 σ 和价格 p 满足 ε -互补松弛。

命题 4.4 (拍卖最优性证书). 如果一个完整分配 σ 满足 ε -互补松弛, 则它对利润最大化问题是 $n\varepsilon$ -最优的, 或者等价地, 对原始代价最小化问题是 $n\varepsilon$ -最优的。如果所有代价都是整数且 $\varepsilon < 1/n$, 则 σ 是最优的。

证明. 令 τ 为任意分配。由 ε -互补松弛,

$$a_{i,\tau(i)} - p_{\tau(i)} \leq \max_j (a_{i,j} - p_j) \leq a_{i,\sigma(i)} - p_{\sigma(i)} + \varepsilon.$$

对 i 求和会抵消价格, 因为 σ 和 τ 都是置换:

$$\sum_i a_{i,\tau(i)} \leq \sum_i a_{i,\sigma(i)} + n\varepsilon.$$

因此不存在利润比 σ 高出超过 $n\varepsilon$ 的分配。由于 $a = -C$, 同一陈述意味着 σ 的代价至多比最小代价高 $n\varepsilon$ 。如果代价为整数, 则所有分配代价都是整数; 因此严格小于一的间隙必然为零。□

在出价过程中, 一个源点的最后一次出价使其所选目标在相差裕量 ε 的意义下优于所有替代目标。后续价格上升只会使目标变得不那么有吸引力, 并且可以通过归纳检查当前已分配的配对满足 ε -互补松弛。标准的有限终止证明通过减去价格最小值来归一化价格, 观察到每次出价都会使某个目标价格至少增加 ε , 并用利润范围来界定归一化后的价格跨度; 完整界与实现细节见 [26, 164]。

注 4.5 (ε -缩放及其与 Sinkhorn 的关系). 实践中, 人们从较粗的 ε 开始并反复减小它, 同时对价格和分配进行热启动。这种 ε -缩放策略是一种同伦方法: 较大的 ε 通过在最佳与次佳约化利润之间强制一个可见裕量来正则化组合问题, 而较小的 ε 则恢复精确的对偶证书。如果想作连续优化类比, 这个裕量更接近精确罚或近端延拓参数, 而不是字面意义上的二次罚。

Sinkhorn 缩放在熵最优传输中扮演平行角色。在那里, 对偶 c -变换中的硬最小值被温度为 ε 的软最小值 (即 log-sum-exp) 取代; 在拍卖算法中, 硬最大值被保留, 但互补松弛条件由 ε 放松。因此, 两种方法都使用由 ε 控制的对偶延拓, 并且在通常假设下都在 $\varepsilon \rightarrow 0$ 时恢复未正则化的传输证书。输出则不同: Sinkhorn 产生稠密的熵耦合, 而拍卖始终保持稀疏分配。

4.3 一般表述

连续对偶是离散线性规划的解析对应物。它使用连续势函数, 因为测度是通过积分来探测的。

为了把这种原始-对偶构造推广到任意测度, 重要的是认识到测度天然地通过配对 $\langle f, \alpha \rangle := \int f d\alpha$ 与连续函数形成对偶。

命题 4.6 (Kantorovich 对偶性). 假设 $\mathcal{X}$ 和 $\mathcal{Y}$ 是紧度量空间, 且 $c \in C(\mathcal{X} \times \mathcal{Y})$ 。则

$$\mathcal{L}_c(\alpha, \beta) = \max_{(f,g) \in \mathcal{R}(c)} \int_{\mathcal{X}} f(x) d\alpha(x) + \int_{\mathcal{Y}} g(y) d\beta(y), \quad (4.5)$$

其中可行对偶势的集合为

$$\mathcal{R}(c) := \{(f, g) \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y}) ; \forall (x, y), f(x) + g(y) \leq c(x, y)\}. \quad (4.6)$$

这里, (f, g) 是一对连续函数, 常称为 “Kantorovich 势”。在通常的下半连续性和可积性假设下, 同一公式仍可推广; 当对偶优化解未必存在时, 用上确界替代最大值。

证明. 弱对偶性是直接的: 如果 $f(x) + g(y) \leq c(x, y)$ 且 $\pi \in \mathcal{U}(\alpha, \beta)$, 则

$$\int f d\alpha + \int g d\beta = \int (f(x) + g(y)) d\pi(x, y) \leq \int c d\pi.$$

对可行势取上确界并对耦合取下确界, 得到 “ $\leq$ ”。

对于反向不等式, 把原始问题视为 Radon 测度的局部凸空间上的线性规划, 并与 $\mathcal{C}(\mathcal{X} \times \mathcal{Y})$ 配对。仿射映射 $\pi \mapsto (\pi_1, \pi_2)$ 对弱拓扑连续; 可行集非空, 因为它包含 $\alpha \otimes \beta$; 代价在紧集上连续且有界。由于紧乘积空间上的概率测度集合是弱紧的, 在加入上面的上图变量后, 可达的代价-边缘三元组集合是闭的。对可达三元组的凸集应用分离超平面定理

$$\left\{ (\pi_1, \pi_2, \int c d\pi + r) : \pi \geq 0, r \geq 0 \right\}$$

给出一个连续仿射分离函数, 因此得到函数 (f, g) 和一个标量乘子, 可以将其归一化为使 $f \oplus g \leq c$ 。随后分离不等式说明, 在这些势上的上确界至少为原始值。这证明了相等。这个论证是命题 4.2 中有限线性规划证明的无限维类比。□

注 4.7 (由 c -变换得到的对偶达到). 在命题 4.6 的紧性和连续性假设下, (4.5) 中的最大值可以达到。如果 c 是 Lipschitz 的, 命题 4.10 表明, 可以用其 c -变换替换一对可行势而不降低对偶目标; 在固定一个加性规范后, 变换后的势一致有界且等度 Lipschitz。随后 Arzelà–Ascoli 定理给出一个收敛的最大化子序列, 而闭约束 $f \oplus g \leq c$ 可以传递到极限。

离散情形 (4.2) 对应于对偶向量是连续势的样本, 即 $(f_i, g_j) = (f(x_i), g(y_j))$ 。原始-对偶最优性条件允许追踪最优计划的支撑, 而 (4.4) 推广为

$$\text{Supp}(\pi) \subset \{(x, y) \in \mathcal{X} \times \mathcal{Y} ; f(x) + g(y) = c(x, y)\}. \quad (4.7)$$

对于一维二次代价, 连续势可以从单调映射 $T = F_\beta^{-1} \circ F_\alpha$ 中读出: 在活跃图上, $f'(x) = 2(x - T(x))$ 且 $g = f^c$ 。




图 4.3: 与图 4.1 中相同源族和目标族对应的连续 Kantorovich 势。上方条带用红色显示源密度 α , 用蓝色显示目标密度 β , 其中包括强烈平移目标和三模态目标。下方条带显示二次代价 $c(x, y) = |x - y|^2$ 下的势 f 与 $g = f^c$, 并采用与离散图相同的规范约定。等值集 $f(x) + g(y) = c(x, y)$ 包含单调传输图。

注意, 与原始问题 (3.5) 相比, 证明 (4.5) 的解存在并不平凡, 因为约束集 $\mathcal{R}(c)$ 不是紧的, 目标也不是强制的。利用第 4.4 节详述的 c -变换机制, 可以证明最优 (f, g) 必然具有 Lipschitz 正则性, 从而可以用紧约束替代原约束。

4.4 c -变换

c -变换是在不改变可行性的情况下改进势函数的操作。它既是证明对偶达到的工具, 也是从对偶性通向 Brenier 凸势的路径。

最佳响应势与 c -变换。 固定一个对偶势 f 后, 可以在对偶问题 (4.5) 中对第二个势作闭式最大化, 这引出对

$$\sup_{g \in \mathcal{C}(\mathcal{Y})} \left\{ \int g d\beta ; \forall (x, y), g(y) \leq c(x, y) - f(x) \right\}.$$

该约束可以替换为

$$\forall y \in \mathcal{Y}, \quad g(y) \leq f^c(y)$$

定义 4.8 (c -变换). 对于函数 $f: \mathcal{X} \rightarrow \mathbb{R} \cup \{-\infty\}$, 它的 c -变换为

$$\forall y \in \mathcal{Y}, \quad f^c(y) := \inf_{x \in \mathcal{X}} c(x, y) - f(x). \quad (4.8)$$

对于函数 $g: \mathcal{Y} \rightarrow \mathbb{R} \cup \{-\infty\}$, 与 $\bar{c}(y, x) = c(x, y)$ 相关的 $\bar{c}$ -变换为

$$\forall x \in \mathcal{X}, \quad g^{\bar{c}}(x) := \inf_{y \in \mathcal{Y}} c(x, y) - g(y).$$

由于 β 是正的, $\int g d\beta$ 的最大化因此在满足 $g = f^c$ 于 β 支撑上的函数处达到, 也就是在 β -几乎处处达到。




图 4.4: 作为代价 $c_p(x, y) = |x - y|^p$ 下包络的离散 c -变换。红色圆点是四个源原子 x_i 及其势值 f_i ; 灰色曲线是平移后的函数 $y \mapsto c_p(x_i, y) - f_i$; 彩色曲线是它们的下包络 $f^c(y) = \min_i c_p(x_i, y) - f_i$ 。这是 $\mathcal{X}$ 有限的半离散情形, 等价地, 源测度 α 是离散的; 第 5 章研究互补情形, 即被消去的势支撑在有限多个目标原子上。

命题 4.9 (c -变换求解半松弛问题). 固定 f 后, 在所有满足 $f \oplus g \leq c$ 的 g 上使对偶目标最大化的函数, 正是那些 β -几乎处处满足 $g = f^c$ 的函数。等价地, f^c 给出单边缘原始问题的值

$$\inf_{\pi: \pi_2 = \beta} \int c(x, y) d\pi(x, y) - \int f(x) d\pi_1(x) = \int f^c(y) d\beta(y).$$

对称地, 固定 g 后, 在 f 上的最大化函数是那些 α -几乎处处满足 $f = g^{\bar{c}}$ 的函数。

证明. 对所有 x 成立的约束 $f(x) + g(y) \leq c(x, y)$ 对每个固定的 y 等价于

$$g(y) \leq \inf_x c(x, y) - f(x) = f^c(y).$$

由于 β 非负, $\int g d\beta$ 的最大可能值通过在 β 的支撑上使这个逐点上界饱和而获得。交换两个边缘后, $f = g^{\bar{c}}$ 的证明完全相同。

对于原始公式, 将任意可行 π 分解为 $\pi(dx, dy) = \pi_y(dx)\beta(dy)$ 。于是

$$\int c d\pi - \int f d\pi_1 = \int \left(\int (c(x, y) - f(x)) d\pi_y(x) \right) d\beta(y) \geq \int f^c(y) d\beta(y).$$

如果最小化点允许可测选择, 则通过选择支撑在 $x \mapsto c(x, y) - f(x)$ 最小化点上的 π_y 得到等号。否则使用近似可测选择, 并令近似误差消失。□

映射 $(f, g) \mapsto (g^{\bar{c}}, f^c)$ 用更好的对偶势替换原对偶势, 含义是它保持可行性并改进对偶目标。形如 f^c 和 $g^{\bar{c}}$ 的函数称为 c -凹函数和 $\bar{c}$ -凹函数。这些部分最小化在 α 和 β 的支撑上定义最大化函数, 而定义 4.8 则在整个空间 $\mathcal{X}$ 与 $\mathcal{Y}$ 上定义函数。这给出了将对偶解延拓到活跃支撑之外的规范方式。

命题 4.10 (c -变换的 Lipschitz 稳定性). 如果 c 关于其第二个变量是 L -Lipschitz 的, 并且这一性质对第一个变量一致、相对于 $\mathcal{Y}$ 上的度量 d_Y 成立, 则 f^c 是 L -Lipschitz 的。

证明. 对每个 x , 令 $F_x(y) = c(x, y) - f(x)$ 且 $F(y) = f^c(y) = \inf_x F_x(y)$ 。由于所有函数 F_x 都是 L -Lipschitz 的,

$$|F(y) - F(y')| = \left| \inf_x F_x(y) - \inf_x F_x(y') \right| \leq \sup_x |F_x(y) - F_x(y')| \leq L d_Y(y, y').$$

□

这种稳定性对对偶达到至关重要。当 c 在紧空间上是 Lipschitz 的, 可以用具有统一 Lipschitz 界的 c -变换势替换任意可行势; 在固定无害的加性规范后, 紧性由 Arzela-Ascoli 定理推出。

欧氏情形。 欧氏二次代价是一个模型情形, 其中 c -变换在去除二次项后变为通常的凸共轭。这是 Kantorovich 对偶性与 Brenier 映射之间的代数桥梁。

在 $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ 上, 特殊代价 $c(x, y) = -\langle x, y \rangle$ 很核心, 因为它把二次 Wasserstein 问题化约为凸对偶。事实上, 对任意 $\pi \in \mathcal{U}(\alpha, \beta)$,

$$\int \|x - y\|^2 d\pi(x, y) = \int \|x\|^2 d\alpha(x) + \int \|y\|^2 d\beta(y) - 2 \int \langle x, y \rangle d\pi(x, y).$$

对于 $c(x, y) = -\langle x, y \rangle$, 有

$$f^c(y) = \inf_x -\langle x, y \rangle - f(x) = -(f)^*(y), \quad h^*(y) := \sup_x \langle x, y \rangle - h(x).$$

因此, c -凹函数是凸函数的相反数。在一维双线性模型情形中, 硬双重 c -变换因而就是取凹包络的操作。

注 4.11 (Brenier 定理的证明). 对于 $c(x, y) = \|x - y\|^2$, 减去无害的二次项会把几何化约为双线性代价 $-\langle x, y \rangle$ 。原始-对偶关系, 加上可以用 $(f^{c\bar{c}}, f^c)$ 替换 (f, g) 这一事实, 说明最优计划满足

$$\text{supp}(\pi) \subset \{(x, y); \varphi(x) + \varphi^*(y) = \langle x, y \rangle\},$$

其中 $\varphi = -f^{c\bar{c}}$ 是凸函数且 $-g = \varphi^*$ 。由 Fenchel 不等式, 等号当且仅当 $y \in \partial\varphi(x)$ 时成立。如果 α 有密度, 则凸函数在 Lebesgue-几乎处处可微, 因而在 α -几乎处处可微, 所以对 α -几乎每个 x , $\partial\varphi(x)$ 是单点集。这给出了 Brenier 映射 $T = \nabla\varphi$, 并解释了为什么最优耦合集中在一张图上。

交替优化的失败。 Legendre 变换的一个关键性质是 $f^{***} = f^*$, 并且 f^{**} 是 f 的凸包络 (位于 f 下方的最大凸函数)。这些性质可以推广到更一般的 c -变换设置。所需的凸分析背景是 Rockafellar 理论中的标准内容 [195]。

命题 4.12 (c -变换的代数). 记 $f^{c\bar{c}} := (f^c)^{\bar{c}}$, 则下列恒等式成立, 其中向量之间的不等号应按元素理解:

$$(i) f \leq f^c \Rightarrow f^c \geq f^{c\bar{c}}, \quad (ii) f^{c\bar{c}} \geq f, \quad (iii) g^{\bar{c}c} \geq g, \quad (iv) f^{c\bar{c}c} = f^c.$$

证明. 第一个不等式 (i) 由 c -变换的定义推出 (因为有 $-$ 号)。为了证明 (ii), 展开 $f^{c\bar{c}}$ 的定义, 有

$$(f^{c\bar{c}})(x) = \min_y c(x, y) - f^c(y) = \min_y c(x, y) - \min_{x'} (c(x', y) - f(x')).$$

现在, 由于 $-\min_{x'} (c(x', y) - f(x')) \geq -(c(x, y) - f(x))$, 得到

$$(f^{c\bar{c}})(x) \geq \min_y c(x, y) - c(x, y) + f(x) = f(x).$$

关系 $g^{\bar{c}c} \geq g$ 以同样方式得到。现在, 为证明 (iv), 先应用 (ii), 再对 $f' = f^{c\bar{c}}$ 应用 (i), 得到 $f^c \geq f^{c\bar{c}c}$ 。然后对 $g = f^c$ 应用 (iii), 得到 $f^c \leq f^{c\bar{c}c}$ 。□

这种不变性表明, 以这种方式只能“改进”一次对偶势。事实上, 从任意一对 (f, g) 出发, 通过交替最大化得到如下迭代

$$(f, g) \mapsto (f, f^c) \mapsto (f^{c\bar{c}}, f^c) \mapsto (f^{c\bar{c}}, f^{c\bar{c}c}) = (f^{c\bar{c}}, f^c) \dots \quad (4.9)$$

因而到达一个驻点。

这种失败是交替最大化在非光滑问题上的经典行为, 其中泛函的非光滑部分 (这里是约束) 把两个变量混合在一起。解决办法是引入平滑化, 这是增广 Lagrangian 的经典方法; 这里我们将用熵正则化来发展它, 对应于 Sinkhorn 算法。

对于紧区间上的双线性代价 $c(x, y) = -xy$, c -凹函数就是普通的凹函数, 且 $f^{c\bar{c}}$ 是 f 的最小凹上界。在该模型情形中, 硬变换会在一步闭包中移除非凹振荡, 而不是产生逐步上升。

算法 4.2 硬交替 c -变换闭包

输入： $\mathcal{X}$ 上的源势 f ，代价 c 。

输出： 闭合的 c -凹对 $(\tilde{f}, \tilde{g})$ 。

设定目标最佳响应： $g = f^c$, $g(y) = \inf_{x \in \mathcal{X}} c(x, y) - f(x)$.

设定源端闭包： $\tilde{f} = g^{\bar{c}} = f^{c\bar{c}}$.

设定闭合目标势： $\tilde{g} = \tilde{f}^c = f^{c\bar{c}c} = f^c$. **返回** $(\tilde{f}, \tilde{g}) = (f^{c\bar{c}}, f^c)$ 。




图 4.5: 双线性代价 $c(x, y) = -xy$ 下的硬 c -变换。源端面板使用偏红的调色板，并从一个剧烈振荡的势 f 开始；目标端面板使用偏蓝的调色板，并从一个视觉上不同的势 g 开始。深色曲线是双重变换闭包 $f^{c\bar{c}}$ 和 $g^{\bar{c}c}$ ，它们是凹上界；较浅的虚线曲线是在无害的竖直规范平移后的单边最佳响应 $g^{\bar{c}}$ 和 f^c 。该图说明了为什么精确交替最佳响应对对偶证书有用，但不会给出随后由熵正则化提供的平滑迭代动力学。

半离散与 $\mathcal{W}_1$

本章关注对偶问题中两个在计算上有用的退化情形。半离散最优传输把连续到离散的映射转化为有限维几何，而 $\mathcal{W}_1$ 用 Lipschitz 函数和流场替代凸势。本章内容把计算几何 [14, 161, 162] 与 Kantorovich–Rubinstein 和 Beckmann 表述 [129, 16] 联系起来。

5.1 半对偶

半对偶通过精确的 c -变换消去一个势。它在去除显式不等式约束的同时保留凹性。将对偶问题 (4.5) 写作

$$\sup_{f, g \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y})} \mathcal{E}(f, g)$$

其中 $\mathcal{E}(f, g)$ 是对偶目标，当可行性约束不满足时取值 $-\infty$ 。可以精确地优化掉 g ，得到如下半对偶问题

$$\sup_{f \in \mathcal{C}(\mathcal{X})} \tilde{\mathcal{E}}(f) := \mathcal{E}(f, f^c) = \sup_g \mathcal{E}(f, g) = \int_{\mathcal{X}} f d\alpha + \int_{\mathcal{Y}} f^c d\beta. \quad (5.1)$$

凹问题的部分最大化会保持凹性，因此 $\tilde{\mathcal{E}}$ 仍然是凹的。半对偶的主要优势在于它移除了显式不等式约束，从而允许使用更简单的优化算法。

5.2 半离散

半离散情形是对偶势变成 Laguerre 胞权重的设置。这为量化和密度拟合同时提供了几何与算法。

离散目标与 Laguerre 胞。 一个特别有意义的情形是 $\beta = \sum_j b_j \delta_{y_j}$ 为离散测度（当然，如果 α 是离散的，通过交换 α, β 的角色，同一构造也适用）。可以通过把最小化限制在 β 的支撑 $(y_j)_j$ 上，将 $\bar{c}$ 变换 (4.8) 的定义适配到这一设置，

$$\forall g \in \mathbb{R}^m, \forall x \in \mathcal{X}, \quad g^{\bar{c}}(x) := \min_{j \in [m]} c(x, y_j) - g_j. \quad (5.2)$$

在与连续设置中相同的 c 正则性假设下，该变换把向量 g 映射为连续函数 $g^{\bar{c}} \in \mathcal{C}(\mathcal{X})$ 。注意，当目标空间 $\mathcal{Y}$ 被限制在 β 的支撑上时，这一定义与 (4.8) 一致。

关键在于，当 β 是离散测度时，使用离散 $\bar{c}$ -变换会得到一个有限维优化问题，

$$\mathcal{L}_c(\alpha, \beta) = \max_{g \in \mathbb{R}^m} \mathcal{E}(g) := \int_{\mathcal{X}} g^{\bar{c}}(x) d\alpha(x) + \sum_j g_j b_j. \quad (5.3)$$

对偶权重编码的几何对象是一个加权最近邻图：源空间中的每个点都被分配给实现离散 $\bar{c}$ -变换的目标原子。

定义 5.1 (Laguerre 胞与幂图)。对于站点 $(y_j)_{j=1}^m$ 和权重 $g \in \mathbb{R}^m$ ，与 y_j 相关的 Laguerre 胞为

$$\mathbb{L}_j(g) := \{x \in \mathcal{X} ; \forall j' \neq j, c(x, y_j) - g_j \leq c(x, y_{j'}) - g_{j'}\}. \quad (5.4)$$

这些胞覆盖 $\mathcal{X}$ ；在公共边界上任意打破平局后，它们诱导一个不交划分。当 $c(x, y) = \|x - y\|^2$ 时，这种 Laguerre 分解也称为幂图。如果 g 为常数，它就退化为普通 Voronoi 图。

对于二次代价，改变对偶权重会移动相邻胞之间的壁，同时保持它们平行；这正是调节胞质量的几何机制。




图 5.1: 半离散二次传输的 Laguerre 胞。红色等高线显示右侧由三成分高斯混合给出的连续源密度 α 。二十一个彩色圆形站点是从左侧紧高斯云采样得到的离散目标 β 的原子；每个站点颜色与其 Laguerre 胞匹配。从普通 Voronoi 胞出发，半对偶权重更新会使胞变形，从而让每个胞捕获的 α -质量接近规定的目标质量。

质量平衡。 这使得半对偶能量可以方便地改写为

$$\mathcal{E}(g) = \sum_{j=1}^m \int_{\mathbb{L}_j(g)} (c(x, y_j) - g_j) d\alpha(x) + \langle g, b \rangle. \quad (5.5)$$

下面的命题给出该凹函数梯度的公式。

命题 5.2 (半离散对偶的梯度). 如果 α 赋予 Laguerre 胞边界的质量为零，则 $\mathcal{E}$ 在 g 处可微，且

$$\forall j \in \llbracket m \rrbracket, \quad \nabla \mathcal{E}(g)_j = b_j - \int_{\mathbb{L}_j(g)} d\alpha.$$

证明. 对 α -几乎每个 x ， $\min_j c(x, y_j) - g_j$ 中的最小化指标是唯一的。如果这个指标为 $j(x)$ ，则沿方向 $h \in \mathbb{R}^m$ 的方向导数为

$$\left. \frac{d}{dt} \right|_{t=0} \min_j (c(x, y_j) - (g_j + th_j)) = -h_{j(x)}.$$

控制收敛给出

$$d\mathcal{E}(g)[h] = - \sum_j h_j \int_{\mathbb{L}_j(g)} d\alpha + \sum_j h_j b_j,$$

这就是所宣称的梯度公式。 $\square$

一阶最优性条件表明，求解对偶半离散问题等价于选择权重 g ，使得 $\int_{\mathbb{L}_j(g)} d\alpha = b_j$ ，也就是说每个胞捕获规定量的质量。在这种情形下，满足 $T_{\sharp} \alpha = \beta$ 的最优传输 T 是分片常数的，并把 $x \in \mathbb{L}_j(g)$ 映射到 y_j ；对于二次代价，当 α 有密度时，唯一性由 Brenier 定理推出。

算法 5.1 半离散 Laguerre 下降

输入： 源测度 α ，目标原子 (y_j, b_j) ，代价 c ，步长 τ_k 。

输出： 半离散对偶权重 g 和 Laguerre 胞。

初始化： 设 $g^{(0)} = 0$ 。

对于 $k = 0, 1, \dots$ **执行：**

计算胞： $\mathbb{L}_j(g^{(k)}) = \left\{ x ; c(x, y_j) - g_j^{(k)} \leq c(x, y_\ell) - g_\ell^{(k)} \quad \forall \ell \right\}.$

计算质量： $m_j^{(k)} = \int_{\mathbb{L}_j(g^{(k)})} d\alpha.$

更新 $g^{(k+1)} = g^{(k)} + \tau_k (b - m^{(k)}).$

如果 $\max_j |m_j^{(k)} - b_j| \leq \text{tol}$ **则：**

返回 $g^{(k+1)}$ 和这些胞。

定义 5.1 中的二次幂图具有多面体胞，并可用计算几何算法高效计算 [13, 14, 161]。一种经典构造把站点提升为点 $(y_j, \|y_j\|^2 - g_j) \in \mathbb{R}^{d+1}$ ，并通过投影其凸包的下包络来得到幂图。在二维和三维中，Chan 的输出敏感凸包算法 [56] 对 m 个站点和 Q 个凸包顶点具有复杂度 $O(m \log Q)$ 。

随机优化。 半离散表述 (5.5) 很有用, 因为目标是关于 α 的期望,

$$\mathcal{E}(g) = \int_{\mathcal{X}} E(g, x) d\alpha(x) = \mathbb{E}_X(E(g, X)), \quad E(g, x) := g^{\bar{c}}(x) + \langle g, b \rangle. \quad (5.6)$$

这里 $X \sim \alpha$ 。远离胞边界时, 被积函数的随机梯度为

$$\nabla_g E(g, x) = (b_j - \mathbb{1}_{\mathbb{L}_j(g)}(x))_{j=1}^m,$$

当胞边界具有零 α -测度时, 它是 $\nabla \mathcal{E}(g)$ 的无偏估计量。因此, 可以在不先离散化 α 的情况下最大化 (5.5): 该测度被用作一个可抽取独立样本的黑箱, 这在高维统计和机器学习上是自然的设置。

从 $g^{(0)} = 0$ 出发, 随机梯度上升抽取 $x_\ell \sim \alpha$ 并执行

$$g^{(\ell+1)} := g^{(\ell)} + \tau_\ell \nabla_g E(g^{(\ell)}, x_\ell). \quad (5.7)$$

等价地, 如果

$$j_\ell \in \operatorname{argmin}_j (c(x_\ell, y_j) - g_j^{(\ell)}),$$

则坐标更新为

$$g_j^{(\ell+1)} = g_j^{(\ell)} + \tau_\ell (b_j - \mathbb{1}_{\{j=j_\ell\}}).$$

步长必须衰减, 使采样噪声被平均掉。一个典型的方案是

$$\tau_\ell := \frac{\tau_0}{1 + \ell/\ell_0}, \quad (5.8)$$

其中 ℓ_0 是预热尺度。在标准随机近似假设下, 可以得到通常的次线性速率

$$\mathcal{E}(g^*) - \mathbb{E}(\mathcal{E}(g^{(\ell)})) = O(\ell^{-1/2}),$$

其中 g^* 是最大化解, 期望关于独立同分布样本而取。这种随机观点是半离散表述的主要算法优势之一 [161, 104]。

算法 5.2 随机半离散上升

输入: 源采样器 $x \sim \alpha$, 目标原子 (y_j, b_j) , 步长 τ_ℓ 。

输出: 随机半离散对偶权重 g 。

初始化: 设 $g^{(0)} = 0$ 。

对于 $\ell = 0, 1, \dots$ **执行:**

抽取 $x_\ell \sim \alpha$ 。

令 $j_\ell = \min \operatorname{argmin}_j (c(x_\ell, y_j) - g_j^{(\ell)})$ 。

对于 $j = 1, \dots, m$ **执行**

$g_j^{(\ell+1)} = g_j^{(\ell)} + \tau_\ell (b_j - \mathbb{1}_{\{j=j_\ell\}})$ 。

返回 $g^{(\ell)}$ 或其运行平均。

5.3 最优量化

最优量化要求用 m 个码点给出一个测度的最佳离散近似。它是向量量化、压缩和 k -均值聚类的几何核心。

测度 α 的最优量化问题为

$$\mathcal{Q}_m(\alpha) := \min_{Y=(y_j)_{j=1}^m, b \in \Sigma_m} \mathcal{W}_p \left(\alpha, \sum_{j=1}^m b_j \delta_{y_j} \right). \quad (5.9)$$

这个问题在逼近论和信息论中是经典问题 [111, 149]。最优传输表述强调, 人们同时优化支撑位置 Y , 以及在未被规定时优化质量 b 。

命题 5.3 (量化速率与维数灾难). 令 $\Omega \subset \mathbb{R}^d$ 为有界 Lipschitz 区域, 并假设在 Ω 上 $\alpha = \rho dx$, 且 $0 < \rho_- \leq \rho \leq \rho_+ < +\infty$ 。则对固定的 $p \geq 1$, 存在常数 $0 < c \leq C < +\infty$, 使得

$$c m^{-1/d} \leq \mathcal{Q}_m(\alpha) \leq C m^{-1/d}.$$

证明. 对于上界, 将 Ω 划分为 m 个直径至多为 $Cm^{-1/d}$ 的胞 (忽略边界效应), 并在每个非空胞中放置一个码点。把每个点送到其所在胞中的码点, 得到的传输距离由 $Cm^{-1/d}$ 控制。

对于下界, 固定任意 m 个码点集合 Y , 并写 $d_Y(x) = \min_j \|x - y_j\|$ 。由于密度有上界, Y 的 t -邻域质量至多为 Cmt^d 。选择足够小的 $t_0 \simeq m^{-1/d}$, 可得当 $0 < t < t_0$ 时 $\alpha(\{d_Y > t\}) \geq c$ 。因此

$$\int d_Y(x)^p d\alpha(x) = \int_0^{+\infty} pt^{p-1} \alpha(\{d_Y > t\}) dt \geq ct_0^p \simeq cm^{-p/d}.$$

取 p 次根并对 Y 最小化, 即证明下界。 $\square$

这个确定性速率反映了经验最优传输的样本复杂度速率: 二者都受 d 维中点间距 $m^{-1/d}$ 支配。量化是最优情形且确定性的, 而经验最优传输是随机的, 但二者表现出相同的维数灾难。对于固定码点 Y , 该问题关于权重 b 是凸的。它对 Y 的依赖是非凸的, 并且通常在计算上很困难。一维情形要简单得多: 单调性固定了胞的排序, 把问题化约为区间端点和质心; 对于二次代价下的均匀律, 最优质心等距分布。

命题 5.4 (自由质量给出 Voronoi 胞). 对于代价 $c(x, y) = d(x, y)^p$, 固定互异码点 $Y = (y_j)_{j=1}^m$ 。重复码点可以事先合并。对权重 $b \in \Sigma_m$ 最小化给出

$$\min_{b \in \Sigma_m} \mathcal{W}_p^p \left(\alpha, \sum_j b_j \delta_{y_j} \right) = \int_{\mathcal{X}} \min_{1 \leq j \leq m} c(x, y_j) d\alpha(x).$$

通过把每个 x 送到最近的码点, 可以诱导出一个最优耦合。相应的胞是 Voronoi 胞

$$\mathbb{V}_j(Y) := \{x; \forall j', c(x, y_j) \leq c(x, y_{j'})\},$$

在公共边界上可任意打破平局。

证明. 对于 α 与支撑在 Y 上的测度之间的任意耦合, 点 x 的条件目的地属于 Y , 因此其条件代价至少为 $\min_j c(x, y_j)$ 。积分得到下界。反过来, 选择一个可测最近码点映射 $T_Y(x) \in \operatorname{argmin}_j c(x, y_j)$, 以可测方式打破平局, 并设 $b_j = \alpha(T_Y^{-1}(y_j))$ 。于是 $(T_Y)_\# \alpha = \sum_j b_j \delta_{y_j}$, 诱导传输达到所显示的下界。 $\square$

因此, 量化能量可以写成最近质心形式

$$\mathcal{Q}_m(\alpha)^p = \min_Y \mathcal{F}(Y), \quad \mathcal{F}(Y) := \int_{\mathcal{X}} \min_{1 \leq j \leq m} c(x, y_j) d\alpha(x).$$

在该能量的可微点, 每个局部最小化解都满足质心条件

$$y_j \in \operatorname{argmin}_y \int_{\mathbb{V}_j(Y)} c(x, y) d\alpha(x).$$

对于平方欧氏代价, 这变为不动点方程

$$y_j = \frac{\int_{\mathbb{V}_j(Y)} x d\alpha(x)}{\int_{\mathbb{V}_j(Y)} d\alpha}.$$

Lloyd 算法, 也称为 k -均值算法, 会迭代这个不动点: 把点分配给最近的站点, 然后用其胞的质心替换每个站点 [149]。在标准平局处理下, 目标在每一步都会下降。由于问题关于 Y 非凸, 迭代通常只收敛到局部最小值。良好的初始化很重要; 对于平方欧氏目标, k -means++ 在期望意义下给出对数近似保证 [12]。



图 5.2: 与图 5.1 中相同连续密度和二十一个初始站点对应的 Lloyd 量化。红色等高线显示密度 α , 而彩色圆盘是当前码点, 并与其 Voronoi 胞颜色相同。迭代会把初始位于左侧的站点移向高密度区域, 并按照质心 Voronoi 几何重塑这些胞。

算法 5.3 Lloyd 量化

输入：源测度 α ，初始码点 $Y^{(0)} = (y_j^{(0)})_{j=1}^m$ ，平方欧氏代价，容差 tol 。

输出：码点 $Y = (y_j)_{j=1}^m$ 。

初始化：设 $d_0 = +\infty$ 且 $k = 0$ 。

当 $d_k > \text{tol}$ **时：**

令 $k \leftarrow k + 1$ 。

计算 Voronoi 胞： $\mathbb{V}_j(Y^{(k-1)}) = \{x; c(x, y_j^{(k-1)}) \leq c(x, y_\ell^{(k-1)}) \quad \forall \ell\}$ 。

对于每个非空胞 $\mathbb{V}_j$ **执行**

$$y_j^{(k)} = \frac{\int_{\mathbb{V}_j(Y^{(k-1)})} x \, d\alpha(x)}{\int_{\mathbb{V}_j(Y^{(k-1)})} d\alpha(x)}.$$

对于每个空胞 $\mathbb{V}_j$ **执行：**

令 $y_j^{(k)} = y_j^{(k-1)}$ 。

令 $d_k = \max_j \|y_j^{(k)} - y_j^{(k-1)}\|$ 。

返回 $Y^{(k)}$ 。

5.4 Wasserstein-1 范数

$\mathcal{W}_1$ 距离具有特别透明的对偶：可行势恰好是 1-Lipschitz 测试函数。这使 $\mathcal{W}_1$ 成为传输、PDE 表述和带符号测度弱范数之间的交汇点。

$\mathcal{W}_1$ 的 c -变换。 假设 d 是 $\mathcal{X} = \mathcal{Y}$ 上的距离，并取基代价 $c(x, y) = d(x, y)$ 。我们把 $f \in \mathcal{C}(\mathcal{X})$ 的 Lipschitz 常数记为

定义 5.5 (Lipschitz 常数)。对于度量空间 $(\mathcal{X}, d)$ 上的函数 $f : \mathcal{X} \rightarrow \mathbb{R}$ ，其 Lipschitz 常数为

$$\text{Lip}(f) := \sup \left\{ \frac{|f(x) - f(y)|}{d(x, y)} ; x \neq y \right\}. \quad (5.10)$$

当 $\text{Lip}(f) \leq 1$ 时，函数为 1-Lipschitz。

命题 5.6 (c -变换与 1-Lipschitz 函数)。假设 $\mathcal{X} = \mathcal{Y}$ 且 $c(x, y) = d(x, y)$ 。则存在 g 使得 $f = g^c$ ，当且仅当 $\text{Lip}(f) \leq 1$ 。进一步，如果 $\text{Lip}(f) \leq 1$ ，则 $f^c = -f$ 。

证明。 首先假设对某个 g 有 $f = g^c$ 。对于 $x, y \in \mathcal{X}$ ，

$$|f(x) - f(y)| = \left| \inf_z [d(x, z) - g(z)] - \inf_z [d(y, z) - g(z)] \right| \leq \sup_z |d(x, z) - d(y, z)| \leq d(x, y),$$

其中最后一个不等式是反三角不等式。因此 $\text{Lip}(f) \leq 1$ 。

如果 $\text{Lip}(f) \leq 1$ ，则 $f(x) \leq f(y) + d(x, y)$ ，所以对所有 x 有 $d(x, y) - f(x) \geq -f(y)$ ，从而 $f^c(y) \geq -f(y)$ 。取 $x = y$ 得到 $f^c(y) \leq -f(y)$ 。因此 $f^c = -f$ 。对 $-f$ 应用同一性质得到 $(-f)^c = f$ ，所以每个 1-Lipschitz 函数都是 c -凹的。 $\square$

使用交替 c -变换方案 (4.9)，可以把对偶对替换为满足 $\text{Lip}(f) \leq 1$ 的 $(f, -f)$ 。因此 Kantorovich 对偶变为 Kantorovich–Rubinstein 公式

$$\mathcal{W}_1(\alpha, \beta) = \max_f \left\{ \int_{\mathcal{X}} f \, d(\alpha - \beta) ; \text{Lip}(f) \leq 1 \right\}. \quad (5.11)$$

该表达式只依赖带符号测度 $\alpha - \beta$ 。因此，它可以推广到总质量为零的有限带符号测度，并在该空间上定义 Kantorovich–Rubinstein 范数 [129]。

对于满足 $\sum_k r_k = 0$ 的离散带符号测度 $\alpha - \beta = \sum_k r_k \delta_{z_k}$ ，(5.11) 变为有限维线性规划

$$\mathcal{W}_1(\alpha, \beta) = \max_{(f_k)_k} \left\{ \sum_k f_k r_k ; \forall k, \ell, |f_k - f_\ell| \leq d(z_k, z_\ell) \right\}. \quad (5.12)$$

这个线性规划可以用通用内点法或一阶方法求解；结构化图版本则允许下面描述的流表述。当 $\mathbb{R}$ 上 $d(x, y) = |x - y|$ 时，将支撑点排序为 $z_1 \leq z_2 \leq \dots$ 会把约束化约为相邻点对，

$$\mathcal{W}_1(\alpha, \beta) = \max_{(f_k)_k} \left\{ \sum_k f_k r_k ; \forall k, |f_{k+1} - f_k| \leq z_{k+1} - z_k \right\}.$$

在一维中，这等价于前面介绍的闭式累积分布公式。

欧氏空间上的 $\mathcal{W}_1$ 。 在欧氏空间 $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ 的特殊情形中，使用 $c(x, y) = \|x - y\|$ ，Kantorovich–Rubinstein 公式中的全局 Lipschitz 约束可以局部化为 f 的梯度的一致上界，

$$\mathcal{W}_1(\alpha, \beta) = \sup_f \left\{ \int_{\mathbb{R}^d} f(d\alpha - d\beta) ; \|\nabla f\|_\infty \leq 1 \right\}. \quad (5.13)$$

这里约束 $\|\nabla f\|_\infty \leq 1$ 表示 f 在任意点 x 处的梯度范数都由 1 上界控制，即对任意 x 有 $\|\nabla f(x)\|_2 \leq 1$ 。考虑 (5.13) 的对偶问题，记 $\xi := \alpha - \beta$ ，并使用等价形式

$$-\iota_{\|\cdot\|_{\mathbb{R}^d} \leq 1}(u) = \inf_v \langle u, v \rangle + \|v\|_{\mathbb{R}^d},$$

可得到关于流向量场 $s : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 的最大化问题

$$\begin{aligned} \mathcal{W}_1(\alpha, \beta) &= \sup_f \inf_{s(x) \in \mathbb{R}^d} \int_{\mathbb{R}^d} f d\xi + \int \langle \nabla f(x), s(x) \rangle dx + \int \|s(x)\|_{\mathbb{R}^d} dx \\ &= \inf_{s(x) \in \mathbb{R}^d} \int \|s(x)\|_{\mathbb{R}^d} dx + \sup_f \int f(x)(d\xi - \operatorname{div}(s)dx) \end{aligned}$$

得到一个在固定散度约束下的优化问题

$$\mathcal{W}_1(\alpha, \beta) = \inf_s \left\{ \int_{\mathbb{R}^d} \|s(x)\|_{\mathbb{R}^d} dx ; \operatorname{div}(s) = \alpha - \beta \right\}, \quad (5.14)$$

它通常称为 Beckmann 表述 [16]。这里向量值函数 $s(x) \in \mathbb{R}^d$ 可以解释为流场，局部描述质量的运动。在两个输入测度的支撑之外， $\operatorname{div}(s) = 0$ ，这就是质量守恒约束。一旦用有限元适当离散化，问题 (5.13) 和 (5.14) 就变成非光滑凸优化问题。

$\mathcal{W}_1$ 的前述表述 (5.13) 和 (5.14) 可以推广到 $\mathcal{X}$ 是 Riemannian 流形的设置，即 $c(x, y) = d(x, y)$ ，其中 d 是相应的测地距离（对于光滑流形，梯度和散度应理解为流形上的微分算子）。

定义 5.7 (图测地距离). 令 $G = (V, E)$ 为具有正边长 $(\ell_e)_{e \in E}$ 的连通有限图。两个顶点之间的图测地距离为

$$d_G(i, j) = \min_{\gamma: i \rightsquigarrow j} \sum_{e \in \gamma} \ell_e.$$

最小值在所有连接 i 与 j 的路径 γ 上取得。

该图距离把 $\mathcal{W}_1$ 转化为有限维流问题。

命题 5.8 (图上的 $\mathcal{W}_1$ 与 Beckmann 流). 令 $G = (V, E)$ 为具有正边长 $(\ell_e)_{e \in E}$ 和图测地距离 d_G 的连通有限图。对于 V 上的两个概率向量 a, b ，设 $r = a - b$ ，并给每条边 $e = (i, j)$ 定向。如果

$$(\nabla_G f)_e = f_j - f_i, \quad \operatorname{div}_G = -\nabla_G^*$$

是有限差分梯度及其负伴随，则定向边 $i \rightarrow j$ 上的正流在 i 处具有正散度，在 j 处具有负散度。在这个约定下，

$$\mathcal{W}_{1,G}(a, b) = \max_f \left\{ \sum_{i \in V} f_i r_i ; |f_i - f_j| \leq \ell_e \quad \forall e = (i, j) \right\} = \min_m \left\{ \sum_{e \in E} \ell_e |m_e| ; \operatorname{div}_G m = r \right\}.$$


向量 m_e 是定向边流，约束 $\operatorname{div}_G m = r$ 表示每个顶点处的质量守恒。

证明. 边约束 $|f_i - f_j| \leq \ell_e$ 通过沿路径求和意味着对所有顶点有 $|f_i - f_j| \leq d_G(i, j)$ 。反过来, 关于 d_G 的任意 1-Lipschitz 函数都满足边约束, 因为每条边都是长度为 ℓ_e 的路径。因此第一个等式就是度量空间 (V, d_G) 上的 Kantorovich–Rubinstein 公式。


对于第二个等式, 写出图 Beckmann 问题, 并用势 f 对其等式约束作对偶化:

$$\inf_m \sum_e \ell_e |m_e| + \sup_f \sum_i f_i (r_i - (\operatorname{div}_G m)_i).$$

使用 $\operatorname{div}_G = -\nabla_G^*$, 耦合项为 $\sum_e m_e (\nabla_G f)_e$ 。对每个标量流 m_e 的最小化当且仅当 $|(\nabla_G f)_e| \leq \ell_e$ 时有限, 并且此时等于零。因此对偶问题正是上面的图 Lipschitz 对偶。强对偶成立, 因为这是一个可行集非空的有限维线性规划: 连通性和 $\sum_i r_i = 0$ 允许带符号盈余沿路径路由。这证明了图 Beckmann 公式。 $\square$



正则 Delaunay 图



更稠密的非均匀 Delaunay 图

图 5.3: 两个 Delaunay 图 $G = (V, E)$ 上 $\mathcal{W}_1$ 的图 Beckmann 表述。左图使用正则顶点集, 右图使用从二成分高斯混合中采样得到的更稠密非均匀顶点集。红色和蓝色圆盘编码 $r = \alpha - \beta$ 的正部和负部, 各自局部化在六个顶点上。较深的图边显示三角剖分, 而紫色箭头显示最优带符号边流 m : 方向给出符号, 宽度与 $\sqrt{|m_e|}$ 成比例, 且流满足 $\operatorname{div}_G m = r$ 。

注 5.9 (稀疏线性规划与网络单纯形). 令 $N = |V|$ 且 $M = |E|$ 。图 Beckmann 问题是一个线性规划, 但它远小于同一顶点集上的稠密 Kantorovich 线性规划。事实上, 写 $m = m^+ - m^-$ 得到

$$\min_{m^+, m^- \geq 0} \sum_{e \in E} \ell_e (m_e^+ + m_e^-) \quad \text{满足} \quad \operatorname{div}_G (m^+ - m^-) = r.$$

该表述有 $2M$ 个非负变量和 $N - 1$ 个独立平衡约束, 而 V 上两个测度之间的标准传输线性规划有 N^2 个耦合变量和 $2N - 1$ 个独立边缘约束。因此, 对于稀疏几何图, 例如通常满足 $M = O(N)$ 的平面 Delaunay 图, 图表述是线性规模而不是二次规模。

同一个线性规划是一个最小成本转运问题。把每条无向边 $\{i, j\}$ 替换为两个有向弧 $i \rightarrow j$ 和 $j \rightarrow i$, 二者代价均为 ℓ_e , 并施加节点平衡 $\sum_j u_{ij} - \sum_j u_{ji} = r_i$ 。这正是网络单纯形方法的设置: 一个基是一棵生成树, 一次枢轴操作加入一条非树弧, 产生一个唯一环, 沿该环发送流, 并更新节点势和约化成本 [27, 175]。基本实现需要 $O(M)$ 工作量来给所有弧定价, 并在每次枢轴操作中需要 $O(N)$ 工作量更新树, 因此在稀疏图上, 对 P 次枢轴操作需要 $O(PM)$ 次算术运算。枢轴次数 P 依赖规则, 在最坏情形单纯形分析中可能很大, 但网络单纯形变体和一般最小成本流算法给出关于 N 与 M 的多项式保证; 实践中, 这种基于边的表述往往远比求解稠密的 N^2 变量传输线性规划便宜。

这种图表述是 $\mathcal{W}_1$ 的转运版本。它是 (5.14) 的自然离散类比: 梯度是边差分, 散度是关联矩阵平衡, 测地距离是最短路径长度。它可以用稀疏图上的最小成本流方法求解, 而熵式或 KL 投影变体会导向图 $\mathcal{W}_1$ 的流-Sinkhorn 算法 [16, 183]。

算法 5.4 图 Beckmann 网络单纯形枢轴

输入：图 $G = (V, E)$ ，边长 ℓ_e ，满足 $\sum_i r_i = 0$ 的节点平衡 r_i 。

输出：最小成本图流 u 。

替换每条无向边为两条有向弧。

施加平衡： $\sum_j u_{ij} - \sum_j u_{ji} = r_i$ 。

初始化：添加人工根弧，并在带节点势的生成树 T 上计算一个可行树流。

当 $\min_{e \notin T} \bar{c}_e < 0$ **时：**

 令入基弧 e 为给定弧顺序下 $a \notin T$ 上 $\bar{c}_a$ 的第一个最小化弧。

 将它加入树。

 令 $C =$ 唯一诱导环，并沿入基弧 e 的方向定向。

 令 $\theta = \min\{u_a : a \in C^-\}$ ，其中 C^- 是与环方向相反的弧。

 更新对 $a \in C^+$ 令 $u_a \leftarrow u_a + \theta$ ，对 $a \in C^-$ 令 $u_a \leftarrow u_a - \theta$ 。

 移除按给定环顺序第一个达到最小值 θ 的 C^- 中的弧。

 更新树、势和约化成本。

返回 u 。

散度与对偶范数

本章比较最优传输与基于散度和对抗式的差异度量方式。核心问题是拓扑性的： φ -散度计算便宜但很强，而对偶范数和 GAN 目标可以弱到足以比较奇异测度。本章讨论把经典信息散度 [67, 3] 与现代积分概率度量和生成建模 [216, 109, 11] 联系起来。

6.1 对偶范数（积分概率度量）

对偶范数推广了 $\mathcal{W}_1$ 的测试函数原则。它们在统计中很有用，因为它们通过限制判别器类来比较分布。

积分概率度量。 表述 (5.13) 是对偶范数的一个特例。这个观点通过用一个受控函数类测试测度的带符号差，来设计“弱”的差异度量。

定义 6.1 (对偶范数与积分概率度量). 对于可测函数的对称凸集 B ，在带符号测度 ξ 上定义

$$\|\xi\|_B := \sup_f \left\{ \int_{\mathcal{X}} f(x) d\xi(x) ; f \in B \right\}. \quad (6.1)$$

当这个量应用于概率测度的 $\alpha - \beta$ 时，通常称为积分概率度量。

测试函数类 B 的选择同时决定该差异度量的拓扑和统计行为；见 [217, 216, 218]。

例 6.2 (总变差). 如定义 2.6 和命题 2.7 所回顾的，总变差是与连续函数单位球相关的对偶范数

$$B = \{f \in \mathcal{C}(\mathcal{X}) ; \|f\|_{\infty} \leq 1\}.$$

总变差是一个同时作为 φ -散度与对偶范数的典型非平凡差异度量；见 [216]。

例 6.3 ($\mathcal{W}_1$ 范数). 如 (5.13) 所定义的 $\mathcal{W}_1$ ，是与

$$B = \{f ; \text{Lip}(f) \leq 1\}$$

即 1-Lipschitz 函数集合，相关的对偶范数 (6.1)。

例 6.4 (平坦范数与 Dudley 度量). 如果集合 B 有界并能分离测度，则 $\|\cdot\|_B$ 是有限测度全空间 $\mathcal{M}(\mathcal{X})$ 上的范数。 $\mathcal{W}_1$ 并非如此，它只在满足 $\int_{\mathcal{X}} d\xi = 0$ 的带符号测度 ξ 上有限；否则 $\|\xi\|_B = +\infty$ ，因为常数属于 Lipschitz 球。可以通过对势 f 的取值施加界来补救这一点，例如导出平坦范数，

$$B = \{f ; \text{Lip}(f) \leq 1 \text{ and } \|f\|_{\infty} \leq 1\}. \quad (6.2)$$

在紧度量空间上，它度量化有限测度全空间 $\mathcal{M}(\mathcal{X})$ 上的弱收敛。有限维版本由通常的 $\mathcal{W}_1$ 对偶线性规划加上盒约束 $|f_k| \leq 1$ 得到。平坦范数有时称为“Kantorovich–Rubinstein”范数 [118]，并已被用作成像反问题中的保真项 [140]。平坦范数类似于 Dudley 度量，后者使用

$$B = \{f ; \|\nabla f\|_{\infty} + \|f\|_{\infty} \leq 1\}.$$

下面的命题给出一个有用的紧空间判据。对偶球应足够丰富，以近似连续观测量；同时又应足够紧，使弱收敛能够推出在判别器类上的一致收敛。

命题 6.5 (由对偶范数度量化). 假设 $\mathcal{X}$ 紧， $B = -B$ ，且所考虑的测度都是概率测度。

1. 如果 $\mathcal{C}(\mathcal{X})$ 中的每个函数都可以由 $\text{Span}(B)$ 中的元素一致逼近，则 $\|\alpha_n - \alpha\|_B \rightarrow 0$ 蕴含 $\alpha_n \rightarrow \alpha$ 。
2. 如果 $B \subset \mathcal{C}(\mathcal{X})$ 对 $\|\cdot\|_{\infty}$ 是紧的，则 $\alpha_n \rightarrow \alpha$ 蕴含 $\|\alpha_n - \alpha\|_B \rightarrow 0$ 。




图 6.1: 积分概率度量的对偶见证函数。红色和蓝色曲线是两个一维概率密度，紫色曲线是 IPM 变分问题 (6.1) 的归一化最优对偶见证函数 $f_{\alpha, \beta}^*$ 。 $\mathcal{W}_1$ 通过 Kantorovich–Rubinstein 对偶性 (5.13) 限制斜率，MMD 如命题 6.10 中那样限制 RKHS 范数，而总变差可以逐点饱和，因此会对带符号密度差作出尖锐反应。

证明. 对于第一个蕴含, $\|\alpha_n - \alpha\|_B \rightarrow 0$ 和 B 的对称性推出

$$|\langle f, \alpha_n - \alpha \rangle| \leq \|\alpha_n - \alpha\|_B \quad \text{for } f \in B.$$

由线性性, 对每个 $h \in \text{Span}(B)$, 积分收敛。令 $u \in \mathcal{C}(\mathcal{X})$, 并选取满足 $\|u - h\|_\infty \leq \eta$ 的 $h \in \text{Span}(B)$ 。由于 α_n 和 α 是概率测度,

$$|\langle u, \alpha_n - \alpha \rangle| \leq |\langle h, \alpha_n - \alpha \rangle| + 2\eta.$$

先取 $n \rightarrow \infty$ 的上极限, 再令 $\eta \rightarrow 0$, 得到对所有 $u \in \mathcal{C}(\mathcal{X})$ 有 $\langle u, \alpha_n \rangle \rightarrow \langle u, \alpha \rangle$, 这就是弱收敛。

对于第二个蕴含, 假设 $\alpha_n \rightarrow \alpha$, 并选择子序列 $(\alpha_{n_k})_k$, 使得 $\|\alpha_{n_k} - \alpha\|_B \rightarrow \limsup_n \|\alpha_n - \alpha\|_B$ 。由于 B 紧, 且映射 $f \mapsto \langle f, \alpha_{n_k} - \alpha \rangle$ 在 B 上连续, 上确界由某个 $f_{n_k} \in B$ 达到。必要时再抽取子序列, 对某个 $f \in B$ 有 $f_{n_k} \rightarrow f$ 一致收敛。于是

$$\langle f_{n_k}, \alpha_{n_k} - \alpha \rangle = \langle f, \alpha_{n_k} - \alpha \rangle + \langle f_{n_k} - f, \alpha_{n_k} \rangle - \langle f_{n_k} - f, \alpha \rangle.$$

第一项由弱收敛趋于零, 后两项由一致收敛趋于零。因此每个上极限子序列的极限都是零, 从而证明 $\|\alpha_n - \alpha\|_B \rightarrow 0$ 。□

推论 6.6 (Wasserstein 度量化弱收敛). 在紧度量空间上, 对每个 $p \geq 1$, $\mathcal{W}_p$ 都度量化概率测度上的弱收敛。

证明. 对于 $p = 1$, 取 $B = \{f; \text{Lip}(f) \leq 1\}$ 。 B 的张成空间包含所有 Lipschitz 函数, 而在紧度量空间上 Lipschitz 函数在 $\mathcal{C}(\mathcal{X})$ 中稠密。由命题 6.5 得到蕴含 $\mathcal{W}_1(\alpha_n, \alpha) \rightarrow 0 \Rightarrow \alpha_n \rightarrow \alpha$ 。

反过来, 常数不会改变与 $\alpha_n - \alpha$ 的配对。固定 $x_0 \in \mathcal{X}$, 并通过 $f(x_0) = 0$ 归一化势。归一化后的单位 Lipschitz 球由 $\text{diam}(\mathcal{X})$ 一致有界且等度连续, 因此由 Arzelà–Ascoli 定理可知它在 $\|\cdot\|_\infty$ 中紧。命题 6.5 给出 $\mathcal{W}_1(\alpha_n, \alpha) \rightarrow 0$ 。命题 3.37 表明, 在紧空间上所有 $\mathcal{W}_p$ 距离诱导相同拓扑, 因此结论对每个 $p \geq 1$ 成立。□

6.2 对偶 RKHS 范数与最大均值差异

核方法把概率测度转化为再生核 Hilbert 空间 (RKHS) 中的均值元素。由此得到的 Hilbert 型对偶范数是二次差异度量, 可以用欧氏几何处理, 同时保留弱测试函数解释。我们首先回顾带符号测度上的二次型非负的正性假设。

定义 6.7 (正定核与条件正定核). 如果对每个 $n \geq 1$ 、每个 $x_1, \dots, x_n \in \mathcal{X}$ 和每个 $r \in \mathbb{R}^n$ 都有

$$\sum_{i,j=1}^n r_i r_j k(x_i, x_j) \geq 0. \quad (6.3)$$

则对称函数 $k: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 是正定的。如果只要求同一不等式对零和向量 $\langle r, \mathbf{1}_n \rangle = 0$ 成立, 则称其为条件正定的。

条件版本是概率距离的正确概念, 因为二次型作用于总质量为零的带符号测度 $\xi = \alpha - \beta$ 。在核中加入形如 $a(x) + a(y)$ 的项不会改变这类测度上的 $\iint k(x, y) d\xi(x) d\xi(y)$, 而许多自然的距离核只是条件正定的。

例 6.8 (Riesz、能量与 Matérn 型核). 在 $\mathbb{R}^d$ 上, 平移不变核在 Fourier 变量中最为透明。与 $(-\Delta)^{-s}$ 相关的 Riesz 族具有乘子 $\|\omega\|^{-2s}$, 并在零质量测度上定义非负二次型, 此时低频奇异性可积; 这是经典 Riesz 势的核对应物 [22]。能量距离对应于条件正定核 $k(x, y) = -\|x - y\|$, 其 Fourier 乘子与 $\|\omega\|^{-(d+1)}$ 成比例; 对于 $\xi = \alpha - \beta$,

$$-\iint \|x - y\| d\xi(x) d\xi(y)$$

在相差一个维数常数的意义下, 这是能量距离的平方 [204, 222]。

移位核用带 $\lambda > 0$ 的 $(-\Delta + \lambda I)^{-s}$ 替代 $(-\Delta)^{-s}$ 。其 Fourier 乘子 $(\|\omega\|^2 + \lambda)^{-s}$ 在原点有界, 因此无需施加零质量条件, 核就是正定的。这些是 Matérn 核; 闭式形式中它们是径向的, 并涉及修正 Bessel 函数 [233]。Laplace 核 $e^{-\|x-y\|/\sigma}$ 是低光滑度的 Matérn 例子, 而高斯核 $e^{-\|x-y\|^2/(2\sigma^2)}$ 是对 Matérn 光滑度参数作通常重缩放后的无限光滑极限。

定义 6.9 (核范数与 MMD). 令 k 为正定核。更一般地, 令 k 为条件正定核, 并把注意力限制在总质量为零的带符号测度上。对于具有有限核能量的带符号测度 ξ , 相关范数为

$$\|\xi\|_k^2 := \iint_{\mathcal{X} \times \mathcal{X}} k(x, y) d\xi(x) d\xi(y). \quad (6.4)$$

对于两个概率测度, 与 k 相关的最大均值差异为

$$\text{MMD}_k(\alpha, \beta) := \|\alpha - \beta\|_k.$$

这些范数在统计和机器学习中通常称为最大均值差异 [112, 169], 在形状分析中称为核范数 [123]。如果 X, X' 独立且服从律 α , 则在该表达式有限时, 有 $\|\alpha\|_k^2 = \mathbb{E}_{X, X'}(k(X, X'))$ 。

命题 6.10 (作为 RKHS 对偶范数的核范数). 令 $\mathcal{H}$ 为具有再生核 k 的 RKHS, 并假设核均值嵌入

$$m_\xi := \int k(x, \cdot) d\xi(x)$$

对带符号测度 ξ 良定义。则

$$\|\xi\|_k = \sup_{\|h\|_{\mathcal{H}} \leq 1} \int h(x) d\xi(x),$$

因此 $\|\cdot\|_k$ 是 (6.1) 意义下与 RKHS 单位球相关的对偶范数。

证明. 由再生性质,

$$\int h(x) d\xi(x) = \left\langle h, \int k(x, \cdot) d\xi(x) \right\rangle_{\mathcal{H}} = \langle h, m_\xi \rangle_{\mathcal{H}}.$$

Cauchy-Schwarz 不等式给出

$$\sup_{\|h\|_{\mathcal{H}} \leq 1} \int h d\xi = \|m_\xi\|_{\mathcal{H}}.$$

最后,

$$\|m_\xi\|_{\mathcal{H}}^2 = \iint k(x, y) d\xi(x) d\xi(y),$$

这正是 (6.4)。□

命题 6.11 (泛核度量收敛). 假设 $\mathcal{X}$ 紧, 且由连续核 k 生成的 RKHS 在一致范数下稠密于 $\mathcal{C}(\mathcal{X})$ 。则

$$\text{MMD}_k(\alpha_n, \alpha) \rightarrow 0 \iff \alpha_n \rightharpoonup \alpha$$

对 $\mathcal{X}$ 上的概率测度成立。

证明. 如果 $\text{MMD}_k(\alpha_n, \alpha) \rightarrow 0$, 则所有 RKHS 函数的积分都收敛。对任意 $h \in \mathcal{C}(\mathcal{X})$ 和任意 $\eta > 0$, 选择满足 $\|h - g\|_\infty \leq \eta$ 的 $g \in \mathcal{H}$ 。由于 α_n 和 α 是概率测度,

$$\left| \int h d(\alpha_n - \alpha) \right| \leq 2\eta + \left| \int g d(\alpha_n - \alpha) \right|,$$

而最后一项趋于零。这证明了弱收敛。反过来, 如果 $\alpha_n \rightharpoonup \alpha$, 则 $\alpha_n \otimes \alpha_n$ 、 $\alpha_n \otimes \alpha$ 和 $\alpha \otimes \alpha$ 在紧乘积空间上弱收敛。把这一点应用于恒等式中的连续有界函数 k

$$\text{MMD}_k(\alpha_n, \alpha)^2 = \iint k \, d\alpha_n d\alpha_n - 2 \iint k \, d\alpha_n d\alpha + \iint k \, d\alpha d\alpha$$

得到收敛到零。 $\square$

关于 RKHS 函数空间的更多细节, 可参见 [23, 123, 205]。

注 6.12 (泛核). 命题 6.11 中的假设称为核的泛性。等价地, 形如 $\sum_{i=1}^n a_i k(x_i, \cdot)$ 的有限和在一致范数下稠密于 $\mathcal{C}(\mathcal{X})$ 。对于 $\mathcal{X} = \mathbb{R}^d$ 上的平移不变核 $k(x, y) = k_0(x - y)$, 在紧集上的通常意义下或在适当衰减假设下, 这等价于 Fourier 变换在其支撑上不消失 [218, 217]。

在 α 是离散测度的特殊情形中, 因此有简单表达式

$$\|\alpha\|_k^2 = \sum_{i=1}^n \sum_{i'=1}^n a_i a_{i'} k_{i,i'} = \langle \mathbf{ka}, \mathbf{a} \rangle \quad \text{where} \quad k_{i,i'} := k(x_i, x_{i'}).$$

特别地, 当 $\alpha = \sum_{i=1}^n a_i \delta_{x_i}$ 和 $\beta = \sum_{i=1}^n b_i \delta_{x_i}$ 支撑在同一组点上时, $\|\alpha - \beta\|_k^2 = \langle \mathbf{k(a-b)}, \mathbf{a-b} \rangle$, 因此 $\|\cdot\|_k$ 是单纯形 Σ_n 上的欧氏范数 (若 k 正定则是真范数; 若 k 半正定则可能退化)。为了计算两个离散测度之间的差异, 可以使用

$$\|\alpha - \beta\|_k^2 = \sum_{i,i'} a_i a_{i'} k(x_i, x_{i'}) + \sum_{j,j'} b_j b_{j'} k(y_j, y_{j'}) - 2 \sum_{i,j} a_i b_j k(x_i, y_j). \quad (6.5)$$

6.3 φ -散度

本节发展基于逐点密度比的散度。它们计算简单且在统计中经典, 但看不见奇异测度之间的小空间位移。

由密度比定义。 现在考虑一类截然不同的分布比较方法, 它们计算更简单 (对离散分布为 $O(n)$), 但从不度量弱-* 收敛。注意, 还有另一种可能方式是使用 Bregman 散度; 当相关熵函数具有弱-* 正则性时, 它可能度量弱-* 收敛。

定义 6.13 (熵函数). 如果函数 $\varphi: \mathbb{R} \rightarrow \mathbb{R} \cup \{\infty\}$ 下半连续、凸、满足 $\text{dom } \varphi \subset [0, \infty[$, 并满足可行性条件 $\text{dom } \varphi \cap (0, +\infty) \neq \emptyset$, 则称其为熵函数。 φ 在 ∞ 处的增长速度由

$$\varphi'_\infty = \lim_{x \rightarrow +\infty} \varphi(x)/x \in \mathbb{R} \cup \{\infty\}.$$

如果 $\varphi'_\infty = \infty$, 则 φ 比任何线性函数增长得都快, 此时称 φ 为超线性。任意熵函数 φ 都如下诱导一个 φ -散度 (也称为 Ciszár 散度 [67, 3] 或 f -散度)。

定义 6.14 (φ -散度). 令 φ 为熵函数。对于 $\alpha, \beta \in \mathcal{M}(\mathcal{X})$, 令 $\frac{d\alpha}{d\beta} \beta + \alpha^\perp$ 为 α 关于 β 的 Lebesgue 分解: 这意味着 α 唯一分解为 $\alpha^{\text{ac}} + \alpha^\perp$, 其中 $\alpha^{\text{ac}} \ll \beta$ 、 $\alpha^\perp \perp \beta$, 且 $\alpha^{\text{ac}} = (d\alpha/d\beta)\beta$ 。散度 $\mathcal{D}_\varphi$ 定义为

$$\mathcal{D}_\varphi(\alpha|\beta) := \int_{\mathcal{X}} \varphi\left(\frac{d\alpha}{d\beta}\right) d\beta + \varphi'_\infty \alpha^\perp(\mathcal{X}) \quad (6.6)$$

若 α, β 非负; 否则定义为 ∞ 。

(6.6) 中的附加项 $\varphi'_\infty \alpha^\perp(\mathcal{X})$ 是透视泛函的退化贡献。当奇异质量出现时, 它给出密度比积分的弱-* 下半连续延拓。这对在无穷远处线性增长的熵至关重要, 例如定义 TV 范数的绝对值 (6.10)。如果 φ 具有超线性增长, e.g. 通常的熵 (6.9), 则 $\varphi'_\infty = +\infty$, 因此当 α 关于 β 没有密度时, $\mathcal{D}_\varphi(\alpha|\beta) = +\infty$ 。

在离散设置中, 假设

$$\alpha = \sum_i a_i \delta_{x_i} \quad \text{and} \quad \beta = \sum_i b_i \delta_{x_i} \quad (6.7)$$

支撑在同一组 n 个点 $(x_i)_{i=1}^n \subset \mathcal{X}$ 上, 则 (6.6) 在 Σ_n 上定义散度

$$\mathcal{D}_\varphi(\mathbf{a}|\mathbf{b}) = \sum_{i \in \text{Supp}(\mathbf{b})} \varphi\left(\frac{a_i}{b_i}\right) b_i + \varphi'_\infty \sum_{i \notin \text{Supp}(\mathbf{b})} a_i, \quad (6.8)$$

其中 $\text{Supp}(b) := \{i \in \llbracket n \rrbracket; b_i \neq 0\}$ 。

命题 6.15 (φ -散度的基本性质). 如果 φ 是熵函数, 则 $\mathcal{D}_\varphi$ 关于 (α, β) 联合 1-齐次、凸且弱-* 下半连续。

证明. 定义相关的透视函数

$$\forall (u, v) \in (\mathbb{R}_+)^2, \quad \psi(u, v) = \begin{cases} \varphi(u/v)v & \text{if } v \neq 0, \\ u\varphi'_\infty & \text{if } v = 0 \end{cases}$$

联合 1-齐次性由该透视函数的定义推出。我们在离散情形中证明凸性, 此时

$$\mathcal{D}_\varphi(a|b) = \sum_i \psi(a_i, b_i),$$

只需说明 ψ 在 $(\mathbb{R}_+)^2$ 上是凸的。我们先在 $\mathbb{R}_+ \times \mathbb{R}_+^*$ 上证明; 到 $v = 0$ 的延拓由退化值 $u\varphi'_\infty$ 的下半连续性推出。事实上, 对任意 $\lambda \in [0, 1]$, 令 $\tau = 1 - \lambda$, 并设

$$\theta_1 = \frac{\tau v_1}{\tau v_1 + \lambda v_2}, \quad \theta_2 = \frac{\lambda v_2}{\tau v_1 + \lambda v_2}.$$

则 $\theta_1 + \theta_2 = 1$ 且

$$\frac{\tau u_1 + \lambda u_2}{\tau v_1 + \lambda v_2} = \theta_1 \frac{u_1}{v_1} + \theta_2 \frac{u_2}{v_2}.$$

因此 φ 的凸性给出

$$\varphi\left(\frac{\tau u_1 + \lambda u_2}{\tau v_1 + \lambda v_2}\right)(\tau v_1 + \lambda v_2) \leq \tau v_1 \varphi\left(\frac{u_1}{v_1}\right) + \lambda v_2 \varphi\left(\frac{u_2}{v_2}\right).$$

在一般测度情形中, 弱-* 下半连续性是具有退化延拓的凸积分泛函的标准下半连续性定理; 在离散情形中, 它直接来自 ψ 的下半连续性。□

下面的命题记录 $\mathcal{D}_\varphi$ 何时非负。

命题 6.16 (φ -散度的非负性). 假设 φ 通过 $\varphi(1) = 0$ 归一化。对于概率分布 $(\alpha, \beta) \in \mathcal{M}_+^1(\mathcal{X})$, 有 $\mathcal{D}_\varphi(\alpha|\beta) \geq 0$ 。如果 φ 严格凸, 则 $\mathcal{D}_\varphi(\alpha|\beta) = 0$ 当且仅当 $\alpha = \beta$ 。如果进一步要求 $\varphi \geq 0$, 这一性质可推广到任意分布 $(\alpha, \beta) \in \mathcal{M}_+(\mathcal{X})$ 。

证明. 令 $m = \alpha + \beta$, 并写 $a = \frac{d\alpha}{dm}$ 、 $b = \frac{d\beta}{dm}$ 。使用上一证明中的透视函数 ψ ,

$$\mathcal{D}_\varphi(\alpha|\beta) = \int \psi(a, b) dm.$$

由于 α 和 β 是概率测度, $\int a dm = \int b dm = 1$ 。Jensen 不等式和 $\psi(1, 1) = \varphi(1) = 0$ 给出

$$\mathcal{D}_\varphi(\alpha|\beta) \geq \psi\left(\int a dm, \int b dm\right) = 0.$$

如果 φ 严格凸, 则 Jensen 不等式取等号迫使 $a = b$ 在 m -几乎处处成立, 因此 $\alpha = \beta$ 。在一般非概率情形中, 如果 $\varphi \geq 0$, 则散度按构造为正。□

经典例子与拓扑。 下面的例子校准 φ -散度的强度。KL 对绝对连续性敏感, 而总变差给出强拓扑, 因此其行为与 Wasserstein 型弱度量非常不同。

例 6.17 (Kullback–Leibler 散度). Kullback–Leibler 散度 $\text{KL} := \mathcal{D}_{\varphi_{\text{KL}}}$, 也称为相对熵, 已经在 (7.12) 和 (7.6) 中介绍过。它是与 Shannon–Boltzmann 熵函数 φ_{KL} 相关的散度, 该函数为

$$\varphi_{\text{KL}}(s) = \begin{cases} s \log(s) - s + 1 & \text{当 } s > 0, \\ 1 & \text{当 } s = 0, \\ +\infty & \text{否则。} \end{cases} \quad (6.9)$$

例 6.18 (总变差). 总变差距离 $\text{TV} := \mathcal{D}_{\varphi_{\text{TV}}}$ 是与

$$\varphi_{\text{TV}}(s) = \begin{cases} |s-1| & \text{当 } s \geq 0, \\ +\infty & \text{否则.} \end{cases} \quad (6.10)$$

相关的散度。它实际上在测度全空间 $\mathcal{M}(\mathcal{X})$ 上定义一个范数，其中

$$\text{TV}(\alpha|\beta) = \|\alpha - \beta\|_{\text{TV}}, \quad \text{where} \quad \|\alpha\|_{\text{TV}} = |\alpha|(\mathcal{X}) = \int_{\mathcal{X}} d|\alpha|(x). \quad (6.11)$$

如果 α 在 $\mathcal{X} = \mathbb{R}^d$ 上有密度 ρ_α ，则 TV 范数就是函数上的 L^1 范数， $\|\alpha\|_{\text{TV}} = \int_{\mathcal{X}} |\rho_\alpha(x)| dx = \|\rho_\alpha\|_{L^1}$ 。如果 α 如 (6.7) 中那样是离散的，则 TV 范数是 $\mathbb{R}^n$ 中向量的 ℓ^1 范数， $\|\alpha\|_{\text{TV}} = \sum_i |a_i| = \|\mathbf{a}\|_{\ell^1}$ 。

注 6.19 (强拓扑与弱拓扑). 总变差范数 (6.11) 在测度空间上定义所谓“强”拓扑。在半径为 R 的紧区域 $\mathcal{X}$ 上，有

$$\mathcal{W}_1(\alpha, \beta) \leq R \|\alpha - \beta\|_{\text{TV}}$$

因此这种强收敛概念蕴含由 Wasserstein 距离度量的弱收敛。然而反过来不成立，因为当 $x \rightarrow y$ 时， δ_x 并不强收敛到 δ_y （注意若 $x \neq y$ ，则 $\|\delta_x - \delta_y\|_{\text{TV}} = 2$ ）。一个主要优势是， $\mathcal{M}_+^1(\mathcal{X})$ （同样在紧底空间 $\mathcal{X}$ 上）对弱拓扑是紧的，因此从任意概率测度序列 $(\alpha_k)_k$ 中，总能抽取一个收敛子序列，这使它成为若干优化问题的合适空间。

φ -散度的主要族。 若干经典散度都适合同一模板。幂散度族

$$\varphi_\gamma(s) = \frac{s^\gamma - \gamma s + \gamma - 1}{\gamma(\gamma - 1)} \quad (\gamma \neq 0, 1)$$

在 $\gamma = 2$ 时给出 Pearson χ^2 散度，在 $\gamma = 1/2$ 时给出 Hellinger 型行为，并通过取极限在 $\gamma \rightarrow 1$ 时给出 KL 散度，在 $\gamma \rightarrow 0$ 时给出反向 KL 或 Burg 熵 $\varphi_0(s) = -\log s + s - 1$ 。Hellinger 散度通常单独写成 $\varphi_H(s) = (\sqrt{s} - 1)^2$ ，当两个测度都有密度时给出 $\mathfrak{h}(\alpha, \beta) = \|\sqrt{\rho_\alpha} - \sqrt{\rho_\beta}\|_{L^2}$ 。Jensen-Shannon 散度是对混合测度的对称化且有界 KL 散度

$$\text{JS}(\alpha, \beta)^2 = \frac{1}{2} \text{KL}\left(\alpha \left| \frac{\alpha + \beta}{2} \right.\right) + \frac{1}{2} \text{KL}\left(\beta \left| \frac{\alpha + \beta}{2} \right.\right),$$

并且由一个有界熵生成，该熵在相差无关仿射项的意义下等价于 $\varphi_{\text{JS}}(s) = s \log s - (s+1) \log((s+1)/2)$ 。总变差对应于非光滑熵 $\varphi_{\text{TV}}(s) = |s-1|$ ，并且是特殊的，因为它既是 φ -散度，又是积分概率度量。




图 6.2: 通过密度比表示的 φ -散度。左图显示常见散度的归一化生成函数，作为 $s = d\alpha/d\beta$ 的函数；所有曲线在相差仿射归一化的意义下都在 $s=1$ 处为零。右图显示离散公式 $D_\varphi(a|b) = \sum_i b_i \varphi(a_i/b_i)$ ：空心蓝圆编码 b_i ，实心红圆编码 a_i ，紫色曲线给出比率 a_i/b_i ，橙色棒棒糖显示局部 KL 型贡献。

注 6.20 (φ -散度与 Bregman 散度). 除 KL 型熵之外，不应把 φ -散度与 Bregman 散度混淆。 φ -散度通过密度比 $d\alpha/d\beta$ 逐点比较测度，并且在可测变量变换下不变。Bregman 散度由线性空间上的凸泛函生成，并通过一阶 Taylor 误差比较两个点。KL 是特殊的，因为积分熵 $\alpha \mapsto \int \rho \log \rho$ 产生一个 Bregman 散度，而其密度比形式同时也是 φ -散度。

变分对偶公式。 下面的公式把逐点密度比惩罚转化为测试函数上的对偶优化问题。对于 φ -散度而言，它是传输代价的 Kantorovich 对偶公式的对应物。

命题 6.21 (对偶表达式). φ -散度可以用 Legendre 变换表示

$$\varphi^{*,\geq 0}(s) := \sup_{t \in \mathbb{R}^+} st - \varphi(t)$$

(注意我们把函数限制在正实数上) 为

$$\mathcal{D}_\varphi(\alpha|\beta) = \sup_{f:\mathcal{X} \rightarrow \mathbb{R}} \int_{\mathcal{X}} f(x) d\alpha(x) - \int_{\mathcal{X}} \varphi^{*,\geq 0}(f(x)) d\beta(x). \quad (6.12)$$

等价地, $\mathcal{D}_\varphi(\cdot|\beta)$ 的 Legendre 变换为

$$\forall f \in \mathcal{C}(\mathcal{X}), \quad \mathcal{D}_\varphi^*(f|\beta) = \int_{\mathcal{X}} \varphi^{*,\geq 0}(f(x)) d\beta(x). \quad (6.13)$$

证明. 我们先考虑超线性情形 $\varphi'_\infty = +\infty$, 此时如果 α 关于 β 没有密度 $\rho \geq 0$, $d\alpha = \rho d\beta$, 则 $\mathcal{D}_\varphi(\alpha|\beta) = +\infty$. 因此 $\mathcal{D}_\varphi(\cdot|\beta)$ 的 Legendre-Fenchel 变换为

$$\begin{aligned} \mathcal{D}_\varphi^*(f|\beta) &= \sup_{\rho \geq 0} \int_{\mathcal{X}} f(x) \rho(x) d\beta(x) - \int_{\mathcal{X}} \varphi(\rho(x)) d\beta(x) \\ &= \int_{\mathcal{X}} \sup_{\rho(x) \geq 0} (f(x) \rho(x) - \varphi(\rho(x))) d\beta(x) = \int_{\mathcal{X}} \varphi^{*,\geq 0}(f(x)) d\beta(x). \end{aligned}$$

随后 Fenchel–Moreau 给出所显示的对偶表达式. 对于一般熵, 同一论证应用于带退化项的透视函数; 奇异部分正是由 $\varphi^{*,\geq 0}$ 的有效定义域编码的. $\square$

6.4 通过对偶性理解 GAN

GAN 自然适合对偶视角: 判别器是参数化势, 而生成器移动一个参考测度. 本节先解释原始的基于散度的 GAN 目标, 然后将其与 MMD 和 Wasserstein 距离等积分概率度量进行对比.

目标是将生成参数模型 $\alpha_\theta = g_{\theta,\#}\zeta$ 拟合到经验数据 $\beta = \frac{1}{m} \sum_j \delta_{y_j}$, 其中 $\zeta \in \mathcal{M}_+^1(\mathcal{Z})$ 是潜在空间上的固定密度, $g_\theta: \mathcal{Z} \rightarrow \mathcal{X}$ 是生成器, 通常为神经网络.

基于散度的对抗损失. 任意 φ -散度都可以通过对偶公式 (6.12) 写成对抗形式:

$$\min_{\theta} \mathcal{D}_\varphi(\alpha_\theta|\beta) = \min_{\theta} \sup_f \int_{\mathcal{X}} f(x) d\alpha_\theta(x) - \mathcal{D}_\varphi^*(f|\beta) = \min_{\theta} \sup_f \int_{\mathcal{X}} f(g_\theta(z)) d\zeta(z) - \frac{1}{m} \sum_j \varphi^*(f(y_j)).$$

用神经网络 f_ξ 替换无约束势 f , 得到鞍点问题

$$\min_{\theta} \max_{\xi} \int_{\mathcal{Z}} f_\xi(g_\theta(z)) d\zeta(z) - \frac{1}{m} \sum_j \varphi^*(f_\xi(y_j)).$$

原始基础 GAN [109] 正是把上述构造应用于前面讨论的 Jensen–Shannon 生成函数,

$$\varphi_{\text{JS}}(s) = s \log s - (s+1) \log \frac{s+1}{2}, \quad \varphi_{\text{JS}}^*(u) = -\log(2 - e^u), \quad u < \log 2,$$

但需相差仿射归一化, 并采用通常做法, 用取值在 $(0, 1)$ 中的判别器对势重新参数化. 实践中, 最小-最大问题通过在 (θ, ξ) 上交替随机梯度下降/上升来求解. 不同于凸-凹变分公式, 神经参数化关于 θ 非凸、关于 ξ 非凹, 这解释了基于散度的 GAN 训练中的不稳定性和模式崩塌问题. 这些损失估计密度比, 当测度重叠时在统计上有意义, 但当模型与数据互相奇异时可能饱和; 例如, Jensen–Shannon 散度在支撑不交时达到最大.

对偶范数与积分概率度量. 除了密度比散度, 也可以最小化对偶范数 (6.1), 它也称为积分概率度量,

$$\min_{\theta} \|\alpha_\theta - \beta\|_B = \min_{\theta} \sup_{f \in B} \int_{\mathcal{X}} f(x) d(\alpha_\theta - \beta)(x) = \min_{\theta} \sup_{f \in B} \int_{\mathcal{Z}} f(g_\theta(z)) d\zeta - \frac{1}{m} \sum_j f(y_j).$$

MMD-GAN 取 B 为 RKHS 中的单位球 [85]; Wasserstein GAN 遵循 Kantorovich–Rubinstein 对偶性 [11, 95], 取 B 为 Lipschitz 球. 这类选择的优点是拓扑性的: 对于有界连续 RKHS 球, 或紧空间上的有界 Lipschitz 球, 所得目标是弱-* 连续的. 因此, 它可以通过测试函数比较奇异的经验测度与生成测度, 而不要求逐点密度比. 代价是必须以几何方式控制判别器类, 即通过核范数、Lipschitz 约束或相关正则化来控制.

注 6.22 (权重裁剪只是代理). Wasserstein GAN 最初使用权重裁剪, 把 $\|\xi\|_\infty \leq 1$ 作为强制 $f_\xi \in B = \{f; \text{Lip}(f) \leq 1\}$ 的代理。这个参数集合既小于真正的 Lipschitz 球, 又是非凸的, 因此裁剪应理解为一种实践启发式, 而不是对 Kantorovich–Rubinstein 对偶约束的忠实实现。

熵正则化：Sinkhorn 算法

熵正则化使最优传输变得光滑、严格凸并且可扩展。本章首先解释离散的 KL 正则化问题，推导 Sinkhorn 的交替矩阵缩放算法，然后把同一构造重写为相对熵投影问题。随后记录一般连续形式，解释静态耦合形式背后的路径空间 Schrödinger 问题，发展对偶软变换图景，并给出主要的凸正则化变体以及去偏的 Sinkhorn 散度。这里的表述把较早的矩阵缩放文献 [209, 211, 210] 与现代熵最优传输 [70, 185] 联系起来。

7.1 离散测度的熵正则化

熵把一个可能不唯一的线性规划变成一个唯一的光滑问题。代价是偏差，而回报是可微性和快速缩放算法。

最优传输的熵正则化思想，是通过加上离散 Shannon–Boltzmann 熵的相反数来惩罚集中的耦合。

定义 7.1 (离散 Shannon–Boltzmann 熵). 对于非负矩阵 P ，其 Shannon–Boltzmann 熵为

$$H(P) := - \sum_{i,j} P_{i,j} \log(P_{i,j}),$$

其中约定 $0 \log(0) = 0$ 。

把这个熵用作正则化函数，可以得到原始传输问题 (3.2) 的近似解

$$L_C^\varepsilon(a, b) := \min_{P \in U(a, b)} \langle P, C \rangle - \varepsilon H(P). \quad (7.1)$$

命题 7.2 (熵最优传输的存在性与唯一性). 假设 a, b 是概率直方图，且 C 有限。对每个 $\varepsilon > 0$ ，问题 (7.1) 都有唯一极小化子。若 a 和 b 的所有条目均为正，则该极小化子在每个条目上都是正的。

证明. 传输多面体 $U(a, b)$ 非空且紧，并且在约定 $0 \log 0 = 0$ 下目标函数在其上连续，因此极小化子存在。在该多面体的相对内部，

$$-\partial^2 H(P) = \text{diag}(1/P_{i,j})$$

在每个非零可行方向上都是正定的。因此 $-H$ 在该多面体上严格凸，且 $\langle P, C \rangle - \varepsilon H(P)$ 严格凸，从而推出唯一性。

若 $a_i, b_j > 0$ 而某个极小化子满足 $P_{i,j} = 0$ ，则对小的 $t > 0$ ，扰动 $P_t = (1-t)P + t a \otimes b$ 仍然可行。熵部分在 $t = 0$ 处的方向导数为 $-\infty$ ，因为 $r \log r$ 在 0 处沿正方向的导数是 $-\infty$ 。因此当 t 足够小时目标函数会下降，这与最优性矛盾。所以该极小化子严格为正。 $\square$

光滑化效应. 由命题 7.2，问题 (7.1) 有唯一最优解。这种光滑化除了提供唯一性之外，实际上还使得只要 a, b 和 C 留在各自定义域的相对内部， $L_C^\varepsilon(a, b)$ 就是这些变量的光滑函数。在有限维中，这可由严格凸性以及应用于对偶问题的包络定理推出。熵的作用是充当正性约束的障碍函数。正如后面将展示的，这会迫使解 P 在 $a \otimes b$ 的支撑上严格为正。我们还会证明，当 $\varepsilon \rightarrow +\infty$ 时，解满足 $P \rightarrow a \otimes b$ 。




图 7.1: 熵正则化与松弛障碍。第一行展示传输多面体一个三角形面上的惩罚目标 $\langle c, p \rangle + \varepsilon \sum_i p_i (\log p_i - 1)$; 颜色和等值线表示正则化泛函本身, 而不只是线性部分。第二行展示二维多面体 $Az \leq b$ 上类似的松弛变量熵目标 $\ell^\top z + \varepsilon H(b - Az)$, 其中 $H(s) = \sum_i s_i (\log s_i - 1)$ 。大的 ε 选择内部参考点, 而小的 ε 会把极小化子推向低成本面。

熵障碍与通用 LP 障碍的比较。 对于受约束于 $Az \leq b$ 的通用线性规划 $\min_z \ell^\top z$, 可以引入正松弛变量 $s = b - Az$, 并把松弛变量熵惩罚 $H(s) = \sum_i s_i (\log s_i - 1)$ 用作光滑的内点正则化。这是理解图 7.1 的有用类比, 但它并不是线性规划的标准内点障碍。正交象限上的典型障碍是 Burg, 或者说反向 KL, 对数障碍 $-\sum_i \log s_i$; 它是自协调的, 因此适合内点法的 Newton 理论 [172]。代价是通用 Newton 步需要求解稠密线性系统, 导致相对于相关变量数或约束数的每次迭代三次方缩放。最优传输是特殊的: 熵放在 P 的条目上, 而约束仅是行、列边缘。这一可分结构把相应的 Bregman 投影变成对角重缩放, 也就是接下来要发展的 Sinkhorn 矩阵-向量迭代。

7.2 Sinkhorn 算法

Sinkhorn 算法是对行与列的交替归一化。本节推导优化器的缩放形式, 并解释为什么每次迭代只需要矩阵-向量乘积。

其背后的矩阵缩放迭代有很长历史, 包括迭代比例拟合以及 Sinkhorn 和 Knopp 的工作 [209, 211, 210]。Cuturi 的熵形式 [70] 改变了它在最优传输中的现代角色: 该算法成为机器学习中大规模工具, 也改变了机器学习中对最优传输的看法, 使其从主要是几何距离转变为可微的计算原语。

下面的命题说明, (7.1) 的解具有一种特定形式, 可以用 $n + m$ 个变量参数化。因此, 这种参数化本质上是对偶的, 因为 $U(a, b)$ 中的耦合 P 有 nm 个变量, 但有 $n + m$ 个约束。

命题 7.3 (熵最优传输的缩放形式). P 是 (7.1) 的唯一解, 当且仅当存在 $(u, v) \in \mathbb{R}_+^n \times \mathbb{R}_+^m$ 使得

$$\forall (i, j) \in [n] \times [m], \quad P_{i,j} = u_i K_{i,j} v_j \quad \text{where} \quad K_{i,j} := e^{-\frac{C_{i,j}}{\varepsilon}}, \quad (7.2)$$

且 $P \in \mathcal{U}(a, b)$ 。

证明。 不失一般性, 假设 $a_i, b_j > 0$ (否则, 质量为零的行或列被固定为零, 可以移除)。由命题 7.2, 极小化子在剩余支撑上严格为正。

因此, 在为每个边缘约束引入两个对偶变量 $f \in \mathbb{R}^n, g \in \mathbb{R}^m$ 时, 可以忽略正性约束, 从而 (7.1) 的 Lagrangian 写为

$$\mathcal{E}(P, f, g) = \langle P, C \rangle + \varepsilon \sum_{i,j} P_{i,j} \log(P_{i,j}) + \langle f, a - P \mathbf{1}_m \rangle + \langle g, b - P^\top \mathbf{1}_n \rangle.$$

考虑一阶条件 (如上所述忽略正性约束), 得到

$$\frac{\partial \mathcal{E}(P, f, g)}{\partial P_{i,j}} = C_{i,j} + \varepsilon (\log(P_{i,j}) + 1) - f_i - g_j = 0.$$

这给出正则化问题的最优耦合 P 的表达式 $P_{i,j} = e^{\frac{f_i + g_j - C_{i,j}}{\varepsilon} - 1}$ 它可以用非负向量 $u_i := e^{f_i/\varepsilon - 1}$ 和 $v_j := e^{g_j/\varepsilon}$ 重写为命题中给出的形式。□

式 (7.2) 中展示的最优解分解可以方便地重写成矩阵形式 $P = \text{diag}(u)K \text{diag}(v)$ 。因此, u, v 必须满足下列非线性方程, 它们对应于 $U(a, b)$ 固有的质量守恒约束:

$$\text{diag}(u)K \text{diag}(v)\mathbf{1}_m = a, \quad \text{and} \quad \text{diag}(v)K^\top \text{diag}(u)\mathbf{1}_n = b, \quad (7.3)$$

这两个方程还可以进一步化简, 因为 $\text{diag}(v)\mathbf{1}_m$ 就是 v , 而 $\text{diag}(u)$ 乘以 Kv 是

$$u \odot (Kv) = a \quad \text{and} \quad v \odot (K^\top u) = b \quad (7.4)$$

其中 $\odot$ 表示向量逐条目相乘。这个问题在数值分析领域被称为矩阵缩放问题 (见 [171] 及其中参考文献)。

归一化正矩阵 K 的问题历史悠久, 从统计学和经济学中的迭代比例拟合 [135, 236, 97], 一直到现代矩阵平衡算法 [125, 68]。通过对角缩放来归一化正矩阵 K 的问题广为人知, 特别是在 $n = m$ 且 a 和 b 均匀时。这对应于朝双随机性的对角缩放, 是一个非常古老的问题。前面的结果表明, 由于正则化问题的强凸性, 存在唯一的这种缩放矩阵 P 。剩下的问题是如何在实践中计算这个缩放矩阵。若 K 的某些条目为零 (等价地, 若成本矩阵 C 可以取无穷值), 则需要额外的支撑条件; 这里我们关注严格为正的情形。

求解这些方程的一种直观方式是迭代求解: 先修改 u , 使其满足式 (7.4) 左侧方程, 再修改 v , 使其满足右侧方程。这两个更新定义了 Sinkhorn 算法

$$u^{(\ell+1)} := \frac{a}{Kv^{(\ell)}} \quad \text{and} \quad v^{(\ell+1)} := \frac{b}{K^\top u^{(\ell+1)}}, \quad (7.5)$$

它用任意正向量初始化, 例如 $v^{(0)} = \mathbf{1}_m$ 。上面对两个向量使用的除法算子应理解为逐条目除法。注意, 不同初始化很可能给出不同的 u, v 解, 因为 u, v 只在乘法常数意义下确定 (若 u, v 满足 (7.3), 则对任意 $\lambda > 0$, $\lambda u, v/\lambda$ 也满足)。交替归一化可以直接在耦合矩阵上理解: 一次行更新强制满足源边缘, 通常会扰动目标边缘; 而下一次列更新则相反。

算法 7.1 Sinkhorn 缩放

输入: 权重 a, b , 成本矩阵 C , 正则化 $\varepsilon > 0$, 容差 tol 。

输出: 熵耦合 P 。

初始化: 令 $K_{ij} = e^{-C_{ij}/\varepsilon}$, $v^{(0)} = \mathbf{1}_m$, $r_0 = +\infty$, 且 $k = 0$ 。

当 $r_k > \text{tol}$ **时执行:**

令 $k \leftarrow k + 1$ 。

$u^{(k)} = \frac{a}{Kv^{(k-1)}}$ 。

$v^{(k)} = \frac{b}{K^\top u^{(k)}}$ 。

$P^{(k)} = \text{diag}(u^{(k)})K \text{diag}(v^{(k)})$ 。

令 $r_k = \max\{\|P^{(k)}\mathbf{1}_m - a\|_1, \|(P^{(k)})^\top \mathbf{1}_n - b\|_1\}$ 。

返回 $P^{(k)}$ 。




图 7.2: 十二个箱的一维问题中 Sinkhorn 缩放过程里的边缘约束。紫色圆圈表示当前耦合矩阵, 由细黑框框出; 红色源边缘显示在左侧, 蓝色目标边缘显示在矩阵下方。空心侧边圆圈表示给定边缘, 而实心圆圈表示当前边缘。行归一化会对齐红色边缘并留下蓝色缺陷; 列归一化会对齐蓝色边缘并留下红色缺陷。

在稠密的一维离散化上, 同样的交替投影机制更加清楚, 此时边缘缺陷表现为连续的侧边曲线。




图 7.3: 一维高斯混合边缘的稠密 Sinkhorn 缩放。灰度矩阵是当前耦合, 细框只界定矩阵而不包括侧边缘图。红色和蓝色侧边曲线是给定的源边缘与目标边缘, 而紫色侧边曲线是当前行和列的和。一次行缩放使紫色曲线与红色源边缘重合, 一次列缩放使其与蓝色目标边缘重合, 而交替过程会快速稳定两侧。

收敛之后, 正则化强度控制 Gibbs 核有多少仍在最优计划中可见。小的 ε 产生集中的传输带, 而较大的 ε 会把相同边缘展开成更光滑的耦合。




图 7.4: 同一组一维高斯混合边缘在四个正则化强度下的最终 Sinkhorn 耦合。每个带框矩阵都是 KL 正则化问题的收敛解, 并使用共同的灰度归一化; 侧边曲线显示固定的源边缘与目标边缘。减小 ε 会使计划向最优传输图变尖锐, 而增大 ε 会保留更多弥散的乘积测度结构。

第 8 章给出形式化收敛分析。在此之前, 下图展示对偶势如何沿着同一缩放迭代稳定下来。




图 7.5: 与图 7.7 相同的一维高斯混合设置下, 固定正则化强度 $\varepsilon = 0.045$ 时沿缩放迭代的 KL 归一化 Sinkhorn 对偶势。底部轮廓同时显示红色的源直方图 a 和蓝色的目标直方图 b, 红色和蓝色曲线则是对数缩放势。所有面板共享同一坐标轴, 从而使稳定过程可见。

Sinkhorn 的复杂度界以及与加速一阶方法的比较见 [4, 84, 132]。Sinkhorn 算法除简单之外, 一个主要计算优势是唯一昂贵的步骤是乘以 Gibbs 核。因此它的复杂度按 Cnm 缩放, 其中 C 是 Sinkhorn 迭代次数。第 8 章给出更精确的收敛陈述: 对固定正则化强度 ε , 熵对偶间隙有一个 $O(1/k)$ 界, 其常数与 $1/\varepsilon$ 成正比; 而当 Gibbs 核一致为正时, Hilbert 度量论证会给出最终线性收敛。若要把未正则化最优传输值近似到精度 δ , 还必须平衡熵偏差; 在有限维中它通常是 $O(\varepsilon)$ 。选择与 δ 成正比的 ε , 并把熵问题求解到 $O(\delta)$ 精度, 会得到未正则化值熟悉的 $1/\delta^2$ 量级迭代缩放, 差别只在对数因子和成本范围因子 [4, 84]。




图 7.6: 同一个一维高斯混合问题中, 四个 ε 取值下 Sinkhorn 半步沿途的边缘违背, 以及相应的极限计划。绘制的误差是在对数尺度上的 $\frac{1}{2}(\|P_k \mathbf{1} - \mathbf{a}\|_1 + \|P_k^\top \mathbf{1} - \mathbf{b}\|_1)$ 。右侧彩色方框使用与收敛曲线相同的颜色。对固定的正 ε , 曲线进入线性区域; 较小的 ε 给出更尖锐的传输几何, 但也给出峰值更强的 Gibbs 核以及更慢的缩放。

然而在许多应用中, 并不需要对最优传输子问题使用高度精确的优化器。下游性能往往更多取决于差异量的几何偏差, 而不是精确最优性。在这类场景中, C 通常是适中的。这应与通用内点法对比, 后者使用上面讨论的对数障碍, 并且需要求解 Newton 系统。对于稠密传输线性规划, 这些算法达到精度 δ 的典型最坏情形复杂度为 $O(n^6 \log(1/\delta))$ 量级, 此外还差一个依赖问题的条件数因子。

Sinkhorn 的第二个关键方面是, 矩阵-向量乘法在 GPU 上具有极好的流式执行效果。更进一步, 如果目标是用固定成本矩阵 C 计算许多最优传输问题, 就可以把许多矩阵-向量乘法替换成矩阵-矩阵乘法, 从而获得可观的计算收益。

注 7.4 (网格上的可分高斯核). 当样本位于笛卡尔网格上且 $c(x, y) = \|x - y\|^2$ 时, Gibbs 核是高斯核, 并沿坐标分解。若在维度 d 中网格每条轴有 q 个点, 从而使用 $N = q^d$ 个网格点, 则

$$K(x, y) = \exp\left(-\frac{\|x - y\|^2}{\varepsilon}\right) = \prod_{\ell=1}^d \exp\left(-\frac{(x_\ell - y_\ell)^2}{\varepsilon}\right).$$

因此, 乘以 K 可以通过沿每个坐标方向依次相乘来实现, 等价地, 也就是沿各轴应用一维高斯核算子。在周期网格或充分填充的均匀网格上, 这些就是字面意义上的离散卷积。一次直接的稠密一维乘法在每条坐标线上花费 $O(q^2)$, 共有 q^{d-1} 条坐标线, 并且要对 d 条轴重复。因此一次 Sinkhorn 半步的成本为

$$O(dq^{d+1}) = O(dN^{1+1/d})$$

而不是 $O(N^2)$ 。借助基于 FFT 的卷积或截断高斯卷积, 可以进一步利用同样的可分性, 但这个简单的张量积估计已经解释了为什么基于网格的 Sinkhorn 可以比通用稠密耦合具有好得多的扩展性。

7.3 使用相对熵的重述

KL 形式把 Sinkhorn 识别为一种投影方法。它也为连续和非平衡设置做好准备; 在这些设置中, 参考测度是必要的。

重述并“归一化”这个离散熵的一个方便工具是相对熵。它是一种有限维散度, 能够把熵正则化变成投影问题, 并允许直接的测度论推广。

定义 7.5 (离散相对熵). 对于同样大小的非负矩阵 P, Q , 广义相对熵, 或者 Kullback–Leibler 散度, 为

$$\text{KL}(P|Q) := \sum_{i,j} P_{i,j} \log\left(\frac{P_{i,j}}{Q_{i,j}}\right) - P_{i,j} + Q_{i,j}. \quad (7.6)$$

约定为 $0 \log(0) = 0$; 若存在 (i, j) 使得 $Q_{i,j} = 0$ 但 $P_{i,j} \neq 0$, 则 $\text{KL}(P|Q) = +\infty$ 。

在比较概率分布的特殊情形中, P 和 Q 具有相同总质量, 这会进一步化简为

$$\text{KL}(P|Q) = \sum_{i,j} P_{i,j} \log \left(\frac{P_{i,j}}{Q_{i,j}} \right).$$

对于参考矩阵 $Q = \mathbf{1}_{n \times m}$, 有

$$-\text{KL}(P|\mathbf{1}_{n \times m}) = H(P) + \sum_{i,j} P_{i,j} - nm.$$

在固定质量耦合上, 最后两项是常数, 因此以 $\mathbf{1}_{n \times m}$ 为参考的 KL 正则化等价于减去 Shannon–Boltzmann 熵。KL 同时是 φ -散度 (如第 6.3 节定义) 和 Bregman 散度的一个特殊实例; 在标准仿射重缩放意义下, 它是这两个族之间的典型重叠。这个特殊性质正是这种正则化能够导向优雅算法与可处理数学分析的核心原因。

命题 7.6 (相对熵具有距离型性质). 令 $P, Q \in \mathbb{R}_+^{n \times m}$ 具有相同总质量, 并假设在 P 的支撑上 $Q_{i,j} > 0$ 。则 $\text{KL}(P|Q) \geq 0$, 且等号成立当且仅当 $P = Q$ 。

证明. 写作 $\varphi(s) = s \log s - s + 1$ 。凸性给出 $\varphi(s) \geq \varphi(1) + \varphi'(1)(s - 1) = 0$, 而严格凸性说明只有在 $s = 1$ 时取等。于是

$$\text{KL}(P|Q) = \sum_{i,j} Q_{i,j} \varphi(P_{i,j}/Q_{i,j}) \geq 0,$$

等号仅当所有满足 $Q_{i,j} > 0$ 的条目都有 $P_{i,j}/Q_{i,j} = 1$ 时成立。支撑约定排除了 $Q = 0$ 处的正 P , 因此等号成立等价于 $P = Q$. $\square$

等价地, 当 P 和 Q 具有相同总质量时, 它可写作

$$\text{KL}(P|Q) = \sum_{i,j} \varphi(P_{i,j}/Q_{i,j}) Q_{i,j}.$$

其中 $\varphi(s) = s \log(s)$ 。事实上, 对任意满足 $\varphi(1) = 0$ 的凸函数 φ , 由 Jensen 不等式可得

$$\sum_{i,j} \varphi(P_{i,j}/Q_{i,j}) Q_{i,j} \geq \varphi\left(\sum_{i,j} P_{i,j}/Q_{i,j} Q_{i,j}\right) = \varphi\left(\sum_{i,j} P_{i,j}\right) = \varphi(1) = 0.$$

例如, 可以把张量积 $a \otimes b = (a_i b_j)_{i,j}$ 用作参考测度, 并考虑

$$\min_{P \in U(a,b)} \langle P, C \rangle + \varepsilon \text{KL}(P|a \otimes b). \quad (7.7)$$

这种归一化在非平衡最优传输中还会再次变得重要; 在那里, 改变参考测度不再只是无害的记号选择。

然而, 对于固定正边缘的平衡问题, 张量积参考的选择不会影响所选耦合: 它只会给目标函数加上一个常数, 如下列命题所示。特别地, (7.7) 和 (7.1) 具有相同的唯一解。

命题 7.7 (KL 的参考测度平移). 在移除零质量行和列之后, 假设 $a, a' \in \Sigma_n$ 与 $b, b' \in \Sigma_m$ 都具有正条目。对每个 $P \in U(a, b)$, 有

$$\text{KL}(P|a \otimes b) = \text{KL}(P|a' \otimes b') - \text{KL}(a|a') - \text{KL}(b|b').$$

因此, 对固定正边缘而言, 改变正的张量积参考测度只会在传输多面体上加上一个常数。特别地, (7.7) 和 (7.1) 具有相同的唯一极小化子。

证明. 展开对数并使用边缘约束得到

$$\begin{aligned} \text{KL}(P|a \otimes b) &= \text{KL}(P|a' \otimes b') + \sum_i a_i \log \frac{a'_i}{a_i} + \sum_j b_j \log \frac{b'_j}{b_j} \\ &= \text{KL}(P|a' \otimes b') - \text{KL}(a|a') - \text{KL}(b|b'). \end{aligned}$$

$\square$

不过, 当支撑发生变化时, 张量积参考仍然有用, 因为它明确指出哪些条目允许为零。它也是能够干净过渡到下面连续形式的归一化; 在连续形式中, 参考测度是 $\alpha \otimes \beta$, 而不是环境 Lebesgue 测度。




图 7.7: 同一组一维高斯混合直方图的 KL 归一化 Sinkhorn 对偶势。底部轮廓同时显示红色的源直方图 a 和蓝色的目标直方图 b。红色和蓝色曲线是对数缩放 $f_i^\epsilon = \epsilon \log u_i^\epsilon$ 与 $g_j^\epsilon = \epsilon \log v_j^\epsilon$, 规范为 $\langle f^\epsilon, a \rangle = 0$, 并由 $P_{i,j} = u_i a_i b_j e^{-C_{i,j}/\epsilon} v_j$ 计算得到。平方欧几里得成本按其正条目中位数归一化, 所有面板使用相同坐标轴; 增大 ϵ 会把硬 c -变换几何变成更光滑的 log-sum-exp 势。

KL 归一化形式也使正则化参数的两个极限状态变得透明。

命题 7.8 (关于 ϵ 的收敛). 假设在移除零质量行和列之后, a 与 b 为正, 且 C 有限。 (7.1) 的唯一解 P_ϵ 收敛到 Kantorovich 问题所有最优解集中熵最大的最优解, 即

$$P_\epsilon \xrightarrow{\epsilon \rightarrow 0} \operatorname{argmin}_P \{-H(P) ; P \in U(a, b), \langle P, C \rangle = L_C(a, b)\} \quad (7.8)$$

因此特别有

$$L_C^\epsilon(a, b) \xrightarrow{\epsilon \rightarrow 0} L_C(a, b).$$

此外,

$$P_\epsilon \xrightarrow{\epsilon \rightarrow \infty} a \otimes b. \quad (7.9)$$

证明. 情形 $\epsilon \rightarrow 0$. 我们考虑一个序列 $(\epsilon_\ell)_\ell$, 使得 $\epsilon_\ell \rightarrow 0$ 且 $\epsilon_\ell > 0$ 。用 P_ℓ 表示当 $\epsilon = \epsilon_\ell$ 时 (7.1) 的解。由于 $U(a, b)$ 有界, 可以抽取一个序列 (为简单起见不重新标号), 使得 $P_\ell \rightarrow P^*$ 。由于 $U(a, b)$ 闭, $P^* \in U(a, b)$ 。考虑任意满足 $\langle C, P \rangle = L_C(a, b)$ 的 P 。利用等价的 KL 归一化形式 (7.7), P 和 P_ℓ 分别对其优化问题 ($\epsilon = 0$ 和 $\epsilon = \epsilon_\ell$) 的最优性给出

$$0 \leq \langle C, P_\ell \rangle - \langle C, P \rangle \leq \epsilon_\ell (\text{KL}(P|a \otimes b) - \text{KL}(P_\ell|a \otimes b)). \quad (7.10)$$

由于 KL 连续, 在该表达式中令 $\ell \rightarrow +\infty$ 得到 $\langle C, P^* \rangle = \langle C, P \rangle$, 因此 P^* 是 (7.8) 的一个可行点。进一步, 在 (7.10) 中除以 ϵ_ℓ 并取极限可得 $\text{KL}(P^*|a \otimes b) \leq \text{KL}(P|a \otimes b)$, 这说明 P^* 是 (7.8) 的一个解。由于 $\text{KL}(\cdot|a \otimes b)$ 在最优面上的严格凸性, 该规划的解 P_0^* 唯一, 所以 $P^* = P_0^*$, 整个序列都收敛。

情形 $\epsilon \rightarrow +\infty$. 从成本中减去 $\min_{i,j} C_{i,j}$ 会使每个可行目标值改变同一个常数, 因此不会改变极小化子。所以可以假设 $C \geq 0$ 。在 $a \otimes b$ (属于约束集 $U(a, b)$) 处评估能量, 有

$$\langle C, P_\epsilon \rangle + \epsilon \text{KL}(P_\epsilon|a \otimes b) \leq \langle C, a \otimes b \rangle + \epsilon \times 0$$

且由于 $\langle C, P_\epsilon \rangle \geq 0$, 这导致

$$\text{KL}(P_\epsilon|a \otimes b) \leq \epsilon^{-1} \langle C, a \otimes b \rangle \leq \frac{\|C\|_\infty}{\epsilon}$$

所以 $\text{KL}(P_\epsilon|a \otimes b) \rightarrow 0$, 又因为 KL 是有效散度, 因而 $P_\epsilon \rightarrow a \otimes b$ 。 $\square$




图 7.8: 四个固定正则化强度下, 标准红色圆盘点云与蓝色环形点云之间的熵正则化耦合。平方欧几里得成本按其中位数归一化, 每个计划都由对数域 Sinkhorn 计算, 直到边缘残差低于计算笔记本容差。紫色线段显示计算计划中最大的可见条目, 其厚度和不透明度与传输质量成正比。对每个 $\varepsilon > 0$, 计划都严格为正, 但随着 ε 增大, 可见质量模式从近似径向且稀疏演化为弥散。

7.4 一般形式

连续形式用测度替代矩阵, 并用相对熵替代离散 KL。它是 Sinkhorn 所求解的静态端点问题; 下一节解释它如何从随机路径上的优化问题得到。

可以通过把离散熵替换为相对于乘积测度 $d\alpha \otimes d\beta(x, y) := d\alpha(x)d\beta(y)$ 的相对熵来考虑任意测度, 并用下式给出 (3.5) 的正则化对应物:

$$\mathcal{L}_c^\varepsilon(\alpha, \beta) := \min_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y) + \varepsilon \text{KL}(\pi | \alpha \otimes \beta) \quad (7.11)$$

测度论定义是定义 7.5 的精确类比, 只是用绝对连续性替代逐条目的支撑条件。

定义 7.9 (测度的相对熵). 对于 $\mathcal{X} \times \mathcal{Y}$ 上的非负测度 π 和 ξ , 相对熵为

$$\text{KL}(\pi | \xi) := \int_{\mathcal{X} \times \mathcal{Y}} \log \left(\frac{d\pi}{d\xi}(x, y) \right) d\pi(x, y) + \int_{\mathcal{X} \times \mathcal{Y}} (d\xi(x, y) - d\pi(x, y)). \quad (7.12)$$

按照约定, 若 π 不关于 ξ 绝对连续, 则 $\text{KL}(\pi | \xi) = +\infty$ 。

对于固定的平衡边缘, 只要替代参考边缘分别与 α 和 β 互相绝对连续, 熵中的具体乘积参考只在加性常数意义下有影响, 这与命题 7.7 完全一样。不过, 它的支撑和绝对连续结构仍然是关键的: 它们决定哪些耦合具有有限熵。在非平衡设置中, 这一区别会变得实质性, 因为边缘约束不再冻结这些加性项。接下来发展这个静态问题的路径空间含义。核心点是, 有噪声的参考动力学首先定义轨迹上的概率律; 在给定端点后把路径的条件律优化掉之后, 剩下的只有端点耦合。

7.5 路径空间 Schrödinger 问题

Schrödinger 的互易问题自然地表述在路径上, 而不是端点对上。将路径律约化到其两个端点边缘之后, 就会出现 Sinkhorn 问题。

未正则化的路径空间传输。 在本节中, 两个端点测度都位于同一状态空间 $\mathcal{X}$ 上; 这是与动态传输和布朗桥相关的设置。上面的静态耦合形式在两个不同空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 之间同样有意义。令 $\Omega = C([0, 1]; \mathcal{X})$ 为路径空间, 并记

$$e_t : \Omega \rightarrow \mathcal{X}, \quad e_t(\omega) = \omega_t$$

为求值映射。概率 $M \in \mathcal{P}(\Omega)$ 是随机轨迹的律。施加端点约束

$$(e_0)_\# M = \alpha, \quad (e_1)_\# M = \beta$$

意味着随机路径以律 α 开始, 并以律 β 结束。给定路径作用量 $\mathcal{A} : \Omega \rightarrow [0, +\infty]$, 未正则化的路径空间问题为

$$\inf_{M \in \mathcal{P}(\Omega)} \left\{ \int_{\Omega} \mathcal{A}(\omega) dM(\omega) ; (e_0)_\# M = \alpha, (e_1)_\# M = \beta \right\}. \quad (7.13)$$

对于 $\mathbb{R}^d$ 上的二次 Wasserstein 几何, 取

$$\mathcal{A}(\omega) = \begin{cases} \int_0^1 \|\dot{\omega}_t\|^2 dt, & \text{若 } \omega \text{ 绝对连续,} \\ +\infty, & \text{否则.} \end{cases}$$

这是备注 12.4 中回顾的 Benamou–Brenier 形式的 Lagrangian 版本。

由作用量诱导的端点成本为

$$c_{\mathcal{A}}(x, y) := \inf_{\omega \in \Omega} \{ \mathcal{A}(\omega) ; e_0(\omega) = x, e_1(\omega) = y \}. \quad (7.14)$$

对上面的二次作用量, 极小化路径是直线段 $\omega_t = (1-t)x + ty$, 并且 $c_{\mathcal{A}}(x, y) = \|x - y\|^2$ 。

命题 7.10 (路径空间传输的端点约化). 假设 (7.14) 中的极小化路径可以可测地选择, 或者更一般地, 其下确界可以由可测选择逼近。则 (7.13) 与 Kantorovich 问题具有相同的值:

$$\inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{X}} c_{\mathcal{A}}(x, y) d\pi(x, y).$$

此外, 若 π^* 是一个最优端点耦合, 且 $\omega^{x,y}$ 是从 x 到 y 的最优路径, 则

$$M^* = \int_{\mathcal{X} \times \mathcal{X}} \delta_{\omega^{x,y}} d\pi^*(x, y)$$

是一个最优路径律。

证明. 令 M 为任意可行路径律, 并设 $\pi = (e_0, e_1)_{\#} M$ 。则 $\pi \in \mathcal{U}(\alpha, \beta)$, 且由 $c_{\mathcal{A}}$ 的定义,

$$\int_{\Omega} \mathcal{A}(\omega) dM(\omega) \geq \int_{\mathcal{X} \times \mathcal{X}} c_{\mathcal{A}}(x, y) d\pi(x, y).$$

这证明路径空间值至少是 Kantorovich 值。反过来, 给定一个耦合 π 以及一个作用量任意接近 $c_{\mathcal{A}}(x, y)$ 的可测选择 $(x, y) \mapsto \omega^{x,y}$, 狄拉克路径律的混合

$$M = \int \delta_{\omega^{x,y}} d\pi(x, y)$$

具有端点 α 和 β , 并且在所选近似误差意义下, 作用量等于 $\int c_{\mathcal{A}} d\pi$ 。对 π 优化并令近似误差消失即可证明相等。若为最优 π^* 选择精确极小化路径, 则显示的 M^* 是最优的。□

因此, 经典耦合问题可以被理解为一个路径问题: 先选择端点, 再选择具有最小作用量的连接路径。Schrödinger 问题改变的正是最后一步: 在两个端点之间, 它保留参考动力学的随机涨落, 而不是坍缩到确定性的最小作用量路径。

熵路径空间问题。 令 $\mathcal{R}^\varepsilon \in \mathcal{P}(\Omega)$ 为参考路径律, 例如噪声水平为 ε 的布朗或 Langevin 动力学。Schrödinger 的动态问题是熵投影

$$\text{SB}_\varepsilon(\alpha, \beta) := \inf_{M \in \mathcal{P}(\Omega)} \{ \varepsilon \text{KL}(M | \mathcal{R}^\varepsilon) ; (e_0)_{\#} M = \alpha, (e_1)_{\#} M = \beta \}. \quad (7.15)$$

这就是动态 Schrödinger 桥问题。它在所有匹配观测端点边缘的路径律中, 寻找相对于先验动力学 $\mathcal{R}^\varepsilon$ 最可能的路径律。这个观点可追溯到 Schrödinger 的互易问题 [206], 并在 [142, 143] 中用现代最优传输语言综述; 随机控制形式则在 [60] 中发展。

黏性 Benamou–Brenier 形式。 Schrödinger 插值也允许动态最优控制描述, 它们是 Benamou–Brenier 公式的黏性类比。本段用 σ 表示扩散归一化; 它独立于其他地方使用的熵温度 ε 。形式上, 对光滑正密度, 并采用约定

$$\partial_t \rho_t + \text{div}(\rho_t v_t) = \frac{\sigma}{2} \Delta \rho_t,$$

在连接给定端点密度的曲线中, 极小化动能作用量

$$\int_0^1 \int \frac{1}{2} \|v_t(x)\|^2 \rho_t(x) dx dt.$$

等价地, 可以把扩散吸收到速度中, 写作

$$u_t = v_t - \frac{\sigma}{2} \nabla \log \rho_t, \quad \partial_t \rho_t + \operatorname{div}(\rho_t u_t) = 0.$$

展开 $v_t = u_t + \frac{\sigma}{2} \nabla \log \rho_t$ 并使用 (ρ_t, u_t) 的连续性方程, 得到

$$\begin{aligned} \int_0^1 \int \frac{1}{2} \|v_t\|^2 \rho_t \, dx \, dt &= \int_0^1 \int \left(\frac{1}{2} \|u_t\|^2 + \frac{\sigma^2}{8} \|\nabla \log \rho_t\|^2 \right) \rho_t \, dx \, dt \\ &\quad + \frac{\sigma}{2} \left[\int \rho_1 \log \rho_1 \, dx - \int \rho_0 \log \rho_0 \, dx \right]. \end{aligned}$$

由于熵项只依赖给定端点, 同样的极小化子也可由修正的 Benamou–Brenier 作用量得到:

$$\int_0^1 \int \left(\frac{1}{2} \|u_t(x)\|^2 + \frac{\sigma^2}{8} \|\nabla \log \rho_t(x)\|^2 \right) \rho_t(x) \, dx \, dt.$$

因此, Schrödinger 桥是一种最小作用量插值, 同时包含传输动能和 Fisher 信息惩罚。若改用扩散系数 $\sigma \Delta \rho_t$ 来写黏性方程, 则在把上面的 σ 替换为 2σ 后得到同一公式, 因此 Fisher 系数变为 $\sigma^2/2$ 。

到端点耦合的约化来自反积分。写作

$$\mathcal{R}^\varepsilon(d\omega) = \int \mathcal{R}^{\varepsilon, x, y}(d\omega) \mathcal{R}_{01}^\varepsilon(dx, dy), \quad \mathcal{R}_{01}^\varepsilon := (e_0, e_1)_\# \mathcal{R}^\varepsilon,$$

其中 $\mathcal{R}^{\varepsilon, x, y}$ 是条件在端点 (x, y) 上的参考桥。类似地, 对任意可行 M , 写作

$$M(d\omega) = \int M^{x, y}(d\omega) \pi(dx, dy), \quad \pi := (e_0, e_1)_\# M.$$

命题 7.11 (Schrödinger 问题的端点约化). 假设上述正则条件律存在, 并且相对熵链式法则适用; 当绝对连续性失败时, 取值为 $+\infty$ 。则

$$\mathrm{SB}_\varepsilon(\alpha, \beta) = \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \varepsilon \mathrm{KL}(\pi | \mathcal{R}_{01}^\varepsilon). \quad (7.16)$$

对于固定的端点耦合 π , 若 $\mathrm{KL}(\pi | \mathcal{R}_{01}^\varepsilon)$ 有限, 则极小化路径律是参考桥的混合:

$$M^\pi = \int \mathcal{R}^{\varepsilon, x, y} d\pi(x, y). \quad (7.17)$$

因此, 若 π^* 求解 (7.16), 则 M^{π^*} 求解路径空间问题 (7.15)。

证明. 若 M 相对于 $\mathcal{R}^\varepsilon$ 具有有限相对熵, 则 $\pi = (e_0, e_1)_\# M$ 必然关于 $\mathcal{R}_{01}^\varepsilon$ 绝对连续。相对熵链式法则给出

$$\mathrm{KL}(M | \mathcal{R}^\varepsilon) = \mathrm{KL}(\pi | \mathcal{R}_{01}^\varepsilon) + \int_{\mathcal{X} \times \mathcal{X}} \mathrm{KL}(M^{x, y} | \mathcal{R}^{\varepsilon, x, y}) d\pi(x, y). \quad (7.18)$$

第二项非负, 并且恰在对 π -几乎每个 (x, y) 都有 $M^{x, y} = \mathcal{R}^{\varepsilon, x, y}$ 时为零。因此, 一旦固定一个满足 $\mathrm{KL}(\pi | \mathcal{R}_{01}^\varepsilon)$ 有限的端点耦合 π , 最佳路径律就是 (7.17), 剩余的极小化正是 (7.16)。若不存在这样的端点耦合, 则两边都是 $+\infty$ 。□

这个命题精确说明了动态观点与静态观点之间的联系。静态 Schrödinger 问题只保存最优随机轨迹的端点; 完整桥则通过为每个被传输的端点对填入相应的参考桥来恢复。在零噪声极限中, 这些桥集中到最小作用量路径上, 并恢复未正则化的路径空间传输问题, 从而恢复 Monge–Kantorovich 问题 [142]。

布朗桥与 Sinkhorn 耦合。 对 $\mathcal{X} = \mathbb{R}^d$, 取 $\mathcal{R}^\varepsilon$ 为布朗参考动力学, 差别只在 ε 的惯例缩放。其端点律具有如下形式的核密度:

$$p_\varepsilon(x, y) \propto \exp\left(-\frac{\|x - y\|^2}{\varepsilon}\right)$$

其中已把无害常数吸收到 ε 中。更一般地, 假设端点先验在一个与 π 无关的归一化常数意义下可写为

$$\mathcal{R}_{01}^\varepsilon(dx, dy) \propto \exp\left(-\frac{c(x, y)}{\varepsilon}\right) \alpha(dx) \beta(dy).$$

只要单时刻端点密度固定且互相绝对连续, 在相对于 $\alpha \otimes \beta$ 重写之后, 这就包含通常的热核参考。额外的单体密度因子在边缘约束下只会增加常数。于是, 对每个 $\pi \in \mathcal{U}(\alpha, \beta)$,

$$\varepsilon \text{KL}(\pi | \mathcal{R}_{01}^\varepsilon) = \int c(x, y) d\pi(x, y) + \varepsilon \text{KL}(\pi | \alpha \otimes \beta) + \text{常数},$$

其中常数不依赖于 π 。因此, (7.16) 正是连续 Sinkhorn 问题 (7.11), 只差值中的一个加性常数。最优静态耦合 π_ε^* 是最可能的受控有噪声动力学的端点律, 而相应的路径律为

$$M_\varepsilon^* = \int \mathcal{R}^{\varepsilon, x, y} d\pi_\varepsilon^*(x, y).$$

换句话说, Sinkhorn 计算哪些端点应当配对; 随后路径空间 Schrödinger 桥用布朗桥而不是确定性直线连接每个已配对端点。

图 7.9 在一个小型离散例子上说明这种从端点到路径的提升。红色原子形成紧凑的源云, 蓝色原子围绕它们。第一个面板使用未正则化的最优传输耦合和零桥噪声; 后续面板增大 ε , 这会同时软化端点耦合并放大配对端点之间的布朗涨落。

算法 7.2 端点到路径的 Schrödinger 提升

输入: 端点律 α, β , 成本 c , 正则化 $\varepsilon > 0$, 参考桥 $\mathcal{R}^{\varepsilon, x, y}$ 。

输出: Schrödinger 路径律 M_ε^* 。

令 π_ε^* 为静态熵端点问题的一个极小化子: $\pi_\varepsilon^* \in \operatorname{argmin}_{\pi \in \mathcal{U}(\alpha, \beta)} \int c d\pi + \varepsilon \text{KL}(\pi | \alpha \otimes \beta)$ 。

对从 π_ε^* 采样的每个端点对 (x, y) 执行:

 抽取桥路径: $\omega \sim \mathcal{R}^{\varepsilon, x, y}$ 。

返回 $M_\varepsilon^* = \int \mathcal{R}^{\varepsilon, x, y} d\pi_\varepsilon^*(x, y)$ 。




图 7.9: 提升到布朗桥的端点耦合。每个面板把集中在中心附近的六个等权红色原子传输到分布在周围的六个蓝色原子。对于所显示的 ε 值, 端点耦合要么是精确二次最优传输计划 ($\varepsilon = 0$), 要么是熵 Sinkhorn 计划 ($\varepsilon > 0$)。通过概率为 π_{ij} 的多项分配总共采样 60 条路径, 并且每个被选中的配对 (x_i, y_j) 都由协方差正比于 $\varepsilon t(1-t)$ 的布朗桥填充。颜色编码从红到蓝的时间。

定义 7.12 (互信息). 若 $(X, Y) \sim \pi$ 具有边缘 $X \sim \alpha$ 和 $Y \sim \beta$, 则该配对的互信息为

$$\mathcal{I}(X, Y) := \text{KL}(\pi | \alpha \otimes \beta).$$

它非负, 并且当且仅当 X 与 Y 独立时为零。

用这个术语, 熵问题 (7.11) 等价于

$$\inf_{X \sim \alpha, Y \sim \beta} \mathbb{E}(c(X, Y)) + \varepsilon \mathcal{I}(X, Y).$$

因此, 大的 ε 偏好近似独立的端点, 而小的 ε 抑制端点随机性, 并在极限中恢复一个最优 Monge–Kantorovich 耦合。当未正则化二次问题具有 Brenier 映射时, 这个极限耦合是确定性的。

7.6 Sinkhorn 的对偶

对偶观点用势和软 c -变换替代耦合。它是稳定化实现与微分的合适形式。

离散对偶。 下面的命题详细说明与 KL 归一化形式 (7.7) 关联的对偶问题。这个形式与 (7.1) 具有相同的极小化子；其最优值被常数 $\varepsilon H(a) + \varepsilon H(b)$ 平移。

命题 7.13 (熵最优传输的对偶). (7.7) 的最优值为

$$\min_{P \in U(a,b)} \langle P, C \rangle + \varepsilon \text{KL}(P|a \otimes b) = \max_{f \in \mathbb{R}^n, g \in \mathbb{R}^m} \langle f, a \rangle + \langle g, b \rangle - \varepsilon \sum_{i,j} \exp\left(\frac{f_i + g_j - C_{i,j}}{\varepsilon}\right) a_i b_j + \varepsilon. \quad (7.19)$$

最优 (f, g) 与 (7.2) 中出现的缩放 (u, v) 通过下式相连：

$$u_i = a_i e^{f_i/\varepsilon} \quad \text{and} \quad v_j = b_j e^{g_j/\varepsilon}. \quad (7.20)$$

证明. 引入 Lagrange 乘子并考虑

$$\min_{P \geq 0} \max_{f, g} \langle C, P \rangle + \varepsilon \text{KL}(P|a \otimes b) + \langle a - P\mathbf{1}, f \rangle + \langle b - P^\top \mathbf{1}, g \rangle.$$

有限维凸对偶允许交换关于 P 的最小化和关于 (f, g) 的最大化，得到

$$\max_{f, g} \langle f, a \rangle + \langle g, b \rangle + \varepsilon \min_{P \geq 0} \left(\text{KL}(P|a \otimes b) - \left\langle \frac{f \oplus g - C}{\varepsilon}, P \right\rangle \right) = \langle f, a \rangle + \langle g, b \rangle - \varepsilon \text{KL}^* \left(\frac{f \oplus g - C}{\varepsilon} | a \otimes b \right).$$

使用 $\varphi(r) = r \log(r) - r + 1$ 对应的 (6.13) 即可完成证明：

$$\text{KL}^*(H|a \otimes b) = \sum_{i,j} \varphi^*(H_{i,j}) a_i b_j.$$

事实上，标量最大化

$$\varphi^*(s) = \sup_{r \geq 0} \{rs - r \log r + r - 1\}$$

具有一阶条件 $s - \log r = 0$ ，因此 $r = e^s$ 且 $\varphi^*(s) = e^s - 1$ 。 $\square$

离散软 c -变换。 由于对偶问题 (7.19) 是光滑且凹的，可以执行交替块最大化。对固定的 g ，关于 f 最大化，并令关于 f 的导数为零，会得到下列方程：

$$a_i - e^{\frac{f_i}{\varepsilon}} a_i \sum_j \exp\left(\frac{g_j - C_{i,j}}{\varepsilon}\right) b_j = 0$$

这给出显式解

$$f_i = -\varepsilon \log \sum_j \exp\left(\frac{g_j - C_{i,j}}{\varepsilon}\right) b_j.$$

log-sum-exp 形式最好理解为光滑化最小值。这给出硬 c -变换的熵类比。

定义 7.14 (软最小值与离散软 c -变换). 对于 $h \in \mathbb{R}^m$ 和权重 $b \in \Sigma_m$ ，温度 $\varepsilon > 0$ 下的加权软最小值为

$$\min_b^\varepsilon(h) := -\varepsilon \log \sum_j e^{-h_j/\varepsilon} b_j.$$

当 $\varepsilon \rightarrow 0$ 时，它收敛到 $\min_j h_j$ 。给定成本矩阵 C ，离散软 c -变换为

$$f_i = \min_b^\varepsilon(C_{i,\cdot} - g) \quad (7.21)$$

以及

$$g_j = \min_a^\varepsilon(C_{\cdot,j} - f). \quad (7.22)$$

对这些迭代取指数，正好恢复 Sinkhorn 算法。不过，当 ε 很小时，这些迭代会变得不稳定。要在这个区域应用该算法，需要使用著名的 log-sum-exp 技巧来稳定它。这来自注意到，与最小值算子类似，有

$$\min_b^\varepsilon(h - \text{常数}) = \min_b^\varepsilon(h) - \text{常数}$$

并把 $\min_b^\varepsilon(h)$ 的计算替换为其稳定化版本（在无限精度计算下相等） $\min_b^\varepsilon(h - \min(h)) + \min(h)$ 。

算法 7.3 通过软变换实现的对数域 Sinkhorn

输入: 权重 a, b , 成本矩阵 C , 正则化 $\varepsilon > 0$, 容差 tol .

输出: 由稳定化势计算出的熵耦合 P .

初始化: 令 $g^{(0)} = 0, \eta_0 = +\infty$, 且 $k = 0$.

当 $\eta_k > \text{tol}$ 时执行:

 令 $k \leftarrow k + 1$.

 计算稳定化软变换: $f_i^{(k)} = -\varepsilon \log \sum_j \exp\left(\frac{g_j^{(k-1)} - C_{ij}}{\varepsilon}\right) b_j$.

 计算稳定化反向软变换: $g_j^{(k)} = -\varepsilon \log \sum_i \exp\left(\frac{f_i^{(k)} - C_{ij}}{\varepsilon}\right) a_i$.

 令 $\eta_k = \max\{\|f^{(k)} - f^{(k-1)}\|_\infty, \|g^{(k)} - g^{(k-1)}\|_\infty\}$, 其中当 $k = 1$ 时忽略第一项.

返回 $P_{ij} = a_i b_j \exp\left(\frac{f_i^{(k)} + g_j^{(k)} - C_{ij}}{\varepsilon}\right)$.




图 7.10: 温度递减时的软 c -变换。硬变换是平移成本函数的下包络, 而正的 ε 会用 $\log\text{-sum-exp}$ 软最小值替代逐点最小值。随着 ε 减小, 软变换变得尖锐, 并接近非光滑的硬包络。

连续对偶与软变换。 对于一般的、不一定离散的测度 (α, β) , KL 正则化问题 (7.11) 具有凹对偶

$$\mathcal{L}_c^\varepsilon(\alpha, \beta) = \sup_{f \in \mathcal{C}(\mathcal{X}), g \in \mathcal{C}(\mathcal{Y})} \mathcal{D}_\varepsilon(f, g), \quad (7.23)$$

其中

$$\mathcal{D}_\varepsilon(f, g) := \int_{\mathcal{X}} f(x) d\alpha(x) + \int_{\mathcal{Y}} g(y) d\beta(y) - \varepsilon \int_{\mathcal{X} \times \mathcal{Y}} \left(e^{\frac{f(x) + g(y) - c(x, y)}{\varepsilon}} - 1 \right) d\alpha(x) d\beta(y). \quad (7.24)$$

这是 Kantorovich 对偶中硬可行性约束 $f \oplus g \leq c$ 的光滑对应物: 违背项会受到指数惩罚, 并在极限 $\varepsilon \rightarrow 0$ 中消失。

相应的软 c -变换是该对偶目标的精确块最大化子。它们是定义 7.14 的连续对数积分对应物。

定义 7.15 (连续软 c -变换). 对 $f \in \mathcal{C}(\mathcal{X})$ 和 $g \in \mathcal{C}(\mathcal{Y})$, 定义

$$f^{c, \varepsilon}(y) := -\varepsilon \log \left(\int_{\mathcal{X}} e^{\frac{f(x) - c(x, y)}{\varepsilon}} d\alpha(x) \right), \quad y \in \mathcal{Y}, \quad (7.25)$$

$$g^{\bar{c}, \varepsilon}(x) := -\varepsilon \log \left(\int_{\mathcal{Y}} e^{\frac{g(y) - c(x, y)}{\varepsilon}} d\beta(y) \right), \quad x \in \mathcal{X}. \quad (7.26)$$

在离散测度情形中, 这些公式化为 (7.21) 和 (7.22)。同样的计算也给出熵半离散问题: 当一个测度离散时, 在有限维势和积分软变换之间交替, 后者通常以随机方式估计。

命题 7.16 (熵对偶势的存在性与唯一性). 假设 $\mathcal{X}$ 和 $\mathcal{Y}$ 紧, 且 c 连续。对偶问题 (7.23) 有解, 并且解集具有如下形式:

$$(f^* + \lambda, g^* - \lambda), \quad \lambda \in \mathbb{R}.$$

证明. 通过施加 $\int f d\alpha = 0$ 来归一化势。用相应的软 c -变换替换任意一对 (f, g) 不会降低对偶目标, 因为每个软变换都是一个块变量中的精确最大化子。对于变换后的势, 其振幅由成本的振幅控制:

$$\|f\|_V + \|g\|_V \leq 2(\sup c - \inf c).$$

此外, 软变换的连续模由 c 的连续模控制; 例如

$$|g^{\bar{c}, \varepsilon}(x) - g^{\bar{c}, \varepsilon}(x')| \leq \sup_y |c(x, y) - c(x', y)|.$$

因此, 归一化之后, 最大化序列一致有界且等度连续. Arzelà–Ascoli 定理给出一致收敛子序列, 而 (7.24) 的连续性给出一个最大化子。

对于唯一性, 使用

$$H \mapsto \int e^{H/\varepsilon} d(\alpha \otimes \beta)$$

在映射 $(f, g) \mapsto H = f \oplus g - c$ 的像上模去常数后的严格凸性。若存在两个最优对, 则它们的中点也最优; 严格凸性迫使两个函数 $f \oplus g$ 在 $\alpha \otimes \beta$ -几乎处处相等。由于势在紧支撑上连续, 这意味着 $f - f'$ 是常数, 而 $g - g'$ 是相反的常数。□

注 7.17 (软变换的凸性性质). $\log\text{-sum-exp}$ 部分表现得像光滑化最大值, 并保持凸性。由于软变换是在插入成本之后取该量的相反数, 它保持通常的 c -凹结构。特别地, 对于双线性成本 $c(x, y) = -\langle x, y \rangle$, 对任意 f , 变换 $f^{c, \varepsilon}$ 都是凹的。因此, 对于二次成本 $c(x, y) = \|x - y\|^2/2$, 最优势具有形式 $f^*(x) = \|x\|^2/2 - \varphi^*(x)$ 和 $g^*(y) = \|y\|^2/2 - \psi^*(y)$, 其中 φ^* 与 ψ^* 是凸函数。

注 7.18 (高斯边缘). 对于 $c(x, y) = \|x - y\|^2$ 和高斯边缘, 软变换保持二次函数, 因为高斯函数的乘积和卷积仍然是高斯函数。因此, 最优熵势是二次的, 最优熵耦合是高斯的。第 8.5 节会明确给出这种有限维闭包性。

7.7 其他凸正则化项

KL 正则化是导向乘性 Sinkhorn 缩放的情形。用另一种密度比惩罚替代 KL 散度, 会保留相同的传输约束, 但改变把最优密度连接到对偶势的标量规律。

令 φ 为定义 6.13 意义下的熵函数, 并回顾定义 6.14 中的 φ -散度 $\mathcal{D}_\varphi$ 。对 $\varepsilon > 0$, 定义 φ -正则化传输值

$$\mathcal{L}_{c, \varphi}^\varepsilon(\alpha, \beta) := \min_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y) + \varepsilon \mathcal{D}_\varphi(\pi | \alpha \otimes \beta). \quad (7.27)$$

命题 7.19 (φ -正则化最优传输的对偶与密度规律). 在通常的 *Fenchel–Rockafellar* 约束资格假设下, 例如空间紧、 c 连续且 (7.27) 中的值有限时, 有

$$\mathcal{L}_{c, \varphi}^\varepsilon(\alpha, \beta) = \sup_{f \in \mathcal{C}(\mathcal{X}), g \in \mathcal{C}(\mathcal{Y})} \int f d\alpha + \int g d\beta - \varepsilon \int \varphi^{*, \geq 0} \left(\frac{f(x) + g(y) - c(x, y)}{\varepsilon} \right) d\alpha(x) d\beta(y). \quad (7.28)$$

若一个最优计划具有密度 $r^* = \frac{d\pi^*}{d(\alpha \otimes \beta)}$, 且最优势为 (f^*, g^*) , 则

$$\frac{f^*(x) + g^*(y) - c(x, y)}{\varepsilon} \in \partial \varphi(r^*(x, y)) \quad \alpha \otimes \beta\text{-a.e.}$$

在光滑内部, 这写作

$$r^*(x, y) = (\varphi')^{-1} \left(\frac{f^*(x) + g^*(y) - c(x, y)}{\varepsilon} \right).$$

证明. 为两个边缘约束引入对偶变量 (f, g) 。对固定的 (f, g) , 关于 π 的最小化给出

$$\int f d\alpha + \int g d\beta + \inf_{\pi \in \mathcal{M}_+(\mathcal{X} \times \mathcal{Y})} \left\{ \int (c - (f \oplus g)) d\pi + \varepsilon \mathcal{D}_\varphi(\pi | \alpha \otimes \beta) \right\}.$$

对凸泛函 $\mathcal{D}_\varphi(\cdot | \alpha \otimes \beta)$ 使用 Legendre 公式 (6.13), 下确界等于

$$-\varepsilon \int \varphi^{*, \geq 0} \left(\frac{f(x) + g(y) - c(x, y)}{\varepsilon} \right) d\alpha(x) d\beta(y),$$

这给出 (7.28)。Fenchel 不等式中的等号等价于次梯度包含

$$\frac{f^* \oplus g^* - c}{\varepsilon} \in \partial \varphi(r^*),$$

当 φ 可微且优化器位于其定义域内部时, 对 φ' 求逆就给出密度规律。□

对于 KL 熵 $\varphi(r) = r \log r - r + 1$, 有 $\varphi^*, \geq 0(s) = e^s - 1$. 在 (7.28) 中把该参数取为 Sinkhorn 温度 ε , 就会精确恢复连续 Sinkhorn 对偶 (7.24). 其他选择会用另一种标量传递函数替代指数规律:

$$\begin{aligned} \varphi(r) = r \log r - r + 1 &\Rightarrow r^* = e^s, \\ \varphi(r) = r - \log r - 1 &\Rightarrow r^* = (1 - s)^{-1} \quad (s < 1), \quad s := \frac{f^* \oplus g^* - c}{\varepsilon}, \\ \varphi(r) = \frac{1}{2}(r - 1)^2 &\Rightarrow r^* = (1 + s)_+, \end{aligned}$$




图 7.11: 密度比正则化项与耦合支撑。红色和蓝色侧边曲线是固定的一维高斯混合边缘。稠密的紫色等值线用共同尺度显示耦合密度的平方根, 使用较小的正则化强度 $\varepsilon = .06$. KL 正则化给出通常的弥散正计划, Burg 障碍保持正但尾部不同的支撑, 而二次密度惩罚可以通过其正部规律把条目精确设为零。

Bregman 正则化与 φ -散度正则化。 前面的构造通过密度比散度来正则化最优传输。这不同于使用由测度空间上的凸泛函生成的 Bregman 散度。

定义 7.20 (测度 Bregman 散度). 若 Φ 是非负测度的某个凸类上的可微凸泛函, 且 ξ 是其定义域中的参考测度, 则由 Φ 生成的测度 Bregman 散度为

$$B_\Phi(\pi|\xi) := \Phi(\pi) - \Phi(\xi) - \int \delta\Phi(\xi)d(\pi - \xi), \quad (7.29)$$

其中 $\delta\Phi(\xi)$ 是一阶变分, 并且该公式在右侧有良好定义时理解。

在有限维中, 这化为定义 8.1. KL 散度是特殊的, 因为它同时是密度比散度和 Bregman 散度。

命题 7.21 (对偶比较: Bregman 惩罚与密度比惩罚). 固定边缘 α, β 并设 $\xi := \alpha \otimes \beta$. 令 Φ 为 $\mathcal{X} \times \mathcal{Y}$ 上非负测度的凸 Gateaux 可微泛函. 对于连续测试函数 u , 其凸共轭为

$$\Phi^*(u) := \sup_{\pi \geq 0} \left\{ \int u d\pi - \Phi(\pi) \right\}.$$

使用与密度比惩罚相同的乘积参考, 定义 Bregman 正则化值

$$\mathcal{L}_{c, \Phi}^\varepsilon(\alpha, \beta) := \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int c d\pi + \varepsilon B_\Phi(\pi|\xi).$$

假设 Fenchel 对偶对此约束问题是精确的; 这在有限维离散化中成立, 更一般地, 在标准紧性和下半连续性假设下也成立。则

$$\mathcal{L}_{c, \Phi}^\varepsilon(\alpha, \beta) = \sup_{f, g} \int f d\alpha + \int g d\beta - \varepsilon \left[\Phi^* \left(\delta\Phi(\xi) + \frac{f \oplus g - c}{\varepsilon} \right) - \Phi^*(\delta\Phi(\xi)) \right]. \quad (7.30)$$

若 (f^*, g^*) 与 π^* 最优且解位于内部, 则

$$\delta\Phi(\pi^*) = \delta\Phi(\xi) + \frac{f^* \oplus g^* - c}{\varepsilon}.$$

相比之下，密度比形式 (7.27) 具有标量积分对偶 (7.28) 以及逐点密度规律

$$\frac{f^* \oplus g^* - c}{\varepsilon} \in \partial \varphi \left(\frac{d\pi^*}{d(\alpha \otimes \beta)} \right).$$

证明. 使用 (7.29), Bregman 正则化目标可以在一个与 π 无关的常数意义下写作

$$\varepsilon \Phi(\pi) + \int (c - \varepsilon \delta \Phi(\xi)) d\pi - \varepsilon \Phi(\xi) + \varepsilon \int \delta \Phi(\xi) d\xi.$$

为两个边缘约束引入对偶势 (f, g) 。关于非负测度 π 的内层最小化给出

$$\inf_{\pi \geq 0} \left\{ \varepsilon \Phi(\pi) + \int (c - f \oplus g - \varepsilon \delta \Phi(\xi)) d\pi \right\} = -\varepsilon \Phi^* \left(\delta \Phi(\xi) + \frac{f \oplus g - c}{\varepsilon} \right).$$

ξ 处的 Fenchel 等式给出

$$-\Phi(\xi) + \int \delta \Phi(\xi) d\xi = \Phi^*(\delta \Phi(\xi)),$$

这得到 (7.30)。Fenchel 不等式中的等号给出 π^* 的最优性条件。密度比对偶和密度规律正是命题 7.19 中的内容。把两个公式并排放置，就能看到结构性差异：Bregman 正则化在对偶坐标 $\delta \Phi$ 中平移参考测度，而 φ -正则化则对相对于移动乘积参考 $\alpha \otimes \beta$ 的密度施加标量非线性。□

当 Φ 相对于固定支配测度 ξ_0 可分，例如在 $\xi \ll \xi_0$ 时 $\Phi(\pi) = \int h(d\pi/d\xi_0) d\xi_0$ ，Bregman 最优性条件变为

$$h' \left(\frac{d\pi^*}{d\xi_0} \right) = h' \left(\frac{d\xi}{d\xi_0} \right) + \frac{f^* \oplus g^* - c}{\varepsilon}.$$

这是熵坐标中的加性更新。密度比形式则使用相对于 $\alpha \otimes \beta$ 与 φ 关联的标量规律。这两种规律在 KL 熵下重合，此时 $h'(r) = \log r$ 会把加性对偶平移变成乘性缩放。下一个命题说明，在自然光滑性假设下，这是唯一的重合。

命题 7.22 (KL 是 Bregman 与 φ 的共同情形). 令 ω 为具有非平凡可测子集的有限参考测度。考虑概率测度 $\alpha = p\omega$ 和 $\beta = q\omega$ ，其密度有上界并且有正下界。假设 Φ 沿有界零质量密度扰动二次 Gateaux 可微，且 $\varphi \in C^2(0, +\infty)$ 为凸函数并满足 $\varphi(1) = 0$ 。若

$$B_\Phi(\alpha|\beta) = \mathcal{D}_\varphi(\alpha|\beta)$$

对所有这样的 α, β 都成立，则存在 $c \geq 0$ 和 $a \in \mathbb{R}$ ，使得

$$\varphi(t) = ct \log t + a(t - 1).$$

因此，共同散度是 $c \text{KL}(\alpha|\beta)$ ，并且 $\Phi(p\omega)$ 与 $c \int p \log p d\omega$ 只相差正概率单纯形上的一个仿射泛函。

证明. 固定 $\beta = q\omega$ ，并用 $\alpha_t = (q + th)\omega$ 扰动它，其中 h 有界， $\int h d\omega = 0$ ，且 t 足够小以保证 $q + th > 0$ 。在 $t = 0$ 处二次求导得到

$$D^2 \Phi(q)[h, h] = \varphi''(1) \int \frac{h^2}{q} d\omega.$$

事实上，左侧是 Bregman 误差的二阶变分，而

$$\mathcal{D}_\varphi(\alpha_t|\beta) = \int q \varphi(1 + th/q) d\omega$$

具有二阶导数 $\varphi''(1) \int h^2/q d\omega$ 。令 $c = \varphi''(1) \geq 0$ ，泛函 $\Psi(p\omega) = \Phi(p\omega) - c \int p \log p d\omega$ 沿正单纯形中的每条零质量线段具有零二阶变分。因此它在那里是仿射的，且 $B_\Psi = 0$ 。于是 $B_\Phi = c \text{KL}$ 。

还需要识别生成函数。由于 $\mathcal{D}_\varphi = c \text{KL}$ ，函数 $g(t) = \varphi(t) - ct \log t$ 生成零 φ -散度。取密度使得比值 p/q 取两个值 $x < 1 < y$ ，并选择权重使平均比值为 1，得到 $(y - 1)g(x) + (1 - x)g(y) = 0$ 。因此 $g(t)/(t - 1)$ 在 $(0, +\infty) \setminus \{1\}$ 上为常数，所以 $g(t) = a(t - 1)$ 。这证明了断言。□

因此，这两种推广会导向不同的对偶和不同的算法。由 $B_\Phi(\pi|\xi)$ 给出的 Bregman 正则化保留了第 8.1 节的投影几何：线性成本会在对偶坐标中倾斜参考，而交替边缘更新是 Bregman 投影。相反，密度比惩罚 $\mathcal{D}_\varphi(\pi|\alpha \otimes \beta)$ 给出 Fenchel 对偶 (7.28)，并且对内部解给出逐点规律 $r^* = (\varphi')^{-1}((f \oplus g - c)/\varepsilon)$ 。命题 7.21 在对偶层面明确了这一区别。Bregman 对偶包含全局共轭 Φ^* 和乘积参考 $\alpha \otimes \beta$ ，而 φ -对偶则把标量共轭对移动乘积测度 $\alpha \otimes \beta$ 积分。只有在 KL 情形下，这两个观点才重合，并化为乘性的 Sinkhorn 缩放。

7.8 Sinkhorn 散度

Sinkhorn 散度在保留光滑性的同时移除熵自偏差。它们在类似最优传输的几何与类似核的范数之间插值，这解释了它们的统计行为。

熵偏差。 Sinkhorn 问题 (7.11) 的值有一个主要问题，即 $\mathcal{L}_c^\varepsilon(\alpha, \beta) > 0$ 。特别地，

$$\alpha_\varepsilon = \operatorname{argmin}_{\beta} \mathcal{L}_c^\varepsilon(\alpha, \beta)$$

除非 $\varepsilon = 0$ ，否则不满足 $\alpha_\varepsilon = \alpha$ 。下面的命题说明，这种熵正则化诱导的偏差支配大的 ε 极限。

命题 7.23 (大温度熵偏差). 假设 c 有界且连续。则当 $\varepsilon \rightarrow +\infty$ 时， $\mathcal{L}_c^\varepsilon(\alpha, \beta) \rightarrow \iint c(x, y) d\alpha(x) d\beta(y)$ 。

证明. 令 $(f_\varepsilon, g_\varepsilon)$ 为最优对偶势，并按 $\int g_\varepsilon d\beta = 0$ 归一化。软 c -变换方程给出

$$f_\varepsilon(x) = -\varepsilon \log \int \exp\left(\frac{g_\varepsilon(y) - c(x, y)}{\varepsilon}\right) d\beta(y).$$

对有界 c ，归一化熵势的振幅由 c 的振幅一致地关于 ε 控制。因此 log-sum-exp 展开是一致的：

$$f_\varepsilon(x) = -\int (g_\varepsilon(y) - c(x, y)) d\beta(y) + O(\varepsilon^{-1}) = \int c(x, y) d\beta(y) + O(\varepsilon^{-1}).$$

在最优性处，对偶中的指数惩罚积分为零，因此

$$\mathcal{L}_c^\varepsilon(\alpha, \beta) = \int f_\varepsilon d\alpha + \int g_\varepsilon d\beta = \iint c(x, y) d\alpha(x) d\beta(y) + O(\varepsilon^{-1}).$$

这证明了该极限。 $\square$

所以在大的 ε 极限下， $\mathcal{L}_c^\varepsilon$ 表现得像内积，而不像范数。下面的特殊情形明确展示由此产生的吸引。

例 7.24 (二次成本的大温度坍塌). 由 α_ε 极小化的极限泛函关于第二个参数是线性的：

$$\beta \mapsto \int V_\alpha(y) d\beta(y), \quad V_\alpha(y) := \int c(x, y) d\alpha(x).$$

因此，任意极限极小化子都支撑在 $\operatorname{argmin} V_\alpha$ 上。当这个极小化子唯一时，

$$\alpha_\varepsilon \rightarrow \delta_{y^*(\alpha)}, \quad y^*(\alpha) = \operatorname{argmin}_y V_\alpha(y).$$

对于 $\mathbb{R}^d$ 上的二次成本 $c(x, y) = \|x - y\|^2$ ，若假设 α 具有有限二阶矩，则 $V_\alpha(y) = \|y - \int x d\alpha(x)\|^2 + \text{常数}$ ，所以坍塌会朝向位于 α 均值处的狄拉克质量。

Sinkhorn 散度。 原始熵最优传输值具有朝向乘积耦合的大温度吸引。标准去偏会减去两个自相互作用能量，其精神类似于从正核值转到关联的平方距离。

定义 7.25 (Sinkhorn 散度). 对 $\varepsilon > 0$ ，与熵最优传输值 $\mathcal{L}_c^\varepsilon$ 关联的去偏 Sinkhorn 散度为

$$\bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) := \mathcal{L}_c^\varepsilon(\alpha, \beta) - \frac{1}{2} \mathcal{L}_c^\varepsilon(\alpha, \alpha) - \frac{1}{2} \mathcal{L}_c^\varepsilon(\beta, \beta). \quad (7.31)$$

虽然这个公式是通过自成本进行去偏，但其非负性并不由定义自动得到；命题 7.29 下面通过核 Cauchy-Schwarz 论证证明这一点。

先记录一个基本引理：在最优对偶对处，指数正则化项积分为零，因此熵成本可以直接从势中读出。每次精确块更新之后，沿 Sinkhorn 迭代也有同样的抵消。

引理 7.26 (最优处的熵对偶成本). 令 $(f_{\alpha, \beta}, g_{\alpha, \beta})$ 为最优对偶势，任意归一化。则

$$\mathcal{L}_c^\varepsilon(\alpha, \beta) = \langle f_{\alpha, \beta}, \alpha \rangle + \langle g_{\alpha, \beta}, \beta \rangle. \quad (7.32)$$




图 7.12: 通过点优化可视化去偏效应。红色等值线显示固定的双高斯目标密度 β , 而蓝色原子是一个优化后的经验测度 α_n , 在所有面板中都以相同方式初始化。对小 ε , 熵成本 $\mathcal{L}_c^\varepsilon$ 和去偏 Sinkhorn 散度 $\bar{\mathcal{L}}_c^\varepsilon$ 都保留两个重叠模式。对大 ε , 最小化 $\mathcal{L}_c^\varepsilon$ 会使原子朝大温度偏差预测的重心坍缩, 而 (7.31) 中的自成本减法会保留双峰云。

证明. 首先注意, 在最优性处, 关系

$$f_{\alpha, \beta} = -\varepsilon \log \int_{\mathcal{Y}} e^{\frac{g_{\alpha, \beta}(y) - c(x, y)}{\varepsilon}} d\beta(y)$$

取指数之后, 等价地写作

$$1 = \int_{\mathcal{Y}} e^{\frac{f_{\alpha, \beta}(x) + g_{\alpha, \beta}(y) - c(x, y)}{\varepsilon}} d\beta(y) \implies \int_{\mathcal{X} \times \mathcal{Y}} \left(e^{\frac{f_{\alpha, \beta} \oplus g_{\alpha, \beta} - c}{\varepsilon}} - 1 \right) d(\alpha \otimes \beta) = 0.$$

把这个恒等式代入 (7.23) 即得结果。□

下一个命题记录这个去偏量的两个极限状态。

命题 7.27 (Sinkhorn 散度的渐近性). 假设两个测度支撑在同一空间上, 并且 c 有界、连续、非负且满足 $c(x, x) = 0$ 。则当 $\varepsilon \rightarrow 0$ 时, $\bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \rightarrow \mathcal{L}_c(\alpha, \beta)$, 且

$$\bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \rightarrow \frac{1}{2} \int -cd(\alpha - \beta) \otimes d(\alpha - \beta) \quad \text{when } \varepsilon \rightarrow +\infty.$$

证明. 上面的离散收敛结果已经给出正确直观; 现在使用标准连续论证。**情形** $\varepsilon \rightarrow 0$ 。第一个极限来自熵最优传输的标准 Γ -收敛论证: 熵项沿弱收敛耦合下半连续, 而任意有限成本耦合都可以由有限熵耦合逼近。由于 $c(x, x) = 0$, 去偏表达式中的两个自成本收敛到零, 交叉项收敛到 $\mathcal{L}_c(\alpha, \beta)$ 。

情形 $\varepsilon \rightarrow +\infty$ 。用 $(f_\varepsilon, g_\varepsilon)$ 表示最优对偶势。归一化它们并使用 c 的有界性后, 其振幅保持一致有界, 因此下列展开是一致的。 f_ε 上的最优性条件 (等价地, f_ε 上的 Sinkhorn 不动点) 写作

$$\begin{aligned} f_\varepsilon &= -\varepsilon \log \int \exp \left(\frac{g_\varepsilon(y) - c(\cdot, y)}{\varepsilon} \right) d\beta(y) = -\varepsilon \log \int \left(1 + \frac{g_\varepsilon(y) - c(\cdot, y)}{\varepsilon} + o(1/\varepsilon) \right) d\beta(y) \\ &= -\varepsilon \log \left(1 + \frac{1}{\varepsilon} \int (g_\varepsilon(y) - c(\cdot, y)) d\beta(y) + o(1/\varepsilon) \right) = - \int g_\varepsilon d\beta + \int c(\cdot, y) d\beta(y) + o(1). \end{aligned}$$

把这个关系代入对偶表达式 (7.32)

$$\mathcal{L}_c^\varepsilon(\alpha, \beta) = \int f_\varepsilon d\alpha + \int g_\varepsilon d\beta = \iint c(x, y) d\alpha(x) d\beta(y) + o(1).$$

把这个展开应用于 (α, β) 、 (α, α) 和 (β, β) , 得到

$$\bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \rightarrow \int c d\alpha \otimes d\beta - \frac{1}{2} \int c d\alpha \otimes d\alpha - \frac{1}{2} \int c d\beta \otimes d\beta = -\frac{1}{2} \int c d(\alpha - \beta) \otimes d(\alpha - \beta).$$

□

注 7.28 (大温度 Hilbert 极限). 若 $-c$ 定义条件正定核, 则命题 7.27 中的大温度极限是 Hilbert 核范数的平方。一个典型例子是 $0 < p < 2$ 时的 $c(x, y) = \|x - y\|^p$, 它对应于能量距离核。这个核范数是齐次 Sobolev 范数的对偶。

现在证明这个去偏 Sinkhorn 散度是正的。

命题 7.29 (Sinkhorn 散度的非负性). 若 $k(x, y) = e^{-c(x, y)/\varepsilon}$ 是正定的, 则 $\bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \geq 0$.

证明. 下文用 $(f_{\alpha, \beta}, g_{\alpha, \beta})$ 表示 α 与 β 之间对偶 Schrödinger 问题的最优对偶势。用 $f_{\alpha, \alpha} = g_{\alpha, \alpha}$ (由对称性可以假设二者相等) 表示 α 与自身之间问题的解。在对偶最大化问题中使用次优函数 $(f_{\alpha, \alpha}, g_{\beta, \beta})$, 并使用关系 (7.32) 得到对偶成本的简化表达式, 可得

$$\mathcal{L}_c^\varepsilon(\alpha, \beta) \geq \langle f_{\alpha, \alpha}, \alpha \rangle + \langle g_{\beta, \beta}, \beta \rangle - \varepsilon \langle e^{\frac{f_{\alpha, \alpha} \oplus g_{\beta, \beta} - c}{\varepsilon}} - 1, \alpha \otimes \beta \rangle$$

此外, $\langle f_{\alpha, \alpha}, \alpha \rangle = \frac{1}{2} \mathcal{L}_c^\varepsilon(\alpha, \alpha)$, 对 β 也类似, 因此前一不等式等价地写为

$$\frac{1}{\varepsilon} \bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \geq 1 - \langle e^{\frac{f_{\alpha, \alpha} \oplus g_{\beta, \beta} - c}{\varepsilon}}, \alpha \otimes \beta \rangle = 1 - \langle \tilde{\alpha}, \tilde{\beta} \rangle_k$$

其中 $\tilde{\alpha} = e^{f_{\alpha, \alpha}/\varepsilon} \alpha$, $\tilde{\beta} = e^{f_{\beta, \beta}/\varepsilon} \beta$, 并且我们引入了如下内积; 由于 k 正定, 这个内积有效: $\langle \tilde{\alpha}, \tilde{\beta} \rangle_k := \int k(x, y) d\tilde{\alpha}(x) d\tilde{\beta}(y)$. 自 Sinkhorn 不动点方程在取指数后逐点写作

$$e^{f_{\alpha, \alpha}(x)/\varepsilon} \int k(x, y) d\tilde{\alpha}(y) = 1 \quad \text{对 } \alpha\text{-几乎处处 } x,$$

因此

$$\|\tilde{\alpha}\|_k^2 = \langle k(\tilde{\alpha}), \tilde{\alpha} \rangle = \int e^{f_{\alpha, \alpha}(x)/\varepsilon} k(\tilde{\alpha})(x) d\alpha(x) = 1$$

并且类似地 $\|\tilde{\beta}\|_k^2 = 1$. 因此, 由 Cauchy-Schwarz, 有 $1 - \langle \tilde{\alpha}, \tilde{\beta} \rangle_k \geq 0$. □

注 7.30 (严格正性). 在对核施加额外假设后, 还可以证明 $\bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) = 0$ 蕴含 $\alpha = \beta$, 并且这个去偏散度量依分布收敛。

熵正则化：收敛性

熵正则化最优传输的收敛性有两种互补含义。在固定边缘分布和固定温度下，人们研究 Sinkhorn 迭代如何逼近正则化优化器；当边缘分布是经验测度时，人们还研究随着样本数趋向平均场极限，正则化取值与势如何表现。本章把这两个尺度放在一起讨论：先讨论矩阵缩放与软变换的算法收敛性，再讨论解释正则化统计作用的高斯闭式形式与样本复杂度后果。

本章的算法部分通过三个互补视角重新考察 Sinkhorn 收敛性。Bregman 投影解释交替投影几何，Fortet 的序论证给出定性的固定点收敛，稳健 Bregman 估计给出非渐近的 $O(1/k)$ 对偶间隙界，而 Hilbert 度量在核一致为正时给出简洁的线性收缩。第一个和最后一个视角解释收敛机制，而稳健估计通常最适合给出显式复杂度保证。

8.1 Sinkhorn 收敛性：Bregman 视角

本节把 Sinkhorn 解释为交替 Bregman 投影。核心信息是几何性的：每一次行缩放或列缩放都是到一个仿射边缘约束上的 KL 投影，因此收敛性来自 Bregman 散度的勾股恒等式。

为简单起见，本节按离散测度来写，但同样的思想可以推广到一般测度。后面的稳健速率一节将通过凸对偶重新考察交替投影机制，其中常数用势的振荡和代价范围的振荡来表示。

交替 KL 投影。 投影视角把 Sinkhorn 解释为每次重复施加一个边缘约束。它并非熵所特有，虽然 KL 情形正是投影化为基本行缩放与列缩放的情形。

定义 8.1 (Bregman 散度). 令 Φ 为凸域 Ω 上的可微严格凸函数。由 Φ 生成的 Bregman 散度为

$$B_{\Phi}(P|Q) := \Phi(P) - \Phi(Q) - \langle \nabla \Phi(Q), P - Q \rangle.$$

对于正正交象限上的负熵 $\Phi(P) = \sum_{i,j} P_{i,j} \log P_{i,j}$ ，在不影响结果的边界约定下，可得到 $B_{\Phi}(P|Q) = \text{KL}(P|Q)$ 。

Bregman 散度之所以有用，是因为它们的几何可以编码约束。Legendre 型生成元 Φ 在其定义域边界处发散，或者具有无穷导数。因此对于负熵，正性已经内置在散度中，所以投影到仿射边缘约束时无需单独处理非负性。

线性倾斜与 Gibbs 参考。 下一个命题解释了为什么向 Bregman 惩罚加入线性代价仅仅是在对偶坐标中平移参考点。通常的 Gibbs-KL 重写是其熵特例。

命题 8.2 (Bregman 惩罚的线性倾斜). 令 Φ 可微且严格凸，并令 B_{Φ} 为其 Bregman 散度。固定定义域内部的参考点 Q 。假设存在 Q^C 使得

$$\nabla \Phi(Q^C) = \nabla \Phi(Q) - C/\varepsilon.$$

则对于定义域中的所有 P ,

$$\langle P, C \rangle + \varepsilon B_{\Phi}(P|Q) = \varepsilon B_{\Phi}(P|Q^C) + \text{cst},$$

其中常数不依赖于 P 。

证明。 将两个 Bregman 散度相减：

$$B_{\Phi}(P|Q^C) - B_{\Phi}(P|Q) = \langle \nabla \Phi(Q) - \nabla \Phi(Q^C), P \rangle + \text{cst}.$$

利用 $\nabla \Phi(Q) - \nabla \Phi(Q^C) = C/\varepsilon$ 并乘以 ε 即得结论。 $\square$

对于负熵 $\Phi(P) = \sum_{i,j} P_{i,j} \log P_{i,j}$ ，有 $B_{\Phi} = \text{KL}$ 。取 $Q = a \otimes b$ 给出倾斜参考

$$K_{a,b}^{\varepsilon} := (a \otimes b) \odot e^{-C/\varepsilon}.$$

因此

$$\langle P, C \rangle + \varepsilon \text{KL}(P|a \otimes b) = \varepsilon \text{KL}(P|K_{a,b}^\varepsilon) + \text{cst}.$$

在传输多面体上, 缩放 $K_{a,b}^\varepsilon$ 等价于缩放 Gibbs 核 $K = e^{-C/\varepsilon}$, 因为因子 a_i 和 b_j 可以被吸收到 Sinkhorn 缩放中。

因此, (7.1) 的唯一解 P_ε 是倾斜 Gibbs 参考到 $U(a, b)$ 上的 KL 投影:

$$P_\varepsilon = \text{Proj}_{U(a,b)}^{\text{KL}}(K_{a,b}^\varepsilon) := \underset{P \in U(a,b)}{\text{argmin}} \text{KL}(P|K_{a,b}^\varepsilon). \quad (8.1)$$

循环投影收敛。 其收敛机制是 Bregman 的经典机制 [42]。

命题 8.3 (仿射约束上的循环 Bregman 投影). 令 Φ 为有限维凸域上的 Legendre 严格凸生成元, 并令 C_1, C_2 为交集与该定义域相交的仿射约束集。定义

$$P_{k+1} = \text{Proj}_{C_2}^{B_\Phi} \text{Proj}_{C_1}^{B_\Phi}(P_k),$$

从内部点 P_0 出发。假设投影良定义, 并且迭代点保持在定义域的一个紧子集内。则 P_k 收敛到 P_0 到 $C_1 \cap C_2$ 上的 Bregman 投影。特别地, 对于有界传输多面体上的正仿射边缘约束, KL 情形收敛。

证明. 我们先证明投影论证所用的勾股恒等式。对于三个内部点, 有 Bregman 三点公式

$$B_\Phi(Q|P) = B_\Phi(Q|P^+) + B_\Phi(P^+|P) + \langle \nabla \Phi(P^+) - \nabla \Phi(P), Q - P^+ \rangle.$$

若 $P^+ = \text{Proj}_C^{B_\Phi}(P)$ 且 C 为仿射集, 则在 $R \in C$ 上最小化 $R \mapsto B_\Phi(R|P)$ 的一阶最优性条件为

$$\langle \nabla \Phi(P^+) - \nabla \Phi(P), R - P^+ \rangle = 0 \quad \forall R \in C,$$

因为 $R - P^+$ 遍历 C 的切线性空间。取 $R = Q \in C$ 会抵消最后一项, 并给出

$$B_\Phi(Q|P) = B_\Phi(Q|P^+) + B_\Phi(P^+|P) \quad \forall Q \in C.$$

令 $(Z_\ell)_\ell$ 为通过交替投影到 C_1 和 C_2 得到的半步序列, 使得 $Z_{2k} = P_k$ 且 $Z_{2k+2} = P_{k+1}$ 。固定 $Q \in C_1 \cap C_2$ 。在每个半步应用该恒等式得到

$$B_\Phi(Q|Z_\ell) - B_\Phi(Q|Z_{\ell+1}) = B_\Phi(Z_{\ell+1}|Z_\ell) \geq 0.$$

因此 $B_\Phi(Q|Z_\ell)$ 递减, 级数 $\sum_\ell B_\Phi(Z_{\ell+1}|Z_\ell)$ 有限。紧性假设给出聚点。由于投影下降趋于零, 并且 Φ 在定义域的紧子集上严格凸, 故 $\|Z_{\ell+1} - Z_\ell\| \rightarrow 0$ 。因此偶子序列的每个聚点也是相邻奇子序列的聚点。由于这两个子序列交替位于闭仿射集 C_1 和 C_2 中, 每个聚点都属于 $C_1 \cap C_2$ 。

令 $\bar{P}$ 为这样一个聚点。对每个半步, 对偶位移

$$\nabla \Phi(Z_{\ell+1}) - \nabla \Phi(Z_\ell)$$

属于所投影仿射集的法空间。望远镜求和并利用 Z_ℓ 的收敛得到

$$\nabla \Phi(\bar{P}) - \nabla \Phi(P_0) \in N_{C_1} + N_{C_2} = N_{C_1 \cap C_2},$$

其中最后一个等式用到了这些集合是仿射的。这正是在 $R \in C_1 \cap C_2$ 上最小化 $R \mapsto B_\Phi(R|P_0)$ 的一阶最优性条件。因此 $\bar{P}$ 是 P_0 到交集上的 Bregman 投影。严格凸性给出该极小元的唯一性, 所以所有聚点一致, 整个序列收敛。KL 结论由选择负熵生成元得到。□

记

$$C_a^1 := \{P; P\mathbf{1}_m = a\} \quad \text{and} \quad C_b^2 := \{P; P^\top \mathbf{1}_n = b\}$$

分别表示行约束和列约束, 则有 $U(a, b) = C_a^1 \cap C_b^2$ 。可以使用 KL, 或更一般地使用 Bregman, 迭代投影 [42, 198, 199]

$$P^{(\ell+1)} := \text{Proj}_{C_a^1}^{\text{KL}}(P^{(\ell)}) \quad \text{and} \quad P^{(\ell+2)} := \text{Proj}_{C_b^2}^{\text{KL}}(P^{(\ell+1)}). \quad (8.2)$$

由于集合 C_a^1 和 C_b^2 是仿射的, 命题 8.3 在 $P_0 = K_{a,b}^\varepsilon$ 下适用, 并说明其收敛到 (8.1) 的解。

算法 8.1 循环 Bregman 投影

输入： 约束集 C_1, C_2 , Bregman 散度 B_Φ , 内部点 P_0 , 约束缺陷 $\text{def}_{C_1}, \text{def}_{C_2}$, 容差 tol .

输出： 当交集可行时, 输出 $C_1 \cap C_2$ 中的点。

特化到熵最优传输, 如有需要: $C_1 = C_a^1, C_2 = C_b^2, B_\Phi = \text{KL}$.

初始化： 令 $r_0 = +\infty$ 且 $k = 0$.

当 $r_k > \text{tol}$ 时执行：

 令 $k \leftarrow k + 1$.

$P_{k-1/2} = \text{Proj}_{C_1}^{B_\Phi}(P_{k-1})$.

$P_k = \text{Proj}_{C_2}^{B_\Phi}(P_{k-1/2})$.

 令 $r_k = \max\{\text{def}_{C_1}(P_k), \text{def}_{C_2}(P_k)\}$.

返回 P_k .

行缩放与列缩放。 这两个投影算子很容易计算, 因为它们分别对应于缩放行和缩放列, 如下一个命题所说明。

命题 8.4 (KL 投影即缩放). 有

$$\text{Proj}_{C_a^1}^{\text{KL}}(P) = \text{diag}\left(\frac{a}{P\mathbf{1}_m}\right)P \quad \text{and} \quad \text{Proj}_{C_b^2}^{\text{KL}}(P) = P \text{diag}\left(\frac{b}{P^\top \mathbf{1}_n}\right).$$

证明。 考虑沿每个行向量或列向量施加固定和 $s \in \mathbb{R}_+$ 的问题

$$\min_p \{ \text{KL}(p|q) ; \langle p, \mathbf{1} \rangle = s \}.$$

该问题的 Lagrange 乘子方程为

$$\log(p/q) + \lambda \mathbf{1} = 0 \implies p = uq \quad \text{where} \quad u = e^{-\lambda} > 0.$$

约束 $\langle p, \mathbf{1} \rangle = s$ 等价于 $\langle uq, \mathbf{1} \rangle = s$, 即 $u = s / \sum_i q_i$, 从而得到所需的缩放公式 $p = sq / \sum_i q_i$. $\square$

这些迭代等价于 Sinkhorn 迭代 (7.5), 因为定义

$$P^{(\ell)} := \text{diag}(u^{(\ell)})K \text{diag}(v^{(\ell)}),$$

one has

$$\begin{aligned} P^{(2\ell+1)} &:= \text{diag}(u^{(\ell+1)})K \text{diag}(v^{(\ell)}) \\ \text{and } P^{(2\ell+2)} &:= \text{diag}(u^{(\ell+1)})K \text{diag}(v^{(\ell+1)}) \end{aligned}$$

然而在实践中, 应优先使用 (7.5), 它只需要操作缩放向量并乘以 Gibbs 核; 当核具有可分、稀疏、低秩或几何结构时, 通常还能加速。

这种使用 Bregman 投影的收敛性分析兴趣有限, 因为它只能在有限维中直接工作。例如, 从强凸性得到的线性收敛速度会随维数和 ε 恶化。下面的稳健对偶分析给出一个不依赖维数的定性信息: 常数通过势的振荡和代价范围来表示, 所得 $O(1/k)$ 估计说明了在任何渐近线性阶段显现之前可以保证什么。也可以在迭代过程中退火 ε , 并在低维中依赖多尺度策略。

8.2 Sinkhorn 收敛性：单调视角

还有一种更早的理解收敛性的方式, 可追溯到 Fortet 对 Schrödinger 系统的证明 [91, 89, 144]。它并不主要估计收缩因子, 而是利用软变换的序结构。

命题 8.5 (通向 Sinkhorn 收敛性的单调固定点路径). 令 c 在紧空间上有界且连续, 并定义双重 Sinkhorn 映射, 通过减去其 α -均值进行归一化,

$$\mathcal{A}(f) := (f^{c,\varepsilon})^{\bar{c},\varepsilon} - \int (f^{c,\varepsilon})^{\bar{c},\varepsilon} d\alpha.$$

映射 $\mathcal{A}$ 在模去加性常数的商空间上是保序的。若选择初始等价类的一个代表, 使得 $f_0 \leq \mathcal{A}(f_0)$, 则可选择迭代 $f_{k+1} = \mathcal{A}(f_k)$ 的代表, 使其逐点递增、振荡一致有界, 并收敛到一个固定点。由于常数可以自由选择, 任意有界初始化都可以向下平移以满足子解不等式。该固定点就是熵势, 因此相应的 Sinkhorn 缩放收敛。

证明. 软 c -变换是反序的: 若 $g \leq g'$, 则

$$-\varepsilon \log \int e^{(g-c)/\varepsilon} d\beta \geq -\varepsilon \log \int e^{(g'-c)/\varepsilon} d\beta.$$

因此两个反序变换的复合是保序的。该变换还在射影意义下与加性常数相容, 这就是该论证自然地表述为模去常数的等价类的原因。从子解代表出发给出 $f_0 \leq f_1$, 而保序性给出满足对所有 k 都有 $f_k \leq f_{k+1}$ 的代表。由 $\sup c - \inf c$ 控制的软变换振荡界防止归一化后逃向无穷。单调逐点收敛、等度连续软变换的紧性以及 $\mathcal{A}$ 的连续性随后给出固定点。命题 7.2 和上面的对偶唯一性陈述表明, 在相差常数意义下熵势唯一, 从而将该固定点识别为 Sinkhorn 解。□

这个证明是定性的而非定量的, 但在概念上很有用: Sinkhorn 不只是交替投影或射影收缩; 一旦模去常数, 它也是势等价类上的单调固定点迭代。

定义 8.6 (变差半范数). 对于有界实值函数 h , 变差半范数为

$$\|h\|_V := \sup h - \inf h.$$

它恰好在常数函数上为零, 因此在模去加性常数后成为范数。

这是 Sinkhorn 势的自然大小, 因为加入常数会改变它们的规范, 但不会改变耦合。

命题 8.7 (Topical 映射关于变差非扩张). 令 E 为逐点有序的实值有界函数向量空间, 并记 $\|\cdot\|_V$ 为定义 8.6 的变差半范数。令 $\mathcal{T}: E \rightarrow E$ 单调且加性齐次,

$$f \leq g \Rightarrow \mathcal{T}(f) \leq \mathcal{T}(g), \quad \mathcal{T}(f + \lambda) = \mathcal{T}(f) + \lambda \quad \forall \lambda \in \mathbb{R}.$$

则

$$\|\mathcal{T}(f) - \mathcal{T}(g)\|_V \leq \|f - g\|_V.$$

对于满足 $\mathcal{T}(f + \lambda) = \mathcal{T}(f) - \lambda$ 的反序映射, 同样结论也成立。

证明. 令 $a = \inf(f - g)$ 且 $b = \sup(f - g)$ 。则

$$g + a \leq f \leq g + b.$$

若 $\mathcal{T}$ 保序且加性齐次, 应用 $\mathcal{T}$ 得到

$$\mathcal{T}(g) + a \leq \mathcal{T}(f) \leq \mathcal{T}(g) + b.$$

因此 $\mathcal{T}(f) - \mathcal{T}(g)$ 的每个取值都落在 $[a, b]$ 中, 所以其振荡至多为 $b - a = \|f - g\|_V$ 。对于反序且加性反齐次的映射, 同样的不等式给出

$$\mathcal{T}(g) - b \leq \mathcal{T}(f) \leq \mathcal{T}(g) - a,$$

振荡界相同。□

推论 8.8 (软变换是非扩张的). 对每个 $\varepsilon > 0$, 软 c -变换 (7.25)–(7.26) 关于变差半范数都是 1-Lipschitz 的。因此, 命题 8.5 中使用的双重 Sinkhorn 映射在模去常数后也关于 $\|\cdot\|_V$ 为 1-Lipschitz。

证明. 软变换是反序的, 并满足 $(g + \lambda)^{\bar{c}, \varepsilon} = g^{\bar{c}, \varepsilon} - \lambda$, 另一个块也类似。命题 8.7 适用于每个块, 而两个 1-Lipschitz 映射的复合仍是 1-Lipschitz。□

注 8.9 (Topical 映射与射影几何). 保序加性齐次映射在非线性的 Perron–Frobenius 理论中称为 topical 映射 [141]。命题 8.7 是 Fortet 单调论证背后的基本非扩张机制。第 8.4 节的 Hilbert 度量分析更强: 在核严格为正的假设下, 它把非扩张提升为真正的射影收缩。

8.3 Sinkhorn 收敛性: 次线性稳健速率

Sinkhorn 是在 (7.24) 中定义的光滑对偶目标 $\mathcal{D}_\varepsilon$ 上的循环坐标上升; 等价地, 它在两个边缘约束集上交替进行 KL 投影。下面的陈述记录了对复杂度估计最有用的速率: 在任何可能的线性阶段显现之前, 对偶目标间隙以 $1/k$ 阶下降。我们针对平衡熵最优传输表述, 这是此处需要的特化情形。相关的稳健 Bregman 投影速率见 [183, 4, 84], 而熵平滑的统计后果见 [103, 30]。

命题 8.10 (Pinsker 不等式). 若 $p, q \in \Sigma_n$, 则

$$\|p - q\|_1^2 \leq 2 \text{KL}(p|q).$$

证明. 令 $A = \{i : p_i \geq q_i\}$, 并设 $a = \sum_{i \in A} p_i$, $b = \sum_{i \in A} q_i$. 则 $a - b = \frac{1}{2} \|p - q\|_1$. 将相对熵的数据处理不等式应用于划分 (A, A^c) 得到

$$\text{KL}(p|q) \geq a \log \frac{a}{b} + (1 - a) \log \frac{1 - a}{1 - b}.$$

对于固定的 $b \in (0, 1)$, 函数

$$h(a) = a \log \frac{a}{b} + (1 - a) \log \frac{1 - a}{1 - b} - 2(a - b)^2$$

满足 $h(b) = h'(b) = 0$ 且

$$h''(a) = \frac{1}{a} + \frac{1}{1 - a} - 4 \geq 0,$$

因为 $a(1 - a) \leq 1/4$. 因此二元相对熵至少为 $2(a - b)^2 = \frac{1}{2} \|p - q\|_1^2$. 边界情形由逼近得到. $\square$

命题 8.11 (一个紧致的 $O(1/k)$ 对偶速率). 假设 $\mathcal{X}$ 和 $\mathcal{Y}$ 紧, c 有界, 并记 $R = \sup c - \inf c$. 令 (f_k, g_k) 为由 $\int f_k d\alpha = 0$ 归一化的 Sinkhorn 对偶迭代, 并令

$$\Delta_k := \mathcal{D}_\varepsilon(f^*, g^*) - \mathcal{D}_\varepsilon(f_k, g_k)$$

为熵对偶目标 (7.24) 的对偶次优间隙. 则存在数值常数 C 使得

$$\Delta_k \leq \frac{CR^2}{\varepsilon(k+1)}.$$

证明. 证明使用三个基本成分. 首先, 软 c -变换界定每个归一化迭代点和每个归一化最优解的振荡:

$$\|f_k\|_V + \|g_k\|_V + \|f^*\|_V + \|g^*\|_V \leq CR.$$

这里 $\|h\|_V := \sup h - \inf h$ 是变差半范数, 也就是第 8.4 节 Hilbert 度量中使用的同一射影范数. 它是自然的, 因为对偶势可以平移常数而不改变耦合.

其次, 每个 Sinkhorn 半步都是精确 KL 投影. KL 投影的勾股恒等式给出上升恒等式

$$\mathcal{D}_\varepsilon(f_{k+1}, g_{k+1}) - \mathcal{D}_\varepsilon(f_k, g_k) = \varepsilon [\text{KL}(\pi^* | \pi_k) - \text{KL}(\pi^* | \pi_{k+1})],$$

其中 $\pi_k = e^{(f_k \oplus g_k - c)/\varepsilon} \alpha \otimes \beta$, π^* 是最优熵耦合. KL 下降通过命题 8.10 的 Pinsker 不等式控制边缘残差. 第三, 指数型对偶目标的凸性给出如下形式的一步估计

$$\Delta_k^2 \leq \frac{CR^2}{\varepsilon} (\mathcal{D}_\varepsilon(f_{k+1}, g_{k+1}) - \mathcal{D}_\varepsilon(f_k, g_k)).$$

这是通常的 Bregman 投影估计: 对偶间隙由有界对偶半径与经下一次投影修正的边缘残差的乘积控制, 而残差平方由 KL 下降控制. 对从最后一个展示式得到的倒数不等式求和, 得到

$$\frac{1}{\Delta_{k+1}} - \frac{1}{\Delta_k} \geq \frac{\varepsilon}{CR^2},$$

因此 $\Delta_k \leq CR^2/(\varepsilon(k+1))$. $\square$

推论 8.12 (用正则化对偶代价近似未正则化最优传输). 考虑离散直方图 $a \in \Sigma_n$, $b \in \Sigma_m$ 以及有限代价矩阵 C . 令 $\mathcal{D}_{\varepsilon,k}$ 为 k 个 Sinkhorn 周期之后经 KL 归一化的熵对偶值, 并令 Δ_k 为其对偶间隙. 定义熵校正下界

$$L_{\varepsilon,k} := \mathcal{D}_{\varepsilon,k} - \varepsilon H(a) - \varepsilon H(b), \quad H(a) = - \sum_i a_i \log a_i.$$

则

$$0 \leq L_C(a, b) - L_{\varepsilon,k} \leq \varepsilon \log(nm) + \Delta_k.$$

因此, 选择 $\varepsilon \leq \delta/(2 \log(nm))$ 并运行 Sinkhorn 直到 $\Delta_k \leq \delta/2$, 即可得到未正则化最优传输取值的一个 δ -精确下界. 在命题 8.11 下, 中间条件为 $k+1 \geq 2CR^2/(\varepsilon\delta)$. 采用上述 ε 选择时, 取

$$k+1 \geq \frac{4CR^2 \log(nm)}{\delta^2},$$

即可, 因此在常数和対数稳定化因子意义下, $k = O(R^2 \log(nm)/\delta^2)$.

证明. 经 KL 归一化的目标与熵约定 (7.1) 在传输多面体上相差常数 $\varepsilon H(a) + \varepsilon H(b)$, 因为

$$\text{KL}(P|a \otimes b) = -H(P) + H(a) + H(b).$$

令 E_ε 为熵正则化目标 $\langle P, C \rangle - \varepsilon H(P)$ 的最优值。由于对任意耦合矩阵都有 $0 \leq H(P) \leq \log(nm)$,

$$L_C(a, b) - \varepsilon \log(nm) \leq E_\varepsilon \leq L_C(a, b).$$

校正后的迭代满足 $L_{\varepsilon, k} = E_\varepsilon - \Delta_k$, 这给出展示的取值界。最后的迭代估计由将 $\Delta_k \leq CR^2/(\varepsilon(k+1))$ 与目标 $\Delta_k \leq \delta/2$ 结合得到。□

同一恒等式也给出可计算的停止诊断。KL 下降正是边缘缺陷：一次行更新之后，行边缘正确，剩余下降由列边缘测量；列更新之后反之。因此，边缘违背同时监控可行性和剩余对偶间隙，差别只在上面的有界半径常数。

算法 8.2 离散最优传输的有证书熵近似

输入： 代价矩阵 $C \in \mathbb{R}^{n \times m}$, 权重 a, b , 目标精度 $\delta > 0$ 。

输出： 精确最优传输的有证书下界 $L_{\varepsilon, k}$ 。

令 $\varepsilon = \frac{\delta}{2 \log(nm)}$ 。

初始化 稳定化 Sinkhorn 势, 并令 $k = 0$, $\hat{\Delta}_0 = +\infty$ 。

当 $\hat{\Delta}_k > \delta/2$ **时执行：**

 令 $k \leftarrow k + 1$ 。

计算 稳定化对数域变量中的一次行软变换更新和一次列软变换更新。

计算 熵对偶值 $\mathcal{D}_{\varepsilon, k}$ 和有证书的间隙上界 Δ_k 。

返回 $L_{\varepsilon, k} = \mathcal{D}_{\varepsilon, k} - \varepsilon H(a) - \varepsilon H(b)$, $0 \leq L_C(a, b) - L_{\varepsilon, k} \leq \delta$ 。

8.4 Sinkhorn 收敛性：Hilbert 度量线性速率

Hilbert 射影度量给出一个互补的收敛机制。它不跟踪目标值，而是度量正缩放向量在模去全局乘法后的距离。正核在这种几何中是收缩映射，从而给出全局线性收敛陈述。

如 [93] 最初解释的，使用正向量上的 Hilbert 射影度量可以大大简化 Sinkhorn 的全局收敛分析。

定义 8.13 (Hilbert 度量). 在 $\mathbb{R}_{+,*}^n$ 上, Hilbert 射影度量为

$$\forall (u, u') \in (\mathbb{R}_{+,*}^n)^2, \quad d_{\mathcal{H}}(u, u') := \|\log(u) - \log(u')\|_V. \quad (8.3)$$

其中对向量而言, $\|z\|_V = \max_i z_i - \min_i z_i$ 。

同时将两个向量乘以任意正常数不会改变该量，因此只有在传到射影类之后它才是距离。

命题 8.14 (射影锥上的 Hilbert 度量). 函数 $d_{\mathcal{H}}$ 在射影锥 $\mathbb{R}_{+,*}^n / \sim$ 上定义了一个完备距离，其中 $u \sim u'$ 表示对某个 $s > 0$ 有 $u = su'$ 。

证明. 映射 $u \mapsto \log u$ 将 $\mathbb{R}_{+,*}^n / \sim$ 识别为商向量空间 $\mathbb{R}^n / \text{Span}(\mathbf{1}_n)$, 因为把 u 乘以 $s > 0$ 会加上常向量 $\log(s)\mathbf{1}_n$. 变差半范数 $\|z\|_V = \max_i z_i - \min_i z_i$ 恰好在常向量上为零，因此它在该商空间上诱导出一个范数。对称性、三角不等式和分离性由相应的范数性质推出。完备性来自 $\mathbb{R}^n / \text{Span}(\mathbf{1}_n)$ 是有限维的，而所有有限维赋范空间都是完备的。□

它由 [32] 和 [200] 独立引入，用于给出 Perron-Frobenius 定理（正矩阵迭代的收敛性）的定量证明。Sinkhorn 应被看作 Perron-Frobenius 的非线性推广。

定理 8.15 (Birkhoff 收缩定理). 令 $K \in \mathbb{R}_{+,*}^{n \times m}$, 则对 $(v, v') \in (\mathbb{R}_{+,*}^m)^2$,

$$d_{\mathcal{H}}(Kv, Kv') \leq \lambda(K) d_{\mathcal{H}}(v, v') \quad \text{其中} \quad \begin{cases} \lambda(K) := \frac{\sqrt{\eta(K)} - 1}{\sqrt{\eta(K)} + 1} < 1 \\ \eta(K) := \max_{i,j,k,\ell} \frac{K_{i,k} K_{j,\ell}}{K_{j,k} K_{i,\ell}}. \end{cases}$$

证明. 回顾有限维 Birkhoff–Hopf 估计. 对于锥上的正线性映射 A , 定义其射影直径

$$\Delta(A) := \sup_{u,v>0} d_{\mathcal{H}}(Au, Av).$$

则

$$d_{\mathcal{H}}(Au, Av) \leq \tanh(\Delta(A)/4) d_{\mathcal{H}}(u, v).$$

事实上, 在模去正缩放后, 记 $r_k = u_k/v_k$, 并归一化使得 $e^{-h/2} \leq r_k \leq e^{h/2}$, 其中 $h = d_{\mathcal{H}}(u, v)$. Au/Av 的两个坐标之间的比值是这些数 r_k 的两个加权平均之商. 一个两点极值论证表明, 当两个权重的质量放在两个端点 $e^{-h/2}$ 和 $e^{h/2}$ 上时, 可能的收缩最大; 于是定义 $\Delta(A)$ 的交比界给出

$$d_{\mathcal{H}}(Au, Av) \leq 2 \log \frac{e^{\Delta(A)/4} e^{h/2} + e^{-\Delta(A)/4} e^{-h/2}}{e^{\Delta(A)/4} e^{-h/2} + e^{-\Delta(A)/4} e^{h/2}} \leq \tanh(\Delta(A)/4) h.$$

对于矩阵 K , 其射影直径为

$$\Delta(K) = \log \eta(K), \quad \eta(K) = \max_{i,j,k,\ell} \frac{K_{i,k} K_{j,\ell}}{K_{j,k} K_{i,\ell}}.$$

因此 $\tanh(\Delta(K)/4) = (\sqrt{\eta(K)} - 1)/(\sqrt{\eta(K)} + 1)$, 这正是所声称的收缩因子. $\square$

该结果可推广到任意凸锥以及从该锥到其内部的仿射映射。

下面来自 [93] 的定理使用定理 8.15 说明 Sinkhorn 迭代的线性收敛。

定理 8.16 (Sinkhorn 的线性收敛). 有 $(u^{(\ell)}, v^{(\ell)}) \rightarrow (u^*, v^*)$ 且

$$d_{\mathcal{H}}(u^{(\ell)}, u^*) = O(\lambda(K)^{2\ell}), \quad d_{\mathcal{H}}(v^{(\ell)}, v^*) = O(\lambda(K)^{2\ell}). \quad (8.4)$$

还具有

$$d_{\mathcal{H}}(u^{(\ell)}, u^*) \leq \frac{d_{\mathcal{H}}(P^{(\ell)} \mathbf{1}_m, \mathbf{a})}{1 - \lambda(K)} \quad \text{and} \quad d_{\mathcal{H}}(v^{(\ell)}, v^*) \leq \frac{d_{\mathcal{H}}(P^{(\ell), \top} \mathbf{1}_n, \mathbf{b})}{1 - \lambda(K)}, \quad (8.5)$$

其中记 $P^{(\ell)} := \text{diag}(u^{(\ell)}) K \text{diag}(v^{(\ell)})$. 最后, 有

$$\|\log(P^{(\ell)}) - \log(P^*)\|_{\infty} \leq d_{\mathcal{H}}(u^{(\ell)}, u^*) + d_{\mathcal{H}}(v^{(\ell)}, v^*) \quad (8.6)$$

其中 P^* 是 (7.1) 的唯一解。

证明. 注意, 对任意 $(v, v') \in (\mathbb{R}_{+,*}^m)^2$, 有

$$d_{\mathcal{H}}(v, v') = d_{\mathcal{H}}(v/v', \mathbf{1}_m) = d_{\mathcal{H}}(\mathbf{1}_m/v, \mathbf{1}_m/v'),$$

因为确实有 $d_{\mathcal{H}}(\mathbf{a}/v, \mathbf{a}/v') = d_{\mathcal{H}}(v, v')$. 这说明

$$d_{\mathcal{H}}(u^{(\ell+1)}, u^*) = d_{\mathcal{H}}\left(\frac{\mathbf{a}}{Kv^{(\ell)}}, \frac{\mathbf{a}}{Kv^*}\right) = d_{\mathcal{H}}(Kv^{(\ell)}, Kv^*) \leq \lambda(K) d_{\mathcal{H}}(v^{(\ell)}, v^*).$$

其中使用了定理 8.15. 这说明 (8.4). 利用三角不等式, 还得到

$$\begin{aligned} d_{\mathcal{H}}(u^{(\ell)}, u^*) &\leq d_{\mathcal{H}}(u^{(\ell+1)}, u^{(\ell)}) + d_{\mathcal{H}}(u^{(\ell+1)}, u^*) \leq d_{\mathcal{H}}\left(\frac{\mathbf{a}}{Kv^{(\ell)}}, u^{(\ell)}\right) + \lambda(K) d_{\mathcal{H}}(u^{(\ell)}, u^*) \\ &= d_{\mathcal{H}}\left(\mathbf{a}, u^{(\ell)} \odot (Kv^{(\ell)})\right) + \lambda(K) d_{\mathcal{H}}(u^{(\ell)}, u^*), \end{aligned}$$

这给出 (8.5) 的第一部分, 因为 $u^{(\ell)} \odot (Kv^{(\ell)}) = P^{(\ell)} \mathbf{1}_m$ (第二部分类似). (8.6) 的证明来自 [93, 引理 3]. $\square$

收缩的对偶势形式。 上面的 Hilbert 度量收缩也可以通过变差范数直接读作对偶势 (f, g) 上的收缩。对于有界代价 c (例如在紧空间上),

$$\|f_k - f^*\|_V = O(\lambda^k) \quad \text{and} \quad \|g_k - g^*\|_V = O(\lambda^k)$$

$$\left\| \log \frac{d\pi_k}{d\pi^*} \right\|_\infty = \|(f_k - f^*) \oplus (g_k - g^*)\|_\infty \leq \|f_k - f^*\|_V + \|g_k - g^*\|_V$$

其中收缩比是 Gibbs 核 $K_\varepsilon = e^{-c/\varepsilon}$ 的 Birkhoff 因子。也就是说, 令 $\eta = \eta(K_\varepsilon)$ 如定理 8.15 中所定义, 并令 $R := \sup c - \inf c$,

$$\lambda = \frac{\sqrt{\eta} - 1}{\sqrt{\eta} + 1} \leq \tanh(R/(2\varepsilon)) < 1.$$

还具有如下界

$$\|f_k - f^*\|_V \leq \frac{\left\| \log \frac{d\pi_{k,1}}{d\alpha} \right\|_\infty}{1 - \lambda}$$

它可用于给出收敛速率的后验估计, 并作为停止准则。

界 (8.5) 表明, 边缘约束违背上的一些误差度量, 例如 $\|P^{(\ell)} \mathbf{1}_m - \mathbf{a}\|_1$ 和 $\|P^{(\ell)\top} \mathbf{1}_n - \mathbf{b}\|_1$, 是监控收敛的有用停止准则。该定理说明 Sinkhorn 算法线性收敛, 但随着 $\varepsilon \rightarrow 0$, 最坏情形速率会指数恶化, 因为全局收缩因子由代价范围除以 ε 控制。在实践中, 经过足够多迭代后, 人们通常会观察到好得多的局部线性阶段。在适当的紧性与正性假设下, 同一个 Hilbert 度量机制可从有限矩阵推广到正积分算子。该分析的一个重要局限是它要求代价一致有界, 并且核远离退化; 因此带二次代价的高斯分布需要不同的方法。

8.5 高斯之间的熵最优传输

高斯边缘分布为 Sinkhorn 的行为提供了一个显式的有限维模型。软 c -变换保持二次势, 最优熵耦合是高斯的, 并且取值可以用矩阵平方根写出 [126]。这是命题 2.39 中高斯 $\mathcal{W}_2$ 公式的熵对应物。

命题 8.17 (Sinkhorn 迭代的二次闭合性). 令 $\beta = \mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta)$ 为 $\mathbb{R}^d$ 上的高斯, 并取 $c(x, y) = \|x - y\|^2$ 。若 $g(y)$ 是二次多项式, 且下面的高斯积分有限, 则软变换

$$f(x) = -\varepsilon \log \int \exp\left(\frac{g(y) - \|x - y\|^2}{\varepsilon}\right) d\beta(y)$$

是关于 x 的二次多项式。特别地, 从 $g_0 = 0$ 启动 Sinkhorn 给出

$$f_1(x) = \frac{\varepsilon}{2} \log \det\left(\text{Id} + \frac{2\Sigma_\beta}{\varepsilon}\right) + \varepsilon \langle x - \mathbf{m}_\beta, (\varepsilon \text{Id} + 2\Sigma_\beta)^{-1}(x - \mathbf{m}_\beta) \rangle.$$

证明. 指数是关于 y 的二次多项式与 β 的高斯密度对数之和。对 y 配方后, 该积分等于一个正常数乘以关于 x 的二次多项式的指数。因此取 $-\varepsilon \log$ 给出二次多项式。

当 $g_0 = 0$ 时, 令 $Y \sim \beta$ 。高斯恒等式

$$\mathbb{E} \exp\left(-\frac{\|x - Y\|^2}{\varepsilon}\right) = \det\left(\text{Id} + \frac{2\Sigma_\beta}{\varepsilon}\right)^{-1/2} \exp(-\langle x - \mathbf{m}_\beta, (\varepsilon \text{Id} + 2\Sigma_\beta)^{-1}(x - \mathbf{m}_\beta) \rangle)$$

给出所展示的表达式。 $\square$

命题 8.18 (高斯之间的平衡熵最优传输). 令 $\alpha = \mathcal{N}(\mathbf{m}_\alpha, \Sigma_\alpha)$ 和 $\beta = \mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta)$ 具有正定协方差, 并令

$$\Sigma_\alpha^{1/2} \Sigma_\beta^{1/2} = U \text{diag}(\sigma_i) V^\top$$

为一个奇异值分解。对于平衡目标

$$\min_{\pi \in \mathcal{U}(\alpha, \beta)} \int \|x - y\|^2 d\pi(x, y) + \varepsilon \text{KL}(\pi | \alpha \otimes \beta),$$

优化器是具有如下交叉协方差的高斯

$$K_\varepsilon = \Sigma_\alpha^{1/2} U \text{diag}(s_i) V^\top \Sigma_\beta^{1/2}, \quad s_i = \frac{\sqrt{\varepsilon^2 + 16\sigma_i^2} - \varepsilon}{4\sigma_i}.$$

最优值为

$$\|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \text{tr}(\Sigma_\alpha) + \text{tr}(\Sigma_\beta) + \sum_i \left(-2\sigma_i s_i - \frac{\varepsilon}{2} \log(1 - s_i^2) \right).$$

当 $\varepsilon \downarrow 0$ 时, $s_i \rightarrow 1$, 并且包含两个迹项在内的完整协方差贡献收敛到 $\mathcal{B}(\Sigma_\alpha, \Sigma_\beta)^2$ 。

证明. 令 (X, Y) 为任意具有有限二阶矩和交叉协方差的耦合

$$K = \mathbb{E}[(X - \mathbf{m}_\alpha)(Y - \mathbf{m}_\beta)^\top].$$

用具有相同均值和协方差的高斯向量替换 (X, Y) 不会改变二次代价。由于边缘分布固定,

$$\text{KL}(\pi|\alpha \otimes \beta) = -h(X, Y) + h(\alpha) + h(\beta),$$

其中 h 在有限时表示微分熵。在具有固定协方差的概率律中, 高斯使熵最大; 若熵不是有限的, 则相对熵已经是 $+\infty$ 。因此高斯替换不会增加目标, 只需在高斯耦合上优化即可。

任意这样的耦合都具有协方差

$$\begin{pmatrix} \Sigma_\alpha & K \\ K^\top & \Sigma_\beta \end{pmatrix}.$$

写作 $K = \Sigma_\alpha^{1/2} S \Sigma_\beta^{1/2}$ 。块协方差约束等价于 S 的奇异值至多为一, 而有限熵强制它们严格小于一。代价通过下式依赖于 K

$$\|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \text{tr}(\Sigma_\alpha) + \text{tr}(\Sigma_\beta) - 2\text{tr}(K),$$

而

$$\text{KL}(\pi|\alpha \otimes \beta) = -\frac{1}{2} \log \det(\text{Id} - SS^\top).$$

由 von Neumann 迹不等式, 极小元将 S 与 $\Sigma_\alpha^{1/2} \Sigma_\beta^{1/2}$ 的奇异向量对齐, 因此 $S = U \text{diag}(s_i) V^\top$ 。问题分解为标量最小化

$$\min_{0 \leq s_i < 1} -2\sigma_i s_i - \frac{\varepsilon}{2} \log(1 - s_i^2).$$

一阶条件为 $2\sigma_i = \varepsilon s_i / (1 - s_i^2)$, 其正解就是所展示的 s_i 。代入得到取值公式。由于当 $\varepsilon \downarrow 0$ 时 $s_i \rightarrow 1$ 且 $\varepsilon \log(1 - s_i^2) \rightarrow 0$, 谱和收敛到 $-2 \sum_i \sigma_i$ 。恒等式

$$\sum_i \sigma_i = \text{tr} \left((\Sigma_\alpha^{1/2} \Sigma_\beta \Sigma_\alpha^{1/2})^{1/2} \right)$$

随后给出 Bures–Wasserstein 协方差贡献。 □

算法 8.3 闭式高斯 Sinkhorn 耦合

输入: 高斯边缘分布 $\alpha = \mathcal{N}(\mathbf{m}_\alpha, \Sigma_\alpha)$ 、 $\beta = \mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta)$, 尺度 $\varepsilon > 0$ 。

输出: 高斯熵耦合协方差。

计算奇异值分解 $\Sigma_\alpha^{1/2} \Sigma_\beta \Sigma_\alpha^{1/2} = U \text{diag}(\sigma_i) V^\top$ 。

对每个 $\sigma_i > 0$ **执行**

$$s_i = \frac{\sqrt{\varepsilon^2 + 16\sigma_i^2} - \varepsilon}{4\sigma_i}.$$

设置交叉协方差: $K_\varepsilon = \Sigma_\alpha^{1/2} U \text{diag}(s_i) V^\top \Sigma_\beta^{1/2}$ 。 **返回** 均值为 $(\mathbf{m}_\alpha, \mathbf{m}_\beta)$ 、边缘协方差为 $(\Sigma_\alpha, \Sigma_\beta)$ 、交叉协方差为 K_ε 的高斯耦合。

推论 8.19 (高斯 Sinkhorn 散度与平滑 Bures 项). 令 $\alpha = \mathcal{N}(\mathbf{m}_\alpha, \Sigma_\alpha)$ 和 $\beta = \mathcal{N}(\mathbf{m}_\beta, \Sigma_\beta)$ 具有正定协方差。对 $r > 0$, 定义

$$\tau_\varepsilon(r) := \frac{\sqrt{\varepsilon^2 + 16r^2} - \varepsilon}{4r}, \quad \psi_\varepsilon(r) := -2r \tau_\varepsilon(r) - \frac{\varepsilon}{2} \log(1 - \tau_\varepsilon(r)^2).$$

若 $\sigma_i(\Sigma, \Lambda)$ 表示 $\Sigma^{1/2} \Lambda^{1/2}$ 的奇异值, $\lambda_i(\Sigma)$ 表示 Σ 的特征值, 则去偏 Sinkhorn 散度 (7.31) 为

$$\tilde{\mathcal{L}}_{\|\cdot\|^2}^\varepsilon(\alpha, \beta) = \|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2 + \mathcal{B}_\varepsilon(\Sigma_\alpha, \Sigma_\beta)^2,$$

其中高斯协方差贡献是去偏的平滑 Bures 项

$$\mathcal{B}_\varepsilon(\Sigma, \Lambda)^2 := \sum_i \psi_\varepsilon(\sigma_i(\Sigma, \Lambda)) - \frac{1}{2} \sum_i \psi_\varepsilon(\lambda_i(\Sigma)) - \frac{1}{2} \sum_i \psi_\varepsilon(\lambda_i(\Lambda)).$$

此外, 当 $\varepsilon \downarrow 0$ 时, $\mathcal{B}_\varepsilon(\Sigma, \Lambda)^2 \rightarrow \mathcal{B}(\Sigma, \Lambda)^2$, 其中 $\mathcal{B}$ 是命题 2.39 的 Bures–Wasserstein 度量。

证明. 命题 8.18 将原始熵取值写作均值位移平方加上迹项与谱和。按上面的记号, 谱部分正是 $\sum_i \psi_\varepsilon(\sigma_i(\Sigma_\alpha, \Sigma_\beta))$ 。将同一公式应用于自代价 (α, α) 和 (β, β) , 会把这些奇异值替换为 Σ_α 和 Σ_β 的特征值。在极化公式 (7.31) 中, 迹项抵消:

$$\text{tr } \Sigma_\alpha + \text{tr } \Sigma_\beta - \frac{1}{2}(2 \text{tr } \Sigma_\alpha) - \frac{1}{2}(2 \text{tr } \Sigma_\beta) = 0,$$

而均值平方项的极化恰好留下 $\|\mathbf{m}_\alpha - \mathbf{m}_\beta\|^2$ 。这给出所展示的公式。由于 $\tau_\varepsilon(r) \rightarrow 1$ 且 $\varepsilon \log(1 - \tau_\varepsilon(r)^2) \rightarrow 0$, 有 $\psi_\varepsilon(r) \rightarrow -2r$ 。因此极限为

$$\text{tr } \Sigma + \text{tr } \Lambda - 2 \sum_i \sigma_i(\Sigma, \Lambda) = \mathcal{B}(\Sigma, \Lambda)^2,$$

这就是 Bures 公式 (2.16)。 $\square$

命题 8.20 (一维高斯 Sinkhorn 速率). 考虑 $\mathbb{R}$ 上的 $\alpha = \beta = \mathcal{N}(0, 1)$, 且 $c(x, y) = (x - y)^2$ 。若对偶势具有形式 $g_q(y) = qy^2 + \text{cst}$, 则一次软变换的二次系数为

$$T_\varepsilon(q) = 1 - \frac{1}{1 - q + \varepsilon/2}, \quad q < 1 + \varepsilon/2,$$

一个完整 Sinkhorn 周期作用为 $q \mapsto T_\varepsilon(T_\varepsilon(q))$ 。固定点 $q_\star = T_\varepsilon(q_\star)$ 由

$$A_\star^2 - \frac{\varepsilon}{2} A_\star - 1 = 0, \quad A_\star := 1 - q_\star + \frac{\varepsilon}{2} = \frac{\varepsilon + \sqrt{\varepsilon^2 + 16}}{4}.$$

因此, 一个完整 Sinkhorn 周期在二次系数上的局部渐近收缩因子为

$$\rho_\varepsilon = A_\star^{-4} = \left(\frac{4}{\varepsilon + \sqrt{\varepsilon^2 + 16}} \right)^4.$$

证明. 对下式配方

$$\int \exp\left(\frac{qy^2 - (x - y)^2}{\varepsilon}\right) d\mathcal{N}(0, 1)(y)$$

给出系数 $T_\varepsilon(q)$ 。固定点方程 $q_\star = 1 - 1/A_\star$, 连同 $q_\star = 1 + \varepsilon/2 - A_\star$, 给出

$$A_\star^2 - \frac{\varepsilon}{2} A_\star - 1 = 0.$$

正解就是所展示的 $A_\star$ 。由于

$$T'_\varepsilon(q) = -\frac{1}{(1 - q + \varepsilon/2)^2},$$

完整周期映射在固定点处的导数为 $T'_\varepsilon(q_\star)^2 = A_\star^{-4}$ 。这给出局部渐近速率。 $\square$

这个标量计算说明了 Chizat、Delalande 和 Vaškevičius [64] 的一般高斯收敛图景: 当 ε 较大或协方差尺度重叠良好时, 速率改善; 而在熵耦合逼近确定性 Brenier 映射的小温度极限中, 速率恶化。

8.6 样本复杂度

本节区分两个统计状态。精确最优传输解析所有空间尺度上的几何, 并付出依赖维数的经验速率; 固定温度的 Sinkhorn 散度平滑对偶势并恢复参数型波动, 代价是正则化偏差。

未正则化最优传输的样本复杂度受到维数灾难影响。熵正则化改变了这一图景: 对于固定的 $\varepsilon > 0$, Sinkhorn 散度具有参数型 $n^{-1/2}$ 统计速率, 尽管当 $\varepsilon \rightarrow 0$ 时常数会恶化 [103, 30]。相关的两样本检验视角见 [192], 而大 ε 核极限与经典 MMD 检验相连 [112]。这种改进需要与正则化偏差权衡, 后者只有在 ε 趋于零时才消失。




图 8.1: 三维和六维中的经验波动。对于每个样本量 n , 从 $\mathbb{R}^d$ 中同一个标准高斯律抽取两个独立经验测度 α_n 和 α'_n 。曲线显示 $D(\alpha_n, \alpha'_n)$ 的中位数, 并按最小展示 n 处的取值归一化, 同时给出四分位间距带。精确最优传输遵循较慢的依赖维数尺度, 而 MMD 和固定 ε 的 Sinkhorn 散度表现得更接近参数型 $n^{-1/2}$ 参考线。这是一个统计说明, 而不是求解器基准。

命题 8.21 (经验最优传输具有依赖维数的取值速率). 令 α 和 β 为 $[0, 1]^d$ 上密度上下有界的概率分布, 并令 $\hat{\alpha}_n$ 和 $\hat{\beta}_m$ 为独立经验测度。对于 $d > 2p$, 估计两样本距离的期望经验误差满足

$$\mathbb{E} \left| \mathcal{W}_p(\hat{\alpha}_n, \hat{\beta}_m) - \mathcal{W}_p(\alpha, \beta) \right| \lesssim n^{-1/d} + m^{-1/d}.$$

低维中指数会改变, 但重要信息是精确最优传输会随环境维数恶化。

证明. 由三角不等式,

$$\left| \mathcal{W}_p(\hat{\alpha}_n, \hat{\beta}_m) - \mathcal{W}_p(\alpha, \beta) \right| \leq \mathcal{W}_p(\hat{\alpha}_n, \alpha) + \mathcal{W}_p(\hat{\beta}_m, \beta).$$

随后回顾每个单样本项的标准多尺度论证, 并省略常数 [82, 92, 232]。对于上界, 将 $[0, 1]^d$ 划分为二进立方体。在尺度 2^{-j} 上, 单元格上的经验质量波动为 $n^{-1/2} 2^{jd/2}$ 阶, 而在单元格内移动这种多余质量的代价为 2^{-j} 。将多尺度贡献求和到每个单元格的期望样本数为一阶的尺度, 得到 2^{-J} , 其中 $2^{Jd} \simeq n$, 因此得到 $n^{-1/d}$ 。对 m 个样本的同样估计给出第二项。经验最优传输的匹配下界来自 packing 论证; 它们表明这种维数依赖对精确最优传输而言是内在的。□

命题 8.22 (MMD 具有参数型取值速率). 令 k 为具有 RKHS $\mathcal{H}_k$ 的有界正定核, 并定义

$$\text{MMD}_k(\alpha, \beta) = \left\| \int k(x, \cdot) d(\alpha - \beta)(x) \right\|_{\mathcal{H}_k}.$$

若 $\hat{\alpha}_n$ 和 $\hat{\beta}_m$ 是独立经验测度, 则

$$\mathbb{E} \left| \text{MMD}_k(\hat{\alpha}_n, \hat{\beta}_m) - \text{MMD}_k(\alpha, \beta) \right| \leq \kappa \left(\frac{1}{\sqrt{n}} + \frac{1}{\sqrt{m}} \right)$$

当 $k(x, x) \leq \kappa^2$ 时成立。

证明. 令 $\Phi(x) = k(x, \cdot)$ 为特征映射, 并令 $m_\alpha = \mathbb{E}\Phi(X)$ 。RKHS 范数的反三角不等式给出

$$\left| \text{MMD}_k(\hat{\alpha}_n, \hat{\beta}_m) - \text{MMD}_k(\alpha, \beta) \right| \leq \text{MMD}_k(\hat{\alpha}_n, \alpha) + \text{MMD}_k(\hat{\beta}_m, \beta).$$

取平方范数并取期望后, 独立性抵消交叉项, 得到

$$\mathbb{E} \text{MMD}_k(\hat{\alpha}_n, \alpha)^2 = \frac{1}{n} \mathbb{E} \|\Phi(X) - m_\alpha\|_{\mathcal{H}_k}^2 = \frac{1}{n} \left(\mathbb{E} k(X, X) - \mathbb{E} k(X, X') \right).$$

同样估计适用于 $\hat{\beta}_m$, Jensen 不等式连同 $k(x, x) \leq \kappa^2$ 给出展示的界。□

命题 8.23 (Sinkhorn 散度插值这些速率). 假设 α 和 β 支撑在 $\mathbb{R}^d$ 的紧子集中, 并且代价光滑. 对于固定的 $\varepsilon > 0$, 去偏 Sinkhorn 散度满足如下形式的代表性经验界

$$\mathbb{E} \left| \bar{\mathcal{L}}_c^\varepsilon(\hat{\alpha}_n, \hat{\beta}_m) - \bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \right| \leq C_{c,d} \varepsilon^{-d/2} \left(\frac{1}{\sqrt{n}} + \frac{1}{\sqrt{m}} \right),$$

其中常数和指数取决于精确的光滑性类别与支撑直径. 因此, 对于固定 ε , 正则化消除了 $n^{-1/d}$ 灾难, 但前因子在 $\varepsilon \rightarrow 0$ 时恶化.

证明. 证明遵循 [103] 的经验过程论证. 由包络定理, $\mathcal{L}_c^\varepsilon$ 关于其第一边缘的波动由熵对偶势类控制. 对于二次型代价, 软 c -变换在空间尺度 $\sqrt{\varepsilon}$ 上平滑这些势. 在该尺度覆盖一个有界 d 维区域, 给出 $\varepsilon^{-d/2}$ 阶的有效复杂度. 标准 Rademacher 或 Dudley 熵界随后为每个边缘给出 $\varepsilon^{-d/2}/\sqrt{n}$ 阶的经验过程波动. 将同样估计应用于定义去偏散度的三项, 得到所述界. $\square$

注 8.24 (近似精确最优传输时没有免费午餐). 命题 8.23 中的参数型速率对固定 ε 成立. 若目标是近似未正则化最优传输取值, 还必须考虑正则化偏差. 在典型的有界代价有限维状态中,

$$\left| \bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) - \mathcal{L}_c(\alpha, \beta) \right| \leq C\varepsilon, \quad \mathbb{E} \left| \bar{\mathcal{L}}_c^\varepsilon(\hat{\alpha}_n, \hat{\beta}_n) - \bar{\mathcal{L}}_c^\varepsilon(\alpha, \beta) \right| \leq C_{c,d} \varepsilon^{-d/2} n^{-1/2}.$$

平衡这两项给出 $\varepsilon \simeq n^{-1/(d+2)}$, 总误差为 $n^{-1/(d+2)}$ 阶. 等价地, 在该界下, 目标精度 η 需要选择 $\varepsilon \simeq \eta$ 和 $n \simeq \eta^{-(d+2)}$ 个样本. 因此, 熵平滑改善了固定尺度下的统计行为, 但近似精确最优传输仍然强制一个偏差-方差权衡, 其指数会随维数恶化.

广义 Wasserstein 距离

第一类扩展保留测度之间距离这一思想，但改变用于比较它们的几何。下面的变体放松质量守恒，将高维传输降为一维投影，或者用谱规范与稳健投影视角替换迹二次代价。当标准 $\mathcal{W}_p$ 过于刚性或过于昂贵时，它们很有用，同时仍保留度量解释。

9.1 非平衡最优传输

非平衡最优传输通过惩罚边缘不匹配来允许质量生成与消灭。当直方图未归一化、观测包含离群点，或者只有源的一部分应该匹配目标时，它是必不可少的 [146, 65, 66]。

松弛表述。 对于非负测度 $(\alpha, \beta) \in \mathcal{M}_+(\mathcal{X}) \times \mathcal{M}_+(\mathcal{Y})$ ，一个通用松弛表述为

$$\text{UW}_c(\alpha, \beta) = \inf_{\pi \in \mathcal{M}_+(\mathcal{X} \times \mathcal{Y})} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y) + \mathcal{D}_{\psi_1}(\pi_1 | \alpha) + \mathcal{D}_{\psi_2}(\pi_2 | \beta), \quad (9.1)$$

其中 ψ_1, ψ_2 是凸熵函数。精确守恒 $(\pi_1, \pi_2) = (\alpha, \beta)$ 被改变边缘分布的代价所替代。写作 $\psi_s = \tau \bar{\psi}_s$ 可以显露松弛尺度：

$$\text{UW}_{c, \tau}(\alpha, \beta) = \inf_{\pi \geq 0} \int c d\pi + \tau \mathcal{D}_{\bar{\psi}_1}(\pi_1 | \alpha) + \tau \mathcal{D}_{\bar{\psi}_2}(\pi_2 | \beta).$$

较大的 τ 会使边缘不匹配代价昂贵，并在总质量兼容时逼近平衡最优传输。较小的 τ 会使生成和消灭便宜；按 τ 重缩放后，零传输部分揭示纯散度几何。

命题 9.1 (边缘惩罚的小传输尺度极限). 假设 α, β 是紧度量空间 $\mathcal{X}$ 上的有限测度， c 连续、 $c \geq 0$ ，且 $c(x, y) = 0$ 当且仅当 $x = y$ 。还假设边缘散度非负、弱-* 下半连续，并且在 $\mathcal{M}_+(\mathcal{X})$ 上具有弱-* 紧的子水平集。则

$$\lim_{\tau \downarrow 0} \frac{1}{\tau} \text{UW}_{c, \tau}(\alpha, \beta) = \inf_{\rho \in \mathcal{M}_+(\mathcal{X})} \mathcal{D}_{\bar{\psi}_1}(\rho | \alpha) + \mathcal{D}_{\bar{\psi}_2}(\rho | \beta).$$

右端是通过公共零传输边缘 ρ 匹配两个测度而得到的下确界粘合散度。在受支配情形下，若 $\alpha = a\lambda$ 、 $\beta = b\lambda$ ，并且极小化公共边缘绝对连续， $\rho = r\lambda$ ，则该散度逐点解耦为

$$\int \mathbf{m}_{\bar{\psi}_1, \bar{\psi}_2}(a(x), b(x)) d\lambda(x), \quad \mathbf{m}_{\bar{\psi}_1, \bar{\psi}_2}(a, b) := \inf_{r \geq 0} a \bar{\psi}_1(r/a) + b \bar{\psi}_2(r/b),$$

其中当 $a = 0$ 或 $b = 0$ 时采用通常的渐近约定。对于超线性熵，特别是 KL ，有限能量强制这种受支配形式。因此，当 $\bar{\psi}_1 = \bar{\psi}_2$ 是 KL 熵时，

$$\inf_{\rho \in \mathcal{M}_+(\mathcal{X})} KL(\rho | \alpha) + KL(\rho | \beta) = \int (\sqrt{a} - \sqrt{b})^2 d\lambda.$$

因此， KL 边缘松弛包含平方 *Hellinger* 距离作为其局部质量变化极限。

证明。 对于上界，限制到对角传输计划 $\pi = (\text{Id}, \text{Id})_{\#} \rho$ ，其传输代价为零，且两个边缘都是 ρ 。对 ρ 优化后得到所需上界。

对于下界，令 $\tau_n \downarrow 0$ ，并令 π_n 为近似极小传输计划，且缩放取值 $\tau_n^{-1} \text{UW}_{c, \tau_n}(\alpha, \beta)$ 有界。由于散度非负， $\int c d\pi_n = O(\tau_n)$ ，因此 $\int c d\pi_n \rightarrow 0$ 。有界的缩放取值还使两个边缘落在紧的散度子水平集中。由于耦合与每个边缘具有相同总质量，耦合在 $\mathcal{X} \times \mathcal{X}$ 上紧。取子序列后， $\pi_n \rightharpoonup \pi_0$ 。传输代价的下半连续性给出 $\int c d\pi_0 = 0$ ，所以 π_0 集中在对角线上。因此它的两个边缘等于同一个测度 ρ 。边缘散度的下半连续性给出

$$\liminf_n \frac{1}{\tau_n} \text{UW}_{c, \tau_n}(\alpha, \beta) \geq \mathcal{D}_{\bar{\psi}_1}(\rho | \alpha) + \mathcal{D}_{\bar{\psi}_2}(\rho | \beta),$$

而对 ρ 优化给出下界。

在受支配情形下, 写 $\rho = r\lambda$ 得到

$$\mathcal{D}_{\bar{\psi}_1}(\rho|\alpha) + \mathcal{D}_{\bar{\psi}_2}(\rho|\beta) = \int a \bar{\psi}_1(r/a) + b \bar{\psi}_2(r/b) d\lambda,$$

所以关于 ρ 的最小化解耦为标量包络 $\mathbf{m}_{\bar{\psi}_1, \bar{\psi}_2}$ 。对于 KL, 当 α 和 β 由 λ 支配时, 不允许奇异部分。逐点目标为 $r \log(r/a) - r + a + r \log(r/b) - r + b$ 。其最优性条件为 $\log(r/a) + \log(r/b) = 0$, 因此 $r = \sqrt{ab}$, 最小值为 $a + b - 2\sqrt{ab} = (\sqrt{a} - \sqrt{b})^2$ 。□

命题 9.2 (非平衡最优传输的对偶). 在通常的 *Fenchel–Rockafellar* 资格条件下, (9.1) 等于

$$\text{UW}_c(\alpha, \beta) = \sup_{f \oplus g \leq c} -\mathcal{D}_{\psi_1}^*(-f|\alpha) - \mathcal{D}_{\psi_2}^*(-g|\beta).$$

证明. 使用散度对偶的变分公式 (6.13), 并通过连续势引入边缘变量:

$$\inf_{\pi \geq 0} \sup_{f, g} \int c d\pi + \int -f d\pi_1 + \int -g d\pi_2 - \mathcal{D}_{\psi_1}^*(-f|\alpha) - \mathcal{D}_{\psi_2}^*(-g|\beta).$$

交换下确界和上确界得到

$$\sup_{f, g} -\mathcal{D}_{\psi_1}^*(-f|\alpha) - \mathcal{D}_{\psi_2}^*(-g|\beta) + \inf_{\pi \geq 0} \int (c - (f \oplus g)) d\pi.$$

当 $f \oplus g \leq c$ 时, 最后一个下确界为 0; 否则为 $-\infty$ 。这给出所展示的对偶。□

反向与齐次表述. Liero–Mielke–Savaré 表述把边缘惩罚重写为局部传输代价, 然后将其齐次化。先假设参考测度和被传输边缘具有相互绝对连续部分, 则可将目标分解为

$$\begin{aligned} & \int c(x, y) d\pi(x, y) + \mathcal{D}_{\psi_1}(\pi_1|\alpha) + \mathcal{D}_{\psi_2}(\pi_2|\beta) \\ &= \int \left(c(x, y) + \psi_1 \left(\frac{d\pi_1}{d\alpha}(x) \right) \frac{d\alpha}{d\pi_1}(x) + \psi_2 \left(\frac{d\pi_2}{d\beta}(y) \right) \frac{d\beta}{d\pi_2}(y) \right) d\pi(x, y). \end{aligned}$$

这启发了局部反向代价

$$L_c(r, s) := c + r\psi_1(1/r) + s\psi_2(1/s), \quad (9.2)$$

其中在 $r = 0$ 或 $s = 0$ 处采用通常的渐近约定。若 $\alpha = F\pi_1 + \alpha^\perp$ 和 $\beta = G\pi_2 + \beta^\perp$ 是参考边缘相对于被传输边缘的 Lebesgue 分解, 则反向表述为

$$\text{UW}_c(\alpha, \beta) = \inf_{\pi \geq 0} \int L_{c(x, y)}(F(x), G(y)) d\pi(x, y) + \psi_1(0)\alpha^\perp(\mathcal{X}) + \psi_2(0)\beta^\perp(\mathcal{Y}).$$

齐次表述通过对 L_c 取透视变换得到,

$$H_c(r, s) := \inf_{\theta > 0} \theta L_c(r/\theta, s/\theta), \quad (9.3)$$

它是正 1-齐次的。它定义

$$\text{HW}_c(\alpha, \beta) = \inf_{\pi \geq 0} \int H_{c(x, y)}(F(x), G(y)) d\pi(x, y) + \psi_1(0)\alpha^\perp(\mathcal{X}) + \psi_2(0)\beta^\perp(\mathcal{Y}). \quad (9.4)$$

命题 9.3 (齐次化不改变非平衡代价). 有 $\text{HW}_c(\alpha, \beta) = \text{UW}_c(\alpha, \beta)$ 。

证明. 不等式 $\text{HW} \leq \text{UW}$ 由 $H_c \leq L_c$ 取 $\theta = 1$ 得到。反过来, 在齐次表述中取一个可行测度 π 。由透视变换的定义, 对每个 (x, y) 和每个 $\eta > 0$, 存在尺度 $\theta(x, y) > 0$ 使得

$$H_{c(x, y)}(F(x), G(y)) + \eta \geq \theta(x, y) L_{c(x, y)}(F(x)/\theta(x, y), G(y)/\theta(x, y)).$$

用重缩放测度 $\tilde{\pi} = \theta\pi$ 替换 π , 并用 F/θ 和 G/θ 替换密度, 给出反向表述的一个可行竞争者, 其代价不大于齐次代价加上 $\eta\pi(\mathcal{X} \times \mathcal{Y})$ 。令 $\eta \rightarrow 0$ 得到 $\text{UW} \leq \text{HW}$ 。奇异项不变, 因为在取边缘的 Lebesgue 分解之前执行了相同的重缩放。□

锥提升。 现在假设 $\mathcal{X} = \mathcal{Y}$ 且 $\psi_1 = \psi_2 = \psi$ 。最后一种表述把问题提升到锥空间 $\mathfrak{C}[\mathcal{X}] := (\mathcal{X} \times \mathbb{R}_+)/\sim$ ，其中所有点 $(x, 0)$ 都在顶点处等同。对于指数 $p \geq 1$ ，定义

$$\Delta((x, r), (y, s)) := H_{c(x, y)}(r^p, s^p)^{1/p}.$$

通过选择 ψ 、 c 和 p 使 Δ 成为锥上的距离，可以得到若干经典非平衡几何：

- $\mathcal{D}_\psi = \text{KL}$ 、 $p = 2$ 且 $c(x, y) = -\log \cos^2(d(x, y) \wedge \pi/2)$ 给出 Hellinger–Kantorovich 或 Wasserstein–Fisher–Rao 锥度量

$$\Delta((x, r), (y, s))^2 = r^2 + s^2 - 2rs \cos(d(x, y) \wedge \pi/2).$$

- $\mathcal{D}_\psi = \text{KL}$ 、 $p = 2$ 且 $c(x, y) = d(x, y)^2$ 给出高斯 Hellinger 锥度量

$$\Delta((x, r), (y, s))^2 = r^2 + s^2 - 2rse^{-d(x, y)^2/2}.$$

- $\mathcal{D}_\psi = \text{TV}$ 、 $p = 1$ 且 $c(x, y) = d(x, y)$ 给出部分传输锥代价

$$\Delta((x, r), (y, s)) = r + s - (r \wedge s)(2 - d(x, y))_+.$$

对应的锥取值为

$$\text{CW}(\alpha, \beta) = \inf_{\gamma \in \mathcal{M}_+(\mathfrak{C}[\mathcal{X}]^2)} \left\{ \int \Delta((x, r), (y, s))^p d\gamma; \int r^p d\gamma_1(\cdot, r) = \alpha, \int s^p d\gamma_2(\cdot, s) = \beta \right\}.$$

定理 9.4 (非平衡最优传输的锥表述). 有 $\text{UW} = \text{HW} = \text{CW}$ 。若 Δ 是距离，则 $\text{CW}^{1/p}$ 是非负测度之间的距离。

证明. 等式 $\text{UW} = \text{HW}$ 是命题 9.3。为证明 $\text{HW} = \text{CW}$ ，相对于空间变量 (x, y) 和半径 (r, s) 对一个可行锥耦合 γ 做解体。锥边缘约束正是说，用 r^p 和 s^p 加权后可恢复空间边缘。由于 $\Delta((x, r), (y, s))^p = H_{c(x, y)}(r^p, s^p)$ ，积分锥代价给出齐次目标。反过来，任何齐次竞争者都可以提升到锥上：在每个 (x, y) 上放置半径，使其 p 次幂等于 H_c 中出现的两个密度因子。

若 Δ 是锥上的距离，则 $\text{CW}^{1/p}$ 是线性锥边缘约束下提升测度之间通常的 p -Wasserstein 距离。对称性和三角不等式来自相应的 Wasserstein 性质以及锥上的粘合引理。若距离为零，则最优锥耦合集中了在对角线上，所以加权投影一致，因而 $\alpha = \beta$ 。□

熵 KL 松弛。 非平衡最优传输的通用熵正则化写作

$$\inf_{\pi \in \mathcal{M}_+(\mathcal{X} \times \mathcal{Y})} \int c d\pi + \mathcal{D}_{\psi_1}(\pi_1 | \alpha) + \mathcal{D}_{\psi_2}(\pi_2 | \beta) + \varepsilon \mathcal{D}_\varphi(\pi | \alpha \otimes \beta).$$

其对偶为

$$\sup_{f, g} -\mathcal{D}_{\psi_1}^*(-f | \alpha) - \mathcal{D}_{\psi_2}^*(-g | \beta) - \varepsilon \mathcal{D}_\varphi^*\left(\frac{f \oplus g - c}{\varepsilon} \middle| \alpha \otimes \beta\right).$$

对于 $\mathcal{D}_\varphi = \text{KL}$ ，原始-对偶关系为 $d\pi = e^{(f \oplus g - c)/\varepsilon} d\alpha d\beta$ 。若另外 $\mathcal{D}_{\psi_1} = \mathcal{D}_{\psi_2} = \tau \text{KL}$ ，则对偶特化为

$$\sup_{f, g} -\tau \int (e^{-f/\tau} - 1) d\alpha - \tau \int (e^{-g/\tau} - 1) d\beta - \varepsilon \iint (e^{(f \oplus g - c)/\varepsilon} - 1) d\alpha d\beta,$$

而坐标最大化给出阻尼软变换

$$\begin{aligned} f(x) &= -\frac{\tau\varepsilon}{\tau + \varepsilon} \log \int_{\mathcal{Y}} \exp\left(\frac{g(y) - c(x, y)}{\varepsilon}\right) d\beta(y), \\ g(y) &= -\frac{\tau\varepsilon}{\tau + \varepsilon} \log \int_{\mathcal{X}} \exp\left(\frac{f(x) - c(x, y)}{\varepsilon}\right) d\alpha(x). \end{aligned}$$

在离散情形下，令 $K_{i, j} = e^{-C_{i, j}/\varepsilon} a_i b_j$ 且 $\rho = \tau/(\tau + \varepsilon)$ ，这给出广义 Sinkhorn 缩放

$$u_i \leftarrow \left(\frac{a_i}{(Kv)_i}\right)^\rho, \quad v_j \leftarrow \left(\frac{b_j}{(K^\top u)_j}\right)^\rho, \quad P = \text{diag}(u)K \text{diag}(v).$$

算法 9.1 非平衡 Sinkhorn 缩放

输入: 权重 a, b , 代价矩阵 C , 熵尺度 $\varepsilon > 0$, KL 强度 $\tau > 0$, 容差 tol 。

输出: 非平衡熵耦合 P 。

初始化: 令 $K_{ij} = e^{-C_{ij}/\varepsilon} a_i b_j$, $\rho = \frac{\tau}{\tau + \varepsilon}$, $u^{(0)} = \mathbf{1}_n$, $v^{(0)} = \mathbf{1}_m$, $\eta_0 = +\infty$, $k = 0$ 。

当 $\eta_k > \text{tol}$ **时执行:**

令 $k \leftarrow k + 1$ 。

$u^{(k)} = \left(\frac{a}{K v^{(k-1)}} \right)^\rho$, $v^{(k)} = \left(\frac{b}{K^\top u^{(k)}} \right)^\rho$ 。

令 $\eta_k = \max\{\|u^{(k)} - u^{(k-1)}\|_\infty, \|v^{(k)} - v^{(k-1)}\|_\infty\}$ 。

返回 $P^{(k)} = \text{diag}(u^{(k)}) K \text{diag}(v^{(k)})$ 。

指数 $\rho < 1$ 是它与平衡 Sinkhorn 的可见差异：由于允许违背边缘分布，边缘修正被阻尼。




图 9.1: 一维高斯混合密度上的 KL 非平衡最优传输。中央矩阵是被传输的耦合。左侧红色曲线是给定源边缘，紫色曲线是被传输源边缘；红色缺口是被消灭的质量。上方蓝色曲线是给定目标边缘，紫色曲线是被传输目标边缘；蓝色缺口是被生成的质量。增大 τ 会使边缘不匹配更昂贵，因此更多质量被传输，包括传向最右侧目标模态。

边缘松弛中使用的熵也会改变量化行为。KL 惩罚导致光滑的乘法重缩放。反向 KL 或 Burg 惩罚会在被传输边缘上给定边缘为正处消失时发散，因此它抑制小模态的完全删除。全变差具有线性折点，其行为更接近部分传输：质量要么保持活跃，要么以几乎恒定的边缘价格被生成和消灭。




图 9.2: 边缘散度在非平衡熵最优传输中的作用。几何代价、熵传输计划正则化 ε 和松弛强度 τ 固定；只有边缘惩罚改变。KL 允许光滑质量变化，Burg 使被传输边缘不在给定模态上消失，而全变差给出更尖锐的活跃质量选择。侧图使用与图 9.1 相同的约定。

9.2 切片 Wasserstein 距离

切片 Wasserstein 用许多一维投影换取精确高维几何。它成本低，排序后可微，并且在成像和学习中通常有效。对于 $\mathbb{R}^d$ 上的测度和 $\theta \in \mathbb{S}^{d-1}$ ，令 $P_\theta(x) = \langle \theta, x \rangle$ 为方向 θ 上的投影。

定义 9.5 (切片 Wasserstein 距离). 令 σ 为球面 $\mathbb{S}^{d-1}$ 上的均匀概率测度。切片 p -Wasserstein 距离

为

$$\text{SW}_p(\alpha, \beta)^p := \int_{\mathbb{S}^{d-1}} \mathcal{W}_p((P_\theta)_\# \alpha, (P_\theta)_\# \beta)^p d\sigma(\theta). \quad (9.5)$$

该构造与 Radon 变换密切相关，并且比高维最优传输便宜得多，因为每个投影问题都可以通过排序或分位数求解 [189, 40, 134]。它度量与 $\mathcal{W}_p$ 相同的弱收敛加矩拓扑，但其几何在高维中不与 $\mathcal{W}_p$ 双 Lipschitz 等价 [170]。

算法 9.2 蒙特卡洛切片 Wasserstein

输入：等权重点云 $(x_i)_{i=1}^n, (y_i)_{i=1}^n$ ，指数 p ，方向数量 L 。

输出：蒙特卡洛估计 $\widehat{\text{SW}}_p^L(\alpha, \beta)$ 。

对 $\ell = 1, \dots, L$ **执行：**

采样 $\theta_\ell \sim \sigma$ 于 $\mathbb{S}^{d-1}$ 。

令 $s_i^\ell = \langle \theta_\ell, x_i \rangle$ 且 $t_i^\ell = \langle \theta_\ell, y_i \rangle$ 。

令 σ_ℓ, τ_ℓ 为稳定排序置换： $s_{\sigma_\ell(1)}^\ell \leq \dots \leq s_{\sigma_\ell(n)}^\ell, \quad t_{\tau_\ell(1)}^\ell \leq \dots \leq t_{\tau_\ell(n)}^\ell$ 。

计算 $E_\ell = \frac{1}{n} \sum_{i=1}^n |s_{\sigma_\ell(i)}^\ell - t_{\tau_\ell(i)}^\ell|^p$ 。

返回 $\widehat{\text{SW}}_p^L(\alpha, \beta) = \frac{1}{L} \sum_{\ell=1}^L E_\ell$ 。




图 9.3: 两个平面密度之间的切片 Wasserstein 投影。源和目标被渲染为平滑黑白密度图像，它们来自两个轮廓的稠密最远点样本。在两个密度图上绘制了五个固定方向。对于每个方向，中间面板显示投影测度 $(P_\theta)_\# \alpha$ 和 $(P_\theta)_\# \beta$ 的平滑一维密度估计。切片最优传输在许多这样的方向上平均一维 Wasserstein 差异，用一组排序后的一维比较替代困难的平面比较。

命题 9.6 (切片 Wasserstein 的度量性质). 对于 $p \geq 1$, SW_p 是 $\mathcal{P}_p(\mathbb{R}^d)$ 上的距离。此外, SW_p 度量弱收敛连同 p 阶矩收敛。最后,

$$\text{SW}_p(\alpha, \beta) \leq \mathcal{W}_p(\alpha, \beta),$$

并且对于球面上的均匀概率测度, 当 $p = 2$ 时,

$$\text{SW}_2(\alpha, \beta)^2 \leq \frac{1}{d} \mathcal{W}_2(\alpha, \beta)^2.$$

证明. 非负性和对称性来自一维 Wasserstein 距离。对于三角不等式, 对每个方向 θ 应用 $\mathcal{W}_p$ 的三角不等式, 然后在 $L^p(\mathbb{S}^{d-1})$ 中应用 Minkowski 不等式。

若 $\text{SW}_p(\alpha, \beta) = 0$, 则对几乎每个方向都有 $(P_\theta)_\# \alpha = (P_\theta)_\# \beta$ 。由特征函数的连续性, 这对所有方向成立, 而 Cramér–Wold 定理推出 $\alpha = \beta$ 。这证明了分离性。

界 $\text{SW}_p \leq \mathcal{W}_p$ 来自 P_θ 是 1-Lipschitz, 因此

$$\mathcal{W}_p((P_\theta)_\# \alpha, (P_\theta)_\# \beta) \leq \mathcal{W}_p(\alpha, \beta)$$

对每个 θ 成立。对于 $p = 2$, 使用 α 与 β 之间的任意耦合 π ,

$$\int_{\mathbb{S}^{d-1}} \int |\langle x - y, \theta \rangle|^2 d\pi(x, y) d\sigma(\theta) = \frac{1}{d} \int \|x - y\|^2 d\pi(x, y).$$

对 π 优化给出更尖锐的不等式。弱收敛陈述来自同一个 Cramér–Wold 机制加上矩条件: SW_p 中的收敛给出几乎所有一维投影的收敛和 p 阶矩的紧性; 反过来, 弱收敛连同 p 阶矩收敛蕴含投影 $\mathcal{W}_p$ 距离的收敛以及球面上的受控收敛。□

注 9.7 (SW₂ 的 Hilbert 嵌入). 在一维中, $\mathcal{W}_2$ 是分位数函数之间的 $L^2(0,1)$ 距离。因此

$$\text{SW}_2(\alpha, \beta)^2 = \int_{\mathbb{S}^{d-1}} \int_0^1 |F_{\theta, \alpha}^{-1}(u) - F_{\theta, \beta}^{-1}(u)|^2 \text{d}u \text{d}\sigma(\theta),$$

其中 $F_{\theta, \alpha}^{-1}$ 是 $(P_\theta)_\# \alpha$ 的分位数。因此, 在把每个测度嵌入到其投影分位数段后, SW_2 是 Hilbert 型距离。因此, 对每个 $\gamma > 0$, $\exp(-\gamma \text{SW}_2^2)$ 是概率测度上的正定核。反过来, 在紧集上, $\mathcal{W}_p$ 可以由 SW_p 的依赖维数幂来界定; 这种不等式弱于命题 9.6 的直接界, 并解释了为什么切片距离能度量相同拓扑, 却在高维中不与 $\mathcal{W}_p$ 双 Lipschitz 等价 [41, 170]。

定义 9.8 (最大切片 Wasserstein). 最大切片距离用最具区分性的方向替代方向平均:

$$\text{MaxSW}_p(\alpha, \beta) := \sup_{\theta \in \mathbb{S}^{d-1}} \mathcal{W}_p((P_\theta)_\# \alpha, (P_\theta)_\# \beta).$$

当只有少数投影承载大部分差异时, 例如在生成建模中, 它很有用 [79]。

子空间切片变体. 一维切片极其便宜, 但在高维中可能丢弃过多几何。一个自然折中是投影到 k 维子空间: 投影后的最优传输问题仍保持较低维度, 而每个投影保留一小块坐标内的相关性。因此, 改变 k 可以在普通切片与完整最优传输之间插值。

定义 9.9 (子空间切片 Wasserstein). 固定 $1 \leq k \leq d$ 。子空间切片变体用 k 维正交投影替代一维直线。若 $U \in \mathbb{R}^{d \times k}$ 满足 $U^\top U = \text{Id}_k$, 则

$$\text{SW}_{p,k}(\alpha, \beta)^p := \int \mathcal{W}_p((U^\top)_\# \alpha, (U^\top)_\# \beta)^p \text{d}U,$$

其中 $\text{d}U$ 表示 Stiefel 流形上的归一化不变测度 $\text{St}(d, k) = \{U \in \mathbb{R}^{d \times k} : U^\top U = \text{Id}_k\}$, and

$$\text{MaxSW}_{p,k}(\alpha, \beta) := \sup_{U^\top U = \text{Id}_k} \mathcal{W}_p((U^\top)_\# \alpha, (U^\top)_\# \beta).$$

情形 $k=1$ 恢复普通切片和最大切片 Wasserstein, 而 $k=d$ 恢复原始 Wasserstein 距离。

命题 9.10 (切片变体的基本界). 令 $p \geq 1$ 且 $\alpha, \beta \in \mathcal{P}_p(\mathbb{R}^d)$ 。对于归一化球面测度和 Stiefel 测度,

$$\text{SW}_p(\alpha, \beta) \leq \text{MaxSW}_p(\alpha, \beta) \leq \mathcal{W}_p(\alpha, \beta).$$

对于 k 维子空间投影,

$$\text{SW}_{p,k}(\alpha, \beta) \leq \text{MaxSW}_{p,k}(\alpha, \beta) \leq \mathcal{W}_p(\alpha, \beta).$$

证明. 每一行中的第一个不等式来自概率空间上的 L^p 平均由相应上确界控制。第二个不等式来自正交投影是 1-Lipschitz: 将 α 与 β 之间的任意可行耦合通过投影推前, 会给出投影测度的一个可行耦合, 且传输代价不更大。先对耦合优化, 再对投影取平均或最大化, 即得结果。□

最小切片提升传输计划. 前述构造定义的是投影测度之间的距离。切片的另一种用法是只把投影作为构造可行高维传输计划的工具。对于等权经验测度 $\alpha = n^{-1} \sum_i \delta_{x_i}$ 和 $\beta = n^{-1} \sum_i \delta_{y_i}$, 对投影样本 $\langle x_i, \theta \rangle$ 和 $\langle y_j, \theta \rangle$ 排序, 并令 σ_θ 为该排序诱导的单调匹配。提升传输计划

$$\pi_\theta = \frac{1}{n} \sum_{i=1}^n \delta_{(x_i, y_{\sigma_\theta(i)})}$$

是原始空间中 α 与 β 之间的真正耦合。Min-SWGG 型方法随后选择其提升传输计划具有最小全维二次代价的投影,

$$\text{MSWGG}_2(\alpha, \beta)^2 := \min_{\theta \in \mathbb{S}^{d-1}} \int \|x - y\|^2 \text{d}\pi_\theta(x, y).$$

该量不是投影距离; 它是一种便宜的可行传输计划构造。因此它给出 $\mathcal{W}_2^2(\alpha, \beta)$ 的上界, 而其兴趣在于算法方面: 传输计划通过排序获得, 而不是通过求解高维线性规划获得。确实, 每个 π_θ 都是原始测度之间的可行耦合, 所以

$$\mathcal{W}_2^2(\alpha, \beta) \leq \int \|x - y\|^2 \text{d}\pi_\theta(x, y), \quad \mathcal{W}_2^2(\alpha, \beta) \leq \text{MSWGG}_2(\alpha, \beta)^2.$$

算法 9.3 提升最小切片匹配

输入：等权重点云 $(x_i)_{i=1}^n, (y_i)_{i=1}^n$ ，有限方向集 $\Theta \subset \mathbb{S}^{d-1}$ 。

输出：由所选投影方向诱导的可行耦合 π_{θ^*} 。

对每个 $\theta \in \Theta$ 执行：

 令 $\sigma_\theta, \tau_\theta$ 为 $\langle \theta, x_i \rangle$ 和 $\langle \theta, y_j \rangle$ 的稳定排序置换。

匹配 $x_{\sigma_\theta(k)}$ 与 $y_{\tau_\theta(k)}$ ，其中 $k = 1, \dots, n$ 。

存储秩匹配置换 $\rho_\theta = \tau_\theta \circ \sigma_\theta^{-1}$ 。

评估 $E(\theta) = \frac{1}{n} \sum_{i=1}^n \|x_i - y_{\rho_\theta(i)}\|^2$ 。

令 $\theta^* = \min \operatorname{argmin}_{\theta \in \Theta} E(\theta)$ ，其中最小值按 Θ 上的固定顺序选取。**返回** $\pi_{\theta^*} = \frac{1}{n} \sum_i \delta_{(x_i, y_{\rho_{\theta^*}(i)})}$ 。




图 9.4: 提升最小切片传输计划。通过小规模确定性扫描选出一个一维方向，然后红色与蓝色原子在投影后排序，并按该顺序匹配。中间面板把这个一维匹配提升回平面；它是可行耦合，但不是右侧所示的二次 W_2 匹配。这说明切片构造为什么计算轻量且可解释，同时会丢失完整传输问题的一部分几何。

9.3 向量分位数与线性最优传输

线性最优传输从分位数坐标的多变量类比出发。一维分位数函数通过把固定参考律送到目标律的单调映射表示概率测度；在维数 $d > 1$ 时，在选择绝对连续参考概率 ρ 后，Brenier 定理给出相应构造，参考概率通常是凸体上的均匀律或标准高斯。

向量分位数。 假设 ρ 绝对连续。对于具有有限二阶矩的目标律 μ ，其相对于 ρ 的向量分位数是 Brenier 映射

$$T_\mu = \nabla \varphi_\mu, \quad (T_\mu)_\# \rho = \mu,$$

或等价地，是如下问题的解

$$\min_{T_\# \rho = \mu} \int \|x - T(x)\|^2 d\rho(x).$$

该构造只有在固定 ρ 之后才是典范的：改变参考律会改变用于表示 μ 的坐标。向量分位数回归条件化地使用同一思想，用条件 Brenier 映射替代标量条件分位数，从而编码多变量秩与深度 [50]。

线性化 Wasserstein 坐标。 线性最优传输用参考映射之间的 Hilbert 范数替代非线性传输距离。当一个参考测度固定，且必须便宜地比较许多邻近分布时，它很有用。令 T_α 为把 ρ 推前到 α 的 Brenier 映射，将其理解为 $L^2(\rho; \mathbb{R}^d)$ 的元素，因此只在 ρ -几乎处处定义。线性最优传输嵌入为

$$\alpha \mapsto T_\alpha - \operatorname{Id} \in L^2(\rho; \mathbb{R}^d), \quad \operatorname{LOT}_\rho(\alpha, \beta) = \|T_\alpha - T_\beta\|_{L^2(\rho)}. \quad (9.6)$$

若两个目标之一等于参考，则线性化距离是精确的：例如， $\operatorname{LOT}_\rho(\rho, \alpha) = \|T_\alpha - \operatorname{Id}\|_{L^2(\rho)} = \mathcal{W}_2(\rho, \alpha)$ 。对于两个任意目标，耦合 $(T_\alpha, T_\beta)_\# \rho$ 是可行的，但通常不是最优的，因此 LOT_ρ 是 Wasserstein 几何的切空间近似 [231]。对于带权重 $(\lambda_s)_s$ 的族 $(\alpha_s)_s$ ，线性化重心通过平均映射获得，

$$\bar{T} = \sum_s \lambda_s T_{\alpha_s}, \quad \bar{\alpha}_{\operatorname{LOT}} = \bar{T}_\# \rho.$$

这在一维中是精确的，因为分位数函数线性化 $\mathcal{W}_2$ ；当必须快速评估许多权重变化的重心时，它尤其有用。

注 9.11 (测度的三种 Hilbert 型嵌入). 本文中若干构造把测度嵌入到 Hilbert 空间, 但它们编码不同的几何。核均值嵌入把 α 送到 RKHS 中的 $\int k(x, \cdot) d\alpha(x)$, 并导致 MMD 距离; 见第 6.2 节。二次切片 Wasserstein 把测度送到其投影的一维分位数函数集合, 并将其视为 $L^2(\mathbb{S}^{d-1} \times [0, 1])$ 中的对象; 见第 9.2 节。线性最优传输把 α 送到固定参考 ρ 出发的位移场 $T_\alpha - \text{Id}$, 该场位于 $L^2(\rho; \mathbb{R}^d)$ 中。第一个构造关于测度是线性的且依赖核, 第二个构造是非线性的但把最优传输降为投影一维分位数, 第三个构造是围绕所选参考对完整 Wasserstein 几何的切近似。




图 9.5: 线性最优传输坐标。固定参考测度 ρ 会把每个目标变成从 ρ 到 α 的映射 T_α , 或等价地变成位移场 $T_\alpha - \text{Id}$ 。在一维中, 这正是 $\mathcal{W}_2$ 的分位数参数化, 因此平均指向双分量 α 和双分量 β 的映射会给出真正的 Wasserstein 重心。在二维中, 第一个面板显示参考到目标的映射, 它们在稠密点云上计算, 并在最远点子集上展示, 其中 β 由两个高斯分量表示。中间的紫色面板显示通过平均两个来自 ρ 的映射得到的线性化重心。右侧紫色面板显示 α 与 β 之间真正的 McCann 中点, 它通过求解两个目标点云之间的直接最优传输问题并在 $t = 1/2$ 处插值得到。

命题 9.12 (线性最优传输的局部稳定性). 假设测度支撑在固定凸紧集上, 密度上下有界, 并且从 ρ 出发的 Brenier 映射正则。则对于位于 ρ 的足够小正则邻域中的 α, β ,

$$\mathcal{W}_2(\alpha, \beta) \leq \text{LOT}_\rho(\alpha, \beta) \quad \text{and} \quad \text{LOT}_\rho(\alpha, \beta) \leq C \mathcal{W}_2(\alpha, \beta)^\eta$$

其中常数 $C > 0$ 和 $\eta \in (0, 1]$ 依赖于正则性。

证明. 第一个不等式是直接的: $(T_\alpha, T_\beta)_\# \rho$ 是 α 与 β 之间的可行耦合。反向局部估计是在所述正则性假设下 Monge–Ampère 方程的标准稳定性陈述: 目标测度的变化控制 Brenier 势在 Hölder 范数中的变化, 从而控制 $T_\alpha - T_\beta$ 在 $L^2(\rho)$ 中的变化。在简单一维设置中, 分位数函数使这一点在 $\eta = 1$ 时成为精确等式。在多维中, 不应把该陈述理解为 $\mathcal{W}_2$ 中的全局 Lipschitz 估计。半离散映射和 Monge–Ampère 映射的定量稳定性结果给出依赖于维数、密度界、支撑几何和正则性的 Hölder 指数; 例如见 Mérigot、Delalande 和 Chazal 的估计 [163]。在一致凸光滑密度的更强光滑扰动下, 椭圆正则性可以在更强函数范数中给出 Lipschitz 依赖, 但把这些控制转换为 Wasserstein 扰动通常会损失幂次。□

9.4 谱与稳健 Wasserstein 距离

谱最优传输通过矩阵规范度量整个位移协方差, 从而改变标量二次代价。同一对象具有稳健投影表述: 不是固定一个投影, 而是在规范的极集上最大化。子空间稳健最优传输是这一思想的重要非凸秩约束版本 [179]; 谱规范提供其凸极小极大对应物, 并连接到 Muon 动力学等近期谱梯度视角 [182]。

定义 9.13 (单调谱规范). 正半定矩阵上的单调谱规范是一个凸、正 1-齐次映射 $\gamma: \mathbb{S}_+^d \rightarrow \mathbb{R}_+$, 满足 $\gamma(M) = 0$ 仅当 $M = 0$, 对每个正交矩阵 Q 有 $\gamma(QMQ^\top) = \gamma(M)$, 并且

$$0 \preceq M \preceq N \implies \gamma(M) \leq \gamma(N).$$

单调性条件意味着, 在 Loewner 序中增大位移协方差不会降低传输惩罚。

定义 9.14 (谱 Wasserstein 距离). 令 γ 为单调谱规范。对于耦合 $\pi \in \mathcal{U}(\alpha, \beta)$, 定义其位移协方差

$$M_\pi := \int (x - y)(x - y)^\top d\pi(x, y).$$

与 γ 关联的谱 Wasserstein 距离为

$$\mathcal{W}_\gamma(\alpha, \beta)^2 := \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \gamma(M_\pi). \quad (9.7)$$

特例 $\gamma(M) = \text{tr}(M)$ 给出通常的二次 Wasserstein 距离 $\mathcal{W}_2$ 。谱规范 $\gamma(M) = \lambda_{\max}(M)$ 则度量最坏的被传输方差方向。对于 $A \succeq 0$, 定义二次投影传输代价

$$\mathcal{W}_{2,A}(\alpha, \beta)^2 := \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int (x - y)^\top A (x - y) d\pi(x, y) = \mathcal{W}_2((A^{1/2})_\# \alpha, (A^{1/2})_\# \beta)^2. \quad (9.8)$$

该规范的极集为

$$\mathcal{B}_\gamma := \{A \succeq 0; \text{tr}(AM) \leq \gamma(M) \text{ 对所有 } M \succeq 0\}, \quad (9.9)$$

因此, 对于闭规范, 有 $\gamma(M) = \sup_{A \in \mathcal{B}_\gamma} \text{tr}(AM)$ 。

命题 9.15 (稳健表示与度量等价性). 为简单起见, 假设测度紧支撑, 并且 γ 在正半定锥上闭且有限。则

$$\mathcal{W}_\gamma(\alpha, \beta)^2 = \sup_{A \in \mathcal{B}_\gamma} \mathcal{W}_{2,A}(\alpha, \beta)^2.$$

若存在常数 $0 < a \leq b < +\infty$ 使得 $a\text{Id} \in \mathcal{B}_\gamma$ 且 $\mathcal{B}_\gamma \subset \{A; 0 \preceq A \preceq b\text{Id}\}$, 等价地

$$a \text{tr}(M) \leq \gamma(M) \leq b \text{tr}(M) \quad (M \succeq 0),$$

则

$$\sqrt{a} \mathcal{W}_2(\alpha, \beta) \leq \mathcal{W}_\gamma(\alpha, \beta) \leq \sqrt{b} \mathcal{W}_2(\alpha, \beta).$$

特别地, $\mathcal{W}_\gamma$ 是距离。当 γ 是某个范数到正半定锥上的限制时, 这些界在有限维中自动成立, 因此 $\mathcal{W}_\gamma$ 在具有有限二阶矩的测度上等价于 $\mathcal{W}_2$ 。

证明. 使用 γ 的极表示,

$$\mathcal{W}_\gamma(\alpha, \beta)^2 = \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \sup_{A \in \mathcal{B}_\gamma} \text{tr}(AM_\pi).$$

在紧支撑下, 耦合集对于弱收敛是凸且紧的。由于 γ 是有限维锥上的有限规范, 且仅在原点为零, 它在切片 $\text{tr}(M) = 1$ 上等价于迹范数, 所以 $\mathcal{B}_\gamma$ 是凸且紧的。映射 $(\pi, A) \mapsto \text{tr}(AM_\pi)$ 对每个变量都是仿射且连续的。Sion 极小极大定理给出

$$\inf_{\pi} \sup_{A \in \mathcal{B}_\gamma} \text{tr}(AM_\pi) = \sup_{A \in \mathcal{B}_\gamma} \inf_{\pi} \text{tr}(AM_\pi) = \sup_{A \in \mathcal{B}_\gamma} \mathcal{W}_{2,A}(\alpha, \beta)^2.$$

对于固定的 $A \succeq 0$, $\mathcal{W}_{2,A}$ 是与半范数 $x \mapsto \|A^{1/2}x\|$ 关联的 Wasserstein 伪距离。由于所有项非负, 稳健恒等式还给出

$$\mathcal{W}_\gamma(\alpha, \beta) = \sup_{A \in \mathcal{B}_\gamma} \mathcal{W}_{2,A}(\alpha, \beta).$$

伪距离的上确界是对称的, 并且满足三角不等式。

若 $a\text{Id} \in \mathcal{B}_\gamma$ 且对所有 $A \in \mathcal{B}_\gamma$ 都有 $A \preceq b\text{Id}$, 则

$$a \mathcal{W}_2(\alpha, \beta)^2 = \mathcal{W}_{2,a\text{Id}}(\alpha, \beta)^2 \leq \mathcal{W}_\gamma(\alpha, \beta)^2 \leq b \mathcal{W}_2(\alpha, \beta)^2,$$

这证明了正定性以及与 $\mathcal{W}_2$ 的等价性。这些算子界与 $a \text{tr}(M) \leq \gamma(M) \leq b \text{tr}(M)$ 的等价性直接来自极公式。在有限维中, 任意范数限制到正半定锥上都等价于该锥上的迹范数。当这些范数等价界成立时, 有限二阶矩情形由截断得到。□

定义 9.16 (子空间稳健 Wasserstein). 对于 $1 \leq k \leq d$, Paty-Cuturi 子空间稳健 Wasserstein 距离为

$$\text{SRW}_{2,k}(\alpha, \beta) := \sup_{U^\top U = \text{Id}_k} \mathcal{W}_2((U^\top)_\# \alpha, (U^\top)_\# \beta) = \sup_{P^2 = P = P^\top, \text{tr}(P) = k} \mathcal{W}_{2,P}(\alpha, \beta).$$

对于 Ky Fan 规范

$$\gamma_k(M) = \sum_{\ell=1}^k \lambda_\ell(M),$$

其中特征值按降序排列, 其极集为

$$\mathcal{B}_{\gamma_k} = \{A; 0 \preceq A \preceq \text{Id}, \text{tr}(A) \leq k\}.$$

因此 $k = d$ 给出 $\gamma_d(M) = \text{tr}(M)$ 并恢复 $\mathcal{W}_2$ 。秩 k 投影算子的凸包为

$$\{A; 0 \preceq A \preceq \text{Id}, \text{tr}(A) = k\},$$

并且由于 $M \succeq 0$, 关联支撑函数是同一个 Ky Fan 规范。因此 $\mathcal{W}_{\gamma_k}$ 是 $\text{SRW}_{2,k}$ 的凸化谱对应物, 而 $\text{SRW}_{2,k}$ 保留原始非凸秩约束。对于 $k = 1$, $\gamma_1(M) = \lambda_{\max}(M)$ 且 $\mathcal{B}_{\gamma_1} = \{A \succeq 0; \text{tr}(A) \leq 1\}$ 。这种最大特征值谱 Wasserstein 几何正是与 [182] 中 Muon 型谱动力学相连的情形。




图 9.6: 位移协方差的迹规范与谱规范。迹规范最小化平均平方位移, 并给出从平移双圆盘源轮廓到平移心形目标的通常二次传输计划。 $\lambda_{\max}$ 规范惩罚最坏投影位移方差; 展示的传输计划通过用有限多个方向近似稳健表述得到。最后两行渲染对应的位移插值, 它们来自非常稠密的最远点轮廓样本和核平滑提升传输计划, 并使用与图 2.2 相同的约定: 白色表示零密度, 高密度在对应时间的红到蓝插值颜色中饱和。空间分离使不同位移几何更易读。

广义最优传输问题

第二类方法改变优化问题本身，而不只是改变底层距离。重心对多个测度取平均，多边缘最优传输一次耦合多个测度，逆最优传输从观测到的传输中学习代价，而弱最优传输允许随机化的条件响应。这些表述仍然接近 Kantorovich 线性规划，但被优化的对象比单个双边缘耦合更丰富。

10.1 最优传输重心

重心研究如何对概率测度而不是点取平均。本节解释其变分定义、一维情形和高斯情形中的特殊闭式形式，以及实践中使用的熵算法。

Fréchet 均值。 对于离散输入直方图 $\{b_s\}_{s=1}^S$ ，其中 $b_s \in \Sigma_{n_s}$ ，以及权重 $\lambda \in \Sigma_S$ ，Wasserstein 重心可以通过最小化

$$\min_{a \in \Sigma_n} \sum_{s=1}^S \lambda_s L_{C_s}(a, b_s), \quad (10.1)$$

来计算，其中代价矩阵 $C_s \in \mathbb{R}^{n \times n_s}$ 已给定。

这个重心问题最初由 [1] 在 [51] 的早期思想之后引入。对于 $\mathcal{X} = \mathbb{R}^d$ 上的二次代价，他们的理论在至少一个输入测度绝对连续时给出存在性和唯一性；更一般地，在保证相关最优映射良定义的假设下也成立。离散存在性、一致性和不动点构造在 [8, 5, 139] 中得到进一步研究。

给定定义在某个空间 $\mathcal{X}$ 上的一组输入测度 $(\beta_s)_s$ ，重心问题变为

$$\min_{\alpha \in \mathcal{M}_+^1(\mathcal{X})} \sum_{s=1}^S \lambda_s \mathcal{L}_c(\alpha, \beta_s). \quad (10.2)$$

对于 $\mathcal{X} = \mathbb{R}^d$ 和 $c(x, y) = \|x - y\|^2$ ，如果一个输入测度具有密度，则重心唯一 [1]。

例 10.1 (两个测度恢复一条 Wasserstein 测地线)。 当 $S = 2$ 、 $c(x, y) = \|x - y\|^2$ 且权重为 $(1 - t, t)$ 时，重心就是 β_0 与 β_1 之间 Wasserstein 测地线上时间 t 处的点。如果 T 是从 β_0 到 β_1 的 Brenier 映射，则该重心为 $((1 - t)\text{Id} + tT)_\# \beta_0$ ，也就是第 13.2 节详述的 McCann 插值。如果没有可用的 Monge 映射，同一构造使用最优耦合 π 和插值映射 $(x, y) \mapsto (1 - t)x + ty$ ，得到 $((1 - t)x + ty)_\# \pi$ 。

例 10.2 (Dirac 输入恢复 Fréchet 均值)。 问题 (10.2) 将点 $(x_s)_{s=1}^S \in \mathcal{X}^S$ 的重心计算推广到任意测度。确实，如果 $\beta_s = \delta_{x_s}$ 是单个 Dirac 质量，则 (10.2) 的一个解为 δ_{x^*} ，其中 x^* 是点 $(x_s)_s$ 的 Fréchet 均值。

注 10.3 (二次重心的均值)。 对于 $c(x, y) = \|x - y\|^2$ ，重心 α^* 的均值必然是各均值的重心，

$$\int_{\mathcal{X}} x d\alpha^*(x) = \sum_s \lambda_s \int_{\mathcal{X}} x d\beta_s(x).$$

确实，平方 Wasserstein 距离可分解为均值之间的平方距离加上一个中心化 Wasserstein 项。最小化所得的关于重心均值的二次函数，即给出所示恒等式。如果输入测度具有紧支撑，通常的多边缘重心构造还会给出一个支撑在输入支撑凸包中的重心。

下面这个基本命题解释了为什么 (10.2) 是测度上的凸优化问题。困难不在于凸性，而在于未知量本身是一个测度，其支撑事先未知。

命题 10.4 (最优传输代价的凸性)。 映射 $(\alpha, \beta) \mapsto \mathcal{L}_c(\alpha, \beta)$ 是凸的。

证明。 令 (α_0, β_0) 和 (α_1, β_1) 为两对概率测度，并令 $t \in [0, 1]$ 。对 $\eta > 0$ ，选择耦合 $\pi_i \in \mathcal{U}(\alpha_i, \beta_i)$ ，使得

$$\int c d\pi_i \leq \mathcal{L}_c(\alpha_i, \beta_i) + \eta \quad (i = 0, 1).$$




图 10.1: 四个角点测度的 Wasserstein 重心网格。左图对一个高斯分布和三个非对称双高斯混合使用一维公式 $Q_{u,v} = \sum_{i,j} \lambda_{ij}(u,v)Q_{ij}$, 并展示由平均分位数重构的密度。右图在共同像素网格上计算猫形、双圆盘、十字和三叶草轮廓的熵 Wasserstein 重心, 使用归一化平方底层代价、 $\varepsilon = 4 \cdot 10^{-4}$ 和 $5 \cdot 10^{-8}$ 的 Sinkhorn 容差。重心被渲染为密度图像, 其数值被截断在自身 95% 分位数, 而不是用阈值等高线渲染。颜色在四个角点之间插值, 并在两个图中编码相同的双线性权重。

则 $\pi_t = (1-t)\pi_0 + t\pi_1$ 是 $(1-t)\alpha_0 + t\alpha_1$ 与 $(1-t)\beta_0 + t\beta_1$ 之间的耦合。因此

$$\mathcal{L}_c((1-t)\alpha_0 + t\alpha_1, (1-t)\beta_0 + t\beta_1) \leq (1-t)\mathcal{L}_c(\alpha_0, \beta_0) + t\mathcal{L}_c(\alpha_1, \beta_1) + \eta.$$

令 $\eta \rightarrow 0$ 即得结论。 $\square$

即使所有输入测度都是离散的, 重心的支撑也无法先验知道。第 10.2 节的多边缘表述表明, 离散重心可以支撑在从每个输入各取一个支撑点所得的所有加权平均上。如果第 s 个输入有 n_s 个原子, 这会给出至多 $\prod_s n_s$ 个候选点; 当输入数量很大时, 这是不可承受的。因此, 一个常见数值折中是为重心预先指定一个较小支撑, 并求解固定支撑问题。

一维情形。 在直线上, 经过分位数变量变换之后, 重心变为线性的。这给出了少见情形: 重心是显式的, 而不是一个高维优化问题的解。

命题 10.5 (直线上的分位数重心). 对于 $\mathcal{X} = \mathbb{R}$ 和 $c(x, y) = |x - y|^2$, Wasserstein 重心的分位数函数是输入分位数函数的加权平均:

$$\mathcal{C}_{\alpha^*}^{-1}(r) = \sum_{s=1}^S \lambda_s \mathcal{C}_{\beta_s}^{-1}(r), \quad r \in [0, 1].$$

证明. 一维公式 (2.11) 给出

$$\sum_s \lambda_s \mathcal{W}_2^2(\alpha, \beta_s) = \int_0^1 \sum_s \lambda_s \left| \mathcal{C}_{\alpha}^{-1}(r) - \mathcal{C}_{\beta_s}^{-1}(r) \right|^2 dr.$$

该最小化在 r 上逐点解耦。对每个固定的 $r, z \mapsto \sum_s \lambda_s |z - \mathcal{C}_{\beta_s}^{-1}(r)|^2$ 的极小化解是加权平均 $\sum_s \lambda_s \mathcal{C}_{\beta_s}^{-1}(r)$ 。这个函数是非降的, 因为它是非降分位数函数的正加权和, 因此是一个合法的分位数函数。 $\square$

高斯情形。 高斯重心表明, 高斯 Wasserstein 公式 (2.18) 中的同样分离仍然存在: 均值线性平均, 而协方差按照 Bures–Wasserstein 几何平均。

例 10.6 (高斯输入仍保持高斯). 高斯测度的重心是高斯的。在一维中, 它通过平均均值和标准差得到, 因此重心方差是这个平均标准差的平方。在更高维中, 协方差 Σ 最小化 Bures 目标

$$\Sigma \mapsto \sum_s \lambda_s \mathcal{B}(\Sigma, \Sigma_s)^2,$$

并且等价地求解不动点方程

$$\Sigma = \sum_s \lambda_s (\Sigma^{1/2} \Sigma_s \Sigma^{1/2})^{1/2}.$$

这是通常欧氏重心方程的协方差类比：均值部分线性平均，而协方差部分通过 Bures–Wasserstein 几何平均 [5, 29]。

算法 10.1 高斯重心不动点

输入： 高斯测度 $\mathcal{N}(\mathbf{m}_s, \Sigma_s)$ ，权重 λ_s ，容差 tol 。

输出： 高斯重心 $\mathcal{N}(\mathbf{m}, \Sigma)$ 。

置 $\mathbf{m} = \sum_s \lambda_s \mathbf{m}_s$ 。

初始化： 置 $\Sigma^{(0)} = \sum_s \lambda_s \Sigma_s$ 。

对 $k = 0, 1, \dots$ **执行：**

$$S^{(k)} = \sum_s \lambda_s ((\Sigma^{(k)})^{1/2} \Sigma_s (\Sigma^{(k)})^{1/2})^{1/2}.$$

$$\Sigma^{(k+1)} = (\Sigma^{(k)})^{-1/2} (S^{(k)})^2 (\Sigma^{(k)})^{-1/2}.$$

若 $\|\Sigma^{(k+1)} - \Sigma^{(k)}\| \leq \text{tol}$ **则：**

置 $\Sigma = \Sigma^{(k+1)}$ 。**返回** $\mathcal{N}(\mathbf{m}, \Sigma)$ 。




图 10.2: 中心化高斯协方差矩阵的 Bures–Wasserstein 重心。每个图展示四个角点协方差的 5×5 重心椭圆网格，没有单独的输入图：角点椭圆本身就是四个输入协方差。右侧网格使用更具各向异性的输入，使协方差重心的非线性旋转和缩放更加可见。

重心的 Sinkhorn 算法。 与正则化双边缘最优传输问题的一个关键差异是，这里没有规范参考测度 $\alpha \otimes \beta$ ，因为重心 α 未知。为降低复杂度，人们通常为重心固定一个候选支撑并求解离散问题 (10.1)；这会引入离散化误差，但能让未知量数量保持可控。

随后可以使用熵平滑，并用

$$\min_{\mathbf{a} \in \Sigma_n} \sum_{s=1}^S \lambda_s L_{C_s}^\varepsilon(\mathbf{a}, \mathbf{b}_s) \quad (10.3)$$

近似 (10.1)，其中 $\varepsilon > 0$ 。这是一个光滑凸最小化问题，可以用梯度下降处理 [72]。另一种选择是在半对偶上使用下降法，通常是拟 Newton 方法 [73]；当要在重心上加入额外正则化（例如施加平滑性）时，这很有用。

如 [19] 所指出，一个简单而有效的方法是把 (10.3) 重写为加权 KL 投影问题

$$\min_{(\mathbf{P}_s)_s} \left\{ \varepsilon \sum_s \lambda_s \text{KL}(\mathbf{P}_s | \mathbf{K}_s); \forall s, \mathbf{P}_s^\top \mathbf{1}_n = \mathbf{b}_s, \quad \mathbf{P}_1 \mathbf{1}_{n_1} = \dots = \mathbf{P}_S \mathbf{1}_{n_S} \right\}, \quad (10.4)$$

其中 $\mathbf{K}_s := e^{-C_s/\varepsilon}$ 。重心 $\mathbf{a}$ 隐式编码在共同的行边缘中：

$$\mathbf{a} = \mathbf{P}_1 \mathbf{1}_{n_1} = \dots = \mathbf{P}_S \mathbf{1}_{n_S}.$$

求解 (10.4) 的最优耦合具有缩放形式

$$P_s = \text{diag}(u_s) K_s \text{diag}(v_s), \quad (10.5)$$

而广义 Sinkhorn 迭代为

$$\forall s \in \llbracket 1, S \rrbracket, \quad v_s^{(\ell+1)} := \frac{b_s}{K_s^\top u_s^{(\ell)}}, \quad (10.6)$$

$$\forall s \in \llbracket 1, S \rrbracket, \quad u_s^{(\ell+1)} := \frac{a^{(\ell+1)}}{K_s v_s^{(\ell+1)}}, \quad (10.7)$$

$$\text{where } a^{(\ell+1)} := \prod_s (K_s v_s^{(\ell+1)})^{\lambda_s}. \quad (10.8)$$

式 (10.8) 中的几何平均强制所有耦合共享同一个重心边缘。

算法 10.2 熵重心 Sinkhorn

输入: 代价 C_s , 目标权重 b_s , 重心权重 λ_s , 正则化 $\varepsilon > 0$, 容差 tol 。

输出: 重心权重 a 和耦合 P_s 。

初始化: 置 $K_s = e^{-C_s/\varepsilon}$, 对所有 s 置 $u_s^{(0)} = \mathbf{1}_n$, 并置 $r_0 = +\infty$, $k = 0$ 。

当 $r_k > \text{tol}$ **时执行:**

 置 $k \leftarrow k + 1$ 。

对每个边缘 s **执行**

$$v_s^{(k)} = \frac{b_s}{K_s^\top u_s^{(k-1)}}.$$

计算重心边缘: $a^{(k)} = \prod_s (K_s v_s^{(k)})^{\lambda_s}$ 。

对每个边缘 s **执行**

$$u_s^{(k)} = \frac{a^{(k)}}{K_s v_s^{(k)}}.$$

置对所有 s , $P_s^{(k)} = \text{diag}(u_s^{(k)}) K_s \text{diag}(v_s^{(k)})$ 。

置 $r_k = \max_s \max\{\|P_s^{(k)} \mathbf{1} - a^{(k)}\|_1, \|(P_s^{(k)})^\top \mathbf{1} - b_s\|_1\}$ 。

返回 $a^{(k)}$ 和 $P_s^{(k)}$ 。

命题 10.7 (熵重心的对偶). 式 (10.5) 中的最优缩放可写为 $(u_s, v_s) = (e^{f_s/\varepsilon}, e^{g_s/\varepsilon})$, 其中 $(f_s, g_s)_s$ 求解对偶问题

$$\max_{(f_s, g_s)_s} \left\{ \sum_s \lambda_s \left(\langle g_s, b_s \rangle - \varepsilon \langle K_s e^{g_s/\varepsilon}, e^{f_s/\varepsilon} \rangle \right) ; \sum_s \lambda_s f_s = 0 \right\}. \quad (10.9)$$

证明. 在 (10.4) 中引入 Lagrange 乘子:

$$\min_{(P_s)_s, a} \max_{(f_s, g_s)_s} \sum_s \lambda_s \left(\varepsilon \text{KL}(P_s | K_s) + \langle a - P_s \mathbf{1}_{n_s}, f_s \rangle + \langle b_s - P_s^\top \mathbf{1}_n, g_s \rangle \right).$$

强对偶成立, 因此可以交换最小化和最大化。关于 a 的最小化给出约束 $\sum_s \lambda_s f_s = 0$, 关于 P_s 的最小化给出 $\text{KL}(\cdot | K_s)$ 的 Legendre 变换:

$$\max_{(f_s, g_s)_s} \sum_s \lambda_s \left[\langle g_s, b_s \rangle - \varepsilon \text{KL}^* \left(\frac{f_s \oplus g_s}{\varepsilon} \middle| K_s \right) \right], \quad \sum_s \lambda_s f_s = 0.$$

可分共轭为

$$\text{KL}^*(U | K) = \sum_{i,j} K_{i,j} (e^{U_{i,j}} - 1), \quad (10.10)$$

因为对 $k > 0$,

$$\sup_{r \geq 0} ur - (r \log(r/k) - r + k) = k(e^u - 1),$$

而 $k = 0$ 的情形由下半连续性推出。去掉与 $(f_s, g_s)_s$ 无关的常数, 得到 (10.9)。关于 g_s 的坐标最大化给出 (10.6); 关于所有 $(f_s)_s$ 的块最大化给出共同边缘 (10.8), 进而给出 (10.7)。□

经典应用包括二维图像插值、三维形状插值, 以及表面上的重心, 其中底层代价是测地距离的平方; 关于计算机图形学和成像中的应用, 见 [213]。

10.2 多边缘最优传输

多边缘最优传输一次耦合两个以上的测度。它是重心、团队匹配和多体代价的自然语言，但其张量维度是主要计算障碍。

定义与基本结构。 多边缘表述用一个具有多个给定边缘的联合分布，替代两个测度之间的耦合。给定空间 $(\mathcal{X}_s)_{s=1}^S$ 上的测度 $(\alpha_s)_{s=1}^S$ 和代价 $c: \mathcal{X}_1 \times \cdots \times \mathcal{X}_S \rightarrow \mathbb{R}$ ，问题写作

$$\inf_{\pi \in \mathcal{U}(\alpha_1, \dots, \alpha_S)} \int_{\mathcal{X}_1 \times \cdots \times \mathcal{X}_S} c(x_1, \dots, x_S) d\pi(x_1, \dots, x_S),$$

其中 $\mathcal{U}(\alpha_1, \dots, \alpha_S)$ 是第 s 个边缘为 α_s 的概率测度集合。在离散设置中，这仍然是一个线性规划，但其环境张量大小为 $\prod_s n_s$ 。

重心的多边缘表述。 Wasserstein 重心是核心例子。对于平方欧氏代价，可以引入一个潜在重心点并将其显式消去，从而得到多边缘代价

$$c_{\text{bar}}(x_1, \dots, x_S) = \min_{x \in \mathbb{R}^d} \sum_{s=1}^S \lambda_s \|x - x_s\|^2.$$

命题 10.8 (二次重心的多边缘公式). 令 $\beta_1, \dots, \beta_S \in \mathcal{P}_2(\mathbb{R}^d)$ 且 $\lambda \in \Sigma_S$ 。定义

$$B(x_1, \dots, x_S) = \sum_{s=1}^S \lambda_s x_s, \quad c_{\text{bar}}(x_1, \dots, x_S) = \min_x \sum_s \lambda_s \|x - x_s\|^2.$$

如果 π^* 求解边缘为 $(\beta_s)_s$ 、代价为 c_{bar} 的多边缘最优传输问题，则 $\alpha^* = B_{\#} \pi^*$ 是一个 Wasserstein 重心。反过来，每个重心都可以用这种方式从一个最优多边缘计划得到。

证明. 对任意候选重心 α 和耦合 $\pi_s \in \mathcal{U}(\alpha, \beta_s)$ ，沿它们共同的 α 边缘粘合这些耦合，得到 $(X, Y_1, \dots, Y_S)$ 的联合律。对 $(Y_s)_s$ 条件化并关于 X 最小化，得到

$$\sum_s \lambda_s \mathbb{E} \|X - Y_s\|^2 \geq \mathbb{E} \min_x \sum_s \lambda_s \|x - Y_s\|^2 = \mathbb{E} c_{\text{bar}}(Y_1, \dots, Y_S).$$

对耦合取下确界可知，重心值至少为多边缘值。反过来，从一个最优多边缘计划 π^* 出发，令 $X = B(Y_1, \dots, Y_S)$ 。 X 与每个 Y_s 之间的耦合对重心问题可行，并且恰好达到多边缘代价，从而证明等式和公式。如果 α^* 是任意重心，选择 α^* 与每个 β_s 之间的最优耦合，并沿共同的 α^* 边缘将它们粘合。由于重心值与多边缘值相等，上述条件最小化不等式必须取等号。因此，对诱导出的最优多边缘计划，几乎必然有 $X = B(Y_1, \dots, Y_S)$ ，且 $\alpha^* = B_{\#} \pi^*$ 。□

推论 10.9 (高斯和离散重心). 高斯测度的二次 Wasserstein 重心是高斯的。如果输入测度是离散的，则存在一个重心，其支撑位于从每个输入各取一个支撑点得到的加权平均 $\sum_s \lambda_s x_{s,i_s}$ 集合上；特别地，如果第 s 个输入有 n_s 个原子，则存在一个至多具有 $\prod_s n_s$ 个原子的重心。

证明. 设输入高斯的均值为 $\mathbf{m}_s$ ，协方差为 Σ_s 。对任意候选重心 α ，其均值为 $\mathbf{m}$ 、协方差为 Σ ，后面定理 14.18 中证明的 Gelbrich 不等式 [102] 给出

$$\mathcal{W}_2^2(\alpha, \beta_s) \geq \|\mathbf{m} - \mathbf{m}_s\|^2 + \mathcal{B}(\Sigma, \Sigma_s)^2,$$

对于均值为 $\mathbf{m}$ 、协方差为 Σ 的高斯律取等号。因此，重心目标由一个只依赖于 $(\mathbf{m}, \Sigma)$ 的函数从下界定，并且该下界由具有最优均值和协方差的高斯测度达到。因此至少有一个重心是高斯的；通常非退化设置下的唯一性给出上面提到的高斯重心。对于离散输入，任意多边缘优化器都支撑在输入支撑的有限乘积上，而 B 将这个乘积映到至多 $\prod_s n_s$ 个点。□

多边缘最优传输的熵正则化。 与双边情形一样，加入相对于乘积测度 $\alpha_1 \otimes \cdots \otimes \alpha_S$ 的熵惩罚，会导致向缩放算法：

$$\inf_{\pi \in \mathcal{U}(\alpha_1, \dots, \alpha_S)} \int c d\pi + \varepsilon \text{KL}(\pi | \alpha_1 \otimes \cdots \otimes \alpha_S).$$

优化器具有广义 Gibbs 形式

$$d\pi^*(x_1, \dots, x_S) = \exp\left(\frac{\sum_s f_s(x_s) - c(x_1, \dots, x_S)}{\varepsilon}\right) \prod_s d\alpha_s(x_s),$$

而广义 Sinkhorn 迭代交替更新一个势 f_s ，使第 s 个边缘正确。瓶颈在于离散情形中的张量大小 $\prod_s n_s$ 。因此，实际重心求解器会利用代价的可分离性、低秩结构、卷积核，或固定重心支撑。

在有限维中，直接的广义缩放方案就是 Sinkhorn 的张量版本。

算法 10.3 多边缘 Sinkhorn

输入： 边缘 $\mathbf{a}_s \in \Sigma_{n_s}$ ，张量代价 C ，正则化 $\varepsilon > 0$ ，容差 tol 。

输出： 多边缘熵耦合张量 P 。

构造 $K_{i_1, \dots, i_S} = \exp\left(-\frac{C_{i_1, \dots, i_S}}{\varepsilon}\right) \prod_{s=1}^S (\mathbf{a}_s)_{i_s}$ 。

初始化： 对所有 s 置 $u_s = \mathbf{1}_{n_s}$ ，并置残差 $r = +\infty$ 。

当 $r > \text{tol}$ **时执行：**

对 $s = 1, \dots, S$ **执行：**

$$(u_s)_i \leftarrow \frac{(\mathbf{a}_s)_i}{\sum_{i_1, \dots, i_{s-1}, i_{s+1}, \dots, i_S} K_{i_1, \dots, i_{s-1}, i, i_{s+1}, \dots, i_S} \prod_{r \neq s} (u_r)_{i_r}}.$$

置 $P_{i_1, \dots, i_S} = K_{i_1, \dots, i_S} \prod_s (u_s)_{i_s}$ 。

置 $r = \max_s \|(\text{proj}_s)_\# P - \mathbf{a}_s\|_1$ 。

返回 P 。

10.3 度量学习与逆最优传输

最后一节指向底层代价本身需要学习的逆问题。这类问题通常是双层且非凸的，但最优传输提供了关于代价的有用梯度。

度量学习与最优传输的导数 最优传输关于测度是凸的，关于代价是凹的。底层度量学习在 [71] 中被明确研究，并且它与更广泛的度量学习文献相连 [137, 17]。

命题 10.10 (关于代价的导数). 在离散设置中，假设 $L_C(\mathbf{a}, \mathbf{b})$ 的最优耦合唯一，并记为 $P^*(C)$ 。则 $C \mapsto L_C(\mathbf{a}, \mathbf{b})$ 在 C 处可微，且

$$\nabla_C L_C(\mathbf{a}, \mathbf{b}) = P^*(C).$$

证明. 该值是 C 的仿射函数族的最小值，

$$L_C(\mathbf{a}, \mathbf{b}) = \min_{P \in \mathcal{U}(\mathbf{a}, \mathbf{b})} \langle C, P \rangle.$$

包络定理，或者等价地 Danskin 定理，说明关于 C 的次微分是最优耦合的凸包。如果优化器唯一，则该次微分是单点集 $\{P^*(C)\}$ ，因此该值可微，并具有所示梯度。 $\square$

因此，如果代价参数化为 C_θ ，则涉及最优传输值的损失梯度可通过内积 $\langle P^*(C_\theta), \partial_\theta C_\theta \rangle$ 反向传播得到。困难不在于对已求解的最优传输问题求导，而在于学习一种代价，使所得匹配具有期望的语义行为；这是一个双层且通常非凸的优化问题。

逆最优传输 逆最优传输要求找到一个底层代价，使观测到的匹配或流可以被解释为最优传输计划。在最直接的形式中，人们观测到一个边缘为 (α, β) 的计划 $\hat{\pi}$ ，并寻找一个代价 c ，使 $\hat{\pi}$ 对

$$\inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int c(x, y) d\pi(x, y).$$

而言是最优的。如果没有结构，这个问题是病态的：向代价加入势 $u(x) + v(y)$ 不会改变最优耦合集合，而且许多代价都可以合理化同一个稀疏计划。

一种有用的统计方法是通过 Fenchel–Young 损失度量观测计划的次优性。将得分写作 $s = -c$ ，并定义凸正则化预测值

$$G_\varepsilon(s) = \sup_{\pi \in \mathcal{U}(\alpha, \beta)} \int s d\pi - \varepsilon \text{KL}(\pi | \alpha \otimes \beta).$$




图 10.3: 改变底层度量会改变最优耦合。同一组红色和蓝色经验测度分别用欧氏度量以及两个各向异性逐渐增强的 Mahalanobis 度量下的 $c_A(x, y) = (x - y)^\top A(x - y)$ 进行匹配。小灰色椭圆展示该度量的单位球: 椭圆被拉长的方向代价更低, 这会使最优传输计划所选择的传输线段发生形变。

Fenchel-Young 损失

$$\mathcal{L}_\varepsilon(c; \hat{\pi}) = G_\varepsilon(-c) + G_\varepsilon^*(\hat{\pi}) + \int c d\hat{\pi}$$

根据 Fenchel 不等式非负, 并且恰好在 $\hat{\pi} \in \partial G_\varepsilon(-c)$ 时为零, 即当 $\hat{\pi}$ 满足关于 c 的正则化最优性条件时为零。测度上逆问题以及逆熵/非平衡最优传输的锐化 Fenchel-Young 损失在 [10] 中发展; 逆最优传输关于代价的曲率和可识别性在 [187] 中研究。熵正则化在这里很重要, 因为它使前向映射更光滑, 并提供关于 c 的梯度, 代价是引入必须在统计上控制的偏差。

在离散非正则化情形中, 这个损失退化为观测耦合的最优性间隙。对于 $\hat{P} \in \mathcal{U}(a, b)$ 和代价矩阵 C , 记其为

$$\mathcal{L}_{\text{OT}}(C; \hat{P}) = \langle C, \hat{P} \rangle - \min_{P \in \mathcal{U}(a, b)} \langle C, P \rangle.$$

这个逆最优传输间隙损失非负, 并且恰好在 $\hat{P}$ 对 C 最优时为零。

实践中, 人们将代价限制在有限维模型类中, 通常为仿射形式:

$$C_\theta = \sum_{r=1}^R \theta_r C^{(r)}, \quad \theta \in \Theta,$$

其中 Θ 是凸的, 而矩阵 $C^{(r)}$ 编码特征、图距离或 Mahalanobis 参数化。这个视角出现在低秩和稀疏逆最优传输模型 [83, 9] 中, 也出现在从观测计划学习最优传输代价的凸表述 [153, 187] 中。

一个最小的有限维模型是学习 $\mathbb{R}^d$ 上的双线性代价,

$$c_A(x, y) = \langle Ax, y \rangle, \quad A \in \mathbb{R}^{d \times d}.$$

对于经验测度 $\alpha = \frac{1}{n} \sum_i \delta_{x_i}$ 和 $\beta = \frac{1}{n} \sum_j \delta_{y_j}$, 这给出代价矩阵

$$C(A)_{i,j} = \langle Ax_i, y_j \rangle,$$

因此两个映射 $A \mapsto C(A)$ 和 $A \mapsto c_A$ 都是线性的。该模型中的逆最优传输询问哪一个矩阵 A 使观测到的匹配或耦合看起来是最优的; 代价学习因此被化约为估计一个线性参数。

对于固定矩阵 A , 前向预测是最优面

$$\mathcal{P}_A := \operatorname{argmin}_{P \in \mathcal{U}(\mathbb{1}_n/n, \mathbb{1}_n/n)} \langle C(A), P \rangle.$$

当这个面是单点时, 将其元素记为 P_A ; 否则 P_A 表示一个确定性打破平局后的选择。尽管 $A \mapsto C(A)$ 是线性的, 解对应 $A \mapsto \mathcal{P}_A$ 却是多面体式的: 改变 A 会改变探测传输多胞形的方向, 而打破平局后的选择在法锥胞元上保持常数。图 10.4 在 OT4ML 点云上展示了这个对应。该构造遵循 Python Optimal Transport 标志的视觉思想 [90]: 红色源原子、蓝色目标原子和直线段展示所选最优双射。秩一矩阵 $A = -e_1 e_1^\top$ 和 $A = -e_2 e_2^\top$ 只对水平或垂直相关性计分。矩阵 $A = -I$ 给出通常的二次 $\mathcal{W}_2$ 指派, 差别只在下面讨论的仅依赖边缘的项上; 而 $A = +I$ 反转相关性并产生反 $\mathcal{W}_2$ 匹配。

这个基本模型已经包含二次 Wasserstein 指派。向代价矩阵加入只依赖于 x_i 或只依赖于 y_j 的项, 会使所有可行耦合平移同一个常数, 因此不会改变优化器。由于

$$\|x - y\|^2 = \|x\|^2 + \|y\|^2 - 2\langle x, y \rangle,$$




图 10.4: OT4ML 标志点云上双线性代价 $c_A(x, y) = \langle Ax, y \rangle$ 的前向解。每个图用不同矩阵 A 求解等权指派问题；源原子为红色，目标原子为蓝色，灰色线段给出一个确定性最优双射。

通常的二次 Wasserstein 指派与 $A_\star = -I$ 的双线性代价具有相同优化器，差别只在这些仅依赖边缘的项和一个无关正因子上。逆问题沿相反方向进行：观测到一个耦合后，人们询问哪些矩阵 A 可能生成它。图 10.5 从两个高斯经验混合上的这个代价生成观测耦合 $\hat{P}$ ，然后沿各向异性路径

$$A_t = -\text{diag}(1+t, 1-t), \quad -1 \leq t \leq 1,$$

评估 $\mathcal{L}_{\text{iOT}}(C(A_t); \hat{P})$ ，使得 $t = 0$ 恢复生成观测耦合的矩阵。等价地，在等权情形中， $\hat{P} \in \mathcal{U}(\mathbb{1}_n/n, \mathbb{1}_n/n) = \mathcal{B}_n/n$ ，所绘制的损失是 Kantorovich 间隙

$$\mathcal{L}_{\text{iOT}}(C(A_t); \hat{P}) = \langle C(A_t), \hat{P} \rangle - \min_{P \in \mathcal{U}(\mathbb{1}_n/n, \mathbb{1}_n/n)} \langle C(A_t), P \rangle, \quad C(A_t)_{i,j} = \langle A_t x_i, y_j \rangle.$$

由于 $t \mapsto C(A_t)$ 是仿射的，而 Kantorovich 值是在固定多胞形 $\mathcal{U}(\mathbb{1}_n/n, \mathbb{1}_n/n)$ 上仿射函数族的最小值，这个一维间隙是凸且分段仿射的。对小样本而言，它的零集可能包含一个区间，反映出同一个观测耦合在邻近代价的一个锥上仍然最优。




图 10.5: 双线性代价的逆最优传输间隙损失。图 (a): 两个双高斯经验混合用 $A_\star = -I$ 对应的代价 $c_{A_\star}(x, y) = \langle A_\star x, y \rangle$ 进行匹配，它给出与二次 $\mathcal{W}_2$ 代价相同的优化器；红色和蓝色等值线展示两个采样密度。图 (b,c): 对 $n = 10$ 和 $n = 100$ ，沿 $A_t = -\text{diag}(1+t, 1-t)$ 绘制非正则化 Fenchel-Young Kantorovich 间隙 $\mathcal{L}_{\text{iOT}}(C(A_t); \hat{P})$ ，使用相同纵轴尺度。红点标记生成参数 $t = 0$ ；曲线凸且分段仿射。

$n = 10$ 与 $n = 100$ 的比较展示了一个重要统计效应：随着采样点数量增加，经验间隙的平坦区域通常收缩，并且损失在生成参数附近发展出更明显的曲率。这预示了 Peyré、Poon 和 Tron 的总体理论 [187]：在极限 $n \rightarrow +\infty$ 中，当极限 Monge 映射本身随代价参数变化而具有非退化曲率时，iOT 损失会稳健地识别代价（差别只在通常的仅依赖边缘的规范自由度上）。在这种状态下，最小化间隙不仅是观测传输最优性的证书，也是恢复底层代价的一种稳定方式。

命题 10.11 (逆最优传输的凸对偶间隙表述). 令 $\hat{P} \in \mathcal{U}(a, b)$ 为观测耦合，并令 C_θ 仿射依赖于 $\theta \in \Theta$ ，其中 Θ 是凸的。 $\hat{P}$ 对代价 C_θ 最优这一条件，等价于存在对偶势 (f, g) ，使得

$$f_i + g_j \leq (C_\theta)_{i,j} \quad \text{and} \quad \sum_{i,j} \hat{P}_{i,j} ((C_\theta)_{i,j} - f_i - g_j) = 0.$$

因此，对于凸正则化器 R ，含噪逆问题可以松弛为凸规划

$$\min_{\theta \in \Theta, f, g} R(\theta) + \lambda \sum_{i,j} \hat{P}_{i,j} ((C_\theta)_{i,j} - f_i - g_j) \quad \text{满足} \quad f_i + g_j \leq (C_\theta)_{i,j} \quad \forall i, j. \quad (10.11)$$

证明. 对于固定代价 C_θ ，Kantorovich 对偶给出

$$\min_{P \in \mathcal{U}(a,b)} \langle C_\theta, P \rangle = \max_{f_i + g_j \leq (C_\theta)_{i,j}} \langle f, a \rangle + \langle g, b \rangle.$$

由于 $\hat{P}$ 具有边缘 (a, b) ，每个对偶可行对都满足

$$\langle C_\theta, \hat{P} \rangle - \langle f, a \rangle - \langle g, b \rangle = \sum_{i,j} \hat{P}_{i,j} ((C_\theta)_{i,j} - f_i - g_j) \geq 0.$$

这个非负量恰好是 $\hat{P}$ 的原始-对偶间隙。它为零当且仅当 $\hat{P}$ 达到对偶值，因此是最优的。如果 C_θ 是仿射的，且 Θ 和 R 是凸的，则 (10.11) 中的约束和目标都是凸的，从而证明松弛结论。□

算法 10.4 通过对偶间隙拟合进行逆最优传输

输入： 观测计划 $\hat{P} \in \mathcal{U}(a, b)$ ，特征 $C^{(r)}$ ，可行集 Θ ，正则化器 R 。

输出： 识别出的代价 C_{θ^*} 和势 (f^*, g^*) 。

设置参数化代价： $C_\theta = \sum_r \theta_r C^{(r)}$ 。

令 (θ^*, f^*, g^*) **为如下问题的极小化解：** $\min_{\theta \in \Theta, f, g} R(\theta) + \lambda \sum_{i,j} \hat{P}_{i,j} ((C_\theta)_{i,j} - f_i - g_j)$

满足约束 $f_i + g_j \leq (C_\theta)_{i,j}$ **对所有** (i, j) 。 **返回** θ^* 、 C_{θ^*} 和 (f^*, g^*) 。

表述 (10.11) 很有用，因为它避免了穿过前向最优传输求解器求导：它通过使观测计划满足互补松弛来学习代价。在统计设置中， $\hat{P}$ 只被部分观测或带有噪声，因此人们加入稀疏性、低秩性、平滑性或度量约束，以选择有意义的代价 [83, 9]。对于熵最优传输，最优性条件变得更光滑：

$$\hat{P}_{i,j} \approx a_i b_j \exp \left(\frac{f_i + g_j - (C_\theta)_{i,j}}{\varepsilon} \right),$$

当 C_θ 是仿射时，这会导向基于似然或基于 KL 的凸目标，并将逆最优传输与广义 Sinkhorn 迭代和传输正则化逆问题相连接 [130, 153]。 C_θ 的神经参数化更灵活，但会重新引入非凸性；上述凸表述是清晰的数学基准线。

10.4 弱最优传输

弱最优传输放松代价，使其依赖于目的地的条件分布，而不只依赖于逐点配对。当源点被允许选择随机化响应，而模型只惩罚该响应的某种聚合量（例如其条件均值）时，它很有用。

耦合的重心投影。 因此，首先要分离出的对象，是通过将每个条件律压缩到其重心得到的映射。

定义 10.12 (耦合的重心投影). 令 $\alpha, \beta \in \mathcal{P}_2(\mathbb{R}^d)$ ，并令 $\pi \in \mathcal{U}(\alpha, \beta)$ 。相对于其第一边缘将 π 分解为 $\pi(dx, dy) = \pi_x(dy)\alpha(dx)$ 。 π 的重心投影是映射

$$\bar{T}_\pi(x) := \int_{\mathbb{R}^d} y d\pi_x(y), \quad \bar{\beta}_\pi := (\bar{T}_\pi)_\# \alpha. \quad (10.12)$$

投影目标 $\bar{\beta}_\pi$ 记录的是条件均值的分布，而不是完整的第二边缘。因此它通常不同于 β ；如果 $\pi = (\text{Id}, T)_\# \alpha$ 由一个映射诱导，则 $\bar{T}_\pi = T$ 且 $\bar{\beta}_\pi = \beta$ 。对任意耦合而言，这个投影并不是最优映射：例如，径向对称源的一个确定性旋转会投影到该旋转本身，而从该源到自身的最优映射是恒等映射。有用的正向陈述附着在二次最优计划上，正如 Ambrosio、Gigli 和 Savaré [7, Chap. 7] 发展出的关于 $\mathcal{W}_2$ 的切空间视角。

命题 10.13 (二次最优计划的重心投影). 令 $\pi \in \mathcal{U}(\alpha, \beta)$ 为 $\alpha, \beta \in \mathcal{P}_2(\mathbb{R}^d)$ 之间关于二次代价 $\|x - y\|^2$ 的最优耦合，并由 (10.12) 定义 $\bar{T}_\pi$ 和 $\bar{\beta}_\pi$ 。则 $(\text{Id}, \bar{T}_\pi)_\# \alpha$ 是 α 与 $\bar{\beta}_\pi$ 之间的最优耦合。等价地， $\bar{T}_\pi$ 是从 α 到投影目标 $\bar{\beta}_\pi$ 的二次最优传输映射。

证明. 由定理 3.28, 对于 $c(x, y) = \|x - y\|^2$, π 集中在一个 c -循环单调集合 Γ 上. 对于二次代价, 并且由于只需检查循环置换, 这意味着每个有限循环 $(x_i, y_i)_{i=1}^m \subset \Gamma$ 都满足

$$\sum_{i=1}^m \langle x_i, y_i \rangle \geq \sum_{i=1}^m \langle x_i, y_{i+1} \rangle, \quad y_{m+1} = y_1.$$

在一个 α -零测集上改变分解后, π_x 支撑在截面

$$\Gamma_x = \{y; (x, y) \in \Gamma\}$$

上, 对 α -几乎处处的 x 成立. 在这个满测集中选择 $x_1, \dots, x_m$, 并独立采样 $Y_i \sim \pi_{x_i}$. 将循环不等式应用于 (x_i, Y_i) 并取期望, 得到

$$\sum_{i=1}^m \langle x_i, \bar{T}_\pi(x_i) \rangle \geq \sum_{i=1}^m \langle x_i, \bar{T}_\pi(x_{i+1}) \rangle.$$

因此 $(\text{Id}, \bar{T}_\pi)_\# \alpha$ 集中在一个循环单调图上. 根据二次最优性的循环单调刻画, 该计划在其两个边缘之间, 即 α 和 $\bar{\beta}_\pi$ 之间, 是最优的. $\square$

弱传输代价使用同样的分解, 但允许目标依赖于整个条件律, 或依赖于重心投影 (10.12) 这样的摘要量. 该框架通过一般传输代价和弱传输不等式在 [110] 中引入; Polish 空间上的存在性、对偶性和最优性条件在 [15] 中发展. 对于弱代价 $C: \mathcal{X} \times \mathcal{P}(\mathcal{Y}) \rightarrow \mathbb{R} \cup \{+\infty\}$, 弱最优传输值为

$$\text{WOT}_C(\alpha, \beta) := \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int C(x, \pi_x) d\alpha(x). \quad (10.13)$$

当 $C(x, \nu) = \int c(x, y) d\nu(y)$ 时恢复经典 Kantorovich 问题, 因为此时目标变为 $\int c(x, y) d\pi(x, y)$. 真正的弱行为从 C 关于 ν 非线性时开始.

命题 10.14 (弱 Kantorovich 对偶). 假设 $\mathcal{X}, \mathcal{Y}$ 是紧度量空间, 且 $C(x, \nu)$ 下半连续、有下界并关于 ν 凸, 同时满足保证 Fenchel–Rockafellar 对偶性的标准资格条件. 对 $g \in \mathcal{C}(\mathcal{Y})$, 定义弱 C -变换

$$g^C(x) := \inf_{\nu \in \mathcal{P}(\mathcal{Y})} \left\{ C(x, \nu) - \int g(y) d\nu(y) \right\}.$$

则

$$\text{WOT}_C(\alpha, \beta) = \sup_{g \in \mathcal{C}(\mathcal{Y})} \left\{ \int g^C(x) d\alpha(x) + \int g(y) d\beta(y) \right\}.$$

当 $C(x, \nu) = \int c(x, y) d\nu(y)$ 时, 这退化为通常的 Kantorovich 对偶, 其中 $g^C(x) = \inf_y (c(x, y) - g(y))$.

证明. 对任意耦合 π 和任意 $g \in \mathcal{C}(\mathcal{Y})$, g^C 的定义给出

$$C(x, \pi_x) \geq g^C(x) + \int g(y) d\pi_x(y).$$

关于 α 积分后, 由于 π 的第二边缘是 β , 第二项变为 $\int g d\beta$. 这证明弱对偶性.

对于反向不等式, 考虑概率核 $x \mapsto \pi_x$ 上的凸最小化, 并带有仿射约束 $\int \pi_x d\alpha(x) = \beta$. Fenchel–Rockafellar 对偶性为该边缘约束给出一个连续 Lagrange 乘子 g . 在每个条件律上最小化 Lagrangian, 恰好给出逐点项 $g^C(x)$, 而乘子贡献 $\int g d\beta$. 紧性、下半连续性、凸性和资格假设确保没有对偶间隙. 这是命题 4.2 的弱代价类比. $\square$

命题 10.15 (重心弱传输弱于 $\mathcal{W}_2$). 令 $\alpha, \beta \in \mathcal{P}_2(\mathbb{R}^d)$ 并定义

$$C_{\text{bar}}(x, \nu) = \|x - \int y d\nu(y)\|^2.$$

等价地, 对于耦合 π , 被积函数为 $\|x - \bar{T}_\pi(x)\|^2$. 于是

$$\mathcal{W}_{C_{\text{bar}}}(\alpha, \beta) \leq \mathcal{W}_2^2(\alpha, \beta).$$




图 10.6: 小型圆盘到环带耦合上的弱重心传输。左图展示完整条件律: 每个红色源原子把自身质量分配到若干蓝色目标原子, 线段粗细与被传输质量成比例。右图将每个条件律 π_x 压缩到其重心 $\bar{T}_\pi(x) = \int y d\pi_x(y)$, 以紫色显示。重心弱代价只看到从红色到紫色的位移, 因此忽略每个重心周围的条件散布。

证明. 令 π 为任意耦合, 并将其分解为 $\pi_x \alpha$ 。由 Jensen 不等式,

$$\|x - \bar{T}_\pi(x)\|^2 \leq \int \|x - y\|^2 d\pi_x(y).$$

关于 x 积分得到 $\int C_{\text{bar}}(x, \pi_x) d\alpha(x) \leq \int \|x - y\|^2 d\pi(x, y)$ 。对 π 取下确界即证得结论。 $\square$

重心代价是应当牢记的典型例子: 可接受性仍然约束完整条件律, 使其具有第二边缘 β , 但目标只对从 x 到 $\bar{T}_\pi(x)$ 的位移收费, 并忽略该重心周围的条件方差。这将弱最优传输与鞅传输、Strassen 型凸序约束、重心投影以及条件平均有意义的学习问题联系起来。

超越测度比较

最后一组方法离开了共同环境空间上的标量测度设置。向量值和矩阵值最优传输会传输带有内部自由度的质量，Gromov–Wasserstein 在没有预设对应的情况下比较度量-测度空间，而量子最优传输用正算子替代标量耦合。在每种情形中，传输计划还必须编码由支撑、纤维或非交换状态空间携带的结构。

11.1 向量值与矩阵值测度

标量最优传输传输非负密度。在成像、颜色处理、谱分析、扩散张量成像和量子启发模型中，附着在一个点上的对象可以改为具有若干非负分量，或是一个正半定矩阵。超越标量最优传输的第一步是正向量值情形，其中纤维仍然是线性且交换的，但通道可以相互作用。

正向量值测度。

定义 11.1 (正向量值测度). $\mathcal{X}$ 上的正 $\mathbb{R}_+^m$ -值测度是一个元组

$$\mu = (\mu^1, \dots, \mu^m) \in \mathcal{M}_+(\mathcal{X}; \mathbb{R}_+^m),$$

其中每个分量 μ^k 都是非负有限测度。

这建模多通道密度，例如颜色直方图、谱箱，或同一域上传输的若干物种。在守恒模型中，每个通道的质量保持不变，因此假设对每个 k 都有 $\mu_0^k(\mathcal{X}) = \mu_1^k(\mathcal{X})$ 。最优传输的自然向量值扩展因此从正锥 $\mathbb{R}_+^m$ 开始。

为保持记号可读，先假设端点和曲线都有密度。Benamou–Brenier 的直接类比固定向量密度 $u_t(x) \in \mathbb{R}_+^m$ 和空间通量 $V_t(x) = (V_{t,1}, \dots, V_{t,d}) \in (\mathbb{R}^m)^d$ ，其中 $V_{t,\ell}^k$ 是通道 k 在空间方向 ℓ 上的动量。与作用量密度 Φ 相关的守恒向量传输代价为

$$\mathcal{W}_\Phi^2(\mu_0, \mu_1) := \inf_{u, V} \int_0^1 \int_{\mathcal{X}} \Phi(u_t(x), V_t(x)) \, dx \, dt \quad (11.1)$$

并满足端点约束 $u_0 dx = \mu_0$ 、 $u_1 dx = \mu_1$ 以及逐分量连续性方程

$$\partial_t u_t + \nabla_x \cdot V_t = 0, \quad (\nabla_x \cdot V_t)^k = \sum_{\ell=1}^d \partial_{x_\ell} V_{t,\ell}^k. \quad (11.2)$$

因此，每个分量都满足自己的连续性方程，但代价仍然可以耦合这些分量。奇异曲线的处理与标量动态最优传输中一样：用测度替代密度和通量，并使用下半连续的透视退化约定。

下面这个基本族将独立通道运动与真正耦合的向量传输区分开来。

例 11.2 (对角与耦合的正迁移率). 选择迁移率矩阵 $M(u) \in \mathbb{S}_+^m$ ，其中 $\mathbb{S}_+^m$ 表示实对称正半定矩阵锥，并置

$$\Phi_M(u, V) = \sum_{\ell=1}^d V_\ell^\top M(u)^\dagger V_\ell,$$

并采用通常约定：只有当每个 V_ℓ 属于 $M(u)$ 的值域时，该值才有限。选择 M ，使这个矩阵透视函数关于 (u, V) 是凸且一齐次的；这对下面的线性正迁移率成立。当 $m = 1$ 且 $M(u) = u$ 时，恰好恢复标量 Benamou–Brenier 作用量。对于

$$M_{\text{diag}}(u) = \text{diag}(u_1, \dots, u_m),$$

各通道独立运动。非对角迁移率是在保持同一个逐分量守恒律的同时耦合坐标的最简单方式。例如，取 $q = m^{-1/2}(1, \dots, 1)$ 和 $\kappa \geq 0$,

$$M_\kappa(u) = \text{diag}(u) + \kappa \left(\sum_{k=1}^m u_k \right) q q^\top$$

会增加公共通道方向 q 上的迁移率，同时让横向方向仍由对角部分控制。因此，移动一个分量的局部代价可以依赖于其他分量的密度和动量，尽管每个分量的质量仍然守恒。

命题 11.3 (对角正向量 Benamou–Brenier). 假设对每个 k , $\mu_0^k, \mu_1^k \in \mathcal{M}_+(\mathcal{X})$ 具有相同质量 m_k 。对于对角迁移率 M_{diag} , (11.1) 的值为

$$\mathcal{W}_{\text{diag}}^2(\mu_0, \mu_1) = \sum_{k: m_k > 0} m_k \mathcal{W}_2^2\left(\frac{\mu_0^k}{m_k}, \frac{\mu_1^k}{m_k}\right),$$

并约定零质量通道贡献为零。

证明. 对于 $M_{\text{diag}}(u) = \text{diag}(u_1, \dots, u_m)$, 作用量分离为

$$\sum_{\ell=1}^d V_\ell^\top M_{\text{diag}}(u)^\dagger V_\ell = \sum_{k=1}^m \frac{|V^k|^2}{u^k},$$

其中 $V^k = (V_1^k, \dots, V_d^k)$ 是通道 k 的空间动量，并使用标量透视约定。约束 (11.2) 也分离为 $\partial_t u^k + \nabla \cdot V^k = 0$ 。因此，最小化分裂为 m 个独立的标量 Benamou–Brenier 问题。如果 $m_k = 0$ ，非负性和守恒迫使整个通道为零。如果 $m_k > 0$ ，归一化 $\rho_t^k = u_t^k/m_k$ 和 $p_t^k = V_t^k/m_k$ 会把通道作用量分解为 $m_k \int |p_t^k|^2 / \rho_t^k$ ，因此标量值为 $m_k \mathcal{W}_2^2(\mu_0^k/m_k, \mu_1^k/m_k)$ 。对通道求和即证明结论。 $\square$

上面的守恒正锥模型是 Benamou–Brenier 的基本扩展。加入源项 $\partial_t u + \nabla \cdot V = S$ 以及关于 S 的凸透视惩罚，可得到非平衡或反应–传输变体。Maas、Rumpf、Schönlieb 和 Simon [155, 156] 发展了带耗散和密度调制的这类广义传输模型；相关非线性迁移率距离和梯度结构见 [80, 165]。图 11.1 对比了精确对角情形 $\kappa = 0$ 与一个大 κ 的示意性公共模式插值：前者中每个正通道由其分位数映射传输，后者中各通道以更协调的方式移动。端点是双模态混合：在每个空间模态处，两个通道具有中心相同但振幅不同的高斯剖面。




图 11.1: 用箭头字形在八个时间层显示的一维正 $\mathbb{R}_+^2$ -值传输。每个端点都是两个局部高斯模态的混合，并且在每个模态内部，两个通道剖面具有相同中心。每个箭头与局部纤维值 $(u_t^1(x), u_t^2(x))$ 成比例，时间从红色源到蓝色目标沿竖直方向推进。左：当 $\kappa = 0$ 时，命题 11.3 的对角迁移率给出两条独立的标量分位数测地线。右：大 κ 的公共模式插值使显示朝方向 $q = 2^{-1/2}(1, 1)$ 弯曲，说明在保持同一逐分量连续性方程的同时，偏好协调通道运动的迁移率所产生的定性效果。

正矩阵值测度。 下一个最简单的纤维是正矩阵锥。这是超越向量的最简单张量值模型：对角元表现得像正通道，而特征向量编码局部方向。

定义 11.4 (正矩阵值测度). 记 S^m 为实对称矩阵空间， S_+^m 为正半定锥。正 S_+^m -值测度是一个元素

$$\mathcal{A} \in \mathcal{M}_+(\mathcal{X}; S_+^m).$$

如果 $\mathcal{A}$ 具有密度 $A(x) \geq 0$ ，则 $\text{tr } A(x)$ 是 x 处的标量质量量；而在 $\text{tr } A(x) > 0$ 的地方，归一化矩阵 $A(x)/\text{tr } A(x)$ 记录内部协方差或方向。这是正向量情形的矩阵类比：对角矩阵编码非负向量分量，非对角矩阵则添加局部特征基。

守恒 Benamou–Brenier 模型固定矩阵密度 $A_t(x) \in \mathbb{S}_+^m$ 和对称矩阵通量 $P_t(x) = (P_{t,1}, \dots, P_{t,d}) \in (\mathbb{S}^m)^d$ 。如果没有通量穿过 $\mathcal{X}$ 的边界，则总矩阵质量 $\int_{\mathcal{X}} A_t(x) dx$ 守恒，因此端点必须具有相同总矩阵。该模型最小化矩阵透视作用量

$$\mathcal{W}_{\text{mat}}^2(\mathcal{A}_0, \mathcal{A}_1) := \inf_{A, P} \int_0^1 \int_{\mathcal{X}} \sum_{\ell=1}^d \text{tr}(P_{t,\ell}^\top A_t^\dagger P_{t,\ell}) dx dt \quad (11.3)$$

并满足 $A_0 dx = \mathcal{A}_0$ 、 $A_1 dx = \mathcal{A}_1$ 以及矩阵值连续性方程

$$\partial_t A_t + \nabla_x \cdot P_t = 0, \quad \nabla_x \cdot P_t = \sum_{\ell=1}^d \partial_{x_\ell} P_{t,\ell}. \quad (11.4)$$

这里 $A^\dagger$ 表示 Moore–Penrose 逆，并采用通常的透视约定：只有当每个 $P_{t,\ell}$ 的列属于 A_t 的值域时，作用量才有限。映射 $(A, P) \mapsto \text{tr}(P^\top A^\dagger P)$ 是矩阵分式函数；它在 $A \succeq 0$ 上联合凸。这给出最简单的非平凡矩阵值传输模型：空间运动是守恒的，但纤维通过 $A_t(x)$ 的特征向量携带方向。

命题 11.5 (对角矩阵子问题). 假设端点在某个固定正交规范基中是对角的，

$$\mathcal{A}_i = \text{diag}(\mu_i^1, \dots, \mu_i^m), \quad i = 0, 1,$$

并且对每个 k 都有 $\mu_0^k(\mathcal{X}) = \mu_1^k(\mathcal{X}) = m_k$ 。如果将 (11.3) 中的可接受曲线限制为在该基中保持对角，

$$A_t = \text{diag}(u_t^1, \dots, u_t^m), \quad P_{t,\ell} = \text{diag}(V_{t,\ell}^1, \dots, V_{t,\ell}^m),$$

则这个受限矩阵问题的值为

$$\sum_{k: m_k > 0} m_k \mathcal{W}_2^2\left(\frac{\mu_0^k}{m_k}, \frac{\mu_1^k}{m_k}\right),$$

其中零质量通道贡献为零。因此，交换矩阵子模型恰好就是命题 11.3 的对角正向量值 Benamou–Brenier 模型。

证明. 连续性方程 (11.4) 按对角元逐项成立，并给出 $\partial_t u^k + \nabla \cdot V^k = 0$ 。此外，

$$\sum_{\ell=1}^d \text{tr}(P_{t,\ell}^\top A_t^\dagger P_{t,\ell}) = \sum_{k=1}^m \frac{|V_t^k|^2}{u_t^k}$$

并采用与之前相同的标量透视约定。因此，可接受集合和作用量恰好就是对角向量模型的可接受集合和作用量。□

限制到固定对角基给出特征值传输；它应被理解为一个交换子模型，而不是声称非对角偏离永远不能改变非受限值。真正的矩阵值情形从特征空间随 x 或沿插值变化时开始，此时被传输对象同时携带质量和方向。静态矩阵值 Monge–Kantorovich 问题和对偶测试函数度量在 [173, 127, 174] 中发展；动态版本和相关非交换几何见 [61, 59, 49, 184]。图 11.2 对正 2×2 矩阵纤维展示类似的独立/耦合对比，使用两个局部矩阵模态，并且在每个模态处其特征值剖面共享一个共同中心。




图 11.2: 一维基空间上的正 2×2 矩阵值传输。每个端点都是两个局部矩阵模态的混合；在一个模态内，两个特征值剖面都是中心相同的高斯凸包。每个椭圆是正半定矩阵 $A_t(x)$ 的字形，其轴由特征向量和特征值给出。左：矩阵在固定基中对角化，给出独立向量通道的交换张量类比。右：一个耦合的示意性插值使包运动向迹密度传输弯曲，并使用非交换特征方向；叠加仍保持正半定，并产生空间变化的方向。

11.2 Gromov–Wasserstein

Gromov–Wasserstein 通过空间的内部距离结构来比较空间，而不是通过固定环境底层代价。这是对点未预对齐的图、形状和点云的正确扩展。

离散表述。 最优传输需要底层代价 C 来比较直方图 (a, b)；因此，如果这些直方图并非定义在同一底层空间上，或者无法预先配准这些空间以定义底层代价，就不能直接使用它。为解决这个问题，可以改用较弱要求：有两个矩阵 $D \in \mathbb{R}^{n \times n}$ 和 $D' \in \mathbb{R}^{m \times m}$ 可用，并表示定义直方图的点之间的关系。典型场景是这些矩阵为距离矩阵的幂。Gromov–Wasserstein 问题写作

$$\text{GW}((a, D), (b, D'))^p := \min_{P \in \mathcal{U}(a, b)} \mathcal{E}_{D, D'}(P) := \sum_{i, j, i', j'} \Delta(D_{i, i'}, D'_{j, j'})^p P_{i, j} P_{i', j'}, \quad (11.5)$$

其中 $p \geq 1$ ， Δ 是 $\mathbb{R}$ 上的距离，通常为 $\Delta(u, v) = |u - v|$ 。这是传输多胞形上的非凸二次问题。在均匀情形中，如果额外施加硬指派约束 $m = n$ 且 P 为置换矩阵，它就变成二次指派问题 (QAP) [150]；这个受限的图匹配形式在完全一般情形下已经是 NP-hard 的。因此，GW 使用的松弛耦合表述可以被理解为软图匹配模型 [152]。




图 11.3: 递增形变下的 Gromov–Wasserstein 对应。红色和蓝色点云不是通过环境欧氏交叉代价比较；相反，GW 耦合比较它们的内部成对距离。完美等距副本允许清晰的结构匹配，而轻微和有意更强的形变会逐渐弯曲对应。

当矩阵 D, D' 是真正的距离矩阵时，下面的一般构造表明 GW 满足三角不等式，并在保测等距意义下定义配备概率分布的度量空间之间的距离。该距离由 Memoli 在 [160] 中引入并详细研究。深入的数学阐述（特别是其测地结构和梯度流）见 [221]。关于计算机视觉中的应用，也见 [203]。它与 Hausdorff 和 Gromov–Hausdorff 距离的关系将在本节末尾讨论。

一般设置。

定义 11.6 (度量-测度空间). 度量-测度空间是一个三元组

$$\mathbb{X} = (\mathcal{X}, d_{\mathcal{X}}, \alpha),$$

其中 $(\mathcal{X}, d_{\mathcal{X}})$ 是度量空间， α 是 $\mathcal{X}$ 上的概率测度。

一般设置对应于计算度量-测度空间 $\mathbb{X} = (\mathcal{X}, d_{\mathcal{X}}, \alpha)$ 与 $\mathbb{Y} = (\mathcal{Y}, d_{\mathcal{Y}}, \beta)$ 之间的耦合，其中距离和测度都是数据的一部分。自然设置是 Polish 度量空间；本节中常假设紧性，以避免存在性和可积性问题。定义

$$\mathcal{GW}(\mathbb{X}, \mathbb{Y})^p := \min_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X}^2 \times \mathcal{Y}^2} \Delta(d_{\mathcal{X}}(x, x'), d_{\mathcal{Y}}(y, y'))^p d\pi(x, y) d\pi(x', y'). \quad (11.6)$$

命题 11.7 (欧氏 GW 由 Wasserstein 控制). 令 α, β 为 $\mathbb{R}^d$ 上的概率测度，配备欧氏距离，并在 (11.6) 中取 $\Delta(u, v) = |u - v|$ 。则

$$\mathcal{GW}((\mathbb{R}^d, \|\cdot\|, \alpha), (\mathbb{R}^d, \|\cdot\|, \beta)) \leq 2 \mathcal{W}_p(\alpha, \beta).$$

证明. 令 π 为 α 与 β 之间的任意耦合。对于两个独立对 $(X, Y), (X', Y') \sim \pi$ ，反三角不等式给出

$$\|X - X'\| - \|Y - Y'\| \leq \|X - Y\| + \|X' - Y'\|.$$

取 L^p 范数并使用 Minkowski 不等式，得到上界 $2(\int \|x - y\|^p d\pi)^{1/p}$ 。对 π 优化即证明结论。□

为了把 GW 从一个畸变分数转化为一个度量陈述，必须商掉同时保持距离和质量的重标记。

定义 11.8 (等距度量-测度空间). 两个度量-测度空间 $\mathbb{X} = (\mathcal{X}, d_{\mathcal{X}}, \alpha)$ 和 $\mathbb{Y} = (\mathcal{Y}, d_{\mathcal{Y}}, \beta)$ 称为等距的, 如果存在可测映射 $\varphi: \text{supp}(\alpha) \rightarrow \text{supp}(\beta)$, 使得 $\varphi_{\#}\alpha = \beta$, $\varphi(\text{supp}(\alpha)) = \text{supp}(\beta)$, 并且

$$d_{\mathcal{Y}}(\varphi(x), \varphi(x')) = d_{\mathcal{X}}(x, x')$$

对所有 $x, x' \in \text{supp}(\alpha)$ 成立。

下一个定理解释了为什么上面的平均畸变不只是一个匹配分数。一旦商掉保测等距, 它就在度量-测度空间之间定义了真正的距离。

定理 11.9 (模等距意义下的 Gromov-Wasserstein 度量). 对于紧度量-测度空间, 当 $p \geq 1$ 且 $\Delta(u, v) = |u - v|$ 时, $\mathcal{GW}$ 在保测等距意义下定义一个距离。

证明. 如果 $\mathcal{GW}(\mathbb{X}, \mathbb{Y}) = 0$ 且 π 是一个最优计划, 则 $d_{\mathcal{X}}(x, x') = d_{\mathcal{Y}}(y, y')$ 在 $\pi \otimes \pi$ -几乎处处成立。由连续性, 该等式在 $\text{supp}(\pi)^2$ 上成立。我们通过证明 $\mathbb{X}$ 和 $\mathbb{Y}$ 都等距于支撑空间 $(\text{supp}(\pi), d_{\pi}, \pi)$, 来证明它们等距, 其中

$$d_{\pi}((x, y), (x', y')) := \frac{1}{2}d_{\mathcal{X}}(x, x') + \frac{1}{2}d_{\mathcal{Y}}(y, y').$$

第一投影 $\psi: (x, y) \mapsto x$ 保持测度。对 $((x, y), (x', y')) \in \text{supp}(\pi)^2$,

$$d_{\mathcal{X}}(\psi(x, y), \psi(x', y')) = d_{\mathcal{X}}(x, x') = d_{\mathcal{Y}}(y, y') = d_{\pi}((x, y), (x', y')),$$

因此 ψ 是等距映射, 从而是单射。为说明其满射到 $\text{supp}(\alpha)$, 取 $x \in \text{supp}(\alpha)$ 。由于 $\psi_{\#}\pi = \alpha$, 存在序列 $(x_k, y_k) \in \text{supp}(\pi)$ 使得 $x_k \rightarrow x$ 。 $\text{supp}(\pi)$ 上的距离相等性使 $(y_k)_k$ 成为 Cauchy 序列, 而紧性给出一个收敛子序列, 其极限为 $(x, y) \in \text{supp}(\pi)$ 。对第二投影使用同样论证, 表明支撑空间也等距于 $\mathbb{Y}$ 。

对于三角不等式, 令 π 为 $\mathbb{X}$ 与 $\mathbb{Y}$ 之间的最优耦合, ξ 为 $\mathbb{Y}$ 与 $\mathbb{Z} = (Z, d_Z, \gamma)$ 之间的最优耦合。由粘合引理, 取 $\mathcal{X} \times \mathcal{Y} \times Z$ 上的 σ , 其 $(\mathcal{X}, \mathcal{Y})$ 和 $(\mathcal{Y}, Z)$ 边缘分别为 π 和 ξ 。令 $\rho = (P_{\mathcal{X}, Z})_{\#}\sigma$, 并记 $\bar{\sigma} = \sigma \otimes \sigma$ 为两个独立三元组 (x, y, z) 与 (x', y', z') 的乘积律。于是 ρ 在 $\mathbb{X}$ 与 $\mathbb{Z}$ 之间可行, 并且

$$\begin{aligned} \mathcal{GW}(\mathbb{X}, \mathbb{Z}) &\leq \left(\int |d_{\mathcal{X}}(x, x') - d_Z(z, z')|^p d\bar{\sigma} \right)^{1/p} \\ &\leq \left(\int |d_{\mathcal{X}}(x, x') - d_{\mathcal{Y}}(y, y')|^p d\bar{\sigma} \right)^{1/p} + \left(\int |d_{\mathcal{Y}}(y, y') - d_Z(z, z')|^p d\bar{\sigma} \right)^{1/p} \\ &= \mathcal{GW}(\mathbb{X}, \mathbb{Y}) + \mathcal{GW}(\mathbb{Y}, \mathbb{Z}), \end{aligned}$$

其中第二个不等式使用逐点三角不等式, 随后使用 Minkowski 不等式。对称性和非负性是直接的。 $\square$

度量结构还给出测地线。Sturm 的构造在概念上很有用, 因为它允许人们直接在度量-测度空间的空间上讨论插值、重心和梯度流, 尽管中间空间位于乘积支撑上, 因此数值代价较高 [221]。

命题 11.10 (Gromov-Wasserstein 测地线). 令 $\mathbb{X}_0 = (\mathcal{X}_0, d_{\mathcal{X}_0}, \alpha_0)$ 和 $\mathbb{X}_1 = (\mathcal{X}_1, d_{\mathcal{X}_1}, \alpha_1)$ 为紧度量-测度空间, 在 (11.6) 中取 $\Delta(u, v) = |u - v|$, 并令 π^* 为最优耦合。在 $Z = \mathcal{X}_0 \times \mathcal{X}_1$ 上定义

$$d_t((x_0, x_1), (x'_0, x'_1)) := (1 - t)d_{\mathcal{X}_0}(x_0, x'_0) + td_{\mathcal{X}_1}(x_1, x'_1), \quad \mathbb{X}_t = (Z, d_t, \pi^*).$$

在 $t = 0$ 和 $t = 1$, 以及可能的退化情形中, 将 Z 按与 d_t 相关的零距离关系取商。则 $t \mapsto \mathbb{X}_t$ 是一条常速测地线:

$$\mathcal{GW}(\mathbb{X}_s, \mathbb{X}_t) = |t - s| \mathcal{GW}(\mathbb{X}_0, \mathbb{X}_1) \quad \forall s, t \in [0, 1].$$

证明. 记 $D = \mathcal{GW}(\mathbb{X}_0, \mathbb{X}_1)$ 。对 $s < t$, 用 Z 上恒等映射和测度 π^* 诱导的对角耦合来耦合 $\mathbb{X}_s$ 与 $\mathbb{X}_t$ 。对于从 π^* 采样的两个独立点 $z = (x_0, x_1)$ 和 $z' = (x'_0, x'_1)$,

$$d_t(z, z') - d_s(z, z') = (t - s)(d_{\mathcal{X}_1}(x_1, x'_1) - d_{\mathcal{X}_0}(x_0, x'_0)).$$

使用这个可行耦合给出 $\mathcal{GW}(\mathbb{X}_s, \mathbb{X}_t) \leq (t - s)D$ 。用从 Z 到 $\mathcal{X}_0$ 和 $\mathcal{X}_1$ 的投影作同样构造, 给出 $\mathcal{GW}(\mathbb{X}_0, \mathbb{X}_t) \leq tD$ 和 $\mathcal{GW}(\mathbb{X}_t, \mathbb{X}_1) \leq (1 - t)D$ 。于是 $\mathcal{GW}$ 的三角不等式给出, 对 $0 \leq s \leq t \leq 1$,

$$D \leq \mathcal{GW}(\mathbb{X}_0, \mathbb{X}_s) + \mathcal{GW}(\mathbb{X}_s, \mathbb{X}_t) + \mathcal{GW}(\mathbb{X}_t, \mathbb{X}_1) \leq sD + \mathcal{GW}(\mathbb{X}_s, \mathbb{X}_t) + (1 - t)D,$$

因此 $\mathcal{GW}(\mathbb{X}_s, \mathbb{X}_t) \geq (t - s)D$ 。这证明了等号成立。 $\square$




图 11.4: 轻微非等距 GW 匹配中的局部畸变。左图按所显示硬对应诱导的平均残差为传输线段着色。右图以白到黑的尺度显示成对距离残差矩阵 $|d_X(x_i, x_{i'}) - d_Y(y_{\sigma(i)}, y_{\sigma(i')})|$, 较暗条目标记较大的局部畸变。该矩阵是离散 GW 目标在所显示对应下最小化的局部贡献。

现在记录上面使用的剖面下界, 作为非凸求解器的有用初始化原则。

命题 11.11 (Mémoli 剖面下界). 令 $\mathbb{X} = (\mathcal{X}, d_X, \alpha)$ 和 $\mathbb{Y} = (\mathcal{Y}, d_Y, \beta)$ 为紧度量-测度空间, 并在 (11.6) 中取 $\Delta(u, v) = |u - v|$, 使用相同指数 $p \geq 1$ 。对每个 $x \in \mathcal{X}$ 和 $y \in \mathcal{Y}$, 定义 $\mathbb{R}_+$ 上的距离剖面测度为

$$\alpha_x := (d_X(x, \cdot))_{\#} \alpha, \quad \beta_y := (d_Y(y, \cdot))_{\#} \beta.$$

令 $E_X = (x \mapsto \alpha_x)_{\#} \alpha$ 和 $E_Y = (y \mapsto \beta_y)_{\#} \beta$, 它们是 $\mathcal{P}(\mathbb{R}_+)$ 上的概率测度。则

$$\mathcal{W}_p(E_X, E_Y) \leq \mathcal{GW}(\mathbb{X}, \mathbb{Y}).$$

这里左侧距离取在剖面测度空间 $\mathcal{P}(\mathbb{R}_+)$ 上。其底层代价是一维 Wasserstein 距离 $\mathcal{W}_p$ 。

证明. 固定任意 $\pi \in \mathcal{U}(\alpha, \beta)$ 。它诱导 E_X 与 E_Y 之间的一个耦合 $(x, y) \mapsto (\alpha_x, \beta_y)$, 因此

$$\mathcal{W}_p(E_X, E_Y)^p \leq \int_{\mathcal{X} \times \mathcal{Y}} \mathcal{W}_p(\alpha_x, \beta_y)^p d\pi(x, y).$$

对于固定的 (x, y) , 映射 $(x', y') \mapsto (d_X(x, x'), d_Y(y, y'))$ 将同一个耦合 π 推到 α_x 与 β_y 之间的耦合。因此

$$\mathcal{W}_p(\alpha_x, \beta_y)^p \leq \int_{\mathcal{X} \times \mathcal{Y}} |d_X(x, x') - d_Y(y, y')|^p d\pi(x', y').$$

对 (x, y) 积分得到

$$\mathcal{W}_p(E_X, E_Y)^p \leq \int_{\mathcal{X}^2 \times \mathcal{Y}^2} |d_X(x, x') - d_Y(y, y')|^p d\pi(x, y) d\pi(x', y').$$

对 π 取下确界, 然后取 p 次根, 即证明结论。 $\square$

这个下界在计算上很有用, 因为剖面代价矩阵 $C_{ij} = \mathcal{W}_p(\alpha_{x_i}, \beta_{y_j})^p$ 是点之间的普通最优传输代价。在优化完整成对距离畸变之前, 求解这个更容易的最优传输问题, 会为下面的非凸 GW 迭代给出一个几何感知初始化。

熵正则化与迭代求解器。 对于常见的平方畸变 $\Delta(u, v)^2 = (u - v)^2$, 人们常计算熵松弛的一个驻点

$$\min_{P \in \mathcal{U}(\mathbf{a}, \mathbf{b})} \mathcal{E}_{D, D'}(P) - \varepsilon H(P). \quad (11.7)$$

尽管目标是非凸的, 连续线性化会导向一个实用的镜像下降方案 [186]。在忽略梯度中无关全局因子的情况下, 交替进行

$$P^{(\ell+1)} := \min_{P \in \mathcal{U}(\mathbf{a}, \mathbf{b})} \langle P, C^{(\ell)} \rangle - \varepsilon H(P), \quad C^{(\ell)} := D^{\odot 2} \mathbf{a} \mathbf{1}_m^\top + \mathbf{1}_n (D'^{\odot 2} \mathbf{b})^\top - 2D P^{(\ell)} D'^\top. \quad (11.8)$$

每次更新都是一个普通熵最优传输问题, 因此可以用 Sinkhorn 迭代求解。这是用于计算域之间软映射的标准熵 GW 求解器; 它改善可扩展性并平滑景观, 但不会消除 GW 目标的非凸性。

算法 11.1 熵 Gromov–Wasserstein 线性化

输入： 度量矩阵 D, D' ，权重 a, b ，正则化 $\varepsilon > 0$ ，容差 tol 。

输出： 近似熵 GW 耦合 $P \in U(a, b)$ 。

初始化： 置 $P^{(0)} = a \otimes b$ 。

对 $k = 0, 1, \dots$ **执行：**

$$C^{(k)} = D^{\odot 2} a \mathbf{1}_m^\top + \mathbf{1}_n (D'^{\odot 2} b)^\top - 2D P^{(k)} D'^\top.$$

求解 熵最优传输子问题： $P^{(k+1)} = \underset{P \in U(a, b)}{\operatorname{argmin}} \langle P, C^{(k)} \rangle - \varepsilon H(P)$ 。

若 $\|P^{(k+1)} - P^{(k)}\| \leq \text{tol}$ **则：**

返回 $P^{(k+1)}$ 。

加入特征。 融合 Gromov–Wasserstein 用特征传输代价增强结构项 [224]。在离散情形中，给定交叉特征代价 $M \in \mathbb{R}^{n \times m}$ 和参数 $\lambda \in [0, 1]$ ，最小化

$$\text{FGW}_{\lambda, p}((a, D), (b, D'))^p := \min_{P \in U(a, b)} (1 - \lambda) \sum_{i, j} M_{ij} P_{ij} + \lambda \sum_{i, j, i', j'} \Delta(D_{ii'}, D'_{jj'})^p P_{ij} P_{i'j'}.$$

第一项以通常的最优传输意义比较节点属性，而第二项比较内在几何。端点 $\lambda = 0$ 和 $\lambda = 1$ 分别恢复仅特征最优传输和纯 GW；中间值在属性匹配与结构匹配之间折中。当两个空间同时具有距离和特征，并且这两种信息源可能不一致时，这很有用。




图 11.5: 融合 Gromov–Wasserstein 中的特征信息与内在几何。小内圆盘编码二元节点特征。仅特征最优传输跟随属性，即使这会穿过形状结构；纯 GW 跟随内在在排序；融合 GW 则在特征项和成对距离畸变之间平衡。

Hausdorff 与 Gromov–Hausdorff 视角。 如果 A, B 是共同度量空间 (Z, d_Z) 的紧子集，则它们的 Hausdorff 距离为

$$d_H^Z(A, B) = \max \left\{ \sup_{a \in A} \inf_{b \in B} d_Z(a, b), \sup_{b \in B} \inf_{a \in A} d_Z(a, b) \right\}.$$

Gromov–Hausdorff 距离通过在到第三个空间的所有等距嵌入上最小化这个量，移除共同环境空间：

$$d_{\text{GH}}(\mathcal{X}, \mathcal{Y}) = \inf_{Z, \varphi, \psi} d_H^Z(\varphi(\mathcal{X}), \psi(\mathcal{Y})).$$

等价地，它是 $\mathcal{X}$ 与 $\mathcal{Y}$ 之间对应的最小畸变的一半 [114, 159]。这是一个最坏情形集合距离：每个点都必须以小畸变匹配。Gromov–Wasserstein 用概率耦合替代对应，并用平均畸变替代最坏情形畸变。因此，它更适合带噪声的采样形状和加权图，但可能忽略会主导 Hausdorff 距离的小质量集合。

11.3 量子最优传输

量子最优传输用密度矩阵替代概率向量，并用张量积空间上的正算子替代标量耦合。当被传输对象是矩阵值信号、类似协方差的描述子或量子态时，这是合适的语言，并且它揭示了最优传输、非交换熵和算子缩放之间的精确桥梁。下面的有限维表述遵循矩阵值和量子最优传输中发展出的半定视角 [173, 61, 59, 184, 108, 55]。

有限维状态与耦合。

定义 11.12 (厄米矩阵与密度矩阵). 令 $\mathbb{H}_n$ 为 $n \times n$ 厄米矩阵构成的实向量空间,

$$\mathbb{H}_n^+ = \{A \in \mathbb{H}_n; A \succeq 0\}, \quad \mathbb{H}_n^{+,1} = \{A \in \mathbb{H}_n^+; \text{tr}(A) = 1\}.$$

$\mathbb{H}_n^{+,1}$ 的元素是密度矩阵。

$\mathbb{C}^n$ 与 $\mathbb{C}^m$ 之间的联合量子态是作用在 $\mathbb{C}^n \otimes \mathbb{C}^m$ 上的矩阵 $T \in \mathbb{H}_{nm}^+$ 。它的边缘是偏迹, 通过对偶性定义为

$$\text{tr}(F \text{Tr}_B T) = \text{tr}((F \otimes \text{Id}_m)T), \quad \text{tr}(G \text{Tr}_A T) = \text{tr}((\text{Id}_n \otimes G)T), \quad (11.9)$$

对所有 $F \in \mathbb{H}_n$ 和 $G \in \mathbb{H}_m$ 成立。因此, $\text{Tr}_B(T) \in \mathbb{H}_n^+$ 和 $\text{Tr}_A(T) \in \mathbb{H}_m^+$ 恰好扮演经典耦合两个边缘的角色。可行集永不为空, 因为 $A \otimes B$ 具有边缘 A 和 B 。

定义 11.13 (有限维量子最优传输). 令 $A \in \mathbb{H}_n^{+,1}$ 、 $B \in \mathbb{H}_m^{+,1}$, 并令 $C \in \mathbb{H}_{nm}$ 为厄米代价可观测量。量子最优传输值是半定规划

$$\text{QOT}_C(A, B) := \min_{T \in \mathbb{H}_{nm}^+} \{\text{tr}(CT); \text{Tr}_B(T) = A, \text{Tr}_A(T) = B\}. \quad (11.10)$$

例 11.14 (经典对角情形). 如果 A, B, C 和 T 在固定基中全是对角的, 则 A 和 B 是概率向量, T 是非负矩阵, 偏迹约束退化为通常的行和列和约束。因此, 经典 Kantorovich 最优传输是 (11.10) 的对角、交换子情形。真正的量子特征是 T 可以包含非对角相干性和纠缠。

命题 11.15 (量子 Kantorovich 对偶). 对于 $A \in \mathbb{H}_n^{+,1}$ 和 $B \in \mathbb{H}_m^{+,1}$, (11.10) 的对偶为

$$\text{QOT}_C(A, B) = \max_{F \in \mathbb{H}_n, G \in \mathbb{H}_m} \{\text{tr}(FA) + \text{tr}(GB); F \otimes \text{Id}_m + \text{Id}_n \otimes G \preceq C\}. \quad (11.11)$$

如果 A 和 B 正定, 强对偶性直接由 Slater 条件推出; 半定情形则通过限制到 A 和 B 的支撑或通过逼近得到。

证明. 为两个边缘约束引入厄米 Lagrange 乘子 F 和 G 。Lagrangian 为

$$\text{tr}(CT) + \text{tr}(F(A - \text{Tr}_B T)) + \text{tr}(G(B - \text{Tr}_A T)) = \text{tr}(FA) + \text{tr}(GB) + \text{tr}((C - F \otimes \text{Id}_m - \text{Id}_n \otimes G)T),$$

其中最后一个等式使用了 (11.9)。在 $T \succeq 0$ 上最小化, 当且仅当 $C - F \otimes \text{Id}_m - \text{Id}_n \otimes G \succeq 0$ 时给出有限下界; 此时关于 T 的下确界为 0。这给出对偶规划。当 $A, B \succ 0$ 时, 耦合 $A \otimes B$ 严格可行, 因此 Slater 定理给出原始值与对偶值相等以及对偶达到。一般有限维半定情形可通过逼近 $A_\delta = (1 - \delta)A + \delta \text{Id}_n/n$ 、 $B_\delta = (1 - \delta)B + \delta \text{Id}_m/m$ 以及紧性得到, 或等价地通过化约到 A 和 B 的支撑得到。□

对偶势具有通常的标量规范自由度: 将 (F, G) 替换为 $(F + t\text{Id}_n, G - t\text{Id}_m)$ 不会改变约束和值, 因为 $\text{tr}(A) = \text{tr}(B) = 1$ 。

熵正则化与 Bregman 迭代。 与标量最优传输一样, 通过加入与矩阵对数相关的凸量子熵泛函, 可以得到一个更光滑的问题。

定义 11.16 (von Neumann 量子熵). 对于密度矩阵或正半定矩阵 T , 这里使用的平移 von Neumann 熵泛函为

$$H(T) = \text{tr}(T(\log T - \text{Id})), \quad \nabla H(T) = \log T,$$

并在特征值上约定 $0 \log 0 = 0$ 。这是凸的负量子熵; 在迹一状态上, 它与物理熵 $-\text{tr}(T \log T)$ 只相差一个符号和一个加性常数。

对 $\varepsilon > 0$, 定义

$$\text{QOT}_C^\varepsilon(A, B) = \min_{T \succeq 0} \{\text{tr}(CT) + \varepsilon H(T); \text{Tr}_B(T) = A, \text{Tr}_A(T) = B\}. \quad (11.12)$$

这是熵最优传输的非交换类比 [184, 55]: 耦合的 Shannon 熵被密度矩阵的迹熵替代。

命题 11.17 (熵量子最优传输对偶). 假设 $A \succ 0$, $B \succ 0$ 且 $\varepsilon > 0$. 则 (11.12) 有唯一正极大化解. 其对偶为

$$\text{QOT}_C^\varepsilon(A, B) = \max_{F \in \mathbb{H}_n, G \in \mathbb{H}_m} \left\{ \text{tr}(FA) + \text{tr}(GB) - \varepsilon \text{tr} \exp \left(\frac{F \otimes \text{Id}_m + \text{Id}_n \otimes G - C}{\varepsilon} \right) \right\}. \quad (11.13)$$

在最优性处, 原始变量和对偶变量由 *Gibbs* 公式联系:

$$T_e(F, G) = \exp \left(\frac{F \otimes \text{Id}_m + \text{Id}_n \otimes G - C}{\varepsilon} \right), \quad (11.14)$$

并满足 $\text{Tr}_B(T_e) = A$ 和 $\text{Tr}_A(T_e) = B$.

证明. 可行集紧且非空, 并包含正定点 $A \otimes B$. 迹熵在正半定矩阵上严格凸, 因此正则化原始问题有唯一极大化解. Slater 条件使 Lagrange 对偶计算成立. Fenchel 恒等式

$$\sup_{T \succeq 0} \text{tr}(YT) - \varepsilon H(T) = \varepsilon \text{tr} \exp(Y/\varepsilon)$$

是标量指数共轭性的矩阵类比. 将其应用于 (11.12) 的 Lagrangian, 并取 $Y = F \otimes \text{Id}_m + \text{Id}_n \otimes G - C$, 得到 (11.13). 这个 Fenchel 恒等式的驻点条件给出 (11.14); 对 F 和 G 求对偶目标的导数, 得到两个边缘方程. $\square$

写 $K = \exp(-C/\varepsilon)$, (11.12) 中的目标与量子 KL 散度的 ε 倍只相差一个常数:

$$D_H(T|K) = \text{tr}(T(\log T - \log K) - T + K).$$

Sinkhorn 的精确量子类比是到仿射边缘集合上的隐式交替 Bregman 投影方案

$$\mathcal{M}_A = \{T \succeq 0 : \text{Tr}_B(T) = A\}, \quad \mathcal{M}_B = \{T \succeq 0 : \text{Tr}_A(T) = B\}.$$

命题 11.18 (精确 Bregman 投影). 假设 $A, B \succ 0$, 并令 $K = \exp(-C/\varepsilon)$. (11.12) 的极大化解等价于 $D_H(T|K)$ 在 $\mathcal{M}_A \cap \mathcal{M}_B$ 上的极大化解. 此外, 如果当前正定矩阵具有 *Gibbs* 形式 $T_e(F, G)$, 则它到 $\mathcal{M}_A$ 的 Bregman 投影具有形式 $T_e(F^+, G)$, 其中选择 F^+ 使得 $\text{Tr}_B T_e(F^+, G) = A$. 到 $\mathcal{M}_B$ 的投影类似. 因此, 当每个单块边缘方程都被精确求解时, 交替 Bregman 投影等价于对偶 (11.13) 的交替块最大化.

证明. 由于 $\log K = -C/\varepsilon$, 恒等式

$$\text{tr}(CT) + \varepsilon H(T) = \varepsilon D_H(T|K) - \varepsilon \text{tr}(K)$$

成立, 因此原始极大化解在相差加性常数的意义下就是 K 的约束 Bregman 投影. 对于把正定矩阵 S 投影到 $\mathcal{M}_A$ 上, 仿射集合包含正定点 $A \otimes \text{Id}_m/m$; 熵导数 $\log T - \log S$ 在边界处奇异, 所以投影位于正锥内部. 其 Lagrangian 一阶变分为

$$\log T - \log S - \Lambda \otimes \text{Id}_m = 0$$

其中 Λ 是厄米乘子. 因此 $T = \exp(\log S + \Lambda \otimes \text{Id}_m)$. 如果 $S = T_e(F, G)$, 这再次具有形式 $T_e(F + \varepsilon \Lambda, G)$. 乘子由边缘方程 $\text{Tr}_B(T) = A$ 固定. 同样的论证适用于 $\mathcal{M}_B$. 最后, 在一个块上最大化 (11.13) 的一阶最优性条件恰好是相应的边缘方程, 所以 Bregman 视角和块对偶视角一致. $\square$

在对角情形中, 这个命题给出通常的乘法 Sinkhorn 更新. 然而, 在非交换情形中, 精确块方程

$$\text{Tr}_B T_e(F, G) = A, \quad \text{Tr}_A T_e(F, G) = B$$

不允许标量除法公式, 因为除非局部势 $F \otimes \text{Id}_m + \text{Id}_n \otimes G$ 与代价 C 交换, 否则 $F \otimes \text{Id}_m + \text{Id}_n \otimes G - C$ 的指数无法分离. 当所有矩阵在同一基中对角时, 交换性恢复标量形式 $T_e = \text{diag}(u)K \text{diag}(v)$, 边缘方程退化通常为 Sinkhorn 除法.

算法 11.2 记录了 Sinkhorn 的这个精确但隐式的非交换类比.

算法 11.2 精确量子 Bregman 投影

输入： 密度矩阵 A, B , 代价 C , 正则化 $\varepsilon > 0$, 容差 tol 。

输出： 偏迹为 A 和 B 的量子熵耦合 T 。

初始化： 置厄米势 $F^{(0)} = 0$ 和 $G^{(0)} = 0$ 。

对 $k = 0, 1, \dots$ **执行：**

$$T^{(k)} = T_e(F^{(k)}, G^{(k)}) = \exp\left(\frac{F^{(k)} \otimes \text{Id}_m + \text{Id}_n \otimes G^{(k)} - C}{\varepsilon}\right).$$

求解 A -投影方程: $\text{Tr}_B T_e(F^+, G^{(k)}) = A$,

置 $F^{(k+1)} = F^+$ 。

求解 B -投影方程: $\text{Tr}_A T_e(F^{(k+1)}, G^+) = B$,

置 $G^{(k+1)} = G^+$ 。

若 两个偏迹残差都至多为 tol **则：**

返回 $T_e(F^{(k+1)}, G^{(k+1)})$ 。

Gurvits 缩放与量子 Sinkhorn. 通常称为量子 Sinkhorn 的算法来自 Gurvits 及后续发展的算子缩放文献 [115, 116, 105, 101]。它用对称分解

$$T_s(F, G) = \exp\left(\frac{Z}{2\varepsilon}\right) \exp(-C/\varepsilon) \exp\left(\frac{Z}{2\varepsilon}\right) = (U \otimes V)K(U \otimes V), \quad Z = F \otimes \text{Id}_m + \text{Id}_n \otimes G, \quad (11.15)$$

替代真正的 Gibbs 耦合 (11.14), 其中 $U = \exp(F/(2\varepsilon))$, $V = \exp(G/(2\varepsilon))$ 且 $K = \exp(-C/\varepsilon)$ 。如果 $[Z, C] = 0$, 则 $T_s(F, G) = T_e(F, G)$; 否则这是一个 Strang 型对称替代。

固定一个 Choi 约定, 并令 $\mathcal{K} : \mathbb{H}_m \rightarrow \mathbb{H}_n$ 为由正 Choi 矩阵 K 表示的完全正映射; 令 $\mathcal{K}^*$ 为其 Hilbert-Schmidt 伴随。在所选 Choi 约定规定的转置意义下, 对称耦合的边缘方程具有算子缩放形式

$$U \mathcal{K}(V^2) U = A, \quad V \mathcal{K}^*(U^2) V = B.$$

它们可以通过显式合同归一化来强制:

$$\begin{aligned} R_V &= \mathcal{K}(V^2), \quad U \leftarrow R_V^{-1/2} (R_V^{1/2} A R_V^{1/2})^{1/2} R_V^{-1/2}, \\ S_U &= \mathcal{K}^*(U^2), \quad V \leftarrow S_U^{-1/2} (S_U^{1/2} B S_U^{1/2})^{1/2} S_U^{-1/2}. \end{aligned} \quad (11.16)$$

当 $K \succ 0$ 且 $U, V, A, B \succ 0$ 时, 这些逆平方根良定义。这是带有指定目标的 Gurvits/算子缩放; 当所

算法 11.3 量子 Sinkhorn 的 Gurvits/算子缩放

输入： 正边缘 A, B , 正核算子 K , 映射 $\mathcal{K}, \mathcal{K}^*$, 容差 tol 。

输出： 对称缩放耦合 T_s 。

初始化： 置 $U = \text{Id}_n$ 和 $V = \text{Id}_m$ 。

置 残差 $r = +\infty$ 。

当 $r > \text{tol}$ **时执行：**

$$R_V = \mathcal{K}(V^2), \quad U \leftarrow R_V^{-1/2} (R_V^{1/2} A R_V^{1/2})^{1/2} R_V^{-1/2}.$$

$$S_U = \mathcal{K}^*(U^2), \quad V \leftarrow S_U^{-1/2} (S_U^{1/2} B S_U^{1/2})^{1/2} S_U^{-1/2}.$$

置 $T_s = (U \otimes V)K(U \otimes V)$, 并将 r 置为它相对于 A 和 B 的两个算子边缘残差的最大值。

返回 T_s 。

有矩阵都是对角的时, 它退化为经典 Sinkhorn 缩放; 当目标与恒等矩阵成比例时, 在常规迹归一化意义下, 它与通常的双随机算子缩放归一化一致。

注 11.19 (Gurvits 缩放不是精确 Bregman 方案). 重要的是不要把 (11.16) 与 (11.12) 的精确 Bregman 方案混同。精确 Bregman 步会强制 $T_e(F, G) = \exp((Z - C)/\varepsilon)$ 的边缘, 并且会是真正凹对偶 (11.13) 的块最大化。Gurvits 缩放反而强制替代量

$$T_s = \exp\left(\frac{Z}{2\varepsilon}\right) \exp(-C/\varepsilon) \exp\left(\frac{Z}{2\varepsilon}\right).$$

二者在交换/对角状态下一致, 但一般而言 Baker-Campbell-Hausdorff 对易子项并不消失。因此, Gurvits 迭代应理解为熵 Q-OT 的可处理对称算子缩放近似, 而不是字面意义上的交替 KL 投影算法。

注 11.20 (算子值耦合). 相同定义可以形式上从矩阵扩展到可分 Hilbert 空间: 用迹为一的正迹类算子替代密度矩阵, 用有界自伴算子替代可观测量, 并用通过与局部有界可观测量对偶而定义的偏迹替代 (11.9)。如果 $\Pi(A, B)$ 表示偏迹为 A 和 B 的正迹类算子, 则有界代价可观测量 C 给出问题 $\inf_{T \in \Pi(A, B)} \text{Tr}(CT)$ 。对于无界正代价, 必须通过二次型或谱截断定义能量; 在熵情形中, 必须确保 Gibbs 算子 $\exp(-C/\varepsilon)$ 是迹类, 并且候选耦合的偏迹良定义。因此, 上面的矩阵公式是清晰的有限维核心; 算子版本添加的是定义域和紧性假设, 而不是不同的代数结构。

动态最优传输

一旦把测度之间的距离看作移动质量的作用量，最优传输就变得尤其有力。本章首先建立动态语言：连续性方程描述可接受的测度演化，而 Benamou–Brenier 公式将 W_2 识别为一个最小作用量原理。这些思想为后续的梯度流和生成模型章节做准备。

12.1 测度空间上的演化

我们从连续性方程开始，因为它是粒子、密度和弱测度演化的共同语言。它也精确说明了哪些速度场真正移动质量。

Lagrangian 与 Eulerian 描述。 我们考虑演化 $t \mapsto \alpha_t \in \mathcal{P}(\mathbb{R}^d)$ 。这样的演化可以用 “Lagrangian” 方式描述为粒子沿 $\mathbb{R}^d$ 中一个（随时间变化的）向量场 $v_t(x)$ 的平流。在粒子层面，这种平流由

$$\frac{dx(t)}{dt} = v_t(x(t)), \quad (12.1)$$

控制，并将相应的流映射记为 T_t ，使得 $T_t(x(0)) = x(t)$ 。于是被平流的测度为 $\alpha_t = (T_t)_\# \alpha_0$ 。对于离散测度， $\alpha_t = \frac{1}{n} \sum_{i=1}^n \delta_{x_i(t)}$ ，这意味着每个 $x_i(t)$ 都求解 (12.1)。

在 Eulerian 描述中，同一运动直接写在演化中的测度上：粒子 ODE 变为 PDE

$$\frac{\partial \alpha_t}{\partial t} + \operatorname{div}(v_t \alpha_t) = 0. \quad (12.2)$$

这个 PDE 通常称为平流方程、连续性方程，或者在相空间上作用时称为 Liouville 方程。只有当 α_t 具有光滑密度时，它才是经典 PDE。对于一般测度，尤其是经验测度，它应在弱意义下理解：对任意在时间上紧支撑的光滑测试函数 $(t, x) \mapsto \varphi(t, x)$ ，

$$\int_0^1 \int_{\mathbb{R}^d} (\partial_t \varphi(t, x) + \langle v_t(x), \nabla_x \varphi(t, x) \rangle) d\alpha_t(x) dt = 0. \quad (12.3)$$

这个方程由 (12.2) 通过分部积分得到。因此，对于光滑正密度，经典表述和弱表述等价；弱表述很有用，因为对于粒子按 (12.1) 演化的离散测度，它仍然有意义。

命题 12.1 (Lagrangian 流求解连续性方程)。考虑光滑流 $T_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，并定义 $\alpha_t = (T_t)_\# \alpha_0$ 。将 Eulerian 速度场定义为

$$v_t(T_t(y)) = \partial_t T_t(y).$$

则 (α_t, v_t) 在弱意义 (12.3) 下求解连续性方程。特别地，如果 $\alpha_0 = \frac{1}{n} \sum_i \delta_{x_i(0)}$ 是经验测度，那么 $\alpha_t = \frac{1}{n} \sum_i \delta_{x_i(t)}$ 也仍是经验测度，其粒子速度为 $\dot{x}_i(t) = v_t(x_i(t))$ 。

证明。令 $\varphi(t, x)$ 为在 $t = 0$ 和 $t = 1$ 消失的光滑测试函数。由于 $\alpha_t = (T_t)_\# \alpha_0$ ，

$$\frac{d}{dt} \int \varphi(t, x) d\alpha_t(x) = \frac{d}{dt} \int \varphi(t, T_t(y)) d\alpha_0(y).$$

链式法则给出

$$\frac{d}{dt} \int \varphi(t, T_t(y)) d\alpha_0(y) = \int (\partial_t \varphi(t, T_t(y)) + \langle \nabla_x \varphi(t, T_t(y)), \partial_t T_t(y) \rangle) d\alpha_0(y).$$

利用 v_t 的定义和推前关系，这等于

$$\int (\partial_t \varphi(t, x) + \langle \nabla_x \varphi(t, x), v_t(x) \rangle) d\alpha_t(x).$$

对时间积分并使用 φ 的边界取值，即得到 (12.3)。□

从测度演化到向量场。 对于给定演化 $(\alpha_t)_t$ ，通常存在无穷多个满足

$$\partial_t \alpha_t + \operatorname{div}(\alpha_t v_t) = 0. \quad (12.4)$$

的速度场 v_t 。这种非唯一性来自加权散度的核。使测度 α 保持不变的向量场组成线性空间

$$\mathcal{H}_\alpha = \{v; \operatorname{div}(\alpha v) = 0\}.$$

它通常并非平凡：例如，如果 α 是各向同性高斯测度，则 $\mathcal{H}_\alpha$ 包含由反对称矩阵生成的旋转向量场。

Dacorogna–Moser 反演。 因此，从观测到的密度演化重构粒子是病态的。Dacorogna 和 Moser [74] 引入的一个简单选择，是要求通量 $\alpha_t v_t$ 为梯度场，从而形式上得到

$$v_t = -\frac{1}{\alpha_t} \nabla \Delta^{-1}(\partial_t \alpha_t), \quad (12.5)$$

并配以合适的边界条件，例如在无穷远处消失。这个公式在概念上很有用，但当 α_t 消失时较为微妙，而且一般不会产生梯度速度场。

最小二乘反演与梯度结构。 一个更稳健的选择隐含地用于流匹配、最优传输和 Wasserstein 梯度流中：在所有可接受速度中选择动能最小的速度：

$$\min_v \frac{1}{2} \int_0^1 \int_{\mathbb{R}^d} \|v_t(x)\|^2 d\alpha_t(x) dt \quad \text{满足} \quad \partial_t \alpha_t + \operatorname{div}(\alpha_t v_t) = 0. \quad (12.6)$$

命题 12.2 (最小二乘速度是梯度). 假设 $\alpha_t = \rho_t dx$ 是光滑正密度曲线，且边界项消失。若 (12.6) 的极小化解存在，则它是一个梯度场

$$v_t = \nabla \varphi_t,$$

其中 φ_t 在相差加性常数的意义下唯一，并求解加权 Poisson 方程

$$-\operatorname{div}(\rho_t \nabla \varphi_t) = \partial_t \rho_t, \quad v_t = -\nabla \Delta_{\alpha_t}^{-1}(\partial_t \alpha_t), \quad \Delta_{\alpha_t} \varphi = \operatorname{div}(\alpha_t \nabla \varphi). \quad (12.7)$$

证明. 为连续性方程引入 Lagrange 乘子 φ_t 。该约束问题具有形式鞍点表述

$$\min_v \max_\varphi \int_0^1 \left[\frac{1}{2} \int_{\mathbb{R}^d} \|v_t(x)\|^2 d\alpha_t(x) + \int_{\mathbb{R}^d} \varphi_t(x) (\operatorname{div}(\alpha_t v_t)(x) + \partial_t \alpha_t(x)) dx \right] dt.$$

对散度项分部积分，对每个 t 得到

$$\int \left(\frac{1}{2} \|v_t\|^2 - \langle \nabla \varphi_t, v_t \rangle \right) d\alpha_t + \int \varphi_t \partial_t \alpha_t.$$

因此关于 v_t 的逐点极小化解为 $v_t = \nabla \varphi_t$ 。将其代入约束 $\partial_t \rho_t + \operatorname{div}(\rho_t v_t) = 0$ ，得到 (12.7) 中的加权 Poisson 方程。逆算子记号只是一个简写，表示在零均值右端项上求解该方程，并模去加性常数。□

一般而言，这种反演在计算上仍然昂贵，但 $(\alpha_t)_t$ 的特殊选择会导向更简单的公式；这正是后面流匹配所利用的机制。

算法 12.1 最小二乘速度重构

输入： 光滑正密度曲线 $(\rho_t)_{t \in [0,1]}$ 和边界条件。

输出： 实现该曲线的最小能量速度场 v_t 。

对每个时间 t 执行：

 计算 $\partial_t \rho_t$ 。

 求解加权 Poisson 方程： $-\operatorname{div}(\rho_t \nabla \varphi_t) = \partial_t \rho_t, \quad \int \varphi_t \rho_t = 0$ 。

 置 $v_t = \nabla \varphi_t$ 。

返回 $(v_t)_{t \in [0,1]}$ 。

12.2 Benamou–Brenier 的最优传输动态表述

动态表述将 $\mathcal{W}_2$ 识别为最便宜的连续性方程路径的动能。正是在这里，最优传输成为一个最小作用量原理。

不再假设整条曲线 $(\alpha_t)_{t \in [0,1]}$ 已给定，而是只固定其端点 α_0 和 α_1 ，并最小化最小二乘能量 (12.6)。Benamou 和 Brenier 的定理说明，这个测地能量恰好是平方 Wasserstein 距离 [18]。

定理 12.3 (Benamou–Brenier). 对于概率测度 $\alpha_0, \alpha_1 \in \mathcal{P}_2(\mathbb{R}^d)$,

$$\mathcal{W}_2^2(\alpha_0, \alpha_1) = \inf_{(\alpha_t, v_t)} \int_0^1 \int_{\mathbb{R}^d} \|v_t(x)\|^2 d\alpha_t(x) dt, \quad (12.8)$$

其中下确界取遍求解 $\partial_t \alpha_t + \nabla \cdot (\alpha_t v_t) = 0$ 、且满足 $\alpha_{t=0} = \alpha_0$ 和 $\alpha_{t=1} = \alpha_1$ 的 (α_t, v_t) 。如果 α_0 有密度，且 T 是最优 Monge 映射 $T_{\#} \alpha_0 = \alpha_1$ ，则极小化解为

$$\alpha_t = ((1-t)\text{Id} + tT)_{\#} \alpha_0, \quad v_t((1-t)x + tT(x)) = T(x) - x. \quad (12.9)$$

证明. 对于不等式“动态 $\leq$ 静态”，先假设存在 Monge 映射 T ，并由 (12.9) 定义 (α_t, v_t) 。由于 Lagrangian 速度 $T(x) - x$ 与 t 无关，

$$\int_0^1 \int \|v_t\|^2 d\alpha_t dt = \int \|T(x) - x\|^2 d\alpha_0(x),$$

所以动态代价不大于静态 Monge 代价。没有 Monge 映射时，同样的构造可用最优耦合 π 完成：采样 $(X, Y) \sim \pi$ ，并沿直线路径 $\gamma_{X,Y}(t) = (1-t)X + tY$ 移动。这个路径测度的作用量为 $\int \|x - y\|^2 d\pi(x, y)$ ；将路径速度投影到其在时间 t 的条件均值，给出一个作用量不更大的可接受 Eulerian 速度，因此动态值不大于 Kantorovich 值。

反过来，对于光滑确定性路径，取由 $\dot{T}_t = v_t \circ T_t$ 和 $T_0 = \text{Id}$ 定义的流 T_t 。则 $\alpha_t = (T_t)_{\#} \alpha_0$ 且 $(T_1)_{\#} \alpha_0 = \alpha_1$ 。Jensen 不等式给出

$$\|T_1(x) - x\|^2 \leq \int_0^1 \|v_t(T_t(x))\|^2 dt.$$

关于 α_0 积分后，Monge 代价由动态作用量从上界定。对于连续性方程的一般有限能量解，叠加原理将曲线提升为绝对连续路径上的概率测度；逐路径应用 Jensen 不等式，得到端点的一个耦合，其二次代价不大于作用量。因此 Kantorovich 值由动态值从上界定。□

尽管 (12.8) 关于 (α_t, v_t) 并非联合凸，但在用动量测度 $m_t = v_t \alpha_t$ 替代速度并使用透视作用量后，它变为凸问题。在绝对连续情形 $\alpha_t = \rho_t dx$ 且 $m_t(x) = \rho_t(x) v_t(x)$ 下，它写作

$$\mathcal{W}_2^2(\alpha_0, \alpha_1) = \inf_{\substack{\partial_t \rho_t + \text{div } m_t = 0 \\ \rho_{t=0} dx = \alpha_0, \rho_{t=1} dx = \alpha_1}} \int_0^1 \int_{\mathbb{R}^d} \frac{\|m_t(x)\|^2}{\rho_t(x)} dx dt, \quad (12.10)$$

并采用通常约定：当 $(\rho_t, m_t) = (0, 0)$ 时被积函数为 0，当 $\rho_t = 0$ 但 $m_t \neq 0$ 时为 $+\infty$ 。对于奇异端点或曲线，同一陈述用向量值动量测度和相应的退化约定来解释。一旦区域被离散化，这个凸重表述就能通过凸优化实现测地插值。

近端分裂。 凸动量表述也解释了原始 Benamou–Brenier 求解器。Papadakis、Peyré 和 Oudet [178] 表明，离散化之后，ALG2 方案就是 Douglas–Rachford 分裂，等价于 Fenchel–Rockafellar 对偶上的 ADMM。省略离散化指标，记 $U = (\rho, m)$ ，并引入透视被积函数

$$J(\rho, m) = \begin{cases} \|m\|^2 / \rho, & \rho > 0, \\ 0, & (\rho, m) = (0, 0), \\ +\infty, & \text{否则}. \end{cases}$$

令

$$\mathcal{F}(U) = \int_0^1 \int_{\mathbb{R}^d} J(\rho_t(x), m_t(x)) dx dt, \quad \mathcal{C} = \{(\rho, m); \partial_t \rho + \text{div } m = 0, \rho_0 dx = \alpha_0, \rho_1 dx = \alpha_1\},$$

并令 $\mathcal{G} = \iota_C$ 为该仿射连续性约束的示性函数。因此凸 Benamou–Brenier 问题为

$$\min_U \mathcal{F}(U) + \mathcal{G}(U).$$

在所得未知量 Hilbert 空间上, 或者形式上对一个 L^2 型乘积结构, 两个近端算子为

$$\text{prox}_{\tau\mathcal{F}}(\bar{U}) = \operatorname{argmin}_U \frac{1}{2} \|U - \bar{U}\|_{\mathcal{H}}^2 + \tau\mathcal{F}(U), \quad \text{prox}_{\tau\mathcal{G}}(\bar{U}) = \operatorname{argmin}_{U \in \mathcal{C}} \frac{1}{2} \|U - \bar{U}\|_{\mathcal{H}}^2.$$

对于标准乘积度量, 第一个映射在 (t, x) 中是局部的: 它是凸透视函数 J 的近端算子。第二个映射是由散度方程和端点约束定义的仿射集合上的正交投影。Douglas–Rachford 随后交替执行这两个简单操作:

$$\begin{aligned} U^{k+1} &= \text{prox}_{\tau\mathcal{F}}(Z^k), \\ \tilde{U}^{k+1} &= \text{prox}_{\tau\mathcal{G}}(2U^{k+1} - Z^k), \\ Z^{k+1} &= Z^k + \tilde{U}^{k+1} - U^{k+1}. \end{aligned}$$

等价地, 也可以交换 $\mathcal{F}$ 和 $\mathcal{G}$ 的角色。收敛时, 两个影子序列 U^k 和 $\tilde{U}^k$ 一致, 并给出凸动态问题的极小化解。这个视角很有用, 因为它将非线性但逐点的透视近端步骤, 与全局但线性的连续性方程投影分离开来 [178, 86]。

算法 12.2 用于动态 Benamou–Brenier 的 Douglas–Rachford

输入: 泛函 $\mathcal{F}, \mathcal{G} = \iota_C$, 近端参数 $\tau > 0$, 初始场 Z^0 。

输出: 离散密度-动量场 U^* 。

对 $k = 0, 1, \dots$ **执行:**

$U^{k+1} = \text{prox}_{\tau\mathcal{F}}(Z^k)$ 。

投影反射点: $\tilde{U}^{k+1} = \text{prox}_{\tau\mathcal{G}}(2U^{k+1} - Z^k) = \text{Proj}_{\mathcal{C}}(2U^{k+1} - Z^k)$ 。

更新 $Z^{k+1} = Z^k + \tilde{U}^{k+1} - U^{k+1}$ 。

若 $\|U^{k+1} - \tilde{U}^{k+1}\| \leq \text{tol}$ **则:**

返回 U^{k+1} 。



图 12.1: 两个采样轮廓之间的 Benamou–Brenier 测地线。精细子采样的猫形和双圆盘点云之间的离散二次最优传输计划诱导 McCann 插值 $Z_t = (1-t)X + tY$, 它是最小作用量解的 Lagrangian 实现。左图渲染较小带宽核平滑密度的局部彩色图像, 并加入足够边距以包含完整轮廓。右图叠加以均匀子采样中点粒子 $Z_{1/2}$ 为中心的缩短速度箭头; 每个显示的箭头在数据坐标中沿匹配特征方向 $Y - X$ 从源侧尾部指向目标侧头部, 但没有画成从 X 到 Y 的完整端点线段。

注 12.4 (路径空间表述). 令 $\mathcal{S} = C([0, 1]; \mathbb{R}^d)$ 为赋予一致拓扑的连续路径空间。对 $t \in [0, 1]$, 定义求值映射

$$P_t : \mathcal{S} \rightarrow \mathbb{R}^d, \quad P_t(\gamma) = \gamma(t).$$

Benamou–Brenier 代价具有等价表述

$$\mathcal{W}_2^2(\alpha_0, \alpha_1) = \inf_{M \in \mathcal{P}(\mathcal{S})} \left\{ \int_{\mathcal{S}} \int_0^1 \|\dot{\gamma}(t)\|^2 dt dM(\gamma); (P_0)_\# M = \alpha_0, (P_1)_\# M = \alpha_1 \right\}.$$

如果 α_0 有密度, 则极小化解 M^* 唯一。它的时间边缘重现最优曲线: 对所有 t , $\alpha_t = (P_t)_\# M^*$ 。此外, 对几乎处处的 t , 在绝对连续路径上记 $Q_t(\gamma) = \dot{\gamma}(t)$, 则速度的条件律是确定性的:

$$(P_t, Q_t)_\# M^*(dx, dq) = \alpha_t(dx) \delta_{v_t^*(x)}(dq),$$

其中 v_t^* 是 Benamou–Brenier 表述中的最优速度场。因此 M^* 集中在直线测地线上, 并且对几乎处处的 t , 在 α_t -几乎处处的空间点处恰好赋予一个方向。

动态表述的扩展。 同一变分语法可扩展到二次 Wasserstein 距离之外。人们可以改变动能指数、迁移率或平衡方程，同时保留连续性型约束和凸透视作用量。

注 12.5 (广义 Benamou–Brenier 距离)。 动态表述并非 $\mathcal{W}_2$ 所特有。对于具有有限 p 阶矩且 $p > 1$ 的测度，有类似的作用量公式

$$\mathcal{W}_p^p(\alpha_0, \alpha_1) = \inf_{\substack{\partial_t \alpha_t + \nabla \cdot (\alpha_t v_t) = 0 \\ \alpha_{t=0} = \alpha_0, \alpha_{t=1} = \alpha_1}} \int_0^1 \int_{\mathbb{R}^d} |v_t(x)|^p d\alpha_t(x) dt.$$

当 $\alpha_t = \rho_t dx$ 且 $m_t = \rho_t v_t$ 时，这变为凸透视作用量

$$\int_0^1 \int_{\mathbb{R}^d} \frac{|m_t(x)|^p}{\rho_t(x)^{p-1}} dx dt, \quad \partial_t \rho_t + \nabla \cdot m_t = 0,$$

并采用通常约定：若 $(\rho, m) = (0, 0)$ ，被积函数为 0；若 $\rho = 0$ 但 $m \neq 0$ ，则为 $+\infty$ 。

第二类变体改变介质的迁移率：二次作用量 $|m|^2/\rho$ 被替换为 $|m|^2/\theta(\rho)$ ，其中 θ 是合适的凹迁移率。在适当结构假设下，这会产生适配于非线性扩散和有限体积离散化的传输度量 [80]。在有限图和 Markov 链上，类似作用量使用边迁移率，常取端点密度的对数平均，并导向离散 Wasserstein 几何 [154, 165]。这些扩展保持与 Benamou–Brenier 相同的变分语法：连续性型约束、作用量密度，以及通过最小化积分动能代价得到的测地线。

动态非平衡最优传输。 非平衡动态传输通过允许质量沿路径被生成和消灭而得到。连续性方程被平衡方程取代，作用量同时惩罚空间运动和增长。这个动态表述支撑 Hellinger–Kantorovich 和 Wasserstein–Fisher–Rao 度量 [145, 66]；它与静态熵-传输和锥表述的等价性在 [146, 65] 中建立。一个代表性的二次作用量是

$$\partial_t \rho_t + \nabla \cdot m_t = s_t, \quad \int_0^1 \int \left(\frac{|m_t|^2}{\rho_t} + \kappa^2 \frac{s_t^2}{\rho_t} \right) dx dt,$$

并采用与上面相同的透视约定。等价地，写 $m_t = \rho_t v_t$ 和 $s_t = \rho_t g_t$ ，则在 $\partial_t \rho_t + \nabla \cdot (\rho_t v_t) = g_t \rho_t$ 约束下最小化 $\int_0^1 \int (|v_t|^2 + \kappa^2 g_t^2) d\rho_t dt$ 。参数 κ 固定反应与传输的相对代价；改变它会重新缩放相关锥度量中的径向/角向平衡。对于测度值三元组，作用量在下半连续透视意义下理解为

$$\mathcal{A}_\kappa(\rho, m, s) := \int \left(\frac{\|\dot{m}\|^2}{\dot{\rho}} + \kappa^2 \frac{\dot{s}^2}{\dot{\rho}} \right) d\lambda, \quad (\dot{\rho}, \dot{m}, \dot{s}) = \left(\frac{d\rho}{d\lambda}, \frac{dm}{d\lambda}, \frac{ds}{d\lambda} \right),$$

其中 λ 支配 ρ 以及 m 和 s 的全变差，且该值与这个选择无关。约定为 $0/0 = 0$ 且当 $a > 0$ 时 $a/0 = +\infty$ ，因此有限作用量迫使通量和源项都相对于被传输质量绝对连续。

命题 12.6 (非平衡最优传输的静态/动态等价性)。 固定上述作用量，并令 CW_κ 为定理 9.4 的锥值，其中锥度量归一化到同一增长尺度 κ 。对于 $\mathbb{R}^d$ 上的非负有限测度 α_0, α_1 ，动态值

$$\text{WFR}_\kappa^2(\alpha_0, \alpha_1) := \inf_{\substack{\partial_t \rho_t + \nabla \cdot m_t = s_t \\ \rho_0 = \alpha_0, \rho_1 = \alpha_1}} \int_0^1 \mathcal{A}_\kappa(\rho_t, m_t, s_t) dt \quad (12.11)$$

等于静态锥表述 $\text{CW}_\kappa(\alpha_0, \alpha_1)$ 。因此，静态非平衡问题和平衡方程最小作用量问题定义同一个测地距离。

证明。 锥构造把质量变化转化为 $\mathfrak{C}[\mathbb{R}^d]$ 上的径向运动，把空间传输转化为角向运动。将锥上的 Benamou–Brenier 定理应用于提升后的端点测度，得到 $\mathfrak{C}[\mathbb{R}^d]$ 上的动态最小作用量问题，其静态值就是定理 9.4 的锥值 CW_κ 。这是 Hellinger–Kantorovich 和 Wasserstein–Fisher–Rao 度量的标准静态/动态识别 [145, 146, 66, 65]。

用权重 r^2 将锥曲线投影回基空间，会产生满足平衡方程的测度曲线 ρ_t 、空间通量 m_t 和源项 s_t 。在锥度量的匹配归一化下，锥动能恰好分解为 (12.11) 中的透视作用量 $\mathcal{A}_\kappa$ 。反过来，任意有限作用量三元组 (ρ_t, m_t, s_t) 都可以提升为一条锥曲线，其径向速度实现增长项，其空间速度实现传输项，并且松弛后具有相同作用量。因此两个下确界相等；下半连续性从光滑正情形给出一般有限测度陈述。 $\square$




图 12.2: 两个模态质量互换的一维高斯混合之间的平衡与非平衡 Sinkhorn 重心插值。平衡行守恒总质量，因此来自占优左侧模态的多余质量必须沿直线移向占优的右侧目标模态，在中间产生瞬态质量。非平衡行使用 KL 松弛边缘约束；质量可以在过度表示的模态附近衰减，并在表示不足的模态附近重新生成，从而给出更接近 Wasserstein-Fisher-Rao 直觉的反应-传输插值。

Wasserstein 梯度流

一旦 $\mathcal{W}_2$ 成为动态度量，就可以直接在测度空间上运行梯度下降。本章推导形式化的 Wasserstein 梯度，解释 JKO 最小化运动格式，记录测地凸性在收敛中的作用，然后把同一套微积分应用到平均场神经网络训练中。

13.1 最小化运动与 Wasserstein 梯度

第一节解释测度上的一个变分隐式 Euler 步如何在小步长极限中产生由能量的 Wasserstein 梯度驱动的连接性方程。

现在考虑函数 $f(\alpha)$ ，并寻找一个最小化演化 $(\alpha_t)_t$ 。在度量空间上进行最小化运动的一般策略，是用隐式 Euler 格式构造离散时间演化：

$$\alpha_{t+\tau} := \arg \min_{\alpha} \frac{1}{2\tau} \mathcal{W}_2(\alpha_t, \alpha)^2 + f(\alpha). \quad (13.1)$$

算法 13.1 JKO 最小化运动

输入： 能量 f ，初始测度 α^0 ，时间步长 $\tau > 0$ ，步数 K 。

输出： 离散梯度流轨迹 $(\alpha^k)_{k=0}^K$ 。

对于 $k = 0, \dots, K-1$ **执行：**

$$\alpha^{k+1} \in \arg \min_{\alpha \in \mathcal{P}_2(\mathbb{R}^d)} \frac{1}{2\tau} \mathcal{W}_2^2(\alpha^k, \alpha) + f(\alpha).$$

置 $\alpha_t^\tau = \alpha^k$ ，其中 $t \in [k\tau, (k+1)\tau)$ 。

返回 $(\alpha^k)_{k=0}^K$ 和 α_t^τ 。

欧几里得梯度流。 如果把 (13.1) 限制到有限维，并假设 $\alpha_t = \delta_{x(t)}$ 且 $\alpha = \delta_x$ (单个 Dirac 测度)，它就和隐式 Euler 格式一致：

$$x(t+\tau) := \arg \min_x \frac{1}{2\tau} \|x - x(t)\|^2 + h(x),$$

其中 $h(x) = f(\delta_x)$ 。其解形式上由隐式 Euler 公式给出：

$$x(t+\tau) = (\text{Id} + \tau \nabla h)^{-1}(x(t)).$$

相比之下，显式 Euler 格式为：

$$x(t+\tau) = (\text{Id} - \tau \nabla h)(x(t)) = x(t) - \tau \nabla h(x(t)).$$

当 $\tau \rightarrow 0$ 时，两种格式都收敛到：

$$\dot{x}(t) = -\nabla h(x(t)). \quad (13.2)$$

Wasserstein 梯度公式。 隐式 Euler 格式的优点是它不要求 h 或 f 光滑。对于 f 而言，这一点对处理测度上的演化至关重要，因为这些测度可能具有密度、原子或其他奇异部分。

当 $\tau \rightarrow 0$ 时，在 f 满足某些条件下，(13.1) 定义连续演化 $t \mapsto \alpha_t$ 。如前所述，这一演化可以描述为 Lagrange 演化 (12.1)。我们使用如下第一变分约定：对任意 $\beta \in \mathcal{P}(\mathbb{R}^d)$ 以及有符号零质量扰动 $\rho = \beta - \alpha$ ，

$$f((1-\tau)\alpha + \tau\beta) = f(\alpha + \tau\rho) = f(\alpha) + \tau \int [\delta f(\alpha)](x) d\rho(x) + o(\tau).$$

关键的无穷小对象，是在 Wasserstein 度量中表示这一微分的向量场。

定义 13.1 (Wasserstein 梯度). 假设 f 具有光滑第一变分 $\delta f(\alpha)$. 在 $\mathcal{P}_2(\mathbb{R}^d)$ 上的光滑形式微积分中, f 在 α 处的 Wasserstein 梯度是梯度向量场

$$\nabla_{\mathcal{W}} f(\alpha) = \nabla_x \delta f(\alpha).$$

相应的形式梯度流是连续性方程

$$\frac{\partial \alpha_t}{\partial t} + \operatorname{div}(-\nabla_{\mathcal{W}} f(\alpha_t) \alpha_t) = 0. \quad (13.3)$$

下面的命题解释为什么该向量场是速度上的 $L^2(\alpha)$ 度量所对应的 Riemann 梯度。

命题 13.2 (形式化 Wasserstein 梯度). 假设 f 具有光滑第一变分 $\delta f(\alpha)$, 并且 α 具有光滑正密度. 对于由速度场 v 通过 $(\operatorname{Id} + \tau v)_{\#} \alpha$ 生成的无穷小扰动, f 的微分为

$$\frac{d}{d\tau} \Big|_{\tau=0} f((\operatorname{Id} + \tau v)_{\#} \alpha) = \int \langle \nabla \delta f(\alpha)(x), v(x) \rangle d\alpha(x).$$

因此, 对于 Riemann 度量 $\|v\|_{L^2(\alpha)}^2 = \int \|v\|^2 d\alpha$, Wasserstein 梯度就是向量场

$$\nabla_{\mathcal{W}} f(\alpha) = \nabla \delta f(\alpha).$$

证明. 推前展开在分布意义下给出

$$(\operatorname{Id} + \tau v)_{\#} \alpha = \alpha - \tau \operatorname{div}(\alpha v) + o(\tau).$$

使用第一变分的定义,

$$f((\operatorname{Id} + \tau v)_{\#} \alpha) = f(\alpha) - \tau \int \delta f(\alpha) \operatorname{div}(\alpha v) dx + o(\tau).$$

在紧支撑或边界通量消失的条件下分部积分, 得到

$$- \int \delta f(\alpha) \operatorname{div}(\alpha v) dx = \int \langle \nabla \delta f(\alpha), v \rangle d\alpha.$$

根据 $L^2(\alpha)$ 度量的 Riesz 表示元定义, 该表示元就是 $\nabla \delta f(\alpha)$. □

Wasserstein 梯度流视角已经出现在 John D. Lafferty 的博士工作中, 该工作以《密度流形与构型空间量子化》发表, 并使用了“密度流形”这一名称. 随后 Otto 系统发展了这一视角, 揭示了该空间的形式 Riemann 结构 [176]. 严格的度量空间处理和数值 JKO 格式可见于 [7, 20, 180, 98].

从 JKO 步到速度场. JKO 步的一阶展开解释了为什么 (13.3) 使用向量场 $\nabla_{\mathcal{W}} f(\alpha)$. 把 (13.1) 写成对位移场 v 的最小化, 其中 $\alpha = (\operatorname{Id} + \tau v)_{\#} \alpha_t$:

$$\min_v \frac{1}{2\tau} \tau^2 \|v\|_{L^2(\alpha_t)}^2 + f((\operatorname{Id} + \tau v)_{\#} \alpha_t).$$

然后使用

$$\begin{aligned} (\operatorname{Id} + \tau v)_{\#} \alpha_t &= \alpha_t - \tau \operatorname{div}(v \alpha_t) + o(\tau) \\ f((\operatorname{Id} + \tau v)_{\#} \alpha_t) &= f(\alpha_t) - \tau \int \delta f(\alpha_t) \operatorname{div}(v \alpha_t) dx + o(\tau) \\ &= f(\alpha_t) + \tau \int \langle \nabla_x \delta f(\alpha_t)(x), v(x) \rangle d\alpha_t(x) + o(\tau) \end{aligned}$$

对这一表述作一阶 Taylor 展开, 从而得到 (13.1) 中被最小化问题关于 τ 的如下第一阶展开

$$\min_v f(\alpha_t) + \tau \int \left[\frac{1}{2} \|v(x)\|^2 + \langle \nabla_{\mathcal{W}} f(\alpha_t)(x), v(x) \rangle \right] d\alpha_t(x) + o(\tau).$$

逐点最小化子为 $v = -\nabla_{\mathcal{W}} f(\alpha_t)$, 这就给出了连续性方程中的速度. 现在详细讨论这类 Wasserstein 梯度流的例子。




图 13.1: 一维熵流的 JKO 最小化运动。左图显示热方程的连续隐式 Euler 最小化子, 颜色从红到蓝。右图跟踪若干选定概率水平 s 的反 CDF 值 $Q_t(s) = F_t^{-1}(s)$, 给出 Wasserstein 空间中邻近运动的 Lagrange 视角。

算法 13.2 经验 Wasserstein 粒子下降

输入: 粒子 $X^0 = (x_1^0, \dots, x_n^0)$, 泛函 f , 步长 h , 容差 tol 。

输出: 粒子轨迹 $(X^k)_k$ 和经验测度。

定义 $F(X) = f(\frac{1}{n} \sum_{i=1}^n \delta_{x_i})$ 。

对于 $k = 0, 1, \dots$ **执行:**

对于 $i = 1, \dots, n$ **执行**

$g_i^k = n \nabla_{x_i} F(X^k), \quad x_i^{k+1} = x_i^k - h g_i^k.$

如果 $\max_i \|x_i^{k+1} - x_i^k\| \leq \text{tol}$ **则:**

返回 $\frac{1}{n} \sum_i \delta_{x_i^{k+1}}$ 。

离散演化。 如果 $f(\alpha)$ 可在离散分布上求值, 且 ∇_W 在这种情形下连续, 则流 (13.3) 保持 Dirac 质量的数量, $\alpha_t = \frac{1}{n} \sum_i \delta_{x_i(t)}$ 。粒子 $X(t) := (x_i(t))_i$ 按照一个耦合 ODE 系统演化:

$$\dot{x}_i(t) = -n \nabla_{x_i} F(X(t)), \quad (13.4)$$

其中 $F(X) := f(\frac{1}{n} \sum_i \delta_{x_i})$, 因子 n 来自经验 Wasserstein 度量 $\frac{1}{n} \sum_i \|\dot{x}_i\|^2$ 。

线性泛函。 第一个基准是第一变分不依赖当前测度的泛函。

例 13.3 (线性势生成独立粒子)。 取线性泛函

$$f(\alpha) = \int h(x) d\alpha(x). \quad (13.5)$$

则 $\delta f(\alpha) = h$ 与 α 无关, 并且流 (13.3) 变为

$$\frac{\partial \alpha_t}{\partial t} + \text{div}(-\nabla h \alpha_t) = 0.$$

这意味着粒子按照通常的梯度流 (13.2) 独立运动。

Shannon 负熵。 熵给出了相反的基准: 该流不再是粒子的确定性推前, 而是密度的扩散。

例 13.4 (熵生成热流和多孔介质流)。 典型的密度依赖泛函是 Shannon 负熵

$$f(\alpha) = \int \log \left(\frac{d\alpha}{dx}(x) \right) d\alpha(x). \quad (13.6)$$

这里, $\delta f(\alpha) = \log(d\alpha/dx)$, 相差一个加性常数, 因此 $\nabla_W f(\alpha) = \nabla \alpha / \alpha$ (常称为 score)。流 (13.3) 变为热方程

$$\partial_t \alpha_t = \Delta \alpha_t.$$

其他熵泛函会导出非线性扩散方程; 有限体积和粒子离散化见 [53, 107, 154, 87]。对于广义熵

$$f(\alpha) = \int g \left(\frac{d\alpha}{dx} \right) dx, \quad (13.7)$$

其中 g 是标量凸函数, 在光滑密度情形下得到非线性扩散:

$$\frac{\partial \alpha_t}{\partial t} = \Delta(P(\alpha_t)),$$

其中压力 P 满足 $P'(s) = sg''(s)$ 。例如, $g(s) = s \log(s)$ 给出 $P(s) = s$ 并恢复 (13.6), 而 $g(s) = s^m/(m-1)$, $m > 1$ 给出相差一个加性常数的 $P(s) = s^m$, 并得到多孔介质方程。

前面的例子也受一个精确的测地凸性准则支配。McCann 的著名定理 [157] 表明, 对于满足 $g(0) = 0$ 的 $g: \mathbb{R}^+ \rightarrow \mathbb{R} \cup \{+\infty\}$, 当 g 是凸的, 并且映射 $r \mapsto r^d g(r^{-d})$ 在 $(0, +\infty)$ 上凸且非增时, 形如 (13.7) 的内能在 $\mathcal{P}(\mathbb{R}^d)$ 上测地凸。这类函数的例子包括 $q > 1$ 时的 $g(s) = s^q$, 以及 Shannon 熵 $g(s) = s \log(s)$ 。相比之下, 与反向 KL 散度相关的 $g(s) = -\log(s)$ 不满足这一位移凸性准则。




图 13.2: 从同一个紧支撑初始密度出发的熵驱动 Wasserstein 梯度流。热流由 Shannon 熵 $g(\rho) = \rho \log \rho$ 生成, 并立即发展出高斯尾部。多孔介质流使用幂熵 $g(\rho) = \rho^m/(m-1)$, 因此 $\partial_t \rho = \Delta(\rho^m)$: 中图为 $m = 2$, 右图具有更强的非线性 $m = 6$, 即 $\partial_t \rho = \Delta(\rho^6)$ 。更大的幂主要在密度较高处扩散, 产生更平坦的核心和更尖锐的紧自由边界。

相互作用能量。 以类似思路, 为了在不要求测度具有密度的情况下得到非线性演化, 可以考虑

$$f(\alpha) := \iint k(x, y) d\alpha(x) d\alpha(y). \quad (13.8)$$

对于对称核 k :

$$\delta f(\alpha)(x) = 2 \int k(x, y) d\alpha(y), \quad \nabla_W f(\alpha)(x) = 2 \int \nabla_x k(x, y) d\alpha(y).$$

对于 $\alpha_0 = \frac{1}{n} \sum_i \delta_{x_i}$, 流 (13.3) 意味着粒子 $(x_i(t))_i$ 满足:

$$\dot{x}_i(t) = -\frac{2}{n} \sum_j \nabla k(x_i(t), x_j(t)).$$

如果 k 是正定的, 或者更一般地, 像能量距离核 $k(x, y) = -\|x - y\|$ 那样在总质量为零的有符号测度上条件正定, 并且最小化到教师分布 β 的平方核差异, 则

$$\|\alpha - \beta\|_k^2 = \iint k d\alpha d\alpha - 2 \int \left(\int k(x, y) d\beta(y) \right) d\alpha(x) + \text{constant}.$$

因此, MMD 型训练能量正是一个相互作用能量加上线性势; 教师分布通过势 $x \mapsto -2 \int k(x, y) d\beta(y)$ 出现。相应的经验 Wasserstein 梯度流为

$$\dot{x}_i(t) = -\frac{2}{n} \sum_j \nabla_x k(x_i(t), x_j(t)) + 2 \int \nabla_x k(x_i(t), y) d\beta(y).$$

相应的仿真循环见算法 13.3。

第一项是核化自相互作用, 第二项是连续教师核均值诱导的吸引。在连续层面, 特征正定核以及概率测度上的欧几里得能量距离核, 都以 β 作为 $\|\alpha - \beta\|_k^2$ 的唯一最小化子。然而, 对于有限数量的粒子, 该流只能形成 β 的核化求积, 小粒子系统可能很差地覆盖目标众数。图 13.3 展示了这种有限粒子效应。

算法 13.3 针对教师分布的 MMD 粒子流

输入：初始粒子 $(x_i^0)_{i=1}^n$ ，教师分布 β 或教师样本 $(y_b)_{b=1}^B$ ，核 k ，步长 h 。

输出：以 β 为目标的粒子轨迹。

对于 $k = 0, 1, \dots$ **执行：**

对于 $i = 1, \dots, n$ **执行：**

置自相互作用 $r_i^k = -\frac{2}{n} \sum_{j=1}^n \nabla_x k(x_i^k, x_j^k)$ 。

如果 β 可解析获得 **则：**

置教师吸引 $a_i^k = 2 \int \nabla_x k(x_i^k, y) d\beta(y)$ 。

如果只有样本 $(y_b)_{b=1}^B$ **可用 则：**

置 $a_i^k = \frac{2}{B} \sum_{b=1}^B \nabla_x k(x_i^k, y_b)$ 。

置速度 $v_i^k = r_i^k + a_i^k$ 。

更新 $x_i^{k+1} = x_i^k + h v_i^k$ 。

返回 $(x_i^k)_{i,k}$ 。




图 13.3: 到平滑双高斯教师分布的平方 MMD 型差异的确定性 Wasserstein 梯度流中的粒子数量，这里使用能量距离核 $k(x, y) = -\|x - y\|$ 。教师本身只通过真实密度等高线显示；红点是远离目标放置的紧致平移高斯初始化，红到蓝的曲线显示抽稀后的粒子轨迹子集，蓝点显示稳定后的长时间粒子。粒子过少时，经验测度形成稀疏的核化求积，并可能不足以覆盖目标众数；增大 n 会使粒子云更忠实地近似连续目标几何。

随机粒子与 McKean–Vlasov 极限。 更一般地，确定性粒子流有随机对应物，其中粒子层面的 Brownian 噪声在测度层面变成熵项。如果漂移不依赖经验测度，则每个粒子按照

$$dX_t = b(X_t)dt + \sqrt{2}\sigma dB_t,$$

独立演化，并且单粒子分布 $\alpha_t = \rho_t dx$ 直接满足线性 Fokker–Planck 方程

$$\partial_t \rho_t = -\operatorname{div}(b \rho_t) + \sigma^2 \Delta \rho_t.$$

例 13.5 (作为自由能流的 Langevin 漂移). 如果 $b = -\nabla V$ ，则这个线性 Fokker–Planck 方程是自由能的 $\mathcal{W}_2$ 梯度流

$$\rho \mapsto \int V \rho dx + \sigma^2 \int \rho \log \rho dx.$$

平均场情形则不同：漂移由所有粒子的当前经验分布重新计算，

$$dX_i^n(t) = b(X_i^n(t), \mu_t^n)dt + \sqrt{2}\sigma dB_i(t), \quad \mu_t^n = \frac{1}{n} \sum_{i=1}^n \delta_{X_i^n(t)}.$$

对于有限 n ，经验分布 μ_t^n 本身是随机的。在合适的 Lipschitz、增长和混沌初始化假设下，混沌传播说明，当 $n \rightarrow \infty$ 时，有限多个粒子渐近独立，并且都具有同一个确定性分布 $\rho_t dx$ ；等价地，经验测度 μ_t^n 依概率收敛到该分布。极限密度求解非线性 Fokker–Planck 方程，也称 McKean–Vlasov 方程：

$$\partial_t \rho_t = -\operatorname{div}(b(x, \rho_t) \rho_t) + \sigma^2 \Delta \rho_t.$$

当相互作用漂移具有变分形式

$$b(x, \rho) = -\nabla \frac{\delta \mathcal{E}}{\delta \rho}(x),$$



图 13.4: 三种 k 选择下的相互作用能量粒子流。正高斯核 $k(x, y) = \exp(-\|x - y\|^2/(2\sigma^2))$ 在 Wasserstein 下降下产生短程排斥；改变其符号会产生吸引和塌缩；向排斥核加入二次长程吸引会得到平衡的吸引-排斥动力学。这些曲线沿耦合粒子 ODE (13.4) 的较长积分，使用基于弧长的红到蓝着色。




图 13.5: 由不同差异几何诱导的粒子轨迹。所有图中的红色粒子和蓝色目标云都相同。直线最优传输位移产生来自最优匹配的射线；MMD 型见证场给出更平滑的非局部力；Sinkhorn 散度力是熵化、去偏的传输吸引；归一化漂移场把对数据的吸引与自排斥结合起来。该图是定性的：它比较几何行为，而不是求解器性能。

这个 PDE 就是熵正则化能量的 Wasserstein 梯度流

$$\mathcal{E}(\rho) + \sigma^2 \int \rho \log \rho \, dx.$$

13.2 测地凸性与收敛

测地凸性是适配 Wasserstein 几何的凸性概念。它是把形式梯度流微积分转化为收敛理论的条件。

测地线与凸性。 如定义 3.35 中那样， α_0 与 α_1 之间的一条常速 $\mathcal{W}_2$ 测地线，可由任意最优耦合 $\pi^* \in \mathcal{U}(\alpha_0, \alpha_1)$ 通过 McCann 插值得到：

$$\alpha_t = ((1-t)P_0 + tP_1)_\# \pi^*, \quad t \in [0, 1],$$

其中 $P_0(x, y) = x$ 且 $P_1(x, y) = y$ 。如果最优计划由 Brenier 映射 T 诱导，则它化为 $((1-t)\text{Id} + tT)_\# \alpha_0$ 。耦合公式很重要，因为即使不存在 Monge 映射，测地线仍然存在，例如当一个 Dirac 质量必须分裂时。

定义 13.6 (测地凸性). $\mathcal{P}_2(\mathbb{R}^d)$ 上的泛函 f 称为测地凸的，如果对每条 $\mathcal{W}_2$ 测地线 $(\alpha_t)_t$,

$$f(\alpha_t) \leq (1-t)f(\alpha_0) + tf(\alpha_1).$$

若右端还可改进一个 $-\frac{\lambda}{2}t(1-t)\mathcal{W}_2^2(\alpha_0, \alpha_1)$ 项，则称其为 λ -测地凸。

命题 13.7 (基本测地凸能量). 以下形式陈述在 $\mathcal{P}_2(\mathbb{R}^d)$ 上成立。

1. 如果 h 是凸的，则 $\alpha \mapsto \int h d\alpha$ 测地凸；如果 h 是 λ -强凸的，则它是 λ -测地凸的。
2. 如果 $W(x-y)$ 作为位移的函数是凸的，则 $\alpha \mapsto \frac{1}{2} \iint W(x-y) d\alpha(x) d\alpha(y)$ 测地凸。
3. Shannon 熵 $\alpha \mapsto \int \rho \log \rho \, dx$ 测地凸。
4. 当 V 是 λ -强凸时，满足 $d\gamma = e^{-V} dx / Z$ 的相对熵 $\text{KL}(\alpha|\gamma)$ 是 λ -测地凸的。




图 13.6: $KL(\rho|\beta)$ 的同一个熵正则化 Wasserstein 梯度流的三种数值表示, 其中 β 是位于初始各向同性高斯密度右侧的双高斯目标。第一行模拟独立 Langevin 粒子, 并在左图显示抽稀后的轨迹集合。第二行用速度 $\tau(\nabla \log \beta - \nabla \log \rho_t)$ 演化大量确定性粒子, 并用更尖锐的核密度 score 估计 $\nabla \log \rho_t$; 只显示代表性轨迹和粒子子集。第三行从左图中的初始密度出发, 在网格上求解相应的 Fokker-Planck 方程。其余列使用前置密集的时间点, 使流的开始阶段和后续向双峰分布的变形都可见。

证明. 沿 Monge 测地线 $X_t = (1-t)X_0 + tX_1$, h 的凸性给出 $h(X_t) \leq (1-t)h(X_0) + th(X_1)$, 强凸性给出额外的二次项; 积分即证明第一条。相互作用项也类似: 把 W 的凸性应用到成对差 $X_t - X'_t = (1-t)(X_0 - X'_0) + t(X_1 - X'_1)$, 再对两个独立副本积分。熵的结论是 McCann 的位移凸性定理; 在密度层面, 它来自最优映射插值下 Jacobian 行列式的凹性。最后, $KL(\alpha|\gamma) = \int \rho \log \rho dx + \int V d\alpha + \text{constant}$, 所以它是位移凸熵与一个 λ -测地凸线性势之和。□

流的收敛。 一般而言, 分析 (13.3) 是细致的。最干净的情形是 f 在上述意义下测地凸。这个条件是欧几里得梯度下降中凸性的 Wasserstein 类比。

命题 13.8 (凸 Wasserstein 流的能量衰减). 形式上假设 f 测地凸, 具有光滑第一变分, 并且有最小化子 α^* 。令 $(\alpha_t)_t$ 为 Wasserstein 梯度流的光滑解

$$\partial_t \alpha_t + \text{div}(\alpha_t v_t) = 0, \quad v_t = -\nabla_W f(\alpha_t).$$

则

$$\frac{d}{dt} f(\alpha_t) = - \int \|\nabla_W f(\alpha_t)(x)\|^2 d\alpha_t(x) \leq 0.$$

如果 T_t 是从 α_t 到 α^* 的最优映射, 则

$$f(\alpha_t) - f(\alpha^*) \leq -\frac{d}{dt} \frac{1}{2} \mathcal{W}_2^2(\alpha_t, \alpha^*),$$

并且因此

$$f(\alpha_t) - f(\alpha^*) \leq \frac{\mathcal{W}_2^2(\alpha_0, \alpha^*)}{2t}.$$

如果 f 是 λ -测地凸且 $\lambda > 0$, 则

$$f(\alpha_t) - f(\alpha^*) \leq e^{-2\lambda t} (f(\alpha_0) - f(\alpha^*)).$$

证明. 链式法则和命题 13.2 给出

$$\frac{d}{dt} f(\alpha_t) = \int \langle \nabla_W f(\alpha_t)(x), v_t(x) \rangle d\alpha_t(x) = - \int \|\nabla_W f(\alpha_t)(x)\|^2 d\alpha_t(x).$$

沿测地线的测地凸性 $((1-s)\text{Id} + sT_t)_\# \alpha_t$ 给出

$$f(\alpha^*) - f(\alpha_t) \geq \int \langle \nabla_W f(\alpha_t)(x), T_t(x) - x \rangle d\alpha_t(x).$$

由于 $v_t = -\nabla_W f(\alpha_t)$, 这可写为

$$f(\alpha_t) - f(\alpha^*) \leq \int \langle v_t(x), T_t(x) - x \rangle d\alpha_t(x).$$

平方 Wasserstein 距离的标准第一变分公式给出

$$\frac{d}{dt} \frac{1}{2} \mathcal{W}_2^2(\alpha_t, \alpha^*) = \int \langle x - T_t(x), v_t(x) \rangle d\alpha_t(x),$$

这证明了微分不等式。从 0 到 t 积分, 并使用 $s \mapsto f(\alpha_s)$ 的单调性, 得到

$$t(f(\alpha_t) - f(\alpha^*)) \leq \int_0^t (f(\alpha_s) - f(\alpha^*)) ds \leq \frac{1}{2} \mathcal{W}_2^2(\alpha_0, \alpha^*).$$

如果 f 是 λ -测地凸的, 强凸性的 Wasserstein 类比给出斜率不等式

$$\int \|\nabla_W f(\alpha_t)\|^2 d\alpha_t \geq 2\lambda(f(\alpha_t) - f(\alpha^*)).$$

将其与能量耗散恒等式结合, 得到

$$\frac{d}{dt}(f(\alpha_t) - f(\alpha^*)) \leq -2\lambda(f(\alpha_t) - f(\alpha^*)),$$

而 Gronwall 引理给出指数速率。 □

命题 13.9 (该理论覆盖的凸例子). 在以下标准情形中, 命题 13.8 的假设成立, 至少在本节使用的形式光滑层面上成立。

1. 对于线性能量 $f(\alpha) = \int h d\alpha$, 当 h 凸时, 测地凸性成立。如果 h 是 λ -强凸的, 则 f 是 λ -测地凸的, 并且该流具有命题 13.8 的指数速率。
2. 对于相互作用能量 $f(\alpha) = \frac{1}{2} \iint W(x-y) d\alpha(x) d\alpha(y)$, 当 W 凸且偶时, 测地凸性成立。这覆盖了位移代价没有非凸势阱的排斥或吸引成对模型。
3. Shannon 熵 $f(\alpha) = \int \rho \log \rho dx$, 以及更一般的 McCann 位移凸内能, 会生成扩散型 Wasserstein 梯度流。
4. 如果 $\gamma = Z^{-1} e^{-V} dx$ 且 V 是 λ -强凸的, 则相对熵 $KL(\alpha|\gamma)$ 是 λ -测地凸的。它的流是以 γ 为不变分布的 Fokker-Planck 方程。

证明. 令 $(\alpha_t)_t$ 为 α_0 与 α_1 之间的 McCann 插值, 并用最优耦合写作 $X_t = (1-t)X_0 + tX_1$ 。对于线性能量, Jensen 不等式给出

$$h(X_t) \leq (1-t)h(X_0) + th(X_1),$$

强凸版本给出额外项 $-\frac{\lambda}{2}t(1-t)\|X_0 - X_1\|^2$ 。对最优耦合积分, 即证明测地凸性和 λ -测地凸性。

对于相互作用能量, 使用最优耦合的两个独立副本。成对位移按如下方式演化:

$$X_t - X'_t = (1-t)(X_0 - X'_0) + t(X_1 - X'_1).$$

W 的凸性在对乘积耦合积分后给出凸性不等式。 W 的偶性保证相互作用关于两个粒子对称, 并与 (13.8) 中通常的因子 $1/2$ 匹配。

关于熵的结论是 McCann 的位移凸性定理。对于光滑正密度和 Brenier 映射, 它来自变量替换公式以及行列式沿正矩阵的凹性; 一般陈述通过近似得到。最后,

$$KL(\alpha|\gamma) = \int \rho \log \rho dx + \int V d\alpha + \log Z,$$

所以它是位移凸熵与由 V 生成的 λ -测地凸线性势之和。因此命题 13.8 适用于全部四种情形。 □

凸性与曲率。 同样的语言并不局限于 $\mathbb{R}^d$ 的子集。如果 $(\mathcal{X}, d, \mathbf{m})$ 是测地度量测度空间，则 $\mathcal{W}_2$ 测地线可以通过沿度量测地线传输每一对端点来定义，或者更内在地通过路径空间上的动态最优计划来定义，如第 3.5 节所讨论。给定参考测度 $\mathbf{m}$ ，相对于 $\mathbf{m}$ 的熵为

$$\text{Ent}_{\mathbf{m}}(\alpha) := \begin{cases} \int_{\mathcal{X}} \rho \log \rho \, d\mathbf{m}, & \text{如果 } \alpha = \rho \mathbf{m}, \\ +\infty, & \text{否则。} \end{cases}$$

在光滑 Riemann 流形 (M, g) 上，Ricci 曲率张量 Ric_g 是 Riemann 曲率张量的迹；下界 $\text{Ric}_g \geq \lambda g$ 意味着对每个切向量 v 都有 $\text{Ric}_g(v, v) \geq \lambda |v|_g^2$ 。曲率与最优传输之间的基本联系在于，这个张量下界正是由熵的测地凸性编码的。

定理 13.10 (Ricci 曲率与熵凸性). 令 (M, g) 为光滑紧致连通无边界 Riemann 流形，并令 $\mathbf{m} = \text{vol}_g$ 。对 $\lambda \in \mathbb{R}$ ，Ricci 下界 $\text{Ric}_g \geq \lambda g$ 成立，当且仅当 $\text{Ent}_{\mathbf{m}}$ 在 $(\mathcal{P}_2(M), \mathcal{W}_2)$ 上是 λ -测地凸的。

这一等价性由 Cordero-Erausquin、McCann 和 Schmuckenschläger 以及 von Renesse 和 Sturm 在光滑 Riemann 情形中发展 [69, 229]；它是 Villani 专著 [226] 中用最优传输研究曲率方法的核心主题。随后 Lott–Villani 和 Sturm 使用同样的熵凸性原则，在度量测度空间上定义合成 Ricci 曲率下界 [151, 219, 220]。在这一由凸性和曲率控制的区域之外，例如下文的平均场神经网络例子中，流仍然可能有信息量，但其收敛分析需要针对问题的专门论证。

13.3 把两层 MLP 训练看作 Wasserstein 流

平均场极限把宽神经网络的训练重写为神经元分布的传输。本节说明梯度下降的粒子 ODE 如何变成参数空间中的 Wasserstein 流。

我们用 $z \in \mathbb{R}^d$ 表示输入数据，用 $y \in \mathbb{R}^{d'}$ 表示标签。一个神经元是粒子

$$x = (u, v) \in \mathbb{R}^d \times \mathbb{R}^{d'},$$

其中 u 是内层权重， v 是外层向量权重。对于标量非线性 σ ，定义向量值特征

$$\psi(x, z) = v \sigma(\langle u, z \rangle) \in \mathbb{R}^{d'}.$$

宽度为 n 的网络及其平均场版本为

$$G_X(z) = \frac{1}{n} \sum_{i=1}^n \psi(x_i, z), \quad G_\alpha(z) = \int \psi(x, z) d\alpha(x), \quad \alpha = \frac{1}{n} \sum_i \delta_{x_i}.$$

这一表述移除了神经元的人为排序，并允许 α 是无限多个神经元的连续分布。

令 ρ 为数据–标签对 $(z, y) \in \mathbb{R}^d \times \mathbb{R}^{d'}$ 上的概率分布。总体风险为

$$f(\alpha) = \int \ell(G_\alpha(z), y) d\rho(z, y),$$

经验风险是特殊情形 $\rho = \rho_N := N^{-1} \sum_{k=1}^N \delta_{(z_k, y_k)}$ 。由于 $\alpha \mapsto G_\alpha$ 是线性的，只要 $\ell(\cdot, y)$ 是凸的， f 作为 α 的函数就是凸的。对于经验神经元分布 $\alpha_X = n^{-1} \sum_i \delta_{x_i}$ ，Wasserstein 度量在粒子上诱导出重缩放度量 $n^{-1} \sum_i \|\dot{x}_i\|^2$ 。相应的粒子流为

$$\dot{x}_i = -n \nabla_{x_i} F(X), \quad F(X) = f\left(\frac{1}{n} \sum_i \delta_{x_i}\right),$$

这是 $F(X) = f(\alpha_X)$ 在这一 Wasserstein 粒子度量下的梯度流，等价于把时间尺度乘以 n 的欧几里得梯度下降。它给出了 (13.3) 的粒子离散化。

假设 ℓ 关于其第一个变量可微。第一变分为

$$\delta f(\alpha)(x) = \int \langle \nabla_1 \ell(G_\alpha(z), y), \psi(x, z) \rangle d\rho(z, y), \quad (13.9)$$

而参数空间中的 Wasserstein 梯度为

$$\nabla_W f(\alpha)(x) = \nabla_x \delta f(\alpha)(x) = \int [D_x \psi(x, z)]^\top \nabla_1 \ell(G_\alpha(z), y) d\rho(z, y).$$

对于平方欧几里得损失 $\ell(s, y) = \frac{1}{2}\|s - y\|^2$, 能量是二次相互作用与线性势之和:

$$f(\alpha) = \frac{1}{2} \iint k(x, x') d\alpha(x) d\alpha(x') + \int g(x) d\alpha(x) + \frac{1}{2} \int \|y\|^2 d\rho(z, y), \quad (13.10)$$

with

$$k(x, x') = \int \langle \psi(x, z), \psi(x', z) \rangle d\rho(z, y), \quad g(x) = - \int \langle y, \psi(x, z) \rangle d\rho(z, y). \quad (13.11)$$

因此

$$\delta f(\alpha)(x) = \int k(x, x') d\alpha(x') + g(x), \quad \nabla_W f(\alpha)(x) = \int \nabla_x k(x, x') d\alpha(x') + \nabla_x g(x).$$

这些核通常在粒子变量中不是凸的, 因此上面的测地凸收敛理论不能直接适用。




图 13.7: 齐次两层模型的平均场训练可看作神经元空间中的传输。左图显示约化齐次坐标 $(|u|v_1, |u|v_2)$ 中的 Wasserstein 粒子梯度流, 黑色虚线射线标记教师方向。右图沿前置密集的时间序列显示加权角密度, 颜色从红到蓝, 使神经元方向的早期集中可见。该显示遵循辅助 MLP 实验的渲染方式, 但不保留谱流比较。

经典凸性与驻定性。 在使用 Chizat 和 Bach 的特定齐次性机制之前, 先分离出许多平均场论证背后一个更简单的凸分析原则是有用的。考虑形如

$$F(\alpha) = \frac{1}{2} \iint k(x, x') d\alpha(x) d\alpha(x') + \int V(x) d\alpha(x) + C,$$

的能量, 它定义在参数域上的概率测度上。假设二次部分在经典意义下是凸的, 即关于测度的仿射结构是凸的:

$$Q((1-s)\alpha + s\beta) \leq (1-s)Q(\alpha) + sQ(\beta), \quad Q(\alpha) = \frac{1}{2} \iint k d\alpha d\alpha.$$

这是泛函在测度凸集上的普通凸性, 而不是沿 $\mathcal{W}_2$ 测地线的位移凸性。

命题 13.11 (仿射凸性与驻定密度). 令 $F = Q + \int V d\alpha + C$ 如上, 并假设 Q 经典凸。假设 F 的 Wasserstein 梯度流收敛到测度 $\alpha_\infty = \rho_\infty dx$ 。还假设具备在第一变分中取极限所需的标准正则性, 并假设 ρ_∞ 的支撑和正性允许用所有可行的零质量密度扰动检验驻定条件。在这里所需的形式下, 假设这一驻定性对每个竞争者 β 给出变分不等式

$$\int \delta F(\alpha_\infty)(x) d(\beta - \alpha_\infty)(x) \geq 0.$$

则 α_∞ 是 F 的全局最小化子。

证明梗概. 梯度流的耗散恒等式给出极限的驻定性: 形式上, 取极限后,

$$\int \|\nabla \delta F(\alpha_\infty)\|^2 d\alpha_\infty = 0.$$

如果没有这样的支撑和正性假设，这个恒等式只控制极限所探索区域上的第一变分。密度假设允许用足够多的总质量为零的有符号密度扰动进行检验。通过近似和所假设的正则性，这给出对任意竞争者 β 的上述一阶变分不等式。随后， F 关于仿射变量 α 的经典凸性给出通常的次梯度不等式

$$F(\beta) \geq F(\alpha_\infty) + \int \delta F(\alpha_\infty) d(\beta - \alpha_\infty) \geq F(\alpha_\infty).$$

因此没有竞争者具有更小能量。对于平方损失两层平均场模型，(13.10) 正是这种二次加线性形式，而诱导核 k 的正半定性就是经典凸性假设。□

两层训练的平均场描述由多项工作发展，包括 [63, 158]。Chizat 和 Bach 的独特贡献在于，他们对正齐次网络给出了全局收敛分析，而不添加显式正则化器，也不依赖带噪 SGD 来产生 Laplacian 项。下面的形式陈述分离出核心机制，并忽略由 ReLU 非光滑性、支撑传播和紧性引起的技术问题。

命题 13.12 (二齐次平均场流的形式全局最优性). 假设特征关于神经元变量是正二齐次的，

$$\psi(\lambda x, z) = \lambda^2 \psi(x, z) \quad (\lambda > 0),$$

并且 $f(\alpha) = J(G_\alpha)$ ，其中 J 作为预测器的泛函是凸且可微的。令 α 为 Wasserstein 流的光滑驻点，使得在 $\text{supp}(\alpha)$ 上 $\nabla_x \delta f(\alpha)(x) = 0$ 。还假设完全方向支撑：对每个非零方向 ω ， α 的支撑都与射线 $\{\lambda \omega : \lambda > 0\}$ 相交。则 α 是平均场模型类上 f 的全局最小化子。

证明. 记

$$h_\alpha(x) = \delta f(\alpha)(x) = \langle \nabla J(G_\alpha), \psi(x, \cdot) \rangle_\rho.$$

由 ψ 的二齐次性，有 $h_\alpha(\lambda x) = \lambda^2 h_\alpha(x)$ 。归一化非零方向 ω ，并选取 $r_\omega > 0$ 使得 $r_\omega \omega \in \text{supp}(\alpha)$ 。驻定性给出该点处径向导数为零：

$$0 = \left. \frac{d}{dr} h_\alpha(r\omega) \right|_{r=r_\omega} = 2r_\omega h_\alpha(\omega).$$

因此对每个方向 ω 都有 $h_\alpha(\omega) = 0$ ，由齐次性可得对每个 x 都有 $h_\alpha(x) = 0$ 。

对任意竞争者 β ， J 的凸性给出

$$f(\beta) - f(\alpha) \geq \int h_\alpha(x) d(\beta - \alpha)(x) = 0.$$

因此没有竞争者具有更小风险。严格定理用传播和过参数化假设替代完全方向支撑假设，以保证若存在负下降方向，它会出现在支撑中，并与驻定性矛盾。□

通过传输的生成模型

前面的梯度流微积分是变分性的。现代机器学习模型经常更广泛地使用同一种传输语言：可以预先指定一个插值并回归其速度，可以把一步生成器拟合到下降场，也可以把网络深度看作 token 测度的连续传输。下面的例子区分真正的 Wasserstein 梯度流，以及具有有用几何解释的传输动力学。

14.1 通过流匹配的生成模型

流匹配通过学习插值的速度场来构造生成映射。关键计算洞见是，一个受约束的连续性方程问题可以通过无约束回归来训练。

生成模型旨在参考分布 α （通常是各向同性高斯）与目标数据分布 β 之间构造传输映射 T 。由于这样的参考测度是非原子的，在标准 Borel 空间上存在满足 $T_{\#}\alpha = \beta$ 的可测映射，例如可把两个概率空间都与单位区间等同起来并使用分位数型重排。这个抽象存在性陈述远弱于拥有 T 的显式且数值稳定的构造。最优传输是实现这一目标的一种方法，但它计算代价高昂，并引出如何从样本估计它的问题。另一条路线是预先指定噪声与数据之间的插值，学习其速度，并通过积分随时间变化的向量场 v_t 得到 T 。这一视角位于两支文献的交汇处，[181] 从传输角度进行了综述。扩散分支建立在 score 匹配 [124]、去噪 score 匹配 [227]、非平衡加噪链 [212]、去噪扩散概率模型 [122]、基于 score 的生成建模 [214]，以及连续时间 score-SDE/概率流表述 [215] 之上。确定性回归分支基本上并行地以三个紧密相关的名称被引入：流匹配 [147]、矫正流 [148] 和随机插值 [2]。在三种情形中，计算对象都是一个速度场，其回归损失避免在训练期间模拟学习到的 ODE。这个向量场 v_t 通过先构造插值 α_t ，再使用最小二乘公式 (12.7) 寻找 v_t 得到。正如我们将解释的，对于一类特定插值（由参数化推前得到），这个 v_t 可以通过避免显式反演 Laplacian、转而计算一个简单条件期望来获得。这个条件期望本身又可以通过求解另一个最小二乘问题来估计，但这一次是无约束的，因此可从 α 和 β 的有限样本中可行地估计。

随机插值。 我们假设 α_t 通过潜在分布 $\pi \in \mathcal{P}(\mathbb{R}^{d'})$ 的一种“投影”（宽泛意义上）来定义，使用算子 $P_t: \mathbb{R}^{d'} \rightarrow \mathbb{R}^d$ ，其中 $d' \gg d$ ，即

$$\forall t \in [0, 1], \quad \alpha_t := (P_t)_{\#}\pi. \quad (14.1)$$

基本的双端点构造已经覆盖实践中使用的大多数流匹配路径。

例 14.1 (线性双端点随机插值)。 令 $d' = 2d$ ，记 $(x, y) \in \mathbb{R}^d \times \mathbb{R}^d$ ，并选择 $P_0(x, y) = x$ 和 $P_1(x, y) = y$ 。如果 π 的边缘为 (α_0, α_1) ，则 $\alpha_t = (P_t)_{\#}\pi$ 在两个端点分布之间插值。最简单的选择是独立耦合 $\pi = \alpha_0 \otimes \alpha_1$ 和直线路径

$$P_t(x, y) = (1 - t)x + ty.$$

使用这条线性路径和任意耦合 π 时，下面的回归就是流匹配与矫正流的共同核心：Lipman 等强调条件概率路径以及连续归一化流的免仿真训练，而矫正流强调直线耦合、再流，以及降低传输代价和离散化误差的可能性 [147, 148]。

当从 π 采样仍然简单时，可以使用更复杂的构造；随机插值会加入潜变量或噪声，从而连接确定性流、概率流 ODE 和扩散 SDE [2]。

如果 $\pi = \alpha \otimes \beta$ ，且 $\alpha = \frac{1}{n} \sum_i \delta_{x_i}$ 、 $\beta = \frac{1}{m} \sum_j \delta_{y_j}$ ，则 α_t 由 $n \times m$ 个 Dirac 质量组成

$$\alpha_t = \frac{1}{nm} \sum_{i,j} \delta_{P_t(x_i, y_j)}.$$

如果 $\pi = (\text{Id}, T)_{\#}\alpha$ 是 Brenier 型耦合，则 $\alpha_t = ((1 - t)\text{Id} + tT)_{\#}\alpha$ 就是所谓的 McCann 最优传输插值。




图 14.1: 同一经验源测度和目标测度之间的流匹配插值。乘积式随机配对产生交叉路径, 最优传输配对给出直接位移射线, 而弯曲桥在保持相同端点的同时改变路径几何。灰色箭头标记代表性的中点速度 $\partial_t P_t$ 。

流匹配公式。 这个插值不能直接用于从 β 采样, 但它可用于定义流场 v_t , 使得 Euler 对流方程 (12.2) 成立。这个流场通过求解无约束最小二乘问题来计算; 等价地, 它是一个条件期望。

命题 14.2 (流匹配向量场). 对每个固定的 t , 假设 $\partial_t P_t \in L^2(\pi; \mathbb{R}^d)$ 。在可测场 $v_t: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 上的流匹配问题

$$\min_{v_t} \int_{\mathbb{R}^{d'}} \|v_t(P_t(u)) - [\partial_t P_t](u)\|^2 d\pi(u). \quad (14.2)$$

等价地, 最小化子由条件期望在 α_t -几乎处处刻画:

$$v_t(z) = \mathbb{E}_{u \sim \pi}([\partial_t P_t](u) \mid z = P_t(u)). \quad (14.3)$$

则二元组 (α_t, v_t) 满足连续性方程 (12.2)。

证明. 我们先回忆写出插值测度的两种等价方式。形式上, 可以写为

$$\alpha_t(z) = \int_{\mathbb{R}^{d'}} \delta(z - P_t(u)) d\pi(u),$$

而其严格含义是, 对每个光滑测试函数 φ ,

$$\int_{\mathbb{R}^d} \varphi(z) d\alpha_t(z) = \int_{\mathbb{R}^{d'}} \varphi(P_t(u)) d\pi(u). \quad (14.4)$$

(14.2) 中的最小化子, 是潜在速度 $\partial_t P_t(u)$ 在 $L^2(\pi; \mathbb{R}^d)$ 中到闭子空间的正交投影; 该子空间由仅通过 $P_t(u)$ 依赖于 u 的函数组成。这个投影就是条件期望 (14.3)。形式上, 它可读作

$$v_t(z) = \frac{1}{\alpha_t(z)} \int_{\mathbb{R}^{d'}} \delta(z - P_t(u)) [\partial_t P_t](u) d\pi(u),$$

严格地说, 它意味着对每个光滑测试向量场 m ,

$$\int \langle m(z), v_t(z) \rangle d\alpha_t(z) = \int \langle m(P_t(u)), [\partial_t P_t](u) \rangle d\pi(u). \quad (14.5)$$

现在证明该场传输曲线 $(\alpha_t)_t$ 。 $\partial_t \alpha_t + \operatorname{div}(\alpha_t v_t) = 0$ 的弱形式是, 对每个光滑标量测试函数 φ ,

$$\frac{d}{dt} \int \varphi(z) d\alpha_t(z) - \int \langle v_t(z), \nabla \varphi(z) \rangle d\alpha_t(z) = 0. \quad (14.6)$$

使用 (14.4) 并在积分号下求导, 得到

$$\frac{d}{dt} \int \varphi(z) d\alpha_t(z) = \int \langle \nabla \varphi(P_t(u)), [\partial_t P_t](u) \rangle d\pi(u). \quad (14.7)$$

另一方面, 在 (14.5) 中取 $m = \nabla \varphi$, 得到

$$\int \langle v_t(z), \nabla \varphi(z) \rangle d\alpha_t(z) = \int \langle \nabla \varphi(P_t(u)), [\partial_t P_t](u) \rangle d\pi(u). \quad (14.8)$$

比较 (14.7) 和 (14.8) 得到 (14.6), 这正是所需的连续性方程。 $\square$

(14.3) 中的条件期望有一个简单的测度论含义。令 $\alpha_t = (P_t)_\# \pi$ ，并在 $\mathbb{R}^d$ 上定义向量值测度 m_t ：

$$\int_{\mathbb{R}^d} \langle \psi(z), dm_t(z) \rangle := \int_{\mathbb{R}^{d'}} \langle \psi(P_t(u)), [\partial_t P_t](u) \rangle d\pi(u)$$

对每个有界连续向量场 ψ 都如此。由于 $\alpha_t(A) = 0$ 蕴含 $\pi(P_t^{-1}(A)) = 0$ ，于是 $m_t \ll \alpha_t$ 。因此 m_t 关于 α_t 的 Radon–Nikodym 分解为

$$dm_t(z) = v_t(z) d\alpha_t(z), \quad v_t = \frac{dm_t}{d\alpha_t}.$$

用 Lebesgue 分解的语言说，通量测度 m_t 关于 α_t 只有绝对连续部分，没有奇异部分；条件期望恰好就是这个密度。等价地，关于映射 P_t 对 π 进行 disintegration，得到 $\pi(du) = \pi_{t,z}(du)\alpha_t(dz)$ ，其中 $\pi_{t,z}$ 支撑在纤维 $\{u : P_t(u) = z\}$ 上，并且

$$v_t(z) = \int_{\{P_t(u)=z\}} [\partial_t P_t](u) d\pi_{t,z}(u).$$

因此，(14.2) 的解是速度 $\partial_t P_t$ 的条件期望：直观地说， $v_t(z)$ 是所有经过 z 的轨迹的平均速度。数值上， $(x, t) \rightarrow v_t(x)$ 可以由神经网络参数化（例如视觉任务中的 U-Net），并使用随机梯度下降在 (14.2) 的目标上估计。

算法 14.1 流匹配回归与采样

输入： 插值 $P_t(u)$ ，训练源 $u \sim \pi$ ，参数化场 $v_\theta(t, z)$ ，训练步数 N 。

输出： 学到的采样器 $X_0 \mapsto X_1$ 。

训练：

对于 $q = 1, \dots, N$ 执行：

 抽取 $t_q \sim \text{Unif}(0, 1)$ 和 $u_q \sim \pi$ 。

 置 $z_q = P_{t_q}(u_q)$ 和 $w_q = \partial_t P_t(u_q)|_{t=t_q}$ 。

 更新 θ ，即在 $\|v_\theta(t_q, z_q) - w_q\|^2$ 上执行一步随机梯度更新。

采样：

 抽取 $X_0 \sim \alpha_0$ 。

 积分 $\dot{X}_t = v_\theta(t, X_t)$ ， $t \in [0, 1]$ 。返回 X_1 。

对于精确场 v_t ，积分 ODE $\dot{x} = v_t(x)$ 定义传输映射 T_t 。如果 v_t 足够正则，或者更一般地，如果连续性方程对该速度有唯一解，则 $(T_t)_\# \alpha_0 = \alpha_t$ 。因此，与 (14.1) 相同的插值由确定性流表示，而不是由原始耦合表示。采样过程包括先抽取 $X_0 \sim \alpha$ ，然后以 $X_{t=0} = X_0$ 为起点积分 ODE $\dot{X}_t = v_t(X_t)$ 。在理想的精确场极限中，得到的 $X_{t=1}$ 服从 $\alpha_1 = \beta$ 。

与扩散模型的联系。 在特殊情形中， $P_t(x, y) = (1-t)x + ty$ 是线性插值且 $\pi = \alpha \otimes \beta$ ，曲线 α_t 是 α_0 和 α_1 的重缩放版本的卷积。流匹配问题 (14.2) 变为

$$\min_{(v_t)_t} \int_{\mathbb{R}^d \times \mathbb{R}^d} \|v_t((1-t)x + ty) - (y-x)\|^2 d\alpha_0(x) d\alpha_1(y).$$

当一个端点是各向同性高斯时，这一构造与扩散模型的概率流表述紧密相关，只差通常的时间参数化改变 [215]。这就是为什么流匹配既可视作扩散训练的确定性替代，也可视为扩散路径、受最优传输启发的路径和矫正路径的共同语言 [147, 148, 2]。下面两个命题按加噪方向书写，即从数据分布 α 到高斯；反转时间给出相应的采样流。它们还给出 v_t 的显式闭式形式，并说明它是梯度场。在这一设定中， v_t 也是受约束最小二乘问题 (12.7) 的解。回归 (14.2) 在计算上更简单，因为连续性方程已经由所选插值强制满足。为证明这一点，我们依赖 Tweedie 公式，它通过 score，即对数密度的梯度，表示最优高斯去噪器。

命题 14.3 (Tweedie 恒等式). 令 W 为 $\mathbb{R}^d$ 中密度为 β 的随机向量。对于 $\sigma > 0$ ，观测

$$Z = W + \sigma \varepsilon, \quad \text{其中 } \varepsilon \sim \mathcal{N}(0, I_d) \text{ 且独立于 } W.$$

记

$$\beta_\sigma = \beta * \mathcal{N}(0, \sigma^2 I_d)$$

为 Z 的密度。则

$$\mathbb{E}[W \mid Z = z] = z + \sigma^2 \nabla \log \beta_\sigma(z) \quad \text{对所有 } z \in \mathbb{R}^d.$$

证明. Bayes 法则给出条件密度 $p_{W|Z}(w | z) = \frac{\beta(w) \varphi_\sigma(z - w)}{\beta_\sigma(z)}$ 其中 φ_σ 是 $\mathcal{N}(0, \sigma^2 I_d)$ 密度. 因此

$$\mathbb{E}[W | Z = z] = \frac{1}{\beta_\sigma(z)} \int_{\mathbb{R}^d} w \beta(w) \varphi_\sigma(z - w) dw.$$

在积分号下对高斯卷积求导, 并使用 $\nabla_z \varphi_\sigma(z - w) = -\sigma^{-2}(z - w) \varphi_\sigma(z - w)$ 得到

$$\nabla_z \beta_\sigma(z) = \int \beta(w) \nabla_z \varphi_\sigma(z - w) dw = -\sigma^{-2} \left(z - \mathbb{E}[W | Z = z] \right) \beta_\sigma(z).$$

重排即完成证明. $\square$

命题 14.4 (高斯端点流匹配场). 令 $X \sim \alpha$ 与 $Y \sim \mathcal{N}(0, I_d)$ 独立. 对 $t \in (0, 1)$, 置

$$Z_t = (1 - t)X + tY, \quad \alpha_t = \text{分布}(Z_t).$$

如下问题的回归最小化子 $v^* : \mathbb{R}^d \times (0, 1) \rightarrow \mathbb{R}^d$

$$\min_v \int_0^1 \iint_{\mathbb{R}^d \times \mathbb{R}^d} |y - x - v((1 - t)x + ty, t)|^2 d\alpha(x) d\mathcal{N}(y) dt$$

为

$$v^*(x, t) = -\frac{1}{1 - t} x - \frac{t}{1 - t} \nabla \log \alpha_t(x) \quad (x \in \mathbb{R}^d, t \in (0, 1)).$$

特别地, 对每个 $t \in (0, 1)$, 该场都是梯度场:

$$v^*(\cdot, t) = -\nabla \left(\frac{\|\cdot\|^2}{2(1 - t)} + \frac{t}{1 - t} \log \alpha_t \right).$$

证明. 固定 $t \in (0, 1)$, 并记 $W = (1 - t)X$ 、 $\sigma = t$, 于是 $Z_t = W + \sigma Y$ 与命题 14.3 的设定相匹配. 条件期望满足 $v^*(z, t) = \mathbb{E}[Y - X | Z_t = z] = \frac{1}{t} \mathbb{E}[Z_t - W | Z_t = z] - \frac{1}{1 - t} \mathbb{E}[W | Z_t = z]$. 将命题 14.3 应用于 $\mathbb{E}[W | Z_t = z]$, 并注意到 $\mathbb{E}[Y | Z_t = z] = -t \nabla \log \alpha_t(z)$, 即可得到所声称的公式. $\square$




图 14.2: 高斯混合数据分布的一维扩散桥. 前向路径 $Z_t = (1 - t)X + tY$ 将红色数据密度平滑到蓝色高斯端点. 反转概率流 ODE 会把更密集的蓝色噪声样本传输回数据众数, 从而让轨迹在混合分量之间的分裂可见.

同样的概率流直觉在二维中也可见. 对于离散数据分布, 或更一般的高斯混合, 加噪密度是一个高斯混合, 其 score 可以显式求值. 这使得无需训练神经网络也能绘制反向轨迹. 在下面的图中, 高斯端点具有协方差 $\sigma^2 \text{Id}$, 以便在三个原子的尺度上保持几何可见. 对于标量加噪日程 $Z_t = a_t X + b_t Y$, 中间分布具有分量中心 $a_t c_j$ 和协方差 $(b_t \sigma)^2 \text{Id}$. 对于线性桥, $p_t(z) = \sum_j w_j \mathcal{N}((1 - t)c_j, (t\sigma)^2 \text{Id})$, 其中 $s_t = \nabla \log p_t$, 而命题 14.4 的缩放版本给出 $v_t(z) = -(z + t\sigma^2 s_t(z))/(1 - t)$.

诱导映射何时最优? 对学习到的速度积分会给出从 α_0 到 α_1 的确定性映射, 但这个映射并不会自动成为 Brenier 最优映射. 只有在累积流保持为凸势梯度的特殊情形下, 它才是最优的. 高斯乘积耦合情形已经展示了精确障碍: 插值协方差很简单, 速度是仿射的, 但终端映射可能包含隐藏的旋转部分. 该现象及其到矫正流和混合的扩展, 在 [121] 中有深入分析.

算法 14.2 高斯混合的精确概率流采样

输入： 高斯混合数据分布，日程 (a_t, b_t) ，噪声水平 σ ，样本数 R 。

输出： 反向样本 $(Z_0^{(r)})_r$ 。

定义加噪变量： $Z_t = a_t X + b_t Y$, $Y \sim \mathcal{N}(0, \sigma^2 \text{Id})$ 。

计算闭式混合密度 p_t 和 score $s_t = \nabla \log p_t$ 。

置概率流速度： $v_t(z) = \frac{a'_t}{a_t} z + \left(\frac{a'_t b'_t}{a_t} - b'_t b_t \right) \sigma^2 s_t(z)$ 。

对于 $r = 1, \dots, R$ 执行：

从 高斯端点抽取 $Z_1^{(r)}$ 。

从 $t = 1$ 到 $t = 0$ 反向积分 $\dot{Z}_t^{(r)} = v_t(Z_t^{(r)})$ 。

返回 $(Z_0^{(r)})_r$ 。




图 14.3: 从三个 Dirac 质量到单个高斯的二维加噪路径。上排显示线性插值 $Z_t = (1-t)X + tY$ ，其分量中心向原点线性移动，协方差按 $(t\sigma)^2 \text{Id}$ 增长。下排使用保方差 Ornstein-Uhlenbeck 系数 $a_\tau = e^{-\tau}$ 和 $b_\tau = \sqrt{1 - e^{-2\tau}}$ ，并用 $\tau = -\log \cos(\pi t/2)$ 重新参数化，使得 $a_t = \cos(\pi t/2)$ 且 $b_t = \sin(\pi t/2)$ 。它具有相同端点，但收缩和加噪速度不同。

命题 14.5 (高斯流匹配与最优性). 令 $\Sigma_0, \Sigma_1 \succ 0$ ，并令 $X_0 \sim \mathcal{N}(0, \Sigma_0)$ 与 $X_1 \sim \mathcal{N}(0, \Sigma_1)$ 独立。考虑线性流匹配插值

$$Z_t = (1-t)X_0 + tX_1, \quad \alpha_t = \text{Law}(Z_t) = \mathcal{N}(0, \Sigma_t),$$

其中

$$\Sigma_t = (1-t)^2 \Sigma_0 + t^2 \Sigma_1. \quad (14.9)$$

则精确流匹配速度是仿射的， $v_t(z) = A_t z$ ，其中

$$A_t = (t\Sigma_1 - (1-t)\Sigma_0)\Sigma_t^{-1}. \quad (14.10)$$

从 α_0 到 α_t 的诱导流映射 T_t^{FM} 为

$$T_t^{\text{FM}} = \Sigma_0^{1/2} \left((1-t)^2 \text{Id} + t^2 \Sigma_0^{-1/2} \Sigma_1 \Sigma_0^{-1/2} \right)^{1/2} \Sigma_0^{-1/2}. \quad (14.11)$$

特别地，

$$T_1^{\text{FM}} = \Sigma_0^{1/2} (\Sigma_0^{-1/2} \Sigma_1 \Sigma_0^{-1/2})^{1/2} \Sigma_0^{-1/2}. \quad (14.12)$$

该终端映射与二次最优传输映射

$$T^{\text{OT}} = \Sigma_0^{-1/2} (\Sigma_0^{1/2} \Sigma_1 \Sigma_0^{1/2})^{1/2} \Sigma_0^{-1/2} \quad (14.13)$$

相一致，当且仅当 $\Sigma_0 \Sigma_1 = \Sigma_1 \Sigma_0$ 。

证明. 条件期望公式给出

$$v_t(z) = \mathbb{E}[X_1 - X_0 \mid Z_t = z].$$

由于所有变量联合高斯，这个条件期望是线性的，并且

$$v_t(z) = \text{Cov}(X_1 - X_0, Z_t) \text{Cov}(Z_t)^{-1} z = (t\Sigma_1 - (1-t)\Sigma_0)\Sigma_t^{-1} z,$$

这证明了 (14.10)。为求解特征方程，通过如下设定白化源：

$$C = \Sigma_0^{-1/2} \Sigma_1 \Sigma_0^{-1/2}, \quad \tilde{Z}_t = \Sigma_0^{-1/2} Z_t.$$

在这些坐标中，源协方差为 Id ，并且

$$\tilde{\Sigma}_t = (1-t)^2 \text{Id} + t^2 C.$$

由于 Id 与 C 可交换，白化坐标中的仿射流映射就是 $\tilde{T}_t = \tilde{\Sigma}_t^{1/2}$ 。事实上，

$$\frac{d}{dt} \tilde{\Sigma}_t^{1/2} = (tC - (1-t)\text{Id}) \tilde{\Sigma}_t^{-1/2},$$

这正是满足 $\tilde{T}_0 = \text{Id}$ 的方程 $\dot{\tilde{T}}_t = \tilde{A}_t \tilde{T}_t$ 。回到原坐标得到 (14.11)，取 $t = 1$ 得到 (14.12)。

T_1^{FM} 和 T^{OT} 都把 $\mathcal{N}(0, \Sigma_0)$ 推前到 $\mathcal{N}(0, \Sigma_1)$ 。非退化高斯之间的 Brenier 映射是具有这一性质的唯一对称正定线性映射。因此， $T_1^{\text{FM}} = T^{\text{OT}}$ 当且仅当 T_1^{FM} 对称正定。映射 T_1^{FM} 与 $C^{1/2}$ 相似，所以如果它是对称的，则它自动正定。剩下只需刻画对称性。由于 $C^{1/2}$ 对称正定，

$$(T_1^{\text{FM}})^\top = \Sigma_0^{-1/2} C^{1/2} \Sigma_0^{1/2}.$$

因此 T_1^{FM} 的对称性等价于 $\Sigma_0 C^{1/2} = C^{1/2} \Sigma_0$ ，进而由泛函演算等价于 $\Sigma_0 C = C \Sigma_0$ 。在该恒等式左右两侧乘以 $\Sigma_0^{1/2}$ ，得到 $\Sigma_0 \Sigma_1 = \Sigma_1 \Sigma_0$ 。反过来，如果 Σ_0 和 Σ_1 可交换，则它们可正交共同对角化，并且 (14.12) 和 (14.13) 在该基下都化为对角映射，其条目为 $\sqrt{\lambda_{1,k}/\lambda_{0,k}}$ 。这证明了等价性。□

该命题对流匹配的一种常见过度解读给出简洁警示。

注 14.6 (改变桥的速度不会恢复最优性)。对任何具有相同端点的标量日程 $Z_t = a_t X_0 + b_t X_1$ ，都会得到同一个终端映射 (14.12)，因为白化后的协方差路径仍为 $a_t^2 \text{Id} + b_t^2 C$ 。因此，改变标量高斯桥的速度，例如使用 OU 日程，无法修复由不可交换协方差造成的非最优性。

可交换协方差会把终端映射化为一维缩放，而不可交换协方差会产生非对称仿射映射，因而产生带有旋转或剪切分量的传输。更一般地，即使每个瞬时速度看起来自然，混合型路径也可能产生同样的障碍。这一区分与一些反例密切相关，这些反例表明，与 Fokker–Planck 或扩散型演化相关的流映射通常并不提供最优传输映射 [138]。特别是，一旦目标分布是非高斯的，仅从各向同性高斯出发本身并不能保证最优性；还需要关于路径或耦合的额外结构假设。

插值的变体。生成轨迹的几何不仅取决于两个端点分布，也取决于所选插值。首先有一个无害的歧义：线性桥的单调重参数化 $Z_t = (1 - \lambda(t))X + \lambda(t)Y$ 只会改变流的速度，

$$v_t(z) = \lambda'(t) v_{\lambda(t)}^{\text{lin}}(z), \quad v_r^{\text{lin}}(z) = \mathbb{E}[Y - X \mid (1-r)X + rY = z].$$

因此它保持空间积分曲线不变。扩散模型使用一族真正不同的加噪路径。如果

$$Z_t = a_t X + b_t Y, \quad Y \sim \mathcal{N}(0, \sigma^2 \text{Id}),$$

则混合中心和分量方差都会改变。记 p_t 为 Z_t 的密度， $s_t = \nabla \log p_t$ ，Tweedie 公式在 $a_t = 0$ 之外的时间给出

$$v_t(z) = a'_t \mathbb{E}[X \mid Z_t = z] + b'_t \mathbb{E}[Y \mid Z_t = z] = \frac{a'_t}{a_t} z + \left(\frac{a'_t b'_t}{a_t} - b'_t b_t \right) \sigma^2 s_t(z).$$

对于线性桥， $a_t = 1 - t$ 且 $b_t = t$ ，这恢复了上面的公式。对于扩散模型中使用的保方差 Ornstein–Uhlenbeck 加噪，

$$a_\tau = e^{-\tau}, \quad b_\tau = \sqrt{1 - e^{-2\tau}},$$

可得到前向概率流速度 $v_\tau(z) = -z - \sigma^2 \nabla \log p_\tau(z)$ 。采样时，随着 τ 减小，沿反向场 $z + \sigma^2 \nabla \log p_\tau(z)$ 演化。这是图 14.4 左图使用的加噪规律；轨迹比线性桥更弯曲，因为中心和方差按照 OU/Fokker–Planck 缩放演化，而不是通过仿射插值演化。数值上，积分会在到达 Dirac 端点之前的一个小正时间停止，因为那里 score 会变奇异。

有限时间系数 $a_t = \cos(\pi t/2)$ 和 $b_t = \sin(\pi t/2)$ 并不是新的空间插值：它们正是时间变换 $\tau = -\log \cos(\pi t/2)$ 之后的 OU 系数。因此，图 14.5 比较 OU 与一个真正不同的标量桥：

$$a_t = (1-t)(1-2t), \quad b_t = t,$$

其数据系数在消失之前会改变符号。这个过冲桥主要是一个诊断性例子：它保持相同端点，但其中间混合会关于原点反射，并产生明显不同的反向轨迹。




图 14.4: 在图 14.3 的三 Dirac 设置中，类扩散采样轨迹与最优传输射线的比较。红色粒子从居中高斯端点采样，并被传输到三个蓝色原子。左图使用闭式高斯混合 score，积分保方差 OU 加噪 $a_\tau = e^{-\tau}$ 、 $b_\tau = \sqrt{1 - e^{-2\tau}}$ 的反向概率流 ODE，并在奇异 Dirac 端点之前停止。右图使用二次最优传输匹配为同一批原子选出的直线位移射线。




图 14.5: 插值对同一三 Dirac 目标和同一高斯端点的精确反向流的影响。线性桥 $a_t = 1 - t$ 、 $b_t = t$ 产生几乎径向的曲线。保方差 OU 桥 $a_\tau = e^{-\tau}$ 、 $b_\tau = \sqrt{1 - e^{-2\tau}}$ 改变收缩与加噪的相对速度。过冲桥 $a_t = (1 - t)(1 - 2t)$ 、 $b_t = t$ 不是前两者任一的时间重参数化，并会产生更明显弯曲的反向轨迹。

14.2 一步生成模型

一步生成模型试图保留流的几何训练原则，同时去除采样时昂贵的多步积分。其思想是在训练期间演化模型分布，但把最终演化存储在一次性生成器求值中。

训练一步流。 令 ζ 为简单潜在分布，并令 $\alpha_\theta = (G_\theta)_\# \zeta$ 为模型分布。假设目标数据分布为 β 。Wasserstein 流构造选择一个差异

$$\mathcal{E}_\beta(\alpha),$$

例如平滑的 $\text{KL}(\alpha|\beta)$ 、MMD/IPM 损失，或第 7.8 节引入的去偏 Sinkhorn 散度 $\bar{\mathcal{L}}_\zeta^\varepsilon(\alpha, \beta)$ 。相应的形式下降为

$$\partial_t \mu_t + \text{div}(\mu_t w_t) = 0, \quad w_t(x) = -\nabla \delta_\alpha \mathcal{E}_\beta(\mu_t)(x). \quad (14.14)$$

与其在推理时积分 (14.14)，不如沿当前模型分布拟合参数化残差场 U_η ：

$$\min_\eta \int_0^1 \int \|U_\eta(t, x) - w_t(x)\|^2 d\mu_t(x) dt. \quad (14.15)$$

在粒子或生成器实现中，随后用学到的残差按如下方式更新当前生成器：

$$\alpha_\theta^+ = (\text{Id} + \tau U_\eta)_\# \alpha_\theta, \quad \text{或等价地} \quad G_\theta^+(z) = G_\theta(z) + \tau U_\eta(G_\theta(z)).$$

经过多次训练更新后，累积生成器在测试时只求值一次。这是近期基于 Wasserstein 梯度流的一步方法背后的组织原则：W-Flow 使用这样的构造，并以 Sinkhorn 散度作为可处理的全局差异 [117]；而

算法 14.3 一步 Wasserstein 流生成器更新

输入：生成器 G_{θ_k} ，潜在分布 ζ ，数据分布 β ，数值下降场 oracle W_β ，步长 τ ，批大小 B 。

输出：更新后的生成器 $G_{\theta_{k+1}}$ 。

抽取 $z_b \sim \zeta$ ， $b = 1, \dots, B$ 。

置 $x_b = G_{\theta_k}(z_b)$ 。

置 $w_k(x) = W_\beta[\alpha_{\theta_k}](x)$ ，其中 $W_\beta[\alpha] = -\nabla \delta_\alpha \mathcal{E}_\beta(\alpha)$ 。

通过最小化经验最小二乘损失来置 $\eta_k: \frac{1}{B} \sum_{b=1}^B \|U_\eta(x_b) - w_k(x_b)\|^2$ 。

通过复合更新： $G_{\theta_{k+1}}(z) = G_{\theta_k}(z) + \tau U_{\eta_k}(G_{\theta_k}(z))$ 。 **返回** $G_{\theta_{k+1}}$ 。

漂移方法在训练期间通过拟合向量场演化生成分布，并且也允许一步推理 [78]。漂移模型的梯度流解释，以及它与 KL、MMD、切片 Wasserstein 和 Sinkhorn 型差异的关系，在 [113, 120] 中得到分析。这些思想还与 Sinkformers 中用于建模注意力的 Sinkhorn 型归一化动力学相关 [201]。

自校正漂移场。 漂移方法不必从精确 Wasserstein 梯度出发。它们常常预先指定一个吸引减排斥场，然后在 $L^2(\mu_t)$ 中回归该场。一个简单的连续版本使用正核 $K_\varepsilon(x, y)$ ，并对任意测度 ν 定义

$$B_\varepsilon[\nu](x) := \frac{\int (y - x) K_\varepsilon(x, y) d\nu(y)}{\int K_\varepsilon(x, y) d\nu(y)}. \quad (14.16)$$

对于高斯核 $K_\varepsilon(x, y) = \exp(-\|x - y\|^2/(2\varepsilon))$ ，这个归一化场是平滑密度的 score：

$$B_\varepsilon[\nu](x) = \varepsilon \nabla \log \left(\int K_\varepsilon(x, y) d\nu(y) \right). \quad (14.17)$$

于是漂移速度为

$$u_t(x) = B_\varepsilon[\beta](x) - B_\varepsilon[\mu_t](x) = \varepsilon \nabla \log \frac{\int K_\varepsilon(x, y) d\beta(y)}{\int K_\varepsilon(x, y) d\mu_t(y)}. \quad (14.18)$$

第一项把样本拉向数据，而第二项校正自吸引，并防止所有粒子塌缩到同一个高密度区域。Sinkhorn 漂移用双边熵正则最优传输耦合替代这些单边核归一化，使交叉项和自项由 Sinkhorn 缩放归一化，而不是由单个分母归一化 [120]。

算法 14.4 自校正漂移粒子更新

输入： μ_k 的粒子 x_i^k ，来自 β 的数据样本 $(y_b)_{b=1}^B$ ，核尺度 ε ，步长 h 。

输出：更新后的粒子 x_i^{k+1} 。

对于每个粒子 i 执行：

置 $Z_{\beta,i} = \sum_{b=1}^B K_\varepsilon(x_i^k, y_b)$ 和 $b_i^k = Z_{\beta,i}^{-1} \sum_{b=1}^B (y_b - x_i^k) K_\varepsilon(x_i^k, y_b)$ 。

置 $Z_{\mu,i} = \sum_{j=1}^n K_\varepsilon(x_i^k, x_j^k)$ 和 $m_i^k = Z_{\mu,i}^{-1} \sum_{j=1}^n (x_j^k - x_i^k) K_\varepsilon(x_i^k, x_j^k)$ 。

置 $u_i^k = b_i^k - m_i^k$ 。

更新 $x_i^{k+1} = x_i^k + h u_i^k$ 。

返回 $(x_i^{k+1})_i$ 。

命题 14.7 (作为时间依赖 Wasserstein 梯度的漂移)。令 μ_t 为正密度的光滑曲线，并令 $u_t = \nabla \varphi_t$ 为光滑时间依赖梯度场。定义半松弛泛函

$$\mathcal{R}_t(\alpha|\mu_t) := - \int \varphi_t(x) d\alpha(x) + \int \varphi_t(x) d\mu_t(x). \quad (14.19)$$

在关于第一个自变量 α 取第一变分时， μ_t 和 φ_t 被冻结。则连续性方程

$$\partial_t \mu_t + \operatorname{div}(\mu_t u_t) = 0$$

是时间依赖泛函 $\alpha \mapsto \mathcal{R}_t(\alpha|\mu_t)$ 的形式 Wasserstein 梯度下降。

证明。 由于关于 α 的变分中 μ_t 和 φ_t 固定，第一变分为

$$\delta_\alpha \mathcal{R}_t(\alpha|\mu_t)(x) = -\varphi_t(x).$$




图 14.6: 小粒子生成器的漂移轨迹。原始 Laplacian 核漂移具有较弱的长程吸引, 可能使粒子远离数据众数。自校正场使用差值 $B_\varepsilon[\beta] - B_\varepsilon[\mu_t]$, 因此较长积分会把粒子带到蓝色众数, 同时将它们从自身当前集中位置排斥开。

由命题 13.2,

$$\nabla_{\mathcal{W}} \mathcal{R}_t(\alpha|\mu_t) = \nabla_{\delta_\alpha} \mathcal{R}_t(\alpha|\mu_t) = -\nabla \varphi_t = -u_t.$$

Wasserstein 梯度下降速度是该梯度的相反数, 即 u_t 。把这个速度代入连续性方程, 得到所声称的流。□

例 14.8 (作为半松弛散度的核漂移). 对于高斯核漂移 (14.18), 置

$$\varphi_t(x) = \varepsilon \log \frac{\int K_\varepsilon(x, y) d\beta(y)}{\int K_\varepsilon(x, y) d\mu_t(y)}.$$

则 $u_t = \nabla \varphi_t$, 因此命题 14.7 表明, 核漂移是如下泛函的 Wasserstein 梯度下降:

$$\mathcal{R}_t^{\text{drift}}(\alpha|\mu_t) = \varepsilon \int \log \frac{\int K_\varepsilon(x, y) d\mu_t(y)}{\int K_\varepsilon(x, y) d\beta(y)} d\alpha(x) + \text{constant}.$$

它是“半松弛的”, 因为当前模型 μ_t 被用来构造势, 但在计算关于 α 的第一变分时, 分母中的 μ_t 并不参与变分。

注 14.9 (一般场与到梯度的投影). 一般回归场 b_t 不一定是 Wasserstein 梯度, 因为 Wasserstein 切向量由梯度场表示, 模去 $L^2(\mu_t)$ -零方向。梯度分量由加权投影得到:

$$\nabla \varphi_t = \underset{\nabla \varphi}{\operatorname{argmin}} \int \|\nabla \varphi(x) - b_t(x)\|^2 d\mu_t(x).$$

在该投影之前, 可以先逐点归一化 b_t , 例如用 $b_t/(\|b_t\| + \eta)$, 也可以用 $\|b_t\|_{L^2(\mu_t)}$ 进行全局归一化。随后命题 14.7 适用于投影后的场。非梯度分量在参数模型中仍可能有用, 但它们不是 $\mathcal{W}_2$ Riemann 度量下某个标量泛函的下降方向。

14.3 Transformer 的深度演化

深度残差架构可以理解为 ODE 或 PDE 的时间离散化。对于 transformer, 被传输的对象是 token 测度, 而速度由注意力诱导。

Transformer 最初作为由 self-attention 驱动序列到序列架构被引入 [223], 此后成为语言和视觉模型的核心架构 [45, 81]。它们的独特特征是, 每个 token 都由所有其他 token 的数据依赖平均来更新。这使得注意力层在位置编码之前具有置换等变性, 在对输入序列进行条件化之后依赖上下文, 并且自然兼容一种测度视角, 即把 prompt 视为 token 的经验分布。

下面使用的数学极限关注深度而非模型尺度: 让残差注意力层的数量增长, 同时每一层只作小更新, 如连续深度神经网络中那样 [58]。对于注意力, 所得速度关于当前 token 分布是非线性的, 因为它由整个上下文归一化。这种测度论视角出现在把注意力分析为 Lipschitz 算子或相互作用粒子算子的工作中 [230, 106], 出现在 Sinkformers 的 Sinkhorn 归一化动力学中 [201], 也出现在若干注意力机制近期的

适定性和平均场极限结果中 [54]。它还把这里研究的无限深度极限与 token 极限问题区分开来；在后者中，人们控制有限经验上下文如何近似其极限注意力算子 [36]。

现在考虑非常深的 transformer。为简单起见，我们聚焦单头注意力机制，并忽略 MLP 层、层归一化、因果性和掩码。这个简化框架最适合建模 encoder 和视觉 transformer；上面的参考文献说明了这一简化图景的哪些部分可以扩展到更丰富的注意力机制。

作为上下文依赖速度的注意力。 经过 tokenization、embedding 和位置编码后，每个输入（来自一组 token）被表示为向量化 token 空间中的 n 个点组成的点云 $(x_i)_{i=1}^n$ 。带跳连并按 $1/T$ （其中 T 是深度）重缩放的注意力层定义 token 的如下变换：

$$x_i \mapsto x_i + \frac{1}{T} \sum_j \frac{e^{\langle Qx_i, Kx_j \rangle} Vx_j}{\sum_\ell e^{\langle Qx_i, Kx_\ell \rangle}},$$

其中 $\theta = (K, Q, V)$ 是注意力层参数，由三个矩阵表示。

Token 测度演化。 为处理任意数量的 token，我们定义 $\alpha = \frac{1}{n} \sum_i \delta_{x_i}$ 为 token 的经验测度，并把 transformer 映射重写为：

$$x_i \mapsto x_i + \frac{1}{T} \Gamma_\theta[\alpha](x_i),$$

其中

$$\Gamma_\theta[\alpha](x) := \frac{\int e^{\langle Qx, Ky \rangle} Vy d\alpha(y)}{\int e^{\langle Qx, Kz \rangle} d\alpha(z)}.$$

在 token 分布层面，该层通过“上下文内”映射 $\Gamma_{\theta_t}[\alpha]$ 将 α 推前；该映射依赖上下文 α 、token，以及依赖深度的参数 θ_t 。记 $t \in [0, 1]$ 为深度， $\tau = 1/T$ 为步长，这给出：

$$\alpha_{t+\tau} = (\text{Id} + \tau \Gamma_{\theta_t}[\alpha_t])_\# \alpha_t.$$

当 $\tau \rightarrow 0$ 时，它形式上收敛到守恒方程

$$\partial_t \alpha_t + \text{div}(\alpha_t \Gamma_{\theta_t}[\alpha_t]) = 0.$$

算法 14.5 残差注意力深度演化

输入： Token $(x_i^0)_{i=1}^n$ ，深度 T ，层参数 (Q_k, K_k, V_k) 。

输出： 最终 token 测度 α_T 。

初始化： $\alpha_0 = \frac{1}{n} \sum_{i=1}^n \delta_{x_i^0}$ ， $\tau = 1/T$ 。

对于 $k = 0, \dots, T-1$ **执行：**

对于 $i = 1, \dots, n$ **执行**

$$\Gamma_{\theta_k}[\alpha_k](x_i^k) = \frac{\sum_j \exp(\langle Q_k x_i^k, K_k x_j^k \rangle) V_k x_j^k}{\sum_j \exp(\langle Q_k x_i^k, K_k x_j^k \rangle)}.$$

$$x_i^{k+1} = x_i^k + \tau \Gamma_{\theta_k}[\alpha_k](x_i^k).$$

$$\text{置 } \alpha_{k+1} = (\text{Id} + \tau \Gamma_{\theta_k}[\alpha_k])_\# \alpha_k.$$

返回 α_T 。

梯度结构与局限。 当 token 空间维度为 d 、query/key 空间维度为 r 时，取 $Q, K \in \mathbb{R}^{r \times d}$ 和 $V \in \mathbb{R}^{d \times d}$ 。如果 $V = Q^\top K$ ，则场 $\Gamma_\theta[\alpha]$ 是 token 变量中的梯度向量场。事实上，定义 log-partition 势

$$\Phi_\alpha(x) = \int \exp(\langle Qx, Ky \rangle) d\alpha(y), \quad U_\alpha(x) = \log \Phi_\alpha(x).$$

则

$$\nabla_x U_\alpha(x) = \frac{\int Q^\top Ky \exp(\langle Qx, Ky \rangle) d\alpha(y)}{\int \exp(\langle Qx, Kz \rangle) d\alpha(z)} = \Gamma_\theta[\alpha](x).$$

这是 x 中的瞬时梯度。然而，它并不是 α 的某个固定泛函的第一变分梯度，因为势 U_α 本身通过同一个注意力归一化依赖于当前测度。因此，该 PDE 通常是传输动力学，而不是 Wasserstein 梯度流。特殊变体可以恢复额外结构：Sinkhorn 注意力可以通过双随机归一化和 Wasserstein 型梯度流来解释 [201, 54]，而层归一化会自然导向球面上的动力学和修正度量。对当前视角而言，关键开放困难是训练：当架构已被重写为受控传输方程后，学习对应于优化时间依赖参数 $(\theta_t)_t$ ，而不只是分析固定参数下的前向 PDE。

14.4 高斯流形上的流

高斯测度为前述动力学提供了有用的试验场。它们在一般 Wasserstein 梯度流下并非不变：非线性速度通常会立即产生非高斯密度。有用的替代做法是识别能精确保高斯性的仿射速度，或者把动力学投影到高斯流形上。在两种情形中，测度 PDE 都化为均值和协方差的矩阵 ODE。这一视角在综述 [181] 中被强调，并有助于比较扩散路径、Wasserstein 梯度流、漂移场和 transformer 型动力学。

对于该族上的约束梯度流，协方差方程是正定矩阵上的有限维 Bures–Wasserstein 梯度流。因此，高斯闭合不只是计算捷径：它是 Wasserstein 几何到高斯子流形的限制，在那里仿射梯度场编码切向量。




图 14.7: 两个重叠各向异性高斯之间传输动力学的高斯闭合。左图是精确 W_2 高斯测地线。中图显示正则化 Sinkhorn 风格闭合，其中同一均值路径伴随膨胀的中间协方差。右图显示漂移风格闭合，具有弯曲均值路径和矩匹配协方差椭圆。这些有限维图像只保留均值和协方差，因此丢弃了真正非线性速度场会产生的高阶形状信息。

高斯性保持。 第一个问题是不变性：我们希望有一个简单准则，保证连续性方程不会离开有限维高斯族。

命题 14.10 (仿射速度保持高斯性). 令 $\alpha_t = \mathcal{N}(\mathbf{m}_t, \Sigma_t)$ ，其中 Σ_t 正定，并假设它用仿射速度求解连续性方程

$$v_t(x) = b_t + A_t(x - \mathbf{m}_t).$$

则 α_t 保持高斯，且其矩求解

$$\dot{\mathbf{m}}_t = b_t, \quad \dot{\Sigma}_t = A_t \Sigma_t + \Sigma_t A_t^\top.$$

反过来，任何具有正定协方差的光滑高斯曲线都可由这样的仿射速度生成。如果希望速度是 Wasserstein 切梯度，则选择 Lyapunov 方程的唯一对称解

$$A_t \Sigma_t + \Sigma_t A_t = \dot{\Sigma}_t.$$

证明. 令 X_t 服从特征 ODE $\dot{X}_t = b_t + A_t(X_t - \mathbf{m}_t)$ 。这个线性 ODE 把高斯随机变量映射为高斯随机变量。取期望得到 $\dot{\mathbf{m}}_t = b_t$ 。记 $\tilde{X}_t = X_t - \mathbf{m}_t$ ，则 $\dot{\tilde{X}}_t = A_t \tilde{X}_t$ ，因此

$$\dot{\Sigma}_t = \frac{d}{dt} \mathbb{E}(\tilde{X}_t \tilde{X}_t^\top) = A_t \Sigma_t + \Sigma_t A_t^\top.$$

对于反向命题，置 $b_t = \dot{\mathbf{m}}_t$ ，并选择任意满足协方差方程的矩阵 A_t 。由于 Σ_t 正定，Lyapunov 映射 $A \mapsto A \Sigma_t + \Sigma_t A$ 在对称矩阵上可逆；当需要梯度速度时，这给出唯一的对称选择。在这种情况下， v_t 是二次势 $x \mapsto \langle b_t, x \rangle + \langle A_t(x - \mathbf{m}_t), x - \mathbf{m}_t \rangle / 2$ 的梯度。□

高斯流形上的约束演化。 对于非仿射速度，有限维替代方案是把 Wasserstein 动力学投影到高斯流形上。

令

$$\mathcal{G} = \{\mathcal{N}(\mathbf{m}, \Sigma) : \mathbf{m} \in \mathbb{R}^d, \Sigma \succ 0\}$$

为 $\mathcal{P}_2(\mathbb{R}^d)$ 的高斯子流形。约束到光滑子流形 $\mathcal{M} \subset \mathcal{P}_2$ 上的泛函的 Wasserstein 梯度，定义为微分限制到 $\mathcal{M}$ 的切速度之后的 Riesz 表示元。等价地，它是约束 JKO 格式的小步长极限

$$\alpha^{k+1} \in \operatorname{argmin}_{\alpha \in \mathcal{M}} \frac{1}{2\tau} \mathcal{W}_2^2(\alpha, \alpha^k) + f(\alpha).$$

对于 $\mathcal{M} = \mathcal{G}$ ，切速度是仿射梯度场 $v(x) = b + A(x - \mathbf{m})$ ，其中 $A = A^\top$ 。因此，只要环境 Wasserstein 梯度存在，约束梯度就是它到该有限维仿射空间的 $L^2(\mathcal{N}(\mathbf{m}, \Sigma))$ 投影。

命题 14.11 (高斯约束 Wasserstein 梯度). 令 f 为光滑泛函, 并假设它到非退化高斯测度的限制可写为

$$f(\mathcal{N}(\mathbf{m}, \Sigma)) = F(\mathbf{m}, \Sigma).$$

则约束到高斯族上的 Wasserstein 梯度是仿射向量场

$$v_F(x) = \nabla_{\mathbf{m}} F(\mathbf{m}, \Sigma) + 2\nabla_{\Sigma} F(\mathbf{m}, \Sigma)(x - \mathbf{m}),$$

其中 $\nabla_{\Sigma} F$ 表示对称矩阵导数。等价地, 只要环境 Wasserstein 梯度存在, v_F 就是它到仿射梯度场上的 $L^2(\mathcal{N}(\mathbf{m}, \Sigma))$ 投影。因此, 约束到高斯测度上的梯度下降流满足

$$\dot{\mathbf{m}}_t = -\nabla_{\mathbf{m}} F(\mathbf{m}_t, \Sigma_t), \quad \dot{\Sigma}_t = -2(\Sigma_t \nabla_{\Sigma} F(\mathbf{m}_t, \Sigma_t) + \nabla_{\Sigma} F(\mathbf{m}_t, \Sigma_t) \Sigma_t), \quad (14.20)$$

并且下降速度是仿射的。

证明. 沿一个高斯切向量测试该泛函, 该切向量由仿射梯度场表示

$$v(x) = b + A(x - \mathbf{m})$$

其中 A 对称。诱导的一阶变分为 $\dot{\mathbf{m}} = b$ 和 $\dot{\Sigma} = A\Sigma + \Sigma A$ 。因此

$$dF(\mathbf{m}, \Sigma)[b, A\Sigma + \Sigma A] = \langle \nabla_{\mathbf{m}} F, b \rangle + \text{tr}(\nabla_{\Sigma} F(A\Sigma + \Sigma A)).$$

由于 A 、 Σ 和 $\nabla_{\Sigma} F$ 都是对称的, 第二项等于

$$2 \text{tr}(\nabla_{\Sigma} F A \Sigma) = \int \langle 2\nabla_{\Sigma} F(x - \mathbf{m}), A(x - \mathbf{m}) \rangle d\mathcal{N}(\mathbf{m}, \Sigma)(x).$$

连同均值项, 这给出

$$dF(\mathbf{m}, \Sigma)[\dot{\mathbf{m}}, \dot{\Sigma}] = \int \langle v_F(x), v(x) \rangle d\mathcal{N}(\mathbf{m}, \Sigma)(x)$$

对所有仿射梯度场 v 都成立。这就在诱导的 $L^2(\alpha)$ 度量中识别出约束 Wasserstein 梯度; 等价地, 当环境梯度存在时, 它就是环境梯度的投影。把下降速度 $-v_F$ 代入命题 14.10, 得到 (14.20)。□

这个命题应被理解为高斯闭合的组织规则: 一旦标量能量已约化为 $(\mathbf{m}, \Sigma)$ 的函数, 其约束 Wasserstein 梯度就自动是仿射的, 并且协方差遵循 Bures 型 ODE (14.20)。当 f 的第一变分是二次的时, 这个约束梯度与完整 Wasserstein 梯度一致。

保高斯的梯度流。 下面的例子表明, 许多熟悉能量在高斯输入上已经具有仿射 Wasserstein 梯度, 因此它们的完整流保持高斯族内。

例 14.12 (高斯能量与仿射梯度). 命题 14.11 把许多标准能量转化为显式仿射场:

- 二次势能。如果

$$f(\alpha) = \int \left(\frac{1}{2} x^\top H x + \langle \ell, x \rangle \right) d\alpha(x), \quad H = H^\top,$$

则

$$\nabla_{\mathcal{W}} f(\alpha)(x) = Hx + \ell = (H\mathbf{m} + \ell) + H(x - \mathbf{m}).$$

这是二次约束下传输的高斯形式。

- 二次相互作用能量。如果

$$f(\alpha) = \frac{1}{4} \iint (x - y)^\top G(x - y) d\alpha(x) d\alpha(y), \quad G = G^\top,$$

则 $F(\mathbf{m}, \Sigma) = \frac{1}{2} \text{tr}(G\Sigma)$, 并且

$$\nabla_{\mathcal{W}} f(\alpha)(x) = G(x - \mathbf{m}).$$

均值不变, 而协方差会根据 G 的符号收缩或扩张。

- 到高斯的相对熵。对于 $\bar{\alpha} = \mathcal{N}(\bar{\mathbf{m}}, \bar{\Sigma})$,

$$f(\alpha) = \text{KL}(\alpha | \bar{\alpha})$$

有

$$\nabla_{\mathcal{W}} f(\alpha)(x) = \bar{\Sigma}^{-1}(\mathbf{m} - \bar{\mathbf{m}}) + (\bar{\Sigma}^{-1} - \Sigma^{-1})(x - \mathbf{m}).$$

下降方程是 Ornstein–Uhlenbeck 矩方程

$$\dot{\mathbf{m}}_t = -\bar{\Sigma}^{-1}(\mathbf{m}_t - \bar{\mathbf{m}}), \quad \dot{\Sigma}_t = 2\text{Id} - \bar{\Sigma}^{-1}\Sigma_t - \Sigma_t\bar{\Sigma}^{-1}.$$

- 到高斯的平方 *Wasserstein* 距离。对于

$$f(\alpha) = \frac{1}{2} \mathcal{W}_2^2(\alpha, \bar{\alpha}), \quad \bar{\alpha} = \mathcal{N}(\bar{\mathbf{m}}, \bar{\Sigma}),$$

高斯 Brenier 映射 $T_{\alpha \rightarrow \bar{\alpha}}$ 是仿射的,

$$T_{\alpha \rightarrow \bar{\alpha}}(x) = \bar{\mathbf{m}} + M(x - \mathbf{m}), \quad M = \Sigma^{-1/2}(\Sigma^{1/2} \bar{\Sigma} \Sigma^{1/2})^{1/2} \Sigma^{-1/2}.$$

因此

$$\nabla_{\mathcal{W}} f(\alpha)(x) = x - T_{\alpha \rightarrow \bar{\alpha}}(x) = (\mathbf{m} - \bar{\mathbf{m}}) + (\text{Id} - M)(x - \mathbf{m}),$$

下降会把每个高斯沿 Bures–Wasserstein 测地线无穷小地移向 $\bar{\alpha}$ 。

- 仅高斯损失。到高斯的切片 SW_2^2 损失、高斯 Sinkhorn 散度, 以及任何只依赖 $(\mathbf{m}, \Sigma)$ 的光滑闭式公式, 都符合相同的约束梯度模板:

$$v_F(x) = \nabla_{\mathbf{m}} F + 2\nabla_{\Sigma} F(x - \mathbf{m}).$$

对于高斯 Sinkhorn 散度, 这一有限维流在 [119] 中得到研究。

并非每个 PDE 都精确保高斯性。例如, 相对 Fisher 信息的 Wasserstein 流与量子漂移或高阶扩散方程相关, 通常需要高斯投影才能在 $(\mathbf{m}, \Sigma)$ 上闭合。这样的投影闭合仍然有用: 它们揭示变分模型预测的有限维动力学, 并便于把变分流与非变分仿射动力学比较, 例如漂移场或下面的高斯 transformer 闭合。

命题 14.13 (居中高斯协方差目录). 令 $\gamma = \mathcal{N}(0, \text{Id})$, 并令 $\mu_t = \mathcal{N}(0, C_t)$, 其中 $C_t \succ 0$ 。对于下面显示的归一化, 约束到居中高斯流形上的 *Wasserstein* 下降满足 $\dot{C}_t = h(C_t)$, 其中

$$\begin{aligned} \text{KL}(\mu|\gamma) &: h(C) = 2(\text{Id} - C), \\ \frac{1}{2} \mathcal{I}(\mu|\gamma) &: h(C) = 2(C^{-1} - C), \\ \mathcal{W}_2^2(\mu, \gamma) &: h(C) = 4(C^{1/2} - C), \\ \text{MMD}_k^2(\mu, \gamma), \quad k(x, y) = \langle x, y \rangle^2 &: h(C) = 8(C - C^2), \\ S_\varepsilon(\mu, \gamma) &: h(C) = 4 \left(C + \frac{\varepsilon^2}{16} \text{Id} \right)^{1/2} - 2 \left(C^2 + \frac{\varepsilon^2}{16} \text{Id} \right)^{1/2} - 2C - \frac{\varepsilon}{2} \text{Id}, \\ \text{SW}_2^2(\mu, \gamma) &: h(C) = V(C)C + CV(C), \end{aligned}$$

其中 S_ε 是二次代价 $\|x - y\|^2$ 和 KL 正则化强度 ε 下的去偏 *Sinkhorn* 散度, 并且

$$V(C) = 2 \int_{\mathbb{S}^{d-1}} \left(\frac{1}{\sqrt{\theta^\top C \theta}} - 1 \right) \theta \theta^\top d\sigma(\theta)$$

其中 σ 是归一化球面测度。这里

$$\mathcal{I}(\mu|\gamma) = \int |\nabla \log \rho(x) + x|^2 \rho(x) dx \quad (\mu = \rho dx).$$

因此, 未除以二的 *Fisher* 散度具有右端 $4(C^{-1} - C)$ 。把这些能量中的任意一个乘以常数, 只会重缩放相应右端。

证明. 每一行都通过识别相应高斯约束计算生成的仿射下降速度 $v(x) = M_C x$, 然后应用命题 14.10 得到; 该命题给出 $\dot{C} = M_C C + C M_C^\top$ 。对于 $\text{KL}(\cdot|\gamma)$, Fokker–Planck 速度为 $(C^{-1} - \text{Id})x$, 因此 $\dot{C} = 2(\text{Id} - C)$ 。对于 Fisher 行, $\frac{1}{2} \mathcal{I}$ 到居中高斯的限制为

$$\frac{1}{2} (\text{tr}(C) + \text{tr}(C^{-1}) - 2d).$$

使用命题 14.11 给出下降速度 $(C^{-2} - \text{Id})x$, 因此 $\dot{C} = 2(C^{-1} - C)$ 。这一行应理解为四阶 Fisher 流的高斯投影闭合。

对于 $\mathcal{W}_2^2(\cdot, \gamma)$, 从 $\mathcal{N}(0, C)$ 到 γ 的 Brenier 映射为 $C^{-1/2}x$, 所以未除以二的平方距离的下降速度是 $2(C^{-1/2} - \text{Id})x$, 给出 $4(C^{1/2} - C)$ 。对于多项式 MMD 行, 居中高斯满足 $\text{MMD}_k^2(\mu, \gamma) = \|C - \text{Id}\|_F^2$; 第一变分是二次的, 其下降速度为 $4(\text{Id} - C)x$, 给出 $8(C - C^2)$ 。

高斯 Sinkhorn 对偶势是二次的, 所以速度再次是线性的; 对闭式高斯公式求导会得到所显示的谱表达式。这些平方根是 C 的谱函数, 因此与 C 可交换, 这也解释了为什么协方差 ODE 仅作为 C 的矩阵函数闭合。对于切片 Wasserstein, 每个一维投影都是速度为 $2((\theta^\top C \theta)^{-1/2} - 1)\langle \theta, x \rangle \theta$ 的高斯传输; 在 $\mathbb{S}^{d-1}$ 上平均这些速度得到 $v(x) = V(C)x$, 从而 $\dot{C} = V(C)C + CV(C)$ 。□

例 14.14 (作为交叉矩流的线性平均场网络). 在上面的两层模型中, 取线性激活 $\sigma(s) = s$, 使得

$$\psi((u, v), z) = v \langle u, z \rangle.$$

预测器是线性映射

$$G_{\alpha_t}(z) = Q_t z, \quad Q_t = \int v u^\top d\alpha_t(u, v) \in \mathbb{R}^{d' \times d}.$$

因此, 能量只通过交叉矩 Q_t 依赖于神经元分布, 而 Q_t 是 $x = (u, v)$ 的原始二阶矩的一个子块。对于平方损失, 置

$$S = \int z z^\top d\rho(z, y), \quad R = \int y z^\top d\rho(z, y), \quad H_t = Q_t S - R.$$

第一变分为

$$\delta f(\alpha_t)(u, v) = \langle H_t, v u^\top \rangle = v^\top H_t u.$$

因此参数空间中的粒子速度是线性的:

$$-\nabla_{(u, v)} \delta f(\alpha_t)(u, v) = - \begin{pmatrix} 0 & H_t^\top \\ H_t & 0 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix}.$$

因此, 神经元的高斯分布会保持高斯。其均值和协方差遵循命题 14.10, 其中矩阵只依赖当前交叉矩 Q_t ; Q_t 是一个原始二阶矩子块, 当神经元分布居中时成为协方差子块。这种精确闭合是线性激活所特有的; 对于非线性激活, 高斯闭合通常是投影, 而不是不变族。

非变分的保高斯流。 最后几个例子不是完整 Wasserstein 空间上某个固定标量能量的普通梯度流。它们保持高斯性, 是因为预先指定的速度场在高斯测度上求值时是仿射的。

例 14.15 (高斯之间的流匹配与扩散路径). 考虑预先指定的高斯插值 $\alpha_t = \mathcal{N}(\mathbf{m}_t, \Sigma_t)$ 。命题 14.10 表明, 精确流匹配速度可以取为仿射形式:

$$v_t(x) = \dot{\mathbf{m}}_t + A_t(x - \mathbf{m}_t), \quad A_t \Sigma_t + \Sigma_t A_t = \dot{\Sigma}_t.$$

在各向同性情形 $\Sigma_t = s_t^2 \text{Id}$ 中, 这化为透明的公式

$$v_t(x) = \dot{\mathbf{m}}_t + \frac{\dot{s}_t}{s_t}(x - \mathbf{m}_t).$$

例如, 扩散加噪路径

$$X_t = a_t X_0 + \sigma_t Z, \quad Z \sim \mathcal{N}(0, \text{Id}),$$

具有 $\mathbf{m}_t = a_t \mathbf{m}_0$ 和 $\Sigma_t = a_t^2 \Sigma_0 + \sigma_t^2 \text{Id}$ 。因此, 在高斯情形中, 扩散路径和流匹配路径化为同样的均值-协方差记账, 尽管相应训练目标不同。

例 14.16 (高斯核漂移). 令目标为 $\beta = \mathcal{N}(\bar{\mathbf{m}}, \bar{\Sigma})$, 并假设 $\mu_t = \mathcal{N}(\mathbf{m}_t, \Sigma_t)$ 。对于高斯核

$$K_\varepsilon(x, y) = \exp(-\|x - y\|^2 / (2\varepsilon)),$$

归一化场 (14.16) 满足

$$B_\varepsilon[\mu_t](x) = -\varepsilon(\Sigma_t + \varepsilon \text{Id})^{-1}(x - \mathbf{m}_t).$$

因此, 漂移速度 (14.18) 是仿射的并保持高斯性。记

$$A_t = (\Sigma_t + \varepsilon \text{Id})^{-1}, \quad \bar{A} = (\bar{\Sigma} + \varepsilon \text{Id})^{-1},$$

则 ODE 为

$$\dot{\mathbf{m}}_t = \varepsilon \bar{A}(\bar{\mathbf{m}} - \mathbf{m}_t), \quad \dot{\Sigma}_t = \varepsilon((A_t - \bar{A})\Sigma_t + \Sigma_t(A_t - \bar{A})).$$

这个有限维模型解释了漂移中自归一化排斥项的稳定作用: 没有它, 协方差方程会失去 $A_t \Sigma_t + \Sigma_t A_t$ 贡献。

例 14.17 (注意力动力学的高斯闭合). 对于 transformer PDE, 假设 $\alpha = \mathcal{N}(\mathbf{m}, \Sigma)$ 。由于指数倾斜保持高斯性,

$$\frac{\int e^{\langle Qx, Ky \rangle} y d\alpha(y)}{\int e^{\langle Qx, Kz \rangle} d\alpha(z)} = \mathbf{m} + \Sigma K^\top Qx.$$

因此

$$\Gamma_\theta[\alpha](x) = V\mathbf{m} + V\Sigma K^\top Qx$$

是仿射的。高斯 token 分布被保持, 并满足

$$\mathbf{m}_t = (V_t + V_t \Sigma_t K_t^\top Q_t) \mathbf{m}_t, \quad \dot{\Sigma}_t = B_t \Sigma_t + \Sigma_t B_t^\top, \quad B_t = V_t \Sigma_t K_t^\top Q_t.$$

当 $V_t = Q_t^\top K_t$ 时, 矩阵 $B_t = Q_t^\top K_t \Sigma_t K_t^\top Q_t$ 对称正半定, 与上面提到的梯度场情形一致。这一闭合不是训练后 transformer 的收敛定理。它只是一个可处理模型, 描述注意力如何通过协方差剪切、放大或收缩 token 云。

收缩的高斯投影。 前面的例子说明了何时高斯性会被保持或通过投影强加。Gelbrich 不等式 [102] 给出一个有用的变分解释: 用具有相同一阶和二阶矩的高斯替换一个测度, 不会增加它到另一个类似投影测度的 Wasserstein 距离。

定理 14.18 (Gelbrich 定理). 对 $\mu \in \mathcal{P}_2(\mathbb{R}^d)$, 令

$$\mathcal{R}\mu := \mathcal{N}(\mathbf{m}_\mu, \Sigma_\mu)$$

为与 μ 具有相同均值和协方差的高斯。则

$$\mathcal{W}_2^2(\mathcal{R}\mu, \mathcal{R}\nu) = \|\mathbf{m}_\mu - \mathbf{m}_\nu\|^2 + \mathcal{B}^2(\Sigma_\mu, \Sigma_\nu) \leq \mathcal{W}_2^2(\mu, \nu).$$

证明. 取 μ 和 ν 的任意耦合 (X, Y) , 将变量居中, 并记 $C = \mathbb{E}[(X - \mathbf{m}_\mu)(Y - \mathbf{m}_\nu)^\top]$ 。在正定情形中, 块协方差矩阵的正性蕴含分解 $C = \Sigma_\mu^{1/2} K \Sigma_\nu^{1/2}$, 其中 $\|K\|_{\text{op}} \leq 1$, 因此由算子范数/核范数对偶性,

$$\text{tr } C \leq \text{tr} \left((\Sigma_\mu^{1/2} \Sigma_\nu \Sigma_\mu^{1/2})^{1/2} \right).$$

半正定情形通过向两个协方差矩阵都加入 ηId 并令 $\eta \downarrow 0$ 得到。展开 $\mathbb{E}\|X - Y\|^2$ 给出下界

$$\mathbb{E}\|X - Y\|^2 \geq \|\mathbf{m}_\mu - \mathbf{m}_\nu\|^2 + \mathcal{B}^2(\Sigma_\mu, \Sigma_\nu).$$

对耦合取下确界证明该不等式, 而高斯分布时的等号情形由命题 2.39 给出。□

下面的保持准则是 Gelbrich 定理的直接推论, 由 Hugo Lavenant 向我们解释。它说明, 在矩匹配高斯投影下不增加的泛函, 从高斯初始数据出发会容许高斯最小化运动。

定理 14.19 (Hugo Lavenant 高斯保持准则). 令 $F : \mathcal{P}_2(\mathbb{R}^d) \rightarrow (-\infty, +\infty]$ 满足

$$F(\mathcal{R}\mu) \leq F(\mu) \quad \forall \mu \in \mathcal{P}_2(\mathbb{R}^d),$$

其中 $\mathcal{R}$ 如定理 14.18 中定义。如果 γ 是高斯, 且 ν 最小化 JKO 步

$$\eta \mapsto F(\eta) + \frac{1}{2\tau} \mathcal{W}_2^2(\gamma, \eta),$$

则 $\mathcal{R}\nu$ 也是最小化子。如果 JKO 最小化子唯一, 则它是高斯。因此, 任何作为该 JKO 格式极限得到的唯一 Wasserstein 梯度流都会保持高斯初始数据。

证明. 对于 JKO 断言, 由于 γ 是高斯, $\mathcal{R}\gamma = \gamma$ 。因此, 对任意竞争者 η ,

$$F(\mathcal{R}\eta) + \frac{1}{2\tau} \mathcal{W}_2^2(\gamma, \mathcal{R}\eta) \leq F(\eta) + \frac{1}{2\tau} \mathcal{W}_2^2(\gamma, \eta).$$

把它应用于最小化子 $\eta = \nu$, 说明 $\mathcal{R}\nu$ 仍是最小化子。唯一性强制 $\nu = \mathcal{R}\nu$ 。□

注 14.20 (来自收缩性的高斯重心). 同一个投影论证也解释了为什么高斯测度的二次 Wasserstein 重心是高斯。如果 β_s 是高斯且

$$F(\mu) = \sum_s \lambda_s \mathcal{W}_2^2(\mu, \beta_s),$$

则 $\mathcal{R}\beta_s = \beta_s$, 并且定理 14.18 给出 $F(\mathcal{R}\mu) \leq F(\mu)$ 。因此, 任何重心的矩匹配高斯投影仍然是重心; 当重心唯一时, 它本身必须是高斯。这就是推论 10.9 背后的收缩性视角。

结论

最优传输之所以有用，是因为它同时保持着若干活跃的视角。它是耦合上的线性规划，是关于势的对偶理论，是概率测度上的几何，是 PDE 和梯度流的来源，也是围绕线性规划、Sinkhorn 缩放和低维投影构建的计算工具箱。这些视角彼此强化：Brenier 映射解释测地线，测地凸性解释流的收敛，熵正则化把传输变成可扩展的可微损失，而对偶范数或切片变体揭示了简化 OT 时获得了什么、又失去了什么。

对机器学习而言，这种相互作用尤其富有启发。现代生成建模、扩散与流匹配、反问题、鲁棒优化，甚至 transformer 的连续深度视角，都要求在高维中移动、比较或学习分布的方法。这些应用并不只是消耗既有的 OT 理论；它们还会产生困难的数学问题，因为经验测度是奇异的，维度很高，模型是参数化且非凸的，计算近似又与统计误差不可分离。OT 的力量恰恰在于，它为这些张力提供了一种共同语言，同时仍保留足够开放的结构，使新的数学成为必要。

致谢

本工作得到欧洲研究理事会 (ERC 项目 WOLF) 以及法国政府在 Agence Nationale de la Recherche 管理下作为 “France 2030” 计划一部分的支持，项目编号为 ANR-23-IACL-0008 (PRAIRIE-PSAI)。

参考文献

- [1] Martial Agueh and Guillaume Carlier. Barycenters in the Wasserstein space. *SIAM Journal on Mathematical Analysis*, 43(2):904–924, 2011.
- [2] Michael S. Albergo, Nicholas M. Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions. *Journal of Machine Learning Research*, 26(209):1–80, 2025.
- [3] Syed Mumtaz Ali and Samuel D Silvey. A general class of coefficients of divergence of one distribution from another. *Journal of the Royal Statistical Society. Series B (Methodological)*, 28(1):131–142, 1966.
- [4] Jason Altschuler, Jonathan Weed, and Philippe Rigollet. Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration. In *Advances in Neural Information Processing Systems*, volume 30, pages 1964–1974, 2017.
- [5] Pedro C Álvarez-Esteban, E del Barrio, JA Cuesta-Albertos, and C Matrán. A fixed-point approach to barycenters in Wasserstein space. *Journal of Mathematical Analysis and Applications*, 441(2):744–762, 2016.
- [6] Luigi Ambrosio and Nicola Gigli. A user’s guide to optimal transport. In *Modelling and Optimisation of Flows on Networks*, volume 2062 of *Lecture Notes in Mathematics*, pages 1–155. Springer, 2013.
- [7] Luigi Ambrosio, Nicola Gigli, and Giuseppe Savaré. *Gradient Flows in Metric Spaces and in the Space of Probability Measures*. Springer, 2006.
- [8] Ethan Anderes, Steffen Borgwardt, and Jacob Miller. Discrete Wasserstein barycenters: optimal transport for discrete data. *Mathematical Methods of Operations Research*, 84(2):389–409, 2016.
- [9] Francisco Andrade, Gabriel Peyré, and Clarice Poon. Sparsistency for inverse optimal transport. In *International Conference on Learning Representations*, 2024.
- [10] Francisco Andrade, Gabriel Peyré, and Clarice Poon. Learning from samples: Inverse problems over measures via sharpened Fenchel–Young losses. *arXiv preprint arXiv:2505.07124*, 2025.
- [11] Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. In Doina Precup and Yee Whye Teh, editors, *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 214–223. PMLR, 2017.
- [12] David Arthur and Sergei Vassilvitskii. k -means++: The advantages of careful seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, pages 1027–1035, 2007.
- [13] Franz Aurenhammer. Power diagrams: properties, algorithms and applications. *SIAM Journal on Computing*, 16(1):78–96, 1987.
- [14] Franz Aurenhammer, Friedrich Hoffmann, and Boris Aronov. Minkowski-type theorems and least-squares clustering. *Algorithmica*, 20(1):61–76, 1998.
- [15] Julio Backhoff Veraguas, Mathias Beiglböck, and Gudmund Pammer. Existence, duality, and cyclical monotonicity for weak transport costs. *arXiv preprint arXiv:1809.05893*, 2018.
- [16] Martin Beckmann. A continuous model of transportation. *Econometrica*, 20:643–660, 1952.
- [17] Aurélien Bellet, Amaury Habrard, and Marc Sebban. Metric learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning*, 9(1):1–151, 2015.

- [18] Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem. *Numerische Mathematik*, 84(3):375–393, 2000.
- [19] Jean-David Benamou, Guillaume Carlier, Marco Cuturi, Luca Nenna, and Gabriel Peyré. Iterative Bregman projections for regularized transportation problems. *SIAM Journal on Scientific Computing*, 37(2):A1111–A1138, 2015.
- [20] Jean-David Benamou, Guillaume Carlier, Quentin Mérigot, and Edouard Oudet. Discretization of functionals involving the Monge–Ampère operator. *Numerische Mathematik*, 134(3):611–636, 2016.
- [21] Jean-David Benamou, Brittany D Froese, and Adam M Oberman. Numerical solution of the optimal transportation problem using the Monge–Ampère equation. *Journal of Computational Physics*, 260(1):107–126, 2014.
- [22] Christian Berg, Jens Peter Reus Christensen, and Paul Ressel. *Harmonic Analysis on Semigroups*. Number 100 in Graduate Texts in Mathematics. Springer Verlag, 1984.
- [23] Alain Berlinet and Christine Thomas-Agnan. *Reproducing Kernel Hilbert Spaces in Probability and Statistics*. Kluwer Academic Publishers, 2003.
- [24] Andrew C. Berry. The accuracy of the Gaussian approximation to the sum of independent variates. *Transactions of the American Mathematical Society*, 49(1):122–136, 1941.
- [25] Dimitri P Bertsekas. A new algorithm for the assignment problem. *Mathematical Programming*, 21(1):152–171, 1981.
- [26] Dimitri P Bertsekas. Auction algorithms for network flow problems: a tutorial introduction. *Computational Optimization and Applications*, 1(1):7–66, 1992.
- [27] Dimitri P Bertsekas and Jonathan Eckstein. Dual coordinate step methods for linear network flow problems. *Mathematical Programming*, 42(1):203–243, 1988.
- [28] Dimitris Bertsimas and John N Tsitsiklis. *Introduction to Linear Optimization*. Athena Scientific, 1997.
- [29] Rajendra Bhatia, Tanvi Jain, and Yongdo Lim. On the Bures–Wasserstein distance between positive definite matrices. *Expositiones Mathematicae*, 37(2):165–191, 2019.
- [30] Jérémie Bigot, Elsa Cazelles, and Nicolas Papadakis. Central limit theorems for entropy-regularized optimal transport on finite spaces and statistical applications. *Electronic Journal of Statistics*, 13(2):5120–5150, 2019.
- [31] Garrett Birkhoff. Tres observaciones sobre el algebra lineal. *Universidad Nacional de Tucumán Revista Series A*, 5:147–151, 1946.
- [32] Garrett Birkhoff. Extensions of jentzsch’s theorem. *Transactions of the American Mathematical Society*, 85(1):219–227, 1957.
- [33] Jose Blanchet and Karthyek Murthy. Quantifying distributional model risk via optimal transport. *Mathematics of Operations Research*, 44(2):565–600, 2019.
- [34] Sergey G. Bobkov. Berry–Esseen bounds and Edgeworth expansions in the central limit theorem for transport distances. *Probability Theory and Related Fields*, 170:229–262, 2018.
- [35] Vladimir I. Bogachev. *Measure Theory*. Springer, Berlin, 2007.
- [36] Léa Bohbot, Cyril Letrouit, Gabriel Peyré, and Francois-Xavier Vialard. Token sample complexity of attention. *arXiv preprint arXiv:2512.10656*, 2025.
- [37] Emmanuel Boissard, Thibaut Le Gouic, and Jean-Michel Loubes. Distribution’s template estimate with Wasserstein metrics. *Bernoulli*, 21(2):740–759, 2015.

- [38] Francois Bolley, Arnaud Guillin, and Cédric Villani. Quantitative concentration inequalities for empirical measures on non-compact spaces. *Probability Theory and Related Fields*, 137(3):541–593, 2007.
- [39] Nicolas Bonneel and Julie Digne. A survey of optimal transport for computer graphics and computer vision. *Computer Graphics Forum*, 42(2):439–460, 2023.
- [40] Nicolas Bonneel, Julien Rabin, Gabriel Peyré, and Hanspeter Pfister. Sliced and Radon Wasserstein barycenters of measures. *Journal of Mathematical Imaging and Vision*, 51(1):22–45, 2015.
- [41] Nicolas Bonnotte. *Unidimensional and evolution methods for optimal transportation*. PhD thesis, Université Paris-Sud, 2013.
- [42] Lev M Bregman. The relaxation method of finding the common point of convex sets and its application to the solution of problems in convex programming. *USSR Computational Mathematics and Mathematical Physics*, 7(3):200–217, 1967.
- [43] Yann Brenier. Décomposition polaire et réarrangement monotone des champs de vecteurs. *C. R. Acad. Sci. Paris Sér. I Math.*, 305(19):805–808, 1987.
- [44] Yann Brenier. Polar factorization and monotone rearrangement of vector-valued functions. *Communications on Pure and Applied Mathematics*, 44(4):375–417, 1991.
- [45] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, 2020.
- [46] Donald Bures. An extension of Kakutani’s theorem on infinite product measures to the tensor product of semifinite w^* -algebras. *Transactions of the American Mathematical Society*, 135:199–212, 1969.
- [47] Luis Caffarelli. The Monge-Ampere equation and optimal transportation, an elementary review. *Lecture Notes in Mathematics*, Springer-Verlag, pages 1–10, 2003.
- [48] Luis Caffarelli, Mikhail Feldman, and Robert McCann. Constructing optimal maps for Monge’s transport problem as a limit of strictly convex costs. *Journal of the American Mathematical Society*, 15(1):1–26, 2002.
- [49] Eric A Carlen and Jan Maas. An analog of the 2-Wasserstein metric in non-commutative probability under which the fermionic Fokker–Planck equation is gradient flow for the entropy. *Communications in Mathematical Physics*, 331(3):887–926, 2014.
- [50] Guillaume Carlier, Victor Chernozhukov, and Alfred Galichon. Vector quantile regression beyond the specified case. *Journal of Multivariate Analysis*, 161:96–102, 2017.
- [51] Guillaume Carlier and Ivar Ekeland. Matching for teams. *Economic Theory*, 42(2):397–418, 2010.
- [52] Guillaume Carlier, Alfred Galichon, and Filippo Santambrogio. From knothe’s transport to Brenier’s map and a continuation method for optimal transport. *SIAM Journal on Mathematical Analysis*, 41(6):2554–2576, 2010.
- [53] José A Carrillo, Alina Chertock, and Yanghong Huang. A finite-volume method for nonlinear nonlocal equations with a gradient flow structure. *Communications in Computational Physics*, 17:233–258, 1 2015.
- [54] Valérie Castin, Pierre Ablin, José Antonio Carrillo, and Gabriel Peyré. A unified perspective on the dynamics of deep transformers. *arXiv preprint arXiv:2501.18322*, 2025.

- [55] Shouvanik Chakrabarti, Yiming Huang, Tongyang Li, Soheil Feizi, and Xiaodi Wu. Quantum Wasserstein generative adversarial networks. *Advances in Neural Information Processing Systems*, 32, 2019.
- [56] Timothy M Chan. Optimal output-sensitive convex hull algorithms in two and three dimensions. *Discrete & Computational Geometry*, 16(4):361–368, 1996.
- [57] Louis H. Y. Chen, Larry Goldstein, and Qi-Man Shao. *Normal Approximation by Stein’s Method*. Springer, 2011.
- [58] Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [59] Yongxin Chen, Wilfrid Gangbo, Tryphon T Georgiou, and Allen Tannenbaum. On the matrix Monge-Kantorovich problem. *European Journal of Applied Mathematics*, 31(4):574–600, 2020.
- [60] Yongxin Chen, Tryphon T Georgiou, and Michele Pavon. On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint. *Journal of Optimization Theory and Applications*, 169(2):671–691, 2016.
- [61] Yongxin Chen, Tryphon T Georgiou, and Allen Tannenbaum. Matrix optimal mass transport: a quantum mechanical approach. *arXiv preprint arXiv:1610.03041*, 2016.
- [62] Sinho Chewi, Jonathan Niles-Weed, and Philippe Rigollet. Statistical optimal transport. *arXiv preprint arXiv:2407.18163*, 2024.
- [63] Lénaïc Chizat and Francis Bach. On the global convergence of gradient descent for over-parameterized models using optimal transport. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [64] Lénaïc Chizat, Alex Delalande, and Tomas Vaškevičius. Sharper exponential convergence rates for Sinkhorn’s algorithm in continuous settings. *arXiv preprint arXiv:2407.01202*, 2024.
- [65] Lénaïc Chizat, Gabriel Peyré, Bernhard Schmitzer, and Francois-Xavier Vialard. Unbalanced optimal transport: dynamic and Kantorovich formulation. *Journal of Functional Analysis*, 274(11):3090–3123, 2018.
- [66] Lénaïc Chizat, Bernhard Schmitzer, Gabriel Peyré, and Francois-Xavier Vialard. An interpolating distance between optimal transport and Fisher–Rao metrics. *Foundations of Computational Mathematics*, 18(1):1–44, 2018.
- [67] Imre Ciszár. Information-type measures of difference of probability distributions and indirect observations. *Studia Scientiarum Mathematicarum Hungarica*, 2:299–318, 1967.
- [68] Michael B Cohen, Aleksander Madry, Dimitris Tsipras, and Adrian Vladu. Matrix scaling and balancing via box constrained Newton’s method and interior point methods. In *58th IEEE Annual Symposium on Foundations of Computer Science*, pages 902–913. IEEE Computer Society, 2017.
- [69] Dario Cordero-Erausquin, Robert J. McCann, and Michael Schmuckenschläger. A Riemannian interpolation inequality à la Borell, Brascamp and Lieb. *Inventiones Mathematicae*, 146(2):219–257, 2001.
- [70] Marco Cuturi. Sinkhorn distances: lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems 26*, pages 2292–2300, 2013.
- [71] Marco Cuturi and David Avis. Ground metric learning. *Journal of Machine Learning Research*, 15:533–564, 2014.
- [72] Marco Cuturi and Arnaud Doucet. Fast computation of Wasserstein barycenters. In *Proceedings of the 31st International Conference on Machine Learning*, volume 32 of *Proceedings of Machine Learning Research*, pages 685–693. PMLR, 2014.
- [73] Marco Cuturi and Gabriel Peyré. A smoothed dual approach for variational Wasserstein problems. *SIAM Journal on Imaging Sciences*, 9(1):320–343, 2016.

- [74] Bernard Dacorogna and Jürgen Moser. On a partial differential equation involving the Jacobian determinant. *Annales de l'Institut Henri Poincaré C, Analyse non linéaire*, 7(1):1–26, 1990.
- [75] George B Dantzig. Application of the simplex method to a transportation problem. *Activity Analysis of Production and Allocation*, 13:359–373, 1951.
- [76] Julie Delon, Julien Salomon, and Andrei Sobolevski. Fast transport optimization for Monge costs on the circle. *SIAM Journal on Applied Mathematics*, 70(7):2239–2258, 2010.
- [77] Julie Delon, Julien Salomon, and Andrei Sobolevski. Local matching indicators for transport problems with concave costs. *SIAM Journal on Discrete Mathematics*, 26(2):801–827, 2012.
- [78] Mingyang Deng, He Li, Tianhong Li, Yilun Du, and Kaiming He. Generative modeling via drifting. *arXiv preprint arXiv:2602.04770*, 2026.
- [79] Ishan Deshpande, Yuan-Ting Hu, Ruoyu Sun, Ayis Pyrros, Nasir Siddiqui, Sanmi Koyejo, Zhizhen Zhao, David A. Forsyth, and Alexander G. Schwing. Max-sliced Wasserstein distance and its use for GANs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10648–10656, 2019.
- [80] Jean Dolbeault, Bruno Nazaret, and Giuseppe Savaré. A new class of transport distances between measures. *Calculus of Variations and Partial Differential Equations*, 34(2):193–231, 2009.
- [81] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [82] Richard M. Dudley. The speed of mean Glivenko-Cantelli convergence. *Annals of Mathematical Statistics*, 40(1):40–50, 1969.
- [83] Arnaud Dupuy, Alfred Galichon, and Yifei Sun. Estimating matching affinity matrices under low-rank constraints. *Information and Inference: A Journal of the IMA*, 8(4):677–689, 2019.
- [84] Pavel Dvurechensky, Alexander Gasnikov, and Alexey Kroshnin. Computational optimal transport: Complexity by accelerated gradient descent is better than by sinkhorn’s algorithm. In Jennifer Dy and Andreas Krause, editors, *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1367–1376. PMLR, 10–15 Jul 2018.
- [85] Gintare Karolina Dziugaite, Daniel M Roy, and Zoubin Ghahramani. Training generative neural networks via maximum mean discrepancy optimization. In *Uncertainty in Artificial Intelligence-Proceedings of the 31st Conference, UAI 2015*, pages 258–267, 2015.
- [86] Jonathan Eckstein and Dimitri P Bertsekas. On the Douglas-Rachford splitting method and the proximal point algorithm for maximal monotone operators. *Mathematical Programming*, 55:293–318, 1992.
- [87] Matthias Erbar. The heat equation on manifolds as a gradient flow in the Wasserstein space. *Annales de l'Institut Henri Poincaré, Probabilités et Statistiques*, 46(1):1–23, 2010.
- [88] Carl-Gustav Esseen. On the Liapunoff limit of error in the theory of probability. *Arkiv for Matematik, Astronomi och Fysik*, 28A(9):1–19, 1942.
- [89] Montacer Essid and Michele Pavon. Traversing the Schrödinger bridge strait: Robert Fortet’s marvelous proof redux. *Journal of Optimization Theory and Applications*, 181:23–60, 2019.
- [90] Rémi Flamary, Nicolas Courty, Alexandre Gramfort, Mokhtar Z. Alaya, Aurélie Boissunon, Stanislas Chambon, Laetitia Chapel, Adrien Corenflos, Kilian Fatras, Nemo Fournier, Léo Gautheron, Nathalie T. H. Gayraud, Hicham Janati, Alain Rakotomamonjy, Ievgen Redko, Antoine Rolet, Antony Schutz, Vivien Seguy, Danica J. Sutherland, Romain Tavenard, Alexander Tong, and Titouan Vayer. POT: Python optimal transport. *Journal of Machine Learning Research*, 22(78):1–8, 2021.

- [91] Robert Fortet. Résolution d'un système d'équations de M. Schrödinger. *Journal de Mathématiques Pures et Appliquées*, 19(1–4):83–105, 1940.
- [92] Nicolas Fournier and Arnaud Guillin. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability Theory and Related Fields*, 162(3–4):707–738, 2015.
- [93] Joel Franklin and Jens Lorenz. On the scaling of multidimensional matrices. *Linear Algebra and its Applications*, 114:717–735, 1989.
- [94] Brittany D Froese and Adam M Oberman. Convergent finite difference solvers for viscosity solutions of the elliptic monge–ampère equation in dimensions two and higher. *SIAM Journal on Numerical Analysis*, 49(4):1692–1714, 2011.
- [95] Charlie Frogner, Chiyuan Zhang, Hossein Mobahi, Mauricio Araya, and Tomaso A Poggio. Learning with a Wasserstein loss. In *Advances in Neural Information Processing Systems*, pages 2053–2061, 2015.
- [96] Alfred Galichon. *Optimal Transport Methods in Economics*. Princeton University Press, 2016.
- [97] Alfred Galichon and Bernard Salanié. Matching with trade-offs: revealed preferences over competing characteristics. Technical report, Preprint SSRN-1487307, 2009.
- [98] Thomas O Gallouët and Leonard Monsaingeon. A JKO splitting scheme for Kantorovich–Fisher–Rao gradient flows. *SIAM Journal on Mathematical Analysis*, 49(2):1100–1130, 2017.
- [99] Wilfrid Gangbo and Robert J McCann. The geometry of optimal transportation. *Acta Mathematica*, 177(2):113–161, 1996.
- [100] Rui Gao and Anton J. Kleywegt. Distributionally robust stochastic optimization with Wasserstein distance. *Mathematics of Operations Research*, 48(2):603–655, 2023.
- [101] Ankit Garg and Rafael Oliveira. Recent progress on scaling algorithms and applications. *arXiv preprint arXiv:1808.09669*, 2018.
- [102] Matthias Gelbrich. On a formula for the l^2 wasserstein metric between measures on euclidean and hilbert spaces. *Mathematische Nachrichten*, 147(1):185–203, 1990.
- [103] Aude Genevay, Lénaïc Chizat, Francis Bach, Marco Cuturi, and Gabriel Peyré. Sample complexity of Sinkhorn divergences. In *Proceedings of the Twenty-Second International Conference on Artificial Intelligence and Statistics*, volume 89 of *Proceedings of Machine Learning Research*, pages 1574–1583. PMLR, 2019.
- [104] Aude Genevay, Marco Cuturi, Gabriel Peyré, and Francis Bach. Stochastic optimization for large-scale optimal transport. In *Advances in Neural Information Processing Systems*, pages 3440–3448, 2016.
- [105] Tryphon T Georgiou and Michele Pavon. Positive contraction mappings for classical and quantum Schrödinger systems. *Journal of Mathematical Physics*, 56(3):033301, 2015.
- [106] Borjan Geshkovski, Cyril Letrouit, Yury Polyanskiy, and Philippe Rigollet. A mathematical perspective on transformers. *arXiv preprint arXiv:2312.10794*, 2023.
- [107] Ugo Gianazza, Giuseppe Savaré, and Giuseppe Toscani. The Wasserstein gradient flow of the Fisher information and the quantum drift-diffusion equation. *Archive for Rational Mechanics and Analysis*, 194(1):133–220, 2009.
- [108] Francois Golse, Emanuele Caglioti, and Thierry Paul. Quantum optimal transport is cheaper. *arXiv preprint arXiv:1908.01829*, 2019.
- [109] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, pages 2672–2680, 2014.
- [110] Nathael Gozlan, Cyril Roberto, Paul-Marie Samson, and Prasad Tetali. Kantorovich duality for general transport costs and applications. *Journal of Functional Analysis*, 273(11):3327–3405, 2017.

- [111] Siegfried Graf and Harald Luschgy. *Foundations of Quantization for Probability Distributions*, volume 1730 of *Lecture Notes in Mathematics*. Springer, 2000.
- [112] Arthur Gretton, Karsten M Borgwardt, Malte J Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13(Mar):723–773, 2012.
- [113] Arthur Gretton, Kevin Wenliang Li, Alexandre Galashov, James Thornton, Valentin De Bortoli, and Arnaud Doucet. On the wasserstein gradient flow interpretation of drifting models. *arXiv preprint arXiv:2605.05118*, 2026.
- [114] Mikhail Gromov. *Metric Structures for Riemannian and Non-Riemannian Spaces*. Progress in Mathematics. Birkhäuser, 2001.
- [115] Leonid Gurvits. Classical deterministic complexity of Edmonds’ problem and quantum entanglement. In *Proceedings of the Thirty-Fifth Annual ACM Symposium on Theory of Computing*, pages 10–19. ACM, 2003.
- [116] Leonid Gurvits. Classical complexity and quantum entanglement. *Journal of Computer and System Sciences*, 69(3):448–484, 2004.
- [117] Jiaqi Han, Puheng Li, Qiushan Guo, Renyuan Xu, Stefano Ermon, and Emmanuel J. Candès. One-step generative modeling via wasserstein gradient flows. *arXiv preprint arXiv:2605.11755*, 2026.
- [118] Leonid G Hanin. Kantorovich-Rubinstein norm and its application in the theory of Lipschitz spaces. *Proceedings of the American Mathematical Society*, 115(2):345–352, 1992.
- [119] Mathis Hardion and Théo Lacombe. The wasserstein gradient flow of the sinkhorn divergence between gaussian distributions. *arXiv preprint arXiv:2602.10726*, 2026.
- [120] Ping He, Om Khangaonkar, Hamed Pirsiavash, Yikun Bai, and Soheil Kolouri. Sinkhorn-drifting generative models. *arXiv preprint arXiv:2603.12366*, 2026.
- [121] Johannes Hertrich, Antonin Chambolle, and Julie Delon. On the relation between rectified flows and optimal transport. In *Advances in Neural Information Processing Systems*, 2025. arXiv:2505.19712.
- [122] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, pages 6840–6851, 2020.
- [123] Thomas Hofmann, Bernhard Schölkopf, and Alexander J Smola. Kernel methods in machine learning. *Annals of Statistics*, 36(3):1171–1220, 2008.
- [124] Aapo Hyvärinen. Estimation of non-normalized statistical models by score matching. *Journal of Machine Learning Research*, 6:695–709, 2005.
- [125] Martin Idel. A review of matrix scaling and Sinkhorn’s normal form for matrices and positive maps. *arXiv preprint arXiv:1609.06349*, 2016.
- [126] Hicham Janati, Boris Muzellec, Gabriel Peyré, and Marco Cuturi. Entropic optimal transport between unbalanced Gaussian measures has a closed form. In *Advances in Neural Information Processing Systems*, 2020.
- [127] Xianhua Jiang, Lipeng Ning, and Tryphon T Georgiou. Distances and Riemannian metrics for multivariate spectral densities. *IEEE Transactions on Automatic Control*, 57(7):1723–1735, 2012.
- [128] Leonid Kantorovich. On the transfer of masses (in russian). *Doklady Akademii Nauk*, 37(2):227–229, 1942.
- [129] LV Kantorovich and G.S. Rubinstein. On a space of totally additive functions. *Vestn Leningrad Universitet*, 13:52–59, 1958.
- [130] Johan Karlsson and Axel Ringh. Generalized Sinkhorn iterations for regularizing inverse problems using optimal mass transport. *arXiv preprint arXiv:1612.02273*, 2016.

- [131] Abdelwahed Khamis, Russell Tsuchida, Mohamed Tarek, Vivien Rolland, and Lars Petersson. Scalable optimal transport methods in machine learning: A contemporary survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.
- [132] Philip A Knight. The Sinkhorn–Knopp algorithm: convergence and applications. *SIAM Journal on Matrix Analysis and Applications*, 30(1):261–275, 2008.
- [133] Herbert Knothe. Contributions to the theory of convex bodies. *Michigan Mathematical Journal*, 4(1):39–52, 1957.
- [134] Soheil Kolouri, Yang Zou, and Gustavo K Rohde. Sliced Wasserstein kernels for probability distributions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 5258–5267, 2016.
- [135] J. Kruithof. Telefoonverkeersrekening. *De Ingenieur*, 52:E15–E25, 1937.
- [136] Harold W. Kuhn. The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1–2):83–97, 1955.
- [137] Brian Kulis. Metric learning: a survey. *Foundations and Trends in Machine Learning*, 5(4):287–364, 2012.
- [138] Hugo Lavenant and Filippo Santambrogio. The flow map of the Fokker–Planck equation does not provide optimal transport. *Applied Mathematics Letters*, 133:108225, 2022.
- [139] Thibaut Le Gouic and Jean-Michel Loubes. Existence and consistency of Wasserstein barycenters. *Probability Theory and Related Fields*, 168:901–917, 2016.
- [140] Jan Lellmann, Dirk A Lorenz, Carola Schönlieb, and Tuomo Valkonen. Imaging with Kantorovich–Rubinstein discrepancy. *SIAM Journal on Imaging Sciences*, 7(4):2833–2859, 2014.
- [141] Bas Lemmens and Roger Nussbaum. *Nonlinear Perron-Frobenius Theory*, volume 189. Cambridge University Press, 2012.
- [142] Christian Léonard. From the Schrödinger problem to the Monge–Kantorovich problem. *Journal of Functional Analysis*, 262(4):1879–1920, 2012.
- [143] Christian Léonard. A survey of the Schrödinger problem and some of its connections with optimal transport. *Discrete Continuous Dynamical Systems Series A*, 34(4):1533–1574, 2014.
- [144] Christian Léonard. Revisiting Fortet’s proof of existence of a solution to the Schrödinger system. *arXiv preprint arXiv:1904.13211*, 2019.
- [145] Matthias Liero, Alexander Mielke, and Giuseppe Savaré. Optimal transport in competition with reaction: the Hellinger–Kantorovich distance and geodesic curves. *SIAM Journal on Mathematical Analysis*, 48(4):2869–2911, 2016.
- [146] Matthias Liero, Alexander Mielke, and Giuseppe Savaré. Optimal entropy-transport problems and a new hellinger–kantorovich distance between positive measures. *Inventiones Mathematicae*, 211(3):969–1117, 2018.
- [147] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matthew Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.
- [148] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *International Conference on Learning Representations*, 2023.
- [149] Stuart Lloyd. Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2):129–137, 1982.
- [150] Eliane Maria Loiola, Nair Maria Maia de Abreu, Paulo Oswaldo Boaventura-Netto, Peter Hahn, and Tania Querido. A survey for the quadratic assignment problem. *European Journal of Operational Research*, 176(2):657–690, 2007.

- [151] John Lott and Cédric Villani. Ricci curvature for metric-measure spaces via optimal transport. *Annals of Mathematics*, 169(3):903–991, 2009.
- [152] Vince Lyzinski, Donniell E Fishkind, Marcelo Fiori, Joshua T Vogelstein, Carey E Priebe, and Guillermo Sapiro. Graph matching: relax at your own risk. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(1):60–73, 2016.
- [153] Shaojun Ma, Haodong Sun, Xiaojing Ye, Hongyuan Zha, and Haomin Zhou. Learning cost functions for optimal transport. *arXiv preprint arXiv:2002.09650*, 2020.
- [154] Jan Maas. Gradient flows of the entropy for finite Markov chains. *Journal of Functional Analysis*, 261(8):2250–2292, 2011.
- [155] Jan Maas, Martin Rumpf, Carola Schönlieb, and Stefan Simon. A generalized model for optimal transport of images including dissipation and density modulation. *ESAIM: Mathematical Modelling and Numerical Analysis*, 49(6):1745–1769, 2015.
- [156] Jan Maas, Martin Rumpf, and Stefan Simon. Generalized optimal transport with singular sources. *arXiv preprint arXiv:1607.01186*, 2016.
- [157] Robert J McCann. A convexity principle for interacting gases. *Advances in Mathematics*, 128(1):153–179, 1997.
- [158] Song Mei, Andrea Montanari, and Phan-Minh Nguyen. A mean field view of the landscape of two-layer neural networks. *Proceedings of the National Academy of Sciences*, 115(33):E7665–E7671, 2018.
- [159] Facundo Mémoli. On the use of Gromov–Hausdorff distances for shape comparison. In *Symposium on Point Based Graphics*, pages 81–90. Eurographics Association, 2007.
- [160] Facundo Mémoli. Gromov–Wasserstein distances and the metric approach to object matching. *Foundations of Computational Mathematics*, 11(4):417–487, 2011.
- [161] Quentin Mérigot. A multiscale approach to optimal transport. *Computer Graphics Forum*, 30(5):1583–1592, 2011.
- [162] Quentin Mérigot. A comparison of two dual methods for discrete optimal transport. In *Geometric science of information*, pages 389–396. Springer, 2013.
- [163] Quentin Mérigot, Alex Delalande, and Frédéric Chazal. Quantitative stability of optimal transport maps and linearization of the 2-Wasserstein space. In *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics*, volume 108 of *Proceedings of Machine Learning Research*, pages 3186–3196. PMLR, 2020.
- [164] Quentin Mérigot and Boris Thibert. Optimal transport: discretization and algorithms. *arXiv preprint arXiv:2003.00855*, 2020.
- [165] Alexander Mielke. Geodesic convexity of the relative entropy in reversible Markov chains. *Calculus of Variations and Partial Differential Equations*, 48(1-2):1–31, 2013.
- [166] Peyman Mohajerin Esfahani and Daniel Kuhn. Data-driven distributionally robust optimization using the wasserstein metric: Performance guarantees and tractable reformulations. *Mathematical Programming*, 171(1-2):115–166, 2018.
- [167] Gaspard Monge. Mémoire sur la théorie des déblais et des remblais. *Histoire de l’Académie Royale des Sciences*, pages 666–704, 1781.
- [168] Eduardo Fernandes Montesuma, Fred Ngolè Mboula, and Antoine Souloumiac. Recent advances in optimal transport for machine learning. *arXiv preprint arXiv:2306.16156*, 2023.
- [169] Krikamol Muandet, Kenji Fukumizu, Bharath Sriperumbudur, and Bernhard Schölkopf. Kernel mean embedding of distributions: a review and beyond. *Foundations and Trends in Machine Learning*, 10(1-2):1–141, 2017.

- [170] Kimia Nadjahi, Alain Durmus, Umut Simsekli, and Roland Badeau. Asymptotic guarantees for learning generative models with the sliced-Wasserstein distance. In *Advances in Neural Information Processing Systems*, 2019.
- [171] Arkadi Nemirovski and Uriel Rothblum. On complexity of matrix scaling. *Linear Algebra and its Applications*, 302:435–460, 1999.
- [172] Yurii Nesterov and Arkadii Nemirovskii. *Interior-point polynomial algorithms in convex programming*, volume 13. SIAM, 1994.
- [173] Lipeng Ning and Tryphon T Georgiou. Metrics for matrix-valued measures via test functions. In *53rd IEEE Conference on Decision and Control*, pages 2642–2647. IEEE, 2014.
- [174] Lipeng Ning, Tryphon T Georgiou, and Allen Tannenbaum. On matrix-valued Monge–Kantorovich optimal mass transport. *IEEE Transactions on Automatic Control*, 60(2):373–382, 2015.
- [175] James B. Orlin. A polynomial time primal network simplex algorithm for minimum cost flows. *Mathematical Programming*, 78(2):109–129, 1997.
- [176] Felix Otto. The geometry of dissipative evolution equations: the porous medium equation. *Communications in Partial Differential Equations*, 26(1–2):101–174, 2001.
- [177] Andrea Ottolini and Stefan Steinerberger. Greedy matching in optimal transport with concave cost. *arXiv preprint arXiv:2307.03140*, 2023.
- [178] Nicolas Papadakis, Gabriel Peyré, and Edouard Oudet. Optimal transport with proximal splitting. *SIAM Journal on Imaging Sciences*, 7(1):212–238, 2014.
- [179] Francois-Pierre Paty and Marco Cuturi. Subspace robust Wasserstein distances. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 5072–5081, 2019.
- [180] Gabriel Peyré. Entropic approximation of Wasserstein gradient flows. *SIAM Journal on Imaging Sciences*, 8(4):2323–2351, 2015.
- [181] Gabriel Peyré. Optimal and diffusion transports in machine learning. *arXiv preprint arXiv:2512.06797*, 2025. Proc. 2026 International Congress of Mathematicians.
- [182] Gabriel Peyré. Muon dynamics as a spectral Wasserstein flow. *arXiv preprint arXiv:2604.04891*, 2026.
- [183] Gabriel Peyré. Robust sublinear convergence rates for iterative Bregman projections. *arXiv preprint arXiv:2602.01372*, 2026.
- [184] Gabriel Peyré, Lenaïc Chizat, Francois-Xavier Vialard, and Justin Solomon. Quantum entropic regularization of matrix-valued optimal transport. *European Journal of Applied Mathematics*, 30(6):1079–1102, 2019.
- [185] Gabriel Peyré and Marco Cuturi. Computational optimal transport with applications to data sciences. *Foundations and Trends in Machine Learning*, 11(5-6):355–607, 2019.
- [186] Gabriel Peyré, Marco Cuturi, and Justin Solomon. Gromov-Wasserstein averaging of kernel and distance matrices. In *International Conference on Machine Learning*, pages 2664–2672, 2016.
- [187] Gabriel Peyré, Clarice Poon, and Oscar Tron. Curvature of optimal transport with respect to the cost and applications to inverse optimal transport. *arXiv preprint arXiv:2604.22670*, 2026.
- [188] Francois Pitié, Anil C. Kokaram, and Rozenn Dahyot. N-dimensional probability density function transfer and its application to color transfer. In *IEEE International Conference on Computer Vision*, pages 1434–1439, 2005.
- [189] Julien Rabin, Gabriel Peyré, Julie Delon, and Marc Bernot. Wasserstein barycenter and its application to texture mixing. In *International Conference on Scale Space and Variational Methods in Computer Vision*, pages 435–446. Springer, 2011.

- [190] Svetlozar T Rachev and Ludger Rüschendorf. *Mass Transportation Problems: Volume I: Theory*. Springer, 1998.
- [191] Svetlozar T Rachev and Ludger Rüschendorf. *Mass Transportation Problems: Volume II: Applications*. Springer, 1998.
- [192] Aaditya Ramdas, Nicolás García Trillos, and Marco Cuturi. On Wasserstein two-sample testing and related families of nonparametric tests. *Entropy*, 19(2):47, 2017.
- [193] Erik Reinhard, Michael Adhikhmin, Bruce Gooch, and Peter Shirley. Color transfer between images. *IEEE Computer Graphics and Applications*, 21(5):34–41, 2001.
- [194] Emmanuel Rio. Asymptotic constants for minimal distance in the central limit theorem. *Electronic Communications in Probability*, 16:96–103, 2011.
- [195] Ralph Tyrell Rockafellar. *Convex Analysis*. Princeton university press, 2015.
- [196] Murray Rosenblatt. Remarks on a multivariate transformation. *The Annals of Mathematical Statistics*, 23(3):470–472, 1952.
- [197] Walter Rudin. *Real and Complex Analysis*. McGraw–Hill, third edition, 1987.
- [198] Ludger Rüschendorf. Convergence of the iterative proportional fitting procedure. *Annals of Statistics*, 23(4):1160–1174, 1995.
- [199] Ludger Rüschendorf and Wolfgang Thomsen. Closedness of sum spaces and the generalized Schrödinger problem. *Theory of Probability and Its Applications*, 42(3):483–494, 1998.
- [200] Hans Samelson. On the perron-frobenius theorem. *Michigan Mathematical Journal*, 4(1):57–59, 1957.
- [201] Michael E. Sander, Pierre Ablin, Mathieu Blondel, and Gabriel Peyré. Sinkformers: Transformers with doubly stochastic attention. In *Proceedings of the 25th International Conference on Artificial Intelligence and Statistics*, volume 151 of *Proceedings of Machine Learning Research*, pages 3515–3530. PMLR, 2022.
- [202] Filippo Santambrogio. *Optimal Transport for Applied Mathematicians: Calculus of Variations, PDEs, and Modeling*. Birkhäuser, 2015.
- [203] Bernhard Schmitzer and Christoph Schnörr. Modelling convex shape priors and matching based on the Gromov-Wasserstein distance. *Journal of Mathematical Imaging and Vision*, 46(1):143–159, 2013.
- [204] Isaac J Schoenberg. Metric spaces and positive definite functions. *Transactions of the American Mathematical Society*, 44(3):522–536, 1938.
- [205] Bernhard Schölkopf and Alexander J Smola. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.
- [206] Erwin Schrödinger. Über die Umkehrung der Naturgesetze. *Sitzungsberichte Preuss. Akad. Wiss. Berlin. Phys. Math.*, 144:144–153, 1931.
- [207] Soroosh Shafieezadeh Abadeh, Peyman Mohajerin Esfahani, and Daniel Kuhn. Distributionally robust logistic regression. In C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, and R. Garnett, editors, *Advances in Neural Information Processing Systems 28*, pages 1576–1584, 2015.
- [208] Aman Sinha, Hongseok Namkoong, and John Duchi. Certifying some distributional robustness with principled adversarial training. In *International Conference on Learning Representations*, 2018.
- [209] Richard Sinkhorn. A relationship between arbitrary positive matrices and doubly stochastic matrices. *The Annals of Mathematical Statistics*, 35(2):876–879, 1964.
- [210] Richard Sinkhorn. Diagonal equivalence to matrices with prescribed row and column sums. *American Mathematical Monthly*, 74:402–405, 1967.

- [211] Richard Sinkhorn and Paul Knopp. Concerning nonnegative matrices and doubly stochastic matrices. *Pacific Journal of Mathematics*, 21(2):343–348, 1967.
- [212] Jascha Sohl-Dickstein, Eric A. Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 2256–2265. PMLR, 2015.
- [213] Justin Solomon, Fernando De Goes, Gabriel Peyré, Marco Cuturi, Adrian Butscher, Andy Nguyen, Tao Du, and Leonidas Guibas. Convolutional Wasserstein distances: efficient optimal transportation on geometric domains. *ACM Transactions on Graphics*, 34(4):66:1–66:11, 2015.
- [214] Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [215] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021.
- [216] Bharath K Sriperumbudur, Kenji Fukumizu, Arthur Gretton, Bernhard Schölkopf, and Gert RG Lanckriet. On integral probability metrics, φ -divergences and binary classification. *arXiv preprint arXiv:0901.2698*, 2009.
- [217] Bharath K Sriperumbudur, Kenji Fukumizu, Arthur Gretton, Bernhard Schölkopf, and Gert RG Lanckriet. On the empirical estimation of integral probability metrics. *Electronic Journal of Statistics*, 6:1550–1599, 2012.
- [218] Bharath K Sriperumbudur, Arthur Gretton, Kenji Fukumizu, Gert Lanckriet, and Bernhard Schölkopf. Injective Hilbert space embeddings of probability measures. In *Proceedings of the 21st Annual Conference on Learning Theory*, pages 111–122. Citeseer, 2008.
- [219] Karl-Theodor Sturm. On the geometry of metric measure spaces. I. *Acta Mathematica*, 196(1):65–131, 2006.
- [220] Karl-Theodor Sturm. On the geometry of metric measure spaces. II. *Acta Mathematica*, 196(1):133–177, 2006.
- [221] Karl-Theodor Sturm. The space of spaces: curvature bounds and gradient flows on the space of metric measure spaces. Preprint 1208.0434, arXiv, 2012.
- [222] Gábor J Székely and Maria L Rizzo. Testing for equal distributions in high dimension. *InterStat*, 5(16.10), 2004.
- [223] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [224] Titouan Vayer, Nicolas Courty, Romain Tavenard, Laetitia Chapel, and Rémi Flamary. Optimal transport for structured data with application on graphs. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 6275–6284. PMLR, 2019.
- [225] Cédric Villani. *Topics in Optimal Transportation*, volume 58 of *Graduate Studies in Mathematics Series*. American Mathematical Society, 2003.
- [226] Cédric Villani. *Optimal Transport: Old and New*, volume 338. Springer, 2009.
- [227] Pascal Vincent. A connection between score matching and denoising autoencoders. *Neural Computation*, 23(7):1661–1674, 2011.
- [228] John von Neumann. A certain zero-sum two-person game equivalent to the optimal assignment problem. In Harold W. Kuhn and Albert W. Tucker, editors, *Contributions to the Theory of Games II*, volume 28 of *Annals of Mathematics Studies*, pages 5–12. Princeton University Press, Princeton, NJ, 1953.

- [229] Max-K. von Renesse and Karl-Theodor Sturm. Transport inequalities, gradient estimates, entropy and Ricci curvature. *Communications on Pure and Applied Mathematics*, 58(7):923–940, 2005.
- [230] James Vuckovic, Aristide Baratin, and Rémi Tachet des Combes. A mathematical theory of attention. *arXiv preprint arXiv:2007.02876*, 2020.
- [231] Wei Wang, Dejan Slepčev, Saurav Basu, John A Ozolek, and Gustavo K Rohde. A linear optimal transportation framework for quantifying and visualizing variations in sets of images. *International Journal of Computer Vision*, 101(2):254–269, 2013.
- [232] Jonathan Weed and Francis Bach. Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance. *Bernoulli*, 25(4A):2620–2648, 2019.
- [233] Holger Wendland. *Scattered Data Approximation*. Cambridge University Press, 2005.
- [234] Huan Xu and Shie Mannor. Distributionally robust markov decision processes. *Mathematics of Operations Research*, 37(2):288–300, 2012.
- [235] Insoon Yang. A convex optimization approach to distributionally robust markov decision processes with Wasserstein distance. *IEEE Control Systems Letters*, 1(1):164–169, 2017.
- [236] G Udny Yule. On the methods of measuring association between two attributes. *Journal of the Royal Statistical Society*, 75(6):579–652, 1912.

记号表

本附录汇集全书使用的主要记号。最后一列指向该记号被定义或首次以数学上有意义的方式使用的章节、方程、定义、命题或定理。

记号	含义	首次引用
环境空间、测度与基本对象		
$\mathbb{R}^d$	欧几里得环境空间。	第 2.1 节
$\mathcal{X}, \mathcal{Y}$	源空间与目标空间。	式 (2.5)
$\mathcal{M}(\mathcal{X})$	$\mathcal{X}$ 上的有限有符号 Radon 测度。	第 2.1 节
$\mathcal{M}_+(\mathcal{X}), \mathcal{M}_+^1(\mathcal{X})$	正有限测度和概率测度。	第 2.1 节
$\mathcal{P}(\mathcal{X}), \mathcal{P}_p(\mathcal{X})$	概率测度, 其中 $\mathcal{P}_p$ 具有有限 p 阶矩。	第 3.3 节
Σ_n	长度为 n 的直方图的概率单纯形。	定义 2.1
δ_x	x 处的 Dirac 质量。	定义 2.2
α, β, γ	源、目标和辅助概率测度。	式 (2.5)
ρ_α	α 关于参考测度的密度。	定义 2.5
$d\alpha, dx$	关于 α 以及关于 Lebesgue 测度的积分。	第 2.1 节
$\mathbb{E}$	随机变量的期望。	第 2.1 节
$\text{supp}(\pi)$	测度的拓扑支撑。	定义 2.4
$\text{Supp}(b)$	直方图的指标支撑。	式 (6.8)
$\mathcal{C}(\mathcal{X})$	$\mathcal{X}$ 上的连续实值函数。	第 2.1 节
$\ \cdot\ $	欧几里得范数, 或由下标指明的范数。	第一章
$\langle \cdot, \cdot \rangle$	欧几里得/Frobenius 配对, 或测度-函数配对。	第 2.1 节
离散匹配与离散 Kantorovich 最优传输		
$(x_i)_i, (y_j)_j$	源点云和目标点云。	式 (1.1)
$C = (C_{i,j})$	源点与目标点之间的代价矩阵。	式 (1.1)
$\sigma \in \text{Perm}(n)$	编码一对一匹配的置换。	式 (1.1)
$P_\sigma, \mathcal{P}_n^{\text{perm}}$	置换矩阵以及所有这类矩阵的集合。	定义 3.7
$\mathcal{B}_n$	双随机矩阵的 Birkhoff 多面体。	定义 3.8
a, b	离散概率直方图。	式 (3.1)
P	离散传输/耦合矩阵。	式 (3.1)
$U(a, b)$	边缘为 a, b 的离散耦合多面体。	式 (3.1)
$\mathbb{1}_n, P^\top$	全一向量和 P 的转置。	式 (3.1)
$L_C(a, b)$	代价为 C 的离散 Kantorovich 最优值。	式 (3.2)
D	离散 Wasserstein 距离的底层距离矩阵。	定义 3.30
$W_p(a, b)$	离散 p -Wasserstein 距离。	定义 3.30
Monge 映射、一维最优传输与高斯		
T, T	传输映射。	式 (2.5)
$T_\# \alpha$	T 对 α 的推前。	定义 2.8
$T^\sharp g$	测试函数的拉回, $T^\sharp g = g \circ T$ 。	备注 2.9
Id	恒等映射。	定义 2.8
$\tilde{W}_p$	有向 Monge 传输距离。	式 (2.6)
$\nabla \varphi$	二次代价下的 Brenier 映射。	定理 2.18
$\mathcal{C}_\alpha$	一维测度的累积分布函数。	式 (2.8)
$\mathcal{C}_\alpha^{-1}$	一维测度的分位数函数。	式 (2.9)
$\mathcal{N}(\mathbf{m}, \Sigma)$	均值为 $\mathbf{m}$ 、协方差为 Σ 的高斯分布。	式 (2.14)
$\mathbf{m}_\alpha, \Sigma_\alpha$	高斯测度 α 的均值和协方差。	式 (2.18)
$\mathcal{B}(\Sigma_\alpha, \Sigma_\beta)$	Bures 协方差距离。	定义 2.38
$\text{tr}(\Sigma)$	矩阵的迹。	式 (2.18)

记号	含义	首次引用
连续 Kantorovich 最优传输与 Wasserstein 距离		
π	耦合或传输计划。	定义 3.17
$\mathcal{U}(\alpha, \beta)$	α 与 β 之间的耦合集合。	式 (3.4)
$\mathcal{L}_c(\alpha, \beta)$	底层代价为 c 的 Kantorovich 最优值。	式 (3.5)
d	底层度量空间上的底层距离。	式 (3.8)
$\mathcal{W}_p(\alpha, \beta)$	p -Wasserstein 距离。	定义 3.33
$\mathcal{W}_\infty(\alpha, \beta)$	最坏位移 Wasserstein 距离。	式 (3.13)
$\mathfrak{A}, \mathfrak{B}$	概率测度上的概率分布。	式 (3.9)
$\bar{\alpha}_{\mathfrak{A}}$	与测度上分布相关联的塌缩混合。	定义 3.47
$\mathbb{W}_2$	Wasserstein 空间上的 Wasserstein 距离。	式 (3.11)
Γ	$\mathcal{X} \times \mathcal{Y}$ 的 c -循环单调子集。	定义 3.27
ρ	胶合或复合耦合。	引理 3.32
$\rightharpoonup$	测度的弱 * 收敛。	定义 3.38
$\mathrm{TV}, \ \cdot\ _{\mathrm{TV}}$	总变差散度/范数。	第 2.1 节
对偶性、变换与弱范数		
f, g	离散对偶势。	式 (4.2)
f, g	连续对偶势。	式 (4.5)
$\mathcal{R}(\mathbf{a}, \mathbf{b})$	离散对偶势的可行集。	式 (4.1)
$\mathcal{R}(c)$	连续对偶势的可行集。	式 (4.6)
f^c, g^c	势函数的 c -变换。	定义 4.8
$\mathbb{L}_j(g)$	半离散最优传输中的 Laguerre/power 胞。	式 (5.4)
$\mathcal{Q}_m(\alpha)$	最优 m 点量化误差。	式 (5.9)
$\mathrm{Lip}(f)$	f 的 Lipschitz 常数。	式 (5.10)
$\mathcal{W}_1$	Kantorovich–Rubinstein 距离/范数。	式 (5.11)
$\mathcal{W}_{1,G}$	图 Wasserstein-1/转运距离。	命题 5.8
$d_G, \nabla_G, \mathrm{div}_G$	图测地距离、梯度与散度。	命题 5.8
$\ \cdot\ _B$	由判别器类 B 诱导的对偶范数。	式 (6.1)
$\mathcal{H}, k$	再生核 Hilbert 空间及其核。	定义 6.9
MMD_k	k 的最大均值差异/核范数。	定义 6.9
$\mathcal{D}_\varphi, \mathrm{D}_\varphi$	连续和离散 φ -散度。	式 (6.6)
φ'_∞	熵函数的衰退斜率。	定义 6.13
φ^*	φ 的 Legendre 变换。	式 (6.13)
KL, KL	连续和离散 Kullback–Leibler 散度。	定义 7.5、7.9
$\mathfrak{h}$	Hellinger 散度/距离。	第 6.3 节
JS	Jensen–Shannon 散度。	第 6.3 节
熵正则化与 Sinkhorn 算法		
ε	熵正则化强度。	式 (7.1)
$\mathrm{H}(\mathbf{P})$	矩阵的 Shannon–Boltzmann 熵。	定义 7.1
$\mathrm{L}_C^\varepsilon(\mathbf{a}, \mathbf{b})$	离散熵正则最优传输值。	式 (7.1)
$\mathcal{L}_c^\varepsilon(\alpha, \beta)$	连续熵正则最优传输值。	式 (7.11)
$\mathbf{K}$	Gibbs 核 $e^{-C/\varepsilon}$ 。	式 (7.2)
$\mathbf{u}, \mathbf{v}$	左、右 Sinkhorn 缩放。	式 (7.2)
$\mathrm{diag}(\mathbf{u})\mathbf{K}\mathrm{diag}(\mathbf{v})$	熵正则耦合的缩放形式。	式 (8.1)
$\odot$	向量的逐项乘积。	式 (7.4)
$\mathbf{u}^{(\ell)}, \mathbf{u}^{(\ell+1)}$	当前与下一步 Sinkhorn 迭代。	式 (7.5)
$d_{\mathcal{H}}$	正向量上的 Hilbert 射影度量。	定义 8.13
$\mathrm{Proj}^{\mathrm{KL}}$	KL/Bregman 投影。	式 (8.1)
$\tilde{\mathcal{L}}_c^\varepsilon(\alpha, \beta)$	去偏 Sinkhorn 散度。	式 (7.31)
最优传输的扩展		
ψ_1, ψ_2	惩罚边缘不匹配的熵函数。	式 (9.1)
$\mathrm{UW}_c, \mathrm{UW}_{c,\tau}$	带边缘惩罚的松弛非平衡最优传输值。	式 (9.1)
L_c	反向表述的局部非平衡代价。	式 (9.2)
H_c	局部代价 L_c 的齐次透视。	式 (9.3)

记号	含义	首次引用
HW	齐次非平衡表述。	式 (9.4)
$\mathfrak{C}[\mathcal{X}]$	度量空间 $\mathcal{X}$ 上的锥。	第 9.1 节
$\text{CW}, \text{CW}_\kappa$	非平衡最优传输的锥表述, 其中 CW_κ 使用增长尺度 κ 。	定理 9.4, 式 (12.11)
$\mathcal{A}_\kappa$	用于传输和增长的动态非平衡透视作用量。	式 (12.11)
WFR_κ	带增长尺度 κ 的 Wasserstein–Fisher–Rao 动态距离。	式 (12.11)
β_s, λ_s	重心问题中的输入测度和权重。	式 (10.2)
α^*	最优测度, 常常是重心。	第 10.1 节
SW_p	切片 Wasserstein 距离。	定义 9.5
$\mathbb{S}^{d-1}$	投影方向的单位球面。	定义 9.5
P_θ	沿方向 θ 的投影。	定义 9.5
MaxSW_p	最大切片 Wasserstein 距离。	定义 9.8
MSWGG_2	$\mathcal{W}_2$ 的最小切片提升计划上界。	第 9.2 节
$\text{SW}_{p,k}, \text{MaxSW}_{p,k}$	k 维投影上的平均和最大 Wasserstein 距离。	定义 9.9
$\mathcal{W}_\gamma$	与矩阵 gauge γ 关联的谱 Wasserstein 距离。	式 (9.7)
$\mathcal{B}_\gamma$	定义 $\mathcal{W}_\gamma$ 鲁棒投影形式的极集。	式 (9.9)
$\mathcal{W}_{2,A}$	经 $A^{1/2}$ 投影后的二次 Wasserstein 伪距离。	式 (9.8)
$\text{SRW}_{2,k}$	Paty–Cuturi 子空间鲁棒 Wasserstein 距离。	第 9.4 节
LOT_ρ	围绕参考 ρ 的线性最优传输距离。	式 (9.6)
$\bar{T}_\pi$	耦合 π 的 barycentric 投影。	式 (10.12)
$\bar{\beta}_\pi$	由 barycentric 投影推前 α 得到的测度。	式 (10.12)
WOT_C	条件分布代价为 C 的弱最优传输值。	式 (10.13)
g^C	弱最优传输对偶性中的弱 C -变换。	命题 10.14
u_t, V_t	正向量值密度与空间通量。	式 (11.1)、(11.2)
$\mathcal{W}_\Phi$	动态向量值 BB 型代价。	式 (11.1)
D, D'	离散 GW 中的域内距离矩阵。	式 (11.5)
Δ	域内距离之间的差异。	式 (11.5)
GW	离散 Gromov–Wasserstein 代价。	式 (11.5)
$\mathbb{X}, \mathbb{Y}$	度量测度空间。	定义 11.6
$\mathcal{GW}$	连续 Gromov–Wasserstein 距离。	式 (11.6)
d_H, d_{GH}	Hausdorff 与 Gromov–Hausdorff 距离。	第 11.2 节
$\text{FGW}_{\lambda,p}$	融合 Gromov–Wasserstein 距离。	第 11.2 节
$\mathbb{S}^m, \mathbb{S}_+^m$	实对称矩阵及其正半定锥。	定义 11.4
A_t, P_t	正矩阵值密度与空间矩阵通量。	式 (11.3)、(11.4)
$\mathcal{W}_{\text{mat}}$	保守矩阵值 BB 型代价。	式 (11.3)
$\mathbb{H}_n, \mathbb{H}_n^+, \mathbb{H}_n^{+,1}$	Hermitian 矩阵、正半定 Hermitian 矩阵和密度矩阵。	定义 11.12
Tr_A, Tr_B	二部矩阵的偏迹。	式 (11.9)
$\text{QOT}_C(A, B)$	代价可观测量为 C 的有限维量子最优传输值。	式 (11.10)
$\text{QOT}_C^\varepsilon(A, B)$	熵正则化量子最优传输值。	式 (11.12)
$T_e(F, G), T_s(F, G)$	精确 Gibbs 耦合和对称 Gurvits 缩放替代量。	式 (11.14)、(11.15)
动态最优传输与 Wasserstein 梯度流		
α_t	随时间变化的概率测度曲线。	式 (12.2)
v_t	传输 α_t 的 Euler 速度场。	式 (12.2)
T_t	Lagrange 粒子流映射。	式 (12.1)
P_t	流匹配中的插值映射; 后文也表示路径求值。	式 (14.1)
经作用量表示的 $\mathcal{W}_2^2$	Benamou–Brenier 动态表述。	式 (12.8)
$\nabla_{\mathcal{W}} f(\alpha)$	泛函的 Wasserstein 梯度。	命题 13.2
$\delta f(\alpha)$	f 在 α 处的第一变分。	命题 13.2
$\partial_t \alpha + \text{div}(\alpha v) = 0$	连续性方程。	式 (12.2)
$\alpha_{t+\tau}$	一个 JKO/最小化运动步。	式 (13.1)
$\mathcal{S} = C([0, 1]; \mathbb{R}^d)$	叠加表述中的路径空间。	第十二章

索引

- absolute continuity, 14, 15, 32, 64, 75, 77
- absolutely continuous path, 133, 134
- additively homogeneous map, 90
- admissible
 - potential, 45
- ADMM, 134
- adversarial
 - loss, i, 66
 - perturbation, 43
- affine
 - closure, 158–161
 - constraint, 88, 118
 - gradient, 158, 159
 - marginal constraint, 87, 88
- affine map, 22, 23, 48, 93, 153
- Alexandrov solution, 17
- alternate optimization, 50
- alternating
 - projection, 70, 87, 88, 90
 - tree, 6, 8
- alternating optimization, 50
- assignment problem, 1, 2, 4–6, 24, 27, 29, 46, 123, 149, 150
- attention, 157, 161
 - mechanism, 157
 - operator, 157
 - self-attention, 156, 157
 - single-head, 157
- auction algorithm, 6, 46, 47

- Baker-Campbell-Hausdorff formula, 129
- balance equation, 135
- Banach dual, 10
- Banach space, 10
- barrier
 - entropy, 69
 - logarithmic, 30, 69, 72
 - LP, 69
 - parameter, 30
- barycenter mean, 109
- barycentric
 - mixture, 41, 42
 - projection, 25, 117–119
 - transport, 119
- Beckmann
 - flow, 57, 59
 - formulation, 52, 57, 58
- Benamou-Brenier, 76, 77, 120–122, 131, 133–135
 - distance, 135
 - formulation, 76, 133, 134
- Berry-Esseen
 - bound, 44
 - theorem, 44
- Bessel function, 62
- bilinear
 - cost, 115
- Birkhoff contraction theorem, 92, 94
- Birkhoff polytope, 27
- Birkhoff-von Neumann theorem, 27–29, 32
- bistochastic matrix, 27, 29
- Boltzmann entropy, 68
- Borel measure, 9, 10, 15
- Borel set, 9–11, 16
- Bregman
 - divergence, 63, 65, 73, 82, 83, 87
 - iteration, 127
 - penalty, 87
 - projection, 69, 83, 87–91, 128
 - regularization, 82, 83
 - three-point formula, 88
- Brenier
 - factor, 15, 16
 - map, 16, 19, 21, 32, 45, 50, 78, 96, 105, 106, 109, 142, 144, 153, 160, 163
 - source hypothesis, 15
 - theorem, 14–18, 21–23, 32, 34, 50, 53, 105
- bridge
 - Brownian, 75, 77, 78
 - OU, 152, 154
 - overshooting, 154
 - variance-preserving, 152–154
- Bures
 - covariance, 22
 - metric, 21–23
 - smoothed term, 95, 96
- Bures-Wasserstein geometry, 21, 23, 42, 95, 96, 110, 111, 158, 160
- Burg entropy, 65

- c-concavity, 81
- c-cyclical monotonicity, 33
- c-transform, 45, 47–52, 56, 74, 79, 80
- Caffarelli regularity, 17
- Catalan number, 5, 6
- causality, 157
- cell mass, 52
- central
 - limit theorem, 39, 44
 - path, 30
- centroidal Voronoi, 55
- change-of-variables, 17, 18, 23, 110, 144
- change-of-variables formula, 17, 144

- characteristic kernel, 140
- Choi matrix, 129
- circle
 - transport, 3, 4
 - unfolded interval, 4
- collapsed mixture, 41, 42
- column normalization, 70
- commutator, 129
- compact space, 32
- compact sublevel set, 99
- complete metric space, 10
- conditional
 - expectation, 148–152
 - quantile, 105
- conditional law, i, 20, 21, 75, 77, 117–119, 134
- conditional probability, 10, 16, 36, 41, 148
- cone
 - formulation, 101
 - lifting, 101, 135
 - metric, 101
- congruence normalization, 129
- conic lifting, 101
- constant-speed geodesic, 16, 37, 124, 142
- continuity equation, 77, 120–122, 131–135, 137, 138, 148–150, 155, 156, 158
- continuous
 - bounded function, 39
 - coupling, 30
 - depth, 157
 - dual, 80
 - Sinkhorn dual, 82
- continuous normalizing flow, 148
- contraction ratio, 94
- controlled transport, 157
- convergence
 - in law, 19, 39, 86
 - in probability, 39
 - law, 38
 - mode, 39
- convex
 - conjugate, 50, 82
 - function, 4, 15, 16, 18, 19, 21, 32, 38, 43, 45, 50, 65, 81, 82, 87, 140
 - potential, 14, 15, 17, 33, 34, 48, 52, 151
 - regularizer, 81, 117
- convex envelope, 50
- convexity
 - along geodesics, 146
 - classical, 146, 147
 - geodesic, 109, 137, 142–145, 163
- coordinate ascent, 90
- correspondence, 25, 120, 123, 125, 126
- cost
 - assignment, 4, 47
 - derivative, 114
 - feature, 126
 - quadratic, 3, 13, 15–17, 19, 21, 22, 42, 46, 48, 50, 52, 53, 55, 81, 94, 95, 99, 104, 106, 109, 117, 118, 133, 160
 - reduced, 6, 29, 58
 - transport, 43, 109
 - unbalanced, 100
- cost matrix, 1, 24, 26, 27, 34, 45, 70, 72, 91, 109, 125
- countable dense subset, 10, 41
- coupling measure, 36
- covariance
 - commuting, 153
 - diagonal, 23
 - matrix, 19, 23, 162
 - ODE, 160
 - subblock, 161
 - term, 22, 23
- Cramer-von Mises distance, 19
- created mass, 102
- cumulative
 - distribution function, 13, 18
 - function, 2, 18, 19
- curse of dimensionality, 54, 55, 96
- cyclic
 - Bregman projection, 89
 - monotonicity, 33, 34, 118
 - projection, 88
 - shift, 3, 4
- Dacorogna-Moser inversion, 132
- Danskin theorem, 114
- data processing inequality, 91
- Delaunay
 - graph, 58
- denoising diffusion probabilistic model, 148
- denoising score matching, 148
- dense linear system, 69
- density
 - formula, 12
 - matrix, 126, 127, 130
 - ratio, 10, 63, 65, 66, 81–83
 - relative, 10
- depth evolution, 156
- destroyed mass, 102
- diffusion model, 150, 153
- dimension dependence, 97
- Dirac mass, 9, 11, 13, 19, 21, 24, 34, 38, 109, 137, 139, 142, 148
- discrete
 - barycenter, 113
 - coupling, 24
 - measure, 9, 37, 39, 68
 - space, 40
 - target, 52
- discretization error, 111, 148
- discriminator class, 60, 66
- disintegration, 10, 20, 36, 49, 77, 101, 118, 119, 150
- displacement
 - convexity, 15, 16, 140, 143, 144, 146

- covariance, 106–108
- interpolation, 16, 17, 19, 20, 108
- distance residual, 125
- distortion, 42, 124–126
- doubly stochastic normalization, 157
- Douglas-Rachford
 - splitting, 133, 134
- drifting
 - field, 155, 158, 160
 - model, 155, 156
- dual
 - attainment, 48, 50, 127
 - certificate, i, 47, 51
 - formula, 65, 66
 - gap, 71, 87, 91, 92, 116, 117
 - norm, 42, 60–62, 66, 163
 - objective gap, 90
 - pairing, 10
 - potential, i, ii, 45, 46, 48–50, 52, 71, 74, 80, 81, 83–86, 91, 94, 96, 98, 116, 127, 160
 - price, 46
 - problem, 45, 49, 52, 57, 58, 68, 79, 80, 112
 - radius, 91
 - rate, 91
 - weight, 52, 53
- duality
 - Fenchel-Rockafellar, 81, 100, 118
 - strong, 58, 112, 127
 - weak, 7, 48, 118
- Dudley entropy, 98
- Dudley metric, 60
- dyadic cube, 97
- dynamic
 - formulation, 133, 135
 - optimal transport, 131
 - unbalanced OT, 135
- dynamic action, 133
- dynamic value, 133
- dynamical optimal plan, 38, 145
- elliptic regularity, 106
- empirical
 - distribution, 141, 156
 - law, 42, 43, 141
 - measure, ii, 3, 9, 13, 26, 29, 39, 85, 97, 104, 115, 131, 141, 157, 163
 - Monge map, 13
 - OT, 55, 97
 - OT rate, 97
 - process, 98
- empirical context, 157
- endpoint coupling, 75–78
- energy
 - decay, 143
 - dissipation, 144
 - distance, 62, 85, 140, 141
 - interaction, 84, 140, 142, 144, 159
- entropic
 - barycenter, 110, 112
 - bias, 71, 84
 - OT, 47, 68, 69, 79, 84, 90, 94, 95, 117, 125, 127, 155
 - path, 69
 - potential, 81, 84, 89, 90
 - regularization, ii, 50, 51, 68, 69, 84, 87, 92, 96, 101, 113, 115, 125, 127, 163
 - smoothing, 68, 90, 98, 111
- entropy
 - function, 63, 64, 81, 99
 - relative, 64, 68, 72, 73, 75, 77, 91, 95, 142, 144, 145, 159
- envelope theorem, 68, 98, 114
- equality constraint, 29, 58
- Eulerian
 - description, 131
 - velocity, 131, 133
- exact OT, 17, 96–98
- extreme minimizer, 28
- extreme point, 26, 28, 29
- feasible coupling, 29, 32, 106, 124
- feature term, 126
- Fenchel duality, 81, 82, 100, 118
- Fenchel-Rockafellar duality, 134
- Fenchel-Young loss, 114, 115
- finite measure, 10, 60, 99, 120
- first variation, 82, 128, 137, 138, 143, 145–147, 155–157, 159–161
- Fisher information, 77, 160
- fixed point
 - iteration, 111
- flow
 - conservation, 29
 - cross-moment, 161
 - map, 131, 152, 153
 - matching, 132, 148–153, 161, 163
 - minimum-cost, 29, 58
 - probability ODE, 148, 151, 154
 - rectified, 148, 151
- flux, 120, 122, 132, 138
- Fokker-Planck equation, 141, 143, 144, 153, 160
- Fourier multiplier, 62
- Frechet mean, 109
- GAN, 66
- Gaussian
 - barycenter, 110, 111, 113, 162
 - closure, 158, 159, 161
 - contractive projection, 162
 - covariance, 96, 160
 - energy, 159
 - flow matching, 152, 153
 - kernel drifting, 156, 161
 - manifold, 158, 160
 - marginals, 81, 94
 - measure, 21, 22, 110, 113, 158, 159, 161, 162

- optimal map, 19
 - preservation, 158, 159, 161, 162
 - preserving flow, 161
 - projection, 160, 162
 - push-forward, 22
 - Sinkhorn, 94–96, 160
 - Sinkhorn divergence, 95, 160
 - submanifold, 158
- Gaussian denoiser, 150
- Gaussian mixture, 3, 41, 42, 53, 71, 72, 74, 82, 102, 110, 151, 152, 154
- Gelbrich theorem, 162
- generalized
 - inverse, 13, 18
 - Wasserstein, 99
- generalized quantile, 20
- generative model, i, 60, 104, 131, 148, 154, 163
- geodesic
 - space, 38, 145
- Gibbs
 - coupling, 128, 129
 - formula, 128
 - kernel, 71, 72, 88, 89, 94
 - reference, 87, 88
- global
 - minimizer, 146, 147
 - optimality, 147
- gluing lemma, 34–36, 101, 124
- gradient
 - field, 15
 - flow, i, ii, 16, 123, 124, 131, 132, 137–146, 148, 155, 157–159, 161–163
 - projection, 156
 - structure, 121, 132, 157
 - velocity, 132, 158
- graph
 - augmenting path, 8
 - bipartite, 26, 29
 - equality, 6–8
 - geodesic distance, 57
 - support, 26
 - transport, 58
- greedy sweep, 26
- Gromov-Hausdorff distance, 123, 126
- Gromov-Wasserstein, 42, 120, 123, 124, 126
 - distance, 42
 - fused, 126
 - geodesic, 124
 - metric, 124
- ground cost, 34, 42, 56, 112, 114, 123, 125
- Gurvits scaling, 129
- Hausdorff distance, 123, 126
- Hausdorff measure, 15
- heat equation, 139, 140
- Hellinger
 - divergence, 65
 - geometry, 23
- Hellinger-Kantorovich, 135
- Hermitian matrix, 127, 128
- Hilbert
 - embedding, 104
 - metric, 92
 - projective metric, 92
- Hilbertian
 - embedding, 106
 - limit, 85
- histogram, 2, 9, 19, 20, 34, 36, 68, 91, 99, 109, 120, 123
- homogeneous formulation, 100
- homogeneous Sobolev norm, 85
- homogenization, 100
- Hungarian primal-dual method, 1, 6, 7, 46
- hypersurface, 15
- implicit Euler scheme, 137
- infinite-depth limit, 157
- integer multiplicity, 6
- integral probability metric, 58, 60, 61, 65, 66, 148, 150, 154
- interior-point method, 30, 69, 72
- interpolation map, 109
- inverse OT, 114–117
 - gap loss, 115
- inverse square root, 129
- isometric embedding, 126
- Jacobian determinant, 143
- Jensen inequality, 38, 64, 73, 97, 119, 133, 144
- Jensen-Shannon divergence, 65, 66
- JKO scheme, 137, 138, 158, 162
- joint
 - law, 30, 32, 113
 - measure, 30
- Jordan decomposition, 11
- Kantorovich
 - duality, ii, 6, 15, 45, 47, 48, 50, 117, 118, 127
 - interpolation, 16
 - potential, 48
 - problem, 4, 25, 29, 32, 33, 38, 45, 74, 76, 77, 118, 122
 - relaxation, 1, 4, 12, 15, 24, 25, 29, 30, 32, 99
- Kantorovich-Rubinstein
 - duality, 44, 61, 66
 - formula, 56–58
- kernel
 - conditionally positive, 61, 62
 - drifting, 156
 - energy, 62
 - Gaussian, 62, 72, 155, 161
 - Laplacian, 62
 - Matern, 62
 - mean embedding, 62, 106
 - norm, 42, 62, 66, 85, 155
 - positive, 61, 62, 84, 92, 155

- positive definite, 85, 97, 104, 140
- Riesz, 62
- translation-invariant, 62, 63
- universal, 62, 63
- kernel quadrature, 140, 141
- kernelized self-interaction, 140
- kinetic action, 76
- KL
 - projection, 58, 87–91, 111, 129
 - relaxation, 101
- Knothe-Rosenblatt rearrangement, 20, 21
- Kolmogorov-Smirnov distance, 19
- Kullback-Leibler divergence, 64, 72, 73, 75
- Lagrangian
 - description, 131
 - flow, 131
- Laguerre cell, 13, 52, 53, 55
- Langevin dynamics, 76
- large-temperature limit, 85
- latent variable, 148
- Lavènant criterion, 153, 162
- layer normalization, 157
- least-square
 - inversion, 132
 - velocity, 132
- Lebesgue decomposition, 63, 100
- Lebesgue measure, 10, 13, 15, 16, 32, 74
- Legendre transform, 50, 66, 112
- linear
 - convergence, 71, 89, 92, 93
 - functional, 139
 - linearization, 18, 125
 - OT, 105, 106
 - tilt, 87
- linear form, 10, 28, 147
- linear objective, 26, 29
- linear programming, i, 28, 29, 69, 109, 163
 - basic feasible solution, 26
 - finite-dimensional, 32, 56, 58
 - sparse, 58
- Lipschitz
 - constant, 56
 - function, 14, 52, 56, 58, 60, 61
 - stability, 50
- Lipschitz stability, 50
- Lloyd algorithm, 55
- local
 - distance distribution, 42
 - matching indicator, 2
- local profile, 42
- localization, 17
- log-domain Sinkhorn, 75
- log-sum-exp, 47, 74, 79–81, 84
- lower semicontinuity, 63, 64, 85, 99, 112, 118, 120, 135
- lower-dimensional set, 15
- Lyapunov equation, 158
- marginal
 - constraint, 24, 26, 30, 32, 58, 69, 70, 73, 75, 78, 81, 83, 87, 88, 90, 94, 101, 118, 127
 - divergence, 99, 102
 - penalty, 99, 100, 102
 - relaxation, 99, 102
 - residual, 75, 91
- Markov kernel, 20, 42
- masking, 157
- mass
 - balance, 2, 53
 - conservation, 24, 70, 99
 - creation, 99
 - free, 55
 - variation, 102
- matching
 - algorithm, 6
 - non-crossing, 5, 6
 - optimal, 1, 33
 - perfect, 5, 6
 - uniform, 4, 6, 27, 29, 32, 33
- matrix
 - cone, 121
 - incidence, 58
 - nonnegative transport, 4
 - permutation, 26–29, 123
 - polar decomposition, 16
 - scaling, 47, 68–70, 87
 - subproblem, 122
- matrix square root, 94
- matrix-valued measure, 120–122
- matrix-vector iteration, 69
- maximum mean discrepancy, 61–63, 66, 96, 97, 106, 140, 141, 154, 160
- McCann interpolation, 17, 20, 37, 38, 108, 109, 134, 142, 144
- McKean-Vlasov limit, 141
- mean-field
 - limit, 87, 145, 157
 - neural network, 137, 145
- measurable function, 10, 60
- measurable selection, 42, 49, 76
- measure
 - atomless, 13
 - evolution, 131, 132, 139
 - isomorphism, 13
- measure-preserving
 - isometry, 123, 124
 - map, 15, 16
- Memoli profile, 42, 125
- metric
 - equivalence, 107
 - learning, 43, 114, 115
- metric space, 9
- metric-measure space, 42, 120, 123–125, 145
- minimax, 106, 107
- minimizing movement, 137, 139, 162

- minimizing movement scheme, 137
- Minkowski inequality, 14, 36, 103, 123, 124
- modulo isometry, 124
- moment matching, 158, 162
- momentum, 120, 121, 133
- Monge
 - distance, 14, 16, 38
 - geodesic, 16, 143
 - interpolation, 16, 19
 - problem, i, 1, 9, 12–16, 18, 21, 24, 32, 37, 38, 109, 133, 142
- Monge-Ampere equation, 17, 18, 106
- Monge-Kantorovich equivalence, 32
- monotone
 - convergence, 89
 - field, 15
 - fixed point, 89
 - matching, 1, 3, 104
 - rearrangement, 2, 3, 18–21, 34
 - spectral gauge, 107
- multi-marginal, 109, 110, 113
 - cost, 113
 - formulation, 113
 - OT, 110, 113
- multi-valued subdifferential, 15
- Muon algorithm, 106, 108
- mutual information, 78
- neuron, ii, 145–147, 161
- neuron law, 145, 161
- Newton step, 30, 69
- node feature, 126
- noising schedule, 151
- non-atomic probability space, 16
- nonnegative measure, 82, 83, 99, 101
- norm
 - flat, 60
 - RKHS, 62
 - Wasserstein-1, 56
- normal approximation, 44
- normalizing flow, 148
- north-west corner
 - plan, 26, 27
 - rule, 26, 29
- one-dimensional
 - projection, 13, 99, 102, 103, 160
 - transport, 18–20, 27
- one-step
 - flow, 154
 - generative model, 154, 155
- operator bound, 107
- operator norm, 10
- operator scaling, 126, 129
- operator-valued coupling, 130
- optimal coupling, 4, 18, 19, 26, 29, 32, 33, 37, 45, 50, 55, 109, 112–114, 117, 124, 133, 142, 144
- optimal plan, 15, 25–27, 33, 34, 48, 50, 71, 81, 117, 124, 142
- optimality
 - certificate, 46, 47
 - complementary slackness, 6, 7, 45–47, 117
 - first-order, 53, 88, 128
- order-preserving map, 89, 90
- Ornstein-Uhlenbeck process, 152, 153, 159
- packing argument, 97
- pairwise distance, 123
- partial transport, 102
- particle
 - Wasserstein descent, 139
- particle ODE, 131, 142, 145
- path
 - measure, 133
 - space, 75–78
- path space, 38
- path-space
 - formulation, 68, 75–78, 134
 - problem, 76
 - transport, 75–77
- Pearson divergence, 65
- permutation
 - matrix, 27
- Perron-Frobenius theorem, 90, 92
- perspective function, 134
- perspective recession, 120
- perspective transform, 100
- phi-divergence, 60, 63–66, 73, 81–83
- phi-divergence regularized OT, 81–83
- Pinsker inequality, 91
- plan
 - interpolation, 37
 - lifted, 104, 105, 108
 - optimal, 37
 - sparse, 25, 26
 - transport, 5, 24, 33, 37, 38, 45, 104, 108, 114, 120
- polar factorization, 15, 16
- polar formula, 107
- polar set, 106–108
- Polish space, 10, 13, 36, 41, 43, 118
- porous medium equation, 140
- positive
 - cone, 120, 121, 128
 - matrix-valued measure, 121
 - semidefinite matrix, 21–23, 107, 120, 122, 128
 - vector-valued measure, 120
- positive operator, 120, 126
- power diagram, 52, 53
- probabilistic coupling, 11, 12, 148
- probability measure, i, 9–11, 13, 14, 19, 21, 30, 32, 34, 39, 41, 43, 48, 60–62, 65, 83, 103–105, 109, 113, 123, 125, 133, 140, 146, 163
- probability path, 148
- probability simplex, 9, 83

- probability-flow ODE, 148, 150–152, 154
- product
 - coupling, 24, 31, 32, 38, 84, 144, 151
 - measure, 71, 75, 83, 113
- profile lower bound, 42, 125
- projected formulation, 106
- projective
 - cone, 92
 - diameter, 93
 - geometry, 90
- Prokhorov theorem, 43
- propagation of chaos, 141
- proximal
 - splitting, 133
- pullback, 12
- push-forward, 9, 11–13, 18, 22–24, 131, 138, 148, 149
- Pythagorean identity, 87, 88, 91
- quadratic
 - assignment problem, 123
 - barycenter, 109, 113
 - closure, 94
 - potential, 15, 22, 23, 94, 158, 159
- quantile, 18
 - barycenter, 110
 - formula, 42
 - function, 2, 18–20, 104–106, 110
 - map, 18, 19, 121
 - push-forward, 18
- quantization
 - energy, 55
 - optimal, 54
 - rate, 54
- quantum
 - Bregman projection, 129
 - coupling, 126
 - Kantorovich duality, 127
 - optimal transport, 126
 - OT, 120, 126–128
 - OT duality, 128
 - Sinkhorn, 129
- Rademacher bound, 98
- Radon
 - measure, 10, 11, 33, 48
 - transform, 103
- Radon-Nikodym derivative, 150
- random probability measure, 41
- random variable, 11, 12, 32, 39, 44, 158
- rank constraint, 106
- rate
 - parametric, 97, 98
 - sublinear, 54, 90
- rational weights, 4, 6, 41
- recession convention, 99, 100, 120, 133
- rectifiable set, 15
- reference
 - distribution, 148
 - measure, 10, 16, 66, 72–74, 82, 83, 100, 105, 106, 111, 148
- reflow, 148
- regression loss, 148
- regular conditional distribution, 20
- regularity theory, 17
- reverse flow, 154
- reverse formulation, 100
- reverse KL divergence, 65, 140
- Ricci curvature, 145
- Riemann sum, 39
- Riemannian manifold, 145
- Riesz potential, 62
- Riesz-Markov-Kakutani theorem, 10, 11
- RKHS, 61–63, 66, 97, 106
- robust
 - envelope, 43
 - representation, 107
 - Wasserstein, 106, 108
 - Wasserstein distance, 106, 108
- robustness
 - distributional, 42
 - distributionally robust optimization, 42
 - Wasserstein infinity, 43
- rotational component, 19, 153
- row normalization, 70
- sample complexity, 55, 87, 96
- scaling
 - algorithm, 68, 113
 - column, 71, 87, 89
 - form, 69, 70, 79, 89, 112, 129
 - iterative proportional fitting, 69, 70
 - potential, 71
 - row, 71, 87, 89
 - vectors, 89, 92
- Schrodinger
 - bridge, 76–78
 - interpolation, 76
 - problem, 68, 75–77, 86
 - system, 89
- score function, 139, 150, 151, 154, 155
- score-based generative modeling, 148
- score-SDE, 148
- second boundary condition, 17
- second moment, 161
- self Sinkhorn, 86
- self-concordance, 69
- self-corrected field, 156
- semi-discrete
 - dual, 53
 - Monge map, 13
 - OT, 13, 32, 49, 52–54, 80, 106
- semi-dual, 52, 53, 111
- semi-relaxed
 - divergence, 156
 - problem, 49

- semidefinite program, 127
- separable space, 10
- Shannon
 - entropy, 63, 64, 68, 127, 140, 142, 144
 - negative entropy, 87, 88, 139
- shearing component, 19, 153
- signed
 - measure, 10, 19, 39, 56, 61, 62, 137, 138, 140
 - negative part, 58
 - positive part, 58
- simplex network, 29, 58, 59
- Sinkhorn
 - algorithm, 47, 50, 58, 68–71, 79, 93, 94
 - barycenter, 111, 136
 - convergence, 87, 89, 90, 92
 - coupling, 77
 - divergence, 68, 84–86, 95–98, 142, 154, 155, 160
 - dual, 78, 82, 91, 160
 - half-step, 72, 88, 91
 - iteration, 71, 84, 89, 94, 112, 114, 117, 125
 - scaling, i, 6, 47, 70, 71, 81, 83, 88, 89, 101, 129, 155, 163
 - update, 128
- Slater condition, 127, 128
- sliced Wasserstein
 - distance, 102–104, 106, 160
 - max, 104
 - min transport, 104, 105
- Sobolev norm, 85
- soft
 - c-transform, 78–80, 84, 90, 91, 94, 98
 - minimum, 47, 79, 80
 - transform, 68, 80, 81, 87, 89, 90, 94, 96, 101
- spanning tree, 29, 58
- spectral
 - gauge, 99, 106–108
 - Wasserstein, 106–108
 - Wasserstein distance, 107
- spectral dynamics, 108
- splitting obstruction, 13, 15, 17
- static-dynamic equivalence, 135
- stationarity, 50, 125, 128, 146, 147
- stationary condition, 146
- stationary density, 146
- Stein method, 44
- Stiefel manifold, 104
- stochastic
 - gradient, 54, 66, 150
 - interpolant, 148
 - optimization, 54
 - particle, 141
- Strang splitting, 129
- strict
 - convexity, 17, 68, 73, 74, 81, 88
 - positivity, 86, 90
- subdifferential, 15, 17, 32, 114
- subgradient inequality, 147
- subspace
 - projection, 104
 - robust Wasserstein, 108
 - sliced Wasserstein, 104
- superposition principle, 133
- support, 10, 11, 13, 15, 29, 32, 45, 48, 57
- synthetic Ricci curvature, 145
- teacher distribution, 140, 141
- teacher kernel mean, 140
- tensor product
 - coupling, 31
- tightness, 8, 9, 19, 32, 41, 103
- time-dependent vector field, 131, 148
- token limit, 157
- token measure, 148, 156, 157
- topical map, 90
- topology
 - strong, 40, 64, 65
 - weak, 32, 39, 40, 44, 48, 65
- total variation, 9, 10, 34, 39, 40, 60, 61, 64, 65, 102
- trace
 - gauge, 108
 - partial, 127, 130
 - partial constraint, 127
- trace entropy, 127, 128
- trace norm, 107, 129
- trace-class operator, 130
- transformer, 156–158, 160, 161, 163
- transport equation, 157
- transport map, 2, 13, 16, 20, 24, 45, 117, 150, 152, 153
- transportation
 - polytope, 24–27, 29, 30, 68, 69, 73, 88, 92, 123
 - simplex, 26, 29
- triangle inequality, 5, 14, 16, 23, 32, 35–37, 56, 92, 93, 97, 101, 103, 107, 123, 124
- triangular
 - map, 20
 - rearrangement, 20, 21
- trivial coupling, 148
- Tweedie identity, 150, 151, 153
- two-layer neural network, 146, 147, 161
- unbalanced
 - barycenter, 136
 - OT, 73, 99–102, 115, 135
 - OT dual, 100
- variation seminorm, 90, 91
- variational dual formula, 65
- vector quantile, 105
- vector-valued measure, 120, 121
- velocity field, 131, 132, 134, 138, 148, 157, 158, 161
- viscous Benamou-Brenier formulation, 76
- von Neumann entropy, 127
- Voronoi cell, 13, 53, 55

Wasserstein

- barycenter, 106, 109–111, 113, 162
- coordinate, 105
- distance, i, 19, 24, 34–42, 44, 65, 66, 99, 101–104, 106–109, 125, 133, 135, 144, 160, 162
- flow, 143
- formula, 19
- geodesic, 16, 37, 109, 124, 160
- gradient, 132, 137, 138, 140, 142–146, 148, 155–159, 162
- gradient flow, 16, 82, 132, 137, 138, 140–144, 146, 148, 155, 157, 158, 162
- infinity distance, 43
- over Wasserstein, 41, 42
- space, 41, 42, 139, 161

Wasserstein topology, 40, 41

Wasserstein-Fisher-Rao, 135

weak

- convergence, 9, 32, 38–42, 44, 60–63, 65, 103, 107
- cost, 118, 119
- Kantorovich duality, 118
- limit, 13, 21, 39
- map, 17
- optimal transport, 117
- transport, 118

weighted

- Poisson equation, 17, 132
- sweep, 27

zero mass, 21, 53, 62, 69

zero mean, 132