

用于高效可扩展数据同化的 Flow Matching

Taos Transue Bohan Chen So Takao Bao Wang

中文技术阅读版: arXiv:2508.13313

Abstract

数据同化 (data assimilation, DA) 要在动力系统不断演化、观测带噪且维度很高的情况下, 顺序估计系统当前状态。传统 Kalman/particle 类方法在非线性、高维或大集合场景中会遇到高成本、退化或近高斯假设问题; 扩散/score 类生成模型能增强非高斯表达, 但采样慢。本文提出 Ensemble Flow Filter (EnFF): 一种 training-free 的 Flow Matching (FM) 数据同化框架。它用 Monte Carlo 估计边际向量场, 用 guidance 把预测分布推向滤波后验, 并设计 filtering-to-predictive (F2P) flow 来利用 DA 的贝叶斯递推结构。核心收益是: 不训练网络, 采样更快, 能扩展到更大 ensemble, 并在 Lorenz-96、Kuramoto-Sivashinsky、2D Navier-Stokes 等基准上获得更好的成本-精度折中。

1 业务问题: 数据同化为什么难

数据同化的目标是从带噪观测中恢复动力系统状态。给定隐藏状态 $\{\mathbf{x}_j\}_{j=0}^J \subset \mathbb{R}^d$ 和观测 $\mathbf{y}_j \in \mathbb{R}^{d_y}$, 论文采用加性高斯模型

$$\mathbf{x}_j = \psi(\mathbf{x}_{j-1}) + \xi_{j-1}, \quad \xi_{j-1} \sim \mathcal{N}(0, \Sigma), \quad (1a)$$

$$\mathbf{y}_j = h(\mathbf{x}_j) + \eta_j, \quad \eta_j \sim \mathcal{N}(0, \Gamma). \quad (1b)$$

每一步都包含 prediction 和 analysis 两个贝叶斯递推:

$$p(\mathbf{x}_j | \mathbf{y}_{1:j-1}) = \int p(\mathbf{x}_j | \mathbf{x}_{j-1}) p(\mathbf{x}_{j-1} | \mathbf{y}_{1:j-1}) d\mathbf{x}_{j-1}, \quad (2)$$

$$p(\mathbf{x}_j | \mathbf{y}_{1:j}) = \frac{p(\mathbf{y}_j | \mathbf{x}_j) p(\mathbf{x}_j | \mathbf{y}_{1:j-1})}{\int p(\mathbf{y}_j | \mathbf{x}_j) p(\mathbf{x}_j | \mathbf{y}_{1:j-1}) d\mathbf{x}_j}. \quad (3)$$

难点在于: 真实天气、流体和混沌系统的状态维度很高, 观测和动力学常非线性; 精确贝叶斯递推不可行, 有限 ensemble 又容易产生虚假相关、方差低估或粒子退化。EnFF 的业务定位, 就是在不牺牲太多精度的前提下, 把“从预测分布到滤波分布”的采样变得更快、更稳定。

2 Flow Matching 的基本角色

Flow Matching 学习一个时间相关向量场 $\mathbf{u}_t : [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$, 其流 ϕ_t 将参考分布 ρ_0 推到目标分布 ρ_1 :

$$p_t = (\phi_t)_\# \rho_0, \quad p_0 = \rho_0, \quad p_1 = \rho_1. \quad (4)$$

FM 的关键是把难以直接学习的边际向量场写成条件向量场的后验平均。若用条件路径 $p_t(\mathbf{z} | \mathbf{z}_0, \mathbf{z}_1)$ 连接样本对 $(\mathbf{z}_0, \mathbf{z}_1)$, 则

$$\mathbf{u}_t(\mathbf{z}) = \iint \mathbf{u}_t(\mathbf{z} | \mathbf{z}_0, \mathbf{z}_1) \frac{p_t(\mathbf{z} | \mathbf{z}_0, \mathbf{z}_1) \rho(\mathbf{z}_0, \mathbf{z}_1)}{p_t(\mathbf{z})} d\mathbf{z}_0 d\mathbf{z}_1. \quad (5)$$

常规 FM 会训练神经网络 $\mathbf{v}_t(\mathbf{z}; \theta)$ 拟合 $\mathbf{u}_t$ 。EnFF 的关键转向是: 在 DA 中每个时间步都重新训练不可接受, 因此直接用 ensemble 样本对做 training-free 的 Monte Carlo 估计。

3 EnFF 的核心机制

3.1 Training-free 边际向量场估计

给定样本对 $\{(\mathbf{z}_0^{(n)}, \mathbf{z}_1^{(n)})\}_{n=1}^N$, EnFF 用

$$\mathbf{u}_t(\mathbf{z}) \approx \sum_{n=1}^N w_n(\mathbf{z}) \mathbf{u}_t(\mathbf{z} | \mathbf{z}_0^{(n)}, \mathbf{z}_1^{(n)}), \quad w_n(\mathbf{z}) = \frac{p_t(\mathbf{z} | \mathbf{z}_0^{(n)}, \mathbf{z}_1^{(n)})}{\sum_{m=1}^N p_t(\mathbf{z} | \mathbf{z}_0^{(m)}, \mathbf{z}_1^{(m)})}. \quad (6)$$

这一步把“训练一个 FM 网络”替换成“用当前 ensemble 直接计算局部加权平均”, 因此算法可以在每个 DA 时间步在线运行。




Figure 1: 原论文 Figure 1: OT flow 与 F2P flow 的轨迹对比。F2P 通过 DA 的参考-目标耦合产生更直的轨迹。

算法 1: Ensemble Flow Filter (EnFF) 中文化伪代码

输入: 粒子数 N ; 转移模型 $p(\mathbf{x}_j|\mathbf{x}_{j-1})$; 观测模型 $p(\mathbf{y}_j|\mathbf{x}_j)$; 观测序列 $\{\mathbf{y}_j\}_{j=1}^J$; 参考分布 ρ_0 ; 条件向量场 $\mathbf{u}_t(\mathbf{z}|\mathbf{z}_0, \mathbf{z}_1)$

初始化: 采样 $\{\mathbf{x}_0^{(n)}\}_{n=1}^N \sim p(\mathbf{x}_0)$

- 1 对 $j = 1, \dots, J$ 执行
 - 2 对每个粒子 $n = 1, \dots, N$ 执行
 - 3 采样参考点 $\mathbf{z}_0^{(n)} \sim \rho_0$
 - 4 经动力学预测 $\mathbf{z}_1^{(n)} = \hat{\mathbf{x}}_j^{(n)} \sim p(\mathbf{x}_j|\mathbf{x}_{j-1})$
 - 5 用 (6) 估计边界向量场 $\mathbf{u}_t(\mathbf{z})$
 - 6 估计 guidance $\mathbf{g}_t(\mathbf{z}; \mathbf{y}_j)$, 通常用 localized guidance
 - 7 令 guided field 为 $\mathbf{u}'_t(\mathbf{z}; \mathbf{y}_j) = \mathbf{u}_t(\mathbf{z}) + \mathbf{g}_t(\mathbf{z}; \mathbf{y}_j)$
 - 8 对每个 n , 从 $\mathbf{z}_0^{(n)}$ 沿 $\mathbf{u}'_t$ 积分到 $t = 1$, 得到 $\mathbf{x}_j^{(n)} = \phi'_1(\mathbf{z}_0^{(n)}; \mathbf{y}_j)$

输出: 每个时刻的滤波粒子集合 $\{\mathbf{x}_j^{(n)}\}_{n=1}^N$

3.2 F2P flow: 利用 DA 的时间结构

普通 conditional OT flow 常从高斯参考分布流向目标分布。论文指出, DA 本身有天然的时序耦合: 上一时刻滤波分布经过动力学转移得到当前预测分布。F2P (filtering-to-predictive) 直接把上一时刻滤波分布作为参考, 把当前预测分布作为目标:

$$p_t(\mathbf{z}_t|\mathbf{z}_0, \mathbf{z}_1) = \mathcal{N}(\mathbf{z}_t | t\mathbf{z}_1 + (1-t)\mathbf{z}_0, \sigma_{\min}^2 \mathbf{I}), \quad \mathbf{u}_t(\mathbf{z}_t|\mathbf{z}_0, \mathbf{z}_1) = \mathbf{z}_1 - \mathbf{z}_0. \quad (7)$$

若取联合分布 $\rho(\mathbf{z}_0, \mathbf{z}_1) = p(\mathbf{z}_1|\mathbf{z}_0)\rho_0(\mathbf{z}_0)$, 就把动力学转移核直接编码进 coupling。直观上, F2P 少走“绕到高斯再回来”的弯路, 流线更直, ODE 积分所需步数更少。

3.3 Observation guidance: 把预测分布推向滤波分布

预测分布 $\rho_1(\mathbf{x}_j) = p(\mathbf{x}_j|\mathbf{y}_{1:j-1})$ 还没有吸收当前观测 $\mathbf{y}_j$ 。EnFF 在 FM 向量场上加 guidance:

$$\mathbf{u}'_t(\mathbf{z}; \mathbf{y}) = \mathbf{u}_t(\mathbf{z}) + \mathbf{g}_t(\mathbf{z}; \mathbf{y}), \quad (8)$$

使其目标从预测分布变成滤波后验 $p(\mathbf{x}_j|\mathbf{y}_{1:j}) \propto p(\mathbf{y}_j|\mathbf{x}_j)\rho_1(\mathbf{x}_j)$ 。若 $p(\mathbf{y}|\mathbf{z}_1) \propto e^{-J(\mathbf{z}_1; \mathbf{y})}$, 精确 guidance 可写成

$$\mathbf{g}_t(\mathbf{z}_t; \mathbf{y}) = \iint \left(\frac{e^{-J(\mathbf{z}_1; \mathbf{y})}}{Z_t(\mathbf{z}_t; \mathbf{y})} - 1 \right) \mathbf{u}_t(\mathbf{z}_t|\mathbf{z}_0, \mathbf{z}_1) p(\mathbf{z}_0, \mathbf{z}_1|\mathbf{z}_t) d\mathbf{z}_0 d\mathbf{z}_1. \quad (9)$$

实际计算中, 论文比较 MC guidance 与 localized guidance。MC guidance 与 BPF 接近, 容易继承粒子退化; localized guidance 通过局部线性化似然来近似 (9), 实践中更稳。

4 理论连接：它不是孤立的新算法

论文的理论部分主要说明 EnFF 与经典滤波器之间的关系。

命题 1 (MC 边际向量场). 给定 i.i.d. 样本对 $\{(z_0^{(n)}, z_1^{(n)})\}_{n=1}^N$, MC 近似的 conditional flow matching 损失在固定 (z, t) 上的唯一最小化解, 正是 (6) 中的加权向量场。

命题 2 (经验测度极限). 若条件路径满足 $p_1(z|z_0, z_1) = \mathcal{N}(z|z_1, \sigma_{\min}^2 \mathbf{I})$, 则 MC 边际向量场在 $t = 1$ 诱导

$$p_1(z) = \frac{1}{N} \sum_{n=1}^N \mathcal{N}(z|z_1^{(n)}, \sigma_{\min}^2 \mathbf{I}), \quad (10)$$

并且当 $\sigma_{\min} \rightarrow 0$ 时弱收敛到经验测度 $\frac{1}{N} \sum_{n=1}^N \delta_{z_1^{(n)}}$ 。

定理 1 (与 BPF 的连接). 若 EnFF 使用 MC guidance, 且 $\sigma_{\min} \rightarrow 0$, 则 EnFF 的采样分布等价于 bootstrap particle filter 的重要性重采样分布。因此 MC guidance 并不能摆脱 BPF 的 mode collapse 风险。

定理 2 (与 EnKF 的连接). 在线性观测算子 $h(\mathbf{x}) = \mathbf{H}\mathbf{x}$ 下, 若为 EnFF 设计特定的 affine guidance, 则当 $\sigma_{\min} \rightarrow 0$ 时, EnFF 可采样到与 EnKF analysis step 相同的滤波分布。

这些结果的价值是: EnFF 不是简单把 FM 套到 DA 上, 而是给出一个包含 BPF、EnKF 和 EnSF 思想的统一框架。真正带来实践收益的是 F2P flow 加 localized guidance 的组合。

5 实验结果

论文在 Lorenz-96、Kuramoto–Sivashinsky (KS) 和二维 Navier–Stokes (NS) 上比较 EnFF-F2P、EnFF-OT 与 EnSF。核心结论是: F2P 在较少 ODE 步数下更稳; EnFF 可以利用更大 ensemble 规模; 在高维非线性问题中, 它能获得比 EnSF 更好的成本–精度折中。




Figure 2: 原论文 Figure 2: Lorenz-96、KS 和 NS 上的 RMSE/CRPS 对比。总体趋势是 EnFF-F2P 在采样步数较少时仍保持竞争力。




Figure 3: KS 轨迹示例：EnFF-F2P 与 EnSF 的状态重建对比。




Figure 4: 二维 Navier-Stokes 示例：高维流场下 EnFF-F2P 的滤波重建。




Figure 5: 与经典 DA 方法的比较：论文强调 EnFF 在高维 nonlinear benchmark 上有更好的成本-精度折中。

6 如何理解这篇工作的核心思想

从工程角度看，EnFF 做了三件事。第一，用 flow matching 的 ODE 采样替代 diffusion/score 方法中的慢 SDE 采样。第二，不训练网络，而是用当前 ensemble 做 MC 边际向量场估计。第三，F2P flow 利用 DA 的时间递推，把上一时刻滤波分布与当前预测分布直接耦合，再用 observation guidance 吸收当前观测。

因此，它不是单纯“换一个生成模型”，而是把 DA 的贝叶斯递推结构、FM 的条件路径设计、以及 ensemble 近似结合起来。其优势在于采样快、结构灵活、能扩展 ensemble；风险在于 guidance 和超参数仍会影响稳定性，且对复杂真实天气系统的工程验证仍需要进一步扩大。

7 结论

这篇论文把 Flow Matching 引入数据同化，提出了 Ensemble Flow Filter。它的最重要贡献不是某个单独公式，而是提供了一个统一视角：BPF、EnKF、EnSF 和 FM-guided filtering 可以被放进同一套“用向量场把预测分布推到滤波分布”的框架中。F2P flow 则进一步利用 DA 自带的时间耦合，使采样轨迹更直、更省步数，从而改善高维数据同化中的成本-精度折中。

References

- [1] F. BAO, Z. ZHANG, AND G. ZHANG, *An ensemble score filter for tracking high-dimensional nonlinear dynamical systems*, Computer Methods in Applied Mechanics and Engineering, 432 (2024), p. 117447.
- [2] G. EVENSEN, *The ensemble kalman filter: Theoretical formulation and practical implementation*, Ocean dynamics, 53 (2003), pp. 343–367.
- [3] R. FENG, T. WU, C. YU, W. DENG, AND P. HU, *On the guidance of flow matching*, arXiv preprint arXiv:2502.02150, (2025).
- [4] N. J. GORDON, D. J. SALMOND, AND A. F. SMITH, *Novel approach to nonlinear/non-gaussian bayesian state estimation*, in IEE proceedings F (radar and signal processing), vol. 140, IET, 1993, pp. 107–113.
- [5] R. E. KALMAN, *A new approach to linear filtering and prediction problems*, Journal of Basic Engineering, 82 (1960), pp. 35–45.
- [6] K. LAW, A. STUART, AND K. ZYGALAKIS, *Data assimilation*, Cham, Switzerland: Springer, 214 (2015), p. 52.
- [7] Y. LIPMAN, R. T. CHEN, H. BEN-HAMU, M. NICKEL, AND M. LE, *Flow matching for generative modeling*, arXiv preprint arXiv:2210.02747, (2022).