

SoMe: 面向基于 LLM 的社交媒体智能体的真实基准

Dizhan Xue^{1,2}, Jing Cui³, Shengsheng Qian^{1,2*}, Chuanrui Hu⁴, Changsheng Xu^{1,2,5}

¹ 中国科学院自动化研究所多模态人工智能系统全国重点实验室

² 中国科学院大学人工智能学院

³ 天津理工大学计算机科学与工程学院

⁴ 南京邮电大学

⁵ 鹏城实验室

xuedizhan17@mails.ucas.ac.cn, cjtxdy@stud.tjut.edu.cn

shengsheng.qian@nlpr.ia.ac.cn, csxu@nlpr.ia.ac.cn

摘要

由大语言模型（LLM）驱动的智能体最近展现出令人印象深刻的能力，并在社交媒体平台上越来越受欢迎。尽管 LLM 智能体正在重塑社交媒体生态，但目前仍缺少对它们理解媒体内容、理解用户行为以及做出复杂决策能力的综合评估。为应对这一挑战，我们提出 SoMe，这是一个开创性的基准，旨在评估配备多种智能体工具、能够访问和分析社交媒体数据的社交媒体智能体。SoMe 包含一组多样化的 8 项社交媒体智能体任务、9,164,284 条帖子、6,591 个用户画像，以及来自多种社交媒体平台和外部网站的 25,686 份报告，并包含 17,869 个经过精细标注的任务查询。与现有社交媒体任务数据集和基准相比，SoMe 是首个为基于 LLM 的社交媒体智能体处理多样化社交媒体任务提供通用且真实平台的基准。通过广泛的定量与定性分析，我们首次概览了主流 agentic LLM 在真实社交媒体环境中的表现，并识别出若干局限。我们的评估表明，当前闭源与开源 LLM 都无法令人满意地处理社交媒体智能体任务。SoMe 为未来社交媒体智能体提供了一个具有挑战性但有意义的测试床。我们的代码和数据可在 <https://github.com/LivXue/SoMe> 获取。

1 引言

语言智能体把工具与大语言模型（LLM）结合起来，已经引起广泛研究兴趣，并在具有人类水平智能的任务中展现出有前景的应用，包括编程 Zhang et al. (2024); Islam, Ali, and Parvez (2024)、网页浏览 He et al. (2024); Li et al. (2025) 和医疗健康 Kim et al. (2024); Li et al. (2024)。与此同时，社交媒体智能体的发展长期以来一直是人工智能领域的目标，其目的在于理解大规模社交数据并执行类似人类的行为 Edwards et al. (2014); Carr and Hayes (2015)。基于 LLM 的智能体近期进展也带来了社交媒体智能体的空前繁荣 Mou, Wei, and Huang (2024); Zhang et al. (2025a)，它们有潜力承担多种任务，例如社会事件分析 Qian, Zhang, and Xu (2016)、帖子与用户推荐 Tang, Tang, and Liu (2014)，以及社会行为模拟 Yang et al. (2024)。这些智能体可以减轻用户和组织维护活跃线上存在、分析海量社交媒体数据的负担。此外，这些类人智能体正逐渐活跃在越来越多人类用户的社交网络中。

随着社交媒体智能体参与度提升并重塑社交媒体生态，人们对其在复合社交媒体任务中的能力理解仍不完整，这引发了担忧。以往对社交媒体领域智能体和 LLM 的评估通常聚焦于单一任务，例如虚假信息检测 Nakazato et al. (2024) 或用户行为预测 Jiang and Ferrara (2023)。例如，BotSim Qiao et al. (2025) 为基于 LLM 的智能体设计了用户行为模拟框架，由从 Reddit 收集的数万条数据驱动。TrendSim Zhang et al. (2025c) 基于从微博收集的 1,000 名用户数据，为社交媒体智能体创建了一个包含时间感知交互机制的用户模拟环境。这些现有

*通讯作者。

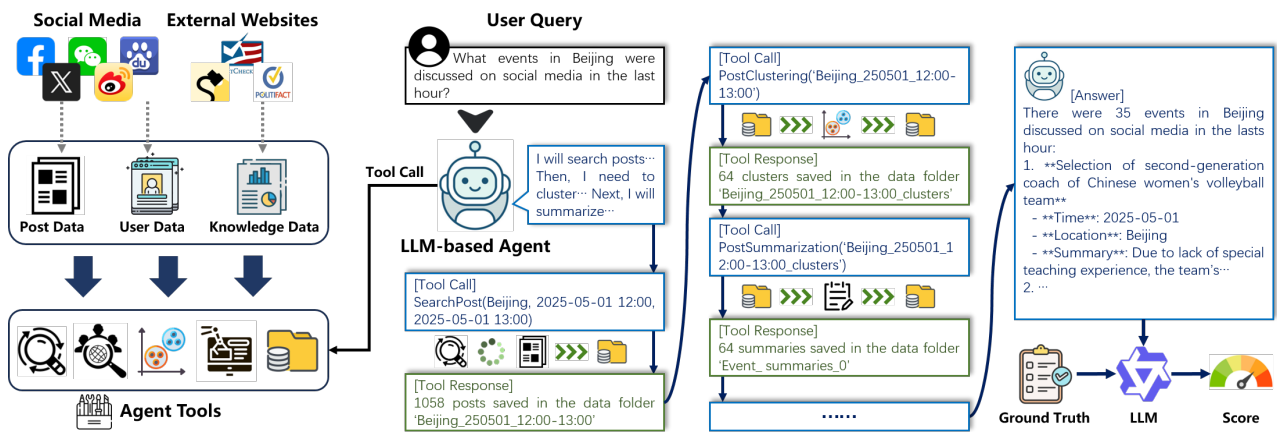


图 1: SoMe 中智能体的工作流程图。社交媒体智能体与用于数据获取、管理和分析的工具交互, 以便为用户查询得到答案。答案在 LLM 评分器的辅助下进行评估。

任务	# 查询	# 数据	数据类型
实时事件检测	568	476,611	帖子
流式事件摘要	154	7,898,959	帖子
虚假信息检测	1,451	27,137	帖子与知识
用户行为预测	3,000	840,200	帖子与用户
用户情绪分析	2,696	840,200	帖子与用户
用户评论模拟	4,000	840,200	帖子与用户
媒体内容推荐	4,000	840,200	帖子与用户
社交媒体问答	2,000	8,651,759	帖子与用户
总计	17,869	9,242,907	全部

表 1: SoMe 中的数据统计: # 查询表示数据集中查询 (含标注) 的数量, # 数据表示数据库中可访问数据的数量, 数据类型表示数据库中的数据类型。

评估也受到数据不足和缺少真实标签的限制 (例如, TrendSim 使用 LLM 在没有真实参考答案的情况下评估智能体行为的合理性)。总之, 这些评估不足以全面认识社交媒体智能体。为进一步推动研究, 需要一个具有大量真实数据和标注的通用基准, 以开发和部署可信赖的社交媒体智能体。

为应对上述挑战, 我们提出 SoMe, 这是首个面向社交媒体智能体的通用基准, 旨在综合评估 LLM 在社交媒体任务中的 agentic 能力。SoMe 在 8 项关键任务上评估 LLM: 实时事件检测、流式事件摘要、虚假信息检测、用户行为预测、用户情绪分析、用户评论模拟、媒体内容推荐和社交媒体问答。为使基于 LLM 的智能体能够执行这些任务, 我们构建了一个包含 8 个智能体工具的平台, 用于获取、管理和分析社交媒体内外的数据。此外, 我们从 32 个社交媒体平台 (例如 X¹ 和微博²) 以及外部网站收集了 900 万条真实公开数据, 与社交媒体智能体的实际应用相一致。这些数据覆盖广泛主题、事件和用户, 同时保留社交媒体数据真实且具有挑战性的属性, 即噪声性、时间性和多样性。我们利用人类-LLM 交互式流程, 为所有任务标注任务查询及其真实答案, 并由总计 10 名专业标注员进行细致验证。在我们的基准中, 基于 LLM 的智能体需要在真实环境中通过适当工具调用进行逐步数据处理和长上下文推理, 如图 1 所示。数据的简要统计见表 1。

我们的贡献总结如下:

- 我们提出 SoMe, 这是首个面向基于 LLM 的社交媒体智能体的真实评估基准。SoMe 包含 8 项任务和数百万条真实数据, 评估社交数据分析、用户人格理解和长上下文知识推理等能力。
- 我们建立了一个面向基于 LLM 的社交媒体智能体的运行平台, 包含 8 个用于数据获取、管理和分析的工具。智能体可以通过逐步数据处理和推理, 并结合适当工具组合, 在社交媒体中执行复杂任务。

¹<https://x.com>

²<https://weibo.com/>

- 我们提供了主流 13 个 agentic LLM 在真实社交媒体环境中的性能概览。我们的发现反映出现有社交媒体智能体的瓶颈，并为未来工作提供建议。

2 相关工作

2.1 基于 LLM 的社交媒体智能体

社交媒体已经成为全球最受欢迎的技术创新之一，吸引了数十亿用户，并从根本上重塑了个人、组织和社会沟通、互动与交换信息的方式。由于其巨大的社会影响，社交媒体研究已经成为人工智能中活跃且长期存在的领域 Roy et al. (2012); Qian, Zhang, and Xu (2016); Qian et al. (2023); Xue et al. (2025)。然而，社交媒体的开放世界属性和复杂结构显著降低了静态输入模型的有效性。

最近，在开发智能体的追求中，人们相当关注把 LLM 与外部工具整合起来 Wang et al. (2024b); Xue, Qian, and Xu (2024); He, Demartini, and Gadiraju (2025); Qian et al. (2024); Yang et al. (2025b)。特别是，agentic LLM Hurst et al. (2024); Comanici et al. (2025); Yang et al. (2025a) 被提出用于增强使用外部工具和处理智能体任务的能力。基于 agentic LLM，这些智能体在环境交互、决策制定和任务执行方面获得了强大能力。尤其是，基于 LLM 的社交媒体智能体在多轮信息获取、分析和推理中展现出空前能力，提升了虚假信息检测 Wan et al. (2024)、用户模拟 Gao et al. (2024) 和事件分析 Wang et al. (2024a) 等任务的表现。例如，Wang et al. (2024a) 设计了一个基于 LLM 的智能体，迭代过滤无关新闻，并采用类人推理分析复杂社会事件。Zhang et al. (2025c) 提出一个基于 LLM 的多智能体系统，用于模拟社交媒体热门话题中的用户交互。Wei et al. (2024) 设计匿名意见领袖智能体，用于模拟和预测用户对社交媒体不同事件的情绪反应。

然而，这些社交媒体智能体专门面向不同社交媒体任务，无法同时处理多种任务。为彻底评估社交媒体智能体能力，我们提出 SoMe，通过一个通用智能体平台衡量 8 项 agentic 社交媒体任务上的性能。该平台配备多种工具，使智能体能够在真实社交媒体环境中交互。

2.2 基于 LLM 的智能体基准

随着基于 LLM 的智能体兴起，人们关注智能体在多种真实世界任务中的性能和可信度 Liu et al. (2024b); He, Demartini, and Gadiraju (2025)。大量研究已经评估基于 LLM 的智能体在工具使用和环境交互方面的能力 Xie et al. (2024); Skrynnik et al. (2025)。例如，CharacterEval Tu et al. (2024) 评估智能体在多轮角色扮演对话中的角色扮演能力。OSWorld Xie et al. (2024) 在真实计算机环境中评估多模态智能体使用真实计算机的能力。VisualWebArena Koh et al. (2024) 在真实视觉接地任务上评估多模态网页智能体的指令执行能力。虽然已有基准已经在多种应用领域评估基于 LLM 的智能体，但尽管社交媒体智能体在真实应用中很普遍，全面的社交媒体智能体基准仍然缺失。

不同于上述基准中具有显式指引的环境，社交媒体是极其嘈杂的环境，关于某一概念的信息通常可能很稀缺，也可能被大量无关信息淹没 Baldwin et al. (2013)。因此，我们建立 SoMe，这是一个新颖且全面的基准，旨在通过为基于 LLM 的社交媒体智能体提供精细且真实的评估框架来填补这一空白。

3 SoMe 基准

在本节中，我们将介绍社交媒体智能体的任务定义、收集的数据，以及所构建评估平台支持的工具。

3.1 社交媒体任务

评估社交媒体智能体能力需要一种全面且结构化的方法。我们收集了 8 项最受关注的、与社交媒体相关的 agentic 任务，并将其分为 3 类：

- **以帖子为中心的任务：**这类任务需要对社交媒体帖子进行多轮数据处理和交互，有时需要访问外部知识库。**实时事件检测 (RED)** 旨在从大量近期帖子中实时检测社会事件。**流式事件摘要 (SES)** 旨在从持续发布的帖子中逐步总结社会事件细节。**虚假信息检测 (MID)** 旨在利用外部知识支持识别帖子中的虚假、误导性或不准确信息。
- **以用户为中心的任务：**这类任务涉及通过多轮工具调用理解用户偏好和行为模式，从而进行个性化预测。**用户行为预测 (UBP)** 旨在预测用户与特定帖子的交互行为。**用户情绪分析 (UEA)** 旨在预测用户对特定帖子产生的情绪。**用户评论模拟 (UCS)** 旨在预测用户会对给定帖子发表的评论。
- **综合任务：**这类任务需要对大量帖子和用户进行综合分析以推导答案。**媒体内容推荐 (MCR)** 旨在推荐符合用户偏好的社交媒体内容。**社交媒体问答 (SMQ)** 旨在回答关于帖子和用户公开信息的问题。

这些任务的细节和示例在附录中介绍。

3.2 数据来源与标注

数据来源。我们主要从 32 个社交媒体平台收集大量数据，例如 X 和微博，其中英文和中文内容占主导。具体而言，这些数据来自三个来源：1) 我们从小影公司³购买商业数据，这些数据是公开可见数据，并从多种社交媒体平台爬取。2) 我们爬取微博上头部影响者及其社交网络中的用户数据。3) 我们采用开源数据集 Yang et al. (2022)，其中来自外部网站的事实核查报告被分离出来，形成用于虚假信息检测的知识库。总之，我们的数据库中有 9,164,284 条帖子、6,591 个用户画像和 25,686 份报告，可通过多种智能体工具访问。

数据标注。虽然文本是社交媒体中的主要模态，但我们把帖子中的图像和视频转换为 caption（由 Qwen2.5-VL-72B Bai et al. (2025) 生成）、OCR 文本（由 Qwen2.5-VL-72B 生成）和 ASR 文本（由 GPT-4o Hurst et al. (2024) 生成）。之后，我们为所有任务提出半自动标注流程。具体而言，对于 UBP、UCS 和 MCR，我们自动生成关于所收集用户的任务查询，并基于模板把收集数据转换成真实答案标注。由于结果已经包含在收集数据中，这些任务的真实答案不涉及 LLM 或人工编辑。对于 RED、SES、UEA 和 SMQ，我们基于 Qwen3-32B，利用多轮人类-LLM 交互式流程为自动生成的任务查询标注真实答案。所有真实答案都经过 10 名专业标注员的人工过滤与验证，以保证标注质量。对于 MID，我们合并开源 LIAR-RAW 和 RAWFC 数据集 Yang et al. (2022)，其中真实标签已经标注完成。

更多数据来源和标注细节见附录。



图 2: SoMe 中社交媒体数据的分布。

³<https://www.xiaoying.tv/>

工具名 (参数)	描述
DataFolder(folder_name, start_idx, end_idx)	输出给定名称数据文件夹中从起始索引到结束索引的数据。
SearchPost(location, start_time, end_time)	搜索某一时间段内发布的、关于某地点的帖子，并保存到数据文件夹。
SearchTopic(topic_name)	搜索关于给定话题的帖子，并保存到数据文件夹。
SearchUser(uid)	搜索特定用户，输出画像，并把帖子保存到数据文件夹。
RetrievePost(query, folder_name, topk)	在数据文件夹中检索与 query 最相关的 top-k 帖子。
RetrieveKnowledge(query, topk)	在知识库中检索与 query 最相关的 top-k 报告。
PostClustering(folder_name)	对数据文件夹中的帖子进行聚类，并把聚类保存到另一个数据文件夹。
PostSummarization(folder_name)	对数据文件夹中的帖子聚类进行摘要，并把摘要保存到另一个数据文件夹。

表 2: SoMe 中的智能体工具。

3.3 数据统计

数据集的简要统计见表 1。我们进一步研究 SoMe 的数据多样性。

用户分析。图 2(a) 展示了 Qwen3-32B 基于所收集用户画像识别出的用户兴趣，呈现了用户兴趣的轮廓与广泛范围。具体而言，存在 4 个主要兴趣，包括娱乐 (36.5%)、社会、生活与健康 (31.6%)、文化与艺术 (24.4%) 以及商业与技术 (7.5%)，并包含 33 个子类别。在子类别中，演艺圈 (12.2%)、名人 (11.6%)、影视 (11.5%)、音乐 (8.4%) 和生活事件 (7.6%) 最受欢迎。总体而言，我们数据中的用户兴趣高度多样，因为最受欢迎的一个兴趣也只占 12.2%，这提高了基准的全面性和鲁棒性。

帖子分析。图 2(b) 展示了由 Qwen3-32B 识别出的所收集帖子主题分布。结果显示，帖子在与用户兴趣相一致的四个主要领域中分布多样：社会、生活与健康 (46.1%)、娱乐 (28.8%)、文化与艺术 (14.8%) 以及商业与技术 (10.3%)。在这些类别中，生活事件 (18.8%) 和名人 (18.5%) 是最常见的子话题。值得注意的是，其他所有被识别出的子话题各自占比均低于 10%。所收集社交媒体帖子中的这种显著异质性凸显了内容覆盖范围。因此，这种多样化表征增强了我们基准的全面性和鲁棒性。

查询分析。我们进一步研究 8 项任务中的所有查询，如图 2(c) 所示。SoMe 中的任务查询大致可以分为关于行为、事件、偏好、数量、因果关系和对象的问题。此外，我们把所有查询划分为 11 个类别，其百分比显示在图中。每个类别对应于对社交媒体智能体一种特定技能的评估。这些类别的标准如下：(1) 行为推断：分析用户行为模式并预测用户行为。(2) 人格分析：基于用户社交媒体活动识别用户人格。(3) 偏好分析：推断并解释用户偏好。(4) 意图推断：辨别行动与言语背后的潜在意图。(5) 关系推断：发现人与人、对象或事件之间的关系。(6) 信息抽取：从噪声数据中为特定查询抽取关键信息。(7) 事件追踪：在长上下文中追踪事件过程与转变。(8) 比较：比较多个对象或多个来源的信息。(9) 知识推理：检索并应用外部知识进行逻辑推理。(10) 时空推测：理解社交媒体数据中的空间和时间关系。(11) 摘要：整合来自各种来源的信息，提供全面而简洁的报告。

3.4 智能体工具

我们为社交媒体智能体构建了一个通用框架，包含 8 个用于数据获取、管理和分析的工具。所有工具均按照 Model Context Protocol (MCP) [Hou et al. \(2025\)](#) 设计，以确保与主流 agentic LLM 的广泛兼容性。这些工具总结于表 2。遵循 MCP，所有工具及其参数的详细描述都会提供给智能体，以确保其充分理解工具。最后，在收到任务查询后，所构建的社交媒体智能体可以与适当工具交互，并进行逐步推理以处理任务。

4 评估

更多评估和实验细节见附录。

模型	规模	RED	SES	MID	UBP	UEA	UCS	MCR	SMQ	Avg.
基于 API										
GPT-4o	N/A	47.59	36.17	50.24	55.17	31.53	52.48	61.63	64.21	49.88
Gemini-2.5-Flash	N/A	54.92	44.87	45.62	57.50	41.94	56.00	62.75	71.01	54.33
Kimi-K2-Instruct	1T	50.40	38.57	47.83	51.50	45.94	58.25	57.00	77.38	53.36
DeepSeek-V3	671B	35.94	38.83	51.00	55.06	42.98	54.92	56.25	75.94	51.37
开源										
Llama-3.3-70B-Instruct	70B	34.84	33.77	50.24	55.83	32.77	53.00	61.40	64.83	48.34
Qwen3-32B	32B	44.25	41.04	47.42	67.03	33.53	54.98	63.28	80.27	53.98
GLM-4-32B-0414	32B	27.55	27.27	41.38	40.17	26.10	47.13	44.08	57.19	38.86
Devstral-Small-2507	24B	30.99	33.31	47.07	47.93	22.43	46.68	47.75	58.25	41.80
Qwen3-14B	14B	43.97	40.19	44.80	66.20	33.35	54.43	62.13	77.47	52.82
GLM-4-9B-0414	9B	14.42	29.68	33.63	48.73	28.63	44.10	49.05	51.82	37.51
Qwen3-8B	8B	40.38	36.69	45.21	61.73	33.03	53.33	60.55	76.18	50.89
DeepSeek-R1-0528-Qwen3-8B	8B	17.71	28.83	<u>26.46</u>	43.53	<u>21.18</u>	<u>31.10</u>	<u>34.33</u>	51.84	<u>31.87</u>
Llama-3.1-8B-Instruct	8B	<u>3.37</u>	<u>20.78</u>	40.45	<u>34.23</u>	37.11	33.98	47.40	<u>31.05</u>	31.65

表 3: 在 SoMe 的 8 项任务上评估 agentic LLM 的性能。Avg. 表示 8 项任务的平均分。最高值以粗体标出，最低值以下划线标出。

模型	规模	RED	SES	MID	UBP	UEA	UCS	MCR	SMQ	Avg.
基于 API										
GPT-4o	N/A	94.54	90.91	95.11	98.00	98.70	96.45	97.35	87.50	94.82
Gemini-2.5-Flash	N/A	99.23	94.81	88.63	95.50	99.04	99.75	99.25	96.63	96.61
Kimi-K2-Instruct	1T	98.86	85.06	94.21	97.17	98.87	99.75	99.25	98.03	96.40
DeepSeek-V3	671B	99.36	92.86	98.62	99.78	99.95	100.00	100.00	98.25	98.60
开源										
Llama-3.3-70B-Instruct	70B	88.91	90.26	98.07	97.15	98.86	97.53	97.85	93.72	95.29
Qwen3-32B	32B	99.47	94.16	97.73	98.11	100.00	99.88	98.60	99.68	98.45
GLM-4-32B-0414	32B	88.67	68.18	87.72	67.67	85.52	86.58	79.40	83.73	80.93
Devstral-Small-2507	24B	82.92	86.36	93.45	79.73	70.10	86.78	78.70	82.53	82.57
Qwen3-14B	14B	96.23	94.81	99.45	99.39	99.00	99.80	99.80	98.62	98.39
GLM-4-9B-0414	9B	76.06	79.87	78.08	88.90	93.35	83.63	91.50	79.15	83.82
Qwen3-8B	8B	91.37	92.86	99.38	98.07	98.68	99.40	97.33	98.73	96.98
DeepSeek-R1-0528-Qwen3-8B	8B	67.43	70.78	64.58	82.93	67.88	62.86	64.88	76.51	69.73
Llama-3.1-8B-Instruct	8B	29.93	56.49	90.63	67.59	85.98	75.86	86.90	44.39	67.20

表 4: agentic LLM 在 SoMe 的 8 项任务上的任务完成率 (TCR)。Avg. 表示 8 项任务的平均 TCR。低于 80 的值以红色标出，高于 99 的值以绿色标出。

4.1 实验设置

我们在 SoMe 上评估 13 个主流 agentic LLM。对于基于 API 的模型，我们选择 GPT-4o [Hurst et al. \(2024\)](#)、Gemini-2.5-Flash [Comanici et al. \(2025\)](#)、Kimi-K2-Instruct [Team \(2025\)](#) 和 DeepSeek-V3 [Liu et al. \(2024a\)](#)。对于开源模型，我们采用 Qwen3 系列 [Yang et al. \(2025a\)](#)、Llama-3 系列 [Dubey et al. \(2024\)](#)、GLM-4 系列 [GLM et al. \(2024\)](#)、Devstral-Small-2507 [Jiang et al. \(2023\)](#) 和 DeepSeek-R1-0528-Qwen3-8B [Guo et al. \(2025\)](#)。尽管 Kimi-K2-Instruct 和 DeepSeek-V3 也是开源的，但由于这些模型规模过大，我们选择 API 调用。实验使用 8 张 NVIDIA A800-SMX4-80GB GPU，并采用 vLLM 框架 [Kwon et al. \(2023\)](#) 部署开源模型。所有 LLM 均使用标准 Model Context Protocol (MCP) 配备智能体工具，同时所有 LLM 的原生工具调用格式都在我们的智能体框架中得到支持并正确解析。

4.2 评估指标

我们分别为 8 项社交媒体智能体任务设计合适指标。对于 RED、SES 和 SMQ，我们采用基于 LLM 的指标，将生成结果与真实答案在语义上进行比较，并分配相应分数。对于 MID、UBP、UEA、UCS 和 MCR，我们利用 LLM 过滤冗余信息，并从智能体回答中抽取关键答案。然后，我们基于真实答案计算准确率 (ACC)。此外，我们为所有任务计算任务完成率 (TCR)，该指标衡量智能体在特定任务中成功完成任务查询的比例。所有指标分数都归一化到 [0, 100] 范围内，并报告所有任务在测试样本上的平均分。指标和 LLM prompt 的细节见附录。

4.3 总体结果

不同 agentic LLM 在社交媒体智能体任务中的实验结果见表 3-4。

性能分析。基于表 3，我们有如下观察：

- 当前闭源和开源 LLM 都无法令人满意地处理社交媒体智能体任务。在多数情况下，当前 agentic LLM 通常无法在大多数任务中取得超过 70 的评估分数。这在 RED、SES 和 MID 等任务中尤其明显，这些任务涉及的信息开放性很高，大多数 LLM 的得分低于 50。这些结果揭示出，构建社交媒体智能体并非易事，还需要更多工作来提升社交媒体智能体的性能和可信度。我们提出的 SoMe 为未来社交媒体智能体提供了具有挑战性但有意义的测试床。
- 在基于 API 的 agentic LLM 中，Gemini-2.5-Flash 取得最高平均性能分 54.33。此外，它在单项任务上表现更优，包括 RED 和 SES，其分数分别为 54.92 和 44.87。在开源 agentic LLM 类别中，Qwen3-32B 达到最高平均分 53.98。此外，它在 UBP、MCR 和 SMQ 等关键任务上领先。
- 比较不同规模的系列 LLM 可以发现，在社交媒体智能体任务中，更大模型通常优于更小模型。例如，从平均评估分看，Qwen3-32B 比 Qwen3-14B 高 2.2%，Qwen3-14B 比 Qwen3-8B 高 3.8%，Llama-3.3-70B-Instruct 比 Llama-3.1-8B-Instruct 高 52.7%。然而，更大模型通常推理效率更低，并面临本地开发兼容性挑战。尤其对于涉及大量帖子、用户画像乃至外部知识的社交媒体智能体任务，开发高效且低成本的智能体尤其关键。
- 有趣的是，尽管 DeepSeek-R1-0528-Qwen3-8B 在推理任务上显著优于 Qwen3-8B [Guo et al. \(2025\)](#)，但当它被用作社交媒体智能体时，其能力下降。与 Qwen3-8B 相比，DeepSeek-R1-0528-Qwen3-8B 在 8 项任务上的性能分别持续下降 56.14%、21.42%、41.07%、29.48%、35.88%、41.68%、43.30% 和 31.95%。这些结果表明，社交媒体任务中的 agentic 能力并不一定来自 LLM 推理技能的增强。因此，在开发更强大 LLM 时，同时提升推理能力和 agentic 能力至关重要。

任务完成率（TCR）分析。基于表 4，我们有如下观察：

- 由于 SoMe 中的任务涉及按正确顺序调用适当工具，完成任务查询并非易事。一些开源 LLM，例如 DeepSeek-R1-0528-Qwen3-8B 和 Llama-3.1-8B-Instruct，在处理社交媒体智能体任务时取得相对较低的 TCR。尤其是，Llama-3.1-8B-Instruct 只能以 65.76% 的平均 TCR 完成任务查询。这些结果表明，对一些小型开源 LLM 来说，提升多轮推理和工具调用能力仍然是一个挑战。
- 在所有被评估的 LLM 中，Gemini-2.5-Flash、DeepSeek-V3、Qwen3-32B 和 Qwen3-14B 可以以极高的平均 TCR 处理任务，分别为 96.61%、98.60%、98.45% 和 98.39%。这些结果显示这些模型杰出的 agentic 能力，它们能够正确理解并执行工具调用。相应地，这些模型也在 SoMe 上取得更好性能，如表 3 所示。这意味着，调用工具和逐步推理的能力是社交媒体智能体的基础。

4.4 挑战分析

在本节中，我们对主流 agentic LLM 在 SoMe 上犯下的典型错误进行深入分析，以识别未来研究的主要挑战。

4.4.1 工具链规划错误

在复杂社交媒体任务中，智能体需要按适当顺序多次调用工具来处理任务查询。然而，智能体在逐步调用工具链时可能遇到挑战。因此，我们进一步研究社交媒体智能体在一次尝试中成功调用工具链的概率。我们在图 3 中报告了实时事件检测任务 100 个样本上工具链调用的一次尝试成功率（OSR）。在图中，我们还概述了




图 3: 不同 agentic LLM 在工具链规划中的一次尝试成功率和错误率。




图 4: 不同 agentic LLM 在工具使用中的幻觉率。

智能体未能正确调用下一个工具的不同情况的比例，即无法生成正确的工具调用格式、选择正确工具或为工具提供正确参数。

有趣的是，我们可以观察到，小模型相比大模型表现出明显更低的 OSR。Qwen3-32B、DeepSeek-V3（671B 参数）、Kimi-K2-Instruct（1T 参数）、Gemini-2.5-Flash 和 GPT-4o 在一次尝试中准确规划工具链的成功率接近 100%。GLM4-32B-0414 相比 GLM4-9B-0414 也显著提升了 OSR。小模型通常更难基于过去交互推断后续工具调用。因此，为了开发更优秀的社交媒体智能体，小型 LLM 的工具规划能力应当成为未来工作的重点。

4.4.2 工具使用中的幻觉

在实验中，我们观察到一种常见错误场景：智能体未能正确调用工具，并想象工具响应或工具调用格式。例如，在实时事件检测中，智能体有时未能调用工具，并想象出满足任务查询的事件。为了进一步研究工具使用中的幻觉，我们设计了一个实验：故意把工具响应改成错误，并观察智能体是否会假装完成任务查询。实验在实时事件检测任务的 100 个样本上进行。

如图 4 所示，大多数开源 LLM（包括 DeepSeek-R1-0528-Qwen3-8B、Qwen3-8B、Qwen3-32B、GLM-4-9B-0414、Kimi-K2-Instruct 和 DeepSeek-V3）都会受到工具响应幻觉影响，其幻觉率分别为 14%、8%、8%、6%、7% 和 13%。有趣的是，无论模型规模是否增加，这一问题都持续存在，因为即使 Kimi-K2-Instruct（1T 参数）和

Query: Please tell me the events in Beijing discussed on social media from 2025-05-06 07:00:00 to 2025-05-06 08:00:00.

[Tool Call]: SearchPost('Beijing', '2025-05-06 07:00:00', '2025-05-06 08:00:00')

[Tool Response]: 297 posts that meet the condition have been stored in the data folder 'Beijing_2025-05-06 07:00:00_2025-05-06 08:00:00'. It can be checked through the tool 'data_folder'. “

[Tool Call]: PostClustering('Beijing_2025-05-06 07:05:00_2025-05-06 08:00:00')

[Tool Response]: Error...

Parameter Error

(a) Kimi-K2-Instruct

Query: Please tell me the events in Jiangxi discussed on social media from 2025-06-02 19:00:00 to 2025-06-02 20:00:00.

[Tool Call]:
print(SearchPost(location='Jiangxi', 2025-06-02 19:00:00', 2025-06-02 20:00:00'))

[Tool Response]: Error...

Format Error

(b) Gemini-2.5-Flash

图 5: Kimi-K2-Instruct 和 Gemini-2.5-Flash 犯下的典型错误。蓝色文本由智能体生成。

DeepSeek-V3 (671B 参数) 也受到幻觉影响。此外, 一些开源 LLM 的工具调用幻觉率 (表示由于格式错误而未能调用任何工具的比例) 也显著偏高。具体而言, DeepSeek-R1-0528-Qwen3-8B 和 Devstral-Small-2507 分别以 29% 和 28% 的比例想象错误工具调用格式, 并未能调用任何工具。然而, 值得注意的是, GLM-4-32B-0414 似乎解决了开源 LLM 的这一普遍局限。这些结果表明, 克服工具使用中的幻觉是当前开源模型面临的重要挑战。

4.4.3 案例研究

我们在图 5 中进一步指出了顶级 agentic LLM 犯下的一些常见错误。如图 5(a) 所示, Kimi-K2-Instruct 有时无法重复工具响应或查询中的关键词, 导致工具参数错误。如图 5(b) 所示, Gemini-2.5-Flash 的一个常见错误是在工具函数外添加 `print(·)`。这些错误可能反映出训练这些最先进 agentic LLM 时的内在缺陷, 未来工作应考虑这些问题。

5 结论

本文介绍了 SoMe, 这是一个用于评估基于 LLM 的社交媒体智能体的新基准。SoMe 包含一组多样化的 8 项社交媒体智能体任务、9,164,284 条帖子、6,591 个用户画像, 以及来自 32 个社交媒体平台和外部网站的

25,686 份报告，并包含 17,869 个经过精细标注的任务查询。我们的实验表明，当前闭源和开源 agentic LLM 都无法令人满意地处理社交媒体智能体任务。此外，我们通过深入实验分析识别出当前智能体面临的若干挑战，以启发未来工作。通过提供一个具有挑战性的基准，我们希望促进能够应对社交媒体智能体任务复杂性的先进模型的发展。

6 致谢

本工作得到国家重点研发计划（No.2023YFC3310700）、北京市自然科学基金（JQ23018, L252032）和国家自然科学基金（No.62276257）的支持。

参考文献

- Bai, S.; Chen, K.; Liu, X.; Wang, J.; Ge, W.; Song, S.; Dang, K.; Wang, P.; Wang, S.; Tang, J.; et al. 2025. Qwen2.5-vl technical report. *arXiv preprint arXiv:2502.13923*.
- Baldwin, T.; Cook, P.; Lui, M.; MacKinlay, A.; and Wang, L. 2013. How noisy social media text, how different social media sources? In *Proceedings of the sixth international joint conference on natural language processing*, 356–364.
- Carr, C. T.; and Hayes, R. A. 2015. Social media: Defining, developing, and divining. *Atlantic journal of communication*, 23(1): 46–65.
- Comanici, G.; Bieber, E.; Schaekermann, M.; Pasupat, I.; Sachdeva, N.; Dhillon, I.; Blistein, M.; Ram, O.; Zhang, D.; Rosen, E.; et al. 2025. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. *arXiv preprint arXiv:2507.06261*.
- Dubey, A.; Jauhri, A.; Pandey, A.; Kadian, A.; Al-Dahle, A.; Letman, A.; Mathur, A.; Schelten, A.; Yang, A.; Fan, A.; et al. 2024. The llama 3 herd of models. *arXiv e-prints*, arXiv–2407.
- Edwards, C.; Edwards, A.; Spence, P. R.; and Shelton, A. K. 2014. Is that a bot running the social media feed? Testing the differences in perceptions of communication quality for a human agent and a bot agent on Twitter. *Computers in Human Behavior*, 33: 372–376.
- Gao, C.; Xu, F.; Chen, X.; Wang, X.; He, X.; and Li, Y. 2024. Simulating human society with large language model agents: City, social media, and economic system. In *Companion Proceedings of the ACM Web Conference 2024*, 1290–1293.
- GLM, T.; Zeng, A.; Xu, B.; Wang, B.; Zhang, C.; Yin, D.; Zhang, D.; Rojas, D.; Feng, G.; Zhao, H.; et al. 2024. Chatglm: A family of large language models from glm-130b to glm-4 all tools. *arXiv preprint arXiv:2406.12793*.
- Guo, D.; Yang, D.; Zhang, H.; Song, J.; Zhang, R.; Xu, R.; Zhu, Q.; Ma, S.; Wang, P.; Bi, X.; et al. 2025. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*.
- He, G.; Demartini, G.; and Gadiraju, U. 2025. Plan-then-execute: An empirical study of user trust and team performance when using llm agents as a daily assistant. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, 1–22.
- He, H.; Yao, W.; Ma, K.; Yu, W.; Dai, Y.; Zhang, H.; Lan, Z.; and Yu, D. 2024. WebVoyager: Building an End-to-End Web Agent with Large Multimodal Models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 6864–6890.
- Hou, X.; Zhao, Y.; Wang, S.; and Wang, H. 2025. Model context protocol (mcp): Landscape, security threats, and future research directions. *arXiv preprint arXiv:2503.23278*.

- Hurst, A.; Lerer, A.; Goucher, A. P.; Perelman, A.; Ramesh, A.; Clark, A.; Ostrow, A.; Welihinda, A.; Hayes, A.; Radford, A.; et al. 2024. Gpt-4o system card. *arXiv preprint arXiv:2410.21276*.
- Islam, M. A.; Ali, M. E.; and Parvez, M. R. 2024. MapCoder: Multi-Agent Code Generation for Competitive Problem Solving. In *Annual Meeting of the Association of Computational Linguistics 2024*, 4912–4944. Association for Computational Linguistics (ACL).
- Jiang, A. Q.; Sablayrolles, A.; Mensch, A.; Bamford, C.; Chaplot, D. S.; de las Casas, D.; Bressand, F.; Lengyel, G.; Lample, G.; Saulnier, L.; Lavaud, L. R.; Lachaux, M.-A.; Stock, P.; Scao, T. L.; Lavril, T.; Wang, T.; Lacroix, T.; and Sayed, W. E. 2023. Mistral 7B. *arXiv:2310.06825*.
- Jiang, J.; and Ferrara, E. 2023. Social-llm: Modeling user behavior at scale using language models and social network data. *arXiv preprint arXiv:2401.00893*.
- Kim, Y.; Park, C.; Jeong, H.; Chan, Y. S.; Xu, X.; McDuff, D.; Lee, H.; Ghassemi, M.; Breazeal, C.; and Park, H. W. 2024. Mdagents: An adaptive collaboration of llms for medical decision-making. *Advances in Neural Information Processing Systems*, 37: 79410–79452.
- Koh, J. Y.; Lo, R.; Jang, L.; Duvvur, V.; Lim, M.; Huang, P.-Y.; Neubig, G.; Zhou, S.; Salakhutdinov, R.; and Fried, D. 2024. VisualWebArena: Evaluating Multimodal Agents on Realistic Visual Web Tasks. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 881–905. Bangkok, Thailand: Association for Computational Linguistics.
- Kwon, W.; Li, Z.; Zhuang, S.; Sheng, Y.; Zheng, L.; Yu, C. H.; Gonzalez, J. E.; Zhang, H.; and Stoica, I. 2023. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles*.
- Li, J.; Lai, Y.; Li, W.; Ren, J.; Zhang, M.; Kang, X.; Wang, S.; Li, P.; Zhang, Y.-Q.; Ma, W.; et al. 2024. Agent hospital: A simulacrum of hospital with evolvable medical agents. *arXiv preprint arXiv:2405.02957*.
- Li, K.; Zhang, Z.; Yin, H.; Zhang, L.; Ou, L.; Wu, J.; Yin, W.; Li, B.; Tao, Z.; Wang, X.; et al. 2025. WebSailor: Navigating Super-human Reasoning for Web Agent. *arXiv preprint arXiv:2507.02592*.
- Liu, A.; Feng, B.; Xue, B.; Wang, B.; Wu, B.; Lu, C.; Zhao, C.; Deng, C.; Zhang, C.; Ruan, C.; et al. 2024a. Deepseek-v3 technical report. *arXiv preprint arXiv:2412.19437*.
- Liu, X.; Yu, H.; Zhang, H.; Xu, Y.; Lei, X.; Lai, H.; Gu, Y.; Ding, H.; Men, K.; Yang, K.; et al. 2024b. AgentBench: Evaluating LLMs as Agents. In *The Twelfth International Conference on Learning Representations*.
- Mou, X.; Wei, Z.; and Huang, X.-J. 2024. Unveiling the Truth and Facilitating Change: Towards Agent-based Large-scale Social Movement Simulation. In *Findings of the Association for Computational Linguistics ACL 2024*, 4789–4809.
- Nakazato, T.; Onishi, M.; Suzuki, H.; and Shibuya, Y. 2024. JSocialFact: a misinformation dataset from social media for benchmarking LLM safety. In *2024 IEEE International Conference on Big Data (BigData)*, 3017–3025. IEEE.
- Qian, S.; Chen, H.; Xue, D.; Fang, Q.; and Xu, C. 2023. Open-world social event classification. In *Proceedings of the ACM web conference 2023*, 1562–1571.
- Qian, S.; Zhang, T.; and Xu, C. 2016. Multi-modal multi-view topic-opinion mining for social event analysis. In *Proceedings of the 24th ACM international conference on Multimedia*, 2–11.
- Qian, S.; Zhou, Z.; Xue, D.; Wang, B.; and Xu, C. 2024. From linguistic giants to sensory maestros: A survey on cross-modal reasoning with large language models. *arXiv preprint arXiv:2409.18996*.

- Qiao, B.; Li, K.; Zhou, W.; Li, S.; Lu, Q.; and Hu, S. 2025. BotSim: LLM-Powered Malicious Social Botnet Simulation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, 14377–14385.
- Roy, S. D.; Mei, T.; Zeng, W.; and Li, S. 2012. Socialtransfer: cross-domain transfer learning from social streams for media applications. In *Proceedings of the 20th ACM international conference on Multimedia*, 649–658.
- Skrynnik, A.; Andreychuk, A.; Borzilov, A.; Chernyavskiy, A.; Yakovlev, K.; and Panov, A. 2025. POGEMA: A Benchmark Platform for Cooperative Multi-Agent Pathfinding. In *The Thirteenth International Conference on Learning Representations*.
- Tang, J.; Tang, J.; and Liu, H. 2014. Recommendation in social media: recent advances and new frontiers. In *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*, 1977–1977.
- Team, K. 2025. Kimi K2: Open Agentic Intelligence. Technical report, Moonshot AI.
- Tu, Q.; Fan, S.; Tian, Z.; Shen, T.; Shang, S.; Gao, X.; and Yan, R. 2024. CharacterEval: A Chinese Benchmark for Role-Playing Conversational Agent Evaluation. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 11836–11850. Bangkok, Thailand: Association for Computational Linguistics.
- Wan, H.; Feng, S.; Tan, Z.; Wang, H.; Tsvetkov, Y.; and Luo, M. 2024. DELL: Generating Reactions and Explanations for LLM-Based Misinformation Detection. In *Findings of the Association for Computational Linguistics ACL 2024*, 2637–2667.
- Wang, X.; Feng, M.; Qiu, J.; Gu, J.; and Zhao, J. 2024a. From news to forecast: Integrating event analysis in llm-based time series forecasting with reflection. *Advances in Neural Information Processing Systems*, 37: 58118–58153.
- Wang, Y.; Xue, D.; Zhang, S.; and Qian, S. 2024b. BadAgent: Inserting and Activating Backdoor Attacks in LLM Agents. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 9811–9827.
- Wei, Q.; Xue, R.; Wang, Y.; Xiao, H.; Wang, Y.; and Duan, X. 2024. Mimicking the mavens: agent-based opinion synthesis and emotion prediction for social media influencers. *arXiv preprint arXiv:2407.20668*.
- Xie, T.; Zhang, D.; Chen, J.; Li, X.; Zhao, S.; Cao, R.; Hua, T. J.; Cheng, Z.; Shin, D.; Lei, F.; et al. 2024. Os-world: Benchmarking multimodal agents for open-ended tasks in real computer environments. *Advances in Neural Information Processing Systems*, 37: 52040–52094.
- Xue, D.; Qian, S.; Hu, C.; and Xu, C. 2025. Short-video Propagation Influence Rating: A New Real-world Dataset and A New Large Graph Model. *arXiv preprint arXiv:2503.23746*.
- Xue, D.; Qian, S.; and Xu, C. 2024. Few-shot multimodal explanation for visual question answering. In *Proceedings of the 32nd ACM International Conference on Multimedia*, 1875–1884.
- Yang, A.; Li, A.; Yang, B.; Zhang, B.; Hui, B.; Zheng, B.; Yu, B.; Gao, C.; Huang, C.; Lv, C.; et al. 2025a. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*.
- Yang, Z.; Hu, Y.; Du, Z.; Xue, D.; Qian, S.; Wu, J.; Yang, F.; Dong, W.; and Xu, C. 2025b. SVBench: A Benchmark with Temporal Multi-Turn Dialogues for Streaming Video Understanding. In *The Thirteenth International Conference on Learning Representations*.
- Yang, Z.; Ma, J.; Chen, H.; Lin, H.; Luo, Z.; and Chang, Y. 2022. A Coarse-to-fine Cascaded Evidence-Distillation Neural Network for Explainable Fake News Detection. In *Proceedings of the 29th International Conference on Computational Linguistics*, 2608–2621.

Yang, Z.; Zhang, Z.; Zheng, Z.; Jiang, Y.; Gan, Z.; Wang, Z.; Ling, Z.; Chen, J.; Ma, M.; Dong, B.; et al. 2024. Oasis: Open agent social interaction simulations with one million agents. *arXiv preprint arXiv:2411.11581*.

Zhang, C.; Yang, Z.; Liu, J.; Li, Y.; Han, Y.; Chen, X.; Huang, Z.; Fu, B.; and Yu, G. 2025a. Appagent: Multimodal agents as smartphone users. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, 1–20.

Zhang, K.; Li, J.; Li, G.; Shi, X.; and Jin, Z. 2024. CodeAgent: Enhancing Code Generation with Tool-Integrated Agent Systems for Real-World Repo-level Coding Challenges. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 13643–13658.

Zhang, Y.; Li, M.; Long, D.; Zhang, X.; Lin, H.; Yang, B.; Xie, P.; Yang, A.; Liu, D.; Lin, J.; Huang, F.; and Zhou, J. 2025b. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. *arXiv preprint arXiv:2506.05176*.

Zhang, Z.; Lian, J.; Ma, C.; Qu, Y.; Luo, Y.; Wang, L.; Li, R.; Chen, X.; Lin, Y.; Wu, L.; et al. 2025c. TrendSim: Simulating Trending Topics in Social Media Under Poisoning Attacks with LLM-based Multi-agent System. In *Findings of the Association for Computational Linguistics: NAACL 2025*, 2930–2949.

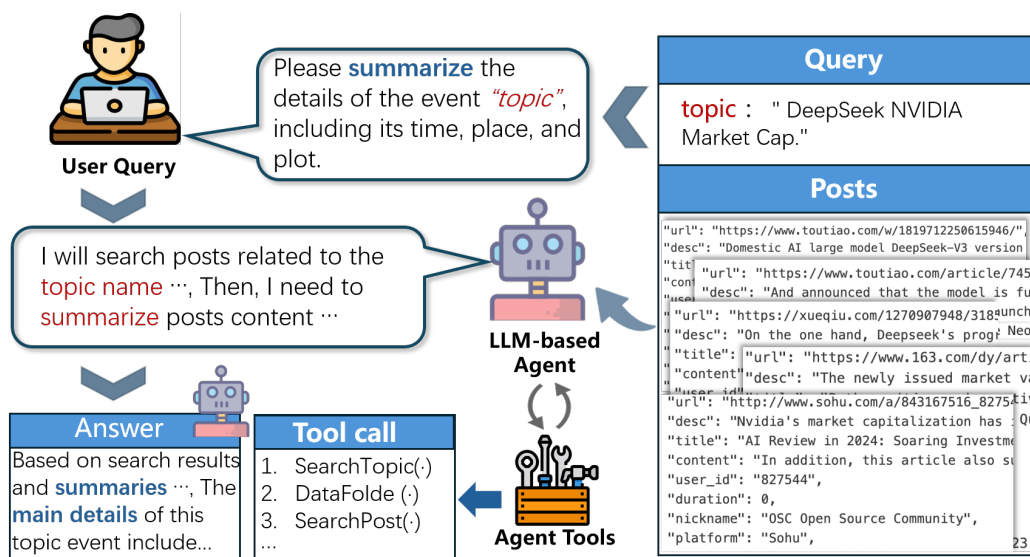


图 6: 流式事件摘要 (SES) 的示例。

A 任务定义

在本节中，我们进一步解释 SoMe 中包含的任务。除图 1 中展示的 RED 示例外，其他 7 项任务的示例见图 6-12。我们详细解释这些任务如下：

- **实时事件检测 (RED)**。如图 6 所示，该任务旨在从大量近期帖子中实时检测社会事件。给定一个指定目标地点和时间段的查询，智能体会从社交媒体中搜索相关帖子。这些帖子包含地点关键词，但可能并未详细描述发生在该地点的事件。如果帖子数量较少，智能体会直接阅读所有帖子并抽取匹配指定地点的事件。如果帖子过多，智能体会对帖子聚类，并总结每一组。随后，智能体会审查所有摘要，以识别并抽取有效事件。
- **流式事件摘要 (SES)**。该任务旨在从持续发布的帖子中逐步总结社会事件细节。给定一个指定事件话题的查询，智能体会持续搜索相关帖子。这些帖子包含与事件无关的大量噪声。同时，智能体会识别关于事件的关键细节，并通过流式过程更新事件摘要。

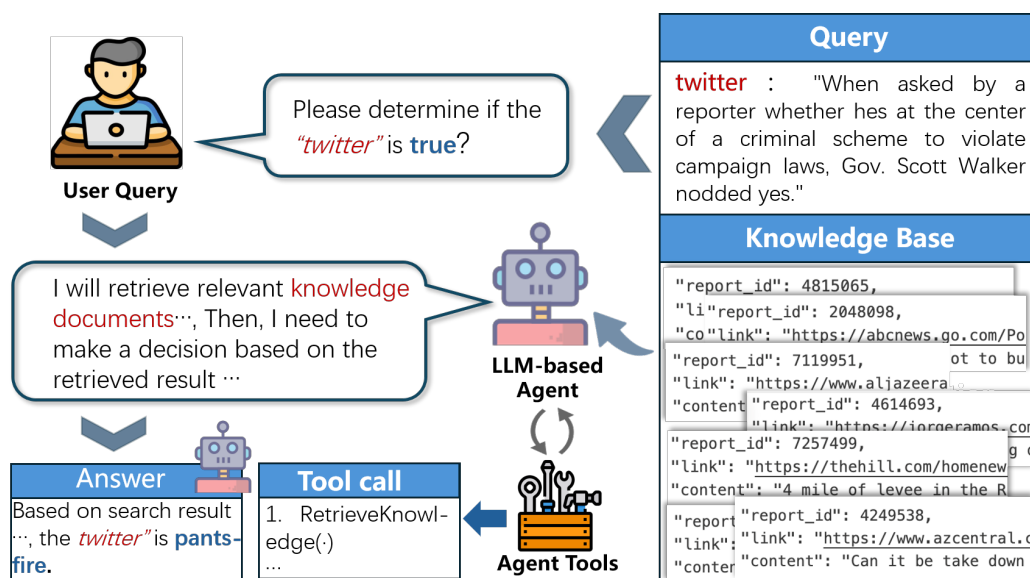


图 7: 虚假信息检测 (MID) 的示例。

- **虚假信息检测 (MID)**。如图 7 所示, 该任务旨在利用外部知识支持识别帖子中的虚假、误导性或不准确信息。给定一条社交媒体帖子, 智能体会主动检索与帖子中的关键概念和声明相关的知识。通过比较材料, 智能体会逐步找出帖子中的任何虚假信息。最后, 智能体会在 *pants-fire*、*false*、*barely-true*、*half-true*、*mostly-true* 和 *true* 中给出判定, 并可能附带解释。
- **用户行为预测 (UBP)**。如图 8 所示, 该任务旨在预测用户与特定帖子的交互行为。给定一个指定帖子、用户和交互行为的查询, 智能体首先检索用户画像和历史帖子, 然后分析其兴趣和过去行为。通过比较用户偏好与帖子内容, 智能体会判断用户是否会点赞、评论或转发该帖子。最后, 智能体会在 *Yes*、*No* 中给出判定, 并可能附带解释。
- **用户情绪分析 (UEA)**。如图 9 所示, 该任务旨在预测用户对特定帖子产生的情绪。给定一条社交媒体帖子和一个用户, 智能体首先检索用户画像和历史帖子, 然后分析并抽取用户表达习惯、兴趣领域和语言情绪等特征。通过比较用户偏好与帖子内容, 智能体会找出用户可能对该帖子产生的情绪。最后, 智能体会在 *Positive*、*Angry*、*Sad*、*Fear*、*Surprise* 和 *Emotionless* 中给出判定, 并可能附带解释。
- **用户评论模拟 (UCS)**。如图 10 所示, 该任务旨在预测用户会对给定帖子发表的评论。给定一条社交媒体帖子、帖子下的一条评论和一个用户, 智能体首先检索用户画像和历史帖子, 然后分析并抽取用户说话风格、常用词汇、兴趣领域和表达习惯等特征。通过比较用户偏好与帖子内容, 智能体会判断帖子下的评论是否由该用户发布。最后, 智能体会在 *Yes*、*No* 中给出判定, 并可能附带解释。
- **媒体内容推荐 (MCR)**。如图 11 所示, 该任务旨在推荐符合用户偏好的社交媒体内容。给定一条社交媒体帖子, 智能体首先检索用户画像和历史帖子, 然后分析并抽取用户可能感兴趣的领域或话题。通过比较用户偏好与帖子内容, 智能体会判断用户是否对该帖子感兴趣。最后, 智能体会在 *Yes*、*No* 中给出判定, 并可能附带解释。
- **社交媒体问答 (SMQ)**。如图 12 所示, 该任务旨在回答关于帖子和用户公开信息的问题。给定一个特定查询, 智能体首先判断该查询与话题相关还是与用户相关。然后, 智能体会基于该判断搜索话题相关帖子或用户相关画像。通过分析搜索结果, 智能体会给出与查询对应的答案。

B 工具实现

在本节中, 我们进一步解释社交媒体智能体框架中使用的工具。

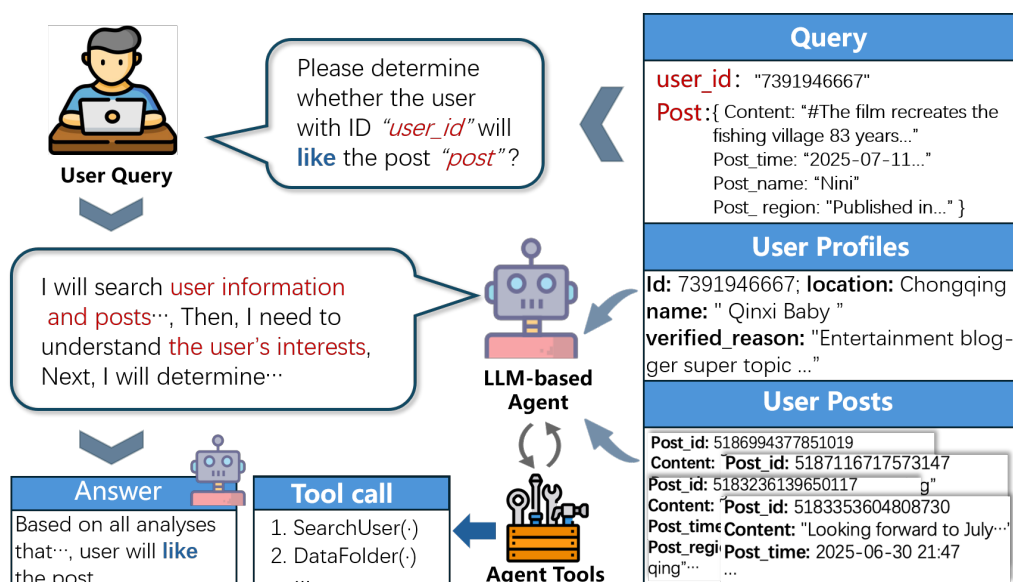


图 8: 用户行为预测 (UBP) 的示例。

- **DataFolder(folder name, start idx, end idx)**. 该工具使用一个字典存储数据，并把显示函数保存在另一个具有相同 key 的字典中。数据由其他工具与相应显示函数同时存储。调用 **DataFolder(folder name, start idx, end idx)** 时，会检索 key 为 *folder name* 的数据及其显示函数。随后，从起始索引 *start idx* 到结束索引 *end idx* 的数据项会由显示函数组织为可读字符串，并返回给智能体。
- **SearchPost(location, start time, end time)**. 该工具在数据库中搜索从 *start time* 到 *end time* 发布的、含有与 *location* 相关关键词（例如 *location* 的子区域）的帖子。搜索到的数据会存储在 *DataFolder* 中，并带有用于展示帖子的显示函数。最后，该工具会向智能体返回包括文件夹名称在内的数据相关信息。
- **SearchTopic(topic name)**. 该工具在数据库中搜索包含 *topic name* 中关键词的帖子。搜索到的数据会存储在 *DataFolder* 中，并带有用于展示帖子的显示函数。最后，该工具会向智能体返回包括文件夹名称在内的数据相关信息。
- **SearchUser(uid)**. 该工具在数据库中搜索 ID 为 *uid* 的用户。该用户发布的帖子会存储在 *DataFolder* 中，并带有用于展示帖子的显示函数。最后，该工具会直接返回用户画像，并返回帖子的文件夹信息。
- **RetrievePost(query, folder name, topk)**. 该工具在 key 为 *folder name* 的数据文件夹中检索与 *query* 语义相关的帖子。检索通过向量搜索实现，其中 *query* 和帖子的语义向量由 Qwen3-Embedding-4B Zhang et al. (2025b) 嵌入。最后，该工具会把 top-k 帖子返回给智能体，其中 k 等于 *topk*，并由显示函数组织。
- **RetrieveKnowledge(query, topk)**. 该工具在知识库中检索与 *query* 语义相关的报告。检索同样通过向量搜索实现，其中 *query* 和报告的语义向量由 Qwen3-Embedding-4B Zhang et al. (2025b) 嵌入。最后，该工具会返回 top-k 报告，其中 k 等于 *topk*，并由内置显示函数组织。
- **PostClustering(folder name)**. 该工具基于 Qwen3-Embedding-4B Zhang et al. (2025b) 编码的帖子 embedding，对 key 为 *folder name* 的数据文件夹中的帖子进行聚类。聚类使用 0.5 的语义相似度阈值进行分组。随后，帖子聚类会存储到数据文件夹中，并带有用于展示聚类的显示函数。最后，该工具会向智能体返回包括文件夹名称在内的已存储聚类信息。
- **PostSummarization(folder name)**. 该工具对 key 为 *folder name* 的数据文件夹中的聚类进行摘要。每个聚类中的帖子会与事件摘要 prompt 一起输入到社交媒体智能体的 backbone LLM。随后，聚类摘要会存储到数据文件夹中，并带有用于展示摘要的显示函数。最后，该工具会向智能体返回包括文件夹名称在内的已存储摘要信息。

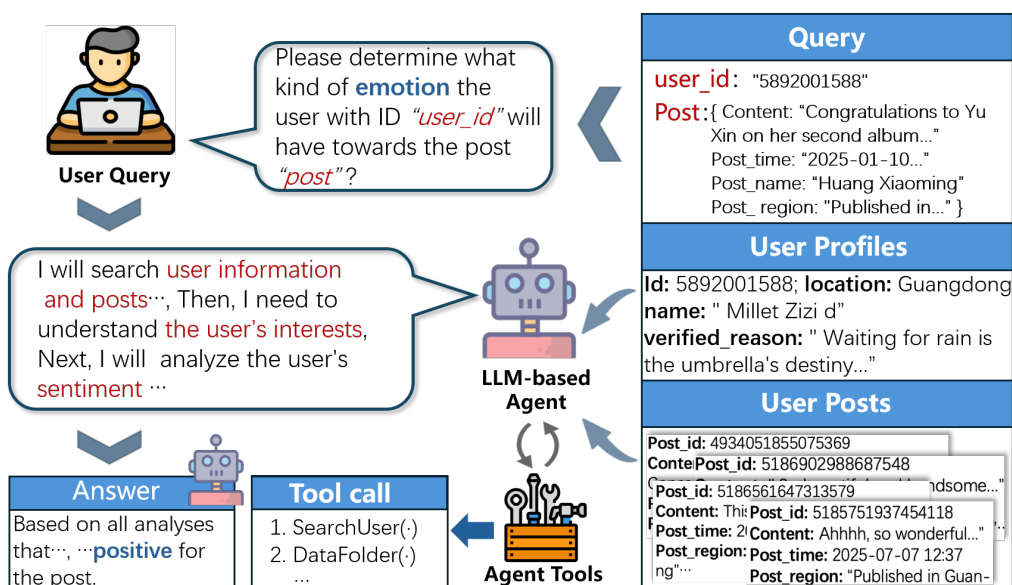


图 9: 用户情绪分析 (UEA) 的示例。

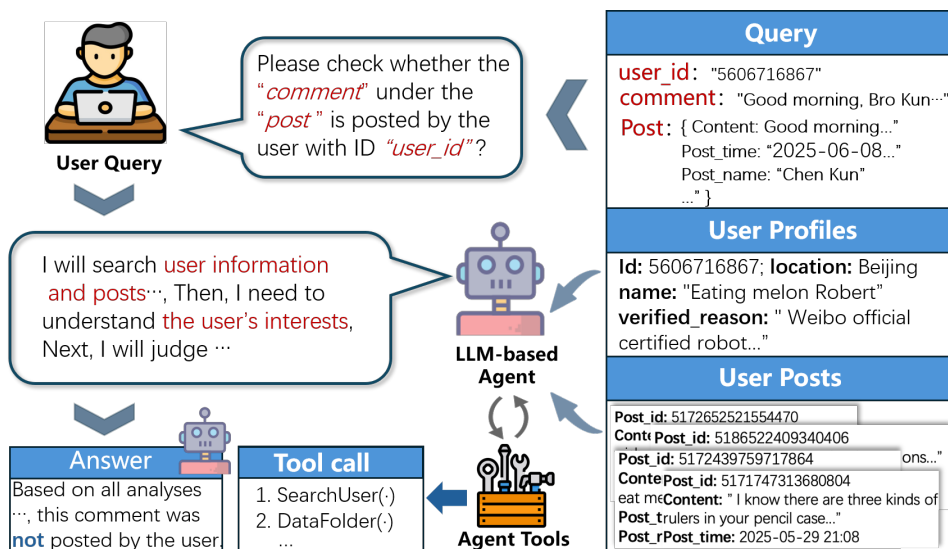


图 10: 用户评论模拟 (UCS) 的示例。

C 数据集标注

在本节中，我们详细介绍每项任务的标注。

C.1 实时事件检测

该任务涉及跨平台社交媒体数据。为构造任务查询，我们选择三个特定地点。每个地点关联 10 天内的 240 个一小时时间段。每个查询由模板 “Please tell me the events in {location} discussed on social media from {start time} to {end time}.” 生成。接下来，我们执行自动流程，对与每个地点和时间段相关的帖子进行聚类，过滤掉与任何事件无关的聚类，并为每个聚类生成事件摘要（包括标题、内容、地点和时间）。为利用充足数据提升聚类性能，聚类在每日数据上进行。随后，我们进行人工标注，基于源帖子检查每个事件摘要，纠正任何不准确之处，并移除无效摘要。在人工验证每个事件摘要后，这些摘要会基于查询中的地点和时间参数链接到任务查询。删除没有事件的查询（通常来自当地深夜时间）后，我们最终获得 568 个带有真实事件摘要的任务查询。

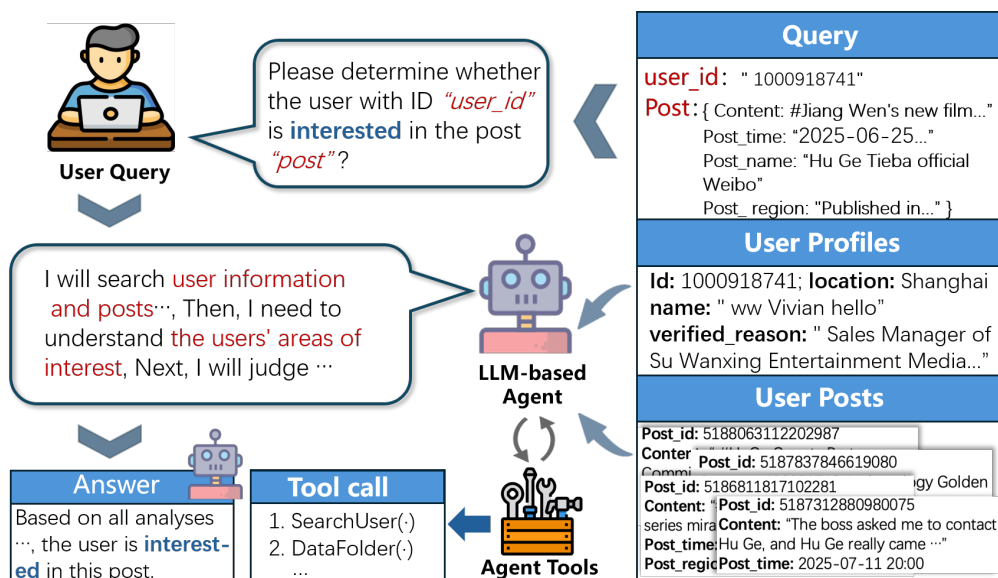


图 11: 媒体内容推荐 (MCR) 的示例。

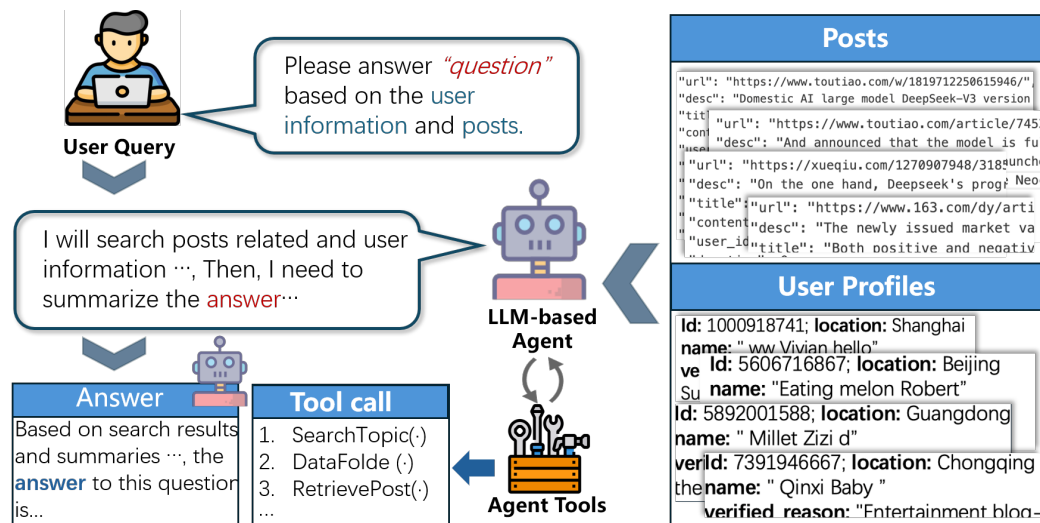


图 12: 社交媒体问答 (SMQ) 的示例。

C.2 流式事件摘要

我们收集了从 2024 年 11 月 25 日到 2025 年 1 月 2 日与热门事件相关的 200 个趋势话题，并包含跨社交媒体平台的大量相关帖子。每个查询由模板 “*Please summarize the details of the event {topic}, including its time, place, and plot.*” 构造。为标注每个事件话题的摘要，我们使用带 web search 工具的 GPT-4o，根据话题关键词生成摘要。然而，搜索到的内容可能与目标事件无关，摘要也可能缺少某些关键细节。因此，我们进行复杂的人类参与式审查：人工指出当前摘要中的任何不准确之处，并细化 prompt 以重新生成摘要。经过多轮改进和严格质量验证后，我们最终在数据集中获得 154 个事件摘要，并移除不合格事件。

C.3 虚假信息检测

对于该任务，我们使用开源 LIAR-RAW 和 RAWFC 数据集 Yang et al. (2022)，其中真实标签已经标注完成。首先，我们合并这两个数据集中的 tweet 及其标签。在源数据集中，每条 tweet 都关联若干报告，用于验证 tweet 中的信息。我们抽取所有这些报告形成知识库，可通过向量搜索访问。最后，我们用模板 “*Please determine if the tweet “{tweet}” is true.*” 生成任务查询。我们获得 1,451 个样本和 25,685 份报告。

C.4 用户行为预测

为标注该任务的真实答案,我们直接使用数据中爬取的交互行为。任务查询由模板 “*Please determine whether the user with ID {user_id} will {interact} with the post “{post}”.*” 构造,其中 {interact} 可以是 like、repost 和 comment。正样本(标签为“yes”)使用用户真实数据构造。为构造负样本,对于每个正样本,我们随机选择同一用户没有以同一交互类型交互过的另一条帖子。该任务不涉及 LLM 或人工标注,所有样本均基于爬取的真实数据构造。最后,我们获得 1,000 个点赞样本、1,000 个转发样本和 1,000 个评论样本。

C.5 用户情绪分析

对于该任务,我们使用爬取的用户评论。我们把每条针对帖子的评论输入 GPT-4o,以识别用户情绪,并将其归类为 positive、angry、sad、surprised、fearful 或 emotionless。为确保准确性,每条评论经过三轮标注,并通过投票机制确定主导情绪。随后,我们进行人工检查,纠正被标注情绪中的任何不准确之处,并过滤掉不当数据。之后,我们随机删除部分 positive 和 emotionless 数据,以缓解类别不平衡。任务查询由模板 “*Please determine what kind of emotion the user with ID {user_id} will have towards the post “{post}”.*” 构造。最终,我们获得 800 个 positive 样本、184 个 angry 样本、550 个 sad 样本、337 个 surprised 样本、25 个 fearful 样本和 800 个 emotionless 样本。

C.6 用户评论模拟

该任务同样使用爬取的评论数据。任务查询由模板 “*Please check whether the comment {comment} under the post “{post}” is posted by the user with ID {user_id}.*” 构造。正样本(标签为“yes”)使用用户的真实评论构造。为构造困难负样本,对于每个正样本,我们在同一帖子下随机选择由不同用户发布的另一条评论作为负样本。我们确保负评论内容也不同于正评论内容。最终,我们获得 2,000 个正样本和 2,000 个负样本。

C.7 媒体内容推荐

我们使用爬取的交互数据来标注该任务。任务查询由模板 “*Please determine whether the user with ID {user_id} is interested in the post “{post}”.*” 构造。正样本(标签为“yes”)使用用户曾交互过的帖子构成。此外,对于每个正样本,我们随机选择一条同一用户未交互过的帖子作为负样本。进一步地,我们保证负帖子的内容不同于正帖子的内容。最终,我们获得 2,000 个正样本和 2,000 个负样本。

C.8 社交媒体问答

我们广泛使用爬取的话题数据和用户数据来标注该任务。我们把每个话题或用户的数据及其发布帖子输入 GPT-4o,为社交媒体数据生成潜在问题和答案。在这一步中,我们为话题生成 3,000 个问答对,并生成 30,000 个问答对。随后,我们进行人工审查,检查每个问答对的正确性,并过滤掉答案不准确、问题含糊,或无需搜索相关社交媒体数据即可回答的问答对。对于剩余问答对,我们人工修改,使其更加简洁准确。最后,我们基于类型平衡原则删除部分问答对,获得 1,000 个话题问答对和 1,000 个问答对。这些问题被直接用作任务查询。

D 评估细节

我们开发了一种系统化方法,在 SoMe 上评估社交媒体智能体。虽然部分任务(MCR、UCS、UBP、MID 和 UEA)可以格式化为多选任务(例如从 6 个选项中选择用户情绪),但社交媒体智能体生成的答案可能包含对选择的解释。因此,我们利用 LLM 从原始答案中抽取选项,其 prompt 如下所示。抽取选项后,我们基于真实标签计算答案准确率。




图 13: LLM 与人工标注员在 RED、SES 和 SMQ 上评估得到的平均分。

由于评估应当可复现且准确，我们在评估中采用 Qwen3-32B，因为它目前是最强大的开源 LLM 之一，并且具有可负担的内存需求。我们排除闭源模型（例如 Gemini 和 GPT-4o），因为它们未来可能被废弃而不可用。

D.1 答案抽取 Prompt

由于智能体生成的响应通常包含大量冗余信息，我们设计任务特定 prompt，使用 LLM 有效抽取关键答案。具体而言，媒体内容推荐（MCR）、用户评论模拟（UCS）、用户行为预测（UBP）、虚假信息检测（MID）和用户情绪分析（UEA）任务使用 LLM 进行答案抽取。我们经验性地发现，LLM 可以以 100% 准确率抽取答案。答案抽取 prompt 如下。

媒体内容推荐（MCR）的答案抽取 prompt

请仔细阅读给定文本，并从中抽取最终判断结果，以确定用户是否可能对该帖子感兴趣。结果只能是“yes”或“no”，不得包含任何解释或额外内容。

输出格式要求：

- 如果文本内容的判断结果是肯定的，输出：yes
- 如果文本内容的判断结果是否定的，输出：no
- 如果文本内容的判断结果不确定，或没有判断结果，输出：error

注意：输出结果时请严格遵循上述要求。

示例输入：

- “Based on the information in the user search results, user 7391946667 primarily posted content about Jackson Yee’s concerts, movies, and daily personal reflections and updates. From these specific posts, we can infer that this user may be interested in areas or topics such as concerts, movies, idol worship, and daily life.”

回顾该用户的五条帖子，只有第五条提到 #YiYangQianxi2025Concert# 并期待 #YiYangQianxiConcert#，表明该用户显然对 Jackson Yee 的演唱会有兴趣。

比较用户兴趣与给定帖子内容：“With awe and curiosity, we once again step into the China Sky Eye. The starry sky will reveal the answers to our persistent exploration. “Salute to science and technology workers, salute the scientific spirit, #ScienceShineChina#.” 该帖子主要关注 “China Sky Eye” 和科技工作者，其主题与用户兴趣不匹配。最终判断该用户可能不会对这条帖子感兴趣。

示例输出：

- “No”

给定输入文本为 “{raw answer}”

用户评论模拟（UCS）的答案抽取 prompt

请仔细阅读给定文本，并从中抽取最终判断结果，以判断该评论是否可能由该用户发布。结果只能是 “Yes” 或 “No”，不得包含任何解释或额外内容。

输出格式要求：

- 如果文本判断结果是肯定的，输出：Yes
- 如果文本判断结果是否定的，输出：No
- 如果文本判断结果不确定，或没有判断结果，输出：Error

注意：输出结果时请严格遵循上述要求。

示例输入：

- “Based on analysis of the post content and comment style of user 7391946667 (Qinxi Baby), their comments primarily focus on topics related to Jackson Yee, daily greetings, and a small amount of event promotion. The comment “It’s my birthday today, please let me win a New Year’s SVIP lottery” mentions birthdays and SVIP lottery content, but this user’s past posts do not display similar lottery or birthday-related interactions. Furthermore, their language style (e.g., frequent use of simple greetings like “good night” and “good morning”) is inconsistent with the casual tone of the comment.”

此外，评论中提到的 “New Year’s SVIP” 与用户近期帖子没有直接联系。其 IP 地址为重庆，而该评论所在帖子发布于北京，这也使其更加可疑。总体判断：No。

示例输出：

- “No”

给定输入文本为 “{raw answer}”

用户行为预测（UBP）的答案抽取 prompt

请仔细阅读给定文本，并从中抽取最终判断结果，以确定用户是否可能对该帖子执行 {behavior} 行为。结果只能是 “Yes” 或 “No”，不得包含任何解释或额外内容。

输出格式要求：

- 如果文本内容的判断结果是肯定的，输出：Yes
- 如果文本内容的判断结果是否定的，输出：No
- 如果文本内容的判断结果不确定，或没有找到判断结果，输出：Error

注意：输出结果时请严格遵循上述要求。

示例输入：

- “Based on an analysis of posts by user “Ultraman and Little Monsters Watching the Stars” (ID: 5288580817), their primary activity is focused on celebrity fan interactions (especially Sun Qian), reposting Weibo posts, and a small amount of original content. They interact more with celebrity-related content, but less with other types of content (such as prayers for safety).”

原帖内容为 “Praying for safety”，发布者为 “Li Xiaolu Super Lu”，属于情感性内容。基于用户历史行为，其点赞和互动主要聚焦于明星粉丝活动，对情感性内容互动较少。因此，总体判断为：No。

示例输出：

- “No”

给定输入文本为 “{raw answer}”

虚假信息检测 (MID) 的答案抽取 prompt

请仔细阅读所提供文本，并抽取最终 verdict，以指出给定 tweet 是否包含任何虚假信息。结果必须是以下之一：“pants-fire”、“false”、“barely-true”、“half-true”、“mostly-true”或“true”。不要提供任何解释或额外内容。你必须显式地从文本中抽取并输出最终 verdict。

输出格式要求：

- 如果 verdict 是 pants-fire，输出：“pants-fire”。
- 如果 verdict 是 false，输出：“false”。
- 如果 verdict 是 barely-true，输出：“barely-true”。
- 如果 verdict 是 half-true，输出：“half-true”。
- 如果 verdict 是 mostly-true，输出：“mostly-true”。
- 如果 verdict 是 true，输出：“true”。
- 如果 verdict 不确定或不清楚，输出：“error”。

你应该始终用英文回应用户。

注意：严格遵循上述输出规则。

示例输入：

- “Based on the retrieved documents, the statement “Building a wall on the U.S.-Mexico border will take literally years” is accurate. Multiple sources indicate that constructing a border wall is a lengthy process, often taking several years due to logistical, financial, and political challenges. For instance, Document 1 mentions it could take more than three years, while Document 3 highlights experts’ skepticism about completing it quickly.”

Therefore, the statement is **mostly-true**.

示例输出：

- “mostly-true”

给定输入文本为 “{raw answer}”

用户情绪分析 (UEA) 的答案抽取 prompt

请仔细阅读给定文本，并抽取最终判断结果，以判断用户对帖子的情绪。结果只能输出一种情绪；无需解释或额外内容。

输出格式要求：

- 如果文本内容生成的情绪被判断为 positive，输出：Positive
- 如果文本内容生成的情绪被判断为 angry，输出：Angry
- 如果文本内容生成的情绪被判断为 sad，输出：Sad
- 如果文本内容生成的情绪被判断为 fearful，输出：Fear
- 如果文本内容生成的情绪被判断为 surprise，输出：Surprise
- 如果文本内容生成的情绪被判断为 emotionless，输出：Emotionless
- 如果文本内容生成的情绪不确定，或没有给出判断结果，输出：Error

注意：输出结果时请严格遵循上述要求。

示例输入：

- “Based on the provided user information and post content, we can see that this user is a fan of Lu Han and frequently reposts and comments on posts about him. The user’s profile and IP location indicate that they are located in Hong Kong and may be interested in entertainment news and celebrity updates from mainland China.”

结合帖子内容，该用户似乎对 Lu Han 的演唱会和音乐非常感兴趣，并多次转发和评论相关帖子。此外，该用户也对 Lu Han 的个人生活和动态感兴趣，例如自拍和日常生活。

因此，对于给定帖子 {Content: “See you this weekend”, Published Time: “2024-11-19 23:24”, Publisher: “VueChen_”, Published Location: “Published in Beijing”, Reposts: 405411, Comments: 44368, Likes: 44368}, 用户可能会对该帖子产生 **positive** 情绪。这是因为帖子内容关于对周末的期待和祝愿，可能让用户感到开心

和兴奋。此外，发布者 VueChen_ 可能是用户感兴趣的博主或名人，进一步增加了其对该帖子的正向情绪。
示例输出：
- “Positive”
给定输入文本为 “{raw answer}”

D.2 答案评分 Prompt

相比之下，实时事件检测（RED）、流式事件摘要（SES）和社交媒体问答（SMQ）任务需要更强的上下文理解，因此使用更大的 Qwen3-32B 模型处理。抽取答案的 prompt 如下。

实时事件检测（RED）的答案评分 prompt

请仔细阅读实时事件摘要的参考答案 “{ground truth}”，并基于参考答案按 0 到 5 的尺度对实时事件内容进行评分。评分标准包括：

- 准确性：内容中的信息是否准确？时间、地点、人物和事件等关键细节是否与所提供参考答案匹配？
- 完整性：内容是否覆盖参考答案中提到的所有重要方面？这包括但不限于标题、摘要、时间和地点。
- 相关性：内容是否与参考答案的主题和内容相关，且不包含无关信息？

请基于三个评分维度评价实时事件内容，并输出综合分数。

准确性评分标准定义如下：

- 5 分：与参考答案完全一致，没有错误或遗漏；
- 4 分：与参考答案大体一致，有少量轻微错误或遗漏；
- 3 分：与参考答案部分一致，有一些错误或遗漏，但不影响整体理解；
- 2 分：与参考答案有限一致，有若干错误或遗漏，部分影响理解；
- 1 分：几乎不一致，有严重错误或大量遗漏；
- 0 分：与参考答案完全不一致，信息错误或为空；

完整性评分标准定义如下：

- 5 分：与参考答案完全一致，覆盖所有关键时间点、地点和重要事件；
- 4 分：与参考答案大体一致，有少量轻微遗漏；
- 3 分：部分匹配参考答案，但遗漏一些关键信息，例如重要事件、时间点或地点；
- 2 分：部分匹配参考答案，但遗漏大量关键信息；
- 1 分：提到的信息非常有限，几乎未覆盖参考答案中的任何关键信息；
- 0 分：完全未能覆盖参考答案，重要信息缺失或为空。

相关性评分标准定义如下：

- 5 分：高度相关，聚焦于参考答案中提到的关键细节。
- 4 分：大体相关，主要内容与参考答案相关，但包含少量无关信息。
- 3 分：部分相关，与主题有一定联系，但包含明显无关内容。
- 2 分：相关性较弱，大部分内容偏离参考答案。
- 1 分：几乎无关，只有少数词语或概念与参考答案相关。
- 0 分：完全无关，与参考答案没有任何联系。

请分别为每个维度评分。

输出格式要求：

- 如果三个维度的分数为：Accuracy: 2, Completeness: 2, Relevance: 2，则输出为：Accuracy: 2, Completeness: 2, Relevance: 2

注意：请严格按照上述输出要求，不要添加任何解释、澄清或多余内容。

给定事件摘要为 “{raw answer}”

流式事件摘要（SES）的答案评分 prompt

请仔细阅读话题事件摘要的参考答案 “{ground truth}”，并基于参考答案按 0 到 5 的尺度评价你的摘要。评分标准包括：

- 准确性：参考答案中的时间、事件和因果关系是否被准确反映；
- 完整性：参考答案中的关键时间点和重要事件是否被完整覆盖。

请基于这两个评分标准评价你的摘要，并输出综合分数。

准确性评分标准定义如下：

- 5 分：与参考答案完全一致，没有错误或遗漏；- 4 分：与参考答案大体一致，有少量轻微错误或遗漏；- 3 分：与参考答案部分一致，有一些错误或遗漏，但不影响整体理解；- 2 分：与参考答案有限一致，有若干错误或遗漏，会影响部分理解；- 1 分：几乎不一致，有严重错误或大量遗漏；- 0 分：与参考答案完全不一致，信息错误或为空；

完整性评分标准定义如下：

- 5 分：与参考答案完全对齐，覆盖所有关键时间点和重要事件；- 4 分：与参考答案大体对齐，有轻微遗漏；- 3 分：与参考答案部分对齐，遗漏一些重要事件或时间点；- 2 分：与参考答案略微对齐，明显遗漏关键信息；- 1 分：几乎不与参考答案对齐，几乎未覆盖关键信息；- 0 分：完全不与参考答案对齐，存在重大遗漏或空白。

请分别为每个维度给出分数。

输出格式要求：

- 如果两个维度的分数为：Accuracy: 2, Completeness: 2，则输出为：Accuracy: 2, Completeness: 2

注意：请严格按照上述要求输出结果，不要添加任何解释、澄清或多余内容。

给定输入文本为“{raw answer}”

社交媒体问答（SMQ）的答案评分 prompt

请仔细阅读给定问题的参考答案“{ground truth}”，并基于参考答案按 0 到 5 的尺度评价你的答案。评分标准是：

- 准确性：答案是否准确反映参考答案中的关键信息；

请基于该评分标准评价你的答案。

准确性评分尺度定义如下：

- 5 分：与参考答案完全一致，没有错误或遗漏；- 4 分：与参考答案大体一致，有少量轻微错误或遗漏；- 3 分：与参考答案部分一致，有一些错误或遗漏，但不影响整体理解；- 2 分：与参考答案有限一致，有若干错误或遗漏，会影响部分理解；- 1 分：几乎不一致，有严重错误或遗漏；- 0 分：与参考答案完全不一致，信息错误或缺失。

输出格式要求：

- 直接输出准确性分数。

注意：请严格按照上述要求输出结果。不要添加任何解释、澄清或多余内容。

给定输入文本为“{raw answer}”

D.3 指标计算

在为 MCR、UCS、UBP、MID 和 UEA 抽取答案后，我们按如下方式计算智能体准确率：

$$ACC = P(\hat{y} = y), \quad (1)$$

其中 $\hat{y}$ 是预测答案， y 是真实答案。ACC 在每项任务的整个测试集上分别计算。

在获得 RED、SES 和 SMQ 的基于 LLM 的分数后，我们分别为每项任务和每个智能体计算所有标准和所有测试样本上的平均分。

D.4 基于 LLM 的评估与人工评估比较

如前所述，我们使用 Qwen3-32B 为社交媒体智能体在 RED、SES 和 SMQ 任务中生成的结果评分。为确保与 LLM 评估的一致性，我们纳入其他 LLM 和人工标注员的评估。此外，GPT-4.1 和 Kimi-K2-Instruct 使用前文相同 prompt 评估所有智能体在三项任务上的结果。同时，我们从三项任务中随机抽取 800 个实例，并邀请 10 名人工标注员评估所有智能体生成的结果。三项任务的平均分见图 13。

我们有如下观察：（1）人工标注员与 Qwen3-32B 之间的分数差异在不同模型上总体一致，尽管人工评分表现出更强区分度，这意味着 Qwen3-32B 的评分具有合理可靠性。（2）Kimi-K2-Instruct 表现出宽松倾向，超过一半模型获得 50 分以上，而 GPT-4.1 倾向于给出更低分。为便于未来复现，我们在基于 LLM 的评估中选择 Qwen3-32B，因为它是开源的，且可以以可承受成本本地部署。