

近最优学习率调度长什么样？

What do near-optimal learning rate schedules look like?

Hiroki Naganuma^{1,2,†} Atish Agarwala³ Priya Kasimbeg³ George E. Dahl³

2026-03-10

¹Mila ²Université de Montréal ³Google DeepMind

[†] 本工作部分完成于 H. Naganuma 在 Google DeepMind 担任 Student Researcher 期间。

Corresponding author(s): gdahl@google.com

摘要

神经网络训练中一个基本而尚未回答的问题是：对于给定工作负载，最佳学习率调度形状是什么？学习率调度的选择是训练过程成败的关键因素；但除了某种形式的 warmup 和 decay 之外，关于什么构成好的调度形状，目前并没有共识。为回答这个问题，我们设计了一种搜索流程，用于在参数化调度族中寻找最佳形状。我们的方法把调度形状从 base learning rate 中分离出来；否则，base learning rate 会主导跨调度比较。我们把搜索流程应用到多种调度族和三个工作负载上：线性回归、CIFAR-10 图像分类，以及 Wikitext103 上的小规模语言建模。我们表明，该搜索流程通常确实能找到近最优调度。我们发现，warmup 和 decay 是优良调度的稳健特征，而常用调度族在这些工作负载上并非最优。最后，我们考察形状搜索的输出如何依赖其他优化超参数，并发现 weight decay 会强烈影响最优调度形状。据我们所知，迄今为止，我们的结果代表了关于深度神经网络训练中近最优调度形状最全面的结果。

1 引言

现代深度神经网络几乎完全通过梯度下降的各种变体来训练。在这些方法中，每一步对参数的更新由当前批次上的梯度（可能经过变换并用移动平均进行累积）乘以一个称为学习率的标量组成。设置合适的学习率对于快速且成功的训练至关重要。学习率不合适时，最好的情况也会拖慢训练过程，最坏的情况则可能导致训练彻底失败。

按照某种调度在训练期间改变学习率，可能带来令人意外的收益。一个好的调度可以让模型在相近数量的更新内达到远低于任何常数学习率所能达到的损失值。当前实践中的有效调度稳定地表现出两个高层共同点：初始的预热阶段，此时学习率从零（或接近零）增加到峰值；以及后续的衰减阶段，此时学习率重新下降到一个小得多的值，通常接近于零。分析非线性损失曲面的曲率

以及由此产生的训练动力学，大体上可以解释预热阶段的价值 (Cohen et al., 2022; Gilmer et al., 2021)，即便它还不能给出预热精确形状的处方。训练后期需要对噪声进行退火，这为使用某种最终衰减阶段提供了理由 (Lee et al., 2022; Qiu et al., 2025)，但同样还不足以精确刻画衰减的形状，或衰减究竟应在何时开始。更一般地说，还存在每个阶段应持续多久，以及如何针对给定工作负载和训练步数构造一个好调度的问题。

尽管人们相对一致地认为预热和衰减阶段通常是有益的调度组成部分，但对于学习率调度究竟应该采取什么形状，我们所知甚少。即便调度确实经过了调优，在许多情况下 (例如 Devlin et al. (2019); Goyal et al. (2017); Vaswani et al. (2017))，研究者也只会预热和衰减阶段采用固定函数形式的前提下，调优少数几个调度参数：预热时长、峰值学习率、衰减起点以及最终学习率。衰减函数形式的常见选择包括线性、反平方根或余弦。很难想象最优形状不会至少在某种程度上依赖于工作负载，因此我们迫切需要关于如何为给定工作负载寻找定制化形状的指导。

在本文中，我们迈出了刻画调度形状如何关联训练结果的第一步。为此，我们定义了若干 (参数化的) 学习率调度族 (第 3.1 节)，其中包括相对灵活的基于样条的族，它们能够覆盖并扩展典型的余弦、线性和反平方根曲线。在第 3.3 节中，我们提出了一种方法，用于在计算成本较低的神经网络训练工作负载上搜索这些调度族，从而找到每个族内的近似最优形状。这种方法使我们能够理解不同调度族之间的差异、不同调度形状的收益，以及表现最佳的形状与工作负载具体细节之间的关系，包括与其他优化器超参数之间的关系。具体而言，本文做出了以下关键贡献：

- 我们给出了首个已知的、针对使用随机梯度下降训练的线性回归的最优调度，并用它来基准检验我们的搜索过程的有效性 (第 4.1 节)。
- 我们在两个神经网络训练工作负载上，为我们定义的不同调度族提供了近似最优调度：一个用于图像分类训练的卷积神经网络 (CNN)，以及一个小型 Transformer 语言模型工作负载。来自所有族的最佳调度都受益于预热和渐进衰减，即便对于 Smooth Non-Monotonic 这类并不强制这些性质的族也是如此 (第 4.2 节)。这些结果与线性回归情形形成对比，在线性回归中，最优调度没有预热，并且具有陡峭衰减。
- 我们提供了多条证据，表明我们的搜索实验能够充分探索除一个调度族以外的所有调度族 (第 4.3 节)。
- 最后，我们展示了在我们的工作负载上，最优调度形状与其他超参数之间的关系，特别是 AdamW 的 β_1 、 β_2 和权重衰减超参数；并且表明，尤其是权重衰减会强烈影响最优学习率调度形状 (第 4.4 节)。

我们的结果代表着朝向更好理解何种学习率调度能有效训练神经网络迈出的重要一步。

2 相关工作

从 20 世纪 80 年代和 90 年代初反向传播的早期开始，学习率调优，包括调度 (尽管带有预热阶段的调度直到后来才流行起来)，一直是任何使用神经网络的人都会遇到的麻烦。全面回顾为减轻这一负担而提出的各种技术超出了本文范围。不过，有一点值得一提。可以说，将学习率从需要考虑的超参数中移除，推动了 2010 年代初关于逐参数学习率算法的一条研究线，最终促成了极受

欢迎的 Adam 算法 (Kingma and Ba, 2014) (其新变体和扩展直到今天仍在不断涌现)。遗憾的是, 尽管 Adam 很流行, 它并没有消除调优其全局学习率超参数的需要。此外, Adam 和类似算法的最佳结果通常需要选择某种非常数调度。

正如几十年来训练神经网络时的常见实践一样, 如果有任何训练超参数被调优, 那么至少学习率很可能会被调优 (例如, Bengio (2012) 将学习率描述为“通常是单个最重要的超参数”)。然而, 将学习率的整体尺度与学习率调度的形状区分开来非常重要。在存在非常数调度时, 未加限定的“学习率”通常指峰值学习率或“基准”学习率, 并充当一个与步数无关的缩放因子; 它与一个形状结合后, 产生绝对学习率调度 (即从步数映射到步长的函数)。原则上, 基准学习率和调度形状参数像训练过程中的任何其他超参数一样, 可以用 (准) 随机搜索 (Bergstra and Bengio, 2012; Bousquet et al., 2017) 或贝叶斯优化 (Mockus et al., 1978; Snoek et al., 2012) 进行调优。在实践中, 绝大多数时候, 研究者会把一个调优过的基准学习率应用到固定的预热和衰减模板上, 最多调优调度阶段的持续时间, 或尝试少数几个不同的离散函数形式, 具体细节因论文而异。一个有代表性的例子是 Shallue et al. (2019), 他们主要使用线性衰减后接常数阶段的调度 (调优两个调度阶段之间的转折点、基准学习率和最终学习率), 但也报告称尝试了少数其他形状, 包括余弦、指数和“反指数多项式”调度。有些论文为特定形状提出了论证, 甚至包括 Loshchilov and Hutter (2016) 和 Smith (2017) 中的周期性形状, 但它们往往是例外。更常见的是, 研究者假定一种特定形状, 然后更仔细地研究基准学习率。例如, Goyal et al. (2017) 和 Shallue et al. (2019) 都研究了基准学习率可能如何依赖于批量大小, 但没有考察最优调度形状与批量大小之间的任何关系。

当具体谈到调度形状时, 有少数工作试图以不同方式发现表现良好的形状, 这些方式既可以在线下进行, 也可以在训练特定模型的过程中进行。自动化学习率形状优化的尝试包括 AutoLRS (Jin et al., 2021), 它通过带有内置时间序列模型的贝叶斯优化来动态设置学习率值, 以预测短期训练进展。Maclaurin et al. (2015) 提出了一种引人入胜的基于梯度的超参数优化方案, 但除了会面对元优化稳定性和计算成本挑战之外, 他们的方法还要求与特定优化器更新规则进行仔细的协同设计, 并且若要应用于新的优化器 (包括 Adam) 则需要修改。另一种基于梯度的方法是 Hypergradient Descent (Baydin et al., 2017), 它在训练期间在线使用梯度来自适应地更新学习率。Population-Based Training (PBT) (Jaderberg et al., 2017) 通过剪枝和变异一个训练实例群体来演化超参数, 包括学习率, 从而回顾性地揭示对于特定起始权重有效的调度。在训练期间在线发现调度的技术, 可能会找到只在其来源的特定训练轨迹上表现良好的调度, 而不是可复用的、在许多不同初始随机种子或其他训练流水线变异来源上平均表现良好的调度。取决于具体情境, 依赖特定训练轨迹才能有效的调度可能是正面的, 也可能是负面的。

3 方法

就我们的目的而言, 学习率调度是一个函数 $s(t)$, 其中 s 是第 t 步的学习率。我们的目标是在某个参数化的调度函数族内, 找到经验上近似最优的调度, 或者换言之, 在仍然属于该调度族的前提下, 尽可能接近真正的最优调度 s^* 。

在实践中, 学习率调度通常定义为 $s(t) = \alpha \cdot \phi(t/T)$, 其中 α 是基准学习率, T 是训练时长

表 1: 我们实验中使用的学习率调度（形状）族

调度族	简称	描述
Constant	con	预热到基准学习率，随后保持常数学习率。
Cosine	cos-std	预热到基准学习率，随后进行固定指数 = 1 的余弦衰减。
Generalized Cosine	cos-gen	预热到基准学习率，随后进行带参数化指数的余弦衰减。
Square-root Decay	sqrt	预热到基准学习率，随后进行反平方根衰减。
Generalized Rex	rex	预热到基准学习率，随后通过 REX (Chen et al., 2022) 参数化衰减。
Two-Point Spline	tps	预热到基准学习率，随后通过两个样条插值点参数化衰减。
Two-Point Linear	tpl	预热到基准学习率，随后通过两个线性插值点参数化衰减。
Smooth Non-Monotonic	snm	由初始学习率、峰值学习率所在步、两个样条插值点和最终学习率参数化。

(总步数)，而 ϕ 是调度形状¹，即一个从 $[0, 1]$ 到 $[0, 1]$ 的函数。注意，有些调度不依赖训练时长来定义；这里我们不考虑这类调度。

3.1 学习率调度族

为约束学习率调度空间，我们定义了多种学习率调度（形状）族（表 1）。这些是从 $[0, 1]$ 到 $[0, 1]$ 的参数化函数族（详见附录 B.2）。我们的 Constant（con）调度族表示没有任何学习率衰减的形状（但可能带有线性预热）。Cosine（cos-std）调度族表示极为流行的衰减形状，由 $\phi(t/T) = (\cos(\pi f) + 1)/2$ 给出。为了允许更丰富的形状，我们还考虑了 Generalized Cosine（cos-gen）族，它加入了一个可调幂 p ，使得 $\phi(t/T) = [(\cos(\pi f) + 1)/2]^p$ 。我们还研究了一些额外的单调衰减调度，包括 Square-root Decay（sqrt）和 Generalized Rex（rex）调度；这些调度已在 Chen et al. (2022) 中得到研究。我们考虑的最灵活的单调衰减调度是 Two-Point Spline（tps）和 Two-Point Linear（tpl），这是两个新的族，其衰减轮廓使用带有两个控制点的样条插值来定义（不计初始峰值和终点）。

到目前为止提到的所有调度族都还包含线性预热，因为预热在许多训练工作负载和许多不同优化器上都可能有用，尤其是在能够访问更高峰值学习率会带来收益时。为求完整，我们还纳入了 Smooth Non-Monotonic（snm）调度族，它可以表达预热或衰减，但并不保证它们存在。该调度族是一个完全一般的双控制点样条（同样不计峰值或端点），它从可调的非零学习率开始和结束，并在独立于控制点的任意水平位置处拥有峰值。

3.2 工作负载与实验设置

工作负载 我们在三个不同工作负载上评估学习率调度，其中每个工作负载对应一个由数据集、模型和训练目标定义的机器学习任务：

- 线性回归：在具有指定协方差的线性回归问题上最小化均方误差（MSE）。详见附录 A.1。
- 图像分类：在 CIFAR-10 数据集 (Krizhevsky, 2009) 上训练一个小型卷积神经网络（CNN）。

¹我们有时会使用“相对调度”一词来指代调度形状，以区别于实际调度或“绝对”调度。




图 1: 我们实验中使用的学习率调度族: Constant、Cosine、Generalized Cosine、Generalized Rex、Smooth Non-Monotonic、Square-root Decay、Two-Point Spline 和 Two-Point Linear。标记点标识了初始学习率、预热完成、中间控制点和训练结束等关键点。数值注释给出了各个调度特有的参数。与其他调度不同, Smooth Non-Monotonic 的峰值相对于控制点可以出现在任意顺序。

- 小型基于 Transformer 的语言模型: 在 WikiText-103 (Merity et al., 2016) 上训练一个 800 万参数的 Transformer 模型 (Vaswani et al., 2017)。

CNN 和 Transformer 的模型架构细节见附录 B.1。为了实现较高的实验吞吐量, 我们有意选择了小型、计算成本较低的工作负载, 使多次训练运行可以在单个加速器上完成。

优化受限情形与训练设置 给定足够大的步数预算，大多数（适当）有界且合理的调度都会达到相似的最小损失，从而抹平我们感兴趣的、调度形状性能之间的经验差异。即使在较小但仍然很大的训练步数下，我们检测不同调度形状表现差异的能力也会受到限制。此外，研究学习率调度的一个自然目标是通过要求更少步数达到相同损失来训练得更快，因此必须研究训练步数还不太足以获得最佳结果的状态。为了突出更相关的效应并减少这些测量问题，我们有意选择了这样的步数预算：它们提供足够时间让训练目标取得进展，但又没有多到使大多数运行饱和。在这种优化受限情形下训练，使我们能够区分有效调度和无效调度：前者取得更好的训练指标，后者产生更差的训练指标。总训练步数和批量大小为：

- 线性回归：1000 步，批量大小 32。
- CIFAR-10：1000 步，批量大小 256。
- WikiText-103：1600 步，批量大小 512。

这些训练步数预算由初步实验提供依据，确保常数调度表现得相对较差，从而让其他调度能够展示清晰改进。在线性回归实验中，我们使用 SGD。对于 CIFAR-10 和 WikiText-103 实验，除非另有说明，我们使用 AdamW (Kingma and Ba, 2014)，其标准 beta 值为 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$ ，权重衰减为 $\lambda_{WD} = 0$ 。其他超参数设置的细节请见附录 B。

3.3 搜索过程

在高层次上，为了回答关于近似最优调度的问题，我们需要一个过程，用于在任一调度形状族内找到最佳（或最佳之一）的调度形状。我们的搜索过程尝试寻找得分最佳（最低）的调度形状，得分定义如下。令 $L_{\text{train}}^{(r)}(\theta, \alpha, t)$ 表示在使用参数化形状 $\phi_{\theta}(t/T)$ 、基准学习率 α 训练 t 步之后的训练损失，其中 r 表示训练过程中的随机性来源（例如权重初始化或数据顺序）。我们将最优训练损失定义为：

$$\mathcal{J}(\theta, \alpha) := \text{median}_{r \sim \mathcal{R}} \left[\min_{0 \leq t \leq T} L_{\text{train}}^{(r)}(\theta, \alpha, t) \right] \quad (1)$$

其中中位数是在分布 $\mathcal{R}$ 上取得的。通过使用中位数，我们的搜索会偏好那些很可能在具有不同初始权重的多次训练运行中表现良好的调度形状，并倾向于避免任何对特定起点或数据顺序过度特化的调度。最优形状是 $\phi_{\theta^*}(t/T)$ ，其参数通过在所有 θ 和 α 上最小化而给出：

$$\theta^* := \arg \min_{\theta} [\min_{\alpha} \mathcal{J}(\theta, \alpha)]. \quad (2)$$

我们使用下面描述的两步过程来近似 θ^* 。

搜索步骤。 我们的搜索将对调度参数的搜索，与对特定形状的最优基准学习率 α 的搜索解耦。每个学习率调度族的参数都根据附录 B.3 中详述的分布进行随机采样。对于每个参数设置，我们在从 10^{-4} 到 10^{-1} 的对数间隔网格上扫描 16 个基准学习率。对于 CIFAR-10 工作负载，除 Smooth Non-Monotonic 调度族外，我们为每个族生成了 3600 个形状；而对于 Smooth Non-Monotonic 调度族，在某些实验中，我们额外生成了 36000 个形状。对于 WikiText-103 工作负载，计算约束将探索限制在每个族约 600 个形状左右。为了在搜索期间为特定调度打分，我们在 CIFAR-10 上




图 2: 对于线性回归工作负载，通过随机搜索找到的调度捕捉到了理论最优调度的一些特征，但未能完全匹配（左）。平均损失看起来优于理论最优；然而，当用 1000 个种子重新评估时，搜索得到的调度与理论预测一致，并且略差于最优调度（右）。

对每个调度使用 10 个 PRNG 种子，并在 WikiText-103 的初始搜索中对每个调度使用 5 个不同种子。每个形状都用 16 个基准学习率进行评估。总计而言，我们实验中的搜索涉及超过 10^7 次 CIFAR-10 单独训练运行，以及超过 10^6 次 WikiText-103 单独训练运行——这一大规模运行数量得益于我们选择了小型、低成本的工作负载。

评估步骤。 搜索之后，我们对有前景的调度执行了额外一轮评估，以便更好地对它们排序。我们首先取搜索中按中位得分排序的前 k 个调度（CIFAR-10 为 $k = 100$ ，WikiText-103 为 $k = 50$ ），并用 100 个种子重新训练它们（由 10 个不同初始化和 10 个不同数据顺序的所有成对组合构成）。我们再次取中位数作为最终得分，并在需要时使用 DKW 方法 (Dvoretzky et al., 1956) 计算置信区间。

这种由搜索和评估两部分组成的策略，使我们能够将计算资源集中在最有前景的调度上。关于该过程噪声特征的更多细节可见附录 B.4。

实验协议在附录 B 中有详细描述；这里我们概述关键点。

4 结果

4.1 线性回归：带有真值的测试用例

作为对我们实验协议的测试，我们首先在一个采用 MSE 损失的合成线性回归问题上评估搜索方法。在这个设定中（详见附录 A），我们定义数据点数量 D 、训练步数 T ，以及数据协方差谱 S ，它是一个 D 维非负数向量。我们选择 $S_k = \frac{2k}{(D+1)}$ ，在 D 很大的极限下，这对应于一个均匀谱 $U(0, 1)$ ，并且为方便起见归一化为 $\langle S_k^2 \rangle = 1$ （该归一化只影响最优调度的基础学习率）。

这个工作负载的一个优势是，在大 D 极限下，对随机初始化取平均的最终训练损失可以被计算为学习率调度的一个相对简单的函数 (Agarwala and Pennington, 2024; Lee et al., 2022)。通过优化这个函数，我们可以找到使训练结束时平均损失最小的真值最优学习率调度。我们在附录 A.3 中描述了寻找最优调度的数值过程。结果是一个带有衰减、没有预热的最优调度（图 2，左，黑色）。考虑到我们直接优化了每一步的 1000 个单独学习率，并且除了最小化最终训练损失外没有




图 3: 线性回归（左）、CIFAR-10（中）和 WikiText-103（右）中，各族最佳调度的训练指标随基础学习率的变化。每一行对应一个调度族，每一列对应一个学习率，颜色越浅表示性能越好。除在所有情况下都表现更差的 Constant 调度外，基础学习率对成功的影响远大于调度身份。

施加约束，这个调度异常平滑。

我们使用 3600 个调度形状进行随机搜索，并以 100 个种子评估，在所有调度族上执行了搜索流程。得到的调度在形状上与真值最优调度有一些相似之处，预热极少，并衰减到接近零（图 2，左）。这对没有内置衰减的 Smooth Non-Monotonic 调度尤其值得注意。更灵活的调度族比 Constant 族给出了更好的平均最终损失，并且乍看之下似乎具有比理论预测的最优调度更好的指标（图中报告了平均值和标准误）。

然而，用更多种子重新评估表明，真实平均性能比初始选择实验所暗示的更差，并且理论最优学习率调度确实优于所有其他被测试的调度（图 2，右）。各族之间的相对排序仍然相近，但绝对性能比预期略差。我们假设这是选择偏差（我们从 3600 个调度中抽取了最好的调度）与该线性回归问题的最终损失已知服从对数正态分布 (Agarwala and Pennington, 2024) 这两者共同造成的，后者使得刻画偏差更加困难。

我们发现，基础学习率是预测一个（绝对的，而非相对的）调度是否成功的最重要因素（图 3，左）。线性回归工作负载的一个有趣特征是，最佳性能出现在非常接近稳定性边缘的位置。我们在附录 A.4 中进一步分析这一现象；通过研究学习曲线可以看到，最优调度在早期使用较大的学习率，这会在大特征方向上带来短期不稳定，但有助于在小特征方向上取得进展；训练末尾的学习率衰减则用于使大特征模态收敛。

对于线性回归工作负载，我们的随机搜索方法找到了总体表现良好且具有真最优调度某些特征的调度，但实际上没有得到各族中的最佳调度。这一点在 Smooth Non-Monotonic 族上最为清楚。我们通过数值优化找到了最接近真值的 Smooth Non-Monotonic 族成员（图 4，左）。得到的调度只比真最优调度差 $2 \cdot 10^{-5}$ ，远小于随机搜索得到的 $8.5 \cdot 10^{-5}$ 差距（图 4，右）。

总体而言，我们对线性回归工作负载的探索表明：

- 我们的搜索流程可以生成达到接近最优损失值的调度。
- 这些形状捕捉到了最优形状的定性和定量特征，尽管可能并非在每个方面都与真值完全匹配。
- 对更灵活的调度族，验证搜索方法的有效性很重要。

我们在本文余下部分用这些经验指导对 CIFAR-10 和 WikiText-103 工作负载的分析。




图 4: 最佳 Smooth Non-Monotonic 族成员并不匹配最优调度 (左, 蓝色)。我们可以数值求解该族中的最佳拟合曲线 (左, 橙色)。它取得了与理论最优调度非常相近的性能 (右)。




图 5: CIFAR-10 (左) 和 WikiText-103 (右) 的近最优学习率调度。这些曲线表示我们搜索流程中找到的、使最终训练错误率 (CIFAR-10) 或训练困惑度 (WikiText-103) 最小的各族最佳绝对学习率调度。每个工作负载中的所有曲线都呈现相似的预热与衰减模式, 包括并不保证具有这些性质的 Smooth Non-Monotonic 族。更灵活的族优于 Constant 和 Cosine。

4.2 CIFAR-10 和 WikiText-103 工作负载的近最优调度

我们在 CIFAR-10 和 WikiText-103 工作负载上, 对第 3.1 节所述的调度族执行了第 3 节所述的实验协议。这产生了性能优于预热 + 常数和标准余弦两者的近最优调度 (图 5)。我们注意到, WikiText-103 实验的标准误差往往大于 CIFAR-10 实验, 部分原因是使用近最优调度的一定比例训练运行会变得不稳定, 并给出非常大的训练困惑度。

我们注意到以下重要趋势:

基础学习率是得到良好调度的最重要因素。 与线性回归情形非常相似, 一旦某个调度同时具有预热和衰减, 与所使用的具体调度族相比, 基础学习率对于获得良好性能而言是重要得多的因素 (图 3, 针对各族最佳调度绘制)。注意, 与线性回归情形不同, 对于非线性模型, 似乎存在一个大于最优值且不会导致训练发散的非凡学习率范围。对于除 Constant 外的所有族, 额外的调参预算通常更适合用于精调基础学习率, 而不是更细致地调整调度超参数。

预热和单调衰减都至关重要。 对两个工作负载而言, 预热比例都不是微不足道的 (占总训练时间的 10 – 30%), 衰减则占据剩余时间。最引人注目的是, 这对 Smooth Non-Monotonic 调度同样成立; 它并没有内置预热或衰减, 但仍然通过随机搜索“发现”了这些技术。这表明, 预热和单




图 6: CIFAR-10 (左) 和 WikiText-103 (右) 的近最优学习率调度, 依据最佳中位测试错误率 (CIFAR-10) 和测试困惑度 (WikiText-103) 选择。其趋势与依据训练指标选择时相似, 但存在一些定量差异。与按训练错误率选择相比, 按测试错误率选择时, CIFAR-10 更偏好绝对基础学习率较小的训练曲线。为清晰起见, 省略了 `snm` 和 `tpl`。

调衰减并不只是我们在昂贵工作负载中优化调度能力有限的结果, 而是深度学习问题中良好调度的一个基本特征。

事实上, 如果研究者在机器学习研究早期曾对 `snm` 这样的族执行过类似我们的搜索, 他们可能会更早发现预热和衰减。尤其是, 我们的 CIFAR-10 工作负载类似于已经存在了数十年的训练工作负载。

深度学习工作负载的最优调度可能显著不同于线性回归工作负载的最优调度。 我们的线性回归工作负载的最优调度没有预热。此外, 它在训练的大部分时间里采用平坦且较大的学习率, 随后急剧衰减。这与我们的两个深度学习工作负载非常不同, 后者受益于非平凡预热, 并偏好更平缓的衰减。

灵活族提供了小但显著的收益。 对 CIFAR-10, 我们发现更灵活的族通常给出了显著不同于 Cosine 的形状, 并且也取得了更低的训练错误率: 最佳灵活族 (Two-Point Spline、Square-root Decay、Generalized Cosine、Two-Point Linear) 的中位训练错误率达到 0.063–0.064, 相比之下 Cosine 为 0.092 (图 5)。对 WikiText-103, 最优调度形状不同于 Cosine, 中位困惑度更小 (26.6–26.7, 而 Cosine 为 27.2), 尽管较大的标准误使更精确的统计陈述变得困难 (图 5)。

当使用测试指标 (分别为 CIFAR-10 和 WikiText-103 的错误率与困惑度) 选择调度时, 我们发现了类似结果; 在 CIFAR-10 的情况下, 调度形状变异略有增加, 基础学习率更小 (图 6)。

4.3 验证搜索的“近最优”性质

为了使上一节的分析有意义, 我们必须理解: 我们的搜索流程在多大程度上真的获得了近最优调度? 在本节中, 我们提供证据表明, 我们的大多数族确实得到了良好搜索, 并且我们预期即使使用更好的搜索流程, 我们的基本结论仍会成立。

我们已经注意到, 基础学习率是预测学习率调度性能的最重要因素 (图 3); 这也促使我们决定为每个族单独优化基础学习率。最优学习率的分布表明, 我们的网格搜索范围对每种调度形状




图 7: CIFAR-10 (左) 和 WikiText-103 (右) 中, 形状搜索点的最佳基础学习率分布。每条曲线表示一个不同的调度族。分布的支撑大多包含在搜索网格内部, 这表明基础学习率范围选择良好。除 Constant 和 Smooth Non-Monotonic 显著小于其他族外, 各族的最优基础学习率分布相似。




图 8: CIFAR-10 和 WikiText-103 中 Cosine、Two-Point Spline 与 Smooth Non-Monotonic 族的前 3 个调度。对 Cosine, 调度在同一工作负载内非常相似, 这表明 Cosine 得到了良好搜索。对 CIFAR-10, 所有 Two-Point Spline 调度彼此相似; 而对 WikiText-103, 除一个 Two-Point Spline 调度外, 其余都具有相似的预热、基础学习率和衰减。这提供了证据, 说明 Two-Point Spline 通常也得到了良好搜索, 但 WikiText-103 工作负载允许更多种具有相似最终训练指标的学习率调度。Smooth Non-Monotonic 调度显示出高变异性, 表明它们没有被良好搜索。

都选择得恰当 (图 7)。

另一个相关问题是: 调度形状本身有多大意义? 如果随机搜索采样不足, 那么每个族的顶尖形状事实上可能高度可变。对 CIFAR-10, 我们发现顶尖形状实际上相对稳定; 这在各族之间成立 (图 5, 左), 也在同一个族内前 3 个形状之间成立 (图 8, 左, 针对 Cosine 和 Two-Point Spline)。对 WikiText-103 工作负载, 不同族的最佳调度之间变异更大 (图 5, 右), 不过仍有广泛一致性; 族内一致性更强 (图 8, 右, 针对 Cosine 和 Two-Point Spline)。两个工作负载中的例外都是 Smooth Non-Monotonic 族, 它既偏离其他族, 也即使在顶尖调度之间也表现出高族内偏差 (图 8)。

Smooth Non-Monotonic 族优化不足这一点, 可以通过在不同坐标方向上对调度执行线搜索直接看出。对于近最优调度, 扰动任何单个参数都不应带来训练指标改进; 对于非最优调度, 至少一个扰动方向会带来清晰改进。我们在两个工作负载的最佳 Smooth Non-Monotonic 和 Two-Point Spline 调度上执行了这样的搜索。我们每次改变一个调度参数、重新优化基础学习率, 并对每个被搜索坐标使用 100 个种子。我们发现, 对 Smooth Non-Monotonic 调度, 在 CIFAR-10 上有两个坐标 $-\Delta x_2$ 和 y_2 可以通过改变来显著改善最终训练错误率 (图 9 (a))。对 WikiText-103, y_2 也很可能是次优的, y_{start} 可能也是; 由于 WikiText-103 的置信区间更大、可获得的改进更小,

详细分析更为困难（图 9 (b)）。相比之下，对最佳 Two-Point Spline 调度，只有坐标 x_0 可测地次优，而且即便如此，找到的最佳值也落在原始点的 95% CI 内（图 10）。这为我们的最佳 Two-Point Spline 调度有多么“近最优”提供了更定量的洞见，并且直接表明 Smooth Non-Monotonic 调度的优化程度远不如 Two-Point Spline 和其他调度。

正如我们在第 4.1 节在线性回归工作负载语境中讨论的，Smooth Non-Monotonic 族的问题并不来自其表示能力的某种根本限制，而是来自仅用随机搜索优化更高维族的困难。通过绘制训练指标的经验累积分布函数（ECDF），我们可以看出这一点（图 11）。ECDF 在 x 轴上绘制选择分数，在 y 轴上绘制归一化排名；换言之，它是从归一化排名到数据集中该排名分数的函数 $s(r)$ 的逆函数。

对于随机搜索，给定一个真实 CDF 函数 $C(s)$ ，在 k 个随机样本上搜索的预期最佳分数由满足 $C(s^*) = k$ 的 s^* 给出。因此，ECDF 为我们提供了一种估计随机搜索样本效率的方法；高效方法的 ECDF 会在等价归一化排名下达到更低的分数值（高效方法生成的 ECDF 会抵达图的左下方）。我们可以看到，Constant 和 Cosine 的 ECDF 收敛到其他族右侧的一个点；相比之下，Smooth Non-Monotonic 的 ECDF 曲线仍在向左推进（直到最后几个排名仍有非零斜率），但没有达到其他调度的水平。这为搜索样本效率存在问题提供了额外证据。事实上，即使专门将 Smooth Non-Monotonic 的样本数量增加 10 倍，也仍然无法弥合差距（附录 C.2）。

用随机搜索优化 Smooth Non-Monotonic 调度的困难在于，从（接近）零开始预热并衰减到（接近）零学习率，是最佳调度的关键特征。在我们的随机搜索流程中，与这些特征相对应的先验对 Smooth Non-Monotonic 调度而言很小。更好的搜索流程（无论是采用更好先验的随机搜索，还是某种自适应搜索方法）很可能会极大提高我们找到近最优 Smooth Non-Monotonic 调度的能力。

总体而言，我们的结果表明，除 Smooth Non-Monotonic 外，我们所有调度都可以合理地被视为“近最优”。这表明，对于小型工作负载，我们的随机搜索流程可用于合理优化那些自然包含预热和衰减的调度族。

4.4 工作负载变体

在我们的工作负载定义中，我们聚焦于除每一步学习率之外的所有优化器超参数都固定的情形。实践中，这些超参数也可能需要调优，这就提出了一个问题：最优调度形状如何依赖于这些其他训练超参数的精确取值，并且依赖到什么程度？

为回答这个问题，我们进行了一系列实验，在其中独立改变 AdamW 超参数 β_1 、 β_2 ，以及 λ_{WD} （解耦权重衰减参数）。我们聚焦于 Two-Point Spline 族；由于它在灵活性和可搜索性之间取得平衡，它在我们之前的实验中给出了强结果。对于每个超参数，我们选择一组网格取值，由此定义一组实验条件。对于每个条件，我们执行搜索和评估协议，以便为该特定超参数取值选择最佳调度。一般而言，即使最佳形状并不真正依赖于 β_1 ，我们的搜索过程也几乎总会为给定的（比如） β_1 设置返回一个看起来至少略微不同于另一取值所返回形状的“最佳”形状。不过，如果 β_1 对哪些形状表现良好影响很小，那么用 $\beta_1 = 0.8$ 选出的形状，在 $\beta_1 = 0.9$ 下重新评估时，应当与最初用 $\beta_1 = 0.9$ 找到的形状表现一样好。为排除表面上不同的最优形状并未导致可检测训练结果差异的情况，我们在每一个其他条件下重新评估了每个条件中找到的最优形状。

所有实验都在 CIFAR-10 和 WikiText-103 两个工作负载上完成。我们在本节余下部分描述结果。

β_1 , 选择条件	β_1 , 评估条件			
	0.8	0.9	0.95	0.975
0.8	0.07 ± 0.002	0.072 ± 0.002	0.089 ± 0.001	0.123 ± 0.002
0.9	0.068 ± 0.002	0.067 ± 0.001	0.083 ± 0.001	0.116 ± 0.002
0.95	0.066 ± 0.001	0.066 ± 0.001	0.082 ± 0.001	0.114 ± 0.001
0.975	0.068 ± 0.004	0.065 ± 0.001	0.081 ± 0.001	0.11 ± 0.001

表 2: 对于调度选择（行）和评估（列）中使用的每一对 β_1 取值，给出带一个标准差的 CIFAR-10 训练错误率中位数。搜索阶段中更大的 β_1 会降低错误率。当在 $\beta_1 = 0.95$ 下找到的调度以 $\beta_1 = 0.8$ 运行时，出现最低错误率。在大多数行中，评估时更低的 β_1 会进一步降低错误率，这表明在高动量搜索之后降低动量可以改善性能。

β_1 , 选择条件	β_1 , 评估条件			
	0.8	0.9	0.95	0.975
0.8	28.8 ± 0.96	28.2 ± 0.09	33.04 ± 0.06	46.67 ± 0.59
0.9	37.58 ± 1.91	27.01 ± 0.92	27.11 ± 0.02	30.97 ± 0.06
0.95	39.27 ± 1.85	26.99 ± 1.02	26.91 ± 0.04	30.51 ± 0.04
0.975	40.61 ± 4.09	26.92 ± 0.92	26.91 ± 0.08	30.47 ± 0.07

表 3: 对于调度选择（行）和评估（列）中使用的每一对 β_1 取值，给出 WikiText-103 训练困惑度中位数和一个标准差。行列出指导搜索的 β_1 ；列给出用于运行调度的 β_1 。搜索阶段中更高的 β_1 会降低困惑度，但在 $\beta_1 = 0.975$ 下选择是例外，它产生更大的取值。当在 $\beta_1 = 0.95$ 或 0.975 下找到的调度以 $\beta_1 = 0.95$ 运行时，出现最佳结果。在 $\beta_1 = 0.8$ 下评估显示出最宽的离散范围，这指向低动量运行中的高不确定性。

改变 AdamW 的 β_1 和 β_2 。 在我们的 CIFAR-10 实验中改变 β_1 和 β_2 时，我们只发现了很小的最优形状变化（图 12，左列）。在 WikiText-103 中，似乎存在一些小变化；较大的 β_1 似乎偏好更晚的衰减，而较大的 β_2 似乎偏好更早的衰减（图 12，右列）。从 β_1 的重新评估实验看，我们看到只有 WikiText-103 中的 $\beta_1 = 0.8$ 为它与学习率调度之间的关系提供了有说服力的证据（表 2 和 3）。在两种情况下，更小的 β_1 都达到了更低的训练损失。相比之下，对于 β_2 ，我们的实验没有提供任何有说服力的证据表明 β_2 的取值会显著影响哪些调度形状表现良好，无论在哪种设置中都是如此。

改变 λ_{WD} 。 有趣的是，改变（解耦）权重衰减强度揭示了 λ_{WD} 和学习率调度之间的强关系。在两个工作负载中，增大权重衰减都会偏好更晚衰减的调度（图 13）。我们的重新评估实验通常表明，针对某个特定 λ_{WD} 取值选择的调度往往对该特定取值是最优的（表 6 和 7），如果改变权重衰减强度确实改变了哪些调度形状表现良好，这也符合我们的预期。注意，在我们搜索过的条件

β_2 , 选择条件	β_2 , 评估条件			
	0.9	0.99	0.999	0.9995
0.9	0.061 ± 0.001	0.062 ± 0.001	0.07 ± 0.001	0.072 ± 0.001
0.99	0.062 ± 0.001	0.062 ± 0.001	0.066 ± 0.001	0.068 ± 0.001
0.999	0.064 ± 0.002	0.064 ± 0.001	0.072 ± 0.002	0.07 ± 0.002
0.9995	0.058 ± 0.001	0.059 ± 0.001	0.066 ± 0.001	0.065 ± 0.001

表 4: 对于调度选择（行）和评估（列）中每一对 β_2 取值，给出 CIFAR-10 训练错误率中位数 $\pm$ 标准差。行列出用于挑选调度的 β_2 ；列给出用于运行该调度的取值。选择时更高的 β_2 往往会削减错误率，不过最低错误率来自在 $\beta_2 = 0.9995$ 下调优、并以 $\beta_2 = 0.9$ 运行的调度。

β_2 , 选择条件	β_2 , 评估条件			
	0.9	0.99	0.999	0.9995
0.9	26.23 ± 0.02	26.4 ± 0.29	26.87 ± 6.03	26.77 ± 11.37
0.99	26.32 ± 0.01	26.29 ± 0.35	26.59 ± 0.85	26.71 ± 2.26
0.999	26.32 ± 0.01	26.56 ± 0.38	26.74 ± 1.42	26.76 ± 1.21
0.9995	26.36 ± 0.01	26.42 ± 0.27	26.75 ± 2.11	26.74 ± 2.77

表 5: 对于调度选择（行）和评估（列）中使用的每一对 β_2 取值，给出 WikiText-103 困惑度中位数 $\pm$ 标准差。选择时更高的 β_2 会降低中位数，不过最佳结果出现在以 $\beta_2 = 0.9995$ 调优的调度以 $\beta_2 = 0.9$ 运行时。在 $\beta_2 = 0.9$ 下选择显示出最宽的离散范围，确认了调优期间低 β_2 会增加噪声。

中， $\lambda_{WD} = 0$ 给出了总体最佳性能（这也符合我们的预期，因为我们比较的是训练指标，而不是验证或测试指标）。


改变训练时域。 对于 WikiText-103 工作负载，我们改变了训练时域，即训练总步数 T ，分别用于 Generalized Cosine 和 Two-Point Spline 调度。所有设置中的基础学习率都相似，对应于我们搜索网格中两个相邻取值，并没有清晰模式。将调度形状相对于训练步数比例作图，揭示出训练步数越多，衰减越平缓的趋势（图 14）。我们还看到预热比例似乎在不同训练时域下保持稳定，这表明设置预热比例可能比搜索/固定预热步数更稳健。在 CIFAR-10 上，训练时域实验要无趣得多，因为即使比我们的实验训练稍长一点，训练错误率也会很快饱和到零错误，从而很难保持在优化受限机制中或学到很多东西。

λ_{WD} , 选择条件	λ_{WD} , 评估条件			
	0.0	0.001	0.01	0.1
0.0	0.071 ± 0.001	0.127 ± 0.003	0.532 ± 0.004	0.9 ± 0.0
0.001	0.067 ± 0.001	0.123 ± 0.002	0.477 ± 0.003	0.9 ± 0.0
0.01	0.101 ± 0.001	0.149 ± 0.001	0.406 ± 0.004	0.9 ± 0.002
0.1	0.109 ± 0.001	0.164 ± 0.001	0.415 ± 0.002	0.839 ± 0.004


表 6: 对于调度选择（行）和后续评估（列）中使用的每一对权重衰减取值，给出 CIFAR-10 训练错误率中位数 $\pm$ 标准差。0.01 或 0.1 的评估衰减会提高所有行中的错误率，而衰减 0 或 0.001 给出最低取值。

λ_{WD} , 选择条件	λ_{WD} , 评估条件			
	0.0	0.001	0.01	0.1
0.0	26.75 ± 1.14	29.2 ± 0.78	122.39 ± 15.95	5336.9 ± 21.36
0.001	27.08 ± 0.72	27.05 ± 0.35	101.69 ± 12.31	4169.88 ± 43.03
0.01	27.8 ± 0.08	27.61 ± 0.06	69.48 ± 4.34	443.55 ± 21.18
0.1	29.16 ± 0.79	30.93 ± 3.52	165.99 ± 33.78	392.74 ± 10.19

表 7: 对于调度选择（行）和后续评估（列）中使用的每一对权重衰减取值，给出 WikiText-103 训练困惑度中位数 $\pm$ 标准差。搜索阶段中较低的衰减给出更小的中位数。评估时，衰减 0 或 0.001 会压低困惑度，而 0.01 或 0.1 会将其推高。



(a) CIFAR-10



(b) WikiText-103

图 9: 从 CIFAR-10 (上 3 行) 和 WikiText-103 (下 3 行) 的最优 Smooth Non-Monotonic 调度形状出发进行逐坐标线搜索。对每个坐标, 我们改变该坐标并重新测量相应的训练指标 (蓝色, 绘制 95% CI), 同时重新优化基础学习率 (橙色为最佳基础 LR)。绿色虚线标记搜索所得该坐标的原始值。改变某些坐标, 特别是 y_2 , 可以显著改善训练指标, 表明 Smooth Non-Monotonic 没有得到良好优化。




图 10: Two-Point Spline 调度的逐坐标线搜索。方法和标注与图 9 相同。线搜索带来的收益通常小于测量不确定性,表明 Two-Point Spline 在我们的实验分辨率下已经得到良好优化 — 不同于 Smooth Non-Monotonic

o




图 11: 各学习率调度族内随机搜索达到的分数的 ECDF (经验累积分布函数)。横轴报告 CIFAR-10 的中位训练错误率或 WikiText-103 的中位训练困惑度, 数值越低表示学习效果越好。纵轴显示达到或超过每个分数的机会。在 CIFAR-10 上, 常数调度和指数为 1.0 的余弦调度以高概率降低错误率, 但在约 0.05 处停滞。Square-root Decay 调度使曲线最明显地向左移动。Two-Point Spline、Two-Point Linear 和 Generalized Cosine 描绘出相似路径。Generalized Rex 和 Smooth Non-Monotonic 在较低 CDF 概率 (或者说, 更多样本之后) 达到更低分数。尤其是 Smooth Non-Monotonic 由于其大参数空间拖慢搜索而落后。




图 12: 改变 β_1 和 β_2 时的最优形状 | 在调优 β_1 和 β_2 后使损失最小的相对学习率调度。上排改变 β_1 ，下排改变 β_2 。左侧图使用 CIFAR-10，右侧图使用 WikiText-103。较低的 β_1 取值给出较短的预热和短暂的高学习率平台，而较高的 β_1 取值会延长二者。在 CIFAR-10 上，较大的 β_2 取值也会延长预热，而在 WikiText-103 上， β_2 与调度形状没有清晰联系。




图 13: 改变权重衰减时的最优形状 | 在调优权重衰减后产生最低损失的相对学习率调度。左图显示 CIFAR-10；右图显示 WikiText-103。较小的衰减取值会拉长预热，而较大的衰减取值会让学习率一直保持较高，直到训练最后几步。两个任务呈现相同模式。




图 14: WikiText-103 工作负载在不同训练时域下训练时，Generalized Cosine（左）和 Two-Point Spline（右）的最优学习率形状。更多步数会改善性能，这偏好更稳定的衰减。预热比例在这一尺度下保持一致。

5 讨论

5.1 关于搜索方法的经验教训

我们的搜索方法被设计得很简单，但它并不是特别高效。关键的是，搜索总是在有更多种子和更多搜索点时表现更好。我们在实验中做出的选择总体上似乎能产生貌似接近最优的调度。对于 CIFAR-10，我们的随机搜索过程在实验的小尺度上似乎已经足够；在 WikiText-103 上，我们通常也能够得出结论，但变异性更大——部分原因是种子和搜索点数量减少，部分原因是具有良好中位最终训练困惑度的训练运行在稳定性上方差增大。

我们的结果（例如图 3 中展示的结果）验证了我们为每个调度形状分别优化基础学习率的选择。通过为每个形状调优基础学习率，我们把形状效应从强基础学习率效应中隔离出来（这些效应可能通过长时间保持接近峰值的形状而隐式出现）。随机搜索的效率显然可以用多种方式改进，但我们甚至还没有真正优化计算资源在搜索点、种子和评估之间的分配，更不用说探索更复杂的搜索策略了。

虽然总体上足够，但对于 Smooth Non-Monotonic 族（它最灵活但相应地难以搜索），我们的搜索过程并没有达到所需的有效程度。部分原因在于预热和衰减似乎是任何成功学习率调度不可或缺的组成部分；具有这些属性的调度只构成 Smooth Non-Monotonic 族配置空间中的一小部分。

搜索更灵活的族（也许甚至比 Smooth Non-Monotonic 族更灵活）可能会受益于改进的技术。随机搜索可以用更好的先验来增强，或者可以使用纳入反馈的多轮搜索，例如贝叶斯优化或进化算法。这些方法也可以提高那些更容易搜索的族中的搜索效率，这对于更昂贵的工作负载可能具有实践意义。不过，虽然更高效，这类技术可能会使结果更难解释，因为它们可能根据具体细节，对搜索空间的不同部分引入误导性的偏置。

尽管我们把搜索方法应用到了学习率调度，大多数优化器还包含其他可能受益于调度的标量超参数。最明显的是动量 (Ferbach et al., 2025; Lee et al., 2022)，但 Adam β_2 和 λ_{WD} 也可能从调度中受益。我们工作的一个自然扩展，是也在这些其他参数上搜索灵活调度族。

5.2 实践要点

我们工作中最重要且有些显然的要点是：如果不优化基础学习率，试图优化调度形状并没有太大意义。任何试图搜索或调优调度形状的人，都应确保把足够资源投入到基础学习率调优中。此外，在尝试某种新的学习率调度族时，必须重新调优基础学习率，以尽量减少假阴性结果。

我们的结果确认，从高层看，先预热后单调衰减这一常见实践确实是一种始终有效的策略。Smooth Non-Monotonic 族并不保证包含这两个阶段，但其中最好的成员表现出了这些特征。这个结果表明，在深度学习历史上，对近最优学习率调度的搜索本可以更早揭示这些经验法则。

据我们所知，我们对线性回归工作负载的分析代表了该类别中一个非平凡高维问题的第一个最优调度。有趣的是，线性回归的最优调度相对“平滑”，尽管优化过程并没有诱导这种约束；每一步的 1000 个学习率都被逐一优化。该调度偏好没有预热，以及一个相对平坦、在训练结束时急

剧衰减的调度。线性回归中最优调度的形状依赖于训练时域，也依赖于数据协方差的谱。我们假设，改变这些选择可能会改变衰减轮廓，但不应让预热突然变得有用。

有趣的是，CIFAR-10 和 WikiText-103 的最优调度与线性回归工作负载的最优调度非常不同，也就是说，在不同族、工作负载和工作负载变体中，预热都是有用的。比较我们在线性回归和神经网络训练上的结果表明，当把来自凸优化研究的原则应用到深度学习优化中的非凸、非线性设置时，必须极其谨慎，尤其是在试图理解早期和中期训练的有用原则时。

我们在 CIFAR-10 和 WikiText-103 上的结果表明，如果有调优资源，确实值得考虑流行的余弦衰减调度之外的调度。改变衰减形状的能力在训练集和测试集指标上都带来了收益。在我们的工作负载中，这些收益往往较小但显著。

各种更灵活族之间，以及每个族的顶尖成员之间，最终训练指标的差异似乎很小。这个结果表明，搜索更加灵活的调度族可能并不值得。即使是比 Cosine 多一个参数的 Generalized Cosine 族，也在 CIFAR-10 情形中捕捉到了显著收益。另一个比 Cosine 更流行且稍稍更一般的余弦族使用非零最终学习率 (`cos-std`)。当这个最终学习率被充分调优时，我们相对于 `cos-std` 看到了一些收益，但结果仍然不如 `cos-gen` (附录 C.1)。如果计算资源更加充足，那么 Two-Point Linear 或 Two-Point Spline 族可能已经有足够多的灵活性来捕捉非常接近最优的调度。

我们寻找近最优调度的能力可能对自动学习率选择器研究有用。通过在训练期间测量不同量，我们可以期望把（已知的）最优学习率调度预测为这些量的函数。这可能涉及一些简单测量，例如损失轨迹、梯度范数，或可以在训练期间低成本测得的简单海森矩阵统计量。在线性回归设置中，我们还可以做得更好，因为我们可以求解最优调度，并解析地计算这些量中的许多。

我们结论的普遍性主要受限于工作负载数量较少。把我们的方法应用到更多种类的工作负载上，将为最优调度形状的哪些特征具有一般性、哪些特征具有特异性提供更多证据。尽管如此，即便这项初步研究也已经澄清了一些谜团，并给出了通向更好理解学习率调度的路径。

致谢

我们感谢 Shankar Krishnan、Sourabh Medapati、Dougal Maclaurin 和 Vincent Roulet 围绕方法进行讨论、支持实验，并对手稿提供详细反馈。

参考文献

- A. Agarwala and J. Pennington. High dimensional analysis reveals conservative sharpening and a stochastic edge of stability. *arXiv preprint arXiv:2404.19261*, 2024.
- A. G. Baydin, R. Cornish, D. M. Rubio, M. Schmidt, and F. Wood. Online learning rate adaptation with hypergradient descent. *arXiv preprint arXiv:1703.04782*, 2017.
- Y. Bengio. Practical recommendations for gradient-based training of deep architectures. In *Neural Networks: Tricks of the Trade: Second Edition*, pages 437–478. Springer, 2012.

- J. Bergstra and Y. Bengio. Random search for hyper-parameter optimization. *The journal of machine learning research*, 13(1):281–305, 2012.
- O. Bousquet, S. Gelly, K. Kurach, O. Teytaud, and D. Vincent. Critical hyper-parameters: No random, no cry, 2017. URL <https://arxiv.org/abs/1706.03200>.
- J. Chen, C. Wolfe, and T. Kyrillidis. Rex: Revisiting budgeted training with an improved schedule. *Proceedings of Machine Learning and Systems*, 4:64–76, 2022.
- J. M. Cohen, B. Ghorbani, S. Krishnan, N. Agarwal, S. Medapati, M. Badura, D. Suo, D. Cardoze, Z. Nado, G. E. Dahl, and J. Gilmer. Adaptive gradient methods at the edge of stability, 2022. URL <https://arxiv.org/abs/2207.14484>.
- J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.
- A. Dvoretzky, J. Kiefer, and J. Wolfowitz. Asymptotic Minimax Character of the Sample Distribution Function and of the Classical Multinomial Estimator. *The Annals of Mathematical Statistics*, 27(3):642 – 669, 1956. doi: 10.1214/aoms/1177728174. URL <https://doi.org/10.1214/aoms/1177728174>.
- D. Ferbach, K. Everett, G. Gidel, E. Paquette, and C. Paquette. Dimension-adapted momentum outpaces sgd. *arXiv preprint arXiv:2505.16098*, 2025.
- J. Gilmer, B. Ghorbani, A. Garg, S. Kudugunta, B. Neyshabur, D. Cardoze, G. Dahl, Z. Nado, and O. Firat. A loss curvature perspective on training instability in deep learning. *arXiv preprint arXiv:2110.04369*, 2021.
- P. Goyal, P. Dollár, R. Girshick, P. Noordhuis, L. Wesolowski, A. Kyrola, A. Tulloch, Y. Jia, and K. He. Accurate, large minibatch sgd: Training imagenet in 1 hour. *arXiv preprint arXiv:1706.02677*, 2017.
- J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. d. L. Casas, L. A. Hendricks, J. Welbl, A. Clark, et al. Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*, 2022.
- M. Jaderberg, V. Dalibard, S. Osindero, W. M. Czarnecki, J. Donahue, A. Razavi, O. Vinyals, T. Green, I. Dunning, K. Simonyan, et al. Population based training of neural networks. *arXiv preprint arXiv:1711.09846*, 2017.
- Y. Jin, T. Zhou, L. Zhao, Y. Zhu, C. Guo, M. Canini, and A. Krishnamurthy. Autolrs: Automatic learning-rate schedule by bayesian optimization on the fly. *arXiv preprint arXiv:2105.10762*, 2021.

- D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- A. Krizhevsky. Learning multiple layers of features from tiny images. 2009.
- K. Lee, A. Cheng, E. Paquette, and C. Paquette. Trajectory of mini-batch momentum: Batch size saturation and convergence in high dimensions. *Advances in Neural Information Processing Systems*, 35:36944–36957, 2022.
- I. Loshchilov and F. Hutter. SGDR: Stochastic gradient descent with warm restarts. *arXiv preprint arXiv:1608.03983*, 2016.
- D. Maclaurin, D. Duvenaud, and R. Adams. Gradient-based hyperparameter optimization through reversible learning. In *International conference on machine learning*, pages 2113–2122. PMLR, 2015.
- S. Merity, C. Xiong, J. Bradbury, and R. Socher. Pointer sentinel mixture models, 2016.
- J. Mockus, V. Tiešis, and A. Žilinskas. The application of Bayesian methods for seeking the extremum. *Towards Global Optimization*, 2(117-129):2, 1978.
- S. Qiu, L. Xiao, A. G. Wilson, J. Pennington, and A. Agarwala. Scaling collapse reveals universal dynamics in compute-optimally trained neural networks. *arXiv preprint arXiv:2507.02119*, 2025.
- C. J. Shallue, J. Lee, J. Antognini, J. Sohl-Dickstein, R. Frostig, and G. E. Dahl. Measuring the effects of data parallelism on neural network training. *Journal of Machine Learning Research*, 20(112):1–49, 2019. URL <http://jmlr.org/papers/v20/18-789.html>.
- L. N. Smith. Cyclical learning rates for training neural networks. In *2017 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 464–472, 2017. doi: 10.1109/WACV.2017.58.
- J. Snoek, H. Larochelle, and R. P. Adams. Practical bayesian optimization of machine learning algorithms. *Advances in neural information processing systems*, 25, 2012.
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

附录

A 线性回归工作负载细节

A.1 工作负载定义

线性回归工作负载由一个作用在 P 维参数向量 θ 上的线性模型构成，该模型在 D 个数据点上按照如下损失函数进行优化：

$$\mathcal{L}(\theta) = \frac{1}{2D} \|z\|^2, \quad z \equiv J\theta - y_{tr} \quad (3)$$

这里， J 是 $D \times P$ 维雅可比矩阵， y_{tr} 是 D 个目标。

我们使用带学习率调度 α_t 的 SGD 训练该模型，每一步都从 D 个数据点中独立地随机采样 B 个数据点。动力学方程可写为

$$\theta_{t+1} - \theta_t = -\frac{\alpha_t}{B} J^T P_t z_t. \quad (4)$$

这里， P_t 是一列随机、独立同分布的对角矩阵，其对角线上恰有 B 个随机的 1，其他位置均为 0，用来表示采样过程。

该模型的动力学可以只用残差 z 表示：

$$z_{t+1} - z_t = -\frac{\alpha_t}{B} \hat{\Theta} P_t z_t. \quad (5)$$

其中 $\hat{\Theta} = JJ^T$ 是经验神经切线核。

这就是我们直接模拟的动力学。我们将 z_t 初始化为一个独立同分布随机向量，其元素从 $\mathcal{N}(0, 1)$ 抽取。我们使用固定的对角矩阵 Λ 和均匀采样的 $D \times D$ 正交矩阵 U 来初始化 $\hat{\Theta}$ ：

$$\hat{\Theta} = U\Lambda U^T \quad (6)$$

我们在 Λ 上使用均匀分布，其特征值由 $\lambda_k = 2k/(D+1)$ 给出，其中 k 从 1 到 D 。这保证了 $\hat{\Theta}$ 的平均特征值为 1。在所有模拟中，我们设定 $D = 500$ ，并训练 1000 步。

A.2 高维极限中的平均损失曲线

在较大 D 的极限下，上述线性回归问题的损失曲线会集中到其平均值附近 (Lee et al., 2022)。该平均值可通过跟踪 $\hat{\Theta}$ 每个特征模态中的方差动力学来描述 (Agarwala and Pennington, 2024)。我们定义：

$$p_t = \text{diag}(U^T E[z_t z_t^T] U) \quad (7)$$

其中期望是对初始化随机性和采样随机性取的。

在高维极限下， p 的动力学由如下 D 维线性递推关系描述：

$$p_{t+1} - p_t = \left[(I - \alpha_t \Lambda)^2 - I + \frac{1}{D} (\beta^{-1} - 1) \alpha_t^2 \Lambda 11^T \Lambda \right] p_t \quad (8)$$

其中 $\beta = B/D$ 。平均损失可写为

$$\mathcal{L}(\mathbf{p}) = \frac{1}{2D} \mathbf{1}^T \mathbf{\Lambda} \mathbf{p}. \quad (9)$$

结合公式 8 和 9 可知，损失可以写成学习率调度的解析函数。这使我们能够使用标准优化技术，在给定 $\mathbf{\Lambda}$ 、批大小 B 和步数 T 的情况下寻找最优学习率调度。

A.3 调度下降

一般而言，对于非平凡的 $\mathbf{\Lambda}$ ，最优学习率调度没有解析解。在某个极限下，公式 8 可以用一个 ODE 近似，从而得到一个变分法问题，用于优化学习率调度，使其在某个固定步数之后的损失最低。然而，当 $\mathbf{\Lambda}$ 有不只一个唯一特征值时，这个问题是不可处理的。

作为替代，我们可以通过公式 8 和 9，用梯度下降直接优化调度。更明确地说， $\mathbf{p}_T$ 是 T 维向量 α_t 的函数，该向量的元素是每一步 t 的学习率。公式 8 意味着 T 步之后的损失可以写为 $\mathcal{L}(\{\alpha_t\})$ ，即一个神经网络输出的损失函数，而该网络的各层都是 α_t 的二次函数。这意味着可以使用深度学习标准机制对 α_t 进行微分，从而对 $\mathcal{L}(\{\alpha_t\})$ 做基于梯度的最小化。

我们按如下方式执行了一个调度空间梯度下降（简称调度下降）算法。我们首先通过对数间隔的网格搜索，找到一个较好的常数调度 $\alpha_t = C$ 作为初始化。

随后，我们在目标 $\log(\mathcal{L}(\mathbf{p}_T(\{\alpha_t\})))$ 上使用常数学习率调度执行标准梯度下降。我们发现，优化 $\log(\mathcal{L})$ 能显著加速收敛，而不需要为调度下降使用（元）学习率调度。我们还向调度下降加入了一条额外更新规则：如果最终损失高于某个阈值（在我们的设置中为 10），那么优化器不会执行梯度下降步，而是将所有学习率统一乘以 0.3。这有助于我们处理如下事实：最优调度往往接近会导致训练发散的调度；一旦到达这种状态，就无法从当前调度获得梯度信号。

我们发现，调度的演化通常是平滑的（图 15）。末端的衰减很快形成，这也使中位基准学习率能够提高。损失仅需约 300 步就不再出现显著变化，调度形状也随之收敛。一个值得注意的特征是，尽管 1000 个离散学习率是在没有限制的情况下同时优化的，调度看起来仍然相对平滑。我们只在常数初始条件中强制了“平滑性”。

我们在线性回归研究中将搜索得到的调度作为最优调度；正如我们在正文中所展示的，在我们研究的所有调度中，它确实具有最低的平均损失。

A.4 来自随机搜索的损失曲线

通过我们在各个族中的搜索得到的调度，其损失曲线有一个有趣特征：许多最优调度会产生非单调的损失曲线（图 16）。这说明许多好的调度会暂时超过稳定性边缘，也就是说，它们使用的学习率大于最大的收敛常数学习率。这可能是有益的，因为超过稳定性边缘有助于优化器在较小特征模态上取得更多进展。

只要较大的特征模态不会不稳定太久，它们就可以在学习率衰减阶段收敛，此时学习率会降到稳定性边缘以下。在这里，这些大特征模态比小特征模态收敛得更快，因此目标上的进展不会




图 15: 线性回归工作负载上调度下降优化器的进展。每条曲线表示在优化最终训练点 $T = 1000$ 处损失的不同步骤中，调度所处的状态。第一步会找到一个较好的常数学习率调度；之后，算法运行标准梯度下降，并在调度导致训练发散时使用后备机制。最终损失以及对应的调度似乎在约 300 步后收敛。调度由一个 T 维离散学习率向量表示，除了初始条件之外并未强制连续性。

受到短暂进入不稳定区域的损害。这类似于在非凸设置中，训练的相当一部分时间里，大特征方向上存在稳定的高频振荡这一事实 (Cohen et al., 2022)。

线性回归工作负载的一个有趣特征是，它不偏好预热。这提供了另一条证据，说明预热确实是由于深度学习工作负载中的非凸性和曲率动力学而有用的特征 (Gilmer et al., 2021)，而不能仅用凸性推理来解释。

A.5 理论与实验比较

鉴于公式 8 表示线性回归问题动力学的高维极限，我们可以问：这在对平均行为的反映有多好？为了验证我们的方法，我们通过将每个族中最优调度的学习轨迹在 1000 个种子上取平均，并与不同调度损失的理论预测进行比较来回答这一问题 (图 16)。对于所有调度，理论与经验平均值之间都有很好的一致性。对于最大学习率较小的调度 (例如常数调度或 `cos-gen`)，整个轨迹上的匹配都很好。

然而，更好的调度会在稳定性边缘处甚至略高于稳定性边缘处停留一段时间，并且在中间时间与理论的一致性较差。例如，理论捕捉到了损失曲线的非单调性，但在中间时间存在定量差异。不过，这些差异会在后期消失。我们推测，对于这些轨迹，有少数特征方向 (对应最大的几个特征值) 主导了轨迹的这些部分，从而导致应用该理论完整高维版本所需的一些假设失效。确实，公式 9 有一个更一般的版本，它在有限维度下是精确的，但由于包含 D^2 个耦合线性方程，无法实际模拟和优化 (Agarwala and Pennington, 2024)。

这些差异会在后期消失，是因为学习率衰减会使大特征值收敛到接近零的值；相比之下，小特征值在后期主导损失 (其动力学非常适合高维近似)。我们相信，模拟完整系统 (这需要分析一个 $D^2 \times D^2$ 矩阵) 只会使最优调度形状产生极其细微的差异，而这些差异都不会影响我们的结论。我们将有限尺寸偏差的详细分析留给未来工作。




图 16: 线性回归工作负载的训练损失曲线。在对 1000 个种子取平均时, 理论很好地预测了早期和后期行为, 但在动力学接近/高于稳定性边缘且损失曲线可能变得非单调的中间时间, 表现出一些系统性偏差。

A.6 用 Smooth Non-Monotonic 族匹配最优调度

在图 4 中, 我们找到了 `snm` 族中的一个成员, 它最接近由调度下降得到的最优学习率调度。我们通过优化该 `snm` 族成员的参数, 使调度取值之间的 MSE 损失最小, 从而找到这个成员。

由于我们的 `snm` 实现使用的是基于 Numpy 的代码, 不容易转换成可微的 JAX 形式, 我们最终用采样实现了一种近似的 GD 算法。我们执行离散坐标下降, 每次对一个参数做小幅改动, 以此给出对梯度的离散近似。

就最小化其到最优调度的 L^2 距离而言, 该 Smooth Non-Monotonic 成员很可能仍有小幅改进空间; 然而, 关键结论仍然成立: 存在一些 Smooth Non-Monotonic 族成员能够更接近地逼近最优调度。事实上, 甚至并不清楚最小化到最优调度的 L^2 距离是否就是使损失最小的做法; 尽管如此, 这个新的 Smooth Non-Monotonic 成员的损失显著低于通过我们的搜索流程找到的调度, 并且在数值上接近最优调度的性能。

B 实验细节

在本节中,我们描述模型架构细节,以及每个调度族如何参数化本研究所用调度的形状。完整实现细节可见于 <https://github.com/google/init2winit/tree/master/init2winit/projects/optlrschedule>。

B.1 模型架构

表 8 中的 CNN 架构面向 CIFAR-10 分类任务。它从一个包含 32 个滤波器 (3x3) 的卷积层开始,随后接 ReLU 和最大池化操作。第二个卷积层使用 64 个滤波器 (3x3), 同样使用 ReLU 和最大池化。池化后,输出被展平,并由一个包含 256 个单元、采用 ReLU 激活的全连接层处理。最后一个全连接层随后输出对应于 10 个 CIFAR-10 类别的 logits。

表 8: 用于 CIFAR-10 分类的 CNN 模型的详细架构。该模型包含两个卷积块, 每个卷积块后接 ReLU 激活和最大池化, 以及两个全连接层。

层	细节	输出形状
输入	图像 ($32 \times 32 \times 3$)	(32, 32, 3)
Conv2D	32 个滤波器, 卷积核大小 = (3, 3), 步幅 = 1	(30, 30, 32)
激活	ReLU	(30, 30, 32)
最大池化	窗口大小 = (2, 2), 步幅 = 2	(15, 15, 32)
Conv2D	64 个滤波器, 卷积核大小 = (3, 3), 步幅 = 1	(13, 13, 64)
激活	ReLU	(13, 13, 64)
最大池化	窗口大小 = (2, 2), 步幅 = 2	(6, 6, 64)
展平	将特征图展平为向量	(2304)
全连接层	全连接, 256 个单元	(256)
激活	ReLU	(256)
全连接层	全连接, 10 个单元 (logits)	(10)

表 9 总结了应用于 WikiText-103 的 Transformer 模型架构。它由一叠标准的解码器式 Transformer 块组成。每个块都包含多头自注意力、层归一化和前馈层。输入处使用词元嵌入和位置嵌入, 最终预测则通过到词表维度的线性投影完成。

B.2 调度族

图 1 展示了来自每个调度族的代表性参数化方式。

Smooth Non-Monotonic 族提供最高程度的灵活性, 用七个参数来参数化调度形状。它不在学习率调度的开头或结尾施加显式约束, 也不要求预热期或衰减期。

表 9: 用于 WikiText-103 训练的 Transformer 语言模型架构。该模型遵循标准的仅解码器 Transformer 结构，包含多个自注意力层和前馈层。

层类型	配置	输出形状
输入嵌入	词元与位置嵌入	(batch, 128, 256)
Transformer 块 (重复 N 次)		
多头自注意力	h 个头, 每个头具有 d_k 、 d_v	(batch, 128, 256)
LayerNorm + 残差	预归一化	(batch, 128, 256)
前馈网络	两个带激活的线性层	(batch, 128, 256)
LayerNorm + 残差	预归一化	(batch, 128, 256)
输出投影	到词表大小的线性层	(batch, 128, 10,000)

Two-Point Spline 和 Two-Point Linear 族各自由五个参数定义，并施加线性预热约束。Two-Point Spline 调度在预热期之后依赖样条插值，而 Two-Point Linear 使用线性插值。

Generalized Cosine 族探索 Cosine 内部的指数参数，同时也包含线性预热期。Cosine 将指数固定为 1，只改变预热时长。Generalized Rex 探索 REX 调度 (Chen et al., 2022) 中 beta 参数的变化。最后，Square-root Decay 调度对学习率应用平方根衰减。

B.3 超参数搜索空间

本节描述与每个调度族和工作负载相关的超参数搜索空间。

对于基础学习率，线性回归实验使用来自 $[0.01, 1.0]$ 的 16 个均匀对数间隔取值；所有其他实验使用来自 $[0.001, 0.1]$ 的 16 个均匀对数间隔取值。所有实验都使用 AdamW 作为优化器。除非另有说明，权重衰减设为 0。第 4.4 节详细描述了消融研究。

对于每个调度族，超参数及其相应搜索范围见表 10。

B.4 CIFAR-10 测量的噪声特征

为了选择在我们的搜索和评估协议中使用的种子数量，我们使用 Two-Point Spline 调度族进行了初步实验。这使我们能够在一个参数数量较多的调度族上进行测试。我们使用两组独立的 100 个种子进行训练，并将其中一组的训练误差中位数作为参考。然后，我们将该参考值与使用第二组种子的子集计算出的中位数进行比较，即 1、3、10 和 100 个种子 (图 17)。我们发现，参考值与 1 个和 3 个种子的测量值之间存在很大的变异，尤其是在低误差区域。这是一个问题，因为我们的协议要求我们使用少量种子的实验来提出供进一步测量的候选项。我们认为 10 个种子的测量显示出足够小的变异性，足以满足我们的目的。此外，100 个种子的测量之间差异很小，这促使我们在评估步骤中使用 100 个种子。

我们进一步测试了我们的选择过程：按照每个指标的误差从低到高对前 100 个调度进行排序，

表 10: 所有调度族的超参数搜索空间。

调度族	超参数	搜索范围
Constant	warmup_steps (比例)	[0, 0.25]
Cosine	warmup_steps (比例)	[0, 0.25]
	exponent	1.0
	alpha	[0, 2.0]
Square-root Decay	warmup_steps (比例)	[0, 0.25]
	alpha	[0, 2.0]
Generalized Rex	warmup_steps (比例)	[0, 0.25]
	beta	$[10^{-8}, 32]$
Two-Point Spline	x0	[0.01, 0.25]
	y1	[0.1, 1.0]
	delta_x1	[0.0, 1.0]
	delta_x2	[0.0, 1.0]
	delta_y2	[0.0, 1.0]
Two-Point Linear	x0	[0.01, 0.25]
	y1	[0.1, 1.0]
	delta_x1	[0.0, 1.0]
	delta_x2	[0.0, 1.0]
	delta_y2	[0.0, 1.0]
Smooth Non-Monotonic	y_start	[0.0, 1.0]
	y_end	[0.0, 1.0]
	x_peak	[0.0, 1.0]
	y1	[0.0, 1.0]
	delta_x1	[0.0, 1.0]
	y2	[0.0, 1.0]
	delta_x2	[0.0, 1.0]

这些指标包括 100 个种子的参考值，以及来自另一组 100 个种子的 4 种测量。然后，我们分别取参考测量中的前 100 个调度与每一种前 100 个测量结果的并集，并绘制它们在每种测量下的误差 (图 18)。所得测量使我们能够理解每种测量中表现最优调度的分布。我们通过询问有多少在参考测量中排入前 100 的调度 没有进入第二次测量的前 100，来定义假阴性率。比较两次独立的 100 个种子测量，得到基线假阴性率为 0.17；这表示在我们的最终评估覆盖 100 个种子的情况下，基线不确定性水平的经验测量。我们发现，当使用 1 个测量种子时，假阴性率为 0.41。我们看到，使用 10 个种子进行测量时，假阴性率为 0.25，我们认为这已经足够接近噪声下限。观察单个数据点时，我们还看到，两种测量中最好的调度都位于各自测量的前 100，这表明我们的选择过程（对于该工作负载和调度族）在计算成本和测量精度之间取得了良好平衡。




图 17: 在四种种子数量下, Two-Point Spline 调度族对应的 CIFAR-10 训练误差中位数。每幅图将横轴上的 1、3、10 或 100 个种子的中位数, 与纵轴上的 100 个种子的参考中位数进行比较。单个种子会产生很宽的散布。三个种子减少了散布, 但仍然漂移。十个种子接近对角线, 并大致匹配参考值, 表明十个种子给出了稳定估计。




图 18: 为了测试我们的选择过程, 我们根据参考测量 (100 个种子的中位数, y 轴) 和较少种子的数据 (x 轴, 不同数量的种子) 选择前 100 个调度。当使用单个种子进行测量时, 我们发现, 按照参考测量误差最低的 100 个调度中, 有 41 个不在单种子测量的前 100 (左)。相比之下, 使用 100 个种子的测量时, 参考前 100 个调度中有 17 个不在新测量的前 100。我们发现, 使用 10 个种子进行测量时, 假阴性率与 100 个种子的测量相近, 并且捕捉到了大多数表现最佳的调度。这促使我们在测量协议的初始阶段选择 10 个种子。

C 其他结果

C.1 非零最终衰减值的影响

除 Smooth Non-Monotonic 之外，在所有调度中，我们都在训练结束时将最终学习率设为 0。一些训练建议使用非零的最终学习率，例如 Hoffmann et al. (2022) 使用一种余弦学习率调度，将其衰减到峰值的 10%。在本节中，我们探索允许非零最终衰减的影响，并表明它不会大幅改变我们的结果。

我们定义了两个额外的调度：`cos-y` 和 `tps-y`，它们分别向 Cosine 和 Two-Point Spline 调度加入一个自由参数，用来表示最终衰减到峰值学习率的比例。然后，我们在两个工作负载上执行了与其他调度族相同的搜索过程。

我们发现，非零的最终基础学习率改善了 CIFAR10 上的 `cos-std`（图 19，左），并弥合了与 `cos-gen` 之间的大部分（但不是全部）差距。对于 CIFAR10，`cos-y` 的性能与 `cos-std` 相近。这表明，可调的最终基础学习率确实相较于 `cos-std` 改善了性能，但至少在我们的工作负载上，调节余弦的幂次比调节最终基础学习率更能有效利用一个额外参数。

相比之下，对于 Two-Point Spline 调度，我们发现加入可调的最终基础学习率并未显著改变性能。前 5 个 `tps-y` 调度的最终衰减值都接近 0，因此没有显示出与 `tps` 相比的显著性能差异。这表明 Two-Point Spline，以及很可能具有类似最终最优形状的其他调度，不会从非零最终学习率中受益。




图 19: 对 `cos-std`、`cos-gen` 和 `cos-y` 族进行搜索得到的前 5 个调度。对于 CIFAR10，非零最终学习率弥合了 `cos-std` 与 `cos-gen` 之间的大部分但非全部差距（左）。对于 wikitext，最优 y 值接近 0，并且没有收益。




图 20: 对 `tps` 和 `tps-y` 族进行搜索得到的前 5 个调度。最优最终学习率值接近 0，族之间没有可观的差异。




图 21: 每个调度族中由随机搜索找到的最佳分数的 ECDF（经验累积分布）。除 Smooth Non-Monotonic 族使用 36000 个候选形状进行搜索（比其余族多 10 $\times$ ）之外，数据与图 11 左图相同。额外样本找到了误差优于原始实验的调度，但 Smooth Non-Monotonic 仍落后于其他族（误差更高）。这支持了我们的主张，即相对于其他族，Smooth Non-Monotonic 族没有得到充分搜索/优化。

C.2 增加样本数的 Smooth Non-Monotonic

为确认相较于其他族, Smooth Non-Monotonic 族没有被高效搜索这一发现, 我们在 CIFAR-10 工作负载上对 Smooth Non-Monotonic 额外搜索了 36000 个形状。绘制 ECDF 后, 我们发现额外样本确实改善了找到的最佳调度, 但幅度很小, 仍然与其他调度族存在差距 (图 21)。这表明 Smooth Non-Monotonic 族仍有改进空间 (正如我们所怀疑的, 因为它比所有其他族更灵活), 但我们的搜索过程无法高效探查搜索空间, 需要在搜索空间几何/搜索分布方面改进, 或者需要全新的技术。