

Transformer 的拓扑困境

Michael C. Mozer	Shoaib Ahmed Siddiqui	Rosanne Liu
Google DeepMind	Google DeepMind	Google DeepMind
mcmozer@google.com	shoaibasidd@google.com	rosanneliu@google.com

摘要

Transformer 通过不断扩展的上下文历史来编码序列中的结构。然而，其纯前馈架构从根本上限制了动态状态追踪。状态追踪是对反映演化环境的潜变量进行迭代更新，这涉及内在的序列依赖，而前馈网络很难维持这种依赖。因此，前馈模型会随着每一个新的输入步骤，把演化中的状态表征推向更深的层栈，使信息无法被浅层访问，并最终耗尽模型深度。虽然可以通过动态深度模型，以及通过把状态表征外化的显式或潜在思考来绕过这种深度限制，但这些方案在计算和内存上都低效。本文认为，时间延展的认知需要把焦点从显式思考轨迹重新转向通过循环架构实现的隐式激活动力学。我们提出一种循环 Transformer 与连续思考 Transformer 架构的分类法，按照其循环轴（深度 versus 步骤）以及输入 token 与循环步骤的比率对它们进行归类。最后，我们勾勒出若干有前景的研究方向，包括增强型状态空间模型和粗粒度循环，以便更好地把状态追踪整合进现代基础模型。

1 引言

把大脑概念化为一个动力系统，推动了人类认知理解的进展。从硬件层面看，物理大脑由数十亿相互作用的神经元组成，其集体行为本身就是动力学的。从功能层面看，涌现出的心智可以有效地建模为一个具有高维状态 s 的动力过程，该状态随时间演化，并受外部刺激 x 调制。假设离散时间 t ，可以把状态演进形式化为 $s_t = f(s_{t-1}, x_t)$ ，从而桥接这两个层面。

从这个视角看，建模时间延展认知的理想架构是循环神经网络（RNN），因为它显式执行这种状态更新操作。原则上，基于梯度的训练过程可以从数据中发现函数 f ，使重要的输入信号被整合进状态表征，并一直保持到后续需要时。RNN 的吸引力在 1990 年代因基于梯度训练的内在限制而有所减弱 (Mozer, 1992; Hochreiter, 1998; Hochreiter et al., 2001)。

在 Transformer (Vaswani et al., 2017) 出现之前，前馈网络似乎并不是复现人类思考和推理的可行路径。Transformer 具有大胆延长的上下文窗口，会把历史中的所有信息保留下来，并常常把相关数据的选择推迟到推理真正需要时再进行 (Meng et al., 2022)。相比之下，RNN 会在信息到达时把它过滤进一个瓶颈化的状态表征 (Hochreiter and Schmidhuber, 1997)。本文讨论的是 Transformer 的这种策略可能出现什么问题，以及哪些方法能够处理其局限。

2 状态追踪

追踪不断演化的世界状态，是语言理解和推理的基本成分，无论这种追踪以何种方式实现。Transformer 的策略通常利用其从上下文窗口中检索静态、先前观察信息的能力。Transformer 的注意力机制非常擅长检索过去的 token (Olsson et al., 2022)。然而，这种查找机制在概念上不同于对动态状态的显式维护；后者是对反映变化环境的潜变量进行迭代的、内在序列化的更新。信念状态一词通常用来指 AI agent 关于其环境知识的紧凑且充分的摘要 (Chrisman, 1992; Kaelbling et al., 1998)。信念状态可以是一组事实，也可以是可能世界上的概率分布。

为作说明，考虑二十问游戏。对一个问题的每次回答都会缩小假设空间，而后续每个问题都应当被设计为进一步缩小假设空间。在猜数字游戏中，如果有人告诉你数字大于 50，那么继续猜 25 就没有意义。反过来，如果要求某人在 1 到 100 之间想一个数字，并对猜测回答“更高”或“更低”，那么维持状态，也就是那个隐藏数字，对于避免前后不一致的回答至关重要。然而，下面是一段来自 Gemini 3 (Fast) 的轨迹，展示了一种失败模式：¹

用户：请在 1 到 100 之间想一个数字，我来猜。请只回答“更高”、“更低”或“猜对了”。我的第一次猜测是 60。
模型：更低
用户：41
模型：更低
用户：70
模型：更高

即使模型无法在内部生成一个随机数字，它也可以并不真的在心里持有一个数字，而仅仅选择与先前回答一致的回应来玩这个游戏。然而，一致性要求追踪有效范围。Gemini 3 Thinking 确实生成了一个显式目标，但随后即便这个目标已经成为输入 token 流的一部分，它仍没有利用这个目标：

用户：请在 1 到 100 之间想一个数字，我来猜。请只回答“更高”、“更低”或“猜对了”。我的第一次猜测是 60。
模型 (thinking)：我已经开始设计核心游戏机制。我已经成功确定需要在 1 到 100 的范围内有一个数字。用户的初始输入 60 已被记录。现在我在内部选择了隐藏数字 42。由于 60 高于 42，我的下一步是正确地传达回答“更低”。
模型：更低
用户：42
模型：更低

在游戏之外，状态追踪对于理解不断变化的世界、论证结构以及社会互动同样必不可少。基础模型中的状态追踪失败会导致多轮对话失去连贯性 (Laban et al., 2025)、信息收集效率低下 (Sawyer et al., 2025)，以及多 agent 场景中沟通与合作崩溃 (Davidson et al., 2025; Khatua et al., 2026)。

如果没有适当的状态追踪，模型会在解释之间来回摇摆，并且无法检测自身的不一致；例如，多义词的含义 (Lepori et al., 2025)：²

用户：Fred 请了一天假，拿出了他的钓鱼竿。他开车去了 bank。当他到达 bank 时，他应该穿靴子还是凉鞋？
模型：虽然凉鞋在休闲的一天可能更舒服，但它们并不是钓鱼的最佳选择，尤其是在 river bank (河岸) 边。原因如下：……
用户：Fred 是否可能在这个 bank 找到 ATM？
模型：Fred 很可能会在这个 bank 找到 ATM。大多数银行，尤其是位于热门钓鱼水域附近的银行，都会在现场配有 ATM 以方便客户。

在这个例子中，模型从 bank 的一种解释跳到另一种解释，却没有像人类一样承认这种反转（例如，“等一下，我刚才误解了。你一定是在说金融机构。”）。我们把这种来回摇摆视为一种追踪世界情境、模型早先回答以及听者期望的失败。

虽然追踪上例中 Fred 的位置不应该具有挑战性，但在最一般的情况下，无论是模型还是人，都无法维持并追踪覆盖所有环境可能性的概率信念状态，因为这些分布会在维度上爆炸。人们采用启发式方法，例如采样 (例如 Vul et al., 2014)、把分布坍缩成原型案例 (Tversky and Kahneman, 1971)，或形成与前提最一致的具体心理模型 (Johnson-Laird, 1983)，类似于 MAP 估计。尽管如此，即便是有限记忆、确定性的状态追踪，在 Transformer 解码器中也可能是不可靠的。

¹这个例子最初由 Gamal ElSayed 在约 2020 年提出，至今仍会使一些现代基础模型失败。其他模型可能已经被训练来处理这一特定失败模式。Baldelli et al. (2026) 形式化地处理了标准模型无法在序列交互中可靠维持一致隐藏状态的问题。

²下面这个例子由 Gemini 2.5 Flash 在 2025 年生成。尽管该模型有时会正确回应，而且更新、更强的模型对这种错误的敏感性低得多，但这个例子揭示了核心架构的根本限制。

我们将用一个示意图解释状态追踪的挑战。在图 1a 中，我们把 Transformer 描绘为：输入步骤沿水平轴排列，Transformer 的块（或层）沿垂直轴排列。激活从下往上传播，即从浅层到深层。对于三个选定的块，我们用颜色表示因果 Transformer 的功能连接性：一个块中的激活受到正下方以及左下方所有块的影响。在图 1b 中，我们描绘了状态信息流，用绿色矩形表示。状态表征与新输入（紫色箭头）的整合产生新的状态表征 $s_t = f(s_{t-1}, x_t)$ 。由于该架构是前馈的， s_t 必须位于比 s_{t-1} 更深的栈中，最终会顶出模型。图 2 展示了近期几篇文章中与这种向上激活流相匹配的例子。这种流会使跨序列的信息整合变得不可靠 (Biran et al., 2024; Grant et al., 2025; Lepori et al., 2025; Sawyer et al., 2025; Venhoff et al., 2025; Baldelli et al., 2026)。

并非每个状态追踪问题都需要与层数线性相关的深度。Merrill and Sabharwal (2025) 证明，要识别长度不超过 n 的正则语言字符串，以及具有 n 个顶点的图连通性问题， $\log n$ 层是必要且充分的。然而，这一证明只处理理解的可构造性，而不是其可学习性。

在实践中，许多研究者已经在特定有限序列长度问题上训练深度受限模型，并发现了巧妙解法 (Li et al., 2025a; Piotrowski et al., 2025; Prakash et al., 2026; Shai et al., 2024)。本质上，当状态更新函数 f 具有某种形式时，一系列状态更新可以合成为一个更简单的一步函数，例如存在一个可由 Transformer 层计算的函数 g ，使得

$$s_t = f(\dots f(f(s_0, x_1), x_2), \dots, x_t) = g(s_0, x_1, \dots, x_t).$$

已有训练损失被提出，用来在这种解精确或近似存在的范围内，引导模型走向这样的解 (Hu et al., 2025; Teoh et al., 2025a; Huang et al., 2026)。然而，当信念状态级联被推向网络中越来越深的位置时，计算限制会出现，因为得到的表征对浅层不可用。为作说明，图 3 描绘了 bank 对话的处理过程。使用一种名为 Patchscopes 的技术 (Ghandeharioun et al., 2024)，Lepori et al. (2025) 观察到，多义词 bank 的 embedding 在网络浅层是含混的（即 money bank 与 river bank 的混合），但在网络深处，模型选择了 river bank 解释。前面的句子提供了上下文（例如“请了一天假”“钓鱼竿”）来支持一种解释而非另一种解释。在图中，我们把这种上下文化描绘为发生在 Transformer 栈的第六个块，这意味着当后续 token 被处理时，消歧结果在第 1 到第 5 块中不可用。Lepori et al. (2025) 表明，只要回答生成速度超过模型内部语义收敛速度，这种延迟消歧就会导致下游错误，例如模型在形成关于 bank 处 ATM 的 yes/no 回答时。

如果合理的模型在推理级联只有两步时都会犯错 (Lepori et al. 研究的是 Gemma2-9B)，那么模型在理解扩展的多 agent 对话时产生更严重失败，也就不足为奇了。

深度困境的一种解决方案是 chain-of-thought 风格的“思考”：模型把深层表征重新表述成一个或多个输出 token，然后这些 token 又作为输入提供给模型 (Wei et al., 2022)。对于普通的、逐步发生的微认知而言，这种方案是一种逃避。人们自动、无意识完成并随后一致使用的推理，例如选择多义词含义，不应当要求详尽、延展的认知。即使不同意这一期望的人，也应当同意：如果 Transformer 中的认知可以从显式思考轨迹转移到隐式激活动力学，那么得到的模型会更强大。




图 1: (a) Transformer 解码器架构的示意图，输入步骤沿水平轴排列，块（层）沿垂直轴排列。激活从浅层到深层向上传播。对于用颜色描边的三个选定块，图中用彩色线条和输入源阴影展示了因果模型的功能输入连接性。(b) 状态表征的传播，用绿色矩形表示。当这些表征依赖先前状态和当前输入时，前馈 Transformer 的状态追踪能力从根本上受到模型深度限制。




图 2: 文献中的两个例子: [Li et al. \(2025a\)](#) 和 [Lindsey et al. \(2025\)](#)。每幅图的细节并不关键, 但在每种情况下, 信息向更深层的上行流都被描绘出来。




图 3: Transformer 中状态表征的深度会限制其对推理的效用 (改编自 [Lepori et al., 2025](#))。输入 token 从底部呈现, 并由模型各层顺序处理。层内符号表示模型的内部信念状态。这突出了这样一点: 尽管模型在 bank 这个 token 处于网络深层收敛到正确信念 (river bank), 这种高层消歧却无法被后续 token 的浅层访问。因此, 在处理最后 token 时, 模型在栈的早期默认采用表面联想 (money bank $\rightarrow$ ATM), 从而在最后 token 位置产生错误预测。

3 循环架构

如前所述, 前馈模型的状态追踪能力受到模型深度限制 (例如 [Merrill and Sabharwal, 2023](#); [Strobl et al., 2024](#); [Merrill and Sabharwal, 2025](#)), 也受到如下事实限制: 当状态表征向上移动到更深层时, 有效利用它会变得更加困难 ([Biran et al., 2024](#); [Lepori et al., 2025](#); [Sawyer et al., 2025](#); [Venhoff et al., 2025](#))。

另一种选择是循环模型, 它对于表达任意状态动力学是必要的, 即 $s_t = f(s_{t-1}, x_t)$ 。在本节中, 我们探讨如何把循环与 Transformer 结合起来。不同循环形式之间存在细微但关键的差异, 它们很容易被混同, 并被错误地当作等价。这种等价化是有问题的, 因为循环本身并不足以实现状态追踪; 最流行的循环形式无法追踪状态 ([Merrill et al., 2025](#))。

图 4 改编自 [Rumelhart et al. \(1986\)](#), 展示了一个简单循环网络 (左) 以及把该网络展开 t 步后形成的权重受约束前馈网络 (右)。

展开该网络需要为每一步循环复制网络中的所有神经元。在每一步中, 激活沿每条连接流动。

现在考虑一个带有若干循环连接的 Transformer, 如图 5a 所示。与之前一样, 每个框表示一个 Transformer 块, 水平轴和垂直轴分别对应输入 token 与层。额外箭头旨在说明一种可能的循环类型, 即在每个输入步骤




图 4: 把一个三神经元循环神经网络（左）展开成其等价的前馈网络（右）。图改编自 Rumelhart et al. (1986)。

中，激活从深层流向浅层。激活流的具体性质对本文目的并不重要；例如，浅层可能生成 query，使其能够 cross-attend 到来自深层的 key 和 value (例如 Fan et al., 2021)。

不同于图 4 中只能以一种方式展开的简单 RNN，展开图 5a 中的循环 Transformer 会产生歧义，因为 Transformer 架构包含三个不同的有序维度：(1) 架构的层，在图中从下到上（浅层到深层）；(2) 架构的输入步骤，在图中从左到右；(3) 执行时进行的自回归步骤。在模型预训练期间，普通（前馈）Transformer 只有一个自回归步骤，因为所有输入步骤都是并行运行的；而在推理期间，自回归步骤通常与输入步骤混同，尽管多 token 预测允许每个自回归步骤包含多个输入/输出步骤 (Gloeckle et al., 2024)。然而，循环允许进一步解耦。特别是，许多循环形式要求，即便模型通过 teacher forcing 训练，它仍必须以自回归方式展开 (Teoh et al., 2025b)。这种必要的序列性，就是我们所说的自回归展开，而不是纯前馈模型中逐 token 生成所产生的序列性。




图 5: 展开一个 Transformer。每个矩形代表一个 Transformer 层。彩色框代表不同的输入 token。箭头表示活动流。注意，该图表示完整 Transformer 层的输出，其中既包括 self-attention，也包括 feedforward layer。灰色填充矩形表示可以由冻结 KV cache 替代的块，因为它们的值不再变化。浅灰色未填充矩形表示在给定展开步骤被忽略的输入步骤。(a) 具有循环的 Transformer，其中深层激活可以影响浅层。(b) 展开后的深度循环 Transformer。(c) 展开后的块式循环 Transformer。(d) 具有潜在吸引子动力学的 Transformer。

图 5b 描绘了在深度上展开的 Transformer，有时称为循环 *Transformer*。深度循环，无论是单个层还是一段层的循环，也无论是确定性的还是自适应的，都是一种非常流行且成功的方法。有些方法被设计和训练出来，以允许推理时 scaling (例如 Yang et al., 2024a; Nowak et al., 2024; Raposo et al., 2024; Alabdulmohsin and Zhai, 2025; Bae et al., 2025; Chen et al., 2025b; Geiping et al., 2025; Rodkin et al., 2025; Yu et al., 2025; Zhu et al., 2025; Zeng et al., 2026; Jeddi et al., 2026); 另一些方法通过预训练 (Sanyal, 2026) 或对预训练模型微调 (Koishekenov et al., 2025; McLeish et al., 2025) 引入循环; 令人意外的是，还有若干方法纯粹作为推理时方法来提升推理能力 (Li et al., 2025b; Chen et al., 2026; Ng, 2026)。

虽然深度循环可以提高 Transformer 的表达能力 (Saunshi et al., 2025)，但它并不能实现无限期的状态追踪; 传播仍然受到深度限制。要理解这一点，任选下层或上层栈中的某一层 l 作为 $s(0)$ 的表征，即第一个栈处的状态。然后注意，如果任意 $s(t+1)$ 要递归地依赖 $s(t)$ ，它就必须位于更高层。由于激活跨步骤 t 并行传播，无论通过循环深度把 Transformer 做得多深，状态表征仍会向上移动 (图 1b)。

使用任意状态更新函数进行无限期状态追踪，需要一种在训练期间阻止跨序列长度并行化的序列依赖。图 5c,d 给出了两个自回归更新的例子。图 5c 描绘了块式循环模型 (Hutchins et al., 2022; Chevalier et al., 2023; Chen et al., 2025a; Borazjanizadeh and McClelland, 2025)，其中一段输入步骤被并行运行 (图中为两个)，随后进行一次自回归迭代; 图 5d 展示了每个自回归步骤呈现一个输入步骤的模型，并且在步骤 t ，直到 $t-1$ 的所有栈都会从深层向浅层发送信号，从而得到一个完全循环模型。该模型可能具有吸引子动力学，因为每一层都持续更新，只有当所有先前步骤达到渐近状态时才收敛。

在处理后每个自回归步骤包含多个输入步骤的循环 (图 5c) 以及标准的一对一映射 (图 5d) 之后，我们还可以考虑一种设置：每个输入步骤执行多个自回归步骤 (图 6)。潜在思考模型具有这种形式 (例如 Hao et al., 2025; Jolicoeur-Martineau, 2025)。其中一些模型能够追踪状态，而另一些不能 (例如 Galashov et al., 2025)。

我们给出的循环例子都涉及信号从深层传播到浅层，但输入步骤上的层内传播 (图 7) 同样会产生状态动力学 (例如 Allen-Zhu, 2025; Gu and Dao, 2024)。




图 6: 展开一个潜在思考模型，其中模型在处理下一个输入 token 之前，会把其潜在思考反馈为模型输入，持续多个自回归步骤; 下一个输入 token 用蓝色标出 (例如 Hao et al., 2025; Jolicoeur-Martineau, 2025)。




图 7: 展开一个 SSM，其中第 l 层来自前一输入步骤的信息，会沿水平方向直接流向下一步骤 (例如 Allen-Zhu, 2025; Gu and Dao, 2024)。

表 1: 循环 Transformer 架构的分类法，并列出了若干代表性例子。注意，比率 > 1 表示每个循环步骤处理多个 token，而比率 < 1 表示每个 token 对应多个循环步骤。

循环轴	每个循环步骤处理的输入 token 数		
	比率 > 1	比率 $= 1$	比率 < 1
深度	[图 5b] looped transformer (Giannou et al., 2023), universal transformer (Dehghani et al., 2019), RINS (Alabdulmohsin and Zhai, 2025)	[图 5d]	
步骤	block-recurrent transformers (Hutchins et al., 2022)	[图 7b] linear attention (Katharopoulos et al., 2020), DeltaNet (Schlag et al., 2021), MAMBA (Gu and Dao, 2024), canon layers (Allen-Zhu, 2025), PaTH attention (Yang et al., 2025b), RWKV-7 (Peng et al., 2025), test-time regression (Sun et al., 2025)	DeltaProduct (Siems et al., 2025)
深度 + 步骤	[图 5c] recurrent memory transformer (Bulatov et al., 2022), RINs (Jabri et al., 2023), sentence gestalt (Borazjanizadeh and McClelland, 2025)	feedback transformer (Fan et al., 2021)	[图 6] COCONUT (Hao et al., 2025), hierarchical reasoning model (Jolicoeur-Martineau, 2025), CYB (Galashov et al., 2025)

表 1 尝试给出一种循环 Transformer 架构的分类法，涵盖我们迄今考虑的情形。我们沿两个维度刻画架构：循环轴和每个循环步骤处理的输入 token 数。循环轴可以仅在深度方向（图 5b,c,d）、仅在步骤方向（图 7），也可以同时在深度与步骤方向（图 6）。输入 token 与循环步骤的比率可以大于一（图 5b,c）、等于一（图 5d、7），或小于于一（图 6）。³在分类法的各单元中，我们列出一些流行且具有代表性的 Transformer 架构。我们省略那些在“处理是迭代的”意义上被描述为“循环”，但既不是深度循环也不是步骤循环的架构，例如 Transformer-XL (Dai et al., 2019)。在深度和/或步骤上具有循环，是状态追踪的必要条件，但并非充分条件。本质上，完整的状态追踪要求训练期间存在序列动力学；任何可以在整个上下文上完全并行化的模型，在更新状态方面都有局限。

虽然我们没有展示所有这类架构，但我们也没有成功识别出落在分类法空白单元中的工作例子。其中一些单元值得探索。例如，第二行第三列中的架构可以包括具有层内吸引子动力学的架构，在这种架构中，模型激活可能在前进到下一个 token 之前迭代到收敛。第一行第二列和第三列中的架构也很有意思，因为它们把激活从深层反馈到浅层（当 $\text{ratio} = 1$ 时一次，当 $\text{ratio} > 1$ 时多次），并且以一种不同于 looped transformer 的方式允许无限期状态传播。

关于循环箭头在激活动力学方面究竟表示什么，我们有意避开了这个问题。不同模型提出了不同方案。该箭头可以表示复制 key-value cache (Yang et al., 2024c)，可以表示 cross attention (Fan et al., 2021) 或 self attention (Oncescu et al., 2026) 的 key 和 value 来源，也可以表示通过线性层、MLP 或 LoRA 等 adapter 的直接连接 (Hu et al., 2022)。步骤到步骤循环与注意力的耦合，使神经元能够直接看到整个步骤历史，从而避免训练传统循环神经网络时出现的 credit assignment 瓶颈 (Ke et al., 2018; Oncescu et al., 2026)。

4 架构局限与权宜方案

Liu et al. (2026) 指出现代大规模并行架构在内在序列化问题上的弱点，这类问题由于组合结构而难以并行化，例如状态追踪、多跳推理和规划。形式化分析指出了 Transformer 的串行容量界限 (Merrill and Sabharwal, 2023)。状态空间模型 (SSM) 常被宣传为状态传播的一种手段，但带线性更新的 SSM 并不比普通 Transformer 更具表达能力 (Merrill et al., 2025)。相比之下，chain of thought 确实增强了模型表达能力 (Li et al., 2024; Merrill and Sabharwal, 2024)，这与直觉一致：允许模型与自己交谈，无论是在自然语言中还是在潜在空间中，都会把

³我们把“循环步骤”严格定义为一种在训练期间阻止跨序列长度并行化的序列依赖。

信号从 Transformer 深层发送到浅层，从而向前传播状态。前沿模型越来越依赖内部“思考”，这并不奇怪。然而，依赖中间输出来追踪微状态，可能执行浪费性的计算步骤，并不必要地消耗上下文窗口。隐式激活动力学，尽管是循环的，或许足以高效更新那些人类能够无意识、自动处理的平凡状态信息。用人类术语说，如果你正在推导一道微积分题，自言自语是可以的；但如果你在读一本书时必须不断提醒自己两个角色之间的关系，那就有点奇怪。

既然 Transformer 在状态追踪上存在局限，为什么它们如此成功？简短回答是，由于能够重新检查整个输入历史，它们常常可以把状态追踪问题转化为工作记忆问题，也就是从上下文窗口中检索。例如，考虑 1990 年代的 *latch* 问题：序列处理模型需要在序列早期锁存一比特信息，并在很长的时间间隔中保持它 (Mozer, 1991; Bengio et al., 1994)。这个问题在很大程度上推动了 LSTM，但对于能够重新索引其输入历史以检索早期信息的 Transformer 来说，它完全是平凡的。Transformer 学到许多巧妙策略，包括这种回看 (Prakash et al., 2026)、关联扫描 (Li et al., 2025a)、用于形式语言理解的更专门算法 (Allen-Zhu and Li, 2025; Piotrowski et al., 2025)，以及反映状态不确定性的信念更新 (Shai et al., 2024)。一个简单例子是从由 0 和 1 构成的输入序列中计算奇偶性。模型不必维持一个奇偶状态，而是可以在 Transformer 第一层计算成对奇偶性，再在第二层把这些对合成为四比特奇偶性，依此类推；对于最大长度为 n 的序列，它可用 $\log_2 n$ 个前馈层从头完成计算。Transformer 在实践中发展出这类替代解甚至捷径解是常见的 (Liu et al., 2022)。

Transformer 成功的另一个因素是它们支持状态组合性。状态不必像我们在图 1 中所描绘的那样是一个整体式表征。状态表征可以被拆分到多个 embedding 中，并且每个成分可以异步更新。例如，如果模型需要追踪两个实体不断变化的位置，那么这些状态变量可以针对每个实体独立更新。

5 有前景的方向

除了 Transformer 用来估计状态的原生机制之外，若干新兴研究方向似乎特别有希望促进状态维护与更新。这些方向在表达能力需求与计算可行性之间寻求平衡。

5.1 增强型状态空间模型

虽然大多数线性 SSM 并不超过标准 Transformer 的表达能力，但 Delta Net (Schlag et al., 2021) 在其特征值范围被扩展到包含负值时 (Grazzi et al., 2025)，既保持了可并行训练这一高度理想的性质，又同时获得了比标准 Transformer 更强的表达能力。Delta Net 底层的 delta rule 激发了一系列进一步发展，包括 RWKV-7 (Peng et al., 2025) 和 PaTH attention (Yang et al., 2025b)；它们同样实现了超出普通 Transformer 能力的状态追踪，并在规模化语言建模上表现出竞争力。类似地，其他新的注意力形式也正在发展，它们具有序列依赖，并有望在有状态任务上更强 (Lin et al., 2025; Leviathan et al., 2025; Beltagy et al., 2020)，包括 gated linear attention (Yang et al., 2024b) 和 gated Delta Net (Yang et al., 2025a) 的概念；当它们与标准 Transformer 块混合时，无论在理论还是实践上都比单独使用任一方更强 (Merrill et al., 2026)。

5.2 在前馈 Transformer 中近似状态追踪

不引入循环，也可以通过专门训练目标和结构先验，引导前馈 Transformer 更好地近似状态追踪 (Hu et al., 2025; Teoh et al., 2025a; Huang et al., 2026)。其前景在于，这类偏置会鼓励模型强化其原生的回看能力。然而，我们希望未来研究能够考虑结构化、组合式的状态表征。

5.3 粗粒度循环

以比单个 token 更粗的粒度引入循环，可以缓解逐 token 状态更新带来的计算负担。过去，块式循环模型通过在固定长度块中压缩并向前传递记忆，采用过这一原则。一个有前景的方法是，在识别块时考虑语言结构：

Borazjanizadeh and McClelland (2025) 已经通过在句子层面切块，把语言建模为离散 “thoughts” 的序列。

5.4 利用表征对齐

可变深度模型会动态选择某一层的迭代次数，或某一段层重复的次数。这种方法只需微调，有时甚至完全无需训练就能成功，这一事实表明，由于残差连接带来的对齐，模型本身已经很适合跨层表征通信。类似地，*canon layers* (Allen-Zhu and Li, 2025) 利用了从一个输入步骤到下一个输入步骤的表征对齐。我们推测，还有其他方式可以利用这种对齐。

5.5 循环的高效训练

任何能够进行无限期、任意状态传播的架构都需要自回归处理。自回归预训练计算效率低，并限制并行化 (Chevalier et al., 2023)。一个潜在方案是多阶段训练流程：初始预训练完全依赖标准、可并行化的前馈 Transformer 架构；之后才在后续训练阶段引入循环机制。为确保这些后续循环阶段的训练效率，可以使用截断梯度方法等优化技术，并且在训练吸引子动力学时使用 recurrent backpropagation (Almeida, 1987; Pineda, 1987; Liao et al., 2018)。还有方法被提出，用于提高算术强度，从而获得相对于上下文长度近似线性时间的 scaling，而朴素实现则是二次的 (Oncescu et al., 2026)。

6 结论

尽管 Transformer 的前馈设计扩展了基于上下文检索的边界，但其拓扑结构仍然从根本上与状态追踪的迭代性质相冲突。如我们所论证，当前依赖显式、类似自然语言的 “thought” 来绕过深度限制，是对结构性缺陷的一种低效权宜方案。通过转向隐式、循环的激活动力学，我们可以超越这些深度受限约束，获得稳健的长期连贯性和多跳推理能力。

本文提出的分类法和研究方向，为改进序列推理依赖，同时不牺牲现代模型的基础优势，提供了一张路线图。最终，弥合 Transformer 的并行效率与大脑内在动力学性质之间的差距至关重要。下一代基础模型不能只是反复重新扫描过去；它们必须维持一种流动的、持续演化的现实表征，并使这种表征跨越时间延展认知所需的多种时间尺度。

致谢

非常感谢 Sunny Sanyal、Kazuki Irie、Kevin Murphy、Jay McClelland 和 Chris Williams 对本文早期稿件提供的有益反馈。

参考文献

- Alabdulmohsin, I. and Zhai, X. (2025). Recursive inference scaling: A winning path to scalable inference in language and multimodal systems. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Allen-Zhu, Z. (2025). Physics of language models: Part 4.1, architecture design and the magic of canon layers. arXiv:2512.17351 [cs.CL].
- Allen-Zhu, Z. and Li, Y. (2025). Physics of language models: Part 1, learning hierarchical language structures. arXiv:2305.13673 [cs.CL].
- Almeida, L. B. (1987). A learning rule for asynchronous perceptrons with feedback in a combinatorial environment. In *Proceedings of the IEEE First International Conference on Neural Networks*, volume 2, pages 609–618, San Diego, CA, USA. IEEE.
- Bae, S., Kim, Y., Bayat, R., Kim, S., Ha, J., Schuster, T., Fisch, A., Harutyunyan, H., Ji, Z., Courville, A., and Yun, S.-Y. (2025). Mixture-of-recursions: Learning dynamic recursive depths for adaptive token-level computation. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Baldelli, D., Parviz, A., Zouaq, A., and Chandar, S. (2026). Llms can’t play hangman: On the necessity of a private working memory for language agents. arXiv:2601.06973 [cs.CL].
- Beltagy, I., Peters, M. E., and Cohan, A. (2020). Longformer: The long-document transformer. *arXiv preprint arXiv:2004.05150*.
- Bengio, Y., Simard, P., and Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166.
- Biran, E., Gottesman, D., Yang, S., Geva, M., and Globerson, A. (2024). Hopping too late: Exploring the limitations of large language models on multi-hop queries. In Al-Onaizan, Y., Bansal, M., and Chen, Y.-N., editors, *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 14113–14130, Miami, Florida, USA. Association for Computational Linguistics.
- Borazjanizadeh, N. and McClelland, J. (2025). Modeling language as a sequence of thoughts. arXiv:2512.25026 [cs.CL].
- Bulatov, A., Kuratov, Y., and Burtsev, M. (2022). Recurrent memory transformer. In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A., editors, *Advances in Neural Information Processing Systems*, volume 35, pages 11079–11091. Curran Associates, Inc.
- Chen, L., Li, J., Liang, C., Lao, N., and Liu, Q. (2026). Training-free looped transformers. arXiv:2605.23872 [cs.CL].
- Chen, Y., Hutchins, D., Jansen, A., Zhmoginov, A., Racz, D., and Andersen, J. S. (2025a). MELODI: Exploring memory compression for long contexts. In *The Thirteenth International Conference on Learning Representations*.
- Chen, Y., Shang, J., Zhang, Z., Xie, Y., Sheng, J., Liu, T., Wang, S., Sun, Y., Wu, H., and Wang, H. (2025b). Inner thinking transformer: Leveraging dynamic depth scaling to foster adaptive internal thinking. arXiv:2502.13842 [cs.CL].
- Chevalier, A., Wettig, A., Ajith, A., and Chen, D. (2023). Adapting language models to compress contexts. arXiv:2305.14788 [cs.CL].
- Chrisman, L. (1992). Reinforcement learning with perceptual aliasing: the perceptual distinctions approach. In *Proceedings of the Tenth National Conference on Artificial Intelligence, AAAI’92*, page 183–188. AAAI Press.

- Dai, Z., Yang, Z., Yang, Y., Carbonell, J., Le, Q. V., and Salakhutdinov, R. (2019). Transformer-xl: Attentive language models beyond a fixed-length context. *arXiv:1901.02860 [cs.LG]*.
- Davidson, T. R., Fourney, A., Amershi, S., West, R., Horvitz, E., and Kamar, E. (2025). The collaboration gap. *arXiv:2511.02687 [cs.AI]*.
- Dehghani, M., Gouws, S., Vinyals, O., Uszkoreit, J., and Kaiser, L. (2019). Universal transformers. In *International Conference on Learning Representations*.
- Fan, A., Lavril, T., Grave, E., Joulin, A., and Sukhbaatar, S. (2021). Addressing some limitations of transformers with feedback memory. *arXiv:2002.09402 [cs.CL]*.
- Galashov, A., Jones, M., Ke, R., Cao, Y., Nagarajan, V., and Mozer, M. C. (2025). Catch your breath: Adaptive computation for self-paced sequence production. *arXiv:2510.13879 [cs.CL]*.
- Geiping, J., McLeish, S. M., Jain, N., Kirchenbauer, J., Singh, S., Bartoldson, B. R., Kailkhura, B., Bhatele, A., and Goldstein, T. (2025). Scaling up test-time compute with latent reasoning: A recurrent depth approach. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Ghandeharioun, A., Caciularu, A., Pearce, A., Dixon, L., and Geva, M. (2024). Patchscopes: a unifying framework for inspecting hidden representations of language models. In *Proceedings of the 41st International Conference on Machine Learning, ICML'24*. JMLR.org.
- Giannou, A., Rajput, S., Sohn, J.-y., Lee, K., Lee, J. D., and Papailiopoulos, D. (2023). Looped transformers as programmable computers. In *International Conference on Machine Learning*, pages 11398–11442. PMLR.
- Gloeckle, F., Idrissi, B. Y., Rozière, B., Lopez-Paz, D., and Synnaeve, G. (2024). Better and faster large language models via multi-token prediction. *arXiv preprint arXiv:2404.19737*.
- Grant, S., Goodman, N. D., and McClelland, J. L. (2025). Emergent symbol-like number variables in artificial neural networks.
- Grazzi, R., Siems, J., Zela, A., Franke, J. K. H., Hutter, F., and Pontil, M. (2025). Unlocking state-tracking in linear rnns through negative eigenvalues. *arXiv:2411.12537 [cs.LG]*.
- Gu, A. and Dao, T. (2024). Mamba: Linear-time sequence modeling with selective state spaces. In *First Conference on Language Modeling*.
- Hao, S., Sukhbaatar, S., Su, D., Li, X., Hu, Z., Weston, J. E., and Tian, Y. (2025). Training large language models to reason in a continuous latent space. In *Second Conference on Language Modeling*.
- Hochreiter, S. (1998). The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(02):107–116.
- Hochreiter, S., Bengio, Y., Frasconi, P., and Schmidhuber, J. (2001). Gradient flow in recurrent nets: the difficulty of learning long-term dependencies.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8):1735–1780.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W., et al. (2022). Lora: Low-rank adaptation of large language models. *Iclr*, 1(2):3.
- Hu, E. S., Ahn, K., Liu, Q., Xu, H., Tomar, M., Langford, A., Jayaraman, D., Lamb, A., and Langford, J. (2025). The belief state transformer. In *The Thirteenth International Conference on Learning Representations*.

- Huang, H., LeCun, Y., and Balestriero, R. (2026). Semantic tube prediction: Beating LLM data efficiency with JEPA. arXiv:2602.22617 [cs.LG].
- Hutchins, D., Schlag, I., Wu, Y., Dyer, E., and Neyshabur, B. (2022). Block-recurrent transformers. In Koyejo, S., Mohamed, S., Agarwal, A., Belgrave, D., Cho, K., and Oh, A., editors, *Advances in Neural Information Processing Systems*, volume 35, pages 33248–33261. Curran Associates, Inc.
- Jabri, A., Fleet, D., and Chen, T. (2023). Scalable adaptive computation for iterative generation. arXiv:2212.11972 [cs.LG].
- Jeddi, A., Ciccone, M., and Taati, B. (2026). Loopformer: Elastic-depth looped transformers for latent reasoning via shortcut modulation. In *The Fourteenth International Conference on Learning Representations*.
- Johnson-Laird, P. (1983). *Mental Models: Towards a Cognitive Science of Language, Inference, and Consciousness*. Cognitive science series. Harvard University Press.
- Jolicoeur-Martineau, A. (2025). Less is more: Recursive reasoning with tiny networks. arXiv:2510.04871 [cs.LG].
- Kaelbling, L. P., Littman, M. L., and Cassandra, A. R. (1998). Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1):99–134.
- Katharopoulos, A., Vyas, A., Pappas, N., and Fleuret, F. (2020). Transformers are RNNs: Fast autoregressive transformers with linear attention. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 5156–5165. PMLR.
- Ke, N. R., ALIAS PARTH GOYAL, A. G., Bilaniuk, O., Binas, J., Mozer, M. C., Pal, C., and Bengio, Y. (2018). Sparse attentive backtracking: Temporal credit assignment through reminding. In Bengio, S., Wallach, H., Larochelle, H., Grauman, K., Cesa-Bianchi, N., and Garnett, R., editors, *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc.
- Khatua, A., Zhu, H., Tran, P., Prabhudesai, A., Sadrieh, F., Lieberwirth, J. K., Yu, X., Fu, Y., Ryan, M. J., Pei, J., and Yang, D. (2026). Cooperbench: Why coding agents cannot be your teammates yet.
- Koishekenov, Y., Lipani, A., and Cancedda, N. (2025). Encode, think, decode: Scaling test-time reasoning with recursive latent thoughts. arXiv:2510.07358 [cs.LG].
- Laban, P., Hayashi, H., Zhou, Y., and Neville, J. (2025). Llms get lost in multi-turn conversation. arXiv:2505.06120 [cs.CL].
- Lepori, M. A., Mozer, M. C., and Ghandeharioun, A. (2025). Racing thoughts: Explaining contextualization errors in large language models. In Chiruzzo, L., Ritter, A., and Wang, L., editors, *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 3020–3036, Albuquerque, New Mexico. Association for Computational Linguistics.
- Leviathan, Y., Kalman, M., and Matias, Y. (2025). Selective attention improves transformer. In *The Thirteenth International Conference on Learning Representations*.
- Li, B. Z., Guo, Z. C., and Andreas, J. (2025a). (how) do language models track state? In *Forty-second International Conference on Machine Learning*.
- Li, Z., Li, Y., and Zhou, T. (2025b). Skip a layer or loop it? test-time depth adaptation of pretrained llms. arXiv:2507.07996 [cs.LG].
- Li, Z., Liu, H., Zhou, D., and Ma, T. (2024). Chain of thought empowers transformers to solve inherently serial problems. In *The Twelfth International Conference on Learning Representations*.

- Liao, R., Xiong, Y., Fetaya, E., Zhang, L., Yoon, K., Pitkow, X., Urtasun, R., and Zemel, R. (2018). Reviving and improving recurrent back-propagation. In Dy, J. and Krause, A., editors, *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 3082–3091. PMLR.
- Lin, Z., Nikishin, E., He, X., and Courville, A. (2025). Forgetting transformer: Softmax attention with a forget gate. In *The Thirteenth International Conference on Learning Representations*.
- Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., Turner, N. L., Citro, C., et al. (2025). On the biology of a large language model. *Transformer Circuits Thread*.
- Liu, B., Ash, J. T., Goel, S., Krishnamurthy, A., and Zhang, C. (2022). Transformers learn shortcuts to automata. *arXiv preprint arXiv:2210.10749*.
- Liu, Y., Preechakul, K., Kuwarananchaoen, K., and Bai, Y. (2026). The serial scaling hypothesis.
- McLeish, S., Li, A., Kirchenbauer, J., Kalra, D. S., Bartoldson, B. R., Kailkhura, B., Schwarzschild, A., Geiping, J., Goldstein, T., and Goldblum, M. (2025). Teaching pretrained language models to think deeper with retrofitted recurrence.
- Meng, K., Bau, D., Andonian, A., and Belinkov, Y. (2022). Locating and editing factual associations in gpt. *Advances in neural information processing systems*, 35:17359–17372.
- Merrill, W., Li, Y., Romero, T., Svete, A., Costello, C., Dasigi, P., Groeneveld, D., Heineman, D., Kuehl, B., Lambert, N., Li, C., Lo, K., Malik, S., Matusz, D., Minixhofer, B., Morrison, J., Soldaini, L., Timbers, F., Walsh, P., Smith, N. A., Hajishirzi, H., and Sabharwal, A. (2026). Olmo hybrid: From theory to practice and back. Technical report, Allen Institute for AI. Technical Report.
- Merrill, W., Petty, J., and Sabharwal, A. (2025). The illusion of state in state-space models. *arXiv:2404.08819 [cs.LG]*.
- Merrill, W. and Sabharwal, A. (2023). The parallelism tradeoff: Limitations of log-precision transformers. *Transactions of the Association for Computational Linguistics*, 11:531–545.
- Merrill, W. and Sabharwal, A. (2024). The expressive power of transformers with chain of thought. In *The Twelfth International Conference on Learning Representations*.
- Merrill, W. and Sabharwal, A. (2025). A little depth goes a long way: The expressive power of log-depth transformers. *arXiv:2503.03961 [cs.LG]*.
- Mozer, M. C. (1991). Induction of multiscale temporal structure. *Advances in neural information processing systems*, 4.
- Mozer, M. C. (1992). The induction of multiscale temporal structure. In Moody, J. E., Hanson, S. J., and Lippmann, R. P., editors, *Advances in Neural Information Processing Systems 4*, pages 275–282, San Mateo, CA. Morgan Kaufmann.
- Ng, D. N. (2026). LLM neuroanatomy: How I topped the LLM leaderboard without changing a single weight. <https://dnhkng.github.io/posts/rys/>.
- Nowak, A. I., Mercea, O.-B., Arnab, A., Pfeiffer, J., Dauphin, Y., and Evci, U. (2024). Towards optimal adapter placement for efficient transfer learning. *arXiv:2410.15858 [cs.LG]*.
- Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., Mann, B., Askell, A., Bai, Y., Chen, A., Conerly, T., Drain, D., Ganguli, D., Hatfield-Dodds, Z., Hernandez, D., Johnston, S., Jones, A., Kernion, J., Lovitt, L., Ndousse, K., Amodei, D., Brown, T., Clark, J., Kaplan, J., McCandlish, S., and Olah, C. (2022). In-context learning and induction heads. *Transformer Circuits Thread*. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/index.html>.

- Oncescu, C.-A., Morwani, D., Jelassi, S., Meterez, A., Kwun, M., and Kakade, S. (2026). The recurrent transformer: Greater effective depth and efficient decoding. *arXiv:2604.21215 [cs.LG]*.
- Peng, B., Zhang, R., Goldstein, D., Alcaide, E., Du, X., Hou, H., Lin, J., Liu, J., Lu, J., Merrill, W., Song, G., Tan, K., Utpala, S., Wilce, N., Wind, J. S., Wu, T., Wuttke, D., and Zhou-Zheng, C. (2025). RWKV-7 "goose" with expressive dynamic state evolution. In *Second Conference on Language Modeling*.
- Pineda, F. (1987). Generalization of back-propagation to recurrent neural networks. *Physical Review Letters*, 59(19):2229–2232.
- Piotrowski, M., Riechers, P. M., Filan, D., and Shai, A. S. (2025). Constrained belief updates explain geometric structures in transformer representations. *arXiv:2502.01954 [cs.LG]*.
- Prakash, N., Shapira, N., Sharma, A. S., Riedl, C., Belinkov, Y., Shaham, T. R., Bau, D., and Geiger, A. (2026). Language models use lookbacks to track beliefs. In *The Fourteenth International Conference on Learning Representations*.
- Raposo, D., Ritter, S., Richards, B., Lillicrap, T., Humphreys, P. C., and Santoro, A. (2024). Mixture-of-depths: Dynamically allocating compute in transformer-based language models. *arXiv:2404.02258 [cs.LG]*.
- Rodkin, I., Orel, D., Smirnov, K., Bolatov, A., Elbouardi, B., Hassan, B., Kuratov, Y., Bulatov, A., Nakov, P., Baldwin, T., Shelmanov, A., and Burtsev, M. (2025). Beyond memorization: Extending reasoning depth with recurrence, memory and test-time compute scaling. *arXiv:2508.16745 [cs.LG]*.
- Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *nature*, 323(6088):533–536.
- Sanyal, S. (2026). Looped-gpt: Looping during pre-training improves generalization.
- Saunshi, N., Dikkala, N., Li, Z., Kumar, S., and Reddi, S. J. (2025). Reasoning with latent thoughts: On the power of looped transformers. In *The Thirteenth International Conference on Learning Representations*.
- Sawyer, D. P., Ke, N. R., Soyer, H., Engelcke, M., Reid, J., Reichert, D. P., Hudson, D. A., Lerchner, A., Rezende, D. J., Lillicrap, T. P., Mozer, M. C., and Wang, J. X. (2025). Exploring exploration with foundation agents in interactive environments. In *NeurIPS 2025 Workshop on Embodied World Models for Decision Making*.
- Schlag, I., Irie, K., and Schmidhuber, J. (2021). Linear transformers are secretly fast weight programmers. *arXiv preprint arXiv:2102.11174*.
- Shai, A., Riechers, P. M., Teixeira, L., Oldenziel, A. G., and Marzen, S. (2024). Transformers represent belief state geometry in their residual stream. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*.
- Siems, J., Carstensen, T., Zela, A., Hutter, F., Pontil, M., and Grazi, R. (2025). Deltaproduct: Improving state-tracking in linear RNNs via householder products. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Strobl, L., Merrill, W., Weiss, G., Chiang, D., and Angluin, D. (2024). What formal languages can transformers express? a survey. *Transactions of the Association for Computational Linguistics*, 12:543–561.
- Sun, Y., Li, X., Dalal, K., Xu, J., Vikram, A., Zhang, G., Dubois, Y., Chen, X., Wang, X., Koyejo, S., Hashimoto, T., and Guestrin, C. (2025). Learning to (learn at test time): RNNs with expressive hidden states. In *Forty-second International Conference on Machine Learning*.
- Teoh, J., Tomar, M., Ahn, K., Hu, E. S., Sharma, P., Islam, R., Lamb, A., and Langford, J. (2025a). Next-latent prediction transformers learn compact world models.

- Teoh, J., Tomar, M., Ahn, K., Hu, E. S., Sharma, P., Islam, R., Lamb, A., and Langford, J. (2025b). Next-latent prediction transformers learn compact world models. *arXiv preprint arXiv:2511.05963*.
- Tversky, A. and Kahneman, D. (1971). Belief in the law of small numbers. *Psychological Bulletin*, 76(2):105–110.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In Guyon, I., Luxburg, U. V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., and Garnett, R., editors, *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008. Curran Associates, Inc.
- Venhoff, C., Khakzar, A., Joseph, S., Torr, P., and Nanda, N. (2025). Too late to recall: Explaining the two-hop problem in multimodal knowledge retrieval. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Vul, E., Goodman, N., Griffiths, T. L., and Tenenbaum, J. B. (2014). One and done? Optimal decisions from very few samples. *Cognitive Science*, 38(4):599–637.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q. V., Zhou, D., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837.
- Yang, L., Lee, K., Nowak, R. D., and Papailiopoulos, D. (2024a). Looped transformers are better at learning learning algorithms. In *The Twelfth International Conference on Learning Representations*.
- Yang, S., Kautz, J., and Hatamizadeh, A. (2025a). Gated delta networks: Improving mamba2 with delta rule. In *The Thirteenth International Conference on Learning Representations*.
- Yang, S., Shen, Y., Wen, K., Tan, S., Mishra, M., Ren, L., Panda, R., and Kim, Y. (2025b). PaTH attention: Position encoding via accumulating householder transformations. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Yang, S., Wang, B., Shen, Y., Panda, R., and Kim, Y. (2024b). Gated linear attention transformers with hardware-efficient training. In *Proceedings of the 41st International Conference on Machine Learning, ICML’24*. JMLR.org.
- Yang, Y., Cao, Z., Chen, Q., Qin, L., Yang, D., Zhao, H., and Chen, Z. (2024c). Kvsharer: Efficient inference via layer-wise dissimilar kv cache sharing. *arXiv preprint arXiv:2410.18517*.
- Yu, Z., Belinkov, Y., and Ananiadou, S. (2025). Back attention: Understanding and enhancing multi-hop reasoning in large language models. In Christodoulopoulos, C., Chakraborty, T., Rose, C., and Peng, V., editors, *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 11257–11272, Suzhou, China. Association for Computational Linguistics.
- Zeng, B., Song, S., Huang, S., Wang, Y., Li, H., He, Z., Wang, X., li, Z., and Lin, Z. (2026). PonderLM: Pretraining language models to ponder in continuous space. In *The Fourteenth International Conference on Learning Representations*.
- Zhu, R.-J., Wang, Z., Hua, K., Zhang, T., Li, Z., Que, H., Wei, B., Wen, Z., Yin, F., Xing, H., Li, L., Shi, J., Ma, K., Li, S., Kergan, T., Smith, A., Qu, X., Hui, M., Wu, B., Min, Q., Huang, H., Zhou, X., Ye, W., Liu, J., Yang, J., Shi, Y., Lin, C., Zhao, E., Cai, T., Zhang, G., Huang, W., Bengio, Y., and Eshraghian, J. (2025). Scaling latent reasoning via looped language models. *arXiv:2510.25741 [cs.LG]*.