

RubricEM: 超越可验证奖励的、由评分规约引导的策略分解元强化学习

Gaotang Li¹, Bhavana Dalvi Mishra², Zifeng Wang², Jun Yan², Yanfei Chen², Chun-Liang Li², Long T. Le², Rujun Han², George Lee², Hanghang Tong¹, Chen-Yu Lee² and Tomas Pfister²

¹ 伊利诺伊大学厄巴纳-香槟分校, ²Google Cloud AI Research

训练深度研究智能体，也就是能够规划、搜索、评估证据并综合生成长篇报告的系统，会把强化学习推到可验证奖励之外的区域。此类系统的输出缺乏标准答案，轨迹跨越许多由工具增强的决策，而标准后训练几乎没有机制能够把过往尝试转化为可复用经验。本文认为，评分规约不应仅仅充当最终答案评估器，而应成为组织策略执行、裁判反馈和智能体记忆的共享接口。基于这一观点，我们提出 RubricEM，这是一个由评分规约引导的强化学习框架，将阶段化策略分解与基于反思的元策略训练结合起来。RubricEM 首先让研究轨迹具备阶段感知能力：规划、证据收集、审阅和综合均以自生成评分规约为条件。随后，它通过 Stage-Structured GRPO 进行信用分配，使用阶段化评分规约判断为长时域优化提供更密集的语义反馈。与此同时，RubricEM 训练一个共享骨干的反思元策略，把经过裁判评定的轨迹蒸馏为可在未来尝试中复用的、以评分规约为基础的指导。最终得到的 RubricEM-8B 在四个代表性长篇研究基准上取得了强劲表现，优于可比较的开放模型，并接近专有深度研究系统。除最终性能外，我们还进行了系统分析，以理解 RubricEM 的关键组成。

1. 引言

深度研究智能体通过自主规划、搜索、评估证据并综合生成长篇报告，来回答复杂的信息寻求问题。然而，如何训练这种能力仍不清楚：Gemini 和 OpenAI deep research 等专有系统 (Google DeepMind, 2025; OpenAI, 2025) 很少披露其方法细节，而大多数现有工作依赖可验证的搜索代理任务 (Jin et al., 2025; Nguyen et al., 2025; Song et al., 2025) 或高质量模仿数据 (Moonshot AI, 2025; Perplexity AI, 2025; Tongyi DeepResearch Team et al., 2025)。用于长篇研究的端到端强化学习很困难，因为输出缺少真值验证，裁判反馈在漫长的工具增强 rollout 中既粗粒度又延迟，而常规后训练主要把被裁判评定的尝试转化为参数更新，并不会生成显式的可复用指导。这引出了本文的核心问题：

 **强化学习如何在超越可验证奖励的情况下训练深度研究智能体，同时实现长时域信用分配并从经验中学习？**

对于无法通过精确答案验证质量的开放式任务，评分规约提供了一个自然抓手 (Chen et al., 2025b; Gunjal et al., 2025; Shao et al., 2025)。以往工作主要把它们用作裁判侧标准，为最终回答分配奖励。我们的核心观点是，评分规约应当作为贯穿强化学习全过程的共享接口。同一组定义成功的标准可以指导智能体的规划与搜索，支撑对中间决策的过程级判断，并被蒸馏成可复用反思，从而支持从经验中学习。基于这一观点，我们提出 RubricEM，这是一个由评分规约引导的强化学习框架，将阶段化策略分解与基于反思的元策略演化相结合。RubricEM 这个名称反映了一种受 Expectation–Maximization (EM) 启发的估计–最大化视角 (Dempster et al., 1977) (超越监督学习设置)：开放式研究任务的潜在结构，也就是什么重要、信用应归于何处、什么应被记住，通过评分规约来估计；这些评分规约进一步调节策略推理、裁判打分和记忆演化。随后，训练在这些由评分规约调节的估计之下最大化任务策略和反思元策略。

RubricEM 首先通过一个评分规约引导的推理脚手架实现评分规约引导的策略分解。在规划阶段，智能体生成任务特定的评分规约，并在规划、研究、审阅和答案综合四个阶段中携带这些规约。这把扁平的长时域 rollout 转化为由评分规约调节的决策阶段；每个阶段既定义一种不同的决策模式，也定义一个自然的优化单元。该脚手架还使评分规约能够在整个训练循环中发挥操作性作用：




图 1 | RubricEM 首先把由评分规约引导的结构化脚手架注入任务策略，使每条轨迹都在自生成评分规约下遵循阶段结构化推理。在 RL 期间，我们提出 Stage-Structured GRPO，以提供更细粒度、更密集的信用分配。与此同时，一个共享骨干的反思元策略被联合训练，用于生成以评分规约为基础的反思；这些反思被存入评分规约库，以同时支持跨 episode 迁移和 episode 内细化。整体来看，评分规约充当智能体、裁判及其演化之间的共享接口。

它们指导搜索与综合，作为裁判的 on-policy 参照，并产生可被蒸馏为可复用反思的结构化轨迹。

在这一分解之上，RubricEM 使用 **Stage-Structured GRPO** (SS-GRPO) 进行信用分配。SS-GRPO 不再把单个终端分数广播到所有 token，而是用阶段特定评分规约分别对 Plan、Research、Review 和 Answer 打分。裁判为每个阶段维护一个演化的评分规约缓冲区，将先前的演化评分规约评估 (Shao et al., 2025) 从最终答案判断扩展到过程级反馈。这些阶段化分数定义了更密集的回报，将局部阶段质量与下游影响结合起来，在保持无 critic 的同时，为 GRPO 提供更细粒度的信用信号。

最后，RubricEM 通过**反思元策略训练**，把经验复用变成一个显式 RL 目标。任务策略和反思元策略共享同一个骨干：当一次任务 rollout 被裁判评定后，该骨干只以查询和原始轨迹为条件，采样由评分规约支撑的反思候选；另一个裁判则使用任务 rollout 的判断结果为这些候选打分。反思分数为反思 token 提供辅助 RL 奖励，从而更新共享参数；得分最高且被接受的反思还会作为自然语言记忆写入智能体的评分规约库。该库以两种模式调节未来 rollout：episode 内细化会为同一查询检索先前反思，跨 episode 迁移则从相关问题中检索反思。因此，每条反思都会同时以参数形式和文本形式更新智能体。我们设计了高效的异步反思分支，使该元策略能够与任务策略 RL 并行训练，而不会引入顺序瓶颈；这正是先前 meta-RL 文献中的一个突出问题 (Jiang et al., 2026)。

这些组件共同产生了 RubricEM-8B，这是一个经过 1400 个 RL step 训练的 8B 深度研究智能体。图 1 给出框架概览，图 2 展示了一个具体示例。在四个代表性长篇研究基准上，RubricEM-8B 在可比较开放模型中达到当前最佳表现，用更少训练 step 超过了强先前 RL 系统，并接近 Gemini 和 OpenAI Deep Research 等专有深度研究系统。除了最终分数，我们还进行了广泛消融和分析，包括多个 600-step RL 消融、脚手架比较、推理扩展，以及分布外短篇任务迁移。这些结果支持一种面向超越可验证奖励的长时域 RL 的更一般配方：暴露任务结构，对该结构进行信用分配，并把经过裁判评定的尝试转化为可复用经验。

2. 相关工作

深度研究智能体的后训练配方。大多数现有开源深度研究训练工作聚焦于带有可验证奖励的短答案任务 (Chen et al., 2025a; Han et al., 2025; Jiang et al., 2025; Jin et al., 2025; Song et al., 2025;




图 2 | 一次 RL step 中，由评分规约引导的阶段结构化搜索智能体轨迹、元策略反思，以及阶段化裁判评分规约示例。

Zhao et al., 2025)。与此同时，专有系统主要报告的是扩展高质量模仿数据，以及在可验证短篇设置上训练 (Google, 2025; Moonshot AI, 2025; OpenAI, 2025; Perplexity AI, 2025)。本文采取正交方向：让强化学习对开放式、长篇深度研究真正有效。与我们最接近的工作是 DR Tulu (Shao et al., 2025)，它研究超越可验证奖励的深度研究端到端 RL。我们这一基础上引入细粒度信用分配和联合训练的元素策略演化，从而在困难的长时域 RL 过程中产生更密集的学习信号和可复用指导。

语言模型中的信用分配与 meta-RL。近期关于智能体强化学习的工作越来越强调更细粒度信用分配的必要性 (DeepSeek-AI, 2026; Mousavi-Hosseini and Erdogdu, 2026; Qian et al., 2025; Xi et al., 2026; Zhang, 2026)。然而，这些方法大多运行在可验证设置中，此时轨迹可以分解为带有可靠过程级监督的子目标。另一条相关路线是在强化学习期间训练元策略，通常称为 Meta-RL (Jiang et al., 2026; Yang et al., 2026a)。这些方法很有前景，但通常在可验证或合成任务上评估，并且常常引入跨 rollout 的显式依赖，造成显著训练开销。相比之下，本文面向开放式真实世界深度研究任务；在这类任务中，无论中间进展还是最终答案都无法简单自动验证。我们通过移除跨 rollout 依赖，并设计高效反思训练基础设施，提高元策略训练效率。

3. RubricEM

3.1. 预备知识与记号

我们研究面向复杂信息寻求型查询的深度研究智能体。给定一个查询 $q \sim \mathcal{D}$ ，智能体与工具环境 $\mathcal{T}$ 交互，并产生一条轨迹 $\tau = (a_1, o_1, \dots, a_T, o_T)$ ，其中 a_t 表示智能体在第 t 轮的输出，既可以是文本片段，也可以是结构化工具调用； o_t 是相应工具输出（当未调用工具时 $o_t = \emptyset$ ）。我们考虑一个基于语言模型的智能体，它自回归地采样下一步 $a_t \sim \pi_\theta(a_t | h_t)$ ， $h_t = (q, a_{<t}, o_{<t})$ ，并最终生成一个以检索证据为依据的长篇答案。

3.2. 结构化推理脚手架

RubricEM 的一个核心设计选择，是为智能体轨迹施加显式阶段结构。阶段指轨迹中由语义定义的片段，它承担一种不同的决策角色，例如规划、证据收集、自我评估或最终综合。在长时域研究任

务中，这些阶段为原本嘈杂的 token 级生成提供稳定的高层组织。当这些决策模式被压缩成一个扁平自回归过程时，轨迹就缺乏这种阶段级组织。因此，策略必须仅从局部上下文推断当前决策模式，这会导致探索低效，并在长时域中累积错误 (Feng et al., 2026; Xu et al., 2025)。我们将显式阶段信息的价值形式化如下。令 h 表示当前策略诱导轨迹上的一个随机决策点，令 $c = \phi(h)$ 表示压缩状态表征，令 z 表示当前阶段标签，并令 $U(h, a)$ 表示在历史 h 处采取动作 a 后继续 rollout 的期望下游价值。

定理 1 (阶段信息的价值). 在假设 1 的温和假设下，定义

$$V_{\text{flat}} := \mathbb{E} \left[\max_{a \in \mathcal{A}} \mathbb{E}[U(h, a) \mid c] \right], \quad V_{\text{stage}} := \mathbb{E} \left[\max_{a \in \mathcal{A}} \mathbb{E}[U(h, a) \mid c, z] \right].$$

如果存在一个具有正概率的可测集合 C_0 ，以及两个任务相关阶段，使得对每个 $c \in C_0$ 都有 $p(z \mid c) > 0$ 、 $p(z' \mid c) > 0$ ，并且

$$\arg \max_{a \in \mathcal{A}} \mathbb{E}[U(h, a) \mid c, z] \cap \arg \max_{a \in \mathcal{A}} \mathbb{E}[U(h, a) \mid c, z'] = \emptyset.$$

则

$$V_{\text{stage}} > V_{\text{flat}}.$$

定理 1 识别了显式阶段信息何时有益。在长时域研究轨迹中，同一局部上下文在规划、搜索、审阅和最终综合等阶段可能需要不同动作。当这些阶段特定最优动作不一致时，扁平策略会在发生混叠的上下文中行动，而阶段感知策略可以以当前决策模式为条件。因此，在任何出现此类混叠且具有正概率的集合上，都会得到严格的价值提升。所以我们让阶段结构在轨迹中显式存在，而不是隐含在扁平轨迹中。证明推迟到附录 E.1。

具体阶段实例化。我们用四个由评分规约引导的阶段实例化这一思想：

Plan $\rightarrow$ Research $\rightarrow$ Review $\rightarrow$ Answer。每个阶段都由一个阶段级 XML tag 标记，并带有轻量内部 schema。外层脚手架是顺序的，而 Research 允许局部迭代和就地计划修订。概览见图 3，细节如下：

Plan. 在 `<structured_plan>` 中，智能体在 `<analysis>` 中分析用户的显式与隐式需求，将其转化为 `<rubrics>`，然后提出具体的 `<research_plan>`。这些评分规约指定：(i) 需要收集的信息知识清单，(ii) 最终写作的分析标准，以及 (iii) 答案应避免内容的负约束。

Research. 智能体迭代发出 `<call_tool>` 动作。在每次工具响应后，智能体执行 `<state_evaluation>` 步骤，将累积证据与计划和评分规约比较，决定是否继续搜索，并可选地就地修订 Plan。

Review. 在 `<review>` 中，智能体通过 `<rubrics_review>` 将收集到的证据映射回评分规约，并准备写作计划，包括主要论点和章节大纲。

Answer. 在 `<answer>` 中，智能体在引用支持下综合生成最终长篇回答。

重要的是，在 RubricEM 中，评分规约不只是评估工件：它们在 Plan 中生成，可以在 Research 中修订，并在整个轨迹中指导后续阶段。这一实例化由三点考虑驱动。第一，它与任务对齐：深度研究自然包含规划、证据获取、自我评估和综合，因此四个阶段反映的是任务本身，而不是任意模板。第二，显式标准为策略的规划、自检和反馈提供稳定目标，这呼应了基于评分规约的学习和显式原则方法 (Bai et al., 2022; Panadero, 2017; Tai et al., 2018)。第三，由于自生成评分规约会在同一查询的不同 rollout 间变化，它们提供了每个 rollout 的参照，帮助裁判发现更对齐、更有区分度的阶段化标准。我们在第 5.2 节验证脚手架的有效性及其对 RL 的重要性。

最后，脚手架直接支撑后续 RL 设计：阶段边界定义了 SS-GRPO 信用分配的单元，而由评分规约调节的轨迹定义了评分规约库的记忆格式 (第 3.4 节)。因此，我们并不把脚手架视作格式预热，而是视作一种由 SFT 注入的结构先验，为有效 RL 准备策略 (Zhang et al., 2026)。




图 3 | RubricEM 中由评分规约引导的结构化推理脚手架。智能体遵循 Plan、Research、Review 和 Answer 的高层工作流，每个阶段都有轻量内部 schema。评分规约在 Plan 中生成，随后指导证据收集、评估和最终写作。在 Research 阶段，智能体在工具使用和状态评估之间迭代；一旦证据足够，就进入 Review，然后产生最终的有根据 Answer。完整描述见附录 B.1。

SFT 蒸馏。为了在策略中实例化脚手架，我们从 Gemini-3.1-Pro 进行教师-学生蒸馏。对每个查询，提示教师生成遵循上述 XML schema 的阶段结构化轨迹。由于原始教师轨迹并不总是遵守目标脚手架，我们使用拒绝采样，丢弃违反阶段边界、工具调用语法、引用格式或证据奠基约束的输出。最终 SFT 语料不仅教会 Qwen3-8B 工具使用和证据引用，也教会后续 RL 设计所需的阶段纪律和评分规约条件化。数据生成和过滤流水线细节见附录 B.2。

3.3. Stage-Structured GRPO

在上述结构化脚手架基础上，我们提出 **Stage-Structured GRPO (SS-GRPO)**，用于深度研究中的更细粒度信用分配。关于过程监督和长时域智能体 RL 的先前工作表明，更密集的过程级奖励可以显著改善信用分配 (Qian et al., 2025; Tan et al., 2026; Wang et al., 2026; Wu et al., 2026; Yang et al., 2026b)。然而，在开放式深度研究中，我们没有 oracle 中间奖励：规划、搜索、审阅和综合的质量是语义化、任务依赖且难以自动验证的。因此，SS-GRPO 使用第 3.2 节中的显式阶段边界，并结合评分规约引导的判断来构造阶段级学习信号，如图 4 所示。

阶段化分数与回报。给定查询 q ，我们采样 n 条 rollout $\{\tau_i\}_{i=1}^n \sim \pi_\theta(\cdot | q)$ ，并将每条划分为 K 个语义阶段；在我们的实例化中， $K = 4$ ，对应 Plan、Research、Review 和 Answer。令 $\mathcal{B}_{i,k}$ 为 rollout τ_i 的第 k 阶段 token，令 $R_{i,k} \in [0, 1]$ 为相应阶段评分规约下的 LLM 裁判分数。SS-GRPO 不把同一个最终分数分配给所有 token，而是使用一个因果阶段依赖矩阵 $\Lambda = (\lambda_{k,j})$ ，其中对 $j < k$ 有 $\lambda_{k,j} = 0$ ，且 $\lambda_{k,k} = 1$ ，并定义 $G_{i,k}^\Lambda = \sum_{j=k}^K \lambda_{k,j} R_{i,j}$ 。因此，每个阶段保留自身分数，同时也从它所促成的下游阶段获得信用。终端奖励广播可视作一个特殊情形。

阶段回报何时有帮助。阶段回报的收益取决于一个简单权衡：中间判断恢复了仅终端奖励遗漏的过程信息，但也引入裁判噪声。附录 E.2 的定理 3 形式化了这一直觉：当恢复出的中间信号超过累积裁判不对齐时，阶段加权信用会改善梯度近似。因此，SS-GRPO 不需要 oracle 过程奖励，只需要带有有界噪声、足够对齐的阶段化判断。这也激励了下面的阶段化演化评分规约裁判。

阶段化演化评分规约裁判。如图 4 上半部分所示，裁判会对同一查询的多条 rollout 进行对比，并为每个阶段提出具有区分度的评分规约。裁判为 Plan、Research、Review 和 Answer 分别维护一个评分规约缓冲区，复用先前高区分度评分规约，并移除不再能区分轨迹质量的条目。由于策略轨迹本身也由评分规约引导，裁判在构造新的裁判评分规约时，也可以使用轨迹生成的评分规约作为参照；但它仍使用裁判侧评分规约缓冲区来给轨迹打分，而不是盲目奖励一条 rollout 自己生成的自评分规约。这使中间奖励既是阶段局部的，又能适应当前策略分布。更多细节见附录 C。

阶段化归一化与目标。我们把 SS-GRPO 实例化为一种无 critic 的阶段化 GRPO 变体：在 rollout group 内，对每个阶段分别归一化回报：

$$A_{i,k} = \frac{G_{i,k}^\Lambda - \frac{1}{n} \sum_{i'=1}^n G_{i',k}^\Lambda}{\text{Std}_{i'}[G_{i',k}^\Lambda] + \epsilon}.$$

同一阶段块 $\mathcal{B}_{i,k}$ 中的所有 token 共享优势 $A_{i,k}$ 。得到的目标为

$$\mathcal{L}_{\text{SS-GRPO}} = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K \sum_{t \in \mathcal{B}_{i,k}} \min(\rho_{i,t} A_{i,k}, \text{clip}(\rho_{i,t}, 1 - \eta, 1 + \eta) A_{i,k}) + \beta D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}}), \quad (1)$$

其中 $\rho_{i,t} = \frac{\pi_\theta(a_{i,t}|h_{i,t})}{\pi_{\theta_{\text{old}}}(a_{i,t}|h_{i,t})}$ 。我们保持估计器无 critic，因为阶段监督由裁判定义，会在训练期间演化，并且从昂贵的长时域工具增强 rollout 中收集；加入一个学习型阶段条件 critic 会引入大量额外复杂度。

3.4. 用强化学习训练元策略

除了单轨迹优化之外，RubricEM 还把经验复用纳入 RL。一个共享骨干同时充当任务策略和反思元策略：由评分规约引导的任务 rollout 提供经过裁判评定的经验，而反思策略则用 LLM 裁判奖励来训练，生成可复用自然语言指导。被接受的反思进入智能体评分规约库，供未来检索使用，从而同时给予智能体参数化 RL 更新和文本记忆更新。这保留了 meta-RL 从过去经验改善未来 rollout 的目标，而我们的异步设计避免了顺序式 rollout-reflection-update 瓶颈。

反思元策略的联合训练。在任务策略 rollout 被裁判评定后，我们采样一个查询-轨迹对，并提示共享骨干生成多个反思候选，把轨迹作为固定上下文，只通过反思 token 反向传播。一个具有特权信息的 LLM 裁判使用原始问题、原始轨迹、阶段化评分规约分数，以及任务 rollout 判断中的评估器理由，为每个候选打分。这些分数评估每条反思是否有助于 *episode* 内细化和跨 *episode* 迁移；所有候选分数都为更新反思元策略提供 RL 信号，而只有得分最高且被接受的反思会写入智能体评分规约库。由于反思生成器和任务策略共享同一个骨干，这个反思侧目标会成为任务策略的辅助 RL 信号，而不仅仅是一种推理时记忆机制。附录 E.3 形式化了裁判评分反思更新与未来任务改进平均对齐时的正迁移情形。

耦合的智能体-裁判共同演化。反思循环与第 3.3 节中的阶段化演化裁判相耦合。On-policy rollout 暴露新的标准和失败模式，用以更新裁判侧阶段化评分规约缓冲区；更新后的裁判随后同时为任务轨迹和反思候选打分。被接受的反思通过评分规约库返回智能体，并调节未来 rollout。因此，智能体通过策略和评分规约库更新而演化，而裁判通过评分规约缓冲区更新而演化，并不更新参数。

评分规约库与两种适应模式。每个库条目都会回顾性地把一条完成轨迹蒸馏为反思评分规约和要点，总结一次尝试之后真正重要的东西。与规划期间生成的前瞻性评分规约不同，库条目编码了结果感知的经验教训。图 2 展示了一个示例。它们支持两种适应模式：*episode* 内细化会在重复尝试时检索查询自己的先前反思，而跨 *episode* 迁移会从相关历史问题中检索反思。训练期间，我们用一个两次遭遇课程实现这两种模式：每个查询先借助跨 *episode* 检索被求解，随后带着新生成的 *episode* 内反思被重放；这一过程不需要额外 rollout 依赖。

高效异步执行。如图 4 下半部分所示，同步实现会阻塞下一次任务 rollout，直到当前 step 的反思生成、反思判断和元策略更新全部完成。我们改为允许反思分支滞后一个 RL step。在 step N 期间，推理引擎运行繁重的工具增强任务 rollout，而训练引擎消费来自 step $N - 1$ 的已准备反思 batch 来进行元策略更新。当 step- N 轨迹被裁判评定后，其反思 rollout 和判断任务会异步启动，为 step $N + 1$ 准备反思 batch。这种一步陈旧性用精确同步换取了更高的基础设施利用率：推理和训练引擎都保持忙碌，元策略训练实际上不会为 SS-GRPO 循环增加额外 wall-clock 开销。详细描述见附录 D。




图 4 | RubricEM 的详细 RL 训练流水线。上半部分把图 1 扩展为两个耦合的裁判-智能体循环。对于任务策略训练，LLM 裁判对比阶段结构化 rollout，构建有区分度的阶段化评分规约缓冲区，为 SS-GRPO 提供密集阶段化奖励。对于反思元策略训练，采样轨迹和查询会提示模型生成多个候选反思；裁判使用其累积评分规约和轨迹分数，并在 episode 内和跨 episode 标准下为所有候选打分。这些分数更新元策略，且只有最佳反思会被写入智能体评分规约库。下半部分显示异步实现，其中反思 rollout、判断和更新在先前轨迹上运行，以避免同步开销。细节见附录 C 和 D；算法 1 给出形式化过程。

4. 实验

4.1. 实验设置

我们在四个代表性长篇基准上评估 RubricEM :**HealthBench** (Arora et al., 2025)、**ResearchQA** (Yifei et al., 2025)、**DeepResearchBench (DRB)** (Du et al., 2025) 和 **ResearchRubrics** (Sharma et al., 2026)。我们的实验设置建立在 DR Tulu 之上，整体共享相同的基础设施、训练数据集、超参数和评估协议。我们使用 Gemini-flash-grounded Google Search 和 Semantic Scholar 作为搜索引擎。训练数据从多样化公开查询来源中采样，包括来自 SearchArena (Miroyan et al., 2025) 的真实搜索对话，以及来自 OpenScholar (Asai et al., 2024) 的研究导向问题。SFT 阶段包含短篇和长篇数据，而 RL 阶段专门聚焦于长篇查询。关于数据集、训练和推理设置、评估协议以及完整基线列表的更多细节见附录 F。

4.2. 主要结果

表 1 按照 Shao et al. (2025)，将 RubricEM 与每个类别中最强的基线进行比较。在可获得时，我们使用已报告数字；其余基线则在可能情况下复现。

RubricEM 取得了强劲的长篇研究性能。 RubricEM-8B-RL 在我们的评估中取得了非专有深度研究系统中的最高平均分，使用 8B 骨干达到 55.5。它超过了强开放基线，包括 DR Tulu-8B-RL、Tongyi DeepResearch-30B-A3B 和 WebThinker-32B-DPO。它也能与专有系统有利比较：在双方都有分数的基准上，RubricEM-8B-RL 的平均表现超过 Perplexity Deep Research；它与 OpenAI Deep Research 的平均差距保持在 4.4 分以内，并且在 DRB 上超过后者。这些结果表明，我们的训练配方能够在小模型规模下产生有竞争力的长篇研究行为。

表 1 | 最佳基线之间的性能比较。粗体数字表示在专有和非专有类别中分别达到的最佳性能。

模型	HealthBench	ResearchQA	DRB	ResearchRubrics	平均
闭源 Deep Research					
Claude-Sonnet Search	—	64.3	34.5	—	—
Perplexity-Sonar (High)	—	69.1	40.7	—	—
Perplexity Deep Research	—	75.3	42.3	48.7	—
Gemini Deep Research	—	68.5	48.8	61.5	—
Gemini 3.1 Pro + Search	47.5	74.5	44.4	49.1	53.9
GPT-5 + Search	59.5	78.2	50.7	60.5	62.2
OpenAI Deep Research	53.8	79.2	46.9	59.7	59.9
固定流水线 Deep Research					
WebThinker QwQ-32B	36.5	72.8	37.9	42.2	47.4
WebThinker-32B-DPO	39.4	74.2	40.6	41.9	49.0
Ai2 ScholarQA – Claude Sonnet	32.0	75.0	36.1	38.1	45.3
开放 Deep Research 模型					
Search-R1-7B	-0.1	27.9	9.5	0.0	9.3
WebExplorer-8B	33.7	64.8	36.7	33.4	42.2
Tongyi DeepResearch-30B-A3B	46.2	66.7	40.6	49.5	50.8
DR Tulu-8B (SFT)	38.1	68.5	39.0	38.4	46.0
DR Tulu-8B (RL, 1900 steps)	50.2	74.3	43.4	46.4	53.6
本文方法					
Qwen3-8B + Our Search	24.5	58.4	28.2	24.5	33.9
RubricEM-8B (SFT)	39.0	71.8	43.0	42.8	49.2
RubricEM-8B (RL, 1400 steps)	49.3	74.5	47.8	50.3	55.5




图 5 | 在 600-step 预算下对 RL 训练配方进行消融研究。每个提出的组件都会提升性能，完整的 RubricEM 配方表现最好。

RL 配方既有效又高效。从结构化 SFT checkpoint 出发，RL 将平均分从 49.2 提高到 55.5，并在四个长篇基准上全部取得收益。这种收益并非简单继承自教师模型：尽管 RubricEM-8B-SFT 从 Gemini-3.1-Pro 蒸馏而来，最终的 RubricEM-8B-RL 模型平均表现仍超过了它。与最接近的先前 RL 系统 DR Tulu 相比，RubricEM 从更强的 SFT checkpoint 出发，达到更高的最终平均分，并使用更少的 RL step (1400 vs. 1900)。由于两个系统在教师模型和搜索后端上也不同（RubricEM 使用更弱的教师但更强的搜索后端），我们在第 5 节进行受控消融，以隔离所提出组件的贡献。

5. 经验分析

5.1. RL 训练配方

我们在固定 600-step 预算下消融 RubricEM 的 RL 组件，使用相同训练配置，并让每次运行都从同一个 RubricEM-SFT checkpoint 初始化。为了降低评估成本，所有消融运行都在每个基准相同的固定随机 100 样本子集上评估。我们比较四种配方：**Baseline-RL**，即标准 answer-only GRPO；




图 6 | 关于结构化脚手架和推理时经验复用的消融。面板 (a,b) 表明，由评分规约引导的脚手架同时改善 SFT 蒸馏质量和后续 RL 收益。面板 (c) 隔离提示层面的影响：在相同 Gemini-3.1-Pro 模型和搜索后端下，我们的脚手架在 DRB 上优于标准 ReAct 提示。面板 (d) 表明学习到的元策略支持跨 episode 迁移和 episode 内细化，而 Baseline-RL 无法从相同复用中受益。

SS-GRPO，它用阶段化评分规约信用替代终端奖励广播；**Meta-Policy**，它保留 answer-only GRPO，但增加反思元策略训练和评分规约库检索；以及 **RubricEM (Full)**，它结合 SS-GRPO 和 Meta-Policy。结果如图 5 所示。在这一匹配设置下，SS-GRPO 和 Meta-Policy 都优于 Baseline-RL，完整配方在各基准上表现最佳。这表明，在相同训练预算和计算量下，阶段化信用分配与可复用经验学习提供了互补收益。

5.2. 结构化脚手架与推理时经验复用

我们在图 6 中进一步分析结构化脚手架和推理时经验复用。对于脚手架，我们比较结构化与非结构化 SFT checkpoint，然后在匹配的 600-step RL 设置下继续训练二者。图 6(a) 显示结构化脚手架提升了蒸馏质量，而图 6(b) 显示它也使随后的 RL 更有效。没有脚手架时，600 step 内 RL 收益较小且不稳定，这说明由评分规约调节的阶段为探索和信用分配提供了有用结构。我们还通过在同一搜索后端下运行 Gemini-3.1-Pro，并分别采用我们的脚手架或标准 ReAct (think & act) 提示，隔离提示层面的影响。如图 6(c) 所示，我们的脚手架在 DRB 上带来更高性能，表明在学生侧训练之前，结构本身已经改善了深度研究行为。我们还评估学习到的元策略能否在 DRB 推理时被进一步利用。跨 episode 复用会从相关历史问题中检索反思，而 episode 内复用会检索智能体针对同一问题的先前反思。如图 6(d) 所示，RubricEM 从两种复用模式中都受益，而 Baseline-RL 在相同检索设置下没有受益。这说明 Reflection Meta-Policy Training 学到的是可行动、可复用的指导，而不仅仅是增加了提供给模型的上下文数量。

5.3. 短篇基准性能

除了表 1 中的长篇基准，我们还在四个短篇搜索基准上评估 RubricEM：SimpleQA (Wei et al., 2024)、2Wiki (Ho et al., 2020)、WebWalker (Wu et al., 2025b) 和 DeepSearchQA (DSQA) (Gupta et al., 2026)。这些评估对 RL 阶段而言是分布外的，因为在线 RL 只使用长篇提示。我们与 DR Tulu 比较，并在表 2 中报告结果。尽管 RubricEM 主要针对长篇深度研究训练，结果显示它能强力迁移到短篇搜索基准。RubricEM-SFT 已经学会有效的搜索与回答行为，而长篇 RL 在没有任何短篇 RL 数据的情况下进一步提升了性能。收益在更复杂任务上最明显，这说明我们的 RL 配方教会的是可迁移的工具使用和证据奠基技能，而不只是长篇报告写作。总体而言，这些结果表明，一个紧凑的 8B 模型可以通过有效 RL 泛化到长篇训练分布之外。

6. 结论

我们提出了 RubricEM，这是一个面向超越可验证奖励的深度研究、由评分规约引导的 RL 框架。RubricEM 对长时域轨迹进行结构化，分配阶段感知信用，并通过共享骨干的反思元策略，把经过裁判评定的尝试蒸馏为可复用指导。在多个基准和分析中，RubricEM-8B 展示出强劲性能，消融实验也支持每个提出的配方。进一步讨论和局限性见附录 H。

表 2 | 短篇模型性能。尽管主要在长篇数据上训练，RubricEM 在分布外短篇深度研究问题上仍能良好泛化。

模型	SimpleQA	2Wiki	WebWalker	DSQA	平均
DR Tulu 基线					
DR Tulu-8B (SFT)	75.5	66.5	31.9	5.3	44.8
DR Tulu-8B (RL, 1900 steps)	80.1	68.0	39.1	8.3	49.0
本文方法					
Qwen3-8B + Our Search	84.0	61.5	42.6	15.2	50.8
RubricEM-8B (SFT)	92.1	77.5	64.7	37.0	67.8
RubricEM-8B (RL, 1400 steps)	92.3	78.8	70.0	53.0	73.5

References

- Rahul K Arora, Jason Wei, Rebecca Soskin Hicks, Preston Bowman, Joaquin Quiñonero-Candela, Foivos Tsimpourlas, Michael Sharman, Meghan Shah, Andrea Vallone, Alex Beutel, et al. Health-bench: Evaluating large language models towards improved human health. *arXiv preprint arXiv:2505.08775*, 2025.
- Akari Asai, Jacqueline He, Rulin Shao, Weijia Shi, Amanpreet Singh, Joseph Chee Chang, Kyle Lo, Luca Soldaini, Sergey Feldman, Mike D’arcy, et al. Openscholar: Synthesizing scientific literature with retrieval-augmented lms. *arXiv preprint arXiv:2411.14199*, 2024.
- Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, et al. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2022.
- Jonathan Bragg, Mike D’Arcy, Nishant Balepur, Dan Bareket, Bhavana Dalvi, Sergey Feldman, Dany Haddad, Jena D Hwang, Peter Jansen, Varsha Kishore, et al. Astabench: Rigorous benchmarking of ai agents with a scientific research suite. *arXiv preprint arXiv:2510.21652*, 2025.
- Mingyang Chen, Tianpeng Li, Haoze Sun, Yijie Zhou, Chenzheng Zhu, Fan Yang, Zenan Zhou, Weipeng Chen, Haofen Wang, Jeff Z. Pan, Wen Zhang, and Huajun Chen. Research: Learning to reason with search for llms via reinforcement learning. *arXiv preprint arXiv:2503.19470*, 2025a.
- Xiusi Chen, Gaotang Li, Ziqi Wang, Bowen Jin, Cheng Qian, Yu Wang, Hongru Wang, Yu Zhang, Denghui Zhang, Tong Zhang, et al. Rm-r1: Reward modeling as reasoning. *arXiv preprint arXiv:2505.02387*, 2025b.
- Yifang Chen, Kevin Jamieson, and Simon Du. Active multi-task representation learning. In *International Conference on Machine Learning*, pages 3271–3298. PMLR, 2022.
- DeepSeek-AI. Deepseek-v4: Towards highly efficient million-token context intelligence. https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf, 2026. Technical report.
- Arthur P Dempster, Nan M Laird, and Donald B Rubin. Maximum likelihood from incomplete data via the em algorithm. *Journal of the royal statistical society: series B (methodological)*, 39 (1):1–22, 1977.
- Mingxuan Du, Benfeng Xu, Chiwei Zhu, Xiaorui Wang, and Zhendong Mao. Deepresearch bench: A comprehensive benchmark for deep research agents. *arXiv preprint arXiv:2506.11763*, 2025.

- Yunshu Du, Wojciech M. Czarnecki, Siddhant M. Jayakumar, Razvan Pascanu, and Balaji Lakshminarayanan. Adapting auxiliary losses using gradient similarity, 2019. URL <https://openreview.net/forum?id=r1gl7hC5Km>.
- Yan Duan, John Schulman, Xi Chen, Peter L Bartlett, Ilya Sutskever, and Pieter Abbeel. RL²: Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*, 2016.
- Yuchen Fan, Kaiyan Zhang, Heng Zhou, Yuxin Zuo, Yanxu Chen, Yu Fu, Xinwei Long, Xuekai Zhu, Che Jiang, Yuchen Zhang, Li Kang, Gang Chen, Cheng Huang, Zhizhou He, Bingning Wang, Lei Bai, Ning Ding, and Bowen Zhou. Ssrl: Self-search reinforcement learning. *arXiv preprint arXiv:2508.10874*, 2025.
- Yenchia Feng, Chirag Sharma, and Karime Maamari. Environment maps: Structured environmental representations for long-horizon agents. *arXiv preprint arXiv:2603.23610*, 2026.
- Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International conference on machine learning*, pages 1126–1135. PMLR, 2017.
- Jiaxuan Gao, Wei Fu, Minyang Xie, Shusheng Xu, Chuyi He, Zhiyu Mei, Banghua Zhu, and Yi Wu. Beyond ten turns: Unlocking long-horizon agentic search with large-scale asynchronous rl. *arXiv preprint arXiv:2508.07976*, 2025.
- Google. Build with gemini deep research. <https://blog.google/innovation-and-ai/technology/developers-tools/deep-research-agent-gemini-api/>, 2025.
- Google DeepMind. Gemini deep research. <https://blog.google/products/gemini/google-gemini-deep-research/>, 2025.
- Anisha Gunjal, Anthony Wang, Elaine Lau, Vaskar Nath, Yunzhong He, Bing Liu, and Sean Hendryx. Rubrics as rewards: Reinforcement learning beyond verifiable domains. *arXiv preprint arXiv:2507.17746*, 2025.
- Nikita Gupta, Riju Chatterjee, Lukas Haas, Connie Tao, Andrew Wang, Chang Liu, Hidekazu Oiwa, Elena Gribovskaya, Jan Ackermann, John Blitzer, et al. Deepsearchqa: Bridging the comprehensiveness gap for deep research agents. *arXiv preprint arXiv:2601.20975*, 2026.
- Rujun Han, Yanfei Chen, Zoey CuiZhu, Lesly Miculicich, Guan Sun, Yuanjun Bi, Weiming Wen, Hui Wan, Chunfeng Wen, Solène Maître, et al. Deep researcher with test-time diffusion. *arXiv preprint arXiv:2507.16075*, 2025.
- Xanh Ho, Anh-Khoa Duong Nguyen, Saku Sugawara, and Akiko Aizawa. Constructing a multi-hop qa dataset for comprehensive evaluation of reasoning steps. In *Proceedings of the 28th International Conference on Computational Linguistics*, pages 6609–6625, 2020.
- Pengcheng Jiang, Jiacheng Lin, Lang Cao, Runchu Tian, SeongKu Kang, Zifeng Wang, Jimeng Sun, and Jiawei Han. Deepretrieval: Hacking real search engines and retrievers with large language models via reinforcement learning. *arXiv preprint arXiv:2503.00223*, 2025.
- Yulun Jiang, Liangze Jiang, Damien Teney, Michael Moor, and Maria Brbic. Meta-RL induces exploration in language agents. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=4GiBscHW1k>.

- Bowen Jin, Hansi Zeng, Zhenrui Yue, Dong Wang, Hamed Zamani, and Jiawei Han. Search-r1: Training llms to reason and leverage search engines with reinforcement learning. *arXiv preprint arXiv:2503.09516*, 2025.
- Jiazheng Li, Yawei Wang, Qiaojing Yan, Yijun Tian, Zhichao Xu, Huan Song, Panpan Xu, and Lin Lee Cheong. Salt: Step-level advantage assignment for long-horizon agents via trajectory graph. In *Findings of the Association for Computational Linguistics: EACL 2026*, pages 4709–4725, 2026.
- Kuan Li, Zhongwang Zhang, Huifeng Yin, Liwen Zhang, Litu Ou, Jialong Wu, Wenbiao Yin, Baixuan Li, Zhengwei Tao, Xinyu Wang, Weizhou Shen, Junkai Zhang, Dingchu Zhang, Xixi Wu, Yong Jiang, Ming Yan, Pengjun Xie, Fei Huang, and Jingren Zhou. Websailor: Navigating super-human reasoning for web agent. *arXiv preprint arXiv:2507.02592*, 2025a.
- Wenjun Li, Zhi Chen, Jingru Lin, Hannan Cao, Wei Han, Sheng Liang, Zhi Zhang, Kuicai Dong, Dexun Li, Chen Zhang, et al. Reinforcement learning foundations for deep research systems: A survey. *arXiv preprint arXiv:2509.06733*, 2025b.
- Xiaoxi Li, Jiajie Jin, Guanting Dong, Hongjin Qian, Yutao Zhu, Yongkang Wu, Ji-Rong Wen, and Zhicheng Dou. Webthinker: Empowering large reasoning models with deep research capability. *arXiv preprint arXiv:2504.21776*, 2025c.
- Zhiwei Li, Yong Hu, and Wenqing Wang. Encouraging good processes without the need for good answers: Reinforcement learning for llm agent planning. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track*, pages 1654–1666, 2025d.
- Zijian Li, Xin Guan, Bo Zhang, Shen Huang, Houquan Zhou, Shaopeng Lai, Ming Yan, Yong Jiang, Pengjun Xie, Fei Huang, et al. Webweaver: Structuring web-scale evidence with dynamic outlines for open-ended deep research. *arXiv preprint arXiv:2509.13312*, 2025e.
- Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=v8L0pN6EOi>.
- Bo Liu, Xingchao Liu, Xiaojie Jin, Peter Stone, and Qiang Liu. Conflict-averse gradient descent for multi-task learning. In *Advances in Neural Information Processing Systems*, 2021. URL https://openreview.net/forum?id=_61Qh8tULj_.
- Junteng Liu, Yunji Li, Chi Zhang, Jingyang Li, Aili Chen, Ke Ji, Weiyu Cheng, Zijia Wu, Chengyu Du, Qidi Xu, Jiayuan Song, Zhengmao Zhu, Wenhui Chen, Pengyu Zhao, and Junxian He. Webexplorer: Explore and evolve for training long-horizon web agents. *arXiv preprint arXiv:2509.06501*, 2025.
- Xiaoqian Liu, Ke Wang, Yuchuan Wu, Fei Huang, Yongbin Li, Jianbin Jiao, and Junge Zhang. Agentic reinforcement learning with implicit step rewards. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=ooR0vpmxMV>.
- Xufang Luo, Yuge Zhang, Zhiyuan He, Zilong Wang, Siyun Zhao, Dongsheng Li, Luna K Qiu, and Yuqing Yang. Agent lightning: Train any ai agents with reinforcement learning. *arXiv preprint arXiv:2508.03680*, 2025.
- Andreas Maurer, Massimiliano Pontil, and Bernardino Romera-Paredes. The benefit of multitask representation learning. *Journal of Machine Learning Research*, 17:2853–2884, 2016. URL <https://www.jmlr.org/papers/v17/15-242.html>.

- Jianbiao Mei, Tao Hu, Daocheng Fu, Licheng Wen, Xuemeng Yang, Rong Wu, Pinlong Cai, Xinyu Cai, Xing Gao, Yu Yang, Chengjun Xie, Botian Shi, Yong Liu, and Yu Qiao. O2-searcher: A searching-based agent model for open-domain open-ended question answering. *arXiv preprint arXiv:2505.16582*, 2025.
- Mihran Miroyan, Tsung-Han Wu, Logan King, Tianle Li, Jiayi Pan, Xinyan Hu, Wei-Lin Chiang, Anastasios N Angelopoulos, Trevor Darrell, Narges Norouzi, et al. Search arena: Analyzing search-augmented llms. *arXiv preprint arXiv:2506.05334*, 2025.
- Moonshot AI. Kimi-researcher: End-to-end rl training for emerging agentic capabilities. <https://moonshotai.github.io/Kimi-Researcher/>, 2025.
- Alireza Mousavi-Hosseini and Murat A Erdogdu. Post-training with policy gradients: Optimality and the base model barrier. *arXiv preprint arXiv:2603.06957*, 2026.
- Xuan-Phi Nguyen, Shrey Pandit, Revanth Gangi Reddy, Austin Xu, Silvio Savarese, Caiming Xiong, and Shafiq Joty. Sfr-deepresearch: Towards effective reinforcement learning for autonomously reasoning single agents. *arXiv preprint arXiv:2509.06283*, 2025.
- Michael Noukhovitch, Shengyi Huang, Sophie Xhonneux, Arian Hosseini, Rishabh Agarwal, and Aaron Courville. Asynchronous rlhf: Faster and more efficient off-policy rl for language models. *arXiv preprint arXiv:2410.18252*, 2024.
- OpenAI. Introducing deep research. <https://openai.com/index/introducing-deep-research/>, 2025.
- Ernesto Panadero. A review of self-regulated learning: Six models and four directions for research. *Frontiers in psychology*, 8:422, 2017.
- Jiangweizhi Peng, Yuanxin Liu, Ruida Zhou, Charles Fleming, Zhaoran Wang, Alfredo Garcia, and Mingyi Hong. Hiper: Hierarchical reinforcement learning with explicit credit assignment for large language model agents. *arXiv preprint arXiv:2602.16165*, 2026.
- Perplexity AI. Sonar deep research. <https://docs.perplexity.ai/docs/sonar/models/sonar-deep-research>, 2025.
- Cheng Qian, Emre Can Acikgoz, Qi He, Hongru Wang, Xiusi Chen, Dilek Hakkani-Tür, Gokhan Tur, and Heng Ji. Toolrl: Reward is all tool learning needs. *arXiv preprint arXiv:2504.13958*, 2025.
- Zile Qiao, Guoxin Chen, Xuanzhong Chen, Donglei Yu, Wenbiao Yin, Xinyu Wang, Zhen Zhang, Baixuan Li, Huifeng Yin, Kuan Li, Rui Min, Minpeng Liao, Yong Jiang, Pengjun Xie, Fei Huang, and Jingren Zhou. Webresearcher: Unleashing unbounded reasoning capability in long-horizon agents. *arXiv preprint arXiv:2509.13309*, 2025.
- Kate Rakelly, Aurick Zhou, Chelsea Finn, Sergey Levine, and Deirdre Quillen. Efficient off-policy meta-reinforcement learning via probabilistic context variables. In *International conference on machine learning*, pages 5331–5340. PMLR, 2019.
- Rulin Shao, Akari Asai, Shannon Zejiang Shen, Hamish Ivison, Varsha Kishore, Jingming Zhuo, Xinran Zhao, Molly Park, Samuel G Finlayson, David Sontag, et al. Dr tulu: Reinforcement learning with evolving rubrics for deep research. *arXiv preprint arXiv:2511.19399*, 2025.

- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- Manasi Sharma, Chen Bo Calvin Zhang, Chaithanya Bandi, Clinton Wang, Ankit Aich, Huy Nghiem, Tahseen Rabbani, Ye Htet, Brian Jang, Sumana Basu, Aishwarya Balwani, Denis Peskoff, Marcos Ayestaran, Sean M. Hendryx, Brad Kenstler, and Bing Liu. Researchrubrics: A benchmark of prompts and rubrics for evaluating deep research agents. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=ErnvfmSXOP>.
- Zhengliang Shi, Yiqun Chen, Haitao Li, Weiwei Sun, Shiyu Ni, Yougang Lyu, Run-Ze Fan, Bowen Jin, Yixuan Weng, Minjun Zhu, et al. Deep research: A systematic survey. *arXiv preprint arXiv:2512.02038*, 2025.
- Amanpreet Singh, Joseph Chee Chang, Dany Haddad, Aakanksha Naik, Jena D Hwang, Rodney Kinney, Daniel S Weld, Doug Downey, and Sergey Feldman. Ai2 scholar qa: Organized literature synthesis with attribution. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations)*, pages 513–523, 2025.
- Huatong Song, Jinhao Jiang, Yingqian Min, Jie Chen, Zhipeng Chen, Wayne Xin Zhao, Lei Fang, and Ji-Rong Wen. R1-searcher: Incentivizing the search capability in llms via reinforcement learning. *arXiv preprint arXiv:2503.05592*, 2025.
- Trevor Standley, Amir R. Zamir, Dawn Chen, Leonidas Guibas, Jitendra Malik, and Silvio Savarese. Which tasks should be learned together in multi-task learning? In *Proceedings of the 37th International Conference on Machine Learning*, 2020. URL <https://proceedings.mlr.press/v119/standley20a.html>.
- Joanna Tai, Rola Ajjawi, David Boud, Phillip Dawson, and Ernesto Panadero. Developing evaluative judgement: enabling students to make decisions about the quality of work. *Higher education*, 76 (3):467–481, 2018.
- Hui-Ze Tan, Xiao-Wen Yang, Hao Chen, Jie-Jing Shao, Yi Wen, Yuteng Shen, Weihong Luo, Xiku Du, Lan-Zhe Guo, and Yu-Feng Li. Hindsight credit assignment for long-horizon llm agents. *arXiv preprint arXiv:2603.08754*, 2026.
- Tongyi DeepResearch Team, Baixuan Li, Bo Zhang, Dingchu Zhang, Fei Huang, Guangyu Li, Guoxin Chen, Huifeng Yin, Jialong Wu, Jingren Zhou, et al. Tongyi deepresearch technical report. *arXiv preprint arXiv:2510.24701*, 2025.
- Nilesh Tripuraneni, Michael I. Jordan, and Chi Jin. On the theory of transfer learning: The importance of task diversity. In *Advances in Neural Information Processing Systems*, 2020. URL <https://proceedings.neurips.cc/paper/2020/file/59587bffec1c7846f3e34230141556ae-Paper.pdf>.
- Yi Wan, Jiuqi Wang, Liam Li, Jinsong Liu, Ruihao Zhu, and Zheqing Zhu. Pokeersearch: Effective deep research via reinforcement learning from ai feedback and robust reasoning scaffold. *arXiv preprint arXiv:2510.15862*, 2025.
- Jane X Wang, Zeb Kurth-Nelson, Dhruva Tirumala, Hubert Soyer, Joel Z Leibo, Remi Munos, Charles Blundell, Dharmashan Kumaran, and Matt Botvinick. Learning to reinforcement learn. *arXiv preprint arXiv:1611.05763*, 2016.

- Peiyi Wang, Lei Li, Zhihong Shao, Runxin Xu, Damai Dai, Yifei Li, Deli Chen, Yu Wu, and Zhifang Sui. Math-shepherd: Verify and reinforce llms step-by-step without human annotations. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 9426–9439, 2024.
- Taiyi Wang, Sian Gooding, Florian Hartmann, Oriana Riva, and Edward Grefenstette. A subgoal-driven framework for improving long-horizon llm agents. *arXiv preprint arXiv:2603.19685*, 2026.
- Ziliang Wang, Xuhui Zheng, Kang An, Cijun Ouyang, Jialu Cai, Yuhang Wang, and Yichao Wu. Stepsearch: Igniting llms search ability via step-wise proximal policy optimization. *arXiv preprint arXiv:2505.15107*, 2025.
- Zirui Wang, Yulia Tsvetkov, Orhan Firat, and Yuan Cao. Gradient vaccine: Investigating and improving multi-task optimization in massively multilingual models. In *International Conference on Learning Representations*, 2021. URL https://openreview.net/forum?id=F1vEjWK-1H_.
- Jason Wei, Nguyen Karina, Hyung Won Chung, Yunxin Joy Jiao, Spencer Papay, Amelia Glaese, John Schulman, and William Fedus. Measuring short-form factuality in large language models. *arXiv preprint arXiv:2411.04368*, 2024.
- Jialong Wu, Baixuan Li, Runnan Fang, Wenbiao Yin, Liwen Zhang, Zhengwei Tao, Dingchu Zhang, Zekun Xi, Gang Fu, Yong Jiang, Pengjun Xie, Fei Huang, and Jingren Zhou. Webdancer: Towards autonomous information seeking agency. *arXiv preprint arXiv:2505.22648*, 2025a.
- Jialong Wu, Wenbiao Yin, Yong Jiang, Zhenglin Wang, Zekun Xi, Runnan Fang, Linhai Zhang, Yulan He, Deyu Zhou, Pengjun Xie, et al. Webwalker: Benchmarking llms in web traversal. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 10290–10305, 2025b.
- Sen Wu, Hongyang R. Zhang, and Christopher Ré. Understanding and improving information transfer in multi-task learning. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=SylzhkBtDB>.
- Xixi Wu, Qianguo Sun, Ruiyang Zhang, Chao Song, Junlong Wu, Yiyan Qi, and Hong Cheng. Demystifying reinforcement learning for long-horizon tool-using agents: A comprehensive recipe. *arXiv preprint arXiv:2603.21972*, 2026.
- Zhiheng Xi, Chenyang Liao, Guanyu Li, Zhihao Zhang, Wenxiang Chen, Binghai Wang, Senjie Jin, Yuhao Zhou, Jian Guan, Wei Wu, et al. Agentprm: Process reward models for llm agents via step-wise promise and progress. In *Proceedings of the ACM Web Conference 2026*, pages 4184–4195, 2026.
- Peng Xia, Jianwen Chen, Xinyu Yang, Haoqin Tu, Jiaqi Liu, Kaiwen Xiong, Siwei Han, Shi Qiu, Haonian Ji, Yuyin Zhou, et al. Metaclaw: Just talk—an agent that meta-learns and evolves in the wild. *arXiv preprint arXiv:2603.17187*, 2026.
- Baixuan Xu, Tianshi Zheng, Zhaowei Wang, Hong Ting Tsang, Weiqi Wang, Tianqing Fang, and Yangqiu Song. The cognitive bandwidth bottleneck: Shifting long-horizon agent from planning with actions to planning with schemas. *arXiv preprint arXiv:2510.07091*, 2025.
- An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.

- Lu Yang, Zelai Xu, Minyang Xie, Jiaxuan Gao, Zhao Shok, Yu Wang, and Yi Wu. Mage: Meta-reinforcement learning for language agents toward strategic exploration and exploitation. *arXiv preprint arXiv:2603.03680*, 2026a.
- Matthew Y. R. Yang, Hao Bai, Ian Wu, Gene Yang, Amrith Setlur, and Aviral Kumar. InT: Self-proposed interventions enable credit assignment in LLM reasoning. In *The Fourteenth International Conference on Learning Representations*, 2026b. URL <https://openreview.net/forum?id=YAhTj2VgBw>.
- Li S Yifei, Allen Chang, Chaitanya Malaviya, and Mark Yatskar. Researchqa: Evaluating scholarly question answering at scale across 75 fields with survey-mined questions and rubrics. *arXiv preprint arXiv:2509.00496*, 2025.
- Tianhe Yu, Saurabh Kumar, Abhishek Gupta, Sergey Levine, Karol Hausman, and Chelsea Finn. Gradient surgery for multi-task learning. In *Advances in Neural Information Processing Systems*, 2020. URL <https://proceedings.neurips.cc/paper/2020/file/3fe78a8acf5fda99de95303940a2420c-Paper.pdf>.
- Chenchen Zhang. From reasoning to agentic: Credit assignment in reinforcement learning for large language models. *arXiv preprint arXiv:2604.09459*, 2026.
- Ding-Chu Zhang, Yida Zhao, Jialong Wu, Liwen Zhang, Baixuan Li, Wenbiao Yin, Yong Jiang, Yu-Feng Li, Kewei Tu, Pengjun Xie, et al. Evolvesearch: An iterative self-evolving search agent. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, page 13123–13136, 2025a.
- Dylan Zhang, Yufeng Xu, Haojin Wang, Qingzhi Chen, and Hao Peng. Good sft optimizes for sft, better sft prepares for reinforcement learning. *arXiv preprint arXiv:2602.01058*, 2026.
- Weizhi Zhang, Yangning Li, Yuanchen Bei, Junyu Luo, Guancheng Wan, Liangwei Yang, Chenxuan Xie, Yuyao Yang, Wei-Chieh Huang, Chunyu Miao, et al. From web search towards agentic deep research: Incentivizing search with reasoning agents. *arXiv preprint arXiv:2506.18959*, 2025b.
- Qingfei Zhao, Ruobing Wang, Dingling Xu, Daren Zha, and Limin Liu. R-search: Empowering llm reasoning with search via multi-reward reinforcement learning. *arXiv preprint arXiv:2506.04185*, 2025.
- Yaowei Zheng, Richong Zhang, Junhao Zhang, Yanhan Ye, and Zheyuan Luo. Llamafactory: Unified efficient fine-tuning of 100+ language models. In *Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 3: system demonstrations)*, pages 400–410, 2024.
- Yuxiang Zheng, Dayuan Fu, Xiangkun Hu, Xiaojie Cai, Lyumanshan Ye, Pengrui Lu, and Pengfei Liu. Deepresearcher: Scaling deep research via reinforcement learning in real-world environments. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 414–431, 2025.

Contents

A 更多相关工作	18
B 结构化脚手架细节	19
B.1 脚手架描述与系统 prompt	19
B.2 SFT 数据生成过程	23
C 阶段化演化评分规约评估细节	28
C.1 评分规约缓冲区	28
C.2 自适应评分规约生成	28
C.3 阶段化打分	30
C.4 缓冲区管理与实现	31
D 异步反思流水线与窗口化课程	31
D.1 训练流水线架构	31
D.2 一步延迟反思训练	32
D.3 窗口化课程	32
D.4 轨迹采样与候选生成	32
D.5 评分规约库持久化与检索	33
D.6 Prompt 模板	33
E 理论分析	36
E.1 阶段信息的价值	36
E.2 裁判对齐的阶段加权信用分配	42
E.3 策略与评分规约库的裁判门控共同演化	46
F 实验细节	51
F.1 训练细节	51
F.2 评估细节	53
F.3 基础设施	54
F.4 基线	54
G 算法	55
H 局限性与讨论	55

A. 更多相关工作

深度研究智能体的后训练配方。深度研究智能体越来越多地被表述为经过后训练、能与工具交互的策略，而不只是提示工程式检索流水线 (Li et al., 2025b; Shi et al., 2025; Zhang et al., 2025b)。闭源系统展示了强大的长时域研究能力，但其训练配方仍然是专有的，或只在高层次上描述 (Google, 2025; Moonshot AI, 2025; OpenAI, 2025; Perplexity AI, 2025)。大多数开放训练工作则把搜索增强推理作为深度研究的代理任务，使用短答案或其他可验证任务，其奖励来自答案匹配、检索质量或基于规则的过程信号 (Chen et al., 2025a; Fan et al., 2025; Jiang et al., 2025; Jin et al., 2025; Mei et al., 2025; Song et al., 2025; Wang et al., 2025; Zhang et al., 2025a; Zhao et al., 2025)。这些方法教会模型何时以及如何检索，但仍未回答 RL 应如何为不可验证的长篇报告组织自身结构。

近期工作开始转向长时域深度研究智能体，关注真实网络或可扩展搜索训练 (Gao et al., 2025; Li et al., 2025a; Wu et al., 2025a; Zheng et al., 2025)、工作流与报告状态设计 (Han et al., 2025; Li et al., 2025c; Qiao et al., 2025)，以及大规模智能体 SFT/RL 或 RLAIIF 配方；这些配方主要围绕可验证或以真值为锚的答案监督构建 (Liu et al., 2025; Nguyen et al., 2025; Tongyi DeepResearch Team et al., 2025; Wan et al., 2025)。这些工作主要改进深度研究智能体的数据、环境、工作流或规模。我们的重点是正交的：我们不在可验证答案监督下扩展智能体流水线，而是研究开放式长篇研究轨迹所需的 RL 算法结构。

与本文最接近的工作是 DR Tulu，它引入 RLER，并建立了第一个开放的端到端配方，用于训练超越可验证奖励的长篇深度研究智能体 (Shao et al., 2025)。我们建立在这一基础上，但目标是在该设置中解决如何让 RL 更有效且训练效率更高的剩余挑战。虽然 DR Tulu 表明扩展 RL 训练对长篇深度研究很重要，RubricEM 则通过“结构化-分配-演化”配方提升 RL 效率：由评分规约引导的阶段结构化轨迹，阶段级信用分配提供更密集学习信号，联合训练的反思元策略把经过裁判评定的经验转化为可供策略演化复用的指导。经验上，这能用更少 RL 训练 step 获得更大收益。

LLM 智能体强化学习中的信用分配。信用分配是智能体 RL 的核心挑战，因为稀疏结果奖励无法明确说明哪些中间规划、工具使用或推理决策应被强化。先前工作通过数学推理的过程监督 (Lightman et al., 2024; Wang et al., 2024)、交互智能体中的工具级或轮次级奖励塑形 (Li et al., 2025d; Qian et al., 2025)，以及更一般的智能体信用分配机制来处理这一问题，例如过程奖励模型、隐式步骤奖励、轨迹图优势分配和分层转移分解 (Li et al., 2026; Liu et al., 2026; Luo et al., 2025; Peng et al., 2026; Xi et al., 2026)。这些方法表明，密集或过程感知监督对长时域智能体训练至关重要，但它们通常为具有可验证中间正确性、结构化环境状态、工具特定信号或学习型 critic 的领域设计。RubricEM 研究的是另一种区域：超越可验证奖励的开放式长篇深度研究，其中间进展是语义性的，而不是客观可检查的。因此，我们在评分规约引导的阶段层面分配信用，使用阶段特定裁判分数和因果阶段依赖回报，在不需要步骤标签或学习型 critic 的情况下提供更密集监督。

语言模型中的 Meta-RL。元强化学习研究使用过去经验来适应未来行为的智能体，经典形式包括 RL² 和 Learning to Reinforcement Learn 等循环快速适应策略、MAML 等基于梯度的适应，以及 PEARL 等潜在上下文推断方法 (Duan et al., 2016; Finn et al., 2017; Rakelly et al., 2019; Wang et al., 2016)。对于 LLM 智能体，这一视角很自然，因为轨迹包含丰富文本工件（计划、工具调用、观测、批评和失败），可以被蒸馏为可复用指导。近期语言智能体 Meta-RL 方法训练元策略，以改善重复任务中的探索以及探索-利用 (Jiang et al., 2026; Yang et al., 2026a)，而 MetaClaw 研究通过失败驱动的技能综合和可复用技能库实现持续智能体演化 (Xia et al., 2026)。然而，这些工作通常在可验证、合成或任务完成设置中评估，并且常依赖显式 support-query 或跨 rollout 依赖；对于长时域网络研究，这些依赖成本很高。RubricEM 面向超越可验证奖励的开放式长篇研究：我们在被裁判评定的轨迹固定上下文上训练共享骨干反思元策略，把由评分规约奠基的反思蒸馏进可复用评分规约库，并异步运行这一反思分支，从而不为任务策略 RL 引入顺序跨 rollout 瓶颈。

B. 结构化脚手架细节

本节详细描述由评分规约引导的结构化脚手架（第 3.2 节），给出完整智能体系统 prompt，并记录 SFT 数据生成流水线。

B.1. 脚手架描述与系统 prompt

结构化推理脚手架把每条智能体轨迹分解为四个语义上不同的阶段，每个阶段都由 XML tag 标记，并受特定行为要求约束。我们先详细描述各阶段，然后给出完整系统 prompt。

B.1.1. 阶段 1: 规划 (Plan)

规划阶段是整条轨迹的基础。收到用户查询后，智能体必须：

1. **探索性思考** (<think>)：智能体先在计算工作区中进行非结构化头脑风暴。该块用于识别初始问题、明显障碍、缺失变量，并评估查询的多维复杂性（检索难度、推理负载、智识深度和格式要求）。该块内部不使用结构化 XML tag。
2. **结构化计划** (<structured_plan>)：智能体随后生成一个可见的结构化规划文档，且只包含三个子组件：
 - <deep_analysis>：把用户查询拆解为显式需求（用户直接要求什么）、隐式需求与缺口（隐藏约束、缺失变量、潜在障碍），并给出复杂性评估，用以决定智能体应投入多少努力。
 - <rubric>：智能体充当专家评分者，为最终答案创建自评清单。该评分规约包含三类内容：(i) 知识清单，指定所需的精确事实、定义、比较或数据点；(ii) 分析与综合标准，描述答案必须实现的智识连接（对简单查询可选）；以及 (iii) 负约束，列出答案必须明确避免的内容。关键是，这些评分规约在任何搜索之前制定，作为前瞻性的目标。
 - <research_plan>：满足评分规约的逻辑路线图。简单查询得到线性的一两步计划，而复杂查询得到带有显式路由逻辑的条件式前瞻策略（例如，“如果 X 证实 Y，则调查 Z；如果 X 无结论，则回退到 W”）。
3. **第一次工具调用** (<call_tool>)：在计划之后，智能体立即执行其研究计划的第一步。智能体被严格禁止在第一轮生成 <answer>，它必须始终先搜索。

一个关键设计原则是自适应认知努力：规划深度随查询复杂性扩展。对于简单事实查找，分析和评分规约较短；对于复杂多面研究问题，智能体会启用完整规划机制，包含详细评分标准和多步条件计划。

B.1.2. 阶段 2: 研究 (Research)

研究阶段是证据收集和评估的迭代循环。每次工具输出后，智能体：

1. **评估性思考** (<think>)：在非结构化内在独白中消化新证据，记录冲突、必要转向或写作障碍。
2. **状态评估** (<state_evaluation>)：生成对当前证据状态的可见评估，将累积发现与评分规约和研究计划比较。基于该评估，智能体选择两条路径之一：
 - **路径 A—继续研究**：如果需要更多信息，智能体要么 (a) 在当前计划仍有效时直接发出另一个 <call_tool>，要么 (b) 在下次工具调用之前输出更新后的 <structured_plan>，其中包含修订后的分析、评分规约和/或研究计划。当初始假设被推翻时，这种动态计划修订支持自适应多跳推理。
 - **路径 B—进入审阅**：如果证据足以满足评分规约，智能体转入审阅阶段。

研究阶段可以多次迭代。外层脚手架是顺序的 (Plan → Research → Review → Answer)，但在 Research 内部，智能体可以在工具使用和状态评估之间自由迭代，并可就地修订其计划。

B.1.3. 阶段 3: 审阅 (Review)

在生成最终答案之前，智能体必须执行结构化自我评估。这不是可选步骤，脚手架会强制执行。审阅块 (<review>) 包含：

- <rubric_review>: 智能体把检索到的证据映射回 Phase 1 评分规约中的具体标准（以及研究期间做出的任何动态更新）。这包括：(i) 知识验证—明确列出哪些清单条目已由检索证据满足；以及 (ii) 综合与约束重述—在实际收集证据的语境中重新表述分析标准和负约束，把抽象评分规约目标转化为写作阶段具体、明确的指令。
- <writing_plan>: 最终答案的架构大纲，并随查询复杂性扩展。对简单查询，它是关于待输出已验证事实的简短说明。对复杂长篇查询，它包括：统一核心论题、价值主张（为什么该答案出色）、带逐节大纲的叙事架构，以及说明已验证事实将如何、在何处嵌入具体章节的引用映射。

这个强制审阅阶段有两个功能：它迫使智能体在写作前验证评分规约是否得到满足（防止过早或不完整答案），并生成一个写作计划来结构化最终综合，而不是让智能体以意识流方式写作。

B.1.4. 阶段 4: 回答 (Answer)

最后阶段在 <answer>...</answer> tag 内生成长篇回答。答案必须遵循审阅中建立的写作计划，满足评分规约审阅中验证过的全部评分标准，并使用 <cite id="SNIPPET_ID">claim text</cite> 格式以内联引用支撑非平凡主张。深度、语气和格式由回答格式（精确匹配、短篇或长篇）以及规划期间评估出的复杂度决定。

B.1.5. 跨阶段设计原则

若干设计原则贯穿全部四个阶段：

- **评分规约作为中心锚点。**评分规约不只是事后应用的评估工件；它在一开始生成，并主动调节后续每个决策：搜索什么、如何评估证据，以及最终答案必须包含或避免什么。这使评分规约成为整条轨迹中的共享接口。
- **每轮一个动作。**每次智能体生成必须且只能以 </call_tool> 或 </answer> 之一结束。智能体必须在闭合 tag 之后立即停止生成。这防止智能体幻觉工具输出或绕过研究阶段，并使工具执行环境能够插入真实搜索结果。
- **实质优先于语法。**回答格式指令（精确/短篇/长篇）决定答案的表层形态，但自生成评分规约决定答案的实质。智能体被要求在起草前执行其评分规约，以防格式指令覆盖深层分析标准。

B.1.6. 完整系统 prompt

下面给出完整系统 prompt。为节省篇幅，工作流示例部分有所省略。

Full Agent System Prompt

Role: Elite Autonomous Research & Synthesis Agent

You are an elite agent designed to analyze complex queries, autonomously perform rubric-guided plans, execute iterative research, and synthesize highly rigorous, evidence-backed answers. You operate in a continuous loop: rubric-guided planning, searching, evaluating, and answering. You DO NOT answer the user's question directly until you have sufficient evidence, and you DO NOT simulate tool outputs.

```
## CORE PRINCIPLE: ADAPTIVE COGNITIVE EFFORT
Your level of planning rigor, research depth, and synthesis
MUST dynamically scale with the true, multi-dimensional
complexity of the user's query and the evolving search
landscape.
- Complexity is Multi-Dimensional: It encompasses retrieval
  difficulty, reasoning load, intellectual depth, and
  formatting demands.
- Scale Your Effort: Do not over-engineer simple tasks.
  Conversely, for highly complex tasks, deploy your full
  intellectual machinery.

## EXPECTED RESPONSE FORMATS & SYNTAX RULES
Map your drafting strategy to the requested format appended
to the prompt. ALL final outputs MUST be enclosed within
<answer>...</answer>:

1. Exact Match: Format strictly as \boxed{exact answer}.
2. Short-Form: Write a single, cohesive paragraph with
  <cite id="...">...</cite> support.
3. Long-Form: Write a comprehensive, markdown-structured
  response. Synthesize sources into a cohesive narrative.
  Ground all nontrivial claims with <cite id="...">...</cite>.

CRITICAL: formatting instructions appended to the user's
prompt dictate the shape of your answer, but your dynamically
updated <rubric> dictates the substance.

---

## PHASE 1: PLANNING & INITIATION

STEP 0: Exploratory Thinking
Begin with a <think> block. Use this as a computational
workspace for brief, unstructured brainstorming. Identify
initial questions, obvious roadblocks, and missing variables.

STEP 1: The Structured Plan
Output a single <structured_plan> block containing exactly
three sections, building upon each other logically:

1. <deep_analysis>: Discover the True Intent.
  - Complexity Assessment: Evaluate the multi-dimensional
    complexity (retrieval, reasoning, insight, formulation).
  - Explicit Needs: What they are directly asking for.
  - Implicit Needs & Gaps: Hidden constraints, missing
    variables, or potential roadblocks.

2. <rubric>: Define the Strict Grading Criteria. Act as an
  expert grader creating a rigorous checklist. Draw upon the
  <deep_analysis> as a foundation. DO NOT focus on formatting;
  focus on required content, intellectual depth, and logical
  constraints.
  - Knowledge Checklist: The exact facts, definitions,
```

```

    comparisons, or data points required.
- Analytical & Synthesis Criteria (Optional, for complex
  queries): What intellectual connections must the response
  achieve?
- Negative Constraints (Pitfalls): What must the response
  explicitly AVOID?

3. <research_plan>: Formulate the Strategy. Create a logical
  roadmap to satisfy the rubric. Simple queries need a linear
  step or two; complex queries require a conditional,
  look-ahead strategy.

STEP 2: The First Tool Call
Immediately after closing </structured_plan>, execute ONLY
the first step of your research plan. Under NO circumstances
should you output an <answer> in this first turn.

---

## PHASE 2: SEARCH & SYNTHESIS

STEP 0: Evaluation Thinking
Begin with a <think> block for raw inner monologue to digest
new evidence.

STEP 1: State Evaluation & Action
Output a <state_evaluation> block to analyze the tool output,
then choose exactly ONE path:

PATH A: Continue Research (More Information Needed)
- Direct Search: If the current plan and rubric are still
  valid, output your next <call_tool>.
- Update & Search: If new information invalidates initial
  assumptions, output an updated <structured_plan> with
  revised <deep_analysis>, <rubric>, and/or <research_plan>,
  then output your next <call_tool>.

PATH B: Ready to Answer (Evidence Sufficient)
1. The Review: Output a <review> block containing:
  - <rubric_review>: Systematically map retrieved evidence
    back to the Phase 1 <rubric>. Verify knowledge checklist
    items. Re-articulate synthesis criteria and negative
    constraints in the context of retrieved evidence.
  - <writing_plan>: Outline the final answer's architecture.
    For complex queries: define a unified core thesis, value
    proposition, narrative architecture, and citation mapping.
2. The Final Answer: Output the response within
  <answer>...</answer> tags.

---

## Available Tools
- google_search: Powered by a grounded AI reasoning engine.
  Use direct, highly specific search queries.

```



```

Input: <call_tool name="google_search">query</call_tool>

- snippet_search: Focused retrieval from scientific papers.
  Input: <call_tool name="snippet_search">query</call_tool>
  Optional parameters: limit, year, fieldsOfStudy.

## Tool Output Format
- Results are appended in <tool_output>...</tool_output> tags.
- For google_search: summary text with grounding snippets.
- For snippet_search: <snippet id="ID">content</snippet>.

## WORKFLOW EXAMPLE
[... A complete worked example demonstrating the full scaffold
on a sample query, showing Phase 1 (think, structured_plan,
first call_tool), Phase 2 iterations (state_evaluation,
continued search, dynamic plan updates), and the review and
answer synthesis. Omitted for brevity. ...]

## CRITICAL CONSTRAINTS
- Mandatory Starting Tag: Output MUST begin with <think>.
- Mandatory First Search: First turn MUST end with
  </call_tool>. Never answer without searching.
- One Action Per Turn: End with </call_tool> OR </answer>.
  STOP generating immediately after. Do NOT simulate
  <tool_output> yourself.
- Mandatory Citations: Wrap claims in
  <cite id="S_123">claim text</cite>. Never use empty tags.
  Multiple sources: <cite id="S_1, S_2">claim</cite>.
- Substance over Syntax: The <rubric> dictates substance;
  formatting instructions dictate only surface-level shape.

```

附加指令。 根据期望回答格式，以下三种任务特定指令之一会附加到用户查询：

- **精确答案：**“Search iteratively to find the precise answer. Format: <answer>\boxed{exact answer}</answer>.”
- **短篇形式：**“Search iteratively to gather evidence from multiple credible sources. Synthesize into a short paragraph within <answer>...</answer> tags.”
- **长篇形式：**“Search iteratively to gather evidence from multiple credible sources. Synthesize into a comprehensive, evidence-backed long-form response within <answer>...</answer> tags.”

B.2. SFT 数据生成过程

为了把由评分规约引导的脚手架注入基础 Qwen3-8B 模型，我们使用教师生成轨迹进行监督微调。数据生成过程由一个多轮、工具增强的流水线构成，它从教师模型产生完整的阶段结构化轨迹。

B.2.1. 教师模型与 *prompt* 适配

我们使用 Gemini-3.1-Pro 作为教师模型。训练查询来自 Dr. Tulu (Shao et al., 2025) 使用的同一数据集，该数据集包含约 ~13K 个跨多个领域的多样开放式研究问题。每个查询都配有一个回答格式标签 (exact_answer、short_form 或 long_form)，用于决定附加到 prompt 的额外指令。

一个关键挑战是，SFT 数据生成 prompt 必须针对 Gemini 适配，因为 Gemini 与目标 Qwen3-8B

模型在若干重要方面不同。

推理轨迹与 <scratchpad>。 我们的脚手架在每轮开始包含非结构化 <think> 块，以保留基础 Qwen3-8B 策略的后训练推理行为。然而，直接提示 Gemini 生成 <think> tag 会被 API 阻止，内部思考轨迹也因反蒸馏策略而不可访问。我们在 SFT 数据生成期间使用 <scratchpad> 作为替代推理 tag；这些 tag 会在后处理中转换为 <think>。尽管这些轨迹不捕获 Gemini 的真实内部 chain-of-thought，它们仍提供可见的规划理由和证据评估，使学生模型学会行动前显式推理的习惯，同时不破坏其原生 <think> 模式。

阶段化 prompt 分离。 由于每一轮都是一次独立的 Gemini API 调用，我们把系统 prompt 拆成第一轮变体（只包含 Phase 1 指令）和后续轮次变体（只包含 Phase 2 指令）。这种分离有两个目的：它让每个 prompt 聚焦当前阶段要求（减少 prompt 长度并提高遵循度），并确保模型在 step 1 中大量投入规划（生成完整 <structured_plan>，包含分析、评分规约和研究计划），而不是跳到搜索或直接回答。每个变体都显式约束轮次结束 tag：第一轮必须以 </call_tool> 结束，后续轮次必须以 </call_tool> 或 </answer> 结束。

下面给出每个生成 prompt 的核心部分（省略工具文档和工作流示例，因为它们与最终智能体 prompt 相对应）。

SFT Generation Prompt: First Round (Phase 1 Only)

```
# Role: Elite Research Planning & Initiation Agent

You are an elite Research Planning Agent. Your purpose is to
analyze complex queries, generate a rigorous, visible research
plan, and initiate the very first search query to kick off the
research process. You DO NOT answer the user's question
directly, and you DO NOT simulate tool outputs.

## CORE PRINCIPLE: ADAPTIVE COGNITIVE EFFORT
[... same as final prompt ...]

## Process

STEP 0: Exploratory Scratchpad
Begin with a <scratchpad> block. This is your mandatory
computational workspace. Use this space for a brief,
unstructured exploration of the user's query --- identify
initial hurdles and missing variables before moving to
structured output. Do not output XML tags inside scratchpad.

STEP 1: The Structured Plan
Output a single <structured_plan> block containing exactly
three sections, building upon each other logically:

1. <deep_analysis>: Discover the True Intent.
  - Complexity Assessment: Evaluate the multi-dimensional
    complexity (retrieval, reasoning, insight, formulation).
  - Explicit Needs: What they are directly asking for
    (including structural/formatting instructions).
  - Implicit Needs & Gaps: Hidden constraints, missing
    variables, or potential roadblocks.
```

2. <rubric>: Define the Strict Grading Criteria. Act as an expert grader creating a rigorous checklist. DO NOT focus on formatting; focus on content, depth, and constraints.
 - Knowledge Checklist: Exact facts, definitions, data points required (e.g., "The response explicitly defines the von Neumann bottleneck").
 - Analytical & Synthesis Criteria (Optional, for complex queries): What intellectual connections must the response achieve?
 - Negative Constraints (Pitfalls): What must the response explicitly AVOID? (e.g., "The response avoids presenting industry blogs as academic consensus").
3. <research_plan>: Formulate the Strategy. Create a logical roadmap to satisfy the rubric. Simple queries: linear steps. Complex queries: conditional, look-ahead strategy (e.g., "Step 1: Find X. Step 2: If X confirms Y, investigate Z; if inconclusive, fallback to W").

STEP 2: The First Tool Call

Immediately after closing </structured_plan>, execute ONLY the first step of your <research_plan>. Once you output </call_tool>, you must STOP generating text.

CRITICAL CONSTRAINTS

- Output MUST begin with <scratchpad>, then <structured_plan>.
- Execute EXACTLY ONE tool call.
- DO NOT simulate <tool_output>.
- DO NOT attempt to write the final <answer>.

[... tool documentation and workflow examples omitted ...]

SFT Generation Prompt: Later Rounds (Phase 2 Only)

Role: Elite Iterative Research & Synthesis Agent

You are in the active research phase. You have already generated an initial Rubric and Research Plan. Your goal is to evaluate the latest retrieved information, dynamically adjust your strategy if necessary, and either continue searching or generate the final answer.

CONTEXT: THE PHASE 1 FOUNDATION

Prior to your current phase, an initial <structured_plan> was generated. This plan is your foundational blueprint consisting of <deep_analysis>, <rubric>, and <research_plan>. You must constantly evaluate incoming evidence against this baseline.

Process & Decision Tree

STEP 0: Evaluation Scratchpad

Begin with a <scratchpad> block. This is your mandatory computational workspace for raw, unstructured inner monologue

to digest newly retrieved evidence. If data contradicts assumptions, briefly identify the conflict and note your pivot. If evidence is sufficient for a complex query, pinpoint writing hurdles before resolving them in <review>.

STEP 1: State Evaluation & Action

Output a <state_evaluation> block to formally analyze the latest tool output, then choose exactly ONE path:

PATH A: Continue Research (More Information Needed)

- Direct Search: If the current plan and rubric are still valid, output your next <call_tool> immediately.
- Update & Search: If new information invalidates initial assumptions, triggers a fallback, or reveals a deeper multi-hop requirement:
 1. Output an updated <structured_plan> with revised <deep_analysis>, <rubric>, and/or <research_plan>. (Only include sections that require updates.)
 2. Then output your next <call_tool>.

PATH B: Ready to Answer (Evidence Sufficient)

1. The Review: Output a <review> block containing:
 - <rubric_review>: Systematically map retrieved evidence back to the Phase 1 <rubric> (plus any dynamic updates).
 - * Knowledge Verification: List the critical facts and data points that satisfy the Knowledge Checklist.
 - * Synthesis & Constraints Restatement: Re-articulate Analytical Criteria and Negative Constraints in the context of retrieved evidence. Transform abstract rubric targets into concrete directives for drafting.
 - <writing_plan>: Outline the final answer architecture, scaling effort to query complexity:
 - * Low-Complexity: State verified facts directly.
 - * High-Complexity: Define (1) unified core thesis, (2) value proposition, (3) narrative architecture with section-by-section outline, (4) citation mapping specifying how verified facts integrate into sections.
2. The Final Answer: Output within <answer>...</answer> tags. Depth and formatting MUST match the writing plan. Follow the Knowledge Checklist and honor all constraints from the <rubric_review>.

CRITICAL CONSTRAINTS

- Output MUST begin with <scratchpad>, then <state_evaluation>.
- One Action Per Turn: end with </call_tool> OR </answer>. STOP generating immediately after the closing tag.
- Mandatory Citations: wrap claims in <cite id="S_123">claim text</cite>. Never use empty tags.
- Substance over Syntax: formatting instructions dictate shape; the <rubric> dictates substance. Enforce the rubric before drafting.

[... tool documentation and workflow examples omitted ...]

与统一最终智能体 prompt 相比，关键差异在于责任的严格分离：第一轮 prompt 禁止回答，并

要求完整规划阶段；后续轮次 prompt 假设计划已经存在，聚焦证据评估和综合。这种分离确保教师投入充分规划，而不是短路到答案。

常见失败模式。 尽管做了这些适配，Gemini-3.1-Pro 仍经常违反脚手架约束。常见失败包括：不搜索而直接基于内部知识回答；输出没有以所需闭合 tag 结束；省略 `<rubric>` 或 `<state_evaluation>` 等必需结构元素；以及生成与预期 schema 不匹配的工具名称变体。这些违反行为使激进拒绝采样成为必要（如下所述）。

B.2.2. 多轮生成流水线

由于脚手架要求迭代工具交互，我们无法在单次模型调用中生成完整轨迹。相反，我们使用一个在模型生成和真实工具执行之间交替的多轮流水线：

- 第 1 轮(启动)：**教师接收第一轮系统 prompt 和用户查询。它生成 Phase 1 输出：`<scratchpad>`、`<structured_plan>`（包含 `<deep_analysis>`、`<rubric>`、`<research_plan>`）以及第一次 `<call_tool>`。生成在闭合 `</call_tool>` tag 处停止。
- 工具路由与执行：**每个 `<call_tool>` 都会被解析以提取工具名和查询。流水线把调用路由到两个后端之一：
 - `google_search`：作为 Vertex AI batch prediction 作业提交，使用启用 Google Search grounding 的 Gemini，返回带 grounding snippet 的 AI 综合摘要。
 - `snippet_search`：针对 Semantic Scholar API 异步执行，返回与查询匹配的论文摘录。
 两个后端并行运行，以最大化吞吐。未能调用有效工具的响应（例如基于内部知识回答）会被分离到错误流中，以便潜在重处理。
- 第 2–N 轮（研究迭代）：**工具输出被迫加到对话历史中，教师接收后续轮次系统 prompt。它生成下一次 Phase 2 轮次：`<scratchpad>`、`<state_evaluation>`，以及另一个 `<call_tool>`，或者 `<review>` 和 `<answer>`。该循环持续到教师产生闭合 `</answer>` tag，或达到最多 10 轮。
- 完成检测：**当教师输出以 `</answer>` 结束时，轨迹被视为完整。耗尽最大轮数的不完整轨迹会被丢弃。由于 Gemini 经常无法产生格式良好的闭合 tag，相当一部分轨迹（约 ~15–25%）会在此阶段被丢弃。

B.2.3. 质量过滤与拒绝采样

原始教师轨迹会经过拒绝采样和若干过滤步骤。这一点很关键，因为 Gemini-3.1-Pro 尽管是强模型，在生成多轮工具增强轨迹时仍经常违反脚手架的结构约束。

拒绝标准。 以下轨迹会被拒绝：

- 缺少 `</answer>` tag (硬拒绝)：**最常见失败模式。教师生成大量内容，却从未产生闭合 `</answer>` tag，可能是因为 token 用尽、进入无尽研究循环，或只是中途停句。这些轨迹会被完全丢弃。
- 非最终轮没有有效工具调用：**每个非最终轮必须以有效 `</call_tool>` tag 结束，其中包含可解析工具名和查询。模型跳过工具使用并尝试从内部知识回答的轨迹（例如生成没有任何 `<call_tool>` 的长回复）会被拒绝。这是第二常见失败模式，尤其出现在 Gemini “知道”答案并拒绝搜索的简单事实查询上。
- 缺少结构元素：**轨迹必须在第一轮包含有效 `<structured_plan>`（带 `<deep_analysis>` 和 `<rubric>`），并在后续轮次包含 `<state_evaluation>`。XML 畸形或缺少必需部分的轨迹会被丢弃。
- 连续工具错误：**如果轨迹中连续两轮或更多轮工具后端返回错误（例如搜索被安全过滤器阻止、API 速率限制、“no grounding data available”），则该轨迹会被丢弃。单轮错误后成功恢复的轨迹会被保留，因为它们教会模型具备错误韧性的行为。

后处理转换。被接受的轨迹会经历以下转换：

- **推理 tag 转换：** Gemini 输出中的所有 `<scratchpad>...</scratchpad>` tag 都会转换为 `<think>...</think>`，以兼容 Qwen3 聊天模板；Qwen3 使用 `<think>` 作为原生推理 tag。
- **工具名归一化：** Gemini 偶尔会生成工具名变体（例如 `google_web_search`、`Scholar_Search`）或畸形属性字符串。这些会被归一化为规范的 `google_search` 和 `snippet_search` 名称。

B.2.4. 训练数据格式

每条过滤后的轨迹都会转换为一个单轮 ChatML 对话，其中包含三条消息：

- **System：** 完整智能体系统 prompt（第 B.1 节中的统一 Qwen3 版本，而不是 Gemini 适配的生成 prompt）。
- **User：** 原始查询，并附加格式特定额外指令。
- **Assistant：** 完整多轮轨迹，其中工具输出被特殊 `span-masking` 标记包裹。训练期间，只有模型生成 token（思考、规划、工具调用、状态评估、审阅和答案）接收梯度；工具输出 token 被 mask，使模型不会学习记忆搜索结果。

最终，该过程产生约 11k 个 SFT 样本；由于上述反复出现的错误被过滤掉，这比 DR Tulu 少约 2k 个样本。

C. 阶段化演化评分规约评估细节

本节提供第 3.3 节中阶段化演化评分规约设计的实现细节。裁判分两阶段运行：自适应评分规约生成通过比较同一问题的轨迹提出新评分规约，阶段化打分则用当前评分规约集合评估每条轨迹。两个阶段都使用带结构化 JSON 输出的 LLM 裁判（Gemini-3-Flash）。

C.1. 评分规约缓冲区

对每个训练问题，我们维护一个评分规约缓冲区，其中包含两类评分规约：持久评分规约（来自训练数据的静态真值评分规约，永不移除）和活跃评分规约（由裁判在线提出的自适应评分规约，按阶段组织，并受每阶段容量上限约束）。持久评分规约改编自 Shao et al. (2025)，且只用于最终答案阶段。在每个训练 step 中，对 batch 内每个唯一问题，裁判会 (i) 通过比较 rollout group 生成新的自适应评分规约，(ii) 将其加入缓冲区，(iii) 使用组合评分规约集合为所有轨迹打分，并 (iv) 移除未能有意义地区分轨迹质量的低区分度评分规约。

C.2. 自适应评分规约生成

评分规约生成 prompt 要求裁判识别最具区分度、阶段局部的标准，用以解释为什么某些轨迹优于其他轨迹。我们考虑了若干设计原则：

- **有区分度且具体：** 每条评分规约必须实际区分同一问题上的强轨迹和弱轨迹。描述必须引用问题的具体方面，使另一个打分器能够无歧义地判断。禁止使用“good research quality”之类模糊评分规约。
- **阶段局部且非冗余：** 评分规约针对每个阶段的特定职责。裁判避免为同一标准创建正负镜像版本，也会跳过已由现有评分规约覆盖的标准。
- **反 hack：** 裁判不得创建仅检查 XML tag 存在、奖励对弱计划的形式服从、过拟合某条轨迹措辞，或把自洽性与真实质量混淆的评分规约。

由评分规约引导的脚手架带来的一个关键特性是：裁判在提出自适应评分规约时，可以使用不同轨迹中智能体自己的 `<rubric>` 块作为参照；跨轨迹的强评分规约可以揭示重要任务维度和失败

模式。然而，轨迹自己的评分规约永远不是打分标准：裁判被指示不得奖励遵循弱自评分规约，也不得惩罚超出原始计划的、基于证据的改进。

prompt 不规定固定模板，而是提供阶段特定指导作为起点。对每个阶段，一个核心问题会框定评估：“智能体是否理解了问题？”（Plan）、“它是否有效搜索并适应？”（Research）、“它是否诚实审查准备状态？”（Review），以及“最终答案是否高质量？”（Answer）。prompt 会建议常见有用维度（例如 Research 中的查询具体性和基于证据的转向），但鼓励裁判发现每个具体问题中真正重要的内容。

每个评分规约条目包含 title、description 和 weight（1=minor, 2=important, 3=critical），并按阶段组织为正向和负向评分规约。阶段 1–3 的目标数量是每阶段 1–4 条，阶段 4 为 2–5 条；这些是目标而不是定额。完整评分规约生成 prompt 如下：

Stagewise Adaptive Rubric Generation Prompt (Core)

You are an expert evaluator generating stagewise comparative rubrics for multiple full trajectories produced by the SAME research agent on the SAME question.

Goal

Identify the most discriminative, stage-local criteria that explain why some trajectories are better than others. Evaluate real process quality and answer quality — not XML compliance, verbosity, or shallow self-consistency.

How to Read the Trajectories

Each trajectory is a structured full execution trace:

- Stage 1 — Plan: <structured_plan> with <deep_analysis>, <rubric>, <research_plan>
- Stage 2 — Research: iterative <state_evaluation>, tool calls, and possible plan/rubric updates
- Stage 3 — Review: <review> with <rubric_review> and <writing_plan>
- Stage 4 — Answer: final <answer>

Do not reward a stage just because the relevant tags exist. Judge whether that stage actually performs its intended function well.

How to Use Agent-Generated Rubrics

A trajectory’s own Stage 1 <rubric> is never the scoring standard. Use it only as a reference signal:

- it shows what the agent recognized as important,
 - it may surface useful task dimensions,
 - it may expose shallow planning if it misses critical needs.
- But: never reward following a weak self-rubric, never let a narrow self-rubric lower the real standard, never penalize evidence-based improvement beyond the original plan.

Stage-by-Stage Guidance

For each stage, the most discriminative criteria often emerge from the specific question and trajectories themselves. The dimensions below are common starting points:

Stage 1 — PLAN: task understanding depth, identification of

```

hidden constraints, rubric specificity, plan proportionality.
Stage 2 — RESEARCH: query specificity, evidence-based
pivoting, triangulation, stopping criteria.
Stage 3 — REVIEW: honest gap assessment, evidence-to-
structure mapping, drafting plan quality.
Stage 4 — ANSWER: readability, instruction following,
insightfulness, comprehensiveness, correctness, evidence
grounding. Evaluated independently from earlier trajectory.

## Anti-Hack Rules
Do NOT create rubrics that: only check tag existence, reward
formal obedience to a bad plan, overfit to one trajectory's
wording, confuse self-consistency with true quality, punish
evidence-based improvement, or reward unnecessary overhead.

## Selection Rules
- Fewer, sharper rubrics over many generic ones.
- Skip criteria where all trajectories perform similarly.
- Never create positive and negative mirrors of the same idea.
- Conservative negative rubrics: target clear failure modes.

## Output Format
Return rubrics by stage (stage_1 through stage_4), each with
positive_rubrics and negative_rubrics. Each item: title,
description, weight (1-3).

```

C.3. 阶段化打分

评分规约生成后，每条轨迹都会独立地依据组合评分规约集合（持久 + 活跃）打分。正向评分规约使用 0/1/2 标度（缺失/部分/完整），负向评分规约使用相同标度，但在聚合时取反：得分 0（无缺陷）会产生正向贡献。每次评估都包含一个基于具体轨迹证据的简短理由。对每个阶段 k ，阶段分数 $R_{i,k} \in [0, 1]$ 是该阶段内评分规约分数的加权平均，负向分数在聚合前取反。

Stagewise Scoring Prompt

```

You are an expert evaluator. You will receive an AI research
agent's full trajectory and a set of rubrics grouped by stage.
Score each rubric strictly based on the trajectory evidence.

## Trajectory Structure
- Stage 1 (Plan): start through end of </structured_plan>
- Stage 2 (Research): after </structured_plan> through all
  tool-call loops
- Stage 3 (Review): last <think> before <review> through
  </review>
- Stage 4 (Answer): <answer> through end of text

## Scoring Rules
[POSITIVE] rubrics:
  2 = FULLY exhibits this quality
  1 = PARTIALLY exhibits it
  0 = Completely ABSENT or fails

```

```
[NEGATIVE] rubrics:
  2 = Fully EXHIBITS the flaw
  1 = PARTIALLY exhibits the flaw
  0 = Successfully AVOIDS the flaw

## Instructions
- Score each rubric independently.
- Use the rubric description as the sole scoring criterion.
- Provide brief justification grounded in specific trajectory
  evidence (quote or reference concrete content).
- Return the exact rubric index with each score.
```

C.4. 缓冲区管理与实现

缓冲区动态。 每个阶段都维护活跃评分规约的容量上限（在我们的实验中，阶段 1–4 分别为 3、2、2、3）。当某阶段在打分后超过其上限时，区分度最低的评分规约会被移除；区分度通过 rollout group 中分数方差衡量。持久评分规约永不移除。当一个问题在后续训练 step 中再次出现时，来自改进策略的新自适应评分规约会被加入，可能替换不再有区分度的陈旧评分规约。这确保裁判标准与策略共同演化，与 Shao et al. (2025) 的演化评分规约范式一致；此处该范式从仅答案扩展到阶段化评估。

结构化 JSON 输出。 评分规约生成和打分都使用 Gemini 的结构化输出模式(response_mime_type="application/json")并配合由 Pydantic 派生的 JSON schema。这保证了 schema 遵循性（评分规约按阶段组织并带 title/description/weight，分数带索引和理由），无需脆弱的事后文本解析。

Batch 并行。 每个训练 step 中，batch 包含 32 个唯一问题 × 8 条 rollout = 256 条轨迹。所有 32 个评分规约生成调用通过 asyncio.gather 并发启动，随后 256 个打分调用并行执行。每个调用都包含指数退避重试逻辑（最多 5 次重试）。失败调用会被视作“无新评分规约”（生成），或回退为仅使用终端答案分数（打分）。

效率。 评分规约生成每个 step 只需要 32 次调用（每个问题一次，而非每条轨迹一次）。打分需要 256 次调用，但每次都较轻量（每条轨迹约 ~8–15 条评分规约）。评分规约生成 + 打分合计每个 step 约需 5 分钟，并与训练引擎的梯度计算重叠。选择 Gemini-3-Flash 作为裁判模型是出于成本和延迟考虑；结构化输出约束和详细 prompt 弥补了较小模型的局限。

D. 异步反思流水线与窗口化课程

本附录提供第 3.4 节中元策略训练流水线和窗口化检索课程的实现细节。

D.1. 训练流水线架构

在我们的智能体循环中，每个 RL 训练 step 都包含若干顺序阶段：rollout 生成（通过 vLLM 生成多轮工具增强轨迹）、阶段化裁判打分（SS-GRPO 奖励计算），以及策略梯度更新。反思生成（提示骨干从采样轨迹生成以评分规约为基础的反思）会引入额外计算需求，我们将其与主循环重叠。

我们的流水线使用三个并发线程：

1. **主线程（训练引擎）：**对策略执行梯度更新。在 Phase A（对上一 step 延迟反思进行元策略更新）和 Phase B（对当前 step rollout 进行任务策略 SS-GRPO 更新）之间交替。

2. **推理线程 (vLLM):** 生成多轮工具增强 rollout。在 Phase A 期间, 训练引擎在延迟反思上训练的同时, 推理引擎开始生成下一 batch rollout, 从而完全重叠推理与反思训练。
3. **数据准备线程:** 运行裁判打分 (异步 Gemini API 调用), 把反思生成和反思判断作为并发后台任务启动, 并准备打包后的训练 batch。奖励打分结果会立即返回用于任务策略训练; 反思打分则继续异步进行。

D.2. 一步延迟反思训练

同步实现会阻塞下一次任务 rollout, 直到反思生成、判断和元策略更新完成。我们改为将反思训练延迟一个 RL step, 如图 4 下半部分所示。

在 step N :

1. 推理引擎为 step N 生成任务 rollout。
2. 数据准备线程为 step N rollout 打分 (SS-GRPO 奖励), 并同时启动后台任务: (a) 通过 vLLM 生成反思 rollout, 为每条采样轨迹产生 n 个候选; 以及 (b) 对反思候选进行裁判打分。
3. 奖励结果立即返回; 训练引擎在 step N 上执行 SS-GRPO 任务策略更新。
4. 与此同时, 反思打分在后台完成。被接受的反思被插入评分规约库, 已打分反思样本被放入延迟缓冲区。
5. 在 step $N+1$ 开始时, 在 **Phase A** 期间, 训练引擎在 step N 的延迟反思缓冲区上训练, 同时推理引擎生成 step $N+1$ rollout。

这种一步陈旧性以精确同步换取更高基础设施利用率: 推理和训练引擎持续保持占用, 元策略训练实际上不会为 SS-GRPO 循环增加额外 wall-clock 开销。

D.3. 窗口化课程

由于反思训练延迟一个 step, 且评分规约库插入异步发生, 一个在查询首次出现后立即重访它的朴素课程, 可能会在相应反思生成并被接受之前就尝试 episode 内检索。为避免这一冲突, 我们引入窗口大小为 K 的窗口化课程, 在查询第一次和第二次出现之间提供足够的时间间隔。

在每个 $2K$ step 窗口内, 训练在两个阶段之间交替:

1. **新查询阶段** (窗口内 step $1, \dots, K$): dataloader 采样 K 个新查询 batch $\{B_1, B_2, \dots, B_K\}$ 。对每个 batch, 评分规约库执行跨 *episode* 检索: 来自过去不同查询的语义相似条目会作为 few-shot 示例注入。每个 step 末尾, 反思生成在后台异步启动。
2. **重复阶段** (窗口内 step $K+1, \dots, 2K$): 相同 batch 按顺序重放: $B_1, B_2, \dots, B_K$ 。对每个 batch, 评分规约库执行 *episode* 内检索: 检索新查询阶段生成的精确反思, 并将其作为直接自我指导注入。

一个查询首次出现和重复出现之间的 K step 间隔保证了延迟反思流水线 (生成、判断、库插入, 以及至少一次延迟训练 step) 会在尝试 episode 内检索之前完全完成。在实验中, 我们使用 $K=3$, 相对于一步延迟提供了充足余量。

D.4. 轨迹采样与候选生成

对新查询阶段中的每个查询, 我们从 rollout group 中随机采样一条轨迹用于反思生成。采样是在轨迹索引上均匀随机进行, 没有长度偏置或基于分数的选择, 这模拟了智能体无法访问特权打分信息的推理条件。从采样轨迹出发, 我们通过 vLLM 并行采样 (temperature 0.7, 单 prompt, n 个 completion) 生成 $n=8$ 个反思候选。每个候选都由裁判独立打分, 只有输出格式有效且得分最高的候选会被接受进入评分规约库。每个查询的反思生成彼此独立, 因此一个查询失败不会影响其他查询。

窗口内 step	阶段	数据	检索模式
1	新查询	B_1 (新)	跨 episode (相似)
2	新查询	B_2 (新)	跨 episode (相似)
3	新查询	B_3 (新)	跨 episode (相似)
4	重复	B_1 (重放)	episode 内 (精确)
5	重复	B_2 (重放)	episode 内 (精确)
6	重复	B_3 (重放)	episode 内 (精确)

图 7 | $K=3$ 的窗口化课程。每个 $2K=6$ step 窗口在带跨 episode 检索的新查询和带 episode 内精确检索的重复查询之间交替。3-step 间隔确保延迟反思流水线在重复前已经完全完成。

D.5. 评分规约库持久化与检索

评分规约库维护一个基于查询 embedding 的内存 FAISS 索引（在 CPU 上通过 Qwen3-Embedding-0.6B 计算）。对于跨 episode 检索，查询 embedding 会通过内积相似度与已存 embedding 比较，并返回 top-k 条目（默认 $k=2$ ）。对于 episode 内检索，条目通过精确问题 hash（SHA-256）匹配。当某查询已有库条目，并在后续训练 step 中再次遇到同一查询时，新反思会覆盖旧反思，使评分规约库与演化中的策略保持同步。

评分规约库每 10 step 以及每个模型 checkpoint 都会持久化，并使用原子写（先写入临时文件，再重命名）以防损坏。训练恢复时，评分规约库会从与模型权重相同 global step 对应的 checkpoint 恢复，从而确保策略参数与记忆内容一致。

D.6. Prompt 模板

D.6.1. 反思生成 *prompt*

策略模型在生成以评分规约为基础的反思时，接收如下系统 prompt：

Reflection System Prompt

You are a strict postmortem editor for long-form deep research QA.

You will receive:

- a question
- a research trajectory ending in a final
<answer>...</answer>

Your job is not to answer the question again. Your job is to extract the most useful guidance for:

1. a stronger next attempt on this question, and
2. similar long-form research questions.

First, read the final <answer>.

Judge it on: correctness and calibration;
instruction-following and coverage; research quality
and verification; synthesis and insight;
communication and structure.

Then identify the 2-4 highest-leverage strengths or weaknesses, trace them back to the visible trajectory, and turn them into reusable guidance.

Rules:

- Stay grounded in the provided question and trajectory.
- Do not invent flaws just to be critical.
- Do not speculate about hidden reasoning not shown in the trajectory.
- Do not rewrite the answer.
- Do not give generic advice like "be more careful."
- Write specific guidance that is grounded in this case but transferable to similar questions.

Output format (exactly two blocks):

```
<reflection_rubrics>
Critical Requirement / Analytical Approach
/ Communication & Structure / Pitfalls
</reflection_rubrics>

<reflection_takeaways>
1-4 concise portable lessons
</reflection_takeaways>
```

用户消息提供问题和完整研究轨迹，指示模型检查最终答案、追踪优势与弱点，并生成两个输出块。

D.6.2. 裁判打分 *prompt*

LLM 裁判（Gemini）以特权方式访问已打分轨迹，包括逐评分规约分数和评估器理由，从而评估每个反思候选。裁判根据候选对未来尝试的有用程度为其打分：

Reflection Judge System Prompt (abridged)

You are an expert judge evaluating reflection candidates produced by a research agent.

Scoring Dimensions (each 0.0 to 1.0):

Diagnostic Accuracy (weight 0.4)

- Does it correctly identify the main strengths and weaknesses? Is it aligned with the evaluator justifications and visible trajectory?
- Penalize: missing a major failure clearly flagged by the evaluator; inventing problems not supported by the trajectory; misidentifying root causes.

Specificity (weight 0.3)

- Is the guidance concrete, actionable, and tailored for next attempt of the question?
- Penalize: generic advice ("be more thorough"); checklist items that could apply to any task; merely restating evaluator language.

Scope & Balance (weight 0.3)

- Is the guidance helpful for other questions?
Are takeaways complementary?
Penalize: missing an important category; repeating the same point across sections.

Rules:

- Score based on the reflection's quality as future guidance, not on the trajectory's quality.
- A reflection on a perfect trajectory can score low if it is generic.
- A reflection on a failed trajectory can score high if it precisely identifies root causes.

用户消息提供原始问题、所有反思候选，以及带评估器反馈的已打分轨迹。裁判返回每个候选在所有三个维度上的分数。

D.6.3. 注入格式

检索到的库条目会作为 <reference_examples> 块注入，并在 tokenization 前附加到用户消息中。第 3.4 节中的两种检索模式—episode 内细化和跨 episode 迁移—使用不同前言来调节智能体对检索指导的使用方式。

episode 内注入。 当智能体重访之前尝试过的问题时（窗口化课程的重复阶段），会注入上一次遭遇中被接受的反思：

Within-Episode Injection Format

```
<reference_examples>
You have attempted this exact question before. Below
are the rubrics and reflections from your previous
attempt. Use them to improve your planning and
answering -- avoid past mistakes and build on what
worked.

## Your Previous Attempt on This Question:

### Rubrics:
{rubrics from bank item}

### Takeaways:
{reflections from bank item}
</reference_examples>

{Original user question}
```

跨 episode 注入。 对新查询（新查询阶段），评分规约库检索 top-k 个语义相似条目，并将其作为评分规约奠基示例呈现：

Cross-Episode Injection Format

```

<reference_examples>
Below are rubrics and reflections from similar
questions that were previously analyzed. Use them as
reference to guide your planning and answering --
adapt to the current question's specific needs.
Do NOT copy them verbatim; extract what is relevant
and adjust.

## Similar Question 1:
{question from bank item 1}

### Rubrics:
{rubrics from bank item 1}

### Takeaways:
{reflections from bank item 1}

---

## Similar Question 2:
{question from bank item 2}

### Rubrics:
{rubrics from bank item 2}

### Takeaways:
{reflections from bank item 2}
</reference_examples>

{Original user question}

```

在两种情况下，参考块都位于原始用户问题之前，因此智能体会在开始结构化计划之前看到指导。episode 内格式传达直接自我改进（“avoid past mistakes”），而跨 episode 格式传达类比迁移（“adapt to the current question’s specific needs”）。

E. 理论分析

E.1. 阶段信息的价值

在正文中，为了可读性，定理 1 在条件期望中使用了非正式记号 h, c, z 。在本附录中，我们显式给出概率空间： H, C, Z 表示随机变量，而 h, c, z 表示实现值。我们还略微强化了定理中的严格性条件，要求被比较阶段在给定 c 时具有正条件概率；如果没有这一要求，不可能阶段事件上的逐点量 $\mathbb{E}[U(H, a) \mid C = c, Z = z]$ 会依赖条件期望版本。

下面结果是一个专门针对结构化智能体推理的信息价值命题。它比较两个信息结构： $\sigma(C)$ 和 $\sigma(C, Z)$ 。不同于完整状态抽象定理，它不假设 (C, Z) 足以代表整个历史 H ；它只量化在压缩决策状态下显式化阶段标签所带来的收益。

假设 1 (定理 1 的设置). 在本小节中，下列假设成立。

1. **底层概率空间。** 存在一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 和随机决策历史

$$H : \Omega \rightarrow \mathcal{H},$$

其中 $(\mathcal{H}, \mathcal{B}(\mathcal{H}))$ 是可测空间。 H 的分布记作 $d := \mathbb{P} \circ H^{-1}$ 。我们把 H 解释为从某个固定历史分布中采样得到的随机可达决策点。

2. **有限动作空间**。动作空间 $\mathcal{A}$ 是有限非空集合。因而， $\mathcal{A}$ 上的每个最大化和 $\argmax$ 都是良定义且非空的。
3. **压缩上下文和阶段标签**。存在可测映射

$$\phi : \mathcal{H} \rightarrow C$$

到标准 Borel 空间 $(C, \mathcal{B}(C))$ ， 以及一个可测阶段映射

$$\psi : \mathcal{H} \rightarrow [K] := \{1, \dots, K\},$$

such that

$$C := \phi(H), \quad Z := \psi(H).$$

由于 C 是标准 Borel 空间且 $[K]$ 有限， 下面使用的正则条件对象存在。

4. **可积效用**。对每个 $a \in \mathcal{A}$ ， 存在可测效用函数

$$U(\cdot, a) : \mathcal{H} \rightarrow \mathbb{R}$$

such that

$$\mathbb{E}[|U(H, a)|] < \infty.$$

在我们的应用中， $U(H, a)$ 可实例化为在决策点 H 选择动作 a 对应的延续效用或延续价值。

定义 1 (条件均值效用与阶段概率). 采用假设 1。对每个 $a \in \mathcal{A}$ ， 固定可测版本

$$\bar{q}(\cdot, a) : C \rightarrow \mathbb{R}, \quad q(\cdot, \cdot, a) : C \times [K] \rightarrow \mathbb{R}$$

such that

$$\bar{q}(C, a) = \mathbb{E}[U(H, a) \mid \sigma(C)] \quad \text{almost surely,}$$

and

$$q(C, Z, a) = \mathbb{E}[U(H, a) \mid \sigma(C, Z)] \quad \text{almost surely.}$$

For each $z \in [K]$, fix a measurable version

$$p(z \mid \cdot) : C \rightarrow [0, 1]$$

such that

$$p(z \mid C) = \mathbb{P}(Z = z \mid \sigma(C)) \quad \text{almost surely.}$$

我们记

$$\mathbb{P}_C := \mathbb{P} \circ C^{-1}$$

为 C 的分布， 并将上下文 $c \in C$ 处的阶段支撑定义为

$$S(c) := \{z \in [K] : p(z \mid c) > 0\}.$$

备注 1 (良定义性). 由于 $\mathcal{A}$ 有限且每个 $U(H, a)$ 可积， 对每个 $a \in \mathcal{A}$ ， 随机变量 $\bar{q}(C, a)$ 和 $q(C, Z, a)$ 都可积。事实上， 由条件期望的 Jensen 不等式，

$$|\bar{q}(C, a)| = |\mathbb{E}[U(H, a) \mid \sigma(C)]| \leq \mathbb{E}[|U(H, a)| \mid \sigma(C)] \quad \text{a.s.,}$$

and therefore

$$\mathbb{E}[|\bar{q}(C, a)|] \leq \mathbb{E}[|U(H, a)|] < \infty.$$

同一论证给出

$$\mathbb{E}[|q(C, Z, a)|] < \infty.$$

因此下文所有期望都是有限的。

定义 2 (扁平与阶段条件化决策价值). 采用假设 1 和定义 1。我们定义

$$V_{\text{flat}} := \mathbb{E} \left[\max_{a \in \mathcal{A}} \bar{q}(C, a) \right], \quad V_{\text{stage}} := \mathbb{E} \left[\max_{a \in \mathcal{A}} q(C, Z, a) \right].$$

这些正是正文定理 1 中出现的量在附录中的版本。等价地,

$$V_{\text{flat}} = \mathbb{E} \left[\max_{a \in \mathcal{A}} \mathbb{E}[U(H, a) | C] \right], \quad V_{\text{stage}} = \mathbb{E} \left[\max_{a \in \mathcal{A}} \mathbb{E}[U(H, a) | C, Z] \right].$$

下面引理是证明定理 1 所需的唯一结构恒等式。

引理 1 (将阶段条件化效用折叠到扁平信息结构). 采用假设 1 和定义 1。则对每个动作 $a \in \mathcal{A}$,

$$\bar{q}(C, a) = \sum_{z=1}^K p(z | C) q(C, z, a) \quad \text{almost surely.}$$

Proof. 固定任意动作 $a \in \mathcal{A}$ 。定义随机变量

$$R_a := \sum_{z=1}^K p(z | C) q(C, z, a).$$

我们将证明 R_a 是 $\mathbb{E}[U(H, a) | \sigma(C)]$ 的一个版本。由于根据定义 1, $\bar{q}(C, a)$ 也是 $\mathbb{E}[U(H, a) | \sigma(C)]$ 的一个版本, 结论随之成立。

首先注意 R_a 是 $\sigma(C)$ -可测的。事实上, 对每个固定 z , $p(z | C)$ 和 $q(C, z, a)$ 都是 $\sigma(C)$ -可测的, 因此它们的乘积是 $\sigma(C)$ -可测的, 而此类项的有限和仍是 $\sigma(C)$ -可测的。

剩下只需验证条件期望的定义性质。令 G 为任意有界 $\sigma(C)$ -可测随机变量。我们必须证明

$$\mathbb{E}[GR_a] = \mathbb{E}[GU(H, a)].$$

从左侧出发并展开 R_a 的定义, 得到

$$\begin{aligned} \mathbb{E}[GR_a] &= \mathbb{E} \left[G \sum_{z=1}^K p(z | C) q(C, z, a) \right] \\ &= \sum_{z=1}^K \mathbb{E}[G p(z | C) q(C, z, a)]. \end{aligned}$$

对每个固定 z , 随机变量 $Gq(C, z, a)$ 是 $\sigma(C)$ -可测且可积的。因此, 由条件期望的定义性质,

$$\begin{aligned} \mathbb{E}[G p(z | C) q(C, z, a)] &= \mathbb{E}[G q(C, z, a) \mathbb{E}[1\{Z = z\} | \sigma(C)]] \\ &= \mathbb{E}[G q(C, z, a) 1\{Z = z\}]. \end{aligned}$$

对 z 求和得到

$$\begin{aligned} \mathbb{E}[GR_a] &= \sum_{z=1}^K \mathbb{E}[G q(C, z, a) 1\{Z = z\}] \\ &= \mathbb{E} \left[G \sum_{z=1}^K 1\{Z = z\} q(C, z, a) \right] \\ &= \mathbb{E}[Gq(C, Z, a)] \end{aligned}$$

由定义 1,

$$q(C, Z, a) = \mathbb{E}[U(H, a) \mid \sigma(C, Z)] \quad \text{almost surely.}$$

因为 G 是 $\sigma(C)$ -可测的, 且 $\sigma(C) \subseteq \sigma(C, Z)$, 随机变量 G 也是 $\sigma(C, Z)$ -可测的。再次应用条件期望的定义性质得到

$$\mathbb{E}[G q(C, Z, a)] = \mathbb{E}[G U(H, a)].$$

结合前述等式, 我们得到

$$\mathbb{E}[G R_a] = \mathbb{E}[G U(H, a)]$$

对每个有界 $\sigma(C)$ -可测随机变量 G 都成立。证明完毕。

□

定义 3 (混叠间隙). *Adopt Assumption 1 and Definition 1.* 对 $c \in C$, 定义阶段混叠间隙

$$\Delta_{\text{alias}}(c) := \sum_{z=1}^K p(z \mid c) \max_{a \in \mathcal{A}} q(c, z, a) - \max_{a \in \mathcal{A}} \sum_{z=1}^K p(z \mid c) q(c, z, a).$$

由于 $\mathcal{A}$ 和 $[K]$ 有限, 且所选版本 p, q 可测, 函数 $\Delta_{\text{alias}} : C \rightarrow \mathbb{R}$ 是可测的。

现在可以重述并强化正文中的定理。

定理 2 (定理 1 的重述与强化). 采用假设 1 和定义 1-3。则

$$V_{\text{stage}} - V_{\text{flat}} = \mathbb{E}[\Delta_{\text{alias}}(C)] \geq 0.$$

因此,

$$V_{\text{stage}} \geq V_{\text{flat}}.$$

此外, 对 $\mathbb{P}_C$ -几乎处处的 $c \in C$, 以下两者等价:

1. $\Delta_{\text{alias}}(c) = 0$.
2. *There exists an action*

$$a_c^* \in \bigcap_{z \in S(c)} \arg \max_{a \in \mathcal{A}} q(c, z, a).$$

特别地, 如果存在可测集合 $C_0 \subseteq C$, 满足

$$\mathbb{P}_C(C_0) > 0$$

以及两个不同阶段 $z \neq z'$, 使得对每个 $c \in C_0$,

$$p(z \mid c) > 0, \quad p(z' \mid c) > 0, \quad \arg \max_{a \in \mathcal{A}} q(c, z, a) \cap \arg \max_{a \in \mathcal{A}} q(c, z', a) = \emptyset,$$

then

$$V_{\text{stage}} > V_{\text{flat}}.$$

Proof. 首先, 我们重写 V_{stage} 和 V_{flat} , 以展示其差值形式为 $\mathbb{E}[\Delta_{\text{alias}}(C)]$ 。由定义 2,

$$V_{\text{stage}} = \mathbb{E} \left[\max_{a \in \mathcal{A}} q(C, Z, a) \right].$$

For each fixed $z \in [K]$, define

$$M_z(C) := \max_{a \in \mathcal{A}} q(C, z, a).$$

由于 $\mathcal{A}$ 有限且对每个 a , $q(\cdot, z, a)$ 可测, 随机变量 $M_z(C)$ 是 $\sigma(C)$ -可测的。此外, 因为 z 取值于有限集合 $[K]$,

$$\max_{a \in \mathcal{A}} q(C, Z, a) = \sum_{z=1}^K 1\{Z = z\} M_z(C) \quad \text{almost surely.}$$

给定 $\sigma(C)$ 取条件期望, 得到

$$\begin{aligned} \mathbb{E} \left[\max_{a \in \mathcal{A}} q(C, Z, a) \mid \sigma(C) \right] &= \mathbb{E} \left[\sum_{z=1}^K 1\{Z = z\} M_z(C) \mid \sigma(C) \right] \\ &= \sum_{z=1}^K \mathbb{E} [1\{Z = z\} M_z(C) \mid \sigma(C)] \\ &= \sum_{z=1}^K M_z(C) \mathbb{E} [1\{Z = z\} \mid \sigma(C)] \\ &= \sum_{z=1}^K p(z \mid C) M_z(C). \end{aligned}$$

再次取期望并使用塔式性质得到

$$V_{\text{stage}} = \mathbb{E} \left[\sum_{z=1}^K p(z \mid C) \max_{a \in \mathcal{A}} q(C, z, a) \right].$$

接着重写 V_{flat} 。由定义 2,

$$V_{\text{flat}} = \mathbb{E} \left[\max_{a \in \mathcal{A}} \bar{q}(C, a) \right].$$

由引理 1,

$$\bar{q}(C, a) = \sum_{z=1}^K p(z \mid C) q(C, z, a) \quad \text{almost surely.}$$

将该恒等式代入前式得到

$$V_{\text{flat}} = \mathbb{E} \left[\max_{a \in \mathcal{A}} \sum_{z=1}^K p(z \mid C) q(C, z, a) \right].$$

于是根据定义 3 可直接看出

$$V_{\text{stage}} - V_{\text{flat}} = \mathbb{E} \left[\sum_{z=1}^K p(z \mid C) \max_{a \in \mathcal{A}} q(C, z, a) - \max_{a \in \mathcal{A}} \sum_{z=1}^K p(z \mid C) q(C, z, a) \right] = \mathbb{E} [\Delta_{\text{alias}}(C)].$$

剩下只需证明对每个 c , $\Delta_{\text{alias}}(c) \geq 0$ 。固定任意 $c \in C$ 。对每个动作 $a \in \mathcal{A}$ 和每个阶段 $z \in [K]$, 有

$$q(c, z, a) \leq \max_{a' \in \mathcal{A}} q(c, z, a').$$

两边乘以非负量 $p(z \mid c)$ 并对 z 求和, 得到

$$\sum_{z=1}^K p(z \mid c) q(c, z, a) \leq \sum_{z=1}^K p(z \mid c) \max_{a' \in \mathcal{A}} q(c, z, a').$$

由于该不等式对每个 $a \in \mathcal{A}$ 都成立，对左侧关于 a 取最大后仍成立，这意味着 $\Delta_{\text{alias}}(c) \geq 0$ 。因此

$$V_{\text{stage}} - V_{\text{flat}} = \mathbb{E}[\Delta_{\text{alias}}(C)] \geq 0,$$

这推出

$$V_{\text{stage}} \geq V_{\text{flat}}.$$

接下来刻画阶段混叠间隙为零的情形。由于 $\mathcal{A}$ 有限且非空，至少存在一个动作

$$a_c^{\text{flat}} \in \arg \max_{a \in \mathcal{A}} \sum_{z=1}^K p(z | c) q(c, z, a).$$

By Definition 3,

$$\begin{aligned} \Delta_{\text{alias}}(c) &= \sum_{z=1}^K p(z | c) M_z(c) - \sum_{z=1}^K p(z | c) q(c, z, a_c^{\text{flat}}) \\ &= \sum_{z=1}^K p(z | c) (M_z(c) - q(c, z, a_c^{\text{flat}})). \end{aligned}$$

右侧每个求和项都是非负的，因为 $M_z(c)$ 是 $q(c, z, \cdot)$ 在 $\mathcal{A}$ 上的最大值。现在分别证明两个方向。

(i) 若 $\Delta_{\text{alias}}(c) = 0$ ，则在 $S(c)$ 上存在公共最大化动作。这意味着

$$\sum_{z=1}^K p(z | c) (M_z(c) - q(c, z, a_c^{\text{flat}})) = 0.$$

和中的每一项都是非负的。因此，对每个满足 $p(z | c) > 0$ 的 z ，必有

$$M_z(c) - q(c, z, a_c^{\text{flat}}) = 0,$$

i.e.,

$$q(c, z, a_c^{\text{flat}}) = M_z(c) = \max_{a \in \mathcal{A}} q(c, z, a).$$

因此

$$a_c^{\text{flat}} \in \arg \max_{a \in \mathcal{A}} q(c, z, a) \quad \text{for every } z \in S(c).$$

等价地，

$$a_c^{\text{flat}} \in \bigcap_{z \in S(c)} \arg \max_{a \in \mathcal{A}} q(c, z, a),$$

所以公共最大化动作存在。

(ii) 若在 $S(c)$ 上存在公共最大化动作，则 $\Delta_{\text{alias}}(c) = 0$ 。

反过来，假设存在动作

$$a_c^{\star} \in \bigcap_{z \in S(c)} \arg \max_{a \in \mathcal{A}} q(c, z, a).$$

则对每个 $z \in S(c)$,

$$q(c, z, a_c^{\star}) = M_z(c).$$

对 $z \notin S(c)$ ，有 $p(z | c) = 0$ ，因此这些阶段对下面任何加权和都没有贡献。所以

$$\sum_{z=1}^K p(z | c) q(c, z, a_c^{\star}) = \sum_{z=1}^K p(z | c) M_z(c).$$

由于 $a_c^\star$ 是最大化中的一个可行动作,

$$\max_{a \in \mathcal{A}} \sum_{z=1}^K p(z | c) q(c, z, a) \geq \sum_{z=1}^K p(z | c) q(c, z, a_c^\star) = \sum_{z=1}^K p(z | c) M_z(c).$$

另一方面, 以下关系显然成立且已在上文证明

$$\max_{a \in \mathcal{A}} \sum_{z=1}^K p(z | c) q(c, z, a) \leq \sum_{z=1}^K p(z | c) M_z(c).$$

因此等号成立:

$$\max_{a \in \mathcal{A}} \sum_{z=1}^K p(z | c) q(c, z, a) = \sum_{z=1}^K p(z | c) M_z(c),$$

这正是

$$\Delta_{\text{alias}}(c) = 0.$$

结合 (i) 和 (ii), 我们得到对每个 $c \in C$,

$$\Delta_{\text{alias}}(c) = 0 \iff \bigcap_{z \in S(c)} \arg \max_{a \in \mathcal{A}} q(c, z, a) \neq \emptyset.$$

由于所有对象都通过所选条件期望和条件概率版本只在 $\mathbb{P}_C$ -零测集之外定义, 该等价性解释为对 $\mathbb{P}_C$ -几乎处处的 c 成立。

最后, 我们证明严格不等式准则。 假设存在可测集合 $C_0 \subseteq C$, 满足

$$\mathbb{P}_C(C_0) > 0$$

以及两个不同阶段 $z \neq z'$, 使得对每个 $c \in C_0$,

$$p(z | c) > 0, \quad p(z' | c) > 0, \quad \arg \max_{a \in \mathcal{A}} q(c, z, a) \cap \arg \max_{a \in \mathcal{A}} q(c, z', a) = \emptyset.$$

由上面证明的零间隙等价性, 并且我们知道 $\Delta_{\text{alias}}(c) \geq 0$, 这意味着 $\Delta_{\text{alias}}(C) \geq 0$ 几乎必然成立, 因此

$$V_{\text{stage}} > V_{\text{flat}}.$$

证明完毕。 □

备注 2 (解释). 定理 2 以两种方式强化正文定理。第一, 它给出了显式化阶段标签带来的精确收益:

$$V_{\text{stage}} - V_{\text{flat}} = \mathbb{E}[\Delta_{\text{alias}}(C)].$$

第二, 它表明, 当且仅当压缩上下文 c 混叠了阶段条件最优动作不一致的决策点时, 收益严格为正; 这通常正是实际情形。这正是显式阶段结构在压缩局部上下文下帮助推理的精确含义。

E.2. 裁判对齐的阶段加权信用分配

本小节形式化正文中定理 3 背后的直觉。与附录 E.1 一样, 我们工作在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 。不过, 不同于研究单个随机决策点的附录 E.1, 这里我们分析完整 rollout 及其策略梯度信号。

设置与记号。 我们省略第 3.3 节中使用的 rollout 索引 i , 分析一条通用 rollout。令 τ 表示从策略诱导分布 $p_\theta(\tau)$ 中采样的 rollout, 并令 $\mathcal{B}_k$ 表示第 k 阶段的 token 集合, 与正文记号一致。对每个 token step t , 令

$$H_t := (q, a_{<t}, o_{<t})$$

表示采取动作 a_t 之前的随机历史, 并定义阶段 score-function 和

$$\Gamma_k := \sum_{t \in \mathcal{B}_k} \nabla_\theta \log \pi_\theta(a_t | H_t).$$

我们假设 $\pi_\theta(a | h)$ 关于 θ 可微, 环境动态独立于 θ , 且对每个 k , Γ_k 平方可积。

对每个阶段 $k \in [K]$, 令

$$R_k : \Omega \rightarrow \mathbb{R}$$

表示观测到的阶段化裁判分数, 并令

$$Y_k : \Omega \rightarrow \mathbb{R}$$

表示第 k 阶段的潜在真实过程分数。两者都假设可积。

如第 3.3 节, 令

$$\Lambda = (\lambda_{k,j}) \in [0, 1]^{K \times K}$$

为满足下式的因果阶段权重矩阵

$$\lambda_{k,j} = 0 \quad \text{for } j < k, \quad \lambda_{k,k} = 1.$$

定义。 对每个阶段 k , 定义 oracle 过程级梯度贡献

$$g_k^\star := \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k Y_j]. \quad (2)$$

这就是如果潜在真实阶段分数可以直接观测时, 由阶段依赖回报诱导出的第 k 阶段梯度贡献 $G_{i,k}^\Lambda := \sum_{j=k}^K \lambda_{k,j} R_{i,j}$ 。

定义由裁判诱导的阶段加权信号

$$g_k^\Lambda := \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k R_j], \quad (3)$$

以及终端广播信号

$$g_k^{\text{term}} := \mathbb{E}[\Gamma_k R_K], \quad (4)$$

最后, 定义

$$M_k^\Lambda := \left\| \mathbb{E}[\Gamma_k Y_K] - \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k Y_j] \right\|_2. \quad (5)$$

量 M_k^Λ 衡量当只使用最终阶段分数 Y_K , 而不是完整阶段加权 oracle 目标时, 遗漏了多少 oracle 过程级信号。

假设 2 (裁判对齐). 对每个阶段对 $k \leq j$, 存在常数 $\epsilon_{k,j} \geq 0$, 使得

$$\|\mathbb{E}[\Gamma_k (R_j - Y_j)]\|_2 \leq \epsilon_{k,j}. \quad (6)$$

也就是说, 在由 Γ_k 定义的梯度相关方向上, 观测裁判分数 R_j 近似潜在真实分数 Y_j 。

定理 3 (阶段加权信用的收益, 非正式). 如果被遗漏的真实中间信号超过累积裁判不对齐, 则阶段加权信用会产生严格更好的梯度近似:

$$\|g_k^\Lambda - g_k^\star\|_2 < \|g_k^{\text{term}} - g_k^\star\|_2.$$

定理 4 (定理 3 的形式版本). 在假设 2 下, 对每个阶段 $k \in [K]$, 以下结论成立.

1. 阶段加权信号相对于 *oracle* 目标的误差:

$$\|g_k^\Lambda - g_k^\star\|_2 \leq \sum_{j=k}^K \lambda_{k,j} \epsilon_{k,j}.$$

2. 终端广播相对于 *oracle* 目标的下界:

$$\|g_k^{\text{term}} - g_k^\star\|_2 \geq M_k^\Lambda - \epsilon_{k,K}.$$

3. 比较. 如果

$$\sum_{j=k}^K \lambda_{k,j} \epsilon_{k,j} < M_k^\Lambda - \epsilon_{k,K},$$

then

$$\|g_k^\Lambda - g_k^\star\|_2 < \|g_k^{\text{term}} - g_k^\star\|_2.$$

特别地, 当裁判不对齐相对于被遗漏的中间阶段 *oracle* 信号足够小时, 阶段加权信号比终端广播严格更接近期望的过程级梯度贡献。

Proof. 固定阶段 k 。首先证明 (1)。由定义 3 和 2,

$$g_k^\Lambda - g_k^\star = \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k R_j] - \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k Y_j] = \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k (R_j - Y_j)].$$

取欧几里得范数并应用三角不等式得到

$$\|g_k^\Lambda - g_k^\star\|_2 \leq \sum_{j=k}^K \lambda_{k,j} \|\mathbb{E}[\Gamma_k (R_j - Y_j)]\|_2.$$

应用假设 2 得到所需形式,

$$\|g_k^\Lambda - g_k^\star\|_2 \leq \sum_{j=k}^K \lambda_{k,j} \epsilon_{k,j}.$$

其次证明 (2)。由定义 4 和 2,

$$g_k^{\text{term}} - g_k^\star = \mathbb{E}[\Gamma_k R_K] - \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k Y_j] = \underbrace{\mathbb{E}[\Gamma_k (R_K - Y_K)]}_{=: E_k} + \underbrace{\left(\mathbb{E}[\Gamma_k Y_K] - \sum_{j=k}^K \lambda_{k,j} \mathbb{E}[\Gamma_k Y_j] \right)}_{=: D_k}.$$

由定义 5 可知 $\|D_k\|_2 = M_k^\Lambda$ 。应用反三角不等式,

$$\|E_k + D_k\|_2 \geq \|D_k\|_2 - \|E_k\|_2,$$

得到

$$\|g_k^{\text{term}} - g_k^\star\|_2 \geq M_k^\Lambda - \|\mathbb{E}[\Gamma_k(R_K - Y_K)]\|_2.$$

使用假设 2 并取 $j = K$,

$$\|\mathbb{E}[\Gamma_k(R_K - Y_K)]\|_2 \leq \epsilon_{k,K}.$$

因此

$$\|g_k^{\text{term}} - g_k^\star\|_2 \geq M_k^\Lambda - \epsilon_{k,K}.$$

最后, 我们给出最后一个结论。我们已经证明

$$\|g_k^\Lambda - g_k^\star\|_2 \leq \sum_{j=k}^K \lambda_{k,j} \epsilon_{k,j}, \quad \|g_k^{\text{term}} - g_k^\star\|_2 \geq M_k^\Lambda - \epsilon_{k,K}.$$

因此, 如果

$$\sum_{j=k}^K \lambda_{k,j} \epsilon_{k,j} < M_k^\Lambda - \epsilon_{k,K},$$

则

$$\|g_k^\Lambda - g_k^\star\|_2 < \|g_k^{\text{term}} - g_k^\star\|_2.$$

这证明了第 3 项, 并完成证明。 $\square$

推论 1 (来自分数 MSE 的充分条件). 进一步假设存在常数 $B_k \geq 0$ 和 $\delta_j \geq 0$, 使得

$$\mathbb{E}[\|\Gamma_k\|_2^2] \leq B_k, \quad \mathbb{E}[(R_j - Y_j)^2] \leq \delta_j^2.$$

则假设 2 对以下取值成立:

$$\epsilon_{k,j} := \sqrt{B_k} \delta_j.$$

因此,

$$\|g_k^\Lambda - g_k^\star\|_2 \leq \sqrt{B_k} \sum_{j=k}^K \lambda_{k,j} \delta_j,$$

and

$$\|g_k^{\text{term}} - g_k^\star\|_2 \geq M_k^\Lambda - \sqrt{B_k} \delta_K.$$

Proof. 固定 $k \leq j$. 由 Cauchy-Schwarz 不等式,

$$\begin{aligned} \|\mathbb{E}[\Gamma_k(R_j - Y_j)]\|_2 &\leq \mathbb{E}[\|\Gamma_k\|_2 |R_j - Y_j|] \\ &\leq \left(\mathbb{E}[\|\Gamma_k\|_2^2]\right)^{1/2} \left(\mathbb{E}[(R_j - Y_j)^2]\right)^{1/2} \\ &\leq \sqrt{B_k} \delta_j. \end{aligned}$$

因此, 假设 2 在 $\epsilon_{k,j} = \sqrt{B_k} \delta_j$ 时成立。随后显示出的界立即由定理 4 得到。 $\square$

备注 3. 定理 4 和推论 1 突出了一个基本权衡: 阶段加权信用的优势取决于被遗漏的中间阶段 *oracle* 信号 M_k^Λ 的强度, 以及由分数误差 δ_j 捕获的裁判对齐质量之间的关系。关键的是, 这表明只要中间阶段包含足够真实的过程信号 (即, M_k^Λ 足够大), 捕获该密集信号的收益就会严格超过来自不完美中间裁判 $\delta_j > 0$ 的累积噪声。在这种区域中, 相较于仅依赖终端广播, 阶段加权信用是期望过程目标的严格更好近似。

E.3. 策略与评分规约库的裁判门控共同演化

本小节形式化第 3.4 节中 SCRIBE 的第三个组件。不同于研究显式阶段信息价值的附录 E.1，以及研究阶段化信用分配的附录 E.2，这里的对象是自我演化循环本身：同一个共享骨干既求解当前任务，也生成以评分规约为基础的反思；这些反思随后可以在 episode 内和跨 episode 被复用。

下面的形式化与我们的实现一致。任务目标更新轨迹 token，而反思目标只在反思 token 上计算。具体而言，在反思更新期间，被选中的 rollout 被视为固定条件上下文，因此反思效用梯度不会通过采样轨迹反向传播。所以，共同演化效应来自参数共享：任务更新和反思更新作用于同一组骨干参数，即便它们由不同的生成 token 块计算得到。

下面的关键假设是一个裁判门控的局部正迁移条件。这并不是全局声称每个生成反思在整个训练过程中总是有用。相反，它隔离出一个局部区域：在该区域中，被裁判接受的反思表现得像有帮助的辅助目标。类似的梯度相似性和正迁移条件在辅助学习和多任务优化文献中很常见：有帮助的辅助目标往往与主任务梯度对齐，而不对齐梯度会诱发负迁移 (Du et al., 2019; Liu et al., 2021; Wang et al., 2021; Wu et al., 2020; Yu et al., 2020)。与此同时，并非所有任务组合都适合一起训练 (Standley et al., 2020)。这一视角也与共享表征学习理论以及迁移中的任务相关性理论一致 (Chen et al., 2022; Maurer et al., 2016; Tripuraneni et al., 2020)。

假设 3 (裁判门控共同演化的设置). 在本小节中，令 $\Theta \subseteq \mathbb{R}^d$ 为开参数域。下列假设成立。

1. **任务目标的查询分布。** 存在查询随机变量

$$Q \sim \mathcal{D}.$$

2. **当前评分规约库。** 在当前训练 *step* 中，评分规约库是一个固定可测对象 $\mathcal{M}$ 。这对应于在把库状态视为固定的情况下分析一次参数更新。
3. **任务 rollout 分布。** 给定查询 $Q = q$ 和库 $\mathcal{M}$ ，rollout

$$T \sim p_\theta(\cdot | q, \mathcal{M})$$

从部署的任务策略中采样。

4. **固定反思上下文分布。** 存在查询-轨迹对上的固定可测分布 ξ

$$(\tilde{Q}, \tilde{T}) \sim \xi.$$

可将 ξ 理解为当前更新中被选用于反思训练的轨迹分布，例如先在当前行为策略下采样 rollout group，然后为每个查询选择一条轨迹。对本小节的局部分析， ξ 被视为固定。这与实现一致：反思目标只在反思 token 上施加梯度，并把选中轨迹视为固定 prompt / context。

5. **共享骨干反思生成。** 给定 $(\tilde{Q}, \tilde{T}) = (q, \tau)$ 和库 $\mathcal{M}$ ，采样一个以评分规约为基础的反思

$$S \sim r_\theta(\cdot | q, \tau, \mathcal{M})$$

。尽管为了清晰起见我们分别写作 p_θ 和 r_θ ，二者都由同一个底层自回归骨干 π_θ 在不同 prompt / context 下诱导。

6. **任务分数、反思效用分数与裁判门控。** 存在可测、可积随机量

$$R(Q, T; \mathcal{M}) \in \mathbb{R}, \quad \Delta^w(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \in \mathbb{R}, \quad \Delta^c(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \in \mathbb{R},$$

以及可测接受指示器

$$A(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \in \{0, 1\}.$$

这里 R 是部署 rollout 的裁判任务分数， Δ^w 是反思经裁判判断的 episode 内有用性， Δ^c 是经裁判判断的跨 episode 迁移有用性，而 $A = 1$ 表示反思被判断为足够有用，可以被接受用于下游适应 / 存储。除了通过采样随机变量和固定库 $\mathcal{M}$ 之外，这些对象不直接依赖 θ 。

7. **可微性与 *score-function* 正则性。** 对 $\mathcal{D}$ -几乎每个 q , 条件分布 $p_\theta(\tau | q, \mathcal{M})$ 关于 θ 可微。对 ξ -几乎每个 (q, τ) , 条件分布 $r_\theta(s | q, \tau, \mathcal{M})$ 关于 θ 可微。微分可与下面期望交换, 且后文引入的所有 *score-function* 项均平方可积。
8. **光滑性。** 下文定义的目标 J_{task} 和 U 连续可微。此外, J_{task} 在 Θ 上是 L_J -smooth, U 在 Θ 上是 L_U -smooth。

定义 4 (任务目标与裁判门控记忆目标). 采用假设 3。定义任务 *rollout* 和反思的 *score-function* 和

$$\Gamma^{\text{traj}} := \nabla_\theta \log p_\theta(T | Q, \mathcal{M}), \quad \Gamma^{\text{ref}} := \nabla_\theta \log r_\theta(S | \tilde{Q}, \tilde{T}, \mathcal{M}).$$

由于两个条件分布都由同一骨干 π_θ 诱导, 它们具有 *token* 级分解

$$\Gamma^{\text{traj}} = \sum_{t=1}^{|T|} \nabla_\theta \log \pi_\theta(a_t | h_t), \quad \Gamma^{\text{ref}} = \sum_{u=1}^{|S|} \nabla_\theta \log \pi_\theta(s_u | c_u),$$

其中 h_t 和 c_u 分别为相应 *rollout* 历史与反思生成上下文。

对权重 $\beta_w, \beta_c \geq 0$, 定义

$$J_{\text{task}}(\theta) := \mathbb{E}[R(Q, T; \mathcal{M})],$$

其中期望关于

$$Q \sim \mathcal{D}, \quad T \sim p_\theta(\cdot | Q, \mathcal{M}),$$

并定义

$$U(\theta) := \mathbb{E}\left[A(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \left(\beta_w \Delta^w(\tilde{Q}, \tilde{T}, S; \mathcal{M}) + \beta_c \Delta^c(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \right)\right],$$

其中期望关于

$$(\tilde{Q}, \tilde{T}) \sim \xi, \quad S \sim r_\theta(\cdot | \tilde{Q}, \tilde{T}, \mathcal{M}).$$

我们还定义组合共同演化目标

$$J_{\text{coevo}}(\theta) := J_{\text{task}}(\theta) + U(\theta).$$

假设 4 (裁判门控的局部正迁移). 采用假设 3 和定义 4。令

$$g := \nabla J_{\text{task}}(\theta),$$

并定义未门控的反思效用 *score-gradient* 随机向量

$$\Psi := \Gamma^{\text{ref}} \left(\beta_w \Delta^w(\tilde{Q}, \tilde{T}, S; \mathcal{M}) + \beta_c \Delta^c(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \right).$$

假设存在常数 $p_0 \in (0, 1]$ 和 $\mu > 0$, 使得

$$\mathbb{P}(A = 1) \geq p_0, \quad \langle g, \mathbb{E}[\Psi | A = 1] \rangle \geq \mu.$$

也就是说, 通过裁判的反思会以非平凡概率被接受, 且其条件期望梯度贡献与任务梯度正向对齐。

定理 5 (裁判门控的共享骨干共同演化). 采用假设 3-4 和定义 4。Let

$$g := \nabla J_{\text{task}}(\theta), \quad h := \nabla U(\theta).$$

则以下结论成立。

1. **相互改进**。对每个步长 $\eta > 0$,

$$U(\theta + \eta g) - U(\theta) \geq \eta p_0 \mu - \frac{L_U \eta^2}{2} \|g\|_2^2,$$

and

$$J_{\text{task}}(\theta + \eta h) - J_{\text{task}}(\theta) \geq \eta p_0 \mu - \frac{L_J \eta^2}{2} \|h\|_2^2.$$

特别地, 如果

$$0 < \eta < \min \left\{ \frac{2p_0\mu}{L_U \|g\|_2^2}, \frac{2p_0\mu}{L_J \|h\|_2^2} \right\},$$

则一个改进任务的 *step* 也会改进裁判门控记忆目标, 而一个改进记忆的 *step* 也会改进任务目标。

2. **相对于带静态记忆的仅任务训练的优势**。考虑仅任务更新

$$\theta_{\text{stat}}^+ := \theta + \eta g,$$

它更新部署任务策略, 但不给反思质量分配任何显式训练信号, 以及共同演化更新

$$\theta_{\text{co}}^+ := \theta + \eta(g + h).$$

Then

$$J_{\text{task}}(\theta_{\text{co}}^+) - J_{\text{task}}(\theta_{\text{stat}}^+) \geq \eta p_0 \mu - L_J \eta^2 \|g\|_2 \|h\|_2 - \frac{L_J \eta^2}{2} \|h\|_2^2.$$

因此, 如果反思足够好,

$$p_0 \mu > L_J \eta \left(\|g\|_2 \|h\|_2 + \frac{1}{2} \|h\|_2^2 \right),$$

then

$$J_{\text{task}}(\theta_{\text{co}}^+) > J_{\text{task}}(\theta_{\text{stat}}^+).$$

Proof. 为证明所需命题, 我们先推导 g 和 h 的公式。令 $\mu_\theta(dq, d\tau) := \mathcal{D}(dq) p_\theta(d\tau | q, \mathcal{M})$ 表示 (Q, T) 的联合分布。由定义 4,

$$J_{\text{task}}(\theta) = \int R(q, \tau; \mathcal{M}) \mu_\theta(dq, d\tau).$$

由假设 3, 微分可与积分交换。由于 $\mathcal{D}$ 不依赖 θ , 由通常的 log-derivative trick,

$$\begin{aligned} \nabla J_{\text{task}}(\theta) &= \int R(q, \tau; \mathcal{M}) \nabla p_\theta(\tau | q, \mathcal{M}) \mathcal{D}(dq) d\tau \\ &= \int R(q, \tau; \mathcal{M}) p_\theta(\tau | q, \mathcal{M}) \nabla \log p_\theta(\tau | q, \mathcal{M}) \mathcal{D}(dq) d\tau \\ &= \mathbb{E}[\Gamma^{\text{traj}} R(Q, T; \mathcal{M})]. \end{aligned}$$

接下来推导 h 的公式。记

$$\Delta(q, \tau, s; \mathcal{M}) := \beta_w \Delta^w(q, \tau, s; \mathcal{M}) + \beta_c \Delta^c(q, \tau, s; \mathcal{M}),$$

so that

$$U(\theta) = \mathbb{E}[A(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \Delta(\tilde{Q}, \tilde{T}, S; \mathcal{M})].$$

Let

$$\nu_\theta(dq, d\tau, ds) := \xi(dq, d\tau) r_\theta(ds | q, \tau, \mathcal{M})$$

表示 $(\tilde{Q}, \tilde{T}, S)$ 的联合分布。则

$$U(\theta) = \int A(q, \tau, s; \mathcal{M}) \Delta(q, \tau, s; \mathcal{M}) \nu_\theta(dq, d\tau, ds).$$

在积分号下求导得到

$$\begin{aligned} \nabla U(\theta) &= \int A(q, \tau, s; \mathcal{M}) \Delta(q, \tau, s; \mathcal{M}) \xi(dq, d\tau) \nabla r_\theta(s | q, \tau, \mathcal{M}) ds \\ &= \int A(q, \tau, s; \mathcal{M}) \Delta(q, \tau, s; \mathcal{M}) \xi(dq, d\tau) r_\theta(s | q, \tau, \mathcal{M}) \nabla \log r_\theta(s | q, \tau, \mathcal{M}) ds \\ &= \mathbb{E}[A(\tilde{Q}, \tilde{T}, S; \mathcal{M}) \Gamma^{\text{ref}} \Delta(\tilde{Q}, \tilde{T}, S; \mathcal{M})] \\ &= \mathbb{E}[A\Psi] := h. \end{aligned}$$

由 A 的定义和假设 4,

$$\mathbb{E}[A\Psi] = \mathbb{P}(A = 1) \mathbb{E}[\Psi | A = 1].$$

并且

$$\langle g, h \rangle = \langle g, \mathbb{P}(A = 1) \mathbb{E}[\Psi | A = 1] \rangle \quad (7)$$

$$= \mathbb{P}(A = 1) \langle g, \mathbb{E}[\Psi | A = 1] \rangle \quad (8)$$

$$\geq p_0 \mu, \quad (9)$$

由假设 3, U 是 L_U -smooth, 对每个向量 $v \in \mathbb{R}^d$, 有标准下界

$$U(\theta + v) \geq U(\theta) + \langle \nabla U(\theta), v \rangle - \frac{L_U}{2} \|v\|_2^2.$$

取 $v = \eta g$ 并使用式 9, 得到

$$U(\theta + \eta g) - U(\theta) \geq \eta \langle h, g \rangle - \frac{L_U \eta^2}{2} \|g\|_2^2 \geq \eta p_0 \mu - \frac{L_U \eta^2}{2} \|g\|_2^2.$$

类似地, 由于 J_{task} 是 L_J -smooth,

$$J_{\text{task}}(\theta + \eta h) - J_{\text{task}}(\theta) \geq \eta \langle g, h \rangle - \frac{L_J \eta^2}{2} \|h\|_2^2 \geq \eta p_0 \mu - \frac{L_J \eta^2}{2} \|h\|_2^2.$$

If

$$0 < \eta < \min \left\{ \frac{2p_0 \mu}{L_U \|g\|_2^2}, \frac{2p_0 \mu}{L_J \|h\|_2^2} \right\},$$

则两个右侧都严格为正。

为证明另一部分，定义

$$\phi(t) := J_{\text{task}}(\theta_{\text{stat}}^+ + t\eta h), \quad t \in [0, 1].$$

则

$$\phi(1) - \phi(0) = J_{\text{task}}(\theta_{\text{co}}^+) - J_{\text{task}}(\theta_{\text{stat}}^+) = \int_0^1 \phi'(t) dt.$$

由链式法则，

$$\phi'(t) = \eta \langle \nabla J_{\text{task}}(\theta_{\text{stat}}^+ + t\eta h), h \rangle.$$

由于 ∇J_{task} 是 L_J -Lipschitz，

$$\|\nabla J_{\text{task}}(\theta_{\text{stat}}^+ + t\eta h) - \nabla J_{\text{task}}(\theta_{\text{stat}}^+)\|_2 \leq L_J t\eta \|h\|_2.$$

因此，对每个 $t \in [0, 1]$ ，由 Cauchy-Schwarz，

$$\langle \nabla J_{\text{task}}(\theta_{\text{stat}}^+ + t\eta h), h \rangle \geq \langle \nabla J_{\text{task}}(\theta_{\text{stat}}^+), h \rangle - L_J t\eta \|h\|_2^2.$$

从 0 到 1 积分得到

$$J_{\text{task}}(\theta_{\text{co}}^+) - J_{\text{task}}(\theta_{\text{stat}}^+) \geq \eta \langle \nabla J_{\text{task}}(\theta_{\text{stat}}^+), h \rangle - \frac{L_J \eta^2}{2} \|h\|_2^2.$$

剩下只需下界右侧内积。再次由梯度的 L_J -Lipschitz 连续性，

$$\|\nabla J_{\text{task}}(\theta_{\text{stat}}^+) - g\|_2 = \|\nabla J_{\text{task}}(\theta + \eta g) - \nabla J_{\text{task}}(\theta)\|_2 \leq L_J \eta \|g\|_2.$$

因此，由 Cauchy-Schwarz，

$$\begin{aligned} \langle \nabla J_{\text{task}}(\theta_{\text{stat}}^+), h \rangle &= \langle g, h \rangle + \langle \nabla J_{\text{task}}(\theta_{\text{stat}}^+) - g, h \rangle \\ &\geq \langle g, h \rangle - \|\nabla J_{\text{task}}(\theta_{\text{stat}}^+) - g\|_2 \|h\|_2 \\ &\geq \langle g, h \rangle - L_J \eta \|g\|_2 \|h\|_2 \\ &\geq p_0 \mu - L_J \eta \|g\|_2 \|h\|_2, \end{aligned}$$

其中最后一步使用式 9。将该界代入上式得到

$$J_{\text{task}}(\theta_{\text{co}}^+) - J_{\text{task}}(\theta_{\text{stat}}^+) \geq \eta p_0 \mu - L_J \eta^2 \|g\|_2 \|h\|_2 - \frac{L_J \eta^2}{2} \|h\|_2^2.$$

这证明了所需下界。如果

$$p_0 \mu > L_J \eta \left(\|g\|_2 \|h\|_2 + \frac{1}{2} \|h\|_2^2 \right),$$

则右侧严格为正，因此

$$J_{\text{task}}(\theta_{\text{co}}^+) > J_{\text{task}}(\theta_{\text{stat}}^+).$$

□

备注 4 (解释). 定理 5 隔离出共同演化收益的来源。关键量是对实际被接受并用于复用的反思施加的裁判门控局部条件。在该条件下，策略训练会改善被接受反思的效用，而被接受反思的训练会改善任务性能。此外，对 $J_{\text{task}} + U$ 的联合更新，在适应后的任务价值上产生严格更大的一级收益，超过带静态记忆目标的仅任务训练。这正是联合训练演化记忆策略强于仅推理时静态记忆的精确含义。共同演化效应得以保留，是因为 g 和 h 仍处在同一个共享参数空间：任务更新会改变未来反思生成器，而反思更新会改变未来任务策略。

备注 5 (为什么参数共享重要). 上述一阶共同演化机制特定于共享骨干设计。如果 *rollout* 生成和反思生成由不相交参数块参数化 $\theta = (\theta_\pi, \theta_{\text{ref}})$, 其中且 J_{task} 只依赖 θ_π , 而 U 只依赖 θ_{ref} , 则

$$\nabla J_{\text{task}}(\theta) = (g_\pi, 0), \quad \nabla U(\theta) = (0, h_{\text{ref}}),$$

于是

$$\langle \nabla J_{\text{task}}(\theta), \nabla U(\theta) \rangle = 0.$$

因此, 定理 5 中的相互改进现象在完全解耦情形下一阶消失。这形式化地说明了为什么统一骨干可以支持真正的共同演化, 而不只是把静态记忆模块包在一个单独训练的策略外面。

F. 实验细节

在训练、评估、基础设施和基线选择方面, 我们大体遵循 DR Tulu (Shao et al., 2025) 的实验设置, 并在必要处适配以支持本文提出的组件。具体细节如下。

F.1. 训练细节

F.1.1. 监督微调

我们使用 LLaMA-Factory 框架 (Zheng et al., 2024) 和 DeepSpeed ZeRO-3 微调 Qwen3-8B (Yang et al., 2025)。SFT 数据生成过程见附录 B.2。关键超参数如下:

超参数	取值
基础模型	Qwen3-8B
训练 epoch	5
学习率	4×10^{-5}
学习率调度器	Cosine with 10% warmup
Batch size (每设备)	1
梯度累积步数	16
有效 batch size	128 (8 GPUs $\times$ 16 accum.)
最大序列长度	16,384 tokens
Precision	BF16
Weight decay	0.0
工具输出 masking	对 <tool_output> 做 span masking
DeepSpeed stage	ZeRO-3
GPUs	8 $\times$ NVIDIA H100 80GB

我们对工具输出 token 应用 span masking, 使模型不会在搜索结果上接收梯度, 而只学习生成自身推理、工具调用和答案。

F.1.2. 强化学习

我们使用修改后的 open-instruct 代码库训练所有 RL 运行, 其中包含基于 Ray 的分布式训练和 vLLM 推理引擎。RL 设置遵循 DR. Tulu 的代码库, 并扩展了阶段化信用分配和元策略训练操作。关键超参数如下:

超参数	取值
算法	GRPO / SS-GRPO
每个 prompt 的 rollout 数	8
每 step 唯一 prompt 数	32
有效 batch size	256 (32 × 8)
学习率	5×10^{-7}
学习率调度器	Constant
KL coefficient (β)	0.001
KL estimator	KL3
Clip ratio (η)	PPO-style clipping
Temperature	1.0
最大回答长度	18,432 tokens
最大 prompt 长度	8,192 tokens
最大总 (pack) 长度	26,624 tokens
每条轨迹最大工具调用数	10
DeepSpeed stage	ZeRO-3 with CPU offloading
梯度 checkpointing	Enabled
评分规约裁判	
裁判模型	Gemini Flash
评分规约生成模型	Gemini Flash
评分规约缓冲区上限 (每阶段)	3, 2, 2, 3
评分规约库 (仅完整 RubricEM)	
库 embedding 模型	Qwen3-Embedding-0.6B
检索 top-k	2
采样反思轨迹数	1
窗口化课程 K	3
库保存频率	每 10 step

另一个超参数是 Section 3.3 中提到的阶段依赖矩阵 Λ ，我们将其设为

$$\Lambda = \begin{pmatrix} 1.0 & 0.4 & 0.6 & 0.8 \\ 0 & 1.0 & 0.4 & 0.8 \\ 0 & 0 & 1.0 & 0.8 \\ 0 & 0 & 0 & 1.0 \end{pmatrix}.$$

训练数据是同一个 DR. Tulu RL 数据集 (rl-research/dr-tulu-rl-data)，其中包含约 ~4.9K 个多样深度研究查询。所有消融运行 (Baseline RL、SS-GRPO、完整 RubricEM) 都使用相同 600-step 预算和 2 个节点，并从同一个 RubricEM-SFT checkpoint 开始。最终 RubricEM 运行使用 4 个节点进行更长训练。

奖励设计。 由于本文重点是通过 LLM-as-judge 反馈改善开放式答案质量，我们只使用基于评分规约的裁判信号作为 RL 奖励。具体而言，任务策略奖励来自裁判使用的演化阶段化评分规约，反思策略奖励则来自裁判对评分规约奠基反思的打分。我们有意不加入辅助可验证奖励，例如格式奖励、引用奖励或工具使用启发式奖励；这些奖励曾用于 DR Tulu (Shao et al., 2025) 等先前深度研究 RL 配方。这一选择隔离了问题的开放式组件：改进应来自更好的语义规划、研究、综合和经验复用，而不是来自优化易于检查的表层约束。我们相信，未来工作可以通过把基于评分规约的奖励与校准后的引用、grounding 或格式奖励结合来进一步提高性能，但当前设计为研究超越可验证奖励的 RL 提供了更干净、更整体的设置。

F.2. 评估细节

F.2.1. 长篇基准

我们在四个长篇基准上评估:

- **HealthBench** (Arora et al., 2025): Subsampled 1000 医疗问题, 涵盖患者咨询、临床指南和健康建议。评估使用 LLM-as-judge (GPT-4), 根据逐问题评分规约在多个轴上为每个回答打分 (准确性、完整性、上下文感知、沟通)。报告分数是整体评分规约满足率。
- **ResearchQA** (Yifei et al., 2025): 756 个科学研究问题, 带专家撰写的评分规约条目。评估使用 LLM-as-judge (GPT-4), 以 5 点标度 (Not at all / Barely / Moderately / Mostly / Completely) 评估每个评分规约条目的覆盖度。报告分数是平均归一化覆盖度。
- **DeepResearchBench (DRB)** (Du et al., 2025): 100 个复杂研究问题, 要求带引用的长篇报告。评估使用 RACE (Report Assessment via Citation Evaluation) 打分, 结合内容质量和引用准确性。裁判 (Gemini) 同时评估报告实质, 以及引用是否准确且 grounding 良好。
- **ResearchRubrics** (Sharma et al., 2026): 101 个跨多样真实世界领域的开放式深度研究 prompt, 每个都配有专家撰写的 prompt 特定评分规约。评估使用 LLM-as-judge, 根据细粒度标准评估评分规约遵循度, 覆盖事实 grounding、推理健全性、综合质量、相关性、清晰度和引用使用。评分规约条目包含带不同权重的正向和负向标准, 报告分数为二值分数。

F.2.2. 短篇基准

我们还在四个短篇基准上评估, 以测试分布外迁移:

- **SimpleQA** (Wei et al., 2024): 1,000 个事实问题, 通过 LLM 打分进行 exact-match 评估 (correct / incorrect / not attempted)。
- **2WikiMultihopQA** (Ho et al., 2020): 1000 个多跳推理问题, 需要来自多个来源的证据。使用 LLM-as-judge 评估。
- **WebWalker** (Wu et al., 2025b): 680 个网页导航问题。使用 LLM-as-judge 评估。
- **DeepSearchQA (DSQA)** (Gupta et al., 2026): 900 个搜索密集型问题, 使用 exact-match 打分。

所有短篇基准都在 zero-shot 设置下评估, 使用与长篇基准相同的智能体流水线和搜索工具。RL 训练期间没有使用任何短篇数据, 因此这些评估完全是分布外的。

关于基准的说明。 不同于 Dr. Tulu, 我们的评估不包含 SQA-v2 (ScholarQA) 基准 (Asai et al., 2024; Bragg et al., 2025)。SQA-v2 高度以引用为中心: 它主要衡量模型能否对特定学术论文生成精确内联引用, 这更接近深度研究中的可验证 citation-grounding 组件, 而不是本文研究的开放式答案质量设置。我们的 RL 目标有意只使用基于评分规约的裁判奖励, 不包含引用特定奖励, 因此 SQA-v2 会测试一种本文方法并未直接设计来优化的能力。这并不意味着我们的评估缺少引用质量: 剩余若干长篇基准, 如 ResearchQA 和 ResearchRubrics, 仍包含与引用、grounding 或证据使用相关的评分规约条目。不过, 这些基准把引用使用作为更广泛长篇答案质量的一部分来评估, 而不是把精确学术引用作为主导目标。此外, 在 SFT 数据生成期间, 即使使用强 prompt 和拒绝采样, Gemini-3.1-Pro 产生的学术引用仍然很少且往往不可靠, 使其成为该特定技能的弱教师。因此, 我们把引用特定 RL 和引用密集型学术评估留作未来工作, 本文聚焦于超越可验证奖励地改善语义质量、覆盖度、推理和综合。

附加说明。 为了与基线公平比较, Table 1 中的主要结果、Figure 5 中的 RL 消融, 以及 Table 2 中的短篇迁移结果, 都使用直接 zero-shot prompt 评估: 测试时我们不附加评分规约库条目、先前反思或其他经验示例。当任务需要工具使用时, 智能体仍遵循相同基准协议并使用相同外部搜索工具。因此, 报告收益并不只是因为评估期间给了 RubricEM 额外反思上下文。虽然任务策略在 RL 训练期间使用反思上下文, 主要评估直接测试得到的任务策略, 这表明反思条件化训练很可能产生

了更高质量 rollout。我们在 Figure 6(c) 中单独研究推理时经验复用，其中评分规约库条目在评估期间被显式注入。

F.3. 基础设施

我们的训练和评估基础设施建立在 DR Tulu 代码库 (Shao et al., 2025) 之上，该代码库提供基于 Ray 的分布式 RL 训练循环、用于 rollout 生成的 vLLM 集成、异步工具调用、样本 packing，以及一步异步训练 (Noukhovitch et al., 2024)。我们使用 GRPO (Shao et al., 2024)，并采用 token 级损失聚合、工具输出 token masking (Jin et al., 2025)，以及一个较小 KL 惩罚 (0.001) 来保证稳定性。完整超参数见上方 RL 训练表。

我们以若干方式扩展基础设施以支持 RubricEM：

- **阶段化打分流水线：**异步阶段化裁判打分模块让 Gemini API 调用与训练循环并行运行。评分规约生成（每 step 32 次调用）和轨迹打分（每 step 256 次调用）通过 `asyncio.gather` 并行化，并使用指数退避重试（见附录 C）。
- **元策略训练流水线：**反思生成和元策略训练通过多线程架构与一步延迟反思训练集成，其中来自 step N 的反思样本会在 step $N+1$ 的 Phase A 中训练，同时推理引擎生成新的 rollout。这实际上不会增加额外 wall-clock 开销（见附录 D）。
- **评分规约库模块：**一个线程安全的内存存储，带有基于查询 embedding 的 FAISS 索引（CPU 上的 Qwen3-Embedding-0.6B）。库操作（检索、prompt 注入和后台反思生成）以一步延迟执行方式集成进数据准备线程（见附录 D）。
- **Checkpoint 管理：**除标准模型和优化器 checkpoint（通过 DeepSpeed）外，我们还定期保存评分规约缓冲区状态、评分规约库内容和 dataloader 状态，以便在记忆和数据顺序一致的情况下无缝恢复训练。

评估时，我们使用 vLLM 在单 GPU 上服务模型 checkpoint，并通过 MCP 后端运行带实时工具执行的智能体流水线。每个基准评估耗时约 2–18 小时，取决于样本数量、查询复杂度、判断延迟，以及每条轨迹的平均工具调用数。

搜索工具。我们向智能体暴露两个搜索工具。主要工具是 `google_search`，通过启用 Google Search grounding 的 Gemin-3-Flash（作为浏览模型）实现¹。它返回带 grounding snippet 的 AI 综合摘要，主要用于一般网络搜索、事实寻求问题和广泛真实世界信息收集。第二个工具是 `snippet_search`，通过 Semantic Scholar API 实现²。它从学术论文中检索文本片段，主要用于查询需要学术证据、论文级上下文或科学文献支持时。两个工具都通过同一个 MCP 后端调用，其输出在返回给智能体之前包裹在 `<tool_output>` 块中。

F.4. 基线

我们按照 Dr. Tulu (Shao et al., 2025) 的选择，并补充近期模型，与三类基线进行比较。已有基线的分数在可用时取自 Dr. Tulu 论文；对未覆盖模型，我们运行相同评估流水线。

- **闭源深度研究模型：**具备完整深度研究能力的专有系统，包括 OpenAI Deep Research (OpenAI, 2025)、Gemini Deep Research (Google DeepMind, 2025)、Perplexity Deep Research (Perplexity AI, 2025)、Claude Sonnet Search、Gemini 3.1 Pro + Search 和 GPT-5 + Search。
- **固定流水线深度研究模型：**使用固定多阶段流水线 (search → synthesis → report)，但没有端到端 RL 训练的模型，包括 WebThinker (Li et al., 2025e) 和 Ai2 ScholarQA (Singh et al., 2025)。
- **开放深度研究模型：**为深度研究端到端训练的开放权重模型，包括 Search-R1-7B (Jin et al., 2025)、WebExplorer-8B (Liu et al., 2025)、Tongyi DeepResearch-30B-A3B (Tongyi DeepResearch Team

¹<https://ai.google.dev/gemini-api/docs/google-search>

²<https://api.semanticscholar.org/api-docs>

et al., 2025) 和 DR Tulu-8B (Shao et al., 2025) (SFT 与 RL checkpoint)。

DR Tulu 是最直接比较对象，因为我们使用相同训练数据，并处于相同开放深度研究设置。与 Dr. Tulu 相比，RubricEM 使用不同搜索工具（带 Gemini grounding 的 Google Search vs. Serper API）和不同 SFT 教师（Gemini-3.1-Pro vs. GPT-5）。我们的搜索工具提供更丰富的 AI 综合摘要，但原始网页 URL 更少；他们的教师更强，但搜索工具返回更短 snippet。我们在正文中讨论这一权衡，并通过消融研究控制它，以隔离训练配方贡献和搜索工具影响。

G. 算法

论文算法完整描述见 Algorithm 1。

H. 局限性与讨论

局限性。 我们的实验涉及带搜索工具调用和外部 LLM 判断的长时域智能体 RL，这使训练循环比标准离线 RL 或监督微调更容易受到基础设施不稳定性的影响。训练期间，我们偶尔观察到 API 延迟和网络连接不一致，因此 wall-clock 执行时间以及部分 rollout-judge 延迟并未在所有 RL step 上得到完全控制。在主要的大规模 RL 运行中，训练服务器还不得不多次关停并重启。尽管我们从 checkpoint 恢复训练，此类中断仍可能在异步反思分支、评分规约库和裁判反馈流水线中引入超过预期一步滞后的额外陈旧性。因此，我们认为报告结果反映了一个真实但并非完全理想的基础设施设置；原则上，一个更稳定、不中断的训练环境可以减少陈旧反馈，并进一步提升我们方法的效率。另一个局限是，我们使用 Gemini Flash 作为成本有效的裁判，用于评分规约生成、阶段化打分和反思评估。更强或更专门化的裁判很可能提供更准确的阶段级信用和更高质量的反思奖励，尤其是在细微的长篇研究任务上；但这也会增加成本和延迟。探索 RubricEM 在更强裁判、多裁判或校准裁判集成下的扩展行为，是未来工作的重要方向。

讨论与更广泛影响。 更广泛地说，我们的结果表明，LLM 生成的评分规约不应仅被当作评估工件，还应被视为一种通用接口，用于结构化智能体行为、分配语义信用并积累可复用经验。这些结果也指向一种面向语言智能体的训练时 Meta-RL 视角：不只在推理时把反思、记忆或自我改进作为提示机制，而是在 RL 期间训练元策略，使经过裁判评定的经验能够直接塑造智能体参数及其可复用文本记忆。虽然我们研究的是超越可验证奖励的开放式深度研究，同一配方也可能迁移到其他质量多维且难以化约为精确答案正确性的领域，例如写作辅助、数据分析、科学评审、辅导和复杂工具使用 workflow。与此同时，由评分规约引导的元策略会继承其裁判和评分规约的风险：定义不佳的标准可能强化浅层偏好、有偏标准或过度自信的综合，而可复用记忆可能把这些错误传播到跨任务场景。未来工作应研究更鲁棒的评分规约生成、更强或集成式裁判、人类可审计的评分规约库、不确定性感知的反思训练，以及面向智能体研究输出可能影响真实决策领域的安全感知标准。

算法 1 RubricEM: 带 Stage-Structured GRPO 与反思元策略训练的强化学习

输入: 结构化 SFT 策略 π_θ 、参考策略 π_{ref} 、训练查询 $\mathcal{D}$ 、工具环境 $\mathcal{T}$ 、裁判 $\mathcal{J}$ 、阶段 $\mathcal{S} = \{\text{Plan, Research, Review, Answer}\}$ 、阶段矩阵 Λ 、rollout 大小 n 、反思样本数 m 、活跃评分规约上限 $C_{1:K}$

- 1: 对每个查询 q 和阶段 k 初始化活跃裁判评分规约缓冲区 $\mathcal{B}_{q,k}^{\text{act}} \leftarrow \emptyset$
- 2: 在可用时初始化持久裁判评分规约 $\mathcal{B}_{q,k}^{\text{pers}}$ ，并初始化智能体评分规约库 $\mathcal{M} \leftarrow \emptyset$
- 3: 初始化延迟反思 batch $\mathcal{P}_0^{\text{ref}} \leftarrow \emptyset$
- 4: **for** RL step $t = 1, \dots, T$ **do**
- 5: $(Q_t, \mu_t) \leftarrow \text{WindowedBatch}(\mathcal{D}, t)$ ▷ $\mu_t \in \{\text{cross, within}\}$
- 6: **for all** $q \in Q_t$ **do**
- 7: $E_q \leftarrow \text{Retrieve}(\mathcal{M}, q, \mu_t)$ ▷ 检索可复用经验
- 8: **end for**
- 9: ▷ 延迟的反思元策略更新
- 10: **if** $\mathcal{P}_{t-1}^{\text{ref}} \neq \emptyset$ **then**
- 11: 使用 $\mathcal{P}_{t-1}^{\text{ref}}$ 中的 GRPO 奖励，在反思 token 上更新共享 π_θ
- 12: **end if**
- 13: ▷ 阶段结构化任务策略 rollout 与判断
- 14: 初始化任务 batch $\mathcal{P}_t^{\text{task}} \leftarrow \emptyset$
- 15: **for all** $q \in Q_t$ in parallel **do**
- 16: Sample tool-augmented rollouts $\{\tau_i\}_{i=1}^n \sim \pi_\theta(\cdot | q, E_q; \mathcal{T})$ under scaffold $\mathcal{S}$ ▷ 任务策略 rollout
- 17: $\Delta \mathcal{B}_{q,1:K} \leftarrow \text{GenerateStageRubrics}(\mathcal{J}, q, \{\tau_i\}_{i=1}^n, \mathcal{B}_{q,1:K}^{\text{act}})$ ▷ 对比 rollout
- 18: **for** $k = 1, \dots, K$ **do**
- 19: $\mathcal{B}_{q,k}^{\text{act}} \leftarrow \mathcal{B}_{q,k}^{\text{act}} \cup \Delta \mathcal{B}_{q,k}$
- 20: $\mathcal{B}_{q,k} \leftarrow \mathcal{B}_{q,k}^{\text{pers}} \cup \mathcal{B}_{q,k}^{\text{act}}$
- 21: **end for**
- 22: $R_{i,k} \leftarrow \text{ScoreStage}(\mathcal{J}, q, \tau_i, \mathcal{B}_{q,k})$ for all $i = 1, \dots, n$ and $k = 1, \dots, K$
- 23: **for** $k = 1, \dots, K$ **do**
- 24: $G_{i,k}^\Lambda \leftarrow \sum_{j=k}^K \lambda_{k,j} R_{i,j}$ for all i
- 25: $G_{i,k}^\Lambda \leftarrow G_{i,k}^\Lambda - \text{mean}_{i'}(G_{i',k}^\Lambda)$
- 26: $A_{i,k} \leftarrow \frac{G_{i,k}^\Lambda}{\text{std}_{i'}(G_{i',k}^\Lambda) + \epsilon}$ for all i
- 27: $\mathcal{B}_{q,k}^{\text{act}} \leftarrow \text{PruneByDiscrimination}(\mathcal{B}_{q,k}^{\text{act}}, \{R_{i,k}\}_{i=1}^n, C_k)$ ▷ 演化阶段化评分规约缓冲区
- 28: **end for**
- 29: $\mathcal{P}_t^{\text{task}} \leftarrow \mathcal{P}_t^{\text{task}} \cup \{(q, \tau_i, B_{i,1:K}, A_{i,1:K})\}_{i=1}^n$
- 30: 异步启动 PrepareReflectionBatch($q, \{\tau_i, R_{i,1:K}\}_{i=1}^n, \mathcal{B}_{q,1:K}, \mathcal{M}, m$)
- 31: **end for**
- 32: ▷ 任务策略更新
- 33: 按式 1，使用阶段优势 $A_{i,k}$ 和到 π_{ref} 的 KL，在 $\mathcal{P}_t^{\text{task}}$ 上用 SS-GRPO 更新 π_θ
- 34: $\mathcal{P}_t^{\text{ref}} \leftarrow$ 来自 step t 的已完成异步反思 batch
- 35: **end for**
- 36: **返回** 训练后的策略 π_θ 和智能体评分规约库 $\mathcal{M}$
- 37: **function** PrepareReflectionBatch($q, \{\tau_i, R_{i,1:K}\}_{i=1}^n, \mathcal{B}_{q,1:K}, \mathcal{M}, m$)
- 38: 从 $\{\tau_i\}_{i=1}^n$ 均匀采样一条轨迹 τ_s ▷ 固定反思上下文
- 39: 生成反思候选 $\{s_\ell\}_{\ell=1}^m \sim \pi_\theta^{\text{refl}}(\cdot | q, \tau_s)$
- 40: **for** $\ell = 1, \dots, m$ **do**
- 41: $(u_\ell^{\text{within}}, u_\ell^{\text{cross}}) \leftarrow \text{JudgeReflection}(\mathcal{J}, q, \tau_s, s_\ell, R_{s,1:K}, \mathcal{B}_{q,1:K})$
- 42: $u_\ell \leftarrow \frac{1}{2}(u_\ell^{\text{within}} + u_\ell^{\text{cross}})$
- 43: **end for**
- 44: $s^* \leftarrow \arg \max_\ell u_\ell$ ，范围为有效反思候选
- 45: $\mathcal{M} \leftarrow \text{WriteBank}(\mathcal{M}, q, s^*)$ ▷ 只存储最佳被接受反思
- 46: **返回** $\{(q, \tau_s, s_\ell, u_\ell)\}_{\ell=1}^m$
- 47: **end function**