

HalluWorld: 通过参考世界模型控制幻觉的基准

HalluWorld: A Controlled Benchmark for Hallucination via Reference World Models

Emmy Liu*

Carnegie Mellon University

Varun Gangal

Patronus AI

Michael Yu

Independent Researcher

Zhuofu Tao

Independent Researcher

Karan Singh

Stanford University

Sachin Kumar

The Ohio State University

Steven Y. Feng

Stanford University

摘要

幻觉仍然是大型语言模型的核心失效模式，但现有基准在摘要、问答、检索增强生成和智能体交互等任务中对它的操作化方式并不一致。这种碎片化使人难以判断，在某一设置中有效的缓解方法是否真的能够跨语境减少幻觉。当前的幻觉基准要么需要人工标注，并依赖最终可能被记忆的固定参考；要么依赖自然主义观察，而这些观察往往记录于难以复现或系统测试的设置中。为推动对幻觉根因的进一步研究，我们引入 HalluWorld，一个建立在显式参考世界表述之上的可扩展基准框架：当模型生成的可观察主张相对于该参考世界为假时，模型即发生幻觉。基于这一观点，我们构造了一族合成与半合成的基准环境，其中参考世界被完全指定，模型的可观察视图受到控制，并且幻觉标签可以按构造自动生成。HalluWorld 覆盖多个在人工智能中具有经典代表性的设置，即网格世界、国际象棋和现实终端任务。这使我们能够受控地改变世界复杂度、可观测性、时间变化和来源冲突策略等关键因素，从而把幻觉拆解为更细粒度的错误类别。我们在这些设置中评估前沿模型和开放权重语言模型，并发现跨领域的一致模式：对于前沿模型，直接观察信息上的感知性幻觉已接近解决，而多步状态跟踪和因果前向模拟即使对前沿模型仍然困难，并且通常不能被扩展思考所解决。尤其在终端设置中，模型还难以判断何时应当放弃回答。不同探针类型和领域中的失败分布并不均匀，这表明不同幻觉来自性质上不同的失效模式，而不是反映单一的底层能力。我们的结果表明，受控参考世界为衡量和减少现代语言模型中的幻觉提供了一条可扩展、可复现的路径。

1 引言

尽管多年来一直努力缓解，幻觉仍然是前沿语言模型（LM）中尚未解决的问题。随着基于 LM 的智能体越来越多地用于高风险场景，准确理解什么条件会导致 LM 产生幻觉以及为什么会产生幻

*所有作者均隶属于 DegenAI Labs。通讯作者：Emmy Liu (mengyan3@cs.cmu.edu)、Varun Gangal (vgtomahawk@gmail.com) 和 Steven Y. Feng (syfeng@stanford.edu)。

代码和数据：<https://github.com/DegenAI-Labs/HalluWorld>

幻觉至关重要。尽管这些现象被归入同一个术语之下，但误读一个事实、误记一个先前决策、错误推理部署语境，或相信错误信息，都是不同的失败模式，需要不同形式的缓解。虽然已有基准在对幻觉进行分类方面取得了进展 [52, 77, 2]，但一个关键限制在于：环境、LM 能观察到的内容，以及它必须如何解决冲突信息，都是由设计固定的，无法独立变化，因此难以隔离失败模式。

为解决这一问题，我们的方法建立在 Liu et al. [41] 近期提出的幻觉统一表述之上，该表述将幻觉分解为一个编码真实状态与转移集合的 **参考世界 (reference world)**、一个控制模型可观察内容的 **视图函数 (view function)**，以及一个决定可观察来源之间冲突如何被裁定的 **冲突策略 (conflict policy)**。在这一设定下，当模型输出与真实参考世界相矛盾时，就发生了 **幻觉**。将这些组成部分显式化，使我们能够以系统方式对模型进行压力测试：在保持其他因素不变的同时，独立改变某一个因素。为使这一点具体化，考虑一个负责定位配置文件的终端智能体：同一个智能体在获得完整目录输出时可能回答正确，在获得部分输出时可能幻觉出一个文件路径，而当过时日志与它当前可观察到的内容相矛盾时，可能又会幻觉出另一条路径。通过隔离哪些条件会触发幻觉，我们可以主动用有针对性的干预来支持模型。




图 1: HalluWorld 基准覆盖三个领域（网格世界、国际象棋和终端），并使用五类探针类别测试模型，每一类都针对不同的认知技能：**因果 (Causal) (C)** 测试对因果关系的理解，**感知 (Perceptual) (P)** 测试空间推理与对象追踪，**记忆 (Memory) (M)** 测试对过往观测的保持，**不确定性 (Uncertainty) (U)** 测试在部分可观测条件下的推理，**复合/X (Compound/X) (X)** 测试跨相连环境的多步推理。幻觉通过放置的探针来测量，这些探针会询问模型关于其已经见过的环境观测的问题。三个领域各自的 HalluWorld 定性示例见 §A。

我们构建了一组基准 HalluWorld, 包含三个领域: 一个可定制的网格世界、一个国际象棋环境, 以及一个智能体式终端环境。在这些世界中, 幻觉的真实标签由构造直接定义, 无需人工标注。关键的是, HalluWorld 被设计为具有可扩展性: 可以很容易地为每个环境添加探测幻觉的新问题。我们的贡献可概括如下:

1. 我们引入 HalluWorld, 这是一个基准框架, 将幻觉操作化为相对于显式参考世界与冲突策略的可观察错误。
2. 我们将该基准实例化为一套受控环境, 覆盖网格世界、国际象棋和终端任务。我们的基准包含网格世界环境中的 33 个唯一关卡和 839 个探针问题, 国际象棋环境中的 7 个唯一关卡和 350 个探针, 以及终端环境中的 110 个唯一终端任务和 529 个探针。此外, 网格世界环境中的关卡编辑器和轨迹记录器支持扩展到更复杂的场景。
3. 我们在 HalluWorld 上评测了十余个前沿模型和开放模型, 发现前沿模型在直接观测信息上的感知准确率已经接近解决, 而即使对前沿模型来说, 记忆幻觉和因果前向模拟仍然是问题。此外, 模型一致地更依赖环境证词而非直接观测。增加思考强度很少能够一致地带来帮助, 这表明单靠推理可能无法缓解幻觉。

2 相关工作 (扩展见 §K)

传统上, 幻觉是相对于固定来源来定义的, 例如摘要中不受支持的内容; 后来, 这一定义被扩展为 LLM 输出中的事实错误 [32, 44, 28, 39, 34]。近期工作强调, 基准往往混合了多种失败模式, 并且缺乏一致定义, 这推动了更结构化的表述, 例如将幻觉视为“世界模型”的观点 [2, 41]。

大多数现有基准在静态设定中评估幻觉: 摘要和问答基准相对于固定文档或事实来定义真值, 而 RAG 基准研究参数化知识与检索知识之间的冲突, 但将给定上下文视为完整参考 [31, 48, 49, 17]。近期关于考虑 RAG 的预训练的工作研究模型在预训练期间应如何在参数记忆与检索之间分配知识, 指出幻觉倾向可能取决于哪些信息被外部可观测化、哪些信息被学习进参数中 [57]。诸如 MIRAGE-Bench 和 AgentHallu 这样的智能体基准评估动作层面的幻觉, 但依赖快照审计或人工标注, 而不是完全指定且可控的世界 [77, 42]。

HalluWorld 的不同之处在于, 它在部分可观测且演化的环境中评估幻觉, 并由模拟器状态定义真实值。这使自动、可复现的标注成为可能, 并允许对可观测性、时间动态和冲突证据进行受控变化。通过将幻觉的显式定义与可控环境和自动标签结合起来, HalluWorld 为研究幻觉何时以及为何发生提供了一个更精确、更具诊断性的框架。

3 HalluWorld 基准套件

HalluWorld 覆盖三个领域: 网格世界、国际象棋和终端任务。每个领域都为模型实例化了一组不同的挑战。网格世界是完全合成且可定制的游戏类环境, 常被用作强化学习与规划的测试平台 [61, 64]。因此, 它们对世界状态和所实例化的具体挑战提供了高度控制, 同时除了特定游戏先验外, 与预训练数据的重叠极少。另一方面, 终端环境为已部署智能体提供了最真实的场景, 因为我们用

表 1: 三个 HalluWorld 家族中参考世界模型框架的实例化。每个领域都提供一个完全指定的 $\mathcal{W}$ 、可控的 V ，以及可计算的 $T_{\mathcal{W},\mathcal{P}}$ 。

家族	$\mathcal{W} = (\mathcal{S}, \mathcal{H}, \mathcal{R})$	V (视图函数)	$T_{\mathcal{W},\mathcal{P}}$ 计算
HalluWorld-Grid	$\mathcal{S}$: 网格状态 (智能体位置、对象、门状态); $\mathcal{H}$: 动作历史; $\mathcal{R}$: MiniGrid 物理规则 (移动、火焰、洪水、压力板)	FOV $\times$ 序列化器 (Sym-bolic、Grid、Memory); 控制可观测性和格式	由环境状态计算: 存在性、数量、位置、因果关系
HalluWorld-Chess	$\mathcal{S} + \mathcal{H}$: FEN+ 走子历史 (PGN); $\mathcal{R}$: 国际象棋规则	FEN + 行棋方	通过国际象棋引擎计算: 合法性、吃子、牵制
HalluWorld-Terminal	$\mathcal{S}$: 文件系统状态 + 进程状态; $\mathcal{H}$: 命令执行轨迹; $\mathcal{R}$: Bash 语义 + 文件操作	终端输出轨迹 (stdout/stderr) 提供部分文件系统视图	与轨迹中的探针共同生成: 文件存在性、命令成功、状态变化

于生成基准的轨迹基于真实的软件工程任务。然而，终端上下文的复杂性与噪声也使隔离特定失败模式变得稍难。国际象棋则处于中间位置：它是一个真实且规则明确的领域，在预训练中有所呈现，但又容易生成新的棋盘状态并检查正确性。

实例化参考世界模型框架。 我们的基准套件直接实例化了近期工作中提出的形式化幻觉定义 [41]，该定义将幻觉定义为相对于参考世界 $\mathcal{W} = (\mathcal{S}, \mathcal{H}, \mathcal{R})$ 、视图函数 V 和真值函数 $T_{\mathcal{W},\mathcal{P}}$ 的可观察世界模型错误。表 1 展示了每个环境家族如何指定这些组成部分。在三个领域中， $\mathcal{W}$ 都是明确定义且可由程序获知的，从而可以在没有人工/模型标注的情况下自动生成真实值。当出现对抗性信息时（例如网格世界中的误导性告示牌、国际象棋中转置的 FEN 字符串），冲突策略 $\mathcal{P}$ 会发挥作用。

共享探针类别。 我们为每个领域使用一组五类 **探针类别**，每一类都针对一种不同的认知需求。**感知 (Perceptual, P)** 探针测试对当前观测中直接呈现的值的准确读出。**记忆 (Memory, M)** 探针要求跨多个先前观测追踪值或状态。**因果 (Causal, C)** 探针要求推理因果关系，或在环境机制下前向模拟动作结果。**不确定性 (Uncertainty, U)** 探针要求识别可用证据的边界，并在上下文不足时避免给出确定答案。按照设计，国际象棋省略不确定性探针 (§3.2)。**复合 (Compound, X)** 探针要求同时整合跨多个上下文章节、房间访问或工件类型的证据。

3.1 HalluWorld-Grid: 用于受控幻觉探测的交互式环境

HalluWorld-Grid 是一组手工构建的网格世界环境，基于 MiniGrid [7]。它包含 **33 个唯一关卡** 和 839 个探针问题（完整关卡列表见 §C）。幻觉标签从环境状态自动生成。我们提供关卡编辑器和轨迹记录器，以允许构造更复杂的环境-探针元组（见 §J）。**序列化器** 控制环境状态如何呈现给模

型；换句话说，这是对 V 的操纵，独立于内容本身。我们实现了三种格式（表 2）。

表 2: HalluWorld-Grid 中使用的序列化器格式。每一种都控制世界状态向模型呈现的方式，且独立于该状态所包含的内容。

序列化器	格式	主要测试
Symbolic	结构化文本对象列表	阅读理解、计数、状态追踪
Grid	完整网格的 ASCII 图	空间解析、布局推理
Memory	Symbolic + Grid 组合，并包含先前观测	时间追踪、变化检测

评估细节：关卡被组织为五类探针类别 (§3)，具体实例化如下：**P**（6 个关卡）在不同对象密度、朝向和变化条件下测试静态场景感知。**M**（6 个关卡）通过多房间穿越和河流物理下的对象追踪来探测时间整合。**C**（9 个关卡）引入交互式机制：火焰、洪水和压力板；更难的关卡会呈现与观测相矛盾的对抗性公告板（见 §D）。**U**（5 个关卡）覆盖未观测房间、可靠性不同的路标，以及包含无法回答问题的场景。**X**（7 个关卡）将上述内容结合为扩展的多房间回合，并在完整观测历史上进行探测。⁰ 在每个关卡中，探针采用六种封闭形式答案类型之一：**presence**（是/否对象检测）、**count**（精确整数）、**state**（属性/门状态）、**location**（坐标）、**causal**（前向模拟结果），以及 **uncertainty**（给出具体答案或 “can’t determine”）。

3.2 HalluWorld-Chess：规则治理领域中的结构化世界模型探针

国际象棋为网格世界提供了一个互补环境：国际象棋是训练数据中有充分表示的领域 [36]，并且拥有一组认知上彼此不同、自然映射到我们探针类别的丰富问题类型。国际象棋还探测一种对抗性形式的幻觉：位置取自真实 Lichess 谜题，因此模型可能同时对“典型”棋局延续持有强分布先验，并且面对一个与这些先验相矛盾的已观测位置。

环境与观测格式。每个回合从一个经过筛选的 Lichess FEN [11] 字符串池中抽取一个位置（覆盖不同等级分和主题分层）。在呈现探针之前，会从该位置执行 k 个随机合法后续着法（默认 $k = 14$ ），将棋盘推进到新颖局面，并抑制对开局库的利用。随后，序列化器渲染一种固定观测格式：i) 带有文件列（a–h）与横排（1–8）标注的 ASCII 8×8 棋盘网格，ii) 行棋方，以及 iii) 一个 FEN 字符串（用于描述特定棋盘位置的标准化单行文本；可选地通过交换两个棋子的位置造成误导）。

探针。我们在 3 类探针类别中评估 7 个探针（见 §B） (§3)。不确定性被省略，因为观测到的棋盘状态总是完全指定当前位置。感知探针要求从当前棋盘进行静态读出。因果探针要求进行前向模拟：应用一到两个假设着法，并评估所得位置的某个属性。记忆探针移除棋盘，要求模型在长走子序列中保持准确的棋局状态。ChatContext 模式会在真实观测之前添加 4-16 个带评论的过往棋局着法（网格世界 X 关卡的国际象棋对应形式），测试模型是否能将上下文信号与噪声区分开来。

⁰对抗性公告板和路标连同智能体的观测一起，是多个信息来源的一个例子；其中冲突解决策略 $\mathcal{P}$ 是智能体应依赖自己的观测（真实来源）。

3.3 HalluWorld-Terminal: 终端任务中的智能体式幻觉

HalluWorld-Terminal 将 HalluWorld 落地到现实的智能体部署中: 参考世界 $\mathcal{W}$ 是一个实时 Linux 文件系统的完整状态, 而视图 V 是在给定轨迹步骤中智能体可见的原始终端历史, 长度约为 $\approx 30\text{-}60\text{K}$ 个字符。

探针构造。我们从 132 条 Terminal-Bench [46] 轨迹中派生出 529 个探针, 这些轨迹覆盖 110 个软件工程任务 (例如内核构建、ML 框架配置等), 并由一个 gpt-4o-mini 智能体在实时 Linux 环境中执行 (以诱发多样的错误模式, 而不是来自更强模型的优化解)。探针由 LLM 使用 (gpt-5.4, reasoning_effort=high) 生成, 并基于触发步骤处的文件系统差异 (例如 SHA-256 哈希、mtimes、目录列表) 进行锚定。我们保留 answerability_score=5 且 difficulty_score ≥ 4 的探针, 得到一个可回答且困难的最终探针集合。¹ 所有 5 类探针类别都以大致相等的覆盖度实例化 (每类 $\approx 105\text{-}108$ 个探针)。每个探针针对五种幻觉失败模式之一: 陈旧记忆 (*stale memory*) (187 个探针), 即依赖过时值而不是最近的终端输出; 跨类别推理 (*cross-category reasoning*) (110), 即无法在进程列表和目录快照等上下文章节之间建立桥接; 不确定性过度断言 (*uncertainty overclaim*) (107), 即在上下文不足时断言确定答案; 因果捷径 (*causal shortcut*) (104), 即错误归因轨迹中的原因; 以及版本/API 幻觉 (*version/API hallucination*) (21), 即用训练时 API 知识替代已观测行为。

评估协议。模型接收未经编辑、已去除 ANSI 的终端上下文, 并且必须以受约束的键值模式返回答案 (例如, outcome=<ok|fail>)。评分完全基于规则, 不使用 LLM 裁判。细节见 §E。

4 实验设置

我们评估了若干模型, 包括前沿闭源模型和开放权重模型, 并在适用时同时评估思考与非思考变体。² **非思考:** GPT-4o-mini, GPT-5.4-mini, GPT-4o, Sonnet 4.6, Opus 4.6; DeepSeek-V3.1, GLM-5, Qwen-3-30B, Kimi K2.6. **思考:** o3-mini, o4-mini, o3, GPT-5.5, Sonnet 4.6 (T), Opus 4.6 (T)。所有带温度参数的模型均以 $\tau = 0$ 查询。思考模型默认以 medium 级别查询, 并针对每个领域中的选定模型进行推理消融。对于 HalluWorld-Grid, 每个 (level, serializer) 对都在非确定性关卡 (P1 和 P3) 的 10 个固定种子上评估。对于 HalluWorld-Chess, 每个探针在 50 个不同棋盘位置上运行。对于 HalluWorld-Terminal, 每个探针都使用完整运行时上下文加探针问题进行评估; 对于更长的智能体轨迹, 最多保留 60k 个字符并进行中部截断。除非另有说明, 模型的回答预算为 256 个 token, 思考预算为 16k 个 token。

表 3: HalluWorld-Grid 中按探针类别和序列化器划分的微平均幻觉率，模型按总体幻觉率排序。(T) = 中等思考模式。列分组为（左）探针类别—**P**（感知）、**M**（记忆）、**C**（因果）、**U**（不确定性）、**X**（跨类别）；以及（右）输入序列化器—**Symbolic**、**Grid** 和 **Memory**。**总体**列报告所有条件下的全局平均幻觉率。单元格颜色反映相对全局幻觉率（绿色 = 低，红色 = 高）；**粗体**表示该列最小值。

模型	探针类别						序列化器		
	总体	P	M	C	U	X	符号	网格	记忆
GPT-5.5 (T)	5.0%	0.4%	5.9%	25.3%	0.1%	2.7%	1.1%	3.1%	21.3%
Claude Opus 4.6	5.9%	3.7%	3.8%	20.1%	3.4%	4.6%	3.8%	5.1%	15.5%
Claude Opus 4.6 (T)	6.4%	1.7%	3.8%	25.2%	3.4%	4.7%	3.7%	4.9%	19.6%
o3	6.8%	0.3%	5.5%	26.0%	0.3%	5.7%	2.7%	6.2%	20.6%
Claude Sonnet 4.6	7.2%	2.8%	5.0%	19.7%	1.1%	7.6%	4.8%	7.2%	16.6%
o4-mini	7.4%	0.8%	4.5%	30.6%	0.9%	5.8%	2.9%	6.4%	23.6%
Claude Sonnet 4.6 (T)	7.7%	1.1%	6.2%	24.0%	1.1%	7.5%	5.0%	6.1%	20.4%
o3-mini	8.1%	0.4%	4.9%	23.8%	5.9%	7.6%	4.9%	7.2%	20.2%
Kimi K2.6	9.3%	5.4%	6.2%	47.4%	1.9%	8.8%	4.3%	10.1%	35.5%
GPT-4o	12.6%	10.0%	17.2%	29.0%	0.5%	11.3%	6.8%	13.6%	27.9%
GLM-5	14.3%	19.8%	15.8%	26.4%	0.0%	13.4%	8.5%	17.7%	24.9%
DeepSeek-V3-0324	15.4%	23.5%	14.3%	32.2%	4.6%	12.7%	9.9%	17.3%	28.6%
GPT-5.4-mini	21.5%	19.8%	26.6%	22.2%	5.7%	24.0%	15.4%	29.0%	23.4%
Qwen-3-30B	23.3%	22.4%	27.7%	31.6%	13.2%	23.0%	18.1%	27.0%	30.8%
GPT-4o-mini	28.1%	34.9%	39.0%	30.9%	5.1%	28.7%	18.8%	39.5%	31.2%

5 HalluWorld-Grid 结果

5.1 类别层面的总结

表 3 报告了每个模型按类别划分的探针级幻觉率。对大多数模型而言，一个一致的层级关系成立： $U < P < M < C$ ，其中 X 呈现高方差。对于强模型，存在性探针接近 100% 准确率，而因果类别即使对前沿模型也很困难（Claude Opus 4.6: 20.1%, GPT-5.5: 25.3%）。出现了两个前沿模型簇：推理模型（GPT-5.5, Claude Opus/Sonnet 4.6, o3, o4-mini, o3-mini）的总体幻觉率为 5.0-8.1%，而非推理前沿模型（GPT-4o）和大多数开放权重模型集中在 12.6-15.4%。Kimi K2.6 展现出一个显著异常：其总体幻觉率较低，为 9.3%，但这几乎完全由 C 类别上的 47.4% 驱动，同时它在 P 和 U 上仍然相对较低。这一分解表明，总体幻觉率会混合不同的失效模式，因此有必要进行类别层面的分解。

¹两个分数都由生成探针的 LLM 在创建过程中分配。可回答性（1–5）衡量探针是否能够从所提供上下文中得到无歧义的真实值；难度（1–5）衡量回答所需推理的程度。

²我们使用外部提供商（Baseten、OpenAI 和 Anthropic）的 API 额度来评估开放模型和闭源模型。

5.2 作为独立变量的序列化器

环境状态的呈现格式对幻觉有显著影响，如 Table 3 所示。Grid 序列化总体上更难，但损害具有探针特异性：在 grid 下，所有模型的 allocentric rotation (P3) 都崩塌到接近 0%，而存在性探针在两种格式中都接近上限。即使对强模型，cross-observation attribute tracking (M2) 在 grid 序列化下也是灾难性的，但计数探针会被差异化地保留：在非思考 GPT 模型降至 13–25% 的地方，o3-mini 在 grid 下仍保持接近 100% 的计数准确率。这种序列化器和探针类型 $\times$ 模型的交互无法被现有基准分解，并且具有直接的实践含义：智能体接收环境状态的格式是幻觉的独立驱动因素。

5.3 思考模型

比较同一模型家族中的思考与非思考变体，会揭示一个一致且反直觉的模式。扩展思考会略微改善感知准确率 (Sonnet 4.6 P: 2.8% $\rightarrow$ 1.1%; Opus 4.6 P: 3.7% $\rightarrow$ 1.7%)，但会恶化因果幻觉 (Sonnet 4.6 C: 19.7% $\rightarrow$ 24.0%; Opus 4.6 C: 20.1% $\rightarrow$ 25.2%)，而在不确定性上差异可以忽略。我们假设，这可能是因为感知探针有清晰答案，可以通过扩展 CoT 细读上下文推导出来；而因果探针需要开放式前向模拟，额外推理会提供更多机会去虚构看似合理的中间状态，而不是信任直接观察。这呼应了 VLMs 中扩展推理可能增加幻觉的结果 [40]。完整推理消融见 §G。

5.4 Hard 子集

Hard 子集包含 12 个 (level, serializer) 对，其中 ≥ 5 个模型达到 $\geq 20\%$ 的幻觉率（完整结果见 §H），并偏向 memory-serializer 因果关卡和 grid-serializer 感知关卡，这确认了序列化器格式是一阶难度驱动因素。前沿模型在该子集上的平均幻觉率为 15.5–21.3%；思考模型没有提供一致优势 (Sonnet 4.6: 有思考为 17.9%，无思考为 20.0%)，这与 §5.3 中的因果思考悖论一致。Kimi K2.6 是最明显的离群点，达到 53.9%，由其在 C1b 变体上近乎完全失败 (95.0% 和 100.0%) 所驱动；C6 (Flood-Fire Escape) 也属于最难关卡之一，其中对抗性证词会在时间约束下叠加因果推理难度 (Sonnet 4.6: 56.1%)。总体而言，我们看到 HalluWorld-Grid 的 Hard 子集是有效的，并且即使对前沿模型也具有挑战性。

5.5 失效模式分析

过度信任文本信息。模型始终更偏向书面证言，而不是直接观察。在 M4 (Unreliable Narrator) 中，即使强模型也会部分服从一个与其可直接观察内容相矛盾的路标。C1a 的 with-board vs. no-board 进一步凸显了这一点：在存在准确公告板时，Opus 4.6 的幻觉更多 (42.0% vs. 无公告板时 28.4%)，这表明书面规则（无论是否准确）都可能干扰隐式因果推理，而不是支持它。

无法追踪多步状态变化。记忆关卡显示，模型难以在多次观察之间维持准确的世界状态。在 M1 (River Field) 中，模型会退回到陈旧的公告板，而不是根据经过的步数计算当前物体位置。在 M2 (Witness Stand) 中，即便存在性检测仍然完整，跨房间属性追踪也会在 grid 序列化下崩塌，从而将失败隔离到跨时间把属性绑定到对象这一环节。

难以推理未来状态。需要前向模拟的因果关卡最难。C3 (Flood Room) 要求预测未来时间步中哪些 tile 可以通行。幻觉率揭示了一个显著的前沿模型内部分裂: Opus 4.6 和 Sonnet 4.6 达到 0%, 而 o3 达到 43.3%, o4-mini 达到 33.3%, 这反映出不同的因果推理行为, 并暴露了跨模型家族的不同失效模式。C6 (Flood-Fire Escape) 将前向模拟与对抗性证词叠加, 并且是前沿模型最难的关卡之一 (Sonnet 4.6: 56.1%)。总体而言, HalluWorld-Grid 使我们能够通过隔离 grid 序列化、前向模拟动态和对抗性证词等特征, 有效地对模型进行压力测试。

5.6 导航中设置 (InNav)

为了在更交互式的设置中研究 HalluWorld-Grid 并贴近真实世界的智能体部署, 我们在 In-Navigation (InNav) 设置中评估模型, 其中模型在主动导航环境时回答探针。通过将 InNav 与具有相同轨迹的 CtrlStatic 条件进行比较, 我们可以考察两个效应: 由行动-感知反馈带来的知识锚定, 以及由导航需求带来的认知负荷。我们发现, 导航通常会降低推理模型的幻觉 (例如最高可达 -13.2%), 尤其是在因果和不确定性类别中; 但在记忆或长时程任务中, 当认知负荷占主导时, 它也可能增加错误。完整细节见 §I。显然, 幻觉不仅取决于静态推理能力, 也取决于模型如何与环境交互。这表明 HalluWorld-Grid 也有助于在更现实的具身情境中评估智能体。

6 HalluWorld-Chess 结果

类别层面总结。非推理模型以及没有扩展推理的模型在 P 和 C 上紧密聚集: gpt-4o、gpt-4o-mini 和没有推理的 gpt-5.4-mini 在这两个类别上几乎无法区分, 幻觉率约为 $\approx 50\%$ 。三者都在两个长序列类别上崩溃: M 和 X 的平均幻觉率均超过 80%。同样的总体模式也适用于开源权重模型: Qwen-3-30B、GLM-5 和 DeepSeek-V3.1。为 gpt-5.4-mini 增加推理预算会显著降低 P (49.3% $\rightarrow$ 7.3%) 和 C (52.0% $\rightarrow$ 13.0%) 上的幻觉, 但仍留下显著的长视距失败: M 仍为 75.0%, X 仍为 36.0%。显然, 我们的探针类别使我们能够区分失败模式, 而不是把它们压缩成一个聚合分数。

作为前沿压力测试的记忆与复合探针。在 P 和 C 上, 最强的四个模型接近饱和: gpt-5.5、o3、gpt-5.4 和 o4-mini 的幻觉率均 $< 10\%$ 。长序列类别把它们与较弱模型区分开来, 同时也揭示了前沿模型组内部有意义的差异。gpt-5.5 在 M 和 X 上均达到 0.0%; o3 仍接近饱和 (M 2.1%, X 6.0%); gpt-5.4 同样很强 (M 8.3%, X 4.0%)。相比之下, o4-mini 解决了复合 SAN 探针 (X 0.0%), 但在纯记忆计数探针上较弱 (M 20.8%), 而 o3-mini 的 P 很低 (1.3%), 但 C (39.0%)、M (20.8%) 和 X (28.0%) 高得多。Claude 思考模型则表现相反: Opus 4.6 (T) 和 Sonnet 4.6 (T) 虽然因果幻觉率很高 (48.0% 和 44.0%), 但在 M/X 上很强 (M 2.1%, X 6.0%; M 8.3%, X 10.0%)。

错误 FEN 元数据测试模型对损坏辅助状态的鲁棒性。虽然整体模型排序基本保持不变, 但这种扰动暴露了脆弱性; 即使是 gpt-5.5 和 o3 这样的顶级模型, 幻觉率也上升了 3–4%。对较弱模型而言, 影响更为混合: 有些模型略有改善, 因为损坏的 FEN 并不是主要失败来源; 另一些模型仍由 M/X 失败主导。FEN 消融充当序列化器鲁棒性探针, 区分那些基于棋盘本身进行推理的模型, 以及那些会被不一致文本状态分散注意力的模型。

表 4: HalluWorld-Chess 在两种序列化器下按探针类别统计的幻觉率：排除 FEN 与包含错误 FEN。列：总体（全部 7 个探针，~348 个问题）；P=感知（can_capture, defended, hanging）；C=因果（hypothetical_in_check, after_move_undefended_count）；M=记忆（hidden_side_capture_stats）；X=复合（san_legal_move）。颜色标记相对幻觉率（绿色=低，红色=高）；**粗体**标记列最小值。

模型	无 FEN					错误 FEN				
	总体	P	C	M	X	总体	P	C	M	X
GPT-5.5 (T)	0.3%	0.0%	1.0%	0.0%	0.0%	4.0%	3.3%	9.0%	0.0%	0.0%
o3	2.0%	0.7%	2.0%	2.1%	6.0%	6.0%	4.7%	11.0%	0.0%	6.0%
GPT-5.4	2.6%	0.0%	3.0%	8.3%	4.0%	4.0%	4.7%	4.0%	4.2%	2.0%
o4-mini	5.7%	2.0%	7.0%	20.8%	0.0%	8.3%	5.3%	12.0%	14.6%	4.0%
o3-mini	18.7%	1.3%	39.0%	20.8%	28.0%	24.7%	12.0%	45.0%	29.2%	18.0%
Claude Sonnet 4.6 (T)	19.8%	10.7%	44.0%	8.3%	10.0%	26.1%	18.7%	46.0%	8.3%	26.0%
GPT-5.4-mini (T)	22.4%	7.3%	13.0%	75.0%	36.0%	22.1%	8.7%	19.0%	75.0%	18.0%
Claude Opus 4.6 (T)	24.7%	22.7%	48.0%	2.1%	6.0%	25.9%	26.0%	46.0%	6.2%	4.0%
Claude Opus 4.6	33.3%	28.0%	50.0%	29.2%	20.0%	33.0%	29.3%	53.0%	25.0%	12.0%
Claude Sonnet 4.6	39.7%	33.3%	49.0%	31.3%	48.0%	39.7%	36.0%	49.0%	29.2%	42.0%
Kimi-K2.6	44.5%	34.7%	34.0%	54.2%	86.0%	42.2%	42.0%	35.0%	56.2%	44.0%
GPT-5.5 (NT)	48.3%	47.3%	43.0%	85.4%	26.0%	48.9%	48.0%	52.0%	87.5%	8.0%
DeepSeek-V3.1	53.4%	48.0%	28.0%	91.7%	84.0%	50.0%	42.7%	32.0%	95.8%	64.0%
GLM-5	56.9%	44.7%	43.0%	85.4%	94.0%	47.4%	44.0%	37.0%	89.6%	38.0%
Qwen-3-30B	59.8%	46.0%	47.0%	95.8%	92.0%	59.5%	46.7%	42.0%	95.8%	98.0%
GPT-5.4-mini (NT)	60.9%	49.3%	52.0%	83.3%	92.0%	54.3%	46.7%	55.0%	87.5%	44.0%
GPT-4o	62.9%	51.3%	53.0%	91.7%	90.0%	57.8%	50.7%	60.0%	87.5%	46.0%
GPT-4o-mini	62.9%	51.3%	52.0%	85.4%	98.0%	62.9%	55.3%	50.0%	79.2%	96.0%

HalluWorld-Chess 展示了结构化探针分类相对于聚合分数的诊断价值。最弱的非推理模型在无 FEN 条件下紧密聚集（总体 57–63%），而 P/C/M/X 分解会立即定位出主要失败来自长序列状态追踪和复合 SAN 重建。模型特异性的异常只有在探针层面才会显现。错误 FEN 条件增加了一项鲁棒性测试，揭示模型是否即使在可见棋盘存在时也会过度信任损坏的辅助元数据。这验证了基准设计：真值可由算法检查，难度可通过游戏长度调节，并且分类体系揭示了特定失败模式。

7 HalluWorld-Terminal 结果

整体准确率。终端领域是 HalluWorld 中最困难的领域：即使 GPT-5.5 也只达到 94.1% 的整体准确率，并且没有任何模型在任何单一探针类别上达到饱和。出现了两个层级，这与 gridworld 的发现相呼应：思考/推理模型整体幻觉率为 5.9–21.0%，而标准模型聚集在 26.3–56.5%。与 gridworld 评估一样，这一差距部分反映了计算预算差异：思考模型被给予 max_output_tokens=16384，而标

表 5: HalluWorld-Terminal 按探针类别统计的幻觉率。 (T) = 扩展思考。类别: C = 因果, X = 跨层级复合, M = 记忆, P = 感知, U = 不确定性。单元格颜色反映相对幻觉率 (绿色 = 低, 红色 = 高); **粗体**标记列最小值。

模型	总体	C	X	M	P	U
GPT-5.5 (T)	5.9%	0.9%	1.9%	2.8%	0.9%	23.1%
o3 (T)	10.2%	4.7%	9.4%	5.6%	8.6%	23.1%
o4-mini (T)	14.2%	6.6%	8.5%	11.1%	7.6%	37.5%
Claude Opus 4.6 (T)	15.7%	10.4%	9.4%	10.2%	9.5%	39.4%
Claude Sonnet 4.6 (T)	17.8%	9.4%	14.1%	11.1%	18.1%	36.5%
o3-mini (T)	21.0%	14.1%	16.0%	13.9%	14.3%	47.1%
GLM-5	26.3%	20.8%	21.7%	21.3%	34.3%	33.7%
GPT-4o	38.4%	35.9%	39.6%	34.3%	35.2%	47.1%
DeepSeek V3.1	45.6%	49.1%	45.3%	34.3%	43.8%	55.8%
GPT-5.4-mini	50.3%	42.4%	46.2%	43.5%	55.2%	64.4%
Qwen3-30B	51.0%	41.5%	44.3%	53.7%	52.4%	63.5%
GPT-4o-mini	51.8%	39.6%	46.2%	57.4%	61.9%	53.8%
Kimi-K2.6	56.5%	56.6%	47.2%	49.1%	57.1%	73.1%

准模型上限为 256。因此, 性能差异应被解释为底层能力差异的上界, 而不是受控比较。

探针类别层级。在大多数模型中存在一致的排序(按准确率): Perceptual $\approx$ Causal $>$ Cross-Tier $\approx$ Memory $\gg$ Uncertainty。对最强模型而言, 感知和因果准确率接近上限; 一旦长上下文检索可靠, 从 50k 字符的终端上下文中正确读取一个直接出现的值就是可处理的。不确定性探针最难: 即使 GPT-5.5 和 o3 的准确率上限也只有 76.9%, 这意味着当正确回答是 “cannot determine” 时, 最佳模型仍会在 $\approx 1/4$ 的答案中产生幻觉。这与受控 gridworld U 类别形成对比, 在那里不确定性往往更容易; 这表明在真实终端上下文中, 认识论层面的拒答会显著更难。

值得注意的异常。GPT-4o-mini 显示出独特的反转记忆画像: 它的记忆幻觉率 (57.4%) 显著高于因果率 (39.6%), 表明它在长视距状态追踪上存在特定失败。Kimi-K2.6 在终端领域表现出最高的不确定性幻觉率 (73.1%)。由于 U 探针专门针对不确定性过度断言失败模式, 这表明在这里的认识论限制下, Kimi 有很高的自信虚构倾向。

思考深度消融。HalluWorld-Grid (§5.3) 中识别出的思考悖论在 HalluWorld-Terminal 中呈现出混合形态。观察 Table 14, 对 Sonnet 4.6 而言, 准确率从 79.2% (无思考) 到 86.2% (最大) 单调增加, 每个探针类别都受益于更深的推理。GPT-5.5 显示出不同模式: 任何推理预算都会带来大幅跃升 (+8.5 pp, 86.4% $\rightarrow$ 94.9%), 但收益并非单调: medium 略低于 low, high 最好, 而 xhigh 相对于 high 略有回退。GPT-5.5 在不确定性上呈现非单调模式: low、medium 和 xhigh 推理低于 no 推理设置, 而 high 推理达到最佳 U 准确率 (84.3%)。这表明, 在大多数情况下, 推理具体干扰的是认识论拒答, 而不是事实检索或因果推断。无论推理深度如何, 不确定性仍是两个模型最难的类别, 所有配置都在 60–85% 范围内平台化。完整消融结果见 §F。关于幻觉率如何随轨迹深度变化

的补充分析见 Figure 2。

8 结论与未来工作

我们的基准 HalluWorld 表明，幻觉从根本上是一种世界建模失败，它可分解为不同类别（感知、记忆、因果、不确定性），其中许多类别对前沿模型而言仍未解决。通过将评估锚定在显式、可控的环境中，HalluWorld 能够对幻觉何时以及为何发生进行可复现的细粒度诊断。HalluWorld 将幻觉从模糊指标转化为实验上可处理的问题，支持有针对性的干预，并支持超越聚合分数的更深入分析。

未来工作有若干方向。首先，我们当前的探针测量显式或陈述出来的信念，但模型的内部表示中可能具有更宽的分布 [56]。因果追踪等机制性技术 [51, 45] 可以提供一个观察这些内部信念的视角。其次，当前探针使用与构造环境共同设计的位置，这些位置被选为认知负荷可能更高的地点。更一般的探针放置表述可以使用主动学习方法 [73]，在给定环境中动态发现智能体会面对最大认知负荷的状态。此外，可以更明确地纳入并评估多源冲突解决。最后，研究小模型和数据受限情形下的幻觉也会很有意思，例如 BabyLM 规模 [71, 25, 16, 43, 15, 24, 75]。

致谢

我们衷心感谢 Modal、National Science Foundation ACCESS Program、Lambda Labs’ Research Grant Program 以及 NVIDIA’s Academic Grant Program 提供计算资源，使本工作得以完成。EL 得到了加拿大自然科学与工程研究委员会（NSERC）[资助参考编号 578085] 以及 SoftBank-ARM Fellowship 的支持。

参考文献

- [1] Zechen Bai, Pichao Wang, Tianjun Xiao, Tong He, Zongbo Han, Zheng Zhang, and Mike Zheng Shou. Hallucination of Multimodal Large Language Models: A Survey. 4 2025.
- [2] Yejin Bang, Ziwei Ji, Alan Schelten, Anthony Hartshorn, Tara Fowler, Cheng Zhang, Nicola Cancedda, and Pascale Fung. HalluLens: LLM Hallucination Benchmark. 4 2025.
- [3] Forrest Sheng Bao, Miaoran Li, Renyi Qu, Ge Luo, Erana Wan, Yujia Tang, Weisi Fan, Manveer Singh Tamber, Suleman Kazi, Vivek Sourabh, Mike Qi, Ruixuan Tu, Chenyu Xu, Matthew Gonzales, Ofer Mendelevitch, and Amin Ahmad. FaithBench: A Diverse Hallucination Benchmark for Summarization by Modern LLMs. 10 2024.

- [4] Center for AI Safety, Scale AI, and HLE Contributors Consortium. A benchmark of expert-level academic questions to assess ai capabilities. *Nature*, 649:1139–1146, 2026. doi: 10.1038/s41586-025-09962-4. URL <https://doi.org/10.1038/s41586-025-09962-4>.
- [5] Jiawei Chen, Hongyu Lin, Xianpei Han, and Le Sun. Benchmarking Large Language Models in Retrieval-Augmented Generation. 12 2023.
- [6] Maxime Chevalier-Boisvert, Dzmitry Bahdanau, Salem Lahlou, Lucas Willems, Chitwan Saharia, Thien Huu Nguyen, and Yoshua Bengio. BabyAI: A Platform to Study the Sample Efficiency of Grounded Language Learning. 12 2019.
- [7] Maxime Chevalier-Boisvert, Bolun Dai, Mark Towers, Rodrigo Perez-Vicente, Lucas Willems, Salem Lahlou, Suman Pal, Pablo Samuel Castro, and Jordan Terry. Minigrid & miniworld: Modular & customizable reinforcement learning environments for goal-oriented tasks. In *Advances in Neural Information Processing Systems 36, New Orleans, LA, USA*, December 2023.
- [8] Peter Clark, Oyvind Tafjord, and Kyle Richardson. Transformers as Soft Reasoners over Language. 5 2020.
- [9] Marc-Alexandre Côté, Ákos Kádár, Xingdi Yuan, Ben Kybartas, Tavian Barnes, Emery Fine, James Moore, Ruo Yu Tao, Matthew Hausknecht, Layla El Asri, Mahmoud Adada, Wendy Tay, and Adam Trischler. TextWorld: A Learning Environment for Text-based Games. 11 2019.
- [10] Alexandre Drouin, Maxime Gasse, Massimo Caccia, Issam H. Laradji, Manuel Del Verme, Tom Marty, Léo Boisvert, Megh Thakkar, Quentin Cappart, David Vazquez, Nicolas Chapados, and Alexandre Lacoste. WorkArena: How Capable Are Web Agents at Solving Common Knowledge Work Tasks? 7 2024.
- [11] Steven J Edwards, SD Forsyth, J Stanback, and A Saremba. Standard: Portable game notation specification and implementation guide. 1994. URL https://ia802908.us.archive.org/26/items/pgn-standard-1994-03-12/PGN_standard_1994-03-12.txt, 1994.
- [12] Steven Y. Feng, Jessica Huynh, Chaitanya Prasad Narisetty, Eduard Hovy, and Varun Gangal. SAPHIRE: Approaches for enhanced concept-to-text generation. In Anya Belz, Angela Fan, Ehud Reiter, and Yaji Sripada, editors, *Proceedings of the 14th International Conference on Natural Language Generation*, pages 212–225, Aberdeen, Scotland, UK, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.inlg-1.21. URL <https://aclanthology.org/2021.inlg-1.21/>.

- [13] Steven Y. Feng, Kevin Lu, Zhuofu Tao, Malihe Alikhani, Teruko Mitamura, Eduard Hovy, and Varun Gangal. Retrieve, caption, generate: Visual grounding for enhancing commonsense in text generation models. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36(10): 10618–10626, Jun. 2022. doi: 10.1609/aaai.v36i10.21306. URL <https://ojs.aaai.org/index.php/AAAI/article/view/21306>.
- [14] Steven Y. Feng, Vivek Khetan, Bogdan Sacaleanu, Anatole Gershman, and Eduard Hovy. CHARD: Clinical health-aware reasoning across dimensions for text generation models. In Andreas Vlachos and Isabelle Augenstein, editors, *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 313–327, Dubrovnik, Croatia, May 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.eacl-main.24. URL <https://aclanthology.org/2023.eacl-main.24/>.
- [15] Steven Y. Feng, Noah D. Goodman, and Michael C. Frank. Is child-directed speech effective training data for language models? In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen, editors, *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 22055–22071, Miami, Florida, USA, November 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.emnlp-main.1231. URL <https://aclanthology.org/2024.emnlp-main.1231/>.
- [16] Steven Y. Feng, Alvin W. M. Tan, and Michael C. Frank. Baby scale: Investigating models trained on individual children’s language input, 2026. URL <https://arxiv.org/abs/2603.29522>.
- [17] Robert Friel, Masha Belyi, and Atindriyo Sanyal. RAGBench: Explainable Benchmark for Retrieval-Augmented Generation Systems. 1 2025.
- [18] Tianrui Guan, Fuxiao Liu, Xiyang Wu, Ruiqi Xian, Zongxia Li, Xiaoyu Liu, Xijun Wang, Lichang Chen, Furong Huang, Yaser Yacoob, Dinesh Manocha, and Tianyi Zhou. HalluBench: An Advanced Diagnostic Suite for Entangled Language Hallucination and Visual Illusion in Large Vision-Language Models. 3 2024.
- [19] David Ha and Jürgen Schmidhuber. World Models. 5 2018. doi: 10.5281/zenodo.1207631.
- [20] Danijar Hafner, Timothy Lillicrap, Ian Fischer, Ruben Villegas, David Ha, Honglak Lee, and James Davidson. Learning Latent Dynamics for Planning from Pixels. 6 2019.
- [21] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to Control: Learning Behaviors by Latent Imagination. 3 2020.
- [22] Romain Harang, Jason Naradowsky, Yaswitha Gujju, and Yusuke Miyao. Tracking World States with Language Models: State-Based Evaluation Using Chess. 8 2025.

- [23] Mikael Henaff, Jason Weston, Arthur Szlam, Antoine Bordes, and Yann LeCun. Tracking the World State with Recurrent Entity Networks. 5 2017.
- [24] Jennifer Hu, Alvin Wei Ming Tan, Steven Y. Feng, and Michael C. Frank. Language production is harder than comprehension for children and language models. In *Proceedings of the Annual Meeting of the Cognitive Science Society*, volume 47, 2025. URL <https://escholarship.org/uc/item/5rz8b9jg>.
- [25] Michael Y Hu, Aaron Mueller, Candace Ross, Adina Williams, Tal Linzen, Chengxu Zhuang, Ryan Cotterell, Leshem Choshen, Alex Warstadt, and Ethan Gotlieb Wilcox. Findings of the second babylm challenge: Sample-efficient pretraining on developmentally plausible corpora. In *The 2nd BabyLM Challenge at the 28th Conference on Computational Natural Language Learning*, pages 1–21, 2024.
- [26] Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, and Ting Liu. A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. 11 2024. doi: 10.1145/3703155.
- [27] Alon Jacovi, Andrew Wang, Chris Alberti, Connie Tao, Jon Lipovetz, Kate Olszewska, Lukas Haas, Michelle Liu, Nate Keating, Adam Bloniarz, Carl Saroufim, Corey Fry, Dror Marcus, Doron Kukliansky, Gaurav Singh Tomar, James Swirhun, Jinwei Xing, Lily Wang, Madhu Gurumurthy, Michael Aaron, Moran Ambar, Rachana Fellingner, Rui Wang, Zizhao Zhang, Sasha Goldshtein, and Dipanjan Das. The FACTS Grounding Leaderboard: Benchmarking LLMs’ Ability to Ground Responses to Long-Form Input. 1 2025.
- [28] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Delong Chen, Wenliang Dai, Ho Shu Chan, Andrea Madotto, and Pascale Fung. Survey of Hallucination in Natural Language Generation. 7 2024. doi: 10.1145/3571730.
- [29] Mehran Kazemi, Quan Yuan, Deepti Bhatia, Najoung Kim, Xin Xu, Vaiva Imbrasaite, and Deepak Ramachandran. BoardgameQA: A Dataset for Natural Language Reasoning with Contradictory Information. 6 2023.
- [30] Harsha Kokel, Michael Katz, Kavitha Srinivas, and Shirin Sohrabi. ACPBench: Reasoning about Action, Change, and Planning. 2 2026. doi: 10.1609/aaai.v39i25.34857.
- [31] Wojciech Kryściński, Bryan McCann, Caiming Xiong, and Richard Socher. Evaluating the Factual Consistency of Abstractive Text Summarization. 10 2019.

- [32] Katherine Lee, Orhan Firat, Ashish Agarwal, Clara Fannjiang, and David Sussillo. Hallucinations in Neural Machine Translation, 2019. URL <https://openreview.net/forum?id=SkxJ-309FQ>.
- [33] Belinda Z. Li, Zifan Carl Guo, and Jacob Andreas. (How) Do Language Models Track State? 10 2025.
- [34] Junyi Li, Xiaoxue Cheng, Wayne Xin Zhao, Jian-Yun Nie, and Ji-Rong Wen. HaluEval: A Large-Scale Hallucination Evaluation Benchmark for Large Language Models. 10 2023.
- [35] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating Object Hallucination in Large Vision-Language Models. 10 2023.
- [36] Lichess. Lichess open database, 2022. URL <https://database.lichess.org/>. Accessed: 2026-05-04.
- [37] Bill Yuchen Lin, Wangchunshu Zhou, Ming Shen, Pei Zhou, Chandra Bhagavatula, Yejin Choi, and Xiang Ren. CommonGen: A constrained text generation challenge for generative commonsense reasoning. In Trevor Cohn, Yulan He, and Yang Liu, editors, *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1823–1840, Online, November 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.findings-emnlp.165. URL <https://aclanthology.org/2020.findings-emnlp.165/>.
- [38] Jessy Lin, Yuqing Du, Olivia Watkins, Danijar Hafner, Pieter Abbeel, Dan Klein, and Anca Dragan. Learning to Model the World with Language. 5 2024.
- [39] Stephanie Lin, Jacob Hilton, and Owain Evans. TruthfulQA: Measuring How Models Mimic Human Falsehoods. 5 2022.
- [40] Chengzhi Liu, Zhongxing Xu, Qingyue Wei, Juncheng Wu, James Zou, Xin Eric Wang, Yuyin Zhou, and Sheng Liu. More thinking, less seeing? assessing amplified hallucination in multi-modal reasoning models, 2025. URL <https://arxiv.org/abs/2505.21523>.
- [41] Emmy Liu, Varun Gangal, Chelsea Zou, Michael Yu, Xiaoqi Huang, Alex Chang, Zhuofu Tao, Karan Singh, Sachin Kumar, and Steven Y. Feng. A unified definition of hallucination: It’s the world model, stupid!, 2026. URL <https://arxiv.org/abs/2512.21577>.
- [42] Xuannan Liu, Xiao Yang, Zekun Li, Peipei Li, and Ran He. AgentHallu: Benchmarking Automated Hallucination Attribution of LLM-based Agents. 1 2026.
- [43] Bria Long, Robert Z Sparks, Violet Xiang, Stefan Stojanov, Zi Yin, Grace E Keene, Alvin WM Tan, Steven Y Feng, Chengxu Zhuang, Virginia A Marchman, et al. The babyview dataset:

- High-resolution egocentric videos of infants’ and young children’s everyday experiences. *arXiv preprint arXiv:2406.10447*, 2024.
- [44] Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. On Faithfulness and Factuality in Abstractive Summarization. 5 2020.
- [45] Kevin Meng, David Bau, Alex Andonian, and Yonatan Belinkov. Locating and editing factual associations in gpt. *Advances in neural information processing systems*, 35:17359–17372, 2022.
- [46] Mike A. Merrill, Alexander G. Shaw, Nicholas Carlini, Boxuan Li, Harsh Raj, Ivan Bercovich, Lin Shi, Jeong Yeon Shin, Thomas Walshe, E. Kelly Buchanan, Junhong Shen, Guanghao Ye, Haowei Lin, Jason Poulos, Maoyu Wang, Marianna Nezhurina, Jenia Jitsev, Di Lu, Orfeas Menis Mastromichalakis, Zhiwei Xu, Zizhao Chen, Yue Liu, Robert Zhang, Leon Liangyu Chen, Anurag Kashyap, Jan-Lucas Uslu, Jeffrey Li, Jianbo Wu, Minghao Yan, Song Bian, Vedang Sharma, Ke Sun, Steven Dillmann, Akshay Anand, Andrew Lanpouthakoun, Bardia Koopah, Changran Hu, Etash Guha, Gabriel H. S. Dreiman, Jiacheng Zhu, Karl Krauth, Li Zhong, Niklas Muennighoff, Robert Amanfu, Shangyin Tan, Shreyas Pimpalgaonkar, Tushar Aggarwal, Xiangning Lin, Xin Lan, Xuandong Zhao, Yiqing Liang, Yuanli Wang, Zilong Wang, Changzhi Zhou, David Heineman, Hange Liu, Harsh Trivedi, John Yang, Junhong Lin, Manish Shetty, Michael Yang, Nabil Omi, Negin Raoof, Shanda Li, Terry Yue Zhuo, Wuwei Lin, Yiwei Dai, Yuxin Wang, Wenhao Chai, Shang Zhou, Dariush Wahdany, Ziyu She, Jiaming Hu, Zhikang Dong, Yuxuan Zhu, Sasha Cui, Ahson Saiyed, Arinbjörn Kolbeinsson, Jesse Hu, Christopher Michael Rytting, Ryan Marten, Yixin Wang, Alex Dimakis, Andy Konwinski, and Ludwig Schmidt. Terminal-bench: Benchmarking agents on hard, realistic tasks in command line interfaces, 2026. URL <https://arxiv.org/abs/2601.11868>.
- [47] Grégoire Mialon, Clémentine Fourrier, Craig Swift, Thomas Wolf, Yann LeCun, and Thomas Scialom. GAIA: a benchmark for General AI Assistants. 11 2023.
- [48] Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Wei Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. 10 2023.
- [49] Cheng Niu, Yuanhao Wu, Juno Zhu, Siliang Xu, Kashun Shum, Randy Zhong, Juntong Song, and Tong Zhang. RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models. 5 2024.
- [50] Artidoro Pagnoni, Vidhisha Balachandran, and Yulia Tsvetkov. Understanding Factuality in Abstractive Summarization with FRANK: A Benchmark for Factuality Metrics. 7 2021.

- [51] Nikhil Prakash, Natalie Shapira, Arnab Sen Sharma, Christoph Riedl, Yonatan Belinkov, Tamar Rott Shaham, David Bau, and Atticus Geiger. Language models use lookbacks to track beliefs. In *The Fourteenth International Conference on Learning Representations*, 2026.
- [52] Abhilasha Ravichander, Shruti Ghela, David Wadden, and Yejin Choi. HALoGEN: Fantastic LLM hallucinations and where to find them. In Wanxiang Che, Joyce Nabende, Ekaterina Shutova, and Mohammad Taher Pilehvar, editors, *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1402–1425, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-251-0. doi: 10.18653/v1/2025.acl-long.71. URL <https://aclanthology.org/2025.acl-long.71/>.
- [53] Anna Rohrbach, Lisa Anne Hendricks, Kaylee Burns, Trevor Darrell, and Kate Saenko. Object Hallucination in Image Captioning. 3 2019.
- [54] Julian Schrittwieser, Ioannis Antonoglou, Thomas Hubert, Karen Simonyan, Laurent Sifre, Simon Schmitt, Arthur Guez, Edward Lockhart, Demis Hassabis, Thore Graepel, Timothy Lillicrap, and David Silver. Mastering Atari, Go, Chess and Shogi by Planning with a Learned Model. 2 2020. doi: 10.1038/s41586-020-03051-4.
- [55] Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. ALFWorld: Aligning Text and Embodied Environments for Interactive Learning. 3 2021.
- [56] Aryan Shrivastava and Ari Holtzman. Linearly decoding refused knowledge in aligned language models. *arXiv preprint arXiv:2507.00239*, 2025.
- [57] Karan Singh, Michael Yu, Varun Gangal, Zhuofu Tao, Sachin Kumar, Emmy Liu, and Steven Y. Feng. To memorize or to retrieve: Scaling laws for rag-considerate pretraining, 2026. URL <https://arxiv.org/abs/2604.00715>.
- [58] Koustuv Sinha, Shagun Sodhani, Jin Dong, Joelle Pineau, and William L. Hamilton. CLUTRR: A Diagnostic Benchmark for Inductive Reasoning from Text. 9 2019.
- [59] Zhaochen Su, Jun Zhang, Xiaoye Qu, Tong Zhu, Yanshu Li, Jiashuo Sun, Juntao Li, Min Zhang, and Yu Cheng. ConflictBank: A Benchmark for Evaluating the Influence of Knowledge Conflicts in LLM. 8 2024.
- [60] Zhiqing Sun, Sheng Shen, Shengcao Cao, Haotian Liu, Chunyuan Li, Yikang Shen, Chuang Gan, Liang-Yan Gui, Yu-Xiong Wang, Yiming Yang, Kurt Keutzer, and Trevor Darrell. Aligning Large Multimodal Models with Factually Augmented RLHF. 9 2023.

- [61] Richard S Sutton, Andrew G Barto, et al. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998.
- [62] Oyvind Tafjord, Bhavana Dalvi Mishra, and Peter Clark. ProofWriter: Generating Implications, Proofs, and Abductive Statements over Natural Language. 6 2021.
- [63] Ronen Tamari, Kyle Richardson, Aviad Sar-Shalom, Noam Kahlon, Nelson Liu, Reut Tsarfaty, and Dafna Shahaf. Dyna-bAbI: unlocking bAbI’s potential with dynamic synthetic benchmarking. 11 2021.
- [64] Craig Tovey and Sven Koenig. Gridworlds as testbeds for planning with incomplete information. In *AAAI/IAAI*, pages 819–824, 2000.
- [65] Karthik Valmeekam, Matthew Marquez, Alberto Olmo, Sarath Sreedharan, and Subbarao Kambhampati. PlanBench: An Extensible Benchmark for Evaluating Large Language Models on Planning and Reasoning about Change. 11 2023.
- [66] Pranav Narayanan Venkit, Tatiana Chakravorti, Vipul Gupta, Heidi Biggs, Mukund Srinath, Koustava Goswami, Sarah Rajtmajer, and Shomir Wilson. An Audit on the Perspectives and Challenges of Hallucinations in NLP. 9 2024.
- [67] Alex Wang, Kyunghyun Cho, and Mike Lewis. Asking and Answering Questions to Evaluate the Factual Consistency of Summaries. 4 2020.
- [68] Junyang Wang, Yuhang Wang, Guohai Xu, Jing Zhang, Yukai Gu, Haitao Jia, Jiaqi Wang, Haiyang Xu, Ming Yan, Ji Zhang, and Jitao Sang. AMBER: An LLM-free Multi-dimensional Benchmark for MLLMs Hallucination Evaluation. 2 2024.
- [69] Yike Wang, Shangbin Feng, Heng Wang, Weijia Shi, Vidhisha Balachandran, Tianxing He, and Yulia Tsvetkov. Resolving Knowledge Conflicts in Large Language Models. 10 2024.
- [70] Zhecan Wang, Garrett Bingham, Adams Yu, Quoc Le, Thang Luong, and Golnaz Ghiasi. HaloQuest: A Visual Hallucination Dataset for Advancing Multimodal Reasoning. 7 2024.
- [71] Alex Warstadt, Aaron Mueller, Leshem Choshen, Ethan Wilcox, Chengxu Zhuang, Juan Ciro, Rafael Mosquera, Bhargavi Paranjabe, Adina Williams, Tal Linzen, et al. Findings of the babyLM challenge: Sample-efficient pretraining on developmentally plausible corpora. In *Proceedings of the BabyLM Challenge at the 27th Conference on Computational Natural Language Learning*, 2023.
- [72] Jason Weston, Antoine Bordes, Sumit Chopra, Alexander M. Rush, Bart van Merriënboer, Armand Joulin, and Tomas Mikolov. Towards AI-Complete Question Answering: A Set of Prerequisite Toy Tasks. 12 2015.

- [73] Yu Xia, Xu Liu, Tong Yu, Sungchul Kim, Ryan Rossi, Anup Rao, Tung Mai, and Shuai Li. Hallucination diversity-aware active learning for text summarization. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 8665–8677, 2024.
- [74] Tianbao Xie, Danyang Zhang, Jixuan Chen, Xiaochuan Li, Siheng Zhao, Ruisheng Cao, Toh Jing Hua, Zhoujun Cheng, Dongchan Shin, Fangyu Lei, Yitao Liu, Yiheng Xu, Shuyan Zhou, Silvio Savarese, Caiming Xiong, Victor Zhong, and Tao Yu. OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. 5 2024.
- [75] Linda Zeng, Steven Y. Feng, and Michael C. Frank. Bringing up a bilingual babyLM: Investigating multilingual language acquisition using small-scale models, 2026. URL <https://arxiv.org/abs/2603.29552>.
- [76] Alex Zhang, Khanh Nguyen, Jens Tuyls, Albert Lin, and Karthik Narasimhan. Language-Guided World Models: A Model-Based Approach to AI Control. 9 2024.
- [77] Weichen Zhang, Yiyu Sun, Pohao Huang, Jiayue Pu, Heyue Lin, and Dawn Song. MIRAGE-Bench: LLM Agent is Hallucinating and Where to Find Them. 7 2025.
- [78] Shuyan Zhou, Frank F. Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, Uri Alon, and Graham Neubig. WebArena: A Realistic Web Environment for Building Autonomous Agents. 4 2024.

A HalluWorld 定性示例

A.1 HalluWorld-Grid

组成部分	细节																																																																						
世界： P1 Dense Array	网格视图（规范位置 1）： <table><tr><td></td><td>L6</td><td>L5</td><td>L4</td><td>L3</td><td>L2</td><td>L1</td><td>0</td><td>R1</td><td>R2</td><td>R3</td><td>R4</td><td>R5</td><td>R6</td></tr><tr><td>ahead 0</td><td>??</td><td>##</td><td>..</td><td>..</td><td>..</td><td>..</td><td>@.</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td></tr><tr><td>ahead 1</td><td>??</td><td>##</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>gB</td><td>..</td><td>..</td></tr><tr><td>ahead 2</td><td>??</td><td>##</td><td>bB</td><td>rB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>..</td><td>..</td></tr></table>		L6	L5	L4	L3	L2	L1	0	R1	R2	R3	R4	R5	R6	ahead 0	??	##	..	..	..	..	@.	..	..	..	..	..	..	ahead 1	??	##	bB	bB	bB	bB	bB	bB	bB	bB	gB	..	..	ahead 2	??	##	bB	rB	bB	bB	bB	bB	bB	bB	bB	..	..														
	L6	L5	L4	L3	L2	L1	0	R1	R2	R3	R4	R5	R6																																																										
ahead 0	??	##	..	..	..	..	@.	..	..	..	..	..	..																																																										
ahead 1	??	##	bB	bB	bB	bB	bB	bB	bB	bB	gB	..	..																																																										
ahead 2	??	##	bB	rB	bB	bB	bB	bB	bB	bB	bB	..	..																																																										
序列化器： Grid	<table><tr><td>ahead 3</td><td>??</td><td>##</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>bB</td><td>..</td><td>..</td></tr><tr><td>ahead 4</td><td>??</td><td>##</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td><td>..</td></tr><tr><td>ahead 5</td><td>??</td><td>##</td><td>rK</td><td>rK</td><td>rK</td><td>..</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>..</td><td>..</td></tr><tr><td>ahead 6</td><td>??</td><td>##</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>bK</td><td>rK</td><td>..</td><td>..</td></tr><tr><td>ahead 7</td><td>??</td><td>##</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>rK</td><td>..</td><td>..</td></tr></table>	ahead 3	??	##	bB	bB	bB	bB	bB	bB	bB	bB	bB	..	..	ahead 4	??	##	..	..	..	..	..	..	..	..	..	..	..	ahead 5	??	##	rK	rK	rK	..	rK	rK	rK	rK	rK	..	..	ahead 6	??	##	rK	rK	rK	rK	rK	rK	rK	bK	rK	..	..	ahead 7	??	##	rK	rK	rK	rK	rK	rK	rK	rK	rK	..	..
ahead 3	??	##	bB	bB	bB	bB	bB	bB	bB	bB	bB	..	..																																																										
ahead 4	??	##	..	..	..	..	..	..	..	..	..	..	..																																																										
ahead 5	??	##	rK	rK	rK	..	rK	rK	rK	rK	rK	..	..																																																										
ahead 6	??	##	rK	rK	rK	rK	rK	rK	rK	bK	rK	..	..																																																										
ahead 7	??	##	rK	rK	rK	rK	rK	rK	rK	rK	rK	..	..																																																										
智能体：朝北	图例： K= 钥匙, B= 球, D= 门, @= 智能体, #= 墙, .= 地板																																																																						
模式： CtrlStatic	颜色： r= 红色, b= 蓝色, g= 绿色, y= 黄色																																																																						

探针（共 4 个）	探针 1（存在性）：“你当前视野中有绿色球吗？” → 标准答案： yes（绿色球位于 R4、ahead 1） 探针 2（计数）：“你看到了多少个蓝色球？” → 标准答案： 14 探针 3（属性）：“R1、ahead 2 处的球是什么颜色？” → 标准答案： red 探针 4（位置）：“蓝色钥匙相对于你在哪里？” → 标准答案： {"steps_ahead": 6, "lateral": 3}
-----------	---

模型回答	GPT-4o： ✓ P1: “yes” ✗ P2: “15”（过度计数） ✗ P3: “blue” ✓ P4: 正确 GPT-5.5： ✓ P1: “yes” ✓ P2: “14” ✓ P3: “red” ✗ P4: （偏差 1 步） o3-mini： ✓ P1: “yes” ✗ P2: “13”（计数不足） ✗ P3: “blue” ✓ P4: 正确 gpt-4o-mini： ✗ P1: “no” ✗ P2: “10” ✓ P3: “red” ✗ P4: （横向位置错误）
------	---

表 6: HalluWorld-Grid 感知探针（P1 Dense Array）：示例展示世界状态（Grid 序列化器）、四种探针类型和模型回答。✗ 表示幻觉，✓ 表示正确答案。

A.2 HalluWorld-Chess

组成部分	细节
世界： C1a Persistent 序列化器： Memory 模式： InNav	记忆序列化（时间步 8）： “你从一个有灰色巨石的房间开始。你把它向北移动，露出了下面的灰色钥匙。你捡起灰色钥匙。你沿走廊向北移动 3 步。你到达一扇上锁的灰色门前。你用灰色钥匙将其切换为打开状态。你进入一个新房间，东侧可见一个红色球。” 当前 FOV： [Ahead: floor Left: wall Right: red ball (rB) Behind: grey open door]
探针（共 3 个）	探针 1（持久性）：“一开始巨石下面藏着什么？” → grey key 探针 2（存在性）：“是否有红色球可见？” → yes 探针 3（因果）：“你为什么能够打开灰色门？” → had grey key
模型回答 (InNav 对比 CtrlStatic)	GPT-4o： P1 (Mem): ✓ P2 (Percep): ✗ InNav “no” P3 (Causal): ✗ InNav “pushed boulder” GPT-5.5： P1 (Mem): ✓ P2 (Percep): ✓ P3 (Causal): ✓ o3-mini： P1 (Mem): ✓ P2 (Percep): ✗ InNav “no” P3 (Causal): ✗ InNav “door was unlocked”

表 7: HalluWorld-Grid 记忆/因果探针 (C1a Persistent Chain)： InNav 模式导航放大了 GPT-4o 和 o3-mini 的幻觉（体现认知负荷），而 GPT-5.5 保持准确（认识论扎根）。

A.3 HalluWorld-Terminal

表 9: HalluWorld-Terminal 运行时探针 (3d-model-format-legacy)： 示例展示一个后期编译循环，其中模型必须协调终端输出、命令历史、文件系统快照和不一致的工作目录信号。

组成部分	细节			
任务： 3d-model-format-legacy	运行时终端证据（步骤 0258）：			
序列化器： 终端 轨迹 + 路径快照	命令	操作	/app/MdfLib mtime	listing_sha256
	0249	timeline memset edit	1777902356	661d...
	0250	header memset edit	1777902356	48dd...
	0251	delete windows.h from stdafx.cpp	1777902356	48dd...
	0252	g++ compile	1777902356	48dd...
	0253	header memset edit	1777902371	e0cf...
	0254	mesh memset edit	1777902372	e0cf...
	0255	timeline memset edit	1777902372	e0cf...
	0256	header memset edit	1777902372	3dfc...
	0257	delete windows.h from stdafx.cpp	1777902373	3dfc...
	0258	g++ compile	1777902373	3dfc...

续于下一页

组成部分	细节
触发命令:	g++ -o MdfFormat MdfFormat.cpp stdafx.cpp -I.
轨迹信号:	编译输出仍然报告 MdfFormat.cpp:543:55 和 stdafx.h:11:10: fatal error: windows.h; 捕获到的提示符显示为 /app/MdfLib#, 而 /app 下 MdfFormat.cpp 和 stdafx.cpp 的相对快照并不存在。
模式: 运行时探针	范围: through_trigger
探针 (共 5 个)	探针 1 (感知): “哪些命令索引改变了 listing_sha256, 同时让 mtime_epoch 保持不变?” → idx=0250,0256 探针 2 (记忆): “此前报告的哪一个编译问题从未被命令 0219-0257 中任何 sed 模式直接处理?” → untouched=line543_cast 探针 3 (因果): “如果命令 0257 删除的是 stdafx.h 而不是 stdafx.cpp 中的 #include <windows.h>, 那个 fatal 诊断会发生什么?” → diag=disappear 探针 4 (不确定性): “相对快照 MdfFormat.cpp 和 stdafx.cpp 是否是在编译命令使用的同一目录上下文中取得的?” → status=contradicted 探针 5 (跨类别): “哪一种反复出现的编辑类型与每一次观测到的 /app/MdfLib listing-hash 变化相关, 并且与 windows.h include 链无关?” → edit=header_memset_fix
评估说明	抽取出的探针 JSON 存储了有依据的问题和黄金答案, 但本次 checkout 不包含逐探针的 probe_eval 模型回答记录。全部 529 个探针上的聚合结果另行提供: GPT-5.5 94.1%, o3 89.8%, GPT-4o 61.6%, GPT-4o-mini 48.2%。

表 10: HalluWorld-Terminal 记忆/因果探针 (hf-train-lora-adapter): 示例展示终端轨迹如何区分语法修复、API 修复、陈旧元数据, 以及关于训练的无支撑主张。

组成部分	细节				
任务： hf-train-lora-adapter	运行时终端证据（步骤 0008）：				
	命令	事件	train_lora.py 状态	输出产物状态	
	0002	echo script with literal \n	size 1094, alpha=16	none	
	0003	pip install peft==0.15.0	unchanged	none	
	0004	python /app/train_lora.py	SyntaxError	none	
	序列化器：终端 轨迹 + 文件快照	0005	sed converts literal \n	size 1060	none
		0006	python /app/train_lora.py	TypeError: unexpected alpha	none
0008		remove alpha and rerun	size 1051, no alpha in config	adapter + results JSON	
触发命令：	python /app/train_lora.py				

续于下一页

组成部分	细节
最终源码信号：	LoraConfig(...) 不再包含 alpha，但 results['lora_config'] 仍记录 {'r': 8, 'alpha': 16, 'epochs': 3}。该脚本只加载 train/val JSON 来统计样本数量，随后在没有优化器、反向传播或训练循环的情况下保存 adapter。
模式：运行时探针	范围：through_trigger
探针（共 5 个）	探针 1（感知）：“比较可执行的 LoraConfig(...) 调用与后续元数据。适用哪一类不匹配？” → mismatch=metadata_extra_alpha 探针 2（记忆）：“在命令 8 开始之前，/app/train_lora.py 相对于原始文件发生了怎样的变化？” → delta=newline_and_alpha_fix 探针 3（因果）：“如果在命令 5 之后代码把 alpha=16 替换为 lora_alpha=16，下一次运行最可能会怎样？” → outcome=would_succeed 探针 4（不确定性）：“最终 adapter 权重是否包含来自 /app/data/train.json 的基于梯度的训练更新？” → status=contradicted 探针 5（跨类别）：“哪个已创建的输出已知会反映数据集内容，而不仅仅反映模型/配置默认值？” → depends_on_dataset=results_only
评估说明	该示例针对那些将成功创建产物与真实训练混淆，或将陈旧元数据与可执行配置混同的幻觉。恢复相关产物后，可以从 runs/probe_eval 结果 JSON 中追加逐探针模型回答。

B HalluWorld-Chess 探针类型

表 11: 所有 HalluWorld-Chess 探针。Cat. = 探针类别（P = 感知，C = 因果，M = 记忆）。Board = 是否显示 ASCII 棋盘；History = 是否提供走法序列。所有探针按 0/1 计分；每类 50 个 episode。

探针	Cat.	Board	History	核心挑战
chess_can_capture	P	✓	–	合法吃子检测；负例偏向被牵制棋子的伪合法着法
chess_defended	P	✓	–	仅在受攻击格上的防守方检测；“yes” 答案是关键承重项
chess_hanging	P	✓	–	被攻击且无人防守的检测；排除国王
chess_hypothetical_in_check	C	✓	–	应用一个指定走法；在后继状态上评估是否被将军
chess_after_move_undefended_count	C	✓	–	在 1-2 个假设走法后计数失去全部防守的棋子
chess_hidden_side_capture_stats	M	–	✓	在 25-88 步走法中维护连续吃子计数；不显示棋盘
chess_san_legal_move	M	–	✓	在 40+ 手前缀后生成一个合法着法；终局位置保证符合条件的走法很少

C 全部 HalluWorld-Grid 关卡列表

组成部分	细节
世界：国际象棋局面	棋盘视图（不显示 FEN）： 8 . n . . . r k . 7 . q 6 . . . p P . p . 5 . p p . . Q . p 4 3 B . b K 2 P . . . P P . P 1 R R . . a b c d e f g h
序列化器：棋盘网格	
行棋方： White	图例：标准国际象棋坐标；“.” 表示空格，小写表示黑方棋子，大写表示白方棋子。
探针（共 5 个）	P / 吃子：“白方下一步能合法吃掉 b5 上的黑兵吗？” → 标准答案： no P / 防守：“c5 上的黑兵受到对手攻击。它是否也受到本方另一枚棋子的防守？” → 标准答案： yes P / 悬子：“d6 上的黑兵是否是悬子？” → 标准答案： no C / 假设性将军：“如果白方走 f5f6，行棋方会被将军吗？” → 标准答案： no C / 展开后计数：“如果白方走 a1c1 且黑方走 b7a6，有多少枚白方棋子失去全部友方防守？” → 标准答案： 1
定性要点	这些探针将基于棋盘的幻觉与长上下文记忆隔离开来。P 类探针要求对可见棋子图进行静态关系读取，而 C 类探针要求应用一到两步合法走法并重新计算派生属性。

表 8: HalluWorld-Chess 感知/因果探针：用于静态棋盘读取探针和短视野因果展开的示例棋盘。标准答案直接由国际象棋引擎计算。

表 13: 全部 33 个 HalluWorld-Grid 关卡。探针：Pr = 存在性, Ct = 计数, St = 状态/属性, Lo = 位置, Ca = 因果, Un = 不确定性。Ser.: Sym = 符号, Grd = 网格, Mem = 记忆, Mix = 混合。● = 包含在 HalluWorld-Hard 子集中。

ID	名称	探针	Ser.	核心挑战	困难
感知（P）					

续于下一页

(续)

ID	名称	探针	Ser.	核心挑战	困难
P1	Dense Array	Pr, Ct, St	Sym, Grd	密集规则网格, 带有刻意设置的违规项 (颜色交换、缺失、状态不匹配); 测试模式补全失败	Grd •
P2	Corridor Gauntlet	Pr, Ct, Lo	Sym, Grd	狭窄走廊; 物体处在不同深度和横向偏移; 测试空间排序精度	Grd •
P3	Rotation Challenge	Lo	Sym, Grd	固定场景, 随机智能体生成朝向; 测试自我中心与客观中心参照系转换	—
P4a	Harder Array	Pr, Ct, St	Sym, Grd	更密集、更大的 P1 变体, 包含更多物体类型; 测试密集条件下的复合计数	Grd •
P4b	Delta Perception	Pr, Ct, St	Sym, Grd	两次观测之间发生智能体移动; 测试 FOV 偏移下的出现与消失检测	—
P5	Object Permanence	Pr, Ct, St	Sym, Grd	物体在两次观测之间移出 FOV; 测试视野外状态跟踪	—
记忆 (M)					
M1 (N=3)	River Field (early)	Pr, Ct, St	Mem	河流以固定速率向东搬运物体; 陈旧告示板显示 t=0 状态; 已过去 3 步	—
M1 (N=6)	River Field (mid)	Pr, Ct, St	Mem	与 M1 相同, 但在 6 步时; 物体位置最为模糊	•
M1 (N=9)	River Field (late)	Pr, Ct, St	Mem	与 M1 相同, 但在 9 步时; 一个物体已干燥, 用于测试时间衰减跟踪	•
M2	Witness Stand	Pr, Ct, St	Sym, Grd	五个连续房间观测; 测试跨观测来源归因和近因干扰	—
M3	Incident Report	Pr, Ct, St	Sym, Grd	两个房间快照, 包含 3 个静默变化 (颜色交换、状态变化、移除); 测试变化枚举	—
M4	Unreliable Narrator	Pr, Ct, St	Mem	路标在直接观测旁对房间作出 3 条虚假声明; 测试标牌与观测之间的冲突	—
因果 (C)					
C1a	Persistent Chain	Pr, Ca	Mem	三步链条; 所有效果都是持久的 (一次性触发); 告示板说明规则; 测试连续性偏置错误	•
C1a (nb)	Persistent Chain (no board)	Pr, Ca	Mem	没有告示板的 C1a; 模型必须仅从机制推断持久性	•

续于下一页

(续)

ID	名称	探针	Ser.	核心挑战	困难
C1b	Continuous Chain	Pr, Ca	Mem	布局与 C1a 相同；所有效果都是连续的（钥匙移除后门重新上锁）；测试持久性偏置错误	•
C1b (nb)	Continuous Chain (no board)	Pr, Ca	Mem	没有告示板的 C1b；模型必须仅从机制推断连续性	•
C2	Fire Crossing	Pr, St, Ca	Mem	湿球熄灭火焰屏障；干燥诱饵球不能；测试时间压力下的湿润条件状态跟踪	—
C3	Flood Room	Pr, St, Ca	Mem	Floodtiles 每步推进一行；智能体必须在路径被切断前到达高处目标；测试步级精确前向模拟	—
C4	Forking Paths	Pr, Ca	Mem	到达目标的三条路径：铁钥匙（有效）、点燃的火把作用于木门（有效）、过水（干扰项，没有船）；测试解空间探索	—
C5a	Adversarial Board	Pr, Ca	Mem	C1a 布局；告示板撒谎（声称门是连续机制）；注释是正确的；让对抗性证词与结构性推断相互对抗	•
C6	Flood-Fire cape	Es-Pr, St, Ca	Mem	洪水在第 4 步熄灭火焰，产生定时动作窗口；撒谎的告示板给出错误时序；测试带对抗性证词的跨机制组合	•
不确定性 (U)					
U1	Fog of War	Pr, Un	Sym	枢纽连接四个从未观测过的密封房间，房间由告示板描述；测试认识论克制与自信虚构之间的差异	—
U2 (high)	Oracle Problem (80%)	Un	Mix	两个路标声称房间内容；告示板说明路标准确率为 80%；测试对声明可靠性的置信度缩放	—
U2 (mid)	Oracle Problem (50%)	Un	Mix	相同设置，但声明准确率为 50%	—
U2 (low)	Oracle Problem (20%)	Un	Mix	相同设置，但声明准确率为 20%	—
U4	The Amnesiac	St, Ca, Un	Sym	房间中有先前活动的证据，但没有存储观测；测试可推导与真正无法回答的因果归因之间的差别	—

续于下一页

(续)

ID	名称	探针	Ser.	核心挑战	困难
跨类别复合 (X)					
X1	Facility Tour	Pr, Ct, Sym St		3 区设施参观; 跨区域侵入的基线多房间测试	—
X2	Facility Tour+	Pr, Ct, Sym, St Grd		5 区参观; 撒谎路标声称关于先前区域的错误细节	—
X3	Facility Tour++	Pr, Ct, Sym, St Grd		7 区参观; 更早的区域在近因偏置下退化更严重	—
X4	Compound Witness	Pr, Ct, Sym St		5 区参观, 中途嵌入 Witness Stand 子序列	—
X5	Cascading Testimony	Pr, Ct, Sym, St Grd		7 区参观; 后续路标与智能体自己先前的直接观测相矛盾	Grd •
X6	Return Visit	Pr, Ct, Sym, St Grd		5 区参观 + 重访; Zone A 在返回时被修改; 测试回溯后的世界模型更新	—
X7	Dragon Keep	Pr, Ct, Sym, St, Ca Grd		8 区 RPG 参观; 不可靠 NPC、绕路、回溯, 目标要求整合所有区域的信息	—

D HalluWorld-Grid 环境机制

除标准 MiniGrid 物体外, 我们实现了以下机制, 以支持对记忆幻觉和因果幻觉的探测。

Tiles. `RiverTile(direction, speed)` 会按固定方向、固定速率在每一步搬运物体。`FireTile` 不可通行, 并会被任何带有 `wet_turns_remaining > 0` 的物体熄灭。`FloodTile(rise_step)` 会在指定步数变为不可通行。`PressurePlate(effect)` 支持两种效果类型: *continuous* (压板被加重时门保持打开) 和 *trigger* (一次性、永久)。`DarkZone` 图块可通行, 但会阻挡智能体视野。

Object states. 物体携带 `condition` 属性 (`dry | wet | soaked`), 其中 `wet_turns_remaining` 在离开河流后每步递减, 并在重新进入河流时重置。该状态是 C2 和 C6 的主要机制。

Adversarial testimony objects. `NoticeBoardObject(text)` 渲染陈旧的书面信息, 并且这些信息在序列化器中始终可见。它在 M1 中准确, 在 M4 中不准确, 并且在 C5a 和 C6 中主动错误, 因此成为跨层级对抗性证词的主要来源。`SignpostObject(text, accurate)` 支持带有声明准确率的受控虚假信息, 用于 U2。

组成部分	细节
探针族 序列化器	没有观测捷径的长视野走法跟踪 走法历史文本；模型必须从一串合法国际象棋走法中重建或跟踪隐藏棋盘状态。
M 探针：隐藏吃子统计	观测摘录： Moves played (UCI with SAN): e3c5 (Bxc5), g3f2 (Bxf2), f5h5 (Qxh5), g6h5 (gxh5), f1f2 (Rxf2), d6c5 (dxc5), f2f8 (Rxf8+), ..., d4f3 (Nf3) 问题：“在上述序列中，有多少枚黑方棋子因吃子而被移除？” → 标准答案： 6
X 探针：SAN 合法着法	观测摘录： Moves played: 1. b3 Nh6 2. e3 g6 3. a4 e5 4. Na3 Na6 5. Bxa6 bxa6 ...52. Kf2 Kh6 53. Ke3 Re8+ 54. Kd2 Re4 问题：“从该局面出发，以 UCI 格式准确回复一个行棋方的合法着法。” → 标准答案： {d2c1, d2c2, d2c3, d2d1, d2d3}
定性要点	记忆探针要求在一条较长的显式轨迹上计数事件。SAN 探针是复合型的：它要求从标准代数记谱法重建隐式棋盘，在许多回合中应用国际象棋转移规则，然后生成一个合法延续。这解释了为什么在简单棋盘读取趋于饱和后，国际象棋基准仍然具有区分力：复合探针测试模型是否保持忠实的内部世界状态。

表 12: HalluWorld-Chess 记忆与复合探针：长视野国际象棋探针示例。M 探针测试走法序列上的事件跟踪；X 探针结合记忆、因果转移规则，以及仅从 SAN 输入生成有效动作。

E HalluWorld-Terminal：更多细节

HalluWorld-Terminal 由 100 多个 Terminal-Bench [46] 任务集合构建而成。我们有意选择一个较旧且较小的智能体 GPT-4o-mini 来尝试这些任务并生成轨迹。这个选择反映了这样一个假设：较弱的智能体往往不够有条理、不够彻底，会产生更长、更嘈杂且更容易失败的交互轨迹。这类轨迹创造了更丰富的情境，其中与幻觉相关的证据可能被隐藏、陈旧、部分矛盾，或分布在许多终端步骤之中，从而让我们测试后续更强的模型是否仍能从可用证据中恢复正确答案。

为构建该基准，我们开发了一个运行时探针注入器，用于在任务执行期间观察智能体的终端会话。注入器记录每条命令、工作目录、终端输出、命令前后的窗格状态，以及相关文件快照。基于这些观测，它构造证据上下文，并生成目标明确的探针问题，其答案扎根于记录下来的轨迹。关键的是，探针由运行时轨迹生成，而不会展示给原始解题智能体，因此不会改变智能体行为或污染轨迹。

由此得到的探针旨在测试智能体式场景中的多种幻觉失败模式，包括陈旧记忆、感知错误、因果过度归因、不确定性过度声称，以及需要连接命令、文件、输出和任务状态的跨类别推理失败。每个探针都有结构化答案模式和对应的黄金答案，使评估在大体上可自动化，同时保持问题狭窄且可审计。抽取之后，探针会按可回答性和难度进行过滤与整理，得到一个由高质量示例构成的紧凑基

表 14: HalluWorld-Terminal 上的思维深度消融（探针准确率，越高越好）。探针类别：Ca = 因果，X = 跨类别，M = 记忆，P = 感知，U = 不确定性。*Medium* 行是主排行榜条目。

模型	预算	N	总体	Ca	X	M	P	U
Claude Sonnet 4.6	none	529	79.2%	89.6%	84.9%	88.0%	74.3%	58.7%
	low	529	80.3%	87.7%	82.1%	88.9%	78.1%	64.4%
	<i>medium</i>	529	<i>82.2%</i>	<i>90.6%</i>	<i>85.8%</i>	<i>88.9%</i>	<i>81.9%</i>	<i>63.5%</i>
	high	529	83.9%	90.6%	86.8%	90.7%	89.5%	61.5%
	max	529	86.2%	95.3%	88.7%	91.7%	90.5%	64.4%
GPT-5.5	none	529	86.4%	93.4%	91.5%	84.3%	81.9%	80.8%
	low	529	94.9%	99.1%	99.1%	99.1%	99.0%	77.9%
	<i>medium</i>	529	<i>94.1%</i>	<i>99.1%</i>	<i>98.1%</i>	<i>97.2%</i>	<i>99.0%</i>	<i>76.9%</i>
	high	527†	96.6%	100.0%	99.1%	99.1%	100.0%	84.3%
	xhigh	527†	95.3%	99.1%	99.1%	99.1%	100.0%	78.6%


准子集。

F HalluWorld-Terminal 思维深度消融


表 14 报告了 Sonnet 4.6 和 GPT-5.5 在不同思维/推理深度下按类别划分的探针准确率，而图 2 可视化了按轨迹深度划分的幻觉率。*medium* 行与主排行榜条目完全一致。† 由于在高推理力度下 `sql-injection-attack` 探针触发内容政策拒绝，GPT-5.5 high/xhigh 运行中永久排除了两个探针（ $N=527$ ）。

G HalluWorld-Grid 推理消融

从表 15 来看，更多推理似乎并不一定与更低幻觉相关。有趣的是，它主要似乎会提高 Causal 类别的幻觉，而对其他探针类别几乎没有改善，这与 §5.3 中的分析一致。



(a) 跨所有模型汇总的幻觉率与轨迹深度关系



(b) 各模型的幻觉率与轨迹深度关系

图 2: HalluWorld-Terminal 幻觉率与轨迹深度关系。 轨迹深度定义为触发命令的索引，即探针注入前执行的 shell 命令数量。幻觉率使用对数深度空间中的高斯核进行平滑。上下文使用中部截断截到 60k 字符（保留轨迹开头和结尾）。不确定性探针（红色）表现出最强的深度敏感性，在较大深度处幻觉率上升，而多数其他探针类型保持稳定或仅轻微上升。

表 15: HalluWorld-Grid 中推理预算对各类别幻觉率的影响。类别: P = 感知, M = 记忆, C = 因果, U = 不确定性, X = 跨类别。对 GPT-5.5 而言, “None” 表示禁用推理; 默认评估使用 medium 预算。对 Claude Sonnet 4.6 而言, 非思考模型作为 None 基线。

模型	预算	总体	P	M	C	U	X
GPT-5.5	None	4.8%	0.3%	5.2%	24.5%	0.8%	2.5%
	Low	5.0%	0.2%	5.5%	25.9%	0.1%	2.6%
	Medium	5.0%	0.4%	5.9%	25.3%	0.1%	2.7%
	High	4.8%	0.3%	5.5%	24.7%	0.3%	2.5%
Claude Sonnet 4.6	None	7.2%	2.8%	5.0%	19.7%	1.1%	7.6%
	Low	8.1%	2.8%	7.2%	25.0%	1.3%	7.3%
	Medium	7.7%	1.1%	6.2%	24.0%	1.1%	7.5%
	High	8.0%	1.0%	6.4%	25.9%	1.3%	7.7%
	Max	8.1%	2.5%	5.9%	27.1%	1.2%	7.5%

H HalluWorld-Grid 困难子集结果

表 16: HalluWorld-Grid 困难子集结果。这里列出 12 个最困难的（关卡，序列化器）组合，其中 ≥ 5 个模型达到 $\geq 20\%$ 的幻觉率（见 §C）。模型按困难子集平均幻觉率升序排列。单元格颜色反映相对幻觉率（绿色 = 低，红色 = 高）。**粗体** = 列最小值。**列：** C1a nb, C1a, C1b, C1b nb, C5a, C6, M1₆, M1₉, P1, P2, P4, X5。

模型	平均	C1a nb	C1a	C1b	C1b nb	C5a	C6	M1 ₆	M1 ₉	P1	P2	P4	X5
o3	15.5%	18.8	13.7	26.2	26.2	31.2	30.8	4.3	14.3	0.0	5.4	0.0	15.4
o3-mini	17.0%	37.5	32.5	21.5	21.3	23.8	28.3	1.4	15.7	2.5	0.0	0.0	19.3
GPT-5.5 (T)	17.1%	36.3	37.5	17.5	17.5	25.0	25.0	10.0	22.9	0.0	5.7	0.0	8.0
Claude Opus 4.6 (T)	17.8%	27.8	46.1	15.6	8.9	37.5	39.6	0.0	7.0	5.0	2.0n	11.1	12.8
Claude Sonnet 4.6 (T)	17.9%	31.2	31.2	8.8	7.5	50.0	38.5	17.7	1.5	7.5	2.0	0.0	18.9
Claude Opus 4.6	19.5%	28.4	42.0	20.0	11.3	35.0	46.7	0.0	5.0	10.0	2.4	20.0	12.8
Claude Sonnet 4.6	20.0%	25.0	35.7	11.4	7.1	45.0	56.1	20.8	0.0	12.5	5.3	0.0	21.4
o4-mini	21.3%	51.2	45.0	26.2	26.2	31.2	30.8	1.4	11.4	7.5	8.3	0.0	15.7
GPT-4o	31.1%	56.2	50.0	12.5	8.8	37.5	42.5	18.6	28.6	22.5	53.3	12.2	30.3
GLM-5	33.5%	57.5	53.8	7.5	10.0	37.5	40.0	21.4	15.7	27.5	41.3	54.4	35.4
GPT-5.4-mini	34.1%	20.0	12.5	16.2	18.8	36.3	40.0	31.4	14.3	35.0	92.3	47.8	44.3
DeepSeek-V3-0324	34.6%	61.3	61.3	11.3	11.3	48.8	32.5	29.4	10.0	35.0	45.1	44.4	24.9
Qwen-3-30B	37.8%	25.0	37.5	37.5	50.0	37.5	41.7	28.6	14.3	20.0	69.5	55.6	36.9
GPT-4o-mini	39.7%	28.7	8.8	42.5	40.0	50.0	31.7	28.6	15.7	30.0	83.3	66.7	50.9
Kimi K2.6	53.9%	80.8	68.2	95.0	100.0	60.0	75.0	36.7	33.3	25.0	38.2	11.1	23.1

I HalluWorld-Grid 的导航中实验

在本节中，我们在 **导航中** (InNav) 设置下评估模型；在该设置中，模型一边主动在环境中导航，一边接受关于世界状态的探查。从技术上说，InNav 模式使用标准 messages 格式下带有对话式逐轮历史的 chat completions：每一个导航步骤（动作选择、接收观察）都会追加到对话历史中，而探查问题则作为这个持续对话中的后续消息提出。这模拟了智能体在交互式设置中的部署方式：与世界相关的查询会在任务执行期间出现，例如用户在回路中与模型对话以理解当前发生的情况。

为了在不把导航能力与推理能力混淆的情况下实现受控比较，我们使用一个单一的高性能导航模型（GPT-5.4-mini, reasoning_effort=high）为所有被探查模型生成轨迹。

I.1 认识论锚定与认知负荷：导航会帮助还是伤害幻觉？

导航引入了两个相互竞争的效应：**认识论锚定**（动作-感知反馈可能更好地锚定智能体的内部世界模型）与 **认知负荷**（导航需求可能削弱状态追踪）。为隔离导航的净影响，我们使用相同轨迹比较两种条件：**导航中** (InNav)，即模型在导航时回答探查；以及 **受控静态** (CtrlStatic)，即模型在没有导航上下文的情况下观察相同状态。这种配对设计控制了轨迹信息，从而隔离导航究竟帮助还是伤害幻觉率。结果见表 17。

表 17: HalluWorld-Grid 中导航对幻觉率的影响（总体以及按类别分解）。 Navigation Effect (NavEff) = InNav – CtrlStatic 幻觉%。左侧：全部 31 个世界上的总体结果。右侧：类别特定的 NavEff 结果 (P=Perception, C=Causal, M=Memory, U=Uncertainty, X=X-level)。模型按总体 NavEff 排序。** 表示具有统计显著性 (95% CI 不包含零)。单元格颜色反映相对幻觉率或效应（绿色 = 低/改善，红色 = 高/退化）；**粗体**标记列最小值。

模型	InNav	CtrlSt	NavEff	模型	P	C	M	U	X
gpt-5.5	27.4	40.7	-13.2**	gpt-5.5	+2.0	-15.8	-9.6	-16.9	-13.3
GLM-5	37.0	41.5	-4.4**	GLM-5	-0.3	-4.3	+2.0	-4.9	-12.6
o3-mini	36.1	40.5	-4.4**	o3-mini	-0.6	-6.0	-3.3	-9.3	-3.1
o4-mini	37.6	41.3	-3.8**	o4-mini	-2.1	-2.9	-3.6	-6.6	-4.3
o3	37.8	41.0	-3.2**	o3	-0.3	-1.2	-3.2	-7.7	-4.3
DeepSeek-V3	43.0	45.4	-2.4	DeepSeek-V3	+0.7	-8.7	+10.2	-8.1	-0.1
gpt-4o	38.9	40.2	-1.3	gpt-4o	-1.8	-5.8	+0.9	-2.1	+3.3
gpt-4o-mini	39.5	39.8	-0.3	gpt-4o-mini	+3.9	-5.1	+6.1	-4.9	+0.9
Opus 4.6	36.8	35.7	+1.1	Opus 4.6	+5.6	+1.1	+1.9	-6.3	+2.2
Sonnet 4.6	37.3	36.1	+1.2	Sonnet 4.6	-0.8	+1.7	+4.1	+0.6	+1.1
Kimi-K2.6	37.0	35.8	+1.3	Kimi-K2.6	+3.1	-0.9	+2.7	-2.6	+4.3
gpt-5.4-mini	40.1	37.2	+2.9	gpt-5.4-mini	+5.5	-0.5	+5.3	+3.2	+2.7

总体上，认识论锚定占主导（左表）：12 个模型中有 5 个模型因导航而表现出具有统计显著性的幻觉下降（95% CI 不包含零），同时没有任何模型表现出显著上升。最强的收益出现在偏推理的

模型中 (gpt-5.5: -13.2%, GLM-5: -4.4%, o3-mini: -4.4%), 说明推理模型会从世界中的多轮动作-反馈循环中稳定获益。

类别特定的模式揭示了更细致的效应 (右表): **Causal** 世界显示出普遍的锚定收益 (几乎所有模型都是负值或接近零), 其中 gpt-5.5 达到 -15.8%。 **Uncertainty** 世界具有最大的变化范围: gpt-5.5 达到总体最强收益 (-16.9%), 多数推理模型也显著受益 (-4.9 到 -9.3%), 但较弱模型呈现混合模式 (gpt-5.4-mini: +3.2%, Sonnet 4.6: +0.6%)。 **Perception** 和 **Memory** 世界表现出依赖模型的效应: 前沿模型呈现多样化模式 (gpt-5.5 在 Perception 上为 +2.0%, 但在 Memory 上为 -9.6%), 而较小模型在 Memory 任务上承受认知负荷 (gpt-4o-mini: +6.1%, gpt-5.4-mini: +5.3%)。 **X-level** 多区域世界显示出最大的模型方差: GLM-5 达到 -12.6% (强锚定), 而 Kimi-K2.6 为 +4.3% (认知负荷占主导)。这些模式表明, 导航的净影响同时取决于任务复杂性和模型推理能力。详细的类别分析见 §I.5。总体而言, InNav 提供了一个丰富的设置, 用来检验模型能否同时处理目标寻求 (导航) 和内部世界模型更新, 以及模型是否能够用推理使二者产生协同。

I.2 轨迹深度分析: 内在难度 vs. 导航影响

为了理解幻觉是否会随轨迹深度增加, 以及这种模式在导航中模式和受控静态模式之间是否不同, 我们将幻觉率作为**相对轨迹位置**的函数进行分析。每条轨迹被划分为五个五分位: 1/5 (前 20% 步)、2/5 (20-40%)、3/5 (40-60%)、4/5 (60-80%) 和 5/5 (最后 80-100%)。我们分别为两种模式计算线性斜率 (每个五分位的幻觉百分比点增幅)。


关键发现: 所有 13 个模型在导航中和受控静态两种模式下都表现出正斜率 (图 3), 说明无论模型是在导航还是被动观察, 随着轨迹推进, 状态都会变得内在更难建模。受控静态模式的中位斜率为每个五分位 +5.1%, 而导航中模式为 +6.6%, 这对应于轨迹终点处的幻觉率相较起点大约高 20-26%。

然而, 差分斜率揭示了模型特定的导航策略 (图 3):

- **6 个模型表现出认知负荷累积 (红色条):** InNav 斜率比 CtrlStatic 高 +1.4% 到 +5.9%/五分位 (例如, o3-mini: +11.2% vs. +5.3%, Opus 4.6: +9.3% vs. +3.6%), 说明导航会放大深度效应。
- **7 个模型表现出锚定缓解 (绿色条):** InNav 斜率比 CtrlStatic 低 0.7% 到 4.4%/五分位 (例如, GPT-5.4-mini: +0.7% vs. +5.1%, GLM-5: +1.7% vs. +4.8%), 表明导航通过认识论锚定缓解深度效应。

i) **对部署的影响:** 在长时程任务中, 模型聚成两类策略。锚定缓解型模型 (绿色条) 会主动利用导航反馈来抵消复杂性累积, 因此更适合扩展的自主运行。认知负荷累积型模型 (红色条) 尽管静态性能很强, 但会随时间产生复合错误, 在具身设置中需要更频繁的人类干预或检查点。

ii) **对评估的影响:** 静态基准会系统性低估具备导航能力的模型中与深度相关的失败。普遍存在的正斜率 (每个五分位 +5.1 到 +6.6%) 意味着幻觉率从轨迹开头到结尾几乎翻倍, 但这一效应在导航下以不同方式显现: 一些模型通过认识论锚定适应, 另一些模型则因认知负荷进一步退化。未来的具身 AI 评估必须跨轨迹深度测量性能, 才能捕捉这些动态。



(a) HalluWorld-Grid 的斜率差异 (InNav – CtrlStatic)。红色：认知负荷放大深度效应。绿色：锚定缓解深度效应。标签显示：Diff (InNav/CtrlStatic)，单位为%/五分位。幅度表示导航对深度累积影响的强度。

(b) HalluWorld-Grid 的深度推进情况 (为清晰起见，仅显示部分模型)。InNav 幻觉随深度增加，展示了当模型探索得更深时，世界理解会如何变得更困难。

图 3: 导航对轨迹深度效应的影响。(a) 全部 13 个模型在 InNav 与 CtrlStatic 模式之间都显示出差分斜率，揭示了认识论锚定与认知负荷之间依模型而异的平衡。正差异（红色）表示认知负荷占主导；负差异（绿色）表示锚定占主导。前沿推理模型反常地表现出更多负荷累积，而效率优化模型表现出锚定缓解。(b) 代表性模型展示了深度推进模式：所有模型在轨迹五分位上的幻觉率都会增加，说明随着轨迹推进，状态在内在上变得更难建模。

I.3 按世界类别划分的轨迹深度分析

我们观察到，深度对 InNav 幻觉的影响会随类别显著变化（图 4；详细分析推迟到 §I.6）。Perception (-1.0%/五分位) 和 Causal 世界 (-1.8%/五分位) 的幻觉会随轨迹深度下降，表明认识论锚定占主导。Memory 和 Uncertainty 世界显示出最小的深度效应 (+0.2%/五分位)，锚定与认知负荷相互平衡。X-level 多区域世界表现出巨大的累积 (+6.5%/五分位)，其中认知负荷占主导：穿过许多区域的长轨迹会压垮 LM 的工作记忆。

I.4 导航中序列化敏感性分析

为了检查表现更好的序列化方式是否会在 InNav 情况下持续存在，我们将表 13 中列出的规范序列化器与替代序列化器进行比较。两个类别显示出显著反转：**Perception** (grid 为规范) 平均偏好 symbolic 14.3% (6 个世界中有 5 个)，而 **Uncertainty** (memory 为规范) 平均偏好 grid 12.8% (5 个世界中有 4 个)，这表明一些序列化器即使在孤立回答探查时并非最优，仍然能支持更好的认识论锚定。完整细节见 §I.7。

I.5 按世界类别划分的导航效应

表 18 按世界类别分解了导航效应。导航影响随类别显著变化：Uncertainty 世界显示出最强的总体收益（中位数 -6.0% ），表明导航帮助模型解决部分可观测性。X-Levels 显示出很大的模型依赖效应，其中 GLM-5 (-12.6%) 和 GPT-5.5 (-11.2%) 显著受益，而较弱模型显示出轻微成本。Memory 世界表现出混合效应（DeepSeek-V3: $+10.2\%$ vs GPT-5.5: -9.6% ），说明记忆需求和导航之间存在复杂的、依赖架构的交互。Perception 世界显示出最小的导航效应（中位数为 -0.3% ），表明视觉-空间推理基本独立于导航需求运行。

表 18: HalluWorld-Grid 按世界类别划分的导航效应。数值表示导航中幻觉率减去受控静态幻觉率。负值表示导航有帮助（降低幻觉）。类别：P = Perception, C = Causal, M = Memory, U = Uncertainty, X = Cross-category。

模型	总体	P	C	M	U	X
GPT-5.5	-13.2	+2.0	-15.8	-9.6	-16.9	-13.3
GLM-5	-4.4	-0.3	-4.3	+2.0	-4.9	-12.6
o3-mini	-4.4	-0.6	-6.0	-3.3	-9.3	-3.1
o4-mini	-3.8	-2.1	-2.9	-3.6	-6.6	-4.3
o3	-3.2	-0.3	-1.2	-3.2	-7.7	-4.3
DeepSeek-V3-0324	-2.4	+0.7	-8.7	+10.2	-8.1	-0.1
GPT-4o	-1.3	-1.8	-5.8	+0.9	-2.1	+3.3
GPT-4o-mini	-0.3	+3.9	-5.1	+6.1	-4.9	+0.9
Claude Opus 4.6	+1.1	+5.6	+1.1	+1.9	-6.3	+2.2
Claude Sonnet 4.6	+1.2	-0.8	+1.7	+4.1	+0.6	+1.1
Kimi K2.6	+1.3	+3.1	-0.9	+2.7	-2.6	+4.3
GPT-5.4-mini	+2.9	+5.5	-0.5	+5.3	+3.2	+2.7

I.6 更多细节：按世界类别划分的轨迹深度分析

为了考察认识论锚定与认知负荷之间的平衡是否会跨推理领域变化，我们按世界类别分解轨迹深度分析。图 4 分别呈现 Perception、Causal、Memory、Uncertainty 和 X-level 世界中 InNav 幻觉率随轨迹深度（从 1/5 到 5/5 的五分位）变化的情况。每个类别都展现出不同的深度动态，说明导航的净影响关键取决于推理任务的性质。

I.6.1 Perception 世界（每个五分位 -1.0% ）

以 Perception 为重点的世界（P1-P5；跨 6 个世界的 5,066 个探查）测试空间推理、对象追踪和视觉记忆。与总体趋势相反，这些世界随着轨迹加深表现出**幻觉下降**（平均斜率：每个五分位 -1.0% ）。这种反转模式表明**认识论锚定占主导**：额外观察通过提供关于空间关系和对象属性的消歧证据，帮助模型解决感知歧义，从而随时间降低不确定性。该效应在 P4_harder_array 和 P1_dense_array

中尤其明显，在这些世界中，系统性探索帮助模型逐步建立准确的空间表征。来自导航的认知负荷被多个视角带来的锚定收益所超过。

I.6.2 Causal 世界（每个五分位 -1.8%）

Causal 推理世界（C1a-C6, C1b_continuous_chain；跨 8 个世界的 8,964 个探查）测试对因果关系、状态转移和行动后果的理解。这些世界表现出最强的**认识论锚定效应**（平均斜率：每个五分位 -1.8%），模型随着轨迹推进显示出一致改善。这一模式表明，导航为因果推断提供了关键的消歧证据：观察行动结果（例如，“推动这块巨石会打开道路吗？”，“拉下杠杆后，火焰屏障可以通过吗？”）允许模型随时间细化其因果模型。该效应在 C2_fire_crossing 和 C3_flood_room 中最明显，在这些世界中必须观察状态变化才能正确回答探查。来自动作-感知反馈回路的锚定显著超过认知负荷。

I.6.3 Memory 世界（每个五分位 +0.2%）

以 Memory 为重点的世界（M1-M4；跨 4 个世界的 6,900 个探查）测试对过去观察的保持、事件排序和证词整合。这些世界显示出很小的深度效应（平均斜率：每个五分位 +0.2%），在轨迹位置上几乎持平。这表明**认识论锚定与认知负荷大致平衡**：随着导航推进，模型必须追踪更多事件（增加认知负荷），但额外观察也提供了补偿性的上下文（认识论锚定）。增量成本很小。M2_witness_stand 和 M3_incident_report 显示出最弱的效应，可能是因为结构化证词提供了显式记忆线索，既降低工作记忆负荷，又同时对回答形成锚定。

I.6.4 Uncertainty 世界（每个五分位 +0.2%）

以 Uncertainty 为重点的世界（U1, U2_oracle_*, U4；跨 5 个世界的 4,898 个探查）测试部分可观测条件下的推理、概率推断和信息寻求行为。与 Memory 世界类似，它们显示出很小的深度效应（每个五分位 +0.2%）。平坦趋势表明模型能很好地处理不断增长的轨迹长度：战争迷雾限制（U1）和 oracle 限制（U2）施加的是恒定而非累积的认知负荷，同时额外观察为概率推理提供锚定。然而，U4_amnesiac 显示出略强的累积（+0.8%），说明记忆擦除会产生复合困难，压过锚定收益。

I.6.5 X-Level 多区域世界（每个五分位 +6.5%）

X-level 复合世界（X1-X7；跨 7 个世界的 6,860 个探查）包含穿过 3-8 个相连区域的多房间导航，并具有复杂的状态追踪需求。这些世界表现出巨大的**认知负荷累积**（平均斜率：每个五分位 +6.5%），超过总体平均值的 5 倍。穿过多个区域的长轨迹会压垮工作记忆，导致轨迹后期位置的幻觉急剧增加。在这些复杂的多区域环境中，**认知负荷主导认识论锚定**。该效应在 X3_facility_7zone（每个五分位 +8.2%）和 X7_dragon_keep（+7.8%）中最强，在这些世界中，穿越许多房间会产生复合记忆需求。X1_facility_3zone 显示出最弱的累积（+4.1%），确认了区域数量会驱动认知负荷。

I.6.6 总结与影响

这些类别特定的模式表明，深度效应反映了**认识论锚定与认知负荷之间的平衡**，而这种平衡会随类别变化。我们识别出三种不同状态：

1. **锚定主导状态** (Perception, Causal)：负斜率（每个五分位 -1.0% 到 -1.8%）表明额外观察提供的收益（对空间/因果关系的消歧）超过其成本（工作记忆负荷）。导航在这些领域会主动帮助状态追踪。
2. **平衡状态** (Memory, Uncertainty)：近零斜率（每个五分位 +0.2%）表明锚定收益和认知负荷成本大致相互抵消。模型在轨迹长度增加时不会出现显著性能退化，说明这些任务类型上的资源分配较为有效。
3. **负荷主导状态** (X-Levels)：大的正斜率（每个五分位 +6.5%）表明来自多区域导航的工作记忆成本压过了任何锚定收益。超线性增长（总体平均的 5 倍）说明这是复合干扰，而非线性扩展。

这种类别依赖性对智能体部署具有实际影响：模型应被部署在带导航的感知/因果任务中（因为导航有帮助），可以在记忆/不确定性任务中自由导航（中性影响），但应在多区域环境中最小化导航步骤（因为导航有害）。这些模式也提示了不同的底层机制：感知和因果推理受益于动作-感知反馈回路（锚定效应），而跨许多房间的空间导航会施加复合的工作记忆成本（认知负荷效应）。未来工作应考察这些模式是否反映了模型在不同任务类型间分配认知资源方式的根本差异，以及架构干预（例如外部记忆、空间记忆模块）能否缓解负荷主导状态。

I.7 更多细节：序列化敏感性分析

为验证我们的规范序列化选择，我们在 InNav 评估期间，对存在多种表示的世界系统比较了替代序列化方式。该分析回应了一个关键的方法论问题：规范序列化器在导航期间是否总是最优，或者某些世界类型是否会从替代表示中受益？

I.7.1 方法

覆盖范围：我们识别出 30 个使用多种序列化器测试过的世界：

- 18 个同时具有 grid 和 memory 的世界 (Causal、Memory、Uncertainty 类别)
- 11 个同时具有 grid 和 symbolic 的世界 (Perception 和 X-level 类别)
- 1 个同时具有 memory 和 symbolic 的世界 (M2_witness_stand)

模型：对每个世界-序列化器组合，我们只纳入在两个序列化器上都经过测试的模型，因此得到跨 30 个世界的 229 个模型级比较。

聚合：为了在每种序列化器具有不同导航轨迹的情况下保证公平比较，我们使用层次化聚合：




图 4: HalluWorld-Grid 中按世界类别划分的轨迹深度效应。深度动态在各领域之间差异很大，反映了认识论锚定与认知负荷之间的平衡。Perception 和 Causal 世界显示出反转效应（锚定占主导：导航有帮助），Memory 和 Uncertainty 世界显示出很小的深度效应（平衡），而 X-level 多区域设施显示出大的认知负荷累积（每个五分位 +6.5%：认知负荷占主导）。这表明导航的影响依赖类别。

1. **探针** → **轨迹**: 按 episode seed 对探针分组, 计算每条轨迹的幻觉率
2. **轨迹** → **世界**: 在轨迹之间取平均 (每个 episode 等权)
3. **世界** → **序列化器**: 比较世界级幻觉率

这避免了轨迹长度差异造成的偏差 (grid 导航可能比 memory 导航需要更多或更少步)。

表 19: HalluWorld-Grid 中按世界类别划分的序列化比较。规范序列化器仅赢得一半的 In-Navigation 比较, 在 Perception 和 Uncertainty 类别中出现系统性反转。“Best Non-Canonical” 显示优于规范选择的序列化器, 并给出以百分点计的平均差距。

类别	规范选择	世界数	InNav 胜出	Best Non-Canon.	平均差距
Perception	grid	6	1/6 (16.7%)	symbolic	14.3%
Uncertainty	memory	5	1/5 (20.0%)	grid	12.8%
Causal	memory	8	5/8 (62.5%)	grid	3.6%
Memory	mixed	4	2/4 (50.0%)	symbolic	8.2%
X-level	symbolic	7	6/7 (85.7%)	—	—
总体	—	30	15/30 (50.0%)	—	—

I.7.2 总体结果

表 19 按世界类别总结结果。规范序列化器只赢得 50.0% 的 InNav 比较 (30 个世界中的 15 个), 说明在导航期间不存在单一的普遍最优序列化。该模式随类别显著变化, 在 Perception 和 Uncertainty 世界中出现系统性反转。

这些反转尤其突出: 在 Perception 世界中, 虽然先前评估将 grid 选为规范选择, 但 symbolic 表示在各模型上平均将幻觉降低 14.3 个百分点, 并在 6 个世界中赢得 5 个。同样, Uncertainty 世界显示 grid 相对于规范 memory 选择有 12.8 个百分点的优势, 并在 5 个世界中赢得 4 个。这些差距很大, 与导航效应本身相当或超过它 (Section I.5), 说明在基于导航的推理中, 序列化选择的影响可以与评估模式一样重要。

I.7.3 按类别分析

Perception 世界: Symbolic 占优 Perception 世界 (P1–P5) 测试空间推理、对象追踪和视觉记忆。尽管 grid 是规范选择, symbolic 表示在导航期间仍在 6 个世界中的 5 个上取得更低幻觉率:

- **P3_rotation_challenge**: Symbolic 胜出 21.5%
- **P2_corridor_gauntlet**: Symbolic 胜出 17.2%
- **P5_object_permanence**: Symbolic 胜出 6.6%




图 5: HalluWorld-Grid 在 In-Navigation 模式下的序列化比较。每个条形表示胜出序列化器与落败序列化器之间的幻觉差异，并按差距排序。绿色表示规范序列化器胜出（15/30 个世界）；红色表示非规范序列化器胜出（15/30 个世界）。显著反转包括 Perception 世界（尽管 grid 是规范选择，symbolic 仍占优：P3_rotation_challenge 21.5%，P2_corridor_gauntlet 17.2%）和 Uncertainty 世界（尽管 memory 是规范选择，grid 仍占优：U2_oracle_mid 19.0%，U2_oracle_high 16.1%）。X-level 世界验证了规范 symbolic 选择（6/7 胜出），其中 X7_dragon_keep 显示最大差距（39.0%）。

- **P4_harder_array**: Symbolic 胜出 5.5%
- **P1_dense_array**: Symbolic 胜出 1.3%

只有 P4b_delta_perception 偏向规范 grid (6.2% 差距)。这种系统性偏好表明, 在导航期间, 基于语言的空间描述(“前方: 红球。左侧: 蓝盒子。右侧: 墙。”)比原始 ASCII 网格布局能为感知推理提供更有效的 grounding。该效应幅度相当大: P3_rotation_challenge 上 21.5% 的差距超过多数模型间差异, 说明对于某些任务, 序列化选择可能比模型选择更重要。

Uncertainty 世界: 尽管 Memory 具备全知性, Grid 仍占优 Uncertainty 世界(U1、U2_oracle_*, U4) 测试在部分可观测条件下的推理, 包括战争迷雾、oracle 访问限制和记忆擦除。尽管 memory 是规范选择, grid 表示仍在 5 个世界中的 4 个上取得更低幻觉率:

- **U2_oracle_mid**: Grid 胜出 19.0%
- **U2_oracle_high**: Grid 胜出 16.1%
- **U2_oracle_low**: Grid 胜出 10.7%
- **U1_fog_of_war**: Grid 胜出 5.5%

只有 U4_amnesiac 偏向 memory (3.7% 差距)。该模式表明, 在导航期间, 显式空间布局比文本式记忆描述更能帮助模型有效推理未观测区域。与 memory 的顺序事件描述相比, 网格可能提供更清晰的空间不变量(“我知道 (5,7) 处有什么, 即便我现在看不到它”)。

X-Level 世界: Symbolic 得到验证 X-level 多区域世界(X1-X7) 测试在 3-8 个互连房间之间的导航, 涉及目击者证词和复杂空间推理。Symbolic 表示(规范选择)在 7 个世界中的 6 个上取得更低幻觉率:

- **X7_dragon_keep**: Symbolic 胜出 39.0%
- **X1_facility_3zone**: Symbolic 胜出 15.8%
- **X2_facility_5zone**: Symbolic 胜出 14.7%
- **X5_facility_tour**: Symbolic 胜出 11.1%
- **X4_compound_witness**: Symbolic 胜出 9.1%
- **X3_facility_7zone**: Symbolic 胜出 7.0%

只有 X6_return_visit 偏向 grid (3.0% 差距)。强 symbolic 优势验证了我们的规范选择: 关于多房间环境的推理受益于更高层的语言抽象, 它们能比低层网格坐标更自然地描述房间连通性、区域属性和目击者位置。

Causal 和 Memory 世界：混合结果 Causal 世界（memory 为规范选择）显示 memory 取得 5/8 胜出，其中 grid 在动态状态变化世界（C2_fire_crossing、C3_flood_room）上具有竞争力。Memory 世界显示混合模式，symbolic 在基于证词的世界里胜出（M2_witness_stand: 19.4%, M3_incident_report: 21.4%），但 grid 在 M4_narrator 上胜出（11.9%）。

I.7.4 模型特定模式

不同模型表现出不同的序列化偏好（表 20）。GPT-4o 和 GPT-4o-mini 表现出最强的 symbolic 偏好（66.7% 胜率），而 Opus 4.6 在各序列化器之间的表现更均衡。O4-mini 展示了最均匀的分布（11 个 symbolic、9 个 grid、9 个 memory 胜出），表明其推理对序列化更不敏感。

表 20: HalluWorld-Grid 的模型特定序列化偏好（In-Navigation 模式）。跨所有世界-序列化器比较的胜出计数。GPT-4o 模型显示强 symbolic 偏好；Claude 模型更均衡。

模型	Symbolic 胜出	Grid 胜出	Memory 胜出
gpt-4o	14/21 (66.7%)	—	7/21 (33.3%)
gpt-4o-mini	14/21 (66.7%)	—	7/21 (33.3%)
o3-mini	14/27 (51.9%)	8/27 (29.6%)	5/27 (18.5%)
claude-sonnet-4-6	13/29 (44.8%)	7/29 (24.1%)	9/29 (31.0%)
claude-opus-4-6	12/29 (41.4%)	11/29 (37.9%)	6/29 (20.7%)
o3	13/27 (48.1%)	7/27 (25.9%)	7/27 (25.9%)
o4-mini	11/29 (37.9%)	9/29 (31.0%)	9/29 (31.0%)

I.7.5 含义

这些结果同时具有方法论和实践含义：

在方法论上，它们验证了我们的多序列化器评估方案：导航期间不存在单一的普遍最优序列化。Perception 和 Uncertainty 类别出现系统性反转，非规范选择显著优于规范选择（平均差距分别为 14.3% 和 12.8%）。

在实践上，它们提示了依任务而定的部署准则：智能体在导航期间进行局部感知推理时（P 世界）应使用 symbolic 序列化器，在不确定性下进行空间推理时（U 世界）应使用 grid 布局，在复杂多区域环境中（X 世界）应使用 symbolic。

在理论上，50% 的规范胜率表明，导航上下文具有不同的表示需求。Symbolic 的语言清晰性似乎有助于与动作整合的感知 grounding，而 grid 的空间显式性有助于不确定性推理。未来工作应研究这些模式是否反映了模型在主动导航期间处理空间表示与语言表示方式上的根本差异。

J HalluWorld-Grid Level Editor 与 Trajectory Recorder 工具

为了让社区能够无摩擦地扩展基准，我们提供两个互补工具：用于原型化和设计世界的 *Level Editor*，以及用于 ground truth 标注和对 HalluWorld-Grid 中轨迹与幻觉脆弱性进行定性分析的 *Trajectory Recorder*。


J.1 Level Editor：支持快速世界原型设计

为了可视化并修改现有关卡（世界）以及构造新关卡，我们提供了一个轻量但直观的关卡编辑器，它既可作为 localhost Web UI 使用，也可作为基于 ncurses 的终端内编辑器使用。


Web UI 还提供用于对象选择、放置和网格状态预览的侧边栏。这让人联想到《Age of Empires II》《Warcraft III》等 RTS 电子游戏中的世界构建 UI，玩家可以在网格画布上可视化地放置单位、地形和目标。

该编辑器支持所有 MiniGrid 兼容对象（墙、门、钥匙、球、盒子），并扩展了我们的自定义机制：火焰格、洪水格、压力板、公告板、路标、河流格和黑暗区域。研究者可以在网格画布上交互式放置对象，配置其属性（例如门的颜色、洪水激活步数、包含刻意虚假声明的公告板文本），并将环境导出为与 AsciiEnv 兼容的纯文本 .txt 格式。编辑器强制执行 MiniGrid 约束（例如墙边界、有效对象放置），并自动生成关卡元数据（智能体起始位置、视野大小、see-through-walls 标志）。


实践中的快速原型设计。 创建新测试世界的门槛很低：我们的自定义“Ring of Fire”关卡（图 6c）使用 Web 界面在 8 分钟内完成原型设计。该关卡包含一条真实路径和一条诱饵路径，两者都受水格与火格约束，并设置提供误导性导航线索的路标。类似地，C6 Flood-Fire Escape 关卡（图 6a）包含定时推进的洪水格、火焰机制、可推动巨石、压力板触发和对抗性公告板证词，展示了编辑器对复杂多机制交互的支持，而且不需要手动编辑文本文件。



(a) Web UI 中的 C6 Flood-Fire Escape 关卡，包含 flood、fire、boulder、plate、door 等元素。



(b) 终端 ncurses 编辑器，提供键盘驱动的终端内编辑 workflow




(c) 自定义“Ring of Fire”关卡：真实路径 + 带误导性路标的诱饵路径（8 分钟原型设计）。

图 6: 跨模态的 Level Editor 界面。 (a) 基于 Web 的编辑器，展示 C6 Flood Fire Escape 的复杂机制。(b) 面向仅 SSH 环境的终端 ncurses 编辑器。(c) 自定义创建的新关卡，展示快速原型设计。所有界面都导出到相同的纯文本 .txt 格式。

J.2 Trajectory Recorder: 由构造得到 Ground Truth

Trajectory Recorder 是一个基于 Flask 的交互式 Web 应用（可在 localhost:5050 访问），支持手动导航关卡并标注、嵌入幻觉探针。与需要事后人工标注或 LLM 裁决的基准不同，我们的记录器在探针放置过程中自然生成可验证的 ground truth：人类操作者使用键盘控制（WASD 移动，G/F 拾取/放下，T 切换）穿过环境，在每一步观察精确的模拟器状态，并在感兴趣的时刻放置具有已知正确答案的探针。

交互式导航与探针放置。 记录器界面显示两个同步视图（图 7a）：全网格状态面板（左侧）显示所有对象、智能体位置和隐藏状态（例如洪水格是否激活、火焰是否熄灭）的上帝视角；观测文本面板（右侧）显示通过 MemorySerializer 渲染的智能体视野，这与模型在评估期间看到的内容完全一致。在任意轨迹步，操作者都可以按 P 打开探针放置面板；该面板提供探针类型下拉框（presence/count/attribute）、问题文本字段和 ground-truth 答案字段。操作者可以通过检查网格状态来验证正确答案，确保探针既不含糊，也不会无意出错。撤销功能（Z 键）允许在当前房间片段内回溯。



(a) Trajectory Recorder Web 界面，显示网格状态（左）、观测文本（右）和探针放置面板（底部）。操作者已在 C6 中导航到 step 12，并正在放置一个关于出口门 DE 是否打开的探针。

```
{
  "segments": [
    {
      "level_file": "levels/c6.txt",
      "seed": 42,
      "actions": [2,2,0,2,5,...]
    }
  ],
  "probes": [
    {
      "segment": 0,
      "step": 12,
      "probe_type": "presence",
      "question": "Is the fire barrier
                    at row 6 currently
                    passable?",
      "ground_truth": "false",
      "metadata": {}
    }
  ]
}
```

(b) 轨迹 JSON 输出，显示动作序列和嵌入的探针。Ground truth (false) 由操作者的观察得知；火焰在 step 14 熄灭，而不是 step 12。

图 7: Trajectory Recorder 工作流。 (a) 用于手动导航和探针标注的交互式 Web UI。(b) 被评估 harness 消费的确定性 JSON 格式。Ground truth 由操作者直接观察确定，而不是由事后裁决确定。

确定性重放与输出格式。 记录器将轨迹保存为具有两个顶层键的 JSON 文件 (图 7b): `segments` 和 `probes`。`segments` 是由 `{level_file、seed、actions}` 字典组成的列表, 每个房间一个; `probes` 是由 `{segment、step、probe_type、question、ground_truth、metadata}` 字典组成的列表。该格式由 `run_trajectory_eval.py` 消费, 后者确定性地重放动作序列, 即相同的关卡文件、相同的随机种子、相同的动作, 并根据存储的 `ground truth` 评估模型响应。确定性重放保证不同模型面对完全相同的世界状态探针, 从而能够进行受控比较, 不会被随机环境变化混淆。

J.3 集成工作流: 从原型设计到评估

这些工具形成了一个端到端流程, 降低了创建可复现幻觉基准的门槛:

1. **设计:** 研究者草拟一个幻觉场景 (例如, “测试模型是否会相信过时公告板而不是直接观察”)。
2. **原型设计:** 使用 Level Editor 构建环境。对于 C6 Flood-Fire Escape, 这包括放置带定时激活的洪水格 (第 1-5 行, 在 step 0-4 激活)、位于第 6 行并阻挡智能体路径的火焰屏障、位于 (col=7, row=6) 的可推动巨石、位于 (col=9, row=6) 并连接到出口门的压力板, 以及一个带有刻意错误洪水时序声明的公告板 (“洪水在 step 2 到达火焰屏障”, 实际: step 4)。所有这些都在 Web 编辑器中可视化配置。
3. **体验:** Trajectory Recorder 使用 seed 42 加载 `c6_flood_fire_escape.txt`。研究者手动解谜: 等待到 step 14 (洪水熄灭火焰), 导航到现在可通过的火焰屏障位置, 将巨石向东推两次到压力板上 (触发出出口门打开), 然后走向目标。该手动 walkthrough 确保研究者观察到精确的状态变化序列 (洪水推进、火焰熄灭、门打开)。
4. **标注:** 在关键步, 研究者通过按 P 放置探针。例如, 在世界 C6 中, 如果只向上移动, 那么在 step 8: “第 6 行的火焰屏障目前是否可通过?” (ground truth: false, 火焰仍处于激活状态)。在 step 16: “火焰屏障现在是否可通过?” (ground truth: true, 火焰在 step 14 熄灭)。在 step 5: “根据公告板, 洪水什么时候到达火焰屏障?” (ground truth: “step 2”, 测试模型是否会在已观察实际时序的情况下仍服从书面信息)。
5. **评估:** `run_trajectory_eval.py` 为每个模型重放轨迹。在每一步, harness 将观测 (由指定序列化器 `grid/memory/symbolic` 渲染) 和轨迹历史提供给模型, 然后收集模型的探针响应。幻觉率通过比较模型答案与存储的 `ground-truth` 标签来计算。
6. **扩展:** 关卡 `.txt` 文件和轨迹 `.json` 被提交到仓库 (例如 `levels/c6_flood_fire_escape.txt`、`trajectories/c6_s42.json`)。其他研究者可以在编辑器中加载该关卡来创建变体 (例如将洪水时序改为 step 6, 加入具有不同火焰模式的诱饵路径), 或记录具有不同探针放置的替代轨迹 (例如聚焦于巨石推动机制, 而不是洪水时序)。

该工作流保证了可复现性: 任何拥有仓库的人都可以在相同世界状态上重新运行评估 (相同关卡、相同种子、相同动作序列)。它也支持扩展性: 工具是开源的, 且纯文本格式 (关卡 `.txt`、轨迹 `.json`) 便于人类阅读, 也适合版本控制, 因而有助于通过 pull request 贡献新关卡和轨迹。

J.4 集成与可扩展性

一个关键设计目标是让外部研究者无需修改核心基准代码即可贡献新测试用例。这些工具通过模块化架构和用于自我中心探测的共享轨迹集合来支持这一点。

模块化对象系统。 可以通过继承 `WorldObj` 并实现 `__init__`、`render` 和 `toggle` 方法，将新的对象类型添加到 `halluworld/envs/objects/`。Level Editor 会通过 Python 的类注册表自动检测已注册对象类，并将它们加入对象调色板。例如，添加 `TorchObject`（一种会影响 `DarkZone` 可见性的可切换光源）需要 40 行代码，且不需要任何编辑器 UI 改动。

序列化器插件。 可以通过实现 `Serializer` 接口（`serialize(env, step) -> str`）来测试替代观测格式。基准 harness 接受 `-serializer grid|memory|symbolic` 标志，从而可以 A/B 测试表示格式是否影响幻觉率。我们的三种序列化器在冗长度上相差 $\sim 2\times$ （`grid`: 150 tokens/step, `memory`: 80 tokens/step, `symbolic`: 40 tokens/step），但对多数模型显示 $<5pp$ 的幻觉率差异，这表明对于幻觉检测而言，格式粒度的重要性低于世界复杂度。

探针类型可扩展性。 可以通过继承 `BaseProbe` 并实现 `generate(env, trajectory, step)`（返回问题字符串和 ground truth）以及 `evaluate(ground_truth, model_response)`（返回正确性布尔值）来添加新的探针类别。Trajectory Recorder 的探针类型下拉框由已注册的 `BaseProbe` 子类填充，使新探针类型能立即在标注 UI 中可用。例如，一个询问“从智能体视角看，对象 X 是否在对象 Y 的左/右侧？”（非自我中心推理）的 `SpatialRelationProbe` 通过实现一个 60 行子类被添加，并且无需 UI 代码改动即可在记录器中使用。

共享轨迹仓库。 我们发布实验中使用的全部 250+ 条导航轨迹（5 episodes $\times$ 31 worlds $\times$ 1–3 serializers，取决于每个世界的规范序列化器），从而即使在自我中心情形下也能精确复现我们的评估设置。研究者可以 fork 轨迹（例如将 M2 Witness Stand 从 5 个 chamber 扩展到 10 个），向已有轨迹添加新探针（例如测试反事实推理：“如果智能体在 step 5 左转，那么在 step 10 能否看到火焰？”），以及用于其他用途。

K 相关工作扩展

定义与范围。 早期幻觉研究主要以来源为基础。例如，在神经机器翻译中，幻觉被定义为脱离输入的翻译；在抽象式摘要中，它指源文档不支持的内容 [32, 44, 28]。后来随着 LLM 的出现，这一术语被扩展为涵盖流畅但不真实或不忠实的内容。近期审计和基准论文指出，该领域仍然缺少一个稳定统一的幻觉定义，并且常把来源不一致、世界知识错误和其他失败类型混在同一标签下 [66, 26, 2]。近期的“世界模型”视角最接近 HalluWorld。它显式给出参考世界，并把幻觉视为模型内部信念与该参考世界之间可观察的不匹配 [41]。

文本与 RAG 中的静态幻觉基准。 FactCC、QAGS、FRANK 和 FaithBench 等摘要基准是文档忠实性的强测试，但它们相对于固定源文章定义真值，而不是相对于演化中的世界状态 [31, 67, 50, 3]。TruthfulQA、HaluEval、FActScore、HALoGEN 和 HalluLens 等开放域基准把覆盖范围扩展到短式问答、长式主张分解和跨领域验证，但它们仍然针对固定事实、语料库或检索证据来评估静态输出 [39, 34, 48, 52]。HLE 等专家级问答基准进一步在困难学术问题上压力测试前沿模型，但主要衡量的是静态问题上的答案正确性，而不是相对于演化参考世界的幻觉不匹配 [4]。RGB、RAGTruth、RAGBench、FACTS Grounding、*Resolving Knowledge Conflicts in Large Language Models* 和 ConflictBank 等 RAG 基准研究参数知识与上下文知识之间的冲突，但参考世界仍然是被检索或给定的证据，而不是具有显式隐藏状态和可观测性的可控模拟器 [5, 49, 17, 27, 69, 59]。近期关于 RAG-aware 预训练的工作研究模型在预训练期间应如何在参数记忆和检索之间分配知识，强调幻觉倾向也可能取决于哪些信息被外部可观测，哪些信息被学进参数 [57]。

多模态与智能体基准。 在 VLM 中，CHAIR 和 POPE 关注对象幻觉，MMHal-Bench 和 HallusionBench 强调开放式视觉 grounding 和控制配对推理，AMBER 与 HaloQuest 则把评估扩展到属性、关系和合成图像 [53, 35, 60, 18, 68, 70]。这些基准对于多模态 grounding 很关键，但多数都是单场景评估，因此不测试具有时间演化潜在状态时的幻觉 [1]。对于智能体，MIRAGE-Bench 和 AgentHallu 是最接近的先前工作，因为它们显式针对动作层面的幻觉和步骤归因；WebArena、WorkArena、OSWorld 和 GAIA 也通过现实任务执行暴露相关失败 [77, 42, 78, 10, 74, 47]。然而，MIRAGE-Bench 审计来自现有环境的决策快照，AgentHallu 依赖人工标注轨迹，而 HalluWorld 围绕合成环境设计，其标签可以按构造获得。

可控环境、世界模型与结构化推理。 bAbI、Dyna-bAbI、TextWorld、BabyAI 和 ALFWorld 等合成环境，以及 PlanBench 和 ACPBench 等形式规划基准，展示了可控生成、可复现动态和精确评估的价值 [72, 63, 9, 6, 55, 65, 30]。但这些资源主要评估问答、规划或任务成功，而不是把幻觉作为可观察的错误主张来打分。另一条关于世界模型和状态跟踪的文献，从 World Models、PlaNet、MuZero、Dreamer、Dynalang、语言引导世界模型，到 EntNet、CLUTRR、RuleTaker、ProofWriter、BoardgameQA 以及近期显式状态跟踪探针，研究模型是否能够随时间表示并更新潜在状态 [19, 20, 54, 21, 76, 38, 23, 58, 8, 62, 29, 33, 22]。这条文献与我们的动机相关，但其标准目标是控制、预测、证明生成或答案正确性，而不是相对于完全指定参考世界的自动幻觉标签。关于 commonsense-aware 生成和推理的相关工作也探索了把生成扎根于检索到的视觉/上下文证据、概念级约束和领域特定推理维度 [37, 13, 12, 14]。这些方法旨在产生更忠实或语义上更受约束的生成，而 HalluWorld 评估的是模型主张相对于指定参考世界是否为真。

HalluWorld 的定位。 对于把幻觉衡量为部分可观察、演化世界中的可观察错误主张这一特定目标，HalluWorld 并不只是另一个来源 grounding 或静态事实性基准：不同于先前文本和问答基准，它不限于固定文档、事实或语料库。不同于基于 RAG 的基准，它不假设检索上下文就是完整参考世界；不同于多模态 grounding 基准，它也不限于单场景评估。相对于 MIRAGE-Bench 和

AgentHallu, 它针对我们目标的主要优势在于世界是合成且完全指定的, 因此幻觉标签可以来自模拟器状态, 而不是快照审计或事后人工标注。从这个意义上说, HalluWorld 把先前工作通常分别处理的四种成分结合在一起: 一个显式的幻觉定义、一个基准、一个可控环境, 以及自动标签。