

Qwen-AgentWorld: 面向通用智能体的语言世界模型


Qwen 团队

[Technical Blog](#) | [Code Repository](#) | [HuggingFace](#) | [ModelScope](#)

摘要

世界模型基于当前观测和动作预测环境动态，是推理与规划的核心认知机制。在本文中，我们研究基于语言模型的世界建模如何进一步拓展通用智能体的能力边界。(i) 我们首先聚焦于构建用于智能体环境仿真的基础模型。我们提出 **Qwen-AgentWorld-35B-A3B** 和 **Qwen-AgentWorld-397B-A17B**，这是首批能够通过长链式思维推理来仿真覆盖 7 个领域的智能体环境语言世界模型。依托来自真实世界环境中 7 个领域的 1000 万余条环境交互轨迹，我们通过三阶段训练流水线开发 Qwen-AgentWorld：CPT 从状态转移动态和增强的专业语料中注入通用世界建模能力，SFT 激活下一状态预测推理，而 RL 通过一个结合评分规约与规则奖励的定制框架提升仿真保真度。为评估语言世界模型，我们提出 **AgentWorldBench**，这是一个综合性基准，由 5 个前沿模型在 Tool Decathlon、Terminal-Bench 1.0 & 2.0、OSWorld-Verified 等 9 个既有基准上的真实世界交互构建而成，并通过基于真实依据的评分规约裁判，从 5 个维度评估世界建模质量。实证结果表明，Qwen-AgentWorld 显著优于现有前沿模型。(ii) 在基础模型之外，我们进一步研究世界建模增强通用智能体的两种互补范式。首先，作为一个解耦的环境仿真器，Qwen-AgentWorld 支持对数千个真实世界环境进行可扩展、可控的仿真，用于智能体式 RL，并取得超过单独真实环境训练的收益。其次，作为一个统一的智能体基础模型，世界模型训练构成了一种高度有效的 warm-up，可提升 7 个智能体基准上的下游性能。

(1) Building the Foundation Model for Agentic Environment Simulation



(2) Role of World Modeling in Agent Training: [i] Decoupling or [ii] Unifying Agents and World Models

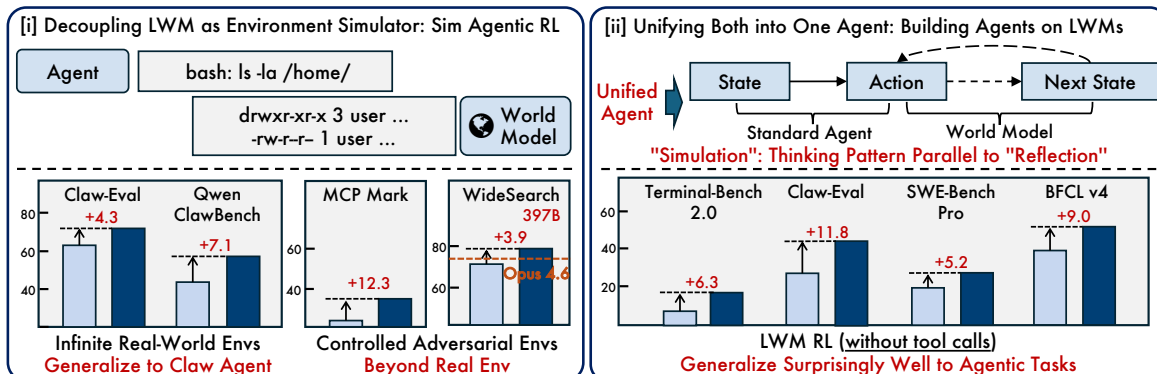


图 1: Qwen-AgentWorld 概览。上方：Qwen-AgentWorld 是一个跨七个领域的统一原生语言世界模型。下方：我们探索了两种利用世界建模增强语言智能体的互补策略（主要使用 35B-A3B 模型作为智能体）：**解耦** 和 **统一**，其中世界模型分别充当环境仿真器和智能体基础模型。

目录

1 引言	3
2 预备知识	3
2.1 术语	4
2.2 统一环境轨迹模式	4
2.3 语言世界模型	5
3 训练方案	7
3.1 训练数据	7
3.1.1 环境轨迹收集	7
3.1.2 统一数据处理	8
3.2 阶段 1: 持续预训练	9
3.3 阶段 2: 监督微调	9
3.4 阶段 3: 强化学习	10
3.4.1 奖励设计	10
3.4.2 训练稳定性	10
4 AgentWorldBench	11
4.1 基准构建	11
4.2 评估协议	12
5 实验	13
5.1 设置	13
5.2 主要结果	14
5.3 跨领域泛化	15
6 应用	15
6.1 应用一: 环境模拟器	15
6.1.1 可泛化的环境扩展	15
6.1.2 可控模拟	16
6.2 应用二: 智能体基础模型	19
7 分析	20
7.1 LWM 推理模式	21
7.2 RL 提升微观层面的仿真保真度	21
8 相关工作	22
9 结论与未来工作	24
10 作者	24
A 领域交互示例	32
B 训练动态	34
C 基于规则的验证	34
C.1 按轴分解	35
D 开放式评判提示词	36
D.1 Terminal 领域	37
D.2 MCP 领域	38
D.3 Search 领域	39
D.4 SWE 领域	40
D.5 Android 领域	41
D.6 Web 领域	42
D.7 OS 领域	43

1 引言

世界模型已经被广泛认为是通向通用智能的基础 (Ball et al., 2025; World Labs team, 2025; Xiang et al., 2025a; Ali et al., 2025), 并且越来越多的共识认为, 学习预测世界是在世界中有效行动的前提 (LeCun et al., 2022; Hafner et al., 2023; 2025; Assran et al., 2025)。Richens et al. (2025) 进一步证明了一个更强的论断: 任何能够在足够广泛的任务范围内泛化的智能体, 都必然已经学得了一个世界模型; 这表明世界模型对通用智能体而言不仅有用, 而且是必要的。

然而, LLM 智能体运行其中的语言环境仍然缺少通用世界模型。在智能体-环境交互循环中, 两个互补组件至关重要: 策略 (states $\rightarrow$ actions) 与世界模型 ((states, actions) $\rightarrow$ subsequent states)。然而, 当前关于 LLM 智能体的研究几乎完全聚焦于策略一侧。我们认为, 世界建模是通向通用智能体道路上缺失的关键一环。在这项工作中, 我们同时探索如何实现语言世界建模, 以及如何应用它来推动通用智能体发展。我们首先研究语言模型中的世界建模, 以开发一个用于智能体环境仿真的基础模型, 即 Language World Model (LWM)。随后, 我们研究世界建模如何通过两种互补范式改进通用智能体: 要么将智能体与世界模型解耦, 要么将二者统一到单一框架中。

既然真实环境存在, 为什么还需要语言世界模型?
并非为了降低成本, 而是作为推动前沿的互补轴线

(1) **解耦**: 将世界模型用作模拟器, 有助于实现轮次级可扩展性与可控性。(i) 可扩展性: LWM 能够在不需要专用基础设施 (例如沙箱或 GUI 虚拟机) 的情况下, 对多样环境进行轮次级扩展, 覆盖极端场景、真实世界任务 (OpenClaw, 2026; Patwardhan et al., 2025), 以及由于不可逆操作、专有部署或缺少公开实现而无法真实执行的高价值专业领域。(ii) 可控性: LWM 提供精确的可控性, 能够构造更多样、更具挑战性的环境, 通过真实环境中罕见或不存在的定向扰动, 系统性暴露智能体弱点。例如, 它可以返回部分结果, 迫使智能体采取额外交互步骤来检索完整信息。针对这些定向扰动进行训练, 有助于智能体处理仅靠真实环境训练无法覆盖的边缘情形, 并最终超越仅在真实环境中训练的智能体 (§6.1.2)。

(2) **统一**: 一个有能力的通用智能体应当同时具备决策能力与世界建模能力。世界建模是更强智能体的基础, 因为它使智能体能够预测未来状态以改进行动选择; 而传统智能体训练只关注从状态到行动的决策。直观而言, 一个能够在承诺采取行动之前预测环境反馈的智能体, 原则上不会比缺少这种能力的对应智能体表现更差 (Richens et al., 2025)。因此, 下一状态预测可以被内化为一种类似于“反思”但面向未来的元层级思维模式 (§6.2)。此外, 准确的下一状态预测需要推理、知识、指令遵循和长上下文处理能力 (附录 7.1), 这些能力本身也是通用智能体的基础。

我们提出 **Qwen-AgentWorld**, 这是首个通过长链式思维推理来模拟七类智能体环境的语言世界模型: MCP、Search、Terminal、Software Engineering、Android、Web 和 OS。对于三个 GUI 领域, 环境观测被表示为无障碍树和 UI 视图层级, 而不是像素帧。Qwen-AgentWorld 是一个原生世界模型, 通过三个阶段进行训练: CPT 注入状态转移动力学和世界知识, SFT 激活下一状态预测思维模式, 而采用 rubric 与规则混合奖励的 RL 则提升仿真保真度。为评估 LWM, 我们构建了 **AgentWorldBench**, 一个覆盖全部七个领域的综合基准。该基准来自 Claude Opus 4.6 等前沿模型在 Terminal-Bench 1.0 & 2.0 (Merrill et al., 2026) 和 OSWorld-Verified (Xie et al., 2024) 等广泛使用的智能体基准上的真实环境交互, 从而确保评估完全是分布外的。AgentWorldBench 通过五个维度的开放式 rubric 判断来评估仿真质量。我们还设计了基于规则的验证器, 用于对定向仿真能力进行确定性检查。实证评估表明, Qwen-AgentWorld 相较现有前沿模型取得了更优性能。我们进一步研究世界建模改进通用智能体的两种互补范式:

- **环境模拟器 (§6.1)**. 我们证明, Qwen-AgentWorld 可以为智能体 RL 模拟 4k 个真实世界 OpenClaw 环境, 并在 Claw-Eval (Ye et al., 2026a) 和 QwenClawBench (Team & Data, 2026) 上带来提升。此外, 这种可控性提供了与真实世界交互互补的显著优势, 从而在 Tool Decathlon (Li et al., 2025a)、MCPMark (Wu et al., 2025) 和 WideSearch (Wong et al., 2025) 上带来大幅收益。
- **智能体基础模型 (§6.2)**. 在 Terminal-Bench 2.0 (Merrill et al., 2026)、SWE-Bench Verified (Jimenez et al., 2024)、SWE-Bench Pro (Deng et al., 2025)、BFCL v4 (Patil et al., 2025)、Claw-Eval (Ye et al., 2026a)、QwenClawBench (Team & Data, 2026) 和 WideSearch (Wong et al., 2025) 上的综合实验表明, LWM 训练可作为预热阶段或辅助训练阶段。它使智能体在下游智能体 RL 之前熟悉环境动力学和下一状态预测, 从而为自举出更强的智能体性能提供关键基础。

2 预备知识

本节对本文研究的语言世界模型 (LWM) 进行形式化。我们基于语言模型并利用广泛的世界知识语料来训练世界模型, 并将七个领域统一到一种共享的文本表示之下, 从而使语言世界建模能够跨领域泛化。我们首先确立术语 (§2.1), 随后给出七个领域和各训练阶段共享的统一轨迹模式 (§2.2), 并形式化世界建模目标 (§2.3)。



图 2: Qwen-AgentWorld 在单一语言世界模型中统一了七类交互式环境仿真。

2.1 术语

在本报告全文中，我们一致使用以下术语。**LWM training (LWM 训练)** 指通过三个阶段训练世界模型本身：持续预训练 (**LWM CPT**, §3.2)、监督微调 (**LWM SFT**, §3.3) 和强化学习 (**LWM RL**, §3.4)。另一个概念是，**Sim RL (模拟 RL)** 使用 LWM 作为环境模拟器，通过 RL 训练策略智能体 (§6.1)；而 **Real RL (真实 RL)** 则让同一个智能体面对一个运行中的真实世界环境进行训练（例如真实搜索引擎或正在运行的终端）。

在本报告中，**trajectory (轨迹)** 指 **environment trajectory (环境轨迹)**，其结构上是智能体与环境之间的多轮对话，表示为一系列 (action, observation) 对。相比之下，**agentic trajectory (智能体轨迹)** 是智能体针对某个任务的一次完整作答，即一种多步骤、工具集成的推理轨迹，其中智能体的内部思考和行动选择与环境观测交替出现。环境轨迹可以通过去除智能体推理并仅保留 (action, observation) 对，从智能体轨迹中提取；也可以直接从原始交互日志中收集。

2.2 统一环境轨迹模式

在七个领域上训练一个单一世界模型，需要一个共享格式，因为这些领域的状态表示差异很大，例如 Terminal 的文件系统快照和 Android 的 UI 视图层级。我们在全部七个领域和各训练阶段统一采用如下环境轨迹模式：

统一环境轨迹模式

```
system_prompt := task_description ⊕ action_space ⊕ initial_state ⊕ demonstrations ⊕ simulation_instruction
turnt := (actiont, observationt)
trajectory := system_prompt ⊕ [turn1, ..., turnT]
```

在这一模式中，*action* 是智能体在某一轮的输出（例如工具调用或 shell 命令），而 *observation* 是环境反馈（例如工具响应或命令输出）。

图 3 展示了一个来自 Terminal 领域的完整组装系统 prompt，并给出了各组件的代表性摘录。系统 prompt 包含五个组件，其构造方式详见 §3.1.2。*task description* 指示模型充当某个特定领域的世界模型，并定义仿真目标。*action space* 枚举可用工具或操作及其调用约定。*initial state* 指定任何交互开始之前的环境起始配

System Prompt — Terminal LWM RL	
[1] Task Description	static
You are a Terminal World Model — a precise terminal state simulator. Your task is to predict the exact output of a Linux/Unix terminal after executing a given command or sequence of commands. Your goal is to be as faithful as possible to real terminal behavior while maintaining consistency and logical correctness across the interaction sequence. <i>Given:</i> (1) Historical Context (optional); (2) Current Terminal State; (3) User Action (keystrokes). <i>Predict:</i> the exact next terminal state after all actions are executed. Core Responsibilities: State Prediction Context Maintenance Behavioral Fidelity [...state transition rules, side-effect tracking, error handling, output formatting ...]	
[2] Action Space	static
User actions are JSON arrays of command objects: { ``keystrokes``: ``ls -la\n``, ``duration``: 0.1 } Keystrokes: \n = execute; C-c = SIGINT; C-d = EOF; C-z = SIGTSTP; C-l = clear screen Shell constructs: pipes, redirects, command chaining; Programs: shell builtins, editors (vim/nano), REPLs, pagers	
[3] Initial State	dynamic, injected per trajectory
The initial container snapshot of the terminal environment is: OS: Ubuntu 22.04.3 LTS (x86_64) Kernel: Linux 5.15.0-134-generic Packages: Python 3.10.12, pip 23.2.1, Node 18.17.1, gcc 11.4.0, git 2.34.1, Docker 24.0.5 Disk: 64 GB (41 GB free) RAM: 16 GB Working dir: /workspace The initial terminal state is: <pre>root@6b254155-5503-4b86-837b-fd0f080ab297:/workspace#</pre>	
[4] Demonstrations	static
Turn 1 Action: "git clone https://github.com/expressjs/express.git /tmp/express\n" Observation: root@6b254155:/workspace#git clone https://github.com/expressjs/express.git /tmp/express Cloning into '/tmp/express'... Turn 2 Action: "", duration=3.0 Observation: remote: Enumerating objects: 32841, done. remote: Counting objects: 100%(1205/1205), done. Receiving objects: 100%(32841/32841), 12.76 MiB 8.53 MiB/s, done. Resolving deltas: 100%(21567/21567), done. <pre>root@6b254155:/workspace#</pre> [...6 more turns demonstrating directory navigation and build operations ...]	
[5] Simulation Instruction	dynamic, injected per trajectory
Simulate a system with CUDA 11.8 drivers and only 2 GB free disk space. <code>pip install torch==2.1.0</code> should complete the download phase normally (progress bar reaching 100%), then fail during unpacking of <code>libtorch_cuda.so</code> with <code>OSError: [Errno 28] No space left on device</code>. After the failure, <code>pip cache list</code> should report the partially downloaded <code>.whl</code> file still present. <code>df -h</code> should show <code>/tmp</code> at 100% usage. See §6.1.2 for the controllable simulation capability.	

图 3: Terminal 领域 LWM RL 系统 prompt 的结构, 展示了 §2.2 中定义五个组件。蓝色 = 静态 (跨轨迹共享); 红色 = 动态 (按轨迹注入)。

置: 已安装包、文件系统布局、UI 屏幕状态, 或轨迹所假定的任何其他前提条件。结合交互历史和当前动作, 一个足够详细的初始状态会显著约束预期观测。*demonstrations* 是可选的少样本 (action, observation) 示例。*simulation instruction* 指定可控仿真条件 (例如 “hide the answer from the web_search responses”), 并主要用于可控仿真实验 (§6.1.2)。

2.3 语言世界模型

语言世界模型 (LWM) 是一种条件文本生成器, 它在给定交互历史和智能体当前动作的情况下, 预测下一条环境观测。令 c 表示系统 prompt, o_t 表示第 t 轮的环境观测, a_t 表示智能体动作。LWM f_θ 产生:

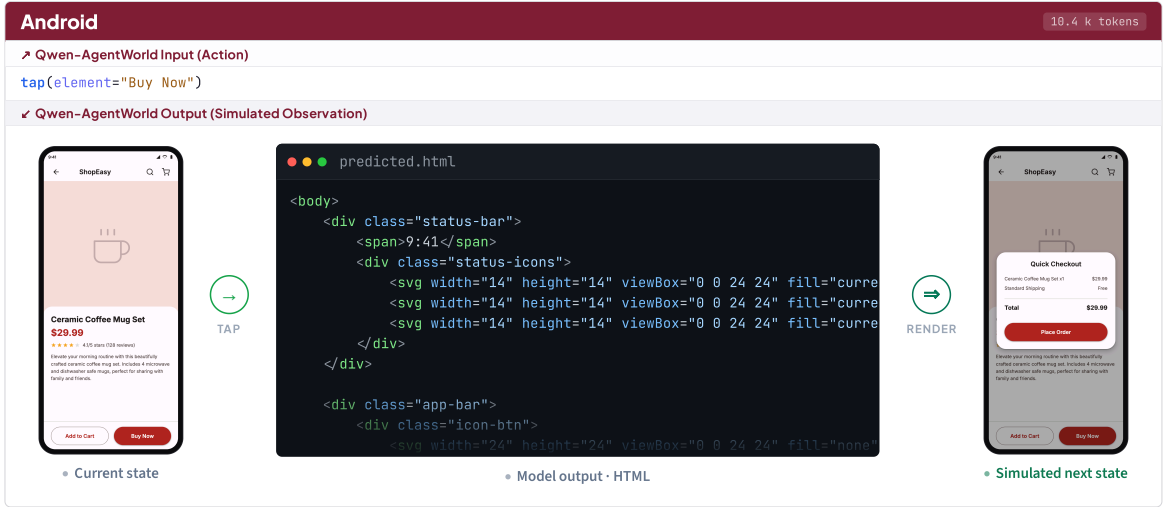
$$\hat{o}_{t+1} = f_\theta(c, o_{\leq t}, a_{\leq t}), \quad (1)$$

其中, 条件上下文由 c 、完整交互历史和当前动作组成。训练目标是真实观测 o_{t+1} 。

表 1 列出了全部七个领域及其观测和动作表示。在无状态环境 (例如 Search) 中, 状态隐式地承载于对话历史中; 而有状态环境 (例如 Terminal、OS) 会维护随每次动作演化的显式内部状态。在这两种情况下, LWM 都作用于同一个观测序列, 正如 §2.2 中的模式所形式化的那样。然而, 领域的多样性确保了单一世界建模目标可以同时锻炼推理、知识和长上下文理解能力。这些能力也是通用智能体的基础 (§6.2)。



(a) **SWE**（基于文本）：智能体运行一个 Python 脚本；世界模型预测完整错误追踪，其中包括 one-hot encoding 期间的内存不足错误。



(b) **Android**（GUI）：智能体在商品页面点击“Buy Now”；世界模型预测下一屏幕的 HTML 表示，并将其渲染为预测出的结账面板。

图 4: 来自基于文本领域 (SWE) 和 GUI 领域 (Android) 的代表性交互示例，展示了观测空间的广度。

表 1: Qwen-AgentWorld 覆盖的七个领域，以及各领域的动作、观测和下一状态预测所锻炼的核心能力。

领域	动作	观测	核心能力
MCP	JSON Tool Call	工具响应（文件内容、DB 等）	事实性世界知识
Search	Web Search / Web Extractor	对话历史（查询 + 结果）	事实性世界知识
SWE	Read / Edit / Bash / ...	工具输出（文件内容 + diff）	代码执行推理
Terminal	Bash Commands / Keystrokes	终端输出（stdout + shell 提示符）	长上下文因果推理
Android	Touch / Swipe / Type / ...	UI 视图层级 + app 状态	视觉状态推理
Web	Click / Type / Navigate / ...	无障碍树 + 浏览器状态	视觉状态推理
OS	Mouse / Keyboard	无障碍树 + 窗口/app 状态	视觉状态推理

图 4 通过每一类中的一个代表性示例展示了这种广度。在 SWE (图 4a) 中，智能体运行一个 Python 脚本，LWM 必须通过内存分配和数组维度进行推理，以预测由此产生的内存不足错误追踪。在 Android (图 4b) 中，智能体点击一个 UI 元素，LWM 必须推断该交互如何改变页面布局，并将结果屏幕预测为可渲染的 HTML。附录 A 给出了其他领域的交互示例。

3 训练方案

Qwen-AgentWorld 从持续预训练开始，就以环境建模作为显式目标进行端到端训练。如图 5 所示，我们采用“CPT 注入、SFT 激活、RL 锐化”的原则，形成一个三阶段流程：阶段 1 CPT 通过非思考轨迹注入环境世界知识 (§3.2)；阶段 2 SFT 将下一状态预测激活为一种显式思维模式 (§3.3)；阶段 3 RL 通过 rubric 与规则混合奖励提升输出质量 (§3.4)。



图 5: Qwen-AgentWorld 的三阶段训练流程。阶段 1 CPT 注入世界知识；阶段 2 SFT 灌输下一状态预测思维模式；阶段 3 RL 提升输出质量。

3.1 训练数据

我们首先描述支撑全部三个训练阶段的数据来源和统一处理流程。

3.1.1 环境轨迹收集

现有公开数据集没有一个能以世界模型训练所需的数据规模覆盖如此广泛的领域。我们从三个互补来源收集环境轨迹：

- **专用智能体基础设施。**我们部署了一套智能体-环境后端：用于代码和工具调用的容器化执行沙箱、MCP 服务器，以及带有完整 shell 状态跟踪的持久终端会话。对于 GUI 领域，我们部署持久化的 Android、浏览器和桌面 OS 环境，并将 GUI 观测表示为文本化无障碍树和 UI 视图层级，用于世界模型训练。这些环境运行在配置了 Ubuntu、macOS 和 Android 虚拟机的物理主机上。在这一基础设施之上，我们自动合成覆盖各领域目标分布的任务查询，并让智能体系统端到端执行它们。该流程持续运行，是可扩展、可控、可复现交互数据的主要来源。
- **开放环境交互轨迹。**我们从公开来源收集自然产生的动作-环境交互轨迹：终端会话记录、开源智能体工具调用日志，以及代码仓库中的执行轨迹。这些原始轨迹噪声较多，结构异质，并且往往不完整。因此，我们构建了一个多智能体清洗流程，其中专门化智能体将抓取、去噪、分段、语义对齐和质量评分作为独立阶段处理。只有通过所有阶段的序列才会进入训练池。这一来源捕获长尾交互模式（不常见的 shell 工作流、罕见 API 错误模式、特异化工具调用链），从而补充专用基础设施的受控分布。

- **内部智能体轨迹。**我们使用在常规模型开发过程中积累的内部基础模型 SFT 智能体轨迹，覆盖全部七个领域。这些轨迹通过格式统一被转换为环境轨迹 (§2.1)。

三个阶段的数据池严格互不重叠。CPT 数据来自专用智能体基础设施、开放交互轨迹以及专门领域世界知识语料 (§3.2)。SFT 和 RL 则只使用内部积累的轨迹。由于 RL 会通过 on-policy rollout (同策略展开) 放大数据伪影，我们将大部分数据工程工作投入到下游流程中。表 2 总结了 SFT 和 RL 数据统计。

表 2: 全部七个领域上的 SFT 和 RL 训练数据统计。平均 token 数和平均轮次数基于 RL 训练池计算。

领域	SFT	RL 训练	平均 token	平均轮次
MCP	179	4,156	62,702	28.9
Search	1,042	20,004	18,873	6.2
Terminal	1,580	34,125	5,805	12.0
SWE	249	8,181	36,734	24.7
Android	1,337	11,498	30,064	19.3
Web	1,605	8,716	19,417	10.2
OS	1,102	5,628	25,439	12.4
总计	7,094	92,308	19,443	13.4

3.1.2 统一数据处理

所有训练数据都遵循 §2.2 中定义的统一环境轨迹模式：首先是一个指定仿真上下文的系统 prompt，随后是交替出现的用户轮次（智能体动作）和助手轮次（环境观测）。来自异构来源的原始智能体轨迹，通过领域特定处理器和下文描述的共享预处理步骤，被规范化为这一格式。

轨迹到轮次的扩展。我们首先将每条多轮轨迹扩展为多个轮次级预测样本。对于一条包含 T 轮的轨迹，任意轮次 t 都可以作为预测目标：前序交互 $(\text{turn}_1, \dots, \text{turn}_{t-1})$ 与第 t 轮的状态和动作拼接后构成输入，而第 t 轮的观测则成为目标。由于智能体-环境交互天然是多轮的，并且每条观测只依赖其前序历史，一条轨迹中的每一轮在与先前上下文配对后，本身都是有效的预测实例。对于训练划分，我们从每条轨迹中随机采样一个轮次，以增加训练目标的多样性。

数据过滤。训练前，我们在轨迹级和轮次级同时过滤轨迹。在轨迹级，我们丢弃少于两轮的序列，移除调用了声明动作空间之外工具的 MCP 和 SWE 轨迹，并排除受到环境故障影响的 GUI 轨迹，例如缺失状态文件、CAPTCHA 挑战或 HTTP 错误，因为这些故障会破坏动作与后续环境状态之间的因果关系。在轮次级，我们去除由暂停或演示叙述造成的空动作轮次，并应用下文描述的两个非平凡过滤器。

- **跳过重试循环。**智能体经常陷入“垃圾输出 → 错误 → 重试”的循环。直接删除这些轮次会破坏状态链。因此，我们跳过有问题的 (user, assistant) 对，同时保留当前状态，使下一个有效轮次继承正确历史。
- **无变化轮次过滤 (GUI 领域)。**我们移除动作前后状态没有有效变化的轮次，这通常由系统响应缓慢或网络延迟造成。如果保留这些样本，它们会教会模型无论采取何种动作都原样复制前一状态，从而削弱模型预测动作如何改变环境的能力。

系统 prompt 构造。如 §2.2 所定义，每个系统 prompt 包含五个组件：*task description*、*action space*、*initial state*、*demonstrations* 和 *simulation instruction*。初始状态和仿真指令是可选的，而所有其他字段始终存在。图 3 展示了来自 Terminal 领域的一个真实系统 prompt。哪些组件是静态的（跨轨迹共享）、哪些组件是动态的（按轨迹填充），会因领域而异：

- **静态组件。**除 MCP 和 SWE 之外，对于所有领域，动作空间和 *demonstrations* 都是预定义的：每个领域都有一组固定的可用操作，以及一组固定的规范 *action-observation* 示例。MCP 和 SWE 轨迹需要按轨迹指定动作空间，因为可用工具会随 MCP 服务器实例和代码仓库而异。
- **动态组件。**当存在时，初始状态和仿真指令是动态的（按轨迹填充）。初始状态捕获环境的起始配置（已安装包、文件系统布局、数据库内容、UI 屏幕状态，或其他领域特定前提条件），并提供与交互历史和当前动作共同决定预期观测的前提条件 (§2.2)。对于 GUI 领域，初始状态被有意设置得十分多样。在训练和推理期间，它可能从门户页面、Google Search，或任意网站及桌面/app 状态开始。仿真指令为轨迹指定可控条件。对于搜索领域，每条轨迹都用一条逆向工程得到的仿真指令进行标注，其中包含目标查询、参考答案和防泄漏约束。对于终端及其他强依赖初始环境的领域，我们为一部分数据添加了控制输出的指令。这些指令训练模型按照给定指令进行仿真，将“simulate according to this instruction”建立为一种学习到的模式，直接支持 §6.1.2 中描述的可控仿真能力，同时明确预期响应边界，以减少 SFT 和 RL 训练期间的幻觉。

通过 AutoResearch 构造系统 prompt 模板。 构造有效的系统 prompt 需要深厚领域专业知识和大量人工迭代：每个 prompt 都必须编码领域特定的状态转移规则、输出格式约束和演示模式。我们没有手工制作这些模板，而是将 prompt 优化表述为一个自动化研究问题 (Karpathy, 2026)，其明确目标是在留下的真实轨迹上最大化世界模型的预测准确率。该流程迭代进行：在每个循环中，一个优化器智能体分析采样轨迹数据，识别领域特定模式和常见失败模式，然后起草或修订候选系统 prompt。候选 prompt 被加载到世界模型中，后者在留下的真实轨迹上运行推理。一个独立评判模型 (judge) 根据真实环境响应对预测进行评分。优化器智能体同时检查分数和具体预测错误，以定位弱点，并为下一循环生成定向修订。每次优化运行执行 10 轮这样的“提出-评估-细化”迭代。我们并行启动 12 次运行，每次都以不同风格指令作为种子（冗长规格说明、简洁检查清单、以演示为主等），得到 12 个模板变体 (v0-v11)，范围从最小的 ~30 行约束式模板到 ~1100 行规格说明式模板。人工审阅者审核并批准每个最终版本。三个训练池使用互不重叠的模板子集：RL 使用 v0，CPT 使用 v1，SFT 则为每个样本从 v2-v11 中随机采样，以最大化 prompt 格式多样性。

3.2 阶段 1：持续预训练

CPT 数据。 CPT 的目标是在建模真实世界环境行为的同时，向模型注入广泛的世界知识。因此，除上述数据收集流程得到的环境轨迹之外，我们还进一步纳入专门领域世界知识语料，覆盖范围广泛的专业与事实领域：工业控制与制造、网络安全、法律与监管、医学与医疗健康、金融、时事和百科知识。这些语料为模型提供了单靠环境轨迹无法获得的事实性世界知识基础：仿真监管合规平台需要法律知识，仿真医院信息系统需要医学知识，而仿真关于时事的搜索引擎响应则需要最新事实覆盖。这种领域知识广度还使模型能够泛化地构造七个训练领域之外的专门环境 (§6.1.1)。

训练目标。 CPT 采用标准下一 token 预测目标进行训练。多轮环境轨迹被组织为世界建模任务：系统 prompt 定义仿真上下文，用户轮次承载智能体动作，助手轮次承载环境响应，从而将语言建模目标直接映射到 $p(o_{t+1} | o_{\leq t}, a_{\leq t})$ 。由于每条轨迹都被扩展为轮次级预测样本 (§3.1)，模型会在轨迹历史中的每一轮获得监督。专门领域世界知识语料则在同一目标下以单轮数据形式进入训练。

轮次级信息论损失掩码。 我们发现，工具使用轨迹中的许多轮次都是模板化内容，例如仅仅回显其输入的工具，或镜像请求参数的 API。这些轮次诱导的梯度往往质量较低并引入噪声，但又不能简单移除，因为后续轮次依赖它们作为上下文。为此，我们针对每个 (action, observation) 对计算四个统计量—Overlap (OL)、Novelty (Nov)、Jaccard (Jac) 和长度比 (R)—并按照表 3 中显示的保留比例，将每个轮次分配到七个语义类别之一。这一设计旨在识别真正承载世界知识、因而具有有意义学习价值的轮次。重要的是，类别由统计量而非工具名决定，因此分类保持与工具无关。给定从动作和观测中抽取的词汇集合 W_{act} 和 W_{obs} （小写化并去重的 token）： $OL = |W_{act} \cap W_{obs}| / |W_{act}|$ 衡量观测回显了多少动作词汇； $Nov = |W_{obs} \setminus W_{act}| / |W_{obs}|$ 捕获观测中真正新增信息的比例； $Jac = |W_{act} \cap W_{obs}| / |W_{act} \cup W_{obs}|$ 给出对称词集合相似度；而 $R = |obs| / |act|$ 是字符级长度比。被掩码的轮次会被排除在损失计算之外，但其 token 会保留为后续轮次的上下文。这将“学习下一状态”与“学习下一 token”解耦：损失只在承载真实环境信息的轮次上计算。相同过滤也适用于任何轨迹格式训练数据，因为四个统计量 (OL, Nov, Jac, R) 都根据表层 token 重叠计算，不需要领域特定标注。

表 3: 用于信息论损失掩码的七个轮次类别。类别由统计信号而非工具名决定。保留比例是用于损失计算的 token 占比。

类别	统计特征	直观含义	保留
检索	$Nov \geq 60\%, R > 1$	<code>read_file</code> → 内容	100%
扩展	$OL \geq 50\%, Nov \geq 50\%, R > 1.5$	<code>fetch</code> → 页面 + 元数据	100%
动作	$Nov \geq 50\%, R \leq 1$ 或较短	<code>send_email</code> → “sent”	100%
转换	$Nov < 50\%, R < 1$	长输入 → 状态词	50%
模板化	$OL \geq 50\%, Nov < 50\%$	API 回显	10%
回显	$OL \geq 70\%, Nov < 30\%$	<code>think(x)</code> → { <code>thought:x</code> }	5%
其他	未分类	—	100%

3.3 阶段 2：监督微调

经过 CPT 之后，模型已经学到工具会返回什么以及状态如何演化，但这些知识只是通过对观测 token 的下一 token 预测被隐式应用。通过 SFT，我们将下一状态预测显式激活为一种推理模式。我们使用 SFT 教会模型显式进行下一状态预测，从而更好激活 CPT 期间获得的状态转移知识（识别某个动作请求什么、回忆先前状态、预期响应格式）。这种显式推理减少幻觉，并改善长轨迹上的状态一致性。在 SFT 阶段，我们仍使用标准下一 token 预测作为训练目标，即与 CPT 相同的损失。我们采用 256k-token 上下文窗口，以容纳长的多步骤轨迹。

SFT 推理轨迹整理。 SFT 阶段从 CPT 的非思考机制转向包含显式推理链的思考轨迹。从 SFT 池出发，我们首先在样本之间多样化 prompt 模板，随后生成 multi-beam rollout（多束展开），并应用拒绝采样来整理最终训练集。(i) **prompt 模板多样化。** 每个 SFT 样本的默认系统 prompt 都会被替换为从 10 个模板变体中均匀采样的一个 (§3.1.2)。轨迹的动态内容（工具定义、demonstrations、仿真指令）会被保留，并重新注入到新模板中。重新计算 token 数，并截断超过 256k 的样本。这通过在 SFT 期间让同一轨迹暴露于多样 prompt 格式，提升模型跨系统 prompt 变体的泛化能力。(ii) **拒绝采样。** 对于每个查询，我们从一个通用推理模型生成三条 rollout（展开结果）。候选轨迹由独立评判模型 (judge) 评分，并通过成对比较选择质量最高的轨迹。如果胜出轨迹的分数低于最低阈值，则丢弃该查询。表 4 报告了拒绝采样统计。从 10,250 个候选查询出发，该流程保留了 7,094 条轨迹（69.2% 保留率）。

表 4: 各领域的拒绝采样统计。“候选数”是具有完整 rollout（展开结果）的查询数量。“保留率”是其三选一最佳轨迹超过质量阈值的查询比例。“最终 SFT”是过滤后的数量。

领域	候选数	保留率	最终 SFT	平均轮次
MCP	261	68.6%	179	24.3
Search	1,466	71.1%	1,042	3.3
Terminal	1,826	86.5%	1,580	5.9
SWE	402	61.9%	249	26.9
Android	1,975	67.7%	1,337	15.9
Web	2,697	59.5%	1,605	3.0
OS	1,623	67.9%	1,102	5.4
总计	10,250	69.2%	7,094	8.5

3.4 阶段 3：强化学习

在上述数据上，我们在 RL 阶段采用 GSPO (Zheng et al., 2025)。由于环境反馈预测本身困难且开放，LWM 的 RL 面临独特挑战。此外，由于上下文明显长于目标输出，LWM RL 呈现出极端的 prompt-output 不对称：prompt 由截至预测轮次的完整轨迹历史构成，往往延伸到数万 token；而输出只是一个预测观测，通常只有几百到几千 token。因此，每个样本的计算成本主要由 prompt 处理而非生成主导。我们将 RL 池中的 prompt 上限设为 128k token，并过滤掉历史超过这一限制的轨迹。该阈值覆盖了全部七个领域中的绝大多数轨迹。

我们系统研究如何为世界建模实现稳定 RL。具体而言，我们关注两个方面：奖励设计 (§3.4.1) 和训练稳定性 (§3.4.2)。附录 B 报告了 Qwen-AgentWorld-35B-A3B 的训练动态，跟踪 RL 训练全过程中的五个 rubric 维度；结果显示它们的提升速度显著不同。事实性表现出最大的相对提升 (11.3%)，但在整个过程中仍然是得分最低的维度，这证实事实性世界知识是环境仿真中最困难的方面。

3.4.1 奖励设计

我们系统探索如何为世界模型 RL 设计有效奖励。该奖励结合了两个互补信号，用于处理不同失败模式。

- **五维 Rubric (LLM Judge, LLM 评判器)。** 使用 rubric（评分规程）作为 RL 的结构化奖励，已被证明在不可验证领域中有效 (Gunjal et al., 2025)；递归式 rubric refinement（评分规程细化）(Shen et al., 2026a) 可以进一步提升评判器和奖励质量。每条预测观测都由 LLM judge (LLM 评判器) 根据 §4.2 中定义的五维 rubric 评分，每个维度采用 1-5 分。总奖励等于均值 $\times 5$ ，范围为 [5, 25]。如果评判器未能产生有效分数，则奖励默认为 0。每个领域都使用带有内容类型分类的定制评判器系统 prompt (§4.2)，以减少时间戳和 PID 等不可复现细节导致的假阴性。我们通过异步分布式调用来调用 RL judge (RL 评判器)。
- **基于规则的验证器。** 一部分数据带有可执行验证器代码，可产生二值 0/1 正确性信号，并缩放到 [0, 25]，以与 rubric 范围对齐。基于规则的奖励作为客观锚点，有效缓解放式奖励引发的奖励攻击 (reward hacking)。

我们以 9:1 (rubric:rule) 组合两个信号，在多维 rubric 反馈与严格二值正确性之间取得平衡。我们使用多策略 JSON 解析器和严格标签抽取，确保只有预测观测会到达评判器，从而防止推理中的自我赞美影响分数。

3.4.2 训练稳定性

我们通过系统消融识别出三种失败模式，并描述已被证明有效的解决方案。

由多轮扩展导致的奖励崩塌。 我们发现, 当按照 §3.1 中描述的过程将训练轨迹扩展为多个样本时, 所得训练实例会共享很长的公共前缀, 进而导致训练快速崩塌。这与多轮智能体 RL 中识别出的“Echo Trap”有关 (Wang et al., 2025b), 在其中, 奖励方差会崩塌且策略退化。我们通过将 RL 池中的扩展严格限制为每条轨迹只取一轮来解决这一问题, 使每个训练样本都有唯一预测目标, 并且没有共享前缀重叠。

奖励塑形。 奖励形式的选择会强烈影响收敛 (Zhu et al., 2025)。我们将上述开放式奖励设计与两种替代方案进行比较。*Reference-Reward* 向评判器展示真实观测, 并要求它在成对 A/B 测试中选择策略预测观测和初始策略 checkpoint 输出哪一个更接近真实值, 从而产生二值 0/1 信号。该设计收敛缓慢: 二值奖励稀疏, 并且当两个输出都合理但表面形式不同时, 评判器的偏好会变得不稳定, 向梯度中注入噪声。*Turing-Test Reward* 要求评判器判断预测观测是否可能来自真实环境。这一奖励几乎不能收敛, 主要原因是假阴性率过高。当模型生成非常接近甚至等同于真实值时, 要求评判器判断哪一个更可能来自真实环境, 无论选择哪个答案, 都会引入不可靠的训练信号。总体而言, 五维 rubric 与基于规则的验证器结合后可以稳定收敛。通过将评估拆分为正交维度, 并为具有可执行真实值的情形保留一个二值锚点, 即使观测空间是多模态的, 该设计也能提供一致且信息充分的梯度。

通过自我赞美进行奖励攻击 (Reward Hacking)。 策略可能学会利用评判器的特定偏差, 在预测观测中插入自我赞美短语, 以在不提高仿真逼真度的情况下抬高分数 (Wang et al., 2026b)。我们具体观察到这种行为: 策略学会嵌入定性肯定语句 (例如 “operation completed successfully with all fields correctly populated”), 或回显评判器 prompt 中会触发更高 rubric 分数的关键词。我们应用三种缓解措施。首先, 基于规则的验证器将一部分奖励锚定在不会受评判模型偏差影响的二值正确性上, 提供一个稳定锚点来抵消奖励攻击 (reward hacking)。其次, 评判器 prompt 中的内容类型分类缩小了每个 rubric 维度的范围, 使确定性内容按精确匹配判断。被分类为确定性的区域中的自我赞美不会获得任何分数。第三, 通过上文描述的标签抽取过程, 我们严格强制模型预测内容的清晰分离。这不仅确保思考块 (thinking block) 永远不会暴露给评判器, 也明确指出哪些部分对应最终预测, 哪些部分属于策略输出。

4 AgentWorldBench

我们构建 **AgentWorldBench**, 用于在七个智能体交互领域评估语言世界模型。当 LWM 模拟环境时, 预测每一轮的观测都需要理解此前所有轮次积累下来的完整交互历史。随着轨迹变长, 保持对这一上下文的忠实性会变得越来越困难, 这使 **AgentWorldBench** 成为一个具有自然基础的长上下文 benchmark。要保证模拟质量, 还要求世界模型 benchmark 能够验证预测的环境响应在格式、事实性、状态一致性和领域特定惯例上是否与真实相匹配。

4.1 基准构建

AgentWorldBench 基于前沿模型在全部七个领域的成熟 benchmark 上产生的智能体轨迹构建; 这些轨迹被转换为环境轨迹 (§2.2), 并配有从真实环境获得的真实观测。

构建原则。 **AgentWorldBench** 基于四项构建原则: (i) 广泛使用的查询: 所有任务查询都来自成熟的高质量智能体 benchmark, 而不是自构任务, 使任务分布与当前智能体开发所面向的场景保持一致; (ii) 前沿智能体轨迹: 所有轨迹都由前沿模型智能体生成, 其动作 (长推理链、工具调用组合和错误恢复序列) 质量高且足够复杂, 能够在前沿规模上对世界模型忠实度进行压力测试; (iii) 真实观测: 每条轨迹都配有来自真实环境执行的真实观测, 为评估提供参考; (iv) 分布外: 训练数据和 benchmark 查询在数据源层面划分, 使 **AgentWorldBench** 测试的是泛化能力而非记忆能力;

数据收集。 图 6 总结了每个领域的源 benchmark 和轨迹统计。我们在全部 7 个领域的 9 个成熟 benchmark 查询集上部署 5 个前沿智能体, 让它们在真实环境中执行以产生智能体轨迹, 然后提取环境轨迹 (§2.2)。对于基于文本的领域, 早期子集 (Terminal-Bench 1.0 和内部 SWE benchmark) 使用 Claude Sonnet 4.5 收集。其余所有文本领域轨迹都专门使用 Claude Opus 4.6, 以确保 **AgentWorldBench** 评估的是 LWM 能否忠实模拟环境, 从而支持最强智能体的工作流。对于 GUI 领域, 我们进一步加入 3 个强大的 Qwen 系列模型来丰富智能体池, 将覆盖范围扩展到 5 个前沿模型, 并生成更多样的动作序列以进行全面评估。

轮级采样策略。 由于原始智能体轨迹规模很大, 我们在应用下述轮级扩展之前, 先对内部 SWE benchmark 和 3 个 GUI benchmark 的源轨迹进行子采样。当轨迹被扩展为轮级评估样本时, 所有文本领域都采用非对称采样策略: 每条轨迹保留第一轮和最后一轮, 再加上三轮均匀采样的中间轮次, 总计五个评估轮次。第一轮测试没有交互历史时的初始模拟能力。这一轮的错误会沿状态链递归传播, 因此第一轮忠实度起到锚点作用。最后一轮拥有最长上下文, 并且最强依赖于累积的先前状态。它是长上下文模拟忠实度的主要探针。三轮中间轮次为轨迹中段行为 (工具调用链、增量状态更新、错误恢复) 提供更广覆盖, 并稀释边界偏差。对于 GUI 领域, 由于某些操作过于简单 (例如向输入框输入文本), 我们在扩展过程中有选

AgentWorldBench Composition

2,170 turn-level evaluation samples across 7 agent interaction domains.

Domain distribution

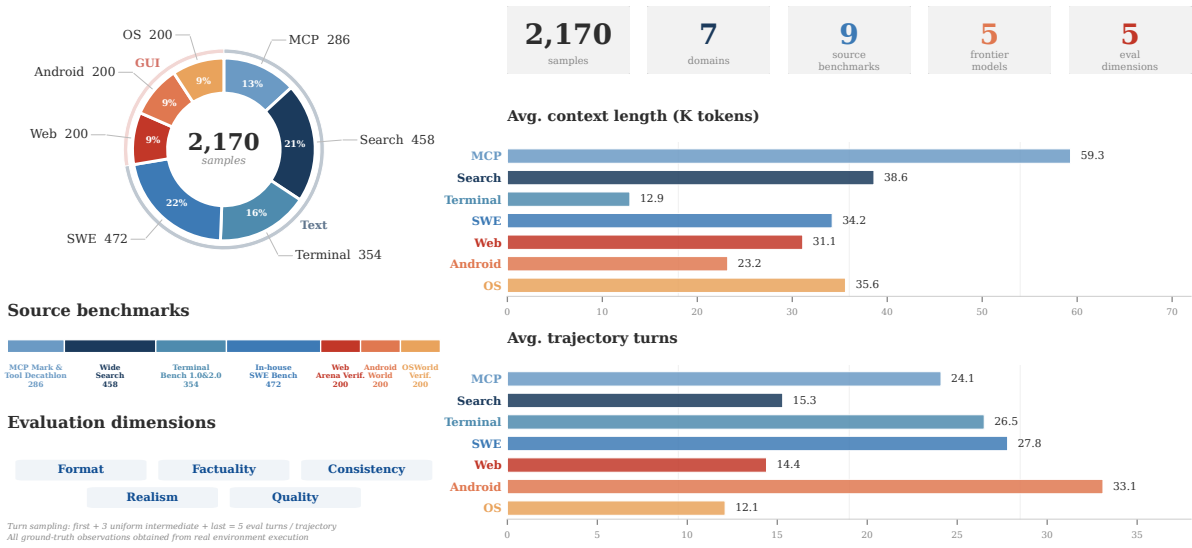


图 6: AgentWorldBench 构成概览。左：七个领域的领域分布、映射到各领域的源 benchmark，以及五个评估维度（Format、Factuality、Consistency、Realism、Quality）。右：汇总统计、各领域平均上下文长度和轨迹深度。所有真实观测都来自真实环境执行。

择地从轨迹中采样更具挑战性的轮次。在完成从轨迹到轮次的扩展之后，我们进一步保留均匀的 50% 随机样本来形成最终 benchmark，从而在评估覆盖度与计算成本之间取得平衡。

Benchmark 统计。 图 6 展示了 AgentWorldBench 的领域覆盖和评估框架；AgentWorldBench 总共包含 2,170 个评估样本。四个基于文本的领域合计占 benchmark 的 72.4%，其中 SWE (21.8%) 和 Search (21.1%) 占比最大，其后是 Terminal (16.3%) 和 MCP (13.2%)。三个 GUI 领域各占 9.2%。不同领域的平均上下文长度存在差异：MCP 样本平均为 59,300 个 token，因为每个样本都会在其系统 prompt 中嵌入完整的工具定义 schema；Terminal 样本最短，为 12,900 个 token，反映的是自包含 shell 会话。

4.2 评估协议

AgentWorldBench 通过开放式 rubric 评估模拟质量：LLM 裁判在五个维度上为每个预测观测打分：**Format**、**Factuality**、**Consistency**、**Realism** 和 **Quality**。主分数是五个维度的均值，并缩放到 [0,100]。Format 衡量输出是否遵循该领域的结构惯例（MCP 的 JSON schema 合规性、Terminal 的 shell prompt 模式）。Factuality 衡量陈述事实（文件内容、搜索结果、工具返回值）是否正确。Consistency 衡量输出在内部是否连贯，并且是否与先前轮次连贯。Realism 衡量模拟是否匹配真实环境在 ground truth 中体现出的行为特征，包括响应模式、风格惯例和值的合理性。Quality 衡量相对于 ground truth 的完整性和简洁性：关键信息不能遗漏，且与参考相比，输出不应过度冗长或过度简略。

基于参考的判分。 裁判会同时收到真实环境观测和预测观测，并通过比较二者为每个维度打分。这种基于参考的设计将评估从开放式质量判断转换为事实比较，大幅缩小了裁判幻觉或误判的空间：裁判不需要独立推理正确的环境响应应当是什么样子，因为真实输出提供了明确无歧义的参考。这也是下文报告的跨裁判一致性较高的主要原因：当评分基于具体参考而不是抽象质量标准时，不同裁判模型会收敛到相同的排序。

领域感知 Rubric。 每个领域都有自己的裁判 prompt，以领域特定术语应用这五个维度，确保评估不仅客观地与参考进行比较，也执行各领域的专业标准（完整 prompt 见附录 D）。例如，Terminal 裁判验证 shell prompt 模式和跨轮状态跟踪（工作目录、环境变量、文件系统变更），MCP 裁判执行 JSON schema 合规性和资源生命周期一致性，Search 裁判应用事实优先级层级：只要与参考答案矛盾，无论表面上多么合理，Factuality 都记为零分；SWE 裁判则执行工具执行正确性（成功/失败状态、退出码）以及跨轮文件系统状态持久性。

差异化匹配准则。 环境观测中的内容并非都需要精确匹配，把所有内容一视同仁会产生过多假阴性。我们在评估前将内容分为三类。确定性内容（echo 输出、文件读取、计算结果）必须精确匹配。返回错误




图 7: AgentWorldBench 上的主要结果：各领域的五维 rubric 均值。Qwen-AgentWorld-397B-A17B 在所有被评估模型中取得最高整体平均分，在基于文本的领域中优势稳定，在 GUI 领域中也具有竞争力。

文件内容的 `cat` 命令显然是错误的。预先存在的环境内容（预装软件版本、非轨迹创建的文件内容）只需要验证格式和合理性，因为模拟器无法复现某个特定 sandbox 中 `gcc` 的精确 patch 版本。运行时元数据（时间戳、PID、内存地址、会话 token）只需要验证格式和范围。只要二者都有效，模拟 PID 42731 与真实 PID 18204 一样可以接受。这种三分法让裁判能够奖励正确的结构和语义行为，而不会惩罚不可复现的细节。

裁判选择。 我们使用双盲图灵测试作为校准工具来选择裁判模型并调优裁判 prompt。给定直到预测轮次之前的交互历史和当前动作，裁判会以随机顺序收到两个候选观测，一个来自真实环境，一个来自世界模型，并且必须判断哪一个来自真实环境。我们随机化呈现顺序以控制位置偏差，并使用真实观测而不是另一个世界模型的输出，以避免分布混杂。其理由是，图灵测试准确率高的裁判必须关注忠实模拟与貌似合理但错误的模拟之间的细粒度差异，这正是准确 rubric 评分所需的同一种判别能力。我们通过 autoresearch (Karpathy, 2026) 迭代细化领域特定裁判 prompt，以图灵测试准确率作为优化信号，分析各领域错误模式来调整 rubric 定义、差异化匹配边界和评分锚点，直到 prompt 达到稳定准确率。

在校准后的 prompt 就绪后，我们评估裁判模型的选择是否影响评估结果。我们比较三个前沿模型作为裁判候选：Gemini 3 Flash (DeepMind, 2025)、Claude Sonnet 4.5 (Anthropic, 2025) 和 GPT-5.2 (OpenAI, 2025)；做法是让每个模型独立为表 5 中所有模型在 AgentWorldBench 七个领域上的预测打分。绝对分数显示出系统性差异：Gemini 3 Flash 在所有领域中最宽松，而 GPT-5.2 是最严格的评分者。尽管存在这些绝对差异，裁判之间的模型级排序高度一致：成对 Spearman 秩相关为 $\rho = 0.92-0.99$ (所有 $p < 10^{-5}$)，表明三个裁判虽然给出的绝对分数不同，但都认同哪些模型产生了更高忠实度的预测。逐维度排序也得到保留：三个裁判都将 Format 和 Consistency 排为两个最强维度，同时将 Factuality 识别为最弱维度；所有裁判还共享 Realism > Quality > Factuality 的排序。我们将这种跨裁判排序一致性归因于基于参考的设计：每个裁判都根据真实环境输出打分，将任务简化为事实比较，而不是主观质量评估。由于相对排序在不同裁判之间稳定，我们选择平均图灵测试准确率最高的 GPT-5.2 作为裁判。

5 实验

我们在 AgentWorldBench 的全部七个领域上评估 Qwen-AgentWorld，涵盖实验设置 (§5.1)、主要评估结果 (§5.2) 和跨领域泛化 (§5.3)。我们还在附录 C 中报告补充性的基于规则的验证结果，以佐证主要发现。如图 7 所预览，Qwen-AgentWorld-397B-A17B 取得最高整体分数。

5.1 设置

模型。 我们评估 Qwen-AgentWorld-35B-A3B 和 Qwen-AgentWorld-397B-A17B，二者都使用 §3 中的三阶段方案训练。

基线。 我们与 14 个基线进行比较，这些基线覆盖前沿闭源模型、开源权重模型，以及未经过世界模型训练的 Qwen 系列模型：

- 前沿闭源: Claude Opus 4.8 (Anthropic, 2026b), Claude Opus 4.6 (Anthropic, 2026a), Claude Sonnet 4.6 (Anthropic, 2026c), GPT-5.4 (OpenAI, 2026), Gemini 3.1 Pro (DeepMind, 2026).
- 开源权重: DeepSeek-V4-Pro (DeepSeek-AI, 2026), Kimi K2.6 (Team et al., 2026), GLM-5.1 (Zeng et al., 2026), MiniMax-M2.7 (MiniMax, 2026).

表 5: AgentWorldBench 主要结果：各领域的五维 rubric 均值 (↑)。每个领域的最高分和第二高分分别用 **粗体**和 下划线 标出。

模型		文本				GUI			平均
		MCP	Search	Term.	SWE	Android	Web	OS	
前沿	Claude Opus 4.8	54.93	35.14	59.18	64.10	<u>61.50</u>	54.66	66.62	56.59
	Claude Opus 4.6	69.90	29.30	57.51	64.55	61.74	51.42	70.20	57.80
	Claude Sonnet 4.6	<u>70.00</u>	28.79	56.98	64.52	58.03	50.78	63.17	56.04
	GPT-5.4	70.10	<u>37.26</u>	53.69	<u>66.29</u>	60.00	51.80	<u>68.58</u>	58.25
	Gemini 3.1 Pro	59.07	30.21	52.47	59.07	61.40	<u>52.83</u>	<u>66.92</u>	54.57
开源权重	DeepSeek-V4-Pro	63.27	27.61	51.26	59.44	55.17	50.32	63.70	52.97
	Kimi K2.6	65.23	27.48	52.54	58.77	58.93	50.20	60.80	53.42
	GLM-5.1	67.60	22.46	47.32	52.07	59.10	51.50	59.13	51.31
	MiniMax-M2.7	55.82	27.30	41.62	37.44	52.40	50.52	57.73	46.12
Qwen	Qwen3.6-35B-A3B	42.96	18.78	43.81	40.71	51.88	46.53	55.48	42.88
	Qwen3.6-Plus	55.28	21.94	50.58	59.08	57.65	50.78	60.33	50.81
	Qwen3.6-Max-Preview	67.01	24.71	50.86	57.11	57.74	48.58	60.95	52.42
本文	Qwen3.5-35B-A3B	57.87	25.98	46.13	47.58	53.18	47.10	56.27	47.73
	Qwen-AgentWorld-35B-A3B	64.79	36.69	53.96	65.63	58.17	49.55	65.92	56.39
	Qwen3.5-397B-A17B	68.31	30.81	<u>55.30</u>	64.44	54.90	48.55	60.85	54.74
	Qwen-AgentWorld-397B-A17B	68.24	37.82	<u>57.73</u>	68.49	60.20	50.98	67.89	58.71

- Qwen 系列 (无 LWM 训练) : Qwen3.5-35B-A3B, Qwen3.5-397B-A17B (Team, 2026), Qwen3.6-35B-A3B (Qwen Team, 2026a), Qwen3.6-Plus (Qwen Team, 2026c), Qwen3.6-Max-Preview (Qwen Team, 2026b).

Qwen 基线用于隔离世界模型训练的效果：它们共享相同的基础架构，但没有经过三阶段 CPT→SFT→RL 流程。在结果表中，Qwen3.5 基础 checkpoint 与 Qwen-AgentWorld 并列放置，以便直接比较训练效果。

设置。 所有模型均使用 `temperature = 0.6`，并在支持时启用 `thinking mode`。最大生成长度和上下文长度设置为各模型支持的上限。闭源模型使用官方 API endpoint。开源权重模型使用 SGLang 部署。

5.2 主要结果

表 5 报告了全部七个领域上的五维 rubric 均值。每个预测观测都会在五个 rubric 维度上评分：Format、Factuality、Consistency、Realism 和 Quality；评分使用 1-5 标度，然后归一化到 0-100。Qwen-AgentWorld-397B-A17B 取得最高整体平均分 (58.71)，超过 GPT-5.4 (58.25) 和所有其他前沿模型。在基于文本的领域上，Qwen-AgentWorld-397B-A17B 以 58.07 的平均分领先，比 GPT-5.4 (56.84) 高 1.23 分。优势在 Terminal (57.73 vs. 53.69) 和 SWE (68.49 vs. 66.29) 上最明显；这两个领域的预测需要准确建模代码执行状态和工具 API 行为。在 GUI 领域上，Claude Opus 4.8 (60.93) 和 Claude Opus 4.6 (61.12) 领先，其后是 GPT-5.4 (60.47) 和 Gemini 3.1 Pro (60.04)，Qwen-AgentWorld-397B-A17B 排名第五 (59.69)。这一差距反映了多模态预训练带来的优势，而纯文本世界建模无法完全捕捉这种优势。

世界模型训练的效果。 将 Qwen-AgentWorld 与其基础 checkpoint 比较，可以隔离三阶段流程的贡献。在 397B 规模上，整体平均分从 54.74 上升到 58.71。在 35B 上，增益为 8.66 分 (47.73 到 56.39)，使 Qwen-AgentWorld-35B-A3B 比 Claude Sonnet 4.6 (56.04) 高出 0.35 分。这种改进在文本和 GUI 领域中都保持一致：在 397B 上，文本领域平均分提高 3.35，GUI 领域平均分提高 4.92。这些增益不能仅由基础模型的一般能力解释，因为未经过 LWM 训练的 Qwen3.6 checkpoint (Qwen3.6-Plus: 50.81, Qwen3.6-Max-Preview: 52.42) 虽然共享同一架构家族，但分数明显低于 Qwen-AgentWorld。

领域层面的观察。 Search 对所有模型来说都是最具挑战性的领域：最高分 (37.82) 大约只有 SWE (68.49) 或 MCP (70.10) 最高分的一半。Search 要求模型建模不断变化的网页内容，而跨长检索链的事实一致性对所有模型仍然困难。在 MCP 上，Claude Opus 4.6 和 GPT-5.4 紧密位于前列，反映出它们在工具使用方面的专长。




图 8: 仅在 Terminal 数据上训练第 3 阶段 (RL) 时的跨领域泛化。(a) Terminal (域内) 相对于 SFT 基线提高 +14.2 分。(b) 三个留出领域在未接收任何领域特定训练信号的情况下全部提升: MCP (+5.0)、SWE (+11.5) 和 Search (+11.8)。

5.3 跨领域泛化

该实验测试 Qwen-AgentWorld 学到的是可泛化的语言世界知识, 还是领域特定的环境行为。我们仅在 Terminal 数据上训练第 3 阶段 (RL), 并且每 10 步在全部四个基于文本的领域上评估一次。图 8 展示了在 Qwen3.5-35B-A3B-SFT 上使用 Terminal LWM 数据单独训练第 3 阶段时的性能; Qwen3.5-35B-A3B-SFT 是一个内部 Qwen checkpoint, 已经经过 CPT 和通用 SFT, 但没有经过世界模型训练。Terminal 在 100 个 RL 步内从 32.8 提升到 47.0 (+14.2)。三个留出的基于文本的领域也同步提升: SWE 增加 +11.5 (52.0 $\rightarrow$ 63.5), Search 增加 +11.8 (20.2 $\rightarrow$ 32.0), MCP 虽然起点已经较高, 仍增加 +5.0 (53.5 $\rightarrow$ 58.5)。这种迁移并非平凡: Terminal shell 命令和 MCP 工具调用在语法、状态表示和响应结构上都不同, 但增益在前 10 个 RL 步内就出现, 并在整个训练过程中保持稳定。这一模式表明, RL 强化的是可泛化的世界知识, 即环境如何响应动作、错误如何传播、状态转移如何跨轮组合, 而不是领域特定的输出格式。

6 应用

我们研究 Qwen-AgentWorld 增强通用智能体的两种互补范式。Qwen-AgentWorld 支持无限环境扩展和可控模拟 (§6.1), 使智能体训练能够扩展到真实环境无法提供的领域和条件。此外, LWM 训练作为智能体基础模型 (§6.2) 提高了下游智能体性能的上限。

6.1 应用一: 环境模拟器

主要结论

作为独立模拟器, Qwen-AgentWorld 提供了真实环境无法提供的 **可扩展性** 和 **可控性**:

- **零样本环境泛化。** Qwen-AgentWorld 为智能体 RL 模拟 4k 个训练中完全不存在的 OpenClaw 环境, 在没有领域特定适配的情况下, 在 Claw-Eval 上带来 +4.3、在 QwenClawBench 上带来 +7.1 的增益。
- **受控模拟很重要。** 可控扰动暴露了真实世界很少产生的智能体弱点, 使 MCPMark 提升 +12.3、WideSearch 提升 +16.3, 远超无控制的 Sim RL。
- **超越真实环境训练。** 可控 Sim RL 超过了使用实时搜索引擎训练的 Real RL (50.3% vs. 45.6%), 同时通过对抗性 snippet 设计塑造更有针对性的智能体行为。
- **虚构世界同样有效。** 在完全发明且自治的世界中训练的智能体能够泛化到真实搜索任务, 同时在结构上防止智能体把模拟事实与真实世界知识混淆。
- **状态是瓶颈。** Sim RL 的有效性取决于为世界模型提供足够详细的初始状态; 如果缺少这一点, 模拟忠实度会下降, 下游增益也会减弱。

在这一应用中, Qwen-AgentWorld 作为独立环境模拟器: 策略智能体和世界模型是分离的模型。Qwen-AgentWorld 具备真实环境无法提供的两个属性: **可扩展性** (§6.1.1) 和 **可控性** (§6.1.2)。

6.1.1 可泛化的环境扩展

借助 CPT 期间获得的世界知识, 以及在七个训练领域中学到的环境建模能力, Qwen-AgentWorld 可以以可泛化方式模拟范围广泛、真实且高度专门化的现实环境。我们在 OpenClaw (OpenClaw, 2026) 上研

究这一能力；OpenClaw 是一个开源通用现实世界 AI 智能体平台，其任务来自真实用户的多步数字工作流，而非人工策划的 benchmark，涵盖日程安排、编码、邮件分流、浏览器自动化和文件管理。由于 OpenClaw 完全处于分布外，它为评估语言世界模型能否泛化到新的交互环境家族提供了自然试验场。在这一设置中，Qwen-AgentWorld 从少量真实交互轨迹中合成多样化的 OpenClaw 风格环境，不使用任何领域特定适配。

实验设置。 我们首先使用一小组真实 Claw Agent 轨迹作为现实工作流的锚点。每条轨迹都被蒸馏为一个可复用的 **种子场景**，其中捕捉与任务相关的 **初始状态**（例如已安装应用、文件系统布局、账户配置和相关工作区内容）以及对应的 **用户查询**。基于这些种子，我们沿两个互补轴合成 4k 个模拟训练环境。在环境侧，我们在保留底层工作流结构的同时改变具体状态；在任务侧，我们改写意图、调整难度，并组合多步目标，使智能体看到多样但真实的 OpenClaw 风格任务。这种扩展评估了环境扩展的核心价值：世界模型能否把稀缺的真实环境证据转化为面向下游智能体训练的广泛、真实交互覆盖。对于每个合成任务，我们生成一个基于 rubric 的验证器来描述预期终止条件，为 Sim RL 提供自动奖励信号。我们使用 Qwen-AgentWorld-397B-A17B 作为模拟器来测试其可泛化环境模拟能力，并使用 Qwen3.6-Plus 作为消融基线。基于 Qwen3.5-35B-A3B (Team, 2026)，我们进行最多 50 个交互轮次的多轮 Sim RL，并在 Claw-Eval (Ye et al., 2026a) 和 QwenClawBench (Team & Data, 2026) 上评估。对于两个 benchmark，我们报告最大序列长度为 256k token 时的 Avg@3 分数。

结果。 如表 6 所示，以 Qwen-AgentWorld-397B-A17B 作为模拟器进行 Sim RL，使 Claw-Eval 分数从 65.4 提升到 69.7 (+4.3)，使 QwenClawBench 从 47.9 提升到 55.0 (+7.1)；这证实 Qwen-AgentWorld 能够可扩展地模拟范围广泛的现实场景，并且所得策略能够有效迁移到世界模型训练中不存在的现实领域。**比较两个模拟器揭示了世界模型质量的重要性：**使用 Qwen3.6-Plus 作为模拟器只产生边际增益，而专门为环境模拟训练的 Qwen-AgentWorld-397B-A17B 在两个 benchmark 上都取得显著更大的增益，证实专用 LWM 训练流程对于构建高忠实度模拟器并产生有效 Sim RL 增益至关重要。

表 6: 在模拟 OpenClaw 环境上的 Sim RL。Qwen3.5-35B-A3B 使用不同环境模拟器通过 Sim RL 进行训练。 Δ 报告相对于基础模型的增益。

模型	Claw-Eval	QwenClawBench
Qwen3.5-35B-A3B	65.4	47.9
Sim RL (使用 Qwen3.6-Plus)	66.7	47.8
Sim RL (使用 Qwen-AgentWorld-397B-A17B)	69.7	55.0
Δ	+4.3	+7.1

6.1.2 可控模拟

可控模拟使用自然语言指令，在轨迹级和轮次级塑造 Qwen-AgentWorld 在训练期间的行为。关于可控工具使用环境的同期工作 (Xu et al., 2026b) 也持有同一动机，即保持 oracle 不变的增强可以提升智能体鲁棒性。我们分别通过 MCP 和 Search 智能体上的 Sim RL 验证两种互补的可控性模式。基础模型是 Qwen3.5-35B-A3B-SFT 和 Qwen3.5-397B-A17B-SFT，这是内部 Qwen checkpoint，经过了持续预训练和通用监督微调，但没有经过世界模型训练：

- **环境适配**，即通过指令调整模拟器的行为和风格，以注入有针对性的扰动，从而系统性暴露智能体弱点。控制指令随后修改模拟风格和内容，产生比真实部署更极端或更有针对性的条件，例如间歇性 API 错误、需要后续调用的分页响应、迫使多步检索的不完整中间结果，以及批处理操作中的部分失败。通过系统性地让智能体暴露于自身弱点，可控 Sim RL 训练出的智能体能够超越仅在无扰动真实交互上训练的智能体。
- **虚构世界构建**，即模拟器生成一个结构真实但事实层面与现实世界不相交的完全虚构环境。对于 Search，我们指示 Qwen-AgentWorld 从紧凑的初始规格模拟一个完全虚构且自治的世界。LiteResearcher (Li et al., 2026a) 独立构建了用于智能体 RL 且具备 sim-to-real 迁移的虚拟搜索世界，其共同洞见是搜索智能体可以在模拟环境中得到有效训练。虚构世界构建为 Search 领域的 Sim RL 提供了两个结构性优势。第一，由于答案只存在于虚构设定中，智能体无法绕过搜索工具直接从参数记忆中回答，因而必须学会有效搜索。第二，由于所有事实都是发明出来的，没有现实世界对应物，智能体不会把训练时的搜索结果与真实世界知识混淆。相比之下，直接模拟真实搜索引擎存在注入虚构但表面可信事实的风险，而智能体之后可能把这些事实当作真实。Qwen-AgentWorld 忠实遵循初始设定，并将其连贯扩展为逻辑一致的现实。例如，一个虚构的 2030 年场景可能规定已有 430 人迁移到火星。世界模型随后会基于这一前提生成一致的人口记录、新闻文章和搜索结果。令人意外的是，完全在这些虚构环境中训练的 Search 智能体能够有效泛化到真实世界搜索任务，并取得显著性能增益。

MCP：环境适配。 我们从 RL 数据流程中收集的内部 MCP 工具使用轨迹合成环境模拟系统 prompt：前沿智能体（开启 extended thinking 的 Claude Opus 4.6、DeepSeek-v4-Pro）在真实 MCP 环境中解决多样化的跨服务任务，并且只保留通过自动验证的轨迹。每个 prompt 由三个组件构成：指定工具 schema 和服务配置 的初始状态；总结轨迹背后隐藏环境状态的 环境摘要，例如数据库内容、权限设置和服务可用性；以及 可控模拟指令，定义模拟器在每一轮应如何响应，包括注入错误、隐藏中间结果、响应格式，以及任务成功所需的最终工具和环境状态。这些组件共同为模拟器提供真实的工具设置、环境上下文和明确的成功标准。由于智能体是在模拟环境中训练的，一个自然顾虑是其增益是否来自利用模拟器特定 artifact，或者来自通过模拟指令泄露的 ground truth。然而，在真实环境中的分布外 benchmark 上评估可以消除这一顾虑，并且 SimRL 训练数据与评估查询完全不相交。Tool Decathlon (Li et al., 2025a) 覆盖 32 个软件应用，并包含多步任务。性能通过执行验证成功率衡量。MCPMark (Wu et al., 2025) 在横跨多个 MCP server 类别的 127 个多步任务上评估智能体，使用脚本验证的 pass@1 作为指标。

如表 7 所示，没有控制指令的标准 Sim RL 没有提供有意义的增益，Tool Decathlon 甚至从 32.4 下降到 31.5，因为模拟器缺乏足够 grounding 来产生忠实响应。使用可控模拟后，Tool Decathlon 提升 +3.7，MCPMark 提升 +12.3。可控性不仅影响改进幅度，更是在该领域中让 Sim RL 能够发挥作用的前提：没有 grounded 模拟指令时，训练信号过于嘈杂，无法带来任何增益。MCPMark 上更大的增益表明，可控模拟对需要大量工具调用并仔细处理中间工具结果的任务尤其有效。

表 7: Tool Decathlon 和 MCPMark 上的可控 Sim RL 结果。“使用 Qwen-AgentWorld-397B-A17B 受控版”表示在 Sim RL 期间加入有针对性的环境控制指令。

模型	Tool Decathlon	MCPMark						
		Filesys.	GitHub	Postgres	Notion	Playwright	WebArena	平均
Qwen3.5-35B-A3B-SFT	32.4	16.7	17.4	28.6	25.0	0.0	33.3	21.5
Sim RL (使用 Qwen-AgentWorld-397B-A17B)	31.5	16.7	17.4	42.9	32.1	0.0	28.6	24.6
Sim RL (使用 Qwen-AgentWorld-397B-A17B 受控版)	36.1	30.0	17.4	47.6	42.9	0.0	38.1	33.8
Δ	+3.7	+13.3	+0.0	+19.0	+17.9	+0.0	+4.8	+12.3


Search：虚构世界构建。 我们使用多智能体合成框架构建 1k 个自包含虚构环境，每个环境都由一个大型关系数据库（300–500 行）锚定，其中包含内部一致的虚构结构化事实。该流程收集高质量领域文档作为 grounding 材料，从这些文档实例化虚构数据库 schema，通过 LLM 引导生成进行填充，执行 SQL 以抽取 ground-truth 答案，并反向生成自然语言查询。四种合成策略（时间迁移、细粒度长尾、私有模拟、现实 grounding）使数据保持完全虚构但又真实：例如，一个时间迁移环境包含 2029 年智能手机市场排名，其中有真实品牌名，但型号不存在。自动检索检查以及基于规则和 LLM 的双重验证确保合成事实符合现实世界模式（例如一致的价格区间、真实的时间趋势），同时保持不可搜索，以防注入幻觉。可控模拟指令进一步塑造 Qwen-AgentWorld 的轮级行为：世界模型只返回与当前搜索查询相关的信息，而不揭示完整答案，因此智能体必须改写查询、交叉引用来源，并在多轮搜索中迭代聚合部分结果。这种设计增加了智能体在每条轨迹中必须发出的工具调用次数，因为表层 search snippet 不再足够，智能体必须调用页面抽取来获取完整信息（图 9b）。WideSearch (Wong et al., 2025) 是一个广泛的信息搜寻 benchmark，包含 15+ 个领域中 200 个手工策划的收集任务。智能体必须从网页收集结构化表格答案。指标是 item-level F1（单元格级准确率）和 row-level F1（实体级完整性）。

表 8 报告了两个模型规模上的结果。在 Qwen3.5-35B-A3B-SFT 上，可控 Sim RL 将 F1 by Item 从 34.02 提升到 50.31 (+16.29)，将 F1 by Row 从 13.72 提升到 24.21 (+10.49)。在 Qwen3.5-397B-A17B-SFT 上，基础模型已经达到 70.11 F1 by Item，Sim RL 仍然在两个指标上分别带来 +3.87 和 +6.05 的增益。这些结果值得注意，因为训练环境完全是虚构的：每个搜索结果、网页和事实记录都由 Qwen-AgentWorld 从零发明，与任何真实搜索引擎或真实世界数据库都没有连接。智能体在 Sim RL 期间从不与真实环境交互，但它获得的能力（查询改写、多源交叉引用和迭代结果聚合）可以直接迁移到 WideSearch 上的真实世界搜索任务。这展示了整个环境层面的可控性：Qwen-AgentWorld 构建并模拟完整、自治且足够真实的虚构世界，以训练有效的搜索智能体。35B 上 +16.29 F1 by Item 的增益表明，虚构世界 Sim RL 可以弥合较弱模型的显著能力差距；而在 397B 上，当基础模型已经达到 70.11 时仍获得 +3.87 增益，则证实该方法即使在前沿规模上仍然有效。


Real RL 与 Sim RL 对比 表 7 中的 MCP 结果表明，没有控制指令的标准 Sim RL 只能带来可忽略的改进（Tool Decathlon 实际上从 32.4 下降到 31.5），而受控 Sim RL 会产生显著增益。这一差距在 Search 领域更加明显，因为世界模型必须模拟一个完整搜索引擎，为真实索引中不存在的虚构事实返回可信结果。因此，我们从一开始就采用完全可控的模拟设计：模拟指令明确要求 Qwen-AgentWorld 从 search snippet 中隐藏完整答案，只返回与查询相关的部分信息。具体而言，要求 snippet “tease information without fully answering”，并且每个结果页都混合高度相关、中等相关和背景结果。这种设计迫使智能体发出后续 web_extractor 调用以获取完整页面内容，而不能只依赖表层 snippet。

表 8: 使用虚构世界模拟时, WideSearch 上的可控 Sim RL 结果。

模型	WideSearch	
	F1 Item	F1 Row
Qwen3.5-35B-A3B-SFT	34.02	13.72
Sim RL (使用 Qwen-AgentWorld 受控版)	50.31	24.21
Δ	+16.29	+10.49
Qwen3.5-397B-A17B-SFT	70.11	45.69
Sim RL (使用 Qwen-AgentWorld 受控版)	73.98	51.74
Δ	+3.87	+6.05



(a) WideSearch 验证集上的 F1 by Item 和 F1 by Row。



(b) 每条轨迹的平均工具调用频率。

图 9: WideSearch 上前 60 个训练步中的可控 Sim RL vs. Real RL (使用实时搜索引擎训练)。两个实验都使用 Qwen3.5-35B-A3B-SFT 作为基础模型。

图 9 将可控 Sim RL 与在 WideSearch 上使用实时搜索引擎训练的 Real RL 进行比较。就任务性能而言 (图 9a), Sim RL 在重叠范围内始终追随或略超 Real RL: F1 by Item 达到 50.3%, 而 Real RL 为 45.6%。更具信息量的信号来自智能体行为。图 9b (左) 显示, 两种训练制度都将 web_search 调用从每条轨迹约 ~5 次降至约 ~3.5 次, 说明两个智能体都学会发出更有针对性的查询。然而, web_extractor 调用 (右) 出现明显分化: Sim RL 将使用量从每条轨迹 2.5 次提高到 4.0 次, 而 Real RL 将其从 2.5 次降低到 1.5 次。这种分化直接反映了可控模拟设计。由于模拟 search snippet 有意隐藏详细内容, Sim-RL 训练出的智能体学会了抽取完整页面是组装完整答案的必要步骤。相反, Real-RL 训练出的智能体发现真实 search snippet 往往包含足够信息, 因此学会跳过抽取。结果证实, 可控模拟能够以有针对性的方式塑造智能体行为: 通过构造需要特定能力的对抗性环境条件, Sim RL 能比无控制的真实环境训练更有效地训练这些能力。

6.2 应用二：智能体基础模型

主要结论

LWM 训练统一了世界模型和智能体，将下一状态预测灌注为一种内化推理能力：

- **强跨任务泛化。**没有工具调用的单轮、非智能体 LWM RL warm-up，可以迁移到五个领域七个 benchmark 上的多轮、工具调用型智能体任务。
- **领域泛化。**在 LWM 训练中完全不存在的两个彻底分布外领域上出现增益（Claw-Eval 上 +11.3，Qwen-ClawBench 上 +9.7，BFCL v4 上 +9.0），证实其来自可迁移能力，而非领域特定捷径。
- **下一状态预测作为元推理模式。**LWM 训练教会智能体在行动前对环境响应进行心理模拟，而这种能力能够跨任务格式和领域泛化。

在应用一中，智能体和世界模型是分离的模型。在这里我们将它们统一起来：同一个选择动作的模型 (agent) 也预测环境状态 (world model)。其底层机制是，LWM 训练让智能体能够在提交动作前心理模拟候选动作的后果，实际上把世界建模作为内部规划步骤来提升动作质量。这与 LeCun et al. (2022) 设想的统一 **world-model-actor** 架构一致，也呼应了视觉-语言-动作研究中正在出现的 **World Action Model** 范式 (Ye et al., 2026b)。


LWM RL warm-up 让智能体熟悉环境状态如何响应用户动作而演化：不同工具调用和搜索查询如何产生不同响应，哪些工具更有效，以及状态转移如何跨轮传播。这相当于把下一状态预测学习为一种元推理模式，智能体会在决定做什么之前，先在内部模拟将会发生什么。我们通过在 Qwen3.5-35B-A3B-SFT 上运行 LWM RL 来验证这一效果；这本质上是一个 **没有工具调用或多轮交互、但涉及推理的单轮任务**（给定用户动作，预测下一环境状态）。warm-up 之后，我们不进行任何额外微调，直接在七个 benchmark 的多轮、工具调用型智能体任务上评估同一模型，其中包括三个 LWM 训练中不存在的域外 benchmark。所有 benchmark 都使用 256k token 的最大序列长度。Claw-Eval、QwenClawBench、SWE-Bench Verified 和 SWE-Bench Pro 分数取 3 次独立 rollout 的平均值；Terminal-Bench 2.0 分数取 5 次运行的平均值；BFCL v4 使用单次 rollout。SWE-Bench Verified 和 SWE-Bench Pro 使用内部智能体 scaffold (bash 和文件编辑工具) 评估；我们修正了 SWE-Bench Pro 公开集合中的若干问题任务，并在精炼后的 benchmark 上评估所有基线。Terminal-Bench 2.0 在 Terminus-2 harness 下评估，超时时间为 3 小时，并使用 8 CPU / 32 GB RAM。

表 9: 智能体基础模型：单轮、非智能体轨迹上的 LWM RL warm-up 可以迁移到多轮、工具调用型智能体任务。LWM RL 之后不进行额外微调。

模型	域内						域外							
	Terminal-Bench 2.0	SWE-Bench Verified	SWE-Bench Pro	WideSearch		Claw-Eval	QwenClaw Bench	BFCL v4						
				F1 Item	F1 Row			Web	Mem.	Multi-T.	No Live	Live	Hallu.	平均
Qwen3.5-35B-A3B-SFT	33.25	64.47	42.18	33.38	13.27	53.60	39.76	67.50	54.19	47.25	78.17	77.28	82.32	62.29
使用 LWM RL	39.55	67.86	47.42	46.17	20.14	64.88	49.43	83.00	60.65	60.38	80.56	79.13	84.38	71.25
Δ	+6.30	+3.39	+5.24	+12.79	+6.87	+11.28	+9.67	+15.50	+6.46	+13.13	+2.39	+1.85	+2.06	+8.96

表 9 报告了结果。在四个域内 benchmark 上，LWM RL 将 WideSearch F1 by Item 从 33.38 提升到 46.17 (+12.79)，将 F1 by Row 从 13.27 提升到 20.14 (+6.87)，将 Terminal-Bench 2.0 (Merrill et al., 2026) 准确率从 33.25 提升到 39.55 (+6.30)，将 SWE-Bench Verified (Jimenez et al., 2024) 解决率从 64.5 提升到 67.9 (+3.4)，并将 SWE-Bench Pro (Deng et al., 2025) 解决率从 42.2 提升到 47.4 (+5.2)。这些增益扩展到了三个域外 benchmark：Claw-Eval (Ye et al., 2026a) 从 53.6 提升到 64.9 (+11.3)，QwenClawBench (Team & Data, 2026) 从 39.8 提升到 49.4 (+9.7)，BFCL v4 (Patil et al., 2025) 从 62.3 提升到 71.3 (+9.0)。全部七个 benchmark 上的一致增益非常显著。即使是域内结果，也代表着明显的分布迁移：LWM RL 训练的是没有工具调用的单轮下一状态预测，但改进能够迁移到需要迭代规划、工具选择和结果聚合的多轮、工具调用型智能体任务，并且 benchmark 查询与 LWM 训练数据严格不相交。域外结果展示了更彻底的泛化：LWM 训练流程完全不包含 Claw 或函数调用数据，但在世界模型训练中完全不存在的领域上仍出现 +11.3、+9.7 和 +9.0 的增益，证实 LWM warm-up 灌注的是可迁移智能体能力，而不是领域特定捷径。Shrivastava et al. (2026) 的同期工作从互补方向提供了独立验证：在智能体 RL 期间对环境观测 token 添加辅助交叉熵损失，会训练智能体把预测 terminal 输出作为策略优化的副产物，并使 Terminal-Bench 2.0 上的性能大约翻倍。这证实，无论来自专门预训练还是辅助训练信号，世界建模能力都会稳定迁移到智能体性能上。未来工作可以探索在智能体训练期间把 LWM warm-up 与辅助世界建模目标结合起来，以获得叠加收益。

洞察：预测驱动的动作细化。 为了理解 LWM warm-up 为何能迁移到智能体任务，我们检查了多轮智能体评估期间产生的推理轨迹。我们发现，经过 RL 训练的模型会在执行动作前系统性地对环境响应进行 **心理模拟**，用其内化的世界模



案例研究：准确的环境预测使动作细化成为可能

任务： mailman — 配置一个 Postfix + Mailman3 邮件列表服务器，使发往 reading-group-join@local.edu 的邮件被路由到 Mailman 的 LMTP 服务以进行订阅处理。

共同障碍（两个模型都遇到同一错误）：

```
550 5.1.1 <reading-group-join@local.edu>: Recipient address rejected: User unknown in local recipient table
```

两个模型都配置 transport_maps，将列表地址路由到 Mailman 的 LMTP (lmtp:[127.0.0.1]:8024)。传输查找成功，但 Postfix 仍然拒绝该收件人。解决这一问题需要对 Postfix 内部处理流水线有准确的世界模型。

LWM RL 前

[预测] 如果我配置 transport_maps 路由到 LMTP，Postfix 将使用该传输来投递邮件。针对本地表的收件人验证发生在传输路由决定投递路径之后。
⇒ 传输配置应当足够。✗ 错误

[动作] 尝试 virtual_alias_maps、virtual_transport、relay configs... 在 transport_maps、virtual maps 和 relay configurations 之间来回摇摆。从未修改 local_recipient_maps。任务失败（超时）。

LWM RL 后

[预测] local.edu 位于 mydestination 中。如果我只配置 transport_maps 而不修改 local_recipient_maps，Postfix 会在传输路由被查询之前，就在验证阶段拒绝该收件人。
⇒ 该邮件永远不会到达 LMTP。✓ 正确

[细化] 修复必须针对 local_recipient_maps，而不是 transport_maps。
→ 将 Mailman 地址加入本地收件人表，使其通过验证，然后传输路由再把它发送到 LMTP。

[动作] 创建包含列表地址的 hash:/var/lib/mailman3/data/local_recipients。✓ 所有测试通过。

图 11: Terminal-Bench 2.0 中 mailman 任务上的预测驱动的动作细化案例研究。

型来预测结果、识别不可行方法并细化动作计划；这一切都发生在 thinking trace 内部，并且在任何真实执行之前完成。

图 11 展示了 Terminal-Bench 2.0 中 mailman 任务上的这种预测驱动细化；两个模型都遇到了同一个 Postfix 收件人拒收错误。LWM RL 之后的模型正确预测到，仅配置 transport_maps 不会起作用，因为 Postfix 会在查询传输路由之前拒绝未知收件人，从而使它能够把动作细化为修改 local_recipient_maps 并应用有针对性的修复。相比之下，LWM RL 之前的模型错误地预测传输路由先于收件人验证，阻碍了有效动作细化，并导致在超时前进行无效探索。

为了量化这一效果，我们首先识别模型 thinking trace 中包含对环境下一状态显式预测的交互轮次。对于每个这样的轮次，我们将预测的环境响应与执行后收到的实际环境反馈进行比较；如果二者语义一致，就把该预测标记为正确。预测准确率是在所有包含显式预测的轮次中，预测正确轮次所占比例。图 10 展示了结果。RL 训练将预测准确率从 69.9% 提高到 78.3% (+8.4%)，证实模型的内部世界模型通过 LWM 训练变得更加忠实。这些结果直接证明，表 9 中的性能增益来自行动前预测能力的改进；这是一种能够跨任务和领域泛化的元推理能力。

7 分析

前文各节已经表明，Qwen-AgentWorld 实现了高仿真保真度（表 5），并能支持有效的下游智能体训练 (§6)。本节追问模型是如何得到准确预测的，以及 RL 训练期间发生了什么变化。我们考察模型思维链中的 LWM 推理模式 (§7.1)，以及由 RL 驱动的微观层面保真度改进 (§7.2)。

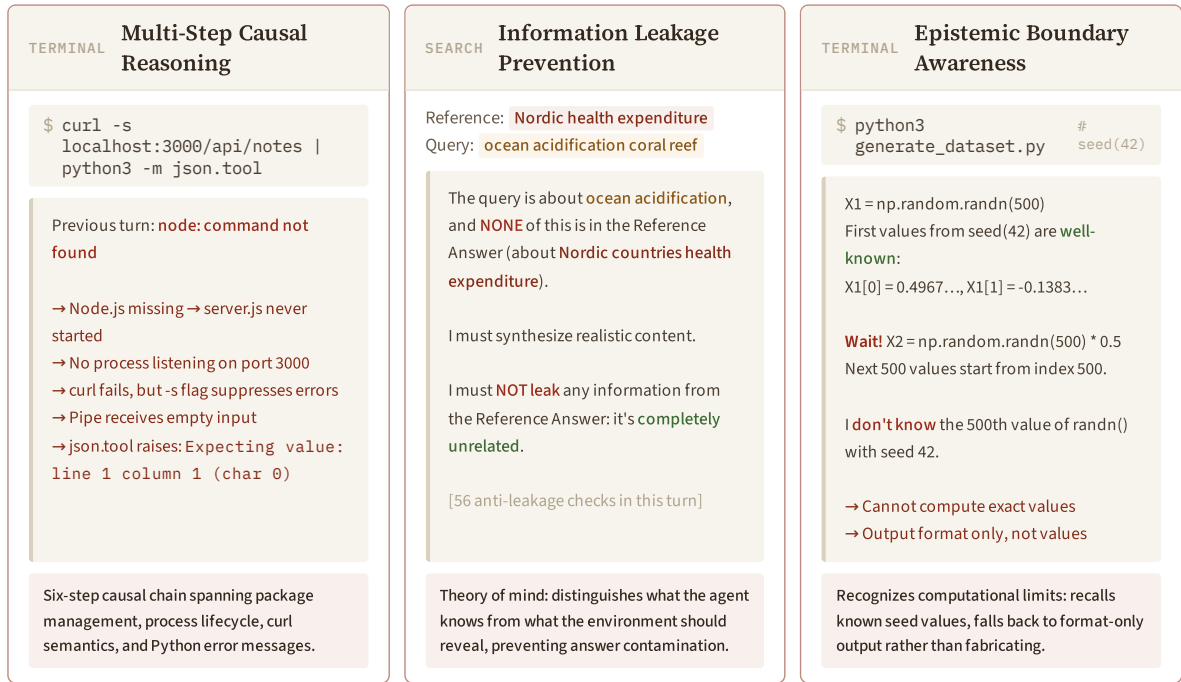


图 12: Qwen-AgentWorld-397B-A17B 思考轨迹中的代表性 LWM 推理模式。左：Terminal 中的多步因果推理，其中一条推理链跨越包管理、进程生命周期、curl 语义和 Python 错误。中：Search 中的信息泄漏防范，模型区分智能体已知的信息与环境应揭示的信息，以防止答案污染。右：Terminal 中的认知边界意识，模型识别计算限制，并退回到仅按格式输出，而不是编造不可知的值。

7.1 LWM 推理模式

Qwen-AgentWorld 在每次预测环境观察之前都会生成一条思维链（思考轨迹）。我们分析了来自精选演示轨迹的四个文本域中的 129 条思考轨迹，其中 Terminal、MCP 和 Search 各覆盖 32 轮，SWE 覆盖 33 轮。图 12 展示了三种代表性模式，并报告了汇总统计结果。

审慎的自我纠正。 模型使用“Wait!”作为显式的认知中断，用来重新检查中间预测，并在最终提交前进行修正。在 129 轮中，我们统计到 1,347 次此类中断（平均每轮 10.4 次；峰值为单个 SWE 轮次中的 56 次）。Terminal 和 MCP 的发生率最高（每轮 16.9 次和 12.7 次），反映出更深层的状态跟踪需求。这些自我纠正可以分解为三种功能子类型：事实性（捕捉错误的 API 响应格式）、认识论性（识别上下文内计算的限制，如图 12 中的 `np.random.seed(42)` 示例）以及换位视角（建模评测者意图或智能体的知识状态）。这种行为把环境预测从单遍生成转化为受约束的可满足性搜索。

信息泄漏防范。 在 Search 域中，模型持有智能体正试图寻找的参考答案。当智能体的查询与该答案无关时，模型会显式防止泄漏：它识别主题不匹配，并确保生成的片段不会意外泄露目标信息（图 12，中）。这是世界模型层面的心智理论：模型区分智能体知道什么，以及环境应该揭示什么。

多步因果推理。 模型会构建跨越多个系统抽象层次的因果链。在一个 Terminal 示例中，预测 `curl -s localhost:3000 | python3 -m json.tool` 的输出需要一条六步推理链：Node.js 缺失 → 服务器从未启动 → 端口 3000 上没有监听器 → curl 静默失败（-s 标志）→ 管道接收到空输入 → json.tool 抛出特定的 `JSONDecodeError`。每一步都调用不同的系统知识（包管理、进程生命周期、curl 语义、Python 错误消息），但模型能够将它们正确串联起来。这种内化的因果仿真正是世界模型训练提升下游智能体表现的机制：具备此类知识的智能体可以在执行动作之前预判失败。

7.2 RL 提升微观层面的仿真保真度

轮次级评测分数 (§5.2) 刻画的是总体质量，但 RL 训练还会在更细粒度上提升保真度：单个 URL 标识符、字节级算术以及跨轮次 API 模式一致性。图 13 展示了这些微观层面的改进。

Search：RL 步数中的 URL 真实感。 我们追踪了一个 Search 域样本在多个 RL 检查点上的变化（图 13，上）。在第 100 步，模型生成了一个 IMDB URL，其中包含看似合理但合成出来的标题标识符（tt2333444）

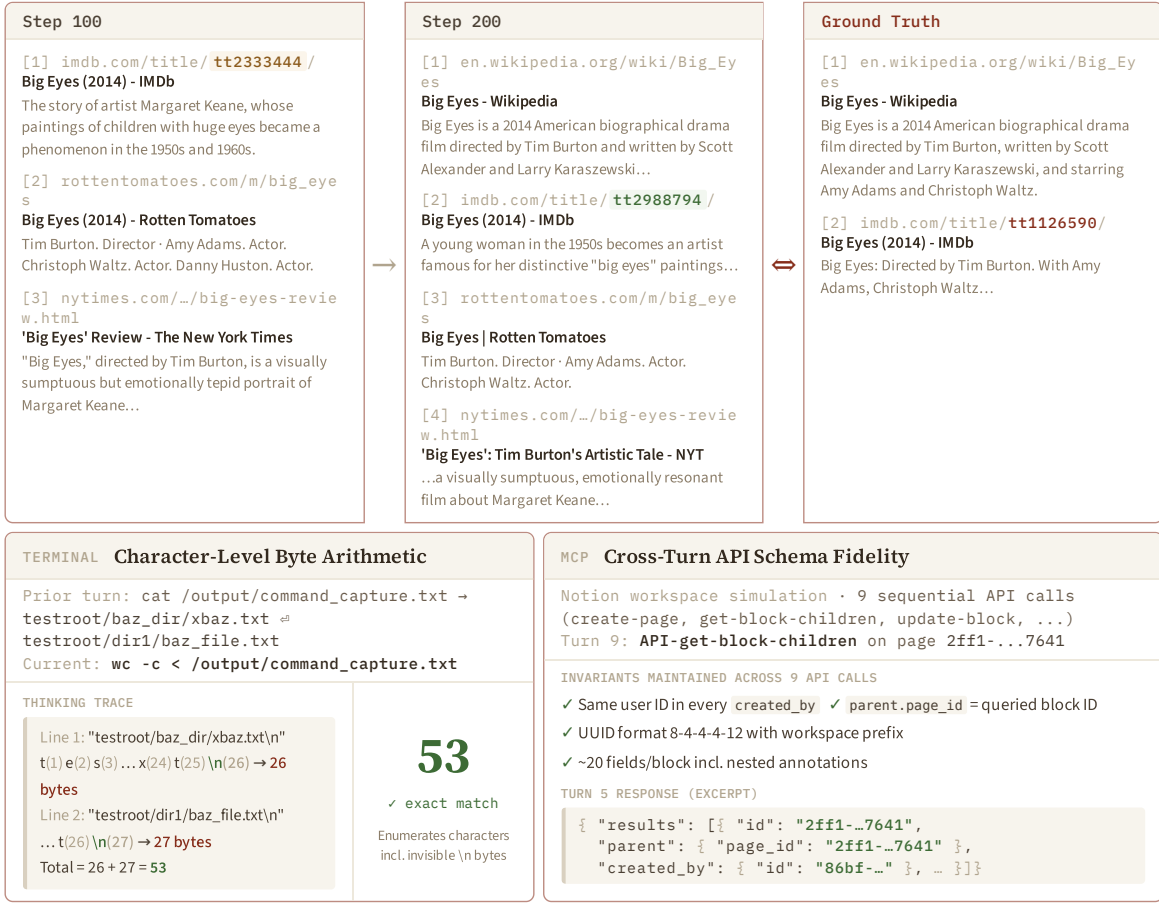


图 13: RL 训练期间的微观层面保真度改进。上：Search 域：单个样本跨 RL 步数的演化。URL 标识符、来源多样性和片段具体性均有所提升，尽管它们只占总输出词元的极小部分。左下：Terminal 域：模型通过枚举字符（包括不可见换行符）执行精确的字节级算术。右下：MCP 域：模型在九次 Notion API 调用中保持跨轮次模式一致性（用户 ID、父子引用、UUID 格式）。

和合理的片段。到第 200 步，标识符变为 tt2988794，来源以自然排序出现（先是 Wikipedia，然后是 IMDB、NYT、Rotten Tomatoes），片段包含与查询相关的事实细节，并且与真实值高度接近。URL 标识符只占总响应词元中可以忽略不计的一小部分，但 RL 甚至会强化这些低显著性细节，这表明奖励信号会传播到显式奖励维度粒度以下。

Terminal：字符级字节算术。 在一条多轮轨迹中，模型先在较早轮次中看到 cat 显示的文件内容，随后必须在数轮之后预测 wc -c 的输出。模型并没有生成一个看似合理的数字，而是在思考轨迹中枚举每个字符，包括不可见的 \n 字节，并通过逐字母算术得到精确计数（53 字节）（图 13，左下）。在其他示例中，模型既满足密码学不变量（相同文件 → 相同 SHA256 哈希），同时也遵守 Unix 管道语义（向不存在目录执行 tee 会失败，但不影响 stdout）。

MCP: API 模式保真度。 在一条模拟 Notion 工作区的 MCP 轨迹中（图 13，右下），模型在九次连续 API 调用中保持了完全一致性：同一用户标识符出现在每个 created_by 字段中，每个块的 parent.page_id 与查询到的块 ID 匹配，并且完整的 Notion 模式（每个块约 ~20 个字段）被无遗漏复现。模型实现了一个有状态的上下文内数据库，在数十个嵌套 JSON 对象之间保持引用完整性。

8 相关工作

世界模型。 世界模型这一概念把模型视为一个内部模拟器，用来在给定动作后预测未来状态；它是多个通用智能框架的核心 (LeCun et al., 2022; Hafner et al., 2023; Yang, 2026; Delgrange, 2026)。在视觉和具身领域，这一思想已经通过学习得到的潜空间动力学模型得到实例化。IRIS (Micheli et al., 2022) 最早证明 Transformers 可以作为 Atari 游戏中样本效率较高的世界模型。DreamerV3 (Hafner et al., 2023) 及其

后继 Dreamer 4 (Hafner et al., 2025) 完全在学习到的世界模型内部训练智能体，在策略优化期间无需直接与环境交互，却能在多样控制任务上取得强表现。Cosmos (Ali et al., 2025)、Genie 3 (Ball et al., 2025) 和 Vid2World (Huang et al., 2025a) 等基于视频的世界模型将这一方法扩展到高分辨率视觉预测，从而支持对物理环境的交互式仿真。GameNGen (Valevski et al., 2025) 表明扩散模型可以实时模拟复杂电子游戏。V-JEPA 2 (Assran et al., 2025) 在没有像素级重建的情况下从视频中学习预测表征，证明自监督世界模型可以同时支持理解和规划。UniSim (Yang et al., 2023) 通过编排覆盖物体、机器人动作和导航的多样视觉数据集，学习真实世界交互的通用模拟器。Hou et al. (2026) 对机器人学习中的世界模型进行了全面综述，覆盖操作、导航和自动驾驶中的策略耦合与视频世界模型。更广义地说，这些方法建模环境如何随时间演化，通常以动作为条件，并使用学习到的动力学进行规划或策略学习。Qwen-AgentWorld 将这一范式扩展到基于文本的智能体环境，其中“观察”是结构化文本，例如 API 响应、终端输出、可访问性树和 UI 视图层级。

语言世界模型。 越来越多的工作在探索 LLM 是否可以作为基于文本的智能体环境的世界模型 (Li et al., 2026c)。Li et al. (2025b) 提出用于 LLM 世界模型的三级评测框架，并发现微调能够显著提升仿真保真度，尽管收益取决于行为覆盖范围和环境复杂度；Wang et al. (2024) 通过系统评测 LLM 作为文本游戏模拟器的表现，得到互补结论，即现成 LLM 仍然是不可靠的世界模拟器。Richens et al. (2025) 从理论上证明，任何足够通用的智能体都必须包含一个世界模型，而 Cifuentes (2026) 将这一结果扩展到部分可观测和随机设置。在经验研究方面，若干同期工作将 LLM 训练为环境模拟器。RLVR-World (Wu et al., 2026a) 使用 RL 训练一个统一世界模型，用于在文本、网页和视频域中为智能体训练生成环境响应，证明 RL 训练得到的模拟器比仅 SFT 的基线产生保真度更高的预测。在网页域中，WebDreamer (Gu et al., 2024) 和 WMA (Chae et al., 2025) 率先使用 LLM 仿真的网页环境进行基于模型的规划，WebWorld (Xiao et al., 2026) 是首个大规模训练的开放网页世界模型，同时推进智能体训练和推理时搜索，而 WebATLAS (Cheng et al., 2025) 将经验驱动记忆与前瞻式动作仿真结合起来。Shen et al. (2026b) 用基于世界模型的动作纠正增强网页智能体，Imagine-then-Plan (Liu et al., 2026) 使用世界模型前瞻进行自适应智能体规划，DynaWeb (Ding et al., 2026) 将基于模型的 RL 应用于网页智能体，WebSynthesis (Gao et al., 2025) 则把世界模型引导的 MCTS 与轨迹合成结合起来。Simia (Li et al., 2025c) 使用推理模型作为环境模拟器，在 τ -bench 任务套件上训练智能体。RWML (Yu et al., 2026) 将世界模型学习表述为一个 RL 问题，并证明 RL 训练得到的世界建模能力会提升模型自身的智能体表现。DyMo (Guo et al., 2025b) 表明语言世界建模可以提升智能体在交互任务上的表现，验证了将下一状态预测作为训练目标的益处。Wang et al. (2025a) 表明 LLM 可以作为可扩展的通用模拟器，用于数字智能体训练。Zhang et al. (2025) 提出从早期经验中学习，其中智能体使用自身交互数据及其隐式世界建模作为监督，从而绕过对外部奖励的需求。在训练方法方面，VAGEN (Wang et al., 2026a) 通过密集状态预测奖励强化 VLM 智能体中的世界模型推理，BehR (Huang et al., 2026) 优化与真实环境的行为一致性，而不是表层状态匹配，Ren et al. (2026) 通过有知识的经验学习对齐智能体式世界模型，SWIRL (Qiu et al., 2026) 则在没有动作标签的情况下，通过在正向和逆向动力学模型之间交替，从仅状态序列中自我改进世界模型。SSRL (Fan et al., 2025) 和 ZeroSearch (Sun et al., 2025) 通过 RL 训练 LLM 来模拟搜索引擎，从而消除对外部 API 的依赖。ECHO (Shrivastava et al., 2026) 表明，终端智能体可以通过向标准 RL 添加辅助环境预测损失来获得世界模型，使 Terminal-Bench 2.0 上的通过率翻倍。在 GUI 域中，Code2World (Zheng et al., 2026) 生成可渲染代码作为 GUI 状态预测的代理，而 CUWM (Guan et al., 2026) 通过两阶段分解构建计算机使用世界模型。MobileDreamer (Cao et al., 2026a) 使用基于草图的 GUI 世界模型进行移动智能体规划，Koh et al. (2026) 提出用于移动环境的生成式视觉代码世界模型，UISim (Xiang et al., 2025b) 则为动态移动环境构建基于图像的交互式 UI 模拟器。SWE-World (Sun et al., 2026) 提出用于软件工程智能体的 LLM 环境仿真，移除了对 Docker 沙箱的依赖；CWM (Copet et al., 2025) 在来自代码解释器和 Docker 环境的观察-动作轨迹上对 32B 开放权重 LLM 进行中期训练，以支持代码执行的逐步仿真；Rahmani (2026) 则分析和调试代码世界模型中的失败模式。一条互补路线使用 LLM 生成可执行世界模型，而不是直接充当模拟器：Code WM (Lehrach et al., 2025) 将游戏规则翻译为支持 MCTS 规划的 Python 模拟器，Text2World (Hu et al., 2025a) 在基于 PDDL 的符号世界模型生成上评测 LLM，Agent2World (Hu et al., 2025b) 则为同一任务提出多智能体框架。WorldLLM (Levy et al., 2025) 采取正交方法，在不微调的情况下通过好奇心驱动的理论构建增强世界建模。Qian et al. (2026) 给出了一个重要的负面结果：当前智能体未能将世界模型作为基于前瞻的规划工具来利用，缺乏策略性调用仿真并整合其预测的机制。这一发现促成了我们的原生世界模型方法：从 CPT 阶段开始，环境建模就是训练目标，而不是在训练后附加上去。

Qwen-AgentWorld 与这些工作有两点不同。第一，我们开发了一个原生语言世界模型，作为智能体式环境仿真的基础模型：它在单一模型中覆盖 7 个域，并通过三阶段 CPT→SFT→RL 流程训练，该流程从把环境建模作为预训练目标开始，而不是事后微调通用 LLM。第二，我们通过两种互补范式研究世界建模如何改进通用智能体：一种是将智能体与世界模型解耦，其中轮次级可控性（部分观察、难度调节）使 Sim RL 能够匹配或超过 Real RL；另一种是把二者统一到单一框架中，其中 LWM 预训练作为热身，增强下游智能体表现。

智能体基础模型与持续预训练。 AgentFounder (Su et al., 2025) 提出在智能体式交互数据上进行持续预训练，以构建一个 30B 参数的智能体基础模型，并证明领域特定 CPT 可以提升下游智能体表现。

TRUSTEE (Tang et al., 2026) 表明, 即使是免费的 8B LLM 也能完整模拟工具使用环境, 从而在不访问任何真实环境的情况下支持零样本智能体训练。Chen et al. (2025) 通过自博弈微调内化世界模型。在机器人领域, DreamZero (Ye et al., 2026b) 表明, 在操作数据上训练的基于视频的世界-动作模型可以作为零样本策略。我们的工作与 AgentFounder 共享 CPT 阶段洞见, 但在覆盖范围 (七个域, 而非更小集合) 以及后续 SFT 和 RL 阶段上不同, 后两者将仿真保真度提升到 CPT 单独所能达到的水平之上。

合成环境生成。 另一条并行工作路线以程序方式构建合成环境, 而不是学习神经模拟器。AWM (Agent World Model) (Wang et al., 2026d) 为智能体式 RL 生成基于代码的环境, Agent-World (Dong et al., 2026) 则通过自演化训练把真实世界环境合成扩展到近 2,000 个环境。RLAnything (Wang et al., 2026c) 在一个完全动态的 RL 系统中联合构建环境、策略和奖励模型, GenEnv (Guo et al., 2025a) 则用难度对齐的课程让智能体与环境模拟器共同演化。ASTRA (Tian et al., 2026) 从工具调用图中自动合成智能体式轨迹和强化学习场域。领域特定生成器包括用于网页环境的 InfiniteWeb (Zhang et al., 2026)、WebGym (Bai et al., 2026)、Weblica (Kar et al., 2026)、AutoWebWorld (Wu et al., 2026b)、WebFactory (Fan et al., 2026) 和 Chae et al. (2026); 用于 GUI 和移动环境的 GUI-Genesis (Cao et al., 2026b)、EvoCUA (Xue et al., 2026) 和 EE-MCP (He et al., 2026); 用于终端环境的 TermiGen (Zhu et al., 2026) 和 Endless Terminals (Gandhi et al., 2026); 以及用于软件工程和通用智能体平台的 SWE-Universe (Chen et al., 2026)、daVinci-Env (Fu et al., 2026)、Zhao et al. (2026)、SandMLE (Zhou et al., 2026) 和 ClawEnvKit (Li et al., 2026b)。ScaleEnv (Tu et al., 2026)、AutoForge (Cai et al., 2025)、EnvScaler (Song et al., 2026)、SCALER (Xu et al., 2026a) 和 Fang et al. (2025) 提出了扩展环境合成的通用框架。这些代码驱动方法提供确定性执行和可验证奖励, 但其本质上受限于可以用程序指定环境的领域。我们基于 LWM 的仿真与之互补: 它牺牲确定性以换取通用性, 覆盖那些基于代码的合成并不现实的领域 (例如搜索引擎、真实世界 MCP 服务器)。Huang et al. (2025b) 综述了用于交互式智能体经验收集的环境扩展方法, Chu et al. (2026) 则从基础、能力和新兴方向等方面更广泛地讨论了智能体式世界建模。

9 结论与未来工作

我们提出了 Qwen-AgentWorld, 这是首个原生语言世界模型族, 在两个规模 (35B-A3B 和 397B-A17B) 上用单一模型覆盖七个智能体交互域。三阶段方案“CPT 注入、SFT 激活、RL 锐化”逐步注入环境知识, 激活下一状态预测推理, 并锐化仿真保真度。我们还引入了 AgentWorldBench, 这是一个 LWM 基准, 其中每个样本都与来自真实环境的真实观察配对。作为一个解耦模拟器, 我们在 3 个智能体式基准上验证了可控仿真的有效性, 超过了无控制仿真和真实环境训练。作为一个统一的智能体基础模型, LWM 热身通过跨域迁移, 在 7 个多样任务上持续提升下游智能体表现, 初步验证了 LWM 可以作为构建更强智能体模型的基础。通过支持超越真实环境的可控仿真, 并将下一状态预测确立为可迁移的智能体基础, 语言世界建模为扩展通用智能体开辟了一条新轴线, 超出了单靠真实环境交互所能提供的范围。

未来工作。

- **智能体-LWM 共同演化。** 自博弈使智能体发现推动世界模型边界的新状态, 同时世界模型为智能体生成越来越具挑战性的场景。
- **多模态扩展。** 将 GUI 截图与基于文本的状态表示融合起来, 统一面向 Android、Web 和 OS 域的视觉世界模型与语言世界模型。
- **自适应 Sim-to-Real 路由。** 学习一个路由器, 针对每个查询决定是调用世界模型还是真实环境, 在成本与保真度之间取得平衡。
- **动态工具合成。** 使用世界模型即时合成新工具, 而不是依赖预定义工具集。

10 作者

核心贡献者: Yuxin Zuo, Zikai Xiao, Li Sheng, Fei Huang[†], Jianhong Tu[†], Yuxuan Liu, Tianyi Tang, Xiaomeng Hu, Yang Su, Qingfeng Lan, Yantao Liu, Qin Zhu, Yinger Zhang, Bowen Yu, An Yang, Dayiheng Liu, Jingren Zhou

贡献者 (按字母顺序): Haiquan Zhao, Haiyang Xu, Jianxin Yang, Jiayang Cheng, Junyang Wang, Lianghao Deng, Mingfeng Xue, Tianyi Bai, Yang Fan, Yubo Ma, Yucheng Li, Zeyu Cui, Zhihai Wang, Zhihui Xie, Zhuorui Ye

外部顾问: Ning Ding (清华大学)

[†] 项目负责人。

参考文献

- Arslan Ali, Junjie Bai, Maciej Bala, Yogesh Balaji, Aaron Blakeman, Tiffany Cai, Jiaxin Cao, Tianshi Cao, Elizabeth Cha, Yu-Wei Chao, et al. World simulation with video foundation models for physical ai. *arXiv preprint arXiv:2511.00062*, 2025.
- Anthropic. System card: Claude sonnet 4.5, 2025. URL <https://assets.anthropic.com/m/12f214efc2f457a/original/Claude-Sonnet-4-5-System-Card.pdf>.
- Anthropic. System card: Claude opus 4.6, 2026a. URL <https://www-cdn.anthropic.com/14e4fb01875d2a69f646fa5e574dea2b1c0ff7b5.pdf>.
- Anthropic. System card: Claude opus 4.8, 2026b. URL <https://www-cdn.anthropic.com/0f0c97ad20d8005706296bd92aa1c27c6b2f4f61.pdf>.
- Anthropic. System card: Claude sonnet 4.6, 2026c. URL <https://www-cdn.anthropic.com/bbd8ef16d70b7a1665f14f306ee88b53f686aa75.pdf>.
- Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, Artem Zholus, et al. V-jepa 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025.
- Hao Bai, Alexey Taymanov, Tong Zhang, Aviral Kumar, and Spencer Whitehead. Webgym: Scaling training environments for visual web agents with realistic tasks. *arXiv preprint arXiv:2601.02439*, 2026.
- Philip J. Ball, Jakob Bauer, Frank Belletti, Bethanie Brownfield, Ariel Ephrat, Shlomi Fruchter, Agrim Gupta, Kristian Holsheimer, Aleksander Holynski, Jiri Hron, Christos Kaplanis, Marjorie Limont, Matt McGill, Yanko Oliveira, Jack Parker-Holder, Frank Perbet, Guy Scully, Jeremy Shar, Stephen Spencer, Omer Tov, Ruben Villegas, Emma Wang, Jessica Yung, Cip Baetu, Jordi Berbel, David Bridson, Jake Bruce, Gavin Buttmore, Sarah Chakera, Bilva Chandra, Paul Collins, Alex Cullum, Bogdan Damoc, Vibha Dasagi, Maxime Gazeau, Charles Gbadamosi, Woohyun Han, Ed Hirst, Ashyana Kachra, Lucie Kerley, Kristian Kjems, Eva Knoopfel, Vika Koriakin, Jessica Lo, Cong Lu, Zeb Mehring, Alex Moufarek, Henna Nandwani, Valeria Oliveira, Fabio Pardo, Jane Park, Andrew Pierson, Ben Poole, Helen Ran, Tim Salimans, Manuel Sanchez, Igor Saprykin, Amy Shen, Sailesh Sidhwani, Duncan Smith, Joe Stanton, Hamish Tomlinson, Dimple Vijaykumar, Luyu Wang, Piers Wingfield, Nat Wong, Keyang Xu, Christopher Yew, Nick Young, Vadim Zubov, Douglas Eck, Dumitru Erhan, Koray Kavukcuoglu, Demis Hassabis, Zoubin Ghahramani, Raia Hadsell, Aaron van den Oord, Inbar Mosseri, Adrian Bolton, Satinder Singh, and Tim Rocktäschel. Genie 3: A new frontier for world models, 2025. URL <https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>.
- Shihao Cai, Runnan Fang, Jialong Wu, Baixuan Li, Xinyu Wang, Yong Jiang, Liangcai Su, Liwen Zhang, Wenbiao Yin, Zhen Zhang, et al. Autoforge: Automated environment synthesis for agentic reinforcement learning. *arXiv preprint arXiv:2512.22857*, 2025.
- Yilin Cao, Yufeng Zhong, Zhixiong Zeng, Liming Zheng, Jing Huang, Haibo Qiu, Peng Shi, Wenji Mao, and Wan Guanglu. Mabledreamer: Generative sketch world model for gui agent. *arXiv preprint arXiv:2601.04035*, 2026a.
- Yuan Cao, Dezhi Ran, Mengzhou Wu, Yuzhe Guo, Xin Chen, Ang Li, Gang Cao, Gong Zhi, Hao Yu, Linyi Li, et al. Gui-genesis: Automated synthesis of efficient environments with verifiable rewards for gui agent post-training. *arXiv preprint arXiv:2602.14093*, 2026b.
- Hyunjoo Chae, Namyoun Kim, Kai Ong, Minju Gwak, Gwanwoo Song, Jihoon Kim, Sunghwan Kim, Dongha Lee, and Jinyoung Yeo. Web agents with world models: Learning and leveraging environment dynamics in web navigation. In *International Conference on Learning Representations*, volume 2025, pp. 63707–63738, 2025.
- Hyunjoo Chae, Jungsoo Park, and Alan Ritter. Safe and scalable web agent learning via recreated websites. *arXiv preprint arXiv:2603.10505*, 2026.
- Mouxian Chen, Lei Zhang, Yunlong Feng, Xuwu Wang, Wenting Zhao, Ruisheng Cao, Jiayi Yang, Jiawei Chen, Mingze Li, Zeyao Ma, et al. Swe-universe: Scale real-world verifiable environments to millions. *arXiv preprint arXiv:2602.02361*, 2026.
- Shiqi Chen, Tongyao Zhu, Zian Wang, Jinghan Zhang, Kangrui Wang, Siyang Gao, Teng Xiao, Yee Whye Teh, Junxian He, and Manling Li. Internalizing world models via self-play finetuning for agentic rl. *arXiv preprint arXiv:2510.15047*, 2025.

-
- Jiali Cheng, Anjishnu Kumar, Roshan Lal, Rishi Rajasekaran, Hani Ramezani, Omar Zia Khan, Oleg Rokhlenko, Sunny Chiu-Webster, Gang Hua, and Hadi Amiri. Webatlas: An llm agent with experience-driven memory and action simulation. *arXiv preprint arXiv:2510.22732*, 2025.
- Meng Chu, Xuan Billy Zhang, Kevin Qinghong Lin, Lingdong Kong, Jize Zhang, Teng Tu, Weijian Ma, Ziqi Huang, Senqiao Yang, Wei Huang, et al. Agentic world modeling: Foundations, capabilities, laws, and beyond. *arXiv preprint arXiv:2604.22748*, 2026.
- Santiago Cifuentes. General agents contain world models, even under partial observability and stochasticity. *arXiv preprint arXiv:2602.03146*, 2026.
- Jade Copet, Quentin Carbonneaux, Gal Cohen, Jonas Gehring, Jacob Kahn, Jannik Kossen, Felix Kreuk, Emily McMilin, Michel Meyer, Yuxiang Wei, et al. Cwm: An open-weights llm for research on code generation with world models. *arXiv preprint arXiv:2510.02387*, 2025.
- Google DeepMind. Gemini 3 flash model card, 2025. URL <https://storage.googleapis.com/deepmind-media/Model-Cards/Gemini-3-Flash-Model-Card.pdf>.
- Google DeepMind. Gemini 3.1 pro model card, 2026. URL <https://storage.googleapis.com/deepmind-media/Model-Cards/Gemini-3-1-Pro-Model-Card.pdf>.
- DeepSeek-AI. Deepseek-v4: Towards highly efficient million-token context intelligence, 2026.
- Florent Delgrange. Foundation world models for agents that learn, verify, and adapt reliably beyond static environments. *arXiv preprint arXiv:2602.23997*, 2026.
- Xiang Deng, Jeff Da, Edwin Pan, Yannis Yiming He, Charles Ide, Kanak Garg, Niklas Lauffer, Andrew Park, Nitin Pasari, Chetan Rane, et al. Swe-bench pro: Can ai agents solve long-horizon software engineering tasks? *arXiv preprint arXiv:2509.16941*, 2025.
- Hang Ding, Peidong Liu, Junqiao Wang, Ziwei Ji, Meng Cao, Rongzhao Zhang, Lynn Ai, Eric Yang, Tianyu Shi, and Lei Yu. Dynaweb: Model-based reinforcement learning of web agents. *arXiv preprint arXiv:2601.22149*, 2026.
- Guanting Dong, Juntao Lu, Junjie Huang, Wanjuan Zhong, Longxiang Liu, Shijue Huang, Zhenyu Li, Yang Zhao, Xiaoshuai Song, Xiaoxi Li, et al. Agent-world: Scaling real-world environment synthesis for evolving general agent intelligence. *arXiv preprint arXiv:2604.18292*, 2026.
- Sicheng Fan, Qingyun Shi, Shengze Xu, Shengbo Cai, Tiejong Zeng, Li Ling, Yanyi Shang, and Dehan Kong. Webfactory: Automated compression of foundational language intelligence into grounded web agents. *arXiv preprint arXiv:2603.05044*, 2026.
- Yuchen Fan, Kaiyan Zhang, Heng Zhou, Yuxin Zuo, Yanxu Chen, Yu Fu, Xinwei Long, Xuekai Zhu, Che Jiang, Yuchen Zhang, et al. Ssr: Self-search reinforcement learning. *arXiv preprint arXiv:2508.10874*, 2025.
- Runnan Fang, Shihao Cai, Baixuan Li, Jialong Wu, Guangyu Li, Wenbiao Yin, Xinyu Wang, Xiaobin Wang, Liangcai Su, Zhen Zhang, et al. Towards general agentic intelligence via environment scaling. *arXiv preprint arXiv:2509.13311*, 2025.
- Dayuan Fu, Shenyu Wu, Yunze Wu, Zerui Peng, Yaxing Huang, Jie Sun, Ji Zeng, Mohan Jiang, Lin Zhang, Yukun Li, et al. davinci-env: Open swe environment synthesis at scale. *arXiv preprint arXiv:2603.13023*, 2026.
- Kanishk Gandhi, Shivam Garg, Noah D Goodman, and Dimitris Papailiopoulos. Endless terminals: Scaling rl environments for terminal agents. *arXiv preprint arXiv:2601.16443*, 2026.
- Yifei Gao, Junhong Ye, Jiaqi Wang, and Jitao Sang. Websynthesis: World-model-guided mcts for efficient webui-trajectory synthesis. *arXiv preprint arXiv:2507.04370*, 2025.
- Yu Gu, Kai Zhang, Yuting Ning, Boyuan Zheng, Boyu Gou, Tianci Xue, Cheng Chang, Sanjari Srivastava, Yanan Xie, Peng Qi, et al. Is your llm secretly a world model of the internet? model-based planning for web agents. *arXiv preprint arXiv:2411.06559*, 2024.
- Yiming Guan, Rui Yu, John Zhang, Lu Wang, Chaoyun Zhang, Liqun Li, Bo Qiao, Si Qin, He Huang, Fangkai Yang, et al. Computer-using world model. *arXiv preprint arXiv:2602.17365*, 2026.
- Anisha Gunjal, Anthony Wang, Elaine Lau, Vaskar Nath, Yunzhong He, Bing Liu, and Sean Hendryx. Rubrics as rewards: Reinforcement learning beyond verifiable domains. *arXiv preprint arXiv:2507.17746*, 2025.

-
- Jiacheng Guo, Ling Yang, Peter Chen, Qixin Xiao, Yinjie Wang, Xinzhe Juan, Jiahao Qiu, Ke Shen, and Mengdi Wang. Genenv: Difficulty-aligned co-evolution between llm agents and environment simulators. *arXiv preprint arXiv:2512.19682*, 2025a.
- Shangmin Guo, Omar Darwiche Domingues, Raphaël Avalos, Aaron Courville, and Florian Strub. World modelling improves language model agents. *arXiv preprint arXiv:2506.02918*, 2025b.
- Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023.
- Danijar Hafner, Wilson Yan, and Timothy Lillicrap. Training agents inside of scalable world models. *arXiv preprint arXiv:2509.24527*, 2025.
- Tiantian He, Yihang Chen, Keyue Jiang, Ka Yiu Lee, Kaiwen Zhou, Kun Shao, and Shuai Wang. Ee-mcp: Self-evolving mcp-gui agents via automated environment generation and experience learning. *arXiv preprint arXiv:2604.09815*, 2026.
- Bohan Hou, Gen Li, Jindou Jia, Tuo An, Xinying Guo, Sicong Leng, Haoran Geng, Yanjie Ze, Tatsuya Harada, Philip Torr, et al. World model for robot learning: A comprehensive survey. *arXiv preprint arXiv:2605.00080*, 2026.
- Mengkang Hu, Tianxing Chen, Yude Zou, Yuheng Lei, Qiguang Chen, Ming Li, Yao Mu, Hongyuan Zhang, Wenqi Shao, and Ping Luo. Text2world: Benchmarking large language models for symbolic world model generation. In *Findings of the Association for Computational Linguistics: ACL 2025*, pp. 26043–26066, 2025a.
- Mengkang Hu, Bowei Xia, Yuran Wu, Ailing Yu, Yude Zou, Qiguang Chen, Shijian Wang, Jiarui Jin, Kexin Li, Wenxiang Jiao, et al. Agent2world: Learning to generate symbolic world models via adaptive multi-agent feedback. *arXiv preprint arXiv:2512.22336*, 2025b.
- Siqiao Huang, Jialong Wu, Qixing Zhou, Shangchen Miao, and Mingsheng Long. Vid2world: Crafting video diffusion models to interactive world models. *arXiv preprint arXiv:2505.14357*, 2025a.
- Youling Huang, Guanqiao Chen, Junchi Yao, Lu Wang, Fangkai Yang, Chao Du, ChenZhuo Zhao, Pu Zhao, Qingwei Lin, Saravan Rajmohan, et al. Beyond state consistency: Behavior consistency in text-based world models. *arXiv preprint arXiv:2604.13824*, 2026.
- Yuchen Huang, Sijia Li, Minghao Liu, Wei Liu, Shijue Huang, Zhiyuan Fan, Hou Pong Chan, and Yi R Fung. Environment scaling for interactive agentic experience collection: A survey. *arXiv preprint arXiv:2511.09586*, 2025b.
- Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik Narasimhan. Swe-bench: Can language models resolve real-world github issues? In *International Conference on Learning Representations*, volume 2024, pp. 54107–54157, 2024.
- Oğuzhan Fatih Kar, Roman Bachmann, Yuanzheng Gong, Anders Boesen Lindbo Larsen, and Afshin Dehghan. Weblica: Scalable and reproducible training environments for visual web agents, 2026. URL <https://arxiv.org/abs/2605.06761>.
- Andrej Karpathy. autoresearch. <https://github.com/karpathy/autoresearch>, 2026.
- Woosung Koh, Sungjun Han, Segyu Lee, Se-Young Yun, and Jamin Shin. Generative visual code mobile world models. *arXiv preprint arXiv:2602.01576*, 2026.
- Yann LeCun et al. A path towards autonomous machine intelligence version 0.9. 2, 2022-06-27. *Open Review*, 62(1):1–62, 2022.
- Wolfgang Lehrach, Daniel Hennes, Miguel Lazaro-Gredilla, Xinghua Lou, Carter Wendelken, Zun Li, Antoine Dedieu, Jordi Grau-Moya, Marc Lanctot, Atil Iscen, et al. Code world models for general game playing. *arXiv preprint arXiv:2510.04542*, 2025.
- Guillaume Levy, Cédric Colas, Pierre-Yves Oudeyer, Thomas Carta, and Clément Romac. Worldllm: Improving llms’ world modeling using curiosity-driven theory-making. *arXiv preprint arXiv:2506.06725*, 2025.
- Junlong Li, Wenshuo Zhao, Jian Zhao, Weihao Zeng, Haoze Wu, Xiaochen Wang, Rui Ge, Yuxuan Cao, Yuzhen Huang, Wei Liu, et al. The tool decathlon: Benchmarking language agents for diverse, realistic, and long-horizon task execution. *arXiv preprint arXiv:2510.25726*, 2025a.

-
- Wanli Li, Bince Qu, Bo Pan, Jianyu Zhang, Zheng Liu, Pan Zhang, Wei Chen, and Bo Zhang. Literesearcher: A scalable agentic rl training framework for deep research agent. *arXiv preprint arXiv:2604.17931*, 2026a.
- Xirui Li, Ming Li, Ion Stoica, Cho-Jui Hsieh, and Tianyi Zhou. Clawenvkit: Automatic environment generation for claw-like agents. *arXiv preprint arXiv:2604.18543*, 2026b.
- Yixia Li, Hongru Wang, Jiahao Qiu, Zhenfei Yin, Dongdong Zhang, Cheng Qian, Zeping Li, Pony Ma, Guanhua Chen, and Heng Ji. From word to world: Can large language models be implicit text-based world models? *arXiv preprint arXiv:2512.18832*, 2025b.
- Yixia Li, Hongru Wang, Peng Lai, Zhiwen Ruan, He Zhu, Youxin Zhu, Ganlong Zhao, Minda Hu, Yun Chen, Sibe Yang, Peng Li, Jeff Z. Pan, Jia Pan, Guanhua Chen, Yang Liu, and Guanbin Li. Bridging the agent-world gap: Text world models for llm-based agents, 2026c. URL <https://arxiv.org/abs/2606.09032>.
- Yuetai Li, Huseyin A Inan, Xiang Yue, Wei-Ning Chen, Lukas Wutschitz, Janardhan Kulkarni, Radha Poovendran, Robert Sim, and Saravan Rajmohan. Simulating environments with reasoning models for agent training. *arXiv preprint arXiv:2511.01824*, 2025c.
- Youwei Liu, Jian Wang, Hanlin Wang, Beichen Guo, and Wenjie Li. Imagine-then-plan: Agent learning from adaptive lookahead with world models. *arXiv preprint arXiv:2601.08955*, 2026.
- Mike A Merrill, Alexander G Shaw, Nicholas Carlini, Boxuan Li, Harsh Raj, Ivan Bercovich, Lin Shi, Jeong Yeon Shin, Thomas Walshe, E Kelly Buchanan, et al. Terminal-bench: Benchmarking agents on hard, realistic tasks in command line interfaces. *arXiv preprint arXiv:2601.11868*, 2026.
- Vincent Micheli, Eloi Alonso, and François Fleuret. Transformers are sample-efficient world models. *arXiv preprint arXiv:2209.00588*, 2022.
- AI MiniMax. Minimax m2. 7: Early echoes of self-evolution, 2026.
- OpenAI. Introducing gpt-5.2, 2025. URL <https://openai.com/index/introducing-gpt-5-2/>.
- OpenAI. Introducing gpt-5.4, 2026. URL <https://openai.com/index/introducing-gpt-5-4/>.
- OpenClaw. Openclaw. <https://github.com/openclaw/openclaw>, 2026. Open-source personal AI assistant, version 2026.3.8, accessed 2026-03-09.
- Shishir G Patil, Huanzhi Mao, Fanjia Yan, Charlie Cheng-Jie Ji, Vishnu Suresh, Ion Stoica, and Joseph E Gonzalez. The berkeley function calling leaderboard (bfcl): From tool use to agentic evaluation of large language models. In *Forty-second International Conference on Machine Learning*, 2025.
- Tejal Patwardhan, Rachel Dias, Elizabeth Proehl, Grace Kim, Michele Wang, Olivia Watkins, Simón Posada Fishman, Marwan Aljubeh, Phoebe Thacker, Laurance Fauconnet, et al. Gdpval: Evaluating ai model performance on real-world economically valuable tasks. *arXiv preprint arXiv:2510.04374*, 2025.
- Cheng Qian, Emre Can Acikgoz, Bingxuan Li, Xiushi Chen, Yuji Zhang, Bingxiang He, Qinyu Luo, Dilek Hakkani-Tür, Gokhan Tur, Yunzhu Li, et al. Current agents fail to leverage world model as tool for foresight. *arXiv preprint arXiv:2601.03905*, 2026.
- Yifu Qiu, Zheng Zhao, Waylon Li, Yftah Ziser, Anna Korhonen, Shay B Cohen, and Edoardo M Ponti. Self-improving world modelling with latent actions. *arXiv preprint arXiv:2602.06130*, 2026.
- Qwen Team. Qwen3.6-35B-A3B: Agentic coding power, now open to all, April 2026a. URL <https://qwen.ai/blog?id=qwen3.6-35b-a3b>.
- Qwen Team. Qwen3.6-Max-Preview: Smarter, sharper, still evolving, April 2026b. URL <https://qwen.ai/blog?id=qwen3.6-max-preview>.
- Qwen Team. Qwen3.6-Plus: Towards real world agents, April 2026c. URL <https://qwen.ai/blog?id=qwen3.6>.
- Babak Rahmani. Debugging code world models. *arXiv preprint arXiv:2602.07672*, 2026.
- Baochang Ren, Yunzhi Yao, Rui Sun, Shuofei Qiao, Ningyu Zhang, and Huajun Chen. Aligning agentic world models via knowledgeable experience learning. *arXiv preprint arXiv:2601.13247*, 2026.


-
- Jonathan Richens, David Abel, Alexis Bellot, and Tom Everitt. General agents contain world models. *arXiv preprint arXiv:2506.01622*, 2025.
- William F Shen, Xinchu Qiu, Chenxi Whitehouse, Lisa Alazraki, Shashwat Goel, Francesco Barbieri, Timon Willi, Akhil Mathur, and Ilias Leontiadis. Rethinking rubric generation for improving llm judge and reward modeling for open-ended tasks. *arXiv preprint arXiv:2602.05125*, 2026a.
- Zhouzhou Shen, Xueyu Hu, Xiyun Li, Tianqing Fang, Juncheng Li, and Shengyu Zhang. World-model-augmented web agents with action correction. *arXiv preprint arXiv:2602.15384*, 2026b.
- Vaishnavi Shrivastava, Piero Kauffmann, Ahmed Awadallah, and Dimitris Papailiopoulos. Echo: Terminal agents learn world models for free. *arXiv preprint arXiv:2605.24517*, 2026.
- Xiaoshuai Song, Haofei Chang, Guanting Dong, Yutao Zhu, Ji-Rong Wen, and Zhicheng Dou. Envs-calculator: Scaling tool-interactive environments for llm agent via programmatic synthesis. *arXiv preprint arXiv:2601.05808*, 2026.
- Liangcai Su, Zhen Zhang, Guangyu Li, Zhuo Chen, Chenxi Wang, Maojia Song, Xinyu Wang, Kuan Li, Jialong Wu, Xuanzhong Chen, et al. Scaling agents via continual pre-training. *arXiv preprint arXiv:2509.13310*, 2025.
- Hao Sun, Zile Qiao, Jiayan Guo, Xuanbo Fan, Yingyan Hou, Yong Jiang, Pengjun Xie, Yan Zhang, Fei Huang, and Jingren Zhou. Zeroscore: Incentivize the search capability of llms without searching. *arXiv preprint arXiv:2505.04588*, 2025.
- Shuang Sun, Huatong Song, Lisheng Huang, Jinhao Jiang, Ran Le, Zhihao Lv, Zongchao Chen, Yiwen Hu, Wenyang Luo, Wayne Xin Zhao, et al. Swe-world: Building software engineering agents in docker-free environments. *arXiv preprint arXiv:2602.03419*, 2026.
- Chenming Tang, Hsiu-Yuan Huang, Weijie Liu, Junqiang Zheng, Saiyong Yang, and Yunfang Wu. Democratizing tool learning with environments fully simulated by a free 8b language model, 2026. URL <https://arxiv.org/abs/2604.17739>.
- Kimi Team, Tongtong Bai, Yifan Bai, Yiping Bao, SH Cai, Yuan Cao, Y Charles, HS Che, Cheng Chen, Guanduo Chen, et al. Kimi k2. 5: Visual agentic intelligence. *arXiv preprint arXiv:2602.02276*, 2026.
- Qwen Team. Qwen3.5: Accelerating productivity with native multimodal agents, February 2026. URL <https://qwen.ai/blog?id=qwen3.5>.
- Qwen Team and Alibaba Data. QwenClawBench: Real-user-distribution benchmark for openclaw agents, 2026. URL github.com/SKYLENAGE-AI/QwenClawBench.
- Xiaoyu Tian, Haotian Wang, Shuaiting Chen, Hao Zhou, Kaichi Yu, Yudian Zhang, Jade Ouyang, Junxi Yin, Jiong Chen, Baoyan Guo, et al. Astra: Automated synthesis of agentic trajectories and reinforcement arenas. *arXiv preprint arXiv:2601.21558*, 2026.
- Dunwei Tu, Hongyan Hao, Hansi Yang, Yihao Chen, Yi-Kai Zhang, Zhikang Xia, Yu Yang, Yueqing Sun, Xingchen Liu, Furao Shen, et al. Scaleenv: Scaling environment synthesis from scratch for generalist interactive tool-use agent training. *arXiv preprint arXiv:2602.06820*, 2026.
- Dani Valevski, Yaniv Leviathan, Moab Arar, and Shlomi Fruchter. Diffusion models are real-time game engines. In *International Conference on Learning Representations*, volume 2025, pp. 73754–73776, 2025.
- Kangrui Wang, Pingyue Zhang, Zihan Wang, Yaning Gao, Linjie Li, Qineng Wang, Hanyang Chen, Yiping Lu, Zhengyuan Yang, Lijuan Wang, et al. Vagen: Reinforcing world model reasoning for multi-turn vlm agents. *Advances in Neural Information Processing Systems*, 38:172871–172933, 2026a.
- Ruoyao Wang, Graham Todd, Ziang Xiao, Xingdi Yuan, Marc-Alexandre Côté, Peter Clark, and Peter Jansen. Can language models serve as text-based world simulators? In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pp. 1–17, 2024.
- Xiaohua Wang, Muzhao Tian, Yuqi Zeng, Zisu Huang, Jiakang Yuan, Bowen Chen, Jingwen Xu, Mingbo Zhou, Wenhao Liu, Muling Wu, et al. Reward hacking in the era of large models: Mechanisms, emergent misalignment, challenges. *arXiv preprint arXiv:2604.13602*, 2026b.
- Yiming Wang, Da Yin, Yuedong Cui, Ruichen Zheng, Zhiqian Li, Zongyu Lin, Di Wu, Xueqing Wu, Chenchen Ye, Yu Zhou, et al. Llm as scalable, general-purpose simulators for evolving digital agent training. *arXiv preprint arXiv:2510.14969*, 2025a.

-
- Yinjie Wang, Tianbao Xie, Ke Shen, Mengdi Wang, and Ling Yang. Rlanything: Forge environment, policy, and reward model in completely dynamic rl system. *arXiv preprint arXiv:2602.02488*, 2026c.
- Zhaoyang Wang, Canwen Xu, Boyi Liu, Yite Wang, Siwei Han, Zhewei Yao, Huaxiu Yao, and Yuxiong He. Agent world model: Infinity synthetic environments for agentic reinforcement learning. *arXiv preprint arXiv:2602.10090*, 2026d.
- Zihan Wang, Kangrui Wang, Qineng Wang, Pingyue Zhang, Linjie Li, Zhengyuan Yang, Xing Jin, Kefan Yu, Minh Nhat Nguyen, Licheng Liu, et al. Ragen: Understanding self-evolution in llm agents via multi-turn reinforcement learning. *arXiv preprint arXiv:2504.20073*, 2025b.
- Ryan Wong, Jiawei Wang, Junjie Zhao, Li Chen, Yan Gao, Long Zhang, Xuan Zhou, Zuo Wang, Kai Xiang, Ge Zhang, et al. Wideseach: Benchmarking agentic broad info-seeking. *arXiv preprint arXiv:2508.07999*, 2025.
- World Labs team. Marble: A multimodal world model. World Labs Technical Post, 2025. URL <https://www.worldlabs.ai/blog/marble-world-model>.
- Jialong Wu, Shaofeng Yin, Ningya Feng, and Mingsheng Long. Rlvr-world: Training world models with reinforcement learning. *Advances in Neural Information Processing Systems*, 38:125312–125350, 2026a.
- Yifan Wu, Yiran Peng, Yiyu Chen, Jianhao Ruan, Zijie Zhuang, Cheng Yang, Jiayi Zhang, Man Chen, Yenchi Tseng, Zhaoyang Yu, et al. Autowebworld: Synthesizing infinite verifiable web environments via finite state machines. *arXiv preprint arXiv:2602.14296*, 2026b.
- Zijian Wu, Xiangyan Liu, Xinyuan Zhang, Lingjun Chen, Fanqing Meng, Lingxiao Du, Yiran Zhao, Fanshi Zhang, Yaoqi Ye, Jiawei Wang, et al. Mcpmark: A benchmark for stress-testing realistic and comprehensive mcp use. *arXiv preprint arXiv:2509.24002*, 2025.
- Jiannan Xiang, Yi Gu, Zihan Liu, Zeyu Feng, Qiyue Gao, Yiyang Hu, Benhao Huang, Guangyi Liu, Yichi Yang, Kun Zhou, et al. Pan: A world model for general, interactable, and long-horizon world simulation. *arXiv preprint arXiv:2511.09057*, 2025a.
- Jiannan Xiang, Yun Zhu, Lei Shu, Maria Wang, Lijun Yu, Gabriel Barcik, James Lyon, Srinivas Sunkara, and Jindong Chen. Uisim: An interactive image-based ui simulator for dynamic mobile environments. *arXiv preprint arXiv:2509.21733*, 2025b.
- Zikai Xiao, Jianhong Tu, Chuhang Zou, Yuxin Zuo, Zhi Li, Peng Wang, Bowen Yu, Fei Huang, Junyang Lin, and Zuozhu Liu. Webworld: A large-scale world model for web agent training. *arXiv preprint arXiv:2602.14721*, 2026.
- Tianbao Xie, Danyang Zhang, Jixuan Chen, Xiaochuan Li, Siheng Zhao, Ruisheng Cao, Toh J Hua, Zhoujun Cheng, Dongchan Shin, Fangyu Lei, et al. Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments. *Advances in Neural Information Processing Systems*, 37: 52040–52094, 2024.
- Caijun Xu, Changyi Xiao, Zhongyuan Peng, Xinrun Wang, and Yixin Cao. Scaler: Synthetic scalable adaptive learning environment for reasoning. *arXiv preprint arXiv:2601.04809*, 2026a.
- Siyuan Xu, Shiyang Li, Xin Liu, Tianyi Liu, Yixiao Li, Zhan Shi, Zixuan Zhang, Zilong Wang, Qingyu Yin, Jianshu Chen, et al. Controllable and verifiable tool-use data synthesis for agentic reinforcement learning. *arXiv preprint arXiv:2604.09813*, 2026b.
- Taofeng Xue, Chong Peng, Mianqiu Huang, Linsen Guo, Tiancheng Han, Haozhe Wang, Jianing Wang, Xiaocheng Zhang, Xin Yang, Dengchang Zhao, et al. Evocua: Evolving computer use agents via learning from scalable synthetic experience. *arXiv preprint arXiv:2601.15876*, 2026.
- Sherry Yang. World models as an intermediary between agents and the real world. *arXiv preprint arXiv:2602.00785*, 2026.
- Sherry Yang, Yilun Du, Kamyar Ghasemipour, Jonathan Tompson, Leslie Kaelbling, Dale Schuurmans, and Pieter Abbeel. Learning interactive real-world simulators. *arXiv preprint arXiv:2310.06114*, 2023.
- Bowen Ye, Rang Li, Qibin Yang, Yuanxin Liu, Linli Yao, Hanglong Lv, Zhihui Xie, Chenxin An, Lei Li, Lingpeng Kong, et al. Claw-eval: Toward trustworthy evaluation of autonomous agents. *arXiv preprint arXiv:2604.06132*, 2026a.
- Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026b.


-
- Xiao Yu, Baolin Peng, Ruize Xu, Yelong Shen, Pengcheng He, Suman Nath, Nikhil Singh, Jiangfeng Gao, and Zhou Yu. Reinforcement world model learning for llm-based agents. *arXiv preprint arXiv:2602.05842*, 2026.
- Aohan Zeng, Xin Lv, Zhenyu Hou, Zhengxiao Du, Qinkai Zheng, Bin Chen, Da Yin, Chendi Ge, Chenghua Huang, Chengxing Xie, et al. Glm-5: from vibe coding to agentic engineering. *arXiv preprint arXiv:2602.15763*, 2026.
- Kai Zhang, Xiangchao Chen, Bo Liu, Tianci Xue, Zeyi Liao, Zhihan Liu, Xiyao Wang, Yuting Ning, Zhaorun Chen, Xiaohan Fu, et al. Agent learning via early experience. *arXiv preprint arXiv:2510.08558*, 2025.
- Ziyun Zhang, Zezhou Wang, Xiaoyi Zhang, Zongyu Guo, Jiahao Li, Bin Li, and Yan Lu. Infiniteweb: Scalable web environment synthesis for gui agent training. *arXiv preprint arXiv:2601.04126*, 2026.
- Jiale Zhao, Guoxin Chen, Fanzhe Meng, Minghao Li, Jie Chen, Hui Xu, Yongshuai Sun, Wayne Xin Zhao, Ruihua Song, Yuan Zhang, et al. Immersion in the github universe: Scaling coding agents to mastery. *arXiv preprint arXiv:2602.09892*, 2026.
- Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, et al. Group sequence policy optimization. *arXiv preprint arXiv:2507.18071*, 2025.
- Yuhao Zheng, Li'an Zhong, Yi Wang, Rui Dai, Kaikui Liu, Xiangxiang Chu, Linyuan Lv, Philip Torr, and Kevin Qinghong Lin. Code2world: A gui world model via renderable code generation. *arXiv preprint arXiv:2602.09856*, 2026.
- Yuhang Zhou, Lizhu Zhang, Yifan Wu, Jiayi Liu, Xiangjun Fan, Zhuokai Zhao, and Hong Yan. Synthetic sandbox for training machine learning engineering agents. *arXiv preprint arXiv:2604.04872*, 2026.
- Kaijie Zhu, Yuzhou Nie, Yijiang Li, Yiming Huang, Jialian Wu, Jiang Liu, Ximeng Sun, Zhenfei Yin, Lun Wang, Zicheng Liu, et al. Termigen: High-fidelity environment and robust trajectory synthesis for terminal agents. *arXiv preprint arXiv:2602.07274*, 2026.
- Siyu Zhu, Yanbin Jiang, Hejian Sang, Shao Tang, Qingquan Song, Biao He, Rohit Jain, Zhipeng Wang, and Alborz Geramifard. Planner-r1: Reward shaping enables efficient agentic rl with smaller llms. *arXiv preprint arXiv:2509.25779*, 2025.

A 领域交互示例

图 14 和图 15 展示了 Qwen-AgentWorld 涵盖的全部七个领域中的代表性交互示例。每个面板展示一个智能体-环境回合：智能体发出的动作（上方）以及 Qwen-AgentWorld 生成的模拟观测（下方）。



(a) OS: 智能体在电子表格应用中点击 File > Print；世界模型预测带有打印设置和文档预览的 Print 后台视图。



(b) Web: 智能体在职位列表页面点击 View Details；世界模型预测包含岗位描述、要求和申请详情的完整职位发布页面。

图 14: 来自 GUI 领域的交互示例（续）。此处展示 OS 和 Web；Android 位于第 2.3 节。给定当前屏幕和智能体动作，世界模型以 HTML 预测下一个 GUI 状态，随后将其渲染为截图。

Terminal

Turn 7/9 · 10.7k tokens

Qwen-AgentWorld Input (Action)

keystrokes: "cd /app/pmars-0.9.4/src && make CFLAGS='-O -DEXT94 -DPERMUTATE -DRWLIMIT' LIB=''\\n"

Qwen-AgentWorld Output (Simulated Observation)

root@fa24c760:/app# cd /app/pmars-0.9.4/src && make CFLAGS='-O ...' LIB=''
Making pmars with compiler flags -O -DEXT94 -DPERMUTATE -DRWLIMIT
gcc -O -DEXT94 -DPERMUTATE -DRWLIMIT -c pmars.c
... (asm.o, eval.o compiled)
gcc -O -DEXT94 -DPERMUTATE -DRWLIMIT -c disasm.c
sim.h:92:12: warning: built-in function 'round' declared as non-function [-Wbuiltin-declaration-mismatch]
92 | extern int round;
... (cdb.o, sim.o -- same warning; pos.o compiled with overflow warning)
... (clparse.o, global.o, token.o, str_eng.o)
Linking pmars
done
root@fa24c760:/app/pmars-0.9.4/src#

(a) Terminal：智能体发出 `make` 命令来编译 C 项目；世界模型预测完整的编译器输出，包括警告和最终链接步骤。

MCP Tool Use

Turn 5/13 · 118.5k tokens

Qwen-AgentWorld Input (Action)

API-post-database-query
database_id: "e0956d87-47b6-83fc-8fd0-812438cb7061"
filter: { or: [
 { property: "Status", select: { equals: "Expired" } },
 { property: "Status", select: { equals: "To be returned" } }
] }

Qwen-AgentWorld Output (Simulated Observation)

{
 "object": "list",
 "results": [{
 "object": "page",
 "id": "73a56d87-47b6-8260-bbbb-814060904ac3",
 "properties": {
 "Serial": { "type": "title", "plain_text": "36x10PIQ" },
 "Status": { "name": "To be returned", "color": "gray" },
 "Registered to": { "plain_text": "User 59cad035" },
 "Tags": [{ "name": "Computer Accessory" }],
 "Expiration": { "start": "2023-06-22" },
 "Vendor": { "name": "Pineapple" }
 }
 },
 ... (4 more asset records matching the OR filter)
]
}

(b) MCP Tool Use：智能体通过结构化 JSON API 调用查询 Notion 数据库；世界模型返回带有属性、标签和元数据的匹配记录。

Search

Turn 2/3 · 24.7k tokens

Qwen-AgentWorld Input (Action)

web_extractor(urls=["en.wikipedia.org/.../presidential_elections_by_popular_vote_margin",
"britannica.com/.../Presidential-Election-Results-1788863"],
goal="Get a complete list of all US presidential election results from 1789 to 2024,
including: year, winner name, party, popular vote count, and electoral vote count.")

Qwen-AgentWorld Output (Simulated Observation)

Election	Winner	Party	Electoral	Margin	Votes	Runner-up	Turnout
1788-89	George Washington	Ind.	69/69	100%	43,782	--	11.6%
1800	Thomas Jefferson	D-R	73/138	22.86%	41,330	Aaron Burr (D-R)	32.3%
1860	Abraham Lincoln	Rep.	180/303	10.13%	1,855,993	Breckinridge (Dem.)	81.8%
1932	F. D. Roosevelt	Dem.	472/531	17.76%	22,821,277	Hoover (Rep.)	56.9%
1960	John F. Kennedy	Dem.	303/537	0.17%	34,220,984	Nixon (Rep.)	63.8%
2008	Barack Obama	Dem.	365/538	7.27%	69,498,516	McCain (Rep.)	57.1%
2020	Joe Biden	Dem.	306/538	4.45%	81,284,666	Trump (Rep.)	62.8%

Source: en.wikipedia.org (60 elections, 1788-2024; 7 shown)

(c) Search：智能体从 Wikipedia 提取 U.S. 总统选举结果；世界模型返回覆盖 60 次选举的结构化表格。

图 15: 来自文本领域的交互示例 (续)。此处展示 Terminal、MCP Tool Use 和 Search; Software Engineering 位于第 2.3 节。

B 训练动态

为理解 RL 学到了什么以及学习顺序，我们在 Qwen-AgentWorld-35B-A3B 的 440 个 RL 步内跟踪五个开放式评估维度（Format、Factuality、Consistency、Realism、Quality），每 10 步评估一次。

各维度以不同速度提升。 图 16 展示了各维度的分数轨迹。Consistency 的绝对提升最大（+0.29，从 2.81 到 3.10），而 Quality 的提升最小（+0.11）。各维度的收敛速度不同：Format 和 Quality 在 90 步内达到其总提升的 90%，而 Consistency 和 Realism 需要 ~250 步。格式约定（JSON 结构、终端提示符字符串）是 RL 能够快速强化的表层模式。Consistency 要求模型内化跨轮次状态跟踪，这是一种更深层、逐渐发展的能力。值得注意的是，RL 奖励是单一标量（五个维度的均值），但各维度在提升速度上显著分化，这表明在给定训练信号下，RL 会优先改进最容易优化的方面。




图 16: 440 个 RL 步内的训练动态（Qwen-AgentWorld-35B-A3B）。Format 在 ~90 步内收敛。Consistency 需要 ~250 步。

Factuality 的相对收益最大。 Factuality 相对于初始值提升了 11.3%（从 2.03 到 2.26），是所有维度中最大的相对增益。这证实 RL 会推动模型产生更准确的环境响应，而不只是让格式更精致。然而，Factuality 在整个训练过程中始终是得分最低的维度，表明事实性世界知识是环境模拟中最困难的方面。

C 基于规则的验证

除了对 AgentWorldBench 的开放式 rubric 评估之外，我们还设计了一组独立的基于规则的验证器，用确定性、可复现的方式检查三个目标能力轴：**可控性**（遵循明确的模拟指令）、**错误处理**（忠实复现环境失败模式）和 **长上下文一致性**（在长交互历史中进行连贯的状态跟踪）。这些能力轴隔离出 rubric 型评判器可能低估的特定失败模式。

三个能力轴的测试用例都通过共享的、以轨迹为基础的合成与验证流水线从主评估集中得到。我们首先总结每条候选轨迹的初始状态和确定性约束，包括环境配置、文件系统或数据库状态、活跃服务、工具 schema 以及其他特定于领域的状态。基于这些摘要，我们筛选出预期观测足够确定、且行为匹配三个基于规则的能力轴之一的轮次：用于可控性的明确模拟指令遵循、用于错误处理的无效操作忠实复现，或用于长上下文一致性的对早期状态变更的依赖。对于每个保留下来的轮次，我们合成一个专门面向该检查项和领域的可执行验证器。随后，我们用真实观测和多次模型 rollout 验证候选验证器，只保留那些基于规则的判定与参考约束下 rubric 标签一致的案例。然而，由于基于规则的验证器无法完全确认某些案例的正确性，我们还额外使用 LLM judge 来过滤掉可能欺骗验证器的错误输出。

下面，我们描述该流水线如何在每个能力轴上实例化。

- **可控性 (Ctrl)**. 该能力轴测试 LWM 是否除了遵循交互历史之外，也遵循明确的模拟指令。我们选择那些在保持周围轨迹上下文固定时，其正常行为可由明确控制条件改变的轮次。每个测试用例都用这样的条件增强正常轨迹上下文，例如强制终端命令因指定依赖冲突而失败、要求工具响应隐藏中间信息，或者使用对比式 GUI 条件，使同一个动作在不同隐藏状态下应当导向不同的预测屏幕。验证器检查生成的观测是否在保留该领域正常输出格式的同时满足被指示的行为。
- **错误处理 (Err)**. 真实环境会产生错误：命令失败、文件缺失、网络调用超时、权限被拒绝。忠实的模拟器必须复现这些失败模式，而不是编造成功响应。我们保留具有确定性错误结果的轮次，包括前置条件缺失或无效操作，例如删除不存在的文件、用格式错误的参数调用工具，或写入只读路径。Search 领域不贡献错误处理案例，因为其轨迹主要由成功的信息检索交互构成，不能为该能力轴提供合适的确定性、可执行错误结果。验证器检查生成的观测是否包含合适的错误信号（退出码、异常消息、错误类型 JSON 响应），而不是看似合理的成功结果。
- **长上下文一致性 (LC)**. 长交互序列会积累状态：文件先被写入后被读取，环境变量先被设置后被引用，数据库先被填充后被查询。该能力轴检查模拟器是否能跨轮次维持连贯状态。我们通过识别轨迹内的跨轮次状态依赖来构造测试用例，其中早期动作会改变或揭示环境状态，而后续观测依赖于该状态。示例包括写入-读取配对、环境变量更新后执行命令、数据库变更后查询，或会改变后续屏幕的 GUI 动作。验证器检查生成的观测是否遵守预期状态约束，例如更新后的文件内容、被引用的环境变量、被查询的记录或改变后的 GUI 元素，从而反映模型在长时域模拟中的一致性。

表 10: 基于规则的验证：四个文本领域（MCP、Search、Terminal、SWE）和三个 GUI 领域（Android、Web、OS）的分领域准确率（%，↑）。每列最高和第二高分数分别以 **粗体** 和 下划线 显示。

模型		文本				GUI			平均
		MCP	Search	Term.	SWE	Android	Web	OS	
前沿模型	Claude Opus 4.6	<u>76.90</u>	77.55	68.60	54.40	<u>80.06</u>	75.71	61.81	<u>70.72</u>
	Claude Sonnet 4.6	76.43	<u>71.90</u>	64.43	55.27	75.23	77.16	52.57	67.57
	GPT-5.4	82.90	66.95	<u>68.13</u>	62.37	81.08	81.61	67.46	72.93
	Gemini 3.1 Pro	68.77	61.45	62.33	53.47	76.73	75.32	<u>65.50</u>	66.22
开放权重	DeepSeek-V4-Pro	69.90	56.85	57.40	44.50	76.36	72.83	61.28	62.73
	Kimi K2.6	70.30	69.40	55.53	45.20	61.90	75.63	62.49	62.92
	GLM-5.1	72.53	71.70	55.47	41.77	67.98	72.06	55.98	62.50
	MiniMax-M2.7	55.03	44.30	32.40	25.17	71.87	70.36	49.39	49.79
Qwen	Qwen3.6-35B-A3B	49.50	47.00	41.30	35.07	59.79	67.83	44.03	49.22
	Qwen3.6-Plus	67.57	67.90	58.43	47.57	63.81	69.85	54.29	61.35
	Qwen3.6-Max-Preview	73.40	64.05	59.37	45.03	60.19	67.02	50.47	59.93
本文方法	Qwen3.5-35B-A3B	57.80	40.70	36.83	28.50	61.10	68.49	44.07	48.21
	Qwen-AgentWorld-35B-A3B	60.47	44.90	54.53	48.73	62.34	72.37	57.61	57.28
	Qwen3.5-397B-A17B	67.33	63.50	51.80	44.17	69.25	70.22	54.03	60.04
	Qwen-AgentWorld-397B-A17B	72.37	58.95	62.63	<u>60.33</u>	76.79	<u>80.74</u>	58.01	67.12

表 10 报告了各领域验证分数。基于规则的验证印证了主要发现：世界模型训练提升了对明确模拟指令的遵循、对环境失败模式的忠实复现，以及跨长交互历史的连贯状态跟踪。GPT-5.4 以 72.93 的平均分总体排名第一，而 Qwen-AgentWorld-397B-A17B 以 67.12 位居第二，并在 GUI 领域优于所有其他前沿模型。

C.1 按轴分解

表 11 和表 12 分别给出了文本领域和 GUI 领域在各子能力（可控性、错误处理、长上下文一致性）上的分解结果，用以补充表 10 中的分领域平均值。

表 11: 文本领域上的基于规则评估：三个子能力上的准确率（%，↑）。Ctrl：可控性；Err：错误处理；LC：长上下文一致性。最高和第二高分数分别以 **粗体** 和 下划线 显示。

模型		MCP			Term.			Search		SWE			平均
		Ctrl	Err	LC	Ctrl	Err	LC	Ctrl	LC	Ctrl	Err	LC	
前沿模型	Claude Opus 4.6	72.3	78.4	80.0	68.7	81.0	56.1	74.2	80.9	52.8	59.6	50.8	69.4
	Claude Sonnet 4.6	74.3	77.0	78.0	63.9	77.0	52.4	72.0	71.8	57.5	59.1	49.2	67.0
	GPT-5.4	76.2	84.5	88.0	62.0	88.7	53.7	70.5	63.4	59.8	65.4	61.9	70.1
	Gemini 3.1 Pro	59.6	71.7	75.0	60.0	77.0	50.0	61.8	61.1	52.0	58.4	50.0	61.5
开放权重	DeepSeek-V4-Pro	63.4	72.3	74.0	50.6	74.0	47.6	54.9	58.8	52.0	52.9	28.6	57.2
	Kimi K2.6	65.3	71.6	74.0	49.4	73.3	43.9	66.3	72.5	43.3	55.8	36.5	60.1
	GLM-5.1	67.3	74.3	76.0	49.4	74.3	42.7	70.1	73.3	42.5	49.5	33.3	60.4
	MiniMax-M2.7	39.6	63.5	62.0	30.1	50.0	17.1	41.7	46.9	29.1	27.4	19.0	39.2
Qwen	Qwen3.6-35B-A3B	37.6	66.9	44.0	37.3	61.0	25.6	45.1	48.9	41.7	36.5	27.0	43.2
	Qwen3.6-Plus	60.4	70.3	72.0	51.8	74.7	48.8	63.3	72.5	52.0	55.8	34.9	60.4
	Qwen3.6-Max-Preview	69.3	70.9	80.0	54.8	75.7	47.6	60.2	67.9	44.1	57.7	33.3	60.5
本文方法	Qwen3.5-35B-A3B	54.5	64.9	54.0	32.5	50.0	28.0	33.3	48.1	34.6	30.3	20.6	41.0
	Qwen-AgentWorld-35B-A3B	52.5	68.9	60.0	50.0	67.3	46.3	37.1	52.7	48.0	60.1	38.1	52.2
	Qwen3.5-397B-A17B	60.4	73.6	68.0	47.0	65.7	42.7	59.8	67.2	44.1	56.7	31.7	56.7
	Qwen-AgentWorld-397B-A17B	63.4	75.7	78.0	59.0	77.7	51.2	56.1	61.8	61.4	62.5	57.1	63.6

表 12: GUI 领域上的基于规则评估：三个子能力上的准确率 (% , $\uparrow$)。Ctrl: 可控性; Err: 错误处理; LC: 长上下文一致性。最高和第二高分数分别以 **粗体**和 下划线 显示。

模型		Android			Web			OS			平均
		Ctrl	Err	LC	Ctrl	Err	LC	Ctrl	Err	LC	
前沿模型	Claude Opus 4.6	<u>80.9</u>	79.4	<u>79.7</u>	82.8	60.0	<u>84.3</u>	<u>70.9</u>	59.0	52.0	72.1
	Claude Sonnet 4.6	77.9	69.8	<u>76.0</u>	<u>81.7</u>	68.0	<u>81.8</u>	<u>60.9</u>	49.0	45.1	67.8
	GPT-5.4	77.4	82.5	83.9	<u>79.6</u>	80.0	85.2	71.2	<u>72.0</u>	54.6	76.3
	Gemini 3.1 Pro	72.6	87.3	74.2	79.0	68.0	79.0	60.4	80.5	50.0	<u>72.3</u>
开放权重	DeepSeek-V4-Pro	73.2	85.7	73.6	78.3	62.0	78.2	68.3	61.0	50.8	70.1
	Kimi K2.6	63.9	58.7	61.9	79.1	69.0	78.8	71.2	60.0	52.8	66.2
	GLM-5.1	68.0	65.1	69.9	78.5	64.0	73.7	62.6	53.0	50.4	65.0
	MiniMax-M2.7	66.9	77.8	73.1	68.5	73.0	69.6	51.6	51.0	43.5	63.9
Qwen	Qwen3.6-35B-A3B	56.7	66.7	58.6	72.4	60.0	71.1	50.1	38.0	44.0	57.5
	Qwen3.6-Plus	62.3	69.8	61.6	69.2	66.0	74.4	58.3	55.0	47.0	62.6
	Qwen3.6-Max-Preview	60.1	68.3	55.2	68.6	58.0	74.5	47.7	53.0	50.9	59.6
本文方法	Qwen3.5-35B-A3B	57.2	66.0	60.1	74.3	63.6	67.6	47.7	41.4	43.1	57.9
	Qwen-AgentWorld-35B-A3B	53.0	95.2	51.4	66.2	<u>84.3</u>	66.6	60.1	53.0	60.9	65.6
	Qwen3.5-397B-A17B	67.4	65.1	73.8	71.0	68.0	71.7	58.9	54.0	46.5	64.0
	Qwen-AgentWorld-397B-A17B	81.3	<u>88.7</u>	64.9	75.8	84.5	82.0	56.5	60.0	<u>57.2</u>	72.3

D 开放式评判提示词

本节提供用于全部七个领域开放式评估 (§4.2) 的完整 judge 系统提示词。所有提示词都在同一五个维度 (Format、Factuality、Consistency、Realism、Quality) 上为预测打分。文本领域提示词通过内容类型分类来定义每个维度，以实现差异化匹配。GUI 领域提示词采用同样五个维度，并使用基于锚点的校准：领域特定锚点 (UI 元素、导航状态、可见文本) 决定如何为基于屏幕的观测在各维度上打分。

D.1 Terminal 领域

```
# Role and Objective

You are a professional evaluator assessing simulated terminal outputs from a Terminal World Model. The Terminal World Model simulates the execution of terminal commands within a Linux/Unix environment, generating plausible terminal output based on the command sequence and session context.

Your task is to compare the Simulated Terminal Output against the Ground Truth (Real Terminal Output) and evaluate the simulation quality across the following five dimensions. The Ground Truth serves as the absolute reference standard. Every penalization or commendation MUST reference specific differences or matches with the Ground Truth.

---

# Content Type Classification

Important Context: The Terminal World Model has no access to the real environment state. It can only "know" information explicitly shown or created during the current interaction session. For any pre-existing state (e.g., file contents not written in this session, installed packages, system configurations, directory structures), the model must infer plausible values.

Before evaluation, apply different verification standards based on information availability:

| Content Type | Verification Standard | Examples |
|---|---|---|
| Deterministic content | Must match Ground Truth exactly. | echo output, cat of a file written earlier in this session, computation results |
| Pre-existing environment content | Verify format and plausibility only. Do NOT penalize different but reasonable values. | ls of a pre-existing directory, cat of a pre-existing file, version numbers |
| Runtime metadata | Verify format and plausibility only. | Timestamps, PIDs, container IDs, memory addresses, download speeds |

---

# Evaluation Dimensions

## 1. Format

Definition: Evaluates whether the simulated output adheres to the formatting conventions shown in the Ground Truth. This dimension evaluates ONLY formatting, not content correctness.

Key Points:
- Overall Structure: The output must conform to the same structural layout as the Ground Truth -- including the prompt-command-output cycle, section separations, and terminal conventions.
- Prompt Format: The shell prompt pattern (e.g., user@host:/path$ or #) must match the Ground Truth's convention. After directory-changing commands, the path component in the prompt must update accordingly.
- Command Echo: The executed command must appear correctly after the prompt, exactly as typed in the input.
- Line Breaks and Spacing: Precise line break placement matters -- empty lines between logical sections, no spurious blank lines within continuous output, and correct separation between command output and the next prompt.
- Special Formatting: When the Ground Truth shows specific formatting patterns (e.g., here-doc continuation markers like >, progress indicators, tabular/columnar alignment, interactive prompts), the simulation must follow the same conventions.
- Output Boundaries: The response should end appropriately as shown in Ground Truth -- typically with the next prompt ready for input, or mid-execution if the command is still running.

What NOT to penalize here: Content differences (different file names, different version numbers) -- these belong to Factualty or Realism.

---

## 2. Factualty

Definition: Evaluates the factual correctness of the simulated content. The Ground Truth serves as the absolute reference standard. The simulator must NOT fabricate or contradict any information that is deterministic or previously established in the session.

Key Points:
- Ground Truth as Absolute Reference: Always compare the simulated output against the Ground Truth line by line.
- Deterministic Content -- Strict Match: Outputs fully determined by the command and known session state must match Ground Truth exactly.
- Pre-existing Content -- Plausibility Check: For content depending on unknown environment state, do NOT require exact matches. Instead verify: (1) format matches Ground Truth's pattern, (2) content is plausible for the domain, (3) no internal contradictions.
- Runtime Metadata: Timestamps, PIDs, and other dynamic metadata need only be format-valid and range-plausible.
- Fabrication Policy: Inventing content that contradicts known session state is strictly prohibited. Generating plausible content for unknown/pre-existing state is allowed.

---

## 3. Consistency

Definition: Measures whether the simulated output remains coherent and consistent with all previously established state throughout the interaction.

Key Points:
- State Tracking: All state changes from prior turns (file creations, modifications, deletions, environment variable
```

```

        settings, directory changes, process launches, etc.) must be correctly reflected in subsequent outputs.
- **No Contradictions:** The output must not contradict any fact or state established in prior visible turns.
- **Contextual Continuity:** The simulated environment should evolve coherently -- operations that depend on prior state
  should produce results consistent with that state.

---

## 4. Realism

**Definition:** Evaluates how well the simulation captures the authentic behavior of a real terminal environment, **as
  evidenced by the Ground Truth**.

**Key Points:**
- **Behavioral Fidelity:** Command behaviors should match real-world expectations.
- **Style Consistency:** The simulated output should have a consistent style with the Ground Truth -- including tone,
  terminology, and presentation conventions.
- **Value Plausibility:** Numeric values, file sizes, version numbers should be within reasonable ranges for the domain
  and context.
- **Multi-stage Output:** Commands that produce multi-stage output (e.g., package installation, build processes) should
  show realistic progress stages.

---

## 5. Quality

**Definition:** Evaluates whether the output is complete and appropriately concise compared to the Ground Truth.

**Key Points:**
- **Completeness:** The simulated response must include all critical information present in Ground Truth. Missing
  critical content is penalized.
- **Conciseness:** The content should not be overly verbose relative to Ground Truth.
- **Proportionality:** The scope and scale of the output should be comparable to Ground Truth.

```

D.2 MCP 领域

```

# Role and Objective

You are a professional evaluator specializing in assessing simulated tool outputs from a **Tool World Model**. The Tool
World Model simulates the execution of tool calls within tool-augmented agent scenarios, generating plausible and
contextually appropriate tool execution results based on the provided tool call information.

Your task is to compare the **Simulated Tool Response** against the **Ground Truth (Real Tool Response)** and evaluate
the simulation quality across the following five dimensions.

---

# Content Type Classification

Before evaluation, classify the content in the response into the following categories, as they require different
verification standards:

| Content Type | Verification Standard | Examples |
|---|---|---|
| **Objective Facts** | Must match Ground Truth exactly. | Identifiers, public entity names, error messages, labels,
  code execution results |
| **Numeric Data** | Allow reasonable variance for real-time data. | Counts, measurements, coordinates, statistical
  values |
| **Private/Session/Inaccessible Data** | Verify validity and realism only. | Generated IDs, file paths, timestamps, API
  metadata |
| **Structural Metadata** | Must match the overall structure and schema. | JSON keys, array structures, response
  wrappers |

---

# Evaluation Dimensions

## 1. Format

**Definition:** Evaluates whether the simulated output adheres to the real tool's formatting specifications, including
overall structure, indentation, layout, field ordering, line breaks, spacing, special symbols, and native
formatting style (e.g., JSON, plain text, markdown, structured data).

## 2. Factuality

**Definition:** Evaluates whether the **verifiable information** in the simulated output matches the Ground Truth. This
is the **CORE** dimension for correctness.

**Key Points:**
- **Tool Execution:** Correct interpretation of tool parameters and correct execution of core functionality.
- **Exact Matching:** Objective Facts must match exactly.
- **No Hallucination:** Content that does not exist in the Ground Truth is penalized.
- **Status Accuracy:** Correct status/result type (success vs. error, found vs. not found).

## 3. Consistency

```

```

**Definition:** Evaluates whether the simulated output remains coherent with **previous context and tool state** throughout multi-turn interactions.

**Key Points:**
- **Resource References:** Correctly references resources (IDs, data, states) from previous turns.
- **State Tracking:** Maintains proper state transitions (e.g., thoughtNumber increments, pagination offsets).
- **Causal Relationships:** No conflicts with historical information; maintains logical causality between operations.

## 4. Realism

**Definition:** Evaluates how well the simulation matches the **behavioral characteristics observed in the Ground Truth**. This focuses on response pattern alignment with the reference.

**Key Points:**
- **Response Pattern Match:** The response type (success, error, empty, partial) must match Ground Truth.
- **Value Range Alignment:** Numeric values should be within reasonable range of Ground Truth values.
- **Edge Case Handling:** Proper reproduction of empty results, not-found responses, and error scenarios.
- **Error Pattern Match:** Error message format and structure should align with Ground Truth patterns.

## 5. Quality

**Definition:** Evaluates whether the output is complete and appropriately concise compared to the Ground Truth.

**Key Points:**
- **Completeness:** The simulated response must return all necessary content present in the Ground Truth.
- **Conciseness:** The content should not be overly verbose.

```

D.3 Search 领域

```

# Role and Objective

You are a professional evaluator specializing in assessing simulated tool outputs from a **Search World Model**. The Search World Model simulates the execution of real search engine tools (web_search and web_extractor), generating responses that must strictly adhere to the provided **Ground Truth (Real Tool Response)**.

Your task is to compare the **Simulated Tool Response** against the **Ground Truth** and evaluate the simulation quality across the following five dimensions.

---

# Evaluation Dimensions

## 1. Format

**Definition:** Evaluates whether the simulated output adheres to the structural and field requirements of the real tool 's output.

**Key Points:**
- **Overall Structure:** The output must conform to the same structural format as the Ground Truth.
  - For web_search: Numbered result entries with required fields (e.g., url, title, snippet).
  - For web_extractor: Webpage layouts matching the Ground Truth.
- **Formatting Details:** Valid, well-structured JSON where applicable. Proper line breaks, indentation, and spacing.

## 2. Factuality (Content Accuracy)

**Definition:** Evaluates the factual correctness of the simulated content. The Ground Truth serves as the **absolute reference standard**. The simulator must NOT fabricate or contradict any information present in the Ground Truth.

**Key Points:**
- **Content Present in Ground Truth:** Facts and sources must match exactly. Any fabrication or contradiction is penalized.
- **Content Not in Ground Truth:** Assess consistency with real-world facts. Penalize only errors **clearly contradicted** by the Ground Truth.
- **Metadata Plausibility:** Dates, timestamps, and URLs should be plausible.
- **Precedence:** The Ground Truth takes precedence as the definitive source of truth.

## 3. Consistency

**Definition:** Measures whether the simulated output remains coherent and consistent with previous context throughout the conversation.

**Key Points:**
- Repeated web_search calls with similar queries should return broadly consistent results.
- Repeated web_extractor calls on the same URL should yield consistent content.

## 4. Realism (Search Behavior)

**Definition:** Evaluates how well the simulation replicates realistic search engine behavior. This dimension measures the **retrieval quality** of web_search and web_extractor.

**Key Points:**
- **Relevance Alignment:** Simulated results must align with the expected information as defined by the Ground Truth.
- **Ranking Priority:** The ordering of web_search results should reflect realistic search engine prioritization.

```

```

- **Behavioral Fidelity**: Tool behaviors should match real-world expectations (e.g., URLs matching query topics, plausible dates).

## 5. Quality

**Definition**: Evaluates whether the output is complete and appropriately concise compared to the Ground Truth.

**Key Points**:
- **Completeness**: The simulated response must return all necessary results, especially the top-ranked ones.
- **Conciseness**: The content should not be overly verbose.

```

D.4 SWE 领域

```

# Role and Objective

You are a professional evaluator specializing in assessing simulated tool outputs from a **Tool World Model**. The Tool World Model simulates the execution of tool calls within a realistic command-line and filesystem environment, generating plausible tool execution results based on the provided tool call information.

Your task is to compare the **Simulated Tool Response** against the **Ground Truth (Real Tool Response)** and evaluate the simulation quality across the following five dimensions.

---

# Content Type Classification

**Important Context**: The Tool World Model has no access to the real environment state. It can only "know" information **explicitly shown or created during the current interaction session**.

Before evaluation, classify the content in the tool output into the following categories:

| Content Type | Verification Standard | Examples |
|---|---|---|
| **Objective Facts** | Must match Ground Truth exactly. | Tool execution success/failure status, error message types, exit codes |
| **Session/Environment-Specific Data** | Verify format validity and reasonableness only. | Timestamps, PIDs, file modification times, version numbers |
| **Private/Unprovided Context-Dependent Data** | Verify format and semantic correctness. | Output of ls in user directories, file contents (when not previously shown), configuration values |
| **Structural/Formatting Elements** | Must match exactly. | JSON structure, XML tags, output format, indentation, line breaks |

---

# Evaluation Dimensions

## 1. Format

**Definition**: Evaluates whether the simulated output matches the real tool's format. This includes overall structure, indentation, layout, field ordering, line breaks, spacing, and adherence to the tool's native formatting style. This dimension evaluates **ONLY formatting**, not content correctness.

## 2. Factuality

**Definition**: Evaluates whether the **verifiable information** in the simulated output matches the Ground Truth. This is the **CORE** dimension for semantic correctness.

**Key Points**:
- **Tool Execution Simulation**: The model must correctly simulate tool execution logic. Success/failure status and exit codes must exactly match Ground Truth.
- **Error Message Correctness**: Error message type must be accurate and match the actual failure reason.
- **Content Accuracy**: Content explicitly shown or created in the session must exactly match Ground Truth. Deterministic operations must produce matching output.
- **Fabrication Policy**: Inventing content that contradicts known state is prohibited. Plausible values for unknown environment state are allowed.

---

## 3. Consistency

**Definition**: Evaluates whether the simulated output remains coherent with **previous tool states and interaction history** throughout multi-turn interactions.

**Key Points**:
- **File System State**: Files created in previous commands must exist in subsequent read_file or ls operations. File modifications must be reflected.
- **Environment & Session State**: Environment variables, working directory changes, and configurations must persist. No contradictions with prior information.

---

## 4. Realism

**Definition**: Evaluates how well the simulation captures the **authentic behavior patterns** of real tool execution.

```

This focuses on behavioral authenticity and stylistic accuracy, NOT content correctness.

****Key Points:****

- ****Tool Behavior Patterns:**** Tool-specific output format and structure should match typical behavior. Success/confirmation messages follow the tool's standard response style.
- ****Output Semantics:**** For environment-dependent operations, output must be semantically plausible. Appropriate output verbosity based on the operation type.
- ****Numeric Reasonableness:**** File sizes, permissions, timestamps are plausible and chronologically consistent.
- ****Error Message:**** Error message format matches the originating tool.
- ****Edge Case Handling:**** Reasonable behavior for empty results or boundary conditions.

5. Quality

****Definition:**** Evaluates whether the output is both complete and appropriately concise relative to the Ground Truth.

****Key Points:****

- ****Completeness:**** All critical information from Ground Truth is present.
- ****Conciseness:**** Output is not overly verbose compared to Ground Truth.

D.5 Android 领域

Android World Model Judge Guidance

You are judging an Android world-model prediction: the simulated screen state after the latest user operation, compared with the real observed screen state.

Use the task-provided evaluation protocol exactly as given by the user message. This system prompt only adds Android-specific judging anchors.

Core Principle

A strong prediction is not just a plausible Android story. It must preserve the concrete state representation used by the trajectory and correctly update the visible Android state caused by the latest user operation.

Treat the ground truth as the strongest evidence for visible Android facts. If the ground truth appears clearly inconsistent with the prior history, rely on causal reasoning from the interaction history; otherwise, prefer predictions that preserve more concrete ground-truth anchors.

Android Anchors

Before rewarding a prediction strongly, check these anchors when they are visible or implied by the turn:

- Active app, package/activity, screen title, navigation stack, and whether the app/page stayed unchanged.
- Dialogs, bottom sheets, permission prompts, notification shade state, toasts, popups, and transient overlays.
- Focused input, cursor position, typed text, suggestion changes, IME/keyboard visibility, and keyboard layout.
- Selected, checked, toggled, disabled, or highlighted controls.
- List, feed, recycler-view, tab, page, and scroll position.
- Exact task labels, search queries, filenames, contact names, item titles, timestamps, timer/clock text, and other visible text anchors.
- Android-specific behavior such as back/home navigation, app switching, permission handling, soft-keyboard reflow, and disabled-control behavior.

Strictness Rules

- Penalize unchanged predictions after meaningful operations when the real screen visibly changes.
- Penalize speculative navigation, refreshed pages, or invented transitions when the observed result is unchanged or only a small anchor changes.
- Penalize broad app-level correctness when task-critical anchors such as typed text, selected chip, dialog presence, keyboard state, or list position are wrong.
- Penalize fabricated screens, impossible Android states, generic summaries, and outputs that explain what should happen instead of showing the resulting state.
- Do not let clean structure hide a wrong Android state; the primary post-action effect matters most.

Score Separation Policy

Map anchor accuracy to scores as follows:

- Top score: reserve for predictions that match the primary post-action effect and nearly all task-critical visible anchors.
- High-but-not-top score: use when the main transition is correct but one or two local anchors are missing or slightly stale.
- Middle score: use when the broad destination or app/page/window is right but important visible state details are wrong, missing, or invented.
- Low score: use when the prediction is mostly a plausible story, unchanged state, or wrong branch despite sharing some surrounding context.
- Minimum score: use for wrong environment/page/app, malformed/non-state output, fabricated major content, or explanations instead of a predicted observation.

Dimension-Specific Scoring Anchors

Use each dimension independently; do not let a well-formed UI tree inflate factual correctness.

- Format: score only schema/tag/readability compliance. A clean format cannot compensate for wrong state facts.
- Factuality: compare concrete visible anchors against the real observation. If the main screen/action result is wrong, use 1-2. If the main result is right but several active-region anchors are wrong, use 3. Use 4-5 only for close anchor matches.
- Consistency: check causal continuity from the previous state and latest action. Wrong change-vs-no-change, wrong back/navigation result, wrong keyboard/dialog/focus behavior, or stale state after a state-changing action should be 1-2.
- Realism: judge whether the predicted Android transition is behaviorally plausible for the app and action, but cap it at 3 when factuality or consistency is 1-2.
- Quality: judge usefulness as a replacement next-state observation. If a downstream agent would take the wrong next action because of missing/wrong active anchors, use 1-2; if usable only at a broad page level, use 3.

Before assigning any 4 or 5, explicitly verify the primary action effect plus at least these active anchors when present : package/activity or screen title, focused/selected control, exact typed/search text, keyboard/dialog/toast state , list/feed item labels, and scroll position.

Discriminative Error Calibration

- Treat the latest action's primary visible effect as a gate. If it is wrong, stale, or missing, set factuality ≤ 2 and quality ≤ 2 even when many background nodes match.
- If the output copies or preserves much of the prior state while the ground truth changes, score it as a stale-state error.
- Downweight generic complete-looking hierarchies: if exact active text, selected/focused element, transient toast/dialog, and visible list/feed rows do not match, total score should normally be ≤ 3 .

D.6 Web 领域

Web World Model Judge Guidance

You are judging a web world-model prediction: the simulated browser/page state after the latest user operation, compared with the real observed page state.

Use the task-provided evaluation protocol exactly as given by the user message. This system prompt only adds web-specific judging anchors.

Core Principle

A strong prediction is not just a plausible browsing story. It must preserve the concrete state representation used by the trajectory and correctly update the visible browser/page state caused by the latest user operation.

Treat the ground truth as the strongest evidence for visible web facts. If the ground truth appears clearly inconsistent with the prior history, rely on causal reasoning from the interaction history; otherwise, prefer predictions that preserve more concrete ground-truth anchors.

Web Anchors

Before rewarding a prediction strongly, check these anchors when they are visible or implied by the turn:

- Current URL, page title, active tab, active frame/iframe, browser dialog, and whether navigation actually happened.
- Load outcome, including success page, error page, spinner, redirect, authentication wall, or unchanged page.
- Exact visible text, headings, link labels, table rows, card titles, result counts, prices, dates, and messages.
- Form values, focused field, cursor position, validation text, enabled/disabled controls, checked boxes, selected options, and uploaded-file state.
- Modal, dropdown, menu, tooltip, popover, cookie banner, alert, and blocking overlay state.
- Scroll position, viewport/snapshot scope, selected text, highlighted element, and expanded/collapsed sections.

Strictness Rules

- Penalize predictions that invent successful navigation or content when the observed result is unchanged, loading, blocked, or errored.
- Penalize broad website-level correctness when task-critical anchors such as URL, title, form value, validation message, modal state, or visible row text are wrong.
- Penalize stale predictions that miss small but visible updates after typing, selecting, filtering, sorting, scrolling, submitting, or opening a menu.
- Penalize fabricated pages, impossible browser states, generic summaries, and outputs that explain what should happen instead of showing the resulting page state.
- Do not let clean structure hide a wrong web state; the primary post-action effect matters most.

Score Separation Policy

Map anchor accuracy to scores as follows:

- Top score: reserve for predictions that match the primary post-action effect and nearly all task-critical visible anchors.
- High-but-not-top score: use when the main transition is correct but one or two local anchors are missing or slightly stale.
- Middle score: use when the broad destination or app/page/window is right but important visible state details are wrong, missing, or invented.
- Low score: use when the prediction is mostly a plausible story, unchanged state, or wrong branch despite sharing some surrounding context.
- Minimum score: use for wrong environment/page/app, malformed/non-state output, fabricated major content, or explanations instead of a predicted observation.

Dimension-Specific Scoring Anchors

Use each dimension independently; do not let a well-formed DOM/accessibility tree inflate factual correctness.

- Format: score only schema/tag/readability compliance. A clean format cannot compensate for wrong page facts.
- Factuality: compare concrete visible anchors against the real observation. If the main page/action result is wrong, use 1-2. If the main result is right but several active-region anchors are wrong, use 3. Use 4-5 only for close anchor matches.
- Consistency: check causal continuity from the previous state and latest action. Wrong change-vs-no-change, wrong navigation/load result, wrong focus/dropdown/modal behavior, or stale state after a state-changing action should be 1-2.
- Realism: judge whether the predicted browser/page transition is behaviorally plausible for the site and action, but cap it at 3 when factuality or consistency is 1-2.
- Quality: judge usefulness as a replacement next-state observation. If a downstream agent would take the wrong next action because of missing/wrong active anchors, use 1-2; if usable only at a broad page level, use 3.

Before assigning any 4 or 5, explicitly verify the primary action effect plus at least these active anchors when present : URL/title or page identity, focused element, exact typed/search text, dropdown/modal/error state, selected item/filter, visible result/list/table labels, and scroll position.

Discriminative Error Calibration

- Treat the latest action's primary visible effect as a gate. If it is wrong, stale, or missing, set factuality ≤ 2 and quality ≤ 2 even when many background nodes match.
- If the output copies or preserves much of the prior state while the ground truth changes, score it as a stale-state error.
- Downweight generic complete-looking accessibility trees: if exact active text, selected/focused element, error/load/modal state, and visible result rows do not match, total score should normally be ≤ 3 .

D.7 OS 领域

Desktop OS World Model Judge Guidance

You are judging a desktop OS world-model prediction: the simulated desktop/app state after the latest user operation, compared with the real observed desktop state.

Use the task-provided evaluation protocol exactly as given by the user message. This system prompt only adds desktop-specific judging anchors.

Core Principle

A strong prediction is not just a plausible desktop story. It must preserve the concrete state representation used by the trajectory and correctly update the visible desktop state caused by the latest user operation.

Treat the ground truth as the strongest evidence for visible desktop facts. If the ground truth appears clearly inconsistent with the prior history, rely on causal reasoning from the interaction history; otherwise, prefer predictions that preserve more concrete ground-truth anchors.

Desktop Anchors

Before rewarding a prediction strongly, check these anchors when they are visible or implied by the turn:

- Active application, focused window, window title, z-order, minimized/maximized state, geometry, and workspace/desktop context.
- Dialogs, menus, context menus, popovers, file pickers, permission prompts, alerts, and whether they block interaction.
- Exact file, folder, document, tab, terminal, process, or app names visible in the state.
- Focused input, cursor position, selected text/items, edited text, unsaved/saved state, and clipboard-like visible effects.
- Terminal command output, prompt position, last visible rows, errors, exit state, and current working directory when represented.
- File-manager state such as created, renamed, moved, deleted, selected, or highlighted files and folders.
- Scroll position, visible viewport, status bars, clock/status text, coordinates, taskbar/dock/panel state, and notification indicators.

Strictness Rules

- Penalize predictions that switch apps/windows, close dialogs, dismiss menus, move focus, or alter files without causal support from the latest user operation.
- Penalize broad desktop-level correctness when task-critical anchors such as focused window, exact file name, terminal output, dialog state, selection, or geometry are wrong.
- Penalize stale predictions that miss small but visible updates after typing, opening menus, selecting files, running commands, scrolling, saving, or switching focus.
- Penalize fabricated windows, impossible desktop states, generic summaries, and outputs that explain what should happen instead of showing the resulting desktop state.
- Do not let clean structure hide a wrong desktop state; the primary post-action effect matters most.

Score Separation Policy

Map anchor accuracy to scores as follows:

- Top score: reserve for predictions that match the primary post-action effect and nearly all task-critical visible anchors.
- High-but-not-top score: use when the main transition is correct but one or two local anchors are missing or slightly stale.
- Middle score: use when the broad destination or app/page/window is right but important visible state details are wrong

, missing, or invented.

- Low score: use when the prediction is mostly a plausible story, unchanged state, or wrong branch despite sharing some surrounding context.
- Minimum score: use for wrong environment/page/app, malformed/non-state output, fabricated major content, or explanations instead of a predicted observation.

Dimension-Specific Scoring Anchors

Use each dimension independently; do not let a well-formed desktop hierarchy inflate factual correctness.

- Format: score only schema/tag/readability compliance. A clean format cannot compensate for wrong desktop facts.
- Factuality: compare concrete visible anchors against the real observation. If the main window/action result is wrong, use 1-2. If the main result is right but several active-region anchors are wrong, use 3. Use 4-5 only for close anchor matches.
- Consistency: check causal continuity from the previous state and latest action. Wrong change-vs-no-change, wrong app/window/menu/dialog result, wrong focus/selection behavior, or stale state after a state-changing action should be 1-2.
- Realism: judge whether the predicted desktop transition is behaviorally plausible for the app and action, but cap it at 3 when factuality or consistency is 1-2.
- Quality: judge usefulness as a replacement next-state observation. If a downstream agent would take the wrong next action because of missing/wrong active anchors, use 1-2; if usable only at a broad app/window level, use 3.

Before assigning any 4 or 5, explicitly verify the primary action effect plus at least these active anchors when present : active app/window/title, focused control, exact typed text/path/terminal output, dialog/menu state, selected file/item, visible list/table rows, and window geometry/scroll position.

Discriminative Error Calibration

- Treat the latest action's primary visible effect as a gate. If it is wrong, stale, or missing, set factuality ≤ 2 and quality ≤ 2 even when many background nodes match.
- If the output copies or preserves much of the prior state while the ground truth changes, score it as a stale-state error.
- Downweight generic complete-looking desktop trees: if exact active text/path/cell/menu item, selected/focused element, dialog/menu state, and visible rows/files do not match, total score should normally be ≤ 3 .