

# 大语言模型能掌握复杂卡牌游戏吗？

Wei Wang Fuqing Bie Junzhe Chen Dan Zhang  
Shiyu Huang Evgeny Kharlamov Jie Tang

中文技术阅读版：OpenReview cmN8Wbvanr, NeurIPS 2025 poster

## Abstract

这篇论文把复杂卡牌游戏作为 LLM 学习能力的压力测试，而不是只看 prompt 下的临场推理。作者用强游戏 AI 或专家数据生成高质量轨迹，把局面、历史动作、合法动作和输出格式整理成指令微调数据，然后测试模型是否能在八种规则差异很大的卡牌游戏中接近专门游戏 AI。核心业务价值是：如果同一个 LLM 架构可以通过模板和高质量数据迁移到多种复杂决策环境，那么企业在做策略助手、游戏智能体、仿真训练和多规则流程自动化时，可以减少为每个场景单独设计网络结构的成本。核心风险是：游戏微调会侵蚀通用知识、数学和代码能力，且 LLM 推理速度仍慢于专用游戏 AI。

## 1 业务问题：LLM 是会玩规则，还是会学策略

复杂游戏一直是 AI 能力展示场：AlphaGo、AlphaZero 和 MuZero 证明了强化学习与搜索可以在围棋、国际象棋等任务上达到顶尖水平。LLM 的问题不同：它本来是通用语言模型，是否只是在 prompt 里背规则，还是能通过数据真正学习复杂策略？

论文选择卡牌游戏，是因为卡牌游戏同时具备三个管理上很有价值的特征：

- **不完全信息**：玩家只能看到自己的牌和公开历史，必须在信息缺口下决策。
- **长程策略**：例如 GuanDan 和 Riichi Mahjong 的平均决策步数远高于简单扑克变体，短视动作会拖累后续局面。
- **规则异构**：斗地主、掇蛋、日麻、UNO、Gin Rummy 和三类德州扑克的动作空间与胜负指标不同，可测试同一模型架构是否能跨规则复用。




Figure 1: 原论文 Figure 1：八种卡牌游戏在信息集规模、信息集平均状态数和动作空间上的复杂度分布。

因此，这篇论文不是在证明“LLM 已经替代所有游戏 AI”，而是在回答一个更可落地的问题：当企业已有通用模型底座时，能否用高质量行为轨迹和统一微调流程，把它变成多个复杂规则系统的可用决策器。

## 2 数据与方法：把牌局变成指令微调样本

### 2.1 八个游戏和教师来源

作者按流行度、复杂度和高质量数据可得性选择八个游戏：DouDizhu、GuanDan、Riichi Mahjong、Uno、Gin Rummy、Leduc Hold'em、Limit Texas Hold'em 和 No-limit Texas Hold'em。数据来源不是让 LLM 从零探索环境，而是用强游戏 AI 或专家对局生成高质量轨迹。

| Game                   | # Players | # Teams | Teacher model/Data | Opponent   | # Games | Avg. Steps per Game | Avg. Steps per Player per Game | Total Steps (Filtered) | Avg. Legal Actions per Step | Training data |
|------------------------|-----------|---------|--------------------|------------|---------|---------------------|--------------------------------|------------------------|-----------------------------|---------------|
| DouDizhu               | 3         | 2       | DouZero            | Rule model | 200k    | 37.31               | 12.44                          | 2,950k                 | 10.06                       | 1,000k        |
| GuanDan                | 4         | 2       | DanZero            | Rule model | 6k      | 311.25              | 155.63                         | 1,220k                 | 48.67                       | 1,000k        |
| Riichi Mahjong         | 4         | 4       | Data from experts  | Mortal     | 7k      | 656.92              | 164.23                         | 1,090k                 | 8.79                        | 1,000k        |
| Uno                    | 2         | 2       | Rule model         | Random     | 50k     | 42.33               | 21.16                          | 410k                   | 3.14                        | 400k          |
| Gin Rummy              | 2         | 2       | Rule model         | Random     | 50k     | 52.14               | 26.07                          | 1,280k                 | 6.22                        | 400k          |
| Leduc Hold'em          | 2         | 2       | DQN model          | Random     | 400k    | 3.61                | 1.81                           | 580k                   | 2.86                        | 400k          |
| Limit Texas Hold'em    | 2         | 2       | DQN model          | Random     | 200k    | 5.01                | 2.50                           | 450k                   | 2.96                        | 400k          |
| No-limit Texas Hold'em | 2         | 2       | DQN model          | Random     | 400k    | 3.78                | 1.89                           | 700k                   | 4.31                        | 400k          |

Table 1: Data generation information of games.

Figure 2: 原论文 Table 1: 各游戏的玩家数、教师模型、对局数、平均步数、合法动作数和训练样本量。

关键数据策略有两点。第一，只保留赢家一方的 observation-action pair，减少失败策略进入监督数据。第二，只保留合法动作数量大于 1 的样本，避免模型在无选择局面里学到虚假的高准确率。这个过滤策略提升了训练数据质量，但也带来一个业务风险：如果赢家一方内部贡献不均，例如斗地主两个农民中只有一个真正主导胜利，另一个农民的动作仍会进入训练集，导致角色数据质量不均。

## 2.2 训练设置

训练对象包括 Qwen2.5-7B-Instruct、Llama3.1-8B-Instruct 和 GLM4-9B-Chat，同时还测试 Qwen2.5 从 0.5B 到 14B 的尺寸变化。微调使用 LLaMA-Factory 和 LoRA，rank 为 8，alpha 为 16，训练 1 epoch，峰值学习率  $10^{-4}$ ，batch size 为 128，实验服务器使用 8 张 H100 GPU。

每个样本被包装成指令格式，通常包含三类信息：

- 游戏规则和目标；
- 当前状态，例如手牌、公共牌、历史动作、剩余牌数、得分或局面阶段；
- 合法动作集合和 JSON 输出格式。

这条路线的优势是工程上清晰：不需要为每个游戏重新设计神经网络结构，只需要为每个游戏定义状态模板和动作输出格式。它的代价也清晰：性能高度依赖教师数据、状态表示和合法动作约束，不能简单外推到没有高质量轨迹的真实环境。

## 2.3 三组研究问题

论文围绕三组问题组织实验：

1. 单游戏学习：LLM 能否掌握复杂卡牌游戏？需要多少数据？
2. 多游戏学习：LLM 能否同时掌握多个游戏？相似规则是否迁移，差异规则是否冲突？
3. 通用能力保持：掌握游戏后，模型的知识问答、数学和代码能力是否下降？能否用通用数据恢复？

# 3 结果：强监督数据能带来策略能力，但会挤压通用能力

## 3.1 RQ1: 高质量数据能让 LLM 接近强游戏 AI

在 DouDizhu、GuanDan 和 Riichi Mahjong 这三个复杂度较高的游戏上，随着训练数据增加，模型表现持续提升。论文的核心判断是：给足高质量数据后，LLM 可以在复杂卡牌游戏上接近强游戏 AI。这个结论的业务意义在于，LLM 不只是能读懂规则描述，也能从轨迹中吸收策略模式。




Figure 3: 原论文 Figure 2: DouDizhu、GuanDan 和 Riichi Mahjong 上，训练数据规模增加会持续改善模型表现。

不过，角色不均衡暴露了数据治理问题。DouDizhu 中 GLM 在地主角色上表现较好，但在农民角色上明显较差；Qwen2.5-14B 也出现平均胜率低于 7B 的反常结果。作者认为原因可能不是模型尺寸本身，而是赢家过滤规则把低质量农民动作混入了训练集。这说明业务系统不能只看总胜率，还要分角色、分场景监控数据质量。

### 3.2 RQ2: 混合训练可以多游戏掌握，但迁移由规则相似性决定

作者将八个游戏的数据合并为约 3.1M 个样本，再训练混合模型。结果显示，混合微调模型在多数游戏上显著超过 API 模型和未微调 base model。尤其在 DouDizhu、GuanDan、Riichi Mahjong 等复杂游戏上，微调收益最明显。

Table 1: 原论文 Table 3 摘要：混合微调模型在复杂游戏上明显优于 API 模型和 base model。

| 模型                       | DouDizhu | GuanDan | Riichi | No-limit |
|--------------------------|----------|---------|--------|----------|
| GPT-4o                   | 0.180    | 0.019   | 0.25   | 2.73     |
| DeepSeek-R1              | 0.185    | 0.020   | 0.05   | 1.88     |
| Qwen2.5-7B-Instruct      | 0.087    | 0.000   | 0.04   | 1.25     |
| Llama3.1-8B-Instruct     | 0.155    | 0.000   | 0.08   | -2.10    |
| GLM4-9B-Chat             | 0.131    | 0.000   | 0.08   | -0.44    |
| Qwen2.5-7B-Instruct-mix  | 0.852    | 0.634   | 1.08   | 4.86     |
| Llama3.1-8B-Instruct-mix | 0.870    | 0.661   | 1.38   | 6.02     |
| GLM4-9B-Chat-mix         | 0.882    | 0.698   | 1.31   | 5.77     |

迁移不是无条件发生。GuanDan 对 DouDizhu 有正迁移，因为两者规则相似；Leduc、Limit Texas 和 No-limit Texas 之间也有正迁移，因为它们都属于德州扑克体系。相反，DouDizhu/GuanDan 与其他六个游戏之间可能存在冲突。业务判断是：多任务训练要按规则族群分层，不应把所有决策任务粗暴混在一起。




Figure 4: 原论文 Figure 5: DouDizhu 与 GuanDan 的混合训练可互相增强，说明规则相似性会带来迁移收益。

### 3.3 RQ3: 游戏能力会挤压通用能力，通用数据可部分恢复

混合游戏微调后，模型在 MMLU-Pro、Math-500 和 HumanEval 上出现下降。作者再用知识、数学、代码和少量游戏数据继续微调，发现通用能力可部分恢复，同时游戏能力大体保持。

**Table 2:** 原论文 Figure 7 摘要：游戏微调损伤通用能力，追加通用数据后部分恢复。

| 模型                      | MMLU-Pro | Math-500 | HumanEval | 平均    |
|-------------------------|----------|----------|-----------|-------|
| Llama3.1-8B             | 47.95    | 46.60    | 70.73     | 55.09 |
| Llama3.1-8B-mix         | 44.74    | 35.20    | 60.98     | 46.97 |
| Llama3.1-8B-mix-general | 45.18    | 47.20    | 65.24     | 52.54 |
| GLM4-9B                 | 48.04    | 52.40    | 76.22     | 58.89 |
| GLM4-9B-mix             | 35.12    | 37.20    | 39.63     | 37.32 |
| GLM4-9B-mix-general     | 31.75    | 41.00    | 68.90     | 47.22 |

这对业务部署很重要：如果一个通用模型被微调为高强度游戏或策略模型，不能默认它仍保留原有办公、数学和代码能力。更稳妥的做法是把专用能力和通用能力都纳入回归评测，并在持续训练中加入通用数据保持机制。

## 4 业务解读：这篇论文适合放在“通用模型专用化”框架里看

### 4.1 优势

这篇工作的最大优势是把 LLM 的学习能力评估从 prompt 迁移到监督微调。prompt 测试只能说明模型是否能临时理解规则；监督微调测试的是模型能否吸收大量高质量决策轨迹，并形成稳定策略。对业务来说，后者更接近真实产品：企业往往有历史工单、交易轨迹、客服决策、流程审批或仿真对局，关键问题是这些轨迹能否转化为模型能力。

第二个优势是架构复用。传统游戏 AI 往往要为每个游戏设计专门网络，DouZero 甚至为不同角色准备不同模型。LLM 路线用同一个模型架构承接不同游戏，差异主要体现在模板、状态表示和动作约束。它降低的是系统建设成本，而不是单次推理成本。

### 4.2 劣势与风险

第一，LLM 推理慢。论文在限制部分明确指出，虽然 LoRA 降低了可训练参数量，但推理仍要计算完整模型参数，因此比专门游戏 AI 慢。对实时游戏、低延迟撮合或高频仿真来说，这是硬约束。

第二，数据过滤会塑造模型偏差。只保留赢家动作是合理的质量控制，但如果赢家团队内部动作质量不均，就会把弱策略混入正样本。斗地主农民角色表现异常就是一个提醒：监督学习系统的上限不是模型参数量，而是轨迹标签质量。

第三，通用能力会被挤压。游戏微调提高了策略表现，但会降低知识问答、数学和代码分数。业务上不能把“某个专用能力变强”误读为“模型整体变强”。上线前必须有通用能力回归测试。

### 4.3 可复用方法论

如果把这篇论文迁移到企业场景，可抽象成五步：

1. 选择有明确状态、动作和收益反馈的复杂决策任务；
2. 建立高质量轨迹来源，优先使用专家、强规则系统或历史成功案例；
3. 将每一步状态和合法动作转成结构化指令样本；
4. 按任务族群做混合训练，避免低相似度任务互相冲突；
5. 同时评测专用能力、通用能力、角色公平性和推理延迟。

## 5 结论

论文的业务结论可以概括为：LLM 可以通过高质量轨迹微调掌握复杂卡牌游戏，甚至在同一架构下同时学习多个规则体系；但迁移收益依赖任务相似性，通用能力会被专用化训练挤压，推理效率仍弱于专用模型。

因此，这篇论文适合放入前沿 BFS 的“通用模型专用化与复杂决策学习”分支。它的价值不在于证明 LLM 已经全面超过游戏 AI，而在于展示了一条可复用路径：用高质量行为数据和模板化状态表达，把通用模型改造成跨规则复杂决策器。