

用于时间序列分析的概率 Transformer

Binh Tang
康奈尔大学统计与数据科学系
Ithaca, NY 14850
bvt5@cornell.edu

David S. Matteson
康奈尔大学统计与数据科学系
Ithaca, NY 14850
matteson@cornell.edu

摘要

多变量时间序列的生成式建模仍然具有挑战性，部分原因在于长距离时间步之间存在复杂且非确定性的动态。本文提出一种把状态空间模型 (SSM) 与 Transformer 架构结合起来的深度概率方法。与先前提出的 SSM 不同，我们的方法使用注意力机制在潜空间中建模非 Markov 动态，并完全避免 recurrent neural networks。我们还把模型扩展为包含多层随机变量，并以层级结构组织这些变量，以进一步增强表达能力。与 Transformer 模型相比，我们的方法是概率式、非自回归的，并且能够生成多样化的长期预测，同时计入不确定性。大量实验表明，我们的模型在多种任务和数据集上持续超越有竞争力的 baseline，包括时间序列预测和人体运动预测。

1 引言

多变量时间序列的生成式建模是一个具有广泛应用的挑战性问题的应用，包括需求预测 [15, 76]、自动驾驶 [2, 16]、机器人学 [29, 67] 和医疗健康 [20, 21, 59]。尽管近年来取得了显著进展，基于少量过去样本来预测高维未来观测的模型仍然难以处理；部分原因在于长距离时间步之间存在复杂且非确定性的时间动态。以一段人体姿态序列为例，这类模型必须在空间和时间上内部辨识多个身体部件所涉及的动态，同时保持多种可能未来固有的不确定性，即便实际只观测到其中一种未来。

在已提出的概率方法中，状态空间模型 (SSM) 为从序列输入中学习和推断提供了原则性框架 [27, 66]。自回归模型会把自身预测反馈到动态模型中，而不对数据进行任何压缩表示；与之不同，SSM 使用潜变量对抽象状态之间的随机转移建模，因此能够进行高效的 state-to-state 采样，而不需要渲染高维观测。Gaussian linear dynamical systems (LDS) 是最著名的 SSM 之一 [92]，它假设线性状态转移，并可通过著名的 Kalman filter 算法进行精确推断。

早期 LDS 扩展主要关注线性化 [46] 和 unscented transform [88]；近来的工作则把状态空间模型与深度神经网络结合，从而为建模不同时间步之间的复杂依赖提供更大灵活性。一些方法保留 LDS 的 Markov 动态，只用 feed-forward networks 替换其线性观测模型 [23, 31, 47, 71]；另一些方法偏好非线性状态转移，并通过 recurrent neural networks (RNN) 参数化这种依赖 [22, 23, 30, 39, 51, 75]。尽管具体方式不同，Markov 转移和 RNN 往往都无法捕捉高度结构化序列输入中的长程依赖 [36, 100]，从而限制对应 SSM 的能力。




图 1: 线性动力系统 (LDS) 以及本文所提出模型 (ProTran) 的图模型表示: (a) LDS, (b) ProTran (1 层), (c) ProTran 生成过程 (3 层), (d) ProTran 推断过程 (3 层)。黑色箭头表示生成机制, 红色箭头表示推断过程。为了可读性, (c) 与 (d) 分开展示生成和推断。传统 SSM 如 LDS 受限于 Markov 动态和线性依赖, 而本文模型通过注意力机制允许时间步之间存在非 Markov 与非线性交互。多层扩展进一步提升模型表达能力, 同时不损害可处理的推断过程。

本文提出将 SSM 与 Transformer 架构 [85] 的互补优势结合起来; Transformer 是一种用于建模长期交互的强大机制, 已在多种序列建模任务中取得成功 [26, 48, 99]。与大多数 SSM 不同, 我们的模型在潜变量之间大量使用注意力机制 [5, 85] 来建模非 Markov 动态 (见图 1)。与基于 Transformer 的方法相比, 我们的模型是概率式的、以类似 LDS 的方式非自回归, 并且能够生成带有不确定性估计的多样长期预测。

我们的主要贡献有三点。第一, 我们提出了基于 Transformer 架构的多变量时间序列新型 SSM, 其中包括基于变分推断 [49, 74] 的生成模型和推断过程。第二, 我们把模型扩展到包含多层随机潜变量, 并以层级结构组织它们, 以进一步提高表达能力。第三, 我们在时间序列预测和人体运动预测上进行了大量实验, 证明 Probabilistic Transformer (ProTran) 相较多种 state-of-the-art baseline 表现显著。

2 预备知识

2.1 变分状态空间模型

令 $\{x_{1:T_i}^{(i)}\}_{i=1}^N$ 表示 N 个单变量时间序列, 其中 $x_{1:T_i}^{(i)} = (x_1^{(i)}, x_2^{(i)}, \dots, x_{T_i}^{(i)})$, $x_t^{(i)}$ 表示第 i 个时间序列在时间 t 的取值。我们考虑多变量形式 $x_{1:T} = (x_1, x_2, \dots, x_T)$, 其中 $x_t = (x_t^{(1)}, \dots, x_t^{(N)}) \in \mathbb{R}^N$ 。在条件化于截至时间 C 的观测值后, 我们的目标是对未来产生分布式预测 $p(x_{C+1:T} | x_{1:C})$ 。为清晰起见, 我们把 $x_{1:C}$ 和 $x_{C+1:T}$ 分别称为 contexts 和 targets。

我们关注由 θ 参数化的概率模型, 其形式为

$$p_\theta(x_{1:T} | x_{1:C}) = \int p_\theta(x_{1:T} | z_{1:T}) p_\theta(z_{1:T} | x_{1:C}) dz_{1:T}, \quad (2.1)$$

其中 $z_{1:T} = (z_1, z_2, \dots, z_T)$ 表示对应的潜变量序列, 有时也称为 states。换言之, 我们假设一个生成模型可分解为: 在 contexts 条件下潜变量之间的 transition model $p_\theta(z_{1:T} | x_{1:C})$, 以及从潜变量到可观测输出的 emission model $p_\theta(x_{1:T} | z_{1:T})$ 。具体而言, 我们进一步对两个模型施加若干假设:

$$p_\theta(z_{1:T} | x_{1:C}) = \prod_{t=1}^T p_\theta(z_t | z_{1:t-1}, x_{1:C}), \quad p_\theta(x_{1:T} | z_{1:T}) = \prod_{t=1}^T p_\theta(x_t | z_t). \quad (2.2)$$

如图 1(b) 所示, 与线性动力系统 (LDS) 不同, 潜变量 z_{t+1} 不仅依赖于 z_t , 还依赖所有前序潜变量, 包括 z_{t-1} 。此外, transition 与 emission 模型允许通过神经网络参数化来引入非线性。这些假设旨在最大化模型对复杂 emission 或时间依赖的真实应用的容量。

然而, $x_{1:t-1}$ 和 $z_{1:t-1}$ 都不包含在 emission model $p(x_t | z_{1:T}, x_{1:C})$ 中。这类假设很重要, 因为此前已有论证指出, 自回归模型中来自潜空间的信息泄漏会妨碍长期预测 [23, 47]。虽然训练时所有真实观测可用, 但测试时整个序列必须顺序生成, 这使得对 $x_{1:t-1}$ 的依赖容易在多个时间步上累积误差。通过让潜变量 z_t 捕获渲染 x_t 所需的全部信息, 我们还避免了在多步预测中反复解码和编码 x_t 所带来的计算成本。

引入非线性状态转移和观测模型必然需要近似推断。我们遵循 stochastic variational inference 框架 [49, 74], 并假设由 ϕ 参数化的变分后验可自回归分解为 $q_\phi(z_{1:T} | x_{1:T}) = \prod_t q_\phi(z_t | z_{1:t-1}, x_{1:T})$, 从而得到 log likelihood 的下界:

$$\log p_\theta(x_{1:T} | x_{1:C}) \geq \sum_{t=1}^T (\mathbb{E}_q[\log p_\theta(x_t | z_t)] - \text{KL}(q_\phi(z_t | z_{1:t-1}, x_{1:T}) \| p_\theta(z_t | z_{1:t-1}, x_{1:C}))), \quad (2.3)$$

其中 KL 是 Kullback-Leibler divergence。

为保证计算稳定性, 我们假设 homoscedasticity, 并选择尺度参数为 β 的 Laplace 分布作为 $p_\theta(x_t | z_t)$ 的参数形式, 即使用 L_1 reconstruction loss, 并为 KL 项使用 cross-validated factor β , 这与类似 VAE 工作一致 [24, 41, 86]。这一假设并不必然限制模型能力, 因为强大的随机转移与灵活 emission model 理论上可以刻画任意噪声协方差 [66]。引入结构化概率输出, 例如 Gaussian copulas [75] 或 normalizing flows [23], 可能进一步改善模型性能。

2.2 Transformer 架构

本文模型和其他基于 Transformer 的方法 [48, 85] 的核心, 是 attention 概念 [5]; 它允许模型聚焦于 context 中的重要部分。例如, multi-head attention 把长度为 ℓ_q 的 query 序列 $Q \in \mathbb{R}^{\ell_q \times d}$ 映射为同等大小的输出序列 $O = [O_1, \dots, O_H] \in \mathbb{R}^{\ell_q \times d}$, 方式是对给定的 ℓ_k 个 key-value 对 $K \in \mathbb{R}^{\ell_k \times d}$ 、 $V \in \mathbb{R}^{\ell_k \times d}$ 进行 attention:

$$O_h = \text{Attention}(Q_h, K_h, V_h) = \text{Softmax}\left(\frac{Q_h K_h^\top}{\sqrt{d}}\right) V_h, \quad (2.4)$$

其中 $Q_h = Q W_h^Q$ 、 $K_h = K W_h^K$ 、 $V_h = V W_h^V$ 是与 head $h \in [1, H]$ 对应的投影 queries、keys 和 values, 学习参数分别为 W_h^Q, W_h^K, W_h^V 。当 $Q = K = V$ 时, 我们称这种 attention 机制为 self-attention。

给定完全观测的输入序列, 该映射可以高效计算, 而不需要 recurrent neural networks 中常见的强制顺序 [19, 42]。更重要的是, 长距离时间步之间的直接连接被内置在机制中; 由于先前时间步信息可以不经压缩为固定表示而被轻易访问, 优化和长期依赖学习也随之变得更容易 [5, 85]。

没有 recurrence 时, Transformer [85] 使用预定义 sinusoidal positional embeddings 编码每个时间步 t 的信息: $\text{Position}(t) = [p_t(1), \dots, p_t(d)] \in \mathbb{R}^d$, 其中第 i 个 embedding 在 i 为偶数时为 $p_t(i) = \sin(t \cdot c^{i/d})$, 在 i 为奇数时为 $p_t(i) = \cos(t \cdot c^{i/d})$, c 是某个较大常数。经验结果表明, 这类 positional embeddings 对我们的模型也很重要。

3 Probabilistic Transformer

本节首先介绍单层模型, 随后介绍面向层级随机潜变量的多层扩展。如前文所述, 我们的模型由生成模型和推断模型组成, 二者广泛共享信息和参数。

3.1 单层 Probabilistic Transformer

生成模型 给定 contexts $x_{1:C}$, 我们首先应用线性投影, 并与 positional embedding 结合, 以获得 $h_{1:C} \in \mathbb{R}^d$, 即

$$h_t = \text{LayerNorm}(\text{MLP}(x_t) + \text{Position}(t)), \quad (3.1)$$

其中 LayerNorm 和 MLP 分别表示 layer normalizations [4] 与 multi-layer perceptrons。传统 Transformer 模型通常会为相同目的使用完整 encoder [55, 72]，但我们发现，当它与对应 decoder 的 context-attention 模块结合时，这种简单映射已经足够有效。

如式 (2.2) 所示，我们的潜动态以自回归方式分解。在每个时间步，我们用 Gaussian 参数化分布 $p_\theta(z_t | z_{1:t-1}, x_{1:C})$ ；其参数由两个连续的 attention 步骤产生：先在此前推断出的 states $z_{1:t-1}$ 上做 self-attention，再在投影后的 contexts $h_{1:C}$ 上做另一个 attention。这两个操作对应 Transformer [85] decoder 中的操作，只是 stochastic latent variables 替代了 decoder inputs。

遗憾的是，直接使用 z_t 的随机样本作为 attention queries 存在问题，因为纯随机转移会使模型难以在多个时间步上可靠保留信息 [17, 30, 39]。因此，我们把潜变量封装进 hidden representations w_t ，其中还包含确定性成分。结合 attention 步骤后，这类表示有助于建模长程时间依赖，同时计入未来观测的随机性。

从一个可学习且 context-agnostic 的表示 w_0 出发，我们使用来自 $p_\theta(z_t | z_{1:t-1}, x_{1:C})$ 的随机样本和当前时间步 t 的 positional embedding 递归更新 w_t 。时间步 t 的生成过程可由如下伪代码概括：

$$\bar{w}_t = \text{LayerNorm}(w_{t-1} + \text{Attention}(w_{t-1}, w_{1:t-1}, w_{1:t-1})), \quad (3.2)$$

$$\hat{w}_t = \text{LayerNorm}(\bar{w}_t + \text{Attention}(\bar{w}_t, h_{1:C}, h_{1:C})), \quad (3.3)$$

$$z_t = \text{Sample}(\mathcal{N}(z_t; \text{MLP}(\hat{w}_t), \text{Softplus}(\text{MLP}(\hat{w}_t)))), \quad (3.4)$$

$$w_t = \text{LayerNorm}(\hat{w}_t + \text{MLP}(z_t) + \text{Position}(t)), \quad (3.5)$$

其中 Sample 和 Softplus 分别是 Gaussian sampling 和近似 rectifier operators。

随后，每个 $w_{1:T}$ 的随机样本通过 multi-layer perceptron 映射到序列 $x_{1:T}$ 。我们强调，在潜空间中的生成过程比在观测空间中的其他方法更高效；后者需要反复编码和解码高维输入。

推断模型 我们以类似 prior $p_\theta(z_t | z_{1:t-1}, x_{1:C})$ 的方式，参数化时间步 t 的近似后验 $q_\phi(z_t | z_{1:t-1}, x_{1:T})$ 。事实上，这些参数化共享大多数参数，并在同一个递归循环中同时完成，遵循式 (3.2) 和式 (3.3) 中完全相同的步骤（见图 1）。我们注意到，生成过程和推断过程之间的类似共享技术，已成为近期成功 VAE 模型中的共同主题 [17, 62, 83]。

prior 只能访问条件观测 $x_{1:C}$ ，而近似后验在训练期间应考虑所有观测，包括 targets $x_{C+1:T}$ 。由于 RNN 固有的单向性，此前使用 RNN 参数化近似后验的工作往往忽略这一性质 [22, 30, 51]，并常退化为 filtering routine $p(z_t | z_{1:t-1}, x_{1:t})$ 。相比之下，我们的推断过程更类似 LDS 中的 smoothing 过程，通过另一次 self-attention 同时纳入过去和未来观测：

$$k_t = \text{Attention}(h_{1:T}, h_{1:T}, h_{1:T}), \quad (3.6)$$

$$z_t = \text{Sample}(\mathcal{N}(z_t; \text{MLP}([\hat{w}_t, k_t]), \text{Softplus}(\text{MLP}([\hat{w}_t, k_t])))). \quad (3.7)$$

这里，我们用式 (3.6) 替换生成模型中的式 (3.4)，其中 hidden representation k_t 汇总了与当前时间步 t 相关的全部信息，并在 Gaussian 参数化之前与 latent-and-context-aware 表示 $\hat{w}_t$ 拼接。

生成模型和推断模型使用式 (2.3) 中的单一 stochastic variational inference 目标端到端训练。该变分界包含 $x_{1:C}$ 的 reconstruction loss 和 $z_{1:C}$ 的 KL 项。另一种选择是从目标中排除这些项，这等价于从 $t = C + 1$ 而非 $t = 1$ 开始推断过程。

我们的模型时间复杂度为 $O(T^2d)$ ，内存成本为 $O(T^2d)$ ，其中 T 是总序列长度， d 是潜空间维度。递归潜动态也不允许充分利用可并行化 attention。不过我们发现，在实践中模型仍然高效，尤其是在 T 取合理小值时。

3.2 Probabilistic Transformer 的多层扩展

受近期非序列输入层级 VAE 工作启发 [17, 80, 83, 101]，我们把所提出模型扩展为包含若干层潜变量，目标是进一步提升其对序列数据建模的灵活性。

为简化起见，我们用 L 个潜变量构成的 Markov chain 表示每个时间步 t ，即 $z_t^{(1:L)} = (z_t^{(1)}, \dots, z_t^{(L)})$ （见图 1）。生成模型和推断模型也在不同时间步之间自回归分解，并可能表现出非 Markov 动态：

$$p_\theta(x_{1:T}, z_{1:T}^{(1:L)} | x_{1:C}) = \prod_{t=1}^T p_\theta(x_t | z_t^{(L)}) \prod_{\ell=1}^L \prod_{t=1}^T p_\theta(z_t^{(\ell)} | z_{1:t-1}^{(\ell)}, z_{1:T}^{(\ell-1)}, x_{1:C}), \quad (3.8)$$

$$q_\phi(z_{1:T}^{(1:L)} | x_{1:T}) = \prod_{\ell=1}^L \prod_{t=1}^T q_\phi(z_t^{(\ell)} | z_{1:t-1}^{(\ell)}, z_{1:T}^{(\ell-1)}, x_{1:T}). \quad (3.9)$$

直观上，我们通过从底向上遵循潜动态，并在每一层内使用前述生成过程，来根据 $x_{1:C}$ 生成样本 $x_{1:T}$ 。类似地，推断以相同顺序进行，从而得到与式 (2.3) 类似的变分界：

$$\log p_\theta(x_{1:T} | x_{1:C}) \geq \sum_{t=1}^T \mathbb{E}_q \left[\log p_\theta(x_t | z_t^{(L)}) \right] \quad (3.10)$$

$$- \sum_{\ell=1}^L \text{KL} \left(q_\phi(z_t^{(\ell)} | z_{1:t-1}^{(\ell)}, z_{1:T}^{(\ell-1)}, x_{1:T}) \| p_\theta(z_t^{(\ell)} | z_{1:t-1}^{(\ell)}, z_{1:T}^{(\ell-1)}, x_{1:C}) \right). \quad (3.11)$$

与前文一样，我们使用同一层此前时间步中推断得到的 latent variables $w_{t-1}^{(\ell)}$ 上的 self-attention，以及 contexts $h_{1:C}$ 上的另一个 attention，来参数化 prior $p_\theta(z_t^{(\ell)} | z_{1:t-1}^{(\ell)}, z_{1:T}^{(\ell-1)}, x_{1:C})$ 。然而在这种情况下，我们额外加入对下一层所有 latent variables 的 self-attention（见式 (3.11)）：

$$\tilde{w}_t^{(\ell)} = \text{LayerNorm}(w_{t-1}^{(\ell)} + \text{Attention}(w_{t-1}^{(\ell)}, w_{1:T}^{(\ell-1)}, w_{1:T}^{(\ell-1)})), \quad (3.12)$$

$$\bar{w}_t^{(\ell)} = \text{LayerNorm}(\tilde{w}_t^{(\ell)} + \text{Attention}(\tilde{w}_t^{(\ell)}, w_{1:t-1}^{(\ell)}, w_{1:t-1}^{(\ell)})), \quad (3.13)$$

$$\hat{w}_t^{(\ell)} = \text{LayerNorm}(\bar{w}_t^{(\ell)} + \text{Attention}(\bar{w}_t^{(\ell)}, h_{1:C}, h_{1:C})), \quad (3.14)$$

$$z_t^{(\ell)} = \text{Sample}(\mathcal{N}(z_t^{(\ell)}; \text{MLP}(\hat{w}_t^{(\ell)}), \text{Softplus}(\text{MLP}(\hat{w}_t^{(\ell)})))), \quad (3.15)$$

$$w_t^{(\ell)} = \text{LayerNorm}(\hat{w}_t^{(\ell)} + \text{MLP}(z_t^{(\ell)} + \text{Position}(t))). \quad (3.16)$$

堆叠多层潜变量会增加模型表达能力，但也会使运行时间和参数数量线性增加。 L 层 Transformer 的时间复杂度为 $O(LT^2d)$ ；由于每个时间步 t 的 chain $z_t^{(1:L)}$ 具有 Markov 结构，空间复杂度仍保持为 $O(T^2d)$ 。在实验中，我们把层级模型层数限制为两层或三层。

4 相关工作

Deep State Space Models 深度神经网络已经被广泛结合到状态空间模型中，由此形成灵活且具有原则性动机的潜变量方法。一些工作保留线性状态转移，以利用高效 Kalman filter 算法 [23, 31, 47, 71]；另一些工作提出由神经网络参数化的更具表达力的非线性潜动态 [51, 52]。这些模型都受限于 LDS 的 Markov 动态，这会妨碍长程依赖学习。通常的缓解方式，是把随机转移与确定性 RNN 结合，使模型能够访问所有过去状态 [3, 8, 22, 30, 39, 77]。我们的模型同样是非 Markov 的，但对过去状态的依赖通过 attention 完成，这使长距离时间步之间能够容易建立连接。此外，多数已有 deep SSM 每个时间步只用一个潜变量表示，而我们的模型包含多层层级潜变量，并具有可处理的推断机制。

Attentive Recurrent Networks 注意力机制也已被近期时间序列工作广泛采用，包括 sequence-to-sequence 模型 [1, 28] 和 Transformer 架构 [14, 55, 57, 72, 81, 94]。虽然我们的模型配备潜变量，但这些 Transformer 方法 [55, 72] 缺少推断机制，并且在测试时容易把观测噪声反馈到动态模型中。相反，我们的工作可被视为对 [1] 中 attentive state space model 的扩展，即把离散潜状态替换为连续对应物。自然语言处理中的近期进展 [58, 60, 90] 也结合 Transformer 与 VAE；然而这些方法往往使用 time-agnostic latent variable，与我们的 SSM 形式不同。

时间序列预测 传统单变量时间序列模型，例如 Box-Jenkins methods [12] 和 exponential smoothing [43]，通常假设任意时间序列集合之间相互独立 [76]。经典方法的多变量扩展，包括 vector autoregression

[82] 和 multivariate GARCH [7], 虽不要求如此强的假设, 但它们引入许多其他假设, 例如 stationarity 和 homoscedasticity, 需要人工选择 covariates 和模型, 并且即使面对中等数量的时间序列也难以良好扩展 [40, 69]。

深度学习时间序列预测方法近来已成为工业应用中富有表达力且可扩展的框架 [10, 68, 79, 91]。早期工作聚焦点预测 [53, 70, 96], 近期方法则常使用 recurrent neural networks 直接参数化概率预测 [76], 或使用 quantile functions [33]、Gaussian copulas [75]、normalizing flows [23]、diffusion models [73]。相比之下, 我们的模型完全不使用这类 recurrent architectures, 而是依靠潜变量输出分布式预测。

人体运动预测 尽管人体运动预测在形式上几乎相同, 但它常被独立于时间序列预测进行研究。一些工作确定性地生成未来运动或视频帧 [13, 32, 34, 56], 也有工作提出使用深度神经网络的随机预测; 在复杂运动数据集上, 这类方法往往优于 hidden Markov models [93] 或 Gaussian processes [89] 等传统方法 [13, 32, 45, 54, 63]。与此前通过 conditional VAE [49] 在不同时间步之间使用全局潜变量的工作 [95, 97] 不同, 我们利用状态空间模型这一原则性框架, 学习并推断层级、时间依赖的潜变量。

5 实验

我们展示两个任务上的实验结果: 时间序列预测和人体运动预测。尽管这两个任务本质上几乎都是条件预测问题, 但它们通常被独立研究。

表 1: 时间序列预测模型测试集 CRPS_{sum} (越低越好)。均值和标准差基于五次不同随机种子运行计算。

Dataset	Solar	Electricity	Traffic	Taxi	Wikipedia
VES [43]	0.900 ± 0.003	0.880 ± 0.004	0.350 ± 0.002	-	-
VAR [61]	0.830 ± 0.006	0.039 ± 0.001	0.290 ± 0.001	-	-
VAR-Lasso [61]	0.510 ± 0.006	0.025 ± 0.000	0.150 ± 0.002	-	3.100 ± 0.004
GARCH [84]	0.880 ± 0.002	0.190 ± 0.001	0.370 ± 0.001	-	-
DeepAR [76]	0.336 ± 0.014	0.023 ± 0.001	0.055 ± 0.003	-	0.127 ± 0.042
LSTM-Copula [75]	0.319 ± 0.011	0.064 ± 0.008	0.103 ± 0.006	0.326 ± 0.007	0.241 ± 0.003
GP-Copula [75]	0.337 ± 0.024	0.024 ± 0.002	0.078 ± 0.002	0.208 ± 0.183	0.086 ± 0.004
KVAE [51]	0.340 ± 0.025	0.051 ± 0.019	0.100 ± 0.005	-	0.095 ± 0.012
NKF [23]	0.320 ± 0.020	0.016 ± 0.001	0.100 ± 0.002	-	0.071 ± 0.002
Transformer-MAF [72]	0.301 ± 0.014	0.021 ± 0.000	0.056 ± 0.001	0.179 ± 0.002	0.063 ± 0.003
TimeGrad [73]	0.287 ± 0.020	0.021 ± 0.001	0.044 ± 0.006	0.114 ± 0.020	0.049 ± 0.002
ProTran (Ours)	0.194 ± 0.030	0.016 ± 0.001	0.028 ± 0.001	0.084 ± 0.003	0.047 ± 0.004

5.1 时间序列预测

数据集与协变量 遵循 [72, 73, 75] 中的实验设置, 我们在五个常用公开数据集上评估模型和多个有竞争力的 baseline: SOLAR、ELECTRICITY、TRAFFIC、TAXI 和 WIKIPEDIA。数据以小时或天为频率记录, 并表现出不同频率的季节性模式 (更多数据集细节见补充材料 Appendix A)。与 [72, 73] 一样, 协变量包括 lagged inputs、固定时间 embeddings (例如星期几、一天中的小时) 和可学习的 time-series embeddings。输入在送入模型之前使用条件样例进行缩放, 预测随后再适当缩放回来。

指标 遵循 [23, 72, 75], 我们使用在时间序列上求和的 continuous ranked probability score (CRPS) [65] 评估模型和所有 baseline, 记为 CRPS_{sum}。给定单变量分布函数 F 和观测 x , CRPS 定义为

$$\text{CRPS}(F, x) = \int_{\mathbb{R}} (F(z) - 1_{\{x \leq z\}})^2 dz, \quad (5.1)$$

其中 $1_{\{x \leq z\}}$ 是 indicator function。如 de Bézenac et al. [23] 所论证, CRPS_{sum} 是 proper scoring rule [35], 并且无需解析预测分布即可计算。我们以 rolling 方式计算指标, 并与上述工作类似, 为分布式预测使用 100 个样本。

Baselines 我们将模型与多种 baseline 比较, 包括: (1) VES [43], 一种 innovation state space model; (2) VAR-Lasso 和 VAR [61], 两种分别带有和不带 Lasso regularization 的多变量线性自回归模型; (3) GARCH [84], 一种多变量条件异方差模型; (4) DeepAR [76], 一种自回归 recurrent neural network; LSTM-Copula 和 GP-Copula [75], 两种使用 Gaussian copula 建模非线性的 RNN-based 模型; (5) KVAE [51], 一种基于线性动态的变分方法; (6) NKF [23], 一种与 Kalman filters 耦合的 normalizing-flow 模型; (7) Transformer [72], 一种基于 masked autoregressive flow 的 Transformer 模型; (8) TimeGrad [73], 一种近期使用 diffusion model 的自回归方法。

实现 我们使用 8-head attention 和 2-layer MLP 参数化生成模型和推断模型。随机潜变量 z_t 为 16 维, 而 hidden representation $w_t \in \mathbb{R}^{128}$ 。用于 SOLAR 和 ELECTRICITY 的 probabilistic transformers 有一层随机层; 其他具有更高维观测的数据集使用两层。我们在补充材料 Appendix C 的表 4 中报告模型参数数量, 它们均与 state-of-the-art 方法相当。更多超参数和训练过程细节见补充材料 Appendix D。

表 2: TRAFFIC 上的消融研究。

组件	A	B	C	D
Two Layers	X	×	×	×
One Layer	×	X	X	X
Context Attention	X	X	×	X
Deterministic	×	×	×	X
CRPS_{sum}	0.028	0.031	0.033	0.041




图 2: ProTran (本文模型) 在 TRAFFIC 数据集前 16 个时间序列中的预测区间和测试集真实值。

准确率比较 表 1 表明, 我们的模型在五个高维时间序列数据集上都具有竞争力; 在 ELECTRICITY 和 WIKIPEDIA 上取得与最佳方法相当的 $CRPS_{sum}$, 并在 SOLAR、TRAFFIC 和 TAXI 上以显著幅度超越所有 baseline, 包括一个非 SSM 的 Transformer-based 方法 [72]。补充材料 Appendix B 中使用 CRPS 和 MSE 等其他指标的进一步分析也确认了这些发现。

定性结果 图 2 显示, 本文模型生成的分布式预测紧密跟随真实值, 这与准确率结果一致。此外, 模型似乎在一定程度上捕捉到了未来预测的不确定性; 幅度较大的观测以及更远未来的观测, 似乎正确地具有更高方差估计。

消融研究 我们在 TRAFFIC 数据集上加入小规模消融研究, 以考察模型中哪些组件是必要的。表 2 表明, 从 w_t 中移除随机性对模型性能影响最大, 这暗示把潜变量并入 Transformer 确实有用。context attention 或多层随机变量等其他方面在本研究中并未显示出剧烈效果; 不过它们确实带来性能收益。

5.2 人体运动预测

数据集 遵循 [97] 中的实验设置, 我们在两个公开 motion capture 数据集上评估模型: Human3.6M [44] 和 HumanEva-I [78]。Human3.6 是一个大规模数据集, 包含以 50Hz 记录的 360 万帧视频; HumanEva-I 较小, 只有 3 个 subject, 并以 60Hz 记录。我们遵循先前工作 [64, 97] 的预处理步骤, 为 Human3.6 得到 17-joint skeleton, 为 HumanEva-I 得到 15-joint skeleton。与 [97] 一样, 我们在 Human3.6 上基于 0.5 秒观测运动预测未来 2 秒运动, 在 HumanEva-I 上基于 0.25 秒观测运动预测未来 1 秒运动。




图 3: 真实姿态序列（第一行）以及 ProTran 对应预测（第二行）。实色表示较晚时间步，淡色表示较早时间步。预测姿态和真实姿态中的身体部件运动呈现相似模式，同时保留一定变异。

表 3: 人体运动预测结果。

方法	Human3.6M		HumanEva-I	
	ADE ↓	FDE ↓	ADE ↓	FDE ↓
ERD [32]	0.722	0.969	0.382	0.461
acLSTM [56]	0.789	1.126	0.429	0.541
MT-VAE [95]	0.457	0.595	0.345	0.403
Pose-Knows [87]	0.461	0.560	0.269	0.296
HP-GAN [6]	0.858	0.867	0.772	0.749
Best-Many [11]	0.448	0.533	0.271	0.279
GMVAE [25]	0.461	0.555	0.305	0.345
DeliGAN [38]	0.483	0.534	0.306	0.322
DSP [98]	0.493	0.592	0.273	0.290
DLow [97]	0.425	0.518	0.251	0.268
ProTran (Ours)	0.381	0.491	0.258	0.255

指标 遵循此前 trajectory forecasting 工作 [2, 37]，我们采用两个常用指标：average displacement error (ADE) 和 final displacement error (FDE)。ADE 衡量所有时间步上真实运动与最近样本之间的平均 L_2 距离，而 FDE 只考虑最终姿态上的该距离。

Baselines 我们将模型与 9 个模型比较，包括 ERD [32] 和 acLSTM [56] 两种 deterministic RNN-based 方法；MT-VAE [95] 和 Pose-Knows [87] 两种 conditional VAE 模型；HP-GAN [6]，一种 conditional GAN；Best-Many [11]、GMVAE [25]、DeliGAN [38] 和 DSP [98] 四种优化 diversity objectives 的方法。这些 baseline 的结果按 [97] 报告。

实现 与前述实验类似，我们使用 8-head attention 和 2-layer MLP。由于 Human3.6M 比时间序列预测数据集明显更复杂且更具多模态性，我们使用 3 层随机层，而 HumanEva-I 使用 2 层。对于 Human3.6M，context 和 target observations 明显更长，并被设置为长期预测，因此我们只对 target observations 推断潜变量。补充材料 Appendix C 还包含关于模型及其参数数量的进一步细节。

定量结果 表 3 显示，基于 ADE 和 FDE 两个指标，我们的模型令人信服地超越所有 baseline；在更大的 Human3.6M 数据集上收益显著更高。我们强调，有利性能是用随机样本评估得到的；而最接近的竞争者 DLow [97] 依赖一个单独模型选择样本以提升多样性，这一机制可能与我们的 probabilistic transformer 结合，以进一步改进。

定性结果 图 3 展示了本文模型做出的人体姿态预测；这些预测是在一组随机预测中与对应真实值最相似的结果。两个序列中身体部件运动的相似性表明，模型已经很好地捕捉了时间动态。

6 结论与讨论

在这项工作中，我们提出了用于多变量时间序列的生成模型，它结合了状态空间模型与 Transformer 架构的优势。与以往工作不同，我们的模型不依赖循环神经网络，而是广泛使用注意力机制。受非序列数据 VAE 近期发展的启发 [17, 83]，我们还将模型扩展为包含层次化潜变量。实证实验表明，我们的模型在时间序列预测和人体运动预测上表现非常好。

然而，我们的模型并非没有局限。与其他基于 Transformer 的方法一样，对注意力的依赖会带来二次时间复杂度和二次内存复杂度。虽然我们在实验中没有发现这会造成问题，但这一限制必然会妨碍模型应用到以长程依赖为特征的任务中，例如语言建模或音乐生成 [36]。幸运的是，关于稀疏 Transformer 的近期工作 [9, 18, 50, 55] 有可能解决这一问题，我们将此类研究留作未来工作。

概率时间序列预测是一个基础研究问题，在社会中有广泛应用。尽管我们没有探索本工作的医疗健康应用，但先前提出的、具有类似表述的方法已经展示了预测技术 [1, 81] 在诊断或疾病控制中的潜力。

7 致谢

作者衷心感谢 Xerox PARC Faculty Research Award、National Science Foundation Awards 1455172、1934985、1940124 和 1940276、USAID，以及 Cornell University Atkinson Center for a Sustainable Future 提供的经费支持。

参考文献

- [1] Ahmed Alaa and Mihaela van der Schaar. Attentive state-space modeling of disease progression. 2019.
- [2] Alexandre Alahi, Kratarth Goel, Vignesh Ramanathan, Alexandre Robicquet, Li Fei-Fei, and Silvio Savarese. Social lstm: Human trajectory prediction in crowded spaces. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 961–971, 2016.
- [3] Evan Archer, Il Memming Park, Lars Buesing, John Cunningham, and Liam Paninski. Black box variational inference for state space models. *arXiv preprint arXiv:1511.07367*, 2015.
- [4] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- [5] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*, 2014.
- [6] Emad Barsoum, John Kender, and Zicheng Liu. Hp-gan: Probabilistic 3d human motion prediction via gan. In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, pages 1418–1427, 2018.
- [7] Luc Bauwens, Sébastien Laurent, and Jeroen VK Rombouts. Multivariate garch models: a survey. *Journal of applied econometrics*, 21(1):79–109, 2006.
- [8] Justin Bayer and Christian Osendorfer. Learning stochastic recurrent networks. In *NIPS 2014 Workshop on Advances in Variational Inference*, 2014.
- [9] Iz Beltagy, Matthew E Peters, and Arman Cohan. Longformer: The long-document transformer. *arXiv preprint arXiv:2004.05150*, 2020.
- [10] Konstantinos Benidis, Syama Sundar Rangapuram, Valentin Flunkert, Bernie Wang, Danielle Maddix, Caner Turkmen, Jan Gasthaus, Michael Bohlke-Schneider, David Salinas, Lorenzo Stella, et al. Neural forecasting: Introduction and literature overview. *arXiv preprint arXiv:2004.10240*, 2020.
- [11] Apratim Bhattacharyya, Bernt Schiele, and Mario Fritz. Accurate and diverse sampling of sequences based on a “best of many” sample objective. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 8485–8493, 2018.
- [12] George EP Box, Gwilym M Jenkins, Gregory C Reinsel, and Greta M Ljung. *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.
- [13] Judith Butepage, Michael J Black, Danica Kragic, and Hedvig Kjellstrom. Deep representation learning for human motion prediction and classification. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6158–6166, 2017.
- [14] Defu Cao, Yujing Wang, Juanyong Duan, Ce Zhang, Xia Zhu, Conguri Huang, Yunhai Tong, Bixiong Xu, Jing Bai, Jie Tong, et al. Spectral temporal graph neural network for multivariate time-series forecasting. *arXiv preprint arXiv:2103.07719*, 2021.
- [15] Real Carbonneau, Kevin Laframboise, and Rustam Vahidov. Application of machine learning

- techniques for supply chain demand forecasting. *European Journal of Operational Research*, 184(3):1140–1154, 2008.
- [16] Ming-Fang Chang, John Lambert, Patsorn Sangkloy, Jagjeet Singh, Slawomir Bak, Andrew Hartnett, De Wang, Peter Carr, Simon Lucey, Deva Ramanan, et al. Argoverse: 3d tracking and forecasting with rich maps. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8740–8749. IEEE Computer Society, 2019.
- [17] Rewon Child. Very deep vaes generalize autoregressive models and can outperform them on images. *arXiv preprint arXiv:2011.10650*, 2020.
- 11
- [18] Rewon Child, Scott Gray, Alec Radford, and Ilya Sutskever. Generating long sequences with sparse transformers. *arXiv preprint arXiv:1904.10509*, 2019.
- [19] Kyunghyun Cho, B van Merriënboer, Caglar Gulcehre, F Bougares, H Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder-decoder for statistical machine translation. In *Conference on Empirical Methods in Natural Language Processing (EMNLP 2014)*, 2014.
- [20] Edward Choi, Mohammad Taha Bahadori, Joshua A Kulas, Andy Schuetz, Walter F Stewart, and Jimeng Sun. Retain: An interpretable predictive model for healthcare using reverse time attention mechanism. *Advances in Neural Information Processing Systems*, pages 3512–3520, 2016.
- [21] Edward Choi, Mohammad Taha Bahadori, Andy Schuetz, Walter F Stewart, and Jimeng Sun. Doctor ai: Predicting clinical events via recurrent neural networks. In *Machine learning for healthcare conference*, pages 301–318. PMLR, 2016.
- [22] Junyoung Chung, Kyle Kastner, Laurent Dinh, Kratarth Goel, Aaron C Courville, and Yoshua Bengio. A recurrent latent variable model for sequential data. *Advances in Neural Information Processing Systems*, 28:2980–2988, 2015.
- [23] Emmanuel de Bézenac, Syama Sundar Rangapuram, Konstantinos Benidis, Michael Bohlke-Schneider, Richard Kurlle, Lorenzo Stella, Hilaf Hasson, Patrick Gallinari, and Tim Januschowski. Normalizing kalman filters for multivariate time series analysis. *Advances in Neural Information Processing Systems*, 33, 2020.
- [24] Emily Denton and Rob Fergus. Stochastic video generation with a learned prior. In *International Conference on Machine Learning*, pages 1174–1183. PMLR, 2018.
- [25] Nat Dilokthanakul, Pedro AM Mediano, Marta Garnelo, Matthew CH Lee, Hugh Salimbeni, Kai Arulkumaran, and Murray Shanahan. Deep unsupervised clustering with gaussian mixture variational autoencoders. *arXiv preprint arXiv:1611.02648*, 2016.
- [26] Linhao Dong, Shuang Xu, and Bo Xu. Speech-transformer: a no-recurrence sequence-to-sequence model for speech recognition. In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5884–5888. IEEE, 2018.
- [27] James Durbin and Siem Jan Koopman. *Time series analysis by state space methods*. Oxford university press, 2012.
- [28] Chenyou Fan, Yuze Zhang, Yi Pan, Xiaoyue Li, Chi Zhang, Rong Yuan, Di Wu, Wensheng Wang, Jian Pei, and Heng Huang. Multi-horizon time series forecasting with temporal attention learning. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2527–2535, 2019.
- [29] Chelsea Finn, Ian Goodfellow, and Sergey Levine. Unsupervised learning for physical interaction through video prediction. In *Proceedings of the 30th International Conference on Neural Information Processing Systems*, pages 64–72, 2016.
- [30] Marco Fraccaro, Søren Kaae Sønderby, Ulrich Paquet, and Ole Winther. Sequential neural models with stochastic layers. In *Proceedings of the 30th International Conference on Neural Information Processing Systems*, pages 2207–2215, 2016.
- [31] Marco Fraccaro, Simon Kamronn, Ulrich Paquet, and Ole Winther. A disentangled recognition and nonlinear dynamics model for unsupervised learning. In *Proceedings of the 31st International Conference on Neural Information Processing Systems*, pages 3604–3613, 2017.
- [32] Katerina Fragkiadaki, Sergey Levine, Panna Felsen, and Jitendra Malik. Recurrent network models for human dynamics. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 4346–4354, 2015.
- [33] Jan Gasthaus, Konstantinos Benidis, Yuyang Wang, Syama Sundar Rangapuram, David Salinas, Valentin Flunkert, and Tim Januschowski. Probabilistic forecasting with spline quantile function rnns. In *The 22nd international conference on artificial intelligence and statistics*, pages 1901–1910. PMLR, 2019.

- [34] Partha Ghosh, Jie Song, Emre Aksan, and Otmar Hilliges. Learning human motion models for long-term predictions. In *2017 International Conference on 3D Vision (3DV)*, pages 458–466. IEEE, 2017.
- [35] Tilmann Gneiting and Adrian E Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American statistical Association*, 102(477):359–378, 2007.

- [36] Alexander Greaves-Tunnell and Zaid Harchaoui. A statistical investigation of long memory in language and music. In International Conference on Machine Learning, pages 2394–2403. PMLR, 2019.
 - [37] Agrim Gupta, Justin Johnson, Li Fei-Fei, Silvio Savarese, and Alexandre Alahi. Social gan: Socially acceptable trajectories with generative adversarial networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 2255–2264, 2018.
 - [38] Swaminathan Gurumurthy, Ravi Kiran Sarvadevabhatla, and R Venkatesh Babu. Deligan: Generative adversarial networks for diverse and limited data. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 166–174, 2017.
 - [39] Danijar Hafner, Timothy Lillicrap, Ian Fischer, Ruben Villegas, David Ha, Honglak Lee, and James Davidson. Learning latent dynamics for planning from pixels. In International Conference on Machine Learning, pages 2555–2565. PMLR, 2019.
 - [40] Andrew C Harvey. Forecasting, Structural Time Series Models and the Kalman Filter. Cambridge University Press, 1990.
 - [41] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-vae: Learning basic visual concepts with a constrained variational framework. 2016.
 - [42] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. Neural computation, 9(8):1735–1780, 1997.
 - [43] Rob Hyndman, Anne B Koehler, J Keith Ord, and Ralph D Snyder. Forecasting with exponential smoothing: the state space approach. Springer Science & Business Media, 2008.
 - [44] Catalin Ionescu, Dragos Papava, Vlad Olaru, and Cristian Sminchisescu. Human3.6m: Large scale datasets and predictive methods for 3d human sensing in natural environments. IEEE transactions on pattern analysis and machine intelligence, 36(7):1325–1339, 2013.
 - [45] Ashesh Jain, Amir R Zamir, Silvio Savarese, and Ashutosh Saxena. Structural-rnn: Deep learning on spatio-temporal graphs. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 5308–5317, 2016.
 - [46] Andrew H Jazwinski. Stochastic processes and filtering theory. Courier Corporation, 2007.
 - [47] Maximilian Karl, Maximilian Soelch, Justin Bayer, and Patrick Van der Smagt. Deep variational bayes filters: Unsupervised learning of state space models from raw data. arXiv preprint arXiv:1605.06432, 2016.
 - [48] Jacob Devlin Ming-Wei Chang Kenton and Lee Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of NAACL-HLT, pages 4171–4186, 2019.
 - [49] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. 2014.
 - [50] Nikita Kitaev, Lukasz Kaiser, and Anselm Levskaya. Reformer: The efficient transformer. arXiv preprint arXiv:2001.04451, 2020.
 - [51] Rahul Krishnan, Uri Shalit, and David Sontag. Structured inference networks for nonlinear state space models. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 31, 2017.
 - [52] Rahul G Krishnan, Uri Shalit, and David Sontag. Deep kalman filters. arXiv preprint arXiv:1511.05121, 2015.
- 13
- [53] Guokun Lai, Wei-Cheng Chang, Yiming Yang, and Hanxiao Liu. Modeling long-and short-term temporal patterns with deep neural networks. In The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval, pages 95–104, 2018.
 - [54] Chen Li, Zhen Zhang, Wee Sun Lee, and Gim Hee Lee. Convolutional sequence to sequence model for human dynamics. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 5226–5234, 2018.
 - [55] Shiyang Li, Xiaoyong Jin, Yao Xuan, Xiyu Zhou, Wenhui Chen, Yu-Xiang Wang, and Xifeng Yan. Enhancing the locality and breaking the memory bottleneck of transformer on time series forecasting. Advances in Neural Information Processing Systems, 32:5243–5253, 2019.
 - [56] Zimo Li, Yi Zhou, Shuangjiu Xiao, Chong He, Zeng Huang, and Hao Li. Auto-conditioned recurrent networks for extended complex human motion synthesis. arXiv preprint arXiv:1707.05363, 2017.
 - [57] Bryan Lim, Sercan O Arik, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. arXiv preprint arXiv:1912.09363, 2019.
 - [58] Zhaojiang Lin, Genta Indra Winata, Peng Xu, Zihan Liu, and Pascale Fung. Variational transformers for diverse response generation. arXiv preprint arXiv:2003.12738, 2020.
 - [59] Zachary C Lipton, David C Kale, Charles Elkan, and Randall Wetzel. Learning to diagnose with lstm recurrent neural networks. In International Conference on Learning Representations, 2016.
 - [60] Danyang Liu and Gongshen Liu. A transformer-based variational autoencoder for sentence generation. In 2019 International Joint Conference on Neural Networks (IJCNN), pages 1–7. IEEE, 2019.
 - [61] Helmut Lütkepohl. New introduction to multiple time series analysis. Springer Science &

- Business Media, 2005.
- [62] Lars Maaløe, Marco Fraccaro, Valentin Lievin, and Ole Winther. Biva: A very deep hierarchy of latent variables for generative modeling. In 33rd Conference on Neural Information Processing Systems, page 8882. Neural Information Processing Systems Foundation, 2019.
 - [63] Julieta Martinez, Michael J Black, and Javier Romero. On human motion prediction using recurrent neural networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 2891–2900, 2017.
 - [64] Julieta Martinez, Rayat Hossain, Javier Romero, and James J Little. A simple yet effective baseline for 3d human pose estimation. In Proceedings of the IEEE International Conference on Computer Vision, pages 2640–2649, 2017.
 - [65] James E Matheson and Robert L Winkler. Scoring rules for continuous probability distributions. *Management science*, 22(10):1087–1096, 1976.
 - [66] Kevin P Murphy. *Machine learning: a probabilistic perspective*. 2012.
 - [67] Junhyuk Oh, Xiaoxiao Guo, Honglak Lee, Richard Lewis, and Satinder Singh. Action-conditional video prediction using deep networks in atari games. *arXiv preprint arXiv:1507.08750*, 2015.
 - [68] Boris N Oreshkin, Dmitri Carpov, Nicolas Chapados, and Yoshua Bengio. N-beats: Neural basis expansion analysis for interpretable time series forecasting. In International Conference on Learning Representations, 2019.
 - [69] Andrew J Patton. A review of copula models for economic time series. *Journal of Multivariate Analysis*, 110:4–18, 2012.
 - [70] Yao Qin, Dongjin Song, Haifeng Chen, Wei Cheng, Guofei Jiang, and Garrison Cottrell. A dual-stage attention-based recurrent neural network for time series prediction. *arXiv preprint arXiv:1704.02971*, 2017.

14

- [71] Syama Sundar Rangapuram, Matthias W Seeger, Jan Gasthaus, Lorenzo Stella, Yuyang Wang, and Tim Januschowski. Deep state space models for time series forecasting. *Advances in neural information processing systems*, 31:7785–7794, 2018.
- [72] Kashif Rasul, Abdul-Saboor Sheikh, Ingmar Schuster, Urs Bergmann, and Roland Vollgraf. Multi-variate probabilistic time series forecasting via conditioned normalizing flows. *arXiv preprint arXiv:2002.06103*, 2020.
- [73] Kashif Rasul, Calvin Seward, Ingmar Schuster, and Roland Vollgraf. Autoregressive denoising diffusion models for multivariate probabilistic time series forecasting. *arXiv preprint arXiv:2101.12072*, 2021.
- [74] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic backpropagation and approximate inference in deep generative models. In International conference on machine learning, pages 1278–1286. PMLR, 2014.
- [75] David Salinas, Michael Bohlke-Schneider, Laurent Callot, Roberto Medico, and Jan Gasthaus. High-dimensional multivariate forecasting with low-rank gaussian copula processes. *arXiv preprint arXiv:1910.03002*, 2019.
- [76] David Salinas, Valentin Flunkert, Jan Gasthaus, and Tim Januschowski. Deepar: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191, 2020.
- [77] Iulian Serban, Alessandro Sordoni, Ryan Lowe, Laurent Charlin, Joelle Pineau, Aaron Courville, and Yoshua Bengio. A hierarchical latent variable encoder-decoder model for generating dialogues. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 31, 2017.
- [78] Leonid Sigal and Michael J Black. Humaneva: Synchronized video and motion capture dataset for evaluation of articulated human motion. Brown University TR, 120(2), 2006.
- [79] Slawek Smyl, Jai Ranganathan, and Andrea Pasqua. M4 forecasting competition: Introducing a new hybrid es-rnn model. URL: <https://eng.uber.com/m4-forecasting-competition>, 2018.
- [80] Casper Kaae Sønderby, Tapani Raiko, Lars Maaløe, Søren Kaae Sønderby, and Ole Winther. Ladder variational autoencoders. In Proceedings of the 30th International Conference on Neural Information Processing Systems, pages 3745–3753, 2016.
- [81] Huan Song, Deepta Rajan, Jayaraman Thiagarajan, and Andreas Spanias. Attend and diagnose: Clinical time series analysis using attention models. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 32, 2018.
- [82] Ruey S Tsay. *Multivariate time series analysis: with R and financial applications*. John Wiley & Sons, 2013.
- [83] Arash Vahdat and Jan Kautz. Nvae: A deep hierarchical variational autoencoder. *arXiv preprint arXiv:2007.03898*, 2020.
- [84] Roy Van der Weide. Go-garch: a multivariate generalized orthogonal garch model. *Journal of Applied Econometrics*, 17(5):549–564, 2002.
- [85] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing Systems, pages 6000–6010, 2017.
- [86] Ruben Villegas, Arkanath Pathak, Harini Kannan, Dumitru Erhan, Quoc V Le, and Honglak

Lee. High fidelity video prediction with large stochastic recurrent neural networks. In NeurIPS, 2019.

- [87] Jacob Walker, Kenneth Marino, Abhinav Gupta, and Martial Hebert. The pose knows: Video forecasting by generating pose futures. In Proceedings of the IEEE international conference on computer vision, pages 3332–3341, 2017.

15

- [88] Eric A Wan and Rudolph Van Der Merwe. The unscented kalman filter for nonlinear estimation. In Proceedings of the IEEE 2000 Adaptive Systems for Signal Processing, Communications, and Control Symposium (Cat. No. 00EX373), pages 153–158. Ieee, 2000.
- [89] Jack M Wang, David J Fleet, and Aaron Hertzmann. Gaussian process dynamical models for human motion. IEEE transactions on pattern analysis and machine intelligence, 30(2): 283–298, 2007.
- [90] Tianming Wang and Xiaojun Wan. T-cvae: Transformer-based conditioned variational autoencoder for story completion. In IJCAI, pages 5233–5239, 2019.
- [91] Yuyang Wang, Alex Smola, Danielle Maddix, Jan Gasthaus, Dean Foster, and Tim Januschowski. Deep factors for forecasting. In International Conference on Machine Learning, pages 6607–6617. PMLR, 2019.
- [92] Mike West and Jeff Harrison. Bayesian forecasting and dynamic models. Springer Science & Business Media, 2006.
- [93] Di Wu and Ling Shao. Leveraging hierarchical parametric networks for skeletal joints based action segmentation and recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 724–731, 2014.
- [94] Neo Wu, Bradley Green, Xue Ben, and Shawn O’ Banion. Deep transformer models for time series forecasting: The influenza prevalence case. arXiv preprint arXiv:2001.08317, 2020.
- [95] Xinchun Yan, Akash Rastogi, Ruben Villegas, Kalyan Sunkavalli, Eli Shechtman, Sunil Hadap, Ersin Yumer, and Honglak Lee. Mt-vae: Learning motion transformations to generate multimodal human dynamics. In Proceedings of the European Conference on Computer Vision (ECCV), pages 265–281, 2018.
- [96] Rose Yu, Stephan Zheng, Anima Anandkumar, and Yisong Yue. Long-term forecasting using tensor-train rnns. Arxiv, 2017.
- [97] Ye Yuan and Kris Kitani. Dlow: Diversifying latent flows for diverse human motion prediction. In European Conference on Computer Vision, pages 346–364. Springer, 2020.
- [98] Ye Yuan and Kris M Kitani. Diverse trajectory forecasting with determinantal point processes. In International Conference on Learning Representations, 2019.
- [99] Han Zhang, Ian Goodfellow, Dimitris Metaxas, and Augustus Odena. Self-attention generative adversarial networks. In International conference on machine learning, pages 7354–7363. PMLR, 2019.
- [100] Jingyu Zhao, Feiqing Huang, Jia Lv, Yanjie Duan, Zhen Qin, Guodong Li, and Guangjian Tian. Do rnn and lstm have long memory? In International Conference on Machine Learning, pages 11365–11375. PMLR, 2020.
- [101] Shengjia Zhao, Jiaming Song, and Stefano Ermon. Learning hierarchical features from generative models. arXiv preprint arXiv:1702.08396, 2017.

1. 对所有作者……

- (a) 摘要和引言中的主要主张是否准确反映了论文的贡献和范围? [Yes] 见第 1 节和第 5 节。
- (b) 是否描述了工作的局限? [Yes] 见第 6 节。
- (c) 是否讨论了工作可能产生的负面社会影响? [Yes] 见第 6 节。
- (d) 是否已经阅读伦理审查指南, 并确保论文符合这些指南? [Yes]

2. 如果包含理论结果……

- (a) 是否陈述了所有理论结果的完整假设集合? [N/A]
- (b) 是否包含了所有理论结果的完整证明? [N/A]

3. 如果开展了实验……

- (a) 是否包含复现主要实验结果所需的代码、数据和说明(在补充材料中或作为 URL)? [Yes] 见补充材料。
- (b) 是否说明了所有训练细节(例如数据划分、超参数、它们如何被选择)? [Yes] 见补充材料附录 D。
- (c) 是否报告了误差条(例如, 多次运行实验后相对于随机种子的误差条)? [Yes] 见表 1。
- (d) 是否包含总计算量和所用资源类型(例如 GPU 类型、内部集群或云服务商)? [Yes] 见补充材料附录 D。

4. 如果使用已有资产(例如代码、数据、模型), 或整理/发布新资产……

- (a) 如果工作使用了已有资产, 是否引用了创建者? [Yes] 见第 4 节。
- (b) 是否提到了这些资产的许可? [Yes] 见补充材料附录 A。
- (c) 是否在补充材料中或以 URL 形式包含了任何新资产? [Yes] 见补充材料。我们还承诺在论文发表后开源代码。
- (d) 是否讨论了是否以及如何从所使用/整理数据所涉及的人那里获得同意? [Yes] 见补充材料附录 A。
- (e) 是否讨论了所使用/整理的的数据是否包含个人身份信息或冒犯性内容? [Yes] 见补充材料附录 A。

5. 如果使用了众包, 或开展了涉及人类受试者的研究……

- (a) 是否包含了提供给参与者的完整说明文本以及截图(如适用)? [N/A]
- (b) 是否描述了任何潜在参与者风险, 并在适用时提供机构审查委员会(IRB)批准链接? [N/A]
- (c) 是否包含支付给参与者的估计小时工资, 以及用于参与者补偿的总金额? [N/A]