

利用程序生成对强化学习进行基准评测

Leveraging Procedural Generation to Benchmark Reinforcement Learning

Karl Cobbe Christopher Hesse Jacob Hilton John Schulman
OpenAI, San Francisco, CA, USA

ICML 2020, PMLR 119:2048–2056

摘要

我们介绍 Progen Benchmark，这是由 16 个程序生成的类游戏环境构成的一套基准，旨在同时评测强化学习中的样本效率和泛化能力。我们认为，社区会因更容易获得高质量训练环境而受益；同时，我们也给出了使用该基准的详细实验规程。我们通过实验证明，多样化的环境分布对于充分训练和评估强化学习智能体是必要的，这也说明了广泛使用程序化内容生成的动机。随后，我们使用该基准研究扩大模型规模的效果，发现更大的模型会显著提高样本效率和泛化能力。

1 引言

泛化仍然是深度强化学习中最根本的挑战之一。在若干近期研究中 (Zhang 等, 2018c; Cobbe 等, 2019; Justesen 等, 2018; Juliani 等, 2019)，智能体表现出了过拟合到相当大训练集的能力。这些证据提出了一种可能性：过拟合也许普遍存在于 Arcade Learning Environment (ALE) (Bellemare 等, 2013) 这样的经典基准中；长期以来，ALE 一直被视为强化学习中的黄金标准。虽然 ALE 中不同游戏之间的多样性是该基准最大的优势之一，但其对泛化的低强调构成了明显短板。已有工作试图通过引入 sticky actions (Machado 等, 2018)，或将自然视频嵌入为背景 (Zhang 等, 2018b)，来缓解 ALE 中的过拟合；但这些方法只是在表面上处理了底层问题，即智能体会持续遭遇近乎相同的状态。对每个游戏都必须提出这样的问题：智能体是在稳健地学习一项相关技能，还是在近似记忆特定轨迹？

已经有若干关于强化学习泛化的研究 (Farebrother 等, 2018; Packer 等, 2018; Zhang 等, 2018a; Lee 等, 2019)，但进展总体上仍然难以取得。可以说，一个主要阻碍是缺少适合衡量泛化的环境。虽然前面提到的研究 (Zhang 等, 2018c; Cobbe 等, 2019; Justesen 等, 2018; Juliani 等, 2019) 揭示了一些有趣趋势，但仅凭如此少的环境很难得出一般性结论。

我们希望兼得两方面优势：一个整体多样性可与 ALE 相比、同时又由从根本上要求泛化的环境组成的基准。为满足这一需求，我们创建了 Progen Benchmark。该基准非常适合评估泛化，因为可以为每个环境分别生成训练集和测试集。该基准也很适合评估样本效率，因为所有环境都向强化学习智能体提出了多样且有吸引力的挑战。环境的内在多样性要求智能体学习稳健策略；只过拟合到状态空间中的狭窄区域并不足够。换言之，当智能体面对不断变化的关卡时，泛化能力就成为成功的内在组成部分。所有环境都是开源的，可在 <https://github.com/openai/progen> 找到。

2 Progen Benchmark

Progen Benchmark 由 16 个独特环境组成，旨在衡量强化学习中的样本效率和泛化能力。这些环境极大受益于程序化内容生成，也就是用算法创建近乎无限且高度随机化的内容供给。在这些环境中，使用程序生成远比依赖固定的、人工设计的内容更加有效。

程序生成逻辑控制关卡布局 (Johnson 等, 2010)、游戏资产的选择、实体的位置与生成时间，以及其他特定于游戏的细节。为了掌握其中任一环境，智能体必须学习一种在所有变化轴上都稳健的策略。学习这样的策略既更有挑战性，也比过拟合到少量固定关卡更有意义。



图 1. Procgen Benchmark 中每个游戏的截图。

每个环境的截图如图 1 所示。我们注意到，所有环境中的状态转移函数都是确定性的。¹

2.1 环境设计目标

我们设计所有环境，使其满足以下标准。

高多样性。 在满足基本设计约束的前提下，程序生成逻辑被赋予最大自由度。由此产生的关卡分布多样性为智能体提供了有意义的泛化挑战。

快速评估。 环境难度经过校准，使基线智能体在 200M 时间步训练期间能够取得显著进展。此外，这些环境经过优化，在单个 CPU 核心上每秒可以执行数千步，其中包括渲染观测所需的时间。这使得快速实验流水线成为可能。

可调难度。 所有环境都支持两个经过良好校准的难度设置：easy 和 hard。这里的难度指关卡分布，而非单个关卡；在两种设置中，单个关卡的难度都有很高方差。除非另有说明，我们使用 hard 难度设置报告结果。我们提供 easy 难度设置，是为了服务计算资源有限的用户，因为它将训练智能体所需资源大约降低 8 倍。

关卡可解性。 每个环境中的程序生成都努力使所有关卡可解，但这并不能得到严格保证。对每个环境而言，我们相信超过 99% 的关卡是可解的。

强调视觉识别和运动控制。 延续先例，这些环境模仿了许多 Atari 和 Gym Retro (Pfau 等, 2018) 游戏的风格。取得良好表现主要依赖于在观测空间中识别关键资产，并执行适当的低层运动响应。

共享动作空间和观测空间。 为支持统一训练流水线，所有环境都使用一个离散的 15 维动作空间，并产生 $64 \times 64 \times 3$ 的 RGB 观测。部分环境包含 no-op 动作，以适配共享动作空间。

¹尽管 Chaser 环境是确定性的，敌方 AI 仍会在以关卡种子为条件时作出伪随机决策。

对探索依赖程度可调。 这些环境被设计为不需要自定义探索奖励，基线强化学习智能体也能处理。然而，如果需要，其中许多环境也可以变成更具挑战性的探索任务。关于评估探索能力的讨论见附录 B.1。

对记忆依赖程度可调。 为了隔离强化学习中的挑战，这些环境被设计为只需要最低限度地使用记忆。不过，若干环境包含确实会测试记忆使用的变体，我们在附录 B.2 中对此进行了讨论。

通过满足这些要求，我们认为 Procgen Benchmark 将成为强化学习研究中的有价值工具。每个具体环境的描述见附录 A。

2.2 实验规程

默认情况下，我们使用 Proximal Policy Optimization (Schulman 等, 2017) 训练智能体 200M 时间步。虽然这一时间步选择是任意的，但它沿用了 ALE 所建立的先例。它在实验上也很方便：在单个 Procgen 环境上用 PPO 训练 200M 时间步，在我们的 PPO 实现中大约需要 24 个 GPU 小时和 60 个 CPU 小时。我们认为这是合理且实际的计算成本。为了进一步缩短训练时间，但以增加实验复杂度为代价，可以把环境设为 easy 难度。我们建议在 easy 难度环境上训练 25M 时间步；使用我们的 PPO 实现，这大约需要 3 个 GPU 小时。

在评估样本效率时，我们在每个环境的完整关卡分布上训练并测试智能体。在评估泛化时，我们在有限关卡集合上训练，并在完整关卡分布上测试。除非另有说明，我们使用包含 500 个关卡的训练集来评估每个环境中的泛化。对 easy 难度环境，我们建议使用包含 200 个关卡的训练集。关于 easy 难度环境的结果见附录 I。

当需要报告覆盖 Procgen Benchmark 的单一个体时，我们计算平均归一化回报。对每个环境，我们将归一化回报定义为 $R_{\text{norm}} = (R - R_{\min}) / (R_{\max} - R_{\min})$ ，其中 R 是原始期望回报，而 $R_{\min}$ 和 $R_{\max}$ 是用于近似界定 R 的常数。在该定义下，归一化回报几乎总会落在 0 和 1 之间。我们使用平均归一化回报，因为它比中位数提供更好的信号，而且这里不需要对异常值保持稳健。我们将所有环境设计为具有相近难度，以防止少数环境主导这一信号。归一化常数列表及其选择讨论见附录 C。




图 2. 每个环境中的泛化性能作为训练集规模的函数。我们报告平均原始 episode 回报，其中每个 episode 包含单个关卡。图中展示了 4 个随机种子上的均值和标准差。

2.3 超参数选择

在深度强化学习中，超参数调优经常决定结果是优秀还是平庸。不幸的是，这一过程在时间和计算上都可能很昂贵。对于更熟悉既有 ALE 基准的人而言，在 Procgen 环境上训练应只需要最少的超参数调优。这部分是有意设计的结果，因为 Procgen Benchmark 很大程度上受到 ALE 和 Gym Retro 的启发。为了提供一个比较点，我们在 ALE 上评估经过 Procgen 调优的 PPO 实现，并取得了有竞争力的性能。详细结果见附录 F。

为方便起见，我们选择在 Procgen 实验中不使用任何 frame stacking，因为我们发现它对性能的影响很小。进一步讨论见附录 H。默认情况下，我们使用 IMPALA (Espeholt 等, 2018) 中的卷积架构训练智能体，因为我们发现该架构在性能和计算需求之间取得了合理平衡。我们注意到，当面对 Procgen 环境的高多样性时，更小的架构往往很难完成训练；这一趋势会在第 4 节中进一步研究。

3 泛化实验

3.1 关卡数量需求

我们首先评估训练集规模对泛化的影响。对每个环境，我们构造若干训练集，其规模从 100 个到 100,000 个关卡不等。我们在每个训练集上用 PPO 训练智能体 200M 时间步，并在留出关卡上测量性能。结果见图 2。超参数列表见附录 D；每个训练集的测试曲线见附录 E。

我们发现，在几乎所有情况下，智能体都会强烈过拟合到小训练集。为了弥合泛化差距，智能体需要访问多达 10,000 个关卡。在许多环境中出现了一个特殊趋势：超过某个阈值后，训练性能会随着训练集变大而提高。这与监督学习中的常见趋势相反；在监督学习中，训练性能通常会随着训练集规模增加而下降。我们将这一趋势归因于关卡分布提供的隐式课程。如果智能体学会了即使在训练集内部的关卡之间也进行泛化，那么更大的训练集就可能改善训练性能。这一效果此前由 Cobbe 等 (2019) 报告；现在，我们用更多环境印证了这些结果。




图 3. 使用确定性关卡序列训练时的训练和测试性能。我们报告平均原始 episode 回报，其中每个 episode 可以包含许多连续关卡。图中展示了 4 个随机种子上的均值和标准差。

3.2 确定性关卡消融

为了充分强调程序生成的重要性，我们进行一个简单的消融研究。我们不在每个 episode 开始时重新采样一个新关卡，而是让智能体在一个固定关卡序列上训练。在每个 episode 中，智能体从第一个关卡开始。当智能体成功完成一个关卡时，它前进到下一个关卡。如果智能体在任意时刻失败，该 episode 就终止。在这种设置下，智能体可以到达任意多的关卡，尽管在实践中它在任何环境中都很少超过第 20 个关卡。这近似模拟了 ALE 的训练设置。为了使这种设置下的训练更容易处理，我们使用 easy 环境难度。

在测试时，我们简单地移除关卡序列中的确定性，转而随机选择关卡序列。结果见图 3。我们发现，在多数环境中，智能体在前几个训练关卡上变得胜任，从而产生有意义进展的错觉。然而，测试性能表明，智能体实际上几乎没有学到关于底层关卡分布的内容。我们认为，训练性能和测试性能之间这一巨大差距值得强调。它揭示了在遵循固定关卡序列的环境上训练时，一个关键的隐藏缺陷。这些结果强调了用多样化环境分布进行训练和评估的重要性。




图 4. 每个环境中基于 500 个关卡训练得到的泛化性能。图中展示了 3 个随机种子上的均值和标准差。

3.3 500 关卡泛化

由于计算成本很高，经常运行第 3.1 节描述的实验并不现实。为了对泛化进行基准评测，我们建议在每个环境的 500 个关卡上训练，并在留出关卡上测试，如 Cobbe 等 (2019) 所做。我们选择这一训练集规模，是因为从图 2 可见，它接近泛化开始产生作用的区域。在测试时，我们测量智能体在未见关卡上的 zero-shot 性能平均值。在评估泛化时，我们并不明确限制训练时长，不过实践中仍然训练 200M 时间步。

基线结果见图 4。我们在多数环境中看到大量过拟合。在一些环境中，泛化差距相对较小，只是因为训练性能和测试性能都较差，如第 3.1 节所讨论。无论如何，随着我们开发出泛化能力更强的智能体，我们预期会看到测试性能显著改善。

4 扩大模型规模

现在，我们研究扩大模型规模如何影响强化学习中的样本效率和泛化。我们进行这些实验，是为了展示 Progen Benchmark 指标的有用性，也因为这一主题本身就很有吸引力。我们遵循第 2.2 节描述的实验规程，在样本效率和泛化两方面评估 4 个不同模型的性能。

前三个模型使用 IMPALA (Espeholt 等, 2018) 中的卷积架构，并将每一层的卷积通道数分别按 1、2 或 4 倍缩放。注意，将通道数按 k 倍缩放，会使总参数量大约按 k^2 倍缩放。最后一个模型使用 Mnih 等 (2015) 中的更小、更基础的卷积架构，我们称之为 Nature-CNN。我们纳入该架构，是因为它经常被用于在 ALE 中训练智能体。

我们使用与最小 IMPALA 模型相同的学习率来训练 Nature-CNN 模型。当我们按 k 倍缩放 IMPALA 通道数时，也按 $\frac{1}{\sqrt{k}}$ 倍缩放学习率，以匹配权重的缩放；权重使用 Glorot 和 Bengio (2010) 的方法初始化。学习率是我们在不同架构之间改变的唯一超参数。我们对其他超参数进行了扫描，包括 batch size 和每次 rollout 的 epoch 数，但没有发现其他明显收益。

结果见图 5。我们发现，更大的架构会显著提高样本效率和泛化能力。值得注意的是，小型 Nature-CNN 模型几乎完全无法训练。这些结果与 Cobbe 等 (2019) 的结果一致；现在我们证明，这一趋势在许多多样化环境中都成立。尽管更大的模型带来相当一致的改进，我们也注意到某些环境从更大模型中受益更多。每个环境的详细训练曲线见附录 G。




图 5. 不同模型规模的性能，同时衡量样本效率（左）和泛化（右）。图中展示了 3 个随机种子上的均值和标准差。

5 比较算法

接下来，我们在 Procgen Benchmark 上比较自己的 PPO 实现和自己的 Rainbow (Hessel 等, 2018) 实现。我们评估样本效率，即在每个环境的完整关卡分布上训练并测试。与 PPO 一样，我们使用 IMPALA 卷积架构训练 Rainbow 智能体，从 64 个并行环境副本中收集经验并放入单个 replay buffer。我们首先尝试了默认 Rainbow 超参数（同时为分布式 min/max 值作出合适选择），但发现智能体很难学到任何非平凡行为。我们推测，环境的多样性可能导致高方差梯度，从而促进不稳定性。因此，我们通过 8 个并行 worker 上运行算法来降低梯度方差，worker 共享模型参数并在 worker 之间平均梯度。这极大改善了性能。

为改善 Rainbow 的 wall-clock 时间，我们还将 batch size 增大 16 倍，并将 update frequency 降低 16 倍，同时把学习率提高 4 倍。尽管这一改变显著降低了 wall-clock 训练时间，但它并未对性能产生不利影响。我们通过扫描附近学习率确认，新学习率大致是最优的。完整 Rainbow 超参数列表见附录 D。

结果见图 6。PPO 在整个基准上表现得一致得多，尽管 Rainbow 在若干环境中带来了显著改进。我们目前无法诊断导致 Rainbow 在部分环境中表现较低的不稳定性，不过我们认为这是未来研究中一个有趣方向。




图 6. Rainbow 与 PPO 的比较。在两种情况下，我们都在每个环境的完整关卡分布上训练并测试。图中展示了 3 个随机种子上的均值和标准差。

6 相关工作

许多近期强化学习基准以不同方式处理泛化问题。Sonic 基准(Nichol 等, 2018)旨在通过将 *Sonic the Hedgehog*TM 电子游戏的关卡划分为训练集和测试集，来衡量强化学习中的泛化。然而，强化学习智能体很难从少量可用训练关卡中泛化，进展也难以测量。CoinRun 环境(Cobbe 等, 2019)通过程序生成大型训练集和测试集以更好衡量泛化，从而回应了这一问题。CoinRun 是 Progen Benchmark 中的第一个环境。

General Video Game AI (GVG-AI) 框架(Perez-Liebana 等, 2018)也鼓励在深度强化学习中使用程序生成。Justesen 等(2018)使用 4 个基于经典电子游戏的程序生成环境，测量跨不同关卡分布的泛化，并发现智能体会强烈过拟合到其特定训练集。Progen Benchmark 中的环境以相似精神设计，其中两个环境(Miner 和 Leaper)直接受到这项工作的启发。

Obstacle Tower 环境(Juliani 等, 2019)试图使用一个 3D、第三人称、程序生成的环境，测量视觉、控制和规划中的泛化。成功要求智能体同时解决低层控制和高层规划问题。虽然在单个复杂环境中研究泛化有一定优势，但我们选择为 Progen Benchmark 设计许多异质环境。

bsuite(Osband 等, 2019)是一组简单环境，被设计为充当“强化学习中的 MNIST”。每个环境针对少数几个核心强化学习能力，其中包括泛化这一核心能力。bsuite 包含一个要求视觉泛化的环境，其形式是 MNIST contextual bandit；相比之下，视觉泛化是所有 Progen 环境中的主要困难来源。

Safety Gym(Achiam 等, 2019)提供了一套基准环境，用于研究安全探索和约束强化学习。虽然泛化不是该基准的明确重点，但所有 Safety Gym 环境都会进行广泛随机化，以防止智能体过拟合到特定环境布局。这样做使这些环境强制要求泛化。

Animal-AI Environment(Beyret 等, 2019)使用受动物认知文献启发的任务来评估智能体智能。由于这些测试在训练期间不会被遇到，高性能依赖于从具体训练配置中良好泛化。使用单一统一环境使泛化前景显著更加可信。

Meta-World(Yu 等, 2019)提出了若干元学习基准，使用多达 50 个独特的连续控制环境进行训练和测试。与 Animal-AI Environment 一样，训练环境和测试环境之间共享的物理与机制带来了对泛化的可信预期，即使测试任务的细节是新的。

7 结论

训练能够跨环境泛化的智能体，仍然是强化学习中最大的挑战之一。我们设计 Procgen Benchmark，是为了帮助社区应对这一挑战。关卡分布内部的内在多样性，使该基准非常适合评估强化学习中的泛化和样本效率。我们预期，从该基准中获得的许多洞见会适用于更复杂的设置，并期待利用这些环境设计出能力更强、效率更高的算法。

参考文献

- J. Achiam, A. Ray, and D. Amodei.**
Safety gym. <https://openai.com/blog/safety-gym/>, 2019.
- M. G. Bellemare, Y. Naddaf, J. Veness, and M. Bowling.**
The arcade learning environment: An evaluation platform for general agents. *Journal of Artificial Intelligence Research*, 47:253–279, jun 2013.
- B. Beyret, J. Hernández-Orallo, L. Cheke, M. Halina, M. Shanahan, and M. Crosby.**
The animal-ai environment: Training and testing animal-like artificial cognition. 2019.
- K. Cobbe, O. Klimov, C. Hesse, T. Kim, and J. Schulman.**
Quantifying generalization in reinforcement learning. In *Proceedings of the 36th International Conference on Machine Learning, ICML 2019, 9-15 June 2019, Long Beach, California, USA*, pages 1282–1289, 2019. URL <http://proceedings.mlr.press/v97/cobbe19a.html>.
- L. Espeholt, H. Soyer, R. Munos, K. Simonyan, V. Mnih, T. Ward, Y. Doron, V. Firoiu, T. Harley, I. Dunning, S. Legg, and K. Kavukcuoglu.**
IMPALA: scalable distributed deep-rl with importance weighted actor-learner architectures. *CoRR*, abs/1802.01561, 2018.
- J. Farebrother, M. C. Machado, and M. Bowling.**
Generalization and regularization in DQN. *CoRR*, abs/1810.00123, 2018. URL <http://arxiv.org/abs/1810.00123>.
- X. Glorot and Y. Bengio.**
Understanding the difficulty of training deep feedforward neural networks. In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pages 249–256, 2010.
- M. Hessel, J. Modayil, H. Van Hasselt, T. Schaul, G. Ostrovski, W. Dabney, D. Horgan, B. Piot, M. Azar, and D. Silver.**
Rainbow: Combining improvements in deep reinforcement learning. In *Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- S. Hochreiter and J. Schmidhuber.**
Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- L. Johnson, G. N. Yannakakis, and J. Togelius.**
Cellular automata for real-time generation of infinite cave levels. In *Proceedings of the 2010 Workshop on Procedural Content Generation in Games*, page 10. ACM, 2010.
- A. Juliani, A. Khalifa, V.-P. Berges, J. Harper, H. Henry, A. Crespi, J. Togelius, and D. Lange.**
Obstacle tower: A generalization challenge in vision, control, and planning. *arXiv preprint arXiv:1902.01378*, 2019.
- N. Justesen, R. R. Torrado, P. Bontrager, A. Khalifa, J. Togelius, and S. Risi.**
Illuminating generalization in deep reinforcement learning through procedural level generation. *CoRR*, abs/1806.10729, 2018.
- D. P. Kingma and J. Ba.**
Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- J. B. Kruskal.**
On the shortest spanning subtree of a graph and the traveling salesman problem. In *Proceedings of the American Mathematical Society*, 7, pages 48–50, 1956.
- K. Lee, K. Lee, J. Shin, and H. Lee.**
A simple randomization technique for generalization in deep reinforcement learning. *arXiv preprint arXiv:1910.05396*, 2019.
- M. C. Machado, M. G. Bellemare, E. Talvitie, J. Veness, M. J. Hausknecht, and M. Bowling.**
Revisiting the arcade learning environment: Evaluation protocols and open problems for general agents. *Journal of Artificial Intelligence Research*, 61:523–562, 2018.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. A. Riedmiller, A. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis.**
Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

A. Nichol, V. Pfau, C. Hesse, O. Klimov, and J. Schulman.

Gotta learn fast: A new benchmark for generalization in RL. *CoRR*, abs/1804.03720, 2018. URL <http://arxiv.org/abs/1804.03720>.

I. Osband, Y. Doron, M. Hessel, J. Aslanides, E. Sezener, A. Saraiva, K. McKinney, T. Lattimore, C. Szepesvári, S. Singh, B. Van Roy, R. Sutton, D. Silver, and H. van Hasselt.

Behaviour suite for reinforcement learning. 2019.

C. Packer, K. Gao, J. Kos, P. Krähenbühl, V. Koltun, and D. Song.

Assessing generalization in deep reinforcement learning. *CoRR*, abs/1810.12282, 2018.

D. Perez-Liebana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas.

General video game ai: a multi-track framework for evaluating agents, games and content generation algorithms. *arXiv preprint arXiv:1802.10363*, 2018.

V. Pfau, A. Nichol, C. Hesse, L. Schiavo, J. Schulman, and O. Klimov.

Gym retro. <https://openai.com/blog/gym-retro/>, 2018.

J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov.

Proximal policy optimization algorithms. *CoRR*, abs/1707.06347, 2017.

T. Yu, D. Quillen, Z. He, R. Julian, K. Hausman, C. Finn, and S. Levine.

Meta-world: A benchmark and evaluation for multi-task and meta-reinforcement learning, 2019. URL <https://github.com/rlworkgroup/metaworld>.

A. Zhang, N. Ballas, and J. Pineau.

A dissection of overfitting and generalization in continuous reinforcement learning. *CoRR*, abs/1806.07937, 2018a.

A. Zhang, Y. Wu, and J. Pineau.

Natural environment benchmarks for reinforcement learning. *arXiv preprint arXiv:1811.06032*, 2018b.

C. Zhang, O. Vinyals, R. Munos, and S. Bengio.

A study on overfitting in deep reinforcement learning. *CoRR*, abs/1804.06893, 2018c. URL <http://arxiv.org/abs/1804.06893>.